

第 1 回 多変量解析とは

最小二乗法は推定手法の一つであり、線形回帰のことではない

本章は講義全体の入り口にあたる。多変量解析は、多数の変数を扱うデータ解析手法に関するテーマである。最小二乗法や線形回帰は、多変量解析の最初に扱われることが多い。そのため最小二乗法(least squares)は、線形回帰の図とともに説明されることが多い。これは誤解につながる可能性がある。最小二乗法とは、特定のモデルの名前ではなく、データとモデルの距離を最小にしてパラメータを決める推定法の一つである。

第 I 部 理論

最小二乗法がよくある図

最小二乗法(least squares)を説明せよ、と言われたら、多くの人は図 1 のような図を描くだろう。横軸に説明変数 x 、縦軸に目的変数 y をとって点を打ち、点の散らばりに 1 本の直線を引く。そして各点から直線へ縦の線を下ろし、その長さの二乗の合計が最小になるように直線を選ぶ。統計の教科書でも、最小二乗法はほぼ例外なくこの図とともに導入される。




図 1: 最小二乗法の説明によく使われる図

この説明は間違いではない。ただし、この図には性質の違う 2 つのものが重ねて描かれている。赤い直線は、データの背後に直線 $y = \beta_0 + \beta_1 x$ があるという仮定を表す。データの生まれ方についてのこうした仮説をモデ

ル(model)と呼ぶ。この図のモデルは線形回帰である。一方、灰色の縦の線は、その長さの二乗和を最小にしてパラメータ(parameter) β_0, β_1 を決めるという手続きを表す。モデルに含まれる未知の値をデータから決める手続きを推定法(estimation method)と呼ぶ。この図の推定法は最小二乗法である。つまり図 1 は、線形回帰というモデルを最小二乗法という推定法で解いた組み合わせの 1 つにすぎない。モデルと推定法は独立に選べる。

では、最小二乗法とは何を最小にする方法なのか。その定義に「直線」という言葉が入っていないのなら、最小二乗法は直線以外のモデルにもそのまま使えるはずである。本章ではこの問いに、点と点の距離から答えていく。本章で覚える言葉は、最小二乗法、目的関数、ユークリッドノルム、偏微分、逆行列の 5 つである。

点と点の距離

まず、2次元の平面上で点と点の距離を考える。3点 (2, 2)、(-3, 1)、(1, -2) を順に点 1、点 2、点 3 とすると、図 2 のようになる。




図 2: 3 点の散布図

点 1 と点 2 の距離、点 1 と点 3 の距離は、三平方の定理からそれぞれ

$$\sqrt{(2 - (-3))^2 + (2 - 1)^2} = \sqrt{26} \quad (1)$$

$$\sqrt{(2 - 1)^2 + (2 - (-2))^2} = \sqrt{17} \quad (2)$$

であり、点 2 よりも点 3 のほうが点 1 に近い。横の差と縦の差をそれぞれ二乗して足し、平方根をとる。距離はこのように、座標ごとの差の二乗を足し合わせて測る。1 次元であれば、2 つの数 y と z の距離は差の絶対値 $|y - z|$ であり、その二乗は $(y - z)^2$ である。

こうした距離の概念は統計学やデータサイエンスでも重要であり、とくに多変量解析では欠かせない。次に、この距離を、何次元でも同じ式で扱える道具(ベクトル)で書き直す。

ベクトルとユークリッドノルム

数を並べてまとめて扱う道具がベクトル(vector)である。図 2 の 3 点を、線形代数では点ではなくベクトルとして扱う。

$$\begin{aligned}\mathbf{a} &= [2, 2]^\top \\ \mathbf{b} &= [-3, 1]^\top \\ \mathbf{c} &= [1, -2]^\top\end{aligned}$$

要素が 2 つあるので 2 次元ベクトルであり、 $\mathbf{a}, \mathbf{b}, \mathbf{c} \in \mathbb{R}^2$ と書く。ベクトルは数を縦に並べたもの(列ベクトル)とするのが約束である。縦に書くのと紙面をとるので、横に並べて $^\top$ を付け、縦のベクトルを表す。

定義 1 (転置). 縦に並んだ数を横に寝かせる操作を転置(transpose)と呼び、 $^\top$ で表す。 $\mathbf{a} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$ なら $\mathbf{a}^\top = [2, 2]$ である。行列 $\mathbf{A}$ の転置 $\mathbf{A}^\top$ は、行と列を入れ替えたもので、 $\mathbf{A}$ の (i, j) 成分が $\mathbf{A}^\top$ の (j, i) 成分になる。

ベクトルどうしの計算の基本は、内積とユークリッドノルムである。計算に使う前に定義しておく。

定義 2 (ベクトルの内積). p 次元ベクトル $\mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ に対して、 $\mathbf{y}^\top \mathbf{z} = \sum_{j=1}^p y_j z_j$ をベクトル $\mathbf{y}$ と $\mathbf{z}$ の内積(inner product)と呼ぶ。内積は掛ける順番によらない(内積の可換性)。

$$\mathbf{y}^\top \mathbf{z} = \mathbf{z}^\top \mathbf{y} \quad (3)$$

定義 3 (ユークリッドノルム). ベクトル $\mathbf{x}$ の ℓ_2 ノルム(ユークリッドノルム(Euclidean norm))は、 $\mathbf{x}$ と $\mathbf{x}$ の内積の平方根 $\|\mathbf{x}\|_2 = \sqrt{\mathbf{x}^\top \mathbf{x}}$ である。

ベクトルの大きさを 1 つの数で表す量をノルム(norm)と呼ぶ。ユークリッドノルムはその代表である。たとえば $\mathbf{a} = [2, 2]^\top$ なら $\|\mathbf{a}\|_2 = \sqrt{2^2 + 2^2} = \sqrt{8}$ である。

定義 4 (ユークリッド距離). p 次元ベクトル $\mathbf{y}, \mathbf{z}$ のユークリッド距離(Euclidean distance)を $\|\mathbf{y} - \mathbf{z}\|_2 = \sqrt{(\mathbf{y} - \mathbf{z})^\top (\mathbf{y} - \mathbf{z})}$ と定義する。これは差のベクトル $\mathbf{e} = \mathbf{y} - \mathbf{z}$ のユークリッドノルム $\|\mathbf{e}\|_2$ と捉えることもできる。

内積は「成分どうしを掛けて足す」計算である。この定義を使うと、(1) 式と (2) 式はベクトルどうしの距離として計算でき、

$$\begin{aligned}\|\mathbf{a} - \mathbf{b}\|_2 &= \sqrt{(\mathbf{a} - \mathbf{b})^\top (\mathbf{a} - \mathbf{b})} = \sqrt{5^2 + 1^2} = \sqrt{26} \\ \|\mathbf{a} - \mathbf{c}\|_2 &= \sqrt{(\mathbf{a} - \mathbf{c})^\top (\mathbf{a} - \mathbf{c})} = \sqrt{1^2 + 4^2} = \sqrt{17}\end{aligned}$$

となる。三平方の定理で求めた値と一致する。平方根は余計な計算になるため、ベクトルのユークリッド距離は二乗して扱うのが一般的である。

私たちは 2 次元や 3 次元の点なら目で捉えられるが、それより高い次元の空間を思い描くことは難しい。しかしベクトルを用いれば、たとえば $\mathbf{x} = [x_1, x_2, \dots, x_{100}]^\top$ のように、数式の上では 100 次元の点も表現でき、距離も同じ式で測れる。 n 次元ベクトル $\mathbf{y}, \mathbf{z} \in \mathbb{R}^n$ のユークリッド距離の二乗は

$$\begin{aligned}\|\mathbf{y} - \mathbf{z}\|_2^2 &= (\mathbf{y} - \mathbf{z})^\top (\mathbf{y} - \mathbf{z}) = \sum_{i=1}^n (y_i - z_i)^2 \\ &= \mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top \mathbf{z} - \mathbf{z}^\top \mathbf{y} + \mathbf{z}^\top \mathbf{z} \\ &= \mathbf{y}^\top \mathbf{y} - 2\mathbf{y}^\top \mathbf{z} + \mathbf{z}^\top \mathbf{z}\end{aligned}\tag{4}$$

と表せる。1 行目の右边が示すとおり、ベクトルの距離の二乗は、成分ごとのスカラーの距離の二乗 $(y_i - z_i)^2$ を足し合わせたものである。最後の等号には、内積の可換性 (3) 式を用いた。

データ行列

ベクトルは数を 1 列に並べたものだった。数を縦にも横にも並べた表を 1 つの記号で扱う道具が、行列 (matrix) である。行列は、ベクトルをより一般化した概念として捉えることができる。 n 行 p 列の行列 $\mathbf{X}$ は

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} = \begin{bmatrix} \tilde{\mathbf{x}}_1^\top \\ \vdots \\ \tilde{\mathbf{x}}_n^\top \end{bmatrix} = [\mathbf{x}_1, \dots, \mathbf{x}_p] \in \mathbb{R}^{n \times p}\tag{5}$$

のように縦だけでなく横にも要素が広がっており、行ベクトル $\tilde{\mathbf{x}}_i$ が n 本縦に連なったもの、あるいは列ベクトル $\mathbf{x}_j$ が p 本横に連なったものと解釈できる。スカラーには添え字がなく、ベクトルの要素は x_i と添え字が 1 つであったが、行列の要素は x_{ij} と添え字が 2 つになる。

ベクトルと行列は、多変量解析の理解に欠かせない。たとえば 100 人の生徒に 5 教科のテストを受けさせて採点すると、その結果は表 1 のように 100×5 の行列 $\mathbf{X} \in \mathbb{R}^{100 \times 5}$ で表現できる。第 i 行のベクトルは生徒 i の各教科の得点、第 1 列のベクトルは各生徒の英語の得点である。このように、行が個体、列が変数を表す行列をデータ行列 (data matrix) と呼ぶ。

表 1: 100 人の生徒の 5 教科の得点

	英語	数学	国語	理科	社会
生徒 1	86	57	71	82	91
生徒 2	81	86	88	75	69
...	...	...	...	...	...
生徒 100	59	43	62	62	41

行列の転置 (定義 1) は、行と列を入れ替える。 $n \times p$ のデータ行列 $\mathbf{X}$ を転置した $\mathbf{X}^\top$ は $p \times n$ であり、その第 j 行は変数 j の n 人ぶんの値である。積の転置は掛ける順番が逆になり、

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top \quad (6)$$

が成り立つ。たとえば $(\mathbf{X}\beta)^\top = \beta^\top \mathbf{X}^\top$ である。 $n \times 1$ の $\mathbf{X}\beta$ を寝かせると $1 \times n$ になり、これは $1 \times p$ の $\beta^\top$ と $p \times n$ の $\mathbf{X}^\top$ の積と同じ大きさである。この規則は、正規方程式を導くところで使う。

単回帰の目的関数

距離・ベクトル・行列という道具がそろった。では実際に、多変量解析の代表的な手法である線形回帰で使ってみよう。図 1 で下ろした縦の線の長さは、各点の y 座標と、その真上または真下にある直線上の点の y 座標との 1 次元の距離であった。最小二乗法は、この距離の二乗和を最小にする。これを実際のデータで確かめる。

最も簡単な場合から始める。説明変数が 1 つだけで、切片も 0 とした単回帰を考える。具体例として、糖尿病の患者 442 人のデータ(第 II 部で詳しく述べる)を使う。BMI (体格指数)を説明変数、1 年後の病気の進行度を目的変数として取り出し、それぞれ全員の平均を引いた(図 3)。患者 i ($i = 1, \dots, n$) の BMI を x_i 、進行度を y_i と書く。 x_i も y_i も 1 つの数、すなわちスカラー(scalar)である。回帰分析の目的は、縦軸の進行度を横軸の BMI によって近似することである。




図 3: BMI と 1 年後の進行度(患者 442 人、どちらも平均を引いた値)。(a) 傾きの違う直線、(b) 最小二乗法で選んだ直線と各点の縦のずれ

図 3 (a) のように傾きの違う直線はいくらでも引けるので、最適な傾きを推定する必要がある。では、どのような基準で最適なパラメータを推定すればよいだろうか。ここでは最小二乗法によって求める。最小二乗法の主な枠組みは次のとおりである。

まず、得られたデータに対して、何らかの仮説であるモデルを立てる。そしてそのデータとモデルとの間の誤差(error)を最小化する。つまり

$$\text{データ} = \text{モデル} + \text{誤差}$$

としたときに、誤差を最小化するようなパラメータを推定する。ここでいうデータは、1 人の患者の値ではな

く、442 人の進行度の全体である。モデルは、その全体を BMI の β 倍で説明しようとする仮説であり、誤差は、モデルで説明しきれずに残る部分の全体である (図 4)。実際は

$$\text{誤差} = \text{データ} - \text{モデル}$$

であるから、データとモデルの距離を最小化することになる。この定義のどこにも「直線」は出てこない。




図 4: データ=モデル+誤差。傾き 5 の直線 (灰色) をモデルとしたときの、442 人ぶんの誤差 (赤い縦線)

この分解を 1 人ずつ書けば、患者 i について

$$y_i = \beta x_i + e_i \quad (i = 1, \dots, n) \quad (7)$$

となる。 β は直線の傾きを表すパラメータ、 e_i は患者 i の誤差である。データとモデルの距離の二乗は、1 人ぶんの差の二乗 $(y_i - \beta x_i)^2$ を全員について足し合わせた

$$f(\beta) = \sum_{i=1}^n (y_i - \beta x_i)^2 \quad (8)$$

が、最小化すべき目的関数(objective function)になる。これは図 3 (b) における直線と各点との縦のずれの二乗和である。図 1 で描いた「縦の線の二乗和を最小にする」操作は、データとモデルの距離を最小にすることの、単回帰の場合の姿だったのである。

この目的関数を、直線の傾き β の関数として描いてみる (図 5)。左の 3 本の直線の傾きは、5、最小二乗法の答え、20 である。それぞれの縦のずれの二乗和が、右の曲線の上の 3 つの点になる。 β を動かすと $f(\beta)$ は下に凸の放物線を描き、その谷底の β が最小二乗法の答えである。谷底を見つけるには、 $f(\beta)$ の接線の傾きに注目す

ればよい(直線の傾き β と紛らわしいが、こちらは横軸を β にとった曲線 $f(\beta)$ の傾きである)。谷の左側では、 β を増やすと f が減るので接線の傾きは負になる。右側では、 β を増やすと f が増えるので正になる。そしてちょうど谷底で、傾きは 0 になる。関数の接線の傾きを与えるのが微分であるから、微分して 0 とおけば谷底の β が求まる。




図 5: 左: 傾きの違う 3 本の直線。右: 傾き β を動かしたときの目的関数 $f(\beta)$ と、3 本の直線に対応する点での接線

(8) 式の二乗を展開し、和を項ごとに分けると

$$f(\beta) = \sum_{i=1}^n y_i^2 - 2\beta \sum_{i=1}^n x_i y_i + \beta^2 \sum_{i=1}^n x_i^2$$

となる。3つの和 $\sum_i y_i^2$ 、 $\sum_i x_i y_i$ 、 $\sum_i x_i^2$ は、データだけで決まる数で β を含まない。したがって $f(\beta)$ は、 β についての見慣れた 2 次関数 $a\beta^2 - 2b\beta + c$ である。 β^2 の係数 $a = \sum_i x_i^2$ は正なので、グラフは下に凸の放物線で、谷底はただ 1 つである。項ごとに微分すると、定数の項 $\sum_i y_i^2$ は 0、 $-2\beta \sum_i x_i y_i$ は $-2 \sum_i x_i y_i$ 、 $\beta^2 \sum_i x_i^2$ は $2\beta \sum_i x_i^2$ になるので

$$\frac{df(\beta)}{d\beta} = -2 \sum_{i=1}^n x_i y_i + 2\beta \sum_{i=1}^n x_i^2 = 0$$

を得る。左辺は $-2 \sum_i x_i (y_i - \beta x_i)$ とまとめることもできる。これを移項すると $\beta \sum_i x_i^2 = \sum_i x_i y_i$ となり、両辺を $\sum_i x_i^2$ で割れば、最適なパラメータは

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2} \quad (9)$$

となる。図 3 (b) の赤い直線は、この $\hat{\beta}$ を傾きとする直線である。ここまでに使ったのは、1 変数の関数の微分だけである。

係数が増えると

1 変数なら、微分して 0 とおくだけで解けた。では、係数が 2 つならどうか。切片を加えた単回帰 $y_i = \beta_0 + \beta_1 x_i + e_i$ を考える。目的関数 $f(\beta_0, \beta_1) = \sum_i (y_i - \beta_0 - \beta_1 x_i)^2$ は 2 つの係数の関数であり、 (β_0, β_1) の平面の上に谷のような曲面を描く(図 6)。偏微分(partial derivative)とは、ほかの係数を固定して、1 つの係数だけを動かしたときの微分である。 β_1 を固定すれば、谷の切り口は β_0 についての放物線になり、その接線の傾きが $\partial f / \partial \beta_0$ である。谷底では、どちらの向きに切っても傾きは 0 になるので、

$$\frac{\partial f}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0, \quad \frac{\partial f}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

という 2 本の連立方程式を解けばよい。(9) 式は、切片を 0 とおいて β_1 についての式だけを残したものに当たる。




図 6: 係数が 2 つのときの目的関数(概念図)。左:等高線と、 β_1 を固定した切り口(緑の破線)。右:その切り口の放物線と、接線の傾き(偏微分)

係数が p 個になればどうか。個体 i の p 個の説明変数を $x_{i1}, \dots, x_{ip}$ とし、モデルを $y_i = \beta_1 x_{i1} + \dots + \beta_p x_{ip} + e_i$ とすると、目的関数 $f = \sum_i (y_i - \sum_j \beta_j x_{ij})^2$ を各 β_k で偏微分して 0 とおいた

$$\frac{\partial f}{\partial \beta_k} = -2 \sum_{i=1}^n x_{ik} \left(y_i - \sum_{j=1}^p \beta_j x_{ij} \right) = 0 \quad (k = 1, \dots, p) \quad (10)$$

という p 本の連立方程式を解くことになる。考え方は 2 変数のときと変わらない。ただ、添え字が二重になった和を p 本書き下すのは煩わしく、 p が大きくなれば手で解くことも難しい。係数の並び $\beta_1, \dots, \beta_p$ はベクトル β で、括弧の中の「掛けて足す」計算 $\sum_j \beta_j x_{ij}$ は内積で、すでに書ける。 $n \times p$ 個の数の表 x_{ij} も、データ行列 $\mathbf{X}$ で書ける。これらを使い、(10) 式の p 本の式を 1 本にまとめる。

目的関数をベクトル・行列で書く

ベクトルと行列がそろったので、目的関数を書き直す。まず単回帰の (8) 式を、ベクトルで書く。 n 人の進行度を縦に並べたベクトルを $\mathbf{y} = [y_1, \dots, y_n]^\top$ 、BMI を並べたベクトルを $\mathbf{x} = [x_1, \dots, x_n]^\top$ とすれば、モデル (7) 式は $\mathbf{y} = \beta \mathbf{x} + \mathbf{e}$ となり、目的関数は

$$f(\beta) = \sum_{i=1}^n (y_i - \beta x_i)^2 = \|\mathbf{y} - \beta \mathbf{x}\|_2^2 \quad (11)$$

と、データのベクトル $\mathbf{y}$ とモデルのベクトル $\beta \mathbf{x}$ の距離の二乗になる。「データ=モデル+誤差」は、全員ぶんをまとめた式 $\mathbf{y} = \beta \mathbf{x} + \mathbf{e}$ として、ベクトルでそのまま書けるのである。解 (9) 式も、分子は内積 $\mathbf{x}^\top \mathbf{y}$ 、分母は $\mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|_2^2$ であるから、 $\hat{\beta} = \mathbf{x}^\top \mathbf{y} / \mathbf{x}^\top \mathbf{x}$ と書ける。スカラーの和で書いた式とベクトルで書いた式は、同じものを表している。

次に説明変数を増やす。重回帰分析(multiple regression)は、目的変数を複数の説明変数によって近似する手法である。個体 i の p 個の説明変数を $x_{i1}, \dots, x_{ip}$ とすると、モデルはスカラーで書けば

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + e_i \quad (i = 1, \dots, n)$$

であり、目的関数は $\sum_i (y_i - \sum_j \beta_j x_{ij})^2$ となる。 p 個の係数を並べたベクトルを $\boldsymbol{\beta} = [\beta_1, \dots, \beta_p]^\top$ とすると、括弧の中の和は $\mathbf{X}$ の第 i 行と $\boldsymbol{\beta}$ の内積 $\tilde{\mathbf{x}}_i^\top \boldsymbol{\beta}$ であり、これを n 個縦に並べたものが $\mathbf{X}\boldsymbol{\beta}$ である。したがって (4) 式の z を $z = \mathbf{X}\boldsymbol{\beta}$ (ただし $\mathbf{X} \in \mathbb{R}^{n \times p}$ 、 $\boldsymbol{\beta} \in \mathbb{R}^p$) と置き換えた

$$f(\boldsymbol{\beta} \mid \mathbf{y}, \mathbf{X}) = \sum_{i=1}^n \left(y_i - \sum_{j=1}^p \beta_j x_{ij} \right)^2 = \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) \quad (12)$$

が、重回帰分析の目的関数になる。「データ=モデル+誤差」は $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$ となり、(12) 式はデータ $\mathbf{y}$ とモデル $\mathbf{X}\boldsymbol{\beta}$ の距離の二乗そのものである。 $p = 1$ のとき $\mathbf{X}$ は 1 列のベクトル $\mathbf{x}$ 、 $\boldsymbol{\beta}$ はスカラー β となり、(12) 式は (11) 式に戻る。記号の意味を表 2 にまとめる。回帰分析では $\mathbf{y}$ と $\mathbf{X}$ はデータとして与えられており、推定すべきパラメータは $\boldsymbol{\beta}$ だけである。 $\boldsymbol{\beta}$ は回帰係数ベクトルであり、値の正負や大小によって、説明変数が目的変数に与える影響を表す。目的関数 (12) 式を最小にする $\boldsymbol{\beta}$ 、すなわち $\operatorname{argmin}_{\boldsymbol{\beta}} f(\boldsymbol{\beta} \mid \mathbf{y}, \mathbf{X})$ を最適なパラメータとする。こうしてパラメータを決める推定法を最小二乗法と呼ぶ。

行列の大きさを四角形で描くと、式の形が確かめやすい(図 7)。 $\mathbf{X}$ は n 行 p 列、 $\boldsymbol{\beta}$ は p 行 1 列なので、 $\mathbf{X}$ の列の数と $\boldsymbol{\beta}$ の行の数がそろい、積 $\mathbf{X}\boldsymbol{\beta}$ は n 行 1 列になる。これは $\mathbf{y}$ と $\mathbf{e}$ と同じ形である。第 i 行だけを取り出せば、(10) 式の前に書いた 1 人ぶんの式 $y_i = \sum_j \beta_j x_{ij} + e_i$ に戻る。




図 7: 重回帰のモデル $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$ を四角形で描いたもの(概念図)。箱の縦は行の数、横は列の数。帯は第 i 行

表 2: 回帰分析の目的関数と記号

記号	意味	大きさ
$\ \mathbf{y} - \mathbf{X}\boldsymbol{\beta}\ _2^2$	回帰分析の目的関数	—
$\mathbf{y}$	各個体の予測したい変数か らなる目的変数ベクトル	$n \times 1$
$\mathbf{X}$	各個体の p 個の説明変数か らなる行列	$n \times p$
$\boldsymbol{\beta}$	各変数の重みを表す回帰係 数ベクトル	$p \times 1$

正規方程式の導出と計算手順

(10) 式の p 本の偏微分を、1 つずつ書き下す代わりに縦に並べたベクトル $\partial f / \partial \boldsymbol{\beta}$ を考え、目的関数をベクトル $\boldsymbol{\beta}$ のまま微分する。このベクトルを勾配(gradient)と呼ぶ。1 変数の関数では微分して 0 とおいたのに対し、多変数の関数では勾配を 0 ベクトルとおく。これは、すべての偏微分を同時に 0 とおくことにほかならない。導出には、次の 2 つの道具を使う。

定義 5 (ベクトル偏微分). ベクトル $\mathbf{x} \in \mathbb{R}^p$ と行列 $\mathbf{A} \in \mathbb{R}^{n \times p}$ があるとする。このとき $\mathbf{Ax}$ の $\mathbf{x}$ についての偏微分(vector derivative)は $\frac{\partial \mathbf{Ax}}{\partial \mathbf{x}} = \mathbf{A}^\top$ で与えられる。また行列 $\mathbf{B} \in \mathbb{R}^{p \times n}$ があるとして、 $\mathbf{x}^\top \mathbf{B}$ の $\mathbf{x}$ についての偏微分は $\frac{\partial \mathbf{x}^\top \mathbf{B}}{\partial \mathbf{x}} = \mathbf{B}$ である。

定義 6 (逆行列). 逆行列(inverse matrix)は、行列の演算で逆数にあたるものである。正方行列 $\mathbf{A} \in \mathbb{R}^{p \times p}$ の逆行列を $\mathbf{A}^{-1}$ と書くと、 $\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}_p$ が成り立つ。ただし、逆行列が存在しない正方行列もあり、その行列を非正則行列や特異行列と呼ぶ。対称行列($\mathbf{X}^\top \mathbf{X}$ など)の固有値がすべて 0 より大きい、つまり正定値のときは正則(nonsingular matrix)行列である。

目的関数 (12) 式を最小にする β を具体的に求めよう。まず目的関数を展開する。ユークリッドノルムの二乗は自分自身との内積(定義 3)なので、(12) 式は

$$\|\mathbf{y} - \mathbf{X}\beta\|_2^2 = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) = \mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top \mathbf{X}\beta - (\mathbf{X}\beta)^\top \mathbf{y} + (\mathbf{X}\beta)^\top \mathbf{X}\beta$$

と括弧を外せる。(6) 式の $(\mathbf{X}\beta)^\top = \beta^\top \mathbf{X}^\top$ と内積の可換性 (3) 式から、真ん中の 2 項はどちらも $\beta^\top \mathbf{X}^\top \mathbf{y}$ に等しい。したがって

$$f(\beta | \mathbf{y}, \mathbf{X}) = \mathbf{y}^\top \mathbf{y} - 2\beta^\top \mathbf{X}^\top \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{X}\beta \quad (13)$$

となる。これをベクトルの偏微分(定義 5)で項ごとに微分する。第 1 項の $\mathbf{y}^\top \mathbf{y}$ は β を含まないので 0 になる。第 2 項と第 3 項の微分は

$$\frac{\partial \beta^\top \mathbf{X}^\top \mathbf{y}}{\partial \beta} = \mathbf{X}^\top \mathbf{y} \quad (14)$$

である。これは 定義 5 の 2 つ目の式で、 $\mathbf{x}$ を β 、 $\mathbf{B}$ を $\mathbf{X}^\top \mathbf{y}$ としたものである。第 3 項は β を 2 つ含むので、片方を定数とみて 1 つずつ微分し、足し合わせる。

$$\frac{\partial \beta^\top \mathbf{X}^\top \mathbf{X}\beta}{\partial \beta} = \frac{\partial \beta^\top (\mathbf{X}^\top \mathbf{X}\beta)}{\partial \beta} + \frac{\partial (\beta^\top \mathbf{X}^\top \mathbf{X})\beta}{\partial \beta} = \mathbf{X}^\top \mathbf{X}\beta + (\beta^\top \mathbf{X}^\top \mathbf{X})^\top = 2\mathbf{X}^\top \mathbf{X}\beta \quad (15)$$

となる。黒の β が定数とみた方である。右辺の第 1 項には 定義 5 の 2 つ目の式($\mathbf{B} = \mathbf{X}^\top \mathbf{X}\beta$)を、第 2 項には 1 つ目の式($\mathbf{A} = \beta^\top \mathbf{X}^\top \mathbf{X}$)を当てはめた。(6) 式から $(\mathbf{X}^\top \mathbf{X})^\top = \mathbf{X}^\top (\mathbf{X}^\top)^\top = \mathbf{X}^\top \mathbf{X}$ なので、 $(\beta^\top \mathbf{X}^\top \mathbf{X})^\top = \mathbf{X}^\top \mathbf{X}\beta$ となり、2 つの項は等しい。(14) 式と (15) 式を (13) 式の各項に当てはめると、方程式

$$\frac{\partial f(\beta | \mathbf{y}, \mathbf{X})}{\partial \beta} = 2(-\mathbf{X}^\top \mathbf{y} + \mathbf{X}^\top \mathbf{X}\beta) = \mathbf{0}_p \quad (16)$$

を得る。よって最適な $\hat{\beta}$ は

$$\begin{aligned} \mathbf{X}^\top \mathbf{X}\hat{\beta} &= \mathbf{X}^\top \mathbf{y} \\ \hat{\beta} &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \end{aligned} \quad (17)$$

によって得られる。(17) 式の 1 行目を正規方程式(normal equation)と呼ぶ。ここで $(\mathbf{X}^\top \mathbf{X})^{-1}$ は正方行列 $\mathbf{X}^\top \mathbf{X}$ の逆行列(定義 6)であり、 $\mathbf{X}^\top \mathbf{X}$ が正則であれば $\hat{\beta}$ は 1 つに決まる。 $p = 1$ のとき $\mathbf{X}^\top \mathbf{X} = \mathbf{x}^\top \mathbf{x} =$

$\sum_i x_i^2$ 、 $\mathbf{X}^\top \mathbf{y} = \mathbf{x}^\top \mathbf{y} = \sum_i x_i y_i$ となり、(17) 式は (9) 式と一致する。1 変数の微分で求めたスカラーの解を、行列で一般化したものが正規方程式である。

計算は次の手順で行う。

1. 説明変数の列の先頭に切片の列(すべて 1)を加えて $\mathbf{X}$ とする(切片も係数の 1 つとして β に入る)
2. $\mathbf{X}^\top \mathbf{X}$ と $\mathbf{X}^\top \mathbf{y}$ を作る
3. 正規方程式を解いて $\hat{\beta}$ を求める
4. 予測値 $\hat{\mathbf{y}} = \mathbf{X}\hat{\beta}$ と残差 $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$ を求める

線形回帰の最小二乗解は、決まった手順を 1 回通すだけで求まる。このような解を閉形式(closed form)の解と呼ぶ。

最小二乗法は線形回帰に限らない

最小二乗法は、線形回帰のための方法ではない。そのことを、まったく別のモデルで確かめておく。k-means クラスタリング(k-means clustering)は、データの点をいくつかの群に分け、群ごとに 1 つの代表点(セントロイド)を置いて、各点をその群の代表点で近似するモデルである。点 i の位置を $\mathbf{X}$ の第 i 行 $\tilde{\mathbf{x}}_i$ 、その点が属する群の代表点を $\mathbf{c}_{q(i)}$ とすれば、誤差は点から代表点までの線であり、k-means はその二乗和

$$\sum_{i=1}^n \|\tilde{\mathbf{x}}_i - \mathbf{c}_{q(i)}\|_2^2 \quad (18)$$

が最小になるように、群分けと代表点を決める。




図 8: 同じ推定法、違うモデル。左：線形回帰(誤差は直線への縦の線)。右：k-means (誤差は群の代表点★への線)。どちらも誤差の二乗和を最小にする

図 8 の左は冒頭の 図 1 と同じ線形回帰で、誤差は各点から直線への縦の線である。右の k-means では、誤差は各点から代表点への線になる。モデルは直線と代表点でまったく違うが、推定法はどちらも「誤差の二乗和を最小にする」、すなわち最小二乗法である。図 1 の図に重なっていた 2 つのもののうち、推定法のほうは線形回帰に固有のものではなかったのである。同じように、主成分分析も、データとモデルの距離の二乗を最小にする最小二乗法として書ける。

モデルと推定法

ここまでで、最小二乗法の定義に「直線」が含まれないことがわかった。モデルと推定法は独立に選べる。表 3 は、本講義で扱うモデル(行)と推定法(列)の組み合わせを、それを扱う回とともに示したものである。

表 3: モデルと推定法の組み合わせ(数字は扱う回)

モデル \ 推定法	最小二乗法	最尤法
線形回帰	第 1 回	第 6 回
線形判別分析(LDA)	第 5 回	第 6 回
ロジスティック回帰	—	第 6 回
主成分分析(PCA)	第 9・10 回	—
k-means	第 11 回	—
混合正規分布(GMM)	—	第 12 回
対応分析	第 14 回(重み付き)	—

行の方向に読むと、同じモデルでも推定法を選べることがわかる。たとえば線形回帰は第 1 回で最小二乗法、第 6 回で最尤法(maximum likelihood)によって推定する。列の方向に読むと、最小二乗法の列には 5 つのモデルが並ぶ。推定法は特定のモデルの付属品ではなく、多くのモデルに共通して使える道具である。

最尤法は、パラメータを決めたときに手元のデータが出てくる確率を計算し、その確率が最も大きくなるパラメータを選ぶ。距離ではなく確率を測る点で、最小二乗法とは考え方が異なる。ただし、誤差が正規分布に従うと仮定した線形回帰では、2 つの推定法は同じ係数を与える。

全 15 回は、この表の上に並んでいる。前半は線形回帰を最小二乗法で解くところから出発し、第 4 回で罰則を加えた最小二乗法へ、第 5~7 回で分類と最尤法へと広げる。後半は第 9・10 回と第 11 回で主成分分析と k-means を最小二乗法として解き直し、第 12 回で同じ群分けを最尤法によって推定する。前半でたどった「最小二乗法から最尤法へ」という道を、後半でもう一度たどる構成である。なお、同じ学期の演習「応用データ分析演習」では、ここで導く手法を実データに当てて結果を読む側を扱う。本講義は、その結果がなぜそうなるのかを導く側である。

第 II 部 実データ解析

糖尿病データ

ここからは、第 I 部で導いた最小二乗法を実データに当てはめる。用いるのは、糖尿病の患者 442 人のデータ (Efron et al., 2004) であり、機械学習ライブラリ scikit-learn に付属している。1 人の患者(データ行列の 1 行)が 1 つの個体にあたる。各患者について、表 4 の 10 の説明変数と、目的変数である 1 年後の病気の進行度(数値が大きいほど進んでいる)が記録されている。以下では、10 の説明変数から進行度を当てることを目指す。

表 4: 糖尿病データの説明変数

変数	意味	変数	意味
age	年齢	s2	LDL コレステロール
sex	性別(1 と 2 で記録)	s3	HDL コレステロール
bmi	BMI (体格指数)	s4	総コレステロール ÷ HDL
bp	平均血圧	s5	中性脂肪(対数)
s1	総コレステロール	s6	血糖値

変数ごとに単位が違う点に注意したい。年齢は歳、BMI は kg/m^2 、血圧は mmHg、中性脂肪は対数をとった値であり、単位の違う量に付く係数の大小はそのまま比べられない。まず 1 つの列について、平均・分散・標準偏差を定義する。

定義 7 (平均・分散・標準偏差). n 個の値 $x_1, \dots, x_n$ の平均を $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ 、分散(variance)を $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ とし、その平方根 s を標準偏差(standard deviation)と呼ぶ。分散は平均からのずれの大きさを表し、標準偏差は同じ量を元の単位で表す。 n ではなく $n-1$ で割るのは、平均そのものをデータから計算したぶん、自由に動ける数が 1 つ減るためである。

次に、2 つの変数の関係を表す量を定義しておく。

定義 8 (共分散・相関係数). 2 つの変数 x, y の共分散(covariance)を $s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$ 、相関係数(correlation coefficient)を $r_{xy} = s_{xy}/(s_x s_y)$ とする。相関係数は -1 から 1 のあいだに収まり、直線的な関係の強さを表す。全変数の組の相関係数を並べた行列を相関行列(correlation matrix)と呼ぶ。

まず目的変数の分布を見る(図 9)。進行度は 25 から 346 の範囲にあり、平均は 152、標準偏差は 77 である。分布はやや右に裾を引き、平均が中央値 140.5 より大きい。

次に、10 の変数それぞれについて、その変数 1 つだけを使う単回帰(simple regression)を当てはめ、当てはめに使ったのと同じデータで決定係数 R^2 を計算した(定義は (19) 式、図 10)。 R^2 は進行度の変動のうちモデルが説明できた割合で、単回帰の場合はその説明変数と進行度の相関係数の 2 乗に等しい。BMI と進行度の相関係数は 0.59 であり、その 2 乗 0.34 が最も長い棒になる。中性脂肪(0.32)がそれに続き、年齢(0.035)や性別(0.002)はほとんど 0 である。どれか 1 つの変数では、進行度の変動の半分も説明できない。ただし、単回帰の




図 9: 目的変数(1 年後の進行度)の分布。赤線は平均

R^2 が小さい変数を使えない変数と決めつけてはいけない。1 変数だけの当てはめは、ほかの変数が自由に動いたままの関係を写しているにすぎないからである。




図 10: 説明変数を 1 つずつ使った単回帰の決定係数

計算の手続きと検証

10 の説明変数をすべて使う重回帰を、第 I 部の計算手順どおりに解いた。データ行列 $\mathbf{X}$ は、442 人 $\times$ 10 変数の説明変数の先頭に切片の列(すべて 1)を加えた 442×11 の行列とした。変数は元の単位のまま用いた。目的変数 $\mathbf{y}$ は 1 年後の進行度である。正規方程式 (17) 式を解き(NumPy の線形方程式ソルバーを用いた)、切片と 10 変数の係数の計 11 個を得た。得られた係数から予測値 $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ を計算し、決定係数 (19) 式を求めると $R^2 = 0.52$ となった。単回帰の最良 0.34 から明確に上がった。BMI だけでは説明しきれなかった変動の一部を、血圧や血液検査の値を同時に使うことで説明できたことになる。

検証として、同じデータを scikit-learn の線形回帰(LinearRegression)にも当てはめ、係数を比べた。11 個の係数の差は最大でも 3×10^{-11} で、計算機の数値誤差の範囲で一致した。scikit-learn は正規方程式を作らず、別の数値計算の方法で $\mathbf{X}$ から直接解いている。それでも、解いている問題は同じ最小二乗法である。

結果の読み方

図 11 は、10 の変数の係数を元の単位のまま並べたものである。青は進行度を押し上げる向き、赤は押し下げる向きを表す。ただし、棒の長さをそのまま比べてはいけない。係数の単位が変数ごとに違うからである。たとえば中性脂肪の係数 68.5 は他より大きく見えるが、中性脂肪は対数をとった値で、全員でも 3.3 から 6.1 までしか動かない。1 単位の重みが列ごとに違うのである。




図 11: 重回帰の係数(元の単位のまま)

列を c 倍すると、予測は変わらず、その列の係数が $1/c$ 倍になる。係数の大きさは単位しだいなので、棒の長さで変数の効きを比べることはできない。ここで読めるのは向き(符号)である。

当てはまりの良さを測るには、まず比べる相手を決める。説明変数を一切使わなければ、できる予測は全員に同じ 1 つの値を当てることだけである。二乗誤差の和 $\sum_i (y_i - c)^2$ を最小にする定数 c は平均 $\bar{y}$ である(c で微分して 0 とおくと $c = \bar{y}$ になる)。そこで、全員を平均で予測したときの誤差の和

$$\sum_{i=1}^n (y_i - \bar{y})^2$$

を基準にする。本データでは 2,621,009 である。これに対し、モデルで予測したときの誤差の和は残差平方和 $\sum_i (y_i - \hat{y}_i)^2$ で、本データでは 1,263,986 に減る。決定係数(coefficient of determination)は、この 2 つの比で

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{\sum_{i=1}^n (y_i - \bar{y})^2 - \sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (19)$$

と定義する。右辺の形で読むと、平均で予測したときの誤差のうち、モデルを使って減らせた割合である。本データでは $(2,621,009 - 1,263,986) \div 2,621,009$ で、約 0.52 になる。分母と分子を人数 n で割っても比は変わらないので、1 人あたりで見てもよい。平均で予測すると 1 人あたりの二乗誤差は 5,930 (n で割った分散にあたる)で、モデルを使うと 2,860 に下がる。誤差がおおよそ半分に減ったので、 R^2 はおおよそ 0.5 になる。

$R^2 = 0$ なら、モデルは平均で予測したのと同じだけしか誤差を減らせていない。 $R^2 = 1$ なら、誤差は 0 で、予測は完全である。切片を含む最小二乗法では、ほかの係数を 0 とし、切片を $\bar{y}$ とおけば、平均での予測そのものになる。この予測も候補に含まれているので、最小二乗法で選んだ予測の残差平方和は基準の誤差を上回らない。そのため、当てはめに使ったデータ上では R^2 は 0 以上 1 以下に収まる。また R^2 は、実測値と予測値の相関係数の 2 乗に等しい。今回の $R^2 \approx 0.52$ は、平均で予測したときの誤差のおよそ半分を、10 の変数で説明できたことを意味する。

実データで起きる落とし穴

ここまで結果を素直に読んできたが、同じ結果を 3 つの角度から見直しておく。

第 1 に、相関は因果ではない。回帰係数が測っているのは、2 つの量がそろって動くという関連であって、一方を変えれば他方が変わるという介入の効果ではない。「ほかの変数を固定したときの効果」という言い方は因果的に響くが、固定できるのは手元のデータに入っている変数だけである。記録されていない第三の要因、たとえば生活習慣が BMI と進行度の両方を動かしていれば、その影響は係数に混ざったまま残る。因果を主張するには、交絡(confounding)の調整や、ランダム化などの実験計画、因果推論の枠組みが要る。

第 2 に、データの外への予測(外挿)は保証されない。図 12 のように、BMI のデータは 18 から 42.2 の範囲にしかないが、直線はその外まで同じ傾きで伸びる。直線は、データのない領域の情報を持たないまま、内側で決めた傾きを延長しているだけである。多変数になると、外挿はさらに見えにくくなる。各変数の値が 1 つずつは観測された範囲に入っている、その組み合わせがデータの中にあるとは限らない。




図 12: BMI だけの単回帰の直線を、データのある範囲(緑)の外まで延ばしたもの

第 3 に、係数の符号が直感と逆になることがある。総コレステロール(s1)の係数は、それだけを使った単回帰では +0.47 と正だが、10 変数の重回帰では -1.09 と負になる。これは矛盾ではない。重回帰の係数は LDL コレステロールを含むほかの変数を固定したときの効果であり、総コレステロールと LDL の相関は 0.90 と非常に強い。重回帰の係数が答えているのは「LDL を変えずに総コレステロールだけを増やしたら進行度はどうなるか」という問いであり、単回帰が答えている問いとはそもそも別である。ただし、相関の強い変数を同時に入れると、その違いの部分を推定する材料がデータにほとんど残らず、係数は大きく振れる。重回帰で総コレステロー

ルと LDL の係数の向きが逆になったのも、この振れの現れである。同じ学期の演習 6 では、エイムズの住宅データで同じ現象に出会う。バスルームの数の係数は、それだけを入れた式では +71,941 ドルなのに、11 本の列を入れた式では -8,610 ドルに反転する。

締め

まとめと次回の問い

本章では、最小二乗法をモデルから切り離して定義し直した。出発点は点と点の距離である。点をベクトルとして書けば距離はユークリッドノルムで測れる。最小二乗法は、データとモデルの距離の二乗を最小にする推定法であり、線形回帰にも k-means にも共通して現れる。線形回帰に当てはめると、目的関数を β で微分して 0 とおいた正規方程式から、係数が一度に求まる。糖尿病データでは、正規方程式の解がライブラリの答えと一致することを確認した。

モデルを変えても、推定法まで変える必要はない。本当の関係が曲線であれば、 x^2 や交互作用(interaction) x_1x_2 を新しい列として $\mathbf{X}$ に加えればよい。モデルは係数について 1 次式のままだので、正規方程式がそのまま使える。ただし列を増やせば手元の当てはまりは必ず良くなり、当てはめすぎの危険も増える。

最後に、次回への問いを置く。本章の $R^2 \approx 0.52$ は、係数を決めるのに使ったのと同じ 442 人の上で測った値である。モデルは手元のデータに合わせて作られているので、そのデータで測った数字は楽観的に出やすい。しかも同じデータで測る限り、列を増やして R^2 が下がることはない。増やした列の係数を 0 と置けばもとのモデルが再現でき、最小二乗法はそれより悪い解を選ばないからである。では、訓練に使った行で測った当てはまりは、見ていない行でも成り立つのだろうか。次回は、行を分けて測る方法と、誤差がどこから生まれるのかを扱う。