

第 2 回 汎化誤差とデータリーク

学習に全てのデータを使ってはいけない

本章の主張は、学習に全てのデータを使ってはいけない、である。作ったモデルが手元のデータの外でも通用するか。それは、係数を決めるのに使わなかった行で測って初めてわかる。全ての行を学習に使えば、測る行が残らない。

第 I 部 理論

最小二乗法の誤差

第 1 回では、最小二乗法で係数を決めた。最小二乗法は、データとモデルの距離を最小にする推定法である。直線のモデルなら、各点と直線の縦のずれを誤差とみて、その二乗和

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

が最小になるように β_0, β_1 を選ぶ(図 1)。ここで測っている誤差は、係数を決めるのに使った点そのものの誤差である。




図 1: 人工データの 10 点(青)に最小二乗法で当てはめた直線と、各点の誤差(赤)

本章の問いは 1 つである。この誤差を小さくすれば、良いモデルになるか。以下ではまず、誤差をどこまでも小さくしていくと何が起きるかを、極端な例で見る。続いて、本当に小さくしたい誤差(汎化誤差)を定義する。前半は、真の関係を自分で決めた人工データで、汎化誤差がなぜ単純すぎても複雑すぎても大きくなるのかを分解する。後半は実データに移る。実データでは汎化誤差を直接は測れないので、手元の行を訓練とテストに分けて、テスト誤差で見積もる手続きを組み立てる。最後に、その分割を壊すデータリークを見る。

極端な例：点を全部通る曲線

第 1 回の直線を、より複雑な曲線に替えて、訓練の点での誤差をどこまでも小さくしてみる。ここでは人工的なデータを使う。真の関係を $g(x) = 0.5x^3 - x^2 + 2$ と決め、区間 $[-3, 3]$ から 10 個の x を取り、標準偏差 2 の正規分布に従うノイズを加えて y を作った。この 10 点に、次数を 1 から 9 まで変えた多項式を最小二乗法で当てはめる。係数を決めた点で測った誤差を訓練誤差と呼ぶ。次数を上げるほど曲線は点に近づき、9 次では 10 点をすべて通って、訓練誤差はちょうど 0 になる。係数が 10 個あれば、10 点は必ず通せるからである。ところが、同じ真の関係から新しく作った 1,000 点で測ると、9 次の曲線は点のない所で大きく外れる(図 2)。新しい点での誤差は 29.6 で、3 次の 4.8 の約 6 倍になる。9 次の曲線は 10 点を覚えてだけで、 x と y の関係をつかんではいない。




図 2: 人工データの 10 点(青)に 1 次・3 次・9 次の多項式を当てはめた曲線と、同じ真の関係から作った新しい点(橙)

次数ごとの訓練誤差と、新しい点での誤差を並べたのが 図 3 である。訓練誤差は次数とともに下がる一方である。新しい点での誤差は 3 次で最小となり、そこから上がっていく。真の関係が 3 次なので、それより複雑なモデルは関係ではなくノイズを覚え始める。訓練誤差だけを見ていると、この U 字の右側は見えない。9 次のように、訓練の点に合わせすぎて新しい点で外れる状態を過学習(overfitting)と呼ぶ。逆に 1 次のように、モデルが単純すぎて訓練の点にも新しい点にも合わない状態を過小学習(underfitting)と呼ぶ。U 字の左側が過小学習、右側が過学習である。

次数を上げて、訓練誤差は上がらない。そのため、訓練誤差が小さいほど良いモデルだと素朴にみなして選ぶと、いちばん複雑なモデルが選ばれてしまう。訓練誤差では、モデルを選べない。本当に小さくしたいのは、係数を決めた点での誤差ではなく、まだ観測されていない値に対する誤差である。




図 3: 人工データでの次数ごとの訓練誤差と、新しい点での誤差

訓練誤差と汎化誤差

ここまで、係数を決めた点で測った誤差を訓練誤差と呼んできた。これを式で書き、本当に小さくしたい誤差と区別しておく。まず 1 人ぶんの誤差から始める。説明変数が x 、目的変数が y の 1 人がいるとする。手元のデータで作ったモデルを $\hat{g}$ とし、この人への予測 $\hat{g}(x)$ の誤差を $(y - \hat{g}(x))^2$ で測る。これは 1 つの数、すなわちスカラーである。

係数を決めた n 人について、この誤差を平均したものが訓練誤差(training error)

$$E_{\text{train}} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{g}(x_i))^2 \quad (1)$$

である。第 1 回と同じように、和はベクトルでまとめて書ける。実測を並べたベクトルを $\mathbf{y}$ 、予測を並べたベクトルを $\hat{\mathbf{y}}$ とすれば、(1) 式は $E_{\text{train}} = \frac{1}{n} \|\mathbf{y} - \hat{\mathbf{y}}\|_2^2$ となる。これは実測と予測の距離の二乗を、人数で割ったものである。最小二乗法は、この訓練誤差を最小にする係数を選んでる。

本当に小さくしたいのは、まだ観測されていない値に対する誤差である。これを数える形で定める。 $\hat{g}$ を作った点とは別に、同じ真の関係から新しい点 $(x_i^{\text{new}}, y_i^{\text{new}})$ を n_{new} 個作り、誤差を平均する。

$$\frac{1}{n_{\text{new}}} \sum_{i=1}^{n_{\text{new}}} (y_i^{\text{new}} - \hat{g}(x_i^{\text{new}}))^2 \quad (2)$$

新しい点の取り方しだい、この平均は少し揺れる。 n_{new} を増やすほど揺れは小さくなり、値は 1 つに落ち着く。その落ち着く先を汎化誤差(generalization error)と呼ぶ。ここでは E_{gen} と書く。9 次の例で新しい点を 1000 個作って測ったのは、 $n_{\text{new}} = 1000$ の (2) 式であり、汎化誤差の近似である。

2 つの平均は、計算の形は同じでも中身が違う。訓練の点では、 $\hat{g}$ がまさにその n 人の誤差を小さくするように選ばれている。まだ観測されていない値は、 $\hat{g}$ を作るのに使っていない。そのため (1) 式は E_{gen} より小さく出る。この楽観の大きさはモデルの複雑さとともに増え、9 次の曲線では新しい点での誤差との差が最も大きく

なった(図 3)。(2) 式を計算できるのは、新しい点をいくらでも作れる人工データだからである。そこでまず人工データのまま、汎化誤差の中身を調べる。

なぜ U 字になるのか : 訓練データの取り直し

新しい点で測ると、誤差は複雑さに対して U 字を描く(図 3)。なぜ単純すぎても複雑すぎても汎化誤差が大きくなるのか。2つの原因は別のものである。それを見るために、同じ真の関係から 30 点の訓練データを 300 回取り直し、そのつど多項式を当てはめた(図 4)。1 次の曲線は、何度取り直しても平均(青)が真の関係(破線)に届かない。これは系統的なずれである。8 次の曲線は、平均こそ真の関係に近いが、1 本 1 本が大きく揺れる。これは取り直しに対する暴れである。真の関係と同じ 3 次の曲線は、平均が真の関係にほぼ重なり、揺れも小さい。ずれも暴れも小さいのは、単純すぎず複雑すぎない、この次数である。




図 4: 人工データで 30 点の訓練データを取り直して当てはめた曲線(灰色、300 本のうち 20 本)と、300 本の平均(青)、真の関係(破線)

同じことを、的当てに置き換えて見る(図 5)。2 点 $x = -2.5, 2.5$ での予測から真の値を引き、横軸と縦軸にとる。的の中心が真の値で、取り直し 1 回ぶんの曲線が矢 1 本に当たる。1 次の矢は、中心から外れた所に固まる。何度投げても同じ側に外れるので、平均(青の $\times$)が中心からずれたままになる。8 次の矢は、平均こそほぼ中心に来るが、広く散らばる。3 次の矢は、中心の近くに小さくまとまる。平均の中心からのずれが Bias、矢の平均のまわりの散らばりが Variance に当たる。

2 つのずれが生まれる理由は、モデルを関数の集合とみるとわかる(図 6)。1 次の多項式で表せる曲線、つまり直線の全体を 1 つの集合とみなす。最小二乗法による当てはめは、データを見て、この集合の中から 1 本を選ぶ操作である。真の関係 g が集合の外にあれば、データをいくら取り直しても、選ばれる曲線は集合の外へは出られない。選ばれた曲線の平均と g との隙間が、Bias² の正体である。多項式の集合は、1 次は 3 次に、3 次は 8 次に含まれる。次数を上げて集合を広げると、 g に近い曲線を選べるようになり、Bias² は減る。その代わり、集合が広いぶん、取り直すたびにノイズに引かれて、選ばれる曲線が集合の中を大きく動く。これが Variance である。集合を広げれば Bias² は減り、Variance は増える。真の関係と同じ 3 次の集合は、ちょうど g を含むほどの広さである。

この 2 つのずれを、平均の曲線をはさんで式で分ける。




図 5: 取り直した 300 回の予測を的当てとして見た図。2 点 $x = -2.5, 2.5$ での予測と真の値の差を横・縦にとり、中心(+)が真の値、灰色の点が 1 回ぶんの予測、青の × がその平均




図 6: モデルを関数の集合とみた概念図。多項式の集合は 1 次 $\subset$ 3 次 $\subset$ 8 次 と入れ子になる。★が真の関数 g 、点を取り直すたびに選ばれる曲線、× がその平均。左：1 次の集合は g に届かない(Bias)。右：8 次の集合は g の近くまで届くが、選ばれる曲線が散らばる (Variance)

バイアス・バリエンス分解

系統的なずれと暴れを、式で分ける。ある 1 点 x を固定する。 r 回目に取り直した訓練データで作った曲線を $\hat{g}_r$ とし($r = 1, \dots, R$, ここでは $R = 300$)、点 x での R 個の予測の平均を

$$\bar{g}(x) = \frac{1}{R} \sum_{r=1}^R \hat{g}_r(x)$$

とおく。図 4 の青い曲線である。この平均が真の値 $g(x)$ からどれだけずれるかを $\text{Bias}^2 = (\bar{g}(x) - g(x))^2$ と

し、1 本 1 本が平均のまわりにどれだけ散らばるかを $\text{Variance} = \frac{1}{R} \sum_r (\hat{g}_r(x) - \bar{g}(x))^2$ とする。1 点での量なので、以下はすべてスカラーの計算になる。

真の値からのずれ $\hat{g}_r - g$ を、平均をはさんで $(\hat{g}_r - \bar{g}) + (\bar{g} - g)$ と分け、二乗して R 回ぶん平均する(点 x は省いて書く)。交差項は $\frac{2}{R}(\bar{g} - g) \sum_r (\hat{g}_r - \bar{g})$ であり、平均からのずれは足すと 0 になるので消える。したがって

$$\frac{1}{R} \sum_{r=1}^R (\hat{g}_r(x) - g(x))^2 = (\bar{g}(x) - g(x))^2 + \frac{1}{R} \sum_{r=1}^R (\hat{g}_r(x) - \bar{g}(x))^2$$

となる。真の値からのずれの二乗の平均は、平均のずれの二乗と、平均のまわりの散らばりの和に分かれる。この式は、取り直しの回数 R が何回でも正確に成り立つ。

実際に測る誤差は、真の値 $g(x)$ ではなく、新しく観測される y との差である。ここで、データは $y = g(x) + \varepsilon$ と表せると仮定する。 g は未知だが決まった関数で揺れない。ノイズ ε は、平均 0、分散 σ^2 の正規分布 $N(0, \sigma^2)$ に従うと仮定する。本章の人工データは、実際に標準偏差 2 の正規分布でノイズを作っている。新しい点は真の曲線のまわりに散らばるので、真の曲線そのもので予測しても、この分は外れる。ノイズは訓練データとも予測とも無関係だと仮定しているので、新しい点を多く取って平均すると、ノイズと予測のずれの交差項は 0 に近づく。誤差には、ノイズの二乗の平均、すなわち σ^2 がそのまま足される。まとめると

$$\text{新しい点での誤差} \approx \underbrace{(\bar{g}(x) - g(x))^2}_{\text{Bias}^2} + \underbrace{\frac{1}{R} \sum_{r=1}^R (\hat{g}_r(x) - \bar{g}(x))^2}_{\text{Variance}} + \sigma^2 \quad (3)$$

を得る。新しい点を増やすほど、 $\approx$ は等号に近づく。これをバイアス・バリエンス分解(bias-variance decomposition)と呼ぶ。

3 つの項は性格が違う。Bias² は、平均的な予測が真の値から系統的にどれだけずれるかを表し、モデルの形を決めた時点で決まる。単純すぎるモデルでは大きい。Variance は、訓練データの取り替えに対する予測の敏感さを表し、複雑すぎるモデルでは大きい。 σ^2 はデータに最初から入っている揺れで、モデルとは無関係に残る。3 項は単位がそろっているので足し算できる。そのため誤差が大きいときに、どの項を削れば誤差が減るのかを分けて考えられる。(3) 式は 1 点 x での分解である。全体の誤差は、これを x について平均したものになる。

(3) 式の 3 項は、真の関係を自分で決めた人工データなら実際に測れる。図 4 と同じ 300 回の取り直しを次数ごとに集計し、次数 1~8 の Bias² と Variance を計算した(図 7)。次数 1 では、Bias² 11.27、Variance 1.27、 σ^2 4 を足すと 16.54 になる。この和は、新しい点で直接測った誤差 16.51 とほぼ一致する。真の関係と同じ次数 3 では Bias² がほぼ 0 となり、和は 4.79 で最小になる。次数 8 では Variance が 62.86 まで増える。複雑さを上げると Bias² は減り、Variance は増える。複雑さというつまみ 1 つでは、両方を同時に小さくできない。これをバイアス・バリエンスのトレードオフ(bias-variance tradeoff)と呼ぶ。片方が減るぶん必ずもう片方が増える、という意味ではない。この例でも、1 次から 3 次までは Bias² だけが下がり、Variance はほとんど変わらない。真の関係より複雑にしたところから、Variance が増え始める。また、これはデータの量を決めたうえで複雑さを動かす場合の話である。データを増やせば、Bias² を増やさずに Variance だけを減らせる(次節の学習曲線)。そのため和は U 字を描き、その底が最もよく汎化する複雑さになる。

どれほど複雑さを調整しても、汎化誤差は σ^2 の下には入らない。同じ x を持つ 2 人が違う y を取るなら、どんな $\hat{g}$ でも両方を同時には当てられないからである。したがって、訓練誤差を 0 にすることは目標にならない。目標を誤ると、その差を埋めようとしてモデルを複雑にし、かえって Variance を増やす。なお σ^2 は、いま手元にある列に対する下限である。測っていなかった変数を加えれば、それまでノイズに見えていた部分を説明できることもある。




図 7: 人工データでのバイアス・バリエンス分解。30 点の訓練データを 300 回取り直して計算した 3 項と、その和(緑)、新しい点で直接測った誤差(×)

U 字の左右は、訓練誤差と新しい点での誤差の組で見分けられる(図 3)。どちらも大きければ左側の過小学習(Bias 過多)で、変数や非線形の項を加えてモデルを複雑にする。訓練誤差だけが小さく新しい点での誤差が大きければ右側の過学習(Variance 過多)で、モデルを単純にするか、データを増やす。Variance は標本数とともに小さくなるが、Bias² は標本数では減らない。診断を誤ると対策は逆効果になり、左側にいるのにモデルを単純にすれば、事態は悪くなる一方である。

学習曲線：人数を増やして測る

U 字のどちら側にいるかは、データの量を変えて測ると見分けやすい。訓練に使う点の数を増やしなが、訓練誤差と新しい点での誤差を並べた図を学習曲線(learning curve)と呼ぶ。人工データの同じ真の関係から、30 点から 200 点までの訓練データを、点の数ごとに 300 回取り、6 次と 1 次の多項式を当てはめて誤差の平均を描いた(図 8)。




図 8: 人工データの学習曲線。(a) 6 次(複雑すぎる)、(b) 1 次(単純すぎる)。点線は σ^2

6 次では、30 点のとき訓練誤差 3.1、新しい点での誤差 10.3 と大きく開いている。点を増やすと開きは縮み、

200 点では 3.9 と 4.2 になって、どちらも $\sigma^2 = 4$ に近づく。Variance は標本数とともに小さくなるので、過学習のモデルにはデータを増やすことが効く。1 次では、点を増やしても 2 本は 16.1 前後の高いところで平らになり、 σ^2 には届かない。Bias² は標本数では減らないので、この場合はデータではなく、モデルを複雑にする。訓練誤差が点の数とともにわずかに上がるのは、おかしいことではない。点が少ないうちは、モデルがその点に合わせきれてしまうので低く出る。点が増えるほど、本来の水準へ近づく。

では、点を十分に集めれば、訓練誤差だけを見ればよく、行を分ける必要はなくなるのだろうか。6 次の過学習が点を増やして解けたのは、列を増やさずに点だけを増やしたからである。点が増えるにつれて列も足すと、事情は変わる。3 次の 4 列に、 y とは無関係な乱数の列を足し、係数の数を点の数の半分にそろえて同じように測った(図 9)。訓練誤差は 2.0 前後、新しい点での誤差は 8.1 前後で、200 点集めても開きは縮まない。過学習のままである。過学習かどうかを決めるのは点の数そのものではなく、点の数と複雑さの釣り合いである。実際のデータ分析でも、点が増えれば列や交互作用を足し、より柔軟なモデルを試す。そのたびに訓練誤差は下がり、どの点の数でも、訓練誤差では複雑さを選べない。




図 9: 人工データで、無関係な列を足して係数の数を点の数の半分にしたときの訓練誤差と新しい点での誤差。点線は σ^2

もう 1 つ見落とししやすい点がある。学習曲線で開きが縮んだと言えたのは、新しい点での誤差を一緒に描いたからである。この図そのものが、学習に使わない点で測ることを前提にしている。手元の点の数がもう十分かどうかは、学習に使わなかった点で測って初めてわかる。

訓練・テスト分割 : 行を分ける

ここからは実データに移る。手元のデータだけで汎化誤差を見積もるにはどうすればよいか。ここまで新しい点や訓練データを好きなだけ作れたのは、真の関係を自分で決めた人工データだったからである。実データで手元にあるのは、1 つのデータ行列だけである。そこで、手元の行を 2 つに分け、片方を係数の決定に一切使わずに、まだ観測されていない値の代役として取っておく。データ行列と目的変数を

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_{\text{train}} \\ \mathbf{X}_{\text{test}} \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} \mathbf{y}_{\text{train}} \\ \mathbf{y}_{\text{test}} \end{bmatrix}$$

と上下に分け、係数は訓練(training)の行だけから

$$\hat{\beta} = (\mathbf{X}_{\text{train}}^\top \mathbf{X}_{\text{train}})^{-1} \mathbf{X}_{\text{train}}^\top \mathbf{y}_{\text{train}}$$

と決める(第1回の正規方程式)。そのうえで、取っておいたテスト(test)の行で

$$E_{\text{test}} = \frac{1}{n_{\text{test}}} \|\mathbf{y}_{\text{test}} - \mathbf{X}_{\text{test}} \hat{\beta}\|_2^2 \quad (4)$$

を測る。これをテスト誤差(test error)と呼ぶ。テストの行の集合を T とすれば、スカラーの和では

$$E_{\text{test}} = \frac{1}{n_{\text{test}}} \sum_{i \in T} (y_i - \hat{g}(x_i))^2 \quad (5)$$

であり、(4) 式はこれをテストの行のベクトルでまとめたものである。(5) 式は、(2) 式の新しい点をテストの行に置き換えたものである。テストの行を増やすほど、(5) 式は汎化誤差に近づく。 $\mathbf{X}_{\text{test}}$ と $\mathbf{y}_{\text{test}}$ は $\hat{\beta}$ の式に一度も現れないので、テストの行は「まだ観測されていない値」の代役になる。この手続きを訓練・テスト分割(train-test split)、またはホールドアウト(holdout)法と呼ぶ。分割は行の集合を2つに分ける操作で、列(変数)は切らない。この方法は、どの行も同じ母集団から独立に得られたとみなせることを前提にしている。時系列のように行に順序がある場合や、同じ対象から繰り返し測った行がある場合には、無作為に分けるとテストが不当に簡単になる。

測り方が壊れるとき：データリーク

行を分け、係数を訓練の行だけで決めても、測り方が壊れることがある。テストの行の情報が、当てはめる前に行う処理(前処理)を通して訓練に入り込むときである。例として、列の単位をそろえる前処理を取る。

定義 1 (標準化). データ行列 $\mathbf{X}$ の第 j 列の平均を $\bar{x}_j$ 、標準偏差を s_j とする。各値から列の平均を引き、標準偏差で割って $z_{ij} = (x_{ij} - \bar{x}_j)/s_j$ とする操作を標準化(standardization)と呼ぶ。全列をまとめると

$$\mathbf{Z} = (\mathbf{X} - \mathbf{1}\bar{\mathbf{x}}^\top) \mathbf{D}^{-1}, \quad \mathbf{D} = \text{diag}(s_1, \dots, s_p) \quad (6)$$

と書ける。 $\mathbf{1}$ は要素がすべて1のベクトル、 $\bar{\mathbf{x}}$ は列の平均を並べたベクトルである。 $\text{diag}(s_1, \dots, s_p)$ は、 p 個の数を対角に並べ、それ以外の成分を0とした $p \times p$ の行列を表す。このような行列を対角行列(diagonal matrix)と呼ぶ。 $\mathbf{D}^{-1}$ は対角に $1/s_1, \dots, 1/s_p$ が並んだ対角行列で、右から掛けると第 j 列が s_j で割られる。標準化した列は平均0・標準偏差1で、単位を持たない。

標準化に使う平均 $\bar{x}_j$ と標準偏差 s_j は、手元のデータから推定した値である。その意味で、前処理はモデルの前置きではなく、モデルの一部である。したがって平均と標準偏差も、係数 $\hat{\beta}$ と同じく訓練の行だけから決めなければならない。テストの行から計算した値が 1 つでも訓練側に入ると、テストはもはや未知データの代役ではなくなる。これをデータリーク (data leakage) と呼ぶ。漏れがあってもエラーは出ず、数字が良くなるだけである。そのため、気づく手がかりがない。

手順を行列で書くと次のとおりである (図 10 の右)。

1. 訓練の行だけから列の平均 $\bar{\mathbf{x}}_{\text{train}} = \frac{1}{n_{\text{train}}} \mathbf{X}_{\text{train}}^T \mathbf{1}$ と標準偏差を求め、 $\mathbf{D}_{\text{train}}$ を作る
2. 訓練の行を $\mathbf{Z}_{\text{train}} = (\mathbf{X}_{\text{train}} - \mathbf{1}\bar{\mathbf{x}}_{\text{train}}^T) \mathbf{D}_{\text{train}}^{-1}$ と変換し、 $\mathbf{Z}_{\text{train}}$ で係数を決める
3. テストの行も、訓練の値のまま $\mathbf{Z}_{\text{test}} = (\mathbf{X}_{\text{test}} - \mathbf{1}\bar{\mathbf{x}}_{\text{train}}^T) \mathbf{D}_{\text{train}}^{-1}$ と変換して測る




図 10: データリーク。左：分割の前に全行で標準化すると、テストの行の平均・分散が訓練に漏れる。右：訓練の行の値でテストも変換する

こうして変換したテストの行の列平均は、ちょうど 0 にはならない。0 にならないことが、訓練の統計量を使った証拠である。分割を何度も繰り返す場合も、各回で係数を決める行だけから平均・標準偏差を計算し直す。同じことは標準化に限らない。欠損値を全体の平均で埋める、目的変数との関係を全行で調べて変数を選ぶ、外れ値を除く閾値を全行で決める、といった操作がそうである。どれもデータから値を計算して全体に当てはめており、訓練の行だけで行わなければならない。変数の選択のように目的変数 y を見る前処理が漏れると、害ははるかに大きくなる。これは第 II 部で確かめる。

評価という軸

本章で扱った「評価」は、第 1 回で見たモデル × 推定法の地図のどこか 1 つのマスに属するものではない。地図全体に掛かるもう 1 本の軸である。当てはめる手続きは何も変わらない。変わるのは、出てきた数字をどの行で測るかという一点である。前処理もデータから平均や標準偏差を計算しているので、モデルの一部として同じ軸に乗る。

第 II 部実データ解析

糖尿病データ

第 II 部では、第 1 回と同じ糖尿病データで、第 I 部の測り方を確かめる。説明変数は患者 442 人の計 10 変数で、年齢・性別・BMI（体格指数）・平均血圧と、コレステロールや血糖など 6 種類の血液検査の値からなる。目的

変数は 1 年後の病気の進行度で、平均は 152、標準偏差は 77 である。第 1 回の単回帰(BMI だけ)と重回帰(10 変数)は、どちらも 442 人全員で係数を決め、同じ 442 人で測っていた。第 1 回では当てはまりを R^2 で見たが、本章では誤差そのもの(二乗誤差の平均)を見る。全員で決めて全員で測った誤差は、単回帰が 3,890、重回帰が 2,860 である。

計算の手続きと検証

計算の手続きは次のとおりである。442 人を無作為に訓練 309 人とテスト 133 人に分けた。訓練の 309 人だけで各列の平均と標準偏差を求め、訓練とテストの両方を標準化した(第 I 部のデータリークの手順どおり)。第 1 回の 2 つのモデルの係数は訓練の行の正規方程式で決め、訓練とテストの両方で誤差(二乗誤差の平均)を測った。さらに、分割の乱数を 20 通りに変えて同じ計算を繰り返した(締めで使う)。

第 1 の検証は、第 1 回のモデルを分けて測り直すことである(図 11)。第 1 回のように 442 人全員で当てはめて全員で測ると、10 変数の重回帰の誤差は 2,860 だった。訓練 309 人で係数を決めると、その 309 人での誤差は 2,804 だが、初めて見る 133 人では 3,097 に増える。BMI だけの単回帰では 3,893 と 3,921 で、ほとんど変わらない。係数を決めた行で測った誤差は、10 変数のモデルでは実際より小さく出ていた。ただし、第 I 部の極端な例のように大きく崩れてはいない。訓練の 309 人に対して係数は 11 個しかなく、1 個の係数を約 28 人で決めている。そのため、訓練の行の癖に合わせ込む余地が小さい。係数が 2 個しかない単回帰では、その余地はさらに小さい。




図 11: 第 1 回の 2 つのモデルを、訓練 309 人で係数を決めて、訓練(青)とテスト 133 人(橙)で測った誤差(二乗誤差の平均)

第 2 の検証は、データリークを避ける手順そのものである。訓練の 309 人の平均・標準偏差でテストの 133 人を変換すると、その列平均は最大で 0.09 と、0 からずれる(図 12)。訓練の統計量を使ったのだから、0 にならないのが正しい。テストの行だけで平均を 0 にそろえ直したら、テストの行から値を学んだことになる。

結果の読み方

第 I 部の学習曲線を、実データで描く(図 13)。対象は第 1 回の 10 変数のモデルで、訓練に使う人数を 92 人から 309 人まで 8 段階に増やした。各段では、442 人を訓練 309 人とテスト 133 人に無作為に分ける操作を 20




図 12: 訓練 309 人の平均・標準偏差で標準化したテスト 133 人の、列ごとの平均

回繰り返した。そのたびに訓練 309 人のうち指定の人数だけで当てはめ、訓練誤差とテスト誤差の平均を描いた。92 人のときは訓練誤差 2,693、テスト誤差 3,391 と開いているが、309 人では 2,825 と 3,051 まで近づく。モデルは何も変えておらず、増やしたのはデータだけである。Variance は標本数とともに小さくなる。訓練誤差が人数とともにわずかに上がるのは、第 I 部の人工データと同じである。右端では 2 本とも平らになりつつあり、これより先は線形モデルの Bias^2 と σ^2 の壁に近い。




図 13: 学習曲線。訓練に使う人数を増やしたときの訓練誤差(青)とテスト誤差(赤)

曲線は形で読む。2 本の開きが大きければ過学習 (Variance 過多) であり、データを増やすかモデルを単純にする。両方が高く開きが小さければ過小学習 (Bias 過多) であり、モデルを複雑にする。右端がまだ下がっていればデータを集める価値があり、平らなら集めても同じ値が続く。

評価の手続きで起きる落とし穴

ここまで、数字を測った手続きは正しいものとして読んできた。最後に、手続きそのもののせいで数字が当てにならなくなる場面を見る。

データリークは性能を水増しする。漏れの害をはっきり見るために、ここでは人工的なデータを使う。100 行のデータを作り、目的変数も 1,000 本の列もすべて互いに無関係な乱数とした。そこから目的変数との相関が強い 20 列を選び、その列で重回帰の係数を決めた。係数を 70 行で決めて 30 行で測る分割を、20 通り変えて平

均する(図 14)。20 列を全行で先に選んだ場合、テスト誤差は 0.67 になる。目的変数はでたらめなのだから、本当の実力は、全員に訓練の平均を当てる予測の誤差 1.11 を下回れない。実際、訓練の行だけで列を選び直すと 1.64 になり、平均を当てる予測にも負ける(少ない行で多くの係数を決めたぶんの Variance である)。全行で選んだ列は、テストの行も含めた 100 行の目的変数にたまたま合うように選ばれている。そのため、テストの行はもはや初めて見る行ではない。標準化の平均・標準偏差のように説明変数だけから計算する値が漏れても、害は小さいことが多い。だが変数の選択のように目的変数を見る前処理が漏れると、害ははるかに大きくなる。漏れの大きさは事前にはわからないので、前処理はつねに係数と同じ行の中で行う。




図 14: 目的変数も列もでたらめな人工データで、列を選ぶ行を変えたときのテスト誤差

締め

発展：過剰パラメータと二重降下

ここまで、パラメータを増やしすぎると汎化誤差は大きくなる、と見てきた。ところが、きわめて精度の高い深層学習のモデルは、学習に使う点の数よりはるかに多いパラメータを持っている。なぜこんな事態になるのだろうか。

これを人工データで見る。隠れた 5 つの量から目的変数を作り、説明変数としては、その隠れた量にノイズの乗った列を 2,000 本作った。訓練の点は 40 個である。最初の p 列だけを使って最小二乗法で係数を決め、新しい 1000 点でテスト誤差を測る。 p ごとに 100 回データを取り直し、中央値を描いた(図 15)。 p が点の数より少ないうちは、おなじみの U 字が現れる。テスト誤差は $p = 12$ 付近で最小の 0.62 となり、そこから上がる。 p が点の数 40 に並ぶと、40 点をすべて通す係数が作れて訓練誤差は 0 になり、テスト誤差は 21.6 まで跳ね上がる。第 I 部の 9 次の曲線と同じことが起きている。

p が点の数を超えると、第 1 回の正規方程式の逆行列はなくなり、40 点を通す係数は無数に存在する。ここでは、その中から係数のユークリッドノルムが最小のものを選んだ。すると、テスト誤差は再び下がりはじめ、 $p = 2,000$ では 0.12 と、U 字の底 0.62 より低くなる。下がって、上がって、また下がるこの形を二重降下(double descent)と呼ぶ。パラメータが点の数より多い状態は、過剰パラメータ(overparameterization)と呼ばれる。

なぜ過剰パラメータのモデルがよく汎化するのかは、いままさに研究が進んでいるテーマである。U 字の「バイアスとバリエーションの釣り合い」の考え方と、現代の機械学習の実践とをどう両立させるかを論じた出発点として、次の論文がある。




図 15: 人工データでの二重降下。訓練 40 点に、列の数 p を変えて最小二乗法を当てはめたときの訓練誤差(青)とテスト誤差(赤)。 $p > 40$ では係数のユークリッドノルムが最小の解を使う。 $p \geq 40$ の訓練誤差は 0 なので描いていない。両軸とも対数目盛り

Belkin, M., Hsu, D., Ma, S., & Mandal, S. (2019). Reconciling modern machine-learning practice and the classical bias–variance trade-off. *Proceedings of the National Academy of Sciences*, 116(32), 15849–15854.

まとめと次回の問い

本章の問いは、最小二乗法で小さくした誤差を、さらに小さくすれば良いモデルになるか、であった。答えは、ならない、である。係数を決めた行で測った誤差(訓練誤差)は、モデルがその行に合わせて作られているので必ず小さく出る。列を増やせば、下がることはあっても上がることはない。まだ観測されていない値に対する誤差の平均を、汎化誤差と呼ぶ。汎化誤差は、ある 1 点ではバイアスの二乗、バリエーション、ノイズの分散の和に分かれる。単純すぎれば第 1 項が、複雑すぎれば第 2 項が大きくなり、第 3 項はどんなモデルでも消せない。汎化誤差を推定するには、行を分けて、係数の決定に使わなかった行で測る。標準化のような前処理も、データから平均や標準偏差を推定しているので、モデルの一部である。そのため、係数と同じく訓練の行だけで学ぶ。

最後に、次回への問いを置く。訓練・テスト分割では、どの行をテストに回すかを乱数で決めた。この分け方に必然性はなく、恣意的である。分け方を変えると、数字はどれほど変わるだろうか。第 1 回の 10 変数のモデルを、分割の乱数だけを 0 から 19 まで変えて 20 回測り直すと、テスト誤差は 2,266 から 3,464 まで動いた(図 16)。データもモデルも同じで、違うのはどの 133 人をテストに回したかだけである。テストの数字が揺れるのは、テストに回った人の当たり外れに加えて、訓練の行が変わるたびに係数そのものが変わるからである。では、線形回帰の係数の揺れは何で決まるのだろうか。(3) 式の Variance は、訓練データを取り直したときの予測の揺れであった。今回は、この揺れを係数について式で表す。




図 16: 第 1 回の 10 変数のモデルを、分割の乱数だけ変えて測り直したテスト誤差(20 通り)