

第 3 回 係数の不安定性と最小二乗法の限界

列が似ているとき、列が多すぎるとき

本章の問いは、第 2 回の締めで残った「係数の不安定性は何で決まるのか」である。最小二乗法の係数の分散は $\sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$ で表される。この 1 本の式を読むと、列が似ているとき・列が行より多いときに最小二乗法が通用しなくなることがわかる。

第 I 部 理論

係数は分割しだいで変わる

線形回帰は、データ行列 $\mathbf{X}$ に係数を掛けて予測値を作る(第 1 回)。

$$\underbrace{\hat{\mathbf{y}}}_{\text{第 2 回}} = \mathbf{X} \underbrace{\hat{\boldsymbol{\beta}}}_{\text{本章}} \quad (1)$$

第 2 回は左辺の予測値 $\hat{\mathbf{y}}$ に着目し、それが新しいデータでどれだけ当たるかを測った。本章は右辺の係数 $\hat{\boldsymbol{\beta}}$ に着目する。

第 2 回の締めでは、訓練データとテストデータへの分け方を変えるだけでテストの数字がばらつくことを見て、なぜばらつくのかという問いを残した。本章では、別のデータで同じことを確かめるところから始める。使うのは、1990 年の米国国勢調査から作られたカリフォルニア州の住宅のデータである。20,640 の地区(数百世帯ずつの区画)について、地区の住宅価格の中央値と 8 列が記録されている。8 列は所得・築年数・1 世帯あたりの部屋数と寝室数・人口・1 世帯あたりの人数・緯度・経度である。8 列から住宅価格を予測する線形回帰を 20 回当てはめ直す。訓練 7 割・テスト 3 割への分け方だけを 20 通り変えると、テスト誤差(第 2 回と同じく、テストの行での二乗誤差の平均)は 0.515 から 0.554 まで動く(図 1 (a))。データもモデルも同じで、違うのはどの 14,448 地区で係数を決め、どの 6,192 地区で測ったかだけである。




図 1: カリフォルニアの住宅価格の 8 列のモデルを、訓練・テストへの分け方だけを変えて 20 回当てはめ直した結果。(a) テスト誤差、(b) 所得(青)と寝室数(赤)の係数(標準偏差 1 つぶんあたりの)、20 通りの平均からのずれ

同じ 20 通りの分割で、決まった係数そのものを並べてみる(図 1 (b))。元の単位のままでは、変数ごとに係数の大きさを比べられない。そこで各変数の標準偏差を掛け、その変数が標準偏差 1 つぶん動いたときの価格(10 万ドル単位)の変化に直した。さらにばらつきだけを比べるために、20 通りの平均からのずれを描いた。所得の係数は平均 0.84 のまわりでほとんど動かないが、寝室数の係数は 0.27 から 0.41 まで動く。20 通りの標準偏差は所得が 0.013、寝室数が 0.048 で、約 4 倍の開きがある。寝室数は、1 世帯あたりの部屋数との相関が 0.85 と強い。同じ手続きで決めた係数の中に、ばらつきやすいものとばらつきにくいものがあるのである。

20,640 地区あれば、ばらついても結論までは変わらない。だが、行が少なく、列どうしが似ているとどうなるか。人工データで極端な例を見る(図 2)。よく似た 2 列(相関 0.98)を 12 行だけ作り、真の係数をどちらも 1 とした。 $\mathbf{X}$ は固定したまま、目的変数だけをノイズのぶん 20 回取り直して当てはめると、列 1 の係数は -1.7 から 3.3 まで動き、20 回のうち 7 回は負になった。符号が変わると、「この列が増えると目的変数も増える」という読みが逆になる。係数のばらつきは、結論そのものを変えうる。




図 2: 似た 2 列(相関 0.98、12 行)の人工データで、 $\mathbf{X}$ を固定して目的変数だけを 20 回取り直したときの列 1 の係数。破線は真の値 1、○は符号が逆になった回

ここで、データの見方を 1 つ切り替える(図 3)。データを生み出すしくみ全体を母集団(population)、そこから取り出して手元に置いたデータを標本(sample)と呼ぶ。線形回帰では、母集団を $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ と考える。 $\mathbf{X}$ は固定し、取り出すたびにノイズ $\boldsymbol{\varepsilon}$ の出方だけが変わる。標本から計算した係数を推定値(estimate)と呼ぶ。標本

を限りなく取り直すと、推定値は1つの分布をつくる。図2の20個の点は、その分布から20回取り出したものである。




図3: 母集団と標本と推定値(概念図)。母集団 $y = X\beta + \epsilon$ (X は固定) から標本を取り出すたびに推定値が1つ決まり、限りなく取り直すと推定値の分布になる。真の β は見えない

困りごととはほかにもある。伝票2枚からラーメン・餃子・ライスの単品の値段を割り出そうとすると、2枚の合計に合う値段の組はいくらでも作れる。2つとも、データから決めた係数が頼りにならない場面である。

本章の問いは1つである。係数の不安定性は、何で決まるのか。まずばらつきを式で書くための道具をそろえ、最小二乗法の係数の分散が $\sigma^2(X^T X)^{-1}$ で表されることを導く。そのうえで、この1本の式から、列どうしが似ていると係数が不安定になること(共線性)と、列が行より多いと係数がそもそも決まらないことを読む。あわせて、係数から作る予測値のばらつきも同じ道具で書く。

第2回では汎化誤差を分け、訓練データの取り直しに対する予測のばらつきを Variance と呼んだ。ただし、その中身は開かなかった。本章はその中身を線形回帰について開く。「モデル × 推定法」の地図でいえば、線形回帰 × 最小二乗法のマスから動かない。そのマスの推定がどこで頼りにならなくなるか、という境目を見ることになる。

ふだんの分析で手に入るのは、このような標本1つだけである。そこから計算した推定値は見えるが、真の係数 β も推定値の分布も見えない。手元のデータそのものを要約する見方を記述統計(descriptive statistics)と呼ぶ。平均や相関係数、第1回の当てはめはこちらにあたる。手元のデータを取り直しうるものの1回分とみて、その背後とばらつきを推し量る見方を推測統計(inferential statistics)と呼ぶ。本章で求める係数のばらつきと標準誤差は、推測統計の道具である。

道具：期待値と分散

係数の不安定性を式で書くための道具を、ここにまとめておく。第2回では、訓練データを300回取り直して平均をとり、Bias²とVarianceを数えた。本章では、その平均を回数無限の極限に置き換えた量を道具として使う。

身近な例から始める。サイコロを振るたびに、出る目は1から6のどれかに変わる。それでも、出た目の平均は、振る回数を増やすと3.5に落ち着いていく(図4)。1回ごとの値は読めないが、平均の行き着く先は決まってい

る。




図 4: サイコロを振った回数と、それまでに出了目の平均(人工データ、2000 回)。横軸は対数。赤の破線は期待値 3.5

定義 1 (期待値・分散・独立). 取り出すたびに値が変わる量を、確率変数(random variable)と呼ぶ。ここでは X と書く。 X を R 回取り出した値 $X_1, \dots, X_R$ の平均の、 $R \rightarrow \infty$ での行き着く先

$$\mathbb{E}[X] = \lim_{R \rightarrow \infty} \frac{1}{R} \sum_{r=1}^R X_r \quad (2)$$

を期待値(expected value)と呼ぶ。期待値は和と定数倍をそのまま通し、 $\mathbb{E}[aX + bY + c] = a\mathbb{E}[X] + b\mathbb{E}[Y] + c$ が成り立つ(線形性)。平均のまわりの散らばりの二乗の平均 $\mathbb{E}[(X - \mathbb{E}[X])^2]$ を、分散(variance)と呼ぶ。ここでは $\text{Var}(X)$ と書く。一方の値がもう一方の値に関係しないとき、 X と Y は独立(independence)であるという。独立なら $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ である。

例 1 (サイコロの目). サイコロの目を X とする。期待値は $(1 + 2 + \dots + 6)/6 = 3.5$ 、分散は $\{(1 - 3.5)^2 + \dots + (6 - 3.5)^2\}/6 \approx 2.92$ である。2 つのサイコロを同時に振ったときの 2 つの目は、独立とみなせる。

□

例 2 (推定値の期待値と分散). 冒頭の推定値も、標本を取り直すたびに値が変わる確率変数である(図 3)。取り直しを限りなく続けたときの推定値の平均の行き着く先が期待値、そのまわりの散らばりの二乗の平均が分散であり、推定値の分布の中心と広がりにあたる。図 2 の 20 回で数えると、列 1 の係数の平均は 0.90、標準偏差は 1.52 だった。回数を増やすほど、この 2 つの数は期待値と分散の平方根に近づく。

□

第 2 回の分解は、この道具で書き直せる。点 x での予測 $\hat{g}(x)$ は、訓練データを取り直すたびに値が変わる確率変数である。第 2 回の平均の曲線 $\bar{g}(x) = \frac{1}{R} \sum_r \hat{g}_r(x)$ は、回数を無限にすれば期待値 $\mathbb{E}[\hat{g}(x)]$ になる。したがって、Bias² は $(\mathbb{E}[\hat{g}(x)] - g(x))^2$ 、Variance は $\text{Var}(\hat{g}(x))$ と書ける。第 2 回で「平均からのずれは足すと 0」として消した交差項は、期待値では $\mathbb{E}[\hat{g}(x) - \mathbb{E}[\hat{g}(x)]] = 0$ として消える。本章はこの Variance の中身を、線形回帰について開く。

データしだいで変わるのは係数 p 個の組なので、期待値と分散を確率ベクトルに広げる。

定義 2 (期待値ベクトルと分散共分散行列). n 個の確率変数を縦に並べたベクトル $\mathbf{y} = [y_1, \dots, y_n]^\top$ を、確率ベクトル(random vector)と呼ぶ。 $\mathbf{y}$ について、各成分の期待値を並べた $\mathbb{E}[\mathbf{y}] = [\mathbb{E}[y_1], \dots, \mathbb{E}[y_n]]^\top$ を期待値ベクトル、

$$\text{Var}(\mathbf{y}) = \mathbb{E}[(\mathbf{y} - \mathbb{E}[\mathbf{y}])(\mathbf{y} - \mathbb{E}[\mathbf{y}])^\top] \quad (3)$$

を分散共分散行列(variance-covariance matrix)と呼ぶ。(3) 式は $n \times n$ の行列で、その (i, i') 成分は y_i と $y_{i'}$ の共分散 $\mathbb{E}[(y_i - \mathbb{E}[y_i])(y_{i'} - \mathbb{E}[y_{i'}])]$ 、対角成分は各 y_i の分散である。

各 y_i が互いに独立なら、定義 1 の $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ から共分散は 0 になる。さらに分散がそろって σ^2 なら、 $\text{Var}(\mathbf{y}) = \sigma^2 \mathbf{I}_n$ と書ける。

確率変数を定数倍し、足し合わせたときの分散は、スカラーから順に広げられる。1 つの確率変数なら $\text{Var}(ay) = a^2 \text{Var}(y)$ である。独立な $y_1, \dots, y_n$ の重み付きの和なら、二乗を展開したときの交差項の期待値が独立性から 0 になるので、 $\text{Var}(\sum_i a_i y_i) = \sum_i a_i^2 \text{Var}(y_i)$ となる。一般に、定数の行列 $\mathbf{A}$ を掛けたベクトル $\mathbf{A}\mathbf{y}$ については

$$\mathbb{E}[\mathbf{A}\mathbf{y}] = \mathbf{A} \mathbb{E}[\mathbf{y}], \quad \text{Var}(\mathbf{A}\mathbf{y}) = \mathbf{A} \text{Var}(\mathbf{y}) \mathbf{A}^\top \quad (4)$$

が成り立つ。1 つ目は期待値の線形性を成分ごとに使ったものである。2 つ目は、 $\mathbf{A}\mathbf{y} - \mathbb{E}[\mathbf{A}\mathbf{y}] = \mathbf{A}(\mathbf{y} - \mathbb{E}[\mathbf{y}])$ を (3) 式に入れると $\mathbb{E}[\mathbf{A}(\mathbf{y} - \mathbb{E}[\mathbf{y}])(\mathbf{y} - \mathbb{E}[\mathbf{y}])^\top \mathbf{A}^\top]$ となり、定数の $\mathbf{A}$ と $\mathbf{A}^\top$ を期待値の外に出せることから従う。 $\mathbf{A}$ が 1 行 $\mathbf{a}^\top$ で $\text{Var}(\mathbf{y}) = \sigma^2 \mathbf{I}_n$ なら、(4) 式は $\sigma^2 \mathbf{a}^\top \mathbf{a} = \sigma^2 \sum_i a_i^2$ となり、独立な和の式に戻る。

例 3 (2 つのサイコロの目の和と差). 2 つのサイコロの目を縦に並べて $\mathbf{y} = [y_1, y_2]^\top$ とする。例 1 から、2 つの目は独立で、分散はどちらも約 2.92 なので、 $\text{Var}(\mathbf{y}) \approx 2.92 \mathbf{I}_2$ である。 $\mathbf{A} = [1 \ 1]$ とすると $\mathbf{A}\mathbf{y} = y_1 + y_2$ は目の和で、(4) 式から分散は $\mathbf{A}(2.92 \mathbf{I}_2) \mathbf{A}^\top = 2 \times 2.92 \approx 5.83$ になる。 $\mathbf{A} = [1 \ -1]$ として目の差 $y_1 - y_2$ をとっても、 $(-1)^2 = 1$ なので分散は同じ約 5.83 である(図 5)。引き算をしても、分散は足し算で増える。

□




図 5: 2 つのサイコロを 20 万回振ったときの、目の和と目の差の分布(人工データ)。どちらも分散は約 5.83

道具：射影と直交補空間

係数の不安定性の式に進む前に、もう 1 つの道具を用意する。予測値を、係数を通さずに $\mathbf{y}$ から直接書く行列である。第 1 回の正規方程式の答え $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ を、予測値の式 $\hat{\mathbf{y}} = \mathbf{X} \hat{\boldsymbol{\beta}}$ に代入すると

$$\hat{\mathbf{y}} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{H} \mathbf{y} \quad (5)$$

となる。 $\mathbf{y}$ の前に、 $\mathbf{X}$ だけでできた行列 $\mathbf{H}$ が残る。大きさを確かめると、 $n \times p$ の $\mathbf{X}$ 、 $p \times p$ の $(\mathbf{X}^\top \mathbf{X})^{-1}$ 、 $p \times n$ の $\mathbf{X}^\top$ を掛けたものなので、 $\mathbf{H}$ は $n \times n$ である (図 6)。隣り合う箱の内側の大きさ (p と p) がそろっているので、掛け算ができる。




図 6: 射影行列 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ の大きさ (概念図)。箱の縦は行数、横は列の数。赤は掛け算でそろった次元

定義 3 (射影行列). $\mathbf{y}$ に掛けると予測値を与える $n \times n$ の行列 $\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ を、射影行列 (projection matrix) (ハット行列) と呼ぶ。ここでは $\mathbf{H}$ と書く。 $\mathbf{H}$ は対称 ($\mathbf{H}^\top = \mathbf{H}$) かつ冪等 (idempotent) ($\mathbf{H}\mathbf{H} = \mathbf{H}$) である。

冪等であることは、行列の計算で確かめられる。

$$\mathbf{H}\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \underbrace{\mathbf{X}^\top \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}}_{\mathbf{I}_p} \mathbf{X}^\top = \mathbf{H}$$

真ん中の $\mathbf{X}^\top \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}$ が単位行列になるので、 $\mathbf{H}$ に戻る。対称であることは、 $(\mathbf{X}^\top \mathbf{X})^{-1}$ が対称であることから従う。 $\mathbf{H}$ は $\mathbf{X}$ だけで決まり、 $\mathbf{y}$ を含まない。

この計算を図で読む (図 7)。 $\mathbf{X}\boldsymbol{\beta} = \sum_j \beta_j \mathbf{x}_j$ は $\mathbf{X}$ の列の重み付き和なので、 $\boldsymbol{\beta}$ をどう選んでも、 $\mathbf{X}$ の列が張る平らな空間 (列空間 (column space)) の中にある。観測 $\mathbf{y}$ はふつうその外にある。最小二乗法は、列空間の中で $\mathbf{y}$ に最も近い点を選ぶ。平面の外から平面へ最も近い点は垂線の足であり、それが $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ である。 $\hat{\mathbf{y}}$ を $\mathbf{y}$ の正射影 (orthogonal projection)、すなわち列空間に落とした影と呼ぶ。冪等であることは、一度落とした影をもう一度落としても動かない、という意味になる。




図 7: 観測 y を、 X の列空間への影 $\hat{y} = Hy$ と、直交補空間(点線)への影 $(I-H)y = e$ に分ける(概念図)。残差 e は平面に垂直で、どの列とも直交する

垂線の足であることは、残差 $e = y - \hat{y}$ がどの列とも直交する、すなわち各列との内積が 0 であることを意味する。全部の列について並べると

$$X^T e = X^T y - X^T X(X^T X)^{-1} X^T y = 0$$

となる。これは第 1 回の正規方程式 $X^T X \hat{\beta} = X^T y$ を並べ替えたものにほかならない。勾配を 0 とおいて得た正規方程式は、残差がどの列とも直角という条件だったのである。

列空間のどの向きとも直交する向きを、すべて集めたものを、列空間の直交補空間(orthogonal complement)と呼ぶ。図 7 のように $n = 3$ で列が 2 本なら、列空間は平面、直交補空間はそれに垂直な 1 本の直線(点線)である。残差は、いつもこの直交補空間の中にある。 $e = y - Hy = (I-H)y$ なので、観測は

$$y = Hy + (I-H)y \quad (6)$$

と、列空間への影と直交補空間への影の和に分かれる。 $I-H$ も対称で、 $(I-H)(I-H) = I-2H+HH = I-H$ を満たす。直交補空間への射影行列である。また $H(I-H) = H-HH = O$ であり、直交補空間への影を列空間に落とすと原点の 1 点になる。

次元を数えておく。 n 次元の空間は、列空間の p 次元と直交補空間の $n-p$ 次元に分かれる。残差は直交補空間に閉じ込められているので、自由に動ける向きは $n-p$ 本しかない。誤差 ϵ のばらつきは n 本の向きに同じ σ^2 ずつ散らばっているが、残差に残るのはそのうち $n-p$ 本ぶんである。この数は、後でノイズの分散 σ^2 を残差から見積もるときに効く。

小さな例で確かめる。千歩ずつ 3 回歩き、歩いた距離が 650m・750m・850m だったとする。歩数(千歩)を $x = [1, 1, 1]^T$ 、距離(m)を $y = [650, 750, 850]^T$ とし、原点を通る直線 $y = \beta x$ を当てはめる。傾き β は千歩で進む距離である。 $X^T X = 3$ なので、 H はすべての成分が $1/3$ の 3×3 行列になる。 $\hat{y} = Hy$ は、どの行も

3 回の距離の平均 750m である。平均をもう一度平均しても 750m のままであり、これが冪等性にあたる。残差は $\mathbf{e} = [-100, 0, 100]^\top$ である。列 $[1, 1, 1]^\top$ と直交するとは、成分を足すと 0 になることであり、直交補空間は 3 次元のうちの「足すと 0」の 2 次元である。

係数の分散を導く

道具がそろったので、係数の不安定性を式にする。まず、何がばらつくのかを決めておく。モデルを

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \mathbb{E}[\boldsymbol{\varepsilon}] = 0, \quad \text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_n \quad (7)$$

とし、データ行列 $\mathbf{X}$ は固定されているとみなす。第 2 回ではノイズが正規分布 $N(0, \sigma^2)$ に従うと仮定したが、ここで使うのはその平均 0 と分散 σ^2 だけである。同じ説明変数の値を持つ行を集め直すたびに、目的変数だけがノイズのぶん変わる、という見方である。第 2 回の $y = g(x) + \varepsilon$ で、 g を線形の $\mathbf{X}\boldsymbol{\beta}$ とした場合にあたる。 $\mathbf{X}\boldsymbol{\beta}$ は定数なので、 $\text{Var}(\mathbf{y}) = \text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_n$ である。

最初はスカラーで考える。第 1 回の単回帰 $y_i = \beta x_i + e_i$ の解は $\hat{\beta} = \sum_i x_i y_i / \sum_i x_i^2$ だった。これは $w_i = x_i / \sum_i x_i^2$ を重みとする y_i の重み付きの和 $\sum_i w_i y_i$ であり、各 y_i は独立で分散 σ^2 なので、独立な和の分散から

$$\text{Var}(\hat{\beta}) = \sum_{i=1}^n w_i^2 \sigma^2 = \frac{\sigma^2 \sum_i x_i^2}{(\sum_i x_i^2)^2} = \frac{\sigma^2}{\sum_{i=1}^n x_i^2} \quad (8)$$

を得る。係数の不安定性は、ノイズの分散 σ^2 が大きいほど大きく、 x の二乗和が大きいほど小さい。標準偏差を真の係数で割ると

$$\frac{\sqrt{\text{Var}(\hat{\beta})}}{\beta} = \frac{\sigma}{\beta \sqrt{\sum_i x_i^2}} \quad (9)$$

となる。 x の平均が 0 なら、二乗和は $\sum_i x_i^2 = (n-1)s_x^2$ と、 x の標本分散 s_x^2 で書ける(第 1 回の定義)。分母の $\beta \sqrt{n-1} s_x$ は、 x の散らばりが y を動かす大きさ、つまり信号の大きさであり、分子の σ はノイズの大きさである。信号とノイズの比 $\beta \sqrt{n-1} s_x / \sigma$ を、SN 比(signal-to-noise ratio)と呼ぶ。(9) 式は、SN 比が高いほど係数が相対的によく決まることを表す。ノイズと真の係数を固定すると、SN 比を決めるのは x の標本分散と行の数だけになる。行を増やしても、 x を大きく散らばらせて取っても、係数は安定する。図 8 は人工データでこれを確かめたものである。真の傾きを 1、ノイズの標準偏差を 1 とし、20 個の x を (a) $[-1, 1]$ 、(b) $[-3, 3]$ から取り、平均を 0 にそろえた。標本分散は (a) 0.25、(b) 4.08 である。 x は固定したまま y だけを 30 回取り直して直線を引くと、(a) の直線は大きく扇状に開き、(b) ではほとんど重なる。SN 比は (a) で 2.2、(b) で 8.8 であり、(8) 式による傾きの標準偏差は、(a) で 0.46、(b) で 0.11 である。

同じ計算をベクトルで書いておく。 x_i と y_i を縦に並べたベクトルを $\mathbf{x}, \mathbf{y}$ とすると、 $\hat{\beta} = \mathbf{x}^\top \mathbf{y} / \mathbf{x}^\top \mathbf{x}$ である。重みを並べた $\mathbf{w} = \mathbf{x} / (\mathbf{x}^\top \mathbf{x})$ を使えば $\hat{\beta} = \mathbf{w}^\top \mathbf{y}$ と書ける。これは (4) 式で $\mathbf{A}$ が 1 行 $\mathbf{w}^\top$ の場合にあたり、

$$\text{Var}(\hat{\beta}) = \mathbf{w}^\top (\sigma^2 \mathbf{I}_n) \mathbf{w} = \sigma^2 \mathbf{w}^\top \mathbf{w} = \frac{\sigma^2}{\mathbf{x}^\top \mathbf{x}}$$

となる。成分で書けば (8) 式に戻る。

次に行列で書く。第 1 回の正規方程式の解 $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ は、 $\mathbf{A} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ とおけば $\mathbf{A} \mathbf{y}$ という形をしており、 $\mathbf{X}$ が固定なので $\mathbf{A}$ は定数の行列である。したがって (4) 式がそのまま使え、

$$\begin{aligned} \mathbb{E}[\hat{\beta}] &= \mathbf{A} \mathbb{E}[\mathbf{y}] = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} \beta = \beta \\ \text{Var}(\hat{\beta}) &= \mathbf{A} (\sigma^2 \mathbf{I}_n) \mathbf{A}^\top = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \end{aligned} \quad (10)$$

を得る。 $\mathbf{y}$ が確率変数なので、 $\hat{\beta}$ も確率変数である。 $\mathbf{y}$ から係数を計算するこの規則を推定量(estimator)と呼ぶ。冒頭で見た推定値は、推定量に手元の標本を入れた 1 つの値である。1 行目は、推定量はデータを取り直すたびにばらつくが、平均すれば真の値に一致すること(不偏性(unbiasedness))を表す。2 行目では、 $\mathbf{X}^\top \mathbf{X}$ が対称なのでその逆行列も対称であり $((\mathbf{X}^\top \mathbf{X})^{-1})^\top = ((\mathbf{X}^\top \mathbf{X})^\top)^{-1}$ 、 $\mathbf{A}^\top = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}$ となることを用いた。真ん中の $\mathbf{X}^\top \mathbf{X}$ が逆行列の 1 つと打ち消し合う。 $p = 1$ のとき $\mathbf{X}^\top \mathbf{X} = \mathbf{x}^\top \mathbf{x} = \sum_i x_i^2$ となり、(10) 式はベクトルの式、さらに (8) 式に戻る。(10) 式の対角の j 番目は係数 $\hat{\beta}_j$ の分散である。対角の外の (j, k) 成分は $\hat{\beta}_j$ と $\hat{\beta}_k$ の共分散で、2 つの係数が同じ向きに動くか逆向きに動くかを表す。これが第 2 回で開かなかった Variance の中身である。

(10) 式の σ^2 は未知なので、残差から見積もる。

$$\hat{\sigma}^2 = \frac{\|\mathbf{y} - \mathbf{X}\hat{\beta}\|_2^2}{n - p} \quad (11)$$

分子は第 1 回の残差平方和である(以下、RSS と略す)。 $\hat{\beta}$ はまさに残差平方和を最小にするように選ばれているので、残差は真の誤差 ϵ より短くなる。 n ではなく $n - p$ で割るのは、 n で割ると σ^2 を小さく見積もるからである。道具の節で見たとおり、残差は $n - p$ 次元の直交補空間に閉じ込められていて、自由に動ける向きは $n - p$ 本しかない。誤差 ϵ のばらつきは n 本の向きに同じ σ^2 ずつ散らばっているが、残差に残るのはそのうち $n - p$ 本ぶんとどまる。3 回の歩きなら $\hat{\sigma}^2 = (100^2 + 0^2 + 100^2)/(3 - 1)$ で、 $\hat{\sigma}$ は 100m になる。(11) 式を (10) 式に入れ、対角の j 番目の平方根を取った $\hat{\sigma} \sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}}$ は、1 回の当てはめから読める推定量 $\hat{\beta}_j$ の標準偏差である。これを標準誤差(standard error)と呼ぶ。

列が似ていると係数が不安定になる：共線性と VIF

では、何が (10) 式の $(\mathbf{X}^\top \mathbf{X})^{-1}$ を大きくするのか。列が 1 本なら、効くのは x の標本分散(SN 比)だけだった。列が 2 本以上になると、列どうしの関係も $\mathbf{X}^\top \mathbf{X}$ に入る。

まず人工データで見ておく(図 10)。50 行の 2 列を、相関がちょうど 0 の場合と 0.9 の場合について作った。真の係数は (1, 1)、ノイズの標準偏差は 1 とし、 $\mathbf{X}$ は固定したまま $\mathbf{y}$ を 300 回取り直した。相関 0 では推定値は★のまわりに丸く小さく散らばる。相関 0.9 では、左上から右下への斜めの向きに細長く伸びる。 $x_1 \approx x_2$ なら




図 8: 人工データで、 x を固定したまま y を 30 回取り直して引いた原点を通る直線(赤)。(a) x の標本分散が小さい、(b) 大きい。青は 1 回ぶんの点

$\beta_1 x_1 + \beta_2 x_2 \approx (\beta_1 + \beta_2) x_1$ なので、データは和 $\beta_1 + \beta_2$ はよく決めるが、その内訳はほとんど決められない。内訳のわずかな違いは当てはまりをほとんど変えないので、ノイズしだいで大きく動くのである。これを共線性と呼ぶ。いつも 2 人そろって押す車にたとえられる(図 9)。車の進み方から 2 人の力の合計はわかるが、1 人ずつの力はわからない。1 人で押す日があれば、2 人の力を分けられる。それが似ていない列である。冒頭の人工データで列 1 の係数の符号が逆になったのも、2 列の相関が 0.98 と高く、行が 12 しかないからである。

1 人ずつの力は？

B さん A さん




図 9: 共線性のたとえ(概念図)。いつも 2 人で押す車では、進み方から 2 人の力の合計はわかるが、内訳はわからない

これを式で確かめる。列が何本あっても、列 j の係数に効くのは、列 j のうち残りの列では説明できない部分である。列 j を、残りのすべての列(と切片)で最小二乗法により回帰し、その残差を $\tilde{x}_j$ と書く(図 11)。第 1 回の正規方程式は、残差がどの列とも直角(内積が 0)であることを言っていた。したがって $\tilde{x}_j$ は残りのすべての列と直角であり、 x_j から $\tilde{x}_j$ を引いた部分(残りの列の重み付き和)とも直角である。

道具の言葉で言えば、 $\tilde{x}_j$ は x_j を、残りの列(と切片)が張る平らな空間の直交補空間へ落とした影であり、残りの列への射影行列を $\mathbf{H}_{-j}$ として $\tilde{x}_j = (\mathbf{I} - \mathbf{H}_{-j})x_j$ と書ける(図 12)。平均を引いた x_j と、その平らな空間とのなす角を θ とすると、影の長さの二乗の割合が決定係数で $R_j^2 = \cos^2 \theta$ 、はみ出した部分の割合が $1 - R_j^2 = \sin^2 \theta$ である。似た列は平らな空間にほとんど寝ていて、 θ が小さく、はみ出した部分 $\tilde{x}_j$ が短い。

当てはめた式 $y = \sum_k \hat{\beta}_k x_k + e$ の両辺と $\tilde{x}_j$ の内積をとる。残りの列と残差 e (これもすべての列と直角なの




図 10: 人工データで $\mathbf{y}$ を 300 回取り直したときの係数の推定値。★は真の値。(a) 2 列の相関が 0、(b) 0.9




図 11: 列 2 を列 1 と切片で回帰したときの残差 $\tilde{x}_2$ (赤)。(a) 相関 0 の 2 列、(b) 相関 0.9 の 2 列(人工データ、50 行)。似た列では、ほかの列で説明できない部分がわずかしかなかった

で、列の重み付き和である $\tilde{\mathbf{x}}_j$ とも直角)との内積は 0 になり、 $\tilde{\mathbf{x}}_j^\top \mathbf{x}_j = \tilde{\mathbf{x}}_j^\top \tilde{\mathbf{x}}_j$ なので

$$\hat{\beta}_j = \frac{\tilde{\mathbf{x}}_j^\top \mathbf{y}}{\tilde{\mathbf{x}}_j^\top \tilde{\mathbf{x}}_j} \quad (12)$$

を得る。これはベクトルの節の $\hat{\beta} = \mathbf{w}^\top \mathbf{y}$ と同じ形で、重みが $\mathbf{w} = \tilde{\mathbf{x}}_j / (\tilde{\mathbf{x}}_j^\top \tilde{\mathbf{x}}_j)$ に替わっただけである。 $\tilde{\mathbf{x}}_j$ は $\mathbf{X}$ だけで決まる定数なので、(4) 式から

(a) 似ていない列 : $\theta = 60^\circ$ 、 $\text{VIF} = 1/\sin^2\theta = 1.3$ (b) 似た列 : $\theta = 26^\circ$ 、 $\text{VIF} = 1/\sin^2\theta = 5.3$



図 12: 共線性の幾何(概念図)。平均を引いた列 $\mathbf{x}_j$ (赤)を、残りの列が張る平面への影(青)と、直交補空間への影 $\tilde{\mathbf{x}}_j$ (緑)に分ける。平面とのなす角 θ が小さいほど $\tilde{\mathbf{x}}_j$ は短く、 $\text{VIF}_j = 1/\sin^2\theta$ は大きい

$$\text{Var}(\hat{\beta}_j) = \sigma^2 \mathbf{w}^\top \mathbf{w} = \frac{\sigma^2}{\tilde{\mathbf{x}}_j^\top \tilde{\mathbf{x}}_j} \quad (13)$$

となる。(8) 式の $\sum_i x_i^2$ を、ほかの列で説明できない部分の二乗和に替えた式であり、列が何本でも成り立つ。残る部分の二乗和は、補助の回帰の残差平方和である。第 1 回の決定係数の定義 $R^2 = 1 - (\text{残差平方和})/(\text{全体的変動})$ を、列 j を目的変数とみて当てはめると、残差平方和は $(1 - R_j^2) \sum_i (x_{ij} - \bar{x}_j)^2 = (1 - R_j^2)(n-1)s_j^2$ と書ける。ここで R_j^2 は列 j を残りの列で回帰した決定係数、 s_j^2 は列 j の標本分散である。似た列があるほど R_j^2 は 1 に近く、残る部分は小さく、係数の分散は大きくなる。SN 比でいえば、信号に使える x の散らばりが $\sqrt{1 - R_j^2}$ 倍に減るのである。身近な例でいえば、カフェのコーヒーの値段を、注いだ量とカップの大きさの 2 列で説明する場合である。大きいカップほど多く注ぐので、量をカップで説明する決定係数は 0.98 にもなり、量のうちカップで説明できない部分はほとんど残らない。値段の差が量によるのかカップによるのかは、ほとんど分けられない。

定義 4 (多重共線性と分散拡大係数). 説明変数の列どうしが、ほぼ 1 次式の関係にある状態を多重共線性 (multicollinearity) と呼ぶ。列 j を、残りのすべての列(と切片)で回帰したときの決定係数を R_j^2 とする。 $1/(1 - R_j^2)$ を、列 j の分散拡大係数 (variance inflation factor) (VIF) と呼ぶ。ここでは VIF_j と書く。係数の分散は

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{(n-1)s_j^2} \cdot \text{VIF}_j, \quad \text{VIF}_j = \frac{1}{1 - R_j^2} \quad (14)$$

と、似ていないときの分散と VIF の積に分かれる。(13) 式に $\tilde{\mathbf{x}}_j^\top \tilde{\mathbf{x}}_j = (n-1)s_j^2(1 - R_j^2)$ を入れたものである。角度で書けば $\text{VIF}_j = 1/\sin^2\theta$ である。

ここで、名前の似た 3 つの量を区別しておく。 r_{12} は 2 本の列の相関係数(第 1 回)、 R_j^2 は列 j を残りすべての列で回帰したときの決定係数、相関行列 $\mathbf{C}$ は列の組ごとの相関係数を並べた表である(r_{12} はその (1, 2) 成分)。列が 2 本なら $R_1^2 = r_{12}^2$ 、つまり決定係数は相関係数の 2 乗であり、倍率は $1/(1 - r_{12}^2)$ になる。 $r_{12} = 0.9$ なら $1/(1 - 0.81) \approx 5.3$ 倍、標準偏差にして約 2.3 倍である。列が何本でも、VIF は $\mathbf{C}^{-1}$ の対角成分に等しい

(後述の計算手順)。 R_j^2 を相関係数ではなく「残りすべての列で回帰した決定係数」で定めるのは、 $x_3 \approx x_1 + x_2$ のように 3 本以上が組み合わさって初めて成り立つ関係も捕まえるためである。このとき、どの 2 本の相関も中くらいでありながら、 R_3^2 は 1 に近くなりうる。

VIF は R_j^2 が小さいうちはほとんど 1 のままで、 $R_j^2 = 0.5$ でも 2 にすぎない。ところが 1 の近くでは急に大きくなり、0.9 で 10、0.95 で 20、0.99 で 100 になる(図 13)。標準誤差は分散の平方根なので $\sqrt{\text{VIF}_j}$ 倍になり、VIF が 10 なら約 3.2 倍である。VIF は倍率であって絶対量ではない。(14) 式の第 1 因子は、行を増やせば小さくなるので、VIF が大きくても行が十分多ければ係数は安定しうる。VIF の値は細かく比べず、 $1 \cdot 10 \cdot 100$ のどのあたりかと桁で読むのがよい。




図 13: 分散拡大係数 $\text{VIF}_j = 1/(1 - R_j^2)$ と、目安とされる $\text{VIF} = 10$ (赤の破線)

VIF は行列の計算で一度に求まる。

1. 切片の列を除いた各列を標準化し、 $\mathbf{Z}$ ($n \times p'$ 、 p' は切片を除いた列の数)を作る
2. 相関行列 $\mathbf{C} = \frac{1}{n-1} \mathbf{Z}^\top \mathbf{Z}$ を作る。その (j, k) 成分は、列 j と列 k の相関係数である
3. $\mathbf{C}^{-1}$ を求め、その対角成分を並べる。 $\text{VIF}_j = [\mathbf{C}^{-1}]_{jj}$ である

列が 2 本なら $\mathbf{C} = \begin{bmatrix} 1 & r_{12} \\ r_{12} & 1 \end{bmatrix}$ で、 $\mathbf{C}^{-1}$ の対角は $1/(1 - r_{12}^2)$ となり、2 列の倍率と一致する。第 1 回の計算手順では正規方程式を解くだけで、逆行列そのものは作らなかった。ここでは逆行列の対角そのものが答えなので、逆行列を作る。列 j を残りの列で回帰して $1/(1 - R_j^2)$ を p' 回計算しても同じ値になり、第 II 部でこれを確かめる。VIF は $\mathbf{X}$ だけで決まり、目的変数 $\mathbf{y}$ を見ていないので、データを集めた段階で「この列の組では係数は読めない」と先にわかる。

予測値の分散

予測値は係数から作るの、係数とともにばらつく。道具の節で見たとおり、手元の行の予測値は、(5) 式のとおり $\mathbf{y}$ の影 $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ である。冒頭の母集団と標本の見方を、この図に重ねる(図 14)。モデル (7) 式が正しければ、母集団の平均 $\mathbb{E}[\mathbf{y}] = \mathbf{X}\boldsymbol{\beta}$ は列空間の上にある。取り直すたびに $\mathbf{y}$ はそのまわりにばらつき、平面の外にも出る。それでも影 $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ は、いつも平面の上で $\mathbf{X}\boldsymbol{\beta}$ のまわりにばらつく。このばらつきを式で書く。

(5) 式は $\mathbf{y}$ に定数の行列を掛けた形なので、(4) 式と、 $\mathbf{H}$ が対称かつ幂等であることから




図 14: 母集団の平均 $\mathbf{X}\beta$ (★)は列空間の上にある(概念図)。取り直した $\mathbf{y}$ (赤、薄い点は平面の下)の影 $\hat{\mathbf{y}}$ (青)は、平面の上で $\mathbf{X}\beta$ のまわりにばらつく

$$\text{Var}(\hat{\mathbf{y}}) = \mathbf{H}(\sigma^2 \mathbf{I}_n) \mathbf{H}^\top = \sigma^2 \mathbf{H} \mathbf{H}^\top = \sigma^2 \mathbf{H} \quad (15)$$

を得る。 $\mathbf{H}$ の対角成分の和は、列空間の次元 p に等しい(3 回の歩きの例なら $1/3$ が 3 つで 1)。したがって、手元の行の予測値の分散を平均すると $\sigma^2 p/n$ になる。列を 1 本足すたびに、予測値の分散は平均で σ^2/n ずつ増える。第 2 回で、列を増やすと過学習(Variance 過多)に向かったのは、このためである。

手元に無い新しい点 $\mathbf{x}_0$ での予測 $\hat{y}_0 = \mathbf{x}_0^\top \hat{\beta}$ も、 $\hat{\beta}$ に定数の 1 行を掛けた形なので、(4) 式と (10) 式から

$$\text{Var}(\hat{y}_0) = \mathbf{x}_0^\top \text{Var}(\hat{\beta}) \mathbf{x}_0 = \sigma^2 \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0 \quad (16)$$

となる。 $p = 1$ なら $\sigma^2 x_0^2 / \sum_i x_i^2$ で、係数の分散 (8) 式が x_0^2 倍されて予測に移る。第 2 回のバイアス・バリエンス分解に戻ると、モデルの形が正しいとき、不偏性から $\mathbb{E}[\hat{y}_0] = \mathbf{x}_0^\top \beta$ なので Bias² は 0 であり、Variance はちょうど (16) 式である。新しい点での誤差の期待値は、 $\sigma^2 \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0 + \sigma^2$ に分かれる。第 2 回では 300 回の取り直しで数えた量が、線形回帰では式で計算できる。

逆行列が無いとき : 完全な共線と $p > n$

(14) 式の倍率 $1/(1 - R_j^2)$ は、 R_j^2 が 1 に近づくほど大きくなり、 $R_j^2 = 1$ では分母が 0 になる。このとき列 j はほかの列の 1 次式でぴったり書け、残る部分 $\tilde{\mathbf{x}}_j$ は 0 である。 $\mathbf{X}^\top \mathbf{X}$ は正則でなく(第 1 回)、逆行列は作れない。分散が「とても大きい」のではなく、係数が 1 つに決まらないのである。

目的関数の形で見るとわかりやすい(図 15)。相関 0.9 の 2 列では、目的関数の等高線は斜めに細長い楕円で、底(★)は 1 点に決まる。図 10 (b) の推定値が伸びた向きは、この楕円の長い向きと同じである。相関が 1、つまり $x_2 = x_1$ なら $\mathbf{X}\beta = (\beta_1 + \beta_2)\mathbf{x}_1$ となる。和が同じ組なら、どれもまったく同じ予測になる。等高線は平行な直

線になり、底は1点に定まらず、直線 $\beta_1 + \beta_2 = 2$ の全体になる。一方で、列空間は1本の直線のままなので、影 $\hat{y}$ は1つに決まっている。決まらないのは、影を列にどう割り振るかという係数の内訳だけである。




図 15: 2 列の場合の目的関数の等高線(人工データ)。(a) 相関 0.9 では底が 1 点(★)、(b) 相関 1 では底が直線(赤)になり、解が無数にある

行より列が多い場合($p > n$)は、列の中身によらず必ずこうなる。伝票の例がこれにあたる(図 16)。昼の伝票はラーメンと餃子で 1,100 円、夜の伝票はラーメンとライスで 1,000 円だった。伝票を行、品目を列、単品の値段を係数とみれば、2 行で係数を 3 個決めることになる。ラーメン 800 円・餃子 300 円・ライス 200 円でも、900 円・200 円・100 円でも、2 枚の合計にぴったり合う。式が 2 本で未知数が 3 個の連立方程式なので、解は無数にある。

		単品の値段の候補			
		ラーメン	餃子	ライス	伝票1・2
伝票1 (昼)	ラーメン + 餃子	800円	300円	200円	合う・合う
伝票2 (夜)	ラーメン + ライス	900円	200円	100円	合う・合う
		700円	400円	300円	合う・合う

…候補はいくらでも作れる

図 16: 列が行より多い例(概念図)。伝票 2 枚(行)から 3 品(列)の単品の値段(係数)は 1 つに決まらない

一般に、 $\mathbf{X}$ の階数(rank)(1 次独立な列の最大の本数)は行の数 n を超えられないので、 $p \times p$ の $\mathbf{X}^\top \mathbf{X}$ の階数も n 以下であり、 p に届かない。遺伝子の発現量のように、数十人について数千の列を測ったデータでは、これが普通の状態である。

行が列より多くても、ある列がほかの列の 1 次式でちょうど書けるとき(完全な多重共線性)は、 $\mathbf{X}^\top \mathbf{X}$ は正則

でない。よく起きるのは、カテゴリを k 本の 0/1 の列に展開し、切片の列も入れた場合である。 k 本の和がつねに 1 になり、切片の列と一致してしまう。

こうして (10) 式の $(\mathbf{X}^T \mathbf{X})^{-1}$ は、列が似ていれば大きく膨らむ。列が完全に重なったり行より多かったりすれば、そもそも存在しない。どちらの場合も、データだけでは無数の候補から 1 つを選べない。

第 II 部 実データ解析

第 II 部の進め方と予想

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、2 つの予想が立つ。第 1 に、係数の不安定性は、1 回の当てはめから計算した $\hat{\sigma}^2(\mathbf{X}^T \mathbf{X})^{-1}$ で読めるはずである。第 2 に、似た列の係数は VIF 倍に膨らんでばらつくと思込める。

カリフォルニア住宅データ

第 II 部では、第 I 部の場面で使ったカリフォルニア州の住宅のデータで、第 I 部の式を確かめる。Pace と Barry が 1990 年の米国国勢調査から作ったデータで、scikit-learn の `fetch_california_housing` で取得した。20,640 の地区のそれぞれについて、8 列の説明変数と、目的変数として住宅価格の中央値(10 万ドル単位)が記録されている。8 列は、世帯の所得の中央値(1 万ドル単位)、住宅の築年数の中央値、1 世帯あたりの部屋数と寝室数の平均、人口、1 世帯あたりの人数の平均、地区の中心の緯度と経度である。価格は 5 (50 万ドル)で打ち切られていて、992 地区がその値になっている。変数は元の単位のまま使い、切片の列を加えた 20,640 行 $\times$ 9 列のデータ行列 $\mathbf{X}$ を作る。第 I 部の場面では、20 通りの分割で寝室数の係数が所得の約 4 倍ばらついた。この差を第 I 部の式で説明できるかも、第 II 部で確かめる。

図 17 は 8 列の相関行列である。似た列の組が 2 つある。1 つは部屋数と寝室数で、相関は 0.85 である。寝室は部屋の一部なので、部屋の多い地区は寝室も多い。もう 1 つは緯度と経度で、相関は -0.92 である。カリフォルニア州は北西から南東へ斜めに伸びているので、北の地区ほど西にある。ほかの列どうしの相関は、所得と部屋数の 0.33 を除けば、どれも 0.3 より小さい。

計算の手続きと結果

計算の手続きは次のとおりである。データ行列 $\mathbf{X}$ で正規方程式を解いて係数 $\hat{\beta}$ を求め、残差平方和から (11) 式で $\hat{\sigma} = 0.724$ を得た ($n - p = 20,631$)。次に $(\mathbf{X}^T \mathbf{X})^{-1}$ を作り、(10) 式の対角から各係数の標準誤差を計算した。比べる相手として、第 I 部の人工データと同じ取り直しを実データの $\mathbf{X}$ で行った。 $\mathbf{X}$ はそのままにして、目的変数を $\mathbf{X}\hat{\beta}$ に標準偏差 $\hat{\sigma}$ の正規分布のノイズを足したものに置き換える。置き換えた目的変数で係数を当てはめ直すことを 1000 回くり返し、係数の標準偏差を求めた。さらに VIF を、第 I 部の手順どおり相関行列の逆行列の対角から求め、列ごとの回帰による $1/(1 - R_j^2)$ と比べた。最後に、20,640 地区を母集団とみ




図 17: カリフォルニア住宅データの 8 列の相関行列

なし、40 地区だけを選んで当てはめることを 20 回くり返した。どれも NumPy の行列計算と scikit-learn の LinearRegression で行った。

予想①を確かめる(図 18)。式から出した標準誤差と、作り直した 1000 回の係数の標準偏差は 8 列すべてで重なり、差は最大でも 3% である。差は 1000 回という有限の回数によるばらつきの範囲に収まっている。係数がどれだけ不安定かは、1 回の当てはめの $\hat{\sigma}^2(\mathbf{X}^\top \mathbf{X})^{-1}$ から読める。予想①どおりである。




図 18: 係数の不安定性。式 $\hat{\sigma}^2(\mathbf{X}^\top \mathbf{X})^{-1}$ による標準誤差(青)と、 $\mathbf{X}$ を固定して目的変数を 1000 回作り直したときの標準偏差(橙)。標準偏差 1 つぶんあたりに直してある

次に、(14) 式を確かめる(表 1)。相関行列の逆行列の対角と、列ごとの回帰による VIF は、差が最大 $8\text{e-}13$ で一

致した。列が互いに似ていなかったとした場合の標準誤差は $\hat{\sigma}/\sqrt{(n-1)s_j^2}$ である。実際の標準誤差をこれで割った比は、どの変数でも $\sqrt{\text{VIF}_j}$ に一致する(差は最大 9e-11)。寝室数の VIF は 7.0 で、標準誤差は似ていないときの 2.6 倍に膨らんでいる。

表 1: カリフォルニア住宅データの VIF。2 通りの計算と、 $\sqrt{\text{VIF}}$ 、実際の標準誤差と列が似ていないときの標準誤差の比

変数	VIF (逆行列の対角)	VIF (回帰)	$\sqrt{\text{VIF}}$	標準誤差の比
緯度	9.30	9.30	3.05	3.05
経度	8.96	8.96	2.99	2.99
部屋数	8.34	8.34	2.89	2.89
寝室数	6.99	6.99	2.64	2.64
所得	2.50	2.50	1.58	1.58
築年数	1.24	1.24	1.11	1.11
人口	1.14	1.14	1.07	1.07
世帯人数	1.01	1.01	1.00	1.00

結果の読み方

予想②を確かめる。図 19 は、作り直した 1000 回の係数を 2 つずつ組にして、同じ縮尺・同じ幅で描いたものである。似ていない所得と築年数の組 (a) は小さく丸くまとまる。似た部屋数と寝室数の組 (b) は、第 I 部の図 10 (b) と同じく、斜めに細長く伸びる。2 つの係数の相関は、作り直した 1000 回で -0.92、(10) 式の対角の外から計算して -0.92 である。片方が大きく出れば、もう片方が小さく出る。部屋数と寝室数をまとめた「広さ」の効き目はよく決まるが、その内訳は決まりにくいのである。第 I 部の場面で、寝室数の係数が分割しだいでばらついたのは、このためである。




図 19: $\mathbf{X}$ を固定して目的変数を 1000 回作り直したときの係数(標準偏差 1 つぶんあたり)。★は全地区で当てはめた値で、2 枚とも★から ± 0.05 の範囲を描いた。(a) 所得と築年数、(b) 部屋数と寝室数

VIF は桁で読む(図 20、表 1)。築年数・人口・世帯人数の VIF は 1 のあたり、所得は 2.5 で、係数はほぼ単独のときと同じ精度で決まっている。部屋数と寝室数、緯度と経度の 4 列は 7~9 で、10 のあたりにある。標準誤差にして約 3 倍に膨らんでいる。




図 20: カリフォルニア住宅データの 8 列の VIF。赤は 5 以上の列、破線は目安とされる $VIF = 10$

ただし、第 I 部で述べたとおり VIF は倍率であって絶対量ではない。(14) 式の第 1 因子 $\sigma^2/\{(n-1)s_j^2\}$ は行が多いほど小さく、このデータは 20,640 行ある。寝室数の係数は標準偏差 1 つぶんあたり 0.306、 ± 2 標準誤差は 0.027 で、3 倍に膨らんでもなお係数の大きさに比べて小さい。部屋数の係数は -0.266 で負であり、単回帰の係数 +0.071 とは符号が逆だが、これもばらつきでひっくり返る大きさではない。重回帰の係数は寝室数などを固定したときの効き目であり、単回帰とは別の問いに答えている(第 1 回)。部屋数を固定して寝室を増やすことは、ほかの部屋(居間など)を減らすことにあたる。共線性が問題になるのは、行の数に比べて VIF が大きいときである。このデータの 8 列の係数は、式の上では十分に決まっている。予想②のうち、似た列の係数が VIF 倍に膨らむことは当たったが、膨らんだ結果として係数が読めなくなる、という見込みは外れた。行の数が、膨らみを打ち消したのである。行の数の効き目は、行を減らしてみるとよくわかる(図 21)。20,640 地区を母集団とみなし、40 地区だけを標本として取り出して当てはめることを 20 回くり返した。部屋数の係数の 20 回の標準

偏差は、14,448 地区で当てはめた場面の分割では 0.029 だったが、40 地区では 0.55 と約 19 倍になり、20 回のうち 4 回は符号まで変わった。同じ列の組で同じように似ていても、行が少なれば係数は読めなくなる。ただし、ここでの取り直しは地区(行)そのものを選び直しており、 $\mathbf{X}$ も変わる。第 I 部の「 $\mathbf{X}$ を固定してノイズだけを取り直す」とは別の取り直し方であることに注意する。

母集団：20,640地区

標本（40地区）ごとの推定値




図 21: 20,640 地区を母集団とみなしたときの、40 地区の標本 3 つ(左、青・緑・赤)と、標本ごとの部屋数の係数の推定値(右、灰色は 20 回ぶん)。★は全地区での値、0 より右は符号が逆

このデータでわかったこと

第 II 部の結果をまとめる。予想①の、係数の不安定性は $\hat{\sigma}^2(\mathbf{X}^T \mathbf{X})^{-1}$ で読める、という見込みは、 $\mathbf{X}$ を固定して目的変数を作り直したときの標準偏差と重なり、当たった。予想②の、似た列の係数が VIF 倍に膨らむことも当たった。だが 20,640 地区という行の多さが膨らみを打ち消し、係数は符号まで変わることはなかった。VIF は倍率であって絶対量ではなく、行が少なければ同じ列の組でも係数は読めなくなる。実際、40 地区だけで当てはめると、部屋数の係数は 20 回のうち 4 回、符号が逆になった。

締め

発展：同じくらい当たるモデルと羅生門効果

本章の最後に、最近の研究の話題を 1 つ紹介する。図 15 では、列が完全に重なると目的関数の谷底が線になり、当てはまりのまったく同じ係数が無数にあった。完全には重ならなくても、似た 2 列では、当てはまりが「ほぼ」同じ係数の組がたくさんある。図 22 は、共線性の節と同じ作り方の 2 列(50 行)に目的変数を 1 組作り、訓練の二乗誤差が最小値から 5% 以内に収まる係数の組を塗ったものである。この集合を羅生門集合(Rashomon set)と呼ぶ。相関 0.9 では★のまわりの小さな楕円だが、相関 0.99 では細長く伸び、両方の軸をまたぐ。その中には、列 1 だけを使うモデル A (列 2 の係数は 0)と、列 2 だけを使うモデル B (列 1 の係数は 0)が含まれる。訓練の二乗誤差は、最小値に比べて A で 0.3%、B で 4.8% 大きいだけである。当てはまりで区別できないのに、「効く

のは列 1 か列 2 か」という説明は正反対になる。

同じくらい当たるモデルが多数あることを、羅生門効果(Rashomon effect)と呼ぶ。同じ出来事を語る人ごとに話が食い違う映画『羅生門』にちなんで、次の論文が名付けた。

Breiman, L. (2001). Statistical modeling: The two cultures. *Statistical Science*, 16(3), 199–231.

羅生門集合が大きいときには、単純で解釈しやすいモデルがその中に見つかりやすい。一方で、変数の重要度や予測の説明は、たまたま選んだ 1 つのモデルしだいで変わりうる。そこで、1 つのモデルを選んで終わりにせず、羅生門集合の全体を調べて、どの説明がどれだけ揺るがないかを確認する、という考え方が示されている。表形式のデータでノイズの多い問題を念頭に、この考え方を論じたのが次の論文である。

Rudin, C., Zhong, C., Semenova, L., Seltzer, M., Parr, R., Liu, J., Katta, S., Donnelly, J., Chen, H., & Boner, Z. (2024). Position: Amazing things come from having many good models. *Proceedings of the 41st International Conference on Machine Learning*, PMLR 235, 42783–42795.

本章で見た「影は 1 つ、内訳は無数」は、羅生門効果のもっとも単純な姿である。




図 22: 羅生門集合(人工データ、50 行)。訓練の二乗誤差が最小(★)から 5% 以内の係数の組(橙)。(左) 相関 0.9、(右) 相関 0.99。A は列 1 だけ、B は列 2 だけを使うモデル

まとめと次回の問い

本章の問いは、係数の不安定性は何で決まるのか、であった。答えは $\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$ の 1 本の式である。係数は $\mathbf{y}$ の線形変換なので、分散共分散行列の変換 (4) 式からこの式が出る。分散はノイズの分散に比例し、ノイズに比べて列の分散が大きいほど(SN 比が高いほど)小さく、列どうしが似ているほど大きい。その膨らみの倍率が VIF である。同じ道具から、予測値の分散 $\sigma^2 \mathbf{H}$ が導かれ、平均すると $\sigma^2 p/n$ になる。そして列が完全に重なるときや列が行より多いときには、逆行列そのものが無くなり、係数は 1 つに決まらない。カリフォルニア住宅データでは、 $\mathbf{X}$ を固定して目的変数を作り直したときの標準偏差が、式の標準誤差と一致した。部屋数と寝室数、緯度と経度の VIF が 10 のあたりにあることも確かめた。ただし行が多いので係数の符号は変わらず、40 地区に減らすと符号が変わった。

最後に、次回への問いを置く。列が似て $(\mathbf{X}^\top \mathbf{X})^{-1}$ の対角が大きくなり係数が非常に不安定になるとき、あるいは逆行列が存在しないとき、データだけでは無数の候補(図 15 の赤い線の上)から 1 つを選べない。当てはまりだけを見る限り、どの候補も同じだからである。候補から 1 つを選ぶには、データの外から何かを足す必要がある。では、何を足せばよいのだろうか。