第 3 回 係数の不安定性と最小二乗法の限界

変数(列)が似ているとき、変数(列)が多すぎるとき

本章の問いは、第 2 回の締めで残った「係数の不安定性は何で決まるのか」である。第 2 回と同じく目的変数を取り直して平均すると、最小二乗法の係数の分散は $\sigma^2[(\mathbf{X}^\top\mathbf{X})^{-1}]_{jj}$ で表される。この 1 本の式を読むと、変数(列)が似ているとき・変数(列)が行より多いときに最小二乗法が通用しなくなることがわかる。

第 I 部　理論

係数は分割しだいで変わる

線形回帰は、データ行列 $\mathbf{X}$ に係数を掛けて予測値を作る(第 1 回)。

$$\underbrace{\hat{\boldsymbol{y}}}_{\text{第 2 回}} = \mathbf{X}\ \underbrace{\hat{\boldsymbol{\beta}}}_{\text{本章}} \tag{1}$$

第 2 回は左辺の予測値 $\hat{\boldsymbol{y}}$ に着目し、それが新しいデータでどれだけ当たるかを測った。本章は右辺の係数 $\hat{\boldsymbol{\beta}}$ に着目する。

第 2 回の締めでは、訓練データとテストデータへの分け方を変えるだけでテストの数字がばらつくことを見て、なぜばらつくのかという問いを残した。本章では、別のデータで同じことを確かめるところから始める。使うのは、1990 年の米国国勢調査から作られたカリフォルニア州の住宅のデータである。20,640 の地区(数百世帯ずつの区画)について、地区の住宅価格の中央値と 8 列が記録されている。8 列は所得・築年数・1 世帯あたりの部屋数と寝室数・人口・1 世帯あたりの人数・緯度・経度である。8 列から住宅価格を予測する線形回帰を 20 回当てはめ直す。訓練 7 割・テスト 3 割への分け方だけを 20 通り変えると、テスト誤差(第 2 回と同じく、テストの行での二乗誤差の平均)は 0.515 から 0.554 まで動く(図 1 (a))。データもモデルも同じで、違うのはどの 14,448 地区で係数を決め、どの 6,192 地区で測ったかだけである。

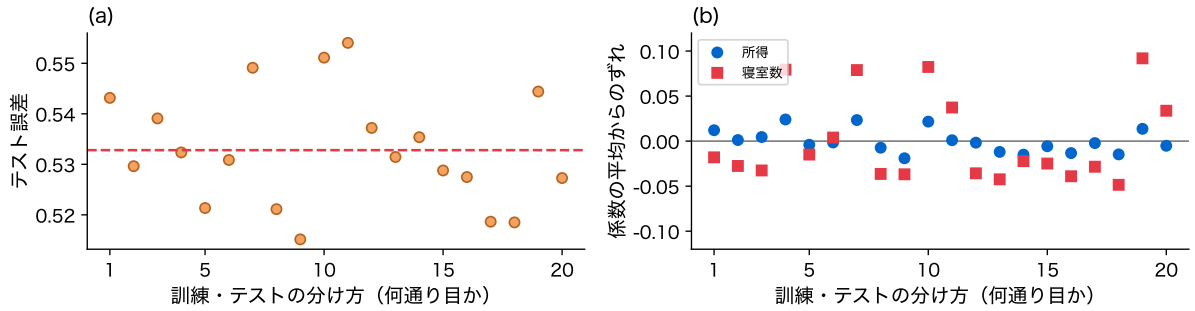


図 1: カリフォルニアの住宅価格の 8 列のモデルを、訓練・テストへの分け方だけを変えて 20 回当てはめ直した結果。(a) テスト誤差、(b) 所得(青)と寝室数(赤)の係数(標準偏差 1 つぶんあたり)の、20 通りの平均からのずれ

同じ 20 通りの分割で、決まった係数そのものを並べてみる(図 1 (b))。元の単位のままでは、変数ごとに係数の大きさを比べられない。そこで各変数の標準偏差を掛け、その変数が標準偏差 1 つぶん動いたときの価格(10 万ドル単位)の変化に直した。さらにばらつきだけを比べるために、20 通りの平均からのずれを描いた。所得の係数は平均 0.84 のまわりでほとんど動かないが、寝室数の係数は 0.27 から 0.41 まで動く。20 通りの標準偏差は所得が 0.013、寝室数が 0.048 で、約 4 倍の開きがある。寝室数は、1 世帯あたりの部屋数との相関が 0.85 と強い。同じ手続きで決めた係数の中に、ばらつきやすいものとばらつきにくいものがあるのである。

20,640 地区あれば、ばらついても結論までは変わらない。だが、行が少なく、列どうしが似ているとどうなるか。人工データで極端な例を見る(図 2)。よく似た 2 列(相関 0.98)を 12 行だけ作り、真の係数をどちらも 1 とした。$\mathbf{X}$ は固定したまま、目的変数だけをノイズのぶん 20 回取り直して当てはめると、列 1 の係数は-1.7 から 3.3 まで動き、20 回のうち 7 回は負になった。符号が変わると、「この列が増えると目的変数も増える」という読みが逆になる。係数のばらつきは、結論そのものを変えうる。

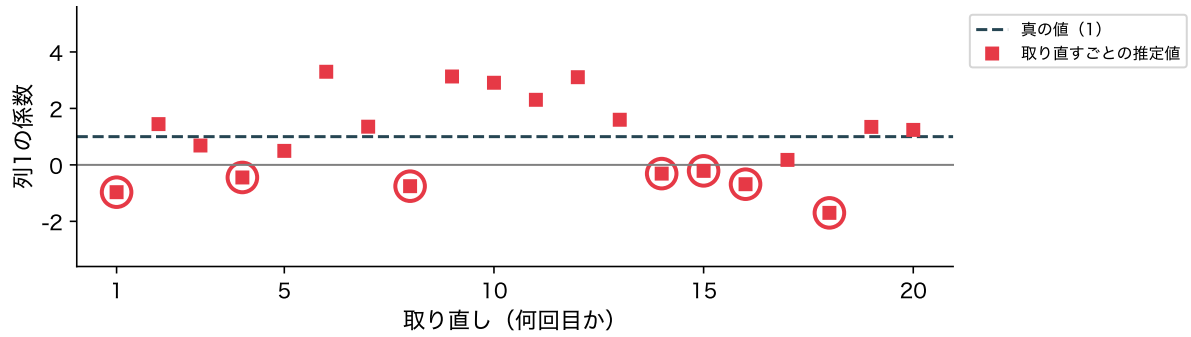


図 2: 似た 2 列(相関 0.98、12 行)の人工データで、$\mathbf{X}$ を固定して目的変数だけを 20 回取り直したときの列 1 の係数。破線は真の値 1、○は符号が逆になった回

ここで、データの見方を 1 つ切り替える(図 3)。データを生み出すしくみ全体を母集団(population)、そこから取り出して手元に置いたデータを標本(sample)と呼ぶ。線形回帰では、母集団を $\boldsymbol{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ と考える。$\mathbf{X}$ は固定し、取り出すたびにノイズ $\boldsymbol{\varepsilon}$ の出方だけが変わる。標本から計算した係数を推定値(estimate)と呼ぶ。標本

を限りなく取り直すと、推定値は 1 つの分布をつくる。図 2 の 20 個の点は、その分布から 20 回取り出したものである。

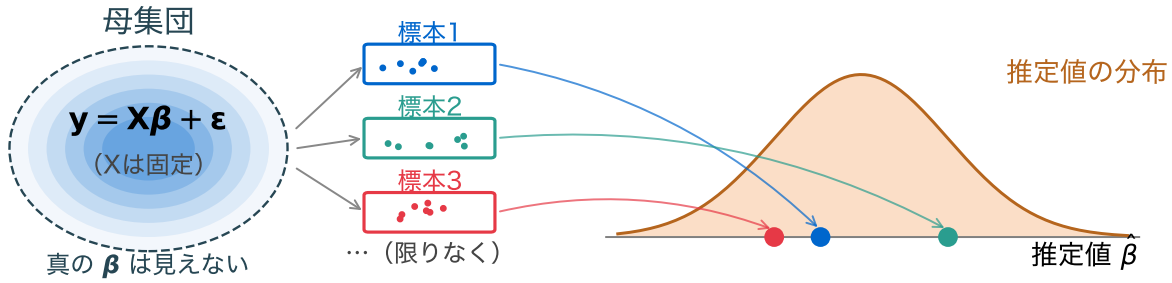


図 3: 母集団と標本と推定値(概念図)。母集団 $\boldsymbol{y} = \mathbf{X}\beta + \varepsilon$（$\mathbf{X}$ は固定)から標本を取り出すたびに推定値が 1 つ決まり、限りなく取り直すと推定値の分布になる。真の β は見えない

困りごとはほかにもある。伝票 2 枚からラーメン・餃子・ライスの単品の値段を割り出そうとすると、2 枚の合計に合う値段の組はいくらでも作れる。2 つとも、データから決めた係数が頼りにならない場面である。

本章の問いは 1 つである。係数の不安定性は、何で決まるのか。まず、第 2 回と同じく目的変数を取り直して平均し、最小二乗法の係数 $\hat{\beta}_j$ の分散が $\sigma^2[(\mathbf{X}^\top\mathbf{X})^{-1}]_{jj}$ で表されることを導く。次に、射影行列の道具を用意し、未知の σ^2 を残差から見積もる。そのうえで、この 1 本の式から、列どうしが似ていると係数が不安定になること(多重共線性)と、列が行より多いと係数がそもそも決まらないことを読む。

第 2 回では汎化誤差を分け、訓練データの取り直しに対する予測のばらつきを Variance と呼んだ。ただし、その中身は開かなかった。本章は、同じ平均の数え方で、その中身を線形回帰の係数について開く。「モデル × 推定法」の地図でいえば、線形回帰 × 最小二乗法のマスから動かない。そのマスの推定がどこで頼りにならなくなるか、という境目を見ることになる。

ふだんの分析で手に入るのは、このような標本 1 つだけである。そこから計算した推定値は見えるが、真の係数 β も推定値の分布も見えない。手元のデータそのものを要約する見方を記述統計(descriptive statistics)と呼ぶ。平均や相関係数、第 1 回の当てはめはこちらにあたる。手元のデータを取り直しうるものの 1 回分とみて、その背後とばらつきを推し量る見方を推測統計(inferential statistics)と呼ぶ。本章で求める係数のばらつきと標準誤差は、推測統計の道具である。

係数の分散を導く

では、係数の不安定性を式にする。第 2 回では、訓練データを 300 回取り直して平均をとり、Variance を数えた。本章も同じ数え方をする。データ行列 $\mathbf{X}$ を固定し、目的変数だけを R 回取り直して係数を求め、その平均と散らばりを調べる。違うのは、R を限りなく大きくしたときの行き先を、式で求めることである。なお、冒頭の場面では分割を変えたので、係数を決める行、つまり $\mathbf{X}$ も変わっていた。ここでは話を簡単にするため、$\mathbf{X}$ を固定して目的変数だけを取り直す。

まず、何がばらつくのかを決めておく。$\mathbf{X}$ は $n \times p$ で(p は、切片の列があればそれも数えた列の数)、列は 1 次独立、つまりどの列もほかの列の 1 次式では書けないとする。このとき $\mathbf{X}^\top\mathbf{X}$ は逆行列をもつ。そうでない場合は、最後の節で扱う。r 回目に取り直した目的変数を

$$\boldsymbol{y}^{(r)} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}^{(r)}, \qquad r = 1, \dots, R \tag{2}$$

とする。$\mathbf{X}$ と真の係数 $\boldsymbol{\beta}$ は変わらず、取り直すたびに変わるのは誤差 $\boldsymbol{\varepsilon}^{(r)} = [\varepsilon_1^{(r)}, \dots, \varepsilon_n^{(r)}]^\top$ だけである。第 2 回の $y = g(x) + \varepsilon$ で、g を線形の $\mathbf{X}\boldsymbol{\beta}$ とした場合にあたる。誤差には、次の 3 つの平均の行き先だけを仮定する。

$$\frac{1}{R}\sum_{r=1}^{R} \varepsilon_i^{(r)} \to 0, \qquad \frac{1}{R}\sum_{r=1}^{R} (\varepsilon_i^{(r)})^2 \to \sigma^2, \qquad \frac{1}{R}\sum_{r=1}^{R} \varepsilon_i^{(r)}\varepsilon_{i'}^{(r)} \to 0 \quad (i \neq i') \tag{3}$$

矢印は $R \to \infty$ での行き先を表す。1 つ目は、誤差が平均して 0 であること、2 つ目は、誤差の二乗の平均がどの行でも同じ σ^2 であることを表す。3 つ目は、別の行の誤差どうしが無関係であることを表す。第 2 回のように、行ごとに別々に正規分布 $N(0, \sigma^2)$ から誤差を作れば、3 つとも成り立つ。3 つ目は、図 4 で確かめられる。1 行目と 2 行目の誤差を 300 回取り直して組を点にすると、点は原点のまわりのどの向きにも同じように散らばる。積 $\varepsilon_1^{(r)}\varepsilon_2^{(r)}$ は右上と左下で正、左上と右下で負になり、足すと打ち消し合う。積の平均は-0.08 で、0 に近い。同じ行どうしの二乗の平均は 0.94 で、$\sigma^2 = 1$ に近い。

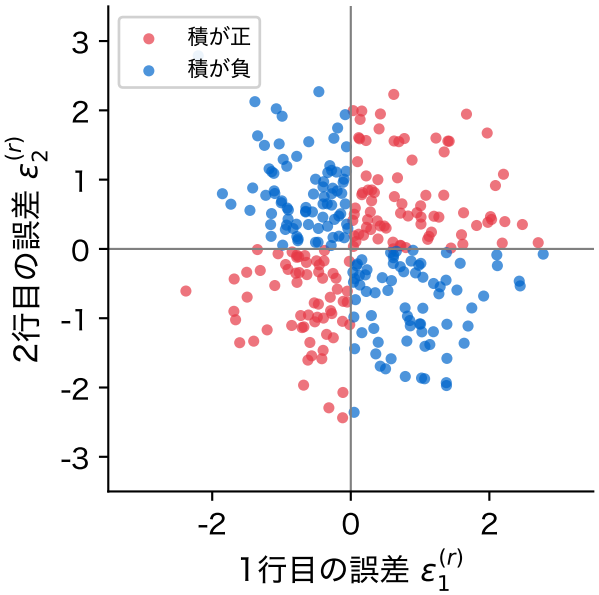


図 4: 1 行目と 2 行目の誤差($\sigma = 1$)を 300 回取り直した組(人工データ)。積が正の組(赤)と負の組(青)が打ち消し合い、積の平均は 0 に近い

第 1 回の正規方程式の解は $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\boldsymbol{y}$ であった。$\mathbf{A} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$ とおくと、$\hat{\boldsymbol{\beta}} = \mathbf{A}\boldsymbol{y}$ と書ける。$\mathbf{A}$ は $\mathbf{X}$ だけで決まる $p \times n$ の行列で、取り直しても変わらない。$\boldsymbol{y}$ から係数を計算するこの規則を推定量

(estimator)と呼ぶ。推定量は、取り直すたびに値が変わる。冒頭で見た推定値は、推定量に手元の標本を入れた 1 つの値である。

以下の導出の要は、

$$\mathbf{A}\mathbf{X} = (\mathbf{X}^\top \mathbf{X})^{-1}\mathbf{X}^\top \mathbf{X} = \mathbf{I}_p \tag{4}$$

の 1 本である。r 回目の目的変数 (2) 式を $\hat{\boldsymbol{\beta}} = \mathbf{A}\boldsymbol{y}$ に代入し、$\mathbf{A}$ を分配して (4) 式を使うと

$$\hat{\boldsymbol{\beta}}^{(r)} = \mathbf{A}\mathbf{X}\boldsymbol{\beta} + \mathbf{A}\boldsymbol{\varepsilon}^{(r)} = \boldsymbol{\beta} + \mathbf{A}\boldsymbol{\varepsilon}^{(r)} \tag{5}$$

となる。係数は、真の値と、誤差に $\mathbf{A}$ を掛けたものに分かれる。係数の揺れは $\mathbf{A}\boldsymbol{\varepsilon}^{(r)}$ そのものである。

(5) 式を $r = 1, \dots, R$ について平均する。$\boldsymbol{\beta}$ は r によらないのでそのまま残る。$\mathbf{A}$ も r によらないので、和の外に出せる。

$$\frac{1}{R}\sum_{r=1}^{R} \hat{\boldsymbol{\beta}}^{(r)} = \boldsymbol{\beta} + \mathbf{A}\Big(\frac{1}{R}\sum_{r=1}^{R} \boldsymbol{\varepsilon}^{(r)}\Big) \;\to\; \boldsymbol{\beta}$$

括弧の中のベクトルは、(3) 式の 1 つ目により成分ごとに 0 へ近づく。推定量は取り直すたびにばらつくが、平均すれば真の値に一致する。推定量の平均の行き先が真の値に一致することを、不偏性(unbiasedness)と呼ぶ。図 3 でいえば、推定値の分布の山の中心が、見えない真の値に重なるということである。

次に、真の値のまわりの散らばりを、係数 1 つずつ求める。$\mathbf{A}$ の j 行目を $\boldsymbol{a}_j^\top = [a_{j1}, \dots, a_{jn}]$ とすると、(5) 式の j 番目の成分は

$$\hat{\beta}_j^{(r)} - \beta_j = \boldsymbol{a}_j^\top \boldsymbol{\varepsilon}^{(r)} = \sum_{i=1}^{n} a_{ji}\varepsilon_i^{(r)}$$

である。その二乗を展開すると、同じ行どうしの項と、別の行どうしの交差項に分かれる。

$$\Big(\sum_i a_{ji}\varepsilon_i\Big)^2 = \sum_i a_{ji}^2\varepsilon_i^2 + \sum_{i\neq i'} a_{ji}a_{ji'}\varepsilon_i\varepsilon_{i'}$$

これを R 回について平均し、r についての和と i についての和の順を入れ替えると

$$\frac{1}{R}\sum_{r=1}^{R}(\hat{\beta}_j^{(r)} - \beta_j)^2 = \sum_i a_{ji}^2\Big(\frac{1}{R}\sum_{r=1}^{R}(\varepsilon_i^{(r)})^2\Big) + \sum_{i\neq i'} a_{ji}a_{ji'}\Big(\frac{1}{R}\sum_{r=1}^{R}\varepsilon_i^{(r)}\varepsilon_{i'}^{(r)}\Big) \;\to\; \sigma^2\sum_i a_{ji}^2 = \sigma^2\boldsymbol{a}_j^\top\boldsymbol{a}_j$$

となる。1 つ目の括弧は (3) 式の 2 つ目により σ^2 に、2 つ目の括弧は 3 つ目により 0 に近づく。交差項が消えるのは、図 4 で見たとおり、別の行の誤差の積が正と負で打ち消し合うからである。

定義 1 (係数の分散)**.** 目的変数を限りなく取り直したときの、推定量と真の値の差の二乗の平均の行き先

$$\mathbb{V}\mathrm{ar}(\hat{\beta}_j) = \lim_{R\to\infty} \frac{1}{R}\sum_{r=1}^{R}\big(\hat{\beta}_j^{(r)} - \beta_j\big)^2$$

を、係数 $\hat{\beta}_j$ の分散(variance)と呼ぶ。その平方根を、係数の標準偏差と呼ぶ。

不偏な推定量では、真の値のまわりの散らばりは、平均のまわりの散らばりと同じになる。R 回の平均を $\bar{\beta}_{j,R} = \frac{1}{R}\sum_r \hat{\beta}_j^{(r)}$ とすると、$\frac{1}{R}\sum_r(\hat{\beta}_j^{(r)} - \bar{\beta}_{j,R})^2 = \frac{1}{R}\sum_r(\hat{\beta}_j^{(r)} - \beta_j)^2 - (\bar{\beta}_{j,R} - \beta_j)^2$ が成り立ち、最後の項は不偏性から 0 に近づくからである。第 2 回の Variance も、取り直した予測の平均のまわりの二乗の平均だった。定義 1 は、同じ数え方を係数に当てたものである。上の計算から $\mathbb{V}\mathrm{ar}(\hat{\beta}_j) = \sigma^2 \boldsymbol{a}_j^\top \boldsymbol{a}_j$ であり、$\boldsymbol{a}_j^\top \boldsymbol{a}_j$ は $\mathbf{A}\mathbf{A}^\top$ の (j,j) 成分である。$\mathbf{X}^\top\mathbf{X}$ は対称なので、その逆行列も対称であり($((\mathbf{X}^\top\mathbf{X})^{-1})^\top = ((\mathbf{X}^\top\mathbf{X})^\top)^{-1}$)、$\mathbf{A}^\top = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}$ となる。よって

$$\mathbf{A}\mathbf{A}^\top = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1} = (\mathbf{X}^\top\mathbf{X})^{-1}$$

で、真ん中の $\mathbf{X}^\top\mathbf{X}$ が逆行列の 1 つと打ち消し合う。こうして

$$\mathbb{V}\mathrm{ar}(\hat{\beta}_j) = \sigma^2\big[(\mathbf{X}^\top\mathbf{X})^{-1}\big]_{jj} \tag{6}$$

を得る。係数の不安定性は、ノイズの大きさ σ^2 と、$(\mathbf{X}^\top\mathbf{X})^{-1}$ の対角で決まる。これが、第 2 回で開かなかった Variance の中身を、係数について開いたものである。

(6) 式を、列が 1 本の場合で読んでおく。原点を通る直線 $y = \beta x$ なら、$\mathbf{X} = \boldsymbol{x}$ で $\mathbf{X}^\top\mathbf{X} = \sum_i x_i^2$ は 1 つの数である。したがって

$$\mathbb{V}\mathrm{ar}(\hat{\beta}) = \frac{\sigma^2}{\sum_{i=1}^n x_i^2} \tag{7}$$

である。係数の不安定性は、ノイズの分散 σ^2 が大きいほど大きく、x の二乗和が大きいほど小さい。二乗和は、x を広く散らばらせて取るほど、行が多いほど大きい。標準偏差を真の係数で割ると

$$\frac{\sqrt{\mathbb{V}\mathrm{ar}(\hat{\beta})}}{|\beta|} = \frac{\sigma}{|\beta|\sqrt{\sum_i x_i^2}} \tag{8}$$

となる。分母の $|\beta|\sqrt{\sum_i x_i^2}$ は、x の散らばりが y を動かす大きさ、つまり信号の大きさであり、分子の σ はノイズの大きさである。信号とノイズの比 $|\beta|\sqrt{\sum_i x_i^2}/\sigma$ を、SN 比(signal-to-noise ratio)と呼ぶ。(8) 式は、SN 比が高いほど係数が相対的によく決まることを表す。ノイズと真の係数を固定すると、SN 比を決めるのは x の二乗和、つまり x の散らばりと行の数だけになる。行を増やしても、x を大きく散らばらせて取っても、係数

は安定する。図 5 は人工データでこれを確かめたものである。真の傾きを 1、ノイズの標準偏差を 1 とし、20 個の x を (a) $[-1, 1]$、(b) $[-3, 3]$ から取り、平均を 0 にそろえた。二乗和は (a) 4.7、(b) 77.5 である。x は固定したまま y だけを 30 回取り直して直線を引くと、(a) の直線は大きく扇状に開き、(b) ではほとんど重なる。SN 比は (a) で 2.2、(b) で 8.8 であり、(7) 式による傾きの標準偏差は、(a) で 0.46、(b) で 0.11 である。

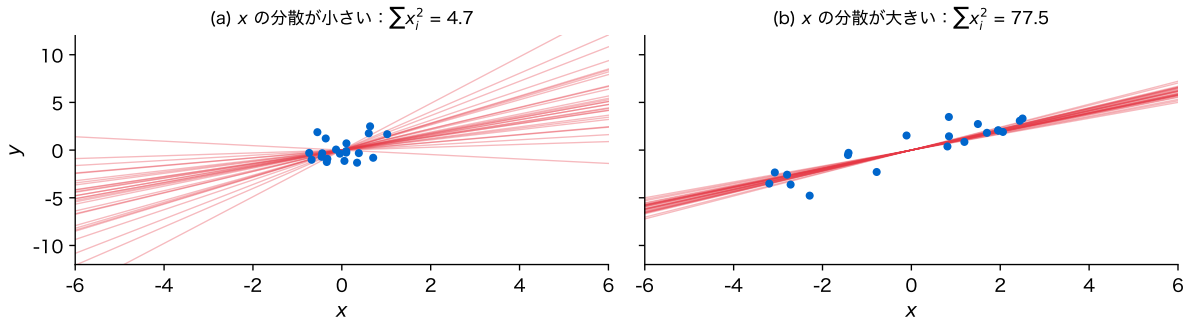


図 5: 人工データで、x を固定したまま y を 30 回取り直して引いた原点を通る直線(赤)。(a) x の標本分散が小さい、(b) 大きい。青は 1 回ぶんの点

道具：射影と直交補空間

係数の分散 (6) 式には、誤差の大きさ σ^2 が入っている。誤差そのものは見えないので、見える残差から σ^2 を見積もりたい。そのために、道具を 1 つ用意する。予測値を、係数を通さずに $\boldsymbol{y}$ から直接書く行列である。第 1 回の正規方程式の答え $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{y}$ を、予測値の式 $\hat{\boldsymbol{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ に代入すると

$$\hat{\boldsymbol{y}} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{y} = \mathbf{H}\boldsymbol{y} \tag{9}$$

となる。$\boldsymbol{y}$ の前に、$\mathbf{X}$ だけでできた行列 $\mathbf{H}$ が残る。大きさを確かめると、$n \times p$ の $\mathbf{X}$、$p \times p$ の $(\mathbf{X}^\top \mathbf{X})^{-1}$、$p \times n$ の $\mathbf{X}^\top$ を掛けたものなので、$\mathbf{H}$ は $n \times n$ である(図 6)。隣り合う箱の内側の大きさ(p と p)がそろうので、掛け算ができる。

定義 2 (射影行列)**.** $\boldsymbol{y}$ に掛けると予測値を与える $n \times n$ の行列 $\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ を、射影行列(projection matrix)(ハット行列)と呼ぶ。ここでは $\mathbf{H}$ と書く。$\mathbf{H}$ は対称($\mathbf{H}^\top = \mathbf{H}$)かつ冪等(idempotent)($\mathbf{HH} = \mathbf{H}$)である。

冪等であることは、行列の計算で確かめられる。

$$\mathbf{HH} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \underbrace{\mathbf{X}^\top \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}}_{\mathbf{I}_p} \mathbf{X}^\top = \mathbf{H}$$

真ん中の $\mathbf{X}^\top \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}$ が単位行列になるので、$\mathbf{H}$ に戻る。対称であることは、次のように確かめられる。$\mathbf{X}^\top \mathbf{X}$ は対称なので、その逆行列も対称である($((\mathbf{X}^\top \mathbf{X})^{-1})^\top = ((\mathbf{X}^\top \mathbf{X})^\top)^{-1} = (\mathbf{X}^\top \mathbf{X})^{-1}$)。したがって $\mathbf{H}^\top = \mathbf{X}((\mathbf{X}^\top \mathbf{X})^{-1})^\top \mathbf{X}^\top = \mathbf{H}$ である。$\mathbf{H}$ は $\mathbf{X}$ だけで決まり、$\boldsymbol{y}$ を含まない。

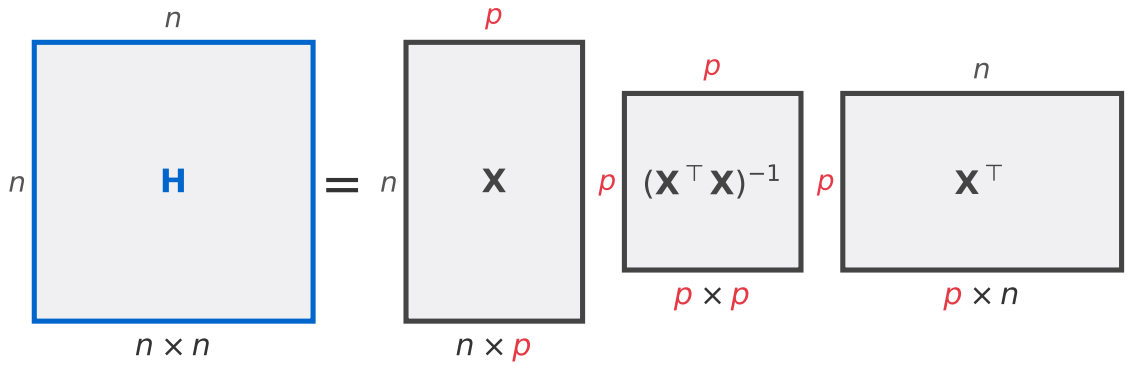


図 6: 射影行列 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$ の大きさ(概念図)。箱の縦は行の数、横は列の数。赤は掛け算でそろう次元

この計算を図で読む(図 7)。$\mathbf{X}\boldsymbol{\beta} = \sum_j \beta_j \boldsymbol{x}_j$ は $\mathbf{X}$ の列の重み付き和なので、$\boldsymbol{\beta}$ をどう選んでも、$\mathbf{X}$ の列が張る平らな空間(列空間(column space))の中にある。観測 $\boldsymbol{y}$ はふつうその外にある。最小二乗法は、列空間の中で $\boldsymbol{y}$ に最も近い点を選ぶ。平面の外の点から平面へ最も近い点は垂線の足であり、それが $\hat{\boldsymbol{y}} = \mathbf{H}\boldsymbol{y}$ である。$\hat{\boldsymbol{y}}$ を $\boldsymbol{y}$ の正射影(orthogonal projection)、すなわち列空間に落とした影と呼ぶ。冪等であることは、一度落とした影をもう一度落としても動かない、という意味になる。

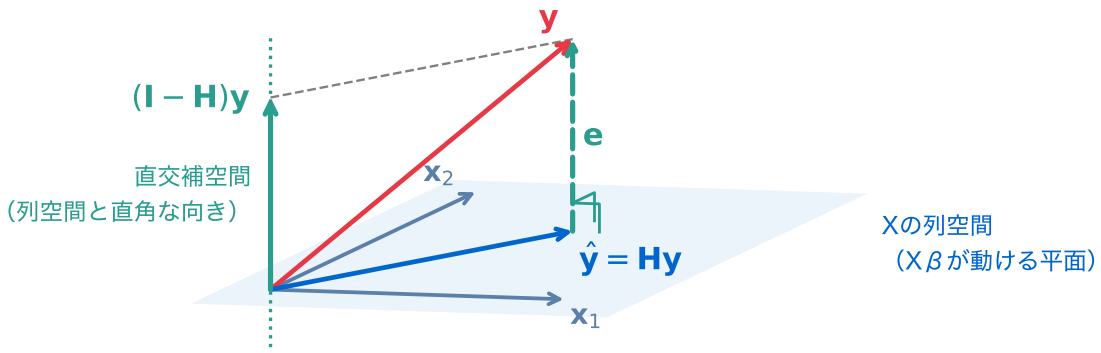


図 7: 観測 $\boldsymbol{y}$ を、$\mathbf{X}$ の列空間への影 $\hat{\boldsymbol{y}} = \mathbf{H}\boldsymbol{y}$ と、直交補空間(点線)への影 $(\mathbf{I} - \mathbf{H})\boldsymbol{y} = \boldsymbol{e}$ に分ける(概念図)。残差 $\boldsymbol{e}$ は平面に垂直で、どの列とも直交する

垂線の足であることは、残差 $\boldsymbol{e} = \boldsymbol{y} - \hat{\boldsymbol{y}}$ がどの列とも直交する、すなわち各列との内積が 0 であることを意味する。全部の列について並べると

$$\mathbf{X}^\top\boldsymbol{e} = \mathbf{X}^\top\boldsymbol{y} - \mathbf{X}^\top\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\boldsymbol{y} = 0$$

となる。これは第 1 回の正規方程式 $\mathbf{X}^\top\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^\top\boldsymbol{y}$ を並べ替えたものにほかならない。勾配を 0 とおいて得た正規方程式は、残差がどの列とも直角という条件だったのである。

列空間のどの向きとも直交する向きを、すべて集めたものを、列空間の直交補空間(orthogonal complement)と呼ぶ。図 7 のように $n = 3$ で列が 2 本なら、列空間は平面、直交補空間はそれに垂直な 1 本の直線(点線)である。残差は、いつもこの直交補空間の中にある。$\boldsymbol{e} = \boldsymbol{y} - \mathbf{H}\boldsymbol{y} = (\mathbf{I} - \mathbf{H})\boldsymbol{y}$ なので、観測は

$$\boldsymbol{y} = \mathbf{H}\boldsymbol{y} + (\mathbf{I} - \mathbf{H})\boldsymbol{y} \tag{10}$$

と、列空間への影と直交補空間への影の和に分かれる。$\mathbf{I}-\mathbf{H}$ も対称で、$(\mathbf{I}-\mathbf{H})(\mathbf{I}-\mathbf{H}) = \mathbf{I}-2\mathbf{H}+\mathbf{H}\mathbf{H} = \mathbf{I}-\mathbf{H}$ を満たす。さらに $\mathbf{H}\mathbf{X} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X} = \mathbf{X}$ なので $(\mathbf{I} - \mathbf{H})\mathbf{X} = \mathbf{O}$($\mathbf{O}$ はすべて 0 の行列)であり、$\mathbf{I} - \mathbf{H}$ を掛けると列空間の向きは消える。$(\mathbf{I} - \mathbf{H})\boldsymbol{y}$ はどの列とも直角なので、$\mathbf{I} - \mathbf{H}$ は直交補空間への射影行列である。

次元を数えておく。n 次元の空間は、列空間の p 次元と直交補空間の $n - p$ 次元に分かれる。残差は直交補空間に閉じ込められているので、自由に動ける向きは $n - p$ 本しかない。誤差 $\boldsymbol{\varepsilon}$ がどの向きにも同じ大きさで散らばるなら、残差に残るのはそのうち $n - p$ 本ぶんである。この数は、後でノイズの分散 σ^2 を残差から見積もるときに効く。

小さな例で確かめる。1 千歩・2 千歩・3 千歩の 3 回歩き、歩いた距離が 950m・1100m・2450m だったとする。歩数(千歩)を $\boldsymbol{x} = [1, 2, 3]^\top$、距離(m)を $\boldsymbol{y} = [950, 1100, 2450]^\top$ とし、原点を通る直線 $y = \beta x$ を当てはめる。傾き β は千歩で進む距離である。列は 1 本なので $\mathbf{X}^\top\mathbf{X} = \boldsymbol{x}^\top\boldsymbol{x} = 14$ であり、$\mathbf{H} = \boldsymbol{x}\boldsymbol{x}^\top/14$ の (i, i') 成分は $x_i x_{i'}/14$ になる。成分は行ごとに違い、対角は 1/14、4/14、9/14 である。$\hat{\boldsymbol{y}} = \mathbf{H}\boldsymbol{y}$ は、傾き $\hat{\beta} = \boldsymbol{x}^\top\boldsymbol{y}/14 = 750$ の直線の上の点 $[750, 1500, 2250]^\top$ になる。この予測値にもう一度 $\mathbf{H}$ を掛けても、直線の上の点は動かない。これが冪等性にあたる。残差は $\boldsymbol{e} = [200, -400, 200]^\top$ で、$\boldsymbol{x}^\top\boldsymbol{e} = 200 - 800 + 600 = 0$ と、列と直交している。直交補空間は、3 次元のうちで $\boldsymbol{x}$ と直角な 2 次元の向き全体である。

ノイズの大きさを見積もる:標準誤差

(6) 式の σ^2 は誤差の大きさで、未知である。誤差 $\boldsymbol{\varepsilon}$ そのものは見えず、見えるのは残差 $\boldsymbol{e} = \boldsymbol{y} - \hat{\boldsymbol{y}}$ である。そこで、残差平方和(以下、RSS と略す)を何かで割って σ^2 を見積もる。何で割れば、平均して σ^2 になるかを、係数の分散と同じ平均の論法で求める。

まず、残差を誤差だけで書く。道具の節で見たとおり $\boldsymbol{e} = (\mathbf{I} - \mathbf{H})\boldsymbol{y}$ である。ここで $\mathbf{H}\mathbf{X} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X} = \mathbf{X}$ なので、$(\mathbf{I} - \mathbf{H})\mathbf{X} = \mathbf{O}$ である。列空間の中にある $\mathbf{X}\boldsymbol{\beta}$ は、直交補空間への影をとると消える。したがって

$$\boldsymbol{e} = (\mathbf{I} - \mathbf{H})(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) = (\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}$$

となり、残差は誤差だけで決まる。$\mathbf{M} = \mathbf{I} - \mathbf{H}$ とおくと、$\mathbf{M}$ は対称で冪等なので $\mathbf{M}^\top\mathbf{M} = \mathbf{M}\mathbf{M} = \mathbf{M}$ であり、

$$\mathrm{RSS} = \boldsymbol{e}^\top\boldsymbol{e} = \boldsymbol{\varepsilon}^\top\mathbf{M}^\top\mathbf{M}\boldsymbol{\varepsilon} = \boldsymbol{\varepsilon}^\top\mathbf{M}\boldsymbol{\varepsilon} = \sum_{i=1}^{n}\sum_{i'=1}^{n} m_{ii'}\varepsilon_i\varepsilon_{i'}$$

と書ける。$m_{ii'}$ は $\mathbf{M}$ の (i, i') 成分である。これを R 回について平均すると、係数の分散のときと同じく、同じ行どうしの項と交差項に分かれる。(3) 式から、同じ行どうしの項の平均は σ^2 に、交差項の平均は 0 に近づくので

$$\frac{1}{R}\sum_{r=1}^{R}\mathrm{RSS}^{(r)} = \sum_i m_{ii}\Big(\frac{1}{R}\sum_{r=1}^{R}(\varepsilon_i^{(r)})^2\Big) + \sum_{i\neq i'} m_{ii'}\Big(\frac{1}{R}\sum_{r=1}^{R}\varepsilon_i^{(r)}\varepsilon_{i'}^{(r)}\Big) \;\to\; \sigma^2\sum_i m_{ii}$$

となる。残るのは $\mathbf{M}$ の対角成分の和である。

正方行列の対角成分の和を、トレース(trace)と呼ぶ。ここでは tr と書く。$\mathbf{U}$ が $n\times p$、$\mathbf{V}$ が $p\times n$ の行列なら、$\mathbf{UV}$ は $n\times n$、$\mathbf{VU}$ は $p\times p$ で大きさが違うが、

$$\mathrm{tr}(\mathbf{UV}) = \sum_{i=1}^{n}\sum_{k=1}^{p} u_{ik}v_{ki} = \sum_{k=1}^{p}\sum_{i=1}^{n} v_{ki}u_{ik} = \mathrm{tr}(\mathbf{VU})$$

が成り立つ。和の順を入れ替えただけである。$\mathbf{U}=\mathbf{X}$、$\mathbf{V}=(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$ とすると

$$\mathrm{tr}\,\mathbf{H} = \mathrm{tr}(\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top) = \mathrm{tr}((\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}) = \mathrm{tr}\,\mathbf{I}_p = p$$

である。3 回の歩きの例では、$\mathbf{H}$ の対角は $1/14, 4/14, 9/14$ で、和は列の数 $p=1$ に等しい。$\mathrm{tr}\,\mathbf{M} = \mathrm{tr}\,\mathbf{I}_n - \mathrm{tr}\,\mathbf{H} = n-p$ なので、RSS の平均は $\sigma^2(n-p)$ に近づく。そこで

$$\hat{\sigma}^2 = \frac{\|\boldsymbol{y}-\mathbf{X}\hat{\boldsymbol{\beta}}\|_2^2}{n-p} \tag{11}$$

と $n-p$ で割れば、平均して σ^2 になる。n で割ると、平均は $\sigma^2(n-p)/n$ で、σ^2 を小さく見積もる。$n-p$ は、道具の節で数えた直交補空間の次元である。$\hat{\boldsymbol{\beta}}$ は残差平方和を最小にするように選ばれるので、残差は真の誤差より短くなる。誤差は n 本の向きに同じ σ^2 ずつ散らばっているが、残差に残るのはそのうち $n-p$ 本ぶんである。図 8 は、5 行・3 列の $\mathbf{X}$ を固定して目的変数を 3,000 回取り直し、それまでの平均を追ったものである。n で割ると平均は $(n-p)/n = 0.4$ に、$n-p$ で割ると 1 に落ち着く。3 回の歩きなら $\hat{\sigma}^2 = (200^2+400^2+200^2)/(3-1) = 120000$ で、$\hat{\sigma}$ は約 346m になる。

(11) 式を (6) 式に入れ、平方根を取った $\hat{\sigma}\sqrt{[(\mathbf{X}^\top\mathbf{X})^{-1}]_{jj}}$ は、1 回の当てはめから読める推定量 $\hat{\beta}_j$ の標準偏差の見積もりである。これを標準誤差(standard error)と呼ぶ。

標準誤差は、推定値の分布の山の幅の見積もりである。第 2 回のように、行ごとに別々に正規分布から誤差を作るなら、正規分布に従う量の重み付き和は正規分布に従うので、$\hat{\beta}_j - \beta_j = \boldsymbol{a}_j^\top\boldsymbol{\varepsilon}$ も正規分布に従う。したがって、取り直した推定値のおよそ 95% が「真の値 $\pm$ 2× 係数の標準偏差」の範囲に入る。σ を $\hat{\sigma}$ で置き換えた標準誤差を使うと、行が少ないときにはこの割合は 95% より少し下がる。真の値が 0 から 2 標準偏差以上離れていれば、取り直しても符号はまず変わらない。真の値が 0 から 1 標準偏差ほどしか離れていなければ、符号はしばしば変わる。困りごと①の列 1 の係数(図 2)では、真の $\sigma=1$ で計算した係数の標準偏差が 1.45 で、真の値 1

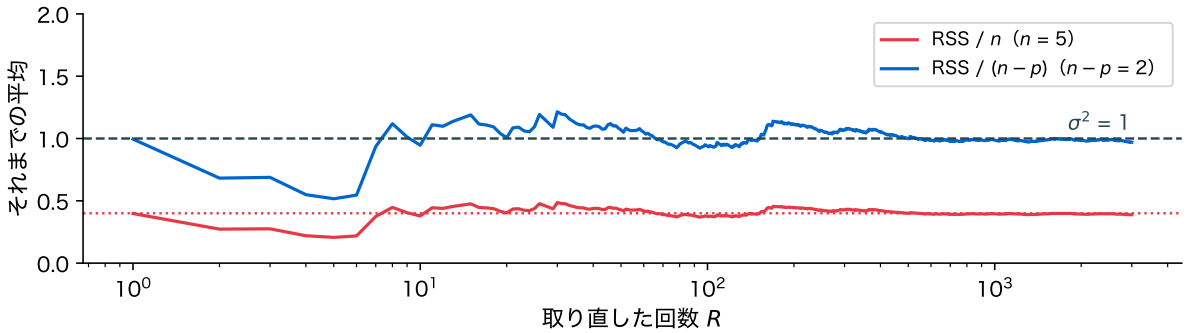


図 8: 5 行・3 列の $\mathbf{X}$ を固定し、目的変数を取り直したときの RSS/n（赤）と RSS/$(n-p)$（青）の、それまでの平均（人工データ、$\sigma = 1$、横軸は対数）。赤は $(n-p)/n = 0.4$（点線）に、青は $\sigma^2 = 1$（破線）に落ち着く

は 0 から 1 標準偏差も離れていない。符号が逆になる割合は約 25% と見込め、実際に 20 回のうち 7 回で逆になった。

列が似ていると係数が不安定になる：多重共線性

列が 1 本なら、係数の不安定性に効くのは x の標本分散（SN 比）だけだった。列が 2 本以上になると、列どうしの関係も $\mathbf{X}^\top\mathbf{X}$ に入り、(6) 式の対角を変える。

まず人工データで見ておく（図 9）。50 行の 2 列を、相関がちょうど 0 の場合と 0.9 の場合について作った。真の係数は $(1, 1)$、ノイズの標準偏差は 1 とし、$\mathbf{X}$ は固定したまま $\boldsymbol{y}$ を 300 回取り直した。相関 0 では推定値は★のまわりに丸く小さく散らばる。相関 0.9 では、左上から右下への斜めの向きに細長く伸びる。$x_1 \approx x_2$ なら $\beta_1 x_1 + \beta_2 x_2 \approx (\beta_1 + \beta_2) x_1$ なので、データは和 $\beta_1 + \beta_2$ はよく決めるが、その内訳はほとんど決められない。内訳のわずかな違いは当てはまりをほとんど変えないので、ノイズしだいで大きく動くのである。

定義 3 (多重共線性)**.** 説明変数の列どうしが、ほぼ 1 次式の関係にある状態を多重共線性（multicollinearity）と呼ぶ。列が 2 本なら、相関係数が ± 1 に近いことである。

多重共線性は、いつも 2 人そろって押す車にたとえられる（図 10）。車の進み方から 2 人の力の合計はわかるが、1 人ずつの力はわからない。1 人で押す日があれば、2 人の力を分けられる。それが似ていない列である。冒頭の人工データで列 1 の係数の符号が逆になったのも、2 列の相関が 0.98 と高く、行が 12 しかないからである。身近な例でいえば、カフェのコーヒーの値段を、注いだ量とカップの大きさの 2 列で説明する場合である。大きいカップほど多く注ぐので、2 列の相関は 0.99 にもなる。値段の差が量によるのかカップによるのかは、ほとんど分けられない。

では、似ていると分散はどれだけ膨らむのか。まず列が 2 本の場合を、手で計算する。

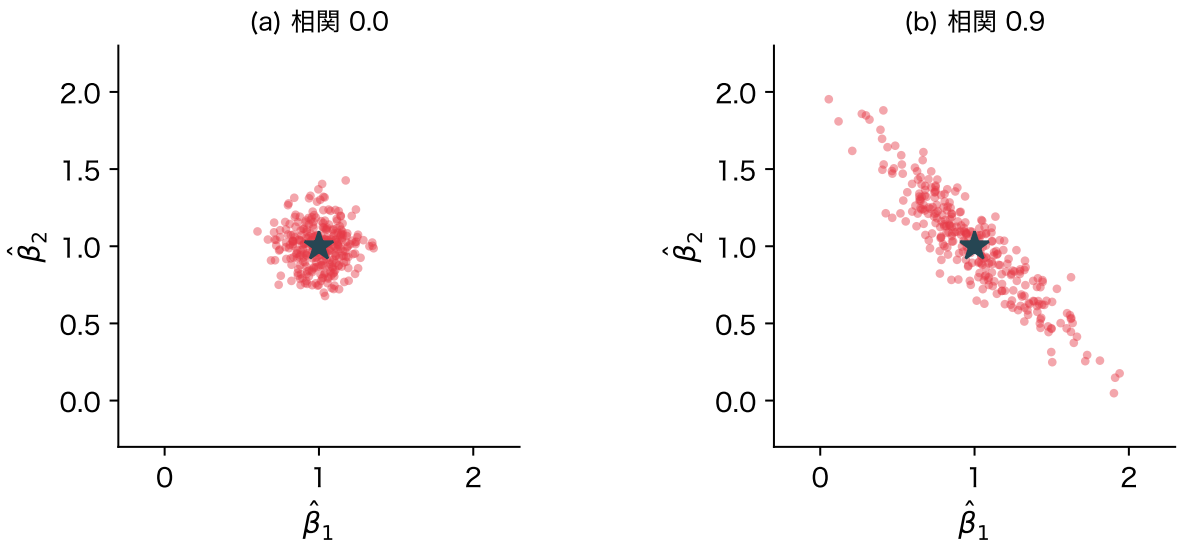


図 9: 人工データで $\boldsymbol{y}$ を 300 回取り直したときの係数の推定値。★は真の値。(a) 2 列の相関が 0、(b) 0.9

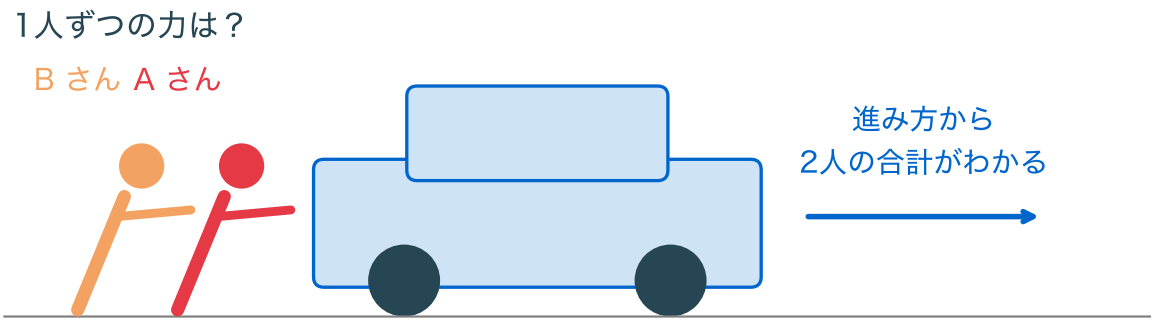


図 10: 多重共線性のたとえ(概念図)。いつも 2 人で押す車では、進み方から 2 人の力の合計はわかるが、内訳はわからない

2 列で計算する：逆行列の対角

列が 2 本の場合を、(6) 式から手で計算する。簡単のため、2 列とも平均 0 で二乗和が同じ S とし(切片の列は入れない)、2 列の相関係数を r_{12} とする。相関係数の定義(第 1 回) $r_{12} = \boldsymbol{x}_1^\top \boldsymbol{x}_2 / (\sqrt{\boldsymbol{x}_1^\top \boldsymbol{x}_1} \sqrt{\boldsymbol{x}_2^\top \boldsymbol{x}_2})$ から $\boldsymbol{x}_1^\top \boldsymbol{x}_2 = rS$ なので

$$\mathbf{X}^\top \mathbf{X} = \begin{bmatrix} \boldsymbol{x}_1^\top \boldsymbol{x}_1 & \boldsymbol{x}_1^\top \boldsymbol{x}_2 \\ \boldsymbol{x}_2^\top \boldsymbol{x}_1 & \boldsymbol{x}_2^\top \boldsymbol{x}_2 \end{bmatrix} = S \begin{bmatrix} 1 & r_{12} \\ r_{12} & 1 \end{bmatrix}$$

である。2 行 2 列の行列の逆行列は

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix}^{-1} = \frac{1}{ad-bc}\begin{bmatrix} d & -b \\ -c & a \end{bmatrix} \tag{12}$$

で求まる。右辺の行列を元の行列に掛けると、対角が $ad-bc$、対角の外が $ab-ba=0$ と $cd-dc=0$ になるので、$ad-bc$ で割れば単位行列になる。$ad-bc=0$ なら割れないので、逆行列は無い。$\mathbf{X}^\top\mathbf{X}$ では $a=d=S$、$b=c=rS$ であり、$ad-bc=S^2-r_{12}^2S^2=S^2(1-r_{12}^2)$ となる。したがって

$$(\mathbf{X}^\top\mathbf{X})^{-1} = \frac{1}{S^2(1-r_{12}^2)}\begin{bmatrix} S & -rS \\ -rS & S \end{bmatrix} = \frac{1}{S(1-r_{12}^2)}\begin{bmatrix} 1 & -r_{12} \\ -r_{12} & 1 \end{bmatrix}$$

である。その $(1,1)$ 成分を (6) 式に入れると

$$\mathbb{V}\mathrm{ar}(\hat{\beta}_1) = \frac{\sigma^2}{S} \times \frac{1}{1-r_{12}^2} \tag{13}$$

を得る。σ^2/S は、列 1 だけで当てはめたときの分散($p=1$ の式 (7) 式)である。似た列が隣にあると、分散は $1/(1-r_{12}^2)$ 倍に膨らむ。$r_{12}=0.9$ なら $1/(1-0.81)\approx 5.3$ 倍、標準偏差にして約 2.3 倍である。図 9 と同じ 2 列で $\boldsymbol{y}$ を 5000 回取り直し、列 1 の係数の分散の比を数えると 5.5 で、式の 5.3 に近い。相関 0.5 なら倍率は 1.33 にすぎないが、0.99 なら約 50 倍になる(表 1)。$r_{12}=\pm 1$ では $ad-bc=0$ となり、逆行列そのものが無くなる。

表 1: 2 列の相関 r_{12} と、係数の分散・標準偏差の倍率

相関 r_{12}	0	0.5	0.9	0.99
分散の倍率 $1/(1-r_{12}^2)$	1	1.33	5.26	50.3
標準偏差の倍率	1	1.15	2.29	7.09

列が 3 本以上になると、何本かの列が組み合わさって似ることがある。次に、これを一般の p で扱う。

列が何本でも：VIF

列が 3 本以上になると、2 列の相関だけでは足りない。$x_3 \approx x_1 + x_2$ のように、何本かの列が組み合わさって初めて似ることがあるからである。このとき、どの 2 本の相関も中くらいでありながら、列 3 の係数は不安定になりうる。一般の p では、列 j の係数に効くのは、列 j のうち残りの列では説明できない部分である。

ここからは、$\mathbf{X}$ に切片の列(すべて 1 の列)が入っているとする。列 j を、切片の列を含む残りのすべての列で最小二乗法により回帰し、その残差を $\tilde{\boldsymbol{x}}_j$ と書く(図 11)。$\tilde{\boldsymbol{x}}_j$ には 2 つの性質がある。第 1 に、$\tilde{\boldsymbol{x}}_j$ は回帰の残差なので、第 1 回の正規方程式により、説明に使った残りのすべての列と直角(内積が 0)である。第 2 に、$\boldsymbol{x}_j$ は $\tilde{\boldsymbol{x}}_j$ と、残りの列の重み付き和(回帰の予測値)の和に分かれる。後ろの部分は第 1 の性質により $\tilde{\boldsymbol{x}}_j$ と直角なので、$\tilde{\boldsymbol{x}}_j^\top \boldsymbol{x}_j = \tilde{\boldsymbol{x}}_j^\top \tilde{\boldsymbol{x}}_j$ である。

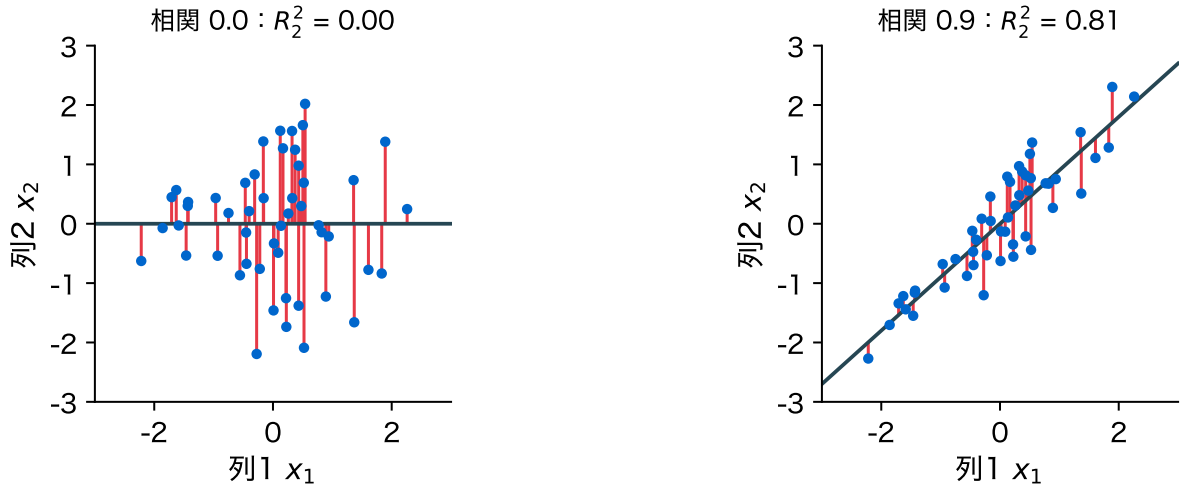


図 11: 列 2 を列 1 と切片で回帰したときの残差 $\tilde{\boldsymbol{x}}_2$（赤）。(a) 相関 0 の 2 列、(b) 相関 0.9 の 2 列（人工データ、50 行）。似た列では、ほかの列で説明できない部分がわずかしか残らない

道具の言葉で言えば、$\tilde{\boldsymbol{x}}_j$ は $\boldsymbol{x}_j$ を、残りの列（と切片）が張る平らな空間の直交補空間へ落とした影であり、切片の列を含む残りの列への射影行列を $\mathbf{H}_{-j}$ として $\tilde{\boldsymbol{x}}_j = (\mathbf{I} - \mathbf{H}_{-j})\boldsymbol{x}_j$ と書ける（図 12）。平均を引いた $\boldsymbol{x}_j$ と、その平らな空間とのなす角を θ とすると、平均を引いた $\boldsymbol{x}_j$ は、平らな空間への影と、はみ出した部分 $\tilde{\boldsymbol{x}}_j$ の和で、2 つは直角である。三平方の定理から、長さの二乗も影の二乗とはみ出しの二乗の和に分かれる。全体の変動のうちはみ出しが占める割合が $1 - R_j^2$ なので（決定係数の定義）、$1 - R_j^2 = \sin^2\theta$、$R_j^2 = \cos^2\theta$ である。似た列は平らな空間にほとんど寝ていて、θ が小さく、はみ出した部分 $\tilde{\boldsymbol{x}}_j$ が短い。

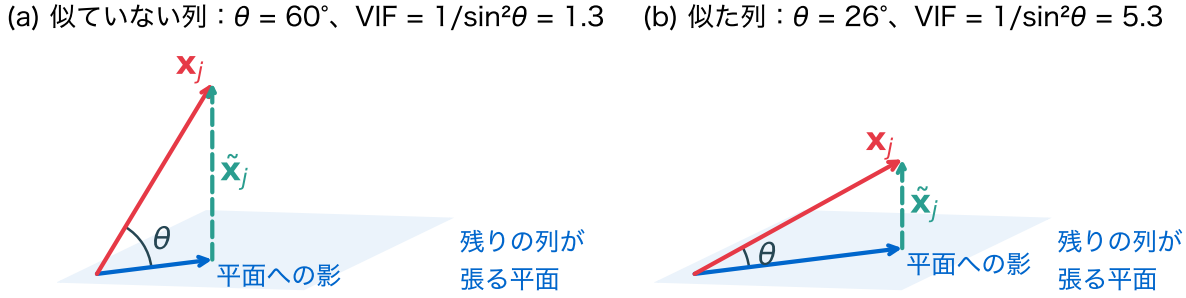


図 12: 多重共線性の幾何（概念図）。平均を引いた列 $\boldsymbol{x}_j$（赤）を、残りの列が張る平面への影（青）と、直交補空間への影 $\tilde{\boldsymbol{x}}_j$（緑）に分ける。平面とのなす角 θ が小さいほど $\tilde{\boldsymbol{x}}_j$ は短く、$\mathrm{VIF}_j = 1/\sin^2\theta$ は大きい

この 2 つの性質から、係数 $\hat{\beta}_j$ を $\tilde{\boldsymbol{x}}_j$ だけで書ける。当てはめた式 $\boldsymbol{y} = \sum_k \hat{\beta}_k \boldsymbol{x}_k + \boldsymbol{e}$ の両辺と $\tilde{\boldsymbol{x}}_j$ の内積をとると

$$\tilde{\boldsymbol{x}}_j^\top \boldsymbol{y} = \sum_k \hat{\beta}_k \tilde{\boldsymbol{x}}_j^\top \boldsymbol{x}_k + \tilde{\boldsymbol{x}}_j^\top \boldsymbol{e}$$

となる。右辺の和のうち $k \neq j$ の項は、第 1 の性質により 0 である。$k = j$ の項は、第 2 の性質により $\hat{\beta}_j \tilde{\boldsymbol{x}}_j^\top \tilde{\boldsymbol{x}}_j$ になる。最後の項について、残差 $\boldsymbol{e}$ はすべての列と直角であり、$\tilde{\boldsymbol{x}}_j = \boldsymbol{x}_j -$ (残りの列の重み付き和) も列の重み付き和なので、$\tilde{\boldsymbol{x}}_j^\top \boldsymbol{e} = 0$ である。したがって

$$\hat{\beta}_j = \frac{\tilde{\boldsymbol{x}}_j^\top \boldsymbol{y}}{\tilde{\boldsymbol{x}}_j^\top \tilde{\boldsymbol{x}}_j} \tag{14}$$

を得る。重みを $\boldsymbol{w} = \tilde{\boldsymbol{x}}_j / (\tilde{\boldsymbol{x}}_j^\top \tilde{\boldsymbol{x}}_j)$ とおくと $\hat{\beta}_j = \boldsymbol{w}^\top \boldsymbol{y}$ である。一方、(6) 式を導いたときの $\mathbf{A}$ の j 行目 $\boldsymbol{a}_j$ についても $\hat{\beta}_j = \boldsymbol{a}_j^\top \boldsymbol{y}$ だった。どんな $\boldsymbol{y}$ でも $\boldsymbol{a}_j^\top \boldsymbol{y} = \boldsymbol{w}^\top \boldsymbol{y}$ なので、$\boldsymbol{y}$ に i 番目だけが 1 の単位ベクトルを入れると $a_{ji} = w_i$ となり、$\boldsymbol{a}_j = \boldsymbol{w}$ である。したがって

$$\mathbb{V}\mathrm{ar}(\hat{\beta}_j) = \sigma^2 \boldsymbol{a}_j^\top \boldsymbol{a}_j = \sigma^2 \boldsymbol{w}^\top \boldsymbol{w} = \frac{\sigma^2 \, \tilde{\boldsymbol{x}}_j^\top \tilde{\boldsymbol{x}}_j}{(\tilde{\boldsymbol{x}}_j^\top \tilde{\boldsymbol{x}}_j)^2} = \frac{\sigma^2}{\tilde{\boldsymbol{x}}_j^\top \tilde{\boldsymbol{x}}_j} \tag{15}$$

となる。(7) 式の $\sum_i x_i^2$ を、ほかの列で説明できない部分の二乗和に替えた式であり、列が何本でも成り立つ。

残る部分の二乗和 $\tilde{\boldsymbol{x}}_j^\top \tilde{\boldsymbol{x}}_j$ は、列 j を目的変数とする補助の回帰の残差平方和である。列 j が平均のまわりにどれだけ散らばるかを、列 j の変動 $S_j = \sum_i (x_{ij} - \bar{x}_j)^2$ で表す。第 1 回の決定係数の分母「全体の変動」を、列 j を目的変数とみて書いたものである。補助の回帰の決定係数を R_j^2 とすると、第 1 回の定義から $R_j^2 = 1 - \tilde{\boldsymbol{x}}_j^\top \tilde{\boldsymbol{x}}_j / S_j$ である。これを残差平方和について解くと

$$\tilde{\boldsymbol{x}}_j^\top \tilde{\boldsymbol{x}}_j = S_j \, (1 - R_j^2)$$

となる。似た列があるほど R_j^2 は 1 に近く、残る部分は小さく、係数の分散は大きくなる。SN 比でいえば、信号に使える x の散らばりが $\sqrt{1 - R_j^2}$ 倍に減るのである。

定義 4 (分散拡大係数)**.** 列 j を、残りのすべての列(と切片)で回帰したときの決定係数を R_j^2 とする。$1/(1 - R_j^2)$ を、列 j の分散拡大係数(variance inflation factor)(VIF)と呼ぶ。ここでは VIF_j と書く。係数の分散は

$$\mathbb{V}\mathrm{ar}(\hat{\beta}_j) = \frac{\sigma^2}{S_j} \cdot \mathrm{VIF}_j, \qquad \mathrm{VIF}_j = \frac{1}{1 - R_j^2} \tag{16}$$

と、似ていないときの分散と VIF の積に分かれる。(15) 式に $\tilde{\boldsymbol{x}}_j^\top \tilde{\boldsymbol{x}}_j = S_j(1 - R_j^2)$ を入れたものである。第 1 因子は、ほかの列と似ていない($R_j^2 = 0$)ときの分散で、(7) 式と同じ形である。角度で書けば $\mathrm{VIF}_j = 1/\sin^2\theta$ である。

列が 2 本なら $R_1^2 = r_{12}^2$、つまり決定係数は相関係数の 2 乗であり、平均 0 で二乗和 $S = S_1$ の列について (16) 式は 2 列の式 (13) 式に一致する。名前の似た 3 つの量を区別しておく。r_{12} は 2 本の列の相関係数(第 1 回)、R_j^2 は列 j を残りすべての列で回帰したときの決定係数、相関行列 $\mathbf{C}$ は列の組ごとの相関係数を並べた表で

ある（r_{12} はその $(1,2)$ 成分）。R_j^2 を相関係数ではなく「残りすべての列で回帰した決定係数」で定めるのは、$x_3 \approx x_1 + x_2$ のように 3 本以上が組み合わさって初めて成り立つ関係も捕まえるためである。

VIF は R_j^2 が小さいうちはほとんど 1 のままで、$R_j^2 = 0.5$ でも 2 にすぎない。ところが 1 の近くでは急に大きくなり、0.9 で 10、0.95 で 20、0.99 で 100 になる（図 13）。標準誤差は分散の平方根なので $\sqrt{\mathrm{VIF}_j}$ 倍になり、VIF が 10 なら約 3.2 倍である。VIF は倍率であって絶対量ではない。(16) 式の第 1 因子は、行を増やせば小さくなるので、VIF が大きくても行が十分多ければ係数は安定しうる。VIF の値は細かく比べず、1・10・100 のどのあたりかと桁で読むのがよい。

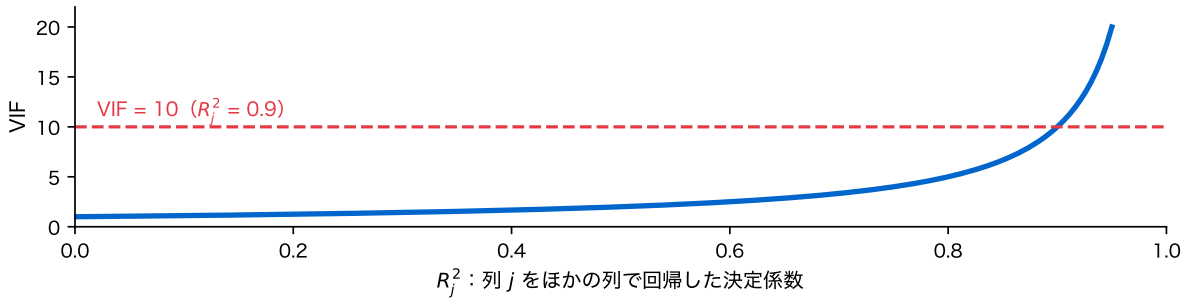


図 13: 分散拡大係数 $\mathrm{VIF}_j = 1/(1-R_j^2)$ と、目安とされる VIF $= 10$（赤の破線）

VIF は、列ごとに回帰しなくても、行列の計算で一度に求まる。$\boldsymbol{a}_j = \boldsymbol{w}$ から $[(\mathbf{X}^\top\mathbf{X})^{-1}]_{jj} = \boldsymbol{a}_j^\top \boldsymbol{a}_j = \boldsymbol{w}^\top \boldsymbol{w} = 1/\tilde{\boldsymbol{x}}_j^\top \tilde{\boldsymbol{x}}_j$ が成り立つ。各列から平均を引き、$\sqrt{S_j}$ で割った列 $\boldsymbol{z}_j = (\boldsymbol{x}_j - \bar{x}_j\mathbf{1})/\sqrt{S_j}$ を並べて $\mathbf{Z}$ とし、切片の列は入れない。$\mathbf{Z}^\top\mathbf{Z}$ の (j,k) 成分は $\sum_i (x_{ij}-\bar{x}_j)(x_{ik}-\bar{x}_k)/\sqrt{S_jS_k}$ で、列 j と列 k の相関係数 r_{jk} そのもの（第 1 回の定義）である。これを並べた $\mathbf{C} = \mathbf{Z}^\top\mathbf{Z}$ を相関行列と呼ぶ。$\boldsymbol{z}_j$ の変動は 1 である。また、列から平均を引いても、列を定数倍しても、R_j^2 は変わらない。平均 0 の列はすべて 1 の列と直角なので、切片の列を入れても入れなくても、残りの列で回帰した残差 $\tilde{\boldsymbol{z}}_j$ は同じである。したがって $\tilde{\boldsymbol{z}}_j^\top \tilde{\boldsymbol{z}}_j = 1 \cdot (1-R_j^2)$ であり、$\mathbf{Z}$ に同じ関係を当てると $[\mathbf{C}^{-1}]_{jj} = 1/\tilde{\boldsymbol{z}}_j^\top \tilde{\boldsymbol{z}}_j = 1/(1-R_j^2) = \mathrm{VIF}_j$ を得る。計算の手順は次のとおりである。

1. 切片の列を除いた各列から平均を引き、$\sqrt{S_j}$ で割って $\mathbf{Z}$（$n \times p'$、p' は切片を除いた列の数）を作る
2. 相関行列 $\mathbf{C} = \mathbf{Z}^\top\mathbf{Z}$ を作る。その (j,k) 成分は、列 j と列 k の相関係数である
3. $\mathbf{C}^{-1}$ を求め、その対角成分を並べる。$\mathrm{VIF}_j = [\mathbf{C}^{-1}]_{jj}$ である。完全な多重共線性があると $\mathbf{C}$ に逆行列が無く、計算できない

列が 2 本なら $\mathbf{C} = \begin{bmatrix} 1 & r_{12} \\ r_{12} & 1 \end{bmatrix}$ で、(12) 式から $\mathbf{C}^{-1}$ の対角は $1/(1-r_{12}^2)$ となり、2 列の倍率と一致する。第 1 回の計算手順では正規方程式を解くだけで、逆行列そのものは作らなかった。ここでは逆行列の対角そのものが答えなので、逆行列を作る。列 j を残りの列で回帰して $1/(1-R_j^2)$ を p' 回計算しても同じ値になり、第 II 部でこれを確かめる。VIF は $\mathbf{X}$ だけで決まり、目的変数 $\boldsymbol{y}$ を見ていないので、データを集めた段階で「この列の組では係数は読めない」と先にわかる。

逆行列が無いとき：完全な多重共線性と p > n

(16) 式の倍率 $1/(1-R_j^2)$ は、R_j^2 が 1 に近づくほど大きくなり、$R_j^2=1$ では分母が 0 になる。このとき列 j はほかの列の 1 次式でぴったり書け、残る部分 $\tilde{\boldsymbol{x}}_j$ は 0 である。$\mathbf{X}^\top\mathbf{X}$ は正則でなく（第 1 回）、逆行列は作れない。分散が「とても大きい」のではなく、係数が 1 つに決まらないのである。

目的関数の形で見るとわかりやすい（図 14）。ここでは形だけを見るため、誤差の無い目的変数 $\mathbf{X}\boldsymbol{\beta}$（真の係数は $(1,1)$）で目的関数を描く。相関 0.9 の 2 列では、目的関数の等高線は斜めに細長い楕円で、底（★）は 1 点に決まる。図 9 (b) の推定値が伸びた向きは、この楕円の長い向きと同じである。相関が 1、つまり $x_2=x_1$ なら $\mathbf{X}\boldsymbol{\beta}=(\beta_1+\beta_2)\boldsymbol{x}_1$ となる。和が同じ組なら、どれもまったく同じ予測になる。等高線は平行な直線になり、底は 1 点に定まらず、直線 $\beta_1+\beta_2=2$ の全体になる。一方で、列空間は 1 本の直線のままなので、影 $\hat{\boldsymbol{y}}$ は 1 つに決まっている。決まらないのは、影を列にどう割り振るかという係数の内訳だけである。

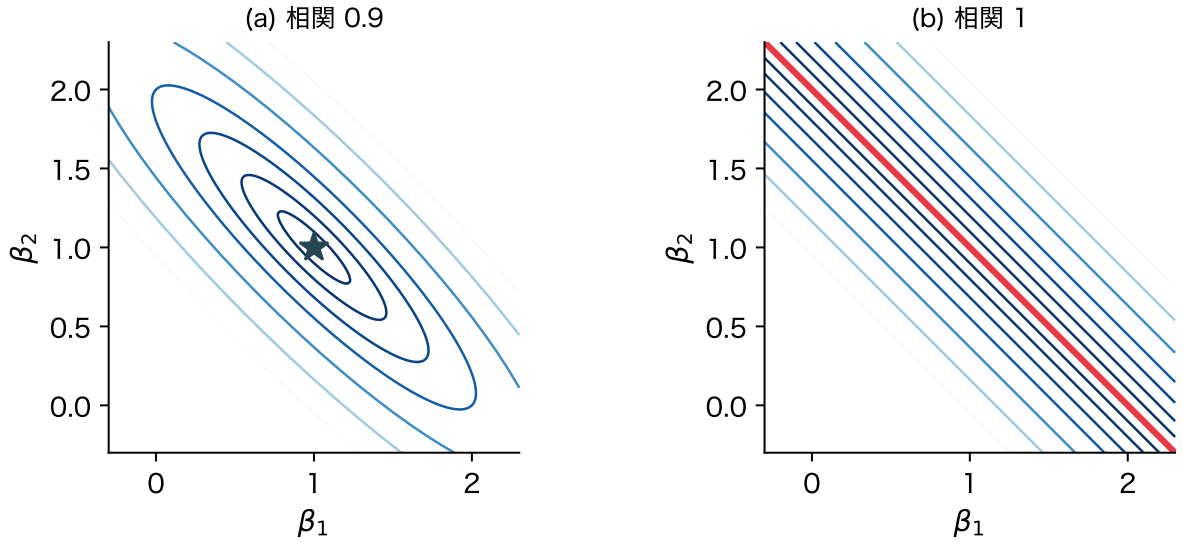


図 14: 2 列の場合の目的関数の等高線（人工データ）。(a) 相関 0.9 では底が 1 点（★）、(b) 相関 1 では底が直線（赤）になり、解が無数にある

行より列が多い場合（$p>n$）は、列の中身によらず必ずこうなる。伝票の例がこれにあたる（図 15）。昼の伝票はラーメンと餃子で 1,100 円、夜の伝票はラーメンとライスで 1,000 円だった。伝票を行、品目を列、単品の値段を係数とみれば、2 行で係数を 3 個決めることになる。ラーメン 800 円・餃子 300 円・ライス 200 円でも、900 円・200 円・100 円でも、2 枚の合計にぴったり合う。式が 2 本で未知数が 3 個の連立方程式なので、解は無数にある。

一般に、$p>n$ なら、連立方程式 $\mathbf{X}\boldsymbol{v}=0$ は式が n 本で未知数が p 個なので、0 でない解 $\boldsymbol{v}$ をもつ。この $\boldsymbol{v}$ では $\mathbf{X}^\top\mathbf{X}\boldsymbol{v}=0$ となる。もし $\mathbf{X}^\top\mathbf{X}$ に逆行列があれば、両辺に掛けて $\boldsymbol{v}=0$ となり矛盾する。したがって、列の中身によらず $\mathbf{X}^\top\mathbf{X}$ は逆行列を持たない。遺伝子の発現量のように、数十人について数千の列を測ったデータでは、これが普通の状態である。

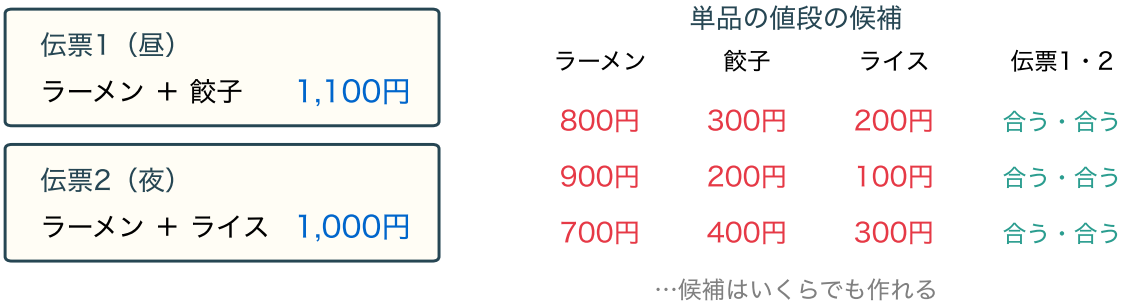


図 15: 列が行より多い例（概念図）。伝票 2 枚（行）から 3 品（列）の単品の値段（係数）は 1 つに決まらない

行が列より多くても、ある列がほかの列の 1 次式でちょうど書けるとき（完全な多重共線性）も、同じ論法で $\mathbf{X}^\top\mathbf{X}$ は正則でない。列 j を残りの列の 1 次式で書いた係数を並べ、列 j の位置に -1 を置いたベクトル $\boldsymbol{v}$ が、$\mathbf{X}\boldsymbol{v} = 0$ を満たすからである。たとえば $\boldsymbol{x}_3 = \boldsymbol{x}_1 + \boldsymbol{x}_2$ なら $\boldsymbol{v} = [1, 1, -1]^\top$ である。よく起きるのは、カテゴリをカテゴリごとの 0/1 の列に展開し、切片の列も入れた場合である。0/1 の列をすべて足すとつねに 1 になり、切片の列と一致してしまう。

こうして (6) 式の $(\mathbf{X}^\top\mathbf{X})^{-1}$ は、列が似ていれば大きく膨らむ。列が完全に重なったり行より多かったりすれば、そもそも存在しない。どちらの場合も、データだけでは無数の候補から 1 つを選べない。

第 II 部　実データ解析

第 II 部の進め方と予想

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、2 つの予想が立つ。第 1 に、係数の不安定性は、1 回の当てはめから計算した標準誤差 $\hat{\sigma}\sqrt{[(\mathbf{X}^\top\mathbf{X})^{-1}]_{jj}}$ で読めるはずである。第 2 に、似た列の組があれば、その係数は VIF 倍に膨らみ、第 I 部の人工データのように斜めに細長くばらつくと見込める。

カリフォルニア住宅データ

第 II 部では、第 I 部の場面で使ったカリフォルニア州の住宅のデータで、第 I 部の式を確かめる。Pace と Barry が 1990 年の米国国勢調査から作ったデータで、scikit-learn の fetch_california_housing で取得した。20,640 の地区のそれぞれについて、8 列の説明変数と、目的変数として住宅価格の中央値（10 万ドル単位）が記録されている。8 列は、世帯の所得の中央値（1 万ドル単位）、住宅の築年数の中央値、1 世帯あたりの部屋数と寝室数の平均、人口、1 世帯あたりの人数の平均、地区の中心の緯度と経度である。価格は 5（50 万ドル）で打ち切られていて、992 地区がその値になっている。変数は元の単位のまま用い、切片の列を加えた 20,640 行 × 9

列 のデータ行列 $\mathbf{X}$ を作る。第 I 部の場面では、20 通りの分割で寝室数の係数が所得の約 4 倍ばらついた。この差を第 I 部の式で説明できるかも、第 II 部で確かめる。

図 16 は 8 列の相関行列である。似た列の組が 2 つある。1 つは部屋数と寝室数で、相関は 0.85 である。寝室は部屋の一部なので、部屋の多い地区は寝室も多い。もう 1 つは緯度と経度で、相関は-0.92 である。カリフォルニア州は北西から南東へ斜めに伸びているので、北の地区ほど西にある。ほかの列どうしの相関は、所得と部屋数の 0.33 を除けば、どれも 0.3 より小さい。

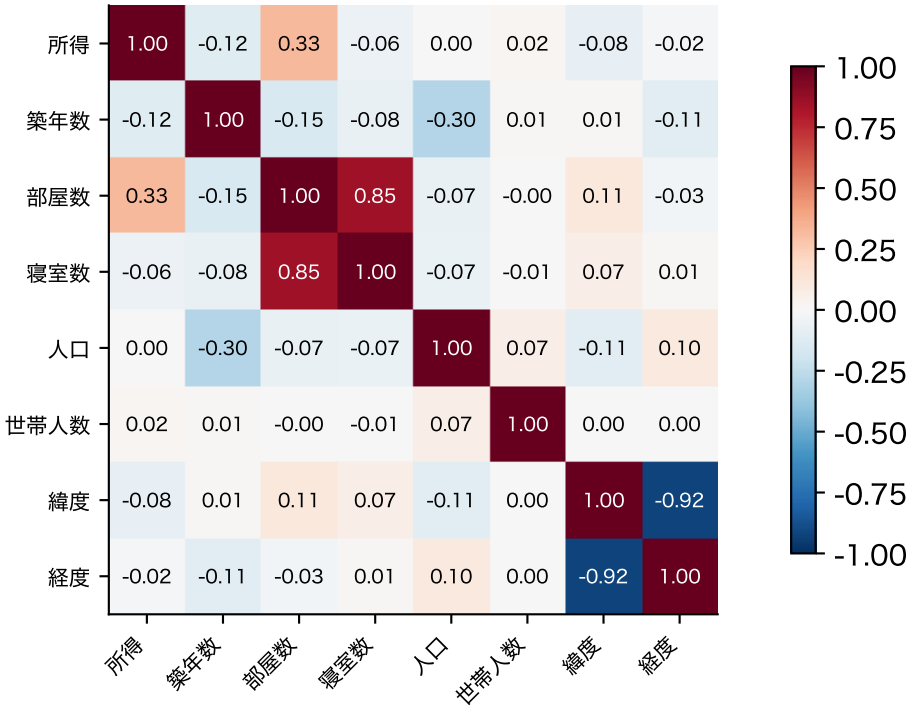


図 16: カリフォルニア住宅データの 8 列の相関行列

計算の手続き

計算の手続きは次のとおりである。データ行列 $\mathbf{X}$ で正規方程式を解いて係数 $\hat{\boldsymbol{\beta}}$ を求め、残差平方和から (11) 式で $\hat{\sigma} = 0.724$ を得た($n - p = 20{,}631$)。次に $(\mathbf{X}^\top \mathbf{X})^{-1}$ を作り、(6) 式と (11) 式から各係数の標準誤差を計算した。

まず、計算そのものを確かめるために、第 I 部の前提どおりのデータを作った。$\mathbf{X}$ はそのままにして、目的変数を $\mathbf{X}\hat{\boldsymbol{\beta}}$ に標準偏差 $\hat{\sigma}$ の正規分布の誤差を足したものに置き換え、当てはめ直すことを 1000 回くり返した。このデータは式の前提をそのまま満たすので、係数の標準偏差は式の標準誤差と一致するはずである。

本番は、実データの揺れとの比較である。20,640 地区を無作為に並べ替え、重ならない 20 組(1,032 地区ずつ)に分けた。組ごとに同じ 8 列の線形回帰を当てはめ、20 組の係数の標準偏差を求めた。これが、地区を選び直したときに実際に係数がどれだけ揺れるかである。組ごとに式の標準誤差も計算し、20 組で平均した。場面の

20 通りの分割は訓練の行が 7 割ずつ重なっているので、揺れが小さく出る。そこで、重ならない組で比べる。さらに VIF を、第 I 部の手順どおり相関行列の逆行列の対角から求め、列ごとの回帰による $1/(1-R_j^2)$ とも比べた。最後に、手元の全地区を母集団に見立て、そこから 40 地区だけを選んで当てはめることを 20 回くり返した。どれも NumPy の行列計算と scikit-learn の LinearRegression で行った。係数はどれも、各列の標準偏差を掛けて「標準偏差 1 つぶんあたり」に直して比べる。

結果①：式は実データで外れた

まず計算を確かめる（図 17）。式の前提どおりに作り直したデータでは、式から出した標準誤差と、1000 回の係数の標準偏差は 8 列すべてで重なり、差は最大でも 3% である。計算は正しい。ただし、このデータは式の前提をそのまま満たすように作ったので、重なるのは当然である。実データが前提を満たすかどうかは、これでは確かめられない。

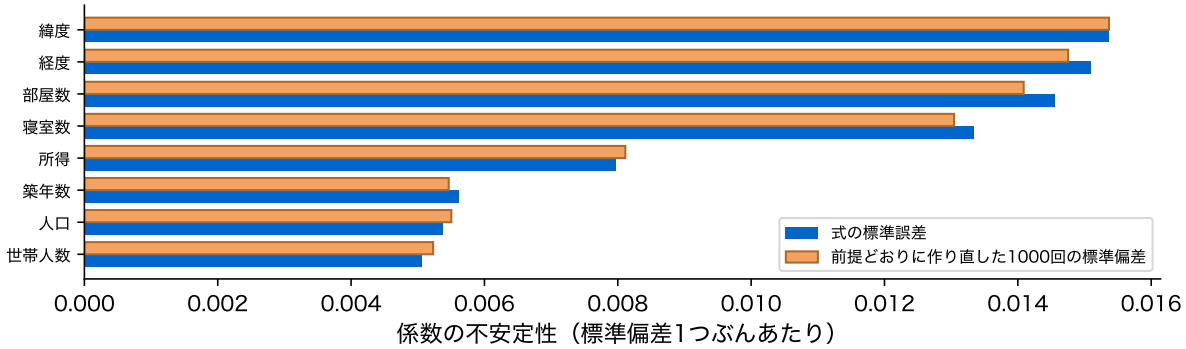


図 17: 式の前提どおりに作り直したデータでの確認。式 $\hat{\sigma}\sqrt{[(\mathbf{X}^\top\mathbf{X})^{-1}]_{jj}}$ による標準誤差（青）と、$\mathbf{X}$ を固定して目的変数を 1000 回作り直したときの標準偏差（橙）。標準偏差 1 つぶんあたりに直してある

そこで、実データの揺れと比べる（図 18）。1,032 地区ずつの重ならない 20 組で当てはめると、緯度と経度の係数の揺れは式の標準誤差とほぼ同じで、比は 0.86 と 0.93 である。ところが、世帯人数の揺れは式の約 6.7 倍、寝室数は 2.3 倍、部屋数と所得は約 1.6 倍だった。1 回の当てはめの式は、これらの係数の揺れを小さく見積もる。予想①は、半分の列で外れた。場面で寝室数の係数が分割しだいでばらついたのも、式で見込める以上の揺れだったのである。

ずれの理由を、第 I 部の前提に戻って考える。式 (6) 式は、$\mathbf{X}$ を固定し、どの行の誤差も同じ σ^2 で散らばると仮定して導いた。実データでは、どちらも崩れている。

第 1 に、列の散らばりの大半が、ごく一部の地区から来ている（図 19）。世帯人数の中央値は 2.8 人だが、最大は 1,243 人である。1 世帯あたりの部屋数・寝室数にも、中央値の数倍から数十倍の地区がある。人の少ない施設や別荘地のような地区で、平均をとる世帯が少ないためと考えられる。$p=1$ の式 (7) 式は、x の散らばりが大きいほど係数が安定すると言う。この式は、散らばりがどの地区から来ているかを区別しない。ところが実際には、極端な地区が組に入るかどうかで、係数が大きく動く。$\mathbf{X}$ を固定した式は、$\mathbf{X}$ が選び直しで変わることによるこの揺れを数えない。

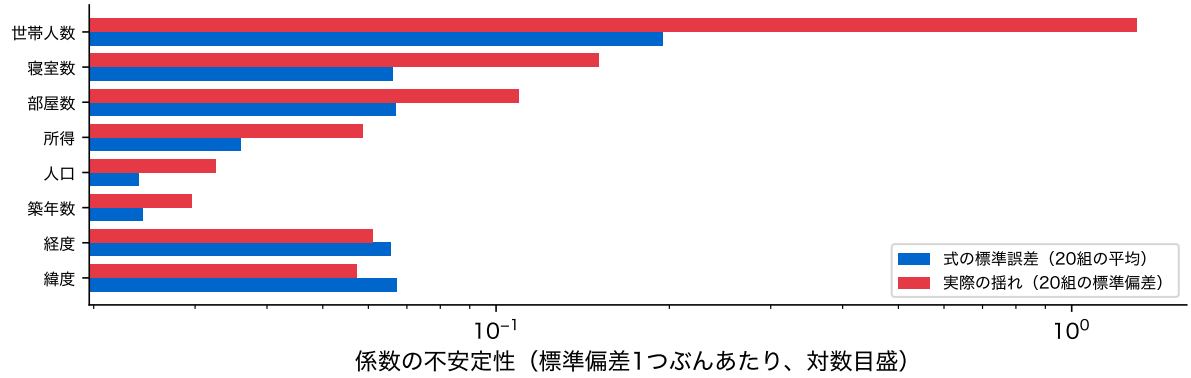


図 18: 地区を重ならない 20 組（1,032 地区ずつ）に分けて当てはめたときの、係数の実際の揺れ（赤）と、式の標準誤差の 20 組の平均（青）。標準偏差 1 つぶんあたり、横軸は対数目盛

第 2 に、極端な地区では誤差も大きい。全地区で当てはめた残差の二乗の平均は、極端な地区で 1.10、ほかの地区で 0.51 であり、「どの行も同じ σ^2」という (3) 式の 2 つ目の仮定も崩れている。

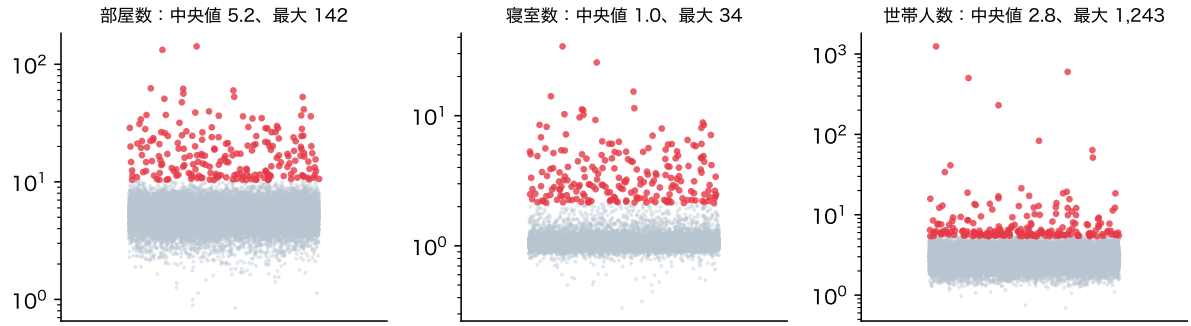


図 19: 1 世帯あたりの部屋数・寝室数・人数の分布（縦軸は対数目盛、横の広がりは見やすくするための散らし）。赤はそれぞれの上位 1% の地区

この説明が正しければ、極端な地区を除くと式は当たるようになるはずである。部屋数・寝室数・世帯人数のどれかが上位 1% に入る 442 地区（全体の 2.1%）を除いて同じ比較をすると、比は 0.9〜1.3 に下がった（図 20）。ずれの大部分は、この 2% ほどの地区から来ていたのである。残るずれは、価格が 5 で打ち切られていることや、誤差の大きさが地区によってなお違うことによると考えられる。

結果②：多重共線性

次に、多重共線性を見る。VIF は桁で読む（図 21、表 2）。2 通りの計算は、差が最大 8e-13 で一致した。築年数・人口・世帯人数の VIF は 1 のあたり、所得は 2.5 である。部屋数と寝室数、緯度と経度の 4 列は 7〜9 で、式の上では標準誤差が約 3 倍に膨らむ。緯度と経度の実際の揺れが式どおりだったことは、この VIF 倍の膨らみが実データでも起きていることを示す。一方、世帯人数の VIF は 1.01 で、ほかの列とはほとんど似ていない。結果①で世帯人数の揺れが式の約 7 倍になったのは、多重共線性のせいではなく、極端な地区のせいである。

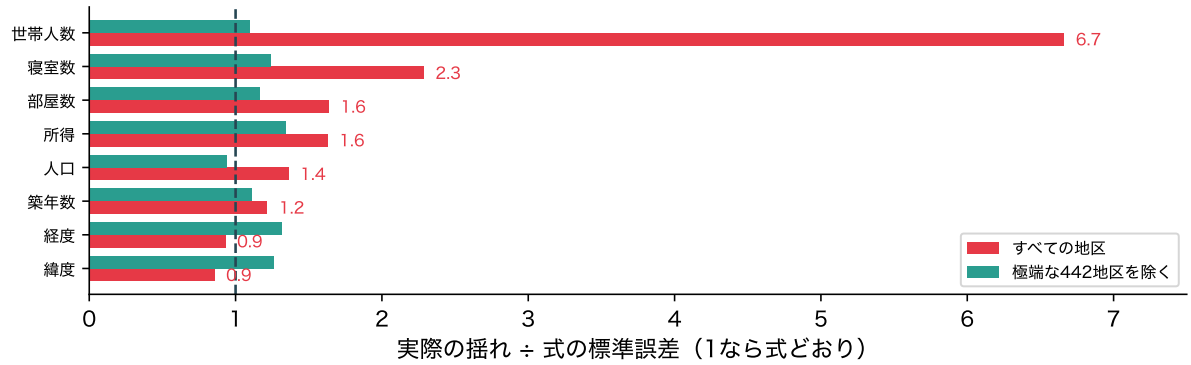


図 20: 実際の揺れと式の標準誤差の比。すべての地区（赤）と、部屋数・寝室数・世帯人数のどれかが上位 1% の地区を除いたとき（緑）。破線の 1 なら式どおり

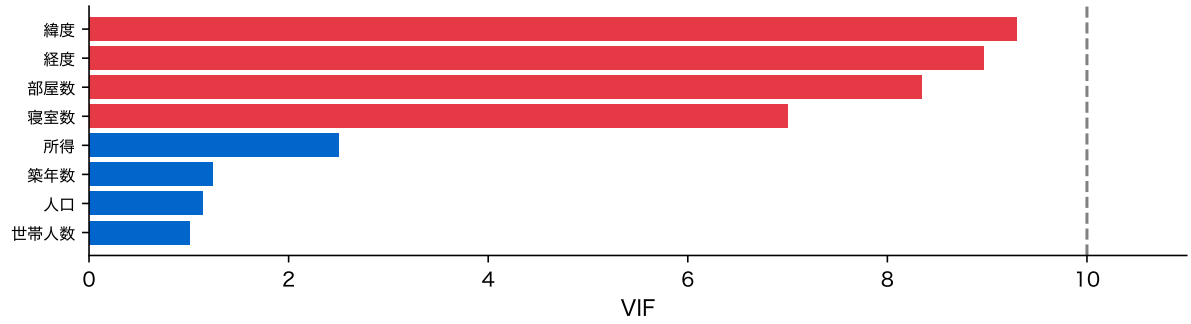


図 21: カリフォルニア住宅データの 8 列の VIF。赤は 5 以上の列、破線は目安とされる VIF = 10

表 2: カリフォルニア住宅データの VIF。相関行列の逆行列の対角と、列ごとの回帰による $1/(1 - R^2)$

変数	VIF（逆行列の対角）	VIF（回帰）
緯度	9.30	9.30
経度	8.96	8.96
部屋数	8.34	8.34
寝室数	6.99	6.99
所得	2.50	2.50
築年数	1.24	1.24
人口	1.14	1.14
世帯人数	1.01	1.01

予想②の、似た列の係数が斜めに細長くばらつくことは、実データの 20 組でも確かめられた（図 22）。似ていない所得と築年数の組 (a) は小さくまとまる。似た部屋数と寝室数の組 (b) は、第 I 部の図 9 (b) と同じく斜めに伸び、2 つの係数の相関は -0.85 である。片方が大きく出れば、もう片方が小さく出る。部屋数と寝室数をまとめた「広さ」の効き目はよく決まるが、その内訳は決まりにくい。

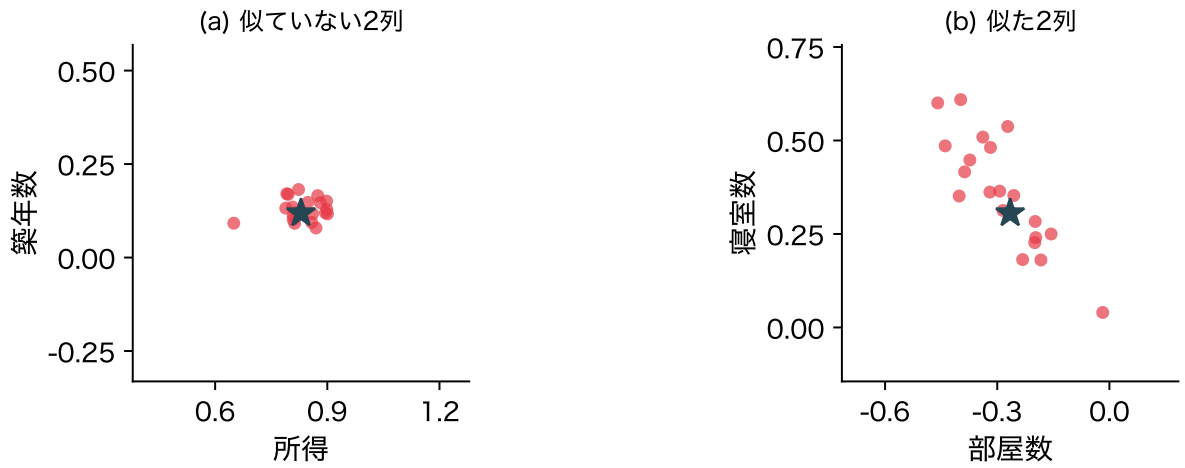


図 22: 地区を重ならない 20 組に分けて当てはめたときの係数(標準偏差 1 つぶんあたり)。★は全地区で当てはめた値で、2 枚とも★から ±0.45 の範囲を描いた。(a) 所得と築年数、(b) 部屋数と寝室数

それでも、1,032 地区ずつの 20 組のどれでも、部屋数の係数は負、寝室数の係数は正のままで、符号は変わらなかった。(16) 式の第 1 因子 σ^2/S_j は行が多いほど小さいので、VIF や極端な地区で膨らんでも、係数の大きさに比べて揺れはまだ小さい。部屋数の係数が負なのは、単回帰(標準偏差 1 つぶんあたり +0.175)と符号が逆だが、重回帰の係数は寝室数などを固定したときの効き目であり、単回帰とは別の問いに答えている(第 1 回)。部屋数を固定して寝室を増やすことは、ほかの部屋(居間など)を減らすことにあたる。

行の数の効き目は、行を減らしてみるとよくわかる(図 23)。手元の全地区を母集団に見立て、40 地区だけを標本として取り出して当てはめることを 20 回くり返した。部屋数の係数の標準偏差は、1,032 地区の組では 0.11 だったが、40 地区では 0.55 と桁違いに大きくなり、20 回のうち 4 回は符号まで変わった。同じ列の組で同じように似ていても、行が少なければ係数は読めなくなる。

このデータでわかったこと

第 II 部の結果をまとめる。予想①の、係数の不安定性は 1 回の当てはめの標準誤差 $\hat{\sigma}\sqrt{[(\mathbf{X}^\top\mathbf{X})^{-1}]_{jj}}$ で読める、という見込みは、半分外れた。地区を重ならない組に分けて実際の揺れを測ると、緯度と経度は式どおりだったが、世帯人数・寝室数・部屋数・所得は式より 2〜7 倍大きく揺れた。理由は、ごく一部の極端な地区が列の散らばりの大半を作り、誤差も大きいことにある。これは、$\mathbf{X}$ を固定し、どの行も同じ σ^2 とした第 I 部の前提が崩れていることを意味する。その地区を除くと、式はほぼ当たるようになった。式は前提が成り立つ範囲で使う道具であり、前提が崩れていないかを、データの分布や組に分けた当てはめで確かめる必要がある。予想②の、似た列の係数が斜めに細長くばらつくことは当たった。それでも 1,032 地区あれば符号は変わらず、40 地区だけで当てはめると、部屋数の係数は 20 回のうち 4 回、符号が逆になった。

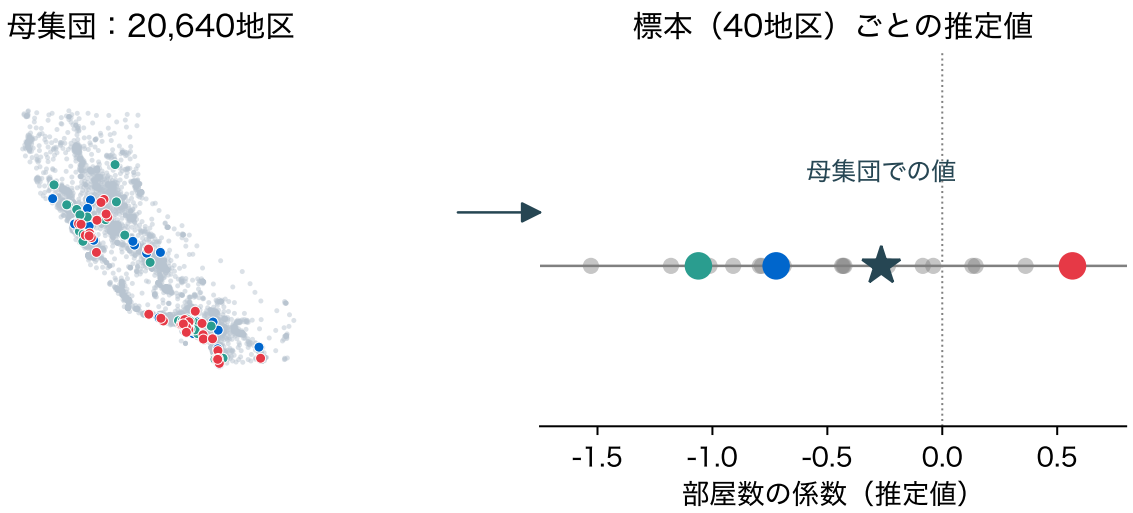


図 23: 20,640 地区を母集団とみなしたときの、40 地区の標本 3 つ(左、青・緑・赤)と、標本ごとの部屋数の係数の推定値(右、灰色は 20 回ぶん)。★は全地区での値、0 より右は符号が逆

締め

まとめと次回の問い

本章の問いは、係数の不安定性は何で決まるのか、であった。答えは $\mathbb{V}\mathrm{ar}(\hat{\beta}_j) = \sigma^2[(\mathbf{X}^\top\mathbf{X})^{-1}]_{jj}$ の 1 本の式である。第 2 回と同じく目的変数を取り直して平均すると、別の行の誤差の積が打ち消し合い、この式が出る。分散はノイズの分散に比例し、ノイズに比べて列の分散が大きいほど(SN 比が高いほど)小さく、列どうしが似ているほど大きい。2 列なら膨らみの倍率は $1/(1-r^2)$、列が何本でも $\mathrm{VIF} = 1/(1-R_j^2)$ である。未知の σ^2 は、残差平方和を $n-p$ で割れば平均して正しく見積もれ、そこから標準誤差が出る。そして列が完全に重なるときや列が行より多いときには、逆行列そのものが無くなり、係数は 1 つに決まらない。カリフォルニア住宅データでは、地区を選び直したときの実際の揺れが、緯度と経度では式どおりだったが、世帯人数や寝室数では式の数倍になった。ごく一部の極端な地区が、$\mathbf{X}$ を固定し、どの行も同じ σ^2 とした式の前提を崩していたためで、その地区を除くと式はほぼ当たった。式は、前提が成り立つかを確かめて使う道具である。似た列の係数が斜めに細長くばらつくことは実データでも確かめられ、行が多いので符号は変わらず、40 地区に減らすと符号が変わった。

最後に、次回への問いを置く。列が似て $(\mathbf{X}^\top\mathbf{X})^{-1}$ の対角が大きくなり係数が非常に不安定になるとき、あるいは逆行列が存在しないとき、データだけでは無数の候補(図 14 の赤い線の上)から 1 つを選べない。当てはまりだけを見る限り、どの候補も同じだからである。候補から 1 つを選ぶには、データの外から何かを足す必要がある。では、何を足せばよいのだろうか。

発展

発展：同じくらい当たるモデルと羅生門効果

本章の最後に、最近の研究の話題を 1 つ紹介する。図 14 では、列が完全に重なると目的関数の谷底が線になり、当てはまりのまったく同じ係数が無数にあった。完全には重ならなくても、似た 2 列では、当てはまりが「ほぼ」同じ係数の組がたくさんある。図 24 は、多重共線性の節と同じ作り方の 2 列（50 行）に目的変数を 1 組作り、訓練の二乗誤差が最小値から 5% 以内に収まる係数の組を塗ったものである。この集合を羅生門集合（Rashomon set）と呼ぶ。相関 0.9 では★のまわりの小さな楕円だが、相関 0.99 では細長く伸び、両方の軸をまたぐ。その中には、列 1 だけを使うモデル A（列 2 の係数は 0）と、列 2 だけを使うモデル B（列 1 の係数は 0）が含まれる。訓練の二乗誤差は、最小値に比べて A で 0.3%、B で 4.8% 大きいだけである。当てはまりで区別できないのに、「効くのは列 1 か列 2 か」という説明は正反対になる。

同じくらい当たるモデルが多数あることを、羅生門効果（Rashomon effect）と呼ぶ。同じ出来事を語る人ごとに話が食い違う映画『羅生門』にちなんで、次の論文が名付けた。

Breiman, L. (2001). Statistical modeling: The two cultures. Statistical Science, 16(3), 199–231.

羅生門集合が大きいときには、単純で解釈しやすいモデルがその中に見つかりやすい。一方で、変数の重要度や予測の説明は、たまたま選んだ 1 つのモデルしだいで変わりうる。そこで、1 つのモデルを選んで終わりにせず、羅生門集合の全体を調べて、どの説明がどれだけ揺るがないかを確かめる、という考え方が示されている。表形式のデータでノイズの多い問題を念頭に、この考え方を論じたのが次の論文である。

Rudin, C., Zhong, C., Semenova, L., Seltzer, M., Parr, R., Liu, J., Katta, S., Donnelly, J., Chen, H., & Boner, Z. (2024). Position: Amazing things come from having many good models. Proceedings of the 41st International Conference on Machine Learning, PMLR 235, 42783–42795.

本章で見た「影は 1 つ、内訳は無数」は、羅生門効果のもっとも単純な姿である。

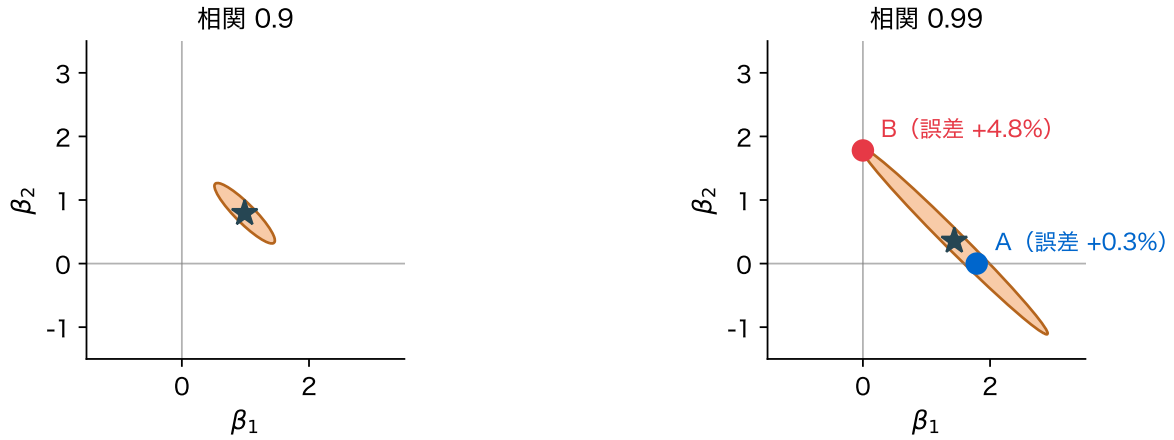


図 24: 羅生門集合（人工データ、50 行）。訓練の二乗誤差が最小（★）から 5% 以内の係数の組（橙）。(左) 相関 0.9、(右) 相関 0.99。A は列 1 だけ、B は列 2 だけを使うモデル