

第 3 回 係数の不安定性と最小二乗法の限界

列が似ているとき、点が遠いとき、列が多すぎる時

本章の問いは、第 2 回の締めで残った「係数の不安定性は何で決まるのか」である。最小二乗法の係数の分散は $\sigma^2(\mathbf{X}^T \mathbf{X})^{-1}$ で表される。この 1 本の式を読むと、列が似ているとき・点が手元の行から遠いとき・列が行より多いときに最小二乗法が通用しなくなることがわかる。

第 I 部 理論

係数は分割しただけで変わる

第 2 回の締めでは、分割の乱数を変えるだけでテストの数字が揺れることを見て、なぜ揺れるのかという問いを残した。本章では、別のデータで同じことを確かめるところから始める。使うのは、1990 年の米国国勢調査から作られたカリフォルニア州の住宅のデータである。20,640 の地区(数百世帯ずつの区画)について、地区の住宅価格の中央値と 8 列が記録されている。8 列は所得・築年数・1 世帯あたりの部屋数と寝室数・人口・1 世帯あたりの人数・緯度・経度である。8 列から住宅価格を予測する線形回帰を 20 回当てはめ直す。訓練 7 割・テスト 3 割に分ける乱数だけを 0 から 19 まで変えると、テスト誤差(第 2 回と同じく、テストの行での二乗誤差の平均)は 0.515 から 0.554 まで動く(図 1 (a))。データもモデルも同じで、違うのはどの 14,448 地区で係数を決め、どの 6,192 地区で測ったかだけである。

同じ 20 通りの分割で、決まった係数そのものを並べてみる(図 1 (b))。元の単位のままでは、変数ごとに係数の大きさを比べられない。そこで各変数の標準偏差を掛け、その変数が標準偏差 1 つぶん動いたときの価格(10 万ドル単位)の変化に直した。さらに揺れだけを比べるために、20 通りの平均からのずれを描いた。所得の係数は平均 0.84 のまわりでほとんど動かないが、寝室数の係数は 0.27 から 0.41 まで動く。20 通りの標準偏差は所得が 0.013、寝室数が 0.048 で、約 4 倍の開きがある。寝室数は、1 世帯あたりの部屋数との相関が 0.85 と強い。同じ手続きで決めた係数の中に、揺れやすいものと揺れにくいものがあるのである。

20,640 地区あれば、揺れても結論までは変わらない。だが、手元に 40 地区しかなかったらどうか。全地区から 40 地区だけを選んで当てはめることを、乱数を変えて 20 回くり返した(図 2)。部屋数の係数は -1.53 から +0.57 まで動き、20 回のうち 4 回は符号が逆になった。全地区で当てはめた値は -0.27 である。符号が変わると、「部屋の多い地区ほど安い」という読みが「高い」に入れ替わる。係数の揺れは、行が少ないと結論そのものを変える。

困りごととはほかにもある。狭い範囲に集まった点に、遠い点を 1 つ足すだけで、直線の傾きが大きく変わるこ




図 1: カリフォルニアの住宅価格の 8 列のモデルを、分割の乱数だけ変えて 20 回当てはめ直した結果。(a) テスト誤差、(b) 所得(青)と寝室数(赤)の係数(標準偏差 1 つぶんあたり)の、20 通りの平均からのずれ




図 2: 20,640 地区から 40 地区を選んで当てはめた部屋数の係数(標準偏差 1 つぶんあたり、20 回)。破線は全地区で当てはめた値、○は符号が逆になった回

がある。人工データでは、20 点で 0.81 だった傾きが、1 点を足すと 0.32 になる。また、伝票 2 枚からラーメン・餃子・ライスの単品の値段を割り出そうとすると、2 枚の合計に合う値段の組はいくらでも作れる。3 つとも、データから決めた係数が頼りにならない場面である。

本章の問いは 1 つである。係数の不安定性は、何で決まるのか。まず揺れを式で書くための道具をそろえ、最小二乗法の係数の分散が $\sigma^2(\mathbf{X}^T \mathbf{X})^{-1}$ で表されることを導く。そのうえで、この 1 本の式から 3 つのことを順に読む。列どうしが似ていると係数が不安定になること(共線性)、手元の行から離れた点では予測が揺れること(外挿)、列が行より多いと係数がそもそも決まらないことである。

第 2 回では汎化誤差を分け、訓練データの取り直しに対する予測の揺れを Variance と呼んだ。ただし、その中身は開かなかった。本章はその中身を線形回帰について開く。「モデル × 推定法」の地図でいえば、線形回帰 × 最小二乗法のマスから動かない。そのマスの推定がどこで頼りにならなくなるか、という境目を見ることになる。

道具：期待値と分散、 2×2 の逆行列

道具の前に、データの見方を 1 つ切り替える。冒頭の場面で、40 地区を選び直すたびに係数は変わった。手元の 20,640 地区も同じで、取り直せば変わるもののうちの 1 回分にすぎない。手元のデータそのものを要約する見方を記述統計(descriptive statistics)と呼ぶ。平均や相関係数、第 1 回の当てはめはこちらにあたる。手元のデータを取り直しうるものの 1 回分とみて、その背後と揺れを推し量る見方を推測統計(inferential statistics)と呼ぶ。本章で求める係数の揺れと標準誤差は、推測統計の道具である。

係数の不安定性を式で書くための道具を、ここにまとめておく。第 2 回では、訓練データを 300 回取り直して平均をとり、Bias² と Variance を数えた。本章では、その平均を回数無限の極限に置き換えた量を道具として使う。

身近な例から始める。サイコロを振るたびに、出る目は 1 から 6 のどれかに変わる。それでも、出た目の平均は、振る回数を増やすと 3.5 に落ち着いていく(図 3)。1 回ごとの値は読めないが、平均の行き着く先は決まっている。




図 3: サイコロを振った回数と、それまでに出了目の平均(人工データ、2000 回)。横軸は対数。赤の破線は期待値 3.5

定義 1 (期待値・分散・独立). 取り出すたびに値が変わる量を、確率変数(random variable)と呼ぶ。ここでは X と書く。 X を R 回取り出した値 $X_1, \dots, X_R$ の平均の、 $R \rightarrow \infty$ での行き着く先

$$\mathbb{E}[X] = \lim_{R \rightarrow \infty} \frac{1}{R} \sum_{r=1}^R X_r \quad (1)$$

を期待値(expected value)と呼ぶ。期待値は和と定数倍をそのまま通し、 $\mathbb{E}[aX + bY + c] = a\mathbb{E}[X] + b\mathbb{E}[Y] + c$ が成り立つ(線形性)。平均のまわりの散らばりの二乗の平均 $\mathbb{E}[(X - \mathbb{E}[X])^2]$ を、分散(variance)と呼ぶ。ここでは $\text{Var}(X)$ と書く。一方の値がもう一方の値に関係しないとき、 X と Y は独立(independence)であるという。独立なら $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ である。

サイコロの目なら、期待値は $(1 + 2 + \dots + 6)/6 = 3.5$ 、分散は $\{(1 - 3.5)^2 + \dots + (6 - 3.5)^2\}/6 \approx 2.92$ となる。2 つのサイコロを同時に振ったときの 2 つの目は、独立とみなせる。

第2回の分解は、この道具で書き直せる。点 x での予測 $\hat{g}(x)$ は、訓練データを取り直すたびに値が変わる確率変数である。第2回の平均の曲線 $\bar{g}(x) = \frac{1}{R} \sum_r \hat{g}_r(x)$ は、回数を無限にすれば期待値 $\mathbb{E}[\hat{g}(x)]$ になる。したがって、Bias² は $(\mathbb{E}[\hat{g}(x)] - g(x))^2$ 、Variance は $\text{Var}(\hat{g}(x))$ と書ける。第2回で「平均からのずれは足すと0」として消した交差項は、期待値では $\mathbb{E}[\hat{g}(x) - \mathbb{E}[\hat{g}(x)]] = 0$ として消える。本章はこの Variance の中身を、線形回帰について開く。

揺れるのは係数 p 個の組なので、期待値と分散をベクトルに広げる。

定義 2 (期待値ベクトルと分散共分散行列). 確率的に揺れる n 個の量を縦に並べたベクトル $\mathbf{y} = [y_1, \dots, y_n]^\top$ について、各成分の期待値を並べた $\mathbb{E}[\mathbf{y}] = [\mathbb{E}[y_1], \dots, \mathbb{E}[y_n]]^\top$ を期待値ベクトル、

$$\text{Var}(\mathbf{y}) = \mathbb{E}[(\mathbf{y} - \mathbb{E}[\mathbf{y}])(\mathbf{y} - \mathbb{E}[\mathbf{y}])^\top] \quad (2)$$

を分散共分散行列 (variance-covariance matrix) と呼ぶ。(2) 式は $n \times n$ の行列で、その (i, i') 成分は y_i と $y_{i'}$ の共分散 $\mathbb{E}[(y_i - \mathbb{E}[y_i])(y_{i'} - \mathbb{E}[y_{i'}])]$ 、対角成分は各 y_i の分散である。

各 y_i が互いに独立なら、定義 1 の $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ から共分散は0になる。さらに分散がそろって σ^2 なら、 $\text{Var}(\mathbf{y}) = \sigma^2 \mathbf{I}_n$ と書ける。

揺れる量を定数倍・足し合わせたときの分散は、スカラーから順に広げられる。1つの量なら $\text{Var}(ay) = a^2 \text{Var}(y)$ である。独立な $y_1, \dots, y_n$ の重み付きの和なら、二乗を展開したときの交差項の期待値が独立性から0になるので、 $\text{Var}(\sum_i a_i y_i) = \sum_i a_i^2 \text{Var}(y_i)$ となる。一般に、定数の行列 $\mathbf{A}$ を掛けたベクトル $\mathbf{A}\mathbf{y}$ については

$$\mathbb{E}[\mathbf{A}\mathbf{y}] = \mathbf{A} \mathbb{E}[\mathbf{y}], \quad \text{Var}(\mathbf{A}\mathbf{y}) = \mathbf{A} \text{Var}(\mathbf{y}) \mathbf{A}^\top \quad (3)$$

が成り立つ。1つ目は期待値の線形性を成分ごとに使ったものである。2つ目は、 $\mathbf{A}\mathbf{y} - \mathbb{E}[\mathbf{A}\mathbf{y}] = \mathbf{A}(\mathbf{y} - \mathbb{E}[\mathbf{y}])$ を (2) 式に入れると $\mathbb{E}[\mathbf{A}(\mathbf{y} - \mathbb{E}[\mathbf{y}])(\mathbf{y} - \mathbb{E}[\mathbf{y}])^\top \mathbf{A}^\top]$ となり、定数の $\mathbf{A}$ と $\mathbf{A}^\top$ を期待値の外に出せることから従う。 $\mathbf{A}$ が1行 $\mathbf{a}^\top$ で $\text{Var}(\mathbf{y}) = \sigma^2 \mathbf{I}_n$ なら、(3) 式は $\sigma^2 \mathbf{a}^\top \mathbf{a} = \sigma^2 \sum_i a_i^2$ となり、独立な和の式に戻る。サイコロ2つの目を並べた $\mathbf{y}$ なら $\text{Var}(\mathbf{y}) \approx 2.92 \mathbf{I}_2$ である。 $\mathbf{A} = [1 \ 1]$ とすると $\mathbf{A}\mathbf{y}$ は目の和で、分散は2倍の約5.83になる。 $\mathbf{A} = [1 \ -1]$ として目の差をとっても、 $(-1)^2 = 1$ なので分散は同じである。引き算をしても、分散は足し算で増える。

もう1つの道具は、 2×2 の行列の逆行列である。

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix}^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} \quad (4)$$

右辺を元の行列に掛ければ単位行列になることで確かめられる。分母の $ad - bc$ を行列式 (determinant) と呼ぶ。行列式が0なら右辺は作れず、逆行列は存在しない。第1回の逆行列の定義でいう、正則でない行列である。また、対称な行列 ($b = c$) の逆行列は、(4) 式のとおりやはり対称になる。これは一般の大きさの対称行列でも成り立つ。

係数の分散を導く

道具がそろったので、係数の不安定性を式にする。まず、何が揺れるのかを決めておく。モデルを

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \mathbb{E}[\boldsymbol{\varepsilon}] = 0, \quad \text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_n \quad (5)$$

とし、データ行列 $\mathbf{X}$ は固定されているとみなす。第 2 回ではノイズが正規分布 $N(0, \sigma^2)$ に従うと仮定したが、ここで使うのはその平均 0 と分散 σ^2 だけである。同じ説明変数の値を持つ行を集め直すたびに、目的変数だけがノイズのぶん変わる、という見方である。第 2 回の $y = g(x) + \varepsilon$ で、 g を線形の $\mathbf{X}\boldsymbol{\beta}$ とした場合にあたる。 $\mathbf{X}\boldsymbol{\beta}$ は定数なので、 $\text{Var}(\mathbf{y}) = \text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_n$ である。

最初はスカラーで考える。第 1 回の単回帰 $y_i = \beta x_i + e_i$ の解は $\hat{\beta} = \sum_i x_i y_i / \sum_i x_i^2$ だった。これは $w_i = x_i / \sum_i x_i^2$ を重みとする y_i の重み付きの和 $\sum_i w_i y_i$ であり、各 y_i は独立で分散 σ^2 なので、独立な和の分散から

$$\text{Var}(\hat{\beta}) = \sum_{i=1}^n w_i^2 \sigma^2 = \frac{\sigma^2 \sum_i x_i^2}{(\sum_i x_i^2)^2} = \frac{\sigma^2}{\sum_{i=1}^n x_i^2} \quad (6)$$

を得る。係数の不安定性は、ノイズの分散 σ^2 が大きいほど大きく、 x の二乗和が大きいほど小さい。二乗和は、行を増やしても、 x を広い範囲で取っても大きくなる。図 4 は人工データでこれを確かめたものである。真の傾きを 1、ノイズの標準偏差を 1 とし、20 個の x を (a) $[-1, 1]$ 、(b) $[-3, 3]$ から取った。 x は固定したまま y だけを 30 回取り直して直線を引くと、(a) の直線は大きく扇状に開き、(b) ではほとんど重なる。(6) 式による傾きの標準偏差は、(a) で 0.41、(b) で 0.11 である。

同じ計算をベクトルで書いておく。 x_i と y_i を縦に並べたベクトルを $\mathbf{x}, \mathbf{y}$ とすると、 $\hat{\beta} = \mathbf{x}^\top \mathbf{y} / \mathbf{x}^\top \mathbf{x}$ である。重みを並べた $\mathbf{w} = \mathbf{x} / (\mathbf{x}^\top \mathbf{x})$ を使えば $\hat{\beta} = \mathbf{w}^\top \mathbf{y}$ と書ける。これは (3) 式で $\mathbf{A}$ が 1 行 $\mathbf{w}^\top$ の場合にあたり、

$$\text{Var}(\hat{\beta}) = \mathbf{w}^\top (\sigma^2 \mathbf{I}_n) \mathbf{w} = \sigma^2 \mathbf{w}^\top \mathbf{w} = \frac{\sigma^2}{\mathbf{x}^\top \mathbf{x}}$$

となる。成分で書けば (6) 式に戻る。

次に行列で書く。第 1 回の正規方程式の解 $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ は、 $\mathbf{A} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ とおけば $\mathbf{A} \mathbf{y}$ という形をしており、 $\mathbf{X}$ が固定なので $\mathbf{A}$ は定数の行列である。したがって (3) 式がそのまま使え、

$$\begin{aligned} \mathbb{E}[\hat{\boldsymbol{\beta}}] &= \mathbf{A} \mathbb{E}[\mathbf{y}] = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} = \boldsymbol{\beta} \\ \text{Var}(\hat{\boldsymbol{\beta}}) &= \mathbf{A} (\sigma^2 \mathbf{I}_n) \mathbf{A}^\top = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \end{aligned} \quad (7)$$

を得る。1 行目は、係数は取り直すたびに揺れるが、平均すれば真の値に一致すること (不偏性 (unbiasedness)) を表す。2 行目では、 $\mathbf{X}^\top \mathbf{X}$ が対称なのでその逆行列も対称であり、 $\mathbf{A}^\top = \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1}$ となることを用い

た。真ん中の $\mathbf{X}^\top \mathbf{X}$ が逆行列の 1 つと打ち消し合う。 $p = 1$ のとき $\mathbf{X}^\top \mathbf{X} = \mathbf{x}^\top \mathbf{x} = \sum_i x_i^2$ となり、(7) 式はベクトルの式、さらに (6) 式に戻る。(7) 式の対角の j 番目は係数 $\hat{\beta}_j$ の分散である。対角の外の (j, k) 成分は $\hat{\beta}_j$ と $\hat{\beta}_k$ の共分散で、2 つの係数がそろって揺れるか逆向きに揺れるかを表す。これが第 2 回で開かなかった Variance の中身である。

(7) 式の σ^2 は未知なので、残差から見積もる。

$$\hat{\sigma}^2 = \frac{\|\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|_2^2}{n - p} \quad (8)$$

分子は第 1 回の残差平方和である(以下、RSS と略す)。 $\hat{\boldsymbol{\beta}}$ はまさに残差平方和を最小に選ばれているので、残差は真の誤差 ε より短くなる。 n ではなく $n - p$ で割るのは、 n で割ると σ^2 を小さく見積もるからである。 p 個の係数を合わせたぶんだけ自由に動ける向きが減る、と言ってもよい。(8) 式を (7) 式に入れ、対角の j 番目の平方根を取った $\hat{\sigma} \sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}}$ は、1 回の当てはめから読める係数 $\hat{\beta}_j$ の揺れである。これを標準誤差(standard error)と呼ぶ。




図 4: 人工データで、 x を固定したまま y を 30 回取り直して引いた原点を通る直線(赤)。(a) x が狭い範囲、(b) 広い範囲。青は 1 回ぶんの点、緑はデータのある範囲、破線は予測の ± 2 標準偏差(後述)

列が似ていると係数が不安定になる : 共線性と VIF

では、何が (7) 式の $(\mathbf{X}^\top \mathbf{X})^{-1}$ を大きくするのか。列が 1 本なら、効くのは x の広がりだけだった。列が 2 本以上になると、列どうしの関係も $\mathbf{X}^\top \mathbf{X}$ に入る。

まず人工データで見ておく(図 6)。50 行の 2 列を、相関がちょうど 0 の場合と 0.9 の場合について作った。真の係数は $(1, 1)$ 、ノイズの標準偏差は 1 とし、 $\mathbf{X}$ は固定したまま $\mathbf{y}$ を 300 回取り直した。相関 0 では推定値は★のまわりに丸く小さく散らばる。相関 0.9 では、左上から右下への斜めの向きに細長く伸びる。 $x_1 \approx x_2$ なら $\beta_1 x_1 + \beta_2 x_2 \approx (\beta_1 + \beta_2) x_1$ なので、データは和 $\beta_1 + \beta_2$ はよく決めるが、その内訳はほとんど決められない。内訳のわずかな違いは当てはまりをほとんど変えないので、ノイズしだいで大きく動くのである。これを共線性と呼ぶ。いつも 2 人そろって押す車にたとえられる(図 5)。車の進み方から 2 人の力の合計はわかるが、1 人ずつの力はわからない。1 人で押す日があれば、2 人の力を分けられる。それが似ていない列である。冒頭の 40 地区で部屋数の係数の符号が逆になった背景にも、部屋数と寝室数がそろって動くことがある。このことは第 II

部で確かめる。

1人ずつの力は？

B さん A さん




図 5: 共線性のたとえ(概念図)。いつも 2 人で押す車では、進み方から 2 人の力の合計はわかるが、内訳はわからない




図 6: 人工データで y を 300 回取り直したときの係数の推定値。★は真の値。(a) 2 列の相関が 0、(b) 0.9

これを式で確かめる。2 本の列はどちらも平均 0 に中心化しておく。中心化した列は切片の列(すべて 1)と直交するので、切片の推定値は $\bar{y}$ になり、傾きの推定はほかから切り離せる。このとき

$$\mathbf{X}^T \mathbf{X} = \begin{bmatrix} \sum_i x_{i1}^2 & \sum_i x_{i1}x_{i2} \\ \sum_i x_{i1}x_{i2} & \sum_i x_{i2}^2 \end{bmatrix} = (n-1) \begin{bmatrix} s_1^2 & s_{12} \\ s_{12} & s_2^2 \end{bmatrix}$$

であり、 s_1^2, s_2^2 は各列の分散、 s_{12} は共分散である(第 1 回の定義)。 $\mathbf{X}^T \mathbf{X}$ は、列どうしがどれだけ似ているかの表になっている。(4) 式で逆行列を作り、左上の成分を取って相関係数 $r_{12} = s_{12}/(s_1 s_2)$ で書き直すと

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2(n-1)s_2^2}{(n-1)^2(s_1^2s_2^2 - s_{12}^2)} = \frac{\sigma^2}{(n-1)s_1^2} \cdot \frac{1}{1-r_{12}^2} \quad (9)$$

となる。第 1 因子は、2 本の列が無相関だったときの分散で、(6) 式の $\sum_i x_i^2$ を $(n-1)s_1^2$ と書いたものと同じである。第 2 因子が、列が似ているために膨らむ倍率である。 $r_{12} = 0.9$ なら $1/(1-0.81) \approx 5.3$ 倍、標準偏差にして約 2.3 倍になる。身近な例でいえば、カフェのコーヒーの値段を、注いだ量とカップの大きさの 2 列で説明する場合である。大きいカップほど多く注ぐので、2 列の相関は 0.99 にもなりうる。このとき倍率は約 50 倍、標準偏差にして約 7 倍であり、値段の差が量によるのかカップによるのかは、ほとんど分けられない。同じく右上の成分からは、 $\hat{\beta}_1$ と $\hat{\beta}_2$ の共分散が $-\sigma^2 s_{12} / \{(n-1)(s_1^2 s_2^2 - s_{12}^2)\}$ となり、 $r_{12} > 0$ なら負である。片方の係数が大きく出れば、もう片方は小さく出る。図 6 (b) が左上から右下へ伸びるのは、このためである。

定義 3 (多重共線性と分散拡大係数). 説明変数の列どうしが、ほぼ 1 次式の関係にある状態を多重共線性 (multicollinearity) と呼ぶ。列 j を、残りのすべての列(と切片)で回帰したときの決定係数を R_j^2 とする。 $1/(1-R_j^2)$ を、列 j の分散拡大係数 (variance inflation factor) (VIF) と呼ぶ。ここでは VIF_j と書く。係数の分散は

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{(n-1)s_j^2} \cdot \text{VIF}_j, \quad \text{VIF}_j = \frac{1}{1-R_j^2} \quad (10)$$

と、似ていないときの分散と VIF の積に分かれる。

列が 2 本なら $R_1^2 = r_{12}^2$ であり、(10) 式は (9) 式に一致する。列が何本でも (10) 式の形になることは、(7) 式の逆行列を区別して計算すると示せる(ここでは証明を省く)。 R_j^2 を相関係数ではなく「残りすべての列で回帰した決定係数」で定めるのは、 $x_3 \approx x_1 + x_2$ のように 3 本以上が組み合わせられて初めて成り立つ関係も捕まえるためである。このとき、どの 2 本の相関も中くらいでありながら、 R_3^2 は 1 に近くなりうる。

VIF は R_j^2 が小さいうちはほとんど 1 のままで、 $R_j^2 = 0.5$ でも 2 にすぎない。ところが 1 の近くでは急に大きくなり、0.9 で 10、0.95 で 20、0.99 で 100 になる(図 7)。標準誤差は分散の平方根なので $\sqrt{\text{VIF}_j}$ 倍になり、VIF が 10 なら約 3.2 倍である。VIF は倍率であって絶対量ではない。(10) 式の第 1 因子は、行を増やせば小さくなるので、VIF が大きくても行が十分多ければ係数は安定しうる。VIF の値は細かく比べず、 $1 \cdot 10 \cdot 100$ のどのあたりかと桁で読むのがよい。




図 7: 分散拡大係数 $\text{VIF}_j = 1/(1-R_j^2)$ と、目安とされる $\text{VIF} = 10$ (赤の破線)

VIF は行列の計算で一度に求まる。

1. 切片の列を除いた各列を標準化し、 $\mathbf{Z}$ ($n \times p'$ 、 p' は切片を除いた列の数)を作る
2. 相関行列 $\mathbf{R} = \frac{1}{n-1} \mathbf{Z}^\top \mathbf{Z}$ を作る
3. $\mathbf{R}^{-1}$ を求め、その対角成分を並べる。 $\text{VIF}_j = [\mathbf{R}^{-1}]_{jj}$ である

列が 2 本なら $\mathbf{R} = \begin{bmatrix} 1 & r \\ r & 1 \end{bmatrix}$ で、(4) 式から $\mathbf{R}^{-1}$ の対角は $1/(1-r^2)$ となり、(9) 式の倍率と一致する。第 1 回の計算手順では正規方程式を解くだけで、逆行列そのものは作らなかった。ここでは逆行列の対角そのものが答えなので、逆行列を作る。列 j を残りの列で回帰して $1/(1-R_j^2)$ を p' 回計算しても同じ値になり、第 II 部でこれを確かめる。VIF は $\mathbf{X}$ だけで決まり、目的変数 $\mathbf{y}$ を見ていないので、データを集めた段階で「この列の組では係数は読めない」と先にわかる。

予測の揺れ : 射影とてこ比

冒頭の困りごとの 1 つは、狭い範囲の点に遠い 1 点を足すだけで、直線の傾きが大きく変わることだった。そうした行を、当てはめる前に見つけられるだろうか。入力ミスや、施設・寮のように性質の違う行を前もって拾えれば、結論を 1 行に握られずにすむ。手がかりは、手元の行の予測値を、係数を通さずに $\mathbf{y}$ から直接書くことにある。第 1 回の正規方程式の答え $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ を、予測値の式 $\hat{\mathbf{y}} = \mathbf{X} \hat{\boldsymbol{\beta}}$ に代入すると

$$\hat{\mathbf{y}} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{H} \mathbf{y} \quad (11)$$

となる。 $\mathbf{y}$ の前に、 $\mathbf{X}$ だけでできた行列 $\mathbf{H}$ が残る。大きさを確かめると、 $n \times p$ の $\mathbf{X}$ 、 $p \times p$ の $(\mathbf{X}^\top \mathbf{X})^{-1}$ 、 $p \times n$ の $\mathbf{X}^\top$ を掛けたものなので、 $\mathbf{H}$ は $n \times n$ である(図 8)。隣り合う箱の内側の大きさ(p と p)がそろっているので、掛け算ができる。




図 8: 射影行列 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ の大きさ(概念図)。箱の縦は行の数、横は列の数。赤は掛け算でそろった次元

定義 4 (射影行列). $\mathbf{y}$ に掛けると予測値を与える $n \times n$ の行列 $\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ を、射影行列(projection matrix)(ハット行列)と呼ぶ。ここでは $\mathbf{H}$ と書く。 $\mathbf{H}$ は対称($\mathbf{H}^\top = \mathbf{H}$)かつ冪等(idempotent)($\mathbf{H}\mathbf{H} = \mathbf{H}$)である。

冪等であることは、行列の計算で確かめられる。

$$\mathbf{H}\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\underbrace{\mathbf{X}^\top\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}}_{\mathbf{I}_p}\mathbf{X}^\top = \mathbf{H}$$

真ん中の $\mathbf{X}^\top\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}$ が単位行列になるので、 $\mathbf{H}$ に戻る。対称であることは、 $(\mathbf{X}^\top\mathbf{X})^{-1}$ が対称であることから従う。 $\mathbf{H}$ は $\mathbf{X}$ だけで決まり、 $\mathbf{y}$ を含まない。

この計算を図で読む(図 9)。 $\mathbf{X}\boldsymbol{\beta} = \sum_j \beta_j \mathbf{x}_j$ は $\mathbf{X}$ の列の重み付き和なので、 $\boldsymbol{\beta}$ をどう選んでも、 $\mathbf{X}$ の列が張る平らな空間(列空間(column space))の中にある。観測 $\mathbf{y}$ はふつうその外にある。最小二乗法は、列空間の中で $\mathbf{y}$ に最も近い点を選ぶ。平面の外から平面へ最も近い点は垂線の足であり、それが $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ である。 $\hat{\mathbf{y}}$ を $\mathbf{y}$ の正射影(orthogonal projection)、すなわち列空間に落とした影と呼ぶ。冪等であることは、一度落とした影をもう一度落としても動かない、という意味になる。




図 9: 観測 $\mathbf{y}$ を、 $\mathbf{X}$ の列空間への影 $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ と、直交補空間(点線)への影 $(\mathbf{I} - \mathbf{H})\mathbf{y} = \mathbf{e}$ に分ける(概念図)。残差 $\mathbf{e}$ は平面に垂直で、どの列とも直交する

垂線の足であることは、残差 $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$ がどの列とも直交する、すなわち各列との内積が 0 であることを意味する。全部の列について並べると

$$\mathbf{X}^\top \mathbf{e} = \mathbf{X}^\top \mathbf{y} - \mathbf{X}^\top \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = 0$$

となる。これは第 1 回の正規方程式 $\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}$ を並べ替えたものにほかならない。勾配を 0 とおいて得た正規方程式は、残差がどの列とも直角という条件だったのである。

列空間のどの向きとも直交する向きを、すべて集めたものを、列空間の直交補空間(orthogonal complement)と呼ぶ。図 9 のように $n = 3$ で列が 2 本なら、列空間は平面、直交補空間はそれに垂直な 1 本の直線(点線)である。残差は、いつもこの直交補空間の中にある。 $\mathbf{e} = \mathbf{y} - \mathbf{H}\mathbf{y} = (\mathbf{I} - \mathbf{H})\mathbf{y}$ なので、観測は

$$\mathbf{y} = \mathbf{H}\mathbf{y} + (\mathbf{I} - \mathbf{H})\mathbf{y} \quad (12)$$

と、列空間への影と直交補空間への影の和に分かれる。 $\mathbf{I}-\mathbf{H}$ も対称で、 $(\mathbf{I}-\mathbf{H})(\mathbf{I}-\mathbf{H}) = \mathbf{I}-2\mathbf{H}+\mathbf{H}\mathbf{H} = \mathbf{I}-\mathbf{H}$ を満たす。直交補空間への射影行列である。また $\mathbf{H}(\mathbf{I}-\mathbf{H}) = \mathbf{H}-\mathbf{H}\mathbf{H} = \mathbf{O}$ であり、直交補空間への影を列空間に落とすと原点の 1 点になる。ラーメン屋の例では、残差は $\mathbf{e} = [-100, 0, 100]^\top$ である。列 $[1, 1, 1]^\top$ と直交するとは、成分を足すと 0 になることであり、直交補空間は 3 次元のうちの「足すと 0」の 2 次元である。

次元を数えると、(8) 式で $n-p$ で割った理由が見える。 n 次元の空間は、列空間の p 次元と直交補空間の $n-p$ 次元に分かれる。残差は直交補空間に閉じ込められているので、自由に動ける向きは $n-p$ 本しかない。誤差 ϵ の揺れは n 本の向きに同じ σ^2 ずつ散らばっているが、残差に残るのはそのうち $n-p$ 本ぶんである。そのため残差平方和を $n-p$ で割ると、 σ^2 の見積もりになる。ラーメン屋なら $\hat{\sigma}^2 = (100^2 + 0^2 + 100^2)/(3-1)$ で、 $\hat{\sigma}$ は 100 円である。

予測値の揺れを読むために、 $\mathbf{H}$ の対角成分に名前を付けておく。

定義 5 (てこ比). 射影行列 $\mathbf{H}$ の i 番目の対角成分を、行 i のてこ比 (leverage) と呼ぶ。ここでは h_{ii} と書く。 $\mathbf{X}$ の第 i 行を縦に並べたものを $\tilde{\mathbf{x}}_i$ とすると、 $h_{ii} = \tilde{\mathbf{x}}_i^\top (\mathbf{X}^\top \mathbf{X})^{-1} \tilde{\mathbf{x}}_i$ である。

(11) 式は $\mathbf{y}$ に定数の行列を掛けた形なので、(3) 式から

$$\text{Var}(\hat{\mathbf{y}}) = \mathbf{H}(\sigma^2 \mathbf{I}_n) \mathbf{H}^\top = \sigma^2 \mathbf{H} \mathbf{H} = \sigma^2 \mathbf{H}, \quad \text{Var}(\hat{y}_i) = \sigma^2 h_{ii} \quad (13)$$

を得る。てこ比は、その行の予測値がノイズにどれだけ揺さぶられるかを表す。冪等性から $h_{ii} = \sum_{i'} h_{ii'}^2 \geq h_{ii}^2$ なので $0 \leq h_{ii} \leq 1$ であり、全員のてこ比の和は列の数 p に等しい。したがって平均は p/n であり、手元の行の予測値の分散を平均すると $\sigma^2 p/n$ になる。列を 1 本足すたびに、揺れは平均で σ^2/n ずつ増える。第 2 回で、列を増やすと過学習 (Variance 過多) に向かったのは、このためである。 $p=1$ なら $h_{ii} = x_i^2 / \sum_{i'} x_{i'}^2$ で、 x_i が真ん中(0)から遠い行ほどてこ比が大きい。てこ比は $\mathbf{X}$ だけで決まり、 y_i が外れているかどうかとは別の概念である。

残差の揺れも同じ道具で読める。 $\mathbf{e} = (\mathbf{I}-\mathbf{H})\mathbf{y}$ に (3) 式を当てると

$$\text{Var}(\mathbf{e}) = (\mathbf{I}-\mathbf{H})(\sigma^2 \mathbf{I}_n)(\mathbf{I}-\mathbf{H})^\top = \sigma^2 (\mathbf{I}-\mathbf{H}), \quad \text{Var}(e_i) = \sigma^2 (1-h_{ii}) \quad (14)$$

となる。予測値の揺れ $\sigma^2 h_{ii}$ と残差の揺れ $\sigma^2 (1-h_{ii})$ は、足すと y_i の揺れ σ^2 になる。てこ比の大きい行は、予測値が自分の y_i に引き寄せられるぶん、残差が小さく出る。

小さな例で確かめる。ラーメン屋に 3 回行き、毎回 1 杯食べて、800 円・900 円・1000 円を払ったとする。杯数を $\mathbf{x} = [1, 1, 1]^\top$ 、支払いを $\mathbf{y} = [800, 900, 1000]^\top$ とし、原点を通る直線 $y = \beta x$ を当てはめる。傾き β は 1 杯の値段である。 $\mathbf{X}^\top \mathbf{X} = 3$ なので、 $\mathbf{H}$ はすべての成分が $1/3$ の 3×3 行列になる。 $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ は、どの行も 3 回の支払いの平均 900 円である。平均をもう一度平均しても 900 円のままであり、これが冪等性にあたる。てこ比はどれも $1/3$ で、和は列の数 1 に等しい。杯数が 1 杯・2 杯・6 杯だったとすると、 $\sum_i x_i^2 = 41$ で、てこ比は $1/41, 4/41, 36/41 \approx 0.88$ になる。6 杯の回だけで、1 杯の値段がほぼ決まる。

シーソーにたとえると覚えやすい(図 10)。直線は、データの中心(原点を通る直線なら原点)を支点に回る板である。同じ重さの子でも、端に座るほど板を大きく傾ける。てこ比の大きい行は、端に座った子にあたる。てこ比

という名前も、この「てこ」から来ている。




図 10: てこ比のたとえ(概念図)。直線はデータを中心を支点に回る板で、中心から遠い行ほど板を大きく傾ける

てこ比の大きい行と、行ごとの取り直し

てこ比の大きい行は、係数を自分のほうへ引き寄せる力が強い。冒頭の困りごとに戻る。図 11 は、図 4 (a) の 20 点に、 $x = 5$ の点を 1 つ足した人工データである。足した点の y は 1 で、真の直線 $y = x$ から下に外れている。この点のてこ比は 0.80 で、平均 $p/n = 1/21 = 0.048$ の約 17 倍である。原点を通る直線の傾きは、この点を除くと 0.81、含めると 0.32 になる。21 行のうちの 1 行が、傾きの大半を握っているのである。しかも、この点は真の直線から -4 外れているのに、残差は -0.60 にすぎない。(14) 式のとおり、この点の残差の標準偏差は $\sigma\sqrt{1-h_{ii}} = 0.44\sigma$ に縮んでいる。残差の大きさを見ても、この点は見つからない。この 1 行の力の強さは、 y を見る前に、 $\mathbf{X}$ だけから計算したてこ比でわかる。

(7) 式は、 $\mathbf{X}$ を固定して y だけを取り直したときの揺れであった。ところが、実際にデータを集め直すと、行そのものが入れ替わる。遠い点が入るかどうかも、集め直すたびに変わる。行の入れ替わりに対する揺れは、手元のデータだけからでも測れる。

定義 6 (ブートストラップ). 手元の n 行から、同じ行を何度選んでもよい形(復元抽出)で n 行を選び直して当てはめ直す。これを何度もくり返して係数の不安定性を測る方法を、ブートストラップ(bootstrap)と呼ぶ。

図 11 の 21 行で 1000 回くり返すと、遠い点を選ばれた回と選ばれなかった回で、直線が 2 つの束に分かれる。傾きの標準偏差は 0.36 で、(8) 式と (7) 式による標準誤差 0.20 の約 1.8 倍である。式は、遠い点がいつもそこにあるとしたときの揺れであり、その点が入ったり入らなかったりする揺れは含まない。てこ比の大きい行があるとき、行ごとの取り直しに対する揺れは、式の標準誤差より大きくなりうる。

外挿：手元の行から離れた点

次に、手元に無い新しい点 $\mathbf{x}_0$ での予測 $\hat{y}_0 = \mathbf{x}_0^\top \hat{\beta}$ を考える。これも $\hat{\beta}$ に定数の 1 行を掛けた形なので、(3) 式と (7) 式から




図 11: てこ比の大きい 1 点(人工データ)。青の 20 点に $x = 5$ の赤の点を足した。赤の実線は 21 点で、黒の破線は赤の点を除いて引いた直線。橙は 21 行を復元抽出して引き直した直線(80 回ぶん)

$$\text{Var}(\hat{y}_0) = \mathbf{x}_0^\top \text{Var}(\hat{\beta}) \mathbf{x}_0 = \sigma^2 \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0 \quad (15)$$

となる。てこ比の $\tilde{x}_i$ を $\mathbf{x}_0$ に置き換えただけの形である。 $p = 1$ なら $\sigma^2 x_0^2 / \sum_i x_i^2$ で、係数の不安定性 (6) 式が x_0^2 倍されて予測に移る。図 4 の破線は、その ± 2 標準偏差の帯であり、 x_0 が 0 から離れるほど開く。切片と x の 2 列なら、(4) 式で計算すると $\sigma^2 \{1/n + (x_0 - \bar{x})^2 / \sum_i (x_i - \bar{x})^2\}$ となり、揺れはデータの中心からの距離の二乗とともに増える。第 2 回のバイアス・バリアンス分解に戻ると、モデルの形が正しいとき、不偏性から $\mathbb{E}[\hat{y}_0] = \mathbf{x}_0^\top \beta$ なので Bias^2 は 0 であり、Variance はちょうど (15) 式である。新しい点での誤差の期待値は、 $\sigma^2 \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0 + \sigma^2$ に分かれる。第 2 回では 300 回の取り直しで数えた量が、線形回帰では式で計算できる。

データのある範囲の外で予測することを、第 1 回で外挿(extrapolation)と呼んだ。(15) 式は範囲の外でも増え続けるので、外挿した予測は揺れが大きい。しかも (15) 式は、モデル (5) 式が範囲の外でも成り立つと仮定したうえでの揺れである。本当の関係が範囲の外で曲がっていれば、その系統的なずれ(第 2 回の Bias^2)は、データの無い場所では確かめようがない。外挿の危うさのうち、揺れの部分は式で見えるが、形の部分は見えないのである。

人工データで極端な例を見ておく(図 12)。かき氷屋の夏の 20 日について、気温 24~34 °C と売れた杯数を記録した。本当の関係は、寒いほど 0 に近づく S 字の曲線とした。夏の 20 日で引いた直線は、記録の範囲ではよく当てはまる。ところが記録にない 10 °C の日まで伸ばすと、予測は -126 杯という、ありえない値になる。本当の売上は 0.6 杯である。この失敗は、夏の 20 日だけを見ていても気づけない。

変数が多いときは、各変数の値が 1 つずつは範囲の中にあっても、その組み合わせが点の雲の外にあることがある。図 13 は、図 6 (b) で使った相関 0.9 の 2 列(50 行)である。★の点 (1.5, -1.5) は、 x_1 も x_2 も範囲の中にあるが、雲を横切る向きに外れている。その $\mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0$ は 0.90 で、平均 $p/n = 0.04$ の約 23 倍、手元の 50 行のてこ比の最大 0.11 よりずっと大きい。原点から同じ遠さでも、雲に沿った点 (1.5, 1.5) なら 0.05 にすぎない。 $\mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0$ は、そうした組み合わせの外れ方も測る。第 1 回の落とし穴では、変数が多いと外挿が見えにくくなることに触れた。この量が、その外れ方を測る道具であり、第 II 部で実データに当てる。




図 12: かき氷の売上と気温(人工データ)。緑は記録のある範囲、赤は記録から引いた直線、破線は本当の関係。
★は記録がない 10 °C の日の予測




図 13: 相関 0.9 の 2 列(人工データ、50 行)。破線は各列の最小値と最大値。★はどちらの列も範囲の中だが雲の外の点、◆は原点から同じ遠さで雲に沿った点

逆行列が無いとき : 完全な共線と $p > n$

(9) 式の倍率 $1/(1-r_{12}^2)$ は、相関が 1 に近づくほど大きくなり、 $r_{12} = 1$ では分母が 0 になる。このとき $\mathbf{X}^T \mathbf{X}$ の行列式 $(n-1)^2 s_1^2 s_2^2 (1-r_{12}^2)$ はちょうど 0 であり、(4) 式の逆行列は作れない。分散が「とても大きい」のではなく、係数が 1 つに決まらないのである。

目的関数の形で見るとわかりやすい(図 14)。相関 0.9 の 2 列では、目的関数の等高線は斜めに細長い楕円で、底(★)は 1 点に決まる。図 6 (b) の推定値が伸びた向きは、この楕円の長い向きと同じである。相関が 1、つまり

$x_2 = x_1$ なら $\mathbf{X}\boldsymbol{\beta} = (\beta_1 + \beta_2)\mathbf{x}_1$ となる。和が同じ組なら、どれもまったく同じ予測になる。等高線は平行な直線になり、底は 1 点に定まらず、直線 $\beta_1 + \beta_2 = 2$ の全体になる。一方で、列空間は 1 本の直線のままだので、影 $\hat{y}$ は 1 つに決まっている。決まらないのは、影を列にどう割り振るかという係数の内訳だけである。




図 14: 2 列の場合の目的関数の等高線(人工データ)。(a) 相関 0.9 では底が 1 点(★)、(b) 相関 1 では底が直線(赤)になり、解が無数にある

行より列が多い場合($p > n$)は、列の中身によらず必ずこうなる。冒頭の伝票がその例である(図 15)。昼の伝票はラーメンと餃子で 1,100 円、夜の伝票はラーメンとライスで 1,000 円だった。伝票を行、品目を列、単品の値段を係数とみれば、2 行で係数を 3 個決めることになる。ラーメン 800 円・餃子 300 円・ライス 200 円でも、900 円・200 円・100 円でも、2 枚の合計にぴったり合う。式が 2 本で未知数が 3 個の連立方程式なので、解は無数にある。

		単品の値段の候補			
伝票1 (昼)		ラーメン	餃子	ライス	伝票1・2
ラーメン + 餃子		800円	300円	200円	合う・合う
伝票2 (夜)		900円	200円	100円	合う・合う
ラーメン + ライス		700円	400円	300円	合う・合う

…候補はいくらでも作れる

図 15: 列が行より多い例(概念図)。伝票 2 枚(行)から 3 品(列)の単品の値段(係数)は 1 つに決まらない

一般に、 $\mathbf{X}$ の階数(rank)(1 次独立な列の最大の本数)は行の数 n を超えられないので、 $p \times p$ の $\mathbf{X}^\top \mathbf{X}$ の階数も n 以下であり、 p に届かない。遺伝子の発現量のように、数十人について数千の列を測ったデータでは、これが普通の状態である。

行が列より多くても、ある列がほかの列の 1 次式でちょうど書けるとき(完全な多重共線性)は、 $\mathbf{X}^T \mathbf{X}$ は正則でない。よく起きるのは、カテゴリを k 本の 0/1 の列に展開し、切片の列も入れた場合である。 k 本の和がつねに 1 になり、切片の列と一致してしまう。

こうして (7) 式の $(\mathbf{X}^T \mathbf{X})^{-1}$ は、列が似ていれば大きく膨らむ。列が完全に重なったり行より多かたりすれば、そもそも存在しない。どちらの場合も、データだけでは無数の候補から 1 つを選べない。

第 II 部 実データ解析

第 II 部の進め方と予想

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、3 つの予想が立つ。第 1 に、係数の不安定性は、1 回の当てはめから計算した $\hat{\sigma}^2(\mathbf{X}^T \mathbf{X})^{-1}$ で読めるはずである。第 2 に、似た列の係数は VIF 倍に膨らんで揺れると見込める。第 3 に、手元の行から離れた組み合わせでは、予測が危うくなるだろう。

カリフォルニア住宅データ

第 II 部では、第 I 部の場面で使ったカリフォルニア州の住宅のデータで、第 I 部の式を確かめる。Pace と Barry が 1990 年の米国国勢調査から作ったデータで、scikit-learn の `fetch_california_housing` で取得した。20,640 の地区のそれぞれについて、8 列の説明変数と、目的変数として住宅価格の中央値(10 万ドル単位)が記録されている。8 列は、世帯の所得の中央値(1 万ドル単位)、住宅の築年数の中央値、1 世帯あたりの部屋数と寝室数の平均、人口、1 世帯あたりの人数の平均、地区の中心の緯度と経度である。価格は 5 (50 万ドル)で打ち切られていて、992 地区がその値になっている。変数は元の単位のまま使い、切片の列を加えた 20,640 行 $\times$ 9 列のデータ行列 $\mathbf{X}$ を作る。第 I 部の場面では、20 通りの分割で寝室数の係数が所得の約 4 倍揺れた。この差を第 I 部の式で説明できるかも、第 II 部で確かめる。

図 16 は 8 列の相関行列である。似た列の組が 2 つある。1 つは部屋数と寝室数で、相関は 0.85 である。寝室は部屋の一部なので、部屋の多い地区は寝室も多い。もう 1 つは緯度と経度で、相関は -0.92 である。カリフォルニア州は北西から南東へ斜めに伸びているので、北の地区ほど西にある。ほかの列どうしの相関は、所得と部屋数の 0.33 を除けば、どれも 0.3 より小さい。

計算の手続きと結果

計算の手続きは次のとおりである。データ行列 $\mathbf{X}$ で正規方程式を解いて係数 $\hat{\beta}$ を求め、残差平方和から (8) 式で $\hat{\sigma} = 0.724$ を得た($n - p = 20,631$)。次に $(\mathbf{X}^T \mathbf{X})^{-1}$ を作り、(7) 式対角から各係数の標準誤差を計算した。比べる相手として、第 I 部の人工データと同じ取り直しを実データの $\mathbf{X}$ で行った。 $\mathbf{X}$ はそのままにして、目的変数を $\mathbf{X}\hat{\beta}$ に標準偏差 $\hat{\sigma}$ の正規分布のノイズを足したものに置き換える。置き換えた目的変数で係数を当




図 16: カリフォルニア住宅データの 8 列の相関行列

てはめ直すことを 1000 回くり返し、係数の標準偏差を求めた。さらに VIF を、第 I 部の手順どおり相関行列の逆行列の対角から求め、列ごとの回帰による $1/(1 - R_j^2)$ と比べた。てこ比 h_{ii} を全地区について計算し、地区を復元抽出して当てはめ直すブートストラップも 1000 回行った。どれも NumPy の行列計算と scikit-learn の LinearRegression で行った。

予想①を確かめる(図 17)。式から出した標準誤差と、作り直した 1000 回の係数の標準偏差は 8 列すべてで重なり、差は最大でも 3% である。差は 1000 回という有限の回数による揺れの範囲に収まっている。係数がどれだけ不安定かは、1 回の当てはめの $\hat{\sigma}^2(\mathbf{X}^\top \mathbf{X})^{-1}$ から読める。予想①どおりである。




図 17: 係数の不安定性。式 $\hat{\sigma}^2(\mathbf{X}^\top \mathbf{X})^{-1}$ による標準誤差(青)と、 $\mathbf{X}$ を固定して目的変数を 1000 回作り直したときの標準偏差(橙)。標準偏差 1 つぶんあたりに直してある

次に、(10) 式を確かめる(表 1)。相関行列の逆行列の対角と、列ごとの回帰による VIF は、差が最大 8e-13 で一致した。列が互いに似ていなかったとした場合の標準誤差は $\hat{\sigma}/\sqrt{(n-1)s_j^2}$ である。実際の標準誤差をこれで割った比は、どの変数でも $\sqrt{\text{VIF}_j}$ に一致する(差は最大 9e-11)。寝室数の VIF は 7.0 で、標準誤差は似ていないときの 2.6 倍に膨らんでいる。

表 1: カリフォルニア住宅データの VIF。2 通りの計算と、 $\sqrt{\text{VIF}}$ 、実際の標準誤差と列が似ていないときの標準誤差の比

変数	VIF (逆行列の対角)	VIF (回帰)	$\sqrt{\text{VIF}}$	標準誤差の比
緯度	9.30	9.30	3.05	3.05
経度	8.96	8.96	2.99	2.99
部屋数	8.34	8.34	2.89	2.89
寝室数	6.99	6.99	2.64	2.64
所得	2.50	2.50	1.58	1.58
築年数	1.24	1.24	1.11	1.11
人口	1.14	1.14	1.07	1.07
世帯人数	1.01	1.01	1.00	1.00

結果の読み方

予想②を確かめる。図 18 は、作り直した 1000 回の係数を 2 つずつ組にして、同じ縮尺・同じ幅で描いたものである。似ていない所得と築年数の組 (a) は小さく丸くまとまる。似た部屋数と寝室数の組 (b) は、第 I 部の図 6 (b) と同じく、斜めに細長く伸びる。2 つの係数の相関は、作り直した 1000 回で -0.92、(7) 式の対角の外から計算して -0.92 である。片方が大きく出れば、もう片方が小さく出る。部屋数と寝室数をまとめた「広さ」の効き目はよく決まるが、その内訳は決まりにくいのである。第 I 部の場面で、寝室数の係数が分割しだいで揺れたのは、このためである。




図 18: X を固定して目的変数を 1000 回作り直したときの係数(標準偏差 1 つぶんあたり)。★は全地区で当てはめた値で、2 枚とも★から ± 0.05 の範囲を描いた。(a) 所得と築年数、(b) 部屋数と寝室数

VIF は桁で読む(図 19、表 1)。築年数・人口・世帯人数の VIF は 1 のあたり、所得は 2.5 で、係数はほぼ単独のときと同じ精度で決まっている。部屋数と寝室数、緯度と経度の 4 列は 7~9 で、10 のあたりにある。標準誤差にして約 3 倍に膨らんでいる。




図 19: カリフォルニア住宅データの 8 列の VIF。赤は 5 以上の列、破線は目安とされる $VIF = 10$

ただし、第 I 部で述べたとおり VIF は倍率であって絶対量ではない。(10) 式の第 1 因子 $\sigma^2/\{(n-1)s_j^2\}$ は行が多いほど小さく、このデータは 20,640 行ある。寝室数の係数は標準偏差 1 つぶんあたり 0.306、 ± 2 標準誤差は 0.027 で、3 倍に膨らんでもなお係数の大きさに比べて小さい。部屋数の係数は -0.266 で負であり、単回帰の係数 +0.071 とは符号が逆だが、これも揺れでひっくり返る大きさではない。重回帰の係数は寝室数などを固定したときの効き目であり、単回帰とは別の問いに答えている(第 1 回)。部屋数を固定して寝室を増やすことは、ほかの部屋(居間など)を減らすことにあたる。共線性が問題になるのは、行の数に比べて VIF が大きいときである。このデータの 8 列の係数は、式の上では十分に決まっている。予想②のうち、似た列の係数が VIF 倍に膨らむことは当たったが、膨らんだ結果として係数が読めなくなる、という見込みは外れた。行の数が、膨らみを打ち消したのである。冒頭の 40 地区の場面と比べると、このことがよくわかる(図 2)。部屋数の係数の 20 回の標準偏差は、14,448 地区で当てはめた場面の分割では 0.029 だったが、40 地区では 0.55 と約 19 倍になり、

符号まで変わった。同じ列の組で同じように似ていても、行が少なれば係数は読めなくなる。

式的前提が崩れるとき

第 I 部の式的前提が、実データでどこまで成り立つかを見る。予想①は、 $\mathbf{X}$ を固定した作り直しでは当たった。では、地区そのものを取り直すとどうなるか。

結果から述べる。(7) 式は $\mathbf{X}$ を固定し、誤差の分散がどの行でも同じだとしたときの揺れである。結果①はその前提どおりに作り直したので一致した。一方、第 I 部のブートストラップで地区を丸ごと復元抽出し、当てはめ直すことを 1000 回くり返した。その係数の標準偏差を式の標準誤差で割ると(図 20)、築年数・人口・緯度・経度は 1.1~1.2 倍だが、寝室数は 3.8 倍、世帯人数は 42 倍になる。予想①は、この取り直し方では外れた。てこ比の大きい数地区が、抽出のたびに入ったり入らなかったりするからである。 $\mathbf{X}$ に極端な行があるとき、行ごとの取り直しに対する係数の不安定性は、式の標準誤差よりずっと大きくなりうる。なお、ブートストラップで見ても寝室数の係数は 1000 回すべてで正であり(割合 100%)、符号までは揺れない。




図 20: 地区を復元抽出して 1000 回当てはめ直したときの係数の標準偏差を、式の標準誤差で割った比。破線は 1 (式どおり)

外れた理由は、てこ比の大きい行にある。1 世帯あたりの人数は、ほとんどの地区で 2~4 人だが、最大の地区では 1,243 人である(図 21)。人口 7,460 人に対して世帯が 6 つしか数えられておらず、人口の大半は世帯に属さない形で住んでいると考えられる。この地区のてこ比は 0.69 で、平均 $p/n = 0.00044$ の約 1,587 倍である。てこ比の上限は 1 なので、0.69 という値は、この 1 地区の予測値が自分の y_i の揺れをほとんどそのまま受け取れることを意味する。1 世帯あたりの部屋数が 142 の地区など、てこ比の大きい地区はほかにも数個ある。

その数行が、係数を握っている。てこ比の大きい順に 5 地区を除いて当てはめ直しても、ほとんどの係数は変わらない(図 22)。ところが世帯人数の係数は、標準偏差 1 つぶんあたり -0.039 から -0.505 へ、約 13 倍になる。20,640 地区で決めたはずの係数が、実質的には数地区で決まっていたのである。第 I 部の人工データ(図 11)で、遠い 1 点が傾きを握ったのと同じことが起きている。てこ比は $\mathbf{X}$ だけで計算でき、 y を見る前にこうした行を見つけられる。

最後に予想③を確かめる。変数が多いと、範囲の中にいるつもりで外挿してしまう。ほかの列はすべて平均で、緯度が 41.5、経度が -115 の架空の地区を考える(図 23)。緯度は 32.5~42.0、経度は -124.3~-114.3 の範囲にあり、1 つずつ見ればどちらも範囲の中である。だが、緯度と経度は強く相関していて、点の雲はカリフォルニア




図 21: 世帯人数と住宅価格。赤丸は世帯人数の大きい 3 地区で、数字はそのてこ比




図 22: 全地区で当てはめた係数(青)と、てこ比の大きい 5 地区を除いて当てはめた係数(赤)。標準偏差 1 つぶんあたり

州の形をしている。この組み合わせは州の外、北東の隣の州にあたる。 $\mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0$ は 0.0109 で、平均 p/n の約 25 倍であり、手元の 20,640 地区のうちこれより大きいのは 23 地区だけである。そして、この地区の予測価格は -2.39、つまりマイナス 24 万ドルになる。(15) 式の予測の標準誤差は 0.076 と小さく、式の上では予測は揺れていない。それでも答えがありえない値になるのは、緯度と経度の直線の関係が州の外でも続くという、確かめようのない仮定に乗っているからである。第 I 部で述べたとおり、外挿の危うさのうち揺れの部分は式で見えるが、形の部分は見えない。そして、変数ごとの範囲では外挿は見つからず、 $\mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0$ を手元のてこ比と比べて初めて見つかる。

このデータでわかったこと

第 II 部の結果をまとめる。予想①の、係数の不安定性は $\hat{\sigma}^2 (\mathbf{X}^\top \mathbf{X})^{-1}$ で読める、という見込みは、 $\mathbf{X}$ を固定して目的変数を作り直す限りは当たった。だが地区そのものを取り直すと、世帯人数の係数は式の約 42 倍揺れた。理由は、てこ比の大きい数地区が係数を握っていて、式がその地区の出入りによる揺れを含まないことにある。予想②の、似た列の係数が VIF 倍に膨らむことは当たった。だが 20,640 地区という行の多さが膨らみを打ち消し、係数は符号まで揺れることはなかった。予想③の外挿の危うさは、緯度と経度がそれぞれ範囲の中にある架空の地区で、負の価格という形で現れた。式は揺れの大きさを教えてくれる。だが、式的前提($\mathbf{X}$ が固定、ど




図 23: 地区の緯度と経度と、架空の地区(★)。破線は緯度・経度それぞれの最小値と最大値

の行も同じ重み、モデルの形が範囲の外でも正しい)が崩れる場所までは教えてくれない。

締め

まとめと次回問い

本章の問いは、係数の不安定性は何で決まるのか、であった。答えは $\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$ の 1 本の式である。係数は $\mathbf{y}$ の線形変換なので、分散共分散行列の変換 (3) 式からこの式が出る。揺れはノイズの分散に比例し、列の広がり大きいほど小さく、列どうしが似ているほど大きい。その膨らみの倍率が VIF である。同じ式から予測の揺れ $\sigma^2 \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0$ が導かれる。手元の行ではそれがてこ比になり、手元の行から離れた点では外挿の揺れになる。そして列が完全に重なるときや列が行より多いときには、逆行列そのものが無くなり、係数は 1 つに決まらない。カリフォルニア住宅データでは、 $\mathbf{X}$ を固定して目的変数を作り直した揺れが、式の標準誤差と一致した。部屋数と寝室数、緯度と経度の VIF が 10 のあたりにあることも確かめた。一方で、てこ比の大きい数地区が世帯人数の係数を握っていて、地区ごと取り直すと係数は式よりずっと大きく揺れた。緯度と経度がそれぞれ範囲の中でも、組み合わせが州の外なら予測が負の価格になることも見た。

同じ学期の演習では、住宅のデータで同じ現象に出会う。演習 6 では、バスルームの数の係数が、それだけを入れた式では +71,941 ドルなのに 11 本の列を入れた式では -8,610 ドルになる。バスルームの多い家はたいがい広い家で、居住面積との相関は 0.65 である。車庫の台数と車庫の面積の相関は 0.88 で、台数の係数は面積も入れると -312 ドル、面積を外すと +7,725 ドルになる。面積も入れた式で住宅を復元抽出して 100 回当てはめ直すと、台数の係数は 64% の回でマイナスになり、符号さえ定まらない。11 本の式の係数はほかの列を固定したときの効き目であり、単独の式とは別の問いに答えている。そのうえ似た列が並ぶと、(10) 式のとおり内訳が揺れやすい。演習 7 では、居住面積が 1 階・2 階・仕上げの低い部分の面積の和とぴったり一致する。行が列よりずっと多くても、完全な共線があれば $\mathbf{X}^\top \mathbf{X}$ は逆行列を持たず、係数の分け前は無数にある。

最後に、次回への問いを置く。列が似て $(\mathbf{X}^\top \mathbf{X})^{-1}$ の対角が大きくなり係数が非常に不安定になるとき、あるいは逆行列が存在しないとき、データだけでは無数の候補(図 14 の赤い線の上)から 1 つを選べない。当てはまりだけを見る限り、どの候補も同じだからである。候補から 1 つを選ぶには、データの外から何かを足す必要がある。では、何を足せばよいのだろうか。