第 4 回 罰則付き最小二乗法

係数の大きさに罰則を足し、罰則の強さを交差検証で選ぶ

本章の問いは、第 3 回の締めで残った「係数が非常に不安定になる、あるいは 1 つに決まらないとき、どうするか」である。目的関数に係数の大きさへの罰則を足すと、$\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I}$ は必ず逆行列を持ち、係数の分散が減るかわりに偏りが入る。罰則の強さ λ は交差検証（クロスバリデーション、CV）で選ぶ。

第 I 部　理論

データだけでは係数を選べない

第 3 回では、最小二乗法の係数の分散が $\mathbb{V}\mathrm{ar}(\hat{\beta}_j) = \sigma^2[(\mathbf{X}^\top\mathbf{X})^{-1}]_{jj}$ で表されることを導いた。不安定性は、ノイズが大きいほど、行が少ないほど、列どうしが似ているほど大きい。列が完全に重なるか行より多いと、逆行列そのものが無くなって係数は 1 つに決まらない。第 3 回の締めには、そのように係数が非常に不安定になるときどうするか、という問いが残った。

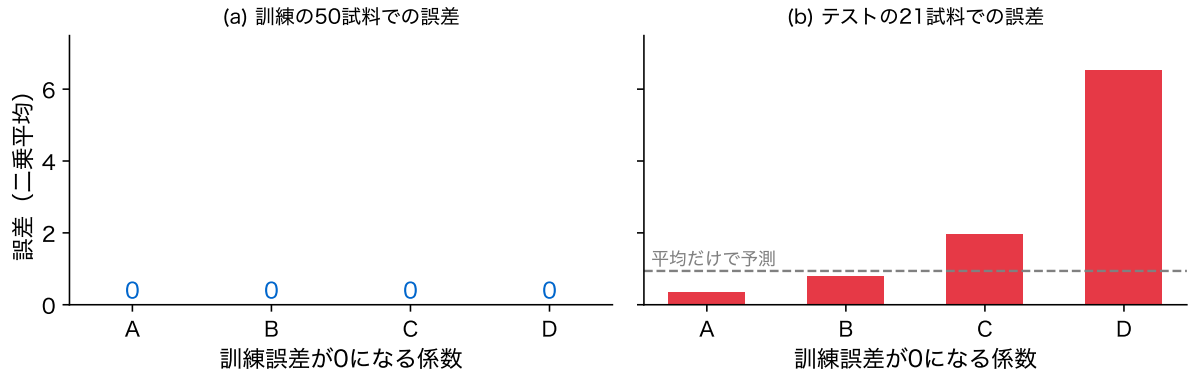


図 1: リボフラビンのデータで、訓練の 50 試料の残差平方和を 0 にする 4 組の係数（標準化した列）。(a) 訓練の試料での誤差はどれも 0、(b) テストの 21 試料での誤差は組ごとに違う。破線は平均だけで予測したときの誤差

本章では、この問いを遺伝子のデータで見直すところから始める。枯草菌にリボフラビン（ビタミン B2）をつくらせたときの生産量（対数）を、4088 個の遺伝子の発現量（対数）から予測するデータで、試料は 71 しかない（第 II 部で詳しく述べる）。列が行よりはるかに多いので、第 3 回で見たとおり $\mathbf{X}^\top\mathbf{X}$ に逆行列は無く、正規方程

式の解は 1 つに決まらない。実際に、71 の試料を訓練 50 とテスト 21 に分け、訓練の試料で残差平方和をちょうど 0 にする係数を 4 組作った(図 1)。4 組はどれも訓練の試料をぴたりと当てる。ところがテストの試料で測ると、誤差は 0.35 から 6.51 まで違い、平均だけで予測したときの 0.94 より悪いものもある。データの当てはまりだけでは、どの係数を選べばよいかが決まらない。

同じ困りごとは、ほかの場面でも起きる。効く列だけを知りたい場合である。人工的に 40 行・20 列のデータを作り、効くのは 3 列だけにした。最小二乗法で当てはめると、効かない 17 列の係数も 0 にならず、大きいものは 1.19 に達する。係数の大きさだけからは、どれが効く列かを読み分けにくい(図 2)。

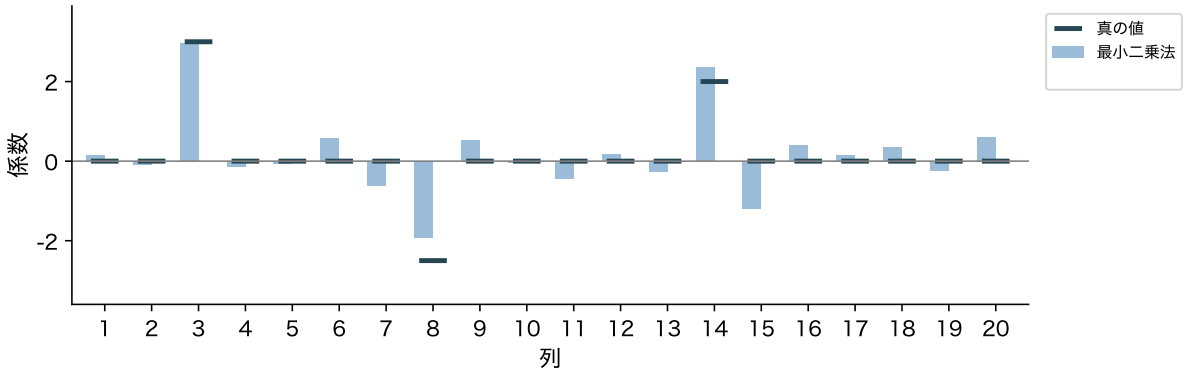


図 2: 40 行・20 列の人工データで、効くのは 3 列だけ(黒の横線が真の値)。最小二乗法(水色)の係数は、効かない 17 列でも 0 にならない

本章の問いは 1 つである。係数が非常に不安定になるとき、あるいはデータの当てはまりだけでは候補が 1 つに決まらないとき、どの 1 つを選ぶか。答えは、目的関数に係数の大きさへの罰則を足すことである。本章は 2 周で進む。前半では、例と図で答えまで一周する。二乗の罰則(Ridge 回帰)を足すと係数が 1 つに決まること、その代わりに偏りが入り分散が減ること、絶対値の罰則(Lasso)が係数をちょうど 0 にすること、罰則の強さを動かしたときの係数の動き、罰則の前に列の目盛りをそろえる必要、罰則の強さを交差検証(クロスバリデーション、CV)で選ぶ手順を順に見る。後半では、前半で結果だけを示した 3 つの点、すなわち、なぜ 1 点に決まるのか、なぜ偏りが入るのか、なぜちょうど 0 になるのか、に戻って式で導く。

「モデル × 推定法」の地図でいえば、モデルは線形回帰のまま動かず、推定法が最小二乗法から罰則付き最小二乗法に変わる。第 1 回で最小二乗法を「データとモデルの距離を最小にする推定法」と呼んだが、本章の推定法は、その距離に罰則を足したものを最小にする。推定法の列が増えるのは、全 15 回でこれが初めてである。

罰則を足す：Ridge 回帰

候補が 1 つに決まらないなら、当てはまりのほかに、候補を選ぶための基準を足せばよい。本章では、「ほかが同じなら、係数は小さいほうがよい」という基準を足す。

まず係数が 1 つの場合で、この基準を式にする。第 1 回の切片の無い単回帰の目的関数 $\sum_i (y_i - \beta x_i)^2$ に、係数の二乗に比例する罰則を足して

$$f_\lambda(\beta) = \sum_{i=1}^{n} (y_i - \beta x_i)^2 + \lambda \beta^2$$

とする。$\lambda \geq 0$ は罰則の強さを決める定数である。図 3 に、人工データでこれを描いた。真の傾きは 0.5、ノイズの標準偏差は 1.5 で、区間 $[-1, 1]$ から 20 個の x を取った。最小二乗の目的関数（青の放物線）に、$\beta = 0$ で最小になる放物線 $\lambda\beta^2$（灰）を足すと、和（赤）の谷底は 0 の側へ寄る。

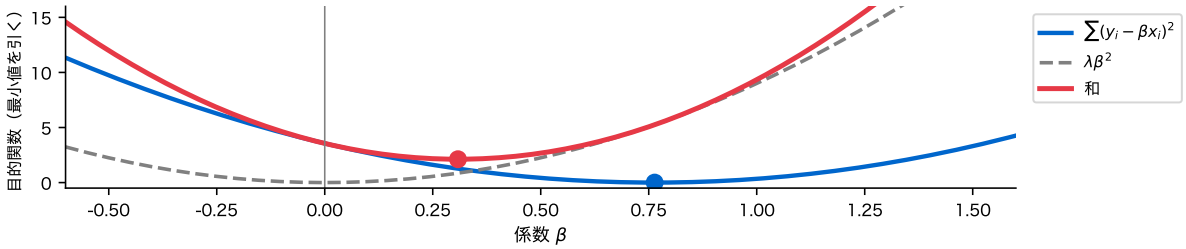


図 3: 1 変数の目的関数（人工データ）。最小二乗の目的関数（青）に罰則 $\lambda\beta^2$（灰の破線）を足すと、和（赤）の谷底は 0 の側へ寄る。点はそれぞれの谷底。縦軸は、どの曲線からも最小二乗の目的関数の最小値を引いた値

係数が p 個あるときは、係数ベクトルの大きさを二乗の和 $\|\boldsymbol{\beta}\|_2^2 = \sum_j \beta_j^2 = \boldsymbol{\beta}^\top \boldsymbol{\beta}$ で測る。第 1 回のユークリッドノルム（ℓ_2 ノルム）の二乗である。目的関数は

$$f_\lambda(\boldsymbol{\beta}) = \|\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \lambda \|\boldsymbol{\beta}\|_2^2 \tag{1}$$

となる。

定義 1 (罰則付き最小二乗法と Ridge 回帰)**.** 最小二乗法の目的関数に、係数の大きさへの罰則（penalty）を足したものを最小にする推定法を、罰則付き最小二乗法（penalized least squares）と呼ぶ。罰則に ℓ_2 ノルムの二乗を用いた (1) 式を Ridge 回帰と呼ぶ。

切片には罰則を課さない。切片まで縮めると、y の原点をずらしただけで答えが変わってしまうからである。各列と y から平均を引けば、切片の無い問題 (1) 式になる（導き方は「なぜ①」の節）。以下、$\mathbf{X}$ と $\boldsymbol{y}$ は中心化してあるものとする。

(1) 式の勾配を 0 とおくと、次の式を得る（導き方は「なぜ①」の節）。

$$(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}_p)\, \hat{\boldsymbol{\beta}}_\lambda = \mathbf{X}^\top \boldsymbol{y} \tag{2}$$

これは、第 1 回の正規方程式の $\mathbf{X}^\top \mathbf{X}$ の対角に λ を足した形である。

(2) 式がいつも解けるかを、3 列の小さな例で確かめる。3 列目が 1 列目と 2 列目の和である 4 行のデータ行列では、

$$\mathbf{X} = \begin{bmatrix} -1 & -1 & -2 \\ 1 & -1 & 0 \\ -1 & 1 & 0 \\ 1 & 1 & 2 \end{bmatrix}, \qquad \mathbf{X}^\top \mathbf{X} = \begin{bmatrix} 4 & 0 & 4 \\ 0 & 4 & 4 \\ 4 & 4 & 8 \end{bmatrix}, \qquad \mathbf{X}\boldsymbol{v} = 0 \quad (\boldsymbol{v} = [1, 1, -1]^\top)$$

となる。係数に $\boldsymbol{v}$ の何倍を足しても予測は変わらない。また

$$\mathbf{X}^\top \mathbf{X}\boldsymbol{v} = \mathbf{X}^\top (\mathbf{X}\boldsymbol{v}) = 0$$

なので、$\mathbf{X}^\top \mathbf{X}$ は 0 でない $\boldsymbol{v}$ を 0 に送る。したがって逆行列を持たない。もし逆行列があれば、両辺に掛けて $\boldsymbol{v} = 0$ となり矛盾するからである。

3 列目の 2 行目と 4 行目を ± 0.1 だけずらした $\tilde{\mathbf{X}}$ では、逆行列は存在するが

$$\tilde{\mathbf{X}} = \begin{bmatrix} -1 & -1 & -2 \\ 1 & -1 & 0.1 \\ -1 & 1 & 0 \\ 1 & 1 & 1.9 \end{bmatrix}, \qquad (\tilde{\mathbf{X}}^\top \tilde{\mathbf{X}})^{-1} = \begin{bmatrix} 100 & 95 & -100 \\ 95 & 91 & -95 \\ -100 & -95 & 100 \end{bmatrix}$$

となり、成分は 100 ほどになる。第 3 回の係数の分散 $\sigma^2[(\tilde{\mathbf{X}}^\top \tilde{\mathbf{X}})^{-1}]_{jj}$ は、σ^2 の約 100 倍である。

ここで対角に $\lambda = 1$ を足すと、逆行列は

$$(\mathbf{X}^\top \mathbf{X} + \mathbf{I})^{-1} = \begin{bmatrix} 0.45 & 0.25 & -0.31 \\ 0.25 & 0.45 & -0.31 \\ -0.31 & -0.31 & 0.38 \end{bmatrix}, \qquad (\tilde{\mathbf{X}}^\top \tilde{\mathbf{X}} + \mathbf{I})^{-1} = \begin{bmatrix} 0.45 & 0.24 & -0.32 \\ 0.24 & 0.43 & -0.30 \\ -0.32 & -0.30 & 0.39 \end{bmatrix}$$

となる。重なる列にも逆行列ができ、ほぼ重なる列の成分も 0.5 ほどに収まる。これは例に限らない。そのことを述べるために、言葉を 1 つ決める。

定義 2 (正定値)**.** 対称行列 $\mathbf{M}$ が、0 でないどの $\boldsymbol{v}$ についても

$$\boldsymbol{v}^\top \mathbf{M}\boldsymbol{v} > 0$$

を満たすとき、$\mathbf{M}$ は正定値(positive definite)であるという。

次の定理が成り立つ。

定理 1 (Ridge 回帰の解はただ 1 つ)**.** $\mathbf{X}$ と $\boldsymbol{y}$ は中心化してあり、$\lambda > 0$ とする。このとき、$\mathbf{X}$ の中身によらず、$\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}_p$ は正定値で、逆行列を持つ。*(1)* 式の f_λ の最小点はただ *1* つで

$$\hat{\boldsymbol{\beta}}_\lambda = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^\top \boldsymbol{y} \tag{3}$$

である。これは *(2)* 式のただ *1* つの解である。

列が完全に重なっていても、列が行より多くても、この定理は成り立つ。証明は「なぜ①」の節で示す。

列が 1 本なら $\mathbf{X}^\top\mathbf{X} = \sum_i x_i^2$ は 1 つの数で、(3) 式は

$$\hat{\beta}_\lambda = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2 + \lambda} \tag{4}$$

となる。最小二乗の解 $\sum_i x_i y_i / \sum_i x_i^2$ の分母に λ が足されただけであり、λ を大きくするほど 0 へ縮む。図 3 の例では、最小二乗の解は 0.76、$\lambda = 9$ の解は 0.31 である。

列が完全に重なる場合を、2 列で見ておく。まったく同じ値の列を 2 本並べ(相関 1)、ノイズの無い $\boldsymbol{y} = \boldsymbol{x}_1 + \boldsymbol{x}_2$ を予測するとする。データは 2 つの係数の和しか決められず、罰則が無ければ目的関数の底は直線 $\beta_1 + \beta_2 = 2$ の全体になる(図 4 (a))。罰則を足すと、底は $\beta_1 = \beta_2$ の上の 1 点に決まる(図は $\lambda/n = 0.1$ で、底は $\beta_1 = \beta_2 = 0.952$)。Ridge 回帰は、データが区別できない似た列に、効き目を等しく分ける。

λ を 0 に近づけると、この点は線に近づく。線 $\beta_1 + \beta_2 = 2$ の上では

$$\beta_1^2 + \beta_2^2 = (\beta_1 - 1)^2 + (\beta_2 - 1)^2 + 2 \;\geq\; 2$$

である。右辺の展開に $2\beta_1 + 2\beta_2 = 4$ を使った。等号は $\beta_1 = \beta_2 = 1$ のときに限るので、着く先は線の上でユークリッドノルムが最も小さい点 $(1, 1)$ である。一般に、λ を 0 に近づけた Ridge 回帰の解は、訓練の残差平方和を最小にする無数の解のうち、ユークリッドノルムが最も小さい 1 点に近づく(証明は省く)。冒頭の場面の A は、この点(ノルム最小の解)であった。

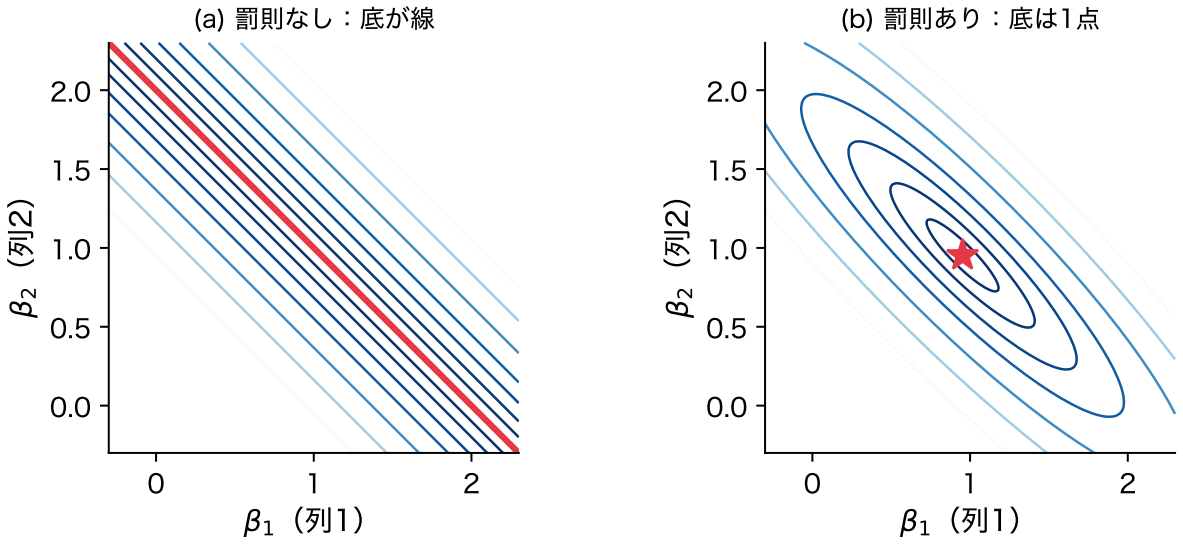


図 4: まったく同じ値の 2 列(相関 1)の目的関数の等高線(人工データ、ノイズなし)。(a) 罰則なしでは底が直線(赤)、(b) 罰則を足すと底は $\beta_1 = \beta_2$ の上の 1 点(赤の★)に決まる

分散が減り、偏りが入る

罰則を足すと、係数は何を得て何を失うのか。第 3 回と同じく、モデルを

$$\boldsymbol{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

とし、$\mathbf{X}$ は固定して誤差だけを取り直す。誤差には第 3 回の仮定①〜③

$$\mathbb{E}[\varepsilon_i] = 0, \qquad \mathbb{E}[\varepsilon_i^2] = \sigma^2, \qquad \mathbb{E}[\varepsilon_i \varepsilon_{i'}] = 0 \quad (i \neq i')$$

を置く。$\mathbb{E}$ は、取り直したときの平均の行き先（期待値）である。

図 5 は、図 3 と同じ 20 個の x のまま y を 30 回取り直し、そのつど原点を通る直線を引いたものである。最小二乗法 (a) の直線は大きく扇状に開き、傾きが負になる回もある。Ridge 回帰 (b) では扇は閉じるが、直線はそろって真の直線より寝ている。

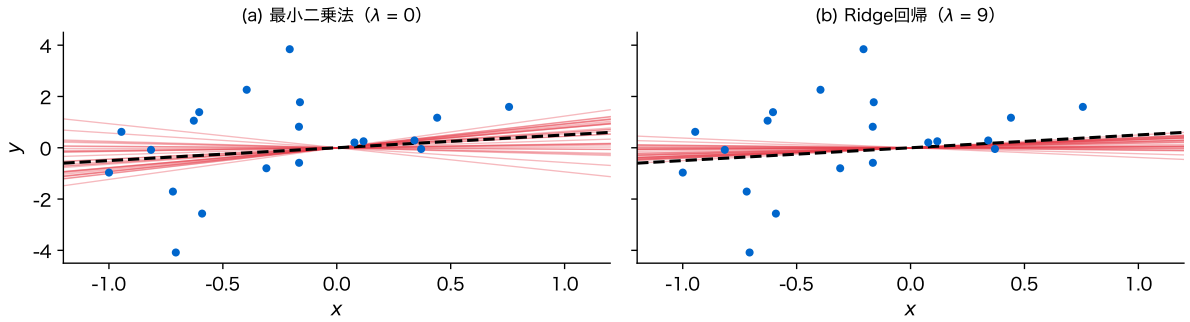


図 5: 同じ x のまま y を 30 回取り直して引いた原点を通る直線（赤、人工データ）。(a) 最小二乗法、(b) Ridge 回帰。黒の破線は真の直線、青は 1 回ぶんの点

取り直したときの推定量の平均が真の値からずれると、平均と真の値が分かれる。そこで、ずれと散らばりを分けて測る。散らばりは平均のまわりで測る。

定義 3 (偏り・分散・二乗誤差)**.** 真の値 θ の推定量 $\hat{\theta}$ について、$\mathbb{E}[\hat{\theta}] - \theta$ を偏り (bias)、$\mathbb{V}\mathrm{ar}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2]$ を分散、$\mathbb{E}[(\hat{\theta} - \theta)^2]$ を二乗誤差と呼ぶ。

最小二乗の係数は不偏で、偏りは 0 であった（第 3 回）。Ridge 回帰の直線がそろって寝るのは、偏りが入るからである。不偏な推定量では $\mathbb{E}[\hat{\theta}]$ が真の値なので、第 3 回の定義と一致する。第 2 回の Variance も、取り直した予測の平均のまわりの散らばりであった。扇が閉じたのは、分散が減ったからである。図 5 の例では、最小二乗法の傾きの標準偏差は 0.61 で、真の傾き 0.5 と同じくらいである。Ridge 回帰では標準偏差は 0.25 に下がるが、傾きの平均は 0.20 に縮む。

偏りと分散のどちらを重く見るべきかは、二乗誤差 $\mathbb{E}[(\hat{\beta}_\lambda - \beta)^2]$ で測れる。係数が 1 つの場合には、次の定理が成り立つ。

定理 2 (Ridge 回帰の偏りと分散)**.** 係数が *1* つで切片の無いモデル $y_i = \beta x_i + \varepsilon_i$ で、x_i は固定し、誤差は仮定①〜③を満たすとする。$S = \sum_i x_i^2 > 0$、$\lambda \geq 0$、$\kappa = S/(S+\lambda)$ とおく。*Ridge* 回帰の係数 *(4)* 式について

$$\mathbb{E}[\hat{\beta}_\lambda] = \kappa\beta, \qquad \mathbb{V}\mathrm{ar}(\hat{\beta}_\lambda) = \kappa^2 \frac{\sigma^2}{S} \tag{5}$$

が成り立つ。二乗誤差は偏りの二乗(*Bias*²)と分散(*Variance*)の和に分かれ

$$\mathbb{E}[(\hat{\beta}_\lambda - \beta)^2] = \underbrace{(1-\kappa)^2\beta^2}_{Bias^2} + \underbrace{\kappa^2 \frac{\sigma^2}{S}}_{Variance} = \frac{\lambda^2\beta^2 + S\sigma^2}{(S+\lambda)^2} \tag{6}$$

となる。$\beta \neq 0$ なら、二乗誤差は $\lambda^* = \sigma^2/\beta^2$ で最小になり、その値 $\sigma^2/(S + \sigma^2/\beta^2)$ は最小二乗法の二乗誤差 σ^2/S より小さい。

証明は「なぜ②」の節で示す。図 6 は、この人工データの設定で、Bias² と Variance を罰則の強さ λ に対して描いたものである。λ を大きくすると Bias² は増え、Variance は減る。和は U 字を描く。つまり、罰則の強さが適切なら、偏りが入ってもなお係数は真の値に近づく。この例では、最小二乗法の二乗誤差 0.369 が、底では 0.149 まで下がる。ただし底の位置は、真の β と σ^2 で決まっている。どちらも未知なので、λ をこの式から決めることはできない。λ はデータから選ぶしかなく、その方法を「罰則の強さを選ぶ」の節で述べる。

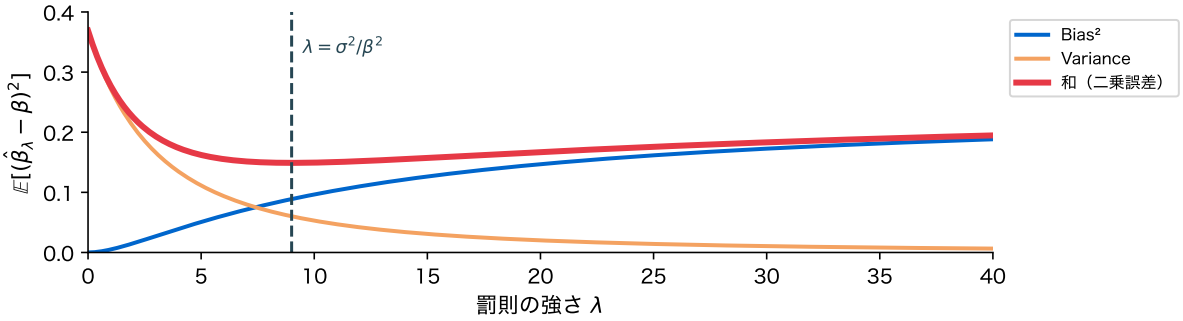


図 6: 1 変数の Ridge 回帰の係数の二乗誤差(赤)と、その Bias² (青)・Variance (橙)。破線は底の位置 $\lambda = \sigma^2/\beta^2$ (人工データの設定で計算)

列が 2 本の場合を、人工的なデータで見ておく(図 7)。60 行で、標準化した 2 列の相関が 0.92 のデータ行列を作った。真の係数を (1.6, 0.4)、ノイズの標準偏差を 1 とおく。$\mathbf{X}$ は固定したまま $\boldsymbol{y}$ を 300 回取り直し、最小二乗法と Ridge 回帰($\lambda = 5$)の係数を並べた。最小二乗法の雲は左上から右下へ細長く伸び、$\hat{\beta}_1$ の標準偏差は 0.34 である。Ridge 回帰では、細長い向き(内訳 $\beta_1 - \beta_2$ の向き)が大きく縮み、標準偏差は 0.18 になる。似た 2 列の内訳の向き $\boldsymbol{v}$ では $\|\mathbf{X}\boldsymbol{v}\|_2$ が小さいので、足した $\lambda\|\boldsymbol{v}\|_2^2$ が強く効くのである。その代わり、雲の中心は★からずれる。平均は 1.27 と 0.66 で、真の値の 1.6 と 0.4 より互いに近い。Ridge 回帰の係数は、データが区別しにくい 2 列に効き目を等しく分ける側へ偏る。データがよく決めている和の向きはほとんど縮まず、データが決められない内訳の向きが強く縮む。

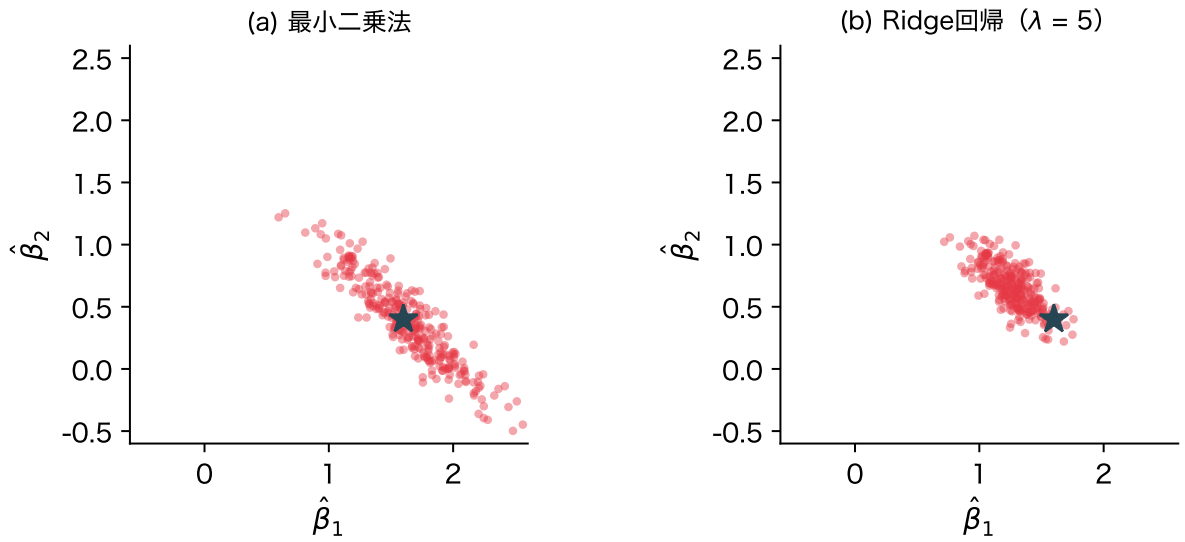


図 7: 相関 0.92 の 2 列で $\boldsymbol{y}$ を 300 回取り直したときの係数(人工データ)。(a) 最小二乗法、(b) Ridge 回帰。★は真の値

Lasso：係数をちょうど 0 にする

係数をちょうど 0 にして、効かない列を外すことはできないか。そのために、罰則の形を変える。係数ベクトルの大きさは、二乗の和のほかに、絶対値の和でも測れる。

定義 4 (ℓ_1 ノルム)**.** ベクトル $\boldsymbol{\beta} = [\beta_1, \dots, \beta_p]^\top$ について、$\|\boldsymbol{\beta}\|_1 = \sum_{j=1}^{p} |\beta_j|$ を ℓ_1 ノルム(L1 norm)と呼ぶ。

1 つの係数についての形を比べると(図 8)、β^2 は原点で傾きが 0 で平らに寝ており、係数を 0.1 から 0 へ動かしても値はほとんど減らない。$|\beta|$ は原点で尖っていて、0 の近くでも傾きが ± 1 に保たれる。この尖りが、係数をちょうど 0 にする理由になる。

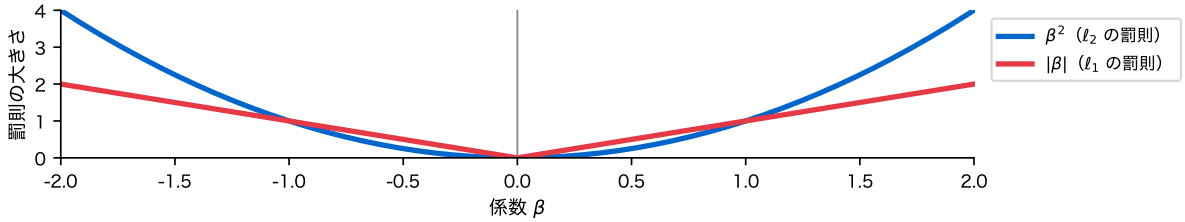


図 8: 1 つの係数についての ℓ_2 の罰則 β^2（青）と ℓ_1 の罰則 $|\beta|$（赤）の形(概念図)

定義 5 (Lasso)**.** 罰則に ℓ_1 ノルムを用い、$\|\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \lambda\|\boldsymbol{\beta}\|_1$ を最小にする罰則付き最小二乗法を Lasso と呼ぶ。

まず係数が 1 つの場合を解く。目的関数は

$$g_\lambda(\beta) = \sum_{i=1}^{n}(y_i - \beta x_i)^2 + \lambda|\beta| = \sum_i y_i^2 - 2c\beta + S\beta^2 + \lambda|\beta|, \qquad c = \sum_i x_i y_i, \quad S = \sum_i x_i^2 \tag{7}$$

である。2 つ目の形は、二乗を展開して β の 1 次と 2 次の項に分けたものである。$|\beta|$ は $\beta = 0$ で尖っていて微分できない。$\beta > 0$ の側と $\beta < 0$ の側に分けて考えると、次の定理を得る。

定理 3 (1 変数の Lasso の解)**.** $S > 0$、$\lambda \geq 0$ とする。*(7)* 式の g_λ の最小点はただ *1* つで

$$\hat{\beta}_\lambda^{\mathrm{L}} = \frac{\operatorname{sign}(c)\ \max(|c| - \lambda/2,\ 0)}{S} \tag{8}$$

である。sign は符号を表す。

特に $|c| \leq \lambda/2$ なら、係数はちょうど 0 である。証明は「なぜ③」の節で示す。図 9 に、図 3 と同じ人工データで (7) 式を描いた。(a) の λ では谷底は 0 の側へ寄るだけで、係数は 0.38（最小二乗は 0.76）である。(b) のように $\lambda/2$ が $|c|$ を超えると、谷底は尖りに引っかかり、係数はちょうど 0 になる。

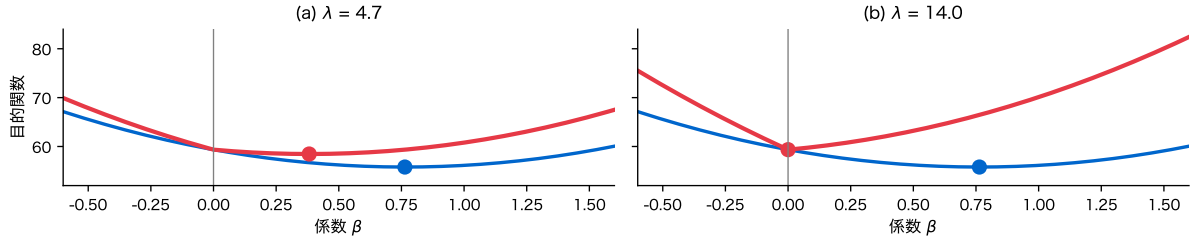


図 9: 1 変数の Lasso の目的関数（赤）と最小二乗の目的関数（青）（人工データ）。(a) 罰則が弱いと谷底は 0 の側へ寄るだけ、(b) 強いと谷底が $\beta = 0$ の尖りに止まる

(4) 式と (8) 式を、最小二乗の推定値 c/S の関数として並べると違いがはっきりする（図 10）。

$$\text{Ridge 回帰：}\ \hat{\beta}_\lambda = \frac{S}{S+\lambda} \cdot \frac{c}{S}, \qquad \text{Lasso：}\ \hat{\beta}_\lambda^{\mathrm{L}} = \operatorname{sign}(c)\ \max\left(\left|\frac{c}{S}\right| - \frac{\lambda}{2S},\ 0\right)$$

Ridge 回帰は c/S に $\kappa = S/(S+\lambda)$ を掛ける。つまり比で縮めるので、どれほど縮めても 0 にはならない。Lasso は $|c/S|$ から $\lambda/(2S)$ を引く。つまり差で縮め、引ききれない小さな推定値をちょうど 0 にする。この形の縮め方を軟しきい値（soft thresholding）と呼ぶ。係数がちょうど 0 の列は予測に使われないので、Lasso は推定と同時に列を選ぶ。二乗の罰則は原点で平らなので、0 の手前で縮めても罰則はほとんど減らず、ちょうど 0 にする理由がない。

列が p 本になると、Lasso の解を 1 本の式で書くことはできない。ほかの係数を止めて 1 つずつ (8) 式で更新することをくり返して解く（「なぜ③」の節）。

旅行の荷物を減らす場面にたとえると、2 つの罰則の違いがつかみやすい。Ridge 回帰は、どの荷物も同じ割合で軽くするので、どれも少しずつ残る。Lasso は、どの荷物からも同じ量を減らすので、もともと軽い荷物は

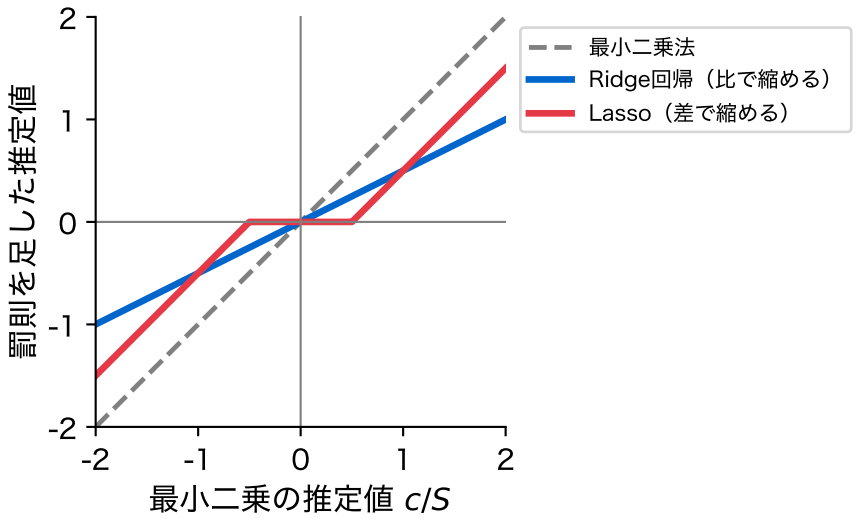


図 10: 最小二乗の推定値に対する、Ridge 回帰（青、比で縮める）と Lasso（赤、差で縮めて小さいものを 0 にする）の推定値（概念図）

減らしきれずに置いていく。冒頭の困りごとのデータ（全列を標準化して作った）に、$\lambda = 40$ の Lasso を当てると（図 11）、残る係数は 3 個で、効く 3 列だけが残る。ほかの 17 列の係数はちょうど 0 になる。このように多くの成分がちょうど 0 のベクトルを、スパース（sparse）（疎）であるという。効く 3 列の係数も真の値より 0 の側に縮むが、どれが効く列かは一目で読める。

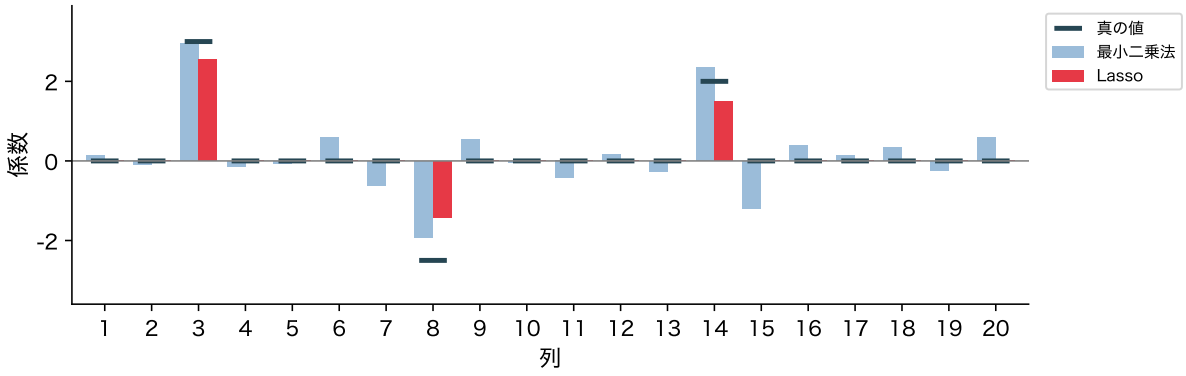


図 11: 40 行・20 列の人工データで、効くのは 3 列だけ（黒の横線が真の値）。最小二乗法（水色）の係数は効かない 17 列でも 0 にならないが、Lasso（赤）は効く 3 列だけを残す

Solution Path

罰則の強さを 0 から大きくしていくと、係数はどう動くか。罰則の強さごとに係数を求めて線でつないだものを、Solution Path と呼ぶ。横軸には罰則の強さ λ を対数の目盛りでとり、右ほど弱くする。右端はほぼ最小二乗法（$\lambda = 0$）で、左へ行くほど罰則が強く、係数は 0 に近づく。

図 12 は、図 7 と同じ相関 0.92 の 2 列で、1 回ぶんの $\boldsymbol{y}$ について Solution Path を描いたものである。Ridge 回帰 (a) では、最小二乗法で 2.01 と 0.14 だった 2 つの係数が、罰則を強めると近づきながら 0 へ縮む。似た列に効き目を等しく分ける性質である。Lasso (b) では、列 2 の係数が先にちょうど 0 になり、λ がおよそ 31 から 248 の間では列 1 の係数だけが残る。列 1 が効き目をほぼ説明してしまうと、列 2 の c が小さくなってしきい値を下回るからである。Ridge 回帰が似た列に効き目を等しく分けるのに対し、Lasso は 1 本を残してほかを 0 にしやすい。

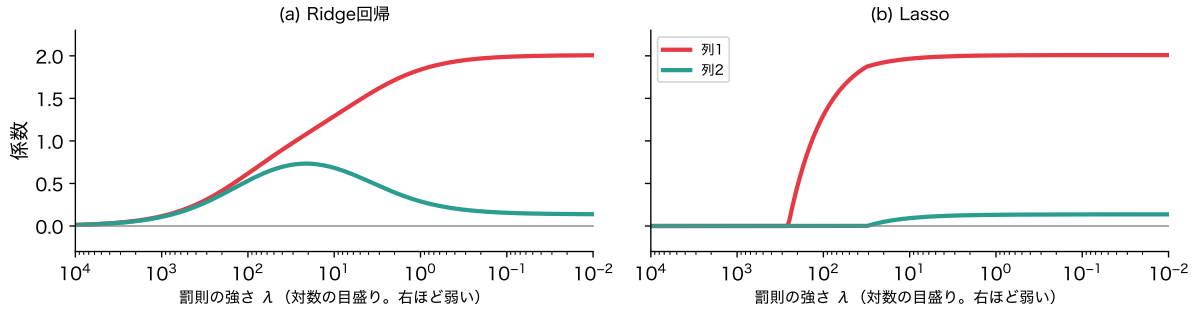


図 12: 相関 0.92 の 2 列での Solution Path（人工データ）。(a) Ridge 回帰、(b) Lasso。横軸は罰則の強さ（対数の目盛り）で、右ほど弱い

罰則の前に目盛りをそろえる

罰則は係数の大きさを、列をまたいで足し合わせる。ところが係数の大きさは、列の目盛りの取り方で変わる。重さを g で測っていた列を kg で測り直すと、値は 1000 分の 1 になり、同じ予測 $\beta_j x_j$ を保つには係数は 1000 倍にならなければならない。最小二乗法ならそれで済む。第 1 回で見たとおり、列を c 倍しても最小二乗法の予測は変わらず、その列の係数が $1/c$ 倍になるだけである。だが罰則は、二乗なら 10^6 倍、絶対値なら 1000 倍になる。予測にとっては同じモデルなのに、罰則の大きさだけが目盛りの取り方で動くのである。裏返せば、値の大きな目盛りで測った列ほど係数は小さく、罰則をほとんど受けずに済む。そうした列は縮められもせず、Lasso に外されもしない。

そこで、罰則を足す前に、第 2 回の標準化 $\mathbf{Z} = (\mathbf{X} - \mathbf{1}\bar{\boldsymbol{x}}^\top)\mathbf{D}^{-1}$ で全列の標準偏差を 1 にそろえる。そうすれば、1 つの λ がすべての列に同じ意味を持つ。標準化は列を中心化もするので、切片を切り離す準備も同時に済む。標準化の平均と標準偏差もデータから推定したものであり、第 2 回で述べたとおりモデルの一部として訓練の行だけで求める。後で交差検証（クロスバリデーション、CV）を行うときは、分けるたびに訓練の側の行で求め直す。

λ を選ぶ：CV

罰則の強さ λ は、(6) 式の底のように真の値を知っていれば決まるが、実際には知らない。では手元のデータからどう選ぶか。訓練誤差は使えない。$\lambda = 0$ の最小二乗の解は訓練の残差平方和を最小にする解そのものなので、罰則を足しても訓練誤差が減ることはない。訓練誤差で選べば、いつも $\lambda = 0$ が選ばれる。第 2 回で、訓練誤差で比べると複雑なモデルがいつも勝つと述べたのと同じ理屈である。

人工データで確かめておく(図 13)。列どうしの相関が 0.6 の 20 列を 40 行だけ作り、ノイズの標準偏差を 2 とした。$\mathbf{X}$ は固定し、λ ごとに、訓練誤差の期待値と、同じ分布から取った新しい 2000 点での誤差の期待値を求めた。新しい点での誤差の Bias^2 と Variance も、取り直しの期待値として計算した。横軸には、Solution Path と同じく罰則の強さ λ を対数の目盛りでとり、右ほど弱くした。訓練誤差は右へ行くほど下がる一方である。新しい点での誤差は U 字を描き、最小二乗法($\lambda = 0$)では 8.45 だが、$\lambda = 16.4$ で最小の 5.07 になる。右へ行くと Variance が増え、左へ行くと Bias^2 が増える。第 2 回で多項式の次数に対して見た U 字と同じ形が、罰則の強さという連続のつまみに対して現れる。

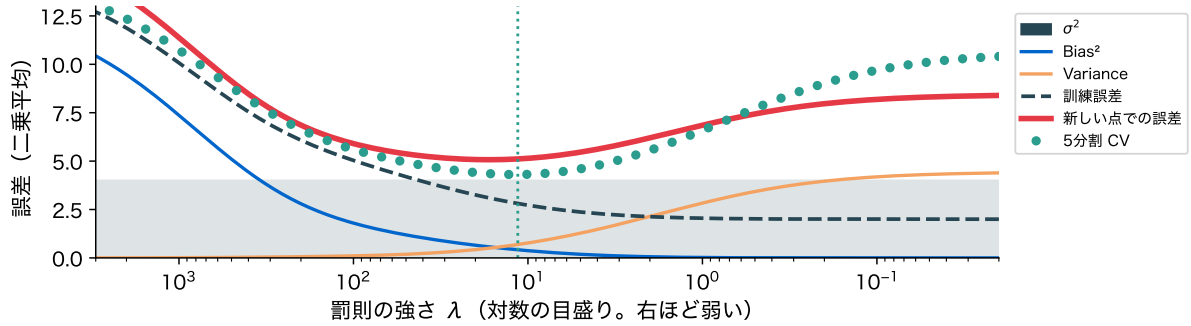


図 13: 人工データ(40 行・20 列)での Ridge 回帰の誤差を、罰則の強さ(対数の目盛り。右ほど弱い)に対して描いたもの。訓練誤差(破線)、新しい点での誤差(赤)とその Bias^2・Variance・σ^2、1 回ぶんのデータで計算した 5 分割 CV（緑の点。点線は選んだ所）

新しい点での誤差を測るには、係数の決定に使わなかった行が要る。第 2 回では、行を訓練とテストに分け、テストの行で汎化誤差を見積もった。ところが、λ の候補をテストの行で比べて選ぶと、新しい問題が起きる。候補を 10 個比べて最良を選べば、報告される誤差は 10 個の測定値の最小値になり、偶然良く出たぶんだけ良く見える。λ を選ぶことも一種の学習であり、選ぶのに使った行は、もう観測されていない値の代役ではない。本番の試験の問題で勉強法を選べば、本番の点は実力より良く見えるのと同じである。そこで行を 3 つに分ける。これを訓練・検証・テストの 3 分割(train-valid-test split)と呼ぶ(図 14)。訓練(training)の行で係数を決め、検証(validation)の行で λ を選び、すべて決め終えたあとでテスト(test)の行で一度だけ測る。問題集・模試・本番にたとえれば、訓練の行は問題集、検証の行は勉強法を選ぶ模試、テストの行は最後に 1 回だけ受ける本番にあたる。検証の数字は候補を並べるための順位にすぎず、実力として報告してよいのはテストの数字だけである。テストで測ったら思ったより悪かったので λ を変える、という一手が入った時点で、テストは選択に使われたことになる。



図 14: 訓練・検証・テストの 3 分割

ただし、検証の行を 1 回だけ取り分けると、第 2 回の締めで見たように、どの行を取り分けたかしだいで数字が

ばらつく。そこで、テスト以外の行を V 組に分け、どの組も 1 度ずつ検証の側に回す（図 15）。この手続きを交差検証（クロスバリデーション、CV）（cross-validation）と呼ぶ。

定義 6 (V 分割交差検証)**.** CV に使う n 行を V 組に分け、第 v 組の行の目的変数を $\boldsymbol{y}_v$ とする。各 v について、第 v 組を除いた行だけで標準化の平均・標準偏差と係数を決め、その係数で第 v 組を予測した値を $\hat{\boldsymbol{y}}_v^{(-v)}$ とする。予測の誤差を合わせた

$$\mathrm{CV}(\lambda) = \frac{1}{n}\sum_{v=1}^{V} \left\| \boldsymbol{y}_v - \hat{\boldsymbol{y}}_v^{(-v)} \right\|_2^2 \tag{9}$$

とする手続きを、V 分割交差検証（K-fold cross-validation）と呼び、略して k-fold CV と書くことが多い（k は組の数で、本章の V にあたる）。$V = 5$ なら 5 分割 CV（5-fold CV）である。

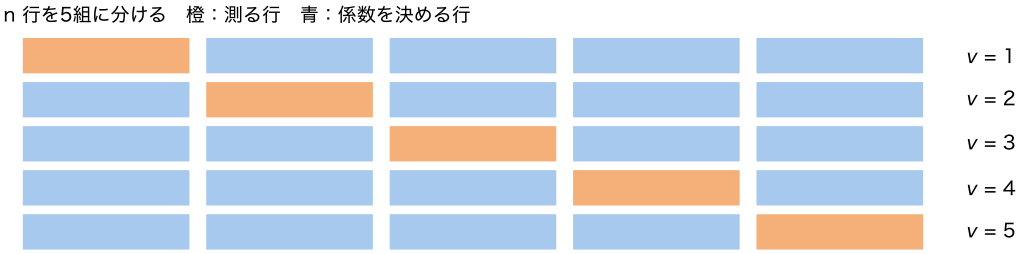


図 15: 5 分割 CV の分け方（概念図）。各回（行）で橙の組を測り、青の組で係数を決める

どの行もちょうど 1 度だけ測る側に回り、そのときの係数はその行を見ていない。λ の候補ごとに (9) 式を計算し、最も小さい λ を選ぶ。図 13 の緑の点は、1 回ぶんの $\boldsymbol{y}$ から 5 分割 CV で計算した (9) 式であり、$\lambda = 11.4$ を選ぶ。選ばれた λ での新しい点での誤差は 5.11 で、真の底 5.07 に近い。右端（最小二乗法に近い所）で CV の誤差が新しい点での誤差より大きく出るのは、各回で係数を決める行が 32 行に減って列の数 20 に近づき、係数のばらつきが大きくなるからである。これは後で述べる、V が小さいと悲観的になる性質の極端な例である。

λ を選ぶ計算は、次の手順で行う。

1. λ の候補 $\lambda_1 < \cdots < \lambda_L$ を並べる
2. V 分割の各回で、第 v 組を除いた行の平均・標準偏差で両方の行を標準化する。除いた行で係数を決め（Ridge 回帰なら正規方程式を解き、Lasso なら「なぜ③」の節の座標降下法で求める）、第 v 組を予測して誤差を測る。これを λ の候補ごとに行い、(9) 式を求める
3. 誤差が最小の λ を選び、その λ ですべての行を使って当てはめ直す

V 分割の手間は、候補 1 つあたり V 回の当てはめである。

V の選び方には釣り合いがある。V が小さいと、各回で係数を決める行は $n(V-1)/V$ 行に減る。その係数はすべての行で決めた係数より当てはまりが悪いので、誤差を大きめに、すなわち悲観的に見積もる。V を大きくすればこの偏りは減るが、当てはめの回数が増える。ふつうは $V = 5$ か 10 が使われる。なお、どの行をどの組に

入れるかという分け方によっても値がばらつく。ただし V 個の組の平均をとるぶん、ばらつきは第 2 回の 1 回の分割よりずっと小さい。これは第 II 部で確かめる。

最後に、CV で λ を選んだあとの誤差の報告について述べる。選んだ λ での (9) 式の値は、L 個の候補の中の最小値である。テストの行で λ を選んだときと同じく、偶然良く出たぶんだけ甘い。λ を選ぶのに使った行で、そのまま予測の良さを報告することはできない。予測の良さを報告するには、λ を選ぶ手続きの外に、測るための行を置く。行を 3 つに分けるのがその 1 つだが、行が少ないと、検証とテストにそれぞれ行を割くのは苦しい。そこで、CV を二重にする（図 16）。

定義 7 (入れ子の交差検証)**.** 行を V 組に分ける。各 v について、第 v 組を除いた行 $\mathbf{X}_{(-v)}, \boldsymbol{y}_{(-v)}$ だけで CV を行って $\hat{\lambda}^{(-v)}$ を選び、その $\hat{\lambda}^{(-v)}$ で $\mathbf{X}_{(-v)}, \boldsymbol{y}_{(-v)}$ に当てはめた係数で第 v 組の誤差を測る。V 組の誤差を合わせたものを、入れ子の交差検証（nested cross-validation）の誤差と呼ぶ。略して入れ子の CV（nested CV）とも書く。外側の CV は測るため、内側の CV は選ぶためにある。

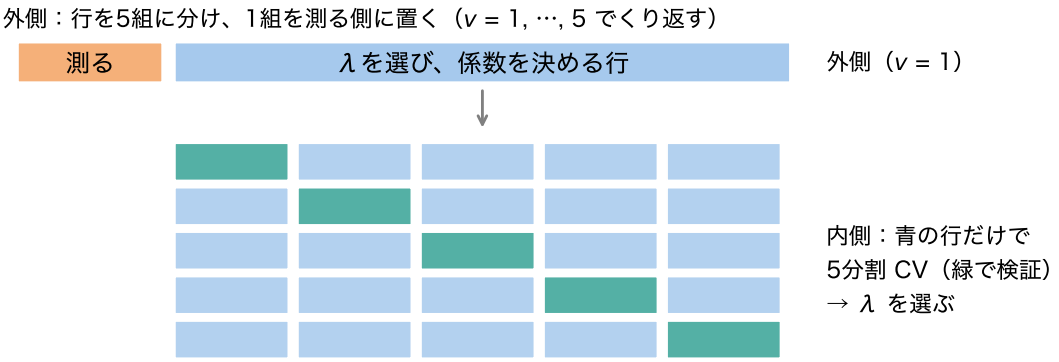


図 16: 入れ子の交差検証（概念図）。外側で第 1 組（橙）を測る側に置き、残りの行（青）だけで内側の 5 分割 CV を行って λ を選ぶ。これを外側の 5 組それぞれについてくり返す

外側の各回で、測る組は λ の選択にも係数の決定にも使われない。したがって入れ子の CV の誤差は、「CV で λ を選んでから当てはめる」という手続き全体を、新しいデータに当てたときの誤差の見積もりになる。選ばれる $\hat{\lambda}^{(-v)}$ は外側の回ごとに違ってよい。測っているのは、ある 1 つの λ の良さではなく、λ の選び方を含めた推定法の良さだからである。手間は、外側の V 回それぞれで内側の CV を行うぶん、ふつうの CV のおよそ V 倍になる。内側の CV でも、分けるたびに標準化し直す。最終的に使うモデルは、すべての行でふつうの CV を行って選んだ λ で当てはめたものであり、入れ子の CV はその手続きの良さの見積もりである。最小二乗法のように選ぶものが無い推定法では、入れ子にする必要はなく、ふつうの CV がそのまま予測の良さの見積もりになる。

なぜ①：必ず 1 点に決まるのか

ここまでで、本章の問いに答えを一周した。ここからは、前半で結果だけを示した 3 つの点に戻り、式で導く。1 つ目は、罰則を足すとなぜ係数が必ず 1 点に決まるのか（定理 1）、である。

まず、切片を切り離す。

命題 1 (切片の切り離し)**.** 切片 β_0 を含む目的関数

$$\sum_{i=1}^{n}(y_i - \beta_0 - \boldsymbol{x}_i^\top \boldsymbol{\beta})^2 + \lambda\|\boldsymbol{\beta}\|_2^2$$

を最小にする $\boldsymbol{\beta}$ は、各列と y から平均を引いたデータで *(1)* 式を最小にする $\boldsymbol{\beta}$ と同じである。切片は、列の平均を並べたベクトル $\bar{\boldsymbol{x}}$ を使って $\hat{\beta}_0 = \bar{y} - \bar{\boldsymbol{x}}^\top \hat{\boldsymbol{\beta}}_\lambda$ と求まる。

証明. $\boldsymbol{\beta}$ を止めると、目的関数は β_0 の 2 次関数で、β_0^2 の係数は $n > 0$ である。罰則は β_0 を含まないので、β_0 で偏微分して 0 とおくと

$$-2\sum_{i=1}^{n}(y_i - \beta_0 - \boldsymbol{x}_i^\top \boldsymbol{\beta}) = 0 \quad \Longrightarrow \quad \beta_0 = \bar{y} - \bar{\boldsymbol{x}}^\top \boldsymbol{\beta}$$

を得る。どの $\boldsymbol{\beta}$ についても、この β_0 が最小を与える。これを入れると

$$y_i - \beta_0 - \boldsymbol{x}_i^\top \boldsymbol{\beta} = (y_i - \bar{y}) - (\boldsymbol{x}_i - \bar{\boldsymbol{x}})^\top \boldsymbol{\beta}$$

となる。各列と y から平均を引けば、切片の無い問題 (1) 式に帰着する。切片はその解から

$$\hat{\beta}_0 = \bar{y} - \bar{\boldsymbol{x}}^\top \hat{\boldsymbol{\beta}}_\lambda$$

と求まる。 □

以下、$\mathbf{X}$ と $\boldsymbol{y}$ は中心化してあるものとする。なお、列が中心化してあれば $\mathbf{X}^\top \mathbf{1} = 0$ なので

$$\mathbf{X}^\top(\boldsymbol{y} - \bar{y}\mathbf{1}) = \mathbf{X}^\top \boldsymbol{y}$$

であり、$\boldsymbol{y}$ を中心化してもしなくても係数は変わらない。

証明には、第 3 回の 2 次形式の微分と、線形代数の基本的な事実を 1 つ使う。$\mathbf{A}$ が対称な $p \times p$ 行列なら $\partial \boldsymbol{\beta}^\top \mathbf{A}\boldsymbol{\beta}/\partial \boldsymbol{\beta} = 2\mathbf{A}\boldsymbol{\beta}$ である。正方行列 $\mathbf{M}$ は、$\mathbf{M}\boldsymbol{v} = 0$ となる $\boldsymbol{v}$ が 0 だけなら逆行列を持つ(正則)。これらを使って定理 1 を証明する。

証明. まず、最小点が満たす式を求める。最小二乗の項の勾配は、第 3 回で見たとおり

$$\frac{\partial}{\partial \boldsymbol{\beta}}\|\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 = -2\mathbf{X}^\top(\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta})$$

である(2 次の項は、2 次形式の微分で $\mathbf{A} = \mathbf{X}^\top\mathbf{X}$ とした)。罰則の項は $\lambda\|\boldsymbol{\beta}\|_2^2 = \boldsymbol{\beta}^\top(\lambda\mathbf{I})\boldsymbol{\beta}$ と書け、$\lambda\mathbf{I}$ も対称なので、$\mathbf{A} = \lambda\mathbf{I}$ として

$$\frac{\partial}{\partial \boldsymbol{\beta}}(\lambda\|\boldsymbol{\beta}\|_2^2) = 2\lambda\boldsymbol{\beta}$$

となる。f_λ は微分できるので、最小点では 2 つの勾配の和が 0 になる。

$$-2\mathbf{X}^\top(\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}) + 2\lambda\boldsymbol{\beta} = 0$$

2 で割って並べ替えると、前半の正規方程式 (2) 式になる。

次に、$\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I}$ が正定値であることを示す。0 でない $\boldsymbol{v}$ について

$$\boldsymbol{v}^\top(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})\,\boldsymbol{v} = (\mathbf{X}\boldsymbol{v})^\top(\mathbf{X}\boldsymbol{v}) + \lambda\boldsymbol{v}^\top\boldsymbol{v} = \|\mathbf{X}\boldsymbol{v}\|_2^2 + \lambda\|\boldsymbol{v}\|_2^2 \tag{10}$$

である。第 1 項は 0 以上、$\lambda > 0$ なので第 2 項は正であり、(10) 式は正になる。定義 2 より、$\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I}$ は正定値である。

正定値なら逆行列がある。もし $(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})\boldsymbol{v} = 0$ となる $\boldsymbol{v} \neq 0$ があれば、左から $\boldsymbol{v}^\top$ を掛けて (10) 式の左辺が 0 になり、矛盾する。0 に送られる向きが 0 のほかに無いので、$\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I}$ は逆行列を持つ。(2) 式の両辺に左から逆行列を掛けると、ただ 1 つの解 (3) 式を得る。

最後に、この解が最小点であり、ほかに最小点が無いことを示す。残差を $\boldsymbol{e} = \boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{\beta}}_\lambda$ とすると、(2) 式は $\mathbf{X}^\top\boldsymbol{e} = \lambda\hat{\boldsymbol{\beta}}_\lambda$ と書ける。任意の向き $\boldsymbol{v}$ について、$f_\lambda(\hat{\boldsymbol{\beta}}_\lambda + \boldsymbol{v}) = \|\boldsymbol{e} - \mathbf{X}\boldsymbol{v}\|_2^2 + \lambda\|\hat{\boldsymbol{\beta}}_\lambda + \boldsymbol{v}\|_2^2$ を展開して $\boldsymbol{v}$ の 1 次と 2 次の項に分けると

$$\begin{aligned} f_\lambda(\hat{\boldsymbol{\beta}}_\lambda + \boldsymbol{v}) &= f_\lambda(\hat{\boldsymbol{\beta}}_\lambda) - 2\boldsymbol{v}^\top(\mathbf{X}^\top\boldsymbol{e} - \lambda\hat{\boldsymbol{\beta}}_\lambda) + \boldsymbol{v}^\top(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})\boldsymbol{v} \\ &= f_\lambda(\hat{\boldsymbol{\beta}}_\lambda) + \boldsymbol{v}^\top(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})\boldsymbol{v} \end{aligned}$$

である。2 つ目の等号では、1 次の項の括弧の中が 0 になることを使った。$\boldsymbol{v} \neq 0$ なら (10) 式により 2 次の項は正なので、$f_\lambda(\hat{\boldsymbol{\beta}}_\lambda + \boldsymbol{v}) > f_\lambda(\hat{\boldsymbol{\beta}}_\lambda)$ である。どの向きに動いても目的関数は大きくなるので、$\hat{\boldsymbol{\beta}}_\lambda$ はただ 1 つの最小点である。この議論は $\mathbf{X}$ の中身によらない。 □

$\lambda = 0$ では、$\mathbf{X}\boldsymbol{v} = 0$ となる向き（前半の 3 列の例の $\boldsymbol{v} = [1, 1, -1]^\top$）に動いても目的関数は増えない。罰則が無いと谷底が線になったのは、このためである。

なぜ②：偏りが入るのか

2 つ目は、罰則を足すとなぜ偏りが入り、分散が減るのか、である。前半の図 5 と同じく、係数が 1 つの場合で導く。モデルと誤差の仮定は「分散が減り、偏りが入る」の節のとおりとする。

証明には、期待値の線形性と、第 3 回で示した最小二乗の係数の平均と分散を使う。取り直しても変わらない定数 a, b と、取り直すたびに値が変わる量 z について $\mathbb{E}[az + b] = a\,\mathbb{E}[z] + b$ である。係数が 1 つで切片

の無いモデルでは、最小二乗の係数 $\hat{\beta}$ について $\mathbb{E}[\hat{\beta}] = \beta$、$\mathbb{E}[(\hat{\beta} - \beta)^2] = \sigma^2 / \sum_i x_i^2$ である（第 3 回の分散 $\sigma^2[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}$ で $p = 1$ とした場合）。これらを使って 定理 2 を証明する。

証明. $S = \sum_i x_i^2$ とおくと、(4) 式は

$$\hat{\beta}_\lambda = \frac{\sum_i x_i y_i}{S + \lambda} = \frac{S}{S + \lambda} \cdot \frac{\sum_i x_i y_i}{S} = \kappa\, \hat{\beta}, \qquad \kappa = \frac{S}{S + \lambda}$$

と、最小二乗の係数 $\hat{\beta}$ の κ 倍に書ける。κ は x と λ だけで決まる定数で、$0 < \kappa \leq 1$ であり、$\lambda = 0$ なら 1 である。

期待値の線形性で $a = \kappa$、$b = 0$ とし、$\mathbb{E}[\hat{\beta}] = \beta$ を使うと

$$\mathbb{E}[\hat{\beta}_\lambda] = \kappa\, \mathbb{E}[\hat{\beta}] = \kappa\beta$$

となる。$\lambda > 0$ では平均が真の値より 0 に近く、直線がそろって寝る。偏りは

$$\mathbb{E}[\hat{\beta}_\lambda] - \beta = -(1 - \kappa)\beta$$

である。

次に分散（定義 3）を求める。Ridge 回帰では

$$\hat{\beta}_\lambda - \mathbb{E}[\hat{\beta}_\lambda] = \kappa\hat{\beta} - \kappa\beta = \kappa(\hat{\beta} - \beta)$$

である。これを二乗し、定数 κ^2 を期待値の線形性で外に出す。最小二乗の係数の分散を使うと

$$\mathbb{V}\mathrm{ar}(\hat{\beta}_\lambda) = \kappa^2\, \mathbb{E}[(\hat{\beta} - \beta)^2] = \kappa^2\, \frac{\sigma^2}{S}$$

を得る。これで (5) 式が示せた。

最後に二乗誤差 $\mathbb{E}[(\hat{\beta}_\lambda - \beta)^2]$ を分ける。$\hat{\beta}_\lambda - \beta$ を、揺れと定数の偏りの和に分ける。

$$\hat{\beta}_\lambda - \beta = \underbrace{(\hat{\beta}_\lambda - \mathbb{E}[\hat{\beta}_\lambda])}_{\text{揺れ}} + \underbrace{(\mathbb{E}[\hat{\beta}_\lambda] - \beta)}_{\text{偏り}}$$

二乗を展開すると、交差項の期待値は

$$2(\mathbb{E}[\hat{\beta}_\lambda] - \beta)\, \mathbb{E}[\hat{\beta}_\lambda - \mathbb{E}[\hat{\beta}_\lambda]] = 2(\mathbb{E}[\hat{\beta}_\lambda] - \beta) \cdot 0 = 0$$

となって消える。偏りは定数なので、期待値の線形性で外に出せる。残る 2 つの項に、上で求めた偏りと分散を入れると

$$\mathbb{E}[(\hat{\beta}_\lambda - \beta)^2] = \underbrace{(1-\kappa)^2\beta^2}_{\text{Bias}^2} + \underbrace{\kappa^2 \frac{\sigma^2}{S}}_{\text{Variance}} = \frac{\lambda^2\beta^2 + S\sigma^2}{(S+\lambda)^2}$$

となる。最後の等号では

$$1-\kappa = \frac{\lambda}{S+\lambda}, \qquad \kappa = \frac{S}{S+\lambda}$$

を入れて通分した。これで (6) 式が示せた。λ で微分すると、商の微分 $(u/w)' = (u'w - uw')/w^2$ で $u = \lambda^2\beta^2 + S\sigma^2$、$w = (S+\lambda)^2$ として

$$\frac{d}{d\lambda}\frac{\lambda^2\beta^2 + S\sigma^2}{(S+\lambda)^2} = \frac{2\lambda\beta^2(S+\lambda) - 2(\lambda^2\beta^2 + S\sigma^2)}{(S+\lambda)^3} = \frac{2S(\lambda\beta^2 - \sigma^2)}{(S+\lambda)^3}$$

である。分母は正なので、符号は $\lambda\beta^2 - \sigma^2$ で決まる。$\beta \neq 0$ なら $\lambda < \sigma^2/\beta^2$ で負、それより大きいと正になる。底とそこでの二乗誤差は

$$\lambda^* = \frac{\sigma^2}{\beta^2}, \qquad \mathbb{E}[(\hat{\beta}_{\lambda^*} - \beta)^2] = \frac{\sigma^2}{S + \sigma^2/\beta^2} < \frac{\sigma^2}{S}$$

である。右端は最小二乗法の二乗誤差で、底の値は分母が大きいぶん必ず小さい。 □

標準偏差は κ 倍に縮み、扇が閉じる。図 17 は、(5) 式の 2 つの分布を描いたものである。

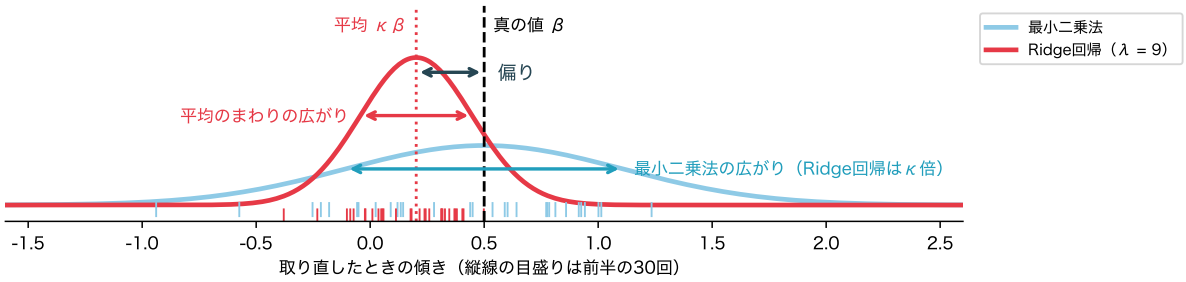


図 17: 図 5 の設定で、取り直したときの傾きの分布。最小二乗法(水色)は真の値 β を中心に広がり、Ridge 回帰(赤)は平均 $\kappa\beta$ が真の値からずれる(偏り)かわりに、平均のまわりの広がりが κ 倍に縮む。下の縦線は 30 回ぶんの傾き

(6) 式の底は、前半の 図 6 の底にあたる。

なぜ③：ちょうど 0 になるのか

3 つ目は、Lasso はなぜ係数をちょうど 0 にするのか、である。1 変数の目的関数 (7) 式で、$|\beta|$ は $\beta = 0$ で尖っていて微分できないので、$\beta > 0$ の側と $\beta < 0$ の側で別々に考える。証明には、$|\beta|$ の微分と、次の命題を使う。$|\beta|$ の微分は、$\beta > 0$ で 1、$\beta < 0$ で -1 である。$\beta = 0$ では左右の傾きが -1 と 1 で食い違うので、微分できない（尖る）。

命題 2 (傾きの符号と最小)**.** 連続な関数 g が有限個の点を除いて微分でき、点 a より左の微分できるすべての点で $g' < 0$、右の微分できるすべての点で $g' > 0$ を満たすとする。このとき、g は a で最小になり、最小点は a だけである。

証明. $x < a$ とする。x と a の間にある微分できない点で、区間 $[x, a]$ を小区間に分ける。各小区間で g は連続で、内側で微分でき、$g' < 0$ である。平均値の定理より、各小区間の右端の値は左端の値より小さい。これをつなぐと $g(x) > g(a)$ である。$x > a$ のときも同じく、$g(x) > g(a)$ である。 □

これらを使って 定理 3 を証明する。

証明. $\beta > 0$ の側では $|\beta| = \beta$ で、罰則の項の傾きは λ である。微分して 0 とおくと

$$g'_\lambda(\beta) = -2c + 2S\beta + \lambda = 0 \quad \Longrightarrow \quad \beta = \frac{c - \lambda/2}{S}$$

となる。これが正の側に入るのは $c > \lambda/2$ のときである。このとき g'_λ は、この点より左で負、右で正になる（$\beta < 0$ の側でも $g'_\lambda = 2S\beta - \lambda - 2c < 0$）。命題 2 より、この点がただ 1 つの最小点である。

$\beta < 0$ の側では $|\beta| = -\beta$ で、罰則の項の傾きは $-\lambda$ である。同様に

$$g'_\lambda(\beta) = -2c + 2S\beta - \lambda = 0 \quad \Longrightarrow \quad \beta = \frac{c + \lambda/2}{S}$$

を得る。これが負の側に入るのは $c < -\lambda/2$ のときである。

どちらの側にも谷底が無いのは $|c| \le \lambda/2$ のときで、$\lambda - 2c \ge 0$ かつ $\lambda + 2c \ge 0$ である。このとき両側の傾きは

$$\beta > 0 : \quad g'_\lambda(\beta) = 2S\beta + (\lambda - 2c) > 0, \qquad \beta < 0 : \quad g'_\lambda(\beta) = 2S\beta - (\lambda + 2c) < 0$$

となる。g_λ は負の側で減り、正の側で増えるので、命題 2 より尖りの $\beta = 0$ がただ 1 つの最小点になる。3 つの場合をまとめると、前半の (8) 式になる。 □

列が p 本になると、Lasso の解を 1 本の式で書くことはできない。そこで、ほかの係数を止めて、1 つの係数 β_j だけを動かすことをくり返す。列 j 以外の分を引いた残差を

$$\boldsymbol{r}_j = \boldsymbol{y} - \sum_{k \neq j} \boldsymbol{x}_k \beta_k$$

とする。$\mathbf{X}\boldsymbol{\beta} = \sum_k \boldsymbol{x}_k \beta_k$ なので $\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta} = \boldsymbol{r}_j - \boldsymbol{x}_j \beta_j$ であり、目的関数は

$$\| \boldsymbol{r}_j - \boldsymbol{x}_j \beta_j \|_2^2 + \lambda |\beta_j| + \lambda \sum_{k \neq j} |\beta_k|$$

となる。最後の和は β_j を含まない定数である。前半は (7) 式の y を $\boldsymbol{r}_j$、x を $\boldsymbol{x}_j$ に替えたものである。したがって

$$c = \boldsymbol{x}_j^\top \boldsymbol{r}_j, \qquad S = \boldsymbol{x}_j^\top \boldsymbol{x}_j$$

とした (8) 式が、β_j の最小点である。これを $j = 1, \ldots, p$ について、係数が動かなくなるまでくり返す。この方法を座標降下法(coordinate descent)と呼ぶ。1 回の更新で目的関数が増えることはなく、罰則が係数ごとの和に分かれているので、くり返すと目的関数の最小の値に近づく。ただし列が行より多いと、Lasso の最小点は 1 つに限らない。前半の困りごとの 20 列も、これで解いた。

第 II 部　実データ解析

リボフラビンのデータ

第 II 部では、第 I 部の理論を遺伝子のデータで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。予想どおりにいけば、それでよい。

第 I 部からは、次の 3 つを予想できる。1 つ目に、二乗の罰則(Ridge 回帰)を足せば、列が行より多くても係数は 1 つに決まる。2 つ目に、Lasso の係数はスパースになる。多くの係数がちょうど 0 になり、少数の遺伝子だけが残るはずである。3 つ目に、罰則の強さを交差検証(クロスバリデーション、CV)で選べば、平均だけで予測するよりよく当たるはずである。最小二乗法は解が 1 つに決まらないので、比べる相手は平均だけの予測にする。

データは、Bühlmann・Kalisch・Meier が 2014 年に高次元のデータ解析の例として紹介したものである(Annual Review of Statistics and Its Application 1, 255–278)。枯草菌にリボフラビン(ビタミン B2)をつくらせた 71 の培養の試料について、リボフラビンの生産量と、4088 個の遺伝子の発現量が測られている。目的変数は生産量の対数、説明変数は発現量の対数である。データは DSM 社(スイス)が提供したもので、R の hdi パッケージ(GPL)に収められたものを書き出して使った。列は行の約 58 倍あり、冒頭の場面で見たとおり、最小二乗法では係数が 1 つに決まらない。

計算の手続き

計算の手続きは次のとおりである。4088 列を標準化したデータ行列 $\mathbf{Z}$ と中心化した生産量の対数について、Ridge 回帰は scikit-learn の Ridge で、λ の候補 40 個(0.1 から 10^5 までを対数で等間隔に並べた値)ごとに解いた。Lasso は scikit-learn の Lasso（座標降下法)で解いた。scikit-learn の Lasso は目的関数を n で割った形で書くので、その罰則の強さ α は本章の λ の $1/(2n)$ にあたる。罰則の強さは、5 分割の交差検証(クロスバリデーション、CV）(9) 式が最小になる値を選んだ。CV の各回では、係数を決める側の行だけで標準化の平均・標準偏差を求めた。予測の良さは、平均だけの予測・Ridge 回帰・Lasso の CV の誤差で比べ、さらに罰則の強さを選ぶ手続きまで含めて、入れ子の CV（定義 7。外側 5 組・内側 5 分割)で測り直した。

結果の読み方

第 1 と第 2 の予想は、どちらも当たった。図 18 は、罰則の強さを動かしたときの Lasso の Solution Path である。罰則が強い左端ではすべての係数が 0 で、右へ弱めていくと、遺伝子が 1 つずつ 0 から離れていく。CV で選んだ強さ $\lambda = 2.9$（scikit-learn の α で 0.021)では、4088 個の遺伝子のうち 53 個だけが残り、ほかの係数はちょうど 0 である。係数はスパースになった。係数の大きい 5 つは YXLD_at、YOAB_at、ARGF_at、YEBC_at、XHLB_at であった。

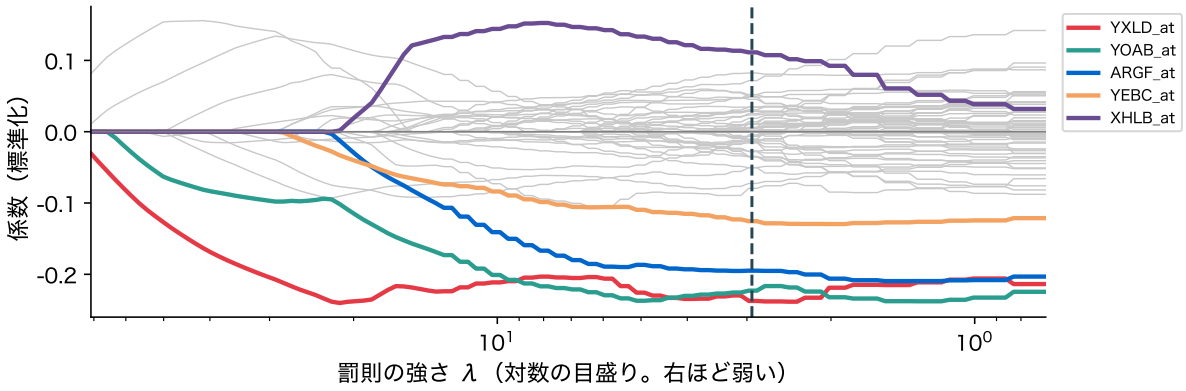


図 18: リボフラビンのデータでの Lasso の Solution Path（標準化した単位)。色は、CV で選んだ強さ(破線)で係数の大きい 5 つの遺伝子、灰はほかの遺伝子

予測も良くなった(図 19、表 1)。平均だけで予測したときの 5 分割 CV の誤差は 0.855 である。Ridge 回帰では $\lambda = 242$ で 0.284、Lasso では 0.283 まで下がる。この最小値は候補の中から選んだぶん甘く出ているので、選ぶ手続きまで含めて入れ子の CV で測り直した。Ridge 回帰は 0.296、Lasso は 0.325 で、やはり平均だけの予測よりはるかによく当たる。外側の 5 回で Lasso が残した遺伝子の数は 39, 20, 42, 44, 27 個と回ごとに違ったが、いずれも数十個である。

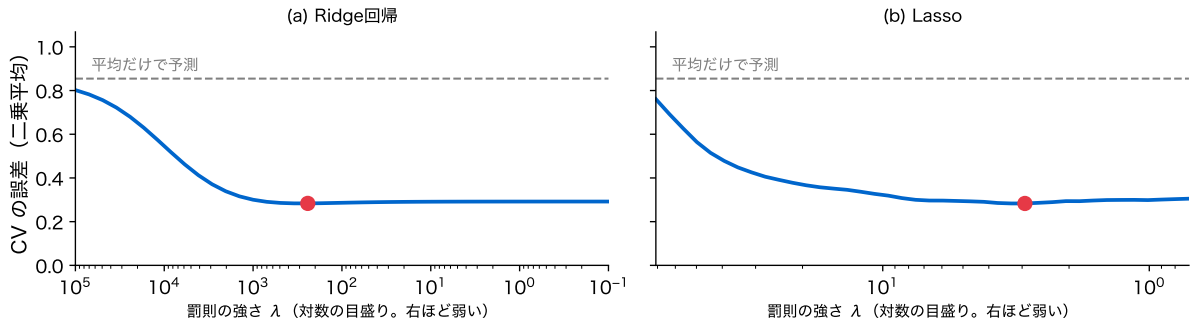


図 19: 罰則の強さに対する 5 分割 CV の誤差（二乗平均）。(a) Ridge 回帰、(b) Lasso。赤は最小の所、破線は平均だけで予測したときの誤差

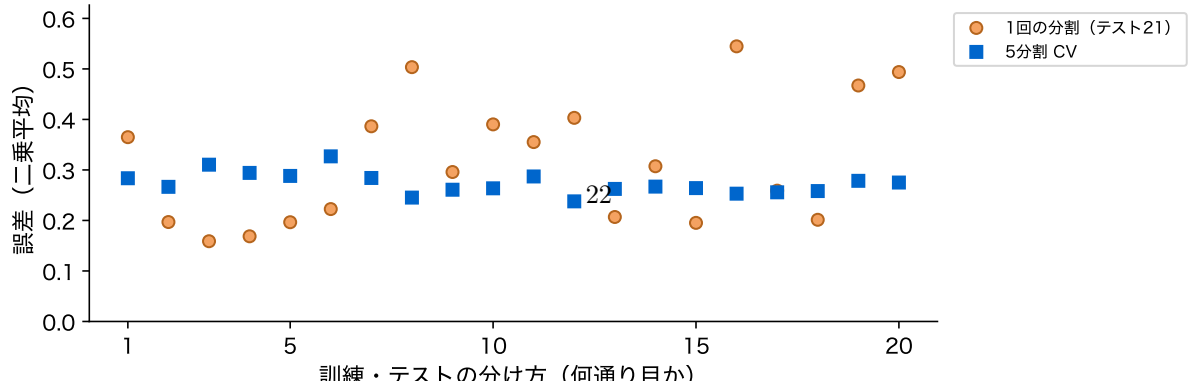
表 1: リボフラビンのデータでの予測の誤差（二乗平均）。CV の最小値と、罰則の強さを選ぶ手続きまで含めた入れ子の CV。平均だけの予測は選ぶものが無いので、どちらも同じ値

	平均だけ	Ridge 回帰	Lasso
CV の最小値	0.855	0.284	0.283
入れ子の CV	0.855	0.296	0.325

一方、予想と違った点もある。第 I 部の人工データでは、新しい点での誤差は罰則の強さに対して U 字を描き、罰則を弱めすぎると誤差は上がった。ところが Ridge 回帰では、罰則をほぼ 0 まで弱めても、CV の誤差はほとんど上がらない（図 19 (a) の右端）。理由は第 I 部の 図 4 にある。谷底が線になるとき、罰則を足すと、線の上でユークリッドノルムが最も小さい 1 点が選ばれた。λ を 0 に近づけても、選ばれる点は線の上のノルム最小の点に近づくだけで、どこでもよい点にはならない。このデータでも、$\lambda \to 0$ の Ridge 回帰は、訓練誤差を 0 にする無数の解のうち、ノルム最小の解に近づく。冒頭の場面の A がその解であり、テストの誤差は 0.35 と悪くなかった。同じく訓練誤差が 0 でも、C や D のように別の解を選べば、平均だけの予測より悪かった（図 1）。罰則を弱めきっても、無数の候補から 1 つを選ぶ働きは残るのである。

分け方によるばらつき

第 I 部の最後には、CV の値も組への分け方でばらつくが、V 個の組の平均をとるぶん、1 回の分割よりずっと小さいと述べた。これも確かめる（図 20）。CV で選んだ強さの Ridge 回帰を、71 の試料から 21 をテストに取り分けて測る。訓練・テストへの分け方だけを 20 通り変えると、テスト誤差は 0.16 から 0.54 まで動き、標準偏差は 0.121 である。分け方を 20 通り変えて 5 分割 CV を行うと、標準偏差は 0.021 で、1 回の分割の約 6 分の 1 になる。1 回の分割では 21 の試料しか測る側に回らないが、CV ではどの試料も 1 度ずつ測る側に回る。試料が少ないデータほど、この違いは大きい。



実データで起きる落とし穴

第 I 部の式から見て、実データで起きやすい失敗を 3 つ挙げる。

第 1 に、訓練誤差を報告してしまう（図 21）。Ridge 回帰の罰則を弱めると、訓練誤差は 0 へ下がる。列が行より多いので、どの試料もぴたりと当てる係数が作れるからである。最も弱い罰則（$\lambda = 0.1$）では訓練誤差はほぼ 0 だが、5 分割 CV の誤差は 0.292（平均だけなら 0.855）であり、訓練誤差は予測の良さについて何も語らない。第 I 部で述べたとおり、予測の良さは、係数の決定に使わなかった行で測る。

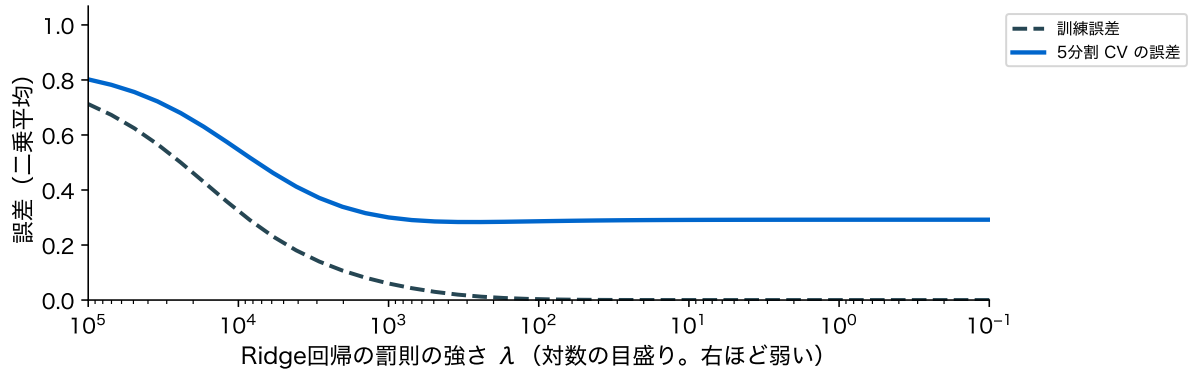


図 21: リボフラビンのデータでの Ridge 回帰の訓練誤差（破線）と 5 分割 CV の誤差（実線）。横軸は罰則の強さ（対数の目盛り）で、右ほど弱い

第 2 に、標準化を忘れる。元の単位のままの列に Lasso を当て、罰則の強さを 10 個だけが残るように調整すると、標準化してから同じことをしたときと両方に残るのは 4 個だけである（表 2）。遺伝子の発現量の標準偏差は 0.10 から 1.83 まで違う。元の単位では、ばらつきの大きい遺伝子ほど同じ効き目を小さな係数で表せるので、罰則をほとんど受けずに残る。第 I 部で見たとおり、罰則は目盛りの取り方で動く。

表 2: Lasso で 10 個の遺伝子だけを残したとき、残った遺伝子の標準偏差（中央値）。標準化してから当てた場合と、元の単位のまま当てた場合

	残った 10 個の遺伝子の標準偏差（中央値）	両方に残った数
標準化してから	0.52	4
元の単位のまま	1.00	4

第 3 に、Lasso が残した遺伝子を、それだけが効く遺伝子だと読んでしまう。訓練 50・テスト 21 への分け方を 20 通り変え、CV で選んだ強さの Lasso を訓練の試料に当てはめ直すと（図 22）、一度でも残った遺伝子は 299 個にのぼり、20 回とも残ったのは 0 個である。発現量の似た遺伝子が多いと、Lasso はその中から 1 つを残すが、どれを残すかは試料の偶然で決まる。言えるのは「残った遺伝子を使えば予測できる」までであり、「残らなかった遺伝子は生産量に関係ない」とは言えない。

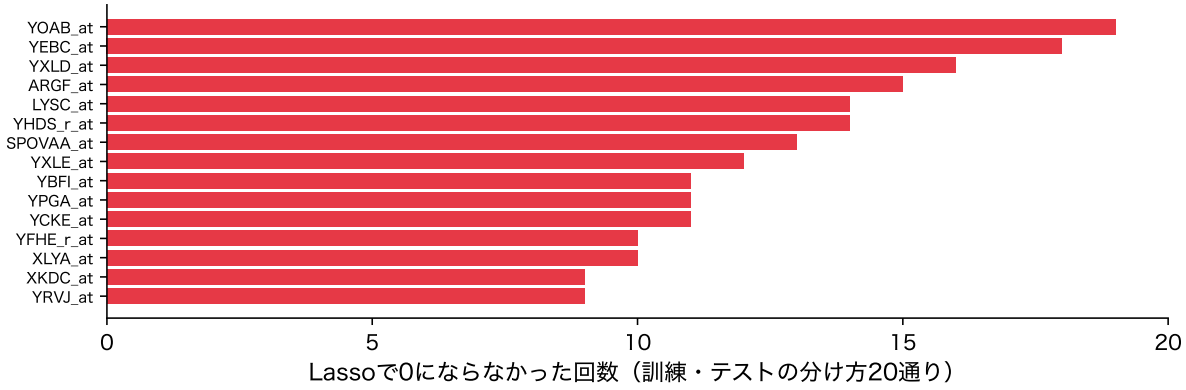


図 22: 訓練・テストへの分け方 20 通りで、CV で選んだ強さの Lasso が係数を 0 にしなかった回数(多い 15 個の遺伝子)

このデータでわかったこと

第 II 部の結果をまとめる。最小二乗法では係数が 1 つに決まらない、列が行の約 58 倍のデータでも、罰則を足せば係数は 1 つに決まり、予測ができた。Lasso の係数はスパースになり、4088 個の遺伝子から 53 個だけを残した。選ぶ手続きまで含めた入れ子の CV でも、平均だけの予測の誤差 0.855 を、Ridge 回帰で 0.296、Lasso で 0.325 まで下げた。予想と違ったのは、Ridge 回帰が罰則をほぼ 0 まで弱めても悪くならなかったことで、$\lambda \to 0$ でもノルム最小の解を選ぶ働きが残るからである。CV の数字のばらつきは、1 回の分割の約 6 分の 1 であった。それでも、Lasso が残す遺伝子は分け方で大きく入れ替わる。残った遺伝子は予測に使える組の 1 つであって、効く遺伝子の一覧ではない。

締め

まとめと次回の問い

本章の問いは、データの当てはまりだけでは係数の候補が 1 つに決まらない、あるいは大きくばらつくとき、どの 1 つを選ぶか、であった。答えは、目的関数に係数の大きさへの罰則を足すことである。二乗の罰則を足した Ridge 回帰では、正規方程式の $\mathbf{X}^\top\mathbf{X}$ が $\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I}$ に変わる。この行列は正定値で、0 でないどの向きも 0 に送らないので、列が重なっていても列が行より多くても逆行列を持つ。代わりに係数には偏りが入り、分散は減る。係数の二乗誤差は Bias^2 と Variance の和であり、罰則の強さに対して U 字を描く。その底は真の係数とノイズで決まるので、手元のデータから交差検証(クロスバリデーション、CV)で探す。選んだあとの予測の良さは、選ぶ手続きまで含めて入れ子の CV で測る。絶対値の罰則を足した Lasso は、小さな係数をちょうど 0 にする。罰則は係数の大きさを列をまたいで比べるので、列を標準化してから足す。リボフラビンのデータは、列が行の約 58 倍あり、最小二乗法では係数が 1 つに決まらなかった。罰則を足すと係数は 1 つに決まり、選ぶ手続きまで含めた入れ子の CV でも、平均だけの予測よりはるかによく当たった。Lasso は 4088 個の遺伝子から 53 個だけを残した。Ridge 回帰は罰則をほぼ 0 まで弱めても悪くならなかったが、これは $\lambda \to 0$ でもノルム最小の解を選ぶ働きが残るからである。CV の数字のばらつきは 1 回の分割の約 6 分の 1 になった。ただし、Lasso

がどの遺伝子を残すかは、分け方でなお大きく入れ替わる。

最後に、次回への問いを置く。ここまで目的変数は、リボフラビンの生産量のような連続の量だった。では、当たりか外れかのように、目的変数が 0 か 1 しか取らないとき、同じ最小二乗法を当ててよいのだろうか。次回は、0/1 の目的変数を最小二乗法で回帰すると、係数の向きが何を表すのかを導く。

発展

発展：選んだ後の検定（選択的推論）

発展として、Lasso で列を選んだ後の検定を紹介する。Lasso は効きそうな列だけを残す。残った列が本当に効くのかを、検定で確かめたいとする。検定では、列 j は効かない（$\beta_j = 0$）と仮定し、その仮定の下で観測した値より極端な値が出る確率を求める。この確率を p 値（p-value）と呼び、5% より小さければ「効く」と判断する（有意水準 5%）。効かない列の p 値は 0 から 1 に一様に散らばるので、誤って「効く」と判断するのは 5% だけのはずである。ところが、選ぶのにも確かめるのにも同じデータを使うと、この約束が崩れる。

人工的なデータで確かめる。100 行・50 列で、列は互いに直交し、長さを 1 にそろえた。真の係数はすべて 0 で、ノイズの標準偏差は 1（既知）とした。$\boldsymbol{x}_j^\top \boldsymbol{x}_j = 1$ なので、(8) 式の S は 1 であり、Lasso が列 j を残すのは $z_j = \boldsymbol{x}_j^\top \boldsymbol{y}$ の大きさが $\lambda/2$ を超えるときである。ここでは $\lambda/2 = 1.5$ とした。$\boldsymbol{y}$ を 1000 回作り直すと、残った列は合わせて 6712 本あった。残った列を、選ばれたことを気にせずに検定すると、p 値は

$$p = \Pr(|Z| \geq |z_j|)$$

である（Z は標準正規分布に従う）。この p 値はすべて 0.13 以下に偏り、37% が有意水準 5% で有意になった（図 24 (a)）。効く列は 1 本も無いのにである。

理由は、選ばれた列が「$|z_j|$ が大きいから選ばれた」ことにある。$\beta_j = 0$ のとき z_j は標準正規分布に従うが、選ばれた列の z_j は、$|z_j| \leq \lambda/2$ の真ん中を除いた所からしか来ない。正規分布の一部だけを残し、面積が 1 になるよう割り増した分布を切断正規分布（truncated normal distribution）と呼ぶ（図 23）。選ばれた列の z_j は、この切断正規分布に従う。したがって、選ばれたことを条件にした p 値は

$$p = \Pr(|Z| \geq |z_j| \;\big|\; |Z| > \lambda/2) = \frac{\Pr(|Z| \geq |z_j|)}{\Pr(|Z| > \lambda/2)}$$

となる。たとえば $z_j = 2.2$ なら、ふつうの p 値は 0.028 だが、条件にした p 値は 0.21 である。この p 値を使うと一様に戻り、有意になったのは 4.8% であった（図 24 (b)）。選んだことを条件にして検定する方法を、選択的推論（selective inference）と呼ぶ。英語では post-selection inference ともいう。

列が直交していないと、どの列の組が残るかは $\boldsymbol{y}$ によって入れ替わり、条件は 1 本の区間では書けない。Lee, Sun, Sun & Taylor (2016) は、Lasso が同じ列の組と同じ符号を選ぶ $\boldsymbol{y}$ の集合が、1 次式の不等式 $\mathbf{A}\boldsymbol{y} \leq \boldsymbol{b}$ で書けることを示した。検定量 $\boldsymbol{\eta}^\top \boldsymbol{y}$ は、その条件の下で区間に切断された正規分布に従う。Duy & Takeuchi

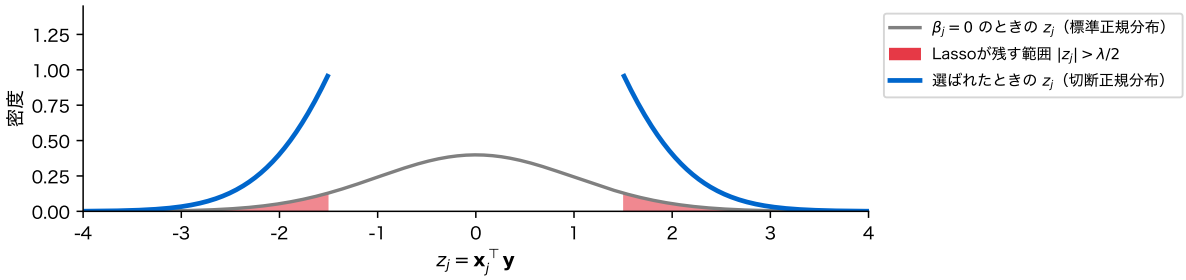


図 23: 効かない列の $z_j = \boldsymbol{x}_j^\top \boldsymbol{y}$ の分布（灰、標準正規分布）と、Lasso が残す範囲 $|z_j| > \lambda/2$（赤）。選ばれた列の z_j は、赤の範囲だけに面積 1 を割り振った切断正規分布（青）に従う（概念図）

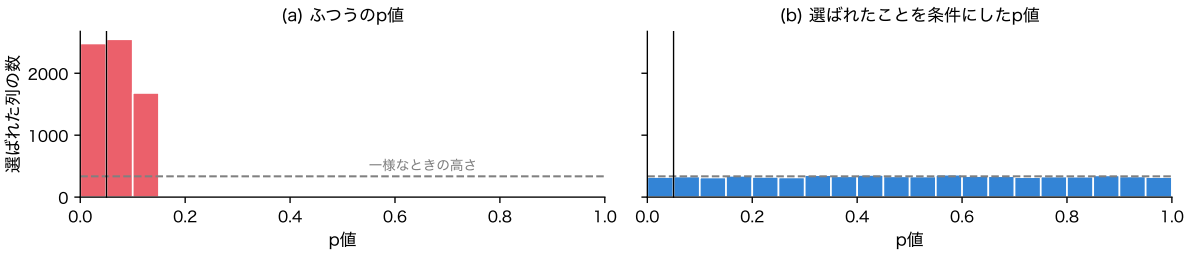


図 24: 係数がすべて 0 の人工データ（100 行・50 列、直交）で、Lasso が残した列の p 値。(a) 選ばれたことを気にしないふつうの p 値、(b) 選ばれたことを条件にした p 値。破線は一様なときの高さ、縦線は 5%

(2022) は、$\boldsymbol{y}$ を 1 本の直線の上で動かして同じ組が残る区間をすべて集め、符号まで条件にするよりも検出力の高い検定を作った（図 25）。

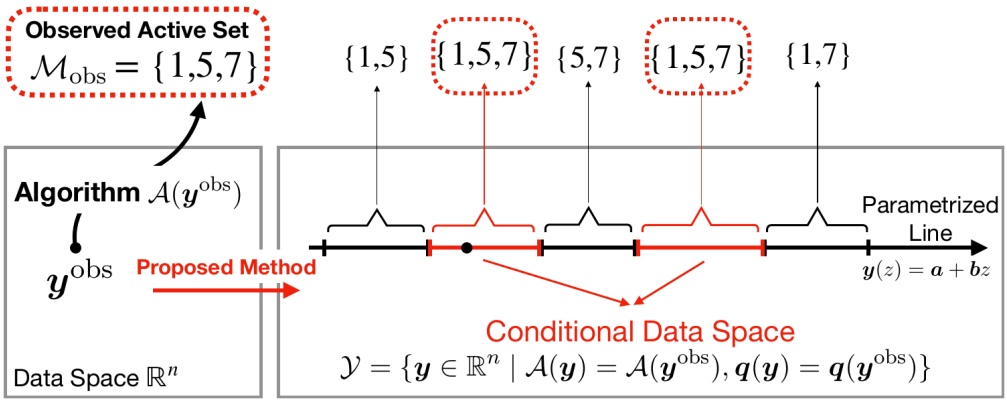


図 25: 選択的推論の考え方。観測した $\boldsymbol{y}$ で Lasso が残した列の組 {1, 5, 7} と同じ組が残る区間（赤）を、$\boldsymbol{y}$ を直線の上で動かして集め、その区間の上の切断正規分布で検定する。出典：Duy & Takeuchi (2022) J. Mach. Learn. Res. 23(300): 1–37, Fig. 1（CC BY 4.0）

スパース推定と選択的推論を研究している梅津佑太先生が、長崎大学にいる。梅津先生には、高次元の分類問題での選択的推論の研究（Umezu & Takeuchi, 2019）があり、スパース推定の教科書（梅津・西井・上田, 2020）も

書いている。この回で見た Lasso の先には、選んだ後にどう確かめるかという、いまも研究が進む問いがある。その問いの専門家から直接学べるのは、めったにない幸運である。その幸運に感謝して、ぜひ梅津先生の担当講義を一生懸命聞いてほしい。

参考文献

- Lee, J. D., Sun, D. L., Sun, Y., & Taylor, J. E. (2016). Exact post-selection inference, with application to the lasso. The Annals of Statistics, 44(3), 907–927.
- Duy, V. N. L., & Takeuchi, I. (2022). More powerful conditional selective inference for generalized lasso by parametric programming. Journal of Machine Learning Research, 23(300), 1–37.
- Umezu, Y., & Takeuchi, I. (2019). Selective inference via marginal screening for high dimensional classification. Japanese Journal of Statistics and Data Science, 2(2), 559–589.
- 梅津佑太・西井龍映・上田勇祐 (2020).『スパース回帰分析とパターン認識』(データサイエンス入門シリーズ). 講談社.