

第 4 回 罰則付き最小二乗法

係数の大きさに罰を足し、罰の強さを交差検証で選ぶ

本章の問いは、第 3 回の締めで残った「係数が非常に不安定になる、あるいは 1 つに決まらないとき、どうするか」である。目的関数に係数の大きさへの罰を足すと、 $\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}$ は必ず逆行列を持ち、係数の分散が減るかわりに偏りが入る。罰の強さ λ は交差検証(クロスバリデーション、CV)で選ぶ。

第 I 部 理論

データだけでは係数を選べない

第 3 回では、最小二乗法の係数の不安定性が $\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}^T \mathbf{X})^{-1}$ で表されることを導いた。不安定性は、ノイズが大きいほど、行が少ないほど、列どうしが似ているほど大きい。列が完全に重なるか行より多いと、逆行列そのものが無くなって係数は 1 つに決まらない。第 3 回の締めには、そのように係数が非常に不安定になるときどうするか、という問いが残った。

本章では、この問いを前立腺がんのデータで見直すところから始める。97 人の患者について、血液中の PSA (前立腺特異抗原) の値の対数を、がんの体積や悪性度など 8 つの測定値から予測するデータである(第 II 部で詳しく述べる)。97 人から 97 人を復元抽出して係数を当てはめ直すこと(ブートストラップ(bootstrap))を 1000 回くり返し、取り直しに対する係数の標準偏差を求めた。すると、8 本の係数のうち 4 本は、全員で当てはめた値から ± 2 標準偏差の幅が 0 をまたぐ(図 1 (a))。係数は標準化した列についてのもので、その列が標準偏差 1 つぶん動いたときの PSA の対数の変化を表す。たとえばグリーンソンスコアの係数は 0.036 だが、取り直しの標準偏差は 0.109 で、符号さえ決まらない。

ばらつき方には形がある。グリーンソンスコアと、グリーンソンの等級 4・5 が占める割合は、どちらもがん組織の悪性度を測った列で、相関は 0.75 である。この 2 つの係数を 1000 回ぶん並べると、左上から右下へ伸びた雲になる(図 1 (b))。2 つの係数の取り直しに対する相関は -0.69 で、片方が大きく出た回はもう片方が小さく出る。和はよく決まるが、内訳はデータからほとんど決められない。

本章の問いは 1 つである。係数が非常に不安定になるとき、あるいはデータの当てはまりだけでは候補が 1 つに決まらないとき、どの 1 つを選ぶか。答えは、目的関数に係数の大きさへの罰を足すことである。まず罰を書くための道具をそろえ、二乗の罰(リッジ回帰)を足すと逆行列が必ず存在することを示す。次に、その代わりに係数に偏りが入り、分散が減ることを見る。続いて、絶対値の罰(ラッソ)が係数をちょうど 0 にすることを示し、罰の強さを動かしたときの係数の動きを 1 枚の図にまとめる。さらに、罰の前に列の目盛りをそろえる必要




図 1: 前立腺がんのデータで、97 人のブートストラップ 1000 回から求めた係数のばらつき (標準化した単位)。(a) 全員で当てはめた係数と ± 2 標準偏差。赤がグリーソンスコア、緑がグリーソン 4・5 の割合。(b) その 2 つの係数の 1000 回ぶん。★は全員で当てはめた値

があることと、罰の効き具合を有効自由度で数えられることを述べる。最後に、罰の強さを交差検証(クロスバリデーション、CV)で選ぶ手順を導く。

「モデル × 推定法」の地図でいえば、モデルは線形回帰のまま動かず、推定法が最小二乗法から罰則付き最小二乗法に変わる。第 1 回で最小二乗法を「データとモデルの距離を最小にする推定法」と呼んだが、本章の推定法は、その距離に罰を足したものを最小にする。推定法の列が増えるのは、全 15 回でこれが初めてである。

道具：ノルム・正定値・トレース

候補が 1 つに決まらないなら、当てはまりのほかに、候補を選ぶための基準を足せばよい。本章では、「ほかが同じなら、係数は小さいほうがよい」という基準を足す。その基準を式に書き、効き方を調べるには、3 つの道具を使う。本章の道具はここにまとめておく。

1 つ目は、係数ベクトルの大きさの測り方である。第 1 回ではベクトルの大きさ(ユークリッドノルム)を定義した。本章ではそれに加えて、絶対値の和で測る大きさを使う。

定義 1 (ℓ_2 ノルムと ℓ_1 ノルム). ベクトル $\beta = [\beta_1, \dots, \beta_p]^\top$ について、

$$\|\beta\|_2^2 = \sum_{j=1}^p \beta_j^2, \quad \|\beta\|_1 = \sum_{j=1}^p |\beta_j| \quad (1)$$

の $\|\beta\|_2$ を ℓ_2 ノルム(第 1 回のユークリッドノルム)、 $\|\beta\|_1$ を ℓ_1 ノルム(L1 norm)と呼ぶ。

1 つの係数についての形を比べると(図 2)、 β^2 は原点の近くで平らに寝ており、係数を 0.1 から 0 へ動かしても値はほとんど減らない。 $|\beta|$ は原点で尖っていて、0 の近くでも傾きが保たれる。この尖りが、後でラッソが係数をちょうど 0 にする理由になる。




図 2: 1 つの係数についての ℓ_2 の罰 β^2 (青)と ℓ_1 の罰 $|\beta|$ (赤)の形(概念図)

2 つ目は、逆行列があるかどうかを確かめる道具である。第 1 回の逆行列の定義では、固有値がすべて正の行列は正則であると述べた。本章では固有値を使わず、同じことを次の形で使う。

定義 2 (正定値). $p \times p$ の対称行列 $\mathbf{A}$ が、0 でないすべてのベクトル $\mathbf{v}$ について $\mathbf{v}^\top \mathbf{A} \mathbf{v} > 0$ を満たすとき、 $\mathbf{A}$ を正定値(positive definite)であるという。正定値な行列は正則である。

正則であることは、次のように確かめられる。もし $\mathbf{A} \mathbf{v} = 0$ となる $\mathbf{v} \neq 0$ があれば、 $\mathbf{v}^\top \mathbf{A} \mathbf{v} = 0$ となって正定値に反する。したがって $\mathbf{A} \mathbf{v} = 0$ を満たすのは $\mathbf{v} = 0$ だけであり、 $\mathbf{A}$ の列は 1 次独立で、逆行列が存在する。逆に、2 列が完全に重なる場合(第 3 回)には、 $\mathbf{v} = [1, -1]^\top$ について $\mathbf{X} \mathbf{v} = 0$ であり、 $\mathbf{X}^\top \mathbf{X} \mathbf{v} = 0$ となる。谷底の直線が伸びる向きが、この $\mathbf{v}$ である。

3 つ目は、行列の対角の和である。

定義 3 (トレース). 正方行列 $\mathbf{A}$ の対角成分の和 $\text{tr } \mathbf{A} = \sum_j a_{jj}$ をトレース(trace)と呼ぶ。 $\mathbf{A}$ が $n \times p$ 、 $\mathbf{B}$ が $p \times n$ のとき

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}) \quad (2)$$

が成り立つ(巡回性)。

(2) 式は、両辺とも $\sum_i \sum_j a_{ij} b_{ji}$ に等しいことから従う。左辺は $n \times n$ の行列の、右辺は $p \times p$ の行列のトレースであり、大きさの違う行列のトレースが等しくなる。この性質は、有効自由度を数えるときに使う。トレースは和と定数倍を通し、スカラーは 1×1 の行列としてそれ自身がトレースである。

罰を足す：リッジ回帰

まずスカラーで考える。第 1 回の切片の無い単回帰の目的関数 $\sum_i (y_i - \beta x_i)^2$ に、係数の二乗に比例する罰を足して

$$f_\lambda(\beta) = \sum_{i=1}^n (y_i - \beta x_i)^2 + \lambda \beta^2 \quad (3)$$

とする。 $\lambda \geq 0$ は罰の強さを決める定数である。図 3 に、人工データでこれを描いた。ラーメンの辛さの段階(店の標準からのずれ)を x 、食べ終わるまでに飲む水の量(いつもからのずれ)を y とした。真の傾きは 0.5、ノイズ

の標準偏差は 1.5 で、区間 $[-1, 1]$ から 20 個の x を取った。第 1 回の放物線(青)に、 $\beta = 0$ で最小になる放物線 $\lambda\beta^2$ (灰)を足すと、和(赤)の谷底は 0 の側へ寄る。(3) 式を β で微分して 0 とおくと

$$\frac{df_\lambda}{d\beta} = -2 \sum_{i=1}^n x_i(y_i - \beta x_i) + 2\lambda\beta = 0 \implies \hat{\beta}_\lambda = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2 + \lambda} \quad (4)$$

を得る。最小二乗の解との違いは、分母に λ が足されたことだけである。 $\lambda = 0$ なら第 1 回の (5) 式に戻り、 λ を大きくするほど $\hat{\beta}_\lambda$ は 0 へ縮む。図 3 の例では、最小二乗の解は 0.76、 $\lambda = 9$ の解は 0.31 である。




図 3: 1 変数の目的関数(人工データ)。最小二乗の目的関数(青)に罰 $\lambda\beta^2$ (灰の破線)を足すと、和(赤)の谷底は 0 の側へ寄る。点はそれぞれの谷底

同じことをベクトルで書く。 n 杯ぶんの x_i と y_i を縦に並べたベクトルを $\mathbf{x}$ 、 $\mathbf{y}$ とすれば、(3) 式は $f_\lambda(\beta) = \|\mathbf{y} - \beta\mathbf{x}\|_2^2 + \lambda\beta^2$ であり、その解は $\hat{\beta}_\lambda = \mathbf{x}^\top \mathbf{y} / (\mathbf{x}^\top \mathbf{x} + \lambda)$ である。内積を成分で書けば (4) 式に戻る。

さらに行列で書く。列が p 本のデータ行列 $\mathbf{X}$ について

$$f_\lambda(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda\|\beta\|_2^2 \quad (5)$$

を最小にする。第 1 回の勾配の計算に、罰の項 $\lambda\beta^\top \beta$ の勾配 $2\lambda\beta$ を足して 0 ベクトルとおけば

$$-2\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\beta) + 2\lambda\beta = 0 \implies (\mathbf{X}^\top \mathbf{X} + \lambda\mathbf{I}_p) \hat{\beta}_\lambda = \mathbf{X}^\top \mathbf{y} \quad (6)$$

となる。第 1 回の正規方程式の $\mathbf{X}^\top \mathbf{X}$ の対角に λ を足した形である。 $p = 1$ なら $\mathbf{X}^\top \mathbf{X} = \mathbf{x}^\top \mathbf{x}$ で、(6) 式はベクトルの解に、したがって (4) 式に戻る。切片は罰さない。切片まで罰すると、 y の原点をずらただけで答えが変わってしまうからである。第 3 回で見たとおり、各列を平均 0 に中心化すれば、切片の推定値は $\bar{y}$ に切り離せる。そこで以下では、 $\mathbf{X}$ は中心化した(後で述べるように標準化した)列だけを持ち、 $\mathbf{y}$ も中心化してあるものとする。

定義 4 (罰則付き最小二乗法とリッジ回帰). 最小二乗法の目的関数に、係数の大きさへの罰を足したものを最小にする推定法を、罰則付き最小二乗法(penalized least squares)と呼ぶ。罰で係数を小さく抑えることを正則化(regularization)ともいう。罰に ℓ_2 ノルムの二乗を用いた (5) 式をリッジ回帰(ridge regression)と呼び、その解は (6) 式で与えられる。

(6) 式の係数行列には、 $\lambda > 0$ である限り、必ず逆行列がある。0 でない $\mathbf{v}$ について

$$\mathbf{v}^\top (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}) \mathbf{v} = \|\mathbf{X}\mathbf{v}\|_2^2 + \lambda \|\mathbf{v}\|_2^2 > 0 \quad (7)$$

であり、第 1 項は 0 以上、第 2 項は正だからである。定義 2 により $\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}$ は正則で、(6) 式の解はただ 1 つに決まる。この議論は $\mathbf{X}$ の中身によらない。列が完全に重なっていても、列が行より多くても成り立つ。第 3 回で逆行列が無かった場合には、 $\mathbf{X}\mathbf{v} = 0$ となる向き $\mathbf{v}$ があり、その向きには目的関数がまったく変わらなかった。罰の第 2 項を足すと、その向きにも少しだけ傾きがつく。

列が完全に重なる場合を、人工的なデータで見ておく。ラーメンの麺の量を 2 台の秤で量り、2 つの値をそれぞれ列にして、たとえば食べ終わったときの満腹度を予測するとする。2 台の秤が正確なら 2 列はまったく同じで(相関 1)、データは 2 つの係数の和しか決められない。真の係数を $(1, 1)$ とすると、罰が無ければ目的関数の底は直線 $\beta_1 + \beta_2 = 2$ の全体になる(図 4 (a))。罰を足すと、その直線の上で $\|\beta\|_2^2$ が最も小さい点、すなわち $\beta_1 = \beta_2$ の 1 点を選ばれる(図は $\lambda/n = 0.1$ で、底は $\beta_1 = \beta_2 = 0.952$)。和が同じなら、2 つの列に効き目を等しく分けたほうが二乗の和は小さいからである。リッジ回帰は、データが区別できない似た列に、効き目を等しく分ける。




図 4: 同じ麺の量を 2 台の秤で量った相関 1 の 2 列の目的関数の等高線(人工データ)。(a) 罰なしでは底が直線(赤)、(b) 罰を足すと底は 1 点(赤の★)に決まる

分散が減り、偏りが入る

罰を足すと、係数は何を失うのか。第 3 回と同じく $\mathbf{X}$ を固定し、 $\mathbf{y}$ だけがノイズのぶんばらつくとする。図 5 は、図 3 と同じ 20 個の x のまま y を 30 回取り直し、そのつど原点を通る直線を引いたものである。最小二乗法 (a) の直線は大きく扇状に開き、傾きが負になる回もある。リッジ回帰 (b) では扇は閉じるが、直線はそろって真の直線より寝ている。




図 5: 同じ x のまま y を 30 回取り直して引いた原点を通る直線(赤、人工データ)。(a) 最小二乗法、(b) リッジ回帰。黒の破線は真の直線、青は 1 回ぶんの点

これをスカラーの式で確かめる。(4) 式は y_i の重み付きの和である。 $\mathbb{E}[y_i] = \beta x_i$ で、各 y_i は独立で分散 σ^2 なので、 $\kappa = \sum_i x_i^2 / (\sum_i x_i^2 + \lambda)$ とおけば

$$\mathbb{E}[\hat{\beta}_\lambda] = \kappa\beta, \quad \text{Var}(\hat{\beta}_\lambda) = \frac{\sigma^2 \sum_i x_i^2}{(\sum_i x_i^2 + \lambda)^2} = \kappa^2 \frac{\sigma^2}{\sum_i x_i^2} \quad (8)$$

を得る。 $\lambda = 0$ なら $\kappa = 1$ で、第 3 回の不偏性と係数の分散の式に戻る。 $\lambda > 0$ では $0 < \kappa < 1$ であり、係数の平均は真の値の κ 倍に縮み、標準偏差も κ 倍に縮む。平均が真の値からずれるので、推定には $(1 - \kappa)\beta$ の偏り (bias) が入る。図 5 の例では、最小二乗法の傾きの標準偏差は 0.61 で、真の傾き 0.5 と同じくらいである。リッジ回帰では標準偏差は 0.25 に下がるが、傾きの平均は 0.20 に縮む。

偏りと分散のどちらを重く見るべきかは、係数の二乗誤差 $\mathbb{E}[(\hat{\beta}_\lambda - \beta)^2]$ で測れる。第 2 回のバイアス・バラランス分解と同じく、平均のまわりに分けると交差項が消えて

$$\mathbb{E}[(\hat{\beta}_\lambda - \beta)^2] = \underbrace{(1 - \kappa)^2 \beta^2}_{\text{Bias}^2} + \underbrace{\kappa^2 \frac{\sigma^2}{\sum_i x_i^2}}_{\text{Variance}} \quad (9)$$

となる。 λ を大きくすると Bias^2 は増え、 Variance は減る(図 6)。和は U 字を描き、 λ で微分して 0 とおくと、底は $\lambda = \sigma^2 / \beta^2$ にある。そのときの二乗誤差は $\sigma^2 / (\sum_i x_i^2 + \sigma^2 / \beta^2)$ で、最小二乗法の $\sigma^2 / \sum_i x_i^2$ より必ず小さい。つまり、罰の強さが適切なら、偏りが入ってもなお係数は真の値に近づく。この例では、最小二乗法の二乗誤差 0.369 が、底では 0.149 まで下がる。ただし底の位置は、真の β と σ^2 で決まっている。どちらも未知なので、この式から λ を決めることはできない。 λ はデータから選ぶしかなく、その方法を本章の後半で導く。

行列でも同じである。(6) 式の解は $\hat{\beta}_\lambda = \mathbf{A}_\lambda \mathbf{y}$ 、 $\mathbf{A}_\lambda = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top$ と書け、第 3 回の線形変換の分散の式から

$$\mathbb{E}[\hat{\beta}_\lambda] = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{X} \beta, \quad \text{Var}(\hat{\beta}_\lambda) = \sigma^2 (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \quad (10)$$




図 6: 1 変数のリッジ回帰の係数の二乗誤差 (9) 式と、その Bias^2 (青)・ Variance (橙)。破線は底の位置 $\lambda = \sigma^2/\beta^2$ (人工データの設定で計算)

を得る。 $\lambda = 0$ なら平均は β 、分散は $\sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$ で、第 3 回の式そのものである。 $p = 1$ なら (8) 式に戻る。図 7 に、人工的なデータでこれを見た。大盛りにするほどスープも多くなる店で、60 杯ぶんの麺の量とスープの量(標準化し、相関 0.92)から、食べ終わったときの満腹度を予測するとした。真の係数を (1.6, 0.4)、ノイズの標準偏差を 1 とおく。 $\mathbf{X}$ は固定したまま $\mathbf{y}$ を 300 回取り直し、最小二乗法とリッジ回帰($\lambda = 5$)の係数を並べた。最小二乗法の雲は左上から右下へ細長く伸び、 $\hat{\beta}_1$ の標準偏差は 0.34 である。リッジ回帰では、細長い向き(内訳 $\beta_1 - \beta_2$ の向き)が大きく縮み、標準偏差は 0.18 になる。その代わり、雲の中心は★からずれる。平均は 1.27 と 0.66 で、真の値の 1.6 と 0.4 より互いに近い。リッジ回帰の係数は、データが区別しにくい 2 列に効き目を等しく分ける側へ偏る。データがよく決めている和の向きはほとんど縮まず、データが決められない内訳の向きが強く縮むのである。




図 7: 麺の量とスープの量(相関 0.92)の 2 列で $\mathbf{y}$ を 300 回取り直したときの係数(人工データ)。(a) 最小二乗法、(b) リッジ回帰。★は真の値

ラッソ：係数をちょうど 0 にする

罰の形を変えると、縮み方が変わる。 ℓ_2 ノルムの二乗のかわりに ℓ_1 ノルムを罰にしたものがラッソである。

定義 5 (ラッソ). 罰に ℓ_1 ノルムを用い、 $\|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda\|\beta\|_1$ を最小にする推定法をラッソ(lasso)と呼ぶ。

まずスカラーで考える。目的関数は

$$g_\lambda(\beta) = \sum_{i=1}^n (y_i - \beta x_i)^2 + \lambda|\beta| \quad (11)$$

である。 $|\beta|$ は $\beta = 0$ で尖っていて微分できないので、 $\beta > 0$ の側と $\beta < 0$ の側で別々に考える。 $c = \sum_i x_i y_i$ 、 $S = \sum_i x_i^2$ とおく。 $\beta > 0$ では $|\beta| = \beta$ なので、微分して 0 とおくと $-2c + 2S\beta + \lambda = 0$ 、すなわち $\beta = (c - \lambda/2)/S$ となる。これが正の側に入るのは $c > \lambda/2$ のときである。 $\beta < 0$ の側も同様に $\beta = (c + \lambda/2)/S$ で、 $c < -\lambda/2$ のときに負の側に入る。どちらの側にも谷底が無いとき、すなわち $|c| \leq \lambda/2$ のときは、 g_λ は $\beta < 0$ で減り $\beta > 0$ で増えるので、尖りの $\beta = 0$ が最小になる。まとめると

$$\hat{\beta}_\lambda^L = \frac{\text{sign}(c) \max(|c| - \lambda/2, 0)}{S} \quad (12)$$

である(sign は符号)。図 8 に、図 3 と同じ人工データで (11) 式を描いた。(a) の λ では谷底は 0 の側へ寄るだけで、係数は 0.38 (最小二乗は 0.76) である。(b) のように $\lambda/2$ が $|c|$ を超えると、谷底は尖りに引っかかり、係数はちょうど 0 になる。




図 8: 1 変数のラッソの目的関数(赤)と最小二乗の目的関数(青)(人工データ)。(a) 罰が弱いと谷底は 0 の側へ寄るだけ、(b) 強いと谷底が $\beta = 0$ の尖りに止まる

(4) 式と (12) 式を、最小二乗の推定値 c/S の関数として並べると違いがはっきりする(図 9)。リッジ回帰は c/S に $S/(S + \lambda)$ を掛ける、つまり比で縮めるので、どれほど縮めても 0 にはならない。ラッソは $|c/S|$ から $\lambda/(2S)$ を引く、つまり差で縮め、引ききれない小さな推定値をちょうど 0 にする。この形の縮め方を軟しきい値(soft thresholding)と呼ぶ。係数がちょうど 0 の列は予測に使われないので、ラッソは推定と同時に列を選ぶ。図 2 で見た原点の尖りが、0 に止まる理由である。二乗の罰は原点で平らなので、0 の手前で縮めても罰はほとんど減らず、ちょうど 0 にする理由がない。




図 9: 最小二乗の推定値に対する、リッジ回帰(青、比で縮める)とラッソ(赤、差で縮めて小さいものを 0 にする)の推定値(概念図)

列が p 本になると、ラッソの解を 1 本の式で書くことはできない。そこで、ほかの係数を固定して 1 つの係数 β_j だけを動かすことをくり返す。ほかの係数を固定すれば、残差 $\mathbf{r}_j = \mathbf{y} - \sum_{k \neq j} \mathbf{x}_k \beta_k$ に対する 1 変数の問題になり、(12) 式で $c = \mathbf{x}_j^\top \mathbf{r}_j$ 、 $S = \|\mathbf{x}_j\|_2^2$ としたものが答えである。これを $j = 1, \dots, p$ について、係数が動かなくなるまでくり返す。この方法を座標降下法(coordinate descent)と呼ぶ。目的関数は下に凸なので、この反復は最小の点に着く。両方の罰を混ぜたエラスティックネット(elastic net)もあるが、本講義では扱わない。

係数の道筋

罰の強さを 0 から大きくしていくと、係数はどう動くか。罰の強さごとに係数を求めて線をつないだものを、係数の道筋(coefficient path)と呼ぶ。横軸には、係数の絶対値の和を最小二乗法での値で割った比をとると、リッジ回帰とラッソを同じ軸で比べられる。右端の 1 が最小二乗法($\lambda = 0$)で、左へ行くほど罰が強く、0 ですべての係数が 0 になる。

図 10 は、図 7 と同じ麺とスープの 60 杯で、1 回ぶんの $\mathbf{y}$ について道筋を描いたものである。リッジ回帰 (a) では、最小二乗法で 2.01 と 0.14 だった 2 つの係数が、罰を強めると近づきながら 0 へ縮む。似た列に効き目を等しく分ける性質である。ラッソ (b) では、スープの係数が先にちょうど 0 になり、横軸の比がおよそ 0.87 より左では麺の係数 1 本だけが残る。麺の列が効き目をほぼ説明してしまうと、スープの列の c が小さくなってしきい値を下回るからである。リッジ回帰が似た列に効き目を等しく分けるのに対し、ラッソは 1 本を残してほかを 0 にしやすい。




図 10: 麺の量とスープの量(相関 0.92)の 2 列での係数の道筋(人工データ)。(a) リッジ回帰、(b) ラッソ。横軸は係数の絶対値の和を最小二乗法での値で割った比で、右端が最小二乗法

罰の前に目盛りをそろえる

罰は係数の大きさを、列をまたいで足し合わせる。ところが係数の大きさは、列の目盛りの取り方で変わる。ラーメンの麺の量を g で測っていた列を kg で測り直すと、値は 1000 分の 1 になり、同じ予測 $\beta_j x_j$ を保つには係数は 1000 倍にならなければならない。最小二乗法ならそれで済む。第 1 回で見たとおり、列を c 倍しても最小二乗法の予測は変わらず、その列の係数が $1/c$ 倍になるだけである。だが罰は、二乗なら 10^6 倍、絶対値なら 1000 倍になる。予測にとっては同じモデルなのに、罰の額だけが目盛りの取り方で動くのである。裏返せば、値の大きな目盛りで測った列ほど係数は小さく、罰をほとんど払わずに済む。そうした列は縮められもせず、ラッソに外されもしない。

そこで、罰を足す前に、第 2 回の標準化 $\mathbf{Z} = (\mathbf{X} - 1\bar{\mathbf{x}}^\top)\mathbf{D}^{-1}$ で全列の標準偏差を 1 にそろえる。そうすれば、1 つの λ がすべての列に同じ意味を持つ。標準化は列を中心化もするので、切片を切り離す準備も同時に済む。標準化の平均と標準偏差もデータから推定したものであり、第 2 回で述べたとおりモデルの一部として訓練の行だけで求める。後で交差検証(クロスバリデーション、CV)を行うときは、分けるたびに訓練の側の行で求め直す。

罰の効き具合：有効自由度

罰の強さ λ は、それ自体では意味を読みにくい。 $\lambda = 10$ が強いかわ弱いかは、 $\mathbf{X}^\top \mathbf{X}$ の大きさしだいだからである。そこで、罰の効き具合を係数の数に換算する。まず予測値を書くと、(6) 式から

$$\hat{\mathbf{y}}_\lambda = \mathbf{X}\hat{\boldsymbol{\beta}}_\lambda = \mathbf{H}_\lambda \mathbf{y}, \quad \mathbf{H}_\lambda = \mathbf{X}(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \quad (13)$$

である。 $\lambda = 0$ なら $\mathbf{H}_0$ は第 3 回の射影行列 $\mathbf{H}$ であり、 $\mathbf{H}_\lambda$ も $\mathbf{X}$ と λ だけで決まって $\mathbf{y}$ を含まない。

最初に $\lambda = 0$ の場合を調べ、第 3 回で使った 2 つの性質を示す。(2) 式で掛ける順を回すと

$$\text{tr } \mathbf{H} = \text{tr}(\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top) = \text{tr}((\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}) = \text{tr } \mathbf{I}_p = p \quad (14)$$

である。左は $n \times n$ 、右は $p \times p$ の行列のトレースである。 $\mathbf{H}$ の対角はてこ比 h_{ii} なので、全員のてこ比の和は列の数 p に等しく、平均は p/n になる。

もう 1 つは、残差平方和の期待値である。 $(\mathbf{I} - \mathbf{H})\mathbf{X} = \mathbf{X} - \mathbf{X} = \mathbf{O}$ なので、残差は $\mathbf{e} = (\mathbf{I} - \mathbf{H})\mathbf{y} = (\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}$ と誤差だけで書ける。 $\mathbf{I} - \mathbf{H}$ も対称かつ冪等なので $\text{RSS} = \mathbf{e}^\top \mathbf{e} = \boldsymbol{\varepsilon}^\top (\mathbf{I} - \mathbf{H}) \boldsymbol{\varepsilon}$ であり、これはスカラーなのでそれ自身のトレースに等しい。(2) 式で順を回して期待値をとると

$$\mathbb{E}[\text{RSS}] = \mathbb{E}[\text{tr}((\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^\top)] = \text{tr}((\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}_n) = \sigma^2(n - p) \quad (15)$$

を得る。2 つ目の等号では、トレースと期待値の順を入れ替え、 $\mathbb{E}[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^\top] = \sigma^2\mathbf{I}_n$ を用いた。3 つ目の等号には (14) 式を用いた。したがって $\text{RSS}/(n - p)$ の期待値はちょうど σ^2 であり、第 3 回で $\hat{\sigma}^2$ を $n - p$ で割ったのはこのためである。 n 個の残差のうち、 p 個の係数を合わせるのに p 個ぶんの自由度が使われ、残りの $n - p$ 個ぶんだけがノイズを映す。

同じ数え方を $\lambda > 0$ に広げる。

定義 6 (有効自由度). リッジ回帰の $\mathbf{H}_\lambda$ のトレース

$$\text{tr } \mathbf{H}_\lambda = \text{tr}((\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{X}) \quad (16)$$

を有効自由度(effective degrees of freedom)と呼ぶ。2 つ目の形には (2) 式を用いた。

$\lambda = 0$ なら (16) 式は (14) 式の p であり、 $\lambda \rightarrow \infty$ なら 0 に近づく。 $p = 1$ なら $\sum_i x_i^2 / (\sum_i x_i^2 + \lambda)$ で、(8) 式の縮みの率 κ そのものである。列が互いに直交していれば、(16) 式は列ごとの $\kappa_j = \|\mathbf{x}_j\|_2^2 / (\|\mathbf{x}_j\|_2^2 + \lambda)$ の和になる。どの列もその縮みの率のぶんだけ「係数 1 個」を使っている、と読める。一般の $\mathbf{X}$ でも $\text{tr } \mathbf{H}_\lambda$ は λ とともに p から 0 へ単調に下がる(図 11)。麺とスープの 2 列では、雲の図で使った $\lambda = 5$ の有効自由度は 1.45 で、罰が係数およそ 0.6 個ぶんを抑えたことになる。有効自由度は、モデルの複雑さを連続的に動かすつまみであり、第 2 回で多項式の次数を動かしたのと同じ役を果たす。




図 11: 麺の量とスープの量の 2 列(人工データ)での、罰の強さ λ に対するリッジ回帰の有効自由度

λ を選ぶ：CV

罰の強さ λ は、(9) 式の底のように真の値を知っていれば決まるが、実際には知らない。では手元のデータからどう選ぶか。訓練誤差は使えない。 $\lambda = 0$ の最小二乗の解は訓練の残差平方和を最小にする解そのものなので、罰を足せば訓練誤差は必ず増える。訓練誤差で選べば、いつも $\lambda = 0$ が選ばれる。第 2 回で、訓練誤差で比べると複雑なモデルがいつも勝つと述べたのと同じ理屈である。

人工データで確かめておく(図 14)。列どうしの相関が 0.6 の 20 列を 40 行だけ作り、ノイズの標準偏差を 2 とした。 $\mathbf{X}$ は固定し、 λ ごとに、訓練誤差の期待値と、同じ分布から取った新しい 2000 点での誤差の期待値を求めた。新しい点での誤差の Bias^2 と Variance も、(10) 式と同じ計算で求めた。横軸には有効自由度 (16) 式をとった。訓練誤差は右(罰が弱い)へ行くほど下がる一方である。新しい点での誤差は U 字を描き、最小二乗法(右端、有効自由度 20)では 8.45 だが、有効自由度 9.1 で最小の 5.07 になる。右へ行くと Variance が増え、左へ行くと Bias^2 が増える。第 2 回で多項式の次数に対して見た U 字と同じ形が、有効自由度という連続のつまみに対して現れる。

新しい点での誤差を測るには、係数の決定に使わなかった行が要る。第 2 回では、行を訓練とテストに分け、テストの行で汎化誤差を見積もった。ところが、 λ の候補をテストの行で比べて選ぶと、新しい問題が起きる。候補を 10 個比べて最良を選べば、報告される誤差は 10 個の測定値の最小値になり、偶然良く出たぶんだけ良く見える。 λ を選ぶことも一種の学習であり、選ぶのに使った行は、もう観測されていない値の代役ではない。そこで行を 3 つに分ける(図 12)。訓練(training)の行で係数を決め、検証(validation)の行で λ を選び、すべて決め終えたあとでテスト(test)の行で一度だけ測る。検証の数字は候補を並べるための順位にすぎず、実力として報告してよいのはテストの数字だけである。テストで測ったら思ったより悪かったので λ を変える、という一手が入った時点で、テストは選択に使われたことになる。




図 12: 訓練・検証・テストの 3 分割

ただし、検証の行を 1 回だけ取り分けると、第 2 回の締めで見たように、どの行を取り分けたかしだいで数字がばらつく。そこで、テスト以外の行を V 組に分け、どの組も 1 度ずつ検証の側に回す(図 13)。この手続きを交差検証(クロスバリデーション、CV)(cross-validation)と呼ぶ。

定義 7 (V 分割交差検証). n 行を V 組に分け、第 v 組の行を $\mathbf{X}_v, \mathbf{y}_v$ 、それ以外の行を $\mathbf{X}_{(-v)}, \mathbf{y}_{(-v)}$ とする。各 v について、第 v 組を除いた行で係数 $\hat{\beta}_{\lambda}^{(-v)} = (\mathbf{X}_{(-v)}^{\top} \mathbf{X}_{(-v)} + \lambda \mathbf{I})^{-1} \mathbf{X}_{(-v)}^{\top} \mathbf{y}_{(-v)}$ を決め、第 v 組で誤差を測って

$$\text{CV}(\lambda) = \frac{1}{n} \sum_{v=1}^V \|\mathbf{y}_v - \mathbf{X}_v \hat{\beta}_{\lambda}^{(-v)}\|_2^2 \quad (17)$$

とする手続きを、 V 分割交差検証(K-fold cross-validation)と呼び、略して k-fold CV と書くことが多い(k は組の数で、本章の V にあたる)。 $V = 5$ なら 5 分割 CV (5-fold CV)である。 $V = n$ の場合を一つ抜き CV (leave-one-out cross-validation) (LOO)と呼ぶ。




図 13: 5 分割 CV の分け方(概念図)。各回(行)で橙の組を測り、青の組で係数を決める

どの行もちょうど1度だけ測る側に回り、そのときの係数はその行を見ていない。 λ の候補ごとに (17) 式を計算し、最も小さい λ を選ぶ。図 14 の緑の点は、1 回ぶんの $\mathbf{y}$ から 5 分割 CV で計算した (17) 式であり、有効自由度 10.6 を選ぶ。選ばれた λ での新しい点での誤差は 5.11 で、真の底 5.07 に近い。右端の最小二乗法の近くで CV の誤差が新しい点での誤差より大きく出るのは、各回で係数を決める行が 32 行に減り、20 列に対して行が足りなくなるからである。これは後で述べる、 V が小さいと悲観的になる性質の極端な例である。




図 14: 人工データ(40 行・20 列)でのリッジ回帰の誤差を有効自由度に対して描いたもの。訓練誤差(破線)、新しい点での誤差(赤)とその $\text{Bias}^2 \cdot \text{Variance} \cdot \sigma^2$ 、1 回ぶんのデータで計算した 5 分割 CV (緑の点。点線は選んだ有効自由度)

CV の各回で測る側に回した行の予測を集めると、 n 行の全員について、その行を見ていない係数による予測 $\hat{y}_i^{\text{CV}}$ が 1 つずつそろそろ。これを第 1 回の決定係数の式に入れた

$$R_{\text{CV}}^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i^{\text{CV}})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (18)$$

を、本章では CV の R^2 と呼ぶ。分子は $n \cdot \text{CV}(\lambda)$ に等しい。訓練の行で測った R^2 と違い、モデルを複雑にしても上がり続けるとは限らない。

V の選び方には釣り合いがある。 V が小さいと、各回で係数を決める行は $n(V-1)/V$ 行に減る。その係数は全員で決めた係数より当てはまりが悪いので、誤差を大きめに、すなわち悲観的に見積もる。 $V = n$ の LOO では係数を決める行は $n-1$ 行で、この偏りはほとんど無い。ただし当てはめを n 回くり返す必要がある。また、 n 回の係数はほとんど同じ行から決まるので互いによく似ており、その平均は、データそのものを取り直したときのばらつきを小さくしない。ふつうは $V = 5$ か 10 が使われる。なお $V < n$ では、どの行をどの組に入れるかという乱数の選び方によっても値がばらつく。ただし V 個の組の平均をとるぶん、ばらつきは第 2 回の 1 回の分割よりずっと小さい。これは第 II 部で確かめる。

LOO は 1 回の当てはめで求まる

一つ抜きの交差検証(クロスバリデーション、CV)、すなわち LOO は偏りの小さい見積もりだが、 n 回の当てはめが要るのが難点である。ところが、予測が $\hat{\mathbf{y}} = \mathbf{H}_\lambda \mathbf{y}$ のように $\mathbf{y}$ の線形変換で書け、 $\mathbf{H}_\lambda$ が $\mathbf{y}$ によらないリッジ回帰では、1 回の当てはめから LOO の残差がすべて求まる。

行 i を抜いて決めた係数による行 i の予測を $\hat{y}_i^{(-i)}$ とする。まず、 y_i だけを $\hat{y}_i^{(-i)}$ に置きかえたデータで全員の当てはめをすると、答えは行 i を抜いた当てはめと一致する。置きかえたデータの目的関数は、行 i を抜いた目的関数に $(\hat{y}_i^{(-i)} - \tilde{\mathbf{x}}_i^\top \boldsymbol{\beta})^2$ を足したものであり、行 i を抜いた解では、第 1 項が最小になると同時に第 2 項がちょうど 0 になるからである($\tilde{\mathbf{x}}_i$ は $\mathbf{X}$ の第 i 行)。当てはめは $\mathbf{H}_\lambda$ を掛けることなので、置きかえたデータでの行 i の予測は $\sum_{i' \neq i} h_{ii'} y_{i'} + h_{ii} \hat{y}_i^{(-i)}$ であり、これが $\hat{y}_i^{(-i)}$ に等しい。一方、元のデータでは $\hat{y}_i = \sum_{i'} h_{ii'} y_{i'}$ である。2 つを引くと $\hat{y}_i - \hat{y}_i^{(-i)} = h_{ii}(y_i - \hat{y}_i^{(-i)})$ となり、両辺から y_i を引いて整理すれば

$$y_i - \hat{y}_i^{(-i)} = \frac{y_i - \hat{y}_i}{1 - h_{ii}} \quad (19)$$

を得る。右辺は全員で 1 回当てはめたときの残差 e_i と、 $\mathbf{H}_\lambda$ の対角 h_{ii} だけで書けている。 $0 \leq h_{ii} < 1$ なので、抜いたときの残差は必ず元の残差より大きい。てこ比の大きい行ほど自分の予測を自分の y_i に引き寄せているので、抜いたときの外れも大きくなる。その二乗和 $\text{PRESS}(\lambda) = \sum_i (e_i / (1 - h_{ii}))^2$ を n で割ったものが、 $V = n$ の (17) 式である。 $\lambda = 0$ なら h_{ii} は第 3 回のでこ比であり、最小二乗法でも同じ式が成り立つ。切片を罰さずに別に推定するときは、 $\mathbf{H}_\lambda$ に切片のぶん $\mathbf{1}\mathbf{1}^\top/n$ を足したものの対角を使う。ただし、この式が再現するのは当てはめのやり直しまでであり、標準化の平均・標準偏差を抜いた行で求め直すところまでは再現しない。1 行を抜いても平均と標準偏差はほとんど変わらないので、LOO では実用上問題にならない。ラッソは $\hat{\mathbf{y}}$ が $\mathbf{y}$ の線形変換にならないので、この式は使えない。

λ を選ぶ計算の手順は次のとおりである。

1. λ の候補 $\lambda_1 < \dots < \lambda_L$ を並べる
2. V 分割の各回で、係数を決める側の行 $\mathbf{X}_{(-v)}$ の平均・標準偏差を求め、両方の行を標準化して $\mathbf{Z}_{(-v)}, \mathbf{Z}_v$ を作る。 $(\mathbf{Z}_{(-v)}^\top \mathbf{Z}_{(-v)} + \lambda \mathbf{I})\boldsymbol{\beta} = \mathbf{Z}_{(-v)}^\top (\mathbf{y}_{(-v)} - \bar{y}_{(-v)} \mathbf{1})$ を連立方程式として解き、 $\mathbf{Z}_v$ の行で誤差を測る。これを λ の候補ごとに行い、(17) 式を求める
3. リッジ回帰なら、かわりに全員で 1 回だけ $\mathbf{H}_\lambda$ と残差 $\mathbf{e}$ を作り、(19) 式から $\text{PRESS}(\lambda)$ を求めてもよい

4. 誤差が最小の λ を選び、その λ で全員の行を使って当てはめ直す

V 分割の手間は、候補 1 つあたり V 回の当てはめである。素朴な LOO は n 回だが、(19) 式を使えば 1 回で済む。

第 II 部 実データ解析

前立腺がんのデータ

第 II 部では、第 I 部の理論を前立腺がんのデータで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。予想どおりにいけば、それでよい。

第 I 部からは、次の 2 つを予想できる。1 つ目は係数の内訳である。罰を足すと、似た 2 列の係数は、リッジ回帰では近づき、ラッソでは片方がちょうど 0 になるはずである。2 つ目に、予測も良くなるはずである。第 I 部の人工データでは、新しい点での誤差が罰の強さに対して U 字を描き、底は最小二乗法より低かった。交差検証 (クロスバリデーション、CV) で底の罰を選べば、最小二乗法より予測が良くなると見込める。

データは Stamey らが 1989 年に報告したものである (Journal of Urology 141, 1076–1083)。前立腺の摘出手術を受けた 97 人の患者について、血液中の PSA (前立腺特異抗原) の値と、手術で取り出した組織の測定値が記録されている。説明変数は、がんの体積・前立腺の重さ・前立腺肥大の量・被膜への浸潤の量 (いずれも対数)、年齢、精嚢への浸潤の有無 (0/1)、グリーソンスコア (組織の悪性度の点数)、グリーソンの等級 4・5 が占める割合 (%) の 8 つで、目的変数は PSA の値の対数である。ラッソを提案した Tibshirani (1996) が例に使い、Hastie・Tibshirani・Friedman の教科書『統計的学習の基礎』でも罰則付き回帰の例として扱われている。その教科書のサイトで公開されているデータ (<https://hastie.su.domains/ElemStatLearn/datasets/prostate.data>) を保存して使った (利用条件の明記は無く、教育・研究の例として広く使われている)。データには教科書の訓練・テストの区別の列もあるが、本章では使わず、97 人全員で CV を行う。

第 I 部で述べたとおり、罰を足す前に 8 列をそれぞれ標準化し、目的変数は平均を引いて中心化して、切片を切り離した。したがって係数は、その変数が標準偏差 1 つぶん動いたときの PSA の対数の変化を表す。第 3 回の VIF を計算すると、最大でも被膜への浸潤の 3.1 で、グリーソンスコアは 2.5、4・5 の割合は 3.0 と大きくはない。それでも場面で見たとおり、97 人に対しては係数の標準偏差が係数そのものと同じくらいある。ばらつきは列の似かたのほか、行の数とノイズの大きさでも決まるからである。本章では、悪性度を測る似た 2 列、グリーソンスコアと 4・5 の割合 (相関 0.75) の係数が、罰によってどう変わるかを追う。

計算の手続き

計算の手続きは次のとおりである。8 列を標準化したデータ行列 $\mathbf{Z}$ と中心化した PSA の対数について、 λ の候補 151 個 (0 と、0.01 から 10^4 までも対数で等間隔に並べた値) ごとに、リッジ回帰の (6) 式を NumPy の線形方程式ソルバーで解いた。ラッソは scikit-learn の Lasso (座標降下法) で解いた。scikit-learn の Lasso は目的関数を n で割った形で書くので、その罰の強さ α は本章の λ の $1/(2n)$ にあたる。罰の強さは、5 分割の交差検証 (クロスバリデーション、CV) (17) 式が最小になる値を選んだ。CV の各回では、scikit-learn の

StandardScaler と Ridge・Lasso をつないで、係数を決める側の行だけで標準化の平均・標準偏差を求めた。リッジ回帰については LOO の閉形式 (19) 式も計算した。予測の良さは、3 つの推定法の CV の R^2 (18) 式で比べた。

結果の読み方

第 1 の予想は係数の内訳についてであり、結果は予想どおりだった。図 15 は、罰の強さを動かしたときの 8 個の係数の道筋である。横軸は第 I 部と同じく、係数の絶対値の和を最小二乗法のそれで割った比である。リッジ回帰 (a) では、最小二乗法で 0.036 と 0.126 と開いていたグリーンソスコアと 4・5 の割合の係数が、罰を強めると近づく。2 つはやがてほぼ同じ値にそろい、そこから 0 へ縮んでいく。第 I 部の図 4 と 図 10 で見た、似た列に効き目を等しく分ける性質である。ラッソ (b) では、係数が 1 本ずつちょうど 0 に落ちる。最小二乗法から罰を強めていくと、最初に 0 になるのは被膜への浸潤(scikit-learn の α で 0.023)、次がグリーンソスコア (0.038) で、4・5 の割合はその後も残る。悪性度の似た 2 列から 1 本を残し、もう 1 本を外したのである。




図 15: 前立腺がんのデータの係数の道筋(標準化した単位)。(a) リッジ回帰、(b) ラッソ。赤がグリーンソスコア、緑がグリーンソン 4・5 の割合、灰はほかの 6 変数。破線は 5 分割 CV で選んだ罰の強さ

第 2 の予想は予測の良さについてであり、こちらは外れた。罰の強さを 5 分割の交差検証(クロスバリデーション、CV)で選ぶと(図 16)、リッジ回帰では $\lambda = 3.78$ (有効自由度 7.41) が選ばれた。LOO の閉形式では $\lambda = 6.01$ であった。ラッソでは $\lambda = 6.7$ (scikit-learn の α で 0.034) が選ばれた。罰を強めすぎると誤差は大きく上がるが、右端の最小二乗法の近くでは曲線はほぼ平らである。底での CV の誤差は、最小二乗法の 0.549 に対してリッジ回帰 0.546、ラッソ 0.545 にとどまる。CV の R^2 (18) 式も、3 つの推定法で 0.584、0.586、0.588 とほとんど同じである。

予想が外れた理由は、第 I 部の (9) 式から読める。罰が減らすのは分散(Variance)であり、偏りの入るぶんと引きかえである。底での二乗誤差は $\sigma^2 / (\sum_i x_i^2 + \sigma^2 / \beta^2)$ 、最小二乗法では $\sigma^2 / \sum_i x_i^2$ であった。行が増えると $\sum_i x_i^2$ が大きくなり、2 つの差は縮む。表 1 で比べると、第 I 部の人工データでは 20 個の係数を 40 行で決めていて、1 個あたり 2 行しかなかった。最小二乗法のばらつきが大きいので、罰で新しい点での誤差が 40% 下がった。前立腺がんのデータでは、切片を含む 9 個の係数を 97 人で決めていて、1 個あたり約 11 人いる。VIF も小さいので、最小二乗法の予測はもともとあまりばらつかない。罰で削れる分散が少なく、CV の誤差は 0.5% しか下がらなかった。そのため、CV は予測を損なわない範囲で弱めの罰を選んだ。




図 16: 罰の強さに対する CV の誤差(二乗平均)。(a) リッジ回帰の 5 分割(青)と LOO の閉形式(橙の破線)、(b) ラッソの 5 分割。赤は選んだ強さ

表 1: 罰で予測が良くなるかどうか。第 I 部の人工データは新しい点での誤差の期待値、前立腺がんのデータは 5 分割 CV の誤差(どちらも最小二乗法 → 最小の罰)

	行	係数の数	係数 1 個あたり	罰で下がった誤差
第 I 部の人工データ	40	20	2 行	8.45 → 5.07 (40% 減)
前立腺がんのデータ	97	9	約 11 人	0.549 → 0.546 (0.5% 減)

では、場面で見た大きな係数のばらつきは何だったのか。ばらつきが大きいのは、効き目の小さい列と、似た 2 列の内訳である。第 I 部の冒頭の図 1 (b) で見たとおり、似た 2 列の係数の和はよく決まり、内訳がばらついていても予測はほとんど動かない。罰が弱いので、係数のばらつきの減り方も小さい(図 17)。場面と同じ 1000 通りのブートストラップで、選んだ λ のリッジ回帰を当てはめ直した。グリーソンスコアの係数の標準偏差は 0.109 から 0.092 に、4・5 の割合は 0.132 から 0.109 に下がる。第 I 部の図 7 と同じ向きだが、縮みは小さい。




図 17: ブートストラップ 1000 回でのグリーソンスコアとグリーソン 4・5 の割合の係数(標準化した単位)。(a) 最小二乗法、(b) CV で選んだ λ のリッジ回帰。★は全員で当てはめた値

それでも、内訳は変わる(表 2)。ラッソは被膜への浸潤の係数をちょうど 0 にし、グリーソンスコアの係数も 0.002 とほぼ 0 にした。がんの体積・精嚢への浸潤・前立腺の重さのように、取り直しでも ± 2 標準偏差が 0 をまたがなかった列の係数は、どの推定法でも大きくは変わらない。罰が強く効くのは、データがよく決められない係数である。

変数	最小二乗法	リッジ($\lambda = 3.8$)	ラッソ($\lambda = 6.7$)
前立腺の重さ	0.266	0.263	0.235
年齢	-0.158	-0.138	-0.065
被膜への浸潤	-0.148	-0.092	0
前立腺肥大	0.140	0.131	0.091
グリーソン 4・5 の割合	0.126	0.107	0.065
グリーソンスコア	0.036	0.042	0.002
CV の R^2	0.584	0.586	0.588

分け方によるばらつき

第 I 部の最後には、CV の値も分け方の乱数でばらつくが、 V 個の組の平均をとるぶん、1 回の分割よりずっと小さいと述べた。これを第 2 の予想として確かめる(図 18)。8 変数の最小二乗法を、97 人から 30 人をテストに取り分けて測る。分割の乱数だけを 0 から 19 まで変えると、テストの R^2 は 0.11 から 0.71 まで動き、標準偏差は 0.159 である。同じ 20 通りの乱数で 5 分割 CV の組を作り、CV の R^2 を求めた。値は 0.513 から 0.610 に収まり、標準偏差は 0.027 で、1 回の分割の約 6 分の 1 になる。予想どおりである。1 回の分割では 30 人しか測る側に回らないが、CV では 97 人の全員が 1 度ずつ測る側に回る。

ただし、ばらつきが消えたわけではない。リッジ回帰の λ を同じ 20 通りの分け方で選び直すと、選ばれる λ は 0.45 から 18.3 まで動く。前節で見たとおり、このデータでは誤差の底が平らである。底の高さはほとんど変わらなくても、底の位置は分け方で動きやすい。




図 18: 分割の乱数を 20 通り変えたときの R^2 。1 回の分割(訓練 67 人・テスト 30 人、橙)と、5 分割 CV (青)

V の選び方も数字で確かめられる。最小二乗法($\lambda = 0$)について、誤差の二乗平均を 20 通りの乱数で平均した。 $V = 2$ で 0.625、 $V = 5$ で 0.560、 $V = 10$ で 0.547、LOO で 0.541 であった。第 I 部で述べたとおり、 V が小さいほど係数を決める行が少なく、誤差を大きめに見積もる。

最後に、第 I 部で導いた 2 つの式が、この計算でも成り立つことを確認しておく。LOO の閉形式 (19) 式から求めた PRESS は、1 行ずつ抜いて 97 回当てはめ直した結果と、4 つの λ のすべてで一致した(表 3)。相対的な差は最大 $4e-16$ で、計算機の丸めの誤差の大きさである。当てはめ直しでは、抜いた後の 96 行の中で平均を求め直して中心化した。切片のぶんの $1/n$ を足した $\mathbf{H}_\lambda$ の対角を使えば、この中心化も含めて再現される。有効自

由度は、 $\lambda = 0$ で切片の列を含めた $\text{tr } \mathbf{H}$ が 9.00 となり、(14) 式のとおり列の数 $p = 9$ に一致する(表 4)。罰を強めると 8 列の分の $\text{tr } \mathbf{H}_\lambda$ は 6.67 ($\lambda = 10$)、3.21 ($\lambda = 100$)と下がり、 $\lambda = 10^4$ では 0.08 になる。

表 3: LOO の閉形式 (19) 式と、97 回の当てはめ直しによる誤差の二乗平均

λ	閉形式 PRESS/N (1 回の当てはめ)	97 回の当てはめ直し
0.0	0.5413	0.5413
3.8	0.5368	0.5368
30.0	0.5569	0.5569
300.0	0.8067	0.8067

表 4: 前立腺がんのデータでのリッジ回帰の有効自由度。切片の列を含めた値と、8 列の分 (16) 式

λ	$\text{tr } \mathbf{H}$ (切片を含む)	$\text{tr } \mathbf{H}_\lambda$ (8 列の分)
0.0	9.00	8.00
3.8	8.41	7.41
10.0	7.67	6.67
100.0	4.21	3.21
1000.0	1.65	0.65
10000.0	1.08	0.08

実データで起きる落とし穴

第 I 部の式から見て、実データで起きやすい失敗を 2 つ挙げる。

第 1 に、標準化を忘れる。元の単位のままの列にラッソを当て、罰の強さを 4 列だけが残るように調整すると、残るのはがんの体積、年齢、前立腺肥大、グリーソン 4・5 の割合である。標準化してから同じことをしたときのがんの体積、前立腺の重さ、精嚢への浸潤、グリーソン 4・5 の割合とは、列が入れ替わる(表 5)。標準化したラッソでは 4 列に絞っても残る前立腺の重さ、精嚢への浸潤が、元の単位では落ちてしまう。標準偏差は前立腺の重さが 0.43、精嚢への浸潤が 0.41 と小さく(精嚢への浸潤は 0 か 1 の列である)、同じ効き目を表すのに大きな係数が要るので、罰を多く払うからである。反対に、標準偏差 28 (%) の 4・5 の割合や 7.4 (歳) の年齢は、係数が小さく罰を免れて残る。第 I 部で見たとおり、罰は目盛りの取り方で動く。どの列が残るかは、効き目ではなく単位で決まってしまった。

表 5: ラッソで 4 列だけを残したときに残る列。標準化してから当てた場合と、元の単位のまま当てた場合

	残った 4 列
標準化してから	がんの体積、前立腺の重さ、精嚢への浸潤、グリーソン 4・5 の割合
元の単位のまま	がんの体積、年齢、前立腺肥大、グリーソン 4・5 の割合

第 2 に、ラッソが残した列を、それだけが効く列だと読んでしまう。全員で当てはめたラッソは被膜への浸潤を 0 にし、グリーソンスコアをほぼ 0、4・5 の割合を残した。だが、場面と同じ 1000 通りのブートストラップで、交差検証(クロスバリデーション、CV)で選んだ強さのラッソを当てはめ直すと(図 19)、グリーソンスコアだけが残る回が 21%、4・5 の割合だけが残る回が 40%、両方が残る回が 31%、両方とも 0 になる回が 8% ある。がんの体積・前立腺の重さ・精嚢への浸潤が毎回残るのに対し、似た 2 列のどちらを残すかは取り直しでばらつく。データが内訳を決められない列の組では、ラッソはどちらか 1 本を選ぶが、どちらを選ぶかはデータの偶然で決まるのである。「グリーソンスコアは PSA に関係ない」と読むのは誤りで、言えるのは「4・5 の割合が入っていれば、グリーソンスコアを加えても予測はほとんど変わらない」までである。




図 19: ブートストラップ 1000 回で、CV で選んだ強さのラッソが係数を 0 にしなかった割合。赤がグリーソンスコア、緑がグリーソン 4・5 の割合

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは、罰を足すと似た 2 列の係数の内訳が変わり、U 字の底の罰を選べば予測が良くなると予想した。内訳は予想どおりに変わった。リッジ回帰はグリーソンスコアと 4・5 の割合の係数を近づけ、ラッソはグリーソンスコアをほぼ 0 にした。一方、予測は良くならず、予想は外れた。係数 1 個を約 11 人で決めていて、最小二乗法の分散がもともと小さく、罰で削れる分散が少なかったからである。罰が予測を大きく良くするのは、第 I 部の人工データのように、行に対して係数が多いデータである。CV で測った数字のばらつきは、予想どおり 1 回の分割の約 6 分の 1 になった。それでも、選ばれる λ やラッソが残す列は、分け方や取り直しでおぼらつく。標準化を忘れれば、残る列は単位で決まってしまう。

締め

まとめと次回問い

本章の問いは、データの当てはまりだけでは係数の候補が1つに決まらない、あるいは大きくばらつくとき、どの1つを選ぶか、であった。答えは、目的関数に係数の大きさへの罰を足すことである。二乗の罰を足したリッジ回帰では、正規方程式の $\mathbf{X}^T \mathbf{X}$ が $\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}$ に変わる。この行列は正定値なので、列が重なっていても列が行より多くても逆行列を持つ。代わりに係数には偏りが入り、分散は減る。係数の二乗誤差は Bias^2 と Variance の和であり、罰の強さに対して U 字を描く。その底は真の係数とノイズで決まるので、手元のデータから交差検証(クロスバリデーション、CV)で探す。リッジ回帰では、LOO の誤差が1回の当てはめから $e_i/(1 - h_{ii})$ で求まる。絶対値の罰を足したラッソは、小さな係数をちょうど0にする。罰は係数の大きさを列をまたいで比べるので、列を標準化してから足す。罰の効き具合は、有効自由度 $\text{tr} \mathbf{H}_\lambda$ として係数の数に換算できる。 $\lambda = 0$ の $\text{tr} \mathbf{H} = p$ からは、第3回の $n - p$ の理由も出る。前立腺がんのデータでは、罰は予測をほとんど良くしなかった。変わったのは、悪性度を測る似た2列、グリーソンスコアと4・5の割合の係数の内訳である。リッジ回帰は2つを近づけ、ラッソはグリーソンスコアをほぼ0にし、係数のばらつきを小さくした。テストの R^2 は、1回の分割では0.11から0.71までばらついたが、5分割CVにするとばらつきが約6分の1になった。ただし、ラッソがどちらの列を残すかや、選ばれる λ そのものは、取り直しや分け方でなおばらつく。

同じ学期の演習では、住宅のデータで同じ現象に出会う。演習7で標準化してから Ridge を当てると、車庫の台数と面積の係数は、 $\alpha = 1$ では1,477と2,031ドルだが、 $\alpha = 1000$ では3,601と3,994ドルと近づく。演習6で相関0.88と見た似た2列に、効き目を等しく分ける方向へ動くのである。また、居住面積が1階・2階・仕上げの低い部分の和にぴったり一致する35本の列に Lasso を当てると、2階の面積の係数が0になる。Lasso は、足すとはかの列になる組から1本を外したのである。前立腺がんのデータで、悪性度の似た2列の片方が0に近づいたのと同じ性質である。

最後に、次回への問いを置く。ここまで目的変数は、PSA の値や価格のような連続の量だった。では、病気か否かのように、目的変数が0か1しか取らないとき、同じ最小二乗法を当ててよいのだろうか。次回は、0/1の目的変数を最小二乗法で回帰すると、係数の向きが何を表すのかを導く。