第 4 回 罰則付き最小二乗法

係数の大きさに罰則を足し、罰則の強さを交差検証で選ぶ

本章の問いは、第 3 回の締めで残った「係数が非常に不安定になる、あるいは 1 つに決まらないとき、どうするか」である。目的関数に係数の大きさへの罰則を足すと、$\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I}$ は必ず逆行列を持ち、係数の分散が減るかわりに偏りが入る。罰則の強さ λ は交差検証（クロスバリデーション、CV）で選ぶ。

第 I 部　理論

データだけでは係数を選べない

第 3 回では、最小二乗法の係数の不安定性が $\mathbb{V}\mathrm{ar}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}$ で表されることを導いた。不安定性は、ノイズが大きいほど、行が少ないほど、列どうしが似ているほど大きい。列が完全に重なるか行より多いと、逆行列そのものが無くなって係数は 1 つに決まらない。第 3 回の締めには、そのように係数が非常に不安定になるときどうするか、という問いが残った。

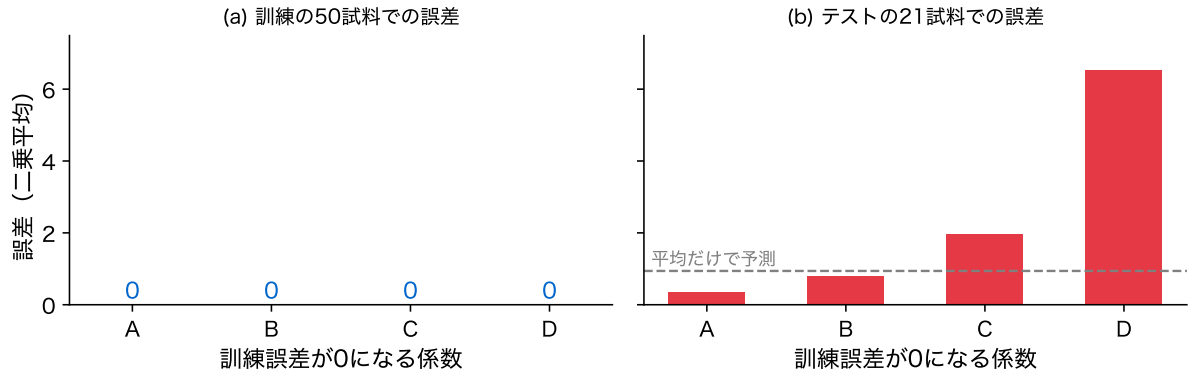


図 1: リボフラビンのデータで、訓練の 50 試料の残差平方和を 0 にする 4 組の係数（標準化した列）。(a) 訓練の試料での誤差はどれも 0、(b) テストの 21 試料での誤差は組ごとに違う。破線は平均だけで予測したときの誤差

本章では、この問いを遺伝子のデータで見直すところから始める。枯草菌にリボフラビン（ビタミン B2）をつくらせたときの生産量（対数）を、4088 個の遺伝子の発現量（対数）から予測するデータで、試料は 71 しかない（第 II 部で詳しく述べる）。列が行よりはるかに多いので、第 3 回で見たとおり $\mathbf{X}^\top\mathbf{X}$ に逆行列は無く、正規方程

式の解は 1 つに決まらない。実際に、71 の試料を訓練 50 とテスト 21 に分け、訓練の試料で残差平方和をちょうど 0 にする係数を 4 組作った(図 1)。4 組はどれも訓練の試料をぴたりと当てる。ところがテストの試料で測ると、誤差は 0.35 から 6.51 まで違い、平均だけで予測したときの 0.94 より悪いものもある。データの当てはまりだけでは、どの係数を選べばよいかが決まらない。

同じ困りごとは、ほかの場面でも起きる。効く列だけを知りたい場合である。人工的に 40 行・20 列のデータを作り、効くのは 3 列だけにした。最小二乗法で当てはめると、効かない 17 列の係数も 0 にならず、大きいものは 1.19 に達する。係数の大きさだけからは、どれが効く列かを読み分けにくい(図 2)。

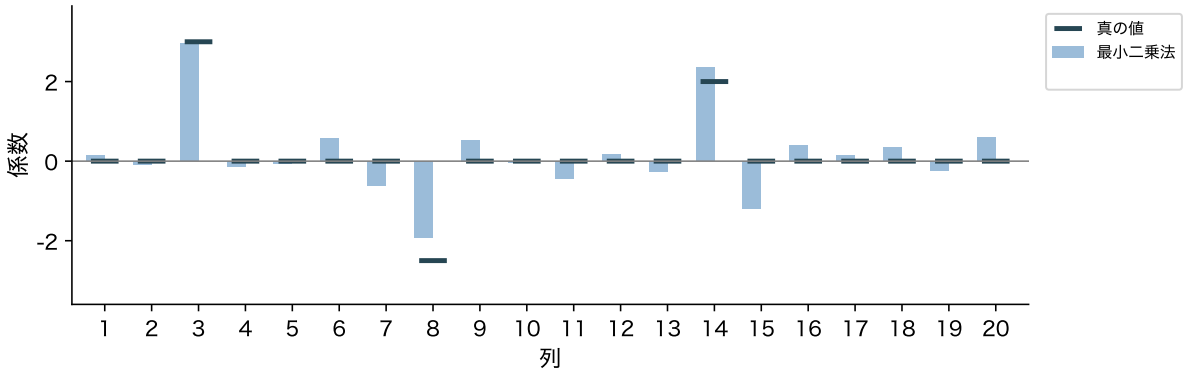


図 2: 40 行・20 列の人工データで、効くのは 3 列だけ(黒の横線が真の値)。最小二乗法(水色)の係数は、効かない 17 列でも 0 にならない

本章の問いは 1 つである。係数が非常に不安定になるとき、あるいはデータの当てはまりだけでは候補が 1 つに決まらないとき、どの 1 つを選ぶか。答えは、目的関数に係数の大きさへの罰則を足すことである。まず罰則を書くための道具をそろえ、二乗の罰則(Ridge 回帰)を足すと逆行列が必ず存在することを示す。次に、その代わりに係数に偏りが入り、分散が減ることを見る。続いて、絶対値の罰則(Lasso)が係数をちょうど 0 にすることを示し、罰則の強さを動かしたときの係数の動きを 1 枚の図にまとめる。さらに、罰則の前に列の目盛りをそろえる必要があることと、罰則の効き具合を有効自由度で数えられることを述べる。最後に、罰則の強さを交差検証(クロスバリデーション、CV)で選ぶ手順を導く。

「モデル × 推定法」の地図でいえば、モデルは線形回帰のまま動かず、推定法が最小二乗法から罰則付き最小二乗法に変わる。第 1 回で最小二乗法を「データとモデルの距離を最小にする推定法」と呼んだが、本章の推定法は、その距離に罰則を足したものを最小にする。推定法の列が増えるのは、全 15 回でこれが初めてである。

道具:ノルム・正定値・トレース

候補が 1 つに決まらないなら、当てはまりのほかに、候補を選ぶための基準を足せばよい。本章では、「ほかが同じなら、係数は小さいほうがよい」という基準を足す。その基準を式に書き、効き方を調べるには、3 つの道具を使う。本章の道具はここにまとめておく。

1 つ目は、係数ベクトルの大きさの測り方である。第 1 回ではベクトルの大きさ(ユークリッドノルム)を定義した。本章ではそれに加えて、絶対値の和で測る大きさを使う。

定義 1 (ℓ_2 ノルムと ℓ_1 ノルム)**.** ベクトル $\boldsymbol{\beta} = [\beta_1, \dots, \beta_p]^\top$ について、

$$\|\boldsymbol{\beta}\|_2^2 = \sum_{j=1}^{p} \beta_j^2, \qquad \|\boldsymbol{\beta}\|_1 = \sum_{j=1}^{p} |\beta_j| \tag{1}$$

の $\|\boldsymbol{\beta}\|_2$ を ℓ_2 ノルム(第 1 回のユークリッドノルム)、$\|\boldsymbol{\beta}\|_1$ を ℓ_1 ノルム(L1 norm)と呼ぶ。

1 つの係数についての形を比べると(図 3)、β^2 は原点の近くで平らに寝ており、係数を 0.1 から 0 へ動かしても値はほとんど減らない。$|\beta|$ は原点で尖っていて、0 の近くでも傾きが保たれる。この尖りが、後で Lasso が係数をちょうど 0 にする理由になる。

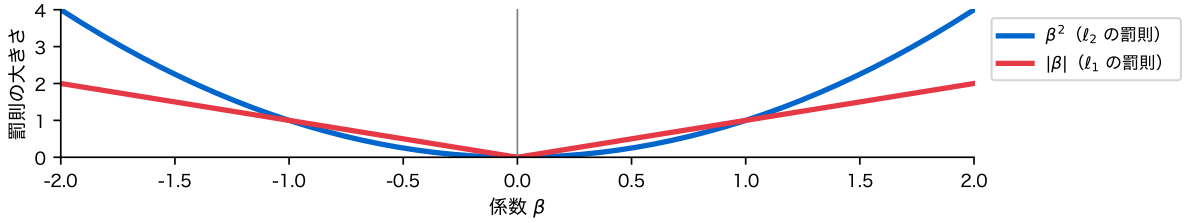


図 3: 1 つの係数についての ℓ_2 の罰則 β^2(青)と ℓ_1 の罰則 $|\beta|$(赤)の形(概念図)

2 つ目は、逆行列があるかどうかを確かめる道具である。第 1 回の逆行列の定義では、固有値がすべて正の行列は正則であると述べた。本章では固有値を使わず、同じことを次の形で使う。

定義 2 (正定値)**.** $p \times p$ の対称行列 $\mathbf{A}$ が、0 でないすべてのベクトル $\boldsymbol{v}$ について $\boldsymbol{v}^\top \mathbf{A} \boldsymbol{v} > 0$ を満たすとき、$\mathbf{A}$ を正定値(positive definite)であるという。正定値な行列は正則である。

正則であることは、次のように確かめられる。もし $\mathbf{A}\boldsymbol{v} = 0$ となる $\boldsymbol{v} \neq 0$ があれば、$\boldsymbol{v}^\top \mathbf{A} \boldsymbol{v} = 0$ となって正定値に反する。したがって $\mathbf{A}\boldsymbol{v} = 0$ を満たすのは $\boldsymbol{v} = 0$ だけであり、$\mathbf{A}$ の列は 1 次独立で、逆行列が存在する。逆に、2 列が完全に重なる場合(第 3 回)には、$\boldsymbol{v} = [1, -1]^\top$ について $\mathbf{X}\boldsymbol{v} = 0$ であり、$\mathbf{X}^\top \mathbf{X} \boldsymbol{v} = 0$ となる。谷底の直線が伸びる向きが、この $\boldsymbol{v}$ である。

3 つ目は、行列の対角の和である。

定義 3 (トレース)**.** 正方行列 $\mathbf{A}$ の対角成分の和 $\operatorname{tr} \mathbf{A} = \sum_j a_{jj}$ をトレース(trace)と呼ぶ。$\mathbf{A}$ が $n \times p$、$\mathbf{B}$ が $p \times n$ のとき

$$\operatorname{tr}(\mathbf{AB}) = \operatorname{tr}(\mathbf{BA}) \tag{2}$$

が成り立つ(巡回性)。

(2) 式は、両辺とも $\sum_i \sum_j a_{ij} b_{ji}$ に等しいことから従う。左辺は $n \times n$ の行列の、右辺は $p \times p$ の行列のトレースであり、大きさの違う行列のトレースが等しくなる。この性質は、有効自由度を数えるときに使う。トレースは和と定数倍を通し、スカラーは 1×1 の行列としてそれ自身がトレースである。

罰則を足す：Ridge 回帰

まずスカラーで考える。第 1 回の切片の無い単回帰の目的関数 $\sum_i (y_i - \beta x_i)^2$ に、係数の二乗に比例する罰則を足して

$$f_\lambda(\beta) = \sum_{i=1}^{n} (y_i - \beta x_i)^2 + \lambda \beta^2 \tag{3}$$

とする。$\lambda \geq 0$ は罰則の強さを決める定数である。図 4 に、人工データでこれを描いた。真の傾きは 0.5、ノイズの標準偏差は 1.5 で、区間 $[-1, 1]$ から 20 個の x を取った。第 1 回の放物線（青）に、$\beta = 0$ で最小になる放物線 $\lambda\beta^2$（灰）を足すと、和（赤）の谷底は 0 の側へ寄る。(3) 式を β で微分して 0 とおくと

$$\frac{df_\lambda}{d\beta} = -2\sum_{i=1}^{n} x_i (y_i - \beta x_i) + 2\lambda\beta = 0 \quad \Longrightarrow \quad \hat{\beta}_\lambda = \frac{\sum_{i=1}^{n} x_i y_i}{\sum_{i=1}^{n} x_i^2 + \lambda} \tag{4}$$

を得る。最小二乗の解との違いは、分母に λ が足されたことだけである。$\lambda = 0$ なら第 1 回の (5) 式に戻り、λ を大きくするほど $\hat{\beta}_\lambda$ は 0 へ縮む。図 4 の例では、最小二乗の解は 0.76、$\lambda = 9$ の解は 0.31 である。

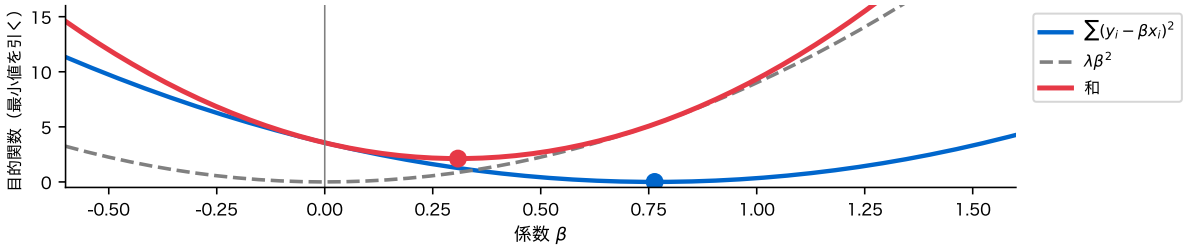


図 4: 1 変数の目的関数（人工データ）。最小二乗の目的関数（青）に罰則 $\lambda\beta^2$（灰の破線）を足すと、和（赤）の谷底は 0 の側へ寄る。点はそれぞれの谷底。縦軸は、どの曲線からも最小二乗の目的関数の最小値を引いた値

同じことをベクトルで書く。n 個の x_i と y_i を縦に並べたベクトルを $\boldsymbol{x}$、$\boldsymbol{y}$ とすれば、(3) 式は $f_\lambda(\beta) = \|\boldsymbol{y} - \beta\boldsymbol{x}\|_2^2 + \lambda\beta^2$ であり、その解は $\hat{\beta}_\lambda = \boldsymbol{x}^\top \boldsymbol{y} / (\boldsymbol{x}^\top \boldsymbol{x} + \lambda)$ である。内積を成分で書けば (4) 式に戻る。

さらに行列で書く。列が p 本のデータ行列 $\mathbf{X}$ について

$$f_\lambda(\boldsymbol{\beta}) = \|\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \lambda \|\boldsymbol{\beta}\|_2^2 \tag{5}$$

を最小にする。第 1 回の勾配の計算に、罰則の項 $\lambda\boldsymbol{\beta}^\top\boldsymbol{\beta}$ の勾配 $2\lambda\boldsymbol{\beta}$ を足して 0 ベクトルとおけば

$$-2\mathbf{X}^\top(\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}) + 2\lambda\boldsymbol{\beta} = 0 \quad \Longrightarrow \quad (\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I}_p)\,\hat{\boldsymbol{\beta}}_\lambda = \mathbf{X}^\top\boldsymbol{y} \tag{6}$$

となる。第 1 回の正規方程式の $\mathbf{X}^\top\mathbf{X}$ の対角に λ を足した形である。$p=1$ なら $\mathbf{X}^\top\mathbf{X}=\boldsymbol{x}^\top\boldsymbol{x}$ で、(6) 式はベクトルの解に、したがって (4) 式に戻る。切片は罰則を課さない。切片まで罰則を課すと、y の原点をずらしただけで答えが変わってしまうからである。第 3 回で見たとおり、各列を平均 0 に中心化すれば、切片の推定値は $\bar{y}$ に切り離せる。そこで以下では、$\mathbf{X}$ は中心化した(後で述べるように標準化した)列だけを持ち、$\boldsymbol{y}$ も中心化してあるものとする。

定義 4 (罰則付き最小二乗法と Ridge 回帰)**.** 最小二乗法の目的関数に、係数の大きさへの罰則(penalty)を足したものを最小にする推定法を、罰則付き最小二乗法(penalized least squares)と呼ぶ。罰則で係数を小さく抑えることを正則化(regularization)ともいう。罰則に ℓ_2 ノルムの二乗を用いた (5) 式を Ridge 回帰と呼び、その解は (6) 式で与えられる。

(6) 式の係数行列には、$\lambda>0$ である限り、必ず逆行列がある。0 でない $\boldsymbol{v}$ について

$$\boldsymbol{v}^\top(\mathbf{X}^\top\mathbf{X}+\lambda\mathbf{I})\,\boldsymbol{v}=\|\mathbf{X}\boldsymbol{v}\|_2^2+\lambda\|\boldsymbol{v}\|_2^2>0 \tag{7}$$

であり、第 1 項は 0 以上、第 2 項は正だからである。定義 2 により $\mathbf{X}^\top\mathbf{X}+\lambda\mathbf{I}$ は正則で、(6) 式の解はただ 1 つに決まる。この議論は $\mathbf{X}$ の中身によらない。列が完全に重なっていても、列が行より多くても成り立つ。第 3 回で逆行列が無かった場合には、$\mathbf{X}\boldsymbol{v}=0$ となる向き $\boldsymbol{v}$ があり、その向きには目的関数がまったく変わらなかった。罰則の第 2 項を足すと、その向きにも少しだけ傾きがつく。

3 列の小さな例で確かめておく。3 列目が 1 列目と 2 列目の和である 4 行のデータ行列では、

$$\mathbf{X}=\begin{bmatrix}-1&-1&-2\\1&-1&0\\-1&1&0\\1&1&2\end{bmatrix},\qquad \mathbf{X}^\top\mathbf{X}=\begin{bmatrix}4&0&4\\0&4&4\\4&4&8\end{bmatrix},\qquad \mathbf{X}\boldsymbol{v}=0\quad(\boldsymbol{v}=[1,1,-1]^\top)$$

となる。$\mathbf{X}^\top\mathbf{X}\boldsymbol{v}=0$ なので、$\mathbf{X}^\top\mathbf{X}$ に逆行列は無い。3 列目の 2 行目と 4 行目を ±0.1 だけずらした $\tilde{\mathbf{X}}$ では、逆行列は存在するが、$(\tilde{\mathbf{X}}^\top\tilde{\mathbf{X}})^{-1}$ の成分は 100 ほどになり、第 3 回の係数の分散 $\sigma^2(\tilde{\mathbf{X}}^\top\tilde{\mathbf{X}})^{-1}$ も同じく巨大になる。対角に $\lambda=1$ を足すと、$\boldsymbol{v}^\top(\mathbf{X}^\top\mathbf{X}+\mathbf{I})\boldsymbol{v}=\|\mathbf{X}\boldsymbol{v}\|_2^2+\|\boldsymbol{v}\|_2^2=0+3>0$ となり、重なる向きにも正の値が残る。逆行列は

$$(\mathbf{X}^\top\mathbf{X}+\mathbf{I})^{-1}=\begin{bmatrix}0.45&0.25&-0.31\\0.25&0.45&-0.31\\-0.31&-0.31&0.38\end{bmatrix},\qquad (\tilde{\mathbf{X}}^\top\tilde{\mathbf{X}}+\mathbf{I})^{-1}=\begin{bmatrix}0.45&0.24&-0.32\\0.24&0.43&-0.30\\-0.32&-0.30&0.39\end{bmatrix}$$

で、どちらも成分は 0.5 ほどに収まる。

列が完全に重なる場合を、人工的なデータで見ておく。まったく同じ値の列を 2 本並べ(相関 1)、y を予測するとする。データは 2 つの係数の和しか決められない。真の係数を $(1,1)$ とすると、罰則が無ければ目的関数の底は直線 $\beta_1+\beta_2=2$ の全体になる(図 5 (a))。罰則を足すと、その直線の上で $\|\boldsymbol{\beta}\|_2^2$ が最も小さい点、すなわち $\beta_1=\beta_2$ の 1 点が選ばれる(図は $\lambda/n=0.1$ で、底は $\beta_1=\beta_2=0.952$)。和が同じなら、2 つの列に効き目を等しく分けたほうが二乗の和は小さいからである。Ridge 回帰は、データが区別できない似た列に、効き目を等

しく分ける。冒頭の場面のように列が行より多い場合も、(7) 式の議論から、罰則を足せば解はただ 1 つに決まる。λ を 0 に近づけると、Ridge 回帰の解は、訓練の残差平方和を最小にする無数の解のうち、ユークリッドノルムが最も小さい 1 点に近づく。2 列の例でいえば、直線 $\beta_1 + \beta_2 = 2$ の上で原点に最も近い $(1, 1)$ である。冒頭の場面の A は、この点(ノルム最小の解)であった。

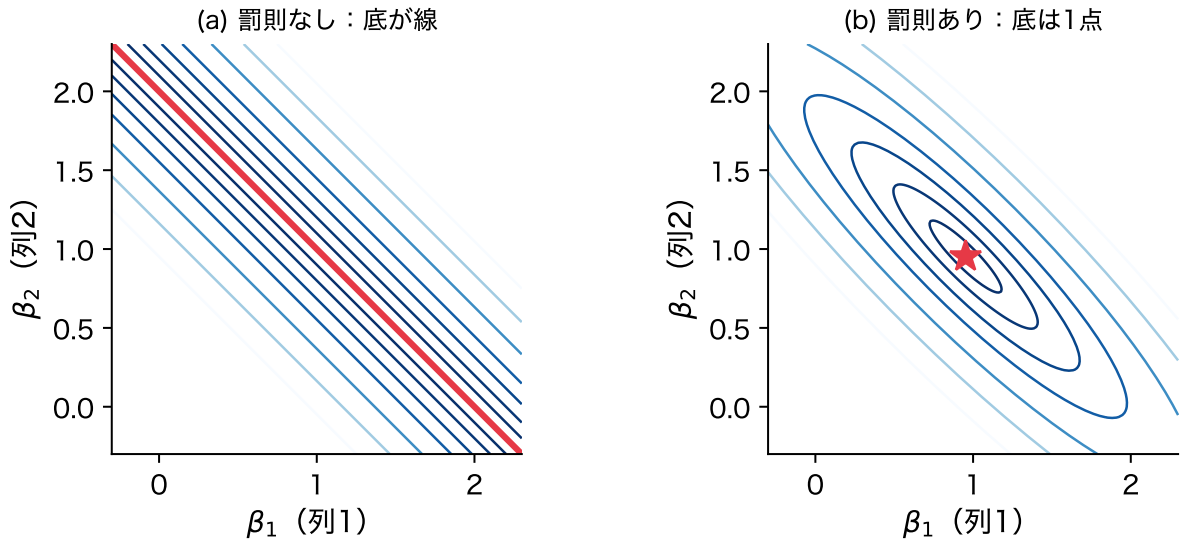


図 5: まったく同じ値の 2 列(相関 1)の目的関数の等高線(人工データ)。(a) 罰則なしでは底が直線(赤)、(b) 罰則を足すと底は 1 点(赤の★)に決まる

分散が減り、偏りが入る

罰則を足すと、係数は何を得て何を失うのか。第 3 回と同じく $\mathbf{X}$ を固定し、$\boldsymbol{y}$ だけがノイズのぶんばらつくとする。図 6 は、図 4 と同じ 20 個の x のまま y を 30 回取り直し、そのつど原点を通る直線を引いたものである。最小二乗法 (a) の直線は大きく扇状に開き、傾きが負になる回もある。Ridge 回帰 (b) では扇は閉じるが、直線はそろって真の直線より寝ている。

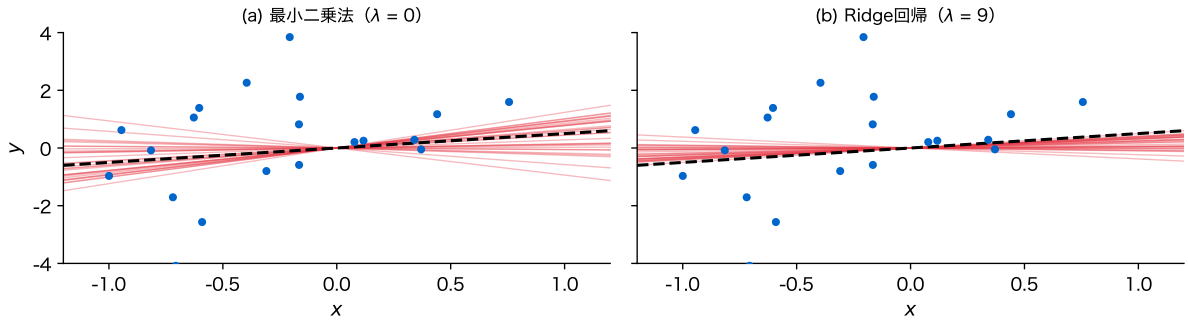


図 6: 同じ x のまま y を 30 回取り直して引いた原点を通る直線(赤、人工データ)。(a) 最小二乗法、(b) Ridge 回帰。黒の破線は真の直線、青は 1 回ぶんの点

これをスカラーの式で確かめる。(4) 式は y_i の重み付きの和である。$\mathbb{E}[y_i] = \beta x_i$ で、各 y_i は独立で分散 σ^2 なので、$\kappa = \sum_i x_i^2 / (\sum_i x_i^2 + \lambda)$ とおけば

$$\mathbb{E}[\hat{\beta}_\lambda] = \kappa\beta, \qquad \mathbb{V}\mathrm{ar}(\hat{\beta}_\lambda) = \frac{\sigma^2 \sum_i x_i^2}{(\sum_i x_i^2 + \lambda)^2} = \kappa^2 \frac{\sigma^2}{\sum_i x_i^2} \tag{8}$$

を得る。$\lambda = 0$ なら $\kappa = 1$ で、第 3 回の不偏性と係数の分散の式に戻る。$\lambda > 0$ では $0 < \kappa < 1$ であり、係数の平均は真の値の κ 倍に縮み、標準偏差も κ 倍に縮む。平均が真の値からずれるので、推定には $(1-\kappa)\beta$ の偏り（bias）が入る。図 6 の例では、最小二乗法の傾きの標準偏差は 0.61 で、真の傾き 0.5 と同じくらいである。Ridge 回帰では標準偏差は 0.25 に下がるが、傾きの平均は 0.20 に縮む。

偏りと分散のどちらを重く見るべきかは、係数の二乗誤差 $\mathbb{E}[(\hat{\beta}_\lambda - \beta)^2]$ で測れる。第 2 回のバイアス・バリアンス分解と同じく、平均のまわりに分けると交差項が消えて

$$\mathbb{E}[(\hat{\beta}_\lambda - \beta)^2] = \underbrace{(1-\kappa)^2\beta^2}_{\text{Bias}^2} + \underbrace{\kappa^2 \frac{\sigma^2}{\sum_i x_i^2}}_{\text{Variance}} \tag{9}$$

となる。λ を大きくすると Bias² は増え、Variance は減る（図 7）。和は U 字を描き、λ で微分して 0 とおくと、底は $\lambda = \sigma^2/\beta^2$ にある。そのときの二乗誤差は $\sigma^2/(\sum_i x_i^2 + \sigma^2/\beta^2)$ で、最小二乗法の $\sigma^2/\sum_i x_i^2$ より必ず小さい。つまり、罰則の強さが適切なら、偏りが入ってもなお係数は真の値に近づく。この例では、最小二乗法の二乗誤差 0.369 が、底では 0.149 まで下がる。ただし底の位置は、真の β と σ^2 で決まっている。どちらも未知なので、この式から λ を決めることはできない。λ はデータから選ぶしかなく、その方法を本章の後半で導く。

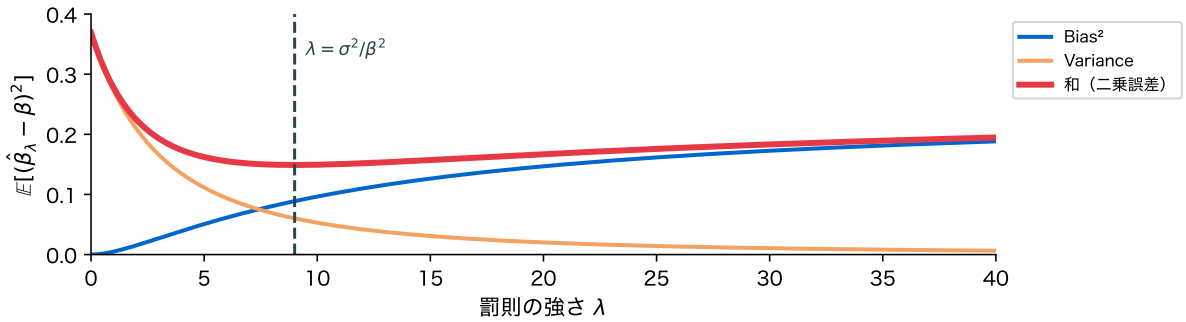


図 7: 1 変数の Ridge 回帰の係数の二乗誤差 (9) 式と、その Bias²（青）・Variance（橙）。破線は底の位置 $\lambda = \sigma^2/\beta^2$（人工データの設定で計算）

行列でも同じである。(6) 式の解は $\hat{\boldsymbol{\beta}}_\lambda = \mathbf{A}_\lambda \boldsymbol{y}$、$\mathbf{A}_\lambda = (\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}^\top$ と書け、第 3 回の線形変換の分散の式から

$$\mathbb{E}[\hat{\boldsymbol{\beta}}_\lambda] = (\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}^\top\mathbf{X}\,\boldsymbol{\beta}, \qquad \mathbb{V}\mathrm{ar}(\hat{\boldsymbol{\beta}}_\lambda) = \sigma^2(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}^\top\mathbf{X}(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})^{-1} \tag{10}$$

を得る。$\lambda = 0$ なら平均は $\boldsymbol{\beta}$、分散は $\sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}$ で、第 3 回の式そのものである。$p = 1$ なら (8) 式に戻る。図 8 に、人工的なデータでこれを見た。60 行で、標準化した 2 列の相関が 0.92 のデータ行列を作った。真の係数を (1.6, 0.4)、ノイズの標準偏差を 1 とおく。$\mathbf{X}$ は固定したまま $\boldsymbol{y}$ を 300 回取り直し、最小二乗法と Ridge 回帰($\lambda = 5$)の係数を並べた。最小二乗法の雲は左上から右下へ細長く伸び、$\hat{\beta}_1$ の標準偏差は 0.34 である。Ridge 回帰では、細長い向き(内訳 $\beta_1 - \beta_2$ の向き)が大きく縮み、標準偏差は 0.18 になる。その代わり、雲の中心は★からずれる。平均は 1.27 と 0.66 で、真の値の 1.6 と 0.4 より互いに近い。Ridge 回帰の係数は、データが区別しにくい 2 列に効き目を等しく分ける側へ偏る。データがよく決めている和の向きはほとんど縮まず、データが決められない内訳の向きが強く縮むのである。

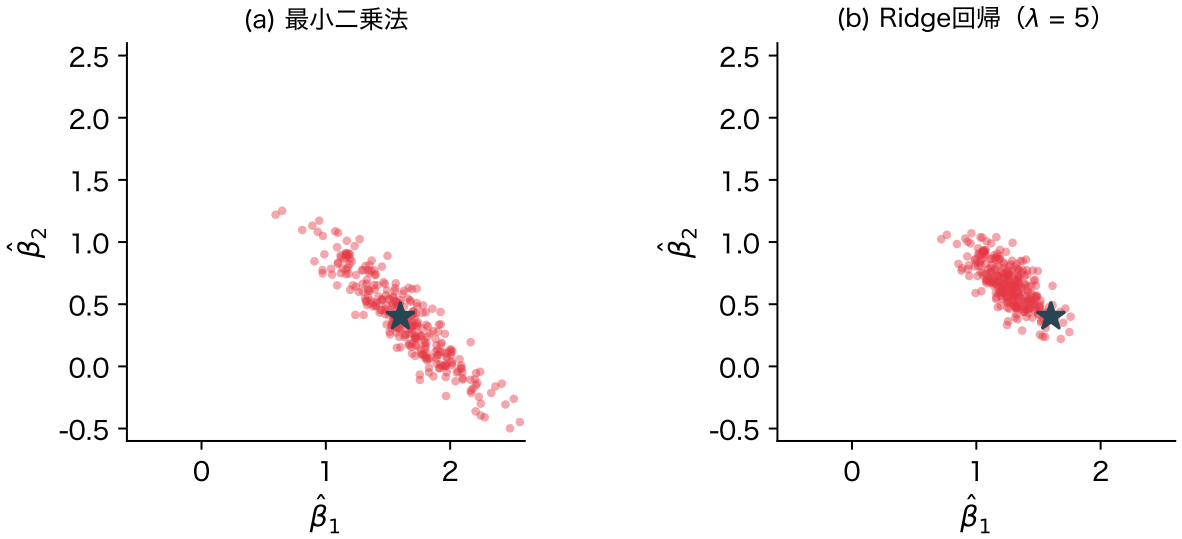


図 8: 相関 0.92 の 2 列で $\boldsymbol{y}$ を 300 回取り直したときの係数(人工データ)。(a) 最小二乗法、(b) Ridge 回帰。★は真の値

Lasso：係数をちょうど 0 にする

罰則の形を変えると、縮み方が変わる。ℓ_2 ノルムの二乗のかわりに ℓ_1 ノルムを罰則にしたものが Lasso である。

定義 5 (Lasso)**.** 罰則に ℓ_1 ノルムを用い、$\|\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \lambda\|\boldsymbol{\beta}\|_1$ を最小にする推定法を Lasso と呼ぶ。

まずスカラーで考える。目的関数は

$$g_\lambda(\beta) = \sum_{i=1}^{n}(y_i - \beta x_i)^2 + \lambda|\beta| \tag{11}$$

である。$|\beta|$ は $\beta = 0$ で尖っていて微分できないので、$\beta > 0$ の側と $\beta < 0$ の側で別々に考える。$c = \sum_i x_i y_i$、$S = \sum_i x_i^2$ とおく。$\beta > 0$ では $|\beta| = \beta$ なので、微分して 0 とおくと $-2c + 2S\beta + \lambda = 0$、すなわち $\beta = (c - \lambda/2)/S$ となる。これが正の側に入るのは $c > \lambda/2$ のときである。$\beta < 0$ の側も同様に

$\beta = (c + \lambda/2)/S$ で、$c < -\lambda/2$ のときに負の側に入る。どちらの側にも谷底が無いとき、すなわち $|c| \le \lambda/2$ のときは、g_λ は $\beta < 0$ で減り $\beta > 0$ で増えるので、尖りの $\beta = 0$ が最小になる。まとめると

$$\hat{\beta}^{\mathrm{L}}_{\lambda} = \frac{\mathrm{sign}(c)\ \max(|c| - \lambda/2,\ 0)}{S} \tag{12}$$

である（sign は符号）。図 9 に、図 4 と同じ人工データで (11) 式を描いた。(a) の λ では谷底は 0 の側へ寄るだけで、係数は 0.38（最小二乗は 0.76）である。(b) のように $\lambda/2$ が $|c|$ を超えると、谷底は尖りに引っかかり、係数はちょうど 0 になる。

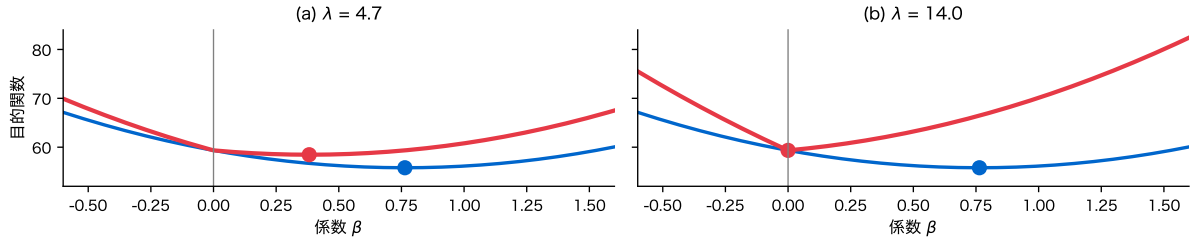


図 9: 1 変数の Lasso の目的関数（赤）と最小二乗の目的関数（青）（人工データ）。(a) 罰則が弱いと谷底は 0 の側へ寄るだけ、(b) 強いと谷底が $\beta = 0$ の尖りに止まる

(4) 式と (12) 式を、最小二乗の推定値 c/S の関数として並べると違いがはっきりする（図 10）。Ridge 回帰は c/S に $S/(S + \lambda)$ を掛ける、つまり比で縮めるので、どれほど縮めても 0 にはならない。Lasso は $|c/S|$ から $\lambda/(2S)$ を引く、つまり差で縮め、引ききれない小さな推定値をちょうど 0 にする。この形の縮め方を軟しきい値（soft thresholding）と呼ぶ。係数がちょうど 0 の列は予測に使われないので、Lasso は推定と同時に列を選ぶ。図 3 で見た原点の尖りが、0 に止まる理由である。二乗の罰則は原点で平らなので、0 の手前で縮めても罰則はほとんど減らず、ちょうど 0 にする理由がない。

列が p 本になると、Lasso の解を 1 本の式で書くことはできない。そこで、ほかの係数を固定して 1 つの係数 β_j だけを動かすことをくり返す。ほかの係数を固定すれば、残差 $\boldsymbol{r}_j = \boldsymbol{y} - \sum_{k \ne j} \boldsymbol{x}_k \beta_k$ に対する 1 変数の問題になり、(12) 式で $c = \boldsymbol{x}_j^{\top} \boldsymbol{r}_j$、$S = \|\boldsymbol{x}_j\|_2^2$ としたものが答えである。これを $j = 1, \ldots, p$ について、係数が動かなくなるまでくり返す。この方法を座標降下法（coordinate descent）と呼ぶ。目的関数は下に凸なので、この反復は最小の点に着く。

旅行の荷物を減らす場面にたとえると、2 つの罰則の違いがつかみやすい。Ridge 回帰は、どの荷物も同じ割合で軽くするので、どれも少しずつ残る。Lasso は、どの荷物からも同じ量を減らすので、もともと軽い荷物は減らしきれずに置いていく。冒頭の困りごとのデータに、$\lambda = 40$ の Lasso を当てると（図 11）、残る係数は 3 個で、効く 3 列だけが残る。ほかの 17 列の係数はちょうど 0 になる。効く 3 列の係数も真の値より 0 の側に縮むが、どれが効く列かは一目で読める。

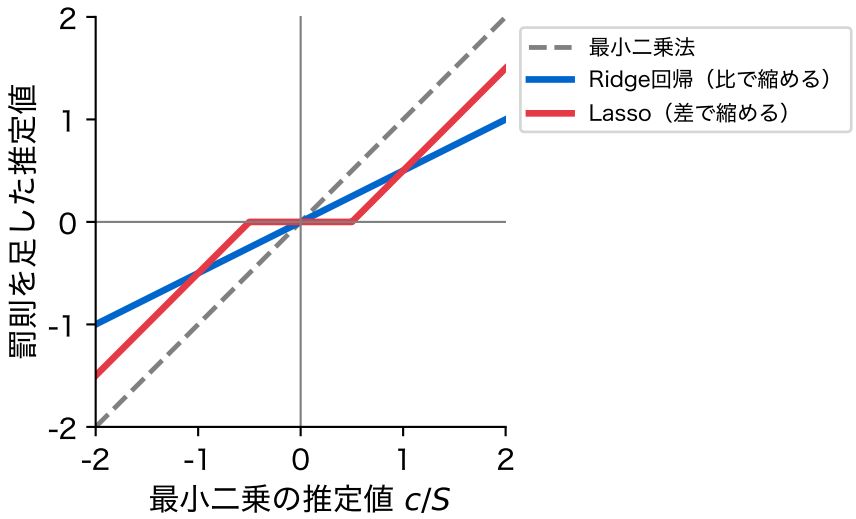


図 10: 最小二乗の推定値に対する、Ridge 回帰（青、比で縮める）と Lasso（赤、差で縮めて小さいものを 0 にする）の推定値（概念図）

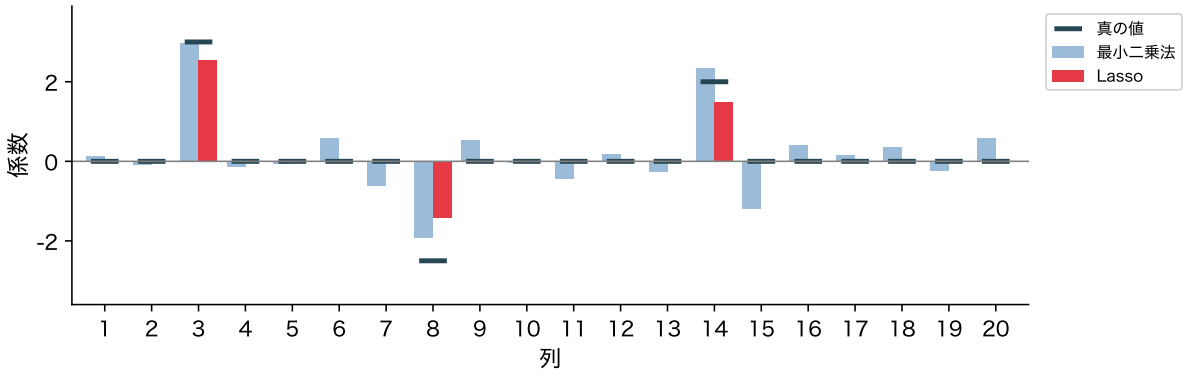


図 11: 40 行・20 列の人工データで、効くのは 3 列だけ（黒の横線が真の値）。最小二乗法（水色）の係数は効かない 17 列でも 0 にならないが、Lasso（赤）は効く 3 列だけを残す

係数の道筋

罰則の強さを 0 から大きくしていくと、係数はどう動くか。罰則の強さごとに係数を求めて線でつないだものを、係数の道筋（solution path）と呼ぶ。横軸には、係数の絶対値の和を最小二乗法での値で割った比をとると、Ridge 回帰と Lasso を同じ軸で比べられる。右端の 1 が最小二乗法（$\lambda = 0$）で、左へ行くほど罰則が強く、0 ですべての係数が 0 になる。

図 12 は、図 8 と同じ相関 0.92 の 2 列で、1 回ぶんの $\boldsymbol{y}$ について道筋を描いたものである。Ridge 回帰 (a) では、最小二乗法で 2.01 と 0.14 だった 2 つの係数が、罰則を強めると近づきながら 0 へ縮む。似た列に効き目を等しく分ける性質である。Lasso (b) では、列 2 の係数が先にちょうど 0 になり、横軸の比がおよそ 0.87 より

左では列 1 の係数だけが残る。列 1 が効き目をほぼ説明してしまうと、列 2 の c が小さくなってしきい値を下回るからである。Ridge 回帰が似た列に効き目を等しく分けるのに対し、Lasso は 1 本を残してほかを 0 にしやすい。

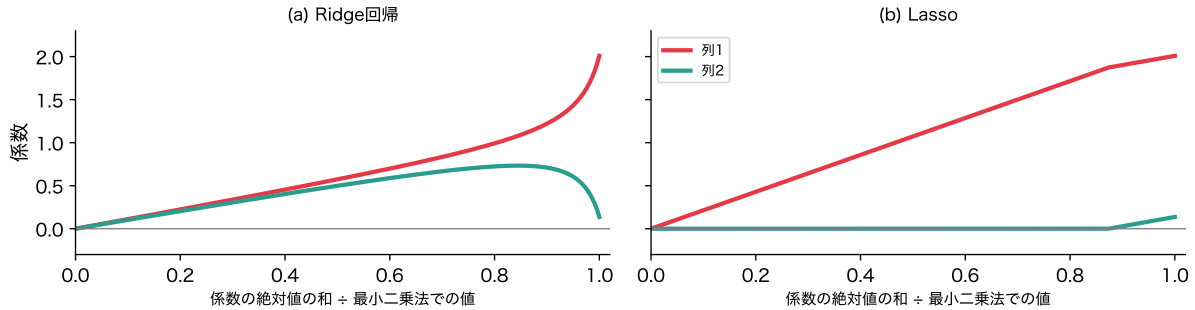


図 12: 相関 0.92 の 2 列での係数の道筋(人工データ)。(a) Ridge 回帰、(b) Lasso。横軸は係数の絶対値の和を最小二乗法での値で割った比で、右端が最小二乗法

罰則の前に目盛りをそろえる

罰則は係数の大きさを、列をまたいで足し合わせる。ところが係数の大きさは、列の目盛りの取り方で変わる。重さを g で測っていた列を kg で測り直すと、値は 1000 分の 1 になり、同じ予測 $\beta_j x_j$ を保つには係数は 1000 倍にならなければならない。最小二乗法ならそれで済む。第 1 回で見たとおり、列を c 倍しても最小二乗法の予測は変わらず、その列の係数が $1/c$ 倍になるだけである。だが罰則は、二乗なら 10^6 倍、絶対値なら 1000 倍になる。予測にとっては同じモデルなのに、罰則の大きさだけが目盛りの取り方で動くのである。裏返せば、値の大きな目盛りで測った列ほど係数は小さく、罰則をほとんど受けずに済む。そうした列は縮められもせず、Lasso に外されもしない。

そこで、罰則を足す前に、第 2 回の標準化 $\mathbf{Z} = (\mathbf{X} - \mathbf{1}\bar{\boldsymbol{x}}^\top)\mathbf{D}^{-1}$ で全列の標準偏差を 1 にそろえる。そうすれば、1 つの λ がすべての列に同じ意味を持つ。標準化は列を中心化もするので、切片を切り離す準備も同時に済む。標準化の平均と標準偏差もデータから推定したものであり、第 2 回で述べたとおりモデルの一部として訓練の行だけで求める。後で交差検証(クロスバリデーション、CV)を行うときは、分けるたびに訓練の側の行で求め直す。

罰則の効き具合:有効自由度

罰則の強さ λ は、それ自体では意味を読みにくい。$\lambda = 10$ が強いか弱いかは、$\mathbf{X}^\top\mathbf{X}$ の大きさしだいだからである。そこで、罰則の効き具合を係数の数に換算する。まず予測値を書くと、(6) 式から

$$\hat{\boldsymbol{y}}_\lambda = \mathbf{X}\hat{\boldsymbol{\beta}}_\lambda = \mathbf{H}_\lambda \boldsymbol{y}, \qquad \mathbf{H}_\lambda = \mathbf{X}(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}^\top \tag{13}$$

である。$\lambda = 0$ なら $\mathbf{H}_0$ は第 3 回の射影行列 $\mathbf{H}$ であり、$\mathbf{H}_\lambda$ も $\mathbf{X}$ と λ だけで決まって $\boldsymbol{y}$ を含まない。

最初に $\lambda = 0$ の場合を調べる。(2) 式で掛ける順を回すと

$$\operatorname{tr} \mathbf{H} = \operatorname{tr}(\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}\mathbf{X}^\top) = \operatorname{tr}((\mathbf{X}^\top \mathbf{X})^{-1}\mathbf{X}^\top \mathbf{X}) = \operatorname{tr} \mathbf{I}_p = p \tag{14}$$

である。左は $n \times n$、右は $p \times p$ の行列のトレースである。$\mathbf{H}$ の対角成分の和は、列の数 p に等しい。第 3 回で、残差が動ける向きを $n - p$ 本と数えたときの p である。p 個の係数を合わせるのに、p 個ぶんの自由度が使われる。

同じ数え方を $\lambda > 0$ に広げる。

定義 6 (有効自由度)**.** Ridge 回帰の $\mathbf{H}_\lambda$ のトレース

$$\operatorname{tr} \mathbf{H}_\lambda = \operatorname{tr}((\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1}\mathbf{X}^\top \mathbf{X}) \tag{15}$$

を有効自由度(effective degrees of freedom)と呼ぶ。2 つ目の形には (2) 式を用いた。

$\lambda = 0$ なら (15) 式は (14) 式の p であり、$\lambda \to \infty$ なら 0 に近づく。$p = 1$ なら $\sum_i x_i^2 / (\sum_i x_i^2 + \lambda)$ で、(8) 式の縮みの率 κ そのものである。列が互いに直交していれば、(15) 式は列ごとの $\kappa_j = \|\boldsymbol{x}_j\|_2^2 / (\|\boldsymbol{x}_j\|_2^2 + \lambda)$ の和になる。どの列もその縮みの率のぶんだけ「係数 1 個」を使っている、と読める。一般の $\mathbf{X}$ でも $\operatorname{tr} \mathbf{H}_\lambda$ は λ とともに p から 0 へ単調に下がる(図 13)。相関 0.92 の 2 列では、雲の図で使った $\lambda = 5$ の有効自由度は 1.45 で、罰則が係数およそ 0.6 個ぶんを抑えたことになる。有効自由度は、モデルの複雑さを連続的に動かすつまみであり、第 2 回で多項式の次数を動かしたのと同じ役を果たす。

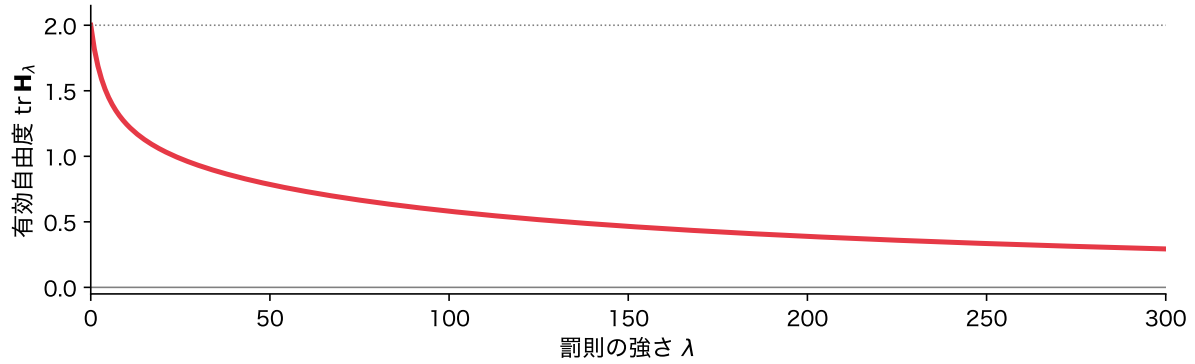


図 13: 相関 0.92 の 2 列(人工データ)での、罰則の強さ λ に対する Ridge 回帰の有効自由度

λ を選ぶ：CV

罰則の強さ λ は、(9) 式の底のように真の値を知っていれば決まるが、実際には知らない。では手元のデータからどう選ぶか。訓練誤差は使えない。$\lambda = 0$ の最小二乗の解は訓練の残差平方和を最小にする解そのものなので、罰則を足せば訓練誤差は必ず増える。訓練誤差で選べば、いつも $\lambda = 0$ が選ばれる。第 2 回で、訓練誤差で比べると複雑なモデルがいつも勝つと述べたのと同じ理屈である。

人工データで確かめておく(図 16)。列どうしの相関が 0.6 の 20 列を 40 行だけ作り、ノイズの標準偏差を 2 とした。$\mathbf{X}$ は固定し、λ ごとに、訓練誤差の期待値と、同じ分布から取った新しい 2000 点での誤差の期待値を求めた。新しい点での誤差の Bias^2 と Variance も、(10) 式と同じ計算で求めた。横軸には、係数の道筋と同じく、係数の絶対値の和を最小二乗法での値で割った比をとった。訓練誤差は右(罰則が弱い)へ行くほど下がる一方である。新しい点での誤差は U 字を描き、最小二乗法(右端)では 8.45 だが、比 0.52 で最小の 5.07 になる。右へ行くと Variance が増え、左へ行くと Bias^2 が増える。第 2 回で多項式の次数に対して見た U 字と同じ形が、罰則の強さという連続のつまみに対して現れる。

新しい点での誤差を測るには、係数の決定に使わなかった行が要る。第 2 回では、行を訓練とテストに分け、テストの行で汎化誤差を見積もった。ところが、λ の候補をテストの行で比べて選ぶと、新しい問題が起きる。候補を 10 個比べて最良を選べば、報告される誤差は 10 個の測定値の最小値になり、偶然良く出たぶんだけ良く見える。λ を選ぶことも一種の学習であり、選ぶのに使った行は、もう観測されていない値の代役ではない。本番の試験の問題で勉強法を選べば、本番の点は実力より良く見えるのと同じである。そこで行を 3 つに分ける。これを訓練・検証・テストの 3 分割(train-valid-test split)と呼ぶ(図 14)。訓練(training)の行で係数を決め、検証(validation)の行で λ を選び、すべて決め終えたあとでテスト(test)の行で一度だけ測る。問題集・模試・本番にたとえれば、訓練の行は問題集、検証の行は勉強法を選ぶ模試、テストの行は最後に 1 回だけ受ける本番にあたる。検証の数字は候補を並べるための順位にすぎず、実力として報告してよいのはテストの数字だけである。テストで測ったら思ったより悪かったので λ を変える、という一手が入った時点で、テストは選択に使われたことになる。



図 14: 訓練・検証・テストの 3 分割

ただし、検証の行を 1 回だけ取り分けると、第 2 回の締めで見たように、どの行を取り分けたかしだいで数字がばらつく。そこで、テスト以外の行を V 組に分け、どの組も 1 度ずつ検証の側に回す(図 15)。この手続きを交差検証(クロスバリデーション、CV)(cross-validation)と呼ぶ。

定義 7 (V 分割交差検証)**.** n 行を V 組に分け、第 v 組の行を $\mathbf{X}_v, \boldsymbol{y}_v$、それ以外の行を $\mathbf{X}_{(-v)}, \boldsymbol{y}_{(-v)}$ とする。各 v について、第 v 組を除いた行で係数 $\hat{\boldsymbol{\beta}}_\lambda^{(-v)} = (\mathbf{X}_{(-v)}^\top \mathbf{X}_{(-v)} + \lambda \mathbf{I})^{-1} \mathbf{X}_{(-v)}^\top \boldsymbol{y}_{(-v)}$ を決め、第 v 組で誤差を測って

$$\mathrm{CV}(\lambda) = \frac{1}{n} \sum_{v=1}^{V} \left\| \boldsymbol{y}_v - \mathbf{X}_v \hat{\boldsymbol{\beta}}_\lambda^{(-v)} \right\|_2^2 \tag{16}$$

とする手続きを、V 分割交差検証(K-fold cross-validation)と呼び、略して k-fold CV と書くことが多い(k は組の数で、本章の V にあたる)。$V = 5$ なら 5 分割 CV (5-fold CV)である。$V = n$ の場合を一つ抜き CV (leave-one-out cross-validation)(LOO)と呼ぶ。

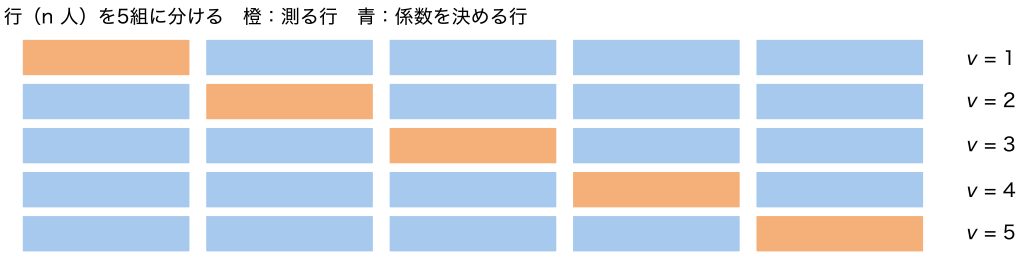


図 15: 5 分割 CV の分け方（概念図）。各回（行）で橙の組を測り、青の組で係数を決める

どの行もちょうど 1 度だけ測る側に回り、そのときの係数はその行を見ていない。λ の候補ごとに (16) 式を計算し、最も小さい λ を選ぶ。図 16 の緑の点は、1 回ぶんの $\boldsymbol{y}$ から 5 分割 CV で計算した (16) 式であり、比 0.59 を選ぶ。選ばれた λ での新しい点での誤差は 5.11 で、真の底 5.07 に近い。右端の最小二乗法の近くで CV の誤差が新しい点での誤差より大きく出るのは、各回で係数を決める行が 32 行に減り、20 列に対して行が足りなくなるからである。これは後で述べる、V が小さいと悲観的になる性質の極端な例である。

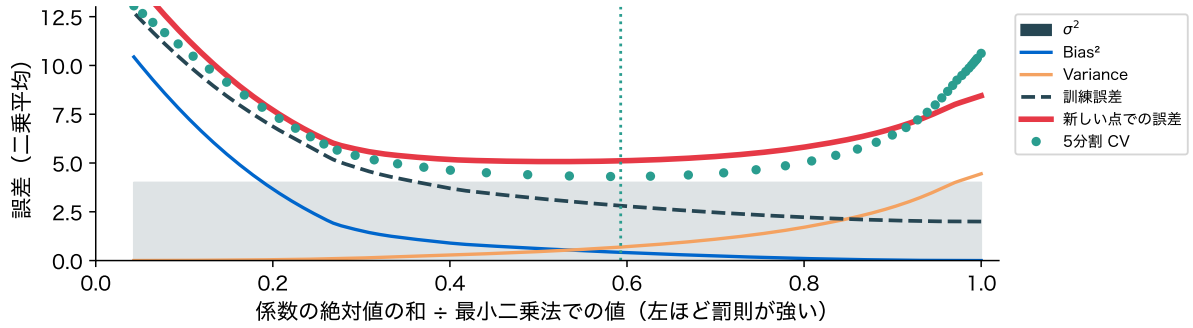


図 16: 人工データ（40 行・20 列）での Ridge 回帰の誤差を、係数の絶対値の和の比（右端が最小二乗法）に対して描いたもの。訓練誤差（破線）、新しい点での誤差（赤）とその Bias^2・Variance・σ^2、1 回ぶんのデータで計算した 5 分割 CV（緑の点。点線は選んだ所）

λ を選ぶ計算は、次の手順で行う。

1. λ の候補 $\lambda_1 < \cdots < \lambda_L$ を並べる
2. V 分割の各回で、係数を決める側の行 $\mathbf{X}_{(-v)}$ の平均・標準偏差を求め、両方の行を標準化して $\mathbf{Z}_{(-v)}, \mathbf{Z}_v$ を作る。$(\mathbf{Z}_{(-v)}^\top \mathbf{Z}_{(-v)} + \lambda \mathbf{I})\boldsymbol{\beta} = \mathbf{Z}_{(-v)}^\top (\boldsymbol{y}_{(-v)} - \bar{y}_{(-v)}\mathbf{1})$ を連立方程式として解き、$\mathbf{Z}_v$ の行で誤差を測る。これを λ の候補ごとに行い、(16) 式を求める
3. 誤差が最小の λ を選び、その λ で全員の行を使って当てはめ直す

V 分割の手間は、候補 1 つあたり V 回の当てはめである。Lasso では、2 の連立方程式のかわりに座標降下法で係数を求める。

V の選び方には釣り合いがある。V が小さいと、各回で係数を決める行は $n(V-1)/V$ 行に減る。その係数は全員で決めた係数より当てはまりが悪いので、誤差を大きめに、すなわち悲観的に見積もる。$V = n$ の LOO では係数を決める行は $n-1$ 行で、この偏りはほとんど無い。ただし当てはめを n 回くり返す必要がある。また、

n 回の係数はほとんど同じ行から決まるので互いによく似ており、その平均は、データそのものを取り直したときのばらつきを小さくしない。ふつうは $V = 5$ か 10 が使われる。なお $V < n$ では、どの行をどの組に入れるかという分け方によっても値がばらつく。ただし V 個の組の平均をとるぶん、ばらつきは第 2 回の 1 回の分割よりずっと小さい。これは第 II 部で確かめる。

最後に、CV で λ を選んだあとの誤差の報告について述べる。選んだ λ での (16) 式の値は、L 個の候補の中の最小値である。テストの行で λ を選んだときと同じく、偶然良く出たぶんだけ甘い。λ を選ぶのに使った行で、そのまま予測の良さを報告することはできない。予測の良さを報告するには、λ を選ぶ手続きの外に、測るための行を置く。行を 3 つに分けるのがその 1 つだが、行が少ないと、検証とテストにそれぞれ行を割くのは苦しい。そこで、CV を二重にする（図 17）。

定義 8 (入れ子の交差検証)**.** 行を V 組に分ける。各 v について、第 v 組を除いた行 $\mathbf{X}_{(-v)}, \boldsymbol{y}_{(-v)}$ だけで CV を行って $\hat{\lambda}^{(-v)}$ を選び、その $\hat{\lambda}^{(-v)}$ で $\mathbf{X}_{(-v)}, \boldsymbol{y}_{(-v)}$ に当てはめた係数で第 v 組の誤差を測る。V 組の誤差を合わせたものを、入れ子の交差検証（nested cross-validation）の誤差と呼ぶ。略して入れ子の CV（nested CV）とも書く。外側の CV は測るため、内側の CV は選ぶためにある。

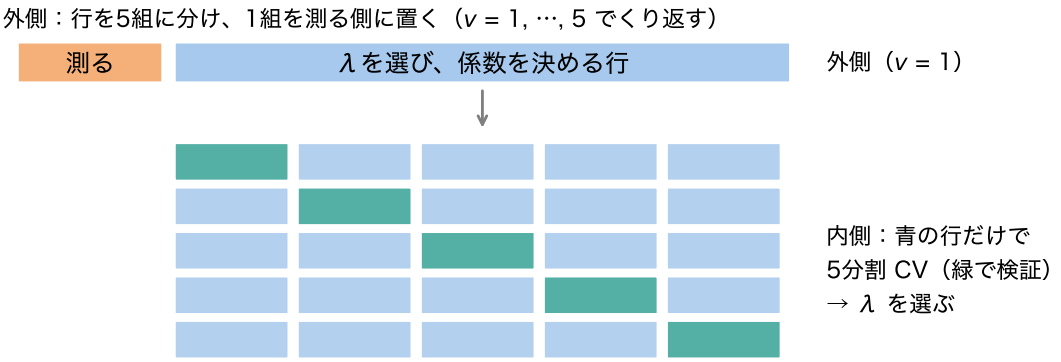


図 17: 入れ子の交差検証（概念図）。外側で第 1 組（橙）を測る側に置き、残りの行（青）だけで内側の 5 分割 CV を行って λ を選ぶ。これを外側の 5 組それぞれについてくり返す

外側の各回で、測る組は λ の選択にも係数の決定にも使われない。したがって入れ子の CV の誤差は、「CV で λ を選んでから当てはめる」という手続き全体を、新しいデータに当てたときの誤差の見積もりになる。選ばれる $\hat{\lambda}^{(-v)}$ は外側の回ごとに違ってよい。測っているのは、ある 1 つの λ の良さではなく、λ の選び方を含めた推定法の良さだからである。手間は、外側の V 回それぞれで内側の CV を行うぶん、ふつうの CV のおよそ V 倍になる。最小二乗法のように選ぶものが無い推定法では、入れ子にする必要はなく、ふつうの CV がそのまま予測の良さの見積もりになる。

第 II 部　実データ解析

リボフラビンのデータ

第 II 部では、第 I 部の理論を遺伝子のデータで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考え

る。予想どおりにいけば、それでよい。

第 I 部からは、次の 3 つを予想できる。1 つ目に、罰則を足せば、列が行より多くても係数は 1 つに決まる。2 つ目に、Lasso は多くの係数をちょうど 0 にし、少数の遺伝子だけを残すはずである。3 つ目に、罰則の強さを交差検証（クロスバリデーション、CV）で選べば、平均だけで予測するよりよく当たるはずである。最小二乗法は解が 1 つに決まらないので、比べる相手は平均だけの予測にする。

データは、Bühlmann・Kalisch・Meier が 2014 年に高次元のデータ解析の例として紹介したものである（Annual Review of Statistics and Its Application 1, 255–278）。枯草菌にリボフラビン（ビタミン B2）をつくらせた 71 の培養の試料について、リボフラビンの生産量と、4088 個の遺伝子の発現量が測られている。目的変数は生産量の対数、説明変数は発現量の対数である。データは DSM 社（スイス）が提供したもので、R の hdi パッケージ（GPL）に収められたものを書き出して使った。列は行の約 58 倍あり、冒頭の場面で見たとおり、最小二乗法では係数が 1 つに決まらない。

計算の手続き

計算の手続きは次のとおりである。4088 列を標準化したデータ行列 $\mathbf{Z}$ と中心化した生産量の対数について、Ridge 回帰は scikit-learn の Ridge で、λ の候補 40 個（0.1 から 10^5 までを対数で等間隔に並べた値）ごとに解いた。Lasso は scikit-learn の Lasso（座標降下法）で解いた。scikit-learn の Lasso は目的関数を n で割った形で書くので、その罰則の強さ α は本章の λ の $1/(2n)$ にあたる。罰則の強さは、5 分割の交差検証（クロスバリデーション、CV）(16) 式が最小になる値を選んだ。CV の各回では、係数を決める側の行だけで標準化の平均・標準偏差を求めた。予測の良さは、平均だけの予測・Ridge 回帰・Lasso の CV の誤差で比べ、さらに罰則の強さを選ぶ手続きまで含めて、入れ子の CV（定義 8。外側 5 組・内側 5 分割）で測り直した。

結果の読み方

第 1 と第 2 の予想は、どちらも当たった。図 18 は、罰則の強さを動かしたときの Lasso の係数の道筋である。罰則が強い左端ではすべての係数が 0 で、右へ弱めていくと、遺伝子が 1 つずつ 0 から離れていく。CV で選んだ強さ $\lambda = 2.9$（scikit-learn の α で 0.021）では、4088 個の遺伝子のうち 53 個だけが残り、ほかの係数はちょうど 0 である。係数の大きい 5 つは YXLD_at、YOAB_at、ARGF_at、YEBC_at、XHLB_at であった。

予測も良くなった（図 19、表 1）。平均だけで予測したときの 5 分割 CV の誤差は 0.855 である。Ridge 回帰では $\lambda = 242$（有効自由度 55.3）で 0.284、Lasso では 0.283 まで下がる。この最小値は候補の中から選んだぶん甘く出ているので、選ぶ手続きまで含めて入れ子の CV で測り直した。Ridge 回帰は 0.296、Lasso は 0.325 で、やはり平均だけの予測よりはるかによく当たる。外側の 5 回で Lasso が残した遺伝子の数は 39, 20, 42, 44, 27 個と回ごとに違ったが、いずれも数十個である。

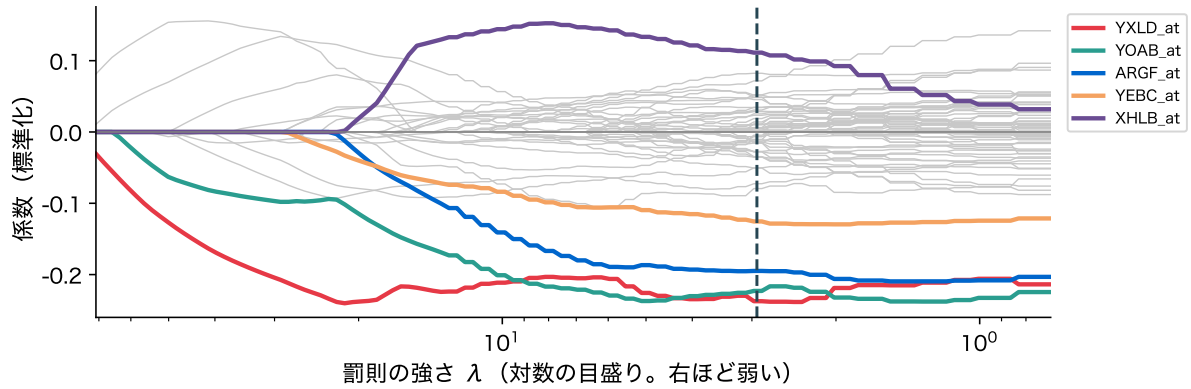


図 18: リボフラビンのデータでの Lasso の係数の道筋（標準化した単位）。色は、CV で選んだ強さ（破線）で係数の大きい 5 つの遺伝子、灰はほかの遺伝子

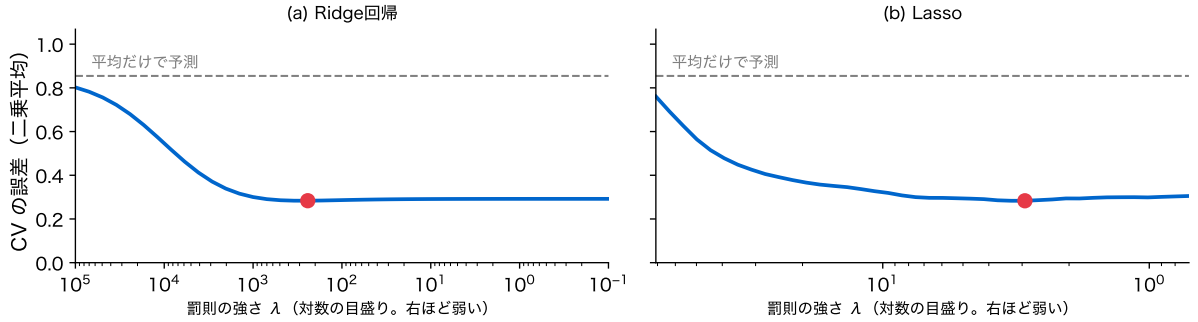


図 19: 罰則の強さに対する 5 分割 CV の誤差（二乗平均）。(a) Ridge 回帰、(b) Lasso。赤は最小の所、破線は平均だけで予測したときの誤差

表 1: リボフラビンのデータでの予測の誤差（二乗平均）。CV の最小値と、罰則の強さを選ぶ手続きまで含めた入れ子の CV。平均だけの予測は選ぶものが無いので、どちらも同じ値

	平均だけ	Ridge 回帰	Lasso
CV の最小値	0.855	0.284	0.283
入れ子の CV	0.855	0.296	0.325

一方、予想と違った点もある。第 I 部の人工データでは、新しい点での誤差は罰則の強さに対して U 字を描き、罰則を弱めすぎると誤差は上がった。ところが Ridge 回帰では、罰則をほぼ 0 まで弱めても、CV の誤差はほとんど上がらない（図 19 (a) の右端）。理由は第 I 部の 図 5 にある。谷底が線になるとき、罰則を足すと、線の上でユークリッドノルムが最も小さい 1 点が選ばれた。λ を 0 に近づけても、選ばれる点は線の上のノルム最小の点に近づくだけで、どこでもよい点にはならない。このデータでも、$\lambda \to 0$ の Ridge 回帰は、訓練誤差を 0 にする無数の解のうち、ノルム最小の解に近づく。冒頭の場面の A がその解であり、テストの誤差は 0.35 と悪くなかった。同じく訓練誤差が 0 でも、C や D のように別の解を選べば、平均だけの予測より悪かった（図 1）。罰則

を弱めきっても、無数の候補から 1 つを選ぶ働きは残るのである。

実データで起きる落とし穴

第 I 部の式から見て、実データで起きやすい失敗を 3 つ挙げる。

第 1 に、訓練誤差を報告してしまう（図 20）。罰則を弱めると、Ridge 回帰の有効自由度は試料の数に近づき、訓練誤差は 0 へ下がる。列が行より多いので、どの試料もぴたりと当てる係数が作れるからである。訓練誤差が 0 でも、5 分割 CV の誤差は 0.802 であり、訓練誤差は予測の良さについて何も語らない。第 I 部で述べたとおり、予測の良さは、係数の決定に使わなかった行で測る。

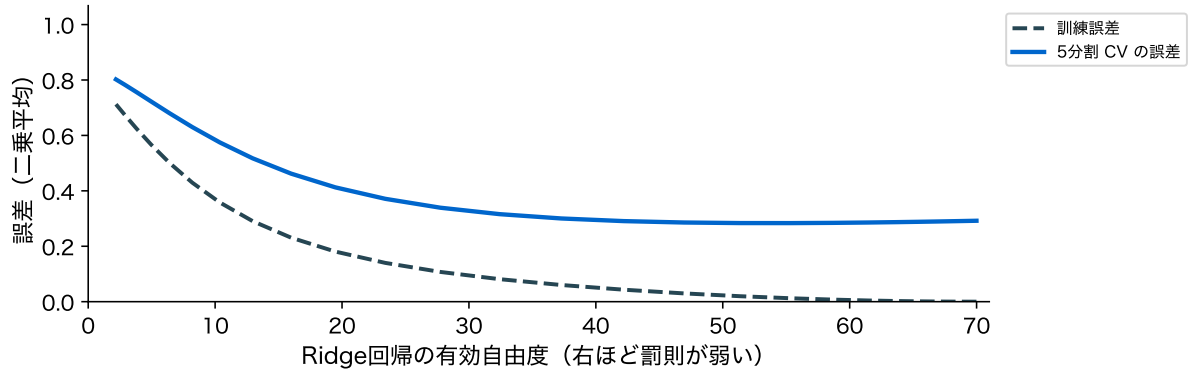


図 20: リボフラビンのデータでの Ridge 回帰の訓練誤差（破線）と 5 分割 CV の誤差（実線）。横軸は有効自由度

第 2 に、標準化を忘れる。元の単位のままの列に Lasso を当て、罰則の強さを 10 個だけが残るように調整すると、標準化してから同じことをしたときと両方に残るのは 4 個だけである（表 2）。遺伝子の発現量の標準偏差は 0.10 から 1.83 まで違う。元の単位では、ばらつきの大きい遺伝子ほど同じ効き目を小さな係数で表せるので、罰則をほとんど受けずに残る。第 I 部で見たとおり、罰則は目盛りの取り方で動く。

表 2: Lasso で 10 個の遺伝子だけを残したとき、残った遺伝子の標準偏差（中央値）。標準化してから当てた場合と、元の単位のまま当てた場合

	残った 10 個の遺伝子の標準偏差（中央値）	両方に残った数
標準化してから	0.52	4
元の単位のまま	1.00	4

第 3 に、Lasso が残した遺伝子を、それだけが効く遺伝子だと読んでしまう。訓練 50・テスト 21 への分け方を 20 通り変え、CV で選んだ強さの Lasso を訓練の試料に当てはめ直すと（図 21）、一度でも残った遺伝子は 299 個にのぼり、20 回とも残ったのは 0 個である。発現量の似た遺伝子が多いと、Lasso はその中から 1 つを残すが、どれを残すかは試料の偶然で決まる。言えるのは「残った遺伝子を使えば予測できる」までであり、「残らなかった遺伝子は生産量に関係ない」とは言えない。

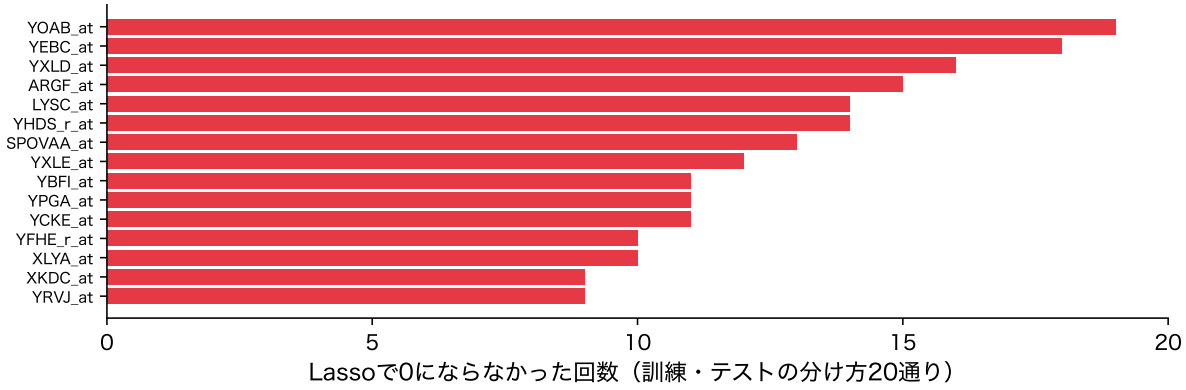


図 21: 訓練・テストへの分け方 20 通りで、CV で選んだ強さの Lasso が係数を 0 にしなかった回数(多い 15 個の遺伝子)

分け方によるばらつき

第 I 部の最後には、CV の値も組への分け方でばらつくが、V 個の組の平均をとるぶん、1 回の分割よりずっと小さいと述べた。これも確かめる(図 22)。CV で選んだ強さの Ridge 回帰を、71 の試料から 21 をテストに取り分けて測る。訓練・テストへの分け方だけを 20 通り変えると、テスト誤差は 0.16 から 0.54 まで動き、標準偏差は 0.121 である。同じ 20 通りの分け方で 5 分割 CV の組を作ると、標準偏差は 0.021 で、1 回の分割の約 6 分の 1 になる。1 回の分割では 21 の試料しか測る側に回らないが、CV では全員が 1 度ずつ測る側に回る。試料が少ないデータほど、この違いは大きい。

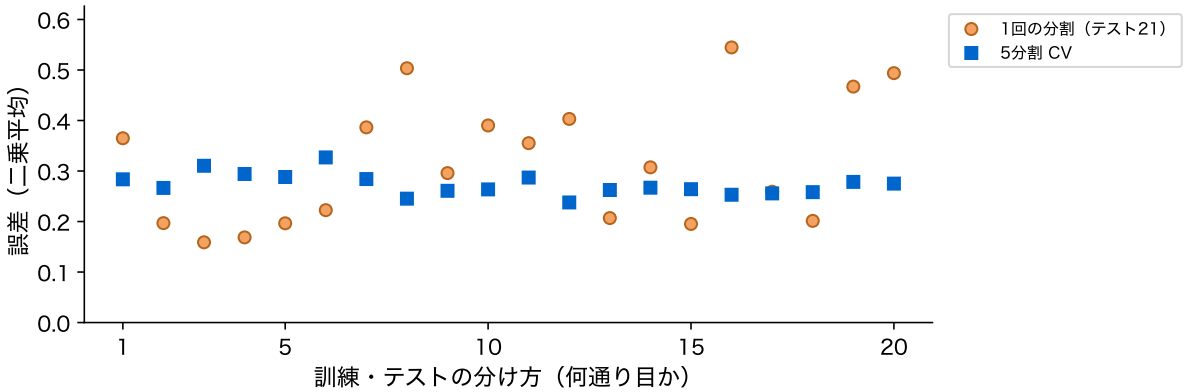


図 22: 訓練・テストへの分け方を 20 通り変えたときの誤差(二乗平均)。1 回の分割(訓練 50・テスト 21、橙)と、5 分割 CV（青）

このデータでわかったこと

第 II 部の結果をまとめる。最小二乗法では係数が 1 つに決まらない、列が行の約 58 倍のデータでも、罰則を足せば係数は 1 つに決まり、予測ができた。Lasso は 4088 個の遺伝子から 53 個だけを残し、選ぶ手続きまで含めた入れ子の CV でも、平均だけの予測の誤差 0.855 を、Ridge 回帰で 0.296、Lasso で 0.325 まで下げた。予想と違ったのは、Ridge 回帰が罰則をほぼ 0 まで弱めても悪くならなかったことで、$\lambda \to 0$ でもノルム最小の解を選ぶ働きが残るからである。CV の数字のばらつきは、1 回の分割の約 6 分の 1 であった。それでも、Lasso が残す遺伝子は分け方で大きく入れ替わる。残った遺伝子は予測に使える組の 1 つであって、効く遺伝子の一覧ではない。

締め

まとめと次回の問い

本章の問いは、データの当てはまりだけでは係数の候補が 1 つに決まらない、あるいは大きくばらつくとき、どの 1 つを選ぶか、であった。答えは、目的関数に係数の大きさへの罰則を足すことである。二乗の罰則を足した Ridge 回帰では、正規方程式の $\mathbf{X}^\top\mathbf{X}$ が $\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I}$ に変わる。この行列は正定値なので、列が重なっていても列が行より多くても逆行列を持つ。代わりに係数には偏りが入り、分散は減る。係数の二乗誤差は Bias^2 と Variance の和であり、罰則の強さに対して U 字を描く。その底は真の係数とノイズで決まるので、手元のデータから交差検証（クロスバリデーション、CV）で探す。選んだあとの予測の良さは、選ぶ手続きまで含めて入れ子の CV で測る。絶対値の罰則を足した Lasso は、小さな係数をちょうど 0 にする。罰則は係数の大きさを列をまたいで比べるので、列を標準化してから足す。罰則の効き具合は、有効自由度 $\operatorname{tr}\mathbf{H}_\lambda$ として係数の数に換算できる。リボフラビンのデータは、列が行の約 58 倍あり、最小二乗法では係数が 1 つに決まらなかった。罰則を足すと係数は 1 つに決まり、選ぶ手続きまで含めた入れ子の CV でも、平均だけの予測よりはるかによく当たった。Lasso は 4088 個の遺伝子から 53 個だけを残した。Ridge 回帰は罰則をほぼ 0 まで弱めても悪くならなかったが、これは $\lambda \to 0$ でもノルム最小の解を選ぶ働きが残るからである。CV の数字のばらつきは 1 回の分割の約 6 分の 1 になった。ただし、Lasso がどの遺伝子を残すかは、分け方でなお大きく入れ替わる。

最後に、次回への問いを置く。ここまで目的変数は、リボフラビンの生産量のような連続の量だった。では、病気か否かのように、目的変数が 0 か 1 しか取らないとき、同じ最小二乗法を当ててよいのだろうか。次回は、0/1 の目的変数を最小二乗法で回帰すると、係数の向きが何を表すのかを導く。