

第 5 回 分類①：最小二乗法

0/1 に直線を当てると、判別の向きが出る

本章の問いは、第 4 回の締めで残った「0/1 の y に最小二乗法を当てるとどうなるか」である。0/1 の目的変数に最小二乗法をそのまま当てると、係数の向きは $\mathbf{S}_W^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$ 、すなわち線形判別分析(LDA)の判別方向に一致する。違うのはしきい値だけで、群の人数が等しければそれも一致する。ただし予測値は 0 と 1 の間に収まらず、確率としては読めない。

第 I 部 理論

0/1 に直線を当てて

第 4 回までの目的変数は、病気の進行度や PSA の値のような連続の量だった。第 4 回の締めには、目的変数が 0 か 1 しか取らないときにも同じ最小二乗法を当ててよいのか、という問いを残した。本章はこの問いから始める。

例として、乳がんの細胞の画像から測った値のデータ(第 II 部で詳しく述べる)を使う。569 件の細胞のそれぞれに、悪性か良性かの診断が付いている。悪性を $y = 1$ 、良性を $y = 0$ とおけば、目的変数は 0 と 1 だけの列になる。変数を細胞核の半径の平均 1 つにして横軸にとり、点を打つ。第 1 回と同じ最小二乗法で直線を当てはめたのが図 1 である。 y の中身が 0 と 1 になっただけで、目的関数も解き方も第 1 回のままである。予測値 $\hat{y}$ が 0.5 以上なら悪性と判定すると、半径が 15.4 以上の細胞が悪性となる。判定が診断と一致した割合を正解率(accuracy)と呼ぶ。この判定の正解率は 88% である。直線は 0 と 1 の外へはみ出しているが、2 つの群を分けることはできている。

変数が 1 つのとき、係数は正か負かの符号しか持たない。30 の変数をすべて使えば、係数は 30 次元のベクトルになる。その向きは、どの変数の組み合わせで悪性と良性を分けるかを表す。本章の問いは 1 つである。0/1 の目的変数に最小二乗法を当てたとき、係数の向きは何を指しているのか。答えは、群の平均の差を群の中のばらつきで割った向き、すなわち線形判別分析の判別方向である。まず群の平均とばらつきを扱う道具をそろえ、判別方向を定義する。次に、0/1 の回帰の係数をスカラー、ベクトル、行列の順に書き直し、判別方向に一致することを導く。続いて、しきい値だけが群の人数の比でずれることを示す。最後に、方向は出ても確率は出ないことと、3 群以上では選べない群が出ることを述べる。

「モデル × 推定法」の地図でいえば、推定法は第 1 回と同じ最小二乗法のまま、答えの読み方が線形回帰から線形判別分析(linear discriminant analysis)(LDA)に変わる。第 1 回の表で LDA の行の最小二乗法の列に「第 5




図 1: 乳がんデータの細胞核の半径の平均と診断(悪性 = 1 が赤、良性 = 0 が青。縦に少しずらして打った)。直線は最小二乗法、破線は予測値が 0.5 になる半径

回」と書いたのがこのマスである。第 4 回では推定法の列が増えたが、本章ではモデルの行が変わる。

道具：群の平均と群の中のばらつき

0/1 の目的変数によって、データの行は 2 つの群に分かれる。本章の導出には、群ごとの平均とばらつきを使う。その道具をここにまとめておく。

まず 1 変数で考える。 n 個の値 $x_1, \dots, x_i$ のうち、 $y_i = 0$ の群に n_0 個、 $y_i = 1$ の群に n_1 個があるとする。群の割合を $\pi_q = n_q/n$ 、群の平均を $\mu_q = \frac{1}{n_q} \sum_{y_i=q} x_i$ とおく ($q = 0, 1$)。全体の平均は

$$\bar{x} = \pi_0 \mu_0 + \pi_1 \mu_1 \quad (1)$$

であり、群の平均を群の割合で重み付けした平均になる。図 2 は人工データの例で、 $y = 0$ の群 150 個、 $y = 1$ の群 30 個である。人数の多い $y = 0$ の側に、全体の平均 $\bar{x}$ が寄っている。




図 2: 1 変数・2 群の人工データ ($y = 0$ が青、 $y = 1$ が赤。縦に少しずらして打った)。破線は群の平均 μ_0, μ_1 と全体の平均 $\bar{x}$

次に、ばらつきを 2 つに分ける。群の和が簡単な形になるので、本章では分散を n で割って定義する。全体の分散 $s_T^2 = \frac{1}{n} \sum_i (x_i - \bar{x})^2$ の各項では、群の平均を通して $x_i - \bar{x} = (x_i - \mu_q) + (\mu_q - \bar{x})$ と分ける。展開す

ると、交差項は群ごとに $\sum_{y_i=q} (x_i - \mu_q) = 0$ となって消える。(1) 式から $\mu_0 - \bar{x} = -\pi_1 d$ 、 $\mu_1 - \bar{x} = \pi_0 d$ ($d = \mu_1 - \mu_0$)なので、残りは

$$s_T^2 = s_W^2 + \pi_0 \pi_1 d^2, \quad s_W^2 = \frac{1}{n} \sum_{q=0}^1 \sum_{y_i=q} (x_i - \mu_q)^2 \quad (2)$$

となる。 s_W^2 を群の中の分散と呼ぶ。全体のばらつきは、群の中のばらつきと、群の平均が離れていることによるばらつきの和である。人工データでは $s_T^2 = 1.790$ 、 $s_W^2 = 0.950$ 、 $\pi_0 \pi_1 d^2 = 0.840$ で、確かに和が合う。

変数が p 個になると、各行は p 次元のベクトル $\mathbf{x}_i$ になり、群の平均も $\boldsymbol{\mu}_q$ というベクトルになる。分散は第3回の分散共分散行列に置きかわる。

定義 1 (群の中の共分散行列)． $\mathbf{d} = \boldsymbol{\mu}_1 - \boldsymbol{\mu}_0$ とする。全体の共分散行列 $\mathbf{S}_T = \frac{1}{n} \sum_i (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top$ に対し、

$$\mathbf{S}_W = \frac{1}{n} \sum_{q=0}^1 \sum_{y_i=q} (\mathbf{x}_i - \boldsymbol{\mu}_q)(\mathbf{x}_i - \boldsymbol{\mu}_q)^\top$$

を群の中の共分散行列(within-class covariance matrix)と呼ぶ。1 変数の分解 (2) 式と同じ計算で

$$\mathbf{S}_T = \mathbf{S}_W + \pi_0 \pi_1 \mathbf{d} \mathbf{d}^\top \quad (3)$$

が成り立つ。

(3) 式の第2項 $\pi_0 \pi_1 \mathbf{d} \mathbf{d}^\top$ は、どのベクトル $\mathbf{v}$ に掛けても $\pi_0 \pi_1 (\mathbf{d}^\top \mathbf{v}) \mathbf{d}$ となり、いつも $\mathbf{d}$ の向きを向く。 $\mathbf{d}^\top \mathbf{v}$ はスカラーだからである。0/1 の回帰の係数の向きは、後でこの性質から決まる。 $p = 1$ なら $\mathbf{S}_T = s_T^2$ 、 $\mathbf{S}_W = s_W^2$ で、(3) 式は (2) 式に戻る。

多変数の行を向き $\mathbf{w}$ に映し、1 本のスコア $z_i = \mathbf{w}^\top \mathbf{x}_i$ にする。スコアの群の平均は $\mathbf{w}^\top \boldsymbol{\mu}_q$ 、その差は $\mathbf{w}^\top \mathbf{d}$ である。群の中の分散は $\frac{1}{n} \sum_q \sum_{y_i=q} (\mathbf{w}^\top (\mathbf{x}_i - \boldsymbol{\mu}_q))^2 = \mathbf{w}^\top \mathbf{S}_W \mathbf{w}$ になる。映したスコアについては、1 変数の量がそのまま使える。

勾配の公式を2つ用意する。第1回のベクトル偏微分の公式から $\partial(\mathbf{w}^\top \mathbf{d}) / \partial \mathbf{w} = \mathbf{d}$ である。対称な $\mathbf{A}$ については、積の両側の $\mathbf{w}$ をそれぞれ微分して足せば

$$\frac{\partial \mathbf{w}^\top \mathbf{A} \mathbf{w}}{\partial \mathbf{w}} = \mathbf{A} \mathbf{w} + \mathbf{A}^\top \mathbf{w} = 2\mathbf{A} \mathbf{w} \quad (4)$$

となる。第1回で $\beta^\top \mathbf{X}^\top \mathbf{X} \beta$ の勾配を $2\mathbf{X}^\top \mathbf{X} \beta$ としたのと同じ計算であり、 $p = 1$ なら aw^2 の微分 $2aw$ に戻る。

最後に、2つのベクトルの向きを比べる量を用意する。

定義 2 (コサイン). 0 でない 2 つのベクトル $\mathbf{a}, \mathbf{b}$ について、

$$\cos \theta = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|_2 \|\mathbf{b}\|_2} \quad (5)$$

を 2 つのベクトルのなす角 θ のコサイン (cosine similarity) と呼ぶ。

分子は第 1 回の内積、分母は 2 つのユークリッドノルムの積である。 $\mathbf{a}$ と $\mathbf{b}$ が同じ向きなら 1、直角なら 0、逆向きなら -1 になる。どちらかを正の数倍しても値は変わらないので、長さを除いた向きだけを比べられる。

LDA の判別方向

2 つの群を分けるには、何を決めればよいか。変数が p 個あるとき、最も素朴な線形の分け方は次のとおりである。各行を向き $\mathbf{w}$ に映したスコア $z = \mathbf{w}^\top \mathbf{x}$ を作り、しきい値 c 以上なら $y = 1$ 、未満なら $y = 0$ とする。 $\mathbf{w}^\top \mathbf{x} = c$ を満たす点の集まりは $\mathbf{w}$ に直角な直線 (p 次元では平面) であり、これが 2 つの群の境界になる。決めるべきものは、向き $\mathbf{w}$ としきい値 c の 2 つである。

向きの候補としてまず思いつくのは、2 つの群の平均を結ぶ向き $\mathbf{d}$ である。だが、この向きがよいとは限らない。図 3 は 2 変数の人工データである。群の中の共分散は 2 つの群で共通とし (分散 0.8、相関 0.95)、 $y = 0$ を 100 個、 $y = 1$ を 50 個とした。群は右上がりに細長く伸びている。(a)(b) のように $\mathbf{d}$ に映すと、細長い向きのばらつきまで拾ってしまい、2 つの山は大きく重なる。スコアの「群の平均の差 ÷ 群の中の標準偏差」は 1.44 である。

群をよく分ける向きとは、映したスコアの群の平均が離れ、しかも群の中のばらつきが小さい向きである。道具で見たとおり、スコアの平均の差は $\mathbf{w}^\top \mathbf{d}$ 、群の中の分散は $\mathbf{w}^\top \mathbf{S}_W \mathbf{w}$ なので、その比

$$J(\mathbf{w}) = \frac{(\mathbf{w}^\top \mathbf{d})^2}{\mathbf{w}^\top \mathbf{S}_W \mathbf{w}} \quad (6)$$

を最大にすればよい。これはフィッシャー (1936) の基準である。 $\mathbf{w}$ を a 倍しても分子と分母がともに a^2 倍になるので J は変わらない。 J の値は $\mathbf{w}$ の向きだけで決まり、長さにはよらない。(4) 式を使って J の勾配を計算し、0 ベクトルとおくと

$$\frac{\partial J}{\partial \mathbf{w}} = \frac{2(\mathbf{w}^\top \mathbf{d})}{\mathbf{w}^\top \mathbf{S}_W \mathbf{w}} \left(\mathbf{d} - \frac{\mathbf{w}^\top \mathbf{d}}{\mathbf{w}^\top \mathbf{S}_W \mathbf{w}} \mathbf{S}_W \mathbf{w} \right) = 0$$

となる。括弧の中が 0 であるためには、 $\mathbf{S}_W \mathbf{w}$ が $\mathbf{d}$ のスカラー倍であればよい。 $\mathbf{S}_W$ が正則なら

$$\mathbf{w} \propto \mathbf{S}_W^{-1} \mathbf{d} \quad (7)$$

を得る ($\propto$ は「スカラー倍を除いて等しい」の意味)。このとき J の値は $D^2 = \mathbf{d}^\top \mathbf{S}_W^{-1} \mathbf{d}$ になる。 $p = 1$ なら $w \propto d/s_W^2$ で、向きは平均の差の符号だけで決まる。

定義 3 (フィッシャーの線形判別). 2 群のデータについて、(6) 式を最大にする向き $\mathbf{w} \propto \mathbf{S}_W^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$ を判別方向(discriminant direction)と呼ぶ。スコア $\mathbf{w}^\top \mathbf{x}$ をしきい値で切って群を分ける方法を線形判別分析(LDA)と呼ぶ。しきい値の素朴な選び方は、2 つの群の平均の midpoint $(\boldsymbol{\mu}_0 + \boldsymbol{\mu}_1)/2$ を通る境界である。

図 3 (c)(d) は、同じデータを $\mathbf{S}_W^{-1} \mathbf{d}$ に映したものである。矢印は平均の差の向きから大きく回っている。群が細く締まっている向きを使うので、2 つの山は離れる。「平均の差 ÷ 群の中の標準偏差」は 4.04 になり、 $\mathbf{d}$ の向きの 1.44 を大きく上回る。 $\mathbf{S}_W^{-1}$ を掛けることは、群の中のばらつきの大きい向きを割り引き、小さい向きを重んじることにあたる。本章では、LDA を「最もよく分ける向き」として扱う。




図 3: 2 変数・2 群の人工データ ($y = 0$ が青、 $y = 1$ が赤)。(a)(b) 平均の差の向き $\mathbf{d}$ に映したとき、(c)(d) フィッシャーの向き $\mathbf{S}_W^{-1} \mathbf{d}$ に映したとき。矢印が向き、破線が中点を通る境界。(b)(d) は映したスコアの分布

判別方向は、群の平均と群の中の共分散から直接計算できる。では、0/1 の目的変数に最小二乗法を当てたときの係数は、どの向きを向くのだろうか。

0/1 回帰の係数は LDA の向き

0/1 の目的変数に最小二乗法を当てるときの目的関数は

$$f(\beta_0, \beta) = \sum_{i=1}^n (y_i - \beta_0 - \mathbf{x}_i^\top \beta)^2, \quad y_i \in \{0, 1\} \quad (8)$$

であり、第 1 回の目的関数と同じ式である。違うのは y_i の中身だけで、0 か 1 しか取らない。第 3 回のとおり、各列を中心化すれば切片は $\hat{\beta}_0 = \bar{y} - \bar{\mathbf{x}}^\top \hat{\beta}$ に切り離せる。0/1 の列の平均は 1 の割合なので $\bar{y} = \pi_1$ である。

まず 1 変数で解く。第 1 回の単回帰の解は、共分散を分散で割った $\hat{\beta} = s_{xy}/s_T^2$ である。本章では共分散も n で割る。 y が 0 と 1 だけなので、共分散は簡単になる。 $y_i - \bar{y}$ は、 $y_i = 1$ の行では $1 - \pi_1 = \pi_0$ 、 $y_i = 0$ の行では $-\pi_1$ の 2 つの値しか取らないから

$$s_{xy} = \frac{1}{n} \left[\pi_0 \sum_{y_i=1} (x_i - \bar{x}) - \pi_1 \sum_{y_i=0} (x_i - \bar{x}) \right] = \pi_0 \pi_1 (\mu_1 - \bar{x}) - \pi_1 \pi_0 (\mu_0 - \bar{x}) = \pi_0 \pi_1 d \quad (9)$$

となる。 x と 0/1 の y の共分散は、群の平均の差 d に比例する。分母に (2) 式を代入すると

$$\hat{\beta} = \frac{\pi_0 \pi_1 d}{s_W^2 + \pi_0 \pi_1 d^2} \quad (10)$$

を得る。傾きは、平均の差を、群の中と群の間のばらつきの和で割ったものである。図 2 の人工データでは $\hat{\beta} = 0.191$ で、第 1 回の単回帰で直接求めた値 0.191 と一致する。

同じ計算をベクトルで書く。 $\mathbf{y} - \pi_1 \mathbf{1}$ は、 $y_i = 1$ の行に π_0 、 $y_i = 0$ の行に $-\pi_1$ が並んだベクトルである。(9) 式は、中心化した列 $\mathbf{x} - \bar{x} \mathbf{1}$ とこのベクトルの内積 $\frac{1}{n} (\mathbf{x} - \bar{x} \mathbf{1})^\top (\mathbf{y} - \pi_1 \mathbf{1})$ にほかならない。列が p 本あれば、中心化したデータ行列 $\mathbf{X}_c$ の各列について同じ内積を作り、縦に並べる。すると $\frac{1}{n} \mathbf{X}_c^\top (\mathbf{y} - \pi_1 \mathbf{1}) = \pi_0 \pi_1 \mathbf{d}$ となる。 $\mathbf{d}$ の第 j 成分は、第 j 列の群の平均の差である。

行列で解く。第 1 回の正規方程式 $\mathbf{X}_c^\top \mathbf{X}_c \hat{\beta} = \mathbf{X}_c^\top (\mathbf{y} - \pi_1 \mathbf{1})$ の両辺を n で割ると、左辺の $\frac{1}{n} \mathbf{X}_c^\top \mathbf{X}_c$ は $\mathbf{S}_T$ である。(3) 式を代入すると

$$\begin{aligned} \mathbf{S}_T \hat{\beta} &= \pi_0 \pi_1 \mathbf{d} \\ \mathbf{S}_W \hat{\beta} + \pi_0 \pi_1 \mathbf{d} (\mathbf{d}^\top \hat{\beta}) &= \pi_0 \pi_1 \mathbf{d} \\ \mathbf{S}_W \hat{\beta} &= \pi_0 \pi_1 (1 - \mathbf{d}^\top \hat{\beta}) \mathbf{d} \end{aligned} \quad (11)$$

となる。2 行目では、 $\mathbf{d} \mathbf{d}^\top \hat{\beta}$ の $\mathbf{d}^\top \hat{\beta}$ がスカラーであることを使った。3 行目の右辺はスカラーと $\mathbf{d}$ の積であり、 $\mathbf{S}_W \hat{\beta}$ は $\mathbf{d}$ と同じ向きになる。これは、(6) 式の勾配を 0 とおいたときの条件と同じである。両辺に左から $\mathbf{S}_W^{-1}$ を掛け、さらに $\mathbf{d}^\top$ を掛ける。スカラー $\mathbf{d}^\top \hat{\beta}$ について解くと $\mathbf{d}^\top \hat{\beta} = \pi_0 \pi_1 D^2 / (1 + \pi_0 \pi_1 D^2)$ となり、

$$\hat{\beta} = \frac{\pi_0\pi_1}{1 + \pi_0\pi_1 D^2} \mathbf{S}_W^{-1} \mathbf{d}, \quad D^2 = \mathbf{d}^\top \mathbf{S}_W^{-1} \mathbf{d} \quad (12)$$

を得る。前の係数は正の数なので、 $\hat{\beta}$ は判別方向 (7) 式と向きまで同じである。 $p = 1$ なら $D^2 = d^2/s_W^2$ で、(12) 式は (10) 式に戻る。

0/1 の目的変数に最小二乗法を当てたときの係数の向きは、フィッシャーの判別方向そのものである。最小二乗法は「データとモデルの距離を最小にする」だけで、群を分けることは何も求めている。それでも y が 0 と 1 しか取らないために、 y との共分散は平均の差になる。全体の共分散も、群の中の共分散と平均の差の分に分かれる。その結果、係数は群を最もよく分ける向きに着く。図 4 は、図 3 と同じ人工データの上で、0/1 の回帰の係数 (橙の破線の矢印) を判別方向 (黒の矢印) に重ねたものである。2 つの向きのコサイン (5) 式は 1.0000000 で、矢印は重なる。




図 4: 図 3 と同じ人工データ。(a) フィッシャーの判別方向 (黒の矢印) と、0/1 の回帰の係数の向き (橙の破線の矢印)、(b) 判別方向に映したスコアの分布

しきい値は人数の比でずれる

向きが同じなら、残る違いはしきい値 c だけである。0/1 の回帰で $\hat{y} \geq 1/2$ を $y = 1$ とする境界は、LDA の中点を通る境界と一致するだろうか。

予測値は $\hat{y}(\mathbf{x}) = \pi_1 + \hat{\beta}^\top (\mathbf{x} - \bar{\mathbf{x}})$ である。(1) 式から、中点 $\mathbf{m} = (\mu_0 + \mu_1)/2$ と全体の平均の差は $\mathbf{m} - \bar{\mathbf{x}} = \frac{\pi_0 - \pi_1}{2} \mathbf{d}$ なので

$$\hat{y}(\mathbf{m}) = \pi_1 + \frac{\pi_0 - \pi_1}{2} \mathbf{d}^\top \hat{\beta} = \frac{1}{2} + \frac{(\pi_1 - \pi_0)(1 - \mathbf{d}^\top \hat{\beta})}{2} \quad (13)$$

となる。(12) 式の前で見たとおり $0 < \mathbf{d}^\top \hat{\beta} < 1$ なので、 $y = 1$ の群が少ない ($\pi_1 < \pi_0$) と、中点での予測値は $1/2$ より小さい。予測値が $1/2$ に届くのは、中点から $y = 1$ の群の側へ進んでからである。0.5 で切る境界は人数の少ない群の側へずれ、多い群の領域が広がる。

図 5 は 図 2 と同じ 1 変数の人工データに、0/1 の回帰の直線を引いたものである。 $y = 1$ の群は 30 個、 $y = 0$ の群は 150 個である。中点 1.17 での予測値は 0.323 で、(13) 式の値 0.323 に一致する。 $\hat{y} = 0.5$ となる x は 2.09 で、中点より赤の群の側にある。




図 5: 図 2 と同じ人工データに当てた 0/1 の回帰の直線。橙の破線と丸は 2 つの群の平均の中点とそこでの予測値、黒の破線は予測値が 0.5 になる点

2 つの群の人数が等しいとき、すなわち $\pi_0 = \pi_1 = 1/2$ のときに限り、(13) 式の第 2 項は 0 になる。このとき 0.5 で切る境界は、中点を通る LDA の境界と一致する。まとめると、0/1 の最小二乗法と LDA の向きはいつも同じで、しきい値だけが人数の比でずれる。人数の比を境界にどう入れるべきかは、確率を考えて初めて決まる。

計算の手順

計算の手順を行列で書くと、次のようになる。第 1 回の最小二乗法の手順に、 y の作り方と最後の判定が加わるだけである。

1. データ行列 $\mathbf{X}$ ($n \times p$) と、0/1 の目的変数 $\mathbf{y}$ を作る。列の平均 $\bar{\mathbf{x}}$ を引いた $\mathbf{X}_c$ と、 $\bar{y} = \pi_1$ を引いた $\mathbf{y}_c$ を作る
2. 正規方程式 $\mathbf{X}_c^\top \mathbf{X}_c \boldsymbol{\beta} = \mathbf{X}_c^\top \mathbf{y}_c$ を連立方程式として解く。(12) 式により、解の向きは判別方向 $\mathbf{S}_W^{-1} \mathbf{d}$ である
3. 新しい行 $\mathbf{x}$ について、スコア $\hat{y} = \bar{y} + (\mathbf{x} - \bar{\mathbf{x}})^\top \hat{\boldsymbol{\beta}}$ を作り、 $\hat{y} \geq 0.5$ なら $y = 1$ と判定する

群が k 個 ($k \geq 3$) あるときは、目的変数を指示行列 $\mathbf{Y}$ ($n \times k$, 行 i の属する群の列だけが 1 で、ほかは 0) にかえる。これは、 $\mathbf{Y}$ の k 本の列のそれぞれを目的変数として回帰する多変量の最小二乗法である。係数は行列 $\mathbf{B}$ ($p \times k$) になる。手順 2 の正規方程式は $\mathbf{X}_c^\top \mathbf{X}_c \mathbf{B} = \mathbf{X}_c^\top \mathbf{Y}_c$ になる。係数行列 $\mathbf{X}_c^\top \mathbf{X}_c$ は共通なので、1 回の分解で k 本の右辺をまとめて解ける。手順 3 では、新しい行の予測値のベクトル $\hat{\mathbf{y}}^\top = \bar{\mathbf{y}}^\top + (\mathbf{x} - \bar{\mathbf{x}})^\top \hat{\mathbf{B}}$ ($1 \times k$) を作り、その最大の成分の群を選ぶ。 $\mathbf{Y}$ の各行の和は 1 なので、予測値の各行の和も必ず 1 になる。 $k = 2$ なら、2 本の列は y と $1 - y$ であり、最大の列を選ぶことは $\hat{y} \geq 0.5$ で切ることと同じである。

方向は出るが、確率は出ない

0/1 の回帰は判別方向を正しく出すが、式から言える限界が 2 つある。

1 つ目は、予測値が 0 と 1 の間に収まらないことである。最小二乗法が近づこうとするのは、 $\mathbf{x}$ ごとの y の平

均、つまり $y = 1$ の割合である。割合は 0 と 1 の間にあるが、 x の 1 次式は x を遠くへ動かせばいくらでも大きく、あるいは小さくなる。図 6 (a) は 図 2 と同じ人工データである。 x を幅 1 の区間に分け、区間ごとの $y = 1$ の割合を黒の四角で示した。割合は左で 0 に、右で 1 に張り付く。直線はそれを追えず、左端では -0.57、右端では 1.34 まで伸びる。予測値が -0.3 の点を「確率 -30% 」と読むことはできない。残差も 0/1 から直線を引いた 2 通りの値しか取らず、その散らばり方は x の場所で変わる。0/1 の回帰の予測値は、群を分けるためのスコアであって、確率ではない。

2 つ目は、群が 3 つ以上のときに起きる。図 6 (b) は、1 変数に 3 つの群(平均 -3 、 0 、 3 、標準偏差 0.8 、各 60 個)を並べた人工データに、指示行列の回帰を当てたものである。両端の群の直線は傾く。真ん中の群の列は、左でも右でも 0 で真ん中だけ 1 という形をしていて、1 次式では表せない。そのため真ん中の群の直線は、ほぼ平ら(傾き 0.004)になる。その結果、真ん中の群の予測値はどの x でもほかの群の予測値を上回らない。最大の列を選ぶと、真ん中の群は一度も選ばれない。180 個のうち群 1・群 2・群 3 と判定されたのは、それぞれ $88 \cdot 0 \cdot 92$ 個である。

定義 4 (マスキング)。3 群以上の指示行列を最小二乗法で回帰して最大の列を選ぶとき、ある群の予測値がどこでもほかの群を上回らず、その群が一度も選ばれないことをマスキング(masking)と呼ぶ。

同じデータでも、群を 2 つずつ比べる判別方向を使えば真ん中の群は分けられる。最適スコアリング(Hastie–Tibshirani–Buja, 1994)は、指示行列の列に得点を割り当て直してからデータ行列で回帰し、得点と係数を交互に更新する。この方法を使うと、最小二乗法のまま k 群の LDA に着き、マスキングは消える。本講義ではこれ以上は扱わない。




図 6: 0/1 の回帰の限界(人工データ)。(a) 図 2 と同じデータの回帰の直線と、 x の区間ごとの $y = 1$ の割合(黒の四角)。(b) 3 群の指示行列の回帰。上の帯は予測値が最大の群で、真ん中の群(緑)はどこでも選ばれない

得られるのは方向であって、確率ではない。

第 II 部 実データ解析

乳がんデータ

第 II 部では、第 I 部の理論を乳がんの細胞のデータで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具

で考える。予想どおりにいけば、それでよい。

第 I 部では、0/1 の回帰の係数が判別方向 $\mathbf{S}_W^{-1}\mathbf{d}$ を向くことを導いた。ここから次の 2 つを予想できる。このデータには似た列が多いので、係数の向きは平均の差 $\mathbf{d}$ の向きから大きく回るはずである。そして、その向きに映せば、半径 1 列や $\mathbf{d}$ の向きに映すより、2 つの群がよく分かれるはずである。しきい値と予測値についての予想は、それぞれの結果の前に述べる。

データは scikit-learn の load_breast_cancer (Wisconsin 診断データ) である。1 行は乳房の腫瘍から針で採った細胞の画像 1 枚で、全部で 569 件ある。各画像では、写っている細胞核の輪郭から 表 1 の 10 種類の量を測った。それぞれを画像の中の核について平均・標準誤差・最も大きい 3 つの平均(最悪値)の 3 通りにまとめ、計 30 列を説明変数とする。目的変数は診断で、悪性が 212 件、良性が 357 件ある。scikit-learn の元のデータは悪性を 0、良性を 1 としているが、本章では悪性を 1 とした。30 列は単位も大きさもまちまちなので、それぞれ標準化した。標準化しても、係数の向きが判別方向と一致することは変わらない。標準化したのは、列ごとの係数を比べやすくするためである。半径・周囲の長さ・面積のように、互いにほぼ決まってしまう列もある。半径の平均と周囲の長さの平均の相関係数は 0.998 である。第 I 部の場面では、半径の平均の 1 列だけで直線を当て、0.5 で切った。そのときの正解率は 87.5% であった。

表 1: 乳がんデータの細胞核の 10 の測定値。それぞれ平均・標準誤差・最悪値の 3 列があり、計 30 列

測定値	測定値
半径	なめらかさ
きめ(濃淡のばらつき)	緻密さ
周囲の長さ	くぼみの深さ
面積	くぼみの数
対称性	輪郭の複雑さ(フラクタル次元)

計算の手続き

計算の手続きは次のとおりである。30 列を標準化したデータ行列 $\mathbf{Z}$ と、悪性を 1 とした $\mathbf{y}$ を用意し、列と $\mathbf{y}$ を中心化した。正規方程式を NumPy の線形方程式ソルバーで解き、0/1 の回帰の係数 $\hat{\beta}$ を求めた。別に、悪性・良性の群ごとの平均 μ_1, μ_0 と群の中の共分散行列 $\mathbf{S}_W$ (定義 1) を計算した。向きの良し悪しは、第 I 部の図 3 と同じく、映したスコアの「群の平均の差 ÷ 群の中の標準偏差」で比べた。正解率は、どの向きでも、映したスコア 1 列に 0/1 の回帰を当てて 0.5 で切って求めた。しきい値については、中点での予測値を求めた。さらに、良性の 357 件から無作為に 212 件を選んで人数をそろえ、同じ計算をした。係数を決めた行とは別の行でも確かめるため、訓練 398 件とテスト 171 件に分けた計算も行った。標準化の平均・標準偏差は訓練の行で求めた。正解率の比較では、訓練・テストへの分け方を 20 通り変えて平均した。

向きと分かれ方

第 1 の予想は、係数の向きについてであり、結果は予想どおりだった。0/1 の回帰の係数 $\hat{\beta}$ と平均の差 $\mathbf{d}$ のコサイン (5) 式は 0.08 で、30 次元の 2 つの向きはほとんど直角である (表 4)。似た列が多いこのデータでは、 $\mathbf{S}_W^{-1}$ を掛けることで向きが大きく回る。図 3 の人工データで見たことが、30 次元で強く起きている。

向きの違いは、群の分かれ方に表れる (表 2)。映したスコアの「群の平均の差 ÷ 群の中の標準偏差」は、半径の平均 1 列では 2.21、平均の差 $\mathbf{d}$ の向きでは 2.88、0/1 の回帰の向きでは 3.83 である。第 I 部の人工データと同じ順に並び、判別方向が最もよく分ける。0/1 の回帰の向きでのこの値は、 $D = \sqrt{D^2}$ にあたる。

表 2: 3 つの向きに映したスコアの「群の平均の差 ÷ 群の中の標準偏差」

向き	平均の差 ÷ 群の中の標準偏差
半径の平均だけ (第 I 部の場面)	2.21
平均の差 $\mathbf{d}$ の向き	2.88
0/1 の回帰 (判別方向)	3.83

図 7 は、全件で当てはめた 0/1 の回帰の予測値 $\hat{y}$ の分布を、診断ごとに描いたものである。判別方向の上で、2 つの山はよく分かれている。0.5 で切ると、全件の正解率は 96.5% で、半径の平均 1 列だけの 87.5% を上回る。平均の差 $\mathbf{d}$ の向きでは 92.8% である (表 3)。ただし全件の正解率は、係数を決めた行で測った数字なので楽観的である。訓練 398 件で当てはめてテスト 171 件で測る分け方を 20 通り作り、正解率を平均した。0/1 の回帰は 95.0%、 $\mathbf{d}$ の向きは 92.4%、半径 1 列は 87.0% であった。全件との差が大きいのは、30 個の係数を訓練の行に合わせる 0/1 の回帰である。それでも順位は変わらず、20 通りのうち 19 通りで、判別方向が $\mathbf{d}$ の向きを上回った。

表 3: 3 つの向きの正解率 (映したスコアに 0/1 の回帰を当てて 0.5 で切る)。全件で当てはめて全件で測った値と、訓練の行で当てはめてテストの行で測った値 (分割 20 通りの平均)

向き	全件	テスト 171 件 (20 通りの平均)
半径の平均だけ (第 I 部の場面)	87.5%	87.0%
平均の差 $\mathbf{d}$ の向き	92.8%	92.4%
0/1 の回帰 (判別方向)	96.5%	95.0%

計算も、第 I 部の式のとおりだった。 $\hat{\beta}$ と $\mathbf{S}_W^{-1}\mathbf{d}$ のコサインは 1.0000000、scikit-learn の LinearDiscriminantAnalysis の係数とのコサインも 1.0000000 である。長さの比も (12) 式の係数 $\pi_0\pi_1/(1+\pi_0\pi_1D^2) = 0.05276$ ($D^2 = 14.7$) に一致し、成分ごとの差は最大 5e-13 である。導出の土台の (3) 式も成り立ち、 $\mathbf{S}_T - \mathbf{S}_W - \pi_0\pi_1\mathbf{d}\mathbf{d}^\top$ の成分の絶対値は最大で 7e-16 となる。




図 7: 乳がんデータの 0/1 の回帰の予測値の分布(青が良性、赤が悪性)。灰の実線は 0 と 1、黒の破線は 0.5、橙の点線は両群の平均の midpoint の予測値

表 4: 乳がんデータの 0/1 の回帰の係数と、3 つの向きのコサイン

0/1 の回帰の係数 $\hat{\beta}$ と	コサイン
$\mathbf{S}_{\mathbf{W}}^{-1} \mathbf{d}$ (手で組んだ判別方向)	1.0000000
scikit-learn の LDA の係数	1.0000000
平均の差 $\mathbf{d}$ そのもの	0.08

しきい値と人数の比

第 I 部では、0/1 の回帰で 0.5 で切る境界が、人数の少ない群の側へずれることを導いた。悪性 212 件・良性 357 件のこのデータでは、 midpoint の予測値は 0.5 より小さくなるはずである。結果は予想どおりだった(表 5)。全件では、 midpoint の予測値は 0.4712452 で、(13) 式から計算した 0.4712452 と一致する。良性を 212 件に間引いて人数をそろえると、 midpoint の予測値はちょうど 0.5000000 になる。このときも係数の向きは、そのデータの判別方向とコサイン 1.0000000 で一致する。

表 5: 両群の平均の midpoint の 0/1 の回帰の予測値。全件と、良性を間引いて人数をそろえた場合

	人数(悪性 : 良性)	midpoint の $\hat{y}$
全件	212 : 357	0.4712452
良性を間引く	212 : 212	0.5000000

ただし、ずれは判定をほとんど変えない。0.5 で切る判定と midpoint で切る判定が食い違うのは、569 件中 2 件であった(図 7)。理由は (13) 式から読める。0.5 からのずれは $(\pi_1 - \pi_0)(1 - \mathbf{d}^\top \hat{\beta})/2$ である。人数の差は $\pi_1 - \pi_0 = -0.25$ とそれなりにある。だが、2 つの群は判別方向の上で遠く離れていて、 $D^2 = 14.7$ と大きい。そのため $\mathbf{d}^\top \hat{\beta} = \pi_0 \pi_1 D^2 / (1 + \pi_0 \pi_1 D^2)$ は 0.77 と 1 に近く、ずれは -0.029 にとどまる。しかも 2 つの山はよく分かれていて、0.5 と midpoint の間に入る件数がわずかである。群が重なっているデータや、人数の比がもっと偏ったデータでは、ずれはもっと大きく効く。

予測値は確率か

第 I 部では、1 変数の人工データで、直線が $y = 1$ の割合を追えず 0 と 1 の外へはみ出すことを見た。30 列にしても、予測値は確率として読めないはずである。結果は予想どおりだった。30 列を使っても予測値は 0 と 1 の間に収まらず、569 件のうち 19.3% (110 件) が 0 未満、12.0% (68 件) が 1 を超える(図 7)。範囲は -0.42 から 1.56 である。訓練の行で当てはめたテストの行でも、0 未満が 30 件、1 超が 13 件あった。

図 8 は、予測値を幅 0.2 の区間に分け、区間ごとに悪性の割合を求めたものである。予測値が確率なら、点は灰の破線の上に乗るはずである。実際には、予測値が 0.2 を下回ると割合はほぼ 0 に、0.8 を超えるとほぼ 1 に張り付く。予測値が 1 を超えた 68 件では悪性の割合が 100%、0 を下回った 110 件では 0% であった。図 6 (a) の人工データと同じ形になっている。予測値 1.3 は「悪性の確率 130%」を意味しない。判別方向の上で、悪性の群の奥のほうにあるというだけである。予測値は並べ替えやしきい値で切るためのスコアとしては使えるが、確率としては読めない。




図 8: 0/1 の回帰の予測値の区間(幅 0.2)ごとの悪性の割合(5 件以上ある区間のみ)。灰の破線は、予測値が確率であれば点に乗る線

落とし穴：係数を 1 列ずつ読む

最後に、0/1 の回帰の係数を 1 列ずつ読むときの落とし穴を見る。悪性の細胞は核が大きいので、半径・周囲の長さ・面積の列は、どれも悪性の群のほうが平均が大きい。図 9 (a) のとおり、大きさを表す 6 列の群の平均の差 d_j はどれも正である。半径の平均では $d_j = 1.51$ (標準化した単位)である。ところが (b) の係数を見ると、半径の平均の係数は -0.77 と負になる。30 列全体では、11 列で係数の符号が平均の差の符号と逆である。

これは第 I 部の結果から説明できる。係数の向きは d ではなく $S_W^{-1}d$ であり、結果①で見たとおり、2 つの向きはほとんど直角であった。半径・周囲の長さ・面積のようにほぼ同じ情報を持つ列が並ぶと、 S_W^{-1} を掛けることで、似た列どうしの係数が打ち消し合う形になる。係数の 1 つ 1 つは「その列が悪性で大きいかな」を表すのではなく、30 列をまとめて 1 本のスコアに映すときの重みである。重みの組として初めて、群を最もよく分ける向きになる。列ごとに悪性との関係を読みたいときは、係数ではなく群の平均の差を見る。




図 9: 乳がんデータの細胞核の大きさを表す 6 列。(a) 群の平均の差(悪性 - 良性、標準化した単位)、(b) 30 列の 0/1 の回帰の係数(青が負)

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部から立てた予想は、このデータではすべて当たった。0/1 の回帰の係数は、平均の差とほとんど直角な判別方向を向き、半径 1 列や平均の差の向きより群をよく分けた。テストの行で測ると差は縮むが、順位は変わらない。しきい値は人数の少ない悪性の側へずれた。ただし 2 つの群が遠く離れているので、ずれは小さく、判定はほとんど変わらなかった。予測値は 0 と 1 の外へはみ出し、確率としては読めなかった。また、似た列が多いと、係数の符号が平均の差の符号と逆になる列が出る。係数は 1 列ずつ読まず、群を分ける向きの組として読む。

締め

まとめと次回への問い

本章の問いは、0/1 の目的変数に最小二乗法を当てたとき、係数の向きは何を指しているのか、であった。答えは、線形判別分析の判別方向 $\mathbf{S}_W^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$ である。 y が 0 と 1 しか取らないため、 $\mathbf{x}$ と y の共分散は群の平均の差 $\pi_0\pi_1\mathbf{d}$ になる。全体の共分散行列も、群の中の共分散行列と平均の差の分 $\pi_0\pi_1\mathbf{d}\mathbf{d}^\top$ に分かれる。第 2 項がいつも $\mathbf{d}$ の向きを向くので、正規方程式の解は $\mathbf{S}_W^{-1}\mathbf{d}$ の正の数倍になる。これはフィッシャーの基準を最大にする向きである。推定法は第 1 回と同じ最小二乗法のままで、答えを LDA の向きとして読める。第 1 回で推定法とモデルを分けて考えた理由の 1 つがここにある。違うのはしきい値だけである。0.5 で切る境界は人数の少ない群の側へずれ、人数が等しいときに限り中点で一致する。乳がんデータの 30 列でも、係数と判別方向のコサインは 1.0000000 であった。人数をそろえると、中点での予測値はちょうど 0.5 になった。一方、予測値は 0 と 1 の外へはみ出し(全件の 31%)、確率としては読めない。3 群以上では、指示行列の回帰で一度も選ばれない群が出るマスキングが起きる。

最後に、次回への問いを置く。0/1 の回帰は群を分ける向きを正しく出すが、確率を出さない。区間ごとの割合は 0 と 1 の間で曲がるのに、直線は曲がれないからである。最小二乗法は、データとモデルの距離を最小にする

だけで、データがどのように出てくるかを何も仮定していない。では、データの出方を確率で仮定すれば、向きと一緒に確率も出せるのだろうか。次回は、この問いから始める。