第 5 回 分類①：最小二乗法

0/1 に直線を当てると、判別の向きが出る

本章の問いは、第 4 回の締めで残った「0/1 の y に最小二乗法を当てるとどうなるか」である。0/1 の目的変数に最小二乗法をそのまま当てると、係数の向きは $\mathbf{S}_{\mathrm{W}}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$、すなわち線形判別分析（LDA）の判別方向に一致する。違うのはしきい値だけで、群の人数が等しければそれも一致する。ただし予測値は 0 と 1 の間に収まらず、確率としては読めない。

第 I 部　理論

0/1 に直線を当てる

第 4 回までの目的変数は、病気の進行度やリボフラビンの生産量のような連続の量だった。第 4 回の締めには、目的変数が 0 か 1 しか取らないときに同じ最小二乗法を当てると何が起きるか、という問いを残した。本章はこの問いから始める。

例として、乳がんの細胞の画像から測った値のデータ（第 II 部で詳しく述べる）を使う。569 件の細胞のそれぞれに、悪性か良性かの診断が付いている。悪性を $y = 1$、良性を $y = 0$ とおけば、目的変数は 0 と 1 だけの列になる。変数を細胞核の半径の平均 1 つにして横軸にとり、点を打つ。第 1 回と同じ最小二乗法で直線を当てはめたのが図 1 である。y の中身が 0 と 1 になっただけで、目的関数も解き方も第 1 回のままである。予測値 $\hat{y}$ が 0.5 以上なら悪性と判定すると、半径が 15.4 以上の細胞が悪性となる。判定が診断と一致した割合を正解率（accuracy）と呼ぶ。この判定の正解率は 88% である。直線は 0 と 1 の外へはみ出しているが、2 つの群を分けることはできている。ただし、この正解率は、当てはめに使った行で測った値である。新しい行での当たり方を知るには、第 2 回と同じく訓練・テスト分割が欠かせない。第 I 部では仕組みを見るため、手元の行はすでに分けた訓練の行とみなす。テストの行での当たり方は、第 II 部で測る。

ここから 3 つの困りごとが出てくる。1 つ目は、変数が 2 つ以上あるとき、どの向きに映せば群が分かれるかである。懐中電灯を当てる向きしだいで、壁に映る 2 つの影が重なったり離れたりするのと同じで、細長い 2 つの群は、横軸に映すと重なっても、別の向きに映せばよく分かれる。2 つ目は、群が 3 つ以上あるときである。3 つの群を、2 つの測定値から当てたいとすれば、0 か 1 かの目的変数では足りない。3 つ目は、予測値の読み方である。半径の最も大きい細胞では予測値が 1.77、最も小さい細胞では -0.34 になる。これを悪性の確率と読んでよいのだろうか。

変数が 1 つのとき、係数は正か負かの符号しか持たない。30 の変数をすべて使えば、係数は 30 次元のベクトル

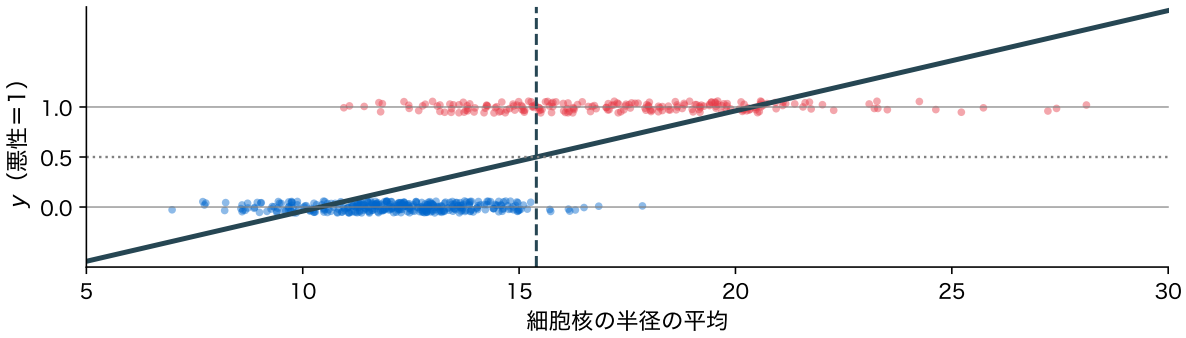


図 1: 乳がんデータの細胞核の半径の平均と診断（悪性＝ 1 が赤、良性＝ 0 が青。縦に少しずらして打った）。直線は最小二乗法、破線は予測値が 0.5 になる半径

になる。その向きは、どの変数の組み合わせで悪性と良性を分けるかを表す。本章の問いは 1 つである。0/1 の目的変数に最小二乗法を当てたとき、係数の向きは何を指しているのか。答えは、群の平均の差を群の中のばらつきで割った向き、すなわち線形判別分析の判別方向である。本章は 2 周で進む。前半では、例と図で答えまで一周する。群の割合・平均と共分散行列を定義し、判別方向を見る。LDA は、群の広がりで測った距離（マハラノビス距離）で近い群へ分ける方法とも読める。次に、0/1 の回帰の係数が判別方向に一致すること、列が似ているときは第 4 回の罰則を足せばよいこと、しきい値だけが群の人数の比でずれることを見る。ずれた境界は少ない群を見逃しやすく、それは正解率には映らないので、再現率と適合率を定義する。3 群以上は指示行列の回帰で分けられるが、群が一直線に並ぶと選ばれない群が出る。そして、方向は出ても確率は出ない。後半では、分類を考えるうえで欠かせない 2 つの点、すなわち、最もよく分ける向きと 0/1 の回帰の係数の向きに戻って、式と図で導く。

「モデル × 推定法」の地図でいえば、推定法は第 1 回と同じ最小二乗法のまま、答えの読み方が線形回帰から線形判別分析（linear discriminant analysis）（LDA）に変わる。第 1 回の表で LDA の行の最小二乗法の列に「第 5 回」と書いたのがこのマスである。第 4 回では推定法の列が増えたが、本章ではモデルの行が変わる。

群の量：割合・平均・共分散行列

0/1 の目的変数によって、データの行は 2 つの群に分かれる。本章では、群ごとの割合・平均・ばらつきを使う。群 q（$q = 0, 1$）の行の数を n_q とし、群の割合と群の平均を

$$\pi_q = \frac{n_q}{n}, \qquad \boldsymbol{\mu}_q = \frac{1}{n_q} \sum_{y_i = q} \boldsymbol{x}_i$$

とおく。群の平均は、群 q の行だけで列ごとに平均をとったベクトルである。全体の平均は、和を群ごとに分けると

$$\bar{\boldsymbol{x}} = \frac{1}{n} \sum_{i=1}^{n} \boldsymbol{x}_i = \frac{n_0 \boldsymbol{\mu}_0 + n_1 \boldsymbol{\mu}_1}{n} = \pi_0 \boldsymbol{\mu}_0 + \pi_1 \boldsymbol{\mu}_1 \tag{1}$$

となり、群の平均を群の割合で重み付けした平均になる。図 2 は 1 変数の人工データの例で、群 0（$y=0$）150 点と群 1（$y=1$）30 点の測定値 x を描いた。人数の多い群 0 の側に、全体の平均が寄っている。

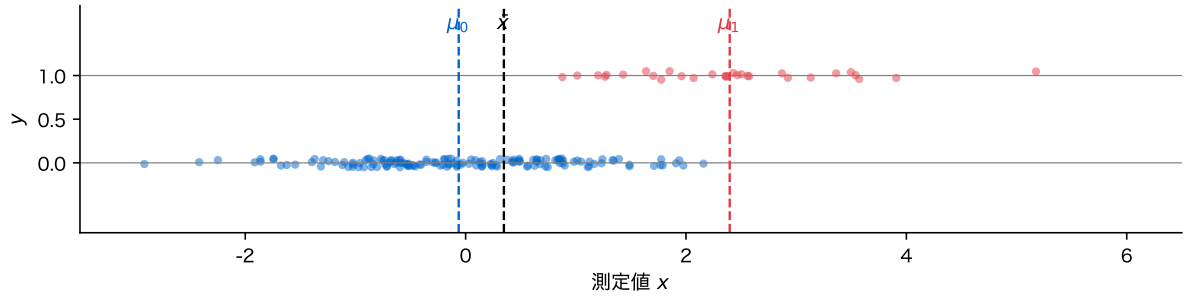


図 2: 1 変数・2 群の人工データ（群 0 $y=0$ が青、群 1 $y=1$ が赤。縦に少しずらして打った）。破線は群の平均 μ_0, μ_1 と全体の平均 $\bar{x}$

ばらつきは共分散行列で表す。第 1・2 回では、列 j の分散と、列 j と列 l の共分散を

$$s_j^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_{ij}-\bar{x}_j)^2, \qquad s_{jl} = \frac{1}{n-1}\sum_{i=1}^{n}(x_{ij}-\bar{x}_j)(x_{il}-\bar{x}_l)$$

と、$n-1$ で割って定義した。本章では、群の割合 π_q と式がそのままつながるように、n で割る。係数の向きや判定は、n で割っても $n-1$ で割っても変わらない。変わるのは、後で出る D^2 などの値の目盛りだけである。

縦ベクトルに横ベクトルを掛けると、行列ができる。$\boldsymbol{r} = [r_1, \dots, r_p]^\top$ について、内積（第 1 回）は 1 つの数だが、順を逆にすると $p \times p$ の行列になる。

$$\boldsymbol{r}^\top \boldsymbol{r} = \sum_{j=1}^{p} r_j^2, \qquad (\boldsymbol{r}\boldsymbol{r}^\top)_{jl} = r_j r_l$$

定義 1 (共分散行列)**.** $\mathbf{X}_{\mathrm{c}}$ を、各列から平均を引いたデータ行列とする。

$$\mathbf{S}_{\mathrm{T}} = \frac{1}{n}\sum_{i=1}^{n}(\boldsymbol{x}_i-\bar{\boldsymbol{x}})(\boldsymbol{x}_i-\bar{\boldsymbol{x}})^\top = \frac{1}{n}\mathbf{X}_{\mathrm{c}}^\top \mathbf{X}_{\mathrm{c}}$$

を全体の共分散行列と呼ぶ。その (j,l) 成分は列 j と列 l の共分散、対角成分は各列の分散である。自分の群の平均から測った

$$\mathbf{S}_{\mathrm{W}} = \frac{1}{n}\sum_{q=0}^{1}\sum_{y_i=q}(\boldsymbol{x}_i-\boldsymbol{\mu}_q)(\boldsymbol{x}_i-\boldsymbol{\mu}_q)^\top$$

を、群の中の共分散行列、または群内共分散行列（within-class covariance matrix）と呼ぶ。

$\mathbf{S}_{\mathrm{T}}$ も $\mathbf{S}_{\mathrm{W}}$ も、$\boldsymbol{r}\boldsymbol{r}^{\top}$ の和なので対称である。以下しばらく、$\mathbf{S}_{\mathrm{W}}$ は正定値(第 4 回)、すなわち

$$\boldsymbol{v}^{\top}\mathbf{S}_{\mathrm{W}}\boldsymbol{v} > 0 \qquad (\boldsymbol{v} \neq 0)$$

であるとする。このとき $\mathbf{S}_{\mathrm{W}}^{-1}$ がある。列が重なるときは、後の節で扱う。図の楕円は群の中の広がりを表し、2 群とも同じ形に作ってある。$\mathbf{S}_{\mathrm{W}}$ を群の広がりの楕円として読めるのは、このように 2 群の広がりが同じ形のときである。

LDA の判別方向

2 つの群を分けるには、何を決めればよいか。最も素朴な線形の分け方は次のとおりである。各行を向き $\boldsymbol{w}$ に映したスコア $z = \boldsymbol{w}^{\top}\boldsymbol{x}$ を作り、しきい値 c 以上なら群 1、未満なら群 0 と判定する。$\boldsymbol{w}^{\top}\boldsymbol{x} = c$ を満たす点の集まりは $\boldsymbol{w}$ に直角な直線(p 次元では平面)であり、これが 2 つの群の境界になる。決めるべきものは、向き $\boldsymbol{w}$ としきい値 c の 2 つである。

スコアの群の平均と、その差は

$$\bar{z}_q = \boldsymbol{w}^{\top}\boldsymbol{\mu}_q, \qquad \bar{z}_1 - \bar{z}_0 = \boldsymbol{w}^{\top}\boldsymbol{d} \qquad (\boldsymbol{d} = \boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$$

である。$\boldsymbol{w}$ はどの行でも同じなので、和の外に出した。スコアの群の中のばらつきは、$(\boldsymbol{w}^{\top}\boldsymbol{r})^2 = \boldsymbol{w}^{\top}\boldsymbol{r}\boldsymbol{r}^{\top}\boldsymbol{w}$ を足して $\boldsymbol{w}$ を和の外に出すと

$$\frac{1}{n}\sum_{q}\sum_{y_i=q}\left(\boldsymbol{w}^{\top}\boldsymbol{x}_i - \boldsymbol{w}^{\top}\boldsymbol{\mu}_q\right)^2 = \boldsymbol{w}^{\top}\mathbf{S}_{\mathrm{W}}\boldsymbol{w}$$

となる。これをスコアの群内分散(within-class variance)と呼ぶ。一方、群の平均が全体の平均 $\bar{\boldsymbol{x}} = \pi_0\boldsymbol{\mu}_0 + \pi_1\boldsymbol{\mu}_1$ のまわりにどう散らばるかを、群の割合で重みをつけて測った行列

$$\mathbf{S}_{\mathrm{B}} = \sum_{q=0}^{1}\pi_q(\boldsymbol{\mu}_q - \bar{\boldsymbol{x}})(\boldsymbol{\mu}_q - \bar{\boldsymbol{x}})^{\top}$$

を、群間共分散行列(between-class covariance matrix)と呼ぶ。$\pi_0 + \pi_1 = 1$ から $\boldsymbol{\mu}_0 - \bar{\boldsymbol{x}} = -\pi_1\boldsymbol{d}$、$\boldsymbol{\mu}_1 - \bar{\boldsymbol{x}} = \pi_0\boldsymbol{d}$ なので

$$\mathbf{S}_{\mathrm{B}} = (\pi_0\pi_1^2 + \pi_1\pi_0^2)\boldsymbol{d}\boldsymbol{d}^{\top} = \pi_0\pi_1\,\boldsymbol{d}\boldsymbol{d}^{\top}$$

となり、2 群では $\mathbf{S}_{\mathrm{B}}$ はいつも $\boldsymbol{d}$ の向きだけを向く。群の平均を映したスコアの散らばり

$$\sum_{q=0}^{1}\pi_q\left(\boldsymbol{w}^{\top}\boldsymbol{\mu}_q - \boldsymbol{w}^{\top}\bar{\boldsymbol{x}}\right)^2 = \boldsymbol{w}^{\top}\mathbf{S}_{\mathrm{B}}\boldsymbol{w} = \pi_0\pi_1\left(\boldsymbol{w}^{\top}\boldsymbol{d}\right)^2$$

を、スコアの群間分散（between-class variance）と呼ぶ。

向きの候補としてまず思いつくのは、2 つの群の平均を結ぶ向き $\boldsymbol{d}$ である。だが、この向きがよいとは限らない。図 4 は、冒頭の困りごと①の人工データである。群 0（$y=0$）100 点と群 1（$y=1$）50 点について、2 つの測定値 x_1, x_2 を作った。群の中の共分散は 2 つの群で共通とした（分散 0.8、相関 0.95）。群は右上がりに細長く伸びている。(a)(b) のように $\boldsymbol{d}$ に映すと、細長い向きのばらつきまで拾ってしまい、2 つの山は大きく重なる。スコアの「群の平均の差 ÷ 群の中の標準偏差」は 1.44 である。

群をよく分ける向きとは、スコアの群間分散が大きく、しかも群内分散が小さい向きである。群間分散 $\boldsymbol{w}^\top \mathbf{S}_\mathrm{B} \boldsymbol{w}$ の $1/(\pi_0\pi_1)$ 倍を分子に、群内分散を分母においた比

$$J(\boldsymbol{w}) = \frac{(\boldsymbol{w}^\top \boldsymbol{d})^2}{\boldsymbol{w}^\top \mathbf{S}_\mathrm{W} \boldsymbol{w}} \tag{2}$$

を最大にすればよい。これはフィッシャー（1936）の基準であり、その平方根は「平均の差 ÷ 群の中の標準偏差」にあたる。$\boldsymbol{w}$ を a 倍しても分子と分母がともに a^2 倍になるので、J は $\boldsymbol{w}$ の向きだけで決まる。

図 3 は、向き $\boldsymbol{w}$ を角度で半周させながら J を描いたものである。J の山は、平均の差の向き $\boldsymbol{d}$ ではなく

$$\boldsymbol{w} \propto \mathbf{S}_\mathrm{W}^{-1} \boldsymbol{d} \tag{3}$$

の向きにある（$\propto$ は「0 でない数倍を除いて等しい」の意味。導き方は「なぜ①」の節）。J は $\boldsymbol{w}$ の符号によらないので、$\boldsymbol{w}^\top \boldsymbol{d} > 0$ となる側を選ぶ。$p=1$ なら $w \propto d/s_\mathrm{W}^2$ で、向きは平均の差の符号だけで決まる。

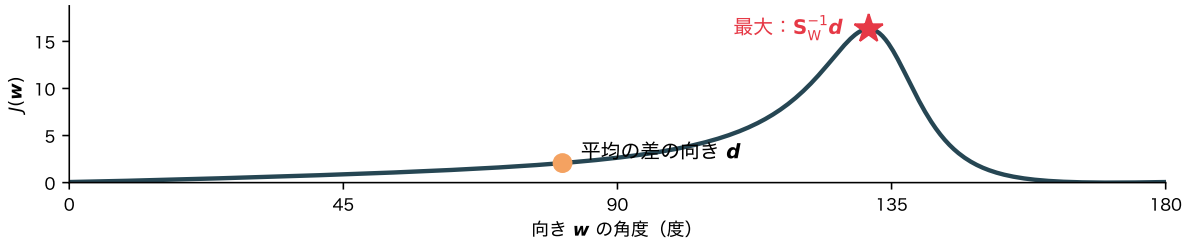


図 3: 向き $\boldsymbol{w}$ の角度に対するフィッシャーの基準 $J(\boldsymbol{w})$（人工データ）。橙の点は平均の差の向き、★は最大の向き $\mathbf{S}_\mathrm{W}^{-1}\boldsymbol{d}$

定義 2（フィッシャーの線形判別）**.** 2 群のデータについて、(2) 式を最大にする向き $\boldsymbol{w} \propto \mathbf{S}_\mathrm{W}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$ を判別方向（discriminant direction）と呼ぶ。スコア $\boldsymbol{w}^\top \boldsymbol{x}$ をしきい値で切って群を分ける方法を線形判別分析（LDA）と呼ぶ。しきい値の素朴な選び方は、2 つの群の平均の中点 $(\boldsymbol{\mu}_0 + \boldsymbol{\mu}_1)/2$ を通る境界である。

図 4 (c)(d) は、同じデータを $\mathbf{S}_\mathrm{W}^{-1}\boldsymbol{d}$ に映したものである。矢印は平均の差の向きから大きく回っている。群が細く締まっている向きを使うので、2 つの山は離れる。「平均の差 ÷ 群の中の標準偏差」は 4.04 になり、$\boldsymbol{d}$ の向きの 1.44 を大きく上回る。$\mathbf{S}_\mathrm{W}^{-1}$ を掛けることは、群の中のばらつきの大きい向きを割り引き、小さい向きを重んじることにあたる。

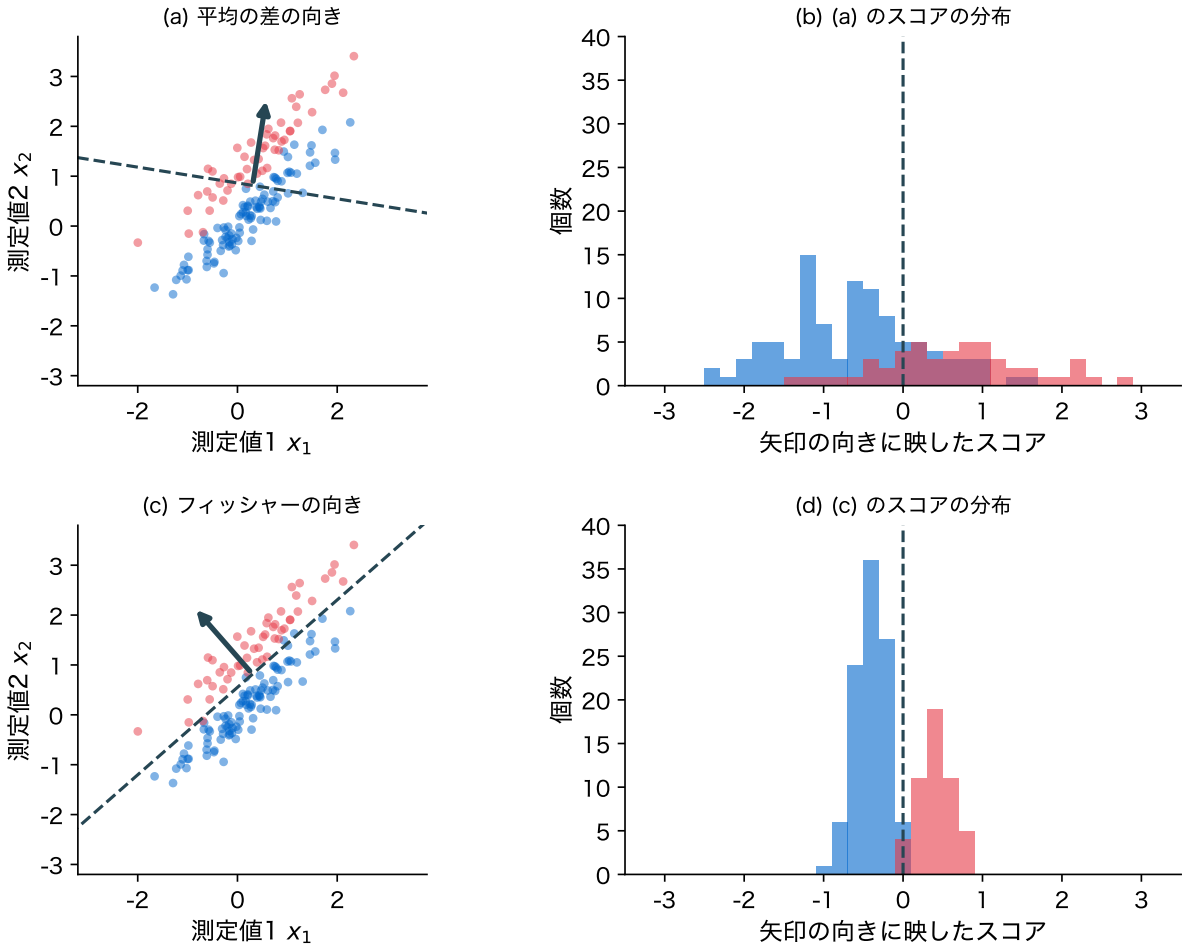


図 4: 2 変数・2 群の人工データ（$y = 0$ が青、$y = 1$ が赤）。(a)(b) 平均の差の向き $\boldsymbol{d}$ に映したとき、(c)(d) フィッシャーの向き $\mathbf{S}_{\mathrm{W}}^{-1}\boldsymbol{d}$ に映したとき。矢印が向き、破線が中点を通る境界。(b)(d) は映したスコアの分布

判別方向は、群の平均と群の中の共分散行列から直接計算できる。では、0/1 の目的変数に最小二乗法を当てたときの係数は、どの向きを向くのだろうか。

マハラノビス距離：近い群の平均へ

LDA には、もう 1 つの読み方がある。中点を通る境界で切ることは、新しい点を「近い方の群の平均」に分けることに見える。では、どんな距離で測ればそうなるのだろうか。

ふつうの距離（ユークリッド距離）で近い平均へ分けると、境界は 2 つの平均を結ぶ線分の垂直二等分線になる。これは平均の差の向き $\boldsymbol{d}$ に映して中点で切るのと同じで、図 4 (a)(b) のように細長い山が重なる。群の広がりが向きによって違うのに、どの向きにも同じ物差しを当てているからである。そこで、群の広がりを単位にして距離を測る。

定義 3 (マハラノビス距離)**.** 点 $\boldsymbol{x}$ と群の平均 $\boldsymbol{\mu}_q$ について、

$$\Delta^2(\boldsymbol{x}, \boldsymbol{\mu}_q) = (\boldsymbol{x} - \boldsymbol{\mu}_q)^\top \mathbf{S}_{\mathrm{W}}^{-1} (\boldsymbol{x} - \boldsymbol{\mu}_q) \tag{4}$$

の平方根 Δ をマハラノビス距離(Mahalanobis distance)と呼ぶ。

$p = 1$ なら (4) 式は $(x - \mu_q)^2 / s_{\mathrm{W}}^2$ で、群の中の標準偏差の何個ぶん離れているかの二乗である。第 2 回の標準化と同じ考え方である。列どうしが無相関なら $\mathbf{S}_{\mathrm{W}}$ は対角行列で、(4) 式は列ごとに群の中の標準偏差で割った距離の二乗和になる。列どうしに相関があると、群が細長く伸びた向きの 1 歩は小さく、締まった向きの 1 歩は大きく数えられる。等しい距離の点の集まりは、群の広がりと同じ形の楕円になる(図 5)。たとえば★の点は、ふつうの距離では群 0 の平均まで 1.45、群 1 の平均まで 1.09 で、群 1 に近い。マハラノビス距離では群 0 まで 1.78、群 1 まで 5.17 で、群 0 に近い。群 1 はその向きには締まっていて、★は群 1 の広がりから大きく外れているからである。

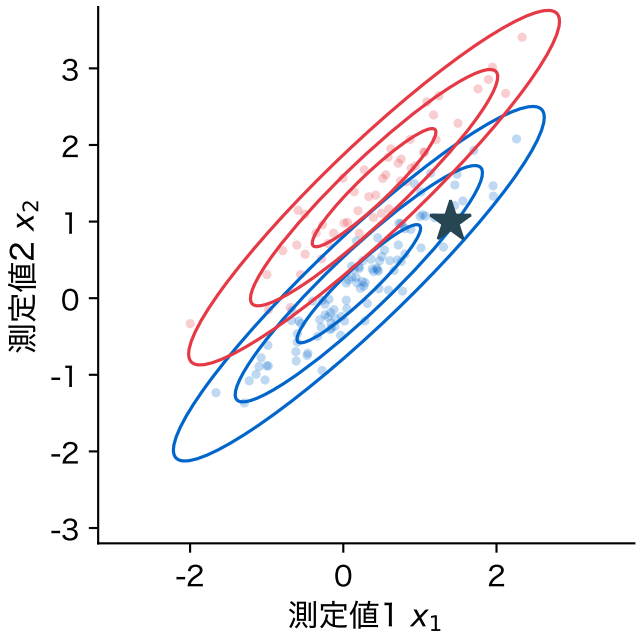


図 5: マハラノビス距離が 1・2・3 の楕円(人工データ。青が群 0、赤が群 1 の平均から)。★の点は、ふつうの距離では群 1 の平均に近いが、マハラノビス距離では群 0 の平均に近い

マハラノビス距離で近い群へ分けると、境界は LDA の境界と一致する。中点を $\boldsymbol{m} = (\boldsymbol{\mu}_0 + \boldsymbol{\mu}_1)/2$ とおくと、2 つの群の平均への距離の差は

$$\Delta^2(\boldsymbol{x}, \boldsymbol{\mu}_0) - \Delta^2(\boldsymbol{x}, \boldsymbol{\mu}_1) = 2\,(\mathbf{S}_{\mathrm{W}}^{-1}\boldsymbol{d})^\top (\boldsymbol{x} - \boldsymbol{m}) \tag{5}$$

となる。$\mathbf{A} = \mathbf{S}_{\mathrm{W}}^{-1}$ とおいて 2 つの 2 次形式を展開すると、$\boldsymbol{x}^\top \mathbf{A} \boldsymbol{x}$ の項は差をとると消え

$$\Delta^2(\boldsymbol{x}, \boldsymbol{\mu}_0) - \Delta^2(\boldsymbol{x}, \boldsymbol{\mu}_1) = 2\boldsymbol{x}^\top \mathbf{A}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0) - (\boldsymbol{\mu}_1^\top \mathbf{A} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_0^\top \mathbf{A} \boldsymbol{\mu}_0)$$

が残る。$\mathbf{A}$ は対称なので $\boldsymbol{\mu}_0^\top \mathbf{A} \boldsymbol{\mu}_1 = \boldsymbol{\mu}_1^\top \mathbf{A} \boldsymbol{\mu}_0$ であり、括弧の中は $(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)^\top \mathbf{A} (\boldsymbol{\mu}_1 + \boldsymbol{\mu}_0) = 2 \boldsymbol{d}^\top \mathbf{A} \boldsymbol{m}$ と書ける。まとめると (5) 式になる。図での読み方は「なぜ①」の節で述べる。左辺が 0 以上、すなわち群 1 の平均のほうが近いのは、判別方向 $\mathbf{S}_\mathrm{W}^{-1} \boldsymbol{d}$ のスコアが中点のスコア以上のときである。LDA は「群を最もよく分ける向きで切る方法」であり、同時に「群の広がりで測って近い群の平均へ分ける方法」でもある。

2 つの平均のマハラノビス距離の二乗

$$D^2 = \Delta^2(\boldsymbol{\mu}_1, \boldsymbol{\mu}_0) = \boldsymbol{d}^\top \mathbf{S}_\mathrm{W}^{-1} \boldsymbol{d} \tag{6}$$

は、群がどれだけ離れているかを、群の広がりを単位に測った物差しである。人工データでは $D = 4.04$ で、ふつうの距離 1.27 とは違う。D^2 は、フィッシャーの基準の最大値にも等しい(「なぜ①」の節)。

0/1 回帰の係数は LDA の向き

0/1 の目的変数に最小二乗法を当てるときの目的関数は

$$f(\beta_0, \boldsymbol{\beta}) = \| \boldsymbol{y} - \beta_0 \mathbf{1}_n - \mathbf{X} \boldsymbol{\beta} \|_2^2, \qquad \boldsymbol{y} \in \{0, 1\}^n \tag{7}$$

であり、第 1 回の目的関数と同じ形である。$\mathbf{1}_n$ は 1 が n 個並んだ縦ベクトルで、切片 β_0 を分けて書いた。違うのは $\boldsymbol{y}$ の中身だけで、各成分は 0 か 1 しか取らない。その係数は

$$\hat{\boldsymbol{\beta}} = \frac{\pi_0 \pi_1}{1 + \pi_0 \pi_1 D^2} \mathbf{S}_\mathrm{W}^{-1} \boldsymbol{d} \tag{8}$$

となる(D^2 は (6) 式。導き方は「なぜ②」の節)。$D^2 > 0$ なので前の係数は正であり、$\hat{\boldsymbol{\beta}}$ は判別方向 (3) 式と向きまで同じである。$p = 1$ では $\mathbf{S}_\mathrm{W}$ を s_W^2 と書くと $D^2 = d^2 / s_\mathrm{W}^2$ で、(8) 式は

$$\hat{\beta} = \frac{\pi_0 \pi_1 \, d}{s_\mathrm{W}^2 + \pi_0 \pi_1 d^2} \tag{9}$$

となる。図 2 の人工データでは $\hat{\beta} = 0.191$ で、直接当てはめた傾き 0.191 と一致する。

0/1 の目的変数に最小二乗法を当てたときの係数の向きは、フィッシャーの判別方向そのものである。最小二乗法は「データとモデルの距離を最小にする」だけで、群を分けることは何も求めていない。それでも y が 0 と 1 しか取らないために、y との共分散は平均の差になる。全体の共分散も、群内の共分散と群間の共分散に分かれる。その結果、係数は群を最もよく分ける向きに着く。この一致は代数の等式であり、群の広がりの形によらない。2 つの向きを比べるには、なす角のコサインを使う。

定義 4 (コサイン)**.** 0 でない 2 つのベクトル $\boldsymbol{a}, \boldsymbol{b}$ について、

$$\cos\theta = \frac{\boldsymbol{a}^\top \boldsymbol{b}}{\|\boldsymbol{a}\|_2 \, \|\boldsymbol{b}\|_2} \tag{10}$$

を 2 つのベクトルのなす角 θ のコサイン(cosine)と呼ぶ。

分子は第 1 回の内積、分母は 2 つのユークリッドノルムの積である。同じ向きなら 1、直角なら 0、逆向きなら -1 になり、どちらかを正の数倍しても値は変わらない。図 6 は、図 4 と同じ人工データの上で、0/1 の回帰の係数(橙の破線)を判別方向(黒)に重ねたものである。2 つの向きのコサインは 1.0000000 で、矢印は重なる。

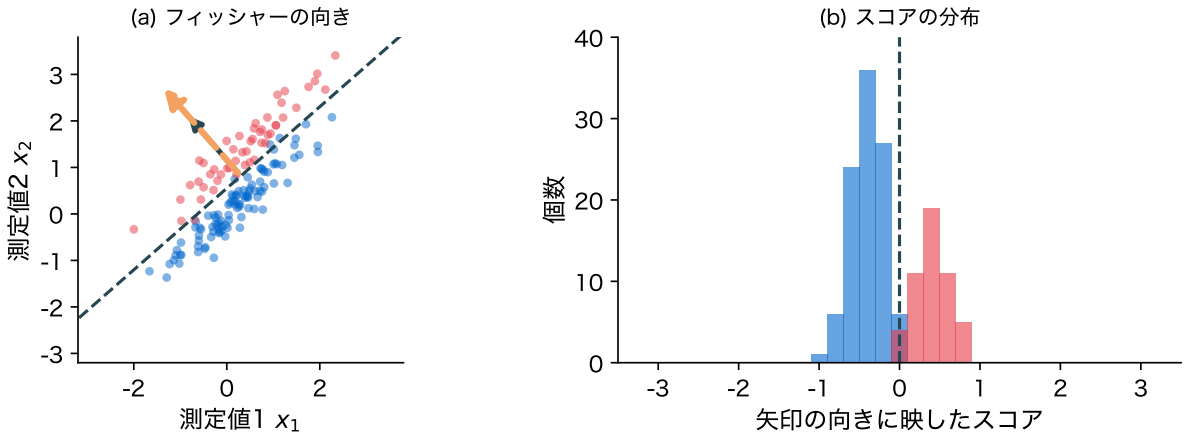


図 6: 図 4 と同じ人工データ。(a) フィッシャーの判別方向(黒の矢印)と、0/1 の回帰の係数の向き(橙の破線の矢印)、(b) 判別方向に映したスコアの分布

列が似ているとき：罰則を足した判別

判別方向 $\mathbf{S}_{\mathrm{W}}^{-1}\boldsymbol{d}$ にも、0/1 の回帰の正規方程式にも、逆行列が要る。第 3 回・第 4 回で見たとおり、列が完全に重なるか行より多いと逆行列は無く、似た列が多いと逆行列は不安定になる。そこで第 4 回の Ridge 回帰と同じく、0/1 の回帰に罰則を足す。本章では、罰則の強さを第 4 回の λ を n で割った値で表し、それを λ と書く。このとき係数は

$$\hat{\beta}_{\lambda} = \frac{\pi_0\pi_1}{1+\pi_0\pi_1 D_{\lambda}^2}\,(\mathbf{S}_{\mathrm{W}}+\lambda\mathbf{I})^{-1}\boldsymbol{d}, \qquad D_{\lambda}^2 = \boldsymbol{d}^{\top}(\mathbf{S}_{\mathrm{W}}+\lambda\mathbf{I})^{-1}\boldsymbol{d} \tag{11}$$

となる(導き方は「なぜ②」の節)。罰則なしの (8) 式の $\mathbf{S}_{\mathrm{W}}$ を、$\mathbf{S}_{\mathrm{W}}+\lambda\mathbf{I}$ に替えた形である。$\lambda>0$ なら $\mathbf{S}_{\mathrm{W}}+\lambda\mathbf{I}$ は正定値で、逆行列が必ずある。この向き $(\mathbf{S}_{\mathrm{W}}+\lambda\mathbf{I})^{-1}\boldsymbol{d}$ を、罰則を足した判別方向と呼ぶ。

λ は、2 つの向きをつなぐつまみである(図 7)。$\lambda=0$ なら判別方向 $\mathbf{S}_{\mathrm{W}}^{-1}\boldsymbol{d}$ である。λ が大きいと、λ を括り出して

$$(\mathbf{S}_{\mathrm{W}}+\lambda\mathbf{I})^{-1}\boldsymbol{d} = \frac{1}{\lambda}\Big(\mathbf{I}+\frac{\mathbf{S}_{\mathrm{W}}}{\lambda}\Big)^{-1}\boldsymbol{d} \approx \frac{1}{\lambda}\,\boldsymbol{d}$$

となり、平均の差の向きに近づく。$\mathbf{S}_{\mathrm{W}}/\lambda$ が $\mathbf{O}$ に近づき、括弧の逆行列が $\mathbf{I}$ に近づくからである。群の中の広がりをどこまで信じて割り引くかを、λ が決める。強さは、第 4 回と同じく交差検証で選べばよい。そのとき測る物差しは、二乗誤差でも、正しく判定できた割合(正解率)でもよい。

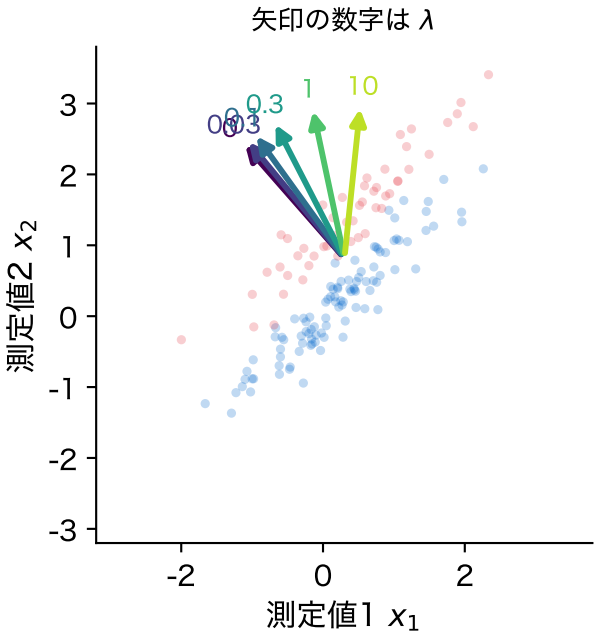


図 7: 罰則を足した判別方向 $(\mathbf{S}_{\mathrm{W}} + \lambda \mathbf{I})^{-1}\boldsymbol{d}$（人工データ）。矢印の数字は λ。$\lambda = 0$ の判別方向から、λ を大きくすると平均の差の向きへ回る

しきい値は人数の比でずれる

向きが同じなら、残る違いはしきい値 c だけである。0/1 の回帰で $\hat{y} \geq 1/2$ を群 1 とする境界は、LDA の中点を通る境界と一致するだろうか。

2 つの群の平均の中点 $\boldsymbol{m} = (\boldsymbol{\mu}_0 + \boldsymbol{\mu}_1)/2$ での予測値は

$$\hat{y}(\boldsymbol{m}) = \frac{1}{2} + \frac{(\pi_1 - \pi_0)(1 - \boldsymbol{d}^{\top}\hat{\boldsymbol{\beta}})}{2} \tag{12}$$

となる。切片 $\hat{\beta}_0 = \pi_1 - \bar{\boldsymbol{x}}^{\top}\hat{\boldsymbol{\beta}}$ を入れると $\hat{y}(\boldsymbol{m}) = \pi_1 + (\boldsymbol{m} - \bar{\boldsymbol{x}})^{\top}\hat{\boldsymbol{\beta}}$ であり、(1) 式と $\pi_0 + \pi_1 = 1$ から

$$\boldsymbol{m} - \bar{\boldsymbol{x}} = \Big(\frac{1}{2} - \pi_0\Big)\boldsymbol{\mu}_0 + \Big(\frac{1}{2} - \pi_1\Big)\boldsymbol{\mu}_1 = \frac{\pi_0 - \pi_1}{2}\,\boldsymbol{d}$$

である。$\pi_1 = \frac{1}{2} + \frac{\pi_1 - \pi_0}{2}$ と書き直すと (12) 式を得る。「なぜ②」の節で示すとおり $\boldsymbol{d}^{\top}\hat{\boldsymbol{\beta}}$ は 0 と 1 の間にあり、$1 - \boldsymbol{d}^{\top}\hat{\boldsymbol{\beta}} > 0$ である。したがって、群 1 が少ない（$\pi_1 < \pi_0$）と、中点での予測値は 1/2 より小さい。予測値が 1/2 に届くのは、中点から群 1 の側へ進んでからである。0.5 で切る境界は人数の少ない群の側へずれ、多い群の領域が広がる。

図 8 は 図 2 と同じ 1 変数の人工データに、0/1 の回帰の直線を引いたものである。群 1 は 30 個、群 0 は 150 個である。中点 1.17 での予測値は 0.323 で、(12) 式の値 0.323 に一致する。$\hat{y} = 0.5$ となる x は 2.09 で、中点より赤の群の側にある。

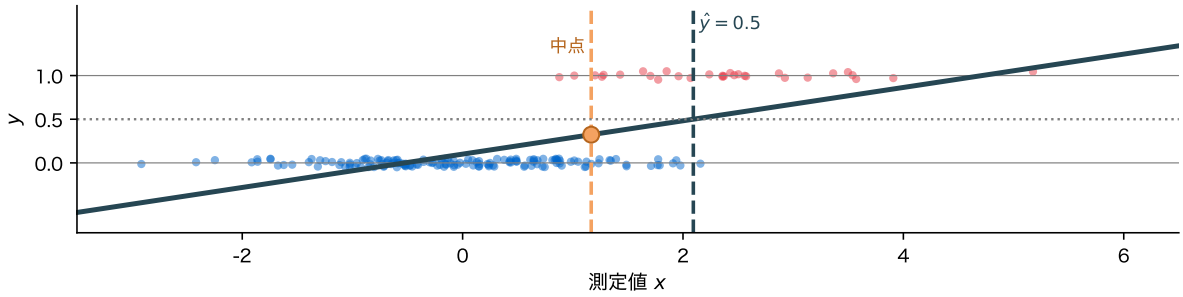


図 8: 図 2 と同じ人工データに当てた 0/1 の回帰の直線。橙の破線と丸は 2 つの群の平均の中点とそこでの予測値、黒の破線は予測値が 0.5 になる点

2 つの群の人数が等しいとき、すなわち $\pi_0 = \pi_1 = 1/2$ のときに限り、(12) 式の第 2 項は 0 になる。このとき 0.5 で切る境界は、中点を通る LDA の境界と一致する。まとめると、0/1 の最小二乗法と LDA の向きはいつも同じで、しきい値だけが人数の比でずれる。人数の比を境界にどう入れるべきかは、確率を考えて初めて決まる。

正解率だけでは見えないもの

しきい値のずれは、判定の良さをどう測るかという問題につながる。0.5 で切る境界は人数の少ない群 1 の側へずれるので、その分だけ群 1 の点を群 0 と判定しやすくなる。この見逃しは、正解率に映るだろうか。

極端な判定から始める。冒頭の 1 変数の人工データ(群 0 が 150 点、群 1 が 30 点)で、どの点も群 0 と判定したとする。群 1 を 1 つも拾えていないのに、正解率は $150/180 = 83\%$ になる。群の人数が偏っていると、多い群だけを当てても正解率は高い。

判定の結果は、本当の群と判定の組み合わせで 4 通りに分かれる。本当の群を行、判定を列にして数えた 2 行 2 列の表を、混同行列(confusion matrix)と呼ぶ。群 1 を群 1 と判定した数を TP、群 1 を群 0 と判定した数(見逃し)を FN、群 0 を群 1 と判定した数を FP、群 0 を群 0 と判定した数を TN と書く。正解率は $(TP + TN)/n$ である。群 1 のうち群 1 と判定できた割合

$$\text{再現率} = \frac{TP}{TP + FN}$$

を再現率(recall)と呼ぶ。群 1 と判定したうち本当に群 1 だった割合

$$\text{適合率} = \frac{TP}{TP + FP}$$

を適合率(precision)と呼ぶ。

表 1 は、同じデータを 3 通りの境界で判定した結果である。0.5 で切ると、正解率は 92.8% と 3 つの中で最も高い。ところが群 1 の 30 点のうち 12 点を見逃し、再現率は 60% にとどまる。2 つの群の平均の中点で切ると、見逃しは 2 点に減り、再現率は 93% に上がる。代わりに群 0 の 16 点を群 1 と判定するので、適合率は 95% から 64% に下がり、正解率も 90% に下がる。

表 1: 1 変数の人工データ（群 0 150 点・群 1 30 点）を 3 通りの境界で判定したときの正解率・再現率・適合率

境界	正解率	再現率	適合率
すべて群 0	83.3%	0%	—
0.5 で切る	92.8%	60%	95%
中点で切る	90.0%	93%	64%

正解率は、2 種類の誤りを同じ重さで数える。人数の少ない群を見逃しても、多い群で当てれば正解率は高いままである。病気の検査のように見逃しが重い場面では再現率を、誤った判定が重い場面では適合率を、正解率と並べて見る必要がある。どの境界がよいかは、データだけでは決まらず、どちらの誤りが重いかという問いで決まる。

計算の手順

計算の手順を行列で書くと、次のようになる。第 1 回の最小二乗法の手順に、y の作り方と最後の判定が加わるだけである。判定の良さは、第 2 回と同じく、当てはめに使っていないテストの行で測る。

1. 行を訓練とテストに分ける（訓練・テスト分割）。2 と 3 は訓練の行だけで行う
2. データ行列 $\mathbf{X}$（$n \times p$）と、0/1 の目的変数 $\boldsymbol{y}$ を作る。列の平均 $\bar{\boldsymbol{x}}$ を引いた $\mathbf{X}_{\mathrm{c}}$ と、$\bar{y} = \pi_1$ を引いた $\boldsymbol{y}_{\mathrm{c}}$ を作る
3. 正規方程式 $\mathbf{X}_{\mathrm{c}}^{\top}\mathbf{X}_{\mathrm{c}}\boldsymbol{\beta} = \mathbf{X}_{\mathrm{c}}^{\top}\boldsymbol{y}_{\mathrm{c}}$ を連立方程式として解く。(8) 式により、解の向きは判別方向 $\mathbf{S}_{\mathrm{W}}^{-1}\boldsymbol{d}$ である
4. 新しい行 $\boldsymbol{x}$ について、スコア $\hat{y} = \bar{y} + (\boldsymbol{x} - \bar{\boldsymbol{x}})^{\top}\hat{\boldsymbol{\beta}}$ を作り、$\hat{y} \geq 0.5$ なら群 1 と判定する
5. テストの行を判定し、正解率・再現率・適合率を数える

3 群以上：指示行列

冒頭の困りごと②、群が 3 つ以上ある場合に戻る。群が k 個（$k \geq 3$）あるときは、目的変数を指示行列 $\mathbf{Y}$（$n \times k$）にかえる。行 i の属する群の列だけが 1 で、ほかは 0 の行列である。$\mathbf{Y}$ の k 本の列のそれぞれを目的変数として正規方程式を解き、係数を横に並べると、係数の行列 $\mathbf{B}$（$p \times k$）が得られる。列の平均を並べた $\bar{\boldsymbol{y}} = (\pi_0, \ldots, \pi_{k-1})^{\top}$ は群の割合で、$\mathbf{Y}_{\mathrm{c}} = \mathbf{Y} - \mathbf{1}\bar{\boldsymbol{y}}^{\top}$ とおくと、正規方程式と新しい行の予測値（$1 \times k$）は

$$\mathbf{X}_{\mathrm{c}}^{\top}\mathbf{X}_{\mathrm{c}}\hat{\mathbf{B}} = \mathbf{X}_{\mathrm{c}}^{\top}\mathbf{Y}_{\mathrm{c}}, \qquad \hat{\boldsymbol{y}}^{\top} = \bar{\boldsymbol{y}}^{\top} + (\boldsymbol{x} - \bar{\boldsymbol{x}})^{\top}\hat{\mathbf{B}}$$

になる。係数行列 $\mathbf{X}_{\mathrm{c}}^{\top}\mathbf{X}_{\mathrm{c}}$ は k 本に共通である。予測値の最大の成分の群を選ぶ。

予測値の和はいつも 1 になる。指示行列の各行の和は 1 で、群の割合の和も 1 なので

$$\mathbf{Y}\mathbf{1}_k = \mathbf{1}_n, \qquad \mathbf{Y}_c\mathbf{1}_k = \mathbf{1}_n - \mathbf{1}_n(\bar{\boldsymbol{y}}^\top \mathbf{1}_k) = 0$$

である。正規方程式の右辺に $\mathbf{1}_k$ を掛けると 0 になるので $\hat{\mathbf{B}}\mathbf{1}_k = 0$ であり、$\bar{\boldsymbol{y}}^\top \mathbf{1}_k = 1$ と合わせて

$$\hat{\boldsymbol{y}}^\top \mathbf{1}_k = \bar{\boldsymbol{y}}^\top \mathbf{1}_k + (\boldsymbol{x} - \bar{\boldsymbol{x}})^\top \hat{\mathbf{B}}\mathbf{1}_k = 1$$

を得る。$k = 2$ なら 2 つの予測値の和が 1 なので、最大の列を選ぶことは群 1 の予測値が 0.5 以上で切ることと同じである。

図 9 は、冒頭の困りごと②の人工データ（困りごと①の群 0 100 点・群 1 50 点に、群 2 60 点を足したもの）に指示行列の回帰を当て、最大の列を選んだ領域を塗ったものである。3 つの群はきれいに分かれ、正解率は 97% になった。指示行列は、3 択の質問を「群 0 か」「群 1 か」「群 2 か」という 3 つのはい・いいえの質問に分けたものと読める。

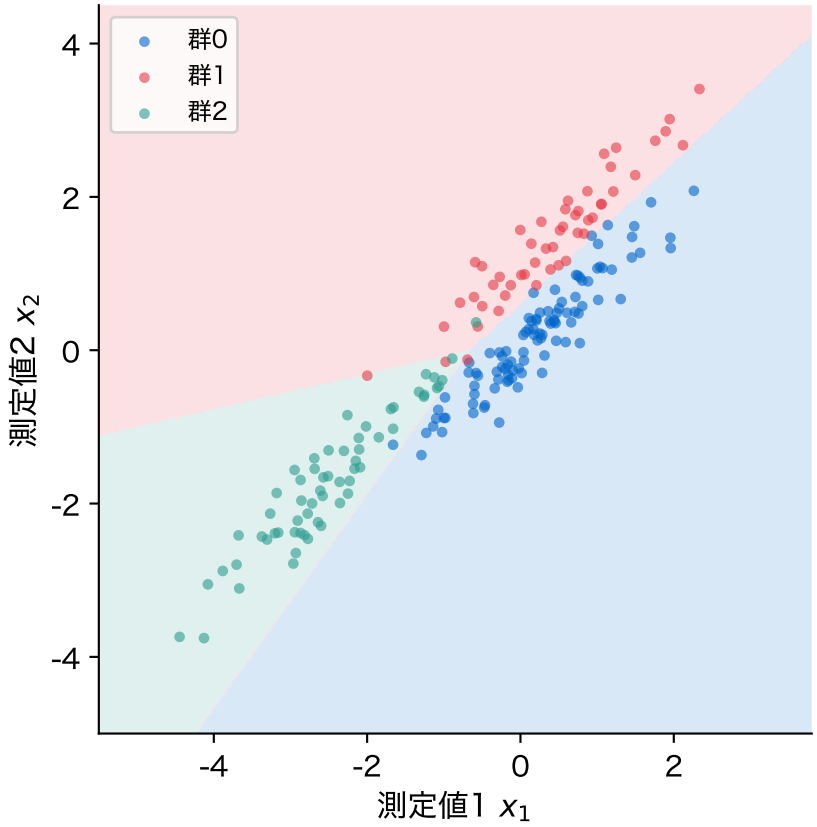


図 9: 3 群（群 0 100 点・群 1 50 点・群 2 60 点）の人工データに指示行列の回帰を当て、予測値が最大の群の領域を淡い色で塗ったもの

ただし、群の並び方によっては困ることがある。図 10 は、1 変数 x だけで、群 0・群 1・群 2（平均 −3、0、3、標準偏差 0.8、各 60 点）を当てようとした人工データに、指示行列の回帰を当てたものである。列 q ごとの傾きは、「なぜ②」の節で正規方程式の右辺を求めたのと同じ計算を列ごとに行うと

$$\hat{\beta}_q = \frac{\pi_q(\mu_q - \bar{x})}{s_{\mathrm{T}}^2}$$

である（s_{T}^2 は x の分散）。両端の群の直線は傾くが、真ん中の群の平均は全体の平均にほぼ等しいので、その直線はほぼ平ら（傾き 0.004）になる。また、どの直線も $x = \bar{x}$ で π_q を通り、人数が等しいこの例では、3 本は $(\bar{x}, 1/3)$ の 1 点で交わる。真ん中の直線の傾きはほかの 2 本の傾きの間にあるので、交点の左では左の群の直線が、右では右の群の直線が上にあり、真ん中の群が最大になる場所は無い。180 点のうち群 0・群 1・群 2 と判定されたのは、それぞれ 88・0・92 点である。

定義 5 (マスキング)**.** 3 群以上の指示行列を最小二乗法で回帰して最大の列を選ぶとき、ある群の予測値がどこでもほかの群を上回らず、その群が一度も選ばれないことをマスキング（masking）と呼ぶ。

同じデータでも、群を 2 つずつ比べるマハラノビス距離で最も近い群の平均へ分ければ、真ん中の群も分けられる。最適スコアリング（Hastie–Tibshirani–Buja, 1994）は、指示行列の列に得点を割り当て直して回帰し、得点と係数をともに最適化する方法で、マスキングを避けられる。本講義ではこれ以上は扱わない。

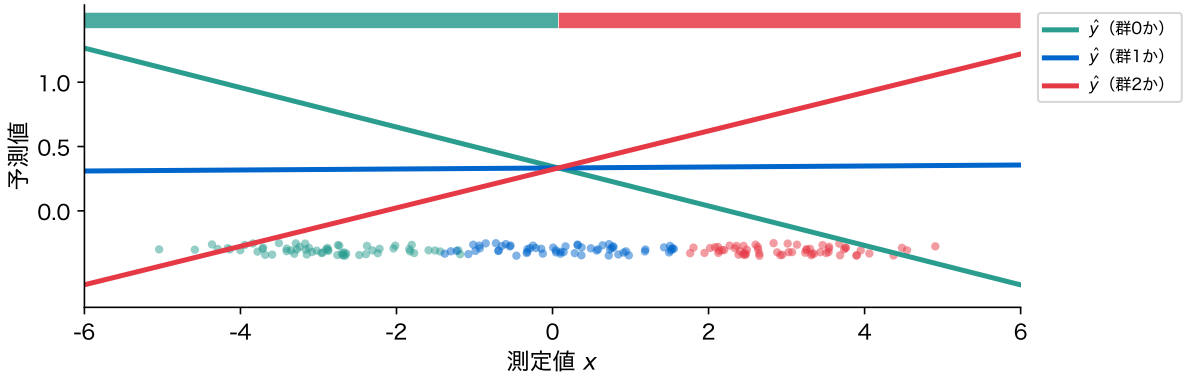


図 10: 1 変数に一直線に並んだ 3 群の指示行列の回帰（人工データ）。上の帯は予測値が最大の群で、真ん中の群 1（青）はどこでも選ばれない

方向は出るが、確率は出ない

0/1 の回帰は判別方向を正しく出すが、予測値は 0 と 1 の間に収まらない。最小二乗法が近づこうとするのは、$\boldsymbol{x}$ ごとの y の平均、つまり $y = 1$ の割合である。割合は 0 と 1 の間にあるが、$\boldsymbol{x}$ の 1 次式は $\boldsymbol{x}$ を遠くへ動かせばいくらでも大きく、あるいは小さくなる。図 11 は 図 2 と同じ人工データである。x を幅 1 の区間に分け、区間ごとの $y = 1$ の割合を黒の四角で示した。割合は左で 0 に、右で 1 に張り付く。直線はそれを追えず、左端では-0.57、右端では 1.34 まで伸びる。予測値が -0.57 の点を「確率-57%」と読むことはできない。0/1 の回帰の予

測値は、群を分けるためのスコアであって、確率ではない。冒頭の困りごと③で見た予測値 1.77 も、悪性の確率が 177% という意味ではない。

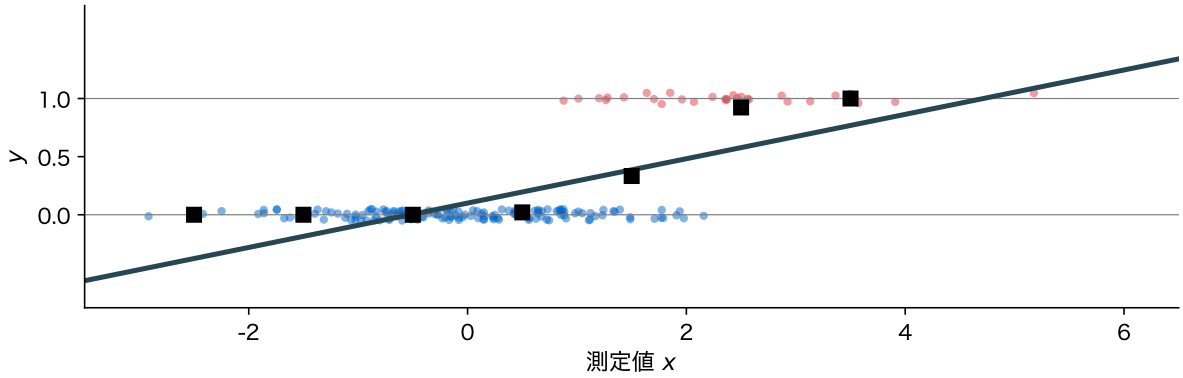


図 11: 0/1 の回帰の直線と、x の区間ごとの $y = 1$ の割合(黒の四角)。図 2 と同じ人工データ

得られるのは方向であって、確率ではない。

なぜ①：J を最大にする向き

ここまでで、本章の問いに答えを一周した。ここからは、前半で結果だけを示した点のうち、2 つに戻って式で導く。1 つ目は、フィッシャーの基準 (2) 式を最大にする向きが、なぜ $\mathbf{S}_{\mathrm{W}}^{-1}\boldsymbol{d}$ なのか、である。

J の勾配を求める。導出には、次の 4 つの道具を使う。

定義 6 (ベクトルで微分する)**.** ベクトル $\boldsymbol{d}$ と対称行列 $\mathbf{A}$ について

$$\frac{\partial \boldsymbol{w}^{\top}\boldsymbol{d}}{\partial \boldsymbol{w}} = \boldsymbol{d}, \qquad \frac{\partial \boldsymbol{w}^{\top}\mathbf{A}\boldsymbol{w}}{\partial \boldsymbol{w}} = 2\mathbf{A}\boldsymbol{w}$$

が成り立つ(第 3 回)。

定義 7 (合成関数の微分)**.** u が $\boldsymbol{w}$ で決まる 1 つの数で、g が 1 変数の関数のとき

$$\frac{\partial g(u)}{\partial \boldsymbol{w}} = g'(u)\,\frac{\partial u}{\partial \boldsymbol{w}}$$

が成り立つ。

定義 8 (割り算の微分)**.** u, v が $\boldsymbol{w}$ で決まる数で $v \neq 0$ のとき

$$\frac{\partial}{\partial \boldsymbol{w}}\,\frac{u}{v} = \frac{1}{v^2}\left(v\,\frac{\partial u}{\partial \boldsymbol{w}} - u\,\frac{\partial v}{\partial \boldsymbol{w}}\right)$$

が成り立つ。1 変数の $(u/v)' = (u'v - uv')/v^2$ と同じ形である。

定義 9 (最大の点の勾配)**.** 微分できる関数 J が、0 でない数 c について $J(c\boldsymbol{w}) = J(\boldsymbol{w})$ を満たし、向きだけで値が決まるとする。J は長さ 1 の $\boldsymbol{w}$ のどこかで最大の値をとり、それは 0 でないすべての $\boldsymbol{w}$ の中での最大でもある。最大の点では、どの向きに動いても値は増えないので、勾配は 0 になる。

分子は u^2（$u = \boldsymbol{w}^\top \boldsymbol{d}$)なので、定義 7 で $g(u) = u^2$ とし、中身の勾配に 定義 6 の 1 つ目を使って

$$\frac{\partial (\boldsymbol{w}^\top \boldsymbol{d})^2}{\partial \boldsymbol{w}} = 2(\boldsymbol{w}^\top \boldsymbol{d})\, \boldsymbol{d}$$

である。$\mathbf{S}_\mathrm{W}$ は $\boldsymbol{r}\boldsymbol{r}^\top$ の和で対称なので、定義 6 の 2 つ目から、分母の勾配は

$$\frac{\partial \boldsymbol{w}^\top \mathbf{S}_\mathrm{W} \boldsymbol{w}}{\partial \boldsymbol{w}} = 2\mathbf{S}_\mathrm{W} \boldsymbol{w}$$

である。定義 8 に入れると

$$\frac{\partial J}{\partial \boldsymbol{w}} = \frac{2(\boldsymbol{w}^\top \boldsymbol{d})\boldsymbol{d} \cdot \boldsymbol{w}^\top \mathbf{S}_\mathrm{W} \boldsymbol{w} - (\boldsymbol{w}^\top \boldsymbol{d})^2 \cdot 2\mathbf{S}_\mathrm{W} \boldsymbol{w}}{(\boldsymbol{w}^\top \mathbf{S}_\mathrm{W} \boldsymbol{w})^2}$$

となる。$2(\boldsymbol{w}^\top \boldsymbol{d})/\boldsymbol{w}^\top \mathbf{S}_\mathrm{W} \boldsymbol{w}$ を括り出すと

$$\frac{\partial J}{\partial \boldsymbol{w}} = \frac{2(\boldsymbol{w}^\top \boldsymbol{d})}{\boldsymbol{w}^\top \mathbf{S}_\mathrm{W} \boldsymbol{w}} \left(\boldsymbol{d} - \frac{\boldsymbol{w}^\top \boldsymbol{d}}{\boldsymbol{w}^\top \mathbf{S}_\mathrm{W} \boldsymbol{w}} \mathbf{S}_\mathrm{W} \boldsymbol{w} \right)$$

である。これが 0 ベクトルになるのは、次の 2 つの場合に限る。1 つは $\boldsymbol{w}^\top \boldsymbol{d} = 0$ の向きで、そこでは $J = 0$ となって最小になる。もう 1 つは括弧の中が 0、すなわち $\mathbf{S}_\mathrm{W} \boldsymbol{w}$ が $\boldsymbol{d}$ のスカラー倍になる場合で、左から $\mathbf{S}_\mathrm{W}^{-1}$ を掛けると前半の (3) 式を得る。

定義 9 より、最大の点でも勾配は 0 である。したがって、$J > 0$ で勾配が 0 になる唯一の向き (3) 式が最大である。$\mathbf{S}_\mathrm{W}^{-1}$ も対称なので、そのときの値は

$$J(\mathbf{S}_\mathrm{W}^{-1} \boldsymbol{d}) = \frac{(\boldsymbol{d}^\top \mathbf{S}_\mathrm{W}^{-1} \boldsymbol{d})^2}{\boldsymbol{d}^\top \mathbf{S}_\mathrm{W}^{-1} \mathbf{S}_\mathrm{W} \mathbf{S}_\mathrm{W}^{-1} \boldsymbol{d}} = \boldsymbol{d}^\top \mathbf{S}_\mathrm{W}^{-1} \boldsymbol{d} = D^2$$

であり、2 つの平均のマハラノビス距離の二乗 (6) 式に等しい。

この答えは、図でも読める。$J(c\boldsymbol{w}) = J(\boldsymbol{w})$ なので、分母の群の中の広がりを $\boldsymbol{w}^\top \mathbf{S}_\mathrm{W} \boldsymbol{w} = 1$ にそろえて、分子の $(\boldsymbol{w}^\top \boldsymbol{d})^2$ を最大にすればよい。$\boldsymbol{w}$ の平面で、$\boldsymbol{w}^\top \mathbf{S}_\mathrm{W} \boldsymbol{w} = 1$ は楕円であり、$\boldsymbol{w}^\top \boldsymbol{d} = c$ は $\boldsymbol{d}$ に直角な直線である（図 12)。直線を外へずらしていくと、最後に楕円と接する。接する点では、楕円の勾配 $2\mathbf{S}_\mathrm{W} \boldsymbol{w}$ と直線の勾配 $\boldsymbol{d}$（定義 6)が同じ向きを向く。これが、勾配を 0 とおいて得た条件 $\mathbf{S}_\mathrm{W} \boldsymbol{w} \propto \boldsymbol{d}$ である。

もう 1 つの読み方は、前半の「楕円を円に直す」である。導出には、さらに次の 2 つの道具を使う。

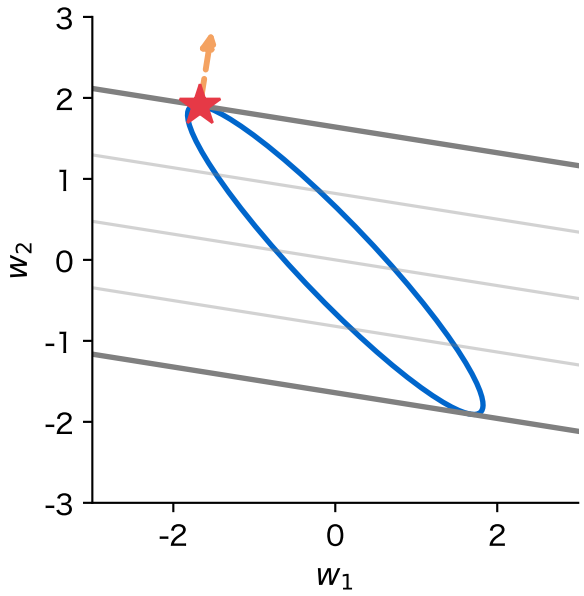


図 12: $\boldsymbol{w}$ の平面での楕円 $\boldsymbol{w}^\top \mathbf{S}_{\mathrm{W}} \boldsymbol{w} =$ 一定(青。大きさは見やすくそろえた)と直線 $\boldsymbol{w}^\top \boldsymbol{d} = c$ (灰)。接する点(★)で、楕円の勾配 $\mathbf{S}_{\mathrm{W}} \boldsymbol{w}$ (青の矢印)と $\boldsymbol{d}$ (橙の破線)が同じ向きになる(人工データ)

定義 10 (コサインは 1 以下)**.** ベクトル $\boldsymbol{v}, \boldsymbol{a}$ のなす角を θ とすると

$$\boldsymbol{v}^\top \boldsymbol{a} = \|\boldsymbol{v}\|_2 \, \|\boldsymbol{a}\|_2 \cos\theta, \qquad -1 \leq \cos\theta \leq 1$$

が成り立つ。前半の (10) 式を書き直したものである。長さを決めると、内積は同じ向きのときに最大になる。

定義 11 (積の逆行列)**.** 逆行列を持つ正方行列 $\mathbf{A}, \mathbf{B}$ について

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}, \qquad (\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top$$

が成り立つ。$\mathbf{AB}\,\mathbf{B}^{-1}\mathbf{A}^{-1} = \mathbf{I}$ から確かめられる。$(\mathbf{A}^{-1})^\top$ を $\mathbf{A}^{-\top}$ と書く。

$\mathbf{S}_{\mathrm{W}}$ は正定値なので、下三角の行列 $\mathbf{L}$ を使って $\mathbf{S}_{\mathrm{W}} = \mathbf{L}\mathbf{L}^\top$ と分けられる。各行に $\mathbf{L}^{-1}$ を掛けた $\boldsymbol{z} = \mathbf{L}^{-1}\boldsymbol{x}$ では、群の中の共分散行列が $\mathbf{L}^{-1}\mathbf{S}_{\mathrm{W}}\mathbf{L}^{-\top} = \mathbf{I}$ になり、群の広がりは円になる(図 13)。$\boldsymbol{v} = \mathbf{L}^\top \boldsymbol{w}$ とおくと

$$\boldsymbol{w}^\top \boldsymbol{x} = \boldsymbol{w}^\top \mathbf{L}\mathbf{L}^{-1}\boldsymbol{x} = \boldsymbol{v}^\top \boldsymbol{z}, \qquad \boldsymbol{w}^\top \mathbf{S}_{\mathrm{W}} \boldsymbol{w} = \boldsymbol{w}^\top \mathbf{L}\mathbf{L}^\top \boldsymbol{w} = \boldsymbol{v}^\top \boldsymbol{v}$$

であり、平均の差も $\boldsymbol{w}^\top \boldsymbol{d} = \boldsymbol{v}^\top \boldsymbol{d}_z$ ($\boldsymbol{d}_z = \mathbf{L}^{-1}\boldsymbol{d}$)となる。定義 10 から

$$J = \frac{(\boldsymbol{v}^\top \boldsymbol{d}_z)^2}{\boldsymbol{v}^\top \boldsymbol{v}} = \|\boldsymbol{d}_z\|_2^2 \cos^2\theta \;\leq\; \|\boldsymbol{d}_z\|_2^2$$

で、等号は $\boldsymbol{v} \propto \boldsymbol{d}_z$ のときに限る。円の世界では、群の中の広がりがどの向きでも同じなので、平均を結ぶ向きが最もよく分ける。最大値は $\|\boldsymbol{d}_z\|_2^2 = \boldsymbol{d}^\top \mathbf{L}^{-\top}\mathbf{L}^{-1}\boldsymbol{d} = D^2$ で、勾配から求めた値と一致する。もとの目盛りに戻すと、定義 11 から

$$\boldsymbol{w} = \mathbf{L}^{-\top}\boldsymbol{v} \propto \mathbf{L}^{-\top}\mathbf{L}^{-1}\boldsymbol{d} = (\mathbf{L}\mathbf{L}^\top)^{-1}\boldsymbol{d} = \mathbf{S}_{\mathrm{W}}^{-1}\boldsymbol{d}$$

である。判別方向は、群の広がりを円に直した世界で平均を結ぶ向きを、もとの目盛りに戻したものである。円の世界で近い平均へ分ける境界は、2 つの平均を結ぶ線分の垂直二等分線 $\boldsymbol{d}_z^\top(\boldsymbol{z} - \mathbf{L}^{-1}\boldsymbol{m}) = 0$ であり、もとの目盛りでは $(\mathbf{S}_{\mathrm{W}}^{-1}\boldsymbol{d})^\top(\boldsymbol{x} - \boldsymbol{m}) = 0$、すなわち LDA の境界になる。前半で見た「マハラノビス距離で近い平均へ分けると、境界は LDA と同じ」は、この図からも読める。

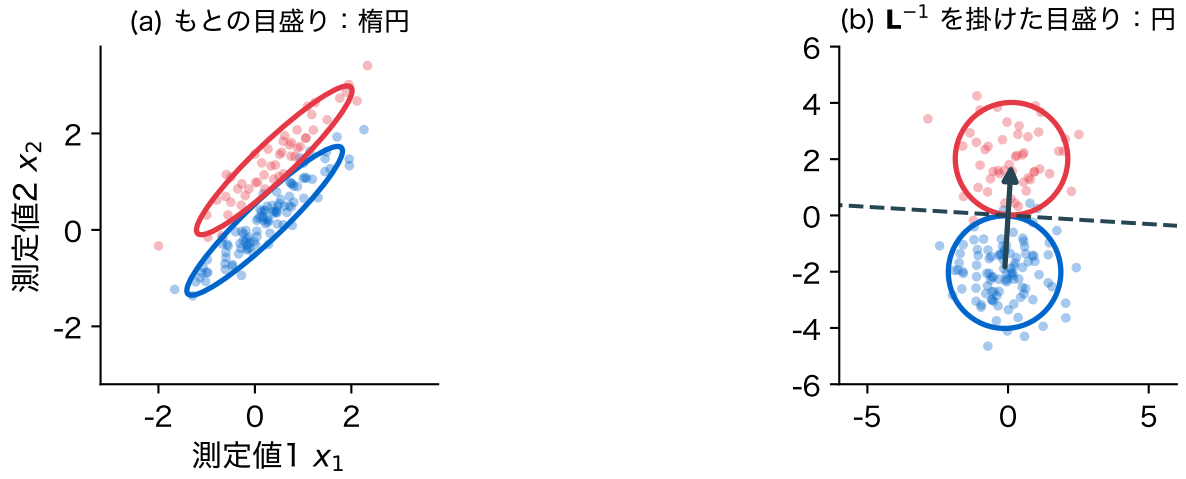


図 13: (a) もとの目盛りでの 2 つの群と、群の中の広がりの楕円。(b) 各点に $\mathbf{L}^{-1}$ を掛けると広がりは円になり、平均を結ぶ矢印の向きが最もよく分け、その垂直二等分線（破線）が近い平均へ分ける境界になる（人工データ）

なぜ②：0/1 回帰が LDA を向く

2 つ目は、0/1 の回帰の係数が、なぜ判別方向を向くのか、である。最小二乗法は、群を分けることを何も求めていない。それでも答えが判別方向になる理由は、全体の共分散行列を 2 つに分けると見えてくる。導出には、共分散行列の定義定義 1 と「なぜ①」の節の 定義 6 のほかに、次の 3 つの道具を使う。

定義 12 (縦 × 横の積の展開)**.** ベクトル $\boldsymbol{a}, \boldsymbol{b}$ について

$$(\boldsymbol{a} + \boldsymbol{b})(\boldsymbol{a} + \boldsymbol{b})^\top = \boldsymbol{a}\boldsymbol{a}^\top + \boldsymbol{a}\boldsymbol{b}^\top + \boldsymbol{b}\boldsymbol{a}^\top + \boldsymbol{b}\boldsymbol{b}^\top$$

が成り立つ。数の $(a+b)^2$ と違い、$\boldsymbol{a}\boldsymbol{b}^\top$ と $\boldsymbol{b}\boldsymbol{a}^\top$ は一般に別の行列である。

定義 13 (縦 × 横の積を掛ける)**.** 同じ長さのベクトル $\boldsymbol{a}, \boldsymbol{b}, \boldsymbol{v}$ について

$$(\boldsymbol{a}\boldsymbol{b}^\top)\,\boldsymbol{v} = (\boldsymbol{b}^\top \boldsymbol{v})\,\boldsymbol{a}, \qquad \boldsymbol{v}^\top \boldsymbol{a}\boldsymbol{a}^\top \boldsymbol{v} = (\boldsymbol{a}^\top \boldsymbol{v})^2 \geq 0$$

が成り立つ。$\boldsymbol{b}^\top \boldsymbol{v}$ と $\boldsymbol{a}^\top \boldsymbol{v}$ は 1 つの数なので、前に出せる。

定義 14 (ずれの和は 0)**.** 群 q の n_q 行について

$$\sum_{y_i = q} (\boldsymbol{x}_i - \boldsymbol{\mu}_q) = n_q \boldsymbol{\mu}_q - n_q \boldsymbol{\mu}_q = 0$$

が成り立つ。群の平均からのずれは、足すと 0 になる。

まず、(7) 式を β_0 で微分して 0 とおき、$\mathbf{1}_n^\top \boldsymbol{y} = n\bar{y}$、$\mathbf{1}_n^\top \mathbf{1}_n = n$、$\mathbf{1}_n^\top \mathbf{X} = n\bar{\boldsymbol{x}}^\top$ を入れて両辺を $-2n$ で割ると

$$\frac{\partial f}{\partial \beta_0} = -2\,\mathbf{1}_n^\top (\boldsymbol{y} - \beta_0 \mathbf{1}_n - \mathbf{X}\boldsymbol{\beta}) = 0 \quad \Longrightarrow \quad \hat{\beta}_0 = \bar{y} - \bar{\boldsymbol{x}}^\top \boldsymbol{\beta}$$

を得る(第 4 回と同じ計算)。0/1 の列の平均は 1 の割合なので $\bar{y} = \pi_1$ である。これを代入すると、$\boldsymbol{y} - \hat{\beta}_0 \mathbf{1}_n - \mathbf{X}\boldsymbol{\beta} = (\boldsymbol{y} - \bar{y}\mathbf{1}_n) - (\mathbf{X} - \mathbf{1}_n \bar{\boldsymbol{x}}^\top)\boldsymbol{\beta}$ となるので、$\boldsymbol{y}_{\mathrm{c}} = \boldsymbol{y} - \pi_1 \mathbf{1}_n$ として

$$f = \|\boldsymbol{y}_{\mathrm{c}} - \mathbf{X}_{\mathrm{c}}\boldsymbol{\beta}\|_2^2 = \boldsymbol{y}_{\mathrm{c}}^\top \boldsymbol{y}_{\mathrm{c}} - 2\boldsymbol{\beta}^\top \mathbf{X}_{\mathrm{c}}^\top \boldsymbol{y}_{\mathrm{c}} + \boldsymbol{\beta}^\top \mathbf{X}_{\mathrm{c}}^\top \mathbf{X}_{\mathrm{c}} \boldsymbol{\beta}$$

となり、切片は消える。定義 6 の 2 つの式から勾配を求めて 0 とおくと

$$\mathbf{X}_{\mathrm{c}}^\top \mathbf{X}_{\mathrm{c}} \hat{\boldsymbol{\beta}} = \mathbf{X}_{\mathrm{c}}^\top \boldsymbol{y}_{\mathrm{c}}$$

となる。両辺を n で割って、右辺と左辺を読む。

右辺から調べる。y が 0 と 1 だけなので、$y_i - \bar{y}$ も 2 つの値しか取らない。

$$y_i - \bar{y} = \begin{cases} 1 - \pi_1 = \pi_0 & (y_i = 1) \\ -\pi_1 & (y_i = 0) \end{cases}$$

行ごとの和を群に分け、$\sum_{y_i = q} (\boldsymbol{x}_i - \bar{\boldsymbol{x}}) = n_q(\boldsymbol{\mu}_q - \bar{\boldsymbol{x}})$ と $n_q/n = \pi_q$ を使うと

$$\frac{1}{n}\mathbf{X}_{\mathrm{c}}^\top \boldsymbol{y}_{\mathrm{c}} = \frac{1}{n}\Big[\pi_0 \sum_{y_i=1} (\boldsymbol{x}_i - \bar{\boldsymbol{x}}) - \pi_1 \sum_{y_i=0} (\boldsymbol{x}_i - \bar{\boldsymbol{x}})\Big] = \pi_0\pi_1(\boldsymbol{\mu}_1 - \bar{\boldsymbol{x}}) - \pi_1\pi_0(\boldsymbol{\mu}_0 - \bar{\boldsymbol{x}}) = \pi_0\pi_1\,\boldsymbol{d} \tag{13}$$

となる。説明変数と 0/1 の y の共分散は、群の平均の差 $\boldsymbol{d}$ に比例する。左辺は 定義 1 から $\frac{1}{n}\mathbf{X}_{\mathrm{c}}^\top \mathbf{X}_{\mathrm{c}} \hat{\boldsymbol{\beta}} = \mathbf{S}_{\mathrm{T}} \hat{\boldsymbol{\beta}}$ なので、正規方程式は

$$\mathbf{S}_{\mathrm{T}}\hat{\boldsymbol{\beta}} = \pi_0\pi_1\boldsymbol{d}$$

になる。

次に、全体の共分散行列を 2 つに分ける。$y_i = q$ の行について、全体の平均からのずれを、自分の群の平均を通して

$$\boldsymbol{x}_i - \bar{\boldsymbol{x}} = \underbrace{(\boldsymbol{x}_i - \boldsymbol{\mu}_q)}_{\boldsymbol{a}} + \underbrace{(\boldsymbol{\mu}_q - \bar{\boldsymbol{x}})}_{\boldsymbol{b}}$$

と分ける。定義 12 で展開して 定義 1 の $\mathbf{S}_{\mathrm{T}}$ に入れ、和を群ごとに分ける。$\boldsymbol{a}\boldsymbol{a}^\top$ の和は $\mathbf{S}_{\mathrm{W}}$ そのものである。$\boldsymbol{b}$ は群の中で定数なので、交差項は

$$\sum_{y_i=q}(\boldsymbol{x}_i - \boldsymbol{\mu}_q)(\boldsymbol{\mu}_q - \bar{\boldsymbol{x}})^\top = \Big(\sum_{y_i=q}(\boldsymbol{x}_i - \boldsymbol{\mu}_q)\Big)(\boldsymbol{\mu}_q - \bar{\boldsymbol{x}})^\top = \mathbf{O}$$

となり、定義 14 から消える（転置の側も同じ）。(1) 式と $\pi_0 + \pi_1 = 1$ から

$$\boldsymbol{\mu}_0 - \bar{\boldsymbol{x}} = -\pi_1\boldsymbol{d}, \qquad \boldsymbol{\mu}_1 - \bar{\boldsymbol{x}} = \pi_0\boldsymbol{d}$$

なので、$\boldsymbol{b}\boldsymbol{b}^\top$ の項は群の中で n_q 個ぶん同じで

$$\frac{1}{n}(n_0\pi_1^2 + n_1\pi_0^2)\boldsymbol{d}\boldsymbol{d}^\top = \pi_0\pi_1(\pi_1 + \pi_0)\,\boldsymbol{d}\boldsymbol{d}^\top = \pi_0\pi_1\,\boldsymbol{d}\boldsymbol{d}^\top$$

となる。まとめると

$$\mathbf{S}_{\mathrm{T}} = \mathbf{S}_{\mathrm{W}} + \pi_0\pi_1\,\boldsymbol{d}\boldsymbol{d}^\top = \mathbf{S}_{\mathrm{W}} + \mathbf{S}_{\mathrm{B}} \tag{14}$$

を得る。全体のばらつきは、群の中のばらつきと、群の平均が離れていることによるばらつきの和である。第 2 項は、前半で定義した群間共分散行列 $\mathbf{S}_{\mathrm{B}}$ そのものである。$\boldsymbol{w}$ に映すと、第 1 項はスコアの群内分散、第 2 項はスコアの群間分散になる。$p = 1$ で $\mathbf{S}_{\mathrm{T}}, \mathbf{S}_{\mathrm{W}}$ を $s_{\mathrm{T}}^2, s_{\mathrm{W}}^2$ と書けば

$$s_{\mathrm{T}}^2 = s_{\mathrm{W}}^2 + \pi_0\pi_1 d^2$$

で、群内分散と群間分散の和が全体の分散になる。人工データでは $1.790 = 0.950 + 0.840$ と和が合う。(14) 式の第 2 項は、どのベクトル $\boldsymbol{v}$ に掛けても $\boldsymbol{d}$ のスカラー倍になる。

$$(\pi_0\pi_1\boldsymbol{d}\boldsymbol{d}^\top)\boldsymbol{v} = \pi_0\pi_1(\boldsymbol{d}^\top\boldsymbol{v})\,\boldsymbol{d}$$

定義 13 の 1 つ目で、$\boldsymbol{d}^\top \boldsymbol{v}$ が 1 つの数だからである。また

$$\boldsymbol{v}^\top \mathbf{S}_{\mathrm{T}} \boldsymbol{v} = \boldsymbol{v}^\top \mathbf{S}_{\mathrm{W}} \boldsymbol{v} + \pi_0 \pi_1 (\boldsymbol{d}^\top \boldsymbol{v})^2 > 0 \qquad (\boldsymbol{v} \neq 0)$$

なので、$\mathbf{S}_{\mathrm{W}}$ が正定値なら $\mathbf{S}_{\mathrm{T}}$ も正定値で、逆行列があり（第 4 回）、正規方程式の解は 1 つに決まる。

正規方程式に (14) 式を入れて、$\boldsymbol{d}$ の項を右辺に移すと

$$\mathbf{S}_{\mathrm{W}} \hat{\boldsymbol{\beta}} = \kappa \boldsymbol{d}, \qquad \kappa = \pi_0 \pi_1 (1 - \boldsymbol{d}^\top \hat{\boldsymbol{\beta}}) \tag{15}$$

となる。$\mathbf{S}_{\mathrm{W}} \hat{\boldsymbol{\beta}}$ は $\boldsymbol{d}$ と平行であり、これは「なぜ①」の節で J の勾配を 0 とおいたときの条件と同じである。前に掛かる数 κ を決める。左から $\mathbf{S}_{\mathrm{W}}^{-1}$ を掛け、さらに左から $\boldsymbol{d}^\top$ を掛けると

$$\hat{\boldsymbol{\beta}} = \kappa \mathbf{S}_{\mathrm{W}}^{-1} \boldsymbol{d}, \qquad \boldsymbol{d}^\top \hat{\boldsymbol{\beta}} = \kappa \boldsymbol{d}^\top \mathbf{S}_{\mathrm{W}}^{-1} \boldsymbol{d} = \kappa D^2$$

である。これを κ の定義に入れて解くと

$$\kappa = \pi_0 \pi_1 (1 - \kappa D^2) \quad \Longrightarrow \quad \kappa = \frac{\pi_0 \pi_1}{1 + \pi_0 \pi_1 D^2}$$

となり、前半の (8) 式を得る。

$D^2 > 0$ なので $\kappa > 0$ であり、係数は判別方向と向きまで同じである。また $\boldsymbol{d}^\top \hat{\boldsymbol{\beta}} = \kappa D^2 = \pi_0 \pi_1 D^2 / (1 + \pi_0 \pi_1 D^2)$ は 0 と 1 の間にある。

この結果は、次のように読める。正規方程式 $\mathbf{S}_{\mathrm{T}} \hat{\boldsymbol{\beta}} = \pi_0 \pi_1 \boldsymbol{d}$ から $\hat{\boldsymbol{\beta}} = \pi_0 \pi_1 \mathbf{S}_{\mathrm{T}}^{-1} \boldsymbol{d}$ であり、最小二乗法は群の中ではなく全体の広がり $\mathbf{S}_{\mathrm{T}}$ で割っている。だが (14) 式のとおり、$\mathbf{S}_{\mathrm{T}}$ は群の中の広がり $\mathbf{S}_{\mathrm{W}}$ を $\boldsymbol{d}$ の向きにだけ膨らませたものである（図 14）。膨らんだのが $\boldsymbol{d}$ の向きなので、$\mathbf{S}_{\mathrm{T}}$ で割っても $\mathbf{S}_{\mathrm{W}}$ で割っても、向きは変わらず倍率だけが変わる。これが、群を分けることを求めていない最小二乗法が、群を最もよく分ける向きに着く理由である。

罰則を足した (11) 式も、同じ道をたどる。Ridge 回帰の正規方程式を n で割ると $(\mathbf{S}_{\mathrm{T}} + \lambda \mathbf{I}) \hat{\boldsymbol{\beta}}_\lambda = \pi_0 \pi_1 \boldsymbol{d}$ となり、(14) 式を入れると、ここまでの導出の $\mathbf{S}_{\mathrm{W}}$ が $\mathbf{S}_{\mathrm{W}} + \lambda \mathbf{I}$ に替わるだけである。

第 II 部　実データ解析

乳がんデータ

第 II 部では、第 I 部の理論を乳がんの細胞のデータで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。予想どおりにいけば、それでよい。

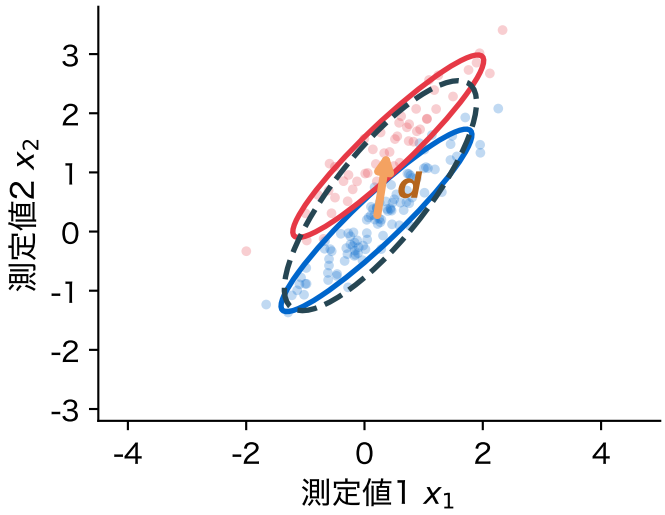


図 14: 群の中の広がりの楕円(青・赤)と、全体の広がりの楕円(破線)。全体の楕円は、群の中の楕円を平均の差 $\boldsymbol{d}$(橙)の向きに膨らませた形になる(人工データ)

第 I 部では、0/1 の回帰の係数が判別方向 $\mathbf{S}_{\mathrm{W}}^{-1}\boldsymbol{d}$ を向くことを導いた。ここから次の 2 つを予想できる。このデータには似た列が多いので、係数の向きは平均の差 $\boldsymbol{d}$ の向きから大きく回るはずである。そして、その向きに映せば、半径 1 列や $\boldsymbol{d}$ の向きに映すより、2 つの群がよく分かれるはずである。しきい値と予測値についての予想は、それぞれの結果の前に述べる。

データは scikit-learn の load_breast_cancer(Wisconsin 診断データ)である。1 行は乳房の腫瘤から針で採った細胞の画像 1 枚で、全部で 569 件ある。各画像では、写っている細胞核の輪郭から 表 2 の 10 種類の量を測った。それぞれを画像の中の核について平均・標準誤差・最も大きい 3 つの平均(最悪値)の 3 通りにまとめ、計 30 列を説明変数とする。ここでの標準誤差は、画像の中の核どうしのばらつきを表す列の名前であり、第 3 回の係数の標準誤差とは別のものである。目的変数は診断で、悪性が 212 件、良性が 357 件ある。scikit-learn の元のデータは悪性を 0、良性を 1 としているが、本章では悪性を 1 とした。30 列は単位も大きさもまちまちなので、それぞれ標準化した。標準化しても、係数の向きが判別方向と一致することは変わらない。標準化したのは、列ごとの係数を比べやすくするためである。半径・周囲の長さ・面積のように、互いにほぼ決まってしまう列もある。半径の平均と周囲の長さの平均の相関係数は 0.998 である。第 I 部の場面では、半径の平均の 1 列だけで直線を当て、0.5 で切った。そのときの正解率は 87.5% であった。

表 2: 乳がんデータの細胞核の 10 の測定値。それぞれ平均・標準誤差・最悪値の 3 列があり、計 30 列

測定値	測定値
半径	なめらかさ
きめ(濃淡のばらつき)	緻密さ
周囲の長さ	くぼみの深さ
面積	くぼみの数

対称性	輪郭の複雑さ（フラクタル次元）

計算の手続き

計算の手続きは次のとおりである。30 列を標準化したデータ行列 $\mathbf{Z}$ と、悪性を 1 とした $\boldsymbol{y}$ を用意し、列と $\boldsymbol{y}$ を中心化した。正規方程式を連立方程式として解き、0/1 の回帰の係数 $\hat{\boldsymbol{\beta}}$ を求めた。別に、悪性・良性の群ごとの平均 $\boldsymbol{\mu}_1, \boldsymbol{\mu}_0$ と群の中の共分散行列 $\mathbf{S}_{\mathrm{W}}$（定義 1）を計算した。向きの良し悪しは、第 I 部の図 4 と同じく、映したスコアの「群の平均の差 ÷ 群の中の標準偏差」で比べた。正解率は、どの向きでも、映したスコア 1 列に 0/1 の回帰を当てて 0.5 で切って求めた。しきい値については、中点での予測値を求めた。さらに、良性の 357 件から無作為に 212 件を選んで人数をそろえ、同じ計算をした。係数を決めた行とは別の行でも確かめるため、訓練 398 件とテスト 171 件に分けた計算も行った。標準化の平均・標準偏差は訓練の行で求めた。正解率の比較では、訓練・テストへの分け方を 20 通り変えて平均した。

向きと分かれ方

第 1 の予想は、係数の向きについてであり、結果は予想どおりだった。0/1 の回帰の係数 $\hat{\boldsymbol{\beta}}$ と平均の差 $\boldsymbol{d}$ のコサイン (10) 式は 0.08 で、30 次元の 2 つの向きはほとんど直角である。似た列が多いこのデータでは、$\mathbf{S}_{\mathrm{W}}^{-1}$ を掛けることで向きが大きく回る。図 4 の人工データで見たことが、30 次元で強く起きている。

向きの違いは、群の分かれ方に表れる（表 3）。映したスコアの「群の平均の差 ÷ 群の中の標準偏差」は、半径の平均 1 列では 2.21、平均の差 $\boldsymbol{d}$ の向きでは 2.88、0/1 の回帰の向きでは 3.83 である。第 I 部の人工データと同じ順に並び、判別方向が最もよく分ける。0/1 の回帰の向きでのこの値は、$D = \sqrt{D^2}$ にあたる。

表 3: 3 つの向きに映したスコアの「群の平均の差 ÷ 群の中の標準偏差」

向き	平均の差 ÷ 群の中の標準偏差
半径の平均だけ（第 I 部の場面）	2.21
平均の差 $\boldsymbol{d}$ の向き	2.88
0/1 の回帰（判別方向）	3.83

図 15 は、全件で当てはめた 0/1 の回帰の予測値 $\hat{y}$ の分布を、診断ごとに描いたものである。判別方向の上で、2 つの山はよく分かれている。0.5 で切ると、全件の正解率は 96.5% で、半径の平均 1 列だけの 87.5% を上回る。平均の差 $\boldsymbol{d}$ の向きでは 92.8% である（表 4）。ただし全件の正解率は、係数を決めた行で測った数字なので楽観的である。訓練 398 件で当てはめてテスト 171 件で測る分け方を 20 通り作り、正解率を平均した。0/1 の回帰は 95.0%、$\boldsymbol{d}$ の向きは 92.4%、半径 1 列は 87.0% であった。全件との差が大きいのは、30 個の係数を訓練の行に合わせる 0/1 の回帰である。それでも順位は変わらず、20 通りのうち 19 通りで、判別方向が $\boldsymbol{d}$ の向きを上回った。

表 4: 3 つの向きの正解率(映したスコアに 0/1 の回帰を当てて 0.5 で切る)。全件で当てはめて全件で測った値と、訓練の行で当てはめてテストの行で測った値(分割 20 通りの平均)

向き	全件	テスト 171 件(20 通りの平均)
半径の平均だけ(第 I 部の場面)	87.5%	87.0%
平均の差 $\boldsymbol{d}$ の向き	92.8%	92.4%
0/1 の回帰(判別方向)	96.5%	95.0%

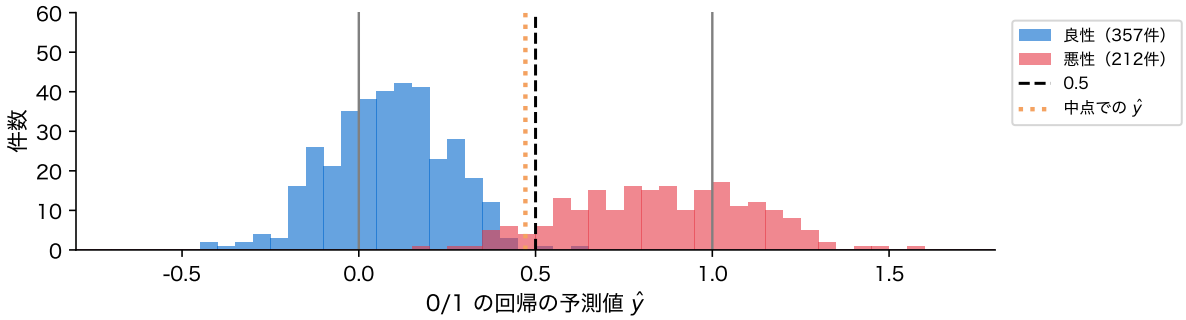


図 15: 乳がんデータの 0/1 の回帰の予測値の分布(青が良性、赤が悪性)。灰の実線は 0 と 1、黒の破線は 0.5、橙の点線は両群の平均の中点での予測値

なお、$\hat{\boldsymbol{\beta}}$ と、群の平均と $\mathbf{S}_{\mathrm{W}}$ から手で組んだ判別方向 $\mathbf{S}_{\mathrm{W}}^{-1}\boldsymbol{d}$ のコサインは 1.0000 で、30 次元でも第 I 部の式のとおり同じ向きを指す。

しきい値と人数の比

第 I 部では、0/1 の回帰で 0.5 で切る境界が、人数の少ない群の側へずれることを導いた。悪性 212 件・良性 357 件のこのデータでは、中点での予測値は 0.5 より小さくなるはずである。結果は予想どおりだった(表 5)。全件では、中点での予測値は 0.4712452 で、(12) 式から計算した 0.4712452 と一致する。良性を 212 件に間引いて人数をそろえると、中点での予測値はちょうど 0.5000000 になる。このときも係数の向きは、そのデータの判別方向とコサイン 1.0000000 で一致する。

表 5: 両群の平均の中点での 0/1 の回帰の予測値。全件と、良性を間引いて人数をそろえた場合

	人数(悪性：良性)	中点での $\hat{y}$
全件	212：357	0.4712452
良性を間引く	212：212	0.5000000

ただし、ずれは判定をほとんど変えない。0.5 で切る判定と中点で切る判定が食い違うのは、569 件中 2 件であった(図 15)。理由は (12) 式から読める。0.5 からのずれは

$$\frac{(\pi_1 - \pi_0)(1 - \boldsymbol{d}^\top \hat{\boldsymbol{\beta}})}{2}$$

である。人数の差は $\pi_1 - \pi_0 =$ -0.25 とそれなりにある。だが、2 つの群は判別方向の上で遠く離れていて、$D^2 =$ 14.7 と大きい。そのため

$$\boldsymbol{d}^\top \hat{\boldsymbol{\beta}} = \frac{\pi_0 \pi_1 D^2}{1 + \pi_0 \pi_1 D^2}$$

は 0.77 と 1 に近く、ずれは -0.029 にとどまる。しかも 2 つの山はよく分かれていて、0.5 と中点の間に入る件数がわずかである。群が重なっているデータや、人数の比がもっと偏ったデータでは、ずれはもっと大きく効く。

ずれが小さくても、2 種類の誤りの数は偏る。第 I 部では、0.5 の境界が少ない群の側へずれるので、少ない群の再現率が下がることを見た。このデータでも、悪性の再現率は良性の再現率より低いはずである。訓練・テストへの分け方を 20 通り変え、テスト 171 件(悪性 64 件)で混同行列を数えて平均した(表 6)。0.5 で切ると正解率は 95.0% だが、悪性の再現率は 87.9% で、良性の再現率 99.3% より低い。予想どおりである。悪性を良性と判定する見逃しは平均 7.8 件、良性を悪性と判定するのは平均 0.8 件で、誤りの大半は見逃しである。中点で切ると悪性の再現率は 89.5% に上がるが、ずれが小さいので見逃しは 6.7 件までしか減らない。

表 6: テストの行での正解率・再現率・適合率と、2 種類の誤りの件数(訓練・テストの分け方 20 通りの平均)。0.5 で切る場合と、訓練の行の群の平均の中点で切る場合

境界	正解率	悪性の再現率	悪性の適合率	良性の再現率	悪性の見逃し	良性を悪性
0.5 で切る	95.0%	87.9%	98.7%	99.3%	7.8 件	0.8 件
中点で切る	95.4%	89.5%	98.0%	98.9%	6.7 件	1.2 件

正解率は 2 種類の誤りを同じ重さで数える。がんの検査では、悪性を見逃す誤りのほうが、良性を悪性と判定する誤りより重い。正解率 95% という 1 つの数字だけでは、悪性の約 8 件に 1 件を見逃していることは見えない。判定の良さは、再現率と適合率を正解率と並べて報告する。

予測値は確率か

第 I 部では、1 変数の人工データで、直線が $y = 1$ の割合を追えず 0 と 1 の外へはみ出すことを見た。30 列にしても、予測値は確率として読めないはずである。結果は予想どおりだった。30 列を使っても予測値は 0 と 1 の間に収まらず、569 件のうち 19.3%(110 件)が 0 未満、12.0%(68 件)が 1 を超える(図 15)。範囲は -0.42 から 1.56 である。訓練の行で当てはめたテストの行でも、0 未満が 30 件、1 超が 13 件あった。

図 16 は、予測値を幅 0.2 の区間に分け、区間ごとに悪性の割合を求めたものである。予測値が確率なら、点は灰の破線の上に乗るはずである。実際には、予測値が 0.4 を下回ると割合は 0.1 未満に、0.6 を超えるとほぼ 1 に張り付く。予測値が 1 を超えた 68 件では悪性の割合が 100%、0 を下回った 110 件では 0% であった。図 11

の人工データと同じ形になっている。予測値 1.3 は「悪性の確率 130%」を意味しない。判別方向の上で、悪性の群の奥のほうにあるというだけである。予測値は並べ替えやしきい値で切るためのスコアとしては使えるが、確率としては読めない。

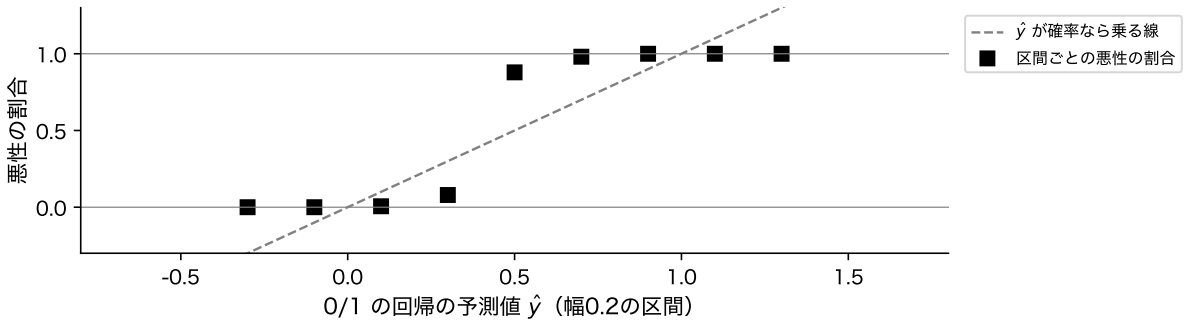


図 16: 0/1 の回帰の予測値の区間（幅 0.2）ごとの悪性の割合（5 件以上ある区間のみ）。灰の破線は、予測値が確率であれば点が乗る線

落とし穴：係数を 1 列ずつ読む

最後に、0/1 の回帰の係数を 1 列ずつ読むときの落とし穴を見る。悪性の細胞は核が大きいので、半径・周囲の長さ・面積の列は、どれも悪性の群のほうが平均が大きい。図 17 (a) のとおり、大きさを表す 6 列の群の平均の差 d_j はどれも正である。半径の平均では $d_j = 1.51$（標準化した単位）である。ところが (b) の係数を見ると、半径の平均の係数は -0.77 と負になる。30 列全体では、11 列で係数の符号が平均の差の符号と逆である。

これは第 I 部の結果から説明できる。係数の向きは $\boldsymbol{d}$ ではなく $\mathbf{S}_{\mathrm{W}}^{-1}\boldsymbol{d}$ であり、結果①で見たとおり、2 つの向きはほとんど直角であった。半径・周囲の長さ・面積のようにほぼ同じ情報を持つ列が並ぶと、$\mathbf{S}_{\mathrm{W}}^{-1}$ を掛けることで、似た列どうしの係数が打ち消し合う形になる。係数の 1 つ 1 つは「その列が悪性で大きいか」を表すのではなく、30 列をまとめて 1 本のスコアに映すときの重みである。重みの組として初めて、群を最もよく分ける向きになる。列ごとに悪性との関係を読みたいときは、係数ではなく群の平均の差を見る。

罰則を足すと

第 I 部では、似た列が多いときは罰則を足した向き $(\mathbf{S}_{\mathrm{W}} + \lambda\mathbf{I})^{-1}\boldsymbol{d}$ を使えばよいと述べた。このデータで試す。罰則を足すと向きは平均の差の側へ回るので、落とし穴で見た半径・周囲の長さ・面積の打ち消し合いは収まり、係数の符号は平均の差とそろうはずである。似た列の不安定さが減るので、テストの正解率も上がると予想できる。

罰則の強さは、第 4 回と同じく 5 分割の交差検証（クロスバリデーション、CV）で選んだ。候補は 0 と、10^{-4} から 10 までを対数で等間隔に並べた 31 個である。各回で係数を決める側の行で標準化し、0.5 で切った正解率が最も高い $\lambda = 0.0215$ を選んだ。この罰則で全件に当てはめると、大きさを表す 6 列の係数の絶対値は、最大 0.94 から 0.13 に縮んだ（図 18）。半径の平均の係数は正になり、大きな正と負が打ち消し合う形は収まった。係数と平均の差 $\boldsymbol{d}$ のコサインは 0.08 から 0.36 に上がり、向きは $\boldsymbol{d}$ の側へ回った。だが、面積の平均と最悪値の

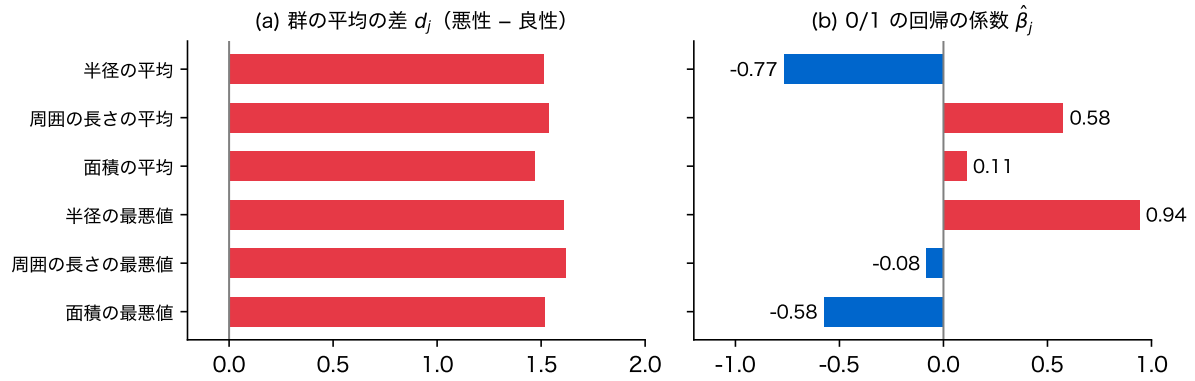


図 17: 乳がんデータの細胞核の大きさを表す 6 列。(a) 群の平均の差（悪性 − 良性、標準化した単位）、(b) 30 列の 0/1 の回帰の係数（青が負）

係数は小さな負のまま残った。30 列のうち符号が平均の差と逆になる列は、罰則なしの 11 列に対して 12 列で、減らなかった。1 つ目の予想は、打ち消し合いについては当たり、符号については外れた。

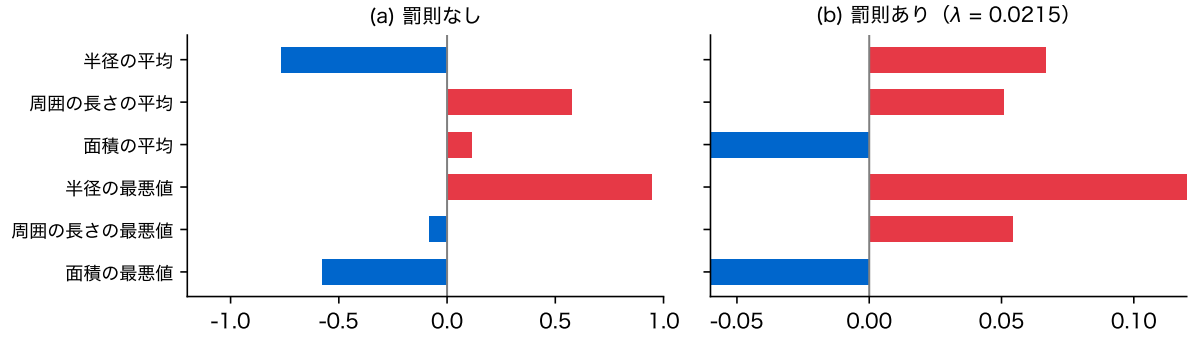


図 18: 細胞核の大きさを表す 6 列の係数（標準化した単位、青が負）。(a) 罰則なしの 0/1 の回帰、(b) 5 分割 CV で選んだ罰則を足した 0/1 の回帰

2 つ目の予想は外れた。訓練・テストの分け方 20 通りで正解率を平均すると、罰則なしで 95.0%、選んだ罰則で 95.2% であり、差は分け方による標準偏差（約 1.2%）に収まる（図 20）。符号をそろえるには、もっと強い罰則が要る（図 19）。罰則を強めると逆符号の列は減り、$\lambda = 0.15$ で大きさの 6 列はすべて正になる。$\lambda = 4.64$ では 30 列中 1 列まで減る。その代わり、向きが平均の差に近づき、正解率は 91.8% まで下がる。

外れた理由は、第 3 回と第 4 回の道具で説明できる。このデータでは、切片を含む 31 個の係数を 569 件で決めており、係数 1 個あたり約 18 件ある。行が係数に比べて十分多いので、最小二乗法の分散はもともと小さく、罰則で減らせる分が少ない。また第 3 回で見たとおり、似た列の係数は、和はよく決まるが内訳がばらつく。半径・周囲の長さ・面積の係数が打ち消し合っていても、3 列を合わせたスコアはほとんど動かない。さらに、第 4 回で見たとおり、CV の誤差（ここでは正解率）の底は平らで、弱い罰則が選ばれる。弱い罰則は大きな打ち消し合いを収めるが、向きはまだ判別方向に近い。符号までそろえる強い罰則は、向きを平均の差へ寄せて、群の中の広がりの情報を捨てるので、正解率が下がる。係数の読みやすさと予測の良さは、罰則の強さを通して引きかえになっている。

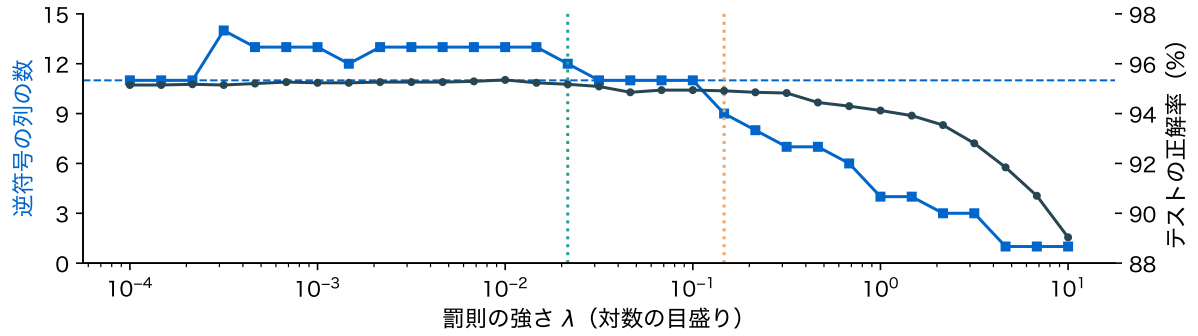


図 19: 罰則の強さに対する、符号が平均の差と逆になる列の数（青、30 列中）とテストの正解率（黒、分け方 20 通りの平均）。緑の点線は 5 分割 CV で選んだ強さ、橙の点線は大きさの 6 列がすべて正になる強さ

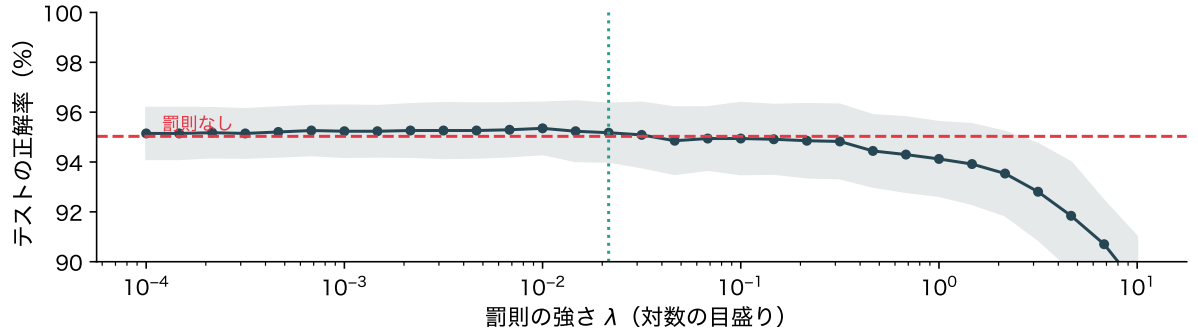


図 20: 罰則の強さに対するテストの正解率（訓練・テストの分け方 20 通りの平均と ±1 標準偏差）。赤の破線は罰則なし、緑の点線は 5 分割 CV で選んだ強さ

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部から立てた予想のうち、向き・しきい値（再現率の偏りを含む）・予測値の読み方の 3 つは当たり、罰則の予想は、打ち消し合いが収まる点だけ当たり、符号と正解率については外れた。0/1 の回帰の係数は、平均の差とほとんど直角な判別方向を向き、半径 1 列や平均の差の向きより群をよく分けた。テストの行で測ると差は縮むが、順位は変わらない。しきい値は人数の少ない悪性の側へずれた。ただし 2 つの群が遠く離れているので、ずれは小さく、判定はほとんど変わらなかった。それでも悪性の再現率は良性の再現率より低く、正解率だけでは見逃しの多さが見えなかった。予測値は 0 と 1 の外へはみ出し、確率としては読めなかった。また、似た列が多いと、係数の符号が平均の差の符号と逆になる列が出る。係数は 1 列ずつ読まず、群を分ける向きの組として読む。罰則を足すと大きな打ち消し合いは収まるが、CV が選ぶ弱い罰則では符号はそろわない。符号までそろえる強い罰則は、正解率を少し下げる。読みやすさと予測は引きかえである。

締め

まとめと次回の問い

本章の問いは、0/1 の目的変数に最小二乗法を当てたとき、係数の向きは何を指しているのか、であった。答えは、線形判別分析の判別方向 $\mathbf{S}_{\mathrm{W}}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$ である。y が 0 と 1 しか取らないため、$\boldsymbol{x}$ と y の共分散は群の平均の差 $\pi_0\pi_1\boldsymbol{d}$ になる。全体の共分散行列も、群内共分散行列と群間共分散行列に分かれる（$\mathbf{S}_{\mathrm{T}} = \mathbf{S}_{\mathrm{W}} + \mathbf{S}_{\mathrm{B}}$、$\mathbf{S}_{\mathrm{B}} = \pi_0\pi_1\boldsymbol{d}\boldsymbol{d}^{\top}$）。第 2 項がいつも $\boldsymbol{d}$ の向きを向くので、正規方程式の解は $\mathbf{S}_{\mathrm{W}}^{-1}\boldsymbol{d}$ の正の数倍になる。これはフィッシャーの基準を最大にする向きである。推定法は第 1 回と同じ最小二乗法のままで、答えを LDA の向きとして読める。第 1 回で推定法とモデルを分けて考えた理由の 1 つがここにある。違うのはしきい値だけである。0.5 で切る境界は人数の少ない群の側へずれ、人数が等しいときに限り中点で一致する。ずれた境界は少ない群を見逃しやすく、その見逃しは正解率には映らない。判定の良さは、再現率と適合率を正解率と並べて測る。乳がんデータの 30 列でも、係数と判別方向のコサインは 1.0000000 であった。人数をそろえると、中点での予測値はちょうど 0.5 になった。一方、予測値は 0 と 1 の外へはみ出し（全件の 31%）、確率としては読めない。3 群以上では、指示行列の回帰で一度も選ばれない群が出るマスキングが起きる。

最後に、次回への問いを置く。0/1 の回帰は群を分ける向きを正しく出すが、確率を出さない。区間ごとの割合は 0 と 1 の間で曲がるのに、直線は曲がれないからである。最小二乗法は、データとモデルの距離を最小にするだけで、データがどのように出てくるかを何も仮定していない。では、データの出方を確率で仮定すれば、向きと一緒に確率も出せるのだろうか。次回は、この問いから始める。

発展

発展：群を分ける列を探す

発展として、判別方向を「群を分ける列を探す」道具として使う研究を 2 つ紹介する。腸内細菌や遺伝子のデータでは列が数百から数千あり、知りたいのは 2 つの群を分けるのがどの列か、であることが多い。

1 つ目は、Segata et al. (2011) の LEfSe（LDA effect size）である。腸内細菌のデータで群の間の違いを探す手法として、広く使われている。手順は 3 段からなる（図 21）。まず列ごとに、群の間で値の大きさがずれているかを順位を使う検定で調べ、差のある列だけを残す。次に、群の中に小分け（体の部位など）があれば、小分けどうしを比べても差の向きがそろうかを確かめる。最後に、残った列で LDA を当てて判別方向を求める。列ごとに、群の平均の差と、判別方向に映したスコアの平均の差を合わせた大きさを求め、10 を底とする対数にした値を LDA スコアと呼ぶ。LDA スコアが 2 を超えた列を、群を分ける列として報告する。

図 22 は、遺伝子を 2 つ欠いたマウス 20 匹と 1 つ欠いたマウス 10 匹の腸内細菌に、LEfSe を当てた結果である。LDA スコアが 2 を超えた菌の群は 19 あった。上位には Clostridiales・Clostridia・Firmicutes が並ぶ。これらは分類の階層で入れ子になった菌の群で、ほぼ同じ情報を持つ列である。1 列ずつ検定して絞るので、似た列はそろって残る。また、LDA スコアは群の平均の差も合わせて使うので、第 II 部の落とし穴で見た、係数だけを 1 列ずつ読む危うさを和らげている。

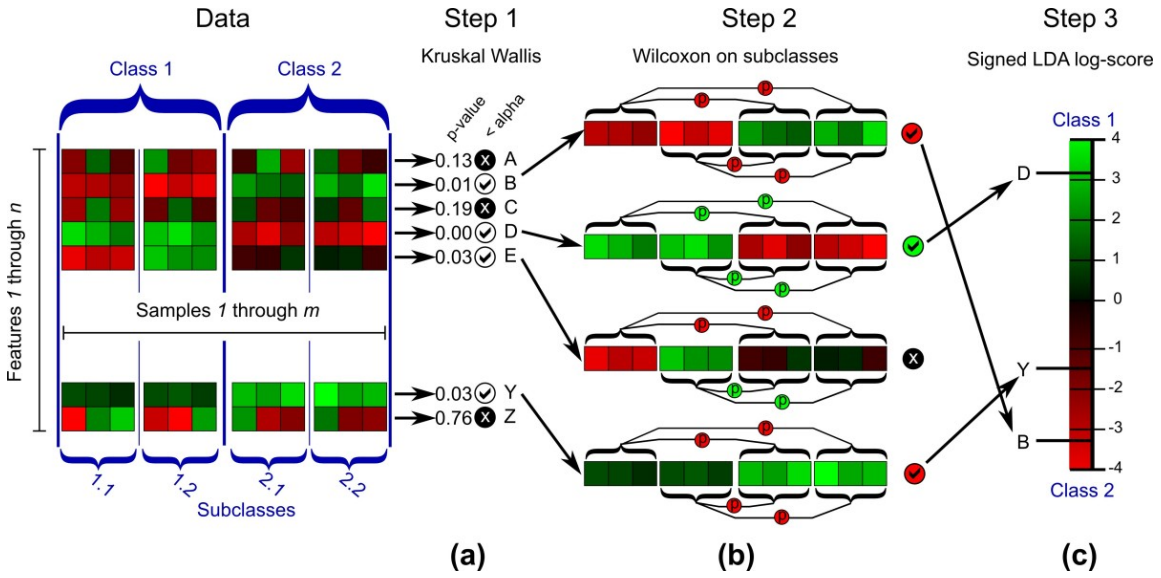


図 21: LEfSe の手順。(a) 列ごとに群の差を検定して絞る、(b) 群の中の小分けでも差の向きがそろうかを確かめる、(c) 残った列に LDA を当てて LDA スコアを付ける。出典：Segata et al. (2011) Genome Biol. 12: R60, Fig. 6（CC BY 2.0）

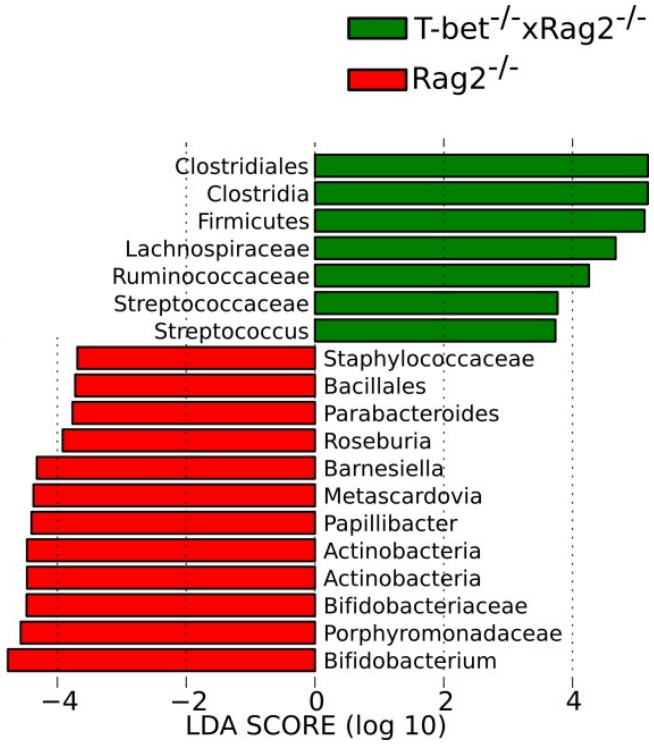


図 22: 遺伝子を 2 つ欠いたマウス(緑)と 1 つ欠いたマウス(赤)で差のあった菌の群の LDA スコア。出典：Segata et al. (2011) Genome Biol. 12: R60, Fig. 3（棒グラフを切り出した。CC BY 2.0）

2 つ目は、Mai, Zou & Yuan (2012) の方法である。本章の中心の結果は、(8) 式のとおり、0/1 の回帰の係数が判別方向の正の数倍になることであった。そこで、0/1 の回帰に第 4 回の Lasso の罰則を足す。本講義の記号で書けば

$$\min_{\beta_0,\boldsymbol{\beta}} \|\boldsymbol{y} - \beta_0 \mathbf{1}_n - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \lambda\|\boldsymbol{\beta}\|_1, \qquad \boldsymbol{y} \in \{0,1\}^n$$

である。論文では y の 2 つの値を 0 と 1 とは別の数にしている。2 つの値を替えても、平均を引いた y が定数倍になるだけなので、λ を同じ倍率で替えれば係数の向きは変わらない。$\lambda = 0$ なら係数は判別方向の正の数倍であり、λ を大きくすると多くの係数がちょうど 0 になる。0 でない係数の列が、群を分ける列として選ばれる。Mai らは、列が行よりずっと多くても、この方法が効く列を選び当て、判別方向を推定できることを示した。

2 つの方法の目的は同じで、群を分ける少数の列を見つけることである。LEfSe は 1 列ずつ検定して絞ってから LDA を当てるので、似た列はそろって残る。Lasso はすべての列をまとめて見ながら係数を 0 にするので、似た列は一部だけが残る。差のある列をすべて挙げたいなら LEfSe、少ない列で群を分けたいなら Lasso が向く。どちらを使うかは、問いに合わせて選ぶ。

参考文献

- Segata, N., Izard, J., Waldron, L., Gevers, D., Miropolsky, L., Garrett, W. S., & Huttenhower, C. (2011). Metagenomic biomarker discovery and explanation. Genome Biology, 12(6), R60.
- Mai, Q., Zou, H., & Yuan, M. (2012). A direct approach to sparse discriminant analysis in ultra-high dimensions. Biometrika, 99(1), 29–42.