

第 6 回 分類② : 最尤法

データの出方を仮定すると、確率が出る

本章の問いは、第 5 回の締めで残った「方向は出るが、確率が出ない。確率を出すには？」である。答えは、データの出方を確率分布で仮定し、そのデータが出てくる確率(尤度)を最大にする最尤法である。最小二乗法は誤差が正規分布のときの最尤法であり、LDA を最尤法で当てはめると第 5 回と同じ向きに事後確率が出る。ロジスティック回帰は事後確率を直接置き、ニュートン法で解く。

第 I 部 理論

確率を出すには

第 5 回では、2 つの群を 0 と 1 で表して最小二乗法の直線を当てると、係数の向きが線形判別分析(LDA)の判別方向 $\mathbf{S}_W^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$ に一致することを見た。しかし予測値は 0 と 1 の間に収まらず、確率としては読めなかった。本章では新しいデータでこの問題を見直す。紙幣の画像から測った量で、偽札($y = 1$)と真札($y = 0$)を見分けるデータである(第 II 部で詳しく述べる)。図 1 は、画像の分散という 1 つの量だけに直線を当てたものである。予測値は -0.37 から 1.39 まで伸び、1,372 枚のうち 256 枚で 0 未満か 1 を超える。一方、分散を幅 1 の区間に分けて偽札の割合を求めた(黒の四角)。割合は分散の小さい側でほぼ 1、大きい側でほぼ 0 になり、その間を S 字に曲がってつなぐ。直線はこの曲がりを追えない。




図 1: 紙幣のデータの画像の分散(ウェーブレット変換後)と真贋(偽札 = 1 が赤、真札 = 0 が青。縦に少しずらして打った)。直線は 0/1 に当てた最小二乗法、黒の四角は分散の区間(幅 1、10 枚以上)ごとの偽札の割合

本章の問いは、第 5 回の締めで残した 1 つである。方向は出るが、確率が出ない。確率を出すにはどうすればよいか。答えは最尤法(maximum likelihood)である。データがどのように出てくるかを確率分布で仮定し、手元の

データが出てくる確率を最大にするパラメータを選ぶ。本章はこの答えを 3 段で示す。まず、第 1 回からの最小二乗法が、誤差に正規分布を仮定したときの最尤法にほかならないことを示す。次に、群ごとに x の出方を正規分布で仮定した LDA を最尤法で当てはめ、第 5 回と同じ向きのうえに確率が出ることを導く。最後に、 x の出方を仮定せず、 y の出方だけを置くロジスティック回帰を導き、その解き方を行列で書く。

道具：尤度と確率の分布

確率を出す推定法には、第 5 回までにない道具が要る。確率の出方を表す分布、尤度、対数、そして確率を 0 と 1 の間に収める関数である。ここにまとめておく。

まず、0 か 1 しか取らない量の出方である。コインを投げて表を $y = 1$ 、裏を $y = 0$ とし、表の確率を θ とすると、1 回の結果の確率は $\Pr(y) = \theta^y(1 - \theta)^{1-y}$ と書ける。 $y = 1$ なら θ 、 $y = 0$ なら $1 - \theta$ になり、指数が場合分けの代わりをしている。これをベルヌーイ分布(Bernoulli distribution)と呼ぶ。10 回投げて表が 7 回出たとき、各回が独立なら、この結果が出る確率は各回の確率の積

$$L(\theta) = \prod_{i=1}^{10} \theta^{y_i} (1 - \theta)^{1-y_i} = \theta^7 (1 - \theta)^3 \quad (1)$$

である。データを固定し、パラメータ θ の関数と見たものを尤度(likelihood)と呼ぶ。図 2 (a) のとおり、尤度が最大になるのは $\theta = 0.7$ 、観測された表の割合そのものである。尤度を最大にするパラメータを選ぶ方法が最尤法である。




図 2: コインを 10 回投げて表が 7 回のときの、表の確率 θ の (a) 尤度と (b) 対数尤度。破線は最大の位置 $\theta = 0.7$

尤度は積なので、そのままでは微分しにくい。対数をとると積が和になり、 $\log L(\theta) = 7 \log \theta + 3 \log(1 - \theta)$ となる(図 2 (b))。log は単調に増える関数なので、対数尤度(log-likelihood)が最大になる位置は尤度が最大になる位置と同じである。微分して 0 とおくと $7/\theta - 3/(1 - \theta) = 0$ 、すなわち $\hat{\theta} = 0.7$ を得る。以後、最尤法ではいつも対数尤度を最大にする。

次に、連続の量の出方である。平均 μ 、分散 σ^2 の正規分布(normal distribution)の確率密度は

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) \quad (2)$$

である(π は円周率)。 x が μ から離れるほど、その距離の二乗に比例して指数の中が小さくなり、出にくくなる。変数が p 個のベクトル $\mathbf{x}$ なら、平均ベクトル μ 、共分散行列 Σ の多変量正規分布の密度は

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)\right) \quad (3)$$

となる。 $|\Sigma|$ は行列式である。距離の二乗が、共分散行列の逆行列で測った 2 次形式に置きかわり、密度の等高線は楕円になる。 $p = 1$ なら $\Sigma = \sigma^2$ で、(3) 式は (2) 式に戻る。

2 つの群があり、群 q の割合が π_q 、群 q の中での $\mathbf{x}$ の密度が $f_q(\mathbf{x})$ であるとき、 $\mathbf{x}$ を見たうえで群 1 である確率は、ベイズの定理(Bayes' theorem)により

$$\Pr(y = 1 | \mathbf{x}) = \frac{\pi_1 f_1(\mathbf{x})}{\pi_0 f_0(\mathbf{x}) + \pi_1 f_1(\mathbf{x})} \quad (4)$$

となる。これを事後確率(posterior probability)と呼ぶ。群の割合と群の中の出やすさの積を、2 つの群で比べた比である。図 3 (a) は 1 変数の例で $\pi_q f_q(x)$ を描いたもの、(b) はその比から求めた事後確率である。 x を動かすと、事後確率は 0 と 1 の間を S 字に曲がってつなぐ。




図 3: 1 変数の 2 群の例(群 1 の割合 1/3、群の中は平均 0 と 2.2、標準偏差 1 の正規分布)。(a) 群の割合と群の中の密度の積、(b) 事後確率。点は $x = 1.5$ の値

(4) 式の分母と分子を $\pi_1 f_1(\mathbf{x})$ で割ると、 $1/(1 + e^{-a})$ 、 $a = \log\{\pi_1 f_1(\mathbf{x})/\pi_0 f_0(\mathbf{x})\}$ の形になる。

定義 1 (シグモイド関数と対数オッズ). $\text{sig}(a) = 1/(1 + e^{-a})$ をシグモイド関数(sigmoid function)(ロジスティック関数)と呼ぶ。どんな実数 a に対しても値は 0 と 1 の間にあり、 $a = 0$ で 1/2 になる。逆に解くと $a = \log\{\theta/(1 - \theta)\}$ ($\theta = \text{sig}(a)$)であり、これを対数オッズ(log-odds)と呼ぶ。

最後に、シグモイド関数の微分を用意する。 $\text{sig}(a) = (1 + e^{-a})^{-1}$ を微分すると $e^{-a}/(1 + e^{-a})^2 = \text{sig}(a)\{1 - \text{sig}(a)\}$ となる。これを使うと

$$\frac{d \log \text{sig}(a)}{da} = 1 - \text{sig}(a), \quad \frac{d \log(1 - \text{sig}(a))}{da} = -\text{sig}(a) \quad (5)$$

となる。対数をとったシグモイドの微分は、シグモイドそのものの 1 次式になる。この性質のおかげで、ロジスティック回帰の勾配は簡単な形になる。

最小二乗法は正規誤差の最尤法

最尤法で確率を出す前に、第 1 回からの最小二乗法を最尤法の立場から見直す。第 1 回で予告した「誤差が正規分布なら 2 つの推定法の答えは一致する」を、ここで導く。

1 変数の回帰 $y_i = \beta x_i + \varepsilon_i$ で、誤差 ε_i が平均 0、分散 σ^2 の正規分布に従い、行ごとに独立だと仮定する。図 4 のように、各 x_i で y_i は直線上の値 βx_i を中心に正規分布で散らばって出てくる、というモデルである。1 点の出やすさは (2) 式の μ を βx_i に置いた $f(y_i) = (2\pi\sigma^2)^{-1/2} \exp\{-(y_i - \beta x_i)^2/(2\sigma^2)\}$ である。行が独立なので、 n 点の尤度はその積になる。対数をとると

$$\log L(\beta, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta x_i)^2 \quad (6)$$

となる。 β を含むのは第 2 項だけで、その中身は第 1 回の目的関数、誤差の二乗和である。 $-1/(2\sigma^2)$ は負の定数なので、対数尤度を最大にする β は二乗和を最小にする β と一致する。




図 4: 1 変数の回帰の人工データ (25 点) と最小二乗法の直線。赤の曲線は、3 つの x の位置で y が出てくる正規分布の密度を横向きに描いたもの

図 5 は、図 4 の人工データで、(a) 二乗和と (b) 対数尤度を β の関数として描いたものである ((b) の σ^2 は後で求める $\hat{\sigma}^2$ に固定した)。二乗和の谷底と対数尤度の山頂は同じ $\hat{\beta} = 0.615$ にある。

最尤法は σ^2 も決める。(6) 式を σ^2 で偏微分して 0 とおくと $\hat{\sigma}^2 = \frac{1}{n} \sum_i (y_i - \hat{\beta} x_i)^2$ 、すなわち残差の二乗和を n で割ったものになる。人工データでは 1.548 である。最小二乗法は直線を決めるだけだったが、最尤法は直線のまわりの散らばりの大きさまでモデルの一部として推定する。

ベクトルで書けば、二乗和は $\|\mathbf{y} - \beta \mathbf{x}\|_2^2$ 、列が p 本のデータ行列 $\mathbf{X}$ なら $\|\mathbf{y} - \mathbf{X}\beta\|_2^2$ であり、

$$\log L(\beta, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 \quad (7)$$

となる。 β についての勾配を 0 とおけば、第 1 回の正規方程式 $\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y}$ を得る。 $p = 1$ なら (7) 式は (6) 式に戻る。最小二乗法は、誤差が独立な正規分布に従うと仮定したときの最尤法である。




図 5: 図 4 の人工データの (a) 二乗和と (b) 対数尤度。破線は最小二乗法の解 $\hat{\beta}$

では、 y が 0 か 1 しか取らないときはどうするか。 y は 2 つの値しか取らないので、 y のまわりに正規分布を置くことはできない。確率の仮定の置き方は 2 通りある。1 つは、 y で分けた群ごとに x の出方を置く方法である。データ全体の出方を仮定するので、生成モデル(generative model)と呼ぶ。LDA がこれにあたる。もう 1 つは、 x を与えたときの y の出方だけを置く方法である。群を識別する確率だけを仮定するので、識別モデル(discriminative model)と呼ぶ。ロジスティック回帰がこれにあたる。以下、この順に見ていく。

LDA を最尤法で当てはめる

y で分けた群ごとに x の出方を置くのが LDA の確率のモデルである。まず 1 変数で考える。各行は確率 π_q で群 q に属する($\pi_0 + \pi_1 = 1$)と仮定する。群 q の中では、 x_i が平均 μ_q 、分散 σ^2 の正規分布に従って出てくるとする。分散は 2 つの群で共通とする。ここでは人工的なデータを使う。みかん 150 個の皮の色の濃さ x (標準化した値)と、食べて甘かった($y = 1$, 30 個)か酸っぱかった($y = 0$, 120 個)かである。図 6 は、群ごとのヒストグラムに、このモデルの密度を個数に合わせて重ねたものである。




図 6: みかんの人工データ(皮の色の濃さ x 、酸っぱい $y = 0$ が青、甘い $y = 1$ が赤)のヒストグラムと、最尤推定した LDA のモデルの群ごとの正規分布の密度(個数と幅 0.5 に合わせて拡大した)

行 i では y_i と x_i の両方を観測している。その出やすさは、「群 y_i が選ばれる確率 π_{y_i} 」と「その群の中で x_i が出る密度 $f_{y_i}(x_i)$ 」の積になる。行が独立なら、対数尤度は

$$\ell(\pi_1, \mu_0, \mu_1, \sigma^2) = \sum_{i=1}^n \left[\log \pi_{y_i} + \log f_{y_i}(x_i) \right] \quad (8)$$

となる。 f_q は (2) 式の μ を μ_q に置いたものである。

(8) 式は、 π の部分と μ_q, σ^2 の部分に分かれる。 π の部分は $n_1 \log \pi_1 + n_0 \log(1 - \pi_1)$ で、(1) 式のコインと同じ形をしている。したがって $\hat{\pi}_1 = n_1/n$ 、すなわち観測された群の割合になる。 μ_q の部分は $-\frac{1}{2\sigma^2} \sum_{y_i=q} (x_i - \mu_q)^2$ であり、 μ_q で偏微分して 0 とおくと $\hat{\mu}_q$ は群 q の平均になる。 σ^2 で偏微分して 0 とおくと、回帰のときと同じ計算で

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{q=0}^1 \sum_{y_i=q} (x_i - \hat{\mu}_q)^2 = s_W^2$$

となり、第 5 回で定義した群の中の分散に一致する。人工データでは $\hat{\pi}_1 = 0.200$ 、 $\hat{\mu}_0 = 0.059$ 、 $\hat{\mu}_1 = 1.978$ 、 $\hat{\sigma}^2 = 1.229$ である。

変数が p 個なら、群の中の分布を (3) 式の変量正規分布 $N(\boldsymbol{\mu}_q, \boldsymbol{\Sigma})$ にする。 $\boldsymbol{\mu}_q$ の部分は $-\frac{1}{2} \sum_{y_i=q} (\mathbf{x}_i - \boldsymbol{\mu}_q)^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_q)$ である。第 5 回の 2 次形式の勾配の公式から、その勾配は $\boldsymbol{\Sigma}^{-1} \sum_{y_i=q} (\mathbf{x}_i - \boldsymbol{\mu}_q)$ となる。これを 0 ベクトルとおけば、 $\hat{\boldsymbol{\mu}}_q$ は群の平均ベクトルになる。 $\boldsymbol{\Sigma}$ の最尤推定には行列の偏微分が要るので、結果だけを述べる。最尤推定は 1 変数と同じ形の

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{q=0}^1 \sum_{y_i=q} (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_q)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_q)^\top = \mathbf{S}_W \quad (9)$$

であり、第 5 回の群の中の共分散行列そのものである。 $p = 1$ なら $\hat{\sigma}^2 = s_W^2$ に戻る。

定義 2 (LDA の確率のモデル)．群の割合 π_q で群を選び、群の中では共通の共分散行列を持つ多変量正規分布 $N(\boldsymbol{\mu}_q, \boldsymbol{\Sigma})$ から $\mathbf{x}$ が出てくる、というモデルを LDA の確率のモデルと呼ぶ。データ全体の出方を仮定するので生成モデルである。最尤推定は $\hat{\pi}_q = n_q/n$ 、群の平均 $\hat{\boldsymbol{\mu}}_q$ 、群の中の共分散行列 $\hat{\boldsymbol{\Sigma}} = \mathbf{S}_W$ であり、数えるだけで求まる。

パラメータが決まれば、ベイズの定理 (4) 式で事後確率が出る。定義 1 により $\Pr(y = 1 | x) = \text{sig}(a(x))$ 、 $a(x) = \log\{\pi_1 f_1(x)/\pi_0 f_0(x)\}$ である。1 変数で中身を書くと、正規分布の密度の比の対数は指数の中の差になり、

$$a(x) = \log \frac{\pi_1}{\pi_0} - \frac{(x - \mu_1)^2 - (x - \mu_0)^2}{2\sigma^2} = \frac{d}{\sigma^2} \left(x - \frac{\mu_0 + \mu_1}{2} \right) + \log \frac{\pi_1}{\pi_0} \quad (10)$$

となる ($d = \mu_1 - \mu_0$)。2 つの二乗を展開すると x^2 の項は係数が同じなので打ち消し合い、 $a(x)$ は x の 1 次式になる。分散が 2 群で共通だと仮定したおかげである。群ごとに分散が違えば x^2 が残り、境界は曲がる (二次判別分析)。

p 変数でも同じ計算で、2 次形式の差のうち $\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x}$ が打ち消し合い、

$$a(\mathbf{x}) = \mathbf{w}^\top \left(\mathbf{x} - \frac{\boldsymbol{\mu}_0 + \boldsymbol{\mu}_1}{2} \right) + \log \frac{\pi_1}{\pi_0}, \quad \mathbf{w} = \hat{\boldsymbol{\Sigma}}^{-1} \mathbf{d} = \mathbf{S}_W^{-1} \mathbf{d} \quad (11)$$

となる。(9) 式により、事後確率の中身の向き $\mathbf{w}$ は第 5 回で 0/1 の最小二乗法の係数が指した判別方向 $\mathbf{S}_W^{-1}\mathbf{d}$ と同じである。LDA の判別方向は、最小二乗法でも最尤法でも同じになる。 $p = 1$ なら $\mathbf{w} = \mathbf{d}/\sigma^2$ で、(11) 式は (10) 式に戻る。

違うのは、最尤法ではこの向きの上に確率が乗ることである。図 7 は 図 6 と同じ人工データに、0/1 に当てた最小二乗法の直線(破線、第 5 回の方法)と、LDA の事後確率 $\text{sig}(a(x))$ (緑)を重ねたものである。直線は 0 と 1 の外へ伸びるが、事後確率はどの x でも 0 と 1 の間にあり、区間ごとの $y = 1$ の割合(黒の四角)を追って S 字に曲がる。




図 7: 図 6 と同じ人工データ(縦に少しずらして打った)。破線は 0/1 に当てた最小二乗法の直線、緑の曲線は LDA の事後確率、黒の四角は x の区間ごとの $y = 1$ の割合。橙の破線は 2 群の平均の中点、緑の点線は事後確率が $1/2$ になる点

確率が $1/2$ になるのは $a(\mathbf{x}) = 0$ のときである。(11) 式から、境界は $\mathbf{w}^\top(\mathbf{x} - \mathbf{m}) = \log(\pi_0/\pi_1)$ ($\mathbf{m}$ は中点) であり、第 5 回で予告したとおり、人数の比の対数が境界に入る。 $y = 1$ の群が少なければ($\pi_1 < \pi_0$) 右辺は正で、境界は中点から $y = 1$ の群の側へずれる。人工データでは中点 1.02 に対し、事後確率が $1/2$ になる x は 1.91 である。0/1 に当てた最小二乗法の境界 2.22 も同じ側へずれるが(第 5 回で見たずれ)、ずれの大きさは違う。最尤法の境界は「どちらの群である確率が高いか」で決まるので、ずれの理由を確率で説明できる。

ロジスティック回帰

(11) 式で見たとおり、LDA の事後確率は $\text{sig}(\mathbf{w}^\top \mathbf{x} + w_0)$ 、すなわち $\mathbf{x}$ の 1 次式をシグモイド関数に通した形になる。この形は、群ごとに正規分布を置き、共分散を共通とした仮定から導かれた。では、 $\mathbf{x}$ の出方は何も仮定せず、事後確率がこの形であることだけを仮定したらどうなるか。これがロジスティック回帰(logistic regression)である。

定義 3 (ロジスティック回帰). $\mathbf{x}_i$ を与えたときの y_i がベルヌーイ分布に従い、その確率が

$$\Pr(y_i = 1 \mid \mathbf{x}_i) = \theta_i = \text{sig}(\mathbf{x}_i^\top \boldsymbol{\beta}) \quad (12)$$

であるとするモデルをロジスティック回帰と呼ぶ。 $\mathbf{x}_i$ の先頭の成分を 1 にして、切片を β に含める。対数オッズ $\log\{\theta_i/(1 - \theta_i)\}$ が $\mathbf{x}_i$ の 1 次式になる。群を識別する確率だけを仮定するので識別モデルである。

1 変数なら $\theta_i = \text{sig}(\beta_0 + \beta x_i)$ 、行列で書けばデータ行列 $\mathbf{X}$ (先頭の列が 1) について $\boldsymbol{\theta} = \text{sig}(\mathbf{X}\boldsymbol{\beta})$ (シグモイド関数は成分ごとに当てる) である。第 1 回の線形回帰と同じ掛け算 $\mathbf{X}\boldsymbol{\beta}$ を作り、最後にシグモイド関数に通して 0 と 1 の間に収める。

y_i はベルヌーイ分布に従うので、1 行の確率は (1) 式のコインと同じ $\theta_i^{y_i}(1 - \theta_i)^{1-y_i}$ である。違うのは、表の確率 θ_i が行ごとに x_i で変わることだけである。行が独立なら、対数尤度は

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^n \left[y_i \log \theta_i + (1 - y_i) \log(1 - \theta_i) \right] \quad (13)$$

となる。

定義 4 (交差エントロピー). 0/1 の y_i と確率 θ_i について、 $-\frac{1}{n} \sum_{i=1}^n \{y_i \log \theta_i + (1 - y_i) \log(1 - \theta_i)\}$ を交差エントロピー(cross-entropy)と呼ぶ。(13) 式の符号を反転して n で割ったものであり、正解の側に付けた確率の $-\log$ の平均である。小さいほど確率がよく当たっている。

図 8 のとおり、1 行の寄与は、正解の側に 0.99 を付ければ 0.01、0.5 なら 0.69、0.01 なら 4.61 である。自信をもって外した行ほど大きく罰せられる。確率を 0.5 で切って一致を数える一致率は、正解の側に 0.51 を付けても 0.99 を付けても同じ 1 回の正解と数える。交差エントロピーは、判定ではなく確率そのものの当たり方を測る。




図 8: 正解の側に付けた確率と、その行の交差エントロピーへの寄与 $-\log$ (その確率)。点は確率 0.99、0.5、0.01 のときの値

まず 1 変数で微分する。 $a_i = \beta_0 + \beta x_i$ とおくと、(5) 式から $y_i \log \theta_i + (1 - y_i) \log(1 - \theta_i)$ の a_i による微分は $y_i(1 - \theta_i) - (1 - y_i)\theta_i = y_i - \theta_i$ になる。 a_i の β による微分は x_i なので、 $d\ell/d\beta = \sum_i (y_i - \theta_i)x_i$ 、同様に $\partial\ell/\partial\beta_0 = \sum_i (y_i - \theta_i)$ である。偏微分を縦に並べると、勾配は

$$\frac{\partial \ell}{\partial \boldsymbol{\beta}} = \mathbf{X}^\top (\mathbf{y} - \boldsymbol{\theta}) \quad (14)$$

となる。第 1 回の最小二乗法の勾配 $-2\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$ と同じく、データ行列の転置と「 y と予測の差」の積である。しかし $\boldsymbol{\theta}$ は $\boldsymbol{\beta}$ をシグモイド関数の中を含むので、勾配を 0 とおいた $\mathbf{X}^\top (\mathbf{y} - \boldsymbol{\theta}) = 0$ は $\boldsymbol{\beta}$ についての連立 1 次方程式にならない。閉じた形の解はなく、反復で解くことになる。

反復の手がかりは2階微分である。 $d\theta_i/d\beta = \theta_i(1-\theta_i)x_i$ なので $d^2\ell/d\beta^2 = -\sum_i \theta_i(1-\theta_i)x_i^2$ であり、 $0 < \theta_i < 1$ だからいつも負である。対数尤度は上に凸で、山頂は1つしかない。行列で書けば、2階の偏微分を並べた行列(ヘッセ行列)は $-\mathbf{X}^\top \mathbf{W} \mathbf{X}$ 、 $\mathbf{W} = \text{diag}(\theta_i(1-\theta_i))$ である。

山頂へは、今の点で対数尤度を放物線 $\ell(\beta) + \ell'(\beta)(t-\beta) + \frac{1}{2}\ell''(\beta)(t-\beta)^2$ で近似し、その頂点 $t = \beta - \ell'(\beta)/\ell''(\beta)$ へ移ることを繰り返せばよい。これがニュートン法(Newton's method)である。図9はみかんの人工データで、切片を最尤推定の値に固定して β だけを動かしたときの対数尤度である。 $\beta = 0.6$ の点で当てた放物線の頂点は1.71で、1回で山頂1.50の近くまで進む。




図9: みかんの人工データにロジスティック回帰を当てたときの、傾き β の対数尤度(切片は最尤推定の値に固定)。赤の破線は山頂、橙の破線は $\beta = 0.6$ で当てた放物線、緑の点はその頂点

計算の手順

2つのモデルの計算手順を行列で書く。LDAは数えて1回解くだけであり、ロジスティック回帰は同じ形の連立方程式を繰り返し解く。

LDAの手順は次のとおりである。

1. データ行列 $\mathbf{X}$ ($n \times p$)と0/1の $\mathbf{y}$ から、群の人数 n_q と割合 $\hat{\pi}_q = n_q/n$ を数える
2. 群の平均 $\hat{\mu}_1 = \frac{1}{n_1} \mathbf{X}^\top \mathbf{y}$ 、 $\hat{\mu}_0 = \frac{1}{n_0} \mathbf{X}^\top (\mathbf{1} - \mathbf{y})$ を作る。各行から自分の群の平均を引いた行列 $\mathbf{R}$ を作り、 $\mathbf{S}_W = \frac{1}{n} \mathbf{R}^\top \mathbf{R}$ とする
3. 連立方程式 $\mathbf{S}_W \mathbf{w} = \hat{\mu}_1 - \hat{\mu}_0$ を解き、 $w_0 = -\mathbf{w}^\top (\hat{\mu}_0 + \hat{\mu}_1)/2 + \log(\hat{\pi}_1/\hat{\pi}_0)$ とする。これは(11)式の切片である
4. 確率を $\theta = \text{sig}(\mathbf{X}\mathbf{w} + w_0\mathbf{1})$ で出す

反復はない。第5回の判別方向の計算に、切片と最後のシグモイド関数を加えれば済む。

ロジスティック回帰の手順は次のとおりである。

1. $\mathbf{X}$ の先頭に1の列を足して $n \times (p+1)$ とし、 $\beta = 0$ から始める
2. 今の β で $\theta = \text{sig}(\mathbf{X}\beta)$ と、対角に $\theta_i(1-\theta_i)$ を並べた $\mathbf{W}$ を作る
3. 連立方程式 $(\mathbf{X}^\top \mathbf{W} \mathbf{X}) \Delta = \mathbf{X}^\top (\mathbf{y} - \theta)$ を解き、 $\beta \leftarrow \beta + \Delta$ とする
4. Δ の成分がすべて十分小さくなるまで2~3を繰り返す

手順3は、1変数の更新 $\beta \leftarrow \beta + \ell'(\beta)/\{-\ell''(\beta)\}$ を、勾配(14)式とヘッセ行列 $-\mathbf{X}^\top \mathbf{W} \mathbf{X}$ で書き直したもの

$$\beta \leftarrow \beta + (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{y} - \theta) \quad (15)$$

である。 $p = 1$ で切片がなければ 1 変数の更新に戻る。係数行列 $\mathbf{X}^\top \mathbf{W} \mathbf{X}$ は第 1 回の $\mathbf{X}^\top \mathbf{X}$ に行ごとの重み $\theta_i(1 - \theta_i)$ を付けたものであり、毎回の更新は重み付きの正規方程式を解くことにあたる。このため、この手順は反復重み付き最小二乗法 (iteratively reweighted least squares) (IRLS) とも呼ばれる。重みは、確率が $1/2$ に近い行ほど大きく、0 や 1 に近い行ほど小さい。

生成と識別：向きがずれるとき

LDA とロジスティック回帰は、事後確率を同じ $\text{sig}(\mathbf{x}$ の 1 次式) の形で表す。LDA の仮定が正しければ、真の事後確率はまさにこの形なので、ロジスティック回帰が推定する対象も同じ 1 次式になる。それでも、2 つの推定値は一般には一致しない。何に合わせて係数を決めるかが違うからである。

LDA の向き $\mathbf{w} = \mathbf{S}_W^{-1}(\hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_0)$ は、すべての行の群の平均と群の中の広がりで決まる。境界から遠く間違えようのない行も、平均と共分散を通して同じ重みで向きに影響する。一方、ロジスティック回帰の勾配 (14) 式を 0 とおく条件 $\sum_i (y_i - \theta_i) \mathbf{x}_i = 0$ では、すでによく当たっている行 (θ_i が y_i に近い行) はほとんど寄与しない。係数を動かすのは、 $y_i - \theta_i$ が大きい当てにくい行、すなわち境界の近くの行である。

図 10 は、みかんを 2 つの量 (皮の色の濃さと皮の張り) で測った人工データで、2 つの向きを比べたものである。(a) のデータは、LDA の仮定どおり共通の共分散を持つ正規分布から作った。2 つの向きの差は 1.5 度である。(b) は $y = 1$ の群に、境界から遠く離れた点 40 個を足したものである。これらの点は、どちらの向きで見ても間違えようがない。それでも LDA の向きは、平均と群の中の共分散が動くために 30.5 度回り、ロジスティック回帰の向きは 0.0 度しか動かない。(b) で 2 つの向きの差は 32.0 度になる。




図 10: LDA の向き (黒の矢印) とロジスティック回帰の向き (橙の破線の矢印)。(a) 共通の共分散を持つ正規分布から作ったみかんの人工データ (2 変数)。(b) (a) の $y = 1$ の群に、境界から遠い 40 個を足したもの

生成モデルの LDA は、 $\mathbf{x}$ の出方の仮定を推定に使う。仮定が正しければ、その分だけ少ない行で安定した推定ができる。仮定が外れていれば、境界と関係のない行の散らばりにまで向きが引っぱられる。識別モデルのロジスティック回帰は $\mathbf{x}$ の出方を仮定しないので、仮定の外れには強いが、その分だけ推定のばらつきが大きくなりうる。2 つの向きが実データでどれだけずれるかは、第 II 部で確かめる。

完全に分けられるとき

ロジスティック回帰の対数尤度は上に凸だが、山頂があるとは限らない。図 11 は、1 変数の人工データで $y = 0$ の点がすべて負、 $y = 1$ の点がすべて正にあり、 $x = 0$ で完全に分けられる例である(切片は 0 とした)。図 11 (a) のとおり、 β の符号が同じなら境界は $x = 0$ のまま動かないが、 β が大きいほど S 字は急になり、階段に近づく。確率の形 $\text{sig}(x^\top \beta)$ では、係数の向きが境界を決め、係数の長さが S 字の急さ、すなわち確率が 0 や 1 に寄る度合いを決める。向きが同じ 2 つのモデルでも、長さが違えば確率の値は違う。

このデータは完全に分けられるので、 β を大きくするほどすべての行で θ_i が y_i に近づく。対数尤度 $\ell(\beta)$ は 0 に向かって上がり続け、どの有限の β でも最大にならない。反復で解けば、係数は際限なく大きくなり続ける。データが完全に分けられるとき、最尤推定は存在しない。変数が多いほど、行数に比べて完全に分けられる場合が起きやすい。

これを止めるには、係数の大きさに罰を付ける。第 4 回のリッジ回帰と同じ形の罰を対数尤度から引いた

$$\ell(\beta) - \frac{\lambda}{2} \sum_{j=1}^p \beta_j^2 \quad (16)$$

を最大にする(切片 β_0 には罰を付けない)。罰は β の 2 次式で下向きに曲がるので、図 11 (b) の破線のように山頂ができ、 $\lambda = 1$ では $\beta = 2.33$ で止まる。勾配は $\mathbf{X}^\top(\mathbf{y} - \boldsymbol{\theta}) - \lambda \mathbf{D}\boldsymbol{\beta}$ になる($\mathbf{D}$ は対角行列で、切片の成分だけ 0、ほかの成分は 1)。ヘッセ行列は $-(\mathbf{X}^\top \mathbf{W} \mathbf{X} + \lambda \mathbf{D})$ になる。(15) 式のニュートン法は、勾配とヘッセ行列をこの 2 つに置きかえればそのまま使える。第 4 回で罰則付き最小二乗法を置いたのと同じく、これは罰則付きの最尤法である。




図 11: 完全に分けられる 1 変数の人工データ($y = 0$ が青、 $y = 1$ が赤、各 20 個)。(a) β を大きくしたときの $\text{sig}(\beta x)$ 。(b) 対数尤度(実線)と、罰 $\beta^2/2$ を引いたもの(破線)

推定法の列が変わる

「モデル × 推定法」の地図でいえば、第 5 回までの推定法はすべて最小二乗法(第 4 回は罰則付き)であった。本章で初めて推定法の列が最尤法に変わった。第 1 回の表で最尤法の列に「第 6 回」と書いたマスは、線形回帰・LDA・ロジスティック回帰の 3 つであり、すべて本章で扱った。同じモデルでも、推定法を変えると答えの読み

方が変わる。LDA は第 5 回の最小二乗法では向き(スコア)を出し、本章の最尤法では同じ向きの上に確率を出した。

第 II 部 実データ解析

紙幣のデータ

第 II 部では、紙幣の真贋のデータ(banknote authentication)で第 I 部の結果を確かめる。このデータは Lohweg と Dörksen が UCI Machine Learning Repository に寄せたもので、CC BY 4.0 で公開されている。1 行は、本物の紙幣と紙幣に似せた試料を工業用のカメラで撮った画像 1 枚で、1,372 枚ある。画像をウェーブレット変換した値の分散・歪度・尖度と、画像のエントロピーの 4 列が説明変数である。目的変数は元のデータの区分の列で、区分 1 (610 枚)を偽札 $y = 1$ 、区分 0 (762 枚)を真札 $y = 0$ と読んだ。元のデータの説明は区分の 0 と 1 がどちらかを明記していないので、広く使われている読み方に従った。以下の計算は読み方によらない。4 列はそれぞれ標準化した。第 I 部の式を確かめる計算は全件で行った。判定の精度は、真贋の割合をそろえて 7:3 に分けた訓練 960 枚とテスト 412 枚で測った(標準化の平均と標準偏差も訓練の行で求めた)。第 I 部の冒頭では、画像の分散の 1 列だけに 0/1 の直線を当て、予測値が-0.37 から 1.39 まではみ出すのを見た。以下では 4 列を使い、3 つのモデルで見直す。

計算の手続きと検証

計算の手続きは次のとおりである。データ行列 $\mathbf{Z}$ は 4 列を標準化したもので、 $\mathbf{y}$ は偽札を 1 とした。LDA では、群の割合・群の平均・群の中の共分散行列 $\mathbf{S}_W$ を数えた。 $\mathbf{S}_W \mathbf{w} = \mathbf{d}$ は NumPy の線形方程式ソルバーで解き、(11) 式から確率を出した。scikit-learn の LinearDiscriminantAnalysis の確率とも比べた。同じ $\mathbf{Z}$ と $\mathbf{y}$ で、第 5 回の方法どおり 0/1 の最小二乗法の正規方程式も解いた。ロジスティック回帰では、罰則付きの目的関数 (16) 式の勾配とヘッセ行列を使い、(15) 式のニュートン法を手で回した。罰の強さは scikit-learn の LogisticRegression の既定と同じ $\lambda = 1$ とし、その係数と比べた。罰を外した $\lambda = 0$ も回した。

第 1 の検証は LDA である(表 1)。手で組んだ確率と scikit-learn の確率の差は最大 $6\text{e-}15$ で、数えて 1 回解くだけで同じ確率が出る。LDA の向きと 0/1 の最小二乗法の係数のコサインは 1.0000000 であり、判別方向は最小二乗法でも最尤法でも同じになる。

表 1: 紙幣のデータでの LDA の検証

確かめたこと	値
LDA の向き $\mathbf{S}_W^{-1} \mathbf{d}$ と 0/1 の最小二乗法の係数のコサイン	1.0000000
手で組んだ確率と scikit-learn の LDA の確率の差 (最大)	$6\text{e-}15$

第 2 の検証はニュートン法である(表 2)。係数を 0 から始めると、対数尤度は最初の数回で大きく上がり、9 回

で更新の大きさが 10^{-10} を下回った。止まった点での罰則付きの勾配の成分は最大 $5e-15$ で、scikit-learn の係数との差は最大 $2e-07$ である。罰を外しても、この 4 列では 14 回で止まる。データは完全には分けられず(真札の側に残る偽札、偽札の側に残る真札がある)、最尤推定が存在するからである。

表 2: ロジスティック回帰のニュートン法(罰の強さ $\lambda = 1$)の反復ごとの対数尤度と、係数の更新の成分の最大の絶対値

反復	1	2	3	4	5	6	7	8	9
対数尤度 ℓ	-270.7	-141.7	-91.1	-70.5	-63.5	-62.4	-62.4	-62.4	-62.4
更新の最大	1.81	1.07	0.99	0.79	0.41	0.08	3e-03	3e-06	3e-12

第 3 の検証は向きである(表 3)。ロジスティック回帰の係数と LDA の向きのコサインは $\lambda = 1$ で 0.998 (3.8 度)、罰なしで 0.9993 (2.1 度)であり、2 つの向きはほぼ重なる。第 I 部の 図 10 (a) と同じく、このデータでは「すべての行に合わせる」LDA と「当てにくい行に合わせる」ロジスティック回帰が、ほぼ同じ向きに着いた。2 つの向きは平均の差 $\mathbf{d}$ とは離れている(ロジスティック回帰と $\mathbf{d}$ のコサインは 0.70)。

表 3: 紙幣のデータの向きのコサインと角度

2 つの向き	コサイン	角度
LDA と 0/1 の最小二乗法	1.0000000	0.0°
ロジスティック回帰($\lambda = 1$)と LDA	0.998	3.8°
ロジスティック回帰(罰なし)と LDA	0.9993	2.1°

結果の読み方

図 12 は、全件で当てはめた 3 つのモデルの予測値を、同じ横軸で描いたものである。(a) の 0/1 の最小二乗法の予測値は、305 枚が 0 未満、179 枚が 1 を超えていた。4 列でほぼ完全に分けられるデータなので、多くの札の予測値が 0 と 1 の外に出てしまう。(b) のロジスティック回帰と (c) の LDA の確率は、どの札でも 0 と 1 の間にある。

LDA の確率は、0/1 の回帰の予測値と同じ向きの上に乗っている。図 13 は、横軸に $\hat{y}$ 、縦軸に LDA の確率をとったもので、すべての札が 1 本の S 字の曲線に乗る。どちらも同じ向き $\mathbf{S}_W^{-1} \mathbf{d}$ のスコアの単調な関数だからである。「122%」とは読めない $\hat{y} > 1$ の札は、LDA の確率ではほぼ 1 になる。最尤法は、向きのスコアを確率の目盛りに直したのである。

では、向きがほぼ同じ LDA とロジスティック回帰の確率は同じか。そうではない(表 4)。事後確率は $\text{sig}(\mathbf{w}^\top \mathbf{x} + w_0)$ であり、第 I 部の 図 11 (a) で見たとおり、向きが同じでも係数の長さ $\|\mathbf{w}\|$ が違えば、境界をまたぐときの S 字の急さが違う。LDA の係数の長さは 22.6、罰 $\lambda = 1$ のロジスティック回帰は 8.4 で、LDA のほうが急




図 12: 紙幣のデータの予測値の分布(青が真札、赤が偽札)。(a) 0/1 の最小二乗法の予測値、(b) ロジスティック回帰($\lambda = 1$)の確率、(c) LDA の確率。灰の線は 0 と 1。縦軸の上端を超える柱には枚数を書き添えた




図 13: 0/1 の最小二乗法の予測値 $\hat{y}$ (横軸)と LDA の確率(縦軸)。青が真札、赤が偽札

である。確率が 0.01 未満か 0.99 を超える札は、LDA で 1297 枚、ロジスティック回帰で 845 枚である。LDA では、0.5 で切ると誤りになる札のうち 5 枚にまで 0.01 未満か 0.99 超の確率が付く。LDA の長さは、群の中の共分散 $\mathbf{S}_W$ の小ささで決まる。この長さは、正規分布と共通の共分散という仮定のもとで「群はこれだけ離れている」と見積もった値である。しかし、このデータでは仮定は厳密には成り立っていない。たとえば尖度の列では、偽札の群の標準偏差が真札の 1.62 倍ある。ロジスティック回帰の長さは、当てにくい札 ($|y_i - \theta_i| > 0.1$ の札は 125 枚) と罰の強さで決まる。

表 4: 係数の長さと、確率が 0 か 1 に寄った札の枚数(全件)

	係数の長さ $\ \mathbf{w}\ $	0.01 未満か 0.99 超	誤りなのに 0.01 未満か 0.99 超
LDA	22.6	1297 枚	5 枚
ロジスティック回帰 ($\lambda = 1$)	8.4	845 枚	0 枚
ロジスティック回帰(罰 なし)	40.3	1296 枚	—

判定の結果は、どのモデルでもほとんど変わらない(表 5)。0.5 で切ると、全件ではロジスティック回帰($\lambda = 1$) が 98.1%、LDA が 97.7% の真贋と一致し、テストの 412 枚でもそれぞれ 99.3%、98.8% である。差が出るのは確率の値である。そこで、第 I 部で定義した交差エントロピー(定義 4)で確率の当たり方を測る。テストで測ると、LDA が 0.032、ロジスティック回帰が $\lambda = 1$ で 0.039、罰なしで 0.026 であった。罰の付け方ひとつで、確率の当たり方が LDA より良くも悪くもなる。これは落とし穴で改めて見る。

表 5: 確率(または予測値)を 0.5 で切ったときの真贋との一致率と、テストの交差エントロピー。テストは訓練の行だけで当てはめ直した

	確率が出るか	全件	テスト 412 枚	テストの交差エントロピー
0/1 の最小二乗法	いいえ	97.7%	98.8%	—
LDA (最尤法)	はい	97.7%	98.8%	0.032
ロジスティック回帰($\lambda = 1$)	はい	98.1%	99.3%	0.039
ロジスティック回帰(罰なし)	はい	99.2%	99.3%	0.026

落とし穴

第 I 部で見た完全な分離は、このデータで実際に起きる。4 列のままでは、真札の側に残る偽札と、偽札の側に残る真札がある。このため罰を外しても最尤推定が存在し、ニュートン法は 14 回で止まる。ところが、4 列の 2 乗と積の 10 列を足して 14 列にすると(足した列も標準化した)、1,372 枚の偽札と真札を 1 枚の平面で完全に分けられるようになる(線形計画法で、すべての札を正しい側に置く係数が見つかることを確かめた)。図 14 は、罰を外したニュートン法の反復ごとに、係数の絶対値の最大と対数尤度を描いたものである。4 列(緑)では

係数は止まるが、14 列(赤)では反復のたびに大きくなり、30 回で 142 に達しても止まらない。対数尤度は 0 に近づき、1,372 枚の確率が 0.01 未満か 0.99 を超える。確率を出すために最尤法を使ったのに、確率はほとんど 0 か 1 に偏り、係数の値は何回で反復を止めたかで決まる。最尤推定が存在しないからである。罰 $\lambda = 1$ を付けければ(黒)、14 列でも 10 回で止まる。列を足さなくても、枚数が少なければ同じことが起きる。全件から 200 枚を抜き出すことを 100 回繰り返すと、4 列のままでも 75 回で完全に分けられた。行に比べて列が多いほど、また群がよく離れているほど、完全な分離は起きやすい。




図 14: 紙幣のデータ(全件)のロジスティック回帰のニュートン法。4 列・罰なし(緑)、2 乗と積を足した 14 列・罰なし(赤)、14 列・罰の強さ $\lambda = 1$ (黒)の、(a) 係数の絶対値の最大と (b) 対数尤度の反復ごとの値

一方、罰は中立ではない。4 列に戻して、訓練の行で罰の強さ λ を変えながらロジスティック回帰を当てはめ、テストの交差エントロピーを測ったのが図 15 である。scikit-learn の LogisticRegression は何も指定しなければ $\lambda = 1$ の罰を付ける。このデータでは $\lambda = 1$ のテストの交差エントロピー 0.039 は、罰なしの 0.026 よりも LDA の 0.032 よりも大きい。罰によって係数が縮み(長さ 40.3 $\rightarrow$ 8.4)、S 字がなだらかになって、確率が 0.5 の側へ寄りすぎたためである。0.5 で切った一致率は変わらないので、判定だけを見ていると気づかない。罰の強さは、第 4 回と同じく交差検証(クロスバリデーション、CV)などで選ぶものである。既定の値に黙って任せてよいものではない。なお、この図はテストの行で測っているので、 λ を選ぶ道具としてではなく、罰の強さで確率が変わることを示すものとして読む。




図 15: 紙幣のデータ(4 列)のロジスティック回帰で、罰の強さ λ を変えたときのテストの交差エントロピー(訓練の行で当てはめ、テストの行で測った。左端は罰なし)。破線は LDA、赤の点は scikit-learn の既定の $\lambda = 1$

締め

まとめと次回の問い

本章の問いは「方向は出るが、確率が出ない。確率を出すにはどうすればよいか」であった。答えは、データの出方を確率分布で仮定し、手元のデータが出てくる確率を最大にする最尤法である。まず、第 1 回からの最小二乗法は、誤差が独立な正規分布に従うと仮定したときの最尤法であることを示した。対数尤度に誤差の二乗和がそのまま現れるからである。次に、群ごとに共通の共分散の正規分布を置いた LDA を最尤法で当てはめた。推定値は群の割合・平均・群の中の共分散行列 $\mathbf{S}_W$ になり、事後確率は $\text{sig}(\mathbf{w}^\top \mathbf{x} + w_0)$ 、 $\mathbf{w} = \mathbf{S}_W^{-1} \mathbf{d}$ となった。向きは第 5 回の最小二乗法と同じで、その上に確率が乗る。最後に、この形だけを直接置くロジスティック回帰を導いた。勾配は $\mathbf{X}^\top (\mathbf{y} - \boldsymbol{\theta})$ で、閉じた形の解がないのでニュートン法で解く。完全に分けられるデータでは最尤推定が存在せず、第 4 回と同じ形の罰で止める。紙幣のデータでは、LDA の向きは 0/1 の最小二乗法の係数とコサイン 1.0000000 で一致し、ロジスティック回帰の向きとも 3.8 度しか違わなかった。それでも係数の長さが違うので確率の値は違い、罰の強さによっても変わった。2 乗と積の列を足すと完全に分けられ、罰なしでは係数が止まらなかった。

同じ学期の演習 8 では、心臓病のデータ (303 人) で、線形回帰の予測が -0.18 から 1.34 にはみ出すのを見たあと、ロジスティック回帰で一人ひとりに 0 から 1 の確率を出す。交差検証 (クロスバリデーション、CV) の正解率はロジスティック回帰が 0.828、LDA が 0.832 でほぼ同じである。本章で見たとおり、確率の仮定の置き方が違っても、判定の成績は近くなりうる。

最後に、次回への問いを置く。本章では、確率を 0.5 で切って一致率を数えてきた。しかし、偽札を真札と言う見逃しと、真札を偽札と言う誤検出とは、誤りの重さが違う。確率が出たとき、どこで切ればよいのか。そして、一致率だけでモデルを比べてよいのか。次回は、誤りの重さからしきい値を決める考え方と、評価の指標が置いている暗黙の仮定を扱う。