第 6 回 分類②：最尤法

データの出方を仮定すると、確率が出る

本章の問いは、第 5 回の締めで残った「方向は出るが、確率が出ない。確率を出すには？」である。答えは、データの出方を確率分布で仮定し、そのデータが出てくる確率（尤度）を最大にする最尤法である。ロジスティック回帰は確率の形 sig（1 次式）だけを置き、ニュートン法で解く。最小二乗法は誤差が正規分布のときの最尤法であり、LDA を最尤法で当てはめると第 5 回と同じ向きに事後確率が出る。

第 I 部　理論

確率を出すには

第 5 回では、2 つの群を 0 と 1 で表して最小二乗法の直線を当てると、係数の向きが線形判別分析（LDA）の判別方向 $\mathbf{S}_{\mathrm{W}}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$ に一致することを見た。しかし予測値は 0 と 1 の間に収まらず、確率としては読めなかった。本章では新しいデータでこの問題を見直す。紙幣の画像から測った量で、偽札（$y = 1$）と真札（$y = 0$）を見分けるデータである（第 II 部で詳しく述べる）。図 1 は、画像の分散という 1 つの量だけに直線を当てたものである。予測値は -0.37 から 1.39 まで伸び、1,372 枚のうち 256 枚で 0 未満か 1 を超える。一方、分散を幅 1 の区間に分けて偽札の割合を求めた（黒の四角）。割合は分散の小さい側でほぼ 1、大きい側でほぼ 0 になり、その間を S 字に曲がってつなぐ。直線はこの曲がりを追えない。新しい行での当たり方を測るには、第 2 回と同じく訓練・テスト分割が欠かせない。第 I 部では仕組みを見るため、手元の行はすでに分けた訓練の行とみなす。テストの行での当たり方は、第 II 部で測る。

ここから 3 つの困りごとが出てくる。1 つ目は、「この札が偽札である確率は」と聞かれたときに、0 と 1 の間に収まる答えを返したいことである。2 つ目は、群が 3 つ以上あるときである。みかんを皮の色の濃さだけで酸っぱい・ふつう・甘いに分けようとすると、第 5 回の最小二乗法では、真ん中の群が一度も選ばれなかった（マスキング）。3 つ目は、係数の効き目の伝え方である。皮の色が 1 段濃くなると甘い確率が 0.32 から 0.68 に上がる、と言っても、確率の差は場所によって変わる。場所によらない 1 つの数で効き目を言いたい。

本章の問いは、第 5 回の締めで残した 1 つである。方向は出るが、確率が出ない。確率を出すにはどうすればよいか。答えは最尤法（maximum likelihood）である。データがどのように出てくるかを確率分布で仮定し、手元のデータが出てくる確率を最大にするパラメータを選ぶ。本章は 2 周で進む。前半では、例と図で答えまで一周する。尤度と確率の分布の道具をそろえたあと、確率の形 sig（1 次式）だけを置くロジスティック回帰を、最尤法で当てはめる。その係数はオッズ比で読め、3 群以上へはソフトマックス関数で広げる。最尤推定が存在しないときも見る。次に、第 1 回からの最小二乗法が、誤差に正規分布を仮定したときの最尤法にほかならないことを

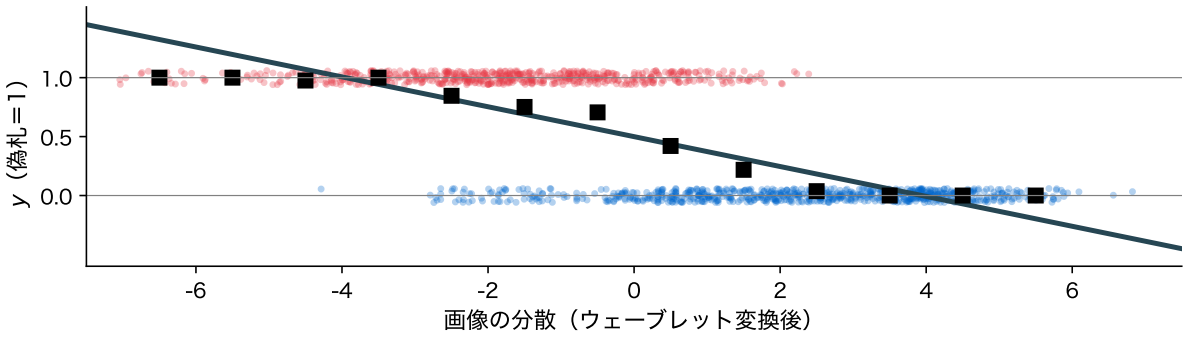


図 1: 紙幣のデータの画像の分散（ウェーブレット変換後）と真贋（偽札＝ 1 が赤、真札＝ 0 が青。縦に少しずらして打った）。直線は 0/1 に当てた最小二乗法、黒の四角は分散の区間（幅 1、10 枚以上）ごとの偽札の割合

確かめる。最後に、群ごとに $\boldsymbol{x}$ の出方を正規分布で仮定した LDA を最尤法で当てはめると、第 5 回と同じ向きの上に確率が乗ることを見て、2 つのモデルを比べる。後半では、前半で結果だけを示したロジスティック回帰の勾配と対数尤度の山の形に戻り、式で導く。

「モデル × 推定法」の地図でいえば、第 5 回までの推定法はすべて最小二乗法（第 4 回は罰則付き）であった。本章で初めて推定法の列が最尤法に変わる。第 1 回の表で最尤法の列に「第 6 回」と書いたマスは、線形回帰・LDA・ロジスティック回帰の 3 つであり、すべて本章で扱う。同じモデルでも、推定法を変えると答えの読み方が変わる。LDA は第 5 回の最小二乗法では向き（スコア）を出し、本章の最尤法では同じ向きの上に確率を出す。

道具：尤度と確率の分布

確率を出す推定法には、第 5 回までにない道具が要る。確率の出方を表す分布、尤度、対数、そして確率を 0 と 1 の間に収める関数である。ここにまとめておく。

まず、0 か 1 しか取らない量の出方である。

定義 1 (ベルヌーイ分布). 0 か 1 をとる確率変数 y が、$0 \leq \theta \leq 1$ について

$$\Pr(y) = \theta^y (1-\theta)^{1-y}, \qquad y \in \{0, 1\}$$

に従うとき、y はパラメータ θ のベルヌーイ分布（Bernoulli distribution）に従うという。

$y = 1$ なら θ、$y = 0$ なら $1 - \theta$ になり、指数が場合分けの代わりをしている。コインを投げて表を $y = 1$、裏を $y = 0$ とすれば、θ は表の確率である。10 回投げて表が 7 回出たとき、各回が独立なら、この結果が出る確率は各回の確率の積

$$L(\theta) = \prod_{i=1}^{10} \theta^{y_i} (1-\theta)^{1-y_i} = \theta^7 (1-\theta)^3 \tag{1}$$

である。この式をデータを固定して θ の関数と見る。一般には、次のように定める。

定義 2 (尤度と最尤推定)**.** データ $y_1, \dots, y_n$ が互いに独立に、パラメータ θ をもつ確率(または密度) $f(y;\theta)$ に従うとする。データを固定して θ の関数と見た

$$L(\theta) = \prod_{i=1}^{n} f(y_i;\theta)$$

を尤度(likelihood)、その対数 $\log L(\theta)$ を対数尤度(log-likelihood)と呼ぶ。$L(\theta)$ を最大にする $\hat{\theta}$ を最尤推定量(maximum likelihood estimator)と呼び、$\hat{\theta}$ で θ を推定する方法を最尤法と呼ぶ。

図 2 (a) のとおり、(1) 式の尤度が最大になるのは $\theta = 0.7$、観測された表の割合そのものである。

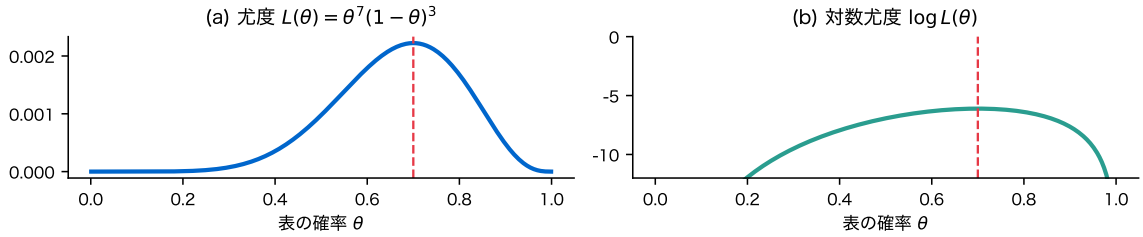


図 2: コインを 10 回投げて表が 7 回のときの、表の確率 θ の (a) 尤度と (b) 対数尤度。破線は最大の位置 $\theta = 0.7$

尤度は積なので、そのままでは扱いにくい。対数をとると、積は和になる。

命題 1 (対数尤度は 1 サンプルずつの和)**.** 定義 2 の尤度で、どの i でも $f(y_i;\theta) > 0$ とする。このとき

$$\log L(\theta) = \sum_{i=1}^{n} \log f(y_i;\theta) \tag{2}$$

である。

証明. 正の数 a, b について $\log(ab) = \log a + \log b$ である。これを $L(\theta) = f(y_1;\theta)\cdots f(y_n;\theta)$ に $n-1$ 回当てればよい。 □

この性質が、最尤法の計算を支える。1 つ目に、対数尤度は 1 サンプルずつの寄与 $\log f(y_i;\theta)$ の和であり、サンプルを 1 つ足すと項が 1 つ増えるだけである。2 つ目に、和の微分は各項の微分の和なので、n 個の積を微分するよりずっと簡単になる。3 つ目に、1 より小さい数を多く掛けた積は極端に小さくなる(0.5 を 1000 回掛けると約 10^{-301})が、和ならそうはならない。コインの例では、(2) 式から $\log L(\theta) = 7\log\theta + 3\log(1-\theta)$ となる(図 2 (b))。log は単調に増える関数なので、対数尤度が最大になる位置は尤度が最大になる位置と同じである。微分して 0 とおくと $7/\theta - 3/(1-\theta) = 0$、すなわち $\hat{\theta} = 0.7$ を得る。以後、最尤法ではいつも対数尤度を最大にする。

次に、連続の量の出方である。

定義 3 (正規分布)**.** $\mu \in \mathbb{R}$、$\sigma^2 > 0$ について、確率密度が

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\Big(-\frac{(x-\mu)^2}{2\sigma^2}\Big) \tag{3}$$

である分布を、平均 μ、分散 σ^2 の正規分布(normal distribution)と呼び、$N(\mu, \sigma^2)$ と書く。添え字のない π は円周率で、あとで群の割合を表す π_q とは別の記号である。$N(0,1)$ を標準正規分布と呼ぶ。

x が μ から離れるほど、その距離の二乗に比例して指数の中が小さくなり、出にくくなる。

密度から確率を読むには、面積をとる。

定義 4 (累積分布関数)**.** 確率変数 X について、$F(x) = \Pr(X \le x)$ を累積分布関数(cumulative distribution function)と呼ぶ。標準正規分布の累積分布関数を

$$\Phi(x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\, dt \tag{4}$$

と書く。

$\Phi(x)$ は、標準正規分布の密度の x より左の面積である。図 3 のとおり、x を右へ動かすと $\Phi(x)$ は 0 から 1 へ S 字で増え、どんな x でも 0 と 1 の間に収まる。この曲線は「はい・いいえ」の確率の形として自然に現れる。たとえば麺のゆで時間を伸ばしていくとき、「やわらかい」と感じる境目が人ごとに正規分布で散らばっているとする。ゆで時間 x で「やわらかい」と答える人の割合は、境目が x 以下の人の割合、すなわち累積分布関数になる。

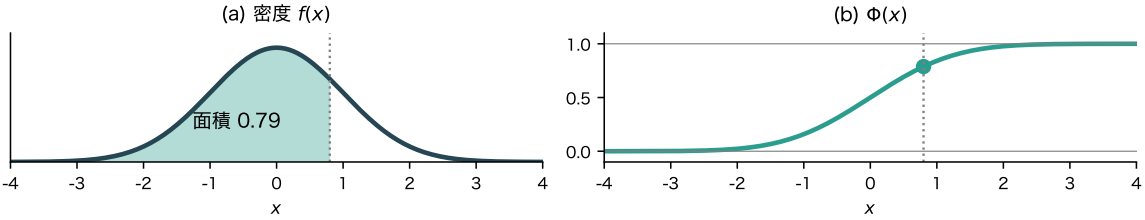


図 3: 標準正規分布の (a) 密度と $x = 0.8$ より左の面積、(b) 累積分布関数 $\Phi(x)$。点は $x = 0.8$ の値

ただし Φ は積分のままで、式で閉じた形には書けない。ほとんど同じ S 字を積分なしで書けるのが、$\mathrm{sig}(a) = 1/(1+e^{-a})$ である。横軸を 1.7 倍に伸ばした $\Phi(a/1.7)$ と比べると、2 本の曲線の差は最大でも 0.01 ほどしかない。以下では、確率の形にこの関数を使う。

定義 5 (シグモイド関数と対数オッズ)**.** 実数 a の関数 $\mathrm{sig}(a) = 1/(1+e^{-a})$ をシグモイド関数(sigmoid function)(ロジスティック関数)と呼ぶ。$0 < \theta < 1$ について、$\log\{\theta/(1-\theta)\}$ を θ の対数オッズ(log-odds)と呼ぶ。

どんな実数 a に対しても $\mathrm{sig}(a)$ は 0 と 1 の間にあり、$a=0$ で $1/2$ になる。$\theta=\mathrm{sig}(a)$ を a について解くと $a=\log\{\theta/(1-\theta)\}$ なので、対数オッズはシグモイド関数の逆関数である。

ロジスティック回帰

確率を出す最初のモデルは、困りごと①の答えをそのまま形にしたものである。図 1 の偽札の割合は、0 と 1 の間で S 字に曲がった。シグモイド関数も 0 と 1 の間の S 字であり、中身を 1 次式 $\beta_0+\beta x$ にすると、β_0 と β で曲線の位置と急さが動く。そこで、確率がこの形であることだけを仮定し、$\boldsymbol{x}$ の出方は何も仮定しない。これがロジスティック回帰(logistic regression)である。

仕組みを見るため、ここでは人工的なデータを使う。みかん 150 個の皮の色の濃さ x（標準化した値)と、食べて甘かった($y=1$、30 個)か酸っぱかった($y=0$、120 個)かである。

定義 6 (ロジスティック回帰)**.** $\boldsymbol{x}_i$ を与えたときの y_i がベルヌーイ分布に従い、その確率が

$$\Pr(y_i=1\mid \boldsymbol{x}_i)=\theta_i=\mathrm{sig}(\boldsymbol{x}_i^{\top}\boldsymbol{\beta}) \tag{5}$$

であるとするモデルをロジスティック回帰と呼ぶ。ただし $\boldsymbol{x}_i$ の先頭の成分を 1 とし、切片を $\boldsymbol{\beta}$ に含める。

対数オッズ $\log\{\theta_i/(1-\theta_i)\}$ が $\boldsymbol{x}_i$ の 1 次式 $\boldsymbol{x}_i^{\top}\boldsymbol{\beta}$ になる。群を識別する確率だけを仮定するので、識別モデル(discriminative model)と呼ぶ。

1 変数なら $\theta_i=\mathrm{sig}(\beta_0+\beta x_i)$、行列で書けばデータ行列 $\mathbf{X}$（先頭の列が 1)について $\boldsymbol{\theta}=\mathrm{sig}(\mathbf{X}\boldsymbol{\beta})$（シグモイド関数は成分ごとに当てる)である。第 1 回の線形回帰と同じ掛け算 $\mathbf{X}\boldsymbol{\beta}$ を作り、最後にシグモイド関数に通して 0 と 1 の間に収める。

ロジスティック回帰の目的関数は、最尤法の対数尤度である。これを最大にする $\boldsymbol{\beta}$ を選ぶ。

y_i はベルヌーイ分布に従うので、1 行の確率は (1) 式のコインと同じ $\theta_i^{y_i}(1-\theta_i)^{1-y_i}$ である。違うのは、表の確率 θ_i が行ごとに $\boldsymbol{x}_i$ で変わることだけである。行が独立なら、命題 1 より対数尤度は

$$\ell(\boldsymbol{\beta})=\sum_{i=1}^{n}\Big[y_i\log\theta_i+(1-y_i)\log(1-\theta_i)\Big] \tag{6}$$

となる。

定義 7 (交差エントロピー)**.** 0/1 の y_i と確率 $\theta_i\in(0,1)$（$i=1,\dots,n$)について

$$-\frac{1}{n}\sum_{i=1}^{n}\{y_i\log\theta_i+(1-y_i)\log(1-\theta_i)\}$$

を交差エントロピー(cross-entropy)と呼ぶ。

交差エントロピーは (6) 式の符号を反転して n で割ったものであり、正解の側に付けた確率の $-\log$ の平均である。小さいほど確率がよく当たっている。対数尤度を最大にすることは、交差エントロピーを最小にすることと同じである。

図 4 のとおり、1 行の寄与は、正解の側に 0.99 を付ければ 0.01、0.5 なら 0.69、0.01 なら 4.61 である。自信をもって外した行ほど寄与が大きい。確率を 0.5 で切って正解を数える正解率（第 5 回）は、正解の側に 0.51 を付けても 0.99 を付けても同じ 1 回の正解と数える。交差エントロピーは、判定ではなく確率そのものの当たり方を測る。

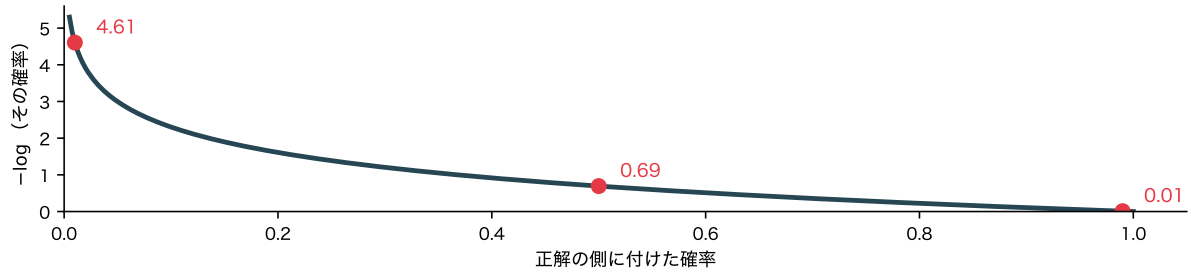


図 4: 正解の側に付けた確率と、その行の交差エントロピーへの寄与 $-\log$（その確率）。点は確率 0.99、0.5、0.01 のときの値

対数尤度 (6) 式の勾配と 2 階微分について、次の定理が成り立つ。

定理 1 (ロジスティック回帰の勾配とヘッセ行列)**.** 定義 *6* のモデルの対数尤度 *(6)* 式について

$$\frac{\partial \ell}{\partial \boldsymbol{\beta}} = \mathbf{X}^{\top}(\boldsymbol{y} - \boldsymbol{\theta}) \tag{7}$$

$$\frac{\partial^2 \ell}{\partial \boldsymbol{\beta}\, \partial \boldsymbol{\beta}^{\top}} = -\mathbf{X}^{\top}\mathbf{W}\mathbf{X}, \qquad \mathbf{W} = \operatorname{diag}(\theta_1(1-\theta_1), \dots, \theta_n(1-\theta_n)) \tag{8}$$

が成り立つ。さらに $\mathbf{X}$ の列が線形独立なら、ℓ を最大にする $\boldsymbol{\beta}$ は多くて *1* つである。

証明は「なぜ」の節で示す。第 1 回の最小二乗法の勾配 $-2\mathbf{X}^{\top}(\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta})$ と同じく、データ行列の転置と「y と予測の差」の積である。行 i の寄与は残差 $y_i - \theta_i$ に比例し、よく当たっている行ほど小さい。しかし $\boldsymbol{\theta}$ は $\boldsymbol{\beta}$ をシグモイド関数の中に含むので、勾配を 0 とおいた $\mathbf{X}^{\top}(\boldsymbol{y} - \boldsymbol{\theta}) = 0$ は $\boldsymbol{\beta}$ についての連立 1 次方程式にならない。閉じた形の解はなく、反復で解くことになる。

反復の手がかりは 2 階微分である。2 階の偏微分を並べた (8) 式の行列を、ヘッセ行列（Hessian matrix）と呼ぶ。$\mathbf{W}$ の対角成分 $\theta_i(1-\theta_i)$ はどれも正なので、対数尤度は上に凸になり、山頂は多くて 1 つである。1 変数なら $d^2\ell/d\beta^2 = -\sum_i \theta_i(1-\theta_i)x_i^2$ で、いつも負である。

山頂へは、今の点で対数尤度を放物線 $\ell(\beta) + \ell'(\beta)(t-\beta) + \frac{1}{2}\ell''(\beta)(t-\beta)^2$ で近似し、その頂点 $t = \beta - \ell'(\beta)/\ell''(\beta)$ へ移ることを繰り返せばよい。これがニュートン法（Newton's method）である。図 5 はみかんの

人工データで、切片を最尤推定の値に固定して β だけを動かしたときの対数尤度である。$\beta = 0.6$ の点で当てた放物線の頂点は 1.71 で、1 回で山頂 1.50 の近くまで進む。

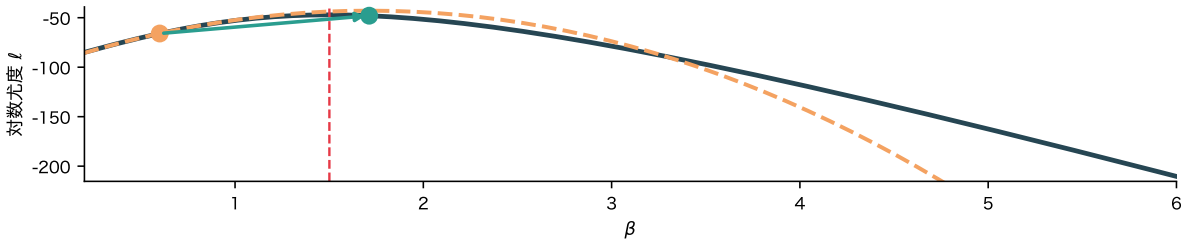


図 5: みかんの人工データにロジスティック回帰を当てたときの、傾き β の対数尤度(切片は最尤推定の値に固定)。赤の破線は山頂、橙の破線は $\beta = 0.6$ で当てた放物線、緑の点はその頂点

オッズとオッズ比

ロジスティック回帰の係数はどう読めばよいか。x を 1 増やしたときに確率がどれだけ上がるかは、S 字のどこにいるかで変わる。冒頭の困りごと③のように、0.32 が 0.68 になることもあれば、0.95 が 0.98 になるだけのこともある。そこで確率を言いかえる。

定義 8 (オッズとオッズ比)**.** 確率 $\theta \in (0,1)$ について、$\theta/(1-\theta)$ をオッズ(odds)と呼ぶ。2 つの確率 θ, θ' について、オッズの比 $\{\theta/(1-\theta)\}/\{\theta'/(1-\theta')\}$ をオッズ比(odds ratio)と呼ぶ。

定義 5 の対数オッズは、オッズの対数である。

試合に勝つ確率 0.8 は、勝つ：負ける ＝ 4：1 であり、オッズは 4 である。確率 0.5 ならオッズは 1、0.2 なら 0.25 になる。(5) 式の確率を対数オッズに直すと

$$\log \frac{\theta_i}{1-\theta_i} = \beta_0 + \beta x_i$$

となり、x の 1 次式になる(図 6)。シグモイド関数の逆の変換であるから当然である。したがって x が 1 増えると、対数オッズはどこでも β だけ増え、オッズは e^{β} 倍になる。この倍率がオッズ比であり、S 字のどこにいても同じである。みかんの人工データでは $\hat{\beta} = 1.50$ で、皮の色が 1 段濃いと、甘いオッズは 4.5 倍になる。

変数が多いときは、ほかの列の値を固定したまま列 j を 1 増やしたときに、オッズが e^{β_j} 倍になる。列を標準化してから当てたなら、1 標準偏差ぶん増やしたときの倍率である。ただし、第 5 回で見たように、似た列があると係数は打ち消し合う。オッズ比も係数の指数なので、同じ注意が要る。

計算の手順

ロジスティック回帰の計算手順を行列で書く。はじめに行を訓練とテストに分け(第 2 回の訓練・テスト分割)、当てはめは訓練の行だけで行う。当たり方は、当てはめに使っていないテストの行で測る。手順は次のとおりである。

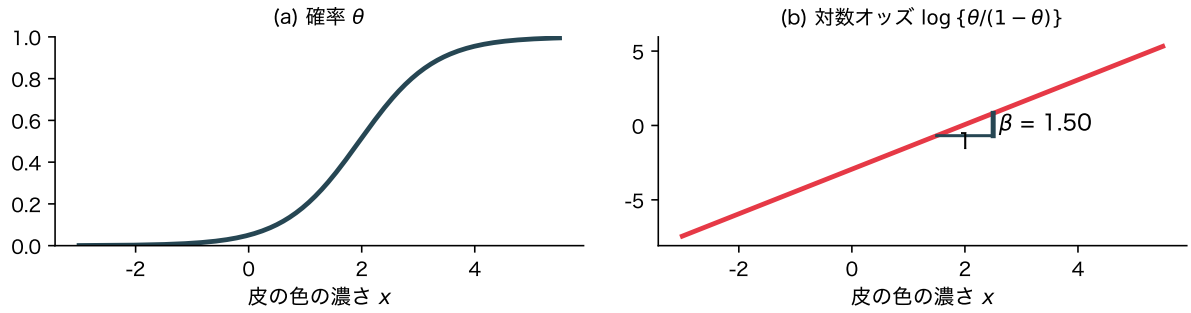


図 6: みかんの人工データに当てたロジスティック回帰。(a) 確率、(b) 対数オッズ。対数オッズは直線で、x が 1 増えると $\hat{\beta}$ だけ上がる

1. $\mathbf{X}$ の先頭に 1 の列を足して $n \times (p+1)$ とし、$\boldsymbol{\beta} = 0$ から始める
2. 今の $\boldsymbol{\beta}$ で $\boldsymbol{\theta} = \mathrm{sig}(\mathbf{X}\boldsymbol{\beta})$ と、対角に $\theta_i(1-\theta_i)$ を並べた $\mathbf{W}$ を作る
3. 連立方程式 $(\mathbf{X}^\top \mathbf{W} \mathbf{X})\boldsymbol{\Delta} = \mathbf{X}^\top(\boldsymbol{y} - \boldsymbol{\theta})$ を解き、$\boldsymbol{\beta} \leftarrow \boldsymbol{\beta} + \boldsymbol{\Delta}$ とする
4. $\boldsymbol{\Delta}$ の成分がすべて十分小さくなるまで 2〜3 を繰り返す
5. テストの行の確率を $\boldsymbol{\theta} = \mathrm{sig}(\mathbf{X}\hat{\boldsymbol{\beta}})$ で出し、当たり方を測る

手順 3 は、1 変数の更新 $\beta \leftarrow \beta + \ell'(\beta)/\{-\ell''(\beta)\}$ を、勾配 (7) 式とヘッセ行列 $-\mathbf{X}^\top \mathbf{W} \mathbf{X}$ で書き直したもの

$$\boldsymbol{\beta} \;\leftarrow\; \boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top (\boldsymbol{y} - \boldsymbol{\theta}) \tag{9}$$

である。$p = 1$ で切片がなければ 1 変数の更新に戻る。係数行列 $\mathbf{X}^\top \mathbf{W} \mathbf{X}$ は第 1 回の $\mathbf{X}^\top \mathbf{X}$ に行ごとの重み $\theta_i(1-\theta_i)$ を付けたものであり、毎回の更新は重み付きの正規方程式を解くことにあたる。このため、この手順は反復重み付き最小二乗法（iteratively reweighted least squares）（IRLS）とも呼ばれる。重みは、確率が 1/2 に近い行ほど大きく、0 や 1 に近い行ほど小さい。

3 群以上：ソフトマックス関数

群が 3 つ以上あるときも、同じ考え方で確率が出る。群 q ごとに 1 次式 $a_q(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{\beta}_q$ を作り、大きいほどその群らしいとする。この k 個の数を、0 と 1 の間にあって足すと 1 になる確率に直せばよい。

定義 9 （ソフトマックス関数）. $\boldsymbol{a} = [a_1, \ldots, a_k]^\top \in \mathbb{R}^k$ について、

$$\mathrm{softmax}(\boldsymbol{a})_q = \frac{e^{a_q}}{\sum_{r=1}^{k} e^{a_r}} \tag{10}$$

をソフトマックス関数（softmax function）と呼ぶ。

ソフトマックス関数は、k 個の数を、0 と 1 の間にあって足すと 1 になる確率に直す。$k = 2$ なら $e^{a_1}/(e^{a_0} + e^{a_1}) = \mathrm{sig}(a_1 - a_0)$ であり、シグモイド関数に戻る。2 群の話は k 群の特別な場合にすぎない。

これを使うと、ロジスティック回帰は 3 群以上へ広がる。x の出方は仮定せず、群 q である確率を $\theta_{iq} = \mathrm{softmax}(\mathbf{B}^\top \boldsymbol{x}_i)_q$ と置く。$\mathbf{B}$ は $(p+1) \times k$ の係数行列で、どれか 1 つの基準の群の列を 0 に固定する（全部の列に同じベクトルを足しても確率が変わらないので）。y_i を第 5 回の指示行列 $\mathbf{Y}$ の行で表すと、対数尤度は $\ell(\mathbf{B}) = \sum_i \sum_q y_{iq} \log \theta_{iq}$、その勾配は $\mathbf{X}^\top(\mathbf{Y} - \boldsymbol{\Theta})$ であり、2 群の (7) 式と同じ形になる。これを多クラスのロジスティック回帰（multinomial logistic regression）と呼ぶ。ニュートン法で解ける。

冒頭の困りごと②に戻る（図 7）。皮の色の濃さだけで酸っぱい・ふつう・甘い（各 60 個）を分けると、第 5 回の指示行列の最小二乗法では、真ん中の「ふつう」と判定されたのは 0 個だった。多クラスのロジスティック回帰の確率で最大の群を選ぶと、60 個が「ふつう」と判定される。確率はどの群も 0 と 1 の間にあり、真ん中の群の確率は真ん中で山になる。最小二乗法の直線にはできなかった形である。

ただし、ソフトマックス関数のモデルは群の順序を使わない。群の番号を入れ替えても同じモデルになるので、品種や手書きの数字のように、順序のない群にそのまま使える。一方、酸っぱい・ふつう・甘いには順序がある。このモデルは、その順序の情報を捨てて当てはめている。順序のある群には、順序を使うモデルがある。たとえば累積ロジットモデル（cumulative logit model）（比例オッズモデル）は、「群 q 以下である確率」を $\Pr(y \le q \mid \boldsymbol{x}) = \mathrm{sig}(c_q - \boldsymbol{x}^\top \boldsymbol{\beta})$ と置く。群ごとに変えるのはしきい値 c_q だけで、傾き $\boldsymbol{\beta}$ はすべての群で共通にする。

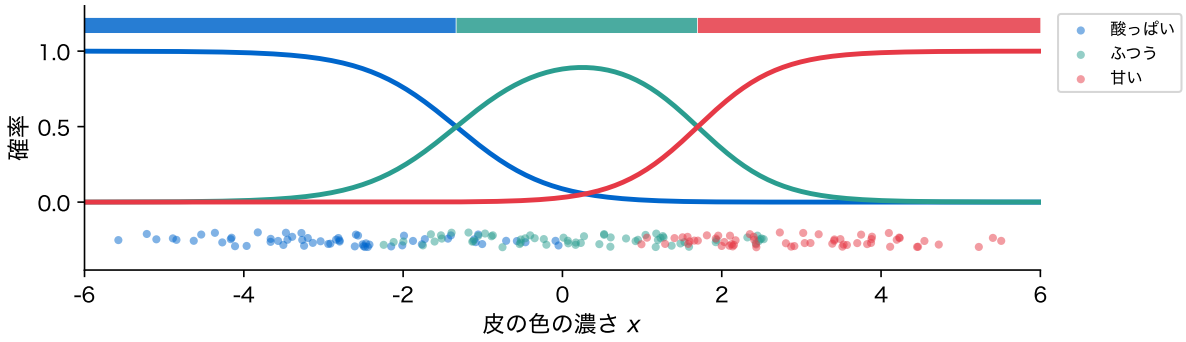


図 7: 皮の色の濃さだけで 3 群（酸っぱい・ふつう・甘い、各 60 個）を分ける人工データに当てた、多クラスのロジスティック回帰の確率。上の帯は確率が最大の群。真ん中の群も選ばれる

完全に分けられるとき

ロジスティック回帰の対数尤度は上に凸だが、山頂があるとは限らない。図 8 は、1 変数の人工データで $y = 0$ の点がすべて負、$y = 1$ の点がすべて正にあり、$x = 0$ で完全に分けられる例である（切片は 0 とした）。図 8 (a) のとおり、β の符号が同じなら境界は $x = 0$ のまま動かないが、β が大きいほど S 字は急になり、階段に近づく。確率の形 $\mathrm{sig}(\boldsymbol{x}^\top \boldsymbol{\beta})$ では、係数の向きが境界を決め、係数の大きさ（ℓ_2 ノルム $\|\boldsymbol{\beta}\|_2$）が S 字の急さ、すなわち確率が 0 や 1 に寄る度合いを決める。向きが同じ 2 つのモデルでも、大きさが違えば確率の値は違う。

このデータは完全に分けられるので、β を大きくするほどすべての行で θ_i が y_i に近づく。対数尤度 $\ell(\beta)$ は 0 に向かって上がり続け、どの有限の β でも最大にならない。反復で解けば、係数は際限なく大きくなり続ける。データが完全に分けられるとき、最尤推定は存在しない。変数が多いほど、行数に比べて完全に分けられる場合

が起きやすい。

これを止めるには、係数の大きさに罰則(penalty)を付ける。第 4 回の Ridge 回帰と同じ形の罰則を対数尤度から引いた

$$\ell(\boldsymbol{\beta}) - \frac{\lambda}{2}\sum_{j=1}^{p}\beta_j^2 \tag{11}$$

を最大にする(切片 β_0 には罰則を付けない)。罰則は β の 2 次式で下向きに曲がるので、図 8 (b) の破線のように山頂ができ、$\lambda = 1$ では $\beta = 2.33$ で止まる。勾配は $\mathbf{X}^\top(\boldsymbol{y} - \boldsymbol{\theta}) - \lambda\mathbf{D}\boldsymbol{\beta}$ になる($\mathbf{D}$ は対角行列で、切片の成分だけ 0、ほかの成分は 1)。ヘッセ行列は $-(\mathbf{X}^\top\mathbf{W}\mathbf{X} + \lambda\mathbf{D})$ になる。(9) 式のニュートン法は、勾配とヘッセ行列をこの 2 つに置きかえればそのまま使える。第 4 回で罰則付き最小二乗法を置いたのと同じく、これは罰則付きの最尤法である。

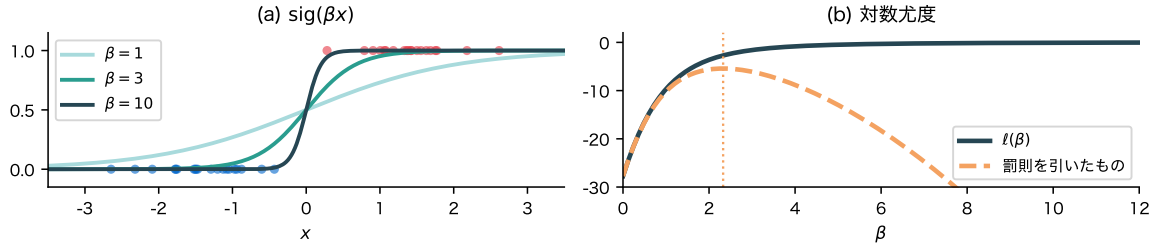


図 8: 完全に分けられる 1 変数の人工データ($y = 0$ が青、$y = 1$ が赤、各 20 個)。(a) β を大きくしたときの $\mathrm{sig}(\beta x)$。(b) 対数尤度(実線)と、罰則 $\beta^2/2$ を引いたもの(破線)

最小二乗法は正規誤差の最尤法

次のモデルに進む前に、第 1 回からの最小二乗法を最尤法の立場から見直す。最小二乗法は、誤差に正規分布を仮定したときの最尤法になっている。

データ行列 $\mathbf{X}$ の第 i 行を $\boldsymbol{x}_i^\top$ として $y_i = \boldsymbol{x}_i^\top\boldsymbol{\beta} + \varepsilon_i$ とし、誤差 $\varepsilon_1, \ldots, \varepsilon_n$ は独立に $N(0, \sigma^2)$ に従うとする。1 点の出やすさは、(3) 式の μ を $\boldsymbol{x}_i^\top\boldsymbol{\beta}$ に置いたものである。命題 1 から対数尤度は n 点の和になり、$\log e^u = u$ を使うと

$$\log L(\boldsymbol{\beta}, \sigma^2) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\|\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 \tag{12}$$

となる。第 1 項は n 個の同じ数の和である。$y_i - \boldsymbol{x}_i^\top\boldsymbol{\beta}$ は $\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}$ の第 i 成分なので、二乗の和は ℓ_2 ノルムの二乗になる。

$\boldsymbol{\beta}$ を含むのは第 2 項だけで、二乗和に負の数 $-1/(2\sigma^2)$ が掛かっている。したがって、対数尤度を最大にする $\boldsymbol{\beta}$ は、二乗和を最小にする $\boldsymbol{\beta}$ と同じであり、第 1 回の正規方程式 $\mathbf{X}^\top\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^\top\boldsymbol{y}$ の解になる。図 9 は、1 変数の

人工データ($y_i = \beta x_i + \varepsilon_i$、25 点)で、(a) 二乗和と (b) 対数尤度を β の関数として描いたものである((b) の σ^2 は下の $\hat{\sigma}^2$ に固定した)。谷底と山頂は、同じ $\hat{\beta} = 0.615$ にある。

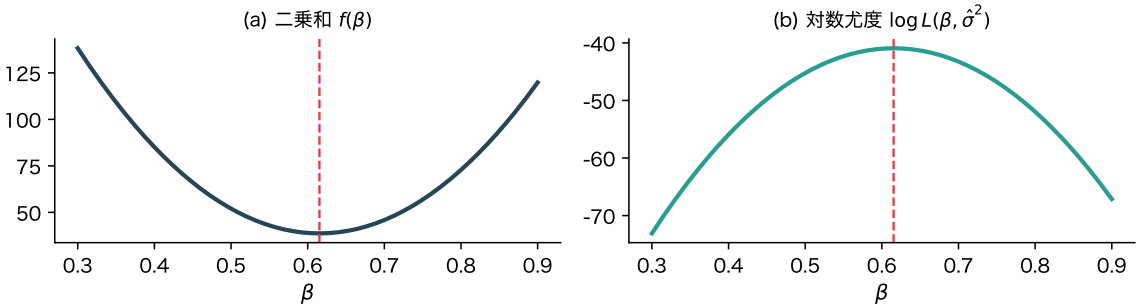


図 9: 1 変数の回帰の人工データ(25 点)の (a) 二乗和と (b) 対数尤度。破線は最小二乗法の解 $\hat{\beta}$

最尤法は σ^2 も決める。$s = \sigma^2$ とおき、$\boldsymbol{\beta}$ に $\hat{\boldsymbol{\beta}}$ を入れて (12) 式を s で微分すると、$\log(2\pi s) = \log 2\pi + \log s$ なので

$$\frac{\partial \log L}{\partial s} = -\frac{n}{2s} + \frac{1}{2s^2}\|\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|_2^2$$

である。これを 0 とおき、両辺に $2s^2$ を掛けると

$$\hat{\sigma}^2 = \frac{1}{n}\|\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|_2^2$$

を得る。残差の二乗和を n で割ったもので、人工データでは 1.548 である。微分は $s < \hat{\sigma}^2$ で正、$s > \hat{\sigma}^2$ で負なので、ここが山頂である。

対数尤度に負の符号を付けた $-\log L$ を、負の対数尤度(negative log-likelihood)と呼ぶ。尤度を最大にすることは、負の対数尤度を最小にすることと同じである。最小二乗法も最尤法も、目的関数を最小にする点を選ぶ方法で、違うのは目的関数の選び方だけである。誤差が正規分布なら、2 つの目的関数は同じ点で最小になる。

LDA に確率を乗せる

ロジスティック回帰は、y の出方だけを置いた。もう 1 つの道は、y で分けた群ごとに $\boldsymbol{x}$ の出方を置くことである。データ全体の出方を仮定するので、生成モデル(generative model)と呼ぶ。第 5 回の LDA をこの立場で見直すと、第 5 回と同じ向きの上に確率が乗る。

群ごとの出方には、多変量正規分布を使う。

定義 10 (多変量正規分布)**.** $\boldsymbol{\mu} \in \mathbb{R}^p$ と正定値の対称行列 $\boldsymbol{\Sigma}$ について、確率密度が

$$f(\boldsymbol{x}) = \frac{1}{(2\pi)^{p/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\Big(-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\Big) \tag{13}$$

である分布を、平均ベクトル $\boldsymbol{\mu}$、共分散行列 $\boldsymbol{\Sigma}$ の多変量正規分布と呼び、$N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ と書く。$|\boldsymbol{\Sigma}|$ は行列式である。

距離の二乗が、共分散行列の逆行列で測った 2 次形式に置きかわり、密度の等高線は楕円になる。$p = 1$ なら $\boldsymbol{\Sigma} = \sigma^2$ で、(13) 式は (3) 式に戻る。

次に、$\boldsymbol{x}$ を見たうえで群 1 である確率を求める。これには条件付き確率を使う。

定義 11 (条件付き確率)**.** 事象 B が起きたという条件のもとで事象 A が起きる確率を、条件付き確率 (conditional probability) と呼ぶ。これを $\Pr(A \mid B)$ と書き、$\Pr(B) > 0$ のとき

$$\Pr(A \mid B) = \frac{\Pr(A \text{ かつ } B)}{\Pr(B)}$$

で定める。B が起きたものの中で、A も起きたものが占める割合である。

2 つの群があり、群 q の割合を $\pi_q = \Pr(y = q)$、群 q の中での $\boldsymbol{x}$ の密度を $f_q(\boldsymbol{x})$ とする。$\boldsymbol{x}$ は連続量なので、ちょうど 1 点をとる確率は 0 である。そこで、$\boldsymbol{x}$ のまわりの小さな範囲をとり、$\boldsymbol{x}$ がそこに入る事象を B、範囲の大きさ (1 変数なら幅) を h とする。範囲が小さければ、群 q の中で B が起きる確率は $\Pr(B \mid y = q) \approx f_q(\boldsymbol{x})h$ である。定義 11 の分母を払うと

$$\Pr(y = q \text{ かつ } B) = \Pr(y = q)\Pr(B \mid y = q) \approx \pi_q f_q(\boldsymbol{x})\, h$$

となる。どの点もどれか 1 つの群に属するので、B の確率は群ごとの和である。

$$\Pr(B) = \sum_q \Pr(y = q \text{ かつ } B) \approx \sum_q \pi_q f_q(\boldsymbol{x})\, h$$

この 2 つを 定義 11 に入れると、分母と分子の h が約分で消える。範囲を狭めた極限を $\Pr(y = 1 \mid \boldsymbol{x})$ と書くと、群が 2 つ ($q = 0, 1$) のときは

$$\Pr(y = 1 \mid \boldsymbol{x}) = \frac{\pi_1 f_1(\boldsymbol{x})}{\pi_0 f_0(\boldsymbol{x}) + \pi_1 f_1(\boldsymbol{x})} \tag{14}$$

となる。これを事後確率 (posterior probability) と呼ぶ。一般に、$\Pr(A \mid B) = \Pr(B \mid A)\Pr(A)/\Pr(B)$ の形の式をベイズの定理 (Bayes' theorem) と呼ぶ。(14) 式は、A を「群 1」、B を「$\boldsymbol{x}$ のまわりの範囲」としたベイズの定理で、範囲を狭めた形である。群の割合と群の中の出やすさの積を、2 つの群で比べた比である。図 10 (a) は 1 変数の例で $\pi_q f_q(x)$ を描いたもの、(b) はその比から求めた事後確率である。x を動かすと、事後確率は 0 と 1 の間を S 字に曲がってつなぐ。

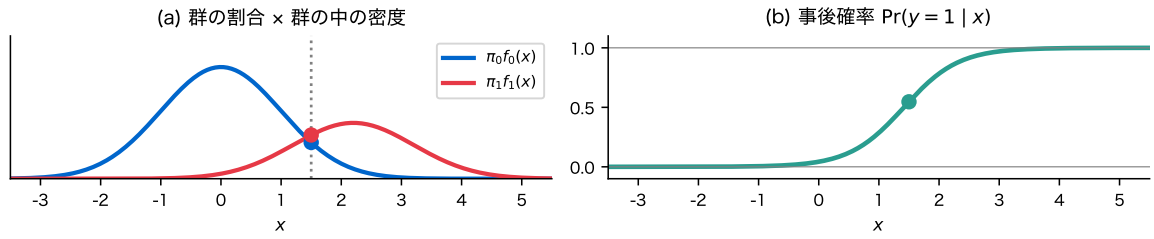


図 10: 1 変数の 2 群の例(群 1 の割合 1/3、群の中は平均 0 と 2.2、標準偏差 1 の正規分布)。(a) 群の割合と群の中の密度の積、(b) 事後確率。点は $x = 1.5$ の値

(14) 式の分母と分子を $\pi_1 f_1(\boldsymbol{x})$ で割ると、$\Pr(y = 1 \mid \boldsymbol{x}) = \mathrm{sig}(a(\boldsymbol{x}))$、$a(\boldsymbol{x}) = \log\{\pi_1 f_1(\boldsymbol{x})/\pi_0 f_0(\boldsymbol{x})\}$ の形になる。a は事後確率の対数オッズ(定義 5)である。シグモイド関数は、事後確率からも自然に出てくる。

LDA の確率のモデルでは、各行 $(\boldsymbol{x}_i, y_i)$ が独立に、次のように出てくると仮定する。まず群 $y_i = q$ が確率 π_q で選ばれ、次に群 q の中で $\boldsymbol{x}_i$ が $N(\boldsymbol{\mu}_q, \boldsymbol{\Sigma})$ に従って出てくる。共分散行列 $\boldsymbol{\Sigma}$ は、すべての群で共通とする。このモデルを最尤法で当てはめると、推定値は数えるだけで決まる。群の割合 $\hat{\pi}_q = n_q/n$、群の平均ベクトル $\hat{\boldsymbol{\mu}}_q$、そして第 5 回の群の中の共分散行列 $\hat{\boldsymbol{\Sigma}} = \mathbf{S}_{\mathrm{W}}$ である。図 11 は、みかんの人工データの群ごとのヒストグラムに、当てはめた正規分布の密度を重ねたものである。人工データでは $\hat{\pi}_1 = 0.200$、$\hat{\mu}_0 = 0.059$、$\hat{\mu}_1 = 1.978$、$\hat{\sigma}^2 = 1.229$ である。

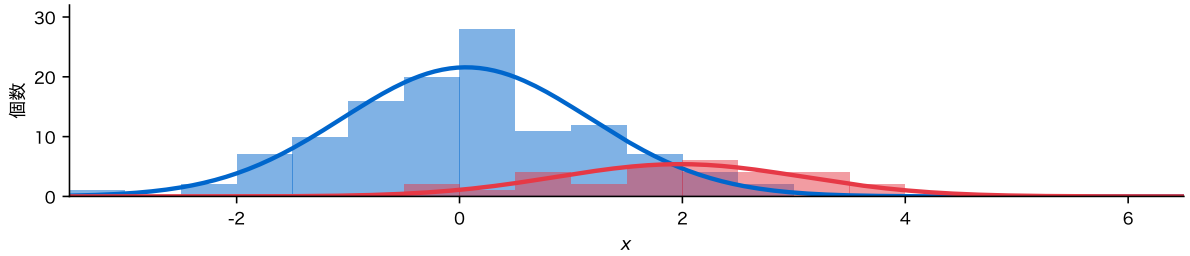


図 11: みかんの人工データ(皮の色の濃さ x。酸っぱい $y = 0$ が青、甘い $y = 1$ が赤)のヒストグラムと、最尤推定した LDA のモデルの群ごとの正規分布の密度(個数と幅 0.5 に合わせて拡大した)

推定値を (14) 式に入れると、事後確率の中身 $a(\boldsymbol{x}) = \log \pi_1 f_1(\boldsymbol{x}) - \log \pi_0 f_0(\boldsymbol{x})$ は

$$a(\boldsymbol{x}) = \boldsymbol{w}^\top \left(\boldsymbol{x} - \frac{\hat{\boldsymbol{\mu}}_0 + \hat{\boldsymbol{\mu}}_1}{2} \right) + \log \frac{\hat{\pi}_1}{\hat{\pi}_0}, \qquad \boldsymbol{w} = \mathbf{S}_{\mathrm{W}}^{-1} \boldsymbol{d}, \quad \boldsymbol{d} = \hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_0 \tag{15}$$

となる。2 つの密度の対数の差をとると、2 群で共通の $\boldsymbol{\Sigma}$ のおかげで 2 次の項 $\boldsymbol{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{x}$ が消え、$\boldsymbol{x}$ の 1 次式が残るからである。向き $\boldsymbol{w}$ は、第 5 回で 0/1 の最小二乗法の係数が指した判別方向と同じである。k 群でも、どの群の $\log \pi_q f_q(\boldsymbol{x})$ にも同じ 2 次の項が入り、ソフトマックス関数の分子と分母で打ち消し合う。事後確率は、群ごとの 1 次式をソフトマックス関数に通した形になる。

違うのは、最尤法ではこの向きの上に確率が乗ることである。図 12 は 図 11 と同じ人工データに、0/1 に当て

た最小二乗法の直線(破線、第 5 回の方法)と、LDA の事後確率 $\mathrm{sig}(a(x))$ (緑)を重ねたものである。直線は 0 と 1 の外へ伸びるが、事後確率はどの x でも 0 と 1 の間にあり、区間ごとの $y=1$ の割合(黒の四角)を追って S 字に曲がる。

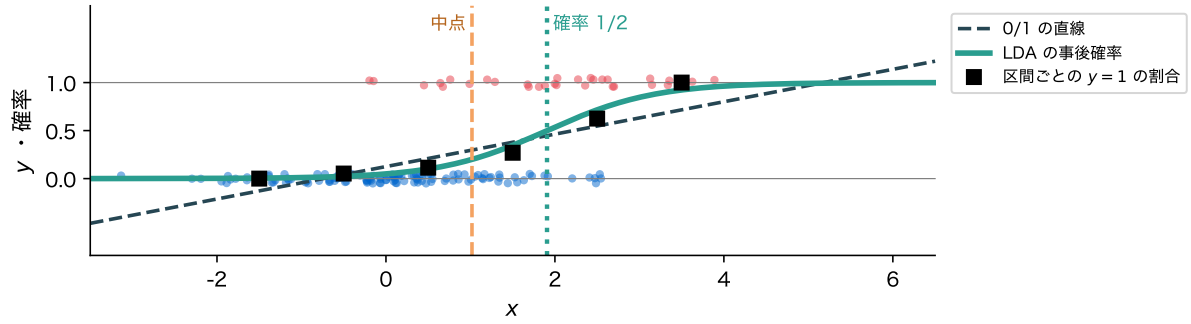


図 12: 図 11 と同じ人工データ(縦に少しずらして打った)。破線は 0/1 に当てた最小二乗法の直線、緑の曲線は LDA の事後確率、黒の四角は x の区間ごとの $y=1$ の割合。橙の破線は 2 群の平均の中点、緑の点線は事後確率が 1/2 になる点

確率が 1/2 になるのは $a(\boldsymbol{x})=0$ のときである。(15) 式から、境界は $\boldsymbol{w}^\top(\boldsymbol{x}-\boldsymbol{m})=\log(\pi_0/\pi_1)$ ($\boldsymbol{m}$ は中点)であり、第 5 回で予告したとおり、人数の比の対数が境界に入る。$y=1$ の群が少なければ($\pi_1<\pi_0$)右辺は正で、境界は中点から $y=1$ の群の側へずれる。人工データでは中点 1.02 に対し、事後確率が 1/2 になる x は 1.91 である。0/1 に当てた最小二乗法の境界 2.22 も同じ側へずれるが(第 5 回で見たずれ)、ずれの大きさは違う。最尤法の境界は「どちらの群である確率が高いか」で決まるので、ずれの理由を確率で説明できる。

生成と識別：向きがずれるとき

LDA とロジスティック回帰は、事後確率を同じ $\mathrm{sig}(\boldsymbol{x}$ の 1 次式 $)$ の形で表す。LDA の仮定が正しければ、真の事後確率はまさにこの形なので、ロジスティック回帰が推定する対象も同じ 1 次式になる。それでも、2 つの推定値は一般には一致しない。何に合わせて係数を決めるかが違うからである。

LDA の向き $\boldsymbol{w}=\mathbf{S}_{\mathrm{W}}^{-1}(\hat{\boldsymbol{\mu}}_1-\hat{\boldsymbol{\mu}}_0)$ は、すべての行の群の平均と群の中の広がりで決まる。境界から遠く間違えようのない行も、平均と共分散を通して同じ重みで向きに影響する。一方、ロジスティック回帰の勾配 (7) 式を 0 とおく条件 $\sum_i(y_i-\theta_i)\boldsymbol{x}_i=0$ では、すでによく当たっている行(θ_i が y_i に近い行)はほとんど寄与しない。係数を動かすのは、$y_i-\theta_i$ が大きい当てにくい行、すなわち境界の近くの行である。

図 13 は、みかんを 2 つの量(皮の色の濃さと皮の張り)で測った人工データで、2 つの向きを比べたものである。(a) のデータは、LDA の仮定どおり共通の共分散を持つ正規分布から作った。2 つの向きの差は 1.5 度である。(b) は $y=1$ の群に、境界から遠く離れた点 40 個を足したものである。これらの点は、どちらの向きで見ても間違えようがない。それでも LDA の向きは、平均と群の中の共分散が動くために 30.5 度回り、ロジスティック回帰の向きは 0.0 度しか動かない。(b) で 2 つの向きの差は 32.0 度になる。

生成モデルの LDA は、$\boldsymbol{x}$ の出方の仮定を推定に使う。仮定が正しければ、その分だけ少ない行で安定した推定ができる。仮定が外れていれば、境界と関係のない行の散らばりにまで向きが引っぱられる。識別モデルのロジ

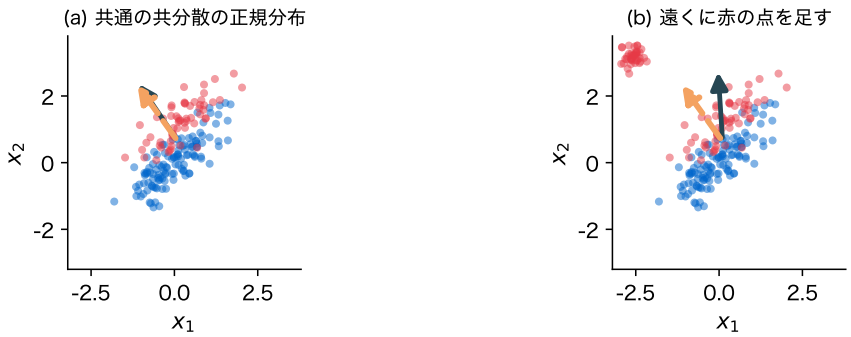


図 13: LDA の向き(黒の矢印)とロジスティック回帰の向き(橙の破線の矢印)。(a) 共通の共分散を持つ正規分布から作ったみかんの人工データ(2 変数)。(b) (a) の $y = 1$ の群に、境界から遠い 40 個を足したもの

スティック回帰は $\boldsymbol{x}$ の出方を仮定しないので、仮定の外れには強いが、その分だけ推定のばらつきが大きくなりうる。2 つの向きが実データでどれだけずれるかは、第 II 部で確かめる。

なぜ：勾配と山の形

ここまでで、本章の問いに答えを一周した。ここからは、前半で結果だけを示した点に戻り、式で導く。ロジスティック回帰の勾配とヘッセ行列(定理 1)と、ニュートン法の更新式である。証明には、対数の性質と合成関数の微分のほかに、次の 2 つの命題を使う。

命題 2 (シグモイド関数の微分)**.** シグモイド関数について、次の *(i)* と *(ii)* が成り立つ。

$$(i) \quad \frac{d\,\mathrm{sig}(a)}{da} = \mathrm{sig}(a)(1 - \mathrm{sig}(a))$$

$$(ii) \quad \frac{d\log \mathrm{sig}(a)}{da} = 1 - \mathrm{sig}(a), \qquad \frac{d\log(1 - \mathrm{sig}(a))}{da} = -\mathrm{sig}(a)$$

証明.

(i) $\mathrm{sig}(a) = (1 + e^{-a})^{-1}$ を微分すると $e^{-a}/(1 + e^{-a})^2$ であり、$1 - \mathrm{sig}(a) = e^{-a}/(1 + e^{-a})$ だからである。(ii) $\log u$ の微分は u'/u なので、(i) を $\mathrm{sig}(a)$ と $1 - \mathrm{sig}(a)$ で割ればよい。

□

命題 3 (山が 1 つの条件)**.** *1* 変数の関数 g の *2* 階微分が、すべての点で負であるとする。このとき $g'(t) = 0$ となる t は多くて *1* つであり、あればそこで g は最大になる。

証明. $g'' < 0$ なので、g' は減り続ける。したがって $g' = 0$ となる点は多くて 1 つであり、その点の左で $g' > 0$、右で $g' < 0$ になる。 □

これらを使って 定理 1 を証明する。

証明. まず目的関数を書き出す。(6) 式の対数尤度は、行ごとの項 ℓ_i の和

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^{n} \ell_i, \qquad \ell_i = y_i \log \theta_i + (1 - y_i) \log(1 - \theta_i)$$

であり、$\theta_i = \mathrm{sig}(a_i)$、$a_i = \boldsymbol{x}_i^\top \boldsymbol{\beta}$ である。和の微分は各項の微分の和なので、ℓ_i を微分すればよい。$\boldsymbol{\beta}$ は、$\boldsymbol{\beta} \to a_i \to \theta_i \to \ell_i$ と a_i を通してだけ ℓ_i に入る。そこで、まず ℓ_i を a_i で微分し、あとで a_i の勾配を掛ける。

θ_i に $\mathrm{sig}(a_i)$ を入れると

$$\ell_i = y_i \log \mathrm{sig}(a_i) + (1 - y_i) \log(1 - \mathrm{sig}(a_i))$$

である。y_i は観測した 0 か 1 で、a_i によらない定数である。命題 2 (ii) の 2 つの式から、第 1 項と第 2 項の微分はそれぞれ

$$\frac{d}{da_i}\, y_i \log \mathrm{sig}(a_i) = y_i(1 - \theta_i), \qquad \frac{d}{da_i}\, (1 - y_i) \log(1 - \mathrm{sig}(a_i)) = -(1 - y_i)\theta_i$$

となる。2 つを足して展開すると、$y_i\theta_i$ が打ち消し合い

$$\frac{d\ell_i}{da_i} = y_i - y_i\theta_i - \theta_i + y_i\theta_i = y_i - \theta_i$$

が残る。観測 y_i と確率 θ_i の差、すなわち残差である。

次に $\boldsymbol{\beta}$ で微分する。合成関数の微分により、外側の微分 $y_i - \theta_i$ に、中身 $a_i = \boldsymbol{x}_i^\top \boldsymbol{\beta}$ の勾配 $\boldsymbol{x}_i$ を掛けて

$$\frac{\partial \ell_i}{\partial \boldsymbol{\beta}} = (y_i - \theta_i)\, \boldsymbol{x}_i$$

を得る。$\mathbf{X}^\top$ の第 i 列は $\boldsymbol{x}_i$ なので、行ごとの勾配を足すと

$$\frac{\partial \ell}{\partial \boldsymbol{\beta}} = \sum_{i=1}^{n} (y_i - \theta_i)\, \boldsymbol{x}_i = \mathbf{X}^\top (\boldsymbol{y} - \boldsymbol{\theta})$$

となり、(7) 式を得る。

もう一度微分する。勾配を

$$\frac{\partial \ell}{\partial \boldsymbol{\beta}} = \sum_{i=1}^{n} y_i \boldsymbol{x}_i - \sum_{i=1}^{n} \theta_i \boldsymbol{x}_i$$

と 2 つの和に分ける。第 1 項は観測だけでできていて $\boldsymbol{\beta}$ によらないので、微分すると零行列になる。$\boldsymbol{\beta}$ を含むのは第 2 項の θ_i だけである。命題 2 (i) と合成関数の微分から

$$\frac{\partial \theta_i}{\partial \boldsymbol{\beta}^\top} = \theta_i(1-\theta_i)\,\boldsymbol{x}_i^\top$$

である。これを第 2 項に入れると、2 階の偏微分を並べたヘッセ行列は

$$\frac{\partial^2 \ell}{\partial \boldsymbol{\beta}\,\partial \boldsymbol{\beta}^\top} = -\sum_{i=1}^{n} \theta_i(1-\theta_i)\,\boldsymbol{x}_i\boldsymbol{x}_i^\top = -\mathbf{X}^\top \mathbf{W}\mathbf{X}, \qquad \mathbf{W} = \mathrm{diag}(\theta_i(1-\theta_i))$$

となり、(8) 式を得る。どの向き $\boldsymbol{v}$ をとっても

$$\boldsymbol{v}^\top(-\mathbf{X}^\top\mathbf{W}\mathbf{X})\boldsymbol{v} = -\sum_{i=1}^{n} \theta_i(1-\theta_i)\,(\boldsymbol{x}_i^\top\boldsymbol{v})^2 \le 0$$

であり、$0<\theta_i<1$ だから、$\mathbf{X}\boldsymbol{v}\neq 0$ なら負である。これは、$\boldsymbol{\beta}$ を向き $\boldsymbol{v}$ に動かす 1 変数の関数 $g(t)=\ell(\boldsymbol{\beta}+t\boldsymbol{v})$ の 2 階微分にあたる。いま、2 つの点 $\boldsymbol{\beta}_1\neq\boldsymbol{\beta}_2$ で ℓ が最大になったとする。どちらでも勾配は 0 なので、$\boldsymbol{v}=\boldsymbol{\beta}_2-\boldsymbol{\beta}_1$ の向きに切った $g(t)=\ell(\boldsymbol{\beta}_1+t\boldsymbol{v})$ は、$t=0$ と $t=1$ で $g'=0$ になる。$\mathbf{X}$ の列が線形独立なら $\mathbf{X}\boldsymbol{v}\neq 0$ で、$g''<0$ がすべての t で成り立つので、これは命題 3 に反する。したがって、最大の点は多くて 1 つである。 □

$p=1$ なら $\ell''(\beta)=-\sum_i \theta_i(1-\theta_i)x_i^2<0$ そのものである。ただし、最大の点があるとは限らない。前半の「完全に分けられるとき」がその例である。

ニュートン法は、今の点 β のまわりで対数尤度を放物線 $\ell(\beta)+\ell'(\beta)(t-\beta)+\frac{1}{2}\ell''(\beta)(t-\beta)^2$ で近似し、その頂点へ移る方法である。$\ell''(\beta)<0$ なので、放物線は微分 $\ell'(\beta)+\ell''(\beta)(t-\beta)$ が 0 になる点で最大になり、その頂点は $t=\beta-\ell'(\beta)/\ell''(\beta)$ にある。行列では、ℓ' を勾配 $\mathbf{X}^\top(\boldsymbol{y}-\boldsymbol{\theta})$ に、ℓ'' をヘッセ行列 $-\mathbf{X}^\top\mathbf{W}\mathbf{X}$ に置きかえ、割り算を逆行列に置きかえる。こうして計算の手順の (9) 式を得る。

第 II 部　実データ解析

第 II 部の進め方と予想

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、2 つのことが予想できる。1 つめに、0/1 の目的変数に直線を当てると、予測値は 0 と 1 の外へはみ出す。LDA とロジスティック回帰の確率は、sig を通すので 0 と 1 の間に収まる。2 つめに、LDA の仮定(群の中は正規分布で、共分散は共通)が正しければ、真の事後確率は sig($\boldsymbol{x}$ の 1 次式) になる。LDA とロジ

スティック回帰は、どちらもこの同じ 1 次式を推定する。紙幣のデータが仮定に近ければ、2 つの係数は向きも大きさもほぼ同じになるはずである。

紙幣のデータ

データには、紙幣の真贋のデータ（banknote authentication）を用いる。このデータは Lohweg と Dörksen が UCI Machine Learning Repository に寄せたもので、CC BY 4.0 で公開されている。1 行は、本物の紙幣と紙幣に似せた試料を工業用のカメラで撮った画像 1 枚で、1,372 枚ある。画像をウェーブレット変換した値の分散・歪度・尖度と、画像のエントロピーの 4 列が説明変数である。目的変数は元のデータの区分の列で、区分 1（610 枚）を偽札 $y = 1$、区分 0（762 枚）を真札 $y = 0$ と読んだ。元のデータの説明は区分の 0 と 1 がどちらかを明記していないので、広く使われている読み方に従った。以下の計算は読み方によらない。4 列はそれぞれ標準化した。第 I 部の冒頭では、画像の分散の 1 列だけに 0/1 の直線を当て、予測値が-0.37 から 1.39 まではみ出すのを見た。以下では 4 列を使い、3 つのモデルで見直す。

計算の手続きと結果

計算の手続きは次のとおりである。データ行列 $\mathbf{Z}$ は 4 列を標準化したもので、$\boldsymbol{y}$ は偽札を 1 とした。0/1 の最小二乗法は、第 5 回の方法どおり正規方程式を解いた。LDA では、群の割合・群の平均・群の中の共分散行列 $\mathbf{S}_{\mathrm{W}}$ を数えた。$\mathbf{S}_{\mathrm{W}}\boldsymbol{w} = \boldsymbol{d}$ を解き、(15) 式から確率を出した。ロジスティック回帰は罰則を付けずに、(9) 式のニュートン法を手で回した。予測値と係数は全件で当てはめて比べた。正解率と交差エントロピーは、真贋の割合をそろえて 7:3 に分けた訓練 960 枚で当てはめ直し、テスト 412 枚で測った（標準化の平均と標準偏差も訓練の行で求めた）。ニュートン法は罰則なしでも 14 回で止まった。4 列ではデータは完全には分けられず、最尤推定が存在するからである。

予想①は予想どおりだった（図 14）。(a) の 0/1 の最小二乗法の予測値は、305 枚が 0 未満、179 枚が 1 を超えた。4 列でほぼ完全に分けられるデータなので、多くの札の予測値が 0 と 1 の外に出る。(b) のロジスティック回帰と (c) の LDA の確率は、どの札でも 0 と 1 の間にある。

LDA の向きは、0/1 の最小二乗法の係数とコサイン 1.0000000 で一致した。これは第 I 部で見たとおりで、どのデータでも成り立つ。そのため図 15 のように、横軸に $\hat{y}$、縦軸に LDA の確率をとると、すべての札が 1 本の S 字の曲線に乗る。「122%」とは読めない $\hat{y} > 1$ の札は、LDA の確率ではほぼ 1 になる。

予想②は半分外れた（表 1）。ロジスティック回帰の係数と LDA の向きのコサインは 0.9993 で、角度は 2.1 度しか違わない。仮定どおりに作った第 I 部の人工データ（図 13 (a)）の 1.5 度と同じくらい近く、向きは予想どおりだった。ところが係数の大きさは、LDA が 22.6、ロジスティック回帰が 40.3 で、2 倍近く違った。第 I 部の図 8 (a) で見たとおり、確率 $\mathrm{sig}(\boldsymbol{w}^{\top}\boldsymbol{x} + w_0)$ は、向きが同じでも大きさが違えば S 字の急さが違う。0.5 で切ると、LDA は 32 枚を誤り、そのうち 5 枚に 0.01 未満か 0.99 超の確率を付けた。ロジスティック回帰の誤りは 11 枚で、そのような自信のある誤りは 0 枚だった。

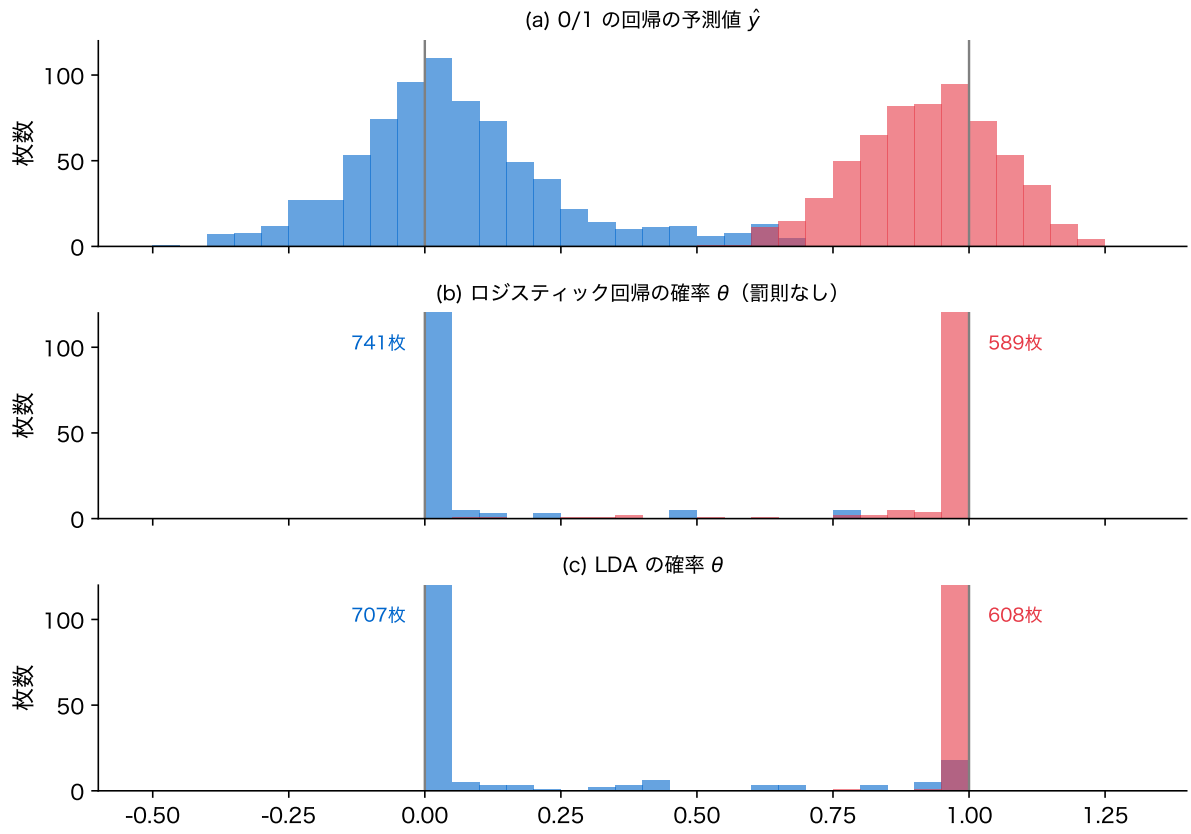


図 14: 紙幣のデータの予測値の分布（青が真札、赤が偽札）。(a) 0/1 の最小二乗法の予測値、(b) ロジスティック回帰（罰則なし）の確率、(c) LDA の確率。灰の線は 0 と 1。縦軸の上端を超える柱には枚数を書き添えた

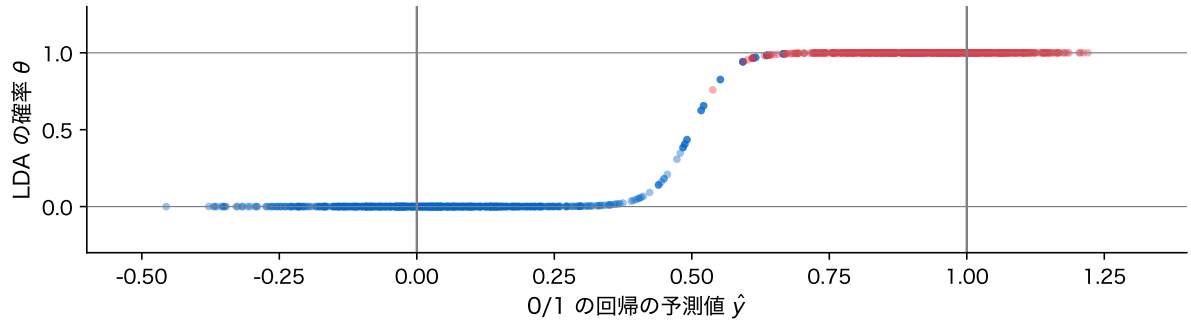


図 15: 0/1 の最小二乗法の予測値 $\hat{y}$（横軸）と LDA の確率（縦軸）。青が真札、赤が偽札

表 1: 係数の大きさと、0.5 で切ったときの誤りの枚数(全件)。右の列は、誤りのうち確率が 0.01 未満か 0.99 超の札

	係数の大きさ $\|\boldsymbol{w}\|$	誤りの枚数	うち 0.01 未満か 0.99 超
LDA	22.6	32 枚	5 枚
ロジスティック回帰(罰則なし)	40.3	11 枚	0 枚

判定の結果は、どのモデルでもほとんど変わらない(表 2)。0.5 で切ると、テストの 412 枚では LDA が 98.8%、ロジスティック回帰が 99.3% の真贋と一致した。差が出るのは確率の値である。第 I 部で定義した交差エントロピー(定義 7)で確率の当たり方を測ると、テストで LDA が 0.032、ロジスティック回帰が 0.026 であった。

表 2: 確率(または予測値)を 0.5 で切ったときの真贋との正解率と、テストの交差エントロピー。テストは訓練の行だけで当てはめ直した

	確率が出るか	全件	テスト 412 枚	テストの交差エントロピー
0/1 の最小二乗法	いいえ	97.7%	98.8%	—
LDA	はい	97.7%	98.8%	0.032
ロジスティック回帰(罰則なし)	はい	99.2%	99.3%	0.026

ずれの理由

係数の大きさがずれた理由は、LDA の仮定が紙幣のデータでは成り立っていないことにある。LDA は、2 つの群の中の散らばり(共分散)が同じだと仮定し、2 群をまとめた $\mathbf{S}_{\mathrm{W}}$ を使う。ところが 表 3 のとおり、尖度の列では偽札の群の標準偏差が真札の 1.62 倍ある。列どうしの相関も群で違い、画像の分散と歪度の相関は、真札で-0.23、偽札で 0.07 である。

表 3: 標準化した 4 列の、群ごとの標準偏差

列	真札の標準偏差	偽札の標準偏差	偽札 ÷ 真札
画像の分散	0.71	0.66	0.93
歪度	0.88	0.92	1.05
尖度	0.75	1.22	1.62
エントロピー	1.01	0.99	0.97

LDA の向き $\boldsymbol{w} = \mathbf{S}_{\mathrm{W}}^{-1}\boldsymbol{d}$ は、すべての札の群の平均と群の中の広がりで決まり、その大きさもそこで決まる。この大きさは、仮定が正しければ真の事後確率の S 字の急さになる。一方、ロジスティック回帰の勾配を 0 とおく条件 $\sum_i (y_i - \theta_i)\boldsymbol{x}_i = 0$ では、$y_i - \theta_i$ が大きい当てにくい札が係数を動かす。紙幣のデータで $|y_i - \theta_i| > 0.1$

となる札は 33 枚しかない。ロジスティック回帰は、境界の近くのこれらの札に合わせて S 字の急さを決める。仮定が正しければ、2 つのやり方は同じ 1 次式を狙う。仮定が外れると、狙う先が分かれる。このデータでは境界がほぼ 1 枚の平面で引けるので、向きはほとんど変わらず、大きさだけが大幅にずれた。境界の近くに合わせたロジスティック回帰のほうが、確率の当たり方もよかった。

オッズ比で読む

第 I 部では、ロジスティック回帰の係数をオッズ比として読めることを見た。冒頭の図 1 では、画像の分散が大きいほど偽札の割合が下がった。分散のオッズ比は 1 より小さく、4 列を入れても同じように読めると予想できる。

分散 1 列だけのロジスティック回帰では、係数は -1.01、オッズ比は 0.36 である。分散が 1 大きいと、偽札のオッズは約 3 分の 1 になる。素直に読める数であり、予想どおりである。

ところが 4 列を標準化して入れると、様子が変わる（表 4）。既定の罰則（$\lambda = 1$）では、1 標準偏差あたりのオッズ比は分散で 0.00724 と極端に小さい。罰則を外すと 2e-10 になり、何桁も変わる。「1 標準偏差で何倍」と読める数ではない。予想は外れた。

表 4: 紙幣のデータの 4 列のロジスティック回帰のオッズ比（1 標準偏差あたり）。既定の罰則と罰則なし

列（1 標準偏差あたり）	既定の罰則（$\lambda = 1$）	罰則なし
画像の分散	0.00724	2e-10
歪度	0.00647	2.1e-11
尖度	0.00991	1.28e-10
エントロピー	1.27	0.28

理由は第 I 部の「完全に分けられるとき」にある。紙幣は 4 列で、ほぼ完全に分けられる。そのとき係数の向きは決まるが、大きさ、つまり S 字の急さはデータでは決まらず、罰則が決める。オッズ比 e^{β_j} は係数の大きさで決まるので、罰則しだいで何桁も動く。オッズ比で読めるのは、群がほどほどに重なり、S 字の急さがデータで決まるときである。

落とし穴

第 I 部で見た完全な分離は、このデータで実際に起きる。4 列のままでは、真札の側に残る偽札と、偽札の側に残る真札がある。このため罰則を外しても最尤推定が存在し、ニュートン法は 14 回で止まる。ところが、4 列の 2 乗と積の 10 列を足して 14 列にすると（足した列も標準化した）、1,372 枚の偽札と真札を 1 枚の平面で完全に分けられるようになる（線形計画法で、すべての札を正しい側に置く係数が見つかることを確かめた）。図 16 は、罰則を外したニュートン法の反復ごとに、係数の絶対値の最大と対数尤度を描いたものである。4 列（緑）では係数は止まるが、14 列（赤）では反復のたびに大きくなり、30 回で 142 に達しても止まらない。対数尤度は 0 に近づき、1,372 枚の確率が 0.01 未満か 0.99 を超える。確率を出すために最尤法を使ったのに、確率はほと

んど 0 か 1 に偏り、係数の値は何回で反復を止めたかで決まる。最尤推定が存在しないからである。罰則 $\lambda = 1$ を付ければ(黒)、14 列でも 10 回で止まる。列を足さなくても、枚数が少なければ同じことが起きる。全件から 200 枚を抜き出すことを 100 回繰り返すと、4 列のままでも 75 回で完全に分けられた。行に比べて列が多いほど、また群がよく離れているほど、完全な分離は起きやすい。

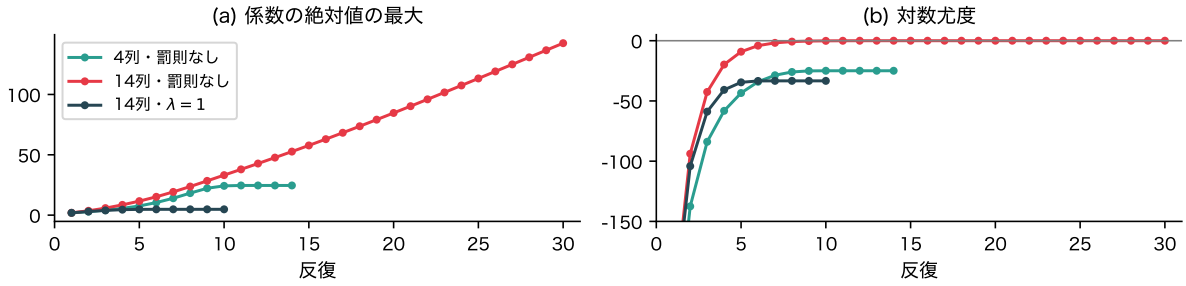


図 16: 紙幣のデータ(全件)のロジスティック回帰のニュートン法。4 列・罰則なし(緑)、2 乗と積を足した 14 列・罰則なし(赤)、14 列・罰則の強さ $\lambda = 1$ (黒)の、(a) 係数の絶対値の最大と (b) 対数尤度の反復ごとの値

一方、罰則は中立ではない。4 列に戻して、訓練の行で罰則の強さ λ を変えながらロジスティック回帰を当てはめ、テストの交差エントロピーを測ったのが図 17 である。広く使われている計算の道具には、何も指定しなければ $\lambda = 1$ の罰則を付けるものがある。このデータでは $\lambda = 1$ のテストの交差エントロピー 0.039 は、罰則なしの 0.026 よりも LDA の 0.032 よりも大きい。罰則によって係数が縮み(大きさ 40.3 → 8.4)、S 字がなだらかになって、確率が 0.5 の側へ寄りすぎたためである。0.5 で切った正解率は変わらないので、判定だけを見ていると気づかない。罰則の強さは、第 4 回と同じく交差検証(クロスバリデーション、CV)などで選ぶものである。既定の値に黙って任せてよいものではない。なお、図 17 はテストの行で測っているので、λ を選ぶ道具としてではなく、罰則の強さで確率が変わることを示すものとして読む。

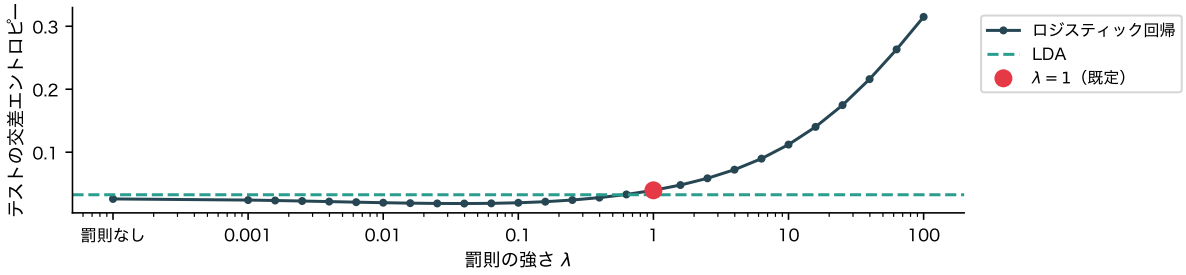


図 17: 紙幣のデータ(4 列)のロジスティック回帰で、罰則の強さ λ を変えたときのテストの交差エントロピー(訓練の行で当てはめ、テストの行で測った。左端は罰則なし)。破線は LDA、赤の点は既定の $\lambda = 1$

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは、0/1 の直線ははみ出し、LDA とロジスティック回帰の確率は 0 と 1 の間に収まると予想した。これは予想どおりだった。さらに、LDA の仮定に近いデータなら、2 つのモデルは同じ 1 次式に着くはずだと予想した。向きは予想どおりで、差は 2.1 度だった。ところが係数の大きさは 22.6

と 40.3 で、予想は外れた。理由は、2 つの群の散らばりが違い、共通の共分散という LDA の仮定が合っていないことにある。LDA はすべての札の平均と散らばりから大きさを決め、ロジスティック回帰は境界の近くの当てにくい札に合わせて大きさを決める。大きさが違うので、0.5 で切った判定はほぼ同じでも、確率の当たり方（交差エントロピー）には差が出た。確率を出すモデルを選ぶときは、判定の正解率だけでなく、確率そのものの当たり方を見る必要がある。係数をオッズ比で読むと、分散 1 列では「1 大きいとオッズは約 3 分の 1」と素直に読めた。だが 4 列ではほぼ完全に分かれるので、係数の大きさが罰則で決まり、オッズ比は何桁も動いた。

締め

まとめと次回の問い

本章の問いは「方向は出るが、確率が出ない。確率を出すにはどうすればよいか」であった。答えは、データの出方を確率分布で仮定し、手元のデータが出てくる確率を最大にする最尤法である。まず、確率の形 $\mathrm{sig}(\boldsymbol{x}^\top \boldsymbol{\beta})$ だけを置くロジスティック回帰を、最尤法で当てはめた。勾配は $\mathbf{X}^\top(\boldsymbol{y} - \boldsymbol{\theta})$ で、閉じた形の解がないのでニュートン法で解く。係数はオッズ比で読め、3 群以上へはソフトマックス関数で広がる。完全に分けられるデータでは最尤推定が存在せず、第 4 回と同じ形の罰則で止める。次に、第 1 回からの最小二乗法は、誤差が独立な正規分布に従うと仮定したときの最尤法であることを確かめた。対数尤度に誤差の二乗和がそのまま現れるからである。最後に、群ごとに共通の共分散の正規分布を置いた LDA を最尤法で当てはめた。推定値は群の割合・平均・群の中の共分散行列 $\mathbf{S}_\mathrm{W}$ になり、事後確率は $\mathrm{sig}(\boldsymbol{w}^\top \boldsymbol{x} + w_0)$、$\boldsymbol{w} = \mathbf{S}_\mathrm{W}^{-1}\boldsymbol{d}$ となった。向きは第 5 回の最小二乗法と同じで、その上に確率が乗る。紙幣のデータでは、LDA の向きは 0/1 の最小二乗法の係数とコサイン 1.0000000 で一致し、ロジスティック回帰（罰則なし）の向きとも 2.1 度しか違わなかった。それでも係数の大きさが違うので確率の値は違い、罰則の強さによっても変わった。2 乗と積の列を足すと完全に分けられ、罰則なしでは係数が止まらなかった。

最後に、次回への問いを置く。本章では、確率を 0.5 で切って正解率を数えてきた。しかし、偽札を真札と言う見逃しと、真札を偽札と言う誤検出とでは、誤りの重さが違う。確率が出たとき、どこで切ればよいのか。そして、正解率だけでモデルを比べてよいのか。次回は、誤りの重さからしきい値を決める考え方と、評価の指標が置いている暗黙の仮定を扱う。

発展

発展：見えない能力を測る

発展として、本章のロジスティック回帰と最尤推定を、見えない能力を測る道具として使う項目反応理論（item response theory）を紹介する。試験の点数や、リハビリで「できる動作の数」は、能力そのものではない。問題ごとに難しさが違うのに、合計点はどの問題も 1 点と数えるからである。

人 $i = 1, \ldots, n$ が問題 $j = 1, \ldots, p$ に正解する（その動作ができる）なら $y_{ij} = 1$、そうでなければ $y_{ij} = 0$ とする。2 パラメータのモデルでは、正解の確率を

$$\theta_{ij} = \Pr(y_{ij} = 1) = \mathrm{sig}(a_j(z_i - b_j)) \tag{16}$$

と置く。z_i は人 i の能力で、観測されない。b_j は問題 j の困難度(difficulty)と呼び、$z_i = b_j$ のとき確率が 1/2 になる。a_j は識別力(discrimination)と呼び、大きいほど S 字が急に立ち上がる。対数オッズ(定義 5)をとると

$$\log \frac{\theta_{ij}}{1-\theta_{ij}} = a_j z_i - a_j b_j$$

となる。問題 j ごとに見れば、能力 z_i を説明変数とするロジスティック回帰である。違いは、説明変数 z_i が観測されないことだけである。z_i・a_j・b_j を合わせて、尤度を最大にして推定する。

1 つ目は教育の例である。Murias Quintana et al. (2024) は、スペインの研修医の選抜試験から、2009 年から 2021 年までの 2,890 問を調べた。各問に (16) 式を当てはめ、問題の形と識別力の関係を比べた(図 18)。(a) は直接問う問題で、能力が上がると正解の確率が急に上がる。(b) は「誤っているものを選べ」という否定形の問題で、能力が上がっても正解の確率は上がらない。この問題では、能力の高い人と低い人を見分けられない。著者らは、否定形の問いを試験から避けるよう勧めている。

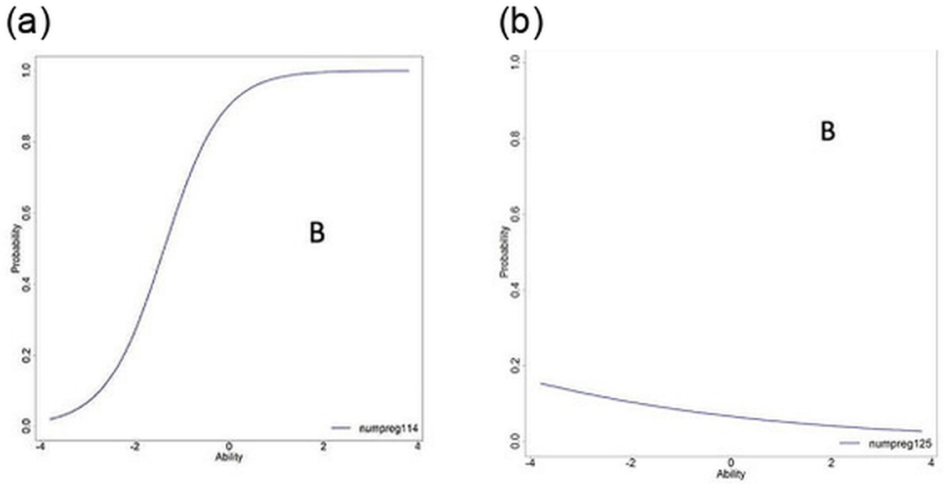


図 18: 研修医の選抜試験の 2 問に当てはめた、能力(横軸)と正解の確率(縦軸)の曲線。(a) 直接問う問題、(b) 否定形の問題。出典：Murias Quintana et al. (2024) BMC Med. Educ. 24: 367, Fig. 2 と Fig. 3（曲線の図を切り出して並べた。CC BY 4.0）

2 つ目はリハビリの例である。Feng et al. (2022) は、入院中の脳卒中の患者 130 人を、WHO の生活機能分類の 45 項目で評価した。各項目は「問題なし(1)」か「問題あり(0)」の 2 値である。識別力 a_j を全項目で同じ値にしたモデル(ラッシュモデル(Rasch model))を当てはめると、曲線は平行に並ぶ(図 19)。右にある項目ほど難しく、「体を洗う」(d510) や「歩く」(d450) が最も難しかった。最も易しいのは「意識」(b110) などであった。

図 20 は、患者の能力 z_i の分布(左)と項目の困難度 b_j（右)を、同じ目盛りに並べた図である。人と項目が同じ物差しに乗るので、ある患者が次にできそうな動作を読み取れる。合計点では、易しい項目の 1 点と難しい項目の 1 点とで、差の重さが違う。能力 z_i の目盛りなら、どこでも差の重さがそろう。そのため、リハビリの前後で z_i を測れば、回復の大きさを比べられる(Tennant & Küçükdeveci, 2023)。学力も回復度も、確率のモデルを置いて最尤推定で測れる。

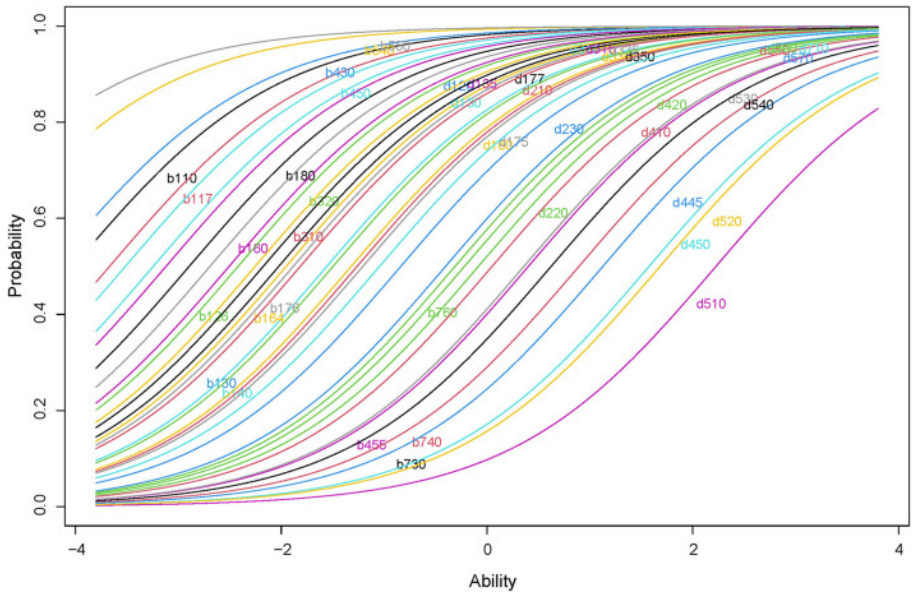


図 19: 脳卒中の患者の生活機能 45 項目の曲線。横軸は能力、縦軸は「問題なし」の確率。出典：Feng et al. (2022) Front. Neurol. 13: 827247, Fig. 7（CC BY 4.0）

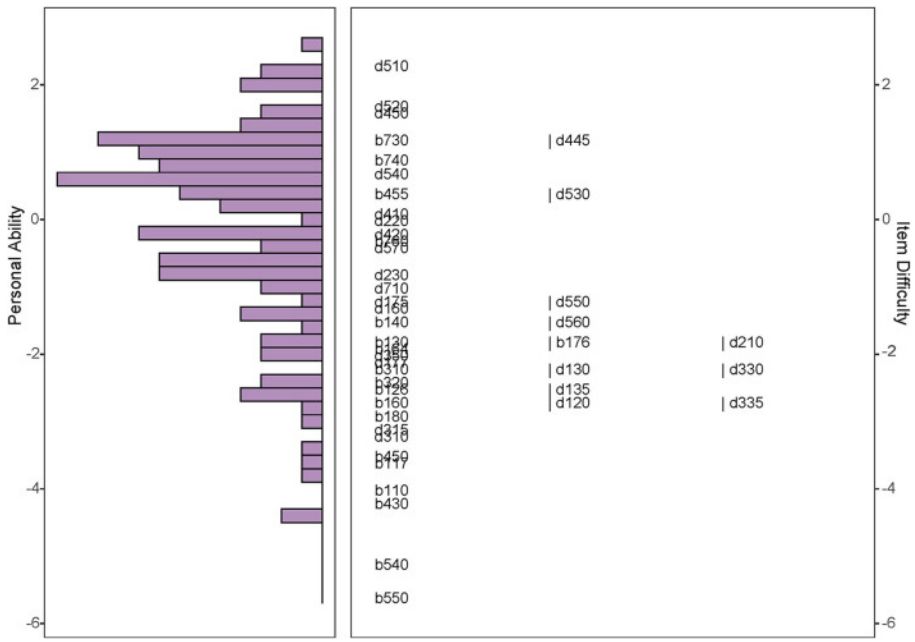


図 20: 患者の能力の分布（左）と項目の困難度（右）を同じ目盛りに並べた図。出典：Feng et al. (2022) Front. Neurol. 13: 827247, Fig. 6（CC BY 4.0）

参考文献

- Murias Quintana, E., Rodríguez Castro, J., Sánchez Lasheras, F., Vega Villar, J., Curbelo García, J. J., Cadenas Rodríguez, M., & Baladrón Romero, J. (2024). Improving the ability to discriminate medical multiple-choice questions through the analysis of the competitive examination to assign residency positions in Spain. BMC Medical Education, 24, 367.
- Feng, C., Jiang, Z.-L., Sun, M.-X., & Lin, F. (2022). Simplified post-stroke functioning assessment based on ICF via dichotomous Mokken scale analysis and Rasch modeling. Frontiers in Neurology, 13, 827247.
- Tennant, A., & Küçükdeveci, A. A. (2023). Application of the Rasch measurement model in rehabilitation research and practice: early developments, current practice, and future challenges. Frontiers in Rehabilitation Sciences, 4, 1208670.