

第 6 回 分類② : 最尤法

データの出方を仮定すると、確率が出る

本章の問いは、第 5 回の締めで残った「方向は出るが、確率が出ない。確率を出すには？」である。答えは、データの出方を確率分布で仮定し、そのデータが出てくる確率(尤度)を最大にする最尤法である。最小二乗法は誤差が正規分布のときの最尤法であり、LDA を最尤法で当てはめると第 5 回と同じ向きに事後確率が出る。ロジスティック回帰は事後確率を直接置き、ニュートン法で解く。

第 I 部 理論

確率を出すには

第 5 回では、2 つの群を 0 と 1 で表して最小二乗法の直線を当てると、係数の向きが線形判別分析(LDA)の判別方向 $\mathbf{S}_W^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$ に一致することを見た。しかし予測値は 0 と 1 の間に収まらず、確率としては読めなかった。本章では新しいデータでこの問題を見直す。紙幣の画像から測った量で、偽札($y = 1$)と真札($y = 0$)を見分けるデータである(第 II 部で詳しく述べる)。図 1 は、画像の分散という 1 つの量だけに直線を当てたものである。予測値は -0.37 から 1.39 まで伸び、1,372 枚のうち 256 枚で 0 未満か 1 を超える。一方、分散を幅 1 の区間に分けて偽札の割合を求めた(黒の四角)。割合は分散の小さい側でほぼ 1、大きい側でほぼ 0 になり、その間を S 字に曲がってつなぐ。直線はこの曲がりを追えない。

ここから 3 つの困りごとが出てくる。1 つ目は、「この札が偽札である確率は」と聞かれたときに、0 と 1 の間に収まる答えを返したいことである。2 つ目は、群が 3 つ以上あるときである。みかんを皮の色の濃さだけで酸っぱい・ふつう・甘いに分けようすると、第 5 回の最小二乗法では、真ん中の群が一度も選ばれなかった(マスキング)。3 つ目は、係数の効き目の伝え方である。皮の色が 1 段濃くなると甘い確率が 0.32 から 0.68 に上がる、と言っても、確率の差は場所によって変わる。場所によらない 1 つの数で効き目を言いたい。

本章の問いは、第 5 回の締めで残した 1 つである。方向は出るが、確率が出ない。確率を出すにはどうすればよいか。答えは最尤法(maximum likelihood)である。データがどのように出てくるかを確率分布で仮定し、手元のデータが出てくる確率を最大にするパラメータを選ぶ。本章はこの答えを 3 段で示す。まず、第 1 回からの最小二乗法が、誤差に正規分布を仮定したときの最尤法にほかならないことを示す。次に、群ごとに $\mathbf{x}$ の出方を正規分布で仮定した LDA を最尤法で当てはめ、第 5 回と同じ向きのうえに確率が出ることを導く。さらに、 $\mathbf{x}$ の出方を仮定せず、 y の出方だけを置くロジスティック回帰を導き、その係数をオッズ比で読む方法と、解き方を行列で書く。最後に、3 群以上へソフトマックス関数で広げる。




図 1: 紙幣のデータの画像の分散(ウェーブレット変換後)と真贋(偽札 = 1 が赤、真札 = 0 が青。縦に少しずらして打った)。直線は 0/1 に当てた最小二乗法、黒の四角は分散の区間(幅 1、10 枚以上)ごとの偽札の割合

道具：尤度と確率の分布

確率を出す推定法には、第 5 回までにない道具が要る。確率の出方を表す分布、尤度、対数、そして確率を 0 と 1 の間に収める関数である。ここにまとめておく。

まず、0 か 1 しか取らない量の出方である。コインを投げて表を $y = 1$ 、裏を $y = 0$ とし、表の確率を θ とすると、1 回の結果の確率は $\Pr(y) = \theta^y(1 - \theta)^{1-y}$ と書ける。 $y = 1$ なら θ 、 $y = 0$ なら $1 - \theta$ になり、指数が場合分けの代わりをしている。これをベルヌーイ分布(Bernoulli distribution)と呼ぶ。10 回投げて表が 7 回出たとき、各回が独立なら、この結果が出る確率は各回の確率の積

$$L(\theta) = \prod_{i=1}^{10} \theta^{y_i} (1 - \theta)^{1-y_i} = \theta^7 (1 - \theta)^3 \quad (1)$$

である。データを固定し、パラメータ θ の関数と見たものを尤度(likelihood)と呼ぶ。図 2 (a) のとおり、尤度が最大になるのは $\theta = 0.7$ 、観測された表の割合そのものである。尤度を最大にするパラメータを選ぶ方法が最尤法である。




図 2: コインを 10 回投げて表が 7 回のときの、表の確率 θ の (a) 尤度と (b) 対数尤度。破線は最大の位置 $\theta = 0.7$

尤度は積なので、そのままでは微分しにくい。対数をとると積が和になり、 $\log L(\theta) = 7 \log \theta + 3 \log(1 - \theta)$ となる(図 2 (b))。log は単調に増える関数なので、対数尤度(log-likelihood)が最大になる位置は尤度が最大になる位置と同じである。微分して 0 とおくと $7/\theta - 3/(1 - \theta) = 0$ 、すなわち $\hat{\theta} = 0.7$ を得る。以後、最尤法ではいつも対数尤度を最大にする。

次に、連続の量の出方である。平均 μ 、分散 σ^2 の正規分布(normal distribution)の確率密度は

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) \quad (2)$$

である(π は円周率)。 x が μ から離れるほど、その距離の二乗に比例して指数の中が小さくなり、出にくくなる。変数が p 個のベクトル $\mathbf{x}$ なら、平均ベクトル $\boldsymbol{\mu}$ 、共分散行列 $\boldsymbol{\Sigma}$ の多変量正規分布の密度は

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right) \quad (3)$$

となる。 $|\boldsymbol{\Sigma}|$ は行列式である。距離の二乗が、共分散行列の逆行列で測った 2 次形式に置きかわり、密度の等高線は楕円になる。 $p = 1$ なら $\boldsymbol{\Sigma} = \sigma^2$ で、(3) 式は (2) 式に戻る。

2 つの群があり、群 q の割合が π_q 、群 q の中での $\mathbf{x}$ の密度が $f_q(\mathbf{x})$ であるとき、 $\mathbf{x}$ を見たうえで群 1 である確率は、ベイズの定理(Bayes' theorem)により

$$\Pr(y = 1 | \mathbf{x}) = \frac{\pi_1 f_1(\mathbf{x})}{\pi_0 f_0(\mathbf{x}) + \pi_1 f_1(\mathbf{x})} \quad (4)$$

となる。これを事後確率(posterior probability)と呼ぶ。群の割合と群の中の出やすさの積を、2 つの群で比べた比である。図 3 (a) は 1 変数の例で $\pi_q f_q(x)$ を描いたもの、(b) はその比から求めた事後確率である。 x を動かすと、事後確率は 0 と 1 の間を S 字に曲がってつなぐ。




図 3: 1 変数の 2 群の例(群 1 の割合 1/3、群の中は平均 0 と 2.2、標準偏差 1 の正規分布)。(a) 群の割合と群の中の密度の積、(b) 事後確率。点は $x = 1.5$ の値

(4) 式の分母と分子を $\pi_1 f_1(\mathbf{x})$ で割ると、 $1/(1 + e^{-a})$ 、 $a = \log\{\pi_1 f_1(\mathbf{x})/\pi_0 f_0(\mathbf{x})\}$ の形になる。

定義 1 (シグモイド関数と対数オッズ). $\text{sig}(a) = 1/(1 + e^{-a})$ をシグモイド関数(sigmoid function)(ロジスティック関数)と呼ぶ。どんな実数 a に対しても値は 0 と 1 の間にあり、 $a = 0$ で $1/2$ になる。逆に解くと $a = \log\{\theta/(1 - \theta)\}$ ($\theta = \text{sig}(a)$)であり、これを対数オッズ(log-odds)と呼ぶ。

最後に、シグモイド関数の微分を用意する。 $\text{sig}(a) = (1 + e^{-a})^{-1}$ を微分すると $e^{-a}/(1 + e^{-a})^2 = \text{sig}(a)\{1 - \text{sig}(a)\}$ となる。これを使うと

$$\frac{d \log \text{sig}(a)}{da} = 1 - \text{sig}(a), \quad \frac{d \log(1 - \text{sig}(a))}{da} = -\text{sig}(a) \quad (5)$$

となる。対数をとったシグモイドの微分は、シグモイドそのものの 1 次式になる。この性質のおかげで、ロジスティック回帰の勾配は簡単な形になる。

最小二乗法は正規誤差の最尤法

最尤法で確率を出す前に、第 1 回からの最小二乗法を最尤法の立場から見直す。第 1 回で予告した「誤差が正規分布なら 2 つの推定法の答えは一致する」を、ここで導く。

1 変数の回帰 $y_i = \beta x_i + \varepsilon_i$ で、誤差 ε_i が平均 0、分散 σ^2 の正規分布に従い、行ごとに独立だと仮定する。図 4 のように、各 x_i で y_i は直線上の値 βx_i を中心に正規分布で散らばって出てくる、というモデルである。1 点の出やすさは (2) 式の μ を βx_i に置いた $f(y_i) = (2\pi\sigma^2)^{-1/2} \exp\{-(y_i - \beta x_i)^2/(2\sigma^2)\}$ である。行が独立なので、 n 点の尤度はその積になる。対数をとると

$$\log L(\beta, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta x_i)^2 \quad (6)$$

となる。 β を含むのは第 2 項だけで、その中身は第 1 回の目的関数、誤差の二乗和である。 $-1/(2\sigma^2)$ は負の定数なので、対数尤度を最大にする β は二乗和を最小にする β と一致する。




図 4: 1 変数の回帰の人工データ(25 点)と最小二乗法の直線。赤の曲線は、3 つの x の位置で y が出てくる正規分布の密度を横向きに描いたもの

図 5 は、図 4 の人工データで、(a) 二乗和と (b) 対数尤度を β の関数として描いたものである ((b) の σ^2 は後で求める $\hat{\sigma}^2$ に固定した)。二乗和の谷底と対数尤度の山頂は同じ $\hat{\beta} = 0.615$ にある。




図 5: 図 4 の人工データの (a) 二乗和と (b) 対数尤度。破線は最小二乗法の解 $\hat{\beta}$

最尤法は σ^2 も決める。(6) 式を σ^2 で偏微分して 0 とおくと $\hat{\sigma}^2 = \frac{1}{n} \sum_i (y_i - \hat{\beta}x_i)^2$ 、すなわち残差の二乗和を n で割ったものになる。人工データでは 1.548 である。最小二乗法は直線を決めるだけだったが、最尤法は直線のまわりの散らばりの大きさまでモデルの一部として推定する。

ベクトルで書けば、二乗和は $\|\mathbf{y} - \beta\mathbf{x}\|_2^2$ 、列が p 本のデータ行列 $\mathbf{X}$ なら $\|\mathbf{y} - \mathbf{X}\beta\|_2^2$ であり、

$$\log L(\beta, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 \quad (7)$$

となる。 β についての勾配を 0 とおけば、第 1 回の正規方程式 $\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y}$ を得る。 $p = 1$ なら (7) 式は (6) 式に戻る。最小二乗法は、誤差が独立な正規分布に従うと仮定したときの最尤法である。

では、 y が 0 か 1 しか取らないときはどうするか。 y は 2 つの値しか取らないので、 y のまわりに正規分布を置くことはできない。確率の仮定の置き方は 2 通りある。1 つは、 y で分けた群ごとに x の出方を置く方法である。データ全体の出方を仮定するので、生成モデル (generative model) と呼ぶ。LDA がこれにあたる。もう 1 つは、 x を与えたときの y の出方だけを置く方法である。群を識別する確率だけを仮定するので、識別モデル (discriminative model) と呼ぶ。ロジスティック回帰がこれにあたる。以下、この順に見ていく。

LDA を最尤法で当てはめる

y で分けた群ごとに x の出方を置くのが LDA の確率のモデルである。まず 1 変数で考える。各行は確率 π_q で群 q に属する ($\pi_0 + \pi_1 = 1$) と仮定する。群 q の中では、 x_i が平均 μ_q 、分散 σ^2 の正規分布に従って出てくるとする。分散は 2 つの群で共通とする。ここでは人工的なデータを使う。みかん 150 個の皮の色の濃さ x (標準化した値) と、食べて甘かった ($y = 1$, 30 個) か酸っぱかった ($y = 0$, 120 個) かである。図 6 は、群ごとのヒストグラムに、このモデルの密度を個数に合わせて重ねたものである。

行 i では y_i と x_i の両方を観測している。その出やすさは、「群 y_i が選ばれる確率 π_{y_i} 」と「その群の中で x_i が出る密度 $f_{y_i}(x_i)$ 」の積になる。行が独立なら、対数尤度は




図 6: みかんの人工データ(皮の色の濃さ x 、酸っぱい $y = 0$ が青、甘い $y = 1$ が赤)のヒストグラムと、最尤推定した LDA のモデルの群ごとの正規分布の密度(個数と幅 0.5 に合わせて拡大した)

$$\ell(\pi_1, \mu_0, \mu_1, \sigma^2) = \sum_{i=1}^n [\log \pi_{y_i} + \log f_{y_i}(x_i)] \quad (8)$$

となる。 f_q は (2) 式の μ を μ_q に置いたものである。

(8) 式は、 π の部分と μ_q, σ^2 の部分に分かれる。 π の部分は $n_1 \log \pi_1 + n_0 \log(1 - \pi_1)$ で、(1) 式のコインと同じ形をしている。したがって $\hat{\pi}_1 = n_1/n$ 、すなわち観測された群の割合になる。 μ_q の部分は $-\frac{1}{2\sigma^2} \sum_{y_i=q} (x_i - \mu_q)^2$ であり、 μ_q で偏微分して 0 とおくと $\hat{\mu}_q$ は群 q の平均になる。 σ^2 で偏微分して 0 とおくと、回帰のときと同じ計算で

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{q=0}^1 \sum_{y_i=q} (x_i - \hat{\mu}_q)^2 = s_W^2$$

となり、第 5 回で定義した群の中の分散に一致する。人工データでは $\hat{\pi}_1 = 0.200$ 、 $\hat{\mu}_0 = 0.059$ 、 $\hat{\mu}_1 = 1.978$ 、 $\hat{\sigma}^2 = 1.229$ である。

変数が p 個なら、群の中の分布を (3) 式の変量正規分布 $N(\mu_q, \Sigma)$ にする。 μ_q の部分は $-\frac{1}{2} \sum_{y_i=q} (x_i - \mu_q)^\top \Sigma^{-1} (x_i - \mu_q)$ である。第 5 回の 2 次形式の勾配の公式から、その勾配は $\Sigma^{-1} \sum_{y_i=q} (x_i - \mu_q)$ となる。これを 0 ベクトルとおけば、 $\hat{\mu}_q$ は群の平均ベクトルになる。 Σ の最尤推定には行列の偏微分が要るので、結果だけを述べる。最尤推定は 1 変数と同じ形の

$$\hat{\Sigma} = \frac{1}{n} \sum_{q=0}^1 \sum_{y_i=q} (x_i - \hat{\mu}_q)(x_i - \hat{\mu}_q)^\top = S_W \quad (9)$$

であり、第 5 回の群の中の共分散行列そのものである。 $p = 1$ なら $\hat{\sigma}^2 = s_W^2$ に戻る。

定義 2 (LDA の確率のモデル). 群の割合 π_q で群を選び、群の中では共通の共分散行列を持つ多変量正規分布 $N(\mu_q, \Sigma)$ から x が出てくる、というモデルを LDA の確率のモデルと呼ぶ。データ全体の出方を仮定するので生成モデルである。最尤推定は $\hat{\pi}_q = n_q/n$ 、群の平均 $\hat{\mu}_q$ 、群の中の共分散行列 $\hat{\Sigma} = S_W$ であり、数えるだけで求まる。

パラメータが決まれば、ベイズの定理 (4) 式で事後確率が出る。定義 1 により $\Pr(y = 1 | x) = \text{sig}(a(x))$ 、 $a(x) = \log\{\pi_1 f_1(x)/\pi_0 f_0(x)\}$ である。1 変数で中身を書くと、正規分布の密度の比の対数は指数の中の差になり、

$$a(x) = \log \frac{\pi_1}{\pi_0} - \frac{(x - \mu_1)^2 - (x - \mu_0)^2}{2\sigma^2} = \frac{d}{\sigma^2} \left(x - \frac{\mu_0 + \mu_1}{2} \right) + \log \frac{\pi_1}{\pi_0} \quad (10)$$

となる ($d = \mu_1 - \mu_0$)。2 つの二乗を展開すると x^2 の項は係数が同じなので打ち消し合い、 $a(x)$ は x の 1 次式になる。分散が 2 群で共通だと仮定したおかげである。群ごとに分散が違えば x^2 が残り、境界は曲がる (二次判別分析)。

p 変数でも同じ計算で、2 次形式の差のうち $\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x}$ が打ち消し合い、

$$a(x) = \mathbf{w}^\top \left(\mathbf{x} - \frac{\boldsymbol{\mu}_0 + \boldsymbol{\mu}_1}{2} \right) + \log \frac{\pi_1}{\pi_0}, \quad \mathbf{w} = \hat{\boldsymbol{\Sigma}}^{-1} \mathbf{d} = \mathbf{S}_W^{-1} \mathbf{d} \quad (11)$$

となる。(9) 式により、事後確率の中身の向き $\mathbf{w}$ は第 5 回で 0/1 の最小二乗法の係数が指した判別方向 $\mathbf{S}_W^{-1} \mathbf{d}$ と同じである。LDA の判別方向は、最小二乗法でも最尤法でも同じになる。 $p = 1$ なら $w = d/\sigma^2$ で、(11) 式は (10) 式に戻る。

違うのは、最尤法ではこの向きの上に確率が乗ることである。図 7 は 図 6 と同じ人工データに、0/1 に当てた最小二乗法の直線 (破線、第 5 回の方法) と、LDA の事後確率 $\text{sig}(a(x))$ (緑) を重ねたものである。直線は 0 と 1 の外へ伸びるが、事後確率はどの x でも 0 と 1 の間にあり、区間ごとの $y = 1$ の割合 (黒の四角) を追って S 字に曲がる。




図 7: 図 6 と同じ人工データ (縦に少しずらして打った)。破線は 0/1 に当てた最小二乗法の直線、緑の曲線は LDA の事後確率、黒の四角は x の区間ごとの $y = 1$ の割合。橙の破線は 2 群の平均の中点、緑の点線は事後確率が 1/2 になる点

確率が 1/2 になるのは $a(x) = 0$ のときである。(11) 式から、境界は $\mathbf{w}^\top (\mathbf{x} - \mathbf{m}) = \log(\pi_0/\pi_1)$ ($\mathbf{m}$ は中点) であり、第 5 回で予告したとおり、人数の比の対数が境界に入る。 $y = 1$ の群が少なければ ($\pi_1 < \pi_0$) 右辺は正で、境界は中点から $y = 1$ の群の側へずれる。人工データでは中点 1.02 に対し、事後確率が 1/2 になる x は 1.91 である。0/1 に当てた最小二乗法の境界 2.22 も同じ側へずれるが (第 5 回で見たずれ)、ずれの大きさは違う。最尤法の境界は「どちらの群である確率が高いか」で決まるので、ずれの理由を確率で説明できる。

ロジスティック回帰

(11) 式で見たとおり、LDA の事後確率は $\text{sig}(\mathbf{w}^\top \mathbf{x} + w_0)$ 、すなわち $\mathbf{x}$ の 1 次式をシグモイド関数に通した形になる。この形は、群ごとに正規分布を置き、共分散を共通とした仮定から導かれた。では、 $\mathbf{x}$ の出方は何も仮定せず、事後確率がこの形であることを仮定したらどうなるか。これがロジスティック回帰(logistic regression)である。

定義 3 (ロジスティック回帰). $\mathbf{x}_i$ を与えたときの y_i がベルヌーイ分布に従い、その確率が

$$\Pr(y_i = 1 \mid \mathbf{x}_i) = \theta_i = \text{sig}(\mathbf{x}_i^\top \boldsymbol{\beta}) \quad (12)$$

であるとするモデルをロジスティック回帰と呼ぶ。 $\mathbf{x}_i$ の先頭の成分を 1 にして、切片を β に含める。対数オッズ $\log\{\theta_i/(1-\theta_i)\}$ が $\mathbf{x}_i$ の 1 次式になる。群を識別する確率だけを仮定するので識別モデルである。

1 変数なら $\theta_i = \text{sig}(\beta_0 + \beta x_i)$ 、行列で書けばデータ行列 $\mathbf{X}$ (先頭の列が 1) について $\boldsymbol{\theta} = \text{sig}(\mathbf{X}\boldsymbol{\beta})$ (シグモイド関数は成分ごとに当てる) である。第 1 回の線形回帰と同じ掛け算 $\mathbf{X}\boldsymbol{\beta}$ を作り、最後にシグモイド関数に通して 0 と 1 の間に収める。

y_i はベルヌーイ分布に従うので、1 行の確率は (1) 式のコインと同じ $\theta_i^{y_i}(1-\theta_i)^{1-y_i}$ である。違うのは、表の確率 θ_i が行ごとに $\mathbf{x}_i$ で変わることだけである。行が独立なら、対数尤度は

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^n \left[y_i \log \theta_i + (1 - y_i) \log(1 - \theta_i) \right] \quad (13)$$

となる。

定義 4 (交差エントロピー). 0/1 の y_i と確率 θ_i について、 $-\frac{1}{n} \sum_{i=1}^n \{y_i \log \theta_i + (1 - y_i) \log(1 - \theta_i)\}$ を交差エントロピー(cross-entropy)と呼ぶ。(13) 式の符号を反転して n で割ったものであり、正解の側に付けた確率の $-\log$ の平均である。小さいほど確率がよく当たっている。

図 8 のとおり、1 行の寄与は、正解の側に 0.99 を付ければ 0.01、0.5 なら 0.69、0.01 なら 4.61 である。自信をもって外した行ほど大きく罰せられる。確率を 0.5 で切って一致を数える一致率は、正解の側に 0.51 を付けても 0.99 を付けても同じ 1 回の正解と数える。交差エントロピーは、判定ではなく確率そのものの当たり方を測る。

まず 1 変数で微分する。 $a_i = \beta_0 + \beta x_i$ とおくと、(5) 式から $y_i \log \theta_i + (1 - y_i) \log(1 - \theta_i)$ の a_i による微分は $y_i(1 - \theta_i) - (1 - y_i)\theta_i = y_i - \theta_i$ になる。 a_i の β による微分は x_i なので、 $d\ell/d\beta = \sum_i (y_i - \theta_i)x_i$ 、同様に $\partial\ell/\partial\beta_0 = \sum_i (y_i - \theta_i)$ である。偏微分を縦に並べると、勾配は

$$\frac{\partial \ell}{\partial \boldsymbol{\beta}} = \mathbf{X}^\top (\mathbf{y} - \boldsymbol{\theta}) \quad (14)$$




図 8: 正解の側に付けた確率と、その行の交差エントロピーへの寄与 $-\log$ (その確率)。点は確率 0.99、0.5、0.01 のときの値

となる。第 1 回の最小二乗法の勾配 $-2\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\beta)$ と同じく、データ行列の転置と「 y と予測の差」の積である。しかし θ は β をシグモイド関数の中を含むので、勾配を 0 とおいた $\mathbf{X}^\top(\mathbf{y} - \theta) = 0$ は β についての連立 1 次方程式にならない。閉じた形の解はなく、反復で解くことになる。

反復の手がかりは 2 階微分である。 $d\theta_i/d\beta = \theta_i(1 - \theta_i)x_i$ なので $d^2\ell/d\beta^2 = -\sum_i \theta_i(1 - \theta_i)x_i^2$ であり、 $0 < \theta_i < 1$ だからいつも負である。対数尤度は上に凸で、山頂は 1 つしかない。行列で書けば、2 階の偏微分を並べた行列(ヘッセ行列)は $-\mathbf{X}^\top \mathbf{W} \mathbf{X}$ 、 $\mathbf{W} = \text{diag}(\theta_i(1 - \theta_i))$ である。

山頂へは、今の点で対数尤度を放物線 $\ell(\beta) + \ell'(\beta)(t - \beta) + \frac{1}{2}\ell''(\beta)(t - \beta)^2$ で近似し、その頂点 $t = \beta - \ell'(\beta)/\ell''(\beta)$ へ移ることを繰り返せばよい。これがニュートン法(Newton's method)である。図 9 はみかんの人工データで、切片を最尤推定の値に固定して β だけを動かしたときの対数尤度である。 $\beta = 0.6$ の点で当てた放物線の頂点は 1.71 で、1 回で山頂 1.50 の近くまで進む。




図 9: みかんの人工データにロジスティック回帰を当てたときの、傾き β の対数尤度(切片は最尤推定の値に固定)。赤の破線は山頂、橙の破線は $\beta = 0.6$ で当てた放物線、緑の点はその頂点

オッズとオッズ比

ロジスティック回帰の係数はどう読めばよいか。 x が 1 増えたときの確率の上がり方は、S 字のどこにいるかで変わる。冒頭の困りごと③のように、0.32 が 0.68 になることもあれば、0.95 が 0.98 になるだけのこともある。そこで確率を言いかえる。

定義 5 (オッズとオッズ比). 確率 θ について、 $\theta/(1 - \theta)$ をオッズ(odds)と呼ぶ。その対数を対数オッズ(log odds)と呼ぶ。2 つのオッズの比をオッズ比(odds ratio)と呼ぶ。

雨の確率 0.8 は、降る : 降らない = 4 : 1 であり、オッズは 4 である。確率 0.5 ならオッズは 1、0.2 なら 0.25 である。(12) 式の確率を対数オッズに直すと

$$\log \frac{\theta_i}{1 - \theta_i} = \beta_0 + \beta x_i$$

となり、 x の 1 次式になる(図 10)。シグモイド関数の逆の変換であるから当然である。したがって x が 1 増えると、対数オッズはどこでも β だけ増え、オッズは e^β 倍になる。この倍率がオッズ比であり、S 字のどこにいても同じである。みかんの人工データでは $\hat{\beta} = 1.50$ で、皮の色が 1 段濃いと、甘いオッズは 4.5 倍になる。




図 10: みかんの人工データに当てたロジスティック回帰。(a) 確率、(b) 対数オッズ。対数オッズは直線で、 x が 1 増えると $\hat{\beta}$ だけ上がる

変数が多いときは、ほかの列の値を固定したまま列 j を 1 増やしたときに、オッズが e^{β_j} 倍になる。列を標準化してから当てたなら、1 標準偏差ぶん増やしたときの倍率である。ただし、第 5 回で見たように、似た列があると係数は打ち消し合う。オッズ比も係数の指数なので、同じ注意が要る。

計算の手順

2 つのモデルの計算手順を行列で書く。LDA は数えて 1 回解くだけであり、ロジスティック回帰は同じ形の連立方程式を繰り返し解く。

LDA の手順は次のとおりである。

1. データ行列 $\mathbf{X}$ ($n \times p$) と 0/1 の $\mathbf{y}$ から、群の人数 n_q と割合 $\hat{\pi}_q = n_q/n$ を数える
2. 群の平均 $\hat{\boldsymbol{\mu}}_1 = \frac{1}{n_1} \mathbf{X}^\top \mathbf{y}$ 、 $\hat{\boldsymbol{\mu}}_0 = \frac{1}{n_0} \mathbf{X}^\top (\mathbf{1} - \mathbf{y})$ を作る。各行から自分の群の平均を引いた行列 $\mathbf{R}$ を作り、 $\mathbf{S}_W = \frac{1}{n} \mathbf{R}^\top \mathbf{R}$ とする
3. 連立方程式 $\mathbf{S}_W \mathbf{w} = \hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_0$ を解き、 $w_0 = -\mathbf{w}^\top (\hat{\boldsymbol{\mu}}_0 + \hat{\boldsymbol{\mu}}_1)/2 + \log(\hat{\pi}_1/\hat{\pi}_0)$ とする。これは (11) 式の切片である
4. 確率を $\theta = \text{sig}(\mathbf{X}\mathbf{w} + w_0\mathbf{1})$ で出す

反復はない。第 5 回の判別方向の計算に、切片と最後のシグモイド関数を加えれば済む。

ロジスティック回帰の手順は次のとおりである。

1. $\mathbf{X}$ の先頭に 1 の列を足して $n \times (p+1)$ とし、 $\beta = 0$ から始める
2. 今の β で $\theta = \text{sig}(\mathbf{X}\beta)$ と、対角に $\theta_i(1 - \theta_i)$ を並べた $\mathbf{W}$ を作る
3. 連立方程式 $(\mathbf{X}^\top \mathbf{W} \mathbf{X}) \Delta = \mathbf{X}^\top (\mathbf{y} - \theta)$ を解き、 $\beta \leftarrow \beta + \Delta$ とする
4. Δ の成分がすべて十分小さくなるまで 2~3 を繰り返す

手順 3 は、1 変数の更新 $\beta \leftarrow \beta + \ell'(\beta) / \{-\ell''(\beta)\}$ を、勾配 (14) 式とヘッセ行列 $-\mathbf{X}^\top \mathbf{W} \mathbf{X}$ で書き直したもの

$$\beta \leftarrow \beta + (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{y} - \theta) \quad (15)$$

である。 $p = 1$ で切片がなければ 1 変数の更新に戻る。係数行列 $\mathbf{X}^\top \mathbf{W} \mathbf{X}$ は第 1 回の $\mathbf{X}^\top \mathbf{X}$ に行ごとの重み $\theta_i(1 - \theta_i)$ を付けたものであり、毎回の更新は重み付きの正規方程式を解くことにあたる。このため、この手順は反復重み付き最小二乗法 (iteratively reweighted least squares) (IRLS) と呼ばれる。重みは、確率が $1/2$ に近い行ほど大きく、0 や 1 に近い行ほど小さい。

3 群以上：ソフトマックス関数

群が 3 つ以上あるときも、同じ考え方で確率が出る。 k 群の LDA では、群 q の割合を π_q 、群の中の x の密度を $f_q(x)$ (平均 μ_q 、共通の分散 σ^2 の正規分布) とする。ベイズの定理から、 x を見たあとに群 q である確率は

$$\Pr(y = q | x) = \frac{\pi_q f_q(x)}{\sum_{r=1}^k \pi_r f_r(x)} = \frac{e^{a_q(x)}}{\sum_{r=1}^k e^{a_r(x)}}, \quad a_q(x) = \log \pi_q f_q(x)$$

である。分散が共通なので、 $a_q(x)$ の中の $-x^2/(2\sigma^2)$ はどの群でも同じであり、分子と分母で打ち消し合う。残りは $a_q(x) = \frac{\mu_q}{\sigma^2} x - \frac{\mu_q^2}{2\sigma^2} + \log \pi_q$ という x の 1 次式である。多変数なら $\mu_q^\top \mathbf{S}_W^{-1} \mathbf{x} - \frac{1}{2} \mu_q^\top \mathbf{S}_W^{-1} \mu_q + \log \pi_q$ となる。

定義 6 (ソフトマックス関数). k 個の数 $\mathbf{a} = [a_1, \dots, a_k]^\top$ について、

$$\text{softmax}(\mathbf{a})_q = \frac{e^{a_q}}{\sum_{r=1}^k e^{a_r}} \quad (16)$$

をソフトマックス関数 (softmax function) と呼ぶ。

ソフトマックス関数は、 k 個の数を、0 と 1 の間にあって足すと 1 になる確率に直す。 $k = 2$ なら $e^{a_1} / (e^{a_0} + e^{a_1}) = \text{sig}(a_1 - a_0)$ であり、シグモイド関数に戻る。2 群の話は k 群の特別な場合にすぎない。

ロジスティック回帰も同じように広がる。 x の出方は仮定せず、群 q である確率を $\theta_{iq} = \text{softmax}(\mathbf{B}^\top \mathbf{x}_i)_q$ と置く。 $\mathbf{B}$ は $(p+1) \times k$ の係数行列で、どれか 1 つの基準の群の列を 0 に固定する (全部の列に同じベクトルを足しても確率が変わらないので)。 y_i を第 5 回の指示行列 $\mathbf{Y}$ の行で表すと、対数尤度は $\ell(\mathbf{B}) = \sum_i \sum_q y_{iq} \log \theta_{iq}$ 、その勾配は $\mathbf{X}^\top (\mathbf{Y} - \boldsymbol{\Theta})$ であり、2 群の (14) 式と同じ形になる。これを多クラスのロジスティック回帰 (multinomial logistic regression) と呼ぶ。ニュートン法で解ける。

冒頭の困りごと②に戻る(図 11)。皮の色の濃さだけで酸っぱい・ふつう・甘い(各 60 個)を分けると、第 5 回の指示行列の最小二乗法では、真ん中の「ふつう」と判定されたのは 0 個だった。多クラスのリジスティック回帰の確率で最大の群を選ぶと、60 個が「ふつう」と判定される。確率はどの群も 0 と 1 の間にあり、真ん中の群の確率は真ん中で山になる。最小二乗法の直線にはできなかった形である。




図 11: 皮の色の濃さだけで 3 群(酸っぱい・ふつう・甘い、各 60 個)を分ける人工データに当てた、多クラスのリジスティック回帰の確率。上の帯は確率が最大の群。真ん中の群も選ばれる

生成と識別：向きがずれるとき

LDA とリジスティック回帰は、事後確率を同じ $\text{sig}(\mathbf{x}$ の 1 次式) の形で表す。LDA の仮定が正しければ、真の事後確率はまさにこの形なので、リジスティック回帰が推定する対象も同じ 1 次式になる。それでも、2 つの推定値は一般には一致しない。何に合わせて係数を決めるかが違うからである。

LDA の向き $\mathbf{w} = \mathbf{S}_W^{-1}(\hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_0)$ は、すべての行の群の平均と群の中の広がりで決まる。境界から遠く間違えようのない行も、平均と共分散を通して同じ重みで向きに影響する。一方、リジスティック回帰の勾配 (14) 式を 0 とおく条件 $\sum_i (y_i - \theta_i) \mathbf{x}_i = 0$ では、すでによく当たっている行 (θ_i が y_i に近い行) はほとんど寄与しない。係数を動かすのは、 $y_i - \theta_i$ が大きい当てにくい行、すなわち境界の近くの行である。

図 12 は、みかんを 2 つの量(皮の色の濃さと皮の張り)で測った人工データで、2 つの向きを比べたものである。(a) のデータは、LDA の仮定どおり共通の共分散を持つ正規分布から作った。2 つの向きの差は 1.5 度である。(b) は $y = 1$ の群に、境界から遠く離れた点 40 個を足したものである。これらの点は、どちらの向きで見ても間違えようがない。それでも LDA の向きは、平均と群の中の共分散が動くために 30.5 度回り、リジスティック回帰の向きは 0.0 度しか動かない。(b) で 2 つの向きの差は 32.0 度になる。

生成モデルの LDA は、 $\mathbf{x}$ の出方の仮定を推定に使う。仮定が正しければ、その分だけ少ない行で安定した推定ができる。仮定が外れていれば、境界と関係のない行の散らばりにまで向きが引っぱられる。識別モデルのリジスティック回帰は $\mathbf{x}$ の出方を仮定しないので、仮定の外れには強いが、その分だけ推定のばらつきが大きくなりうる。2 つの向きが実データでどれだけずれるかは、第 II 部で確かめる。




図 12: LDA の向き(黒の矢印)とロジスティック回帰の向き(橙の破線の矢印)。(a) 共通の共分散を持つ正規分布から作ったみかんの人工データ(2変数)。(b) (a) の $y = 1$ の群に、境界から遠い 40 個を足したもの

完全に分けられるとき

ロジスティック回帰の対数尤度は上に凸だが、山頂があるとは限らない。図 13 は、1 変数の人工データで $y = 0$ の点がすべて負、 $y = 1$ の点がすべて正にあり、 $x = 0$ で完全に分けられる例である(切片は 0 とした)。図 13 (a) のとおり、 β の符号が同じなら境界は $x = 0$ のまま動かないが、 β が大きいほど S 字は急になり、階段に近づく。確率の形 $\text{sig}(\mathbf{x}^\top \beta)$ では、係数の向きが境界を決め、係数の長さが S 字の急さ、すなわち確率が 0 や 1 に寄る度合いを決める。向きが同じ 2 つのモデルでも、長さが違えば確率の値は違う。

このデータは完全に分けられるので、 β を大きくするほどすべての行で θ_i が y_i に近づく。対数尤度 $\ell(\beta)$ は 0 に向かって上がり続け、どの有限の β でも最大にならない。反復で解けば、係数は際限なく大きくなり続ける。データが完全に分けられるとき、最尤推定は存在しない。変数が多いほど、行数に比べて完全に分けられる場合が起きやすい。

これを止めるには、係数の大きさに罰を付ける。第 4 回のリッジ回帰と同じ形の罰を対数尤度から引いた

$$\ell(\beta) - \frac{\lambda}{2} \sum_{j=1}^p \beta_j^2 \quad (17)$$

を最大にする(切片 β_0 には罰を付けない)。罰は β の 2 次式で下向きに曲がるので、図 13 (b) の破線のように山頂ができ、 $\lambda = 1$ では $\beta = 2.33$ で止まる。勾配は $\mathbf{X}^\top(\mathbf{y} - \boldsymbol{\theta}) - \lambda \mathbf{D}\beta$ になる($\mathbf{D}$ は対角行列で、切片の成分だけ 0、ほかの成分は 1)。ヘッセ行列は $-(\mathbf{X}^\top \mathbf{W} \mathbf{X} + \lambda \mathbf{D})$ になる。(15) 式のニュートン法は、勾配とヘッセ行列をこの 2 つに置きかえればそのまま使える。第 4 回で罰則付き最小二乗法を置いたのと同じく、これは罰則付きの最尤法である。




図 13: 完全に分けられる 1 変数の人工データ ($y = 0$ が青、 $y = 1$ が赤、各 20 個)。(a) β を大きくしたときの $\text{sig}(\beta x)$ 。(b) 対数尤度(実線)と、罰 $\beta^2/2$ を引いたもの(破線)

推定法の列が変わる

「モデル × 推定法」の地図でいえば、第 5 回までの推定法はすべて最小二乗法(第 4 回は罰則付き)であった。本章で初めて推定法の列が最尤法に変わった。第 1 回の表で最尤法の列に「第 6 回」と書いたマスは、線形回帰・LDA・ロジスティック回帰の 3 つであり、すべて本章で扱った。同じモデルでも、推定法を変えると答えの読み方が変わる。LDA は第 5 回の最小二乗法では向き(スコア)を出し、本章の最尤法では同じ向きの上に確率を出した。

第 II 部 実データ解析

第 II 部の進め方と予想

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、2 つのことが予想できる。1 つめに、0/1 の目的変数に直線を当てると、予測値は 0 と 1 の外へはみ出す。LDA とロジスティック回帰の確率は、 sig を通すので 0 と 1 の間に収まる。2 つめに、LDA の仮定(群の中は正規分布で、共分散は共通)が正しければ、真の事後確率は $\text{sig}(x$ の 1 次式)になる。LDA とロジスティック回帰は、どちらもこの同じ 1 次式を推定する。紙幣のデータが仮定に近ければ、2 つの係数は向きも長さもほぼ同じになるはずである。

紙幣のデータ

データには、紙幣の真贋のデータ(banknote authentication)を用いる。このデータは Lohweg と Dörksen が UCI Machine Learning Repository に寄せたもので、CC BY 4.0 で公開されている。1 行は、本物の紙幣と紙幣に似せた試料を工業用のカメラで撮った画像 1 枚で、1,372 枚ある。画像をウェーブレット変換した値の分散・歪度・尖度と、画像のエントロピーの 4 列が説明変数である。目的変数は元のデータの区分の列で、区分 1

(610 枚)を偽札 $y = 1$ 、区分 0 (762 枚)を真札 $y = 0$ と読んだ。元のデータの説明は区分の 0 と 1 がどちらかを明記していないので、広く使われている読み方に従った。以下の計算は読み方によらない。4 列はそれぞれ標準化した。第 I 部の冒頭では、画像の分散の 1 列だけに 0/1 の直線を当て、予測値が -0.37 から 1.39 まではみ出すのを見た。以下では 4 列を使い、3 つのモデルで見直す。

計算の手続きと結果

計算の手続きは次のとおりである。データ行列 $\mathbf{Z}$ は 4 列を標準化したもので、 $\mathbf{y}$ は偽札を 1 とした。0/1 の最小二乗法は、第 5 回の方法どおり正規方程式を解いた。LDA では、群の割合・群の平均・群の中の共分散行列 $\mathbf{S}_W$ を数えた。 $\mathbf{S}_W \mathbf{w} = \mathbf{d}$ を解き、(11) 式から確率を出した。ロジスティック回帰は罰を付けずに、(15) 式のニュートン法を手で回した。予測値と係数は全件で当てはめて比べた。一致率と交差エントロピーは、真贋の割合をそろえて 7:3 に分けた訓練 960 枚で当てはめ直し、テスト 412 枚で測った(標準化の平均と標準偏差も訓練の行で求めた)。手で組んだ LDA の確率は、scikit-learn の LinearDiscriminantAnalysis の確率と最大 6e-15 の差で一致した。ニュートン法は罰なしでも 14 回で止まった。4 列ではデータは完全には分けられず、最尤推定が存在するからである。

予想①は予想どおりだった(図 14)。(a) の 0/1 の最小二乗法の予測値は、305 枚が 0 未満、179 枚が 1 を超えた。4 列ではほぼ完全に分けられるデータなので、多くの札の予測値が 0 と 1 の外に出る。(b) のロジスティック回帰と (c) の LDA の確率は、どの札でも 0 と 1 の間にある。

LDA の向きは、0/1 の最小二乗法の係数とコサイン 1.0000000 で一致した。これは第 I 部で導いたとおりで、どのデータでも成り立つ。そのため図 15 のように、横軸に $\hat{y}$ 、縦軸に LDA の確率をとると、すべての札が 1 本の S 字の曲線に乗る。「122%」とは読めない $\hat{y} > 1$ の札は、LDA の確率ではほぼ 1 になる。

予想②は半分外れた(表 1)。ロジスティック回帰の係数と LDA の向きのコサインは 0.9993 で、角度は 2.1 度しか違わない。仮定どおりに作った第 I 部の人工データ(図 12 (a))の 1.5 度と同じくらい近く、向きは予想どおりだった。ところが係数の長さは、LDA が 22.6、ロジスティック回帰が 40.3 で、2 倍近く違った。第 I 部の図 13 (a) で見たとおり、確率 $\text{sig}(\mathbf{w}^\top \mathbf{x} + w_0)$ は、向きが同じでも長さが違えば S 字の急さが違う。0.5 で切ると、LDA は 32 枚を誤り、そのうち 5 枚に 0.01 未満か 0.99 超の確率を付けた。ロジスティック回帰の誤りは 11 枚で、そのような自信のある誤りは 0 枚だった。

表 1: 係数の長さと、0.5 で切ったときの誤りの枚数(全件)。右の列は、誤りのうち確率が 0.01 未満か 0.99 超の札

	係数の長さ $\ \mathbf{w}\ $	誤りの枚数	うち 0.01 未満か 0.99 超
LDA	22.6	32 枚	5 枚
ロジスティック回帰(罰なし)	40.3	11 枚	0 枚

判定の結果は、どのモデルでもほとんど変わらない(表 2)。0.5 で切ると、テストの 412 枚では LDA が 98.8%、ロジスティック回帰が 99.3% の真贋と一致した。差が出るのは確率の値である。第 I 部で定義した交差エント




図 14: 紙幣のデータの予測値の分布(青が真札、赤が偽札)。(a) 0/1 の最小二乗法の予測値、(b) ロジスティック回帰(罰なし)の確率、(c) LDA の確率。灰の線は 0 と 1。縦軸の上端を超える柱には枚数を書き添えた




図 15: 0/1 の最小二乗法の予測値 $\hat{y}$ (横軸)と LDA の確率(縦軸)。青が真札、赤が偽札

ロピー(定義 4)で確率の当たり方を測ると、テストで LDA が 0.032、ロジスティック回帰が 0.026 であった。

表 2: 確率(または予測値)を 0.5 で切ったときの真贋との一致率と、テストの交差エントロピー。テストは訓練の行だけで当てはめ直した

	確率が出るか	全件	テスト 412 枚	テストの交差エントロピー
0/1 の最小二乗法	いいえ	97.7%	98.8%	—
LDA	はい	97.7%	98.8%	0.032
ロジスティック回帰(罰なし)	はい	99.2%	99.3%	0.026

ずれの理由

係数の長さがずれた理由は、LDA の仮定が紙幣のデータでは成り立っていないことにある。LDA は、2 つの群の中の散らばり(共分散)が同じだと仮定し、2 群をまとめた $\mathbf{S}_W$ を使う。ところが表 3 のとおり、尖度の列では偽札の群の標準偏差が真札の 1.62 倍ある。列どうしの相関も群で違い、画像の分散と歪度の相関は、真札で -0.23、偽札で 0.07 である。

表 3: 標準化した 4 列の、群ごとの標準偏差

列	真札の標準偏差	偽札の標準偏差	偽札 ÷ 真札
画像の分散	0.71	0.66	0.93
歪度	0.88	0.92	1.05
尖度	0.75	1.22	1.62
エントロピー	1.01	0.99	0.97

LDA の向き $\mathbf{w} = \mathbf{S}_W^{-1} \mathbf{d}$ は、すべての札の群の平均と群の中の広がりで決まり、その長さもそこで決まる。この長さは、仮定が正しければ真の事後確率の S 字の急さになる。一方、ロジスティック回帰の勾配を 0 とおく条件 $\sum_i (y_i - \theta_i) \mathbf{x}_i = 0$ では、 $y_i - \theta_i$ が大きい当てにくい札が係数を動かす。紙幣のデータで $|y_i - \theta_i| > 0.1$ となる札は 33 枚しかない。ロジスティック回帰は、境界の近くのこれらの札に合わせて S 字の急さを決める。仮定が正しければ、2 つのやり方は同じ 1 次式を狙う。仮定が外れると、狙う先が分かれる。このデータでは境界がほぼ 1 枚の平面で引けるので、向きはほとんど変わらず、長さだけが大きくずれた。境界の近くに合わせたロジスティック回帰のほうが、確率の当たり方もよかった。

オッズ比で読む

第 I 部では、ロジスティック回帰の係数をオッズ比として読めることを見た。冒頭の図 1 では、画像の分散が大きいほど偽札の割合が下がった。分散のオッズ比は 1 より小さく、4 列を入れても同じように読めると予想できる。

分散 1 列だけのロジスティック回帰では、係数は -1.01、オッズ比は 0.36 である。分散が 1 大きいと、偽札のオッズは約 3 分の 1 になる。素直に読める数であり、予想どおりである。

ところが 4 列を標準化して入れると、様子が変わる(表 4)。既定の罰($\lambda = 1$)では、1 標準偏差あたりのオッズ比は分散で 0.00724 と極端に小さい。罰を外すと 2e-10 になり、何桁も変わる。「1 標準偏差で何倍」と読める数ではない。予想は外れた。

表 4: 紙幣のデータの 4 列のロジスティック回帰のオッズ比(1 標準偏差あたり)。既定の罰と罰なし

列(1 標準偏差あたり)	既定の罰($\lambda = 1$)	罰なし
画像の分散	0.00724	2e-10
歪度	0.00647	2.1e-11
尖度	0.00991	1.28e-10
エントロピー	1.27	0.28

理由は第 I 部の「完全に分けられるとき」にある。紙幣は 4 列で、ほぼ完全に分けられる。そのとき係数の向きは決まるが、長さ、つまり S 字の急さはデータでは決まらず、罰が決める。オッズ比 e^{β_j} は係数の長さで決まるので、罰しだいで何桁も動く。オッズ比で読めるのは、群がほどほどに重なり、S 字の急さがデータで決まるときである。

落とし穴

第 I 部で見た完全な分離は、このデータで実際に起きる。4 列のままでは、真札の側に残る偽札と、偽札の側に残る真札がある。このため罰を外しても最尤推定が存在し、ニュートン法は 14 回で止まる。ところが、4 列の 2 乗と積の 10 列を足して 14 列にすると(足した列も標準化した)、1,372 枚の偽札と真札を 1 枚の平面で完全に分けられるようになる(線形計画法で、すべての札を正しい側に置く係数が見つかることを確かめた)。図 16 は、罰を外したニュートン法の反復ごとに、係数の絶対値の最大と対数尤度を描いたものである。4 列(緑)では係数は止まるが、14 列(赤)では反復のたびに大きくなり、30 回で 142 に達しても止まらない。対数尤度は 0 に近づき、1,372 枚の確率が 0.01 未満か 0.99 を超える。確率を出すために最尤法を使ったのに、確率はほとんど 0 か 1 に偏り、係数の値は何回で反復を止めたかで決まる。最尤推定が存在しないからである。罰 $\lambda = 1$ を付ければ(黒)、14 列でも 10 回で止まる。列を足さなくても、枚数が少なければ同じことが起きる。全件から 200 枚を抜き出すことを 100 回繰り返すと、4 列のままでも 75 回で完全に分けられた。行に比べて列が多いほど、また群がよく離れているほど、完全な分離は起きやすい。

一方、罰は中立ではない。4 列に戻して、訓練の行で罰の強さ λ を変えながらロジスティック回帰を当てはめ、テストの交差エントロピーを測ったのが図 17 である。scikit-learn の LogisticRegression は何も指定しなければ $\lambda = 1$ の罰を付ける。このデータでは $\lambda = 1$ のテストの交差エントロピー 0.039 は、罰なしの 0.026 よりも LDA の 0.032 よりも大きい。罰によって係数が縮み(長さ 40.3 $\rightarrow$ 8.4)、S 字がなだらかになって、確率が 0.5 の側へ寄りすぎたためである。0.5 で切った一致率は変わらないので、判定だけを見ていると気づかない。罰の強さは、第 4 回と同じく交差検証(クロスバリデーション、CV)などで選ぶものである。既定の値に黙って




図 16: 紙幣のデータ(全件)のロジスティック回帰のニュートン法。4 列・罰なし(緑)、2 乗と積を足した 14 列・罰なし(赤)、14 列・罰の強さ $\lambda = 1$ (黒)の、(a) 係数の絶対値の最大と (b) 対数尤度の反復ごとの値

任せてよいものではない。(手で回した $\lambda = 1$ の係数は、scikit-learn の LogisticRegression の既定の結果と最大 $2e-07$ の差で一致した。)なお、この図はテストの行で測っているのもので、 λ を選ぶ道具としてではなく、罰の強さで確率が変わることを示すものとして読む。




図 17: 紙幣のデータ(4 列)のロジスティック回帰で、罰の強さ λ を変えたときのテストの交差エントロピー(訓練の行で当てはめ、テストの行で測った。左端は罰なし)。破線は LDA、赤の点は scikit-learn の既定の $\lambda = 1$

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは、0/1 の直線をはみ出し、LDA とロジスティック回帰の確率は 0 と 1 の間に収まると予想した。これは予想どおりだった。さらに、LDA の仮定に近いデータなら、2 つのモデルは同じ 1 次式に着くはずだと予想した。向きは予想どおりで、差は 2.1 度だった。ところが係数の長さは 22.6 と 40.3 で、予想は外れた。理由は、2 つの群の散らばりが違い、共通の共分散という LDA の仮定が合っていないことにある。LDA はすべての札の平均と散らばりから長さを決め、ロジスティック回帰は境界の近くの当てにくい札に合わせて長さを決める。長さが違うので、0.5 で切った判定はほぼ同じでも、確率の当たり方(交差エントロピー)には差が出た。確率を出すモデルを選ぶときは、判定の一致率だけでなく、確率そのものの当たり方を見る必要がある。係数をオッズ比で読むと、分散 1 列では「1 大きいとオッズは約 3 分の 1」と素直に読めた。だが 4 列ではほぼ完全に分かれるので、係数の長さが罰で決まり、オッズ比は何桁も動いた。

締め

まとめと次回問い

本章の問いは「方向は出るが、確率が出ない。確率を出すにはどうすればよいか」であった。答えは、データの出力を確率分布で仮定し、手元のデータが出てくる確率を最大にする最尤法である。まず、第 1 回からの最小二乗法は、誤差が独立な正規分布に従うと仮定したときの最尤法であることを示した。対数尤度に誤差の二乗和がそのまま現れるからである。次に、群ごとに共通の共分散の正規分布を置いた LDA を最尤法で当てはめた。推定値は群の割合・平均・群の中の共分散行列 $\mathbf{S}_W$ になり、事後確率は $\text{sig}(\mathbf{w}^\top \mathbf{x} + w_0)$ 、 $\mathbf{w} = \mathbf{S}_W^{-1} \mathbf{d}$ となった。向きは第 5 回の最小二乗法と同じで、その上に確率が乗る。最後に、この形だけを直接置くロジスティック回帰を導いた。勾配は $\mathbf{X}^\top (\mathbf{y} - \boldsymbol{\theta})$ で、閉じた形の解がないのでニュートン法で解く。完全に分けられるデータでは最尤推定が存在せず、第 4 回と同じ形の罰で止める。紙幣のデータでは、LDA の向きは 0/1 の最小二乗法の係数とコサイン 1.0000000 で一致し、ロジスティック回帰(罰なし)の向きとも 2.1 度しか違わなかった。それでも係数の長さが違うので確率の値は違い、罰の強さによっても変わった。2 乗と積の列を足すと完全に分けられ、罰なしでは係数が止まらなかった。

最後に、次回への問いを置く。本章では、確率を 0.5 で切って一致率を数えてきた。しかし、偽札を真札と言う見逃しと、真札を偽札と言う誤検出とでは、誤りの重さが違う。確率が出たとき、どこで切ればよいのか。そして、一致率だけでモデルを比べてよいのか。次回は、誤りの重さからしきい値を決める考え方と、評価の指標が置いている暗黙の仮定を扱う。