第 7 回 k-means

交互最小二乗法で局所解を得る

本章の問いは、第 6 回の締めで残った「群のラベルが無いとき、行をどう群に分けるか？」である。第 6 回の LDA は、群のラベルを見て群ごとの平均を数えた。k-means では、各行に 1 が 1 つだけ立つ 0/1 の所属行列 $\mathbf{G}$ も未知になる。交互最小二乗法で答え、2 つの更新式はその場で導く。$\mathbf{C}$ を固定すれば、各行を最も近い代表点の群に入れるのが $\mathbf{G}$ の最良の更新になる。$\mathbf{G}$ を固定すれば、$\hat{\mathbf{C}} = (\mathbf{G}^\top \mathbf{G})^{-1} \mathbf{G}^\top \mathbf{X}$、すなわち群ごとの平均が $\mathbf{C}$ の最良の更新になる。J は毎回下がり、有限回で止まる。ただし着く先は初期値しだいなので、初期値を変えてやり直し、J が最も小さい答えを採る（ランダムスタート）。

第 I 部　理論

行を群に分ける

第 6 回の LDA では、どの行にも正解の群 y が付いていたので、群ごとの割合と平均を数えるだけで推定できた。第 6 回の最後に、「群のラベルが無いとき、行をどう群に分けるか？」という問いを残した。ラベルが無ければ、群ごとの平均は数えられない。平均を数えるには群が要り、群を決めるには平均が要る。本章では、群の所属そのものを未知として、データ行列を群の代表点で近似する。

場面として、図 1 のワインを考える。ワイン 178 本について、アルコールやフラバノイドなど 13 種類の化学成分を測ったデータである。図 1 はそのうちフラバノイドと色の濃さの 2 列を描いたもので、1 点がデータ行列の 1 行、すなわち 1 本のワインである。どのワインがどの群に属するかの記録は無いものとする。近い点どうしは成分が似ているので、似たワインを群にまとめたい。

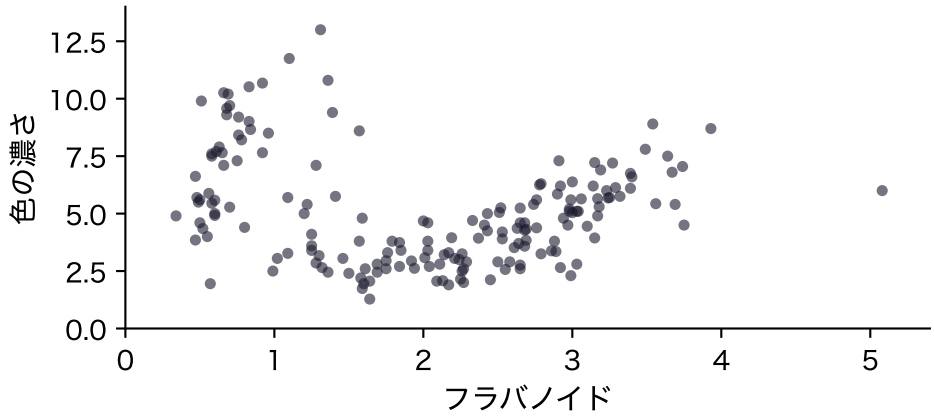


図 1: ワイン 178 本の化学成分(13 列のうちフラバノイドと色の濃さの 2 列)

困りごとは 3 つある。1 つ目は、所属が 0 か 1 しかとれないことである。回帰では目的関数を微分して傾きを 0 とおけば答えが出たが、0 と 1 の 2 点しかとれない g_{iq} には傾きが無い。2 つ目は、分け方の多さである。n 行を k 群に分ける分け方は k^n 通りあり、ワイン 178 本を 2 つに分けるだけでも 2 の 178 乗通りになる。すべて試すことはできない。3 つ目は、始め方で答えが変わることである。同じワインを同じ手順で 3 群に分けても、始め方を変えると分け方が変わる(図 2)。どちらを信じればよいのか。

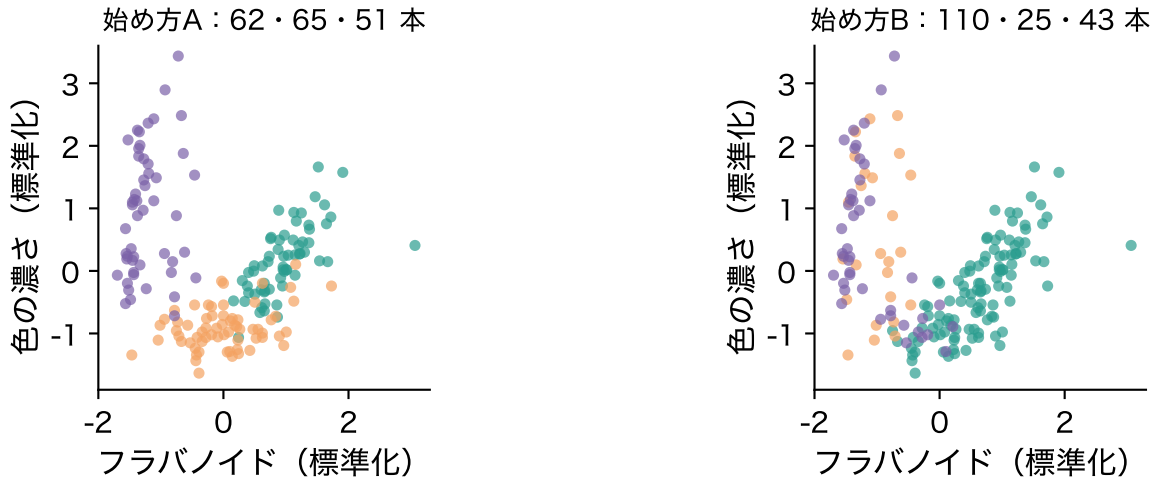


図 2: ワイン 178 本(13 列を標準化)を、同じ手順で 3 群に分けた 2 つの答え。始め方だけが違う。描いたのはフラバノイドと色の濃さの 2 列

本章では、行を群に分けるとき、0/1 の $\mathbf{G}$ と、代表点を並べた $\mathbf{C}$ をどう求めるかを問う。k-means は、反復して解くしかない問題の代表例である。

答えは交互最小二乗法である。$\mathbf{C}$ を固定すれば、各行を最も近い代表点の群に入れることが $\mathbf{G}$ の最良の選び方になる。$\mathbf{G}$ を固定すれば、$\hat{\mathbf{C}} = (\mathbf{G}^\top\mathbf{G})^{-1}\mathbf{G}^\top\mathbf{X}$、すなわち群ごとの平均が $\mathbf{C}$ の最良の選び方になる。この 2 つを交互に繰り返すと目的関数は毎回下がり、有限回で止まる。2 つの更新がなぜ最良になるかは、それぞれの

節で導く。ただし、止まる先は初期値によって変わる。そこで初期値を変えてやり直し、目的関数が最も小さい答えを採る。

代表点で近似する

2 変数の人工データで、群に分けて代表点で近似するとはどういうことかを見る。図 3 (a) は、アイスクリーム 120 個の甘さと固さ(10 点満点)を描いた人工的なデータと、$k = 4$ 個の代表点(セントロイド(centroid)、代表ベクトル)である。代表点は、データの中から 3 個を選んで置いた。k-means クラスタリング(k-means clustering)では、各個体をどれか 1 つの群(クラスター)に入れ、その群の代表点で近似する。図 3 (b) の色は各個体を入れた群、線は個体から代表点への近似の誤差である。第 6 回の LDA は群ごとの平均を数えたが、ここでは群の所属も分からないまま、k 個の代表点のどれかで近似する。

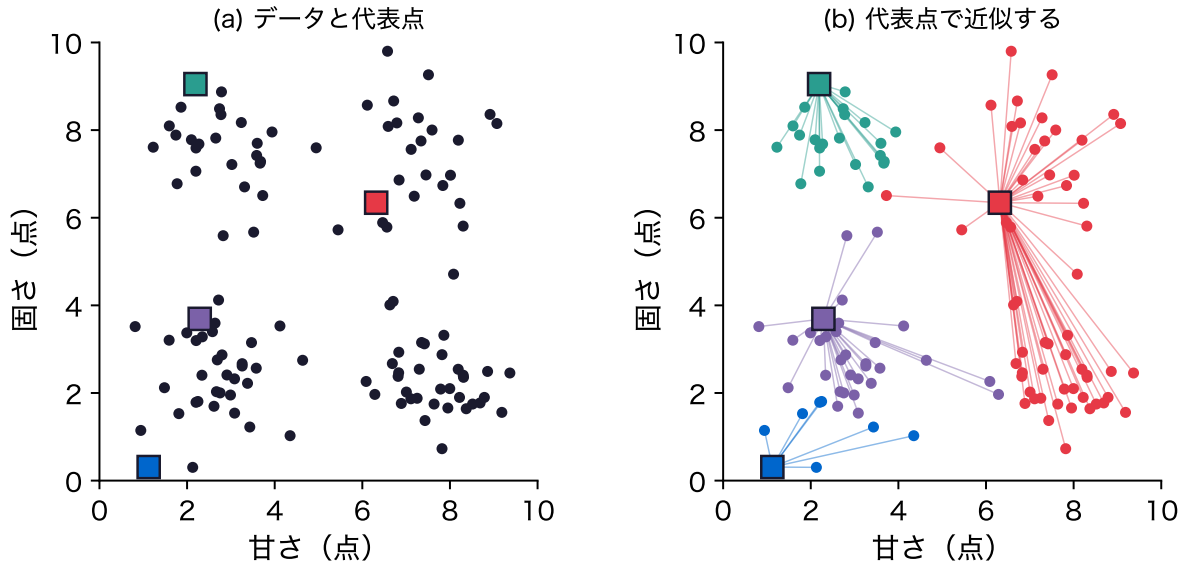


図 3: アイスクリーム 120 個の甘さと固さ(人工データ)。(a) データと $k = 4$ の代表点(■)、(b) 各個体を 1 つの群に入れ、その群の代表点で近似したもの。線が近似の誤差

行列で書けば、データ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ は、所属を表す $\mathbf{G} \in \{0,1\}^{n \times k}$ と、代表点を行に並べた $\mathbf{C} = [\boldsymbol{c}_1, \ldots, \boldsymbol{c}_k]^\top \in \mathbb{R}^{k \times p}$ の積で近似される(図 4)。第 1 回の「データ＝モデル＋誤差」の形に書けば

$$\mathbf{X} = \mathbf{GC} + \mathbf{E} \tag{1}$$

である。$\mathbf{G}$ の第 i 行は 1 が立った列だけで $\mathbf{C}$ の 1 行を拾うので、$\mathbf{GC}$ の第 i 行は、個体 i が入った群の代表点になる。線形回帰の $\mathbf{X}\boldsymbol{\beta}$ では $\mathbf{X}$ が手元にあり、未知は $\boldsymbol{\beta}$ だけだった。$\mathbf{GC}$ は未知の行列どうしの積で、しかも $\mathbf{G}$ の成分は 0 か 1 に限られる。

$\mathbf{G}$ は第 5 回の指示行列 $\mathbf{Y}$ と同じ形をしている。LDA では $\mathbf{Y}$ が手元にあったので、群ごとの平均を数えるだけで済んだ。k-means では、$\mathbf{G}$ も推定する。第 1〜6 回のように正解 $\boldsymbol{y}$ と比べて当てはめるやり方を教

師あり学習(supervised learning)、$\boldsymbol{y}$ を使わずにデータ行列 $\mathbf{X}$ そのものを近似するやり方を教師なし学習(unsupervised learning)と呼ぶ。k-means は教師なし学習である。

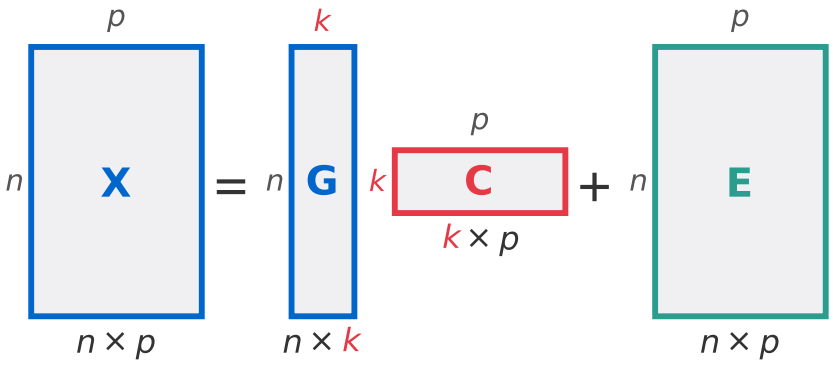


図 4: k-means のモデルの型(概念図)。$n \times p$ の $\mathbf{X}$ を、$n \times k$ の $\mathbf{G}$ と $k \times p$ の $\mathbf{C}$ の積と誤差 $\mathbf{E}$ に分ける

目的関数とメンバーシップ関数

(1) 式の誤差の大きさを、スカラー・ベクトル・行列の順に書く。そのために、所属を数で表す。個体 i がクラスター q に所属するとき 1、しないとき 0 をとる

$$g_{iq} = \begin{cases} 1 & \text{個体 } i \text{ がクラスター } q \text{ に所属する} \\ 0 & \text{個体 } i \text{ がクラスター } q \text{ に所属しない} \end{cases} \tag{2}$$

をメンバーシップ関数(membership function)と呼ぶ(指示関数と呼ぶこともある)。k-means では 1 つの個体が複数のクラスターに所属することは許されないので、任意の i について制約

$$\sum_{q=1}^{k} g_{iq} = 1 \tag{3}$$

が成り立つ。行 i が入った群の番号を $q(i)$ と書くと、$q(i)$ は $g_{iq} = 1$ となるただ 1 つの q である。

まず 1 マスずつ書く。個体 i の第 j 変数 x_{ij} を、所属する群の代表点の第 j 成分 c_{qj} で近似するので、目的関数は

$$J = \sum_{i=1}^{n} \sum_{q=1}^{k} g_{iq} \sum_{j=1}^{p} (x_{ij} - c_{qj})^2 \tag{4}$$

である。$g_{iq} = 0$ の項は消えるので、行 i からは所属する群 $q(i)$ の項だけが残り、$\sum_i \sum_j (x_{ij} - c_{q(i)j})^2$ と同じ値になる。内側の j についての和は、個体 i のデータベクトル $\tilde{\boldsymbol{x}}_i \in \mathbb{R}^p$ と代表点 $\boldsymbol{c}_q \in \mathbb{R}^p$ のユークリッド距離の二乗であるから

$$J = \sum_{i=1}^{n} \sum_{q=1}^{k} g_{iq} \, \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2 \tag{5}$$

と書ける。$p = 1$ なら距離の二乗は $(x_i - c_q)^2$ であり、(4) 式の内側の和は 1 項だけになる。

最後に行列で書く。g_{iq} を (i, q) 成分とする $\mathbf{G} \in \{0, 1\}^{n \times k}$ をメンバーシップ行列（指示行列）と呼ぶ（定義 1）。$\mathbf{GC}$ の (i, j) 成分 $\sum_q g_{iq} c_{qj}$ では、(3) 式により、1 が立った q の c_{qj} だけが残る。同じ理由で $\sum_q g_{iq}(x_{ij} - c_{qj})^2 = (x_{ij} - \sum_q g_{iq} c_{qj})^2$ であるから、(4) 式は $\mathbf{X} - \mathbf{GC}$ の全マスの二乗和である。行列 $\mathbf{A}$ の全マスの二乗和の平方根 $\|\mathbf{A}\|_F = (\sum_i \sum_j a_{ij}^2)^{1/2}$ をフロベニウスノルム（Frobenius norm）と呼ぶ。1 列の行列なら ℓ_2 ノルムと同じである。これを使えば、目的関数は

$$J(\mathbf{G}, \mathbf{C}) = \|\mathbf{X} - \mathbf{GC}\|_F^2 \tag{6}$$

に等しい。たとえば 7 個体を 3 つのクラスターに分ける。個体 1〜3 をクラスター 1 に、個体 4・5 をクラスター 2 に、個体 6・7 をクラスター 3 に入れると

$$\mathbf{G} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix} \tag{7}$$

である。制約 (3) 式は、各行の和が 1 であることを表す。$\mathbf{1}_k$ を k 個の 1 を並べたベクトルとすると

$$\mathbf{G}\mathbf{1}_k = \mathbf{1}_n \tag{8}$$

と書ける。(7) 式はこれを満たしている。

定義 1 (メンバーシップ行列)**.** 個体 i がクラスター q に所属するとき 1、しないとき 0 をとる g_{iq} をメンバーシップ関数、g_{iq} を並べた $n \times k$ の行列 $\mathbf{G}$ をメンバーシップ行列と呼ぶ。各個体はちょうど 1 つのクラスターに所属し、$\mathbf{G}\mathbf{1}_k = \mathbf{1}_n$ を満たす。

定義 2 (k-means クラスタリング)**.** データ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ とクラスター数 k が与えられたとき、$\mathbf{G}\mathbf{1}_k = \mathbf{1}_n$ を満たすメンバーシップ行列 $\mathbf{G}$ とセントロイド行列 $\mathbf{C} \in \mathbb{R}^{k \times p}$ について、目的関数 (6) 式を最小にすることを k-means クラスタリングという。

交互に解く

(6) 式を最小にする $\mathbf{G}$ と $\mathbf{C}$ を一度に求めることはできない。回帰と違い、未知は 2 つの行列の積になっている。そのうえ $\mathbf{G}$ の成分は 0 か 1 に限られるので、$\mathbf{G}$ について微分して 0 とおくことができない。n 個の個体

を k 個のクラスターに入れる入れ方は k^n 通りある。ワイン 178 本を 2 つに分けるだけでも 2 の 178 乗、およそ 10 の 53 乗通りになるので、すべて試すこともできない。線形回帰では $\boldsymbol{\beta}$ が連続な値をとれたので、正規方程式を 1 回解けば答えが得られた（第 1 回）。k-means にはそのような近道が無い。

そこで、交互最小二乗法（alternating least squares）を使う（図 5）。$\mathbf{C}$ を固定して $\mathbf{G}$ を更新し、次に $\mathbf{G}$ を固定して $\mathbf{C}$ を更新する。どちらの更新も、固定したもののもとで目的関数を最小にするので、目的関数は更新のたびに下がるか変わらない。$\mathbf{C}$ を固定したときの最良の $\mathbf{G}$ は、(9) 式のとおり、各個体を最も近い代表点のクラスターに入れるものである。$\mathbf{G}$ を固定したときの最良の $\mathbf{C}$ は、(22) 式のとおり、クラスターごとの平均 $\hat{\mathbf{C}} = (\mathbf{G}^\top \mathbf{G})^{-1} \mathbf{G}^\top \mathbf{X}$ である。前者は場合分けで、後者は微分で導く。次の 2 つの節で順に示す。中心に近い個体の上に代表点を置くより、平均に置くほうが二乗和は小さい。所属が変わらなくなれば、代表点も動かなくなる。

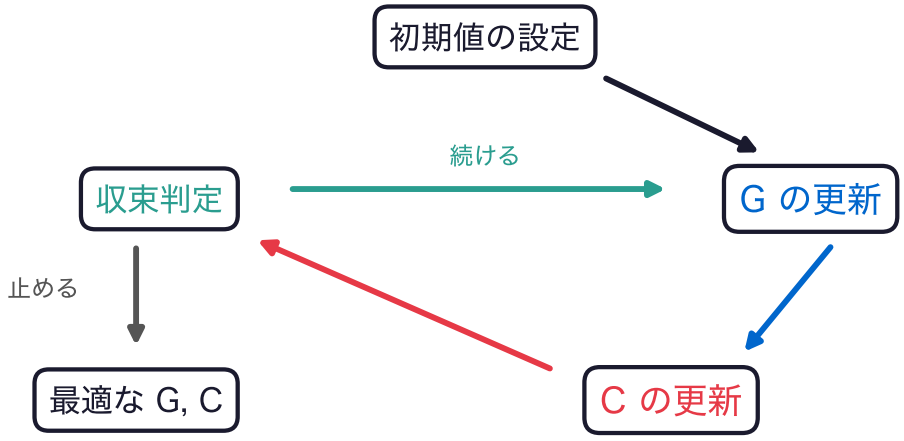


図 5: k-means の交互最小二乗法の概要図（概念図）

G の更新

$\mathbf{C}$ を固定したときの $\mathbf{G}$ の更新が最良であることを導く。$\mathbf{C}$ を固定して $\mathbf{G}$ を更新する。1 つの個体に注目する。図 6 には、図 3 と同じデータの真ん中あたりの個体 104 と、4 つの代表点を描いた。個体 104 のデータベクトルは $\tilde{\boldsymbol{x}}_i = (5.45, 5.72)$ である。3 つの代表点との距離の二乗 $\|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2$ は、それぞれ 1.14、48.00、21.66、14.10 となる。

(5) 式のうちこの個体の項は $\sum_q g_{iq} \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2$ である。制約 (3) 式のもとで選べるのは、4 つの g_{iq} のどれを 1 にするかだけである。1 にした列の距離の二乗だけが残り、残りの距離は無視される。そこで、距離の二乗が最も小さいクラスター 1 を選び、その列だけを 1 にすればよい。選んだ列を q^* と書けば

$$\sum_{q=1}^{4} g_{iq} \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2 = \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_{q^*}\|_2^2$$

となる。g_{iq} は 0 か 1 しかとらないので、微分して 0 とおく方法は使えない。このように場合分けで求めるしか

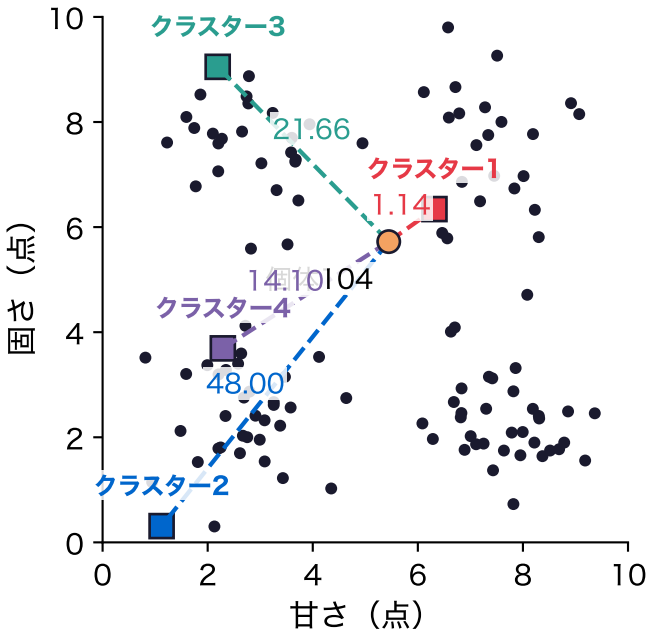


図 6: 真ん中あたりの 1 個(橙)と 4 つの代表点(人工データ)。数字は距離の二乗

ない。

同じことはすべての個体について言える。$d_{iq} = \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2$ とおくと、$\mathbf{C}$ を固定したときの目的関数は $J = \sum_i (\sum_q g_{iq} d_{iq})$ となる。括弧の中は、行 i の $g_{i1}, \ldots, g_{ik}$ だけを含む。行ごとに別々に最小にすればよいので、$\mathbf{G}$ の更新式は

$$\hat{g}_{iq} = \begin{cases} 1 & (q = \operatorname{argmin}_{1 \le l \le k} \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_l\|_2^2) \\ 0 & (\text{それ以外}) \end{cases} \tag{9}$$

となる。つまり、各個体を最も近い代表点のクラスターに入れる。図 3 (b) の色は、はじめに置いた代表点のもとで、この更新を 120 個すべてに行った結果である。

計算の手順として行列で書くために、距離の二乗を $d_{iq} = \|\tilde{\boldsymbol{x}}_i\|_2^2 - 2\tilde{\boldsymbol{x}}_i^\top \boldsymbol{c}_q + \|\boldsymbol{c}_q\|_2^2$ と展開する。$a_i = \|\tilde{\boldsymbol{x}}_i\|_2^2$、$b_q = \|\boldsymbol{c}_q\|_2^2$ を並べたベクトルを $\boldsymbol{a} \in \mathbb{R}^n$、$\boldsymbol{b} \in \mathbb{R}^k$ とすれば、d_{iq} を並べた $n \times k$ の行列は

$$\mathbf{D} = \boldsymbol{a}\mathbf{1}_k^\top - 2\mathbf{X}\mathbf{C}^\top + \mathbf{1}_n \boldsymbol{b}^\top \tag{10}$$

である。(9) 式は、$\mathbf{D}$ の各行で最も小さい列に 1 を置き、残りを 0 とすることにあたる。第 1 項は行の中で一定なので、どの列が最小かは $-2\mathbf{X}\mathbf{C}^\top + \mathbf{1}_n \boldsymbol{b}^\top$ だけで決まる。主な計算は、$n \times p$ と $p \times k$ の行列の積 $\mathbf{X}\mathbf{C}^\top$ である。

C の更新

$\mathbf{C}$ の更新を、まずベクトルで、次に行列のまま導く。導出には、次の 3 つの道具を使う。

定義 3 (ベクトルの微分)**.** $\boldsymbol{c} \in \mathbb{R}^p$ の関数 f について、各成分 c_j で f を偏微分し、縦に並べたベクトルを $\partial f / \partial \boldsymbol{c}$ と書く。$\boldsymbol{a} \in \mathbb{R}^p$ について、次が成り立つ。

$$\frac{\partial (\boldsymbol{a}^\top \boldsymbol{c})}{\partial \boldsymbol{c}} = \boldsymbol{a} \tag{11}$$

$$\frac{\partial (\boldsymbol{c}^\top \boldsymbol{c})}{\partial \boldsymbol{c}} = 2\boldsymbol{c} \tag{12}$$

定義 4 ($\mathbf{G}^\top\mathbf{G}$ と $\mathbf{G}^\top\mathbf{X}$)**.** メンバーシップ行列 $\mathbf{G}$ とデータ行列 $\mathbf{X}$ について、次が成り立つ。n_q はクラスター q に入った個体の数である。

$$\mathbf{G}^\top\mathbf{G} = \mathrm{diag}(n_1, \dots, n_k), \qquad n_q = \sum_{i=1}^{n} g_{iq} \tag{13}$$

$$(\mathbf{G}^\top\mathbf{X})_{qj} = \sum_{i=1}^{n} g_{iq}\, x_{ij} \tag{14}$$

定義 5 (トレースとその偏微分)**.** 正方行列 $\mathbf{M}$ の対角の和を $\mathrm{tr}(\mathbf{M})$ と書く。行列 $\mathbf{B}$ の関数 f について、各マス b_{qj} で偏微分し、$\mathbf{B}$ と同じ形に並べた行列を $\partial f / \partial \mathbf{B}$ と書く。$\mathbf{B}$ と同じ大きさの $\mathbf{M}$ と、対称な $\mathbf{S}$ について、次が成り立つ。

$$\frac{\partial \mathrm{tr}(\mathbf{B}^\top\mathbf{M})}{\partial \mathbf{B}} = \mathbf{M} \tag{15}$$

$$\frac{\partial \mathrm{tr}(\mathbf{B}^\top\mathbf{S}\mathbf{B})}{\partial \mathbf{B}} = 2\mathbf{S}\mathbf{B} \tag{16}$$

定義 3 は成分ごとに確かめられる。$\boldsymbol{a}^\top\boldsymbol{c} = \sum_j a_j c_j$ を c_j で偏微分すると a_j が残り、$\boldsymbol{c}^\top\boldsymbol{c} = \sum_j c_j^2$ を c_j で偏微分すると $2c_j$ が残る。1 変数の ac と c^2 の微分と同じ形をしている。

定義 4 の $\mathbf{G}^\top\mathbf{G}$ は、$k \times n$ の $\mathbf{G}^\top$ と $n \times k$ の $\mathbf{G}$ の積なので、$k \times k$ の正方行列になる。その (q, l) 成分は $\sum_i g_{iq} g_{il}$ である。(3) 式により 1 つの行には 1 が 1 つしかないので、$q \neq l$ なら $g_{iq} g_{il}$ はどの行でも 0 になる。$q = l$ なら $g_{iq}^2 = g_{iq}$ であるから、対角には群の人数が並ぶ。(7) 式の例では $\mathbf{G}^\top\mathbf{G} = \mathrm{diag}(3, 2, 2)$ である。どのクラスターにも 1 個体以上入っていれば、その逆行列は対角を逆数にしたものになる。空のクラスターがあると対角に 0 が現れ、第 3 回で見た正則でない行列になる。$\mathbf{G}^\top\mathbf{X}$ は $\mathbf{C}$ と同じ $k \times p$ の行列で、第 q 行はクラスター q に入った行 $\tilde{\boldsymbol{x}}_i^\top$ の和である。

定義 5 のトレースは第 3 回で導入した。転置しても対角は変わらないので $\operatorname{tr}(\mathbf{M}^\top) = \operatorname{tr}(\mathbf{M})$ であり、$\operatorname{tr}(\mathbf{E}^\top\mathbf{E})$ は $\mathbf{E}$ の全マスの二乗和 $\|\mathbf{E}\|_F^2$ になる。(15) 式は、$\operatorname{tr}(\mathbf{B}^\top\mathbf{M}) = \sum_q \sum_j b_{qj} m_{qj}$ を b_{qj} で偏微分すると m_{qj} が残ることから従う。(16) 式は、$\operatorname{tr}(\mathbf{B}^\top\mathbf{S}\mathbf{B}) = \sum_j \sum_q \sum_l s_{ql} b_{qj} b_{lj}$ を b_{qj} で偏微分すると、$\mathbf{S}$ が対称なので $\sum_l s_{ql} b_{lj} + \sum_l s_{lq} b_{lj} = 2(\mathbf{S}\mathbf{B})_{qj}$ となることから従う。1×1 なら $d(sb^2)/db = 2sb$ であり、1 変数の微分と同じ形をしている。

次に、$\mathbf{G}$ を固定して $\mathbf{C}$ を更新する。スカラーから始める。変数が 1 つ ($p = 1$) なら、(4) 式のうちクラスター q の代表点 c_q を含むのは $\sum_i g_{iq}(x_i - c_q)^2$ だけで、これは c_q の放物線である。1 変数の微分を 0 とおくと

$$\frac{d}{dc_q} \sum_{i=1}^{n} g_{iq}(x_i - c_q)^2 = -2 \sum_{i=1}^{n} g_{iq}(x_i - c_q) = 0 \quad \Longrightarrow \quad \hat{c}_q = \frac{\sum_i g_{iq} x_i}{\sum_i g_{iq}} \tag{17}$$

を得る。分母はクラスター q の個体の数、分子はその和であるから、$\hat{c}_q$ はクラスター q の平均である。

変数が p 個なら、(5) 式の $\boldsymbol{c}_q$ を含む項 $\sum_i g_{iq} \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2$ をベクトル $\boldsymbol{c}_q$ で偏微分し、勾配を 0 とおく。距離の二乗を内積で展開し、定義 3 の (11) 式を第 2 項に、(12) 式を第 3 項に使う。第 1 項は $\boldsymbol{c}_q$ を含まないので消える。

$$\begin{aligned} \frac{\partial}{\partial \boldsymbol{c}_q} \sum_{i=1}^{n} g_{iq} \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2 &= \frac{\partial}{\partial \boldsymbol{c}_q} \sum_{i=1}^{n} g_{iq} (\tilde{\boldsymbol{x}}_i^\top \tilde{\boldsymbol{x}}_i - 2\tilde{\boldsymbol{x}}_i^\top \boldsymbol{c}_q + \boldsymbol{c}_q^\top \boldsymbol{c}_q) \\ &= \sum_{i=1}^{n} g_{iq}(-2\tilde{\boldsymbol{x}}_i + 2\boldsymbol{c}_q) = -2\Big(\sum_{i=1}^{n} g_{iq} \tilde{\boldsymbol{x}}_i\Big) + 2\boldsymbol{c}_q \Big(\sum_{i=1}^{n} g_{iq}\Big) = 0_p \end{aligned} \tag{18}$$

したがって $\boldsymbol{c}_q$ の更新式は

$$\hat{\boldsymbol{c}}_q = \frac{\sum_{i=1}^{n} g_{iq} \tilde{\boldsymbol{x}}_i}{\sum_{i=1}^{n} g_{iq}} \tag{19}$$

である。これはクラスター q に入った個体のデータベクトルの平均で、$p = 1$ なら (17) 式に戻る。k 個の $\hat{\boldsymbol{c}}_q^\top$ を縦に積めば $\hat{\mathbf{C}}$ になる。

同じ更新を行列のまま導く。二乗和をトレースで表すと

$$J(\mathbf{C} \mid \mathbf{G}) = \operatorname{tr}((\mathbf{X} - \mathbf{G}\mathbf{C})^\top (\mathbf{X} - \mathbf{G}\mathbf{C})) = \operatorname{tr}(\mathbf{X}^\top \mathbf{X}) - 2\operatorname{tr}(\mathbf{C}^\top \mathbf{G}^\top \mathbf{X}) + \operatorname{tr}(\mathbf{C}^\top \mathbf{G}^\top \mathbf{G}\mathbf{C}) \tag{20}$$

と展開できる。交差項は $\operatorname{tr}(\mathbf{X}^\top \mathbf{G}\mathbf{C}) = \operatorname{tr}(\mathbf{C}^\top \mathbf{G}^\top \mathbf{X})$ (転置) で 1 つにまとめた。定義 5 の (15) 式を第 2 項に、(16) 式を $\mathbf{S} = \mathbf{G}^\top \mathbf{G}$ として第 3 項に使うと

$$\frac{\partial J}{\partial \mathbf{C}} = -2\mathbf{G}^\top \mathbf{X} + 2\mathbf{G}^\top \mathbf{G}\,\mathbf{C} = \mathbf{O} \quad \Longrightarrow \quad \mathbf{G}^\top \mathbf{G}\,\mathbf{C} = \mathbf{G}^\top \mathbf{X} \tag{21}$$

を得る。これは第 1 回の正規方程式 $\mathbf{X}^\top\mathbf{X}\boldsymbol{\beta} = \mathbf{X}^\top\boldsymbol{y}$ の $\mathbf{X}$ を $\mathbf{G}$ に、$\boldsymbol{y}$ を $\mathbf{X}$ に替えた形である。$\mathbf{G}$ を固定すると、(1) 式は所属の 0/1 の列を説明変数にして $\mathbf{X}$ の各列を回帰するモデルになり、$\mathbf{C}$ はその係数にあたる。どのクラスターにも個体が入っていれば $\mathbf{G}^\top\mathbf{G}$ は正則なので

$$\hat{\mathbf{C}} = (\mathbf{G}^\top\mathbf{G})^{-1}\mathbf{G}^\top\mathbf{X} = \mathrm{diag}\Big(\frac{1}{n_1}, \dots, \frac{1}{n_k}\Big)\mathbf{G}^\top\mathbf{X} \tag{22}$$

となる。2 つ目の等号は 定義 4 の (13) 式による。(14) 式により、第 q 行はクラスター q の行の和を n_q で割ったものになり、(19) 式の $\hat{\boldsymbol{c}}_q^\top$ と一致する。行列で書いても、クラスターごとの平均を縦に積んだだけである。図 7 は、図 3 (b) の群を固定して $\mathbf{C}$ を 1 回更新したところで、代表点はそれぞれの群の平均へ動いた。

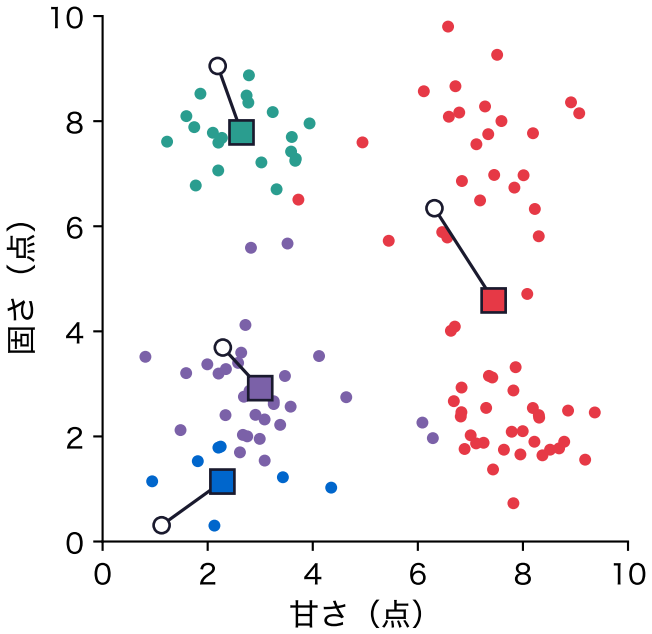


図 7: 図 3 (b) の群を固定して $\mathbf{C}$ を 1 回更新したもの（人工データ）。白丸が更新の前の代表点、■が群の平均

計算の手順

2 つの更新を、実際に計算する行列の形で手順にまとめる。

1. 列の目盛りをそろえたデータ行列 $\mathbf{X} \in \mathbb{R}^{n\times p}$ と、クラスター数 k を用意する
2. 初期値を置く。$\mathbf{C}$ は観測されていないが既知として与える必要があるので、$\mathbf{X}$ の行から k 行を無作為に選んで $\mathbf{C} \in \mathbb{R}^{k\times p}$ とする
3. $\mathbf{C}$ を固定して、(10) 式の $\mathbf{D}$ を作り、(9) 式により各行で最小の列に 1、残りに 0 を置いて $\mathbf{G}$ とする
4. $\mathbf{G}$ を固定して、(22) 式により $\mathbf{C} \leftarrow (\mathbf{G}^\top\mathbf{G})^{-1}\mathbf{G}^\top\mathbf{X}$ とする
5. $\mathbf{G}$ が前回と同じなら止める。そうでなければ 3 に戻る
6. 2〜5 を R 通りの初期値で行い、$J = \|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2$ が最も小さい答えを採る

1 回の反復で行うのは、行列の積 $\mathbf{X}\mathbf{C}^\top$ と $\mathbf{G}^\top\mathbf{X}$、各行の最小の列を探すこと、そして対角行列 $\mathbf{G}^\top\mathbf{G}$ の逆数である。線形回帰の手順（正規方程式を 1 回解く）には無かったのが、手順 6 のやり直しである。なぜ要るかは「どこに止まるか」の節で、手順 1 で目盛りをそろえるのはなぜかは「J は何を測るか」の節で見る。

回すと止まる

交互最小二乗法を回すと何が起きるかを見る。

まず、目的関数は更新のたびに下がるか変わらない。$\mathbf{G}$ の更新 (9) 式は $\mathbf{C}$ を固定したもとでの最良の $\mathbf{G}$ で、$\mathbf{C}$ の更新 (22) 式は $\mathbf{G}$ を固定したもとでの最良の $\mathbf{C}$ である。どちらも、更新する前の値を候補に含む中から最良を選ぶので、J を上げることはない。図 8 に、図 3 の 120 個で、はじめに置いた 3 つの代表点を初期値として手順を回したときの J の推移を示す。J は 928.4 から始まり、更新のたびに下がって 410.4 で止まった。

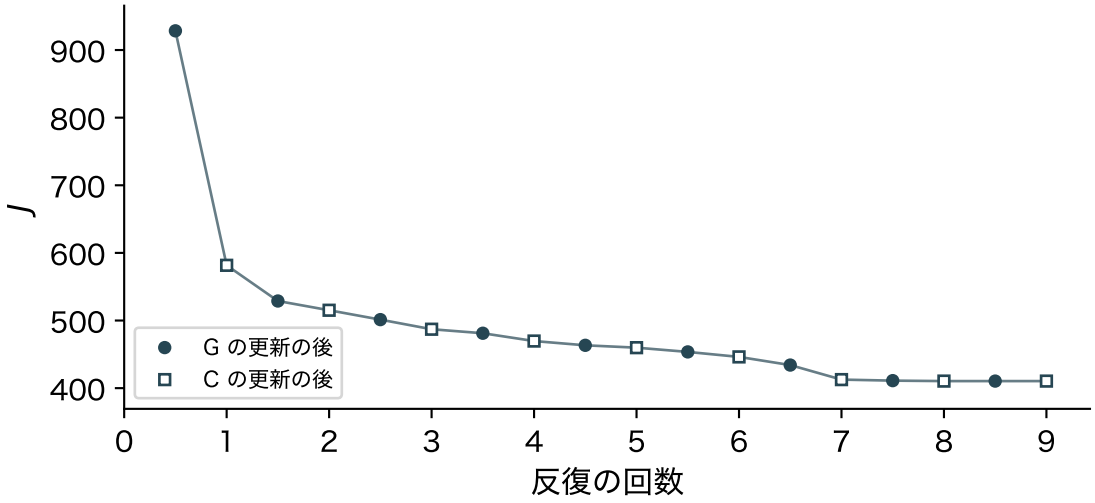


図 8: アイス 120 個の人工データで、はじめに置いた代表点を初期値にしたときの目的関数 J の推移。丸は $\mathbf{G}$ の更新の後、四角は $\mathbf{C}$ の更新の後

次に、手順は有限回で止まる。$\mathbf{G}$ のとりうる値は高々 k^n 通りの有限個である。J が真に下がり続ける限り同じ $\mathbf{G}$ に戻ることはない。そのため、いつかは $\mathbf{G}$ が変わらなくなり、そこで $\mathbf{C}$ も変わらなくなる。この例では 9 回の反復で止まった。図 9 (a) の黒い線は、代表点が初期値（白丸）から動いた道筋である。

また、2 つのクラスターの境目は直線になる。(9) 式で個体 $\tilde{\boldsymbol{x}}$ がクラスター 1 とクラスター 2 のどちらに入るかの境目は、$\|\tilde{\boldsymbol{x}} - \boldsymbol{c}_1\|_2^2 = \|\tilde{\boldsymbol{x}} - \boldsymbol{c}_2\|_2^2$ である。これを展開すると、$\|\tilde{\boldsymbol{x}}\|_2^2$ が両辺で消えて

$$2(\boldsymbol{c}_2 - \boldsymbol{c}_1)^\top \tilde{\boldsymbol{x}} = \|\boldsymbol{c}_2\|_2^2 - \|\boldsymbol{c}_1\|_2^2 \tag{23}$$

となる。$\tilde{\boldsymbol{x}}$ について 1 次の式なので、境目は直線（p 変数なら超平面）になる。この直線は、2 つの代表点を結ぶ線分の垂直二等分線である。図 10 のように、平面は代表点ごとの凸な領域に切り分けられる。そして $\mathbf{G}$ は 0 か 1 なので、境目のすぐそばの個体も、どちらか一方の群に完全に入る。

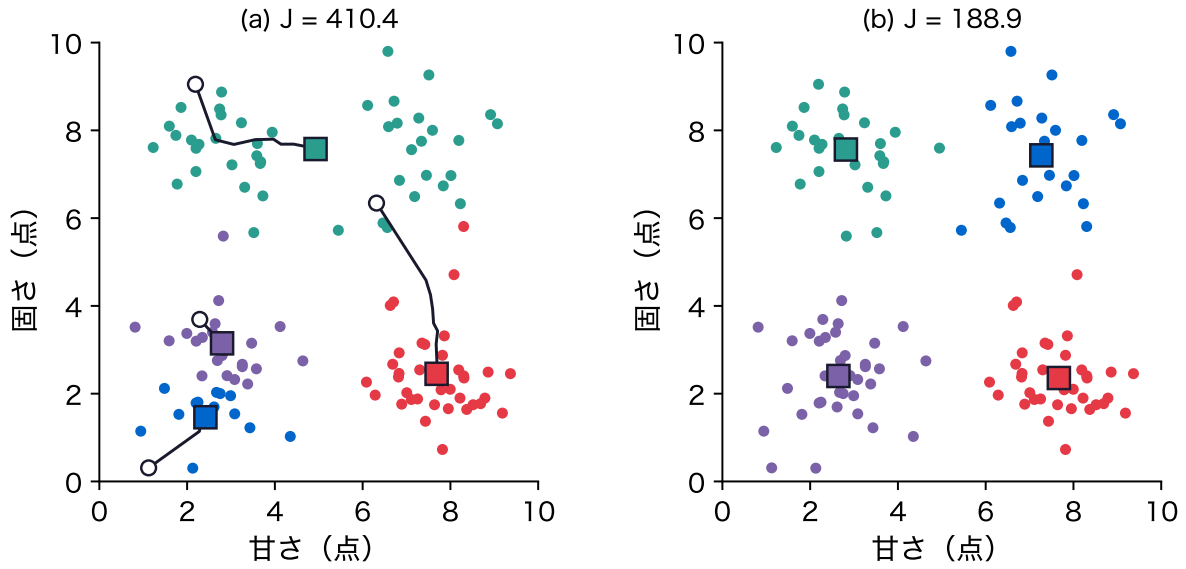


図 9: 同じアイス 120 個を $k = 4$ に分けた 2 つの答え（人工データ）。(a) はじめに置いた代表点を初期値にしたもの（黒い線は代表点の道筋、白丸は初期値）、(b) 別の初期値から着いたもの

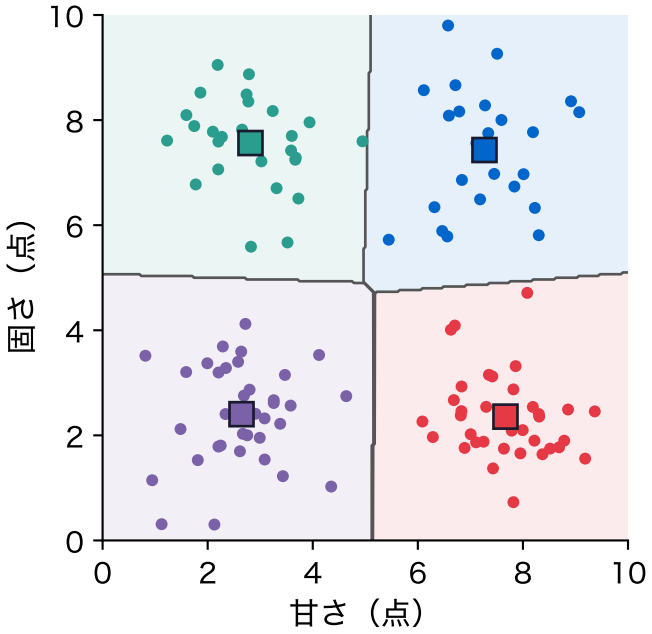


図 10: 図 9 (b) の答えで、平面の各点を最も近い代表点の群に塗り分けたもの（人工データ）。灰色の線が境目

J は何を測るか

J が何を測っているかを見る。

代表点を群の平均 $\hat{\mathbf{C}}$ に置けば、$J = \|\mathbf{X} - \mathbf{G}\hat{\mathbf{C}}\|_F^2$ は、各個体と自分の群の平均との距離の二乗和、すなわち群内の平方和である。k-means は、群内の平方和を最小にする分け方を探している。これを全体のばらつきと比べる。ここでは $\mathbf{X}$ の各列の平均を 0 にしておく。列ごとに同じ数を引いても個体どうしの距離は変わらないので、$\mathbf{G}$ の更新も J も変わらず、代表点が同じだけずれるだけである。$\mathbf{G}$ を決め、$\mathbf{C}$ を群の平均 $\hat{\mathbf{C}} = (\mathbf{G}^\top\mathbf{G})^{-1}\mathbf{G}^\top\mathbf{X}$ に置くと、

$$\mathbf{X}^\top\mathbf{X} = (\mathbf{X} - \mathbf{G}\hat{\mathbf{C}})^\top(\mathbf{X} - \mathbf{G}\hat{\mathbf{C}}) + \hat{\mathbf{C}}^\top\mathbf{G}^\top\mathbf{G}\hat{\mathbf{C}} \tag{24}$$

が成り立つ。左辺を n で割ったものは第 5 回の全体の共分散行列 $\mathbf{S}_\mathrm{T}$ である。右辺の第 1 項は各個体の自分の群の平均からのずれ、第 2 項は群の平均の全体の平均からのずれを、群の人数で重みを付けて集めたものである。3 つとも分散ではなく平方和の行列で、n で割ればそれぞれ全体・群内・群間の共分散行列になる。ここで群の平均が全体の平均からのずれになるのは、$\mathbf{X}$ の各列の平均を 0 にしてあるからである。第 5 回で 2 群について見た $\mathbf{S}_\mathrm{T} = \mathbf{S}_\mathrm{W} + \mathbf{S}_\mathrm{B}$ が、群を与えなくても、どんな $\mathbf{G}$ についても成り立つ。(24) 式を導く。導出には、次の 1 つの道具を使う。

定義 6 (転置とトレース)**.** 行列の積の転置について $(\mathbf{AB})^\top = \mathbf{B}^\top\mathbf{A}^\top$ が成り立つ。同じ大きさの正方行列について $\mathrm{tr}(\mathbf{A} + \mathbf{B}) = \mathrm{tr}(\mathbf{A}) + \mathrm{tr}(\mathbf{B})$ が成り立つ。

転置すると積の順が入れ替わり、トレースは対角の和なので足し算に分けられる。

まず、$\mathbf{X}$ を、各行を自分の群の平均に置き換えた $\mathbf{G}\hat{\mathbf{C}}$ と、その残り $\mathbf{E} = \mathbf{X} - \mathbf{G}\hat{\mathbf{C}}$ に分ける。$\hat{\mathbf{C}}$ は正規方程式 (21) 式を満たすので

$$\mathbf{G}^\top\mathbf{E} = \mathbf{G}^\top\mathbf{X} - \mathbf{G}^\top\mathbf{G}\hat{\mathbf{C}} = \mathbf{O} \tag{25}$$

である。$\mathbf{G}^\top\mathbf{E}$ の第 q 行は群 q に入った個体の残差の和なので、(25) 式は、どの群でも平均からのずれの和が 0 であることを言っている。$\mathbf{X} = \mathbf{G}\hat{\mathbf{C}} + \mathbf{E}$ を代入し、定義 6 の転置を使って展開すると

$$\mathbf{X}^\top\mathbf{X} = \hat{\mathbf{C}}^\top\mathbf{G}^\top\mathbf{G}\hat{\mathbf{C}} + \hat{\mathbf{C}}^\top\mathbf{G}^\top\mathbf{E} + \mathbf{E}^\top\mathbf{G}\hat{\mathbf{C}} + \mathbf{E}^\top\mathbf{E}$$

となる。(25) 式により、第 2 項は $\hat{\mathbf{C}}^\top\mathbf{O} = \mathbf{O}$、第 3 項は $(\mathbf{G}^\top\mathbf{E})^\top\hat{\mathbf{C}} = \mathbf{O}$ である。よって (24) 式を得る。これは第 1 回の回帰で、当てはめた値と残差が直交し、二乗和が 2 つに分かれたのと同じ三平方の定理である。$\mathbf{G}$ を固定すれば、k-means は 0/1 の列を説明変数にした回帰だからである。

両辺のトレースをとると

$$\|\mathbf{X}\|_F^2 = J + \sum_{q=1}^{k} n_q \|\hat{\boldsymbol{c}}_q\|_2^2 \tag{26}$$

となる。左辺は全体の平方和で、群の分け方によらない。右辺第 1 項が群内の平方和 J、第 2 項が群間の平方和で、この 2 つは分け方によって変わる。変わるのは全体を群内と群間にどう配分するかであり、全体の量は変わらない。したがって、J を最小にする $\mathbf{G}$ は、群間の平方和を最大にする $\mathbf{G}$ でもある。k-means は、群の平均を全体の平均からできるだけ離す分け方を探している。図 11 は、アイスの人工データで、群の数 k ごとの最小の J と群間の平方和を積んだものである。どの k でも高さの合計は同じで、J が下がった分だけ群間が増える。

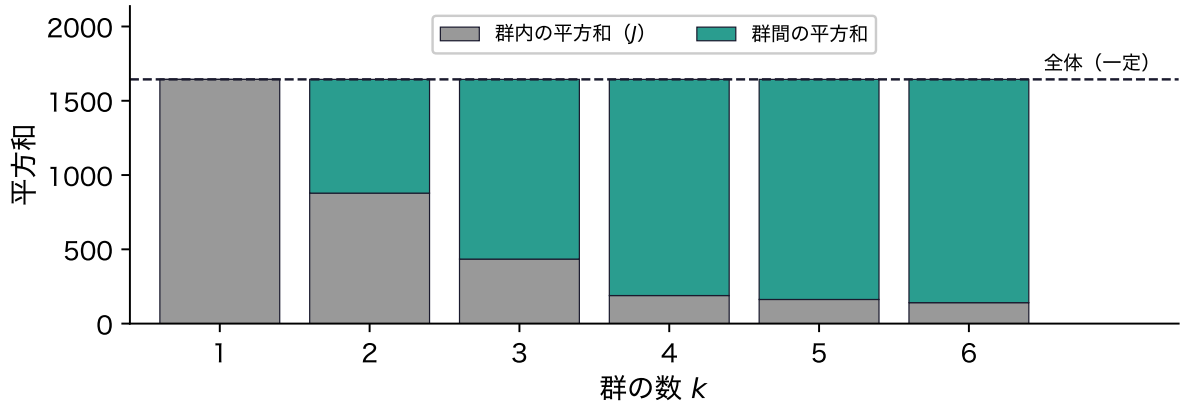


図 11: アイス 120 個の人工データの全体の平方和を、群内 (J) と群間に分けたもの。k ごとに初期値 50 通りで J が最小の答え。破線が全体

全体のうち群間が占める割合を、群で説明できた割合と呼ぶ (定義 7)。第 1 回の決定係数が、y のばらつきのうち回帰で説明できた割合だったのと同じ形である。アイスの $k = 4$ では 0.89 であった。ただし k を増やせば J は下がり続けるので、この割合は k とともに 1 に近づく。

定義 7 (群で説明できた割合)**.** 群の平均に置いた代表点 $\hat{\mathbf{C}}$ について、$\sum_q n_q \|\hat{\boldsymbol{c}}_q\|_2^2 / \|\mathbf{X}\|_F^2 = 1 - J/\|\mathbf{X}\|_F^2$ を、群で説明できた割合と呼ぶ。$\mathbf{X}$ は各列の平均を 0 にしたものとする。

群の数 k を増やすと、最小の J は下がり続ける。k 群の答えの 1 つの群を 2 つに分ければ、J は下がるか変わらないからである。$k = n$ なら全員が自分だけの代表点になり、$J = 0$ になる。図 12 は、アイスの人工データを $k = 1$ から 6 まで、初期値 50 通りのランダムスタートで分けたときの最小の J である。4 つの塊を置いて作ったデータでも、$k = 4$ を過ぎて J は下がり続ける。J を小さくすることだけでは、群の数は決められない。

群の数を増やすと最小の J が下がる理由も、ここで示せる。k 群で J が最小の答えから、1 つの群を 2 つに分け、2 つの代表点をどちらも元の平均に置く。各個体の代表点は変わらないので、J も変わらない。そこから $\mathbf{C}$ を更新して各群の平均に置くと、$\mathbf{C}$ の更新の節で示したとおり J は下がるか変わらない。したがって $k+1$ 群の最小の J は、k 群の最小の J を超えない。(26) 式の左辺は一定なので、群で説明できた割合は k とともに上がる。

また、答えは列の目盛りで変わる。(4) 式の和の順を入れ替えると

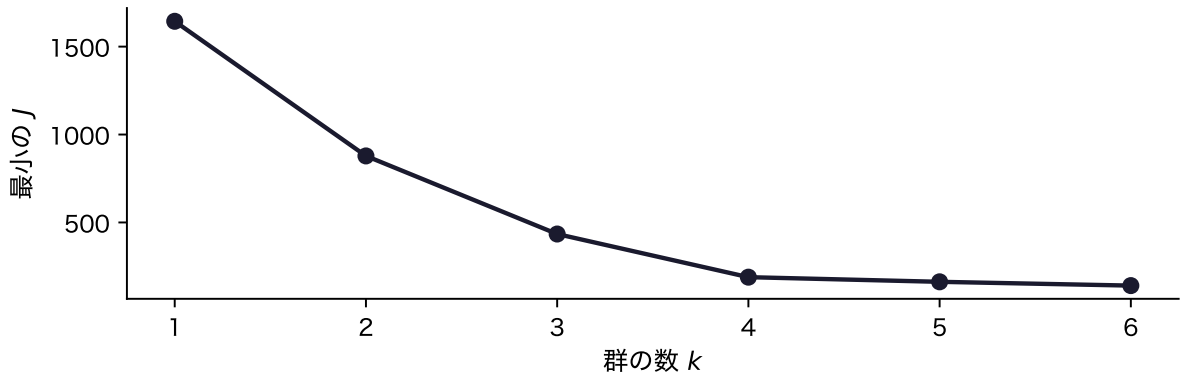


図 12: アイス 120 個の人工データを $k = 1$〜6 に分けたときの最小の J（初期値 50 通りのランダムスタート）

$$J = \sum_{j=1}^{p} \sum_{i=1}^{n} \left(x_{ij} - c_{q(i)j}\right)^2 \tag{27}$$

であり、J は列ごとの誤差の二乗和を足したものである。どの列も同じ重みで足されるので、列 j を a 倍すると、その列の誤差は a^2 倍に数えられる。図 13 (b) は、図 3 と同じアイスの固さだけを 5 倍(50 点満点)にして分け、元の目盛りの上に描いたものである。(a) とは違い、固さの向きに切る答えになった。元の目盛りで測った J は 778.5 で、(a) の 188.9 より大きい。手順 1 で列の目盛りをそろえるのはこのためで、第 2 回の標準化はその 1 つの方法である。

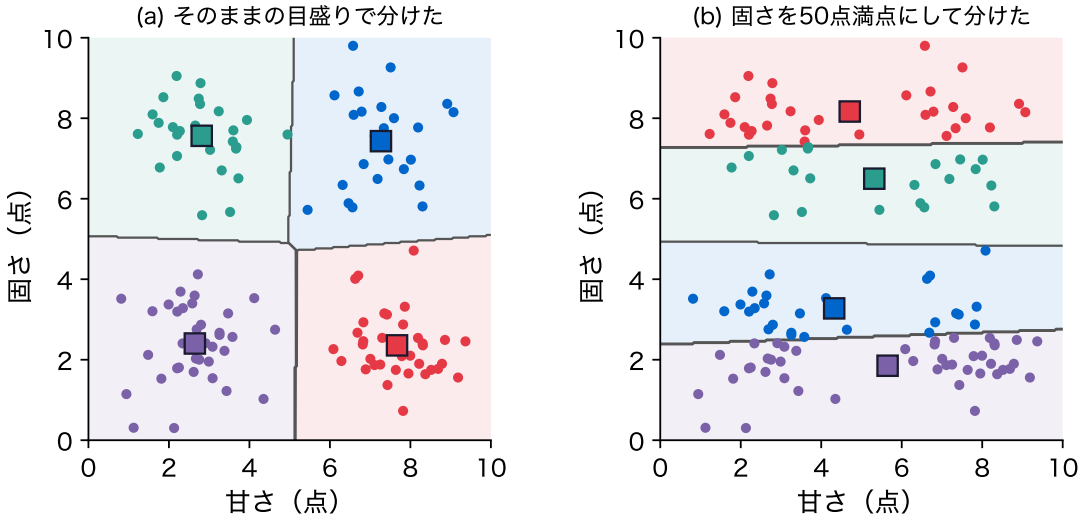


図 13: 同じアイス 120 個の人工データを $k = 4$ に分けた 2 つの答え。(a) そのままの目盛りで分けたもの、(b) 固さを 50 点満点にして分け、元の目盛りの上に描いたもの。灰色の線が境目

この分解は、第 5 回の LDA と k-means の関係も示している。LDA では群が与えられ、映す向き $\boldsymbol{w}$ を、群間と

群内の比が最大になるように探した。k-means では向きは探さず、群そのものを、群内の平方和が最小（群間の平方和が最大）になるように探す。同じ「全体＝群内＋群間」を、逆の側から使っている。

どこに止まるか

回せば止まることは分かった。だが、止まった先が最良とは限らない。止まった点は、$\mathbf{C}$ を固定しても $\mathbf{G}$ を固定しても、それ以上 J を下げられない点にすぎない。図 9 (b) は、同じデータで、$\mathbf{X}$ の行から 4 行を選んだ別の初期値から始めた答えである。その $J = 188.9$ は、(a) の 410.4 より小さい。(a) の答えは、そこから 2 つの更新のどちらを行っても動かないが、目的関数を最小にしてはいない。このような点を局所解と呼ぶ（定義 9）。k-means では、得られた解が真の解であるという保証は無い。これは目的関数の非凸性と関係している（Jain & Kar, 2017）。2 つの答えを比べるときは、群の番号の付け替えを除いて、所属が違う個体を数える。番号を入れ替えても J は変わらないからである。(a) と (b) では、番号をそろえても 39 個の所属が違う。

そこで実際には、複数の初期値から解を求め、その中で目的関数が最も小さいものを採用する。これをランダムスタートと呼ぶ（定義 10）。図 14 は、$\mathbf{X}$ の行から 4 行を選ぶ初期値を 300 通り試し、着いた J を並べたものである。着いた先の J は 27 通りに分かれ、最小の 188.9 に着いたのは 244 回であった。

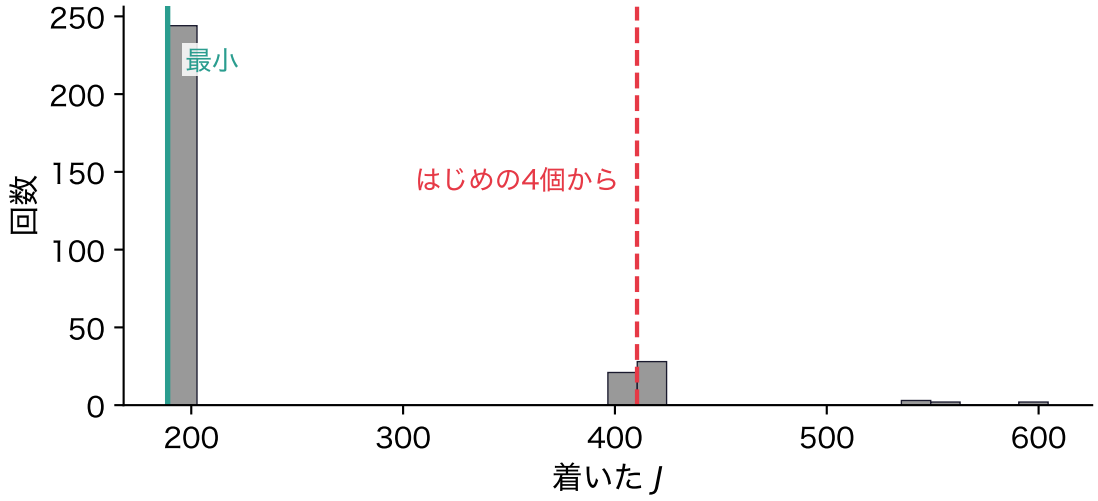


図 14: アイス 120 個の人工データ、$k = 4$。初期値を変えて着いた J の分布。緑の線が最小、赤の破線がはじめに置いた代表点から着いた値

何回やり直せばよいかは、次のように考える。1 回の初期値で最小に着く割合を θ とし、初期値を独立に R 回選ぶ。R 回とも最小に着かない見込みは $(1-\theta)^R$ なので、少なくとも 1 回は着く見込みは

$$1 - (1-\theta)^R \tag{28}$$

である。この例では $\theta = 0.81$ で、$R = 3$ なら 99.3%、$R = 5$ なら 100.0% になる。どの 1 回も最小に着くとは限らないが、やり直すほど見込みは 1 に近づく。ただし、最小に着いたことを確かめる手立ては無く、試した中で最小であることしか言えない。θ もデータと k によって変わり、前もっては分からない。

初期値の選び方そのものを工夫することもできる。k-means++（定義 8）は、すでに選んだ代表点から遠い行ほど、次の代表点に選ばれやすくする（Arthur & Vassilvitskii, 2007）。代表点どうしが近すぎる初期値を避けるためである。この選び方には保証がある。k-means++ で選んだ初期値 $\mathbf{C}_0$ について、各行を最も近い代表点に入れたときの目的関数は、期待値で

$$\mathbb{E}\big[J(\mathbf{C}_0)\big] \le 8(\ln k + 2)\, J_{\min} \tag{29}$$

を満たす。$J_{\min}$ は J の最小値である。交互最小二乗法は J を下げるだけなので、そこから回して止まった答えにも同じ上限が付く。交互最小二乗法が止まる局所解について言える、数少ない保証である。ただし $k = 4$ でも右辺は最小の約 27 倍で、最悪の場合の目安にすぎない。表 1 は、アイスの人工データで初期値を 300 通りずつ選んだ結果である。回す前の J は最小の 5.08 倍から 2.76 倍に下がり、最小に着く割合は $\theta = 0.81$ から 0.89 に上がった。局所解はなくならないので、k-means++ で選んだ初期値でもやり直しは要る。

表 1: アイスの人工データ（$k = 4$）で、初期値の選び方を変えたときの回す前の J と、最小に着く割合（初期値 300 通りずつ）

初期値の選び方	回す前の $J \div$ 最小の J（平均）	最小に着く割合 θ
行から無作為に	5.08	0.81
k-means++	2.76	0.89

定義 8 (k-means++)**.** 1 つ目の代表点を $\mathbf{X}$ の行から無作為に選ぶ。2 つ目からは、各行 i について、すでに選んだ代表点のうち最も近いものまでの距離の二乗 D_i^2 を測り、行 i を確率 $D_i^2 / \sum_l D_l^2$ で選んで次の代表点とする。これを k 個そろうまで繰り返す初期値の選び方を、k-means++ と呼ぶ。

定義 9 (局所解)**.** 交互最小二乗法が止まった点のように、そこから更新しても目的関数が下がらないが、目的関数を最小にするとは限らない点を局所解と呼ぶ。

定義 10 (ランダムスタート)**.** 複数の初期値から交互最小二乗法を行い、得られた答えのうち目的関数が最も小さいものを採用することを、ランダムスタートと呼ぶ。

第 II 部　実データ解析

ワインと手続き

第 II 部では、第 I 部の理論をワインのデータで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部では、J が更新のたびに下がって有限回で止まること、止まる先が初期値しだいであること（局所解）、J が列ごとの誤差の和であることを見た。そこから 3 つの予想が立つ。1 つ目に、ワインでも、初期値を変えると

着く先が変わるはずである。2 つ目に、ワインの成分に群ごとの違いがあれば、分けた 3 群は品種と重なるはずである。3 つ目に、標準化しないと、目盛りの大きい列が群を決めるはずである。

データは UCI Machine Learning Repository の Wine（Aeberhard & Forina, 1991。CC BY 4.0）で、scikit-learn の load_wine で取得した。イタリアの同じ地方で、3 つの品種のブドウから作ったワイン 178 本について、アルコール・リンゴ酸・灰分・灰分のアルカリ度・マグネシウム・全フェノール・フラバノイド・非フラバノイドフェノール・プロアントシアニン・色の濃さ・色相・吸光度の比・プロリンの 13 種類の化学成分を測っている。品種（59・71・48 本）も記録されている。だが品種は $\mathbf{G}$ と $\mathbf{C}$ を求めるのには使わず、答え合わせにだけ使う。

列の目盛りは大きく違う。表 2 のとおり、プロリンの標準偏差は 314 で、非フラバノイドフェノールの 0.12 の 2,530 倍である。(27) 式のとおり、k-means の目的関数は列ごとの誤差の二乗和を足す。平均を引いただけでは、$\|\mathbf{X}\|_F^2$ の 99.8% をプロリンの 1 列が占める（図 15）。そこで、13 列を列ごとに標準化したものをデータ行列 $\mathbf{X}$ とした。標準化すると、どの列も $\|\mathbf{X}\|_F^2$ の同じ割合を占める。この判断が妥当だったかは、落とし穴の節で、しなかった場合と比べて確かめる。

表 2: ワイン 178 本の 13 列のうち、標準偏差の大きい 3 列と小さい 2 列

列	プロリン	マグネシウム	灰分のアルカリ度	色相	非フラバノイドフェノール
標準偏差	314.02	14.24	3.33	0.23	0.12

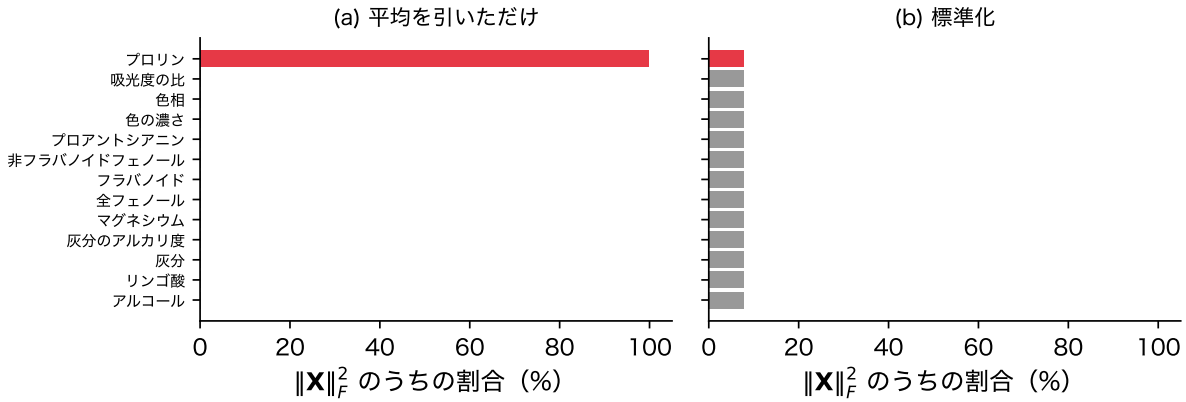


図 15: ワイン 178 本の各列が $\|\mathbf{X}\|_F^2$ に占める割合。(a) 平均を引いただけ、(b) 列ごとに標準化

手続きは次のとおりである。I-6 の手順を NumPy の行列計算でそのまま書いた。$k = 3$ について、$\mathbf{X}$ の行から 3 行を無作為に選ぶ初期値を 100 通り試した。J が最小の答えを品種と突き合わせた。最後に、標準化しない $\mathbf{X}$ でも手順を回した。

先に、手順そのものを確かめておく。3 通りの初期値から回すと、J は $\mathbf{G}$ と $\mathbf{C}$ のどちらの更新でも一度も上がらず、7〜9 回の反復で止まった。同じ初期値を scikit-learn の KMeans（Lloyd の方法）に渡すと、J の差は

最大 0、所属が違う行は 0 本だった。止まった答えでは、代表点は群ごとの平均に一致し（差は最大 0）、最も近い代表点の群に入っていない行は 0 本である。2 つの更新式を両方とも満たす点で止まっている。

k=3：着く先

1 つ目の予想から確かめる。$k = 3$ で初期値を 100 通り変えて回すと、着いた J は 9 通りに分かれた（図 16）。着く先が初期値しだいであることは、予想どおりである。

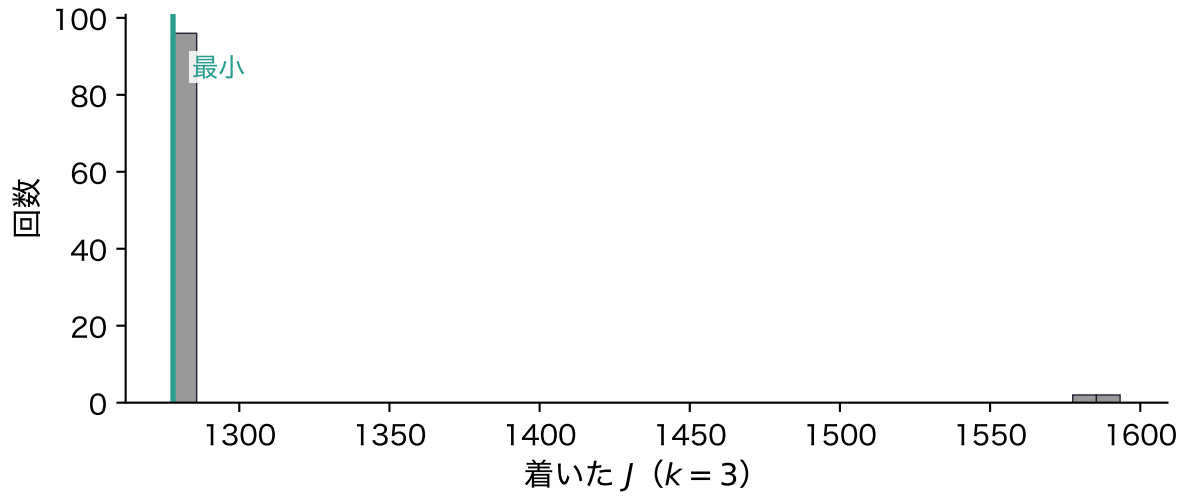


図 16: ワインを $k = 3$ に分けたとき、初期値 100 通りから着いた J の分布。緑の線が最小

ただし、着いた先は 2 か所に集まった。96% の初期値は、最小から 1% 以内の 5 つの谷に着いた。これらの谷は、最小の答えと最大 7 本の所属が違うだけで、ほぼ同じ答えである。残りの 4 回は、J が最小より 24% 以上大きい谷に止まった。図 17 は、最小の答え (a) と最も悪い答え (b) を、フラバノイドと色の濃さの 2 列の上に描いたものである（描いたのは 13 列のうち 2 列）。(b) では 78 本の所属が (a) と違い、群の大きさは 110・25・43 本で、右と下の塊が 1 つにまとめられ、左の塊が 2 つに割られている。(a) と (b) はどちらも、2 つの更新をしても動かない点である。手順が止まったというだけでは、どちらが良い答えかは分からない。J を比べて初めて (a) を選べる。定義 7 の群で説明できた割合で言えば、(a) は 0.45、(b) は 0.31 で、(a) のほうが群の平均どうしを遠くに離している。

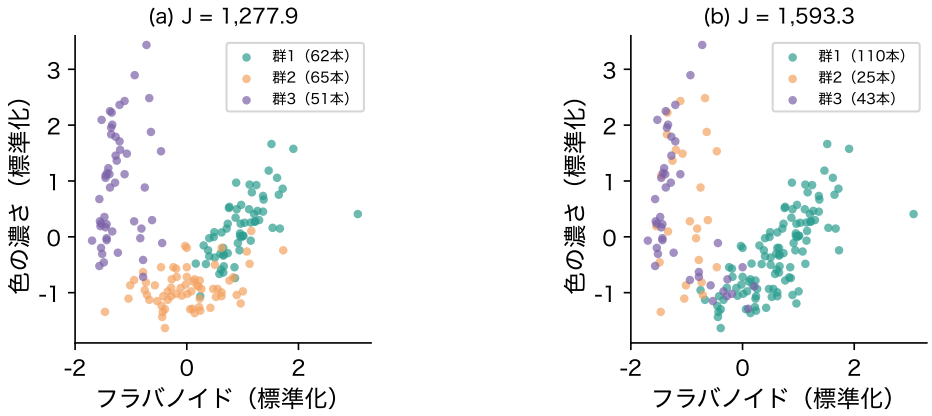


図 17: ワインを $k = 3$ に分けた 2 つの答え。(a) 100 通りのうち J が最小、(b) J が最大。描いたのはフラバノイドと色の濃さの 2 列（標準化）

何回やり直せばよいか。最小そのものに着いた割合は $\theta = 0.35$、最小から 1% 以内に着いた割合は 0.96 である。第 I 部の (28) 式に入れると、表 4 のとおり、$R = 10$ で最小に 1 回は着く見込みは 98.7% になる。1% 以内の谷なら、$R = 3$ で 99.99% であり、ほぼ確実に着く。遠い谷に止まる初期値は少なく、数回やり直せば避けられる。初期値を k-means++ で選んでも、最小に着く割合は 0.32、最小から 1% 以内は 0.96 で、無作為に選んだときとほとんど変わらなかった（表 3）。k-means++ の保証 (29) 式は回す前の J の上限であり、どの谷に止まるかまでは決めない。ワインでは無作為に選んでも大半の初期値が最小のそばに着くので、選び方を工夫しても改善の余地がほとんど無い。

表 3: ワイン（$k = 3$）で、初期値の選び方を変えたときの最小に着く割合（初期値 100 通りずつ）

初期値の選び方（100 通り）	最小に着く割合 θ	最小から 1% 以内
行から無作為に	0.35	0.96
k-means++	0.32	0.96

表 4: 初期値の数と、最小（または最小から 1% 以内）の谷に少なくとも 1 回着く見込み（ワイン、$k = 3$）

初期値の数 R	1	3	5	10
最小に 1 回は着く見込み	35.0%	72.5%	88.4%	98.7%
最小から 1% 以内に 1 回は着く見込み	96.0%	100.0%	100.0%	100.0%

品種と突き合わせる

2 つ目の予想を確かめる。表 5 は、J が最小の答えを品種と突き合わせた表である。群の番号には意味が無いので、品種と最も重なる付け方にそろえた。品種 1 と品種 3 はすべて 1 つの群に入り、外れたのは品種 2 の 6 本だけであった。品種と同じ群に入ったのは 178 本のうち 172 本(96.6%)で、全部を最も多い品種とみなしたときの 39.9% を大きく上回る。品種は $\mathbf{G}$ と $\mathbf{C}$ を求めるのに一度も使っていない。13 種類の成分だけで分けた群が、ほぼ品種と一致した。ただし、k-means は与えた k 個の群を必ず作るので、群があること自体は手順からは言えない。群が品種と重なったのは、品種ごとに成分が違うという分かれ目がデータの側にあったからである。なお、遠い谷の答え(図 17 の (b))では、品種と重なる割合は 53.9% にとどまる。J を比べて最小を採ることが、ここでも効いている。

表 5: ワインを $k = 3$ に分けた答え(J が最小)と品種の突き合わせ。数字は本数

品種＼群	群 1	群 2	群 3	計
品種 1	59	0	0	59
品種 2	3	65	3	71
品種 3	0	0	48	48

外れた 6 本は、どこにあるのか。図 18 の × がその本で、どれも群と群の境目のそばにある。各本について、最も近い代表点と 2 番目に近い代表点への距離の二乗の比を求めた。比が 1 に近いほど、2 つの代表点から等しく離れた、境目のそばの本である。外れた本の比は 0.47、0.73、0.78、0.86、0.93、0.95 で、当たった本の中央値 0.28 より大きい。第 I 部で見たとおり、$\mathbf{G}$ は 0 か 1 なので、境目のそばの本もどちらか一方の群に 100% 入る。品種 2 の成分が品種 1 や品種 3 に近い本は、近いほうの群に入れられた。

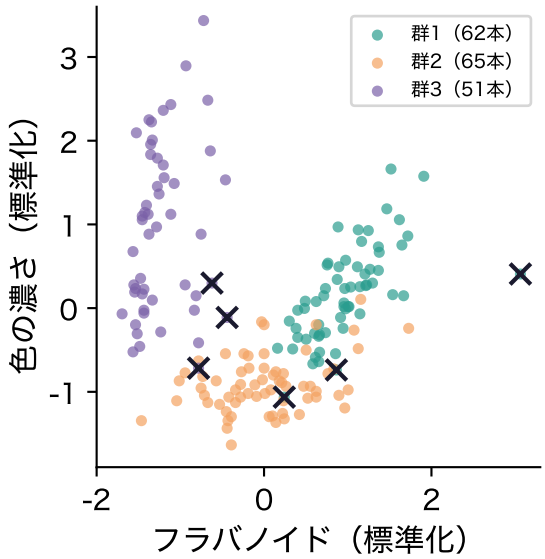


図 18: ワインを $k = 3$ に分けた答え（J が最小）。× は品種と違う群に入った本。描いたのはフラバノイドと色の濃さの 2 列（標準化）

目盛りを変える

3 つ目の予想を確かめる。第 I 部の手順 1 で、列の目盛りをそろえたデータ行列を用意した。そろえないとどうなるかを、標準化せず平均を引いただけの化学成分で確かめた。$k = 3$、初期値 50 通りで J が最小の答えを見る。

(27) 式のとおり、目的関数はすべての列の誤差を同じ重みで足す。そのため、目盛りの大きい列ほど誤差も大きく数えられる。この $\mathbf{X}$ では、$\|\mathbf{X}\|_F^2$ の 99.8% をプロリンの 1 列が占める（図 15）。止まった答えでも、J の 98.6% はプロリンの列であった。表 6 のとおり、3 つの群のプロリンの範囲は重ならない。群は、プロリンの値に 2 本の切れ目を入れただけのものになった。品種と同じ群に入ったのは 70.2% で、標準化したときの 96.6% を大きく下回る（図 19）。第 I 部の 図 13 で変数 2 を 5 倍にしたときと同じことが起きた。群で説明できた割合は 0.87 で、標準化したときの 0.45 より高い。だがこれは、全体の平方和のほとんどを占めるプロリン 1 列を、3 つに切って説明したというだけである。$\mathbf{X}$ が違えば分母の全体も違うので、この割合は同じ $\mathbf{X}$ の答えどうしでしか比べられない。

表 6: 標準化しないワインを $k = 3$ に分けた答え（初期値 50 通りで J が最小）の、群ごとのプロリンの範囲

群（プロリンの小さい順）	本数	プロリンの範囲
群 1	69	278〜590
群 2	62	600〜937
群 3	47	970〜1,680

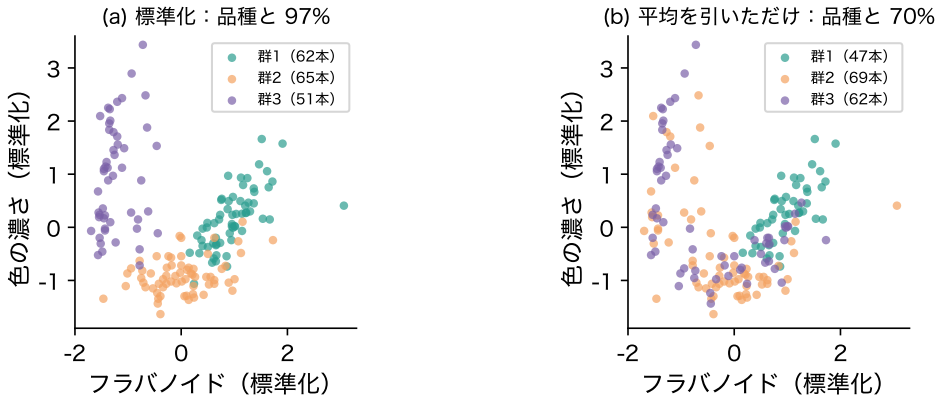


図 19: ワインを $k = 3$ に分けた答え。(a) 列ごとに標準化した $\mathbf{X}$、(b) 平均を引いただけの $\mathbf{X}$。どちらもフラバノイドと色の濃さの 2 列(標準化)で描いた

この失敗は、手順の中からは見えない。交互最小二乗法は、与えられた $\mathbf{X}$ に対して J を下げるだけで、J は毎回下がって止まる。どの列の誤差をどれだけ重く見るかは、$\mathbf{X}$ を用意する側が決めている。

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは、ワインでも初期値によって着く先が変わり、成分に群の違いがあれば群は品種と重なり、標準化しないと目盛りの大きい列が群を決めると予想した。3 つとも予想どおりだった。初期値 100 通りは 9 通りの答えに分かれたが、96% は最小から 1% 以内に着き、遠い谷は数回のやり直しで避けられた。J が最小の答えは、品種を一度も使わずに 96.6% のワインを品種と同じ群に入れた。外れた数本は、2 つの代表点からほぼ等しく離れた境目のそばにあり、0 か 1 で切る $\mathbf{G}$ が無理にどちらかへ入れた本である。また、J が下がって止まることは手順が保証するが、どの列をどれだけ重く見るかは保証しない。標準化しないと、プロリン 1 列の値で群が切られ、品種とは重ならなかった。

締め

まとめと次回の問い

本章の問いは、行を群に分けるとき、0/1 の所属行列 $\mathbf{G}$ と代表点の行列 $\mathbf{C}$ をどう求めるか、であった。k-means は、メンバーシップ関数 g_{iq} を並べた $\mathbf{G}$ と $\mathbf{C}$ の積でデータ行列を近似し、$\|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2$ を最小にする最小二乗法である。$\mathbf{G}$ は 0/1 に限られるので微分できず、一度には解けない。しかし片方を固定すれば解ける。$\mathbf{C}$ を固定すれば、場合分けにより、各個体を最も近い代表点のクラスターに入れるのが最良になる。$\mathbf{G}$ を固定すれば、第 1 回の正規方程式と同じ形から $\hat{\mathbf{C}} = (\mathbf{G}^\top\mathbf{G})^{-1}\mathbf{G}^\top\mathbf{X}$、すなわちクラスターごとの平均が得られる。この 2 つを交互に繰り返すと、目的関数は毎回下がり、有限回で止まる。ただし、止まる先は初期値しだいの局所解である。回帰と違って 1 回で解く方法も無いので、初期値を変えてやり直し、目的関数が最も小さい答えを採る。また、目的関数は列ごとの誤差の和なので、答えは列の目盛りで変わる。ワイン 178 本の 13 種類の化学成分を標

準化したデータでは、自分で書いた手順が、同じ初期値のライブラリと同じ J・同じ所属に着いた。$k = 3$ では初期値 100 通りが 9 通りの答えに分かれたが、96% は最小から 1% 以内に着いた。J が最小の答えは、品種を使わずに 96.6% のワインを品種と同じ群に入れた。標準化しないと、プロリン 1 列の値で群が切られた。

最後に、次回への問いを置く。k-means の $\mathbf{G}$ は 0 か 1 なので、境目のすぐそばの個体も、どちらか一方の群に 100% 入る。境目は代表点どうしの垂直二等分線であり、k-means は群の形や広がりを見ていない。前半では、第 1 回の最小二乗法の答えを、第 6 回で確率のモデルを置いた最尤法から読み直した。群に分ける問題でも同じ道をたどれるだろうか。同じ群を最尤法で推定するとどうなるかを、次回に考える。

発展

発展：データが増えると

発展として、データが増えたときの k-means の振る舞いを紹介する。ここまでの J は手元の n 行の和であった。行が同じ分布から独立に取られているとき、行を増やせば、J を最小にする代表点 $\hat{\mathbf{C}}$ は何かに近づくだろうか。

Pollard (1981) はこれに答えた。J を n で割ったものは、代表点 $\mathbf{C}$ を決めるごとに、行 $\tilde{\boldsymbol{x}}_i$ の関数 $\min_q \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2$ の平均である。そこで母集団の側に

$$\bar{J}(\mathbf{C}) = \mathbb{E}\Big[\min_q \|\boldsymbol{x} - \boldsymbol{c}_q\|_2^2\Big]$$

を置く。Pollard は、$\mathbb{E}\|\boldsymbol{x}\|_2^2$ が有限で、$\bar{J}$ を最小にする $\mathbf{C}^*$ が番号の付け替えを除いてただ 1 つなら、$\hat{\mathbf{C}}$ が確率 1 で $\mathbf{C}^*$ に近づくことを示した（強一致性）。

なぜこれが自明でないのか。$\mathbf{C}$ を 1 つ、データを見る前に固定すれば、$J(\mathbf{C})/n$ は独立な量の平均なので、大数の法則で $\bar{J}(\mathbf{C})$ に近づく。だが $\hat{\mathbf{C}}$ は、手元のデータで J が最小になるように選んだ点である。どの $\mathbf{C}$ でも 1 つずつ見ればゆらぎは平均 0 だが、たくさんの候補から最小を選ぶと、選んだ点ではゆらぎが下向きに偏る。図 20 は、2 つの正規分布 $N(-2, 1)$ と $N(2, 1)$ を半々に混ぜた 1 次元の分布から n 個を取り、$k = 2$ で J を最小にする $\hat{\mathbf{C}}$ を求めた結果である（300 回の平均）。選んだ点を手元のデータで測った $J(\hat{\mathbf{C}})/n$ は、母集団の最小 $\bar{J}(\mathbf{C}^*)$ より小さく出る。同じ点を母集団で測った $\bar{J}(\hat{\mathbf{C}})$ は、それより大きい。第 2 回で、訓練データで選んだ係数の訓練誤差がテスト誤差より小さく出たのと同じことである。n が増えると、この開きは縮む。

示したいのは $\bar{J}(\hat{\mathbf{C}}) \to \bar{J}(\mathbf{C}^*)$ である。差を 3 つに分けると

$$\bar{J}(\hat{\mathbf{C}}) - \bar{J}(\mathbf{C}^*) = \Big[\bar{J}(\hat{\mathbf{C}}) - \tfrac{1}{n}J(\hat{\mathbf{C}})\Big] + \Big[\tfrac{1}{n}J(\hat{\mathbf{C}}) - \tfrac{1}{n}J(\mathbf{C}^*)\Big] + \Big[\tfrac{1}{n}J(\mathbf{C}^*) - \bar{J}(\mathbf{C}^*)\Big] \tag{30}$$

となる。第 2 項は、$\hat{\mathbf{C}}$ が手元の J の最小なので 0 以下である。第 3 項は、データによらない点 $\mathbf{C}^*$ での値なので、大数の法則で 0 に近づく。残る第 1 項は、データで選んだ点での手元と母集団のずれであり、固定した点についての大数の法則は使えない。そこで、どの $\mathbf{C}$ についても同時にずれが小さいこと

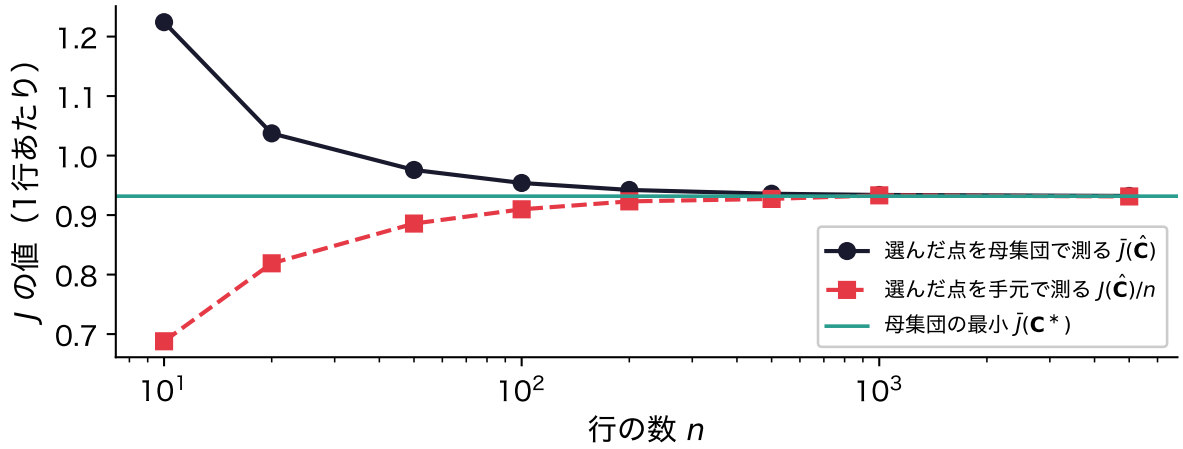


図 20: 1 次元・$k = 2$ の人工データで、J を最小にする $\hat{\mathbf{C}}$ を手元のデータで測った値と、母集団で測った値（300 回の平均）。緑の線が母集団の最小

$$\sup_{\mathbf{C}} \left| \frac{1}{n} J(\mathbf{C}) - \bar{J}(\mathbf{C}) \right| \longrightarrow 0$$

を示す（一様な大数の法則）。これが言えれば、第 1 項はこの値以下なので 0 に近づき、$\bar{J}(\hat{\mathbf{C}}) \to \bar{J}(\mathbf{C}^*)$ が出る。$\mathbf{C}^*$ がただ 1 つであることから、$\hat{\mathbf{C}}$ そのものも $\mathbf{C}^*$ に近づく。$\mathbf{C}$ を動かしたときのゆらぎ $J(\mathbf{C})/n - \bar{J}(\mathbf{C})$ を関数として丸ごと見たものを、経験過程と呼ぶ。Pollard は、代表点が十分大きな球の中にとどまることを示したうえで、その範囲で経験過程が一様に 0 に近づくことを示した。

図 21 は、1 点ずつの収束では足りない理由を模式的に描いたものである。(a) のように、どの $\mathbf{C}$ でも 1 点ずつは $\bar{J}$ に近づいていても、手元だけの大きな下向きのゆらぎがどこかに残れば、最小の位置はそこに選ばれてしまう。(b) のように関数全体が $\bar{J}$ のまわりの細い帯に入れば、選ばれる点は母集団の最小の近くにあるしかない。

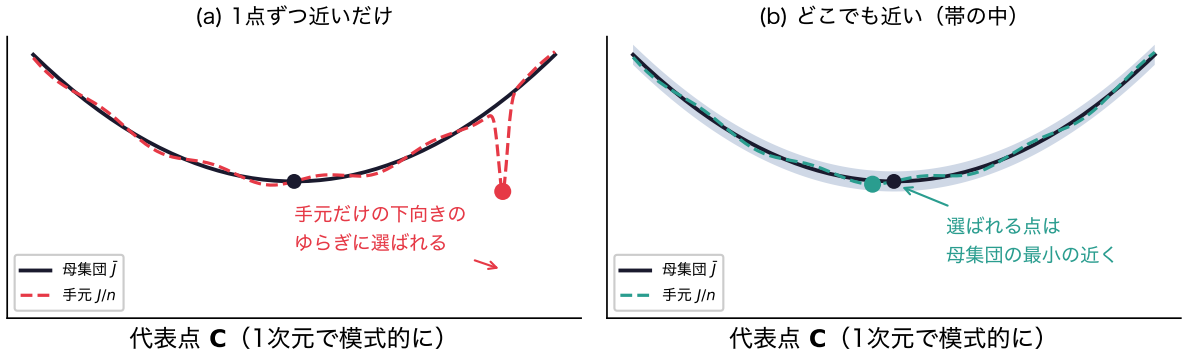


図 21: 1 点ずつの収束と一様な収束（概念図）。(a) 各点では近くても、手元だけの下向きのゆらぎが残れば最小の位置がそこに選ばれる。(b) 関数全体が帯の中なら、選ばれる点は母集団の最小の近くにある

ここで扱ったのは、手元の J/n が母集団の $\bar{J}$ からずれるという、関数のずれの問題である。これと、交互最小二乗法が最小でない場所（局所解）で止まるという、手順の問題は別である。Pollard の定理が保証するのは、J を本当に最小にする $\hat{\mathbf{C}}$ についてであり、局所解について同じことが言えるかは、Pollard 自身が分からないと書いている。データが増えても、手順が最小に着かなければ、定理の保証は届かない。ランダムスタートや k-means++ で J の最小に近づけることには、この意味でも理由がある。なお、この定理が言うのは近づくことだけで、どれだけの速さで近づくかは別の問題である。経験過程の考え方は、k-means に限らず、データを見てから目的関数を最小にする推定量（M 推定量）の一致性を示す標準の道具になっている（van der Vaart & Wellner, 1996）。次に紹介する Sun, Wang & Fang (2012) の一致性も、この考え方を列の数が増える場合に広げたものである。

参考文献

- Pollard, D. (1981). Strong consistency of k-means clustering. The Annals of Statistics, 9, 135–140.
- van der Vaart, A. W., & Wellner, J. A. (1996). Weak Convergence and Empirical Processes. Springer.

発展：列を選びながら群に分ける

発展として、列を選びながら群に分ける方法を紹介する。遺伝子やタンパク質のデータでは列が数千あっても、群を分けるのに効く列は一部だけのことが多い。(27) 式のとおり、k-means の目的関数はすべての列の誤差を同じ重みで足す。効かない列の揺れも、そのまま J に入る。

Sun, Wang & Fang (2012) は、k-means の目的関数に、代表点の行列 $\mathbf{C}$ の列ごとの罰則を足した。本講義の記号で書けば、列の平均を引いた $\mathbf{X}$ について

$$\min_{\mathbf{G},\mathbf{C}} \ \frac{1}{n}\|\mathbf{X}-\mathbf{G}\mathbf{C}\|_F^2 + \sum_{j=1}^{p} \lambda_j \|\boldsymbol{c}_{(j)}\|_2$$

である。$\boldsymbol{c}_{(j)}$ は $\mathbf{C}$ の第 j 列で、k 個の代表点の第 j 成分を並べたものである。第 4 回の Lasso は係数を 1 つずつ 0 にしたが、この罰則（group lasso）は列 j の k 個の値をまとめて 0 にする。どの群の代表点も列 j で 0、つまり平均と同じ値になれば、列 j は群分けに使われない。λ_j は列ごとに重みを変えた罰則の強さで、全体の強さと群の数は、データを作り直しても同じ群に分かれるか（安定性）で選ぶ。

著者らは、この方法を 2 つの遺伝子発現データに当てた（表 7）。白血病のデータは患者 72 人（急性骨髄性 25 人・急性リンパ性 47 人）、リンパ腫のデータは腫瘍 62 個（3 つの型、42・9・11 個）で、それぞれ数千の遺伝子の発現量を対数にして標準化してある。どちらの方法も初期値を 100 通り変えて回し、得られた群を腫瘍の型と突き合わせた。罰則付きの k-means は、白血病で 211 個、リンパ腫で 66 個の遺伝子だけを使い、型と違う群に入ったのはそれぞれ 2 人と 1 個だった。罰則の無い k-means はすべての遺伝子を使い、リンパ腫では群の数を 2 と選んで、型と違う群に 4 個を入れた。

表 7: 2 つの遺伝子発現データで選ばれた群の数と遺伝子の数、腫瘍の型と違う群に入った数。出典：Sun, Wang & Fang (2012) Electron. J. Stat. 6: 148–167, Table 5（一部を日本語にした。CC BY 4.0）

データ	方法	群の数	使った遺伝子	型と違った数
白血病(72 人)	k-means	2	3571	2/72
	罰則付き k-means	2	211	2/72
リンパ腫(62 個)	k-means	2	4026	4/62
	罰則付き k-means	3	66	1/62

図 22 は、リンパ腫の 62 個の腫瘍(行)を、選ばれた 66 個の遺伝子(列)で描いたヒートマップである。右端の文字が腫瘍の型で、色が発現量の高低を表す。遺伝子 1〜22 は FL と CLL を、23〜27 は FL を、28〜66 は DLBCL を見分ける信号を持ち、3 つの型が色の塊として分かれている。4026 個から選んだ 66 個の列だけで、群の違いが見える。

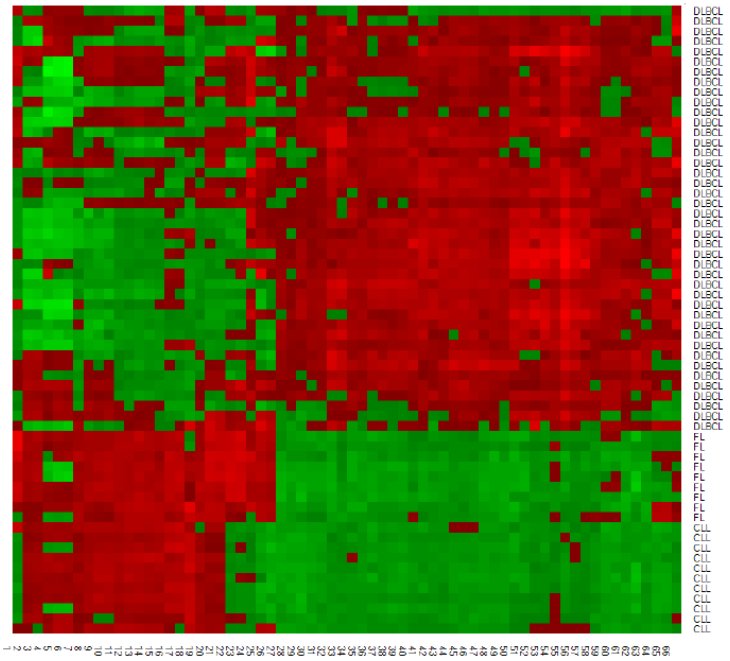


図 22: リンパ腫の 62 個の腫瘍(行)と、罰則付き k-means が選んだ 66 個の遺伝子(列)のヒートマップ。右端は腫瘍の型(DLBCL・FL・CLL)。出典：Sun, Wang & Fang (2012) Electron. J. Stat. 6: 148–167, Fig. 2（CC BY 4.0）

参考文献

- Sun, W., Wang, J., & Fang, Y. (2012). Regularized k-means clustering of high-dimensional data and its asymptotic consistency. Electronic Journal of Statistics, 6, 148–167.