

第 7 回 決定理論と評価

損失を決めると、切る場所と測る量が決まる

本章の問いは、第 6 回の締めで残った「確率が出た。どこで切り、どう測るか？」である。答えは、2 種類の誤り（見逃しと誤検出）に重さ（損失）を付けることにある。損失を決めれば、損失の平均（期待損失）を最小にするしきい値が $t^* = c_{FP} / (c_{FP} + c_{FN})$ と式で決まる。測る量も、その同じ期待損失になる。精度・F1・ROC/AUC・適合率などの指標は、損失の比や陽性の割合 π について何かを黙って仮定している。

第 I 部 理論

確率をどこで切るか

第 6 回で、0/1 の答えに確率を出せるようになった。ここまでは、その確率を 0.5 で切り、一致率を数えてきた。しかし、0.5 で切ってよいのか、一致率で比べてよいのかは確かめていない。本章の問いは、その締めで残した 1 つである。確率が出た。どこで切り、どう測るか。

身近な場面で考える。ここでは人工的なデータを使う。毎朝の湿度を記録し、その日に雨が降ったかどうかを 360 日分集めた。降った日を $y = 1$ 、降らなかった日を $y = 0$ とし、降った日は 120 日ある。第 6 回の LDA を当てると、朝の湿度から「今日、雨が降る確率」が出る。図 1 (a) はその確率の分布である。0.5 以上なら傘を持って出ると決めると、84.2% の日は当たる。しかし外れた日は 2 種類ある。降ったのに確率が 0.5 に届かず傘を持たなかった日（見逃し、36 日）と、降らなかったのに傘を持った日（誤検出、21 日）である。しきい値を 0.2 に下げると（図 1 (b)）、見逃しは 10 日に減るが、誤検出は 66 日に増え、当たった日は 78.9% に下がる。しきい値を動かすと、2 種類の誤りが入れ替わる。当たりの割合で比べれば 0.5 がよいが、濡れるのが何より嫌な人には 0.2 のほうがよい。

どこで切るかとどう測るかは、別々の問いに見える。しかし 2 つの問いの答えは同じで、2 種類の誤りに重さ（損失(loss)）を付けることである。本章はこの答えを 4 段で示す。まず、切った結果を 4 つのマスで数える道具をそろえる。次に、誤りに重さを付け、損失の平均（期待損失）を目的関数として書く。続いて、期待損失を最小にするしきい値が、損失の比だけから式で決まることを導く。最後に、測る量もその同じ期待損失になること、よく使われる精度などの指標がこの損失を黙って決めていること、損失が決まらないときにはすべてのしきい値での成績を ROC 曲線に並べることを見る。




図 1: 人工的な 360 日分の、朝の湿度から LDA で出した雨の確率の分布(青が降らなかった日、赤が降った日。縦軸の上端を超える柱には日数を添えた)。破線はしきい値で、(a) 0.5、(b) 0.2

道具：4 つのマスと率

確率をどこで切るかを考えるには、切った結果を数える道具が要る。図 2 は、場面の人工データを朝の湿度 x で並べ直したものである(降らなかった $y = 0$ が 240 日、降った $y = 1$ が 120 日)。見つけたいほうの群($y = 1$ 、雨の日)を陽性(positive)、もう一方を陰性(negative)と呼ぶ。良い悪いの意味ではなく、拾いたい側という役割の名前である。LDA の事後確率 θ_i をしきい値(threshold) t で切り、

$$\hat{y}_i = \begin{cases} 1 & (\theta_i \geq t) \\ 0 & (\theta_i < t) \end{cases} \quad (1)$$

と判定する。事後確率は x について単調に増える。そのため $\theta_i \geq t$ は、 x_i がある値以上であることと同じになる。 $t = 0.5$ は湿度 65.7% の縦線にあたる。

本当の群と判定の組み合わせは 4 通りある。

定義 1 (混同行列)。本当の群(行)と判定(列)の組み合わせごとに個数を数えた 2 行 2 列の表を混同行列(confusion matrix)と呼ぶ。陰性を陰性と判定した個数を TN (真陰性)、陰性を陽性と判定した個数を FP (偽陽性、誤検出)、陽性を陰性と判定した個数を FN (偽陰性、見逃し)、陽性を陽性と判定した個数を TP (真陽性)と書く。T・F は判定が当たったかどうか、P・N は判定が陽性か陰性かを表す。

図 2 では $TN = 219$ 、 $FP = 21$ 、 $FN = 36$ 、 $TP = 84$ である。4 つのマスから作る率は、どれも割り算で、分母




図 2: 人工的な 360 日を朝の湿度で並べ(降らなかった日が青、降った日が赤)、LDA の事後確率 0.5 (破線) で切ったときの 4 つのマスの日数

が違う。

定義 2 (真陽性率・偽陽性率・適合率). 本物の陽性のうち陽性と判定できた割合 $TPR = TP/(TP + FN)$ を真陽性率(true positive rate)または再現率(recall)と呼び、 $1 - TPR$ を見逃し率と呼ぶ。本物の陰性のうち誤って陽性と判定した割合 $FPR = FP/(FP + TN)$ を偽陽性率(false positive rate)と呼ぶ。陽性と判定したもののうち本物の陽性の割合 $TP/(TP + FP)$ を適合率(precision)と呼ぶ。

人工データでは $TPR = 0.700$ 、 $FPR = 0.087$ 、適合率 $= 0.800$ である。真陽性率は混同行列の陽性の行だけ、偽陽性率は陰性の行だけで計算する。適合率だけは判定の列で割るので、分母に陽性と陰性の両方の群が混ざる。後で陽性の割合を変えたとき、率がどう動くかはこの違いで分かれる。

損失を決める

2 種類の誤りは、重さが違うことが多い。身近な例では、傘を持って出るとどうかがある。雨が降る日を陽性とする。傘を持って出て降らなかった(誤検出)ときの損は、荷物になることである。持たずに出て降られた(見逃し)ときの損は、濡れることである。たとえば荷物になる損を 1、濡れる損をその 5 倍の 5 とおく。どちらがどれだけ困るかは人によって違い、天気の数値からは決まらない。

定義 3 (損失行列と期待損失). 本当の群と判定の組ごとに、その誤りの重さを並べた表を損失行列(loss matrix)と呼ぶ。当たりの損失は 0 とし、誤検出 1 件の損失を c_{FP} 、見逃し 1 件の損失を c_{FN} と書く。損失の 1 行あたりの平均を期待損失(expected loss)と呼ぶ。

行 i の損失は、見逃しなら c_{FN} 、誤検出なら c_{FP} 、当たりなら 0 である。式では $\ell_i(t) = c_{FN} y_i(1 - \hat{y}_i) + c_{FP} (1 - y_i) \hat{y}_i$ と書ける。 y_i と $\hat{y}_i$ は 0 か 1 なので、 $y_i(1 - \hat{y}_i)$ は見逃しの行でだけ 1 になり、 $(1 - y_i) \hat{y}_i$ は誤検出の行でだけ 1 になる。判定 $\hat{y}_i$ は (1) 式によりしきい値 t で決まるので、期待損失は t の関数

$$R(t) = \frac{1}{n} \sum_{i=1}^n [c_{FN} y_i(1 - \hat{y}_i) + c_{FP} (1 - y_i) \hat{y}_i] \quad (2)$$

である。これが決定の目的関数であり、 $R(t)$ を最小にする t を選ぶ。

ベクトルで書けば、見逃しの個数は $\mathbf{y}^\top(\mathbf{1} - \hat{\mathbf{y}})$ 、誤検出の個数は $(\mathbf{1} - \mathbf{y})^\top \hat{\mathbf{y}}$ である。さらに、0/1 の $\mathbf{y}$ を 2 列に広げた $n \times 2$ の行列 $\mathbf{Y} = [\mathbf{1} - \mathbf{y}, \mathbf{y}]$ を作り、判定も同じく $\hat{\mathbf{Y}} = [\mathbf{1} - \hat{\mathbf{y}}, \hat{\mathbf{y}}]$ に広げる。すると $\mathbf{M} = \mathbf{Y}^\top \hat{\mathbf{Y}}$ の (q, l) 成分は、本当の群が q で判定が l の個数になる。すなわち $\mathbf{M}$ は混同行列そのものである。損失行列は、1 行目が $(0, c_{FP})$ 、2 行目が $(c_{FN}, 0)$ の 2×2 の行列 $\mathbf{C}$ で表す。このとき

$$R(t) = \frac{1}{n} \sum_{q,l} C_{ql} M_{ql} = \frac{1}{n} \text{tr}(\mathbf{C}^\top \mathbf{M}) \quad (3)$$

となる。 $n = 1$ なら $\mathbf{M}$ は 1 か所だけが 1 の行列になり、(3) 式は 1 行の損失 $\ell_i(t)$ に戻る。

(3) 式を群の中の率で書き直しておく。見逃しの個数は、陽性の個数 n_1 に見逃し率を掛けた $n_1(1 - \text{TPR})$ である。誤検出の個数は、陰性の個数 n_0 に偽陽性率を掛けた $n_0 \text{FPR}$ になる。陽性の割合を $\pi = n_1/n$ とおくと

$$R(t) = c_{FN} \pi(1 - \text{TPR}(t)) + c_{FP} (1 - \pi) \text{FPR}(t) \quad (4)$$

となる。期待損失は、群の割合と群の中の率の積の和である。陽性の割合 π は、ここで初めて表に出てくる。

最適なしきい値

期待損失 (2) 式を最小にするしきい値は、どこにあるか。まず描いてみる。図 3 では、雨の日の人工データで正規分布のモデル(群の平均、共通の分散、群の割合)を推定し、そのモデルから (4) 式の見逃し率と偽陽性率を計算して $R(t)$ を描いた。360 日を数えると曲線がでこぼこになるので、モデルそのもので計算した。損失の比が 1:1 なら谷底は 0.50 にあり、見逃しを 5 倍重くすると 0.17 へ左に動く。




図 3: 雨の日の人工データで推定した正規分布のモデルで計算した期待損失 $R(t)$ 。点は谷底、点線は (5) 式の t^* (損失の比 1:1 で 0.5、1:5 で 1/6)

谷底の位置は、1 件ずつ考えれば求まる。陽性である確率が θ の行を陽性と判定すると、外れる(本当は陰性である)確率は $1 - \theta$ になる。そのときの損失の見込みは $c_{FP}(1 - \theta)$ である。陰性と判定すると外れる確率は θ で、見込みは $c_{FN}\theta$ となる。見込みの小さいほうを選べばよいので、 $c_{FN}\theta > c_{FP}(1 - \theta)$ のときに陽性と判定する。これを θ について解くと

$$\theta > \frac{c_{FP}}{c_{FP} + c_{FN}} = t^* \quad (5)$$

を得る。傘の例で濡れる損失を 5、荷物になる損失を 1 とすれば、 $t^* = 1/6$ になる。雨の確率がおよそ 17% を超えたら、傘を持って出るのがよい。(5) 式には、データもモデルも現れない。現れるのは 2 つの損失の比だけである。どの行でも見込みの小さいほうを選んでいるので、その平均である期待損失も最小になる。図 3 の谷底は、(5) 式の 0.5 と 1/6 に一致している。ただし、 θ がその行の本当の陽性の確率であることが前提になる。この前提は、本章の終わりの帰結で扱う。

しきい値を対数オッズで見ると、第 6 回とのつながりがはっきりする。 $\theta = \text{sig}(a)$ なので $\theta \geq t^*$ は $a \geq \log\{t^*/(1 - t^*)\} = \log(c_{FP}/c_{FN})$ と同じである。第 6 回の LDA の対数オッズ $a(x) = w\{x - (\mu_0 + \mu_1)/2\} + \log(\pi_1/\pi_0)$ を代入すると

$$w\left(x - \frac{\mu_0 + \mu_1}{2}\right) \geq \log \frac{\pi_0}{\pi_1} + \log \frac{c_{FP}}{c_{FN}} \quad (6)$$

となる。第 6 回では、群の人数の比の対数 $\log(\pi_0/\pi_1)$ が境界を中点からずらした。損失の比の対数 $\log(c_{FP}/c_{FN})$ は、それとまったく同じ形で境界をずらす。見逃しが重い($c_{FN} > c_{FP}$)なら右辺は小さくなり、境界は陰性の群の側へ動く。




図 4: 損失の比 c_{FN}/c_{FP} と最適なしきい値 $t^* = 1/(1 + c_{FN}/c_{FP})$

図 4 は (5) 式を損失の比の関数として描いたものである。 $c_{FP} = c_{FN}$ のときに限り $t^* = 1/2$ になる。0.5 で切るのは中立な既定値ではなく、2 種類の誤りが同じ重さだと宣言することである。場面で 0.5 で切ったときも、第 6 回までに一致率で比べたときも、この宣言を黙って置いていた。見逃しが重いほど t^* は下がり、迷ったら陽性と判定するようになる。

同じ損失で測る

しきい値を損失で選んだら、測る量も同じ損失にするのが筋である。損失行列 $\mathbf{C}$ を決めてしきい値 t^* を選んだら、第 2 回のとおりテストの行で混同行列 $\mathbf{M}_{\text{test}}$ を数える。テストの行は、当てはめにもしきい値の選択にも使っていない行である。その $\mathbf{M}_{\text{test}}$ から、(3) 式で $R(t^*)$ を計算する。どう切るかとどう測るかには、同じ目的関数で答えられる。

よく使われる指標は、この期待損失の特別な場合として読める。精度 (accuracy) は判定が当たった割合 $(TP + TN)/n$ で、第 6 回の一致率と同じものである。 $1 - \text{精度} = (FN + FP)/n$ なので、 $1 - \text{精度}$ は $c_{FP} = c_{FN} = 1$ とおいた期待損失 (2) 式そのものになる。精度でモデルを比べると、2 種類の誤りを同じ重さと決めたことになる。これは 0.5 で切るのと同じ仮定である。この仮定は、陽性が少ないときに目立つ。すべての行を陰性と判定すると、 $FP = 0$ 、 $FN = n\pi$ なので精度は $1 - \pi$ になる。陽性が 5% なら、何も見分けなくても精度は 0.95 である。精度という指標に欠陥があるわけではない。見逃しの重さを誤検出と同じとみなしているので、少ない陽性を全部見逃しても損が小さく出るのである。

適合率と再現率を 1 つにまとめる F1 値 (F1 score) $2 \cdot \text{適合率} \cdot \text{再現率} / (\text{適合率} + \text{再現率})$ は、2 つの調和平均である。適合率と再現率を入れ替えても値が変わらないので、見逃しと誤検出のどちらが重いかを表せない。F1 値は損失の比を使わない。

損失が決まらないとき：ROC 曲線

損失の比は使う人が決めるもので、決まる前にモデルの良し悪しだけを見たいこともある。そのときには、ある 1 つのしきい値での成績ではなく、すべてのしきい値での成績を並べて見る。1 つのしきい値で切ると、偽陽性率と真陽性率の組 (FPR, TPR) が 1 つ決まり、平面の上の 1 点になる。

定義 4 (ROC 曲線と AUC). しきい値 t を 1 から 0 まで動かしたときの点 $(FPR(t), TPR(t))$ の軌跡を ROC 曲線 (ROC curve) と呼び、その下の面積を AUC (area under the curve) と呼ぶ。

図 5 (a) は、雨の日の人工データで推定した正規分布のモデルの ROC 曲線である。しきい値が 1 なら、どの行も陽性と判定しないので、曲線の端は原点にある。しきい値が 0 なら、すべてを陽性と判定するので右上の点にある。しきい値を下げるほど、曲線の上の点は右上へ進む。曲線が左上の角に近いほど、少ない誤検出で多くの陽性を拾える。対角線は、確率を使わずに無作為に判定したときにあたる。




図 5: 雨の日の人工データで推定した正規分布のモデルの ROC 曲線。(a) 全体。色を塗った部分の面積が AUC、黒の点は $t = 0.5$ 。(b) (a) の点線の枠(左上の角)を拡大したもの。橙の点は損失の比 1:5 の $t^* = 1/6$ 、橙の破線は期待損失が $R(t^*)$ に等しい点の直線 (7) 式

損失を決めることは、この曲線の上の 1 点を選ぶことにあたる。(4) 式で R を一定とおいて TPR について解くと

$$\text{TPR} = 1 - \frac{R}{c_{\text{FN}} \pi} + \frac{c_{\text{FP}}(1 - \pi)}{c_{\text{FN}} \pi} \text{FPR} \quad (7)$$

となり、期待損失が等しい点は ROC の平面で傾き $c_{\text{FP}}(1 - \pi)/(c_{\text{FN}} \pi)$ の直線に並ぶ。直線が左上にあるほど R は小さい。曲線の上で R が最小になるのは、この傾きの直線が曲線に接する点である。図 5 (b) の橙の破線 (損失の比 1:5、 $\pi = 0.33$ で傾き 0.4) は、 $t^* = 1/6$ の点で曲線に接している。見逃しが重いほど傾きは緩くなり、接点は右上へ、すなわち低いしきい値へ動く。

AUC は、しきい値を 1 つに決めずに曲線全体をまとめた量である。陽性の行 i と陰性の行 i' を 1 つずつ無作為に選んだとき、陽性のほうの確率が高い割合

$$\text{AUC} = \Pr(\theta_i > \theta_{i'} \mid y_i = 1, y_{i'} = 0) \quad (8)$$

に等しい。人工データのモデルでは 0.906 である。(8) 式に入るのは確率の順位だけである。確率の値が正しいかどうか、実際に使うしきい値でどれだけ損をするかも、AUC には表れない。

ROC 曲線の 2 つの軸は、どちらも群の中の率である。陽性の割合 π が変わっても、陽性の群の中で拾える割合や、陰性の群の中で誤る割合は変わらない。そのため ROC 曲線と AUC は π に左右されない。一方、適合率は判定の列で割るので

$$\text{適合率} = \frac{\pi \text{TPR}}{\pi \text{TPR} + (1 - \pi) \text{FPR}} \quad (9)$$

となり、 π を含む。図 6 は、同じモデルで π だけを 0.33 から 0.05 に変えたときの ROC 曲線と、再現率を横軸、適合率を縦軸にとった PR 曲線(precision-recall curve)である。ROC 曲線は 1 本のままだが、PR 曲線は大きく下がる。陽性が少ない現場で「陽性と言った中で本当に陽性は何割か」を知りたいとする。これは π に依存する量なので、PR 曲線を見る必要がある。PR 曲線の下を面積を平均適合率(average precision)と呼ぶ。 π を含む問いには PR 曲線で、含まない問いには ROC 曲線で答える。

計算の手順

ここまでで、切った結果を数える混同行列と 3 つの率、切る場所を決める損失行列と t^* 、測る量としての期待損失と ROC 曲線がそろった。確率からしきい値を決め、期待損失で測る手順を行列で書く。

1. 訓練の行で確率のモデル(第 6 回のロジスティック回帰や LDA)を当てはめ、テストの行のデータ行列 $\mathbf{X}$ から確率 $\boldsymbol{\theta} = \text{sig}(\mathbf{X}\hat{\boldsymbol{\beta}})$ を出す
2. 損失行列 $\mathbf{C}$ を決め、(5) 式でしきい値 t^* を計算する
3. $\theta_i \geq t^*$ の行を 1、ほかを 0 とした判定 $\hat{\mathbf{y}}$ を作り、 $\mathbf{Y} = [\mathbf{1} - \mathbf{y}, \mathbf{y}]$ 、 $\hat{\mathbf{Y}} = [\mathbf{1} - \hat{\mathbf{y}}, \hat{\mathbf{y}}]$ から混同行列 $\mathbf{M} = \mathbf{Y}^\top \hat{\mathbf{Y}}$ を作る




図 6: 図 5 と同じモデルで、陽性の割合 π だけを変えたときの (a) ROC 曲線と (b) PR 曲線

4. 期待損失 $R = \text{tr}(\mathbf{C}^\top \mathbf{M})/n$ を、混同行列 $\mathbf{M}$ とともに報告する
5. 損失が決まらないときは、しきい値を θ の値ごとに動かして $\mathbf{M}$ を数え直し、真陽性率と偽陽性率を並べて ROC 曲線を描く

しきい値 t^* はデータを見ずに損失だけから決まるので、テストの行を覗いてしきい値を選ぶことにはならない。反復はなく、確率を 1 回出したあとは数えるだけである。

理論の帰結

しきい値と損失の式から、いくつかの性質が言える。

第 1 に、しきい値を動かしても境界の向きは変わらない。第 6 回のロジスティック回帰や LDA の確率は $\text{sig}(\mathbf{w}^\top \mathbf{x} + w_0)$ の形をしている。そのため $\theta \geq t$ は $\mathbf{w}^\top \mathbf{x} + w_0 \geq \log\{t/(1-t)\}$ と同じで、 t で変わるのは右辺の定数だけである。図 7 は、雨の日の例を 2 変数(朝の湿度と雲の量、どちらも標準化した値)にした人工データに、確率が 0.02、0.5、0.98 になる線を引いたものである。境界は平行に動くだけなので、境界を動かして一方の群の誤りを減らせば、もう一方の群の誤りが増える。2 種類の誤りを同時に減らすには、しきい値ではなくモデル(向き $\mathbf{w}$)を良くするしかない。ROC 曲線が右上がりになるのは、このためである。

第 2 に、しきい値を動かす代わりに、当てはめの重みを変えても同じことができる。陽性の行の対数尤度に重み $w = c_{\text{FN}}/c_{\text{FP}}$ を掛けて当てはめると、LDA では陽性の群の割合が w 倍に数え直される。その結果、対数オッズに $\log w$ が足される。したがって、重みを付けたモデルの確率 θ_w を 0.5 で切ることは $\text{sig}^{-1}(\theta) + \log w \geq 0$ と同じである。これは、重みのないモデルの確率を $1/(1+w) = t^*$ で切ることにあたる(図 8)。ロジスティック回帰でも、モデルが正しければ切片がおおよそ $\log w$ ずれるだけである。

陽性の行を r 倍に複製して人数を増やす水増し(oversampling)(オーバーサンプリング)も、重みを付けたのと同じことになる。水増しは陽性の割合 π を書き換えるので、確率のオッズがおおよそ r 倍される。水増ししたモデルの確率 θ_{os} を 0.5 で切ることは、元の確率を $1/(1+r)$ で切ることにあたる。すなわち、損失の比 $c_{\text{FN}}/c_{\text{FP}} = r$




図 7: 朝の湿度と雲の量(標準化)の 2 変数の人工データに LDA を当て、事後確率が 0.02 (点線)・0.5 (実線)・0.98 (破線)になる境界を引いたもの




図 8: 雨の日の人工データ(朝の湿度 1 変数)の LDA の事後確率 θ (実線)と、陽性の行に重み 5 を付けた確率 θ_w (破線)。 $\theta_w = 0.5$ と $\theta = 1/6$ は同じ x (灰の線)で起きる

を黙って選んだことになる。 r が使う人の損失の比と違えば、その分だけ切る場所がずれる。

第 3 に、(5) 式は確率が正しいことを前提にしている。1 件ごとの天秤で θ を「外れる確率」として使ったからである。モデルが確率 θ を付けた行の中で、実際に陽性が割合 θ だけあるとき、確率は較正(calibration)されているという。確かめるには、確率の近い行を集めて区間に分け、区間ごとの平均の確率を横軸、実際の陽性の割合を縦軸に打つ。これを較正曲線(calibration curve)と呼び、較正されていれば点是对角線に沿う。図 9 の赤の曲線は、対数オッズを本当の 2 倍に出してしまい、確率を 0 と 1 に寄せすぎたモデルである。このモデルの確率を $t^* = 1/6$ で切ると、実際の陽性の割合が 0.31 の行で切ることになる。本来切るべき所はモデルの確率で 0.038 であり、そこからずれる。モデルの仮定(たとえば LDA の共通の分散)が成り立たないと、確率はこのようにずれる。

以上をまとめると、評価の指標はそれぞれ、損失の比と陽性の割合 π について何かを黙って仮定している(表 1)。期待損失だけは、使う人がその仮定を自分で書く指標である。ただし、損失の値そのものはデータからは決まらない。誤検出 1 件の手間や見逃し 1 件の害は、どれだけデータを集めても推定できない。それは使う人が決めるものである。統計で示せるのは、損失を決めればしきい値と測る量が決まる、ということまでである。




図 9: 較正の概念図。横軸はモデルの確率、縦軸は実際の陽性の割合。破線は較正された確率、赤の曲線は対数オッズを本当の 2 倍に出したモデル

表 1: 評価の指標が黙って置いている仮定

指標	見ているもの	黙って置いている仮定
精度	誤りの件数	$c_{FP} = c_{FN}$ (0.5 で切るのと同じ)
F1	適合率と再現率の調和平均	2 つを対称に扱い、損失の比を使わない
ROC・AUC	群の中の率・順位	しきい値を決めない。 π を見ない
PR・平均適合率	陽性と言った中の当たり	π に依存する
期待損失	損失の合計	仮定を自分で書く

推定の後ろの決定

「モデル × 推定法」の地図でいえば、本章ではモデル(ロジスティック回帰・LDA)も推定法(最尤法)も第 6 回そのまま変えない。推定された確率 θ を判定 $\hat{y}$ に変える段に、期待損失という別の目的関数を置く。推定の目的関数(尤度)と決定の目的関数(期待損失)は別物であり、地図の後ろに決定の層が加わる。

第 II 部 実データ解析

与信データと手続き

第 II 部では、損失の表が付いたデータで、しきい値を決めて測る。使うのは、ドイツの銀行の与信データ (Statlog German Credit Data、Hans Hofmann 提供)である。UCI Machine Learning Repository に CC BY 4.0 で収録されたものを、OpenML の 31 番から一度だけ取得して保存した。1 行は融資の申込者 1 人で、1,000 人ある。説明変数は、融資期間・融資額・返済額が所得に占める割合の段階・現住所の年数・年齢・この銀

行での借入件数・扶養家族の人数の数値 7 列と、当座預金の残高の区分・返済の履歴・借りる目的・貯蓄の区分・勤続年数の区分などのカテゴリ 13 列である。性別や国籍にあたる列を審査に使うてよいかは別に論じるべき問題だが、ここでは配布されたままのデータを使う。目的変数は、銀行がその人の返済の信用を悪い(bad)と見たか、良い(good)と見たかである。bad を陽性(300 人)とした。

このデータには提供者が損失の表を添えている。bad の人を good と判定して貸す見逃しの損失が 5、good の人を bad と判定して断る誤検出の損失が 1 である。(5) 式から $t^* = 1/6$ となり、しきい値はデータを見る前に決まる。比べる相手は、これまでのやり方である。テストの確率を 0.5 で切ると、精度(一致率)は 0.783、損失の比 1:5 の期待損失は 0.777 になる。

手続きは次のとおりである。層化して訓練 700 人・テスト 300 人(bad 90 人)に分けた。数値の列は標準化し、カテゴリの列は区分ごとに 0/1 の列に展開して、61 列のデータ行列にした。標準化の平均・標準偏差と区分の一覧は、訓練の行で学んだ。これに罰の強さ $\lambda = 1$ のロジスティック回帰(scikit-learn の LogisticRegression の既定)を当て、テストの確率 θ を固定した。以後、モデルは変えずにしきい値だけを動かす。まず、確率を切った判定から $\mathbf{Y}$ と $\hat{\mathbf{Y}}$ の積で混同行列を作った。AUC は、bad と good の組 18,900 通りをすべて作り、bad のほうの確率が高い割合として数えた。どちらもライブラリの値と比べた。次に、しきい値を 0.01 刻みで動かして(3) 式の期待損失を数え、谷底の位置を t^* と比べた。ずれの出どころを調べるために、テストの確率の較正曲線を描き、分割を 100 通り変えて当てはめ直した。最後に、bad の行の尤度に重み 5 を付けたモデル、bad を間引いて陽性の割合を下げたテスト、訓練の bad の行を good と同じ人数まで複製して水増ししたモデルを調べた。

表 2 のとおり、行列の積で作った混同行列は scikit-learn の confusion_matrix と一致する。組の数え上げで求めた AUC も、roc_auc_score と $1e-16$ の差で一致する。AUC は (8) 式の順位的一致率そのものである。

表 2: 与信データのテストでの、数え上げとライブラリの比較

確かめたこと	値
$\mathbf{Y}^T \hat{\mathbf{Y}}$ と confusion_matrix の差(最大、 $t = 0.5$ と t^*)	0
bad と good の組 18,900 通りの数え上げの AUC	0.8011
組の数え上げと roc_auc_score の差	$1e-16$

与信データでしきい値を確かめる

図 10 は、テスト 300 人の確率を固定し、しきい値を 0.01 刻みで動かして数えた期待損失である。損失の比が 1:1 なら谷底は 0.49 で、 $t^* = 0.5$ とほぼ一致する。提供者の比 1:5 では、谷底は 0.24 (期待損失 0.500)にあり、 $t^* = 1/6$ での期待損失は 0.513 となる。0.5 で切ると 0.777 になる。 t^* は 0.5 よりはるかによいが、谷底からはずれている。

ずれの出どころは 2 つ考えられる。確率が較正されていない(第 I 部の帰結)か、300 人の標本が揺れたかである。図 11 (a) は、テストの確率を幅 0.1 の区間に分け、20 人以上いる区間で平均の確率と実際の bad の割合を比べた較正曲線である。点はおおむね対角線に沿う。(b) は、分割を 100 通り変えるたびに当てはめ直し、そ




図 10: 与信データのテスト(300 人)で数えた期待損失 $R(t)$ 。点は谷底、点線は (5) 式の t^* (損失の比 1:1 で 0.5、1:5 で 1/6)

のテストで谷底の位置を数えたものである。谷底は中央値 0.14、10% 点 0.07 から 90% 点 0.22 まで揺れる。 $t^* = 1/6$ はその揺れの中にある。今回の分割の 0.24 は、揺れの一例にすぎない。谷底はそのテストを見てから選んだ値なので、その期待損失は t^* の期待損失より平均で 0.040 だけ小さく出る。この差は、テストを覗いた分の甘さである(第 2 回)。




図 11: 与信データの谷底のずれの出どころ。(a) テストの確率の較正曲線(20 人以上の区間)。(b) 分割を 100 通り変えたときの、損失の比 1:5 の谷底の位置

帰結で述べた重みとしきい値の関係も確かめた(表 3)。1 つは、bad の行に重み 5 を付けて当てはめ直したモデルを 0.5 で切った混同行列である。もう 1 つは、重みのないモデルを $t^* = 1/6$ で切った混同行列である。2 つはほぼ同じになる。重みを付けることも、しきい値を動かすことも、同じ損失の比を表している。

表 3: 与信データのテストでの、重みとしきい値の比較(期待損失は損失の比 1:5)

	TN	FP (断る)	FN (貸す)	TP	期待損失
重み 5 で当てはめて 0.5 で切る	116	94	12	78	0.513
重みなしで $t^* = 1/6$ で切る	111	99	11	79	0.513

与信データで測る

これまでのやり方のおりテストの確率を 0.5 で切ると、bad 90 人のうち 42 人に貸してしまう。表 4 は、同じ確率を $t^* = 1/6$ で切ったときの混同行列である。真陽性率(再現率)は 0.878、偽陽性率は 0.471、適合率は 0.444 である。bad 90 人のうち貸してしまうのは 11 人に抑えられるが、その代わりに good 210 人のうち 99 人を断る。見逃しが誤検出の 5 倍重いので、断りすぎるほうを選んでいる。

表 4: 与信データのテストでの、 $t^* = 1/6$ で切った混同行列

$t^* = 1/6$ で切る	good と判定(貸す)	bad と判定(断る)
本当は good	TN 111	FP (断る) 99
本当は bad	FN (貸す) 11	TP 79

図 12 は、同じテストの確率の ROC 曲線である。AUC は 0.801 で、曲線は左上の角に近いとはいえない。0.5 で切った点(黒)は左下に寄り、誤検出は少ないが bad の多くを見逃す。(7) 式に $\pi = 0.30$ を入れると、等損失線の傾きは 0.47 になる。 t^* の点(橙)を通るこの直線は、曲線にほぼ接している。300 人の階段状の曲線なので、接点は少し揺れる。谷底が t^* からずれたのと同じことである。AUC には、この点の選び方が表れない。




図 12: 与信データのテスト(300 人)での ROC 曲線。色を塗った部分の面積が AUC。黒の点は $t = 0.5$ 、橙の点は $t^* = 1/6$ 、橙の破線は損失の比 1:5 の等損失線

表 5 は、同じテストの確率で 3 つのやり方を比べたものである。精度で比べると、0.5 で切るのが 0.783 で最もよい。全員に貸すだけでも 0.700 になり、 t^* で切ると 0.633 に下がる。しかし提供者の損失で比べると順位は入れ替わり、 t^* の期待損失 0.513 が最も小さい。0.5 で切ると bad の 42 人に貸してしまう。精度が高いやり方は、見逃しの重さを誤検出と同じとみなしたときに得をするやり方にすぎない。

表 5: 与信データのテストでの、3 つのやり方の精度と期待損失

やり方	精度	見逃し(貸す)	誤検出(断る)	期待損失(1:5)
全員に貸す	0.700	90	0	1.500
しきい値 0.5	0.783	42	23	0.777
しきい値 $t^* = 1/6$	0.633	11	99	0.513

与信データの落とし穴

陽性の割合 π を変えると指標がどう動くかを、テストの bad を間引いて確かめた。bad の少ない客層に同じモデルを使う場面にあたる。good 210 人は全部残し、bad 90 人から 15 人だけが無作為に残したテストを 200 通り作った。確率はそのままにして t^* で切った指標を数え、200 通りで平均した(表 6)。陽性の割合は 0.300 から 0.067 に下がる。

表 6: 与信データのテストの bad を間引いたときの指標(間引いたテストは 200 通りの平均、しきい値 $t^* = 1/6$)

	元のテスト (bad 90 人)	間引いたテスト (bad 15 人)
陽性の割合 π	0.300	0.067
全員に貸すときの精度	0.700	0.933
t^* で切った精度	0.633	0.552
TPR (再現率)	0.878	0.876
FPR	0.471	0.471
適合率	0.444	0.117
AUC	0.801	0.800

真陽性率・偽陽性率・AUC は、間引く前とほぼ同じである。どれも群の中の率が順位なので、群の大きさが変わっても動かない。一方、全員に貸すだけの精度は 0.700 から 0.933 に上がり、何も見分けられない判定が t^* で切った精度 0.552 を上回る。適合率は 0.444 から 0.117 に下がる。(9) 式のとおり、陽性が少ないほど、分母の誤検出の分だけ「断った中で本当に bad だった人」の割合は減る。bad の少ない顧客層に同じモデルを使うなら、AUC が同じでも適合率は下がると見込む必要がある。

陽性が少ないデータでは、第 I 部の帰結で見た水増し(オーバーサンプリング)がよく使われる。訓練の bad 210 人を good と同じ 490 人まで復元抽出で複製して当てはめ直すと、テストの平均の確率は 0.303 から 0.423 に上がる(表 7)。水増しは陽性の割合を 0.30 から 0.5 に書き換えるので、確率のオッズがおよそ $490/210 = 2.33$ 倍になる。このモデルを 0.5 で切ることは、元のモデルを $1/(1+2.33) = 0.30$ で切ることにあたる。すなわち、損失の比 $c_{FN}/c_{FP} = 2.33$ を黙って選んだことになり、提供者の比 5 とは違う。AUC は順位しか見ないのでほとんど変わらず、この違いは AUC に表れない。水増しを使うなら、オッズの倍率で t^* を直した 0.318 で切ればよい。そうすれば期待損失は 0.527 になり、元のモデルを t^* で切ったときに近づく。

表 7: 与信データで bad を水増ししたモデルのテストの平均の確率としきい値(期待損失は損失の比 1:5)

	平均の確率	しきい値	期待損失	AUC
元のモデル	0.303	1/6	0.513	0.801
水増し	0.423	0.5	0.603	0.806
水増し(尺度を直す)	0.423	0.318	0.527	0.806

締め

まとめと次回の問い

本章の問いは「確率が出た。どこで切り、どう測るか」であった。答えは、2 種類の誤りに損失を付けることである。見逃しの損失 c_{FN} と誤検出の損失 c_{FP} を決めると、期待損失 $R(t) = \text{tr}(\mathbf{C}^\top \mathbf{M})/n$ を最小にするしきい値は、1 件ごとの天秤から $t^* = c_{FP}/(c_{FP} + c_{FN})$ と決まる。0.5 は 2 つの誤りが同じ重さだという表明であった。測る量も同じ期待損失になる。精度は、損失を等しいとおいた期待損失にあたる。F1 は損失の比を使わない。ROC 曲線と AUC は陽性の割合 π を含まず、しきい値も選ばない。適合率と PR 曲線は π に依存する。損失が決まらないときは、ROC 曲線ですべてのしきい値を並べる。損失を決めることは、その上の 1 点を等損失の直線で選ぶことにあたる。 t^* が最適なのは、確率が校正されているときである。与信データでは、提供者の損失 1:5 から決めた $t^* = 1/6$ で切ると、精度で選ぶ 0.5 より期待損失が大きく下がった。谷底とのずれは、標本の揺れの範囲にあった。bad を間引くと、AUC は動かずに適合率が下がった。bad を水増しして 0.5 で切ると、黙って別の損失の比を選ぶことになった。

同じ学期の演習 8 では、心臓病のデータ(テスト 61 人)を扱う。しきい値 0.5 では見逃しが 2 人、0.3 に下げると 0 人になり、AUC は 0.951 である。演習 9 では、その 0.3 がテストを見て選んだ値だったことに気づく。訓練の中で数え直すと、0.3 でも見逃しは 111 人中 11 人になる。しきい値もテストを覗かずに決める必要がある。損失から決める t^* は、データを見る前に決まる。

最後に、次回への問いを置く。第 1 回の二乗誤差 $\|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2$ 、第 6 回の対数尤度、本章の期待損失は、どれも正解 y と比べて誤りを測っていた。しかし、手元に $\mathbf{X}$ だけがあり、 y が無いこともある。そのとき何を誤りと呼べばよいのか、何を最小化すればよいのか。