

第 8 回 教師あり学習と教師なし学習

y が無ければ、 X 自身を近似する

本章の問いは、第 7 回の締めで残った「ラベルが無いとき、何を最小化するか？」である。答えは、 X 自身を近似することである。k-means は $\|X - GC\|_F^2$ 、主成分分析は $\|X - FA^T\|_F^2$ を最小にする。推定法は回帰の $\|y - X\beta\|_2^2$ と同じ最小二乗法であり、違いは目的関数に y が入るかどうかの一点にある。 y が入らないので、答えを正解と照らして測ることはできない。評価は目的関数の値と人の読み方に頼ることになる。

第 I 部 理論

ラベルが無いとき

第 7 回の締めで見たように、これまでの目的関数は、どれも正解 y との食い違いを測るものであった。第 1 回の二乗誤差も、第 6 回の対数尤度も、第 7 回の期待損失もそうである。では、正解の列が無いときは何を最小にすればよいのか。本章ではこれを、ワインのデータで考える。データは、イタリアの同じ地方で 3 つの品種のブドウから造られたワイン 178 本である。1 本ごとに、アルコール度数、フラボノイド、色の濃さ、プロリンなど 13 種類の成分を測ってある。図 1 (a) には、そのうちフラボノイドと色の濃さの 2 列を、品種で塗り分けて描いた。品種の列があれば、それを目的変数とし、第 5 回の指示行列の回帰で新しいワインの品種を当てられる。図 1 (b) は同じ点から品種の色を消したものである。手元に残るのは成分のデータ行列 X だけになる。それでも点の濃い所はいくつかに分かれて見える。分けるとすれば、何を基準に分ければよいのか。

本章の問いは、ラベルが無いとき何を最小化するか、である。答えは、 X 自身を近似することである。k-means は X の各行を少数の代表点で、主成分分析は少数の軸で近似し、その誤差の二乗和を最小にする。推定法は回帰と同じ最小二乗法であり、違うのは目的関数に y が入るかどうかの一点だけである。そして y が入らないために、得られた答えを正解と照らして測ることができなくなる。評価は目的関数の値と、答えを人が読むことに頼るしかない。

第 1 回の「モデル × 推定法」の地図に、近似する相手の列を足すと表 1 になる。上の 2 行は y を近似し、下の 3 行は X を近似する。推定法の列を見ると、上下で同じ推定法が使われている。本章は、この上下を分ける線を扱う回である。




図 1: ワインのデータの 2 列(フラボノイドと色の濃さ)。(a) 品種で塗り分けた図、(b) 品種の列を消した図

表 1: 「モデル × 推定法」の地図に、近似する相手を足したもの

モデル	推定法	近似する相手	回
線形回帰	最小二乗法・最尤法	y	第 1～4・6 回
LDA・ロジスティック回帰	最小二乗法・最尤法	y	第 5～7 回
主成分分析	最小二乗法	$\mathbf{X}$	第 9・10 回
k-means・GMM	最小二乗法・最尤法	$\mathbf{X}$	第 11～13 回
対応分析	重み付き最小二乗法	$\mathbf{X}$	第 14 回

何を何で近似するか

何を何で近似するかという、モデルの型から見ていく。第 1 回から第 7 回までのモデルは、データ行列 $\mathbf{X}$ の横に置かれた答えの列 $\mathbf{y}$ を、 $\mathbf{X}$ から作るものであった。線形回帰なら $\mathbf{y} \approx \mathbf{X}\beta$ であり、0/1 の y を回帰した第 5 回も、確率を出した第 6 回も同じ型である。行の数だけ答えがあり、モデルはその 1 列を近似する。

y の列が無ければ、近似する相手は $\mathbf{X}$ しか残らない。式どおりの姿を見るために、ここでは人工的なデータを使う。図 2 は、店の印の付いていないおにぎり 30 個の幅と高さ (cm) である。点は $\mathbf{X}$ の 1 行である。

1 つ目の近似には、第 1 回の地図に載せた k-means を使う。k-means は、形の似た点どうしをいくつかの群に分け、群ごとに代表点(★)を 1 つ置く。★は群の点の平均の位置にある。そして各点を、その群の代表点で近似する。近似の誤差は、点から自分の群の代表点へ引いた線になる(図 2 (a))。

2 つ目の近似には主成分分析を使う。代表点の代わりに、点の中心を通る 1 本の軸を引き、各点を軸に下ろした足で近似する。誤差は点から軸へ下ろした線になる(図 2 (b))。どちらのモデルも、 $\mathbf{X}$ の各行を $\mathbf{X}$ から作った点で近似しており、 y はどこにも出てこない。




図 2: $\mathbf{X}$ を $\mathbf{X}$ で近似する 2 つのモデル(人工データ。おにぎり 30 個の幅と高さ)。(a) k-means (3 群)は各点を群の代表点★で、(b) 主成分分析(軸 1 本)は各点を軸に下ろした足で近似する。灰色の線が近似の誤差である

近似する相手が y か $\mathbf{X}$ か

近似する相手が y か $\mathbf{X}$ かで、目的関数がどう変わるかを、スカラー・ベクトル・行列の順に書く。まず回帰である。第 1 回の重回帰の目的関数は

$$f(\beta) = \sum_{i=1}^n \left(y_i - \sum_{j=1}^p \beta_j x_{ij} \right)^2 = \|\mathbf{y} - \mathbf{X}\beta\|_2^2 \quad (1)$$

であった。近似の誤差は、行 i の答え y_i と予測の差であり、1 行に 1 つの数である。右辺は、 n 個の誤差を縦に並べたベクトルの ℓ_2 ノルムの二乗になっている。

k-means では、近似するのは $\mathbf{X}$ の 1 マス 1 マスである。おにぎりの例なら、点 i の誤差は代表点までの線の長さの二乗であり、幅の差の二乗と高さの差の二乗の和になる。一般に、行 i が属する群を $q(i)$ 、群 q の代表点の第 j 成分を c_{qj} とすると、マス x_{ij} は $c_{q(i)j}$ で近似される。誤差は 1 マスに 1 つになる。目的関数は $n \times p$ 個の誤差の二乗和

$$J = \sum_{i=1}^n \sum_{j=1}^p (x_{ij} - c_{q(i)j})^2 = \sum_{i=1}^n \|\tilde{\mathbf{x}}_i - \mathbf{c}_{q(i)}\|_2^2 \quad (2)$$

である。2つ目の等号では、内側の j についての和を、行ベクトル $\tilde{\mathbf{x}}_i$ と代表点 $\mathbf{c}_{q(i)} \in \mathbb{R}^p$ のユークリッド距離の二乗にまとめた。右辺は第1回の k-means の式そのものであり、 $p = 1$ なら各行は1つの数になって、左辺の1重の和に戻る。

回帰は行列とベクトルで1つの式に書けたが、(2)式には添え字に群の番号 $q(i)$ が入っている。これを行列で書くために、道具を2つ用意する。1つ目は、行列の全マスの二乗和である。たとえば $\mathbf{E}$ の1行目が $(3, -1)$ 、2行目が $(0, 2)$ なら、全マスの二乗和は $9 + 1 + 0 + 4 = 14$ である。一般に、行列 $\mathbf{E} \in \mathbb{R}^{n \times p}$ について

$$\|\mathbf{E}\|_F^2 = \sum_{i=1}^n \sum_{j=1}^p e_{ij}^2 = \sum_{i=1}^n \|\tilde{\mathbf{e}}_i\|_2^2 \quad (3)$$

をフロベニウスノルム(Frobenius norm)の二乗と呼ぶ(定義1)。これは行ごとの長さの二乗を足したものでもあり、例では1行目の10と2行目の4を足して14になる。 $\mathbf{E}$ が1列のとき、すなわちベクトル $\mathbf{e}$ のときは $\|\mathbf{e}\|_2^2$ に一致する。2つ目は、群への所属を表す行列 $\mathbf{G} \in \{0, 1\}^{n \times k}$ である。 $\mathbf{G}$ の第 i 行は、行 i の群 $q(i)$ の列だけが1で、ほかは0である。代表点を行に並べた $\mathbf{C} = [\mathbf{c}_1, \dots, \mathbf{c}_k]^\top \in \mathbb{R}^{k \times p}$ を右から掛けると、 $\mathbf{GC}$ の第 i 行は $\mathbf{c}_{q(i)}^\top$ 、すなわち行 i の代表点になる。たとえば4行を2群に分け、1行目と3行目を群1、2行目と4行目を群2とする。このとき $\mathbf{G}$ の各行は $(1, 0), (0, 1), (1, 0), (0, 1)$ であり、 $\mathbf{GC}$ は $\mathbf{c}_1^\top, \mathbf{c}_2^\top, \mathbf{c}_1^\top, \mathbf{c}_2^\top$ を縦に並べたものになる。積 $\mathbf{GC}$ は $n \times p$ であり、 $\mathbf{X}$ と同じ大きさである。

2つの道具を使うと、 $\mathbf{X} - \mathbf{GC}$ の第 i 行は $\tilde{\mathbf{x}}_i - \mathbf{c}_{q(i)}$ であるから、(3)式により(2)式は

$$J(\mathbf{G}, \mathbf{C}) = \|\mathbf{X} - \mathbf{GC}\|_F^2 \quad (4)$$

と書ける。主成分分析も同じ形に乗る。主成分分析は、各マスを Q 本の軸の組み合わせで近似する。行 i の軸 m の得点を f_{im} 、軸 m の第 j 成分を a_{jm} とすると、マス x_{ij} は $\sum_m f_{im} a_{jm}$ で近似され、目的関数は

$$\sum_{i=1}^n \sum_{j=1}^p \left(x_{ij} - \sum_{m=1}^Q f_{im} a_{jm} \right)^2 = \|\mathbf{X} - \mathbf{FA}^\top\|_F^2 \quad (5)$$

となる。 $\mathbf{F} \in \mathbb{R}^{n \times Q}$ は得点の行列、 $\mathbf{A} \in \mathbb{R}^{p \times Q}$ は軸の行列であり、軸には長さ1で互いに直角という条件 $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$ を付ける。 $Q = 1$ のときが図2(b)の1本の軸である。

(1)式、(5)式、(4)式を図3のように並べると、どれも「データ - モデル」の二乗和を最小にする最小二乗法だと分かる。違いは、近似するデータが $\mathbf{y}$ か $\mathbf{X}$ かにある。(1)式には $\mathbf{y}$ が入っているが、(5)式と(4)式は $\mathbf{X}$ だけで書けている。この違いで、2つの学び方を定義する。

定義1 (フロベニウスノルム). 行列 $\mathbf{E} \in \mathbb{R}^{n \times p}$ のフロベニウスノルムを $\|\mathbf{E}\|_F = \sqrt{\sum_i \sum_j e_{ij}^2}$ と定義する。その二乗は全マスの二乗和であり、行ベクトルのユークリッドノルムの二乗の和に等しい。




図 3: 3つのモデルの型(概念図)。回帰は答えの列 $\mathbf{y}$ (赤)を $\mathbf{X}\boldsymbol{\beta}$ で、主成分分析と k-means は $\mathbf{X}$ 自身を2つの行列の積で近似する

定義 2 (教師あり学習・教師なし学習). 目的関数が目的変数 y を含み、 y を $\mathbf{X}$ から近似してパラメータを決めることを教師あり学習(supervised learning)という。目的関数が $\mathbf{X}$ だけで書け、 $\mathbf{X}$ を $\mathbf{X}$ 自身から作ったモデルで近似してパラメータを決めることを教師なし学習(unsupervised learning)という。

第1回から第7回までの回帰、LDA、ロジスティック回帰は、すべて教師あり学習である。分かれ目は手法の名前ではなく、目的関数に y があるかどうかである。推定法は、どちらでも最小二乗法を使える。

解き方と計算の手順

目的関数の形の違いは、解き方にも表れる。回帰の (1) 式で未知なのは $\boldsymbol{\beta}$ だけであり、 $\mathbf{X}$ はデータとして与えられている。勾配を0とおけば正規方程式 $\mathbf{X}^T \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^T \mathbf{y}$ が得られ、それを1回解けば答えが出る(第1回)。一方、(5)式と(4)式では、モデル $\mathbf{F} \mathbf{A}^T$ と $\mathbf{G} \mathbf{C}$ が未知の行列どうしの積になっている。片方を固定すると、残りの片方だけについての最小化になる。たとえば $\mathbf{G}$ を固定すれば、 $\mathbf{C}$ については第1回と同じ形の最小二乗の問題である。そこで2つを交互に解き直していく。

計算の手順を行列で並べると表2になる。教師ありでは、 $\mathbf{X}$ と $\mathbf{y}$ を訓練の行とテストの行に分ける(第2回)。訓練の行で正規方程式を解き、テストの行の予測 $\hat{\mathbf{y}} = \mathbf{X}_{\text{テスト}} \hat{\boldsymbol{\beta}}$ を正解 $\mathbf{y}_{\text{テスト}}$ と比べて測る。教師なしでは、 $\mathbf{X}$ だけを使って $J(\mathbf{G}, \mathbf{C})$ を最小にし、所属 $\mathbf{G}$ 、代表点 $\mathbf{C}$ 、そして J の値を出す。最後の「測る」の段に、比べる相手の y が無い。

表 2: 教師ありと教師なしの計算の手順

	教師あり(回帰)	教師なし(k-means)
1. 用意する	$\mathbf{X}$ と $\mathbf{y}$. 訓練とテストの行に分ける	$\mathbf{X}$ だけ
2. 解く	訓練の行で $\mathbf{X}^T \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^T \mathbf{y}$	$\ \mathbf{X} - \mathbf{G} \mathbf{C}\ _F^2$ を $\mathbf{G}, \mathbf{C}$ について最小に
3. 出す	$\hat{\mathbf{y}} = \mathbf{X}_{\text{テスト}} \hat{\boldsymbol{\beta}}$	$\mathbf{G}$ (所属)、 $\mathbf{C}$ (代表点)、 J の値
4. 測る	$\mathbf{y}_{\text{テスト}}$ と $\hat{\mathbf{y}}$ を比べる	比べる y が無い。 J と、 $\mathbf{C}$ を人が読むこと

評価の根拠が変わる

目的関数に y が入らないことから、評価について 4 つのことが言える。

第 1 に、照らす相手が無い。教師ありでは、テストの行の正解 $\mathbf{y}_{\text{テスト}}$ と予測との差 $\|\mathbf{y}_{\text{テスト}} - \mathbf{X}_{\text{テスト}}\hat{\boldsymbol{\beta}}\|_2^2$ で、手元のない行への当たり方を測れた(第 2 回)。教師なしの J は $\mathbf{X}$ とモデルの距離であり、 J が小さいことは $\mathbf{X}$ をよく近似したことしか意味しない。外に正解が無いので、答えが「合っている」かを式の中で確かめる手段が無い。

第 2 に、群の番号には意味が無い。k-means の答えには群 1、群 2、群 3 と番号が付いて返ってくる。群の番号を並べ替える行列 $\mathbf{P}$ ($k \times k$ で、各行・各列に 1 が 1 つだけある行列。 $\mathbf{P}\mathbf{P}^\top = \mathbf{I}_k$) を使って、 $\mathbf{G}$ を $\mathbf{G}\mathbf{P}$ に、 $\mathbf{C}$ を $\mathbf{P}^\top\mathbf{C}$ に替えると

$$\|\mathbf{X} - \mathbf{G}\mathbf{P}\mathbf{P}^\top\mathbf{C}\|_F^2 = \|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2 \quad (6)$$

であり、 J はまったく変わらない。図 4 (a) と (b) は同じ答えである。教師ありの出力の「品種 1」は、外で決まった意味を持つ。教師なしの「群 1」はそれとは違い、人が後から名前を付けるまで何も意味しない。




図 4: k-means の答えの番号を付け替えても J は変わらない(人工データ。おにぎり 30 個)。(a) と (b) は群の番号(と色)だけが違う

第 3 に、群を増やせば J は下がる。 k 群の答えに群を 1 つ足し、どれかの点をそこへ移すとする。その点の誤差は 0 になり、ほかの点はそのままでよい。だから J の最小値は下がるか変わらない。 $k = n$ にすれば全点が自分自身を代表点にでき、 $J = 0$ になる。図 5 はおにぎり 30 個でこれを確かめたものである。 J だけを見ては、群の数を選べない。

第 4 に、 J を最小にする群は y の群とは限らない。図 6 は、2 つの店のおにぎりの幅と高さを並べた人工データである。どちらの店でも大きいおにぎりほど幅も高さも大きく(店の中の相関 0.95)、店 B のほうが縦長に握




図 5: 群の数 k と J の最小値(人工データ。おにぎり 30 個)

る。 y は店である。(a) は y の 2 群で、それぞれの群の平均を代表点にすると $J = 271.9$ になる。(b) は y を使わずに J を最小にした 2 群で、 $J = 154.5$ と小さい。 y の 2 群は、雲の短い向きに並んでいる。一方、 J が小さくなるのは細長い雲を長い向きの途中で 2 つに切ったときであり、 y との一致は 61% にとどまる。 J は y を含まないのだから、その最小が y の群に一致する理由は、式のどこにも無い。




図 6: 2 つの店のおにぎり(人工データ。店の中の共分散は共通、相関 0.95)。(a) y の 2 群と各群の平均★、(b) y を使わずに J を最小にした 2 群と代表点★。 J は (b) のほうが小さい

以上を 表 3 にまとめる。

表 3: 教師ありと教師なしの評価の根拠

	教師あり	教師なし
目的関数	$\ \mathbf{y} - \mathbf{X}\beta\ _2^2$ (y を含む)	$\ \mathbf{X} - \mathbf{G}\mathbf{C}\ _F^2, \ \mathbf{X} - \mathbf{F}\mathbf{A}^\top\ _F^2$
測る相手	テストの行の正解 y	無い(J の値と人の読み方)
出力の番号	「品種 1」など、外で決まった意味	付け替えても J は同じ。意味は人が付ける
大きさを増やすと	テストの誤差はいずれ上がる(第 2 回)	J は下がり続ける

第 II 部 実データ解析

ワインのデータと手続き

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、次の 2 つを予想できる。第 1 に、 J は群を増やせば必ず下がるので、ワインのデータでも J は群の数 k とともに下がり続けるはずである。第 2 に、 J は y を含まず、その最小が y の群に一致する理由は無い。第 I 部の 2 つの店のおにぎりでは、 J を最小にした 2 群と店の一致は 61% にとどまった。だから、品種を見ずに分けた k-means の 3 群は、品種とずれるはずである。

データは、Forina らがイタリアのワインを分析したものである。UCI 機械学習リポジトリで公開され(CC BY 4.0)、scikit-learn に同梱されている。1 行はワイン 1 本で、178 本ある。説明変数はアルコール度数、フラボノイド、色の濃さ、プロリンなどの成分 13 列であり、目的変数は 3 つの品種(59・71・48 本)である。品種で層化して訓練 124 本とテスト 54 本に分け、13 列を訓練の行の平均と標準偏差で標準化した。成分の単位はまちまちで、プロリンは 278 から 1680 までの値をとり、色相の平均は 0.96 である。プロリンの標準偏差は 314 で、ほかの 12 列はどれも 14 以下である。標準化しないと、距離がプロリンだけで決まってしまう。品種を使うのは教師ありの解析だけであり、教師なしの解析には $\mathbf{X}$ しか渡さない。

手続きは次のとおりである。教師ありでは、第 5 回の多群の場合と同じく、品種を指示行列 $\mathbf{Y}$ ($n \times 3$, 行 i の品種の列だけが 1)にした。そして訓練の行で、3 本の列をまとめて最小二乗回帰した。切片の列を加えた正規方程式は、NumPy の線形方程式ソルバーで解いた。目的関数は $\|\mathbf{Y} - \mathbf{X}\mathbf{B}\|_F^2 = \sum_q \|\mathbf{y}_q - \mathbf{X}\mathbf{b}_q\|_2^2$ であり、(1) 式の回帰を列ごとに 3 本並べたものである。テストの行は、予測値の最大の列の品種に判定した。教師なしでは、訓練の行の $\mathbf{X}$ だけで $k = 3$ の k-means を当てはめた(scikit-learn の KMeans。初期値を 20 通り試し、 J が最も小さい答えを採った)。テストの行は、近い代表点の群に振り分けた。最後に、隠していた品種を持ち出して、群と品種を突き合わせた。群の番号は任意なので、6 通りの番号の付け方のうち、訓練の行で品種と最も多く重なる付け方を採った。品種 q と多く重なる群を、群 q と呼ぶ。 J は、 $k = 1$ から 8 までの k-means と、品種の 3 群を代表点にした場合について、訓練の行で求めた。

群の数と J

第1の予想は、群の数 k と J の関係である。図7の折れ線のとおり、 $k=1$ の J は 1,612.0 で、 $n \times p = 1,612$ に一致する。 $k=1$ の代表点は列の平均、すなわち 0 であり、標準化した列の二乗和はどれも n だからである。 k を 1 から 8 まで増やすと、 J は毎回下がった。予想どおりであり、 J の値だけでは群の数を選べない。

計算そのものも確かめておく(表4)。番号を付け替えた $\mathbf{GP}$ と $\mathbf{P}^T \mathbf{C}$ で計算し直した J は、元の J との差が 0 で、(6) 式のとおりであった。行列で書いた $\|\mathbf{X} - \mathbf{GC}\|_F^2$ は KMeans の返す J と一致し、正規方程式から自分で求めた係数は、scikit-learn の LinearRegression の係数と最大 $5.1\text{e-}16$ しか違わなかった。




図7: ワインのデータの訓練の行での、群の数 k と k-means の J 。点線は $n \times p$ 。★は品種の3群を代表点にしたときの J

表4: ワインのデータの訓練の行での確認

確かめたこと	値
$k=1$ の J と $np = 124 \times 13$	1,612.0 と 1,612
$k=1 \sim 8$ で J が毎回下がったか	はい
番号を付け替えた J - 元の J ($k=3$)	0
$\ \mathbf{X} - \mathbf{GC}\ _F^2$ と KMeans の J の差	0
正規方程式の $\hat{\mathbf{B}}$ と LinearRegression の係数の差(最大)	$5.1\text{e-}16$

y を使う解析と使わない解析

第2の予想は、k-means の3群と品種の関係である。まず比べる相手として、 y を使った指示行列の回帰を見る。表5のとおり、テストの行54本で品種と100.0%一致した。 y を目的関数に入れて学び、手元にないテストの行の正解と照らした成績である。次に、 y を使わずに分けた k-means の3群は、品種と94.4%重なった。予想に反して、品種とほとんどずれていない。図8は、第I部の場面の図と同じ2列に、13列で決めた k-means の群の色を塗ったものである。代表点は訓練の行で決め、全178本を近い代表点に振り分けた。品種で塗った図1(a)とよく似た分かれ方をしている。

表5: テストの行(54本)での2つの解析と品種の突き合わせ(本数)。上の3行は指示行列の回帰(y を使う、一致100.0%)、下の3行は k-means ($k=3$ 、 y を使わない、一致94.4%)

テストの行	品種1	品種2	品種3
回帰: 1 と判定	18	0	0
回帰: 2 と判定	0	21	0
回帰: 3 と判定	0	0	15
k-means : 群1	18	1	0
k-means : 群2	0	18	0
k-means : 群3	0	2	15




図8: 図1と同じ2列を、13列の k-means ($k=3$ 、品種は使わない)の群で塗り分けたもの

ただし、k-means の94.4%は、k-means が知らなかった y を、分析者が後から持ち出して作った表の数字である。3つの群の番号の付け方は6通りあり、付け方しだいで一致は1.9%から94.4%まで変わる。どの群をどの品種と呼ぶかも、品種を見て決めた。ふつう教師なしの解析をするのは y が無いときであり、そのときこの表は作れない。

予想のうち、 J の最小が品種の群ではないという部分は当たっている。品種の 3 群をそのまま群とし、品種ごとの平均を代表点にして J を計算すると、訓練の行で 904.1 になり、k-means の 883.2 より大きい(図 7 の★)。 J から見れば、品種の分け方は最良ではない。

それでも群が品種と重なった理由は、 J の値を並べるとわかる(表 6)。おにぎりの店の 2 群は、1 群のときの J を 337 から 272 にしか下げず、 J の最小の 1.76 倍だった。店の差は雲の短い向きにあり、長い向きの広がり比べて小さい。そのため、 J を最小にする分け方は雲を長い向きで切り、店とは別物になった。ワインでは、品種で分けるだけで J が 1,612 から 904 まで下がり、 J の最小のわずか 1.02 倍である。品種の違いそのものが、13 列の点の雲のいちばん大きな分かれ目になっているからである。 J の小さい分け方は品種の近くにしか無く、 J の最小も品種に近い所に落ちた。 J の最小が y を知らないことは変わらない。ワインでは、 $\mathbf{X}$ のいちばん大きな分かれ方が、たまたま品種に近かったのである。

表 6: y の群の J と J の最小。比は「 y の群の $J \div J$ の最小」、一致は J を最小にした群と y の一致

	1 群の J	y の群の J	J の最小	比	y との一致
第 I 部のおにぎりの店	337.1	271.9	154.5	1.76	61%
ワインの品種(訓練の行)	1,612.0	904.1	883.2	1.02	95%

結果の読み方と落とし穴

y があるかないかで、データを分ける向きも変わる。標準化した列の平均は 0 である。そのため、群 q の代表点 $\mathbf{c}_q$ 、品種 q の平均、回帰の係数の第 q 列 $\mathbf{b}_q$ は、どれも全体の平均から品種 q の側へのずれの向きとして比べられる。表 7 のとおり、代表点と品種の平均のコサインは 3 群とも 0.99 を超え、ほぼ同じ向きである。一方、第 5 回で見たとおり、指示行列の回帰の係数は、群の中の広がり平均のずれを割り引いた向きである。代表点とのコサインは 0.64 から 0.83 にとどまる。13 列には、フラボノイド、全フェノール、希釈ワインの吸光度の比のように一緒に動く列がある。平均のずれの向きは、そうした列がまとめて大きい向きになる。 y を目的関数に入れて初めて、その向きを割り引いて品種を当てる向きが選ばれる。

表 7: k-means の代表点と、品種の平均・指示行列の回帰の係数の向き(訓練の行、標準化した 13 列)

群 q の代表点 $\mathbf{c}_q$ とのコサイン	品種 q の平均	回帰の係数 $\mathbf{b}_q$
群 1	0.999	0.639
群 2	0.994	0.832
群 3	0.997	0.635

2 つの目的関数を並べると、違いがもう 1 つ見える。指示行列の回帰の $\|\mathbf{Y} - \mathbf{XB}\|_F^2$ の $\mathbf{Y}$ と、k-means の $\|\mathbf{X} - \mathbf{GC}\|_F^2$ の所属行列 $\mathbf{G}$ は、どちらも $n \times 3$ で各行に 1 が 1 つだけある、同じ形の行列である。教師ありでは $\mathbf{Y}$ がデータとして与えられ、近似される側に置かれる。k-means では $\mathbf{G}$ は与えられず、 $\mathbf{X}$ をよく近似する

ように推定される側に置かれる。k-means の答えの $\mathbf{G}$ は、 $\mathbf{X}$ だけから作った見えない $\mathbf{Y}$ の候補である。 $\mathbf{G}$ が本当の $\mathbf{Y}$ にどれだけ近いかは、 $\mathbf{Y}$ を持ち出さないと分からない。

落とし穴を 2 つ挙げる。1 つ目は群の数である。同じ訓練の行で $k = 4$ にすると、 J は 883.2 から 809.7 に下がり、表 8 のように群が 1 つ増える。 J が下がったことは、分け方がよくなったことを意味しない。帰結で見たとおり J は k とともに必ず下がるので、群の数は J からは決まらない。

表 8: $k = 4$ の k-means の群と品種(テストの行。群の番号は、訓練の行で多く重なる品種の順)

k-means ($k = 4$, テスト)	群 1	群 2	群 3	群 4
本当は品種 1	18	0	0	0
本当は品種 2	1	18	1	1
本当は品種 3	0	0	0	15

2 つ目は群の名前である。k-means が返すのは所属 $\mathbf{G}$ と代表点 $\mathbf{C}$ であり、品種の名前は返さない。表 9 は $k = 3$ の代表点を、標準化した値で 5 列だけ示したものである。群 1 はアルコール度数が高くプロリンが多い。群 3 は色が濃く、フラボノイドが少なく、色相の値が小さい。群 2 はアルコール度数が低く色が淡い。これらをどの品種らしいと読むかは、ワインを知る人の仕事である。品種の列が無いときの教師なしの評価は、 J の値と、このように代表点を人が読むことに頼るしかない。

表 9: $k = 3$ の k-means の代表点(訓練の行の平均 0・標準偏差 1 の目盛り、13 列のうち 5 列)

代表点 $\mathbf{C}$ (標準化した値)	群 1	群 2	群 3
アルコール度数	+0.90	-0.94	+0.17
フラボノイド	+0.97	+0.12	-1.22
色の濃さ	+0.22	-0.86	+0.82
色相	+0.64	+0.32	-1.11
プロリン	+1.23	-0.75	-0.44

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは、 J は群の数とともに下がり続け、 J の最小は品種とずれるはずだと予想した。前者は予想どおりで、 k を 1 から 8 まで増やすと J は毎回下がった。後者は外れ、k-means の 3 群はテストの行で品種と 94.4% 重なった。理由は J の値に表れている。ワインでは品種で分けるだけで J が最小の 1.02 倍まで下がり、 J の小さい分け方が品種の近くにしか無かった。おにぎりの店では、その比が 1.76 倍だった。それでも J の最小は品種の群ではなく、 J が y を知らないことは実データでも変わらない。そして、群と品種がよく重なったという結論そのものは、隠していた y を持ち出して初めて言えたことである。

締め

まとめと次回の問い

本章の問いは、ラベルが無いとき何を最小化するか、であった。答えは、 $\mathbf{X}$ 自身を近似することである。k-means は各行を代表点で近似して $\|\mathbf{X} - \mathbf{GC}\|_F^2$ を、主成分分析は各行を少数の軸で近似して $\|\mathbf{X} - \mathbf{FA}^\top\|_F^2$ を最小にする。どちらも回帰の $\|\mathbf{y} - \mathbf{X}\beta\|_2^2$ と同じ最小二乗法であり、教師ありと教師なしの違いは、目的関数に y が入るかどうかの一点にある。 y が入らないために、 J は群の番号を付け替えても変わらず、群の数とともに下がり続ける。その最小も、 y の群とは限らない。ワインのデータでは、 y を使わない k-means の 3 群が、テストの行で品種と 94.4% 重なった。しかし品種の 3 群の J は k-means の J より大きい。この一致を知るには、隠していた y を持ち出す必要があった。

最後に、次回への問いを置く。本章では主成分分析の目的関数 $\|\mathbf{X} - \mathbf{FA}^\top\|_F^2$ (ただし $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$) を書いただけで、解いていない。回帰では未知が β だけだったので、正規方程式を 1 回解けば答えが出た。主成分分析では $\mathbf{F}$ も $\mathbf{A}$ も未知で、モデルはその積になっている。 $\mathbf{X}$ 自身を少数の軸で近似するとき、 $\mathbf{F}$ と $\mathbf{A}$ はどう求めればよいか。次回は、この問いから始める。