

第9回 主成分分析①

$\mathbf{X}$ を1回特異値分解し、上位 Q 本を残す

本章の問いは、第8回の締めで残った「 $\mathbf{X}$ 自身を少数の軸で近似すると？」である。目的関数は第8回で書いた $\|\mathbf{X} - \mathbf{F}\mathbf{A}^\top\|_F^2$ (ただし $\mathbf{A}^\top\mathbf{A} = \mathbf{I}_Q$) であり、未知の $\mathbf{F}$ と $\mathbf{A}$ の積を含む。答えは、データ行列 $\mathbf{X}$ そのものを1回特異値分解することである。 $\mathbf{X}$ は特異値分解でちょうど $\mathbf{K}\mathbf{\Delta}\mathbf{L}^\top$ に分けられ、上位 Q 本を残して $\hat{\mathbf{F}} = \mathbf{K}_1\mathbf{\Delta}_1$ 、 $\hat{\mathbf{A}} = \mathbf{L}_1$ とすればよい(Eckart-Young の定理)。目的関数の最小値は捨てた特異値の二乗和であり、特異値の小さい層はノイズとみなして捨てる。

第I部 理論

少数の軸で近似する

第8回の締めで残った問いは、 $\mathbf{X}$ 自身を少数の軸で近似するとどうなるか、であった。本章では、写真1枚をデータ行列として扱う。図1(a)は、白黒の写真の各画素の明るさを、黒を0、白を1として並べたものである。画素の行を行、画素の列を列とすれば、この写真は427行・400列、170,800個の数の行列になる。(b)では、その一部の6×6マスを拡大した。




図1: (a) 写真1枚(白黒、明るさ0~1)。(b) 赤い枠の中の6×6マスの明るさ。写真は行列である

困りごとは3つある。1つ目は数の多さである。もっと少ない数で、写真をほぼ言い表せないだろうか。2つ目は解き方である。第8回で書いた目的関数 $\|\mathbf{X} - \mathbf{F}\mathbf{A}^\top\|_F^2$ (ただし $\mathbf{A}^\top\mathbf{A} = \mathbf{I}_Q$) は、未知の $\mathbf{F}$ と $\mathbf{A}$ の積を含む。回帰のように、正規方程式を1回解けば済むのかどうかはわからない。3つ目は、近似で何を捨てたかである。写真には細かなざらつきもある。少数の軸で近似したとき、何を残し、何を捨てたことになるのか。

本章の問いは、 $\mathbf{X}$ 自身を少数の軸で近似するとき、 $\mathbf{F}$ と $\mathbf{A}$ をどう求めるか、である。以下ではまず、2列の人工データで近似の形を見て、目的関数と制約を書き直し、列の平均を引く理由を確かめる。次に特異値分解を道具として用意し、データ行列をちょうど分解する。その分解の上位の分を残すことが、主成分分析の答えになることを示す。最後に、捨てた分が何を意味するか、答えの何が決まり何が決まらないかを確かめる。

点の雲を直線で近似する

もっと簡単な場面として、2列の人工データで、少数の軸で近似するとはどういうことかを見る。図2(a)の40点は、食パン40枚の焼き時間と焦げ目の濃さとして作り、列の平均を0にしてある。行 i の点を $\tilde{\mathbf{x}}_i = [x_{i1}, x_{i2}]^\top$ と書く。原点を通り長さ1の向き $\mathbf{a}$ を持つ直線(赤)を1本引き、各点をその直線の上の点 $f_i\mathbf{a}$ (青)で近似する。 f_i は直線の上の位置を表す1つの数である。2つの数 x_{i1}, x_{i2} を、1つの数 f_i で言い表したことになる。近似の誤差は $\tilde{\mathbf{x}}_i - f_i\mathbf{a}$ (灰色の線)である。この線は、第1回の回帰のような縦の向きではなく、直線に垂直な向きに下ろした線になる。回帰では x_1 は与えられていて x_2 だけに誤差があったが、ここでは2つの列を対等に近似するからである。

近似のよさは、直線の向きで変わる。図2(b)のように向きを160度にとると垂線は長くなり、誤差の二乗和は(a)の7.0から54.4に増える。




図2: 点の雲を1本の直線で近似する(人工データ、食パン40枚の焼き時間と焦げ目)。赤は長さ1の向き $\mathbf{a}$ の直線、青は近似 $f_i\mathbf{a}$ 、灰色は誤差。(a) 点の雲に沿った向き、(b) 160度の向き

列が p 個、軸が Q 本の場合も同じである。行 i の軸 m の上の位置を f_{im} 、軸 m の向きを $\mathbf{a}_m \in \mathbb{R}^p$ とし、それ

それを並べて $\mathbf{F} \in \mathbb{R}^{n \times Q}$ と $\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_Q] \in \mathbb{R}^{p \times Q}$ を作る。データ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ は、図 3 のように 2 つの行列の積 $\mathbf{F}\mathbf{A}^\top$ で近似される。第 1 回の「データ＝モデル＋誤差」の形に書けば

$$\mathbf{X} = \mathbf{F}\mathbf{A}^\top + \mathbf{E} \quad (1)$$

である。回帰のモデル $\mathbf{X}\beta$ では $\mathbf{X}$ が与えられていて未知は β だけだったが、(1) 式のモデルは未知の $\mathbf{F}$ と $\mathbf{A}$ の積になっている。




図 3: 主成分分析のモデルの型(概念図)。 $n \times p$ の $\mathbf{X}$ を、 $n \times Q$ の $\mathbf{F}$ と $Q \times P$ の $\mathbf{A}^\top$ の積で近似する

目的関数と制約

(1) 式の誤差 $\mathbf{E}$ の大きさを、スカラー・ベクトル・行列の順に書く。まず軸が 1 本 ($Q = 1$) のとき、マス x_{ij} は行の位置 f_i と軸の向きの第 j 成分 a_j の積 $f_i a_j$ で近似される。目的関数は $n \times p$ 個の誤差の二乗和

$$J = \sum_{i=1}^n \sum_{j=1}^p (x_{ij} - f_i a_j)^2 \quad (2)$$

である。軸が Q 本なら、マス x_{ij} は Q 本の軸の組み合わせ $\sum_m f_{im} a_{jm}$ で近似され、

$$J = \sum_{i=1}^n \sum_{j=1}^p \left(x_{ij} - \sum_{m=1}^Q f_{im} a_{jm} \right)^2 = \sum_{i=1}^n \left\| \tilde{\mathbf{x}}_i - \mathbf{A} \tilde{\mathbf{f}}_i \right\|_2^2 \quad (3)$$

となる。 $Q = 1$ とおけば (2) 式に戻る。2 つ目の等号では、 $\mathbf{F}$ の第 i 行を縦に並べた $\tilde{\mathbf{f}}_i \in \mathbb{R}^Q$ を使い、内側の j についての和を行ベクトルの距離の二乗にまとめた。 $\mathbf{A} \tilde{\mathbf{f}}_i$ の第 j 成分が $\sum_m a_{jm} f_{im}$ だからである。さらに行を縦に積む。 $\mathbf{X} - \mathbf{F}\mathbf{A}^\top$ の第 i 行は $(\tilde{\mathbf{x}}_i - \mathbf{A} \tilde{\mathbf{f}}_i)^\top$ であるから、第 8 回のフロベニウスノルムを使って

$$J(\mathbf{F}, \mathbf{A}) = \left\| \mathbf{X} - \mathbf{F}\mathbf{A}^\top \right\|_F^2 \quad (4)$$

と書ける。これが第 8 回で並べた主成分分析の目的関数である。

(4) 式だけでは、答えが 1 つに決まらない。(2) 式で、ある $c \neq 0$ について f_i をすべて c 倍し、 a_j をすべて $1/c$ 倍しても、積 $f_i a_j$ は変わらず J も変わらない。倍率を $\mathbf{F}$ と $\mathbf{A}$ の間で押し付け合えるのである。そこで $\mathbf{A}$ の列に、長さ 1 で互いに直角という条件

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q \quad (5)$$

を付ける(正規直交制約)。 $\mathbf{A}^\top \mathbf{A}$ の (m, r) 成分は $\mathbf{a}_m^\top \mathbf{a}_r$ である。対角が 1 なら各軸の長さが 1 で、対角の外が 0 なら軸どうしは直角になる。 $Q = 1$ では $\|\mathbf{a}\|_2 = 1$ 、すなわち 図 2 の赤い直線の向きを長さ 1 で表すことにあたる。

定義 1 (主成分分析). データ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ が与えられたとき、制約 (5) 式のもとで目的関数 (4) 式を最小にする $\mathbf{F}$ と $\mathbf{A}$ を求めることを主成分分析(principal component analysis)という。 $\mathbf{F} \in \mathbb{R}^{n \times Q}$ を主成分得点行列(各行の、軸の上の位置)、 $\mathbf{A} \in \mathbb{R}^{p \times Q}$ を主成分負荷量行列(変数と軸の関係)と呼ぶ。

列の平均を引く

ここまでの直線は、いつも原点を通っていた。(4) 式のモデル $\mathbf{F}\mathbf{A}^\top$ には定数の項が無いからである。点の雲の中心が原点から離れているとどうなるかを、直感の 40 点を $(2.5, -2.5)$ だけずらした人工データで見る(図 4 (a))。原点を通る直線で誤差の二乗和を最小にすると、直線は雲の中心のほうを向き、雲が伸びる向きはとらえられない。誤差の二乗和は 68.2 になる。

そこで、列ごとに平均 $\bar{x}_j = \frac{1}{n} \sum_i x_{ij}$ を引いて、雲の中心を原点に移す。これを中心化(centering)と呼ぶ。行列で書けば、すべての成分が 1 の列 $\mathbf{1} \in \mathbb{R}^n$ と列の平均を並べた $\bar{\mathbf{x}} \in \mathbb{R}^p$ を使って $\mathbf{X} - \mathbf{1}\bar{\mathbf{x}}^\top$ である。中心化してから近似すると、直線は雲の伸びる向きに沿い、誤差の二乗和は 7.0 に下がる(図 4 (b))。元のデータに戻して書けば $\mathbf{X} \approx \mathbf{1}\bar{\mathbf{x}}^\top + \mathbf{F}\mathbf{A}^\top$ であり、平均の行は別に持ち、平均からの散らばりだけを少数の軸で近似していることになる。以下では、 $\mathbf{X}$ は中心化したものとする。

交互に解かずに 1 回で

回帰の目的関数では未知は β だけであり、勾配を 0 とおいた正規方程式を 1 回解けば答えが出た(第 1 回)。(4) 式では $\mathbf{F}$ と $\mathbf{A}$ がどちらも未知で、モデルはその積になっている。このままでは、勾配を 0 とおいて 1 回で解く方法は使えない。そこで見方を変えて、データ行列 $\mathbf{X}$ そのものを、どんな行列にも使える分解で 3 つの行列の積に分ける。その分解の上位の分を残すことが、主成分分析の答えになる。そのための道具を次に用意する。

道具：トレースと特異値分解

行列のまま計算するための道具を用意する。




図 4: 中心化(人工データ、2 列・40 点)。(a) 点の雲を原点から離れたまま、原点を通る直線で近似したもの、(b) 列の平均を引いてから近似したもの。十字は原点

1 つ目は、第 4 回で有効自由度を求めるときに使ったトレースである。 $p \times p$ の正方行列 $\mathbf{M}$ の対角成分の和 $\text{tr}(\mathbf{M}) = \sum_j m_{jj}$ をトレース(trace)と呼んだ。行列の積 $\mathbf{BC}$ ($\mathbf{B} \in \mathbb{R}^{n \times p}$ 、 $\mathbf{C} \in \mathbb{R}^{p \times n}$)について

$$\text{tr}(\mathbf{BC}) = \text{tr}(\mathbf{CB}), \quad \text{tr}(\mathbf{M}) = \text{tr}(\mathbf{M}^\top) \quad (6)$$

が成り立つ。どちらも成分で書けば $\sum_i \sum_j b_{ij} c_{ji}$ であり、転置は対角成分を変えないからである。3 つ以上の積でも、順番を回して並べ直してよい。さらに、 $\mathbf{M} \in \mathbb{R}^{n \times p}$ について $\mathbf{M}^\top \mathbf{M}$ の第 j 対角成分は第 j 列の二乗和であるから

$$\|\mathbf{M}\|_F^2 = \sum_{i=1}^n \sum_{j=1}^p m_{ij}^2 = \text{tr}(\mathbf{M}^\top \mathbf{M}) \quad (7)$$

となる。第 8 回で定義したフロベニウスノルムの二乗が、トレースで書けた。

2 つ目は特異値分解(singular value decomposition)である。 $n \times p$ ($p \leq n$)のどんな行列 $\mathbf{X}$ も

$$\mathbf{X} = \mathbf{K} \mathbf{\Delta} \mathbf{L}^\top, \quad \mathbf{K}^\top \mathbf{K} = \mathbf{I}_p, \quad \mathbf{L}^\top \mathbf{L} = \mathbf{L} \mathbf{L}^\top = \mathbf{I}_p \quad (8)$$

と書ける(定義 2)。 $\mathbf{K} \in \mathbb{R}^{n \times p}$ を左特異行列、 $\mathbf{L} \in \mathbb{R}^{p \times p}$ を右特異行列、対角行列 $\mathbf{\Delta}$ の対角成分 $\delta_1 \geq \delta_2 \geq \dots \geq \delta_p \geq 0$ を特異値と呼ぶ。 $\mathbf{K}$ は列が長さ 1 で互いに直交な縦長の行列、 $\mathbf{L}$ は正方の正規直交行列である。 $\mathbf{L}$ は正方なので $\mathbf{L} \mathbf{L}^\top = \mathbf{I}_p$ も成り立つが、 $\mathbf{K}$ は縦長なので $\mathbf{K} \mathbf{K}^\top = \mathbf{I}_n$ は成り立たない。特異値分解は近似ではなく、 $\mathbf{X}$ をちょうど 3 つの積に分ける。

定義 2 (特異値分解). 行列 $\mathbf{X}$ を (8) 式の形 $\mathbf{K} \mathbf{\Delta} \mathbf{L}^\top$ に書くことを特異値分解と呼ぶ。 $\mathbf{K}$ と $\mathbf{L}$ は列が長さ 1 で互いに直交な行列、 $\mathbf{\Delta}$ は特異値を降順に並べた対角行列である。

2 列で見る特異値分解

データ行列そのものを特異値分解すると何が出てくるかを、点の雲の節の食パン 40 枚で見る(図 5)。列の平均は 0 である。この 40×2 の行列を $\mathbf{X} = \mathbf{K}\mathbf{\Delta}\mathbf{L}^\top$ と分解する。 $\mathbf{K}$ は 40×2 、 $\mathbf{\Delta}$ は特異値 $\delta_1 \geq \delta_2$ を並べた 2×2 の対角行列、 $\mathbf{L} = [l_1, l_2]$ は 2×2 である。 l_1 と l_2 は長さ 1 で互いに直角な 2 本の向きになる(図 5 (a))。 l_1 は点の雲の長い向き、 l_2 はそれに直角な向きである。分解の両辺に右から $\mathbf{L}$ を掛けると、 $\mathbf{L}^\top \mathbf{L} = \mathbf{I}$ から

$$\mathbf{XL} = \mathbf{K}\mathbf{\Delta} \quad (9)$$

となる。 $\mathbf{XL}$ の第 i 行 ($\tilde{x}_i^\top l_1, \tilde{x}_i^\top l_2$) は、点 i の座標を l_1 と l_2 の向きで測り直したものである。これが $(\delta_1 k_{i1}, \delta_2 k_{i2})$ に等しい。特異値分解は、点の雲を見る座標軸を、長い向きから順に取り直す操作である。




図 5: 2 列の人工データ(食パン 40 枚の焼き時間と焦げ目)の特異値分解。(a) $\mathbf{L}$ の 2 本の向き、(b) 上位 1 本 l_1 だけを残した近似(青)と、捨てた l_2 の分の誤差(紫)

ここで l_1 の座標だけを残し、 l_2 の座標を捨てる。点 i は $\delta_1 k_{i1} l_1$ 、すなわち赤い直線の上の青い点で近似される(図 5 (b))。これは 図 2 の直線の上の近似と同じ形である。誤差は捨てた分 $\delta_2 k_{i2} l_2$ であり、その二乗和は $\delta_2^2 \sum_i k_{i2}^2 = \delta_2^2 = 6.98$ になる($\mathbf{K}$ の列は長さ 1)。分解して 1 本捨てるだけで、1 本の直線による近似とその誤差が出た。

道具：ランク

2 列の例で見たことを一般の $n \times p$ のデータ行列で確かめるために、道具をあと 2 つ用意する。

1 つ目はランク(rank)である。行列 $\mathbf{Y} \in \mathbb{R}^{n \times p}$ の 0 でない特異値の個数を $\mathbf{Y}$ のランクと呼び、 $\text{rank}(\mathbf{Y})$ と書く(定義 3)。ランクが Q 以下であることは、 $\mathbf{Y}$ のすべての行が Q 本の向きの組み合わせで書けることと同じである。その Q 本の向きを長さ 1 で互いに直角にそろえて $\mathbf{A} \in \mathbb{R}^{p \times Q}$ ($\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$) とし、各行の組み合わせの重みを $\mathbf{F} \in \mathbb{R}^{n \times Q}$ に並べれば

$$\text{rank}(\mathbf{Y}) \leq Q \iff \mathbf{Y} = \mathbf{F}\mathbf{A}^\top \quad (\mathbf{F} \in \mathbb{R}^{n \times Q}, \mathbf{A} \in \mathbb{R}^{p \times Q}, \mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q) \quad (10)$$

と書ける。 $Q = 1$ なら、どの行も 1 本の向き $\mathbf{a}$ の定数倍 $f_i \mathbf{a}$ である。図 5 (b) の青い点を並べた 40×2 の行列がその例で、ランクは 1 になる。主成分分析の近似 $\mathbf{F}\mathbf{A}^\top$ は、ランクが Q 以下の行列である。

2 つ目は、列が長さ 1 で互いに直角な行列を掛けても、フロベニウスノルムが変わらないことである。 $\mathbf{K}^\top \mathbf{K} = \mathbf{I}$ なら、(7) 式から

$$\|\mathbf{K}\mathbf{M}\|_F^2 = \text{tr}(\mathbf{M}^\top \mathbf{K}^\top \mathbf{K} \mathbf{M}) = \text{tr}(\mathbf{M}^\top \mathbf{M}) = \|\mathbf{M}\|_F^2 \quad (11)$$

となる。右から $\mathbf{L}^\top$ ($\mathbf{L}^\top \mathbf{L} = \mathbf{I}$) を掛けたときも、(6) 式で順番を回せば $\mathbf{L}^\top \mathbf{L}$ が隣り合って消える。2 次元でベクトルを回しても長さが変わらないことの、行列版である。(8) 式に使うと、 $\mathbf{K}$ と $\mathbf{L}^\top$ が両方消えて

$$\|\mathbf{X}\|_F^2 = \|\Delta\|_F^2 = \sum_{m=1}^p \delta_m^2 \quad (12)$$

を得る。データ行列の全マスの二乗和は、特異値の二乗和に等しい。

定義 3 (ランク). 行列の 0 でない特異値の個数を、その行列のランクと呼ぶ。ランクが Q 以下の行列は、 Q 本の向きの組み合わせで全行が書ける行列であり、(10) 式の形 $\mathbf{F}\mathbf{A}^\top$ に書ける。

X を上位と残りに分ける

(8) 式を、スカラー・ベクトル・行列の順に書き下す。まず 1 マスずつ書くと、

$$x_{ij} = \sum_{m=1}^p \delta_m k_{im} l_{jm} \quad (13)$$

である。マス x_{ij} は、向き m ごとの「行の位置 $\delta_m k_{im}$ × 向きの成分 l_{jm} 」を p 本分足したものである。どの項も、(2) 式の $f_i a_j$ と同じ形をしている。

次に、向き m の項をまとめて行列にすると

$$\mathbf{X} = \sum_{m=1}^p \delta_m \mathbf{k}_m \mathbf{l}_m^\top \quad (14)$$

となる。 $\mathbf{k}_m \in \mathbb{R}^n$ と $\mathbf{l}_m \in \mathbb{R}^p$ はそれぞれ $\mathbf{K}$ と $\mathbf{L}$ の第 m 列である。 $\mathbf{k}_m \mathbf{l}_m^\top$ は、どの行も $\mathbf{l}_m$ の定数倍になっている $n \times p$ の行列、すなわちランク 1 の行列である。その全マスの二乗和は $\|\mathbf{k}_m\|_2^2 \|\mathbf{l}_m\|_2^2 = 1$ なので、 $\mathbf{X}$ は大きさ 1 の p 枚の行列に重み δ_m を付けて重ねたものと読める。

最後に、 $\mathbf{K}$ を左から Q 列の $\mathbf{K}_1 \in \mathbb{R}^{n \times Q}$ と残りの $\mathbf{K}_2 \in \mathbb{R}^{n \times (p-Q)}$ に分ける。 $\mathbf{L}$ も同じく $\mathbf{L}_1 \in \mathbb{R}^{p \times Q}$ と $\mathbf{L}_2 \in \mathbb{R}^{p \times (p-Q)}$ に、 Δ も上位 Q 個の Δ_1 と残りの Δ_2 に分ける。列で分けても列の正規直交性は保たれ、 $\mathbf{K}_1^\top \mathbf{K}_1 = \mathbf{L}_1^\top \mathbf{L}_1 = \mathbf{I}_Q$ 、 $\mathbf{K}_2^\top \mathbf{K}_2 = \mathbf{L}_2^\top \mathbf{L}_2 = \mathbf{I}_{p-Q}$ である。(14) 式の和を $m \leq Q$ と $m > Q$ に分けたものを行列で書けば

$$\mathbf{X} = [\mathbf{K}_1, \mathbf{K}_2] \begin{bmatrix} \Delta_1 & \\ & \Delta_2 \end{bmatrix} [\mathbf{L}_1, \mathbf{L}_2]^\top = \mathbf{K}_1 \Delta_1 \mathbf{L}_1^\top + \mathbf{K}_2 \Delta_2 \mathbf{L}_2^\top = \mathbf{X}_1 + \mathbf{X}_2 \quad (15)$$

となる。 $\mathbf{X}$ 、 $\mathbf{X}_1$ 、 $\mathbf{X}_2$ はどれも $n \times p$ の行列であり、 $\mathbf{X}_1$ は上位 Q 枚、 $\mathbf{X}_2$ は残りの枚を重ねたものである(図 6)。 $\mathbf{X}_1$ は $n \times Q$ の $\mathbf{K}_1 \Delta_1$ と $p \times Q$ の $\mathbf{L}_1^\top$ の積なので、 np 個のマスを持つのに $(n+p)Q$ 個の数で足りる。




図 6: データ行列の特異値分解を、上位 Q 本(青)と残り(紫)に分けたもの。箱の縦は行の数、横は列の数。積でそろふ次元を赤で示す

低ランク近似と Eckart–Young の定理

(15) 式の $\mathbf{X}_1$ はランク Q 以下の行列である。だが、ランク Q 以下の行列はほかにも無数にある。その中で $\mathbf{X}$ に最も近いのはどれか。行列の大きさは $n \times p$ のままで、ランクだけを Q 以下に落とし、 $\mathbf{X}$ に最も近い行列を探す問題を考える。1 マスずつ書けば、目的関数は $\sum_i \sum_j (x_{ij} - y_{ij})^2$ であり、第 1 回からの最小二乗法の形そのものである。行列で書けば

$$\min_{\mathbf{Y}} \|\mathbf{X} - \mathbf{Y}\|_F^2 \quad \text{ただし } \text{rank}(\mathbf{Y}) \leq Q \quad (16)$$

である。 $\mathbf{X}$ のランクはふつう p である。それより低いランクの行列で近似するので、(16) 式を低ランク近似 (low-rank approximation) の問題と呼ぶ(定義 4)。特異値が降順に並んでいるとき、(16) 式を最小にする $\mathbf{Y}$ は

$$\hat{\mathbf{Y}} = \mathbf{K}_1 \mathbf{\Delta}_1 \mathbf{L}_1^\top \quad (17)$$

であり、(15) 式の $\mathbf{X}_1$ 、すなわち上位 Q 枚を重ねただけの行列である (Eckart and Young, 1936)。(16) 式の問題と (17) 式の答えを合わせて Eckart–Young の定理 (Eckart–Young theorem) (Eckart–Young–Mirsky の定理) と呼ぶ (定理 1)。 $\delta_Q > 0$ なら $\text{rank}(\hat{\mathbf{Y}}) = Q$ である。

定理 1 (Eckart–Young の定理). $\mathbf{X} \in \mathbb{R}^{n \times p}$ ($p \leq n$) の特異値分解を (15) 式のように上位 Q 個と残りに分ける。ランクが Q 以下という条件のもとで $\|\mathbf{X} - \mathbf{Y}\|_F^2$ を最小にする $\mathbf{Y}$ は $\hat{\mathbf{Y}} = \mathbf{K}_1 \mathbf{\Delta}_1 \mathbf{L}_1^\top$ である。

ここで

$$\mathbf{F} = \mathbf{K}_1 \mathbf{\Delta}_1, \quad \mathbf{A} = \mathbf{L}_1, \quad \mathbf{E} = \mathbf{K}_2 \mathbf{\Delta}_2 \mathbf{L}_2^\top \quad (18)$$

とおくと、 $\mathbf{A}^\top \mathbf{A} = \mathbf{L}_1^\top \mathbf{L}_1 = \mathbf{I}_Q$ で主成分分析の制約を満たし、

$$\|\mathbf{X} - \mathbf{K}_1 \mathbf{\Delta}_1 \mathbf{L}_1^\top\|_F^2 = \|\mathbf{X} - \mathbf{F} \mathbf{A}^\top\|_F^2 = \|\mathbf{E}\|_F^2$$

と書ける。(10) 式のとおり、ランクが Q 以下の行列は $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$ を満たす $\mathbf{F} \mathbf{A}^\top$ の形の行列と同じものである。したがって、低ランク近似の問題と主成分分析の問題は同じ問題であり、データ行列の特異値分解によって主成分分析のパラメータを求めることができる。目的関数の最小値は、(11) 式で $\mathbf{K}_2$ と $\mathbf{L}_2^\top$ を消して

$$\min J = \|\mathbf{K}_2 \mathbf{\Delta}_2 \mathbf{L}_2^\top\|_F^2 = \|\mathbf{\Delta}_2\|_F^2 = \sum_{m=Q+1}^p \delta_m^2 \quad (19)$$

となる。捨てた特異値の二乗和である。2 列の食パンの例 ($p = 2$, $Q = 1$) では、捨てるのは δ_2 だけであり、図 5 (b) の紫の線の二乗和 δ_2^2 がこれにあたる。未知が 2 つの積であっても、データ行列を 1 回特異値分解し、上位 Q 本を取り出すだけで答えが出る。

定義 4 (低ランク近似). 行列 $\mathbf{X}$ を、大きさは同じでランクが Q 以下の行列 $\mathbf{Y}$ で、 $\|\mathbf{X} - \mathbf{Y}\|_F^2$ が最小になるように近似することを、低ランク近似と呼ぶ。

計算の手順

主成分分析の計算を、Eckart–Young の定理に従って行列の形で手順にまとめる。

1. 列の平均を 0 にしたデータ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ と、軸の数 Q を用意する
2. $\mathbf{X}$ を 1 回特異値分解し、 $\mathbf{X} = \mathbf{K} \mathbf{\Delta} \mathbf{L}^\top$ を得る
3. $\mathbf{L}$ の左から Q 列を $\mathbf{L}_1$ とし、 $\mathbf{A} \leftarrow \mathbf{L}_1$ 、 $\mathbf{F} \leftarrow \mathbf{X} \mathbf{A}$ とする。(9) 式により $\mathbf{F} = \mathbf{K}_1 \mathbf{\Delta}_1$ である
4. 目的関数の値は、(19) 式により $J = \sum_{m>Q} \delta_m^2$ である

初期値の設定も、反復も、収束判定も要らない。分解は Q によらない。軸の数を変えて比べるときも、特異値分解をやり直さずに、 $\mathbf{L}$ から取る列の数を変えるだけでよい。

理論の帰結：捨てた分と決まらない分

(18) 式の答えから、3 つのことが言える。

第 1 に、目的関数の最小値は捨てた特異値の二乗和 (19) 式である。図 7 は、3 列・60 点の人工データの特異値の二乗である。このデータは、ホットケーキ 60 枚の直径・厚さ・重さを、平均を引いて並べたものとして作った点で、2 本の軸でほぼ表せる。 $Q = 2$ なら、灰色の 3 本目 1.27 がそのまま J である。軸を 1 本増やすごとに、 J は次の特異値の二乗だけ下がる。




図 7: 3 列・60 点の人工データの特異値の二乗 δ_m^2 。 $Q = 2$ では青を残し、灰を捨てる。灰の高さが目的関数の最小値

第 2 に、特異値の小さい層は、ノイズとみなして捨てられる。図 8 は、10 台の温度計で測った 100 日分の記録として作った人工データである。本当の信号は 2 つの模様の組み合わせ(ランク 2)で、そこに温度計ごとの測りむらを足した。 $\mathbf{X}$ を特異値分解すると、特異値の二乗は 2 つだけが大きく、残り 8 つは小さくほぼ平らに並ぶ(図 8 (a))。軸の数 Q を増やすと、 $\mathbf{X}$ との誤差 J は下がり続け、 $Q = 10$ で 0 になる。一方、人工データなので本当の信号がわかっており、近似と本当の信号との誤差も測れる。こちらは $Q = 2$ で最小(50.7)になり、それより多く残すと測りむらまで写し取って、本当の信号から離れていく(図 8 (b))。 $\mathbf{X}$ をちょうど再現することは、本当の信号に近づくこととは違う。特異値の大きい層はデータの大きな模様を、小さい層は小さな揺れを受け持つ。小さい層を捨てることは、その揺れをノイズとみなして捨てることにあたる。話を要約するとき、大事な順に数行を残せば筋は伝わり、言いよどみまで書き写すとかえって筋から離れるのと同じである。

近似が全体のどれだけを表したかは、割合で読める。(12) 式と (19) 式から

$$\frac{\sum_{m \leq Q} \delta_m^2}{\sum_m \delta_m^2} = 1 - \frac{J}{\|\mathbf{X}\|_F^2} \quad (20)$$

を上位 Q 本の累積寄与率(cumulative contribution ratio)と呼び、1 本ずつの $\delta_m^2 / \sum_{m'} \delta_{m'}^2$ を軸 m の寄与




図 8: 10 台の温度計の 100 日分の人工データ(本当の信号はランク 2、そこに測りむらを足した)。(a) 特異値の二乗、(b) 残す軸の数 Q と、 $\mathbf{X}$ との誤差 J (黒)・本当の信号との誤差(赤)

率(contribution ratio)と呼ぶ(定義 5)。累積寄与率は、 J が全体に占める割合の裏返しである。特異値の二乗を大きい順に並べて線をつないだ図をスクリープロット(scrie plot)と呼ぶ(図 9)。温度計のデータでは、2 本の後で急に平らになる。急に平らになる手前を肘と呼び、肘までを残すのが軸の数の 1 つの目安である。温度計では 2 本で累積寄与率は 84.2% になり、本当の信号に最も近かった Q と一致する。平らな部分は、小さい層(ノイズ)が並んだところである。




図 9: 温度計 10 台の人工データのスクリープロット。青の 2 本が肘の手前

定義 5 (寄与率とスクリープロット). 特異値の二乗 δ_m^2 の合計に対する割合を軸 m の寄与率、上位 Q 本の割合を累積寄与率と呼ぶ。特異値の二乗を大きい順に並べた図をスクリープロットと呼ぶ。

第 3 に、答えは軸を回す自由を残す。 $\mathbf{R}$ を $Q \times Q$ の正規直交行列($\mathbf{R}^\top \mathbf{R} = \mathbf{R} \mathbf{R}^\top = \mathbf{I}_Q$)とし、 $\mathbf{F}$ を $\mathbf{F} \mathbf{R}$ に、 $\mathbf{A}$ を $\mathbf{A} \mathbf{R}$ に替えると

$$(\mathbf{F} \mathbf{R})(\mathbf{A} \mathbf{R})^\top = \mathbf{F} \mathbf{R} \mathbf{R}^\top \mathbf{A}^\top = \mathbf{F} \mathbf{A}^\top, \quad (\mathbf{A} \mathbf{R})^\top (\mathbf{A} \mathbf{R}) = \mathbf{R}^\top \mathbf{A}^\top \mathbf{A} \mathbf{R} = \mathbf{I}_Q \quad (21)$$

であり、近似も制約も目的関数も変わらない。 $Q = 2$ の $\mathbf{R}$ は角 θ の回転か、裏返しを含む形のどちらかであり、 $Q = 1$ なら $\mathbf{R} = \pm 1$ 、すなわち向きの反転である。第 8 回で k-means の群の番号を付け替えても J が変わ

らなかったのと同じ性質である。制約 (5) 式は倍率の押し付け合いを止めたが、回転までは止めない。図 10 は、ホットケーキの得点を 40 度回したもので、 J は同じ 1.27 である。特異値分解の答え (18) 式は、その中の 1 つを選ぶ。 $\mathbf{F}^T \mathbf{F} = \Delta_1 \mathbf{K}_1^T \mathbf{K}_1 \Delta_1 = \Delta_1^2$ なので得点の列どうしは直交し(相関 0.00)、得点 1 の二乗和が最も大きく、以下 δ_m の順に並ぶ。回した得点では相関が -0.79 残る。特異値がすべて異なれば、残る自由は各軸の向きの反転だけである。さらに、 $Q = 1$ の答え $\mathbf{l}_1$ は $Q = 2$ の答え $\mathbf{L}_1$ の第 1 列そのものであるから、軸を 1 本足しても前の軸は変わらない。




図 10: ホットケーキの人工データの得点 $\mathbf{F}$ ($Q = 2$)。 (a) 特異値分解の答え、 (b) それを 40 度回したもの。 J は同じ。色の 3 点は同じ行

地図の中の主成分分析

表 1 は、第 8 回で並べた 3 つの目的関数に解き方を添えたものである。回帰は正規方程式を 1 回解けば済んだ。主成分分析も、未知の行列どうしの積を含むにもかかわらず、データ行列の特異値分解を 1 回計算すれば済む。本章で解いたのは主成分分析の行である。

表 1: 3 つの目的関数と解き方

モデル	近似する相手	目的関数	解き方	回
線形回帰	y	$\ \mathbf{y} - \mathbf{X}\beta\ _2^2$	正規方程式を 1 回解く	第 1 回
主成分分析	$\mathbf{X}$	$\ \mathbf{X} - \mathbf{F}\mathbf{A}^T\ _F^2$	特異値分解を 1 回	第 9・10 回
k-means	$\mathbf{X}$	$\ \mathbf{X} - \mathbf{G}\mathbf{C}\ _F^2$	交互に解く	第 11 回

第 II 部 実データ解析

写真と手続き

第 II 部では、第 I 部の理論を写真 1 枚で試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、次の 2 つを予想できる。目的関数の最小値は捨てた特異値の二乗和 (19) 式であり、累積寄与率 (20) 式はその裏返しだった。ホットケーキの 3 列の人工データでは、2 本の軸で累積寄与率が 99.6% に達した。写真も、数本の軸で累積寄与率がほぼ 100% になり、スクリープロットに肘が出るはずである。また、特異値分解の答えは、1 枚目に最もよい 1 本を置き、以下 δ_m の順に並べる。写真でも、1 枚目から番号の順に、大きな明暗を受け持つはずである。

写真は scikit-learn に付いている見本の写真 china.jpg (danielbuechele 氏の撮影、CC BY 2.0) である。これを白黒にして、明るさを黒 0・白 1 の数にした。行の数が列の数以上になるよう、左の 400 列を切り出した。画素の行 427 を行、画素の列 400 を列とする行列から各列の平均を引き、 $\mathbf{X}$ とした。どの列も同じ明るさの目盛りで測っているので、標準化はしない。

手続きは次のとおりである。I-6 の手順で $\mathbf{X}$ を NumPy の特異値分解で 1 回分解し、400 個の特異値と $\mathbf{K}$ 、 $\mathbf{L}$ を得た。 Q を 1、5、20、50 と変えて近似 $\mathbf{F}\mathbf{A}^\top$ を作り、列の平均を足し戻して写真として見た。 $Q = 0$ から 100 までの J と累積寄与率、スクリープロットも、同じ分解から求めた。最後に、列の平均を引かない写真そのものも同じように分解した。

結果：数本の軸で足りるか

図 11 は、 Q を 1、5、20、50 と増やしたときの近似 $\mathbf{F}\mathbf{A}^\top$ に列の平均を足し戻した写真と、誤差 $\mathbf{E} = \mathbf{X} - \mathbf{F}\mathbf{A}^\top$ である (誤差は赤が明るすぎ、青が暗すぎ)。 $Q = 1$ の近似は、(14) 式の 1 枚 $\delta_1 \mathbf{k}_1 \mathbf{l}_1^\top$ だけである。どの行も同じ $\mathbf{l}_1$ の定数倍なので、横の縞と縦の縞を掛け合わせた模様しか描けない。 $Q = 5$ で塔と空と水面の大きな明暗が現れ、 $Q = 20$ で屋根の段が分かれ、 $Q = 50$ ではほぼ元の写真に戻る。誤差は、 Q が増えるにつれて大きな明暗から木の葉や輪郭の細部へ移っていく。 $Q = 50$ の近似を保つのに要する数は $\mathbf{F}$ と $\mathbf{A}$ の $(n+p)Q = 41,350$ 個で、元の 170,800 個の 24% にあたる。

図 13 の線は、(19) 式の $\sum_{m>Q} \delta_m^2$ を $Q = 0$ から 100 まで並べたもので、 $Q = 0$ の値は $\|\mathbf{X}\|_F^2 = 11,948.8$ である。各 Q の誤差の二乗和を直接計算した値 ($Q = 1, 5, 20, 50$ で 5,699.3、2,599.1、1,354.3、688.4) も、この線に重なる。軸を 1 本増やすごとに、 J は次の特異値の二乗 δ_{Q+1}^2 だけ下がる。はじめの数本で大きく下がり、あとはゆっくり下がる。累積寄与率で読むと、 $Q = 1, 5, 20, 50$ で 52.3%、78.2%、88.7%、94.2% である。2 本では 70.4% にとどまり、90% に届くのは $Q = 25$ 、99% に届くのは $Q = 155$ である。スクリープロット (図 12) も、はじめの数本で急に下がった後、はっきりした肘を見せずにゆっくり下がりが続ける。数本でほぼ 100% になり肘が出るという予想は外れた。




図 11: 写真の低ランク近似。各行の左から、元の写真、上位 Q 本の近似に列の平均を足したもの、誤差 $\mathbf{X} - \mathbf{F}\mathbf{A}^T$ (赤は明るすぎ、青は暗すぎ)。上から $Q = 1, 5, 20, 50$




図 12: 写真の $\mathbf{X}$ のスクリープロット(上位 40 本の δ_m^2)

なお、特異値分解なら 1 回の分解から、すべての Q の答えと J が出る。




図 13: 写真の $\mathbf{X}$ の目的関数の最小値 $J = \sum_{m>Q} \delta_m^2$ (線)と、近似の誤差を直接計算した値(赤い丸、 $Q = 1, 5, 20, 50$)

外れた理由は、(19) 式の和の中身を見るとわかる(表 2)。ホットケーキでは、3 本目の寄与率は 0.4% しかなく、捨てる分はこの 1 本だけだった。写真でも、3 本目以降の寄与率は 1 本ずつは小さく、最大でも 3.4% である。ところが写真には捨てる軸が 398 本あり、 J はそのすべての和になる。合計すると 29.6% が残る。ホットケーキは、2 本の向きに小さなずれを足して作ったデータだった。写真には、そうした決まった数の向きがない。誤差に残った葉や輪郭のような細かな模様は、 δ_m^2 の小さい多くの軸に少しずつ散っている。第 I 部の温度計の測りむらと同じ散り方であり、小さい層を捨てた近似は、こうした細部をノイズとして手放している。

表 2: 上位 2 本の累積寄与率と、3 本目以降の寄与率(ホットケーキは第 I 部の人工データ)

	列の数	上位 2 本の累積寄与率	3 本目以降の 1 本 (最大)	3 本目以降の合計
ホットケーキ(第 I 部)	3	99.6%	0.4%	0.4%
写真	400	70.4%	3.4%	29.6%

結果：1 枚ずつの模様

2 つ目の予想は、上位の枚が写真の大きな明暗を受け持つことだった。図 14 は、(14) 式の 1 枚ずつ $\delta_m \mathbf{k}_m \mathbf{l}_m^\top$ を $m = 1$ から 4 まで並べたものである(色の濃さは枚ごとにそろえた)。1 枚目は空と塔・木の明暗の大きな区切りを受け持ち、番号が進むにつれてより細かい明暗の区切りを受け持つ。それぞれの枚の二乗和は δ_m^2 で、番号の順に小さくなる。予想どおりである。特異値分解の答えは、1 枚目に最もよい 1 本を、2 枚目に次により 1 本を置く。




図 14: 特異値分解の 1 枚ずつの模様 $\delta_m \mathbf{k}_m \mathbf{l}_m^\top$ (赤は正、青は負)。 $m = 1 \sim 4$

落とし穴：列の平均を引かないと

最後に、本章の手順の 1 段階「列の平均を 0 にする」を省くとどうなるかを見る。写真の明るさはどこも 0 以上なので、平均を引かない写真そのものを分解すると、1 枚目 $\delta_1 \mathbf{k}_1 \mathbf{l}_1^\top$ は写真全体の明るさの大まかな形を受け持つ。図 15 のとおり、 $\mathbf{l}_1$ は列の平均の明るさとほぼ同じ形(相関 0.997)、 $\mathbf{k}_1$ は行の平均の明るさとほぼ同じ形(相関 0.992)である。1 本目は「どの列がどれだけ明るい」という平均の情報に取られる。

平均を引かずに分解すると、1 本目を平均の明るさに使ってしまう、写真の中の明暗の違いを受け持てる軸が 1 本減る。第 I 部の中心化の節で、原点を通る直線が点の雲の中心を向いたのと同じことである。

このとき、寄与率の数字も大きく変わる。表 3 のとおり、平均を引かない写真では $Q = 1$ の累積寄与率が 89.8% になり、平均を引いた $\mathbf{X}$ の 52.3% を大きく上回る。ところが誤差 J はむしろ大きい(6,319 と 5,699)。分母の $\|\mathbf{X}\|_F^2$ が、平均を引かないと 61,868 に膨らみ、その大半が平均の明るさだからである。累積寄与率は (20)




図 15: (a) 列の平均を引かない写真の 1 枚目 $\delta_1 \mathbf{k}_1 \mathbf{l}_1^\top$ 。(b) 列の平均の明るさを各行に並べたもの

式のとおり $1 - J/\|\mathbf{X}\|_F^2$ であり、何を $\mathbf{X}$ にしたかで分母が変わる。異なる $\mathbf{X}$ どうしで寄与率を比べることはできず、比べるなら同じ目盛りの J で比べる。

表 3: 列の平均を引くかどうかで変わる寄与率と、変わりにくい誤差 J (写真の $\mathbf{X}$)

	列の平均を引いた $\mathbf{X}$	写真そのもの
$\ \mathbf{X}\ _F^2$	11,949	61,868
$Q = 1$ の累積寄与率	52.3%	89.8%
$Q = 1$ の J	5,699	6,319
$Q = 5$ の累積寄与率	78.2%	95.7%
$Q = 5$ の J	2,599	2,663

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは、写真も数本の軸で累積寄与率がほぼ 100% になり、肘が出ると予想した。実際には、2 本で 70.4%、90% に届くのに 25 本、99% に届くのに 155 本を要し、肘もはっきりせず、予想は外れた。理由は、目的関数の最小値 J が捨てた特異値の二乗の和であることにある。写真の 3 本目以降の δ_m^2 は 1 本ずつは小さいが、数が多く、合わせると無視できない。2 本の向きに小さなずれを足して作ったホットケーキとは違い、写真の細かな模様は多くの軸に散っている。それでも $Q = 50$ で見た目はほぼ元に戻り、そのとき要する数は元の 24% である。一方、1 枚目から番号の順に大きな明暗から細部へと受け持つことは、予想どおり確かめられた。列の平均を引かなければ、1 本目を平均の明るさに取られ、寄与率だけが高く見える。

締め

まとめと次回問い

本章の問いは、 $\mathbf{X}$ 自身を少数の軸で近似するとき、 $\mathbf{F}$ と $\mathbf{A}$ をどう求めるか、であった。答えは、データ行列 $\mathbf{X}$ そのものを 1 回特異値分解することである。 $\mathbf{X}$ は特異値分解でちょうど $\mathbf{K}\mathbf{\Delta}\mathbf{L}^\top$ に分けられ、重み δ_m を付けたランク 1 の層の重ね合わせとして書ける。Eckart–Young の定理により、ランク Q 以下で $\mathbf{X}$ に最も近い行列は上位 Q 枚を重ねた $\mathbf{K}_1\mathbf{\Delta}_1\mathbf{L}_1^\top$ である。ランク Q 以下の行列は $\mathbf{F}\mathbf{A}^\top$ の形の行列と同じものなので、 $\hat{\mathbf{F}} = \mathbf{K}_1\mathbf{\Delta}_1$ 、 $\hat{\mathbf{A}} = \mathbf{L}_1$ が主成分分析の答えになる。未知が 2 つの積であっても、反復はいらない。目的関数の最小値は捨てた特異値の二乗和であり、特異値の小さい層はデータの小さな揺れとみなして捨てる。本当の信号がわかる人工データでは、小さい層を捨てた近似のほうが、本当の信号に近かった。答えの軸は、目的関数だけでは回転と裏返しの分だけ決まらないが、特異値分解はそこから得点が無相関で δ_m の順に並ぶ 1 つを選ぶ。写真 1 枚では、上位の層が大きな明暗を、下位の層が細部を受け持った。数本の軸では誤差が多く残ったが、それは細部が多く小さい層に散っているからであった。

最後に、次回への問いを置く。本章では $\mathbf{F}$ と $\mathbf{A}$ を求めたが、それをどう読むかは扱っていない。 $\mathbf{A}$ の各列は p 個の列への重みであり、 $\mathbf{F}$ は各行の軸の上の位置である。この 2 つから何を読めばよいのか。また、写真の列はどれも同じ明るさの目盛りだったが、単位がまちまちな列なら、どう扱えばよいのだろうか。