

第 9 回 主成分分析①

$\mathbf{X}$ を少数の軸で近似し、 $\mathbf{F}$ と $\mathbf{A}$ を交互に解く

本章の問いは、第 8 回の締めで残った「 $\mathbf{X}$ 自身を少数の軸で近似すると？」である。目的関数は第 8 回で書いた $\|\mathbf{X} - \mathbf{F}\mathbf{A}^\top\|_F^2$ (ただし $\mathbf{A}^\top\mathbf{A} = \mathbf{I}_Q$) である。この式は、未知の $\mathbf{F}$ と $\mathbf{A}$ の積を含む。答えは、片方を固定して残りを解くことを交互に繰り返す交互最小二乗法である。 $\mathbf{A}$ を固定すれば $\hat{\mathbf{F}} = \mathbf{X}\mathbf{A}$ 、 $\mathbf{F}$ を固定すれば $\mathbf{X}^\top\mathbf{F}$ の特異値分解から $\hat{\mathbf{A}} = \mathbf{K}\mathbf{L}^\top$ が得られる。

第 I 部 理論

少数の軸で近似する

第 8 回の締めで残った問いは、 $\mathbf{X}$ 自身を少数の軸で近似するとどうなるか、であった。本章では、手書きの数字の画像を例にする。図 1 (a) のように、1 枚の画像は $8 \times 8 = 64$ マスの濃さ (0~16 の整数) である。1,797 枚の画像を 1 枚 1 行に並べると、 $1,797 \times 64$ のデータ行列 $\mathbf{X}$ になる。2 列の組は 2,016 通りあり、2 列ずつ散布図を描いて全体を見ることはできない。一方、マスの中には一緒に動くものがある。図 1 (b) は、1 段目の左から 3 マス目と、8 段目の左から 3 マス目の濃さを、全 1,797 枚について描いたものである (値は整数なので、重ならないよう少しずらした)。相関は 0.938 であり、点はほぼ 1 本の直線 (赤) の上に並ぶ。このような 2 列は、直線の上の位置という 1 つの数でほぼ言い表せる。

第 8 回では、 $\mathbf{X}$ 自身を少数の軸で近似する目的関数 $\|\mathbf{X} - \mathbf{F}\mathbf{A}^\top\|_F^2$ (ただし $\mathbf{A}^\top\mathbf{A} = \mathbf{I}_Q$) を書いたが、解かなかった。本章の問いは、 $\mathbf{X}$ 自身を少数の軸で近似するとき、 $\mathbf{F}$ と $\mathbf{A}$ をどう求めるか、である。以下ではまず、2 列の人工データで近似の形を見て、目的関数をスカラーから行列まで書き直す。次に、未知が 2 つあるときの解き方を決め、そのための道具をそろえてから、2 つの更新を導く。最後に、その解き方から言えることを確かめる。

点の雲を直線で近似する

もっと簡単な場面として、2 列の人工データで、少数の軸で近似するとはどういうことかを見る。図 2 (a) の 40 点は列の平均を 0 にしてあり、行 i の点を $\tilde{\mathbf{x}}_i = [x_{i1}, x_{i2}]^\top$ と書く。原点を通り長さ 1 の向き $\mathbf{a}$ を持つ直線 (赤) を 1 本引き、各点をその直線の上の点 $f_i\mathbf{a}$ (青) で近似する。 f_i は直線の上の位置を表す 1 つの数である。2 つの数 x_{i1}, x_{i2} を、1 つの数 f_i で言い表したことになる。近似の誤差は $\tilde{\mathbf{x}}_i - f_i\mathbf{a}$ (灰色の線) である。この線は、第 1 回の回帰のような縦の向きではなく、直線に垂直な向きに下ろした線になる。回帰では x_1 は与えられていて x_2 だけに誤差があったが、ここでは 2 つの列を対等に近似するからである。




図 1: 手書き数字の画像。(a) 1 枚は $8 \times 8 = 64$ マスの濃さ(0~5 の最初の 1 枚ずつ)、(b) 赤い枠の 2 マス(左の 0 の画像に示す)の濃さを全 1,797 枚で描いたもの。点はほぼ 1 本の直線に乗る

近似のよさは、直線の向きで変わる。図 2 (b) のように向きを 160 度になると垂線は長くなり、誤差の二乗和は (a) の 11.6 から 73.1 に増える。

列が p 個、軸が Q 本の場合も同じである。行 i の軸 m の上の位置を f_{im} 、軸 m の向きを $\mathbf{a}_m \in \mathbb{R}^p$ とし、それぞれを並べて $\mathbf{F} \in \mathbb{R}^{n \times Q}$ と $\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_Q] \in \mathbb{R}^{p \times Q}$ を作る。データ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ は、図 3 のように 2 つの行列の積 $\mathbf{FA}^\top$ で近似される。第 1 回の「データ=モデル+誤差」の形に書けば

$$\mathbf{X} = \mathbf{FA}^\top + \mathbf{E} \quad (1)$$

である。回帰のモデル $\mathbf{X}\beta$ では $\mathbf{X}$ が与えられていて未知は β だけだったが、(1) 式のモデルは未知の $\mathbf{F}$ と $\mathbf{A}$ の積になっている。

目的関数と制約

(1) 式の誤差 $\mathbf{E}$ の大きさを、スカラー・ベクトル・行列の順に書く。まず軸が 1 本($Q = 1$)のとき、マス x_{ij} は行の位置 f_i と軸の向きの第 j 成分 a_j の積 $f_i a_j$ で近似される。目的関数は $n \times p$ 個の誤差の二乗和




図 2: 点の雲を 1 本の直線で近似する (人工データ、2 列・40 点)。赤は長さ 1 の向き $\mathbf{a}$ の直線、青は近似 $f_i \mathbf{a}$ 、灰色は誤差。(a) 点の雲に沿った向き、(b) 160 度の向き




図 3: 主成分分析のモデルの型 (概念図)。 $n \times p$ の $\mathbf{X}$ を、 $n \times Q$ の $\mathbf{F}$ と $Q \times P$ の $\mathbf{A}^\top$ の積で近似する

$$J = \sum_{i=1}^n \sum_{j=1}^p (x_{ij} - f_i a_j)^2 \quad (2)$$

である。軸が Q 本なら、マス x_{ij} は Q 本の軸の組み合わせ $\sum_m f_{im} a_{jm}$ で近似され、

$$J = \sum_{i=1}^n \sum_{j=1}^p \left(x_{ij} - \sum_{m=1}^Q f_{im} a_{jm} \right)^2 = \sum_{i=1}^n \|\tilde{\mathbf{x}}_i - \mathbf{A} \tilde{\mathbf{f}}_i\|_2^2 \quad (3)$$

となる。 $Q = 1$ とおけば (2) 式に戻る。2 つ目の等号では、 $\mathbf{F}$ の第 i 行を縦に並べた $\tilde{\mathbf{f}}_i \in \mathbb{R}^Q$ を使い、内側の j についての和を行ベクトルの距離の二乗にまとめた。 $\mathbf{A} \tilde{\mathbf{f}}_i$ の第 j 成分が $\sum_m a_{jm} f_{im}$ だからである。さらに

行を縦に積む。 $\mathbf{X} - \mathbf{F}\mathbf{A}^\top$ の第 i 行は $(\tilde{x}_i - \mathbf{A}\tilde{\mathbf{f}}_i)^\top$ であるから、第 8 回のフロベニウスノルムを使って

$$J(\mathbf{F}, \mathbf{A}) = \|\mathbf{X} - \mathbf{F}\mathbf{A}^\top\|_F^2 \quad (4)$$

と書ける。これが第 8 回で並べた主成分分析の目的関数である。

(4) 式だけでは、答えが 1 つに決まらない。(2) 式で、ある $c \neq 0$ について f_i をすべて c 倍し、 a_j をすべて $1/c$ 倍しても、積 $f_i a_j$ は変わらず J も変わらない。倍率を $\mathbf{F}$ と $\mathbf{A}$ の間で押し付け合えるのである。そこで $\mathbf{A}$ の列に、長さ 1 で互いに直角という条件

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q \quad (5)$$

を付ける(正規直交制約)。 $\mathbf{A}^\top \mathbf{A}$ の (m, r) 成分は $\mathbf{a}_m^\top \mathbf{a}_r$ である。対角が 1 なら各軸の長さが 1 で、対角の外が 0 なら軸どうしは直角になる。 $Q = 1$ では $\|\mathbf{a}\|_2 = 1$ 、すなわち 図 2 の赤い直線の向きを長さ 1 で表すことにあたる。

定義 1 (主成分分析). データ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ が与えられたとき、制約 (5) 式のもとで目的関数 (4) 式を最小にする $\mathbf{F}$ と $\mathbf{A}$ を求めることを主成分分析(principal component analysis)という。 $\mathbf{F} \in \mathbb{R}^{n \times Q}$ を主成分得点行列(各行の、軸の上の位置)、 $\mathbf{A} \in \mathbb{R}^{p \times Q}$ を主成分負荷量行列(変数と軸の関係)と呼ぶ。

交互最小二乗法

回帰の目的関数では未知は β だけであり、勾配を 0 とおいた正規方程式を 1 回解けば答えが出た(第 1 回)。(4) 式では $\mathbf{F}$ と $\mathbf{A}$ がどちらも未知で、モデルはその積になっている。このように推定するパラメータが複数あって一度に推定できない場合は、各パラメータを順に推定し、収束したと判断するまで計算を続ける。これを交互最小二乗法(alternating least squares)と呼ぶ(図 4)。

各パラメータを推定するときには、ほかのパラメータは既知として計算する。あるパラメータを既知として扱うことを、そのパラメータを固定するという。主成分分析では、 $\mathbf{A}$ を固定して $\mathbf{F}$ を更新し、次に $\mathbf{F}$ を固定して $\mathbf{A}$ を更新する。各更新はそのパラメータについて目的関数を最小にするので、更新のたびに目的関数は下がるかわからない。これを単調減少と呼び、交互最小二乗法ではこの性質が保証されている。また、交互最小二乗法のように収束するまでパラメータの更新を繰り返す計算を、反復計算と呼ぶ。

2 つの更新を導くために、次節で道具をそろえる。 $\mathbf{F}$ の更新はスカラー・ベクトルなら第 1 回と同じ微分で済むが、行列のまま書くにはトレースとその偏微分が要る。 $\mathbf{A}$ の更新では、制約 (5) 式があるので微分を 0 とおく方法が使えない。そこで特異値分解と部分正規直交行列が要る。

道具：トレースと特異値分解

行列のまま計算するための道具を用意する。

1 つ目はトレースである。 $p \times p$ の正方行列 $\mathbf{M}$ の対角成分の和




図 4: 交互最小二乗法の概要図(概念図。博士論文抜粋の図 1.4 を描き直したもの)

$$\text{tr}(\mathbf{M}) = \sum_{j=1}^p m_{jj} \quad (6)$$

を $\mathbf{M}$ のトレース(trace)と呼ぶ(定義 2)。行列の積 $\mathbf{BC}$ ($\mathbf{B} \in \mathbb{R}^{n \times p}$ 、 $\mathbf{C} \in \mathbb{R}^{p \times n}$)について

$$\text{tr}(\mathbf{BC}) = \text{tr}(\mathbf{CB}), \quad \text{tr}(\mathbf{BC}) = \text{tr}((\mathbf{BC})^\top) = \text{tr}(\mathbf{C}^\top \mathbf{B}^\top) \quad (7)$$

が成り立つ。どちらも成分で書けば $\sum_i \sum_j b_{ij} c_{ji}$ であり、転置は対角成分を変えないからである。3つ以上の積でも、順番を回して並べ直してよい。

2つ目は、二乗和のトレースによる表現である。 $\mathbf{M} \in \mathbb{R}^{n \times p}$ について $\mathbf{M}^\top \mathbf{M}$ の第 j 対角成分は $\sum_i m_{ij}^2$ 、すなわち第 j 列の二乗和であるから

$$\|\mathbf{M}\|_F^2 = \sum_{i=1}^n \sum_{j=1}^p m_{ij}^2 = \text{tr}(\mathbf{M}^\top \mathbf{M}) \quad (8)$$

となる。第 8 回で定義したフロベニウスノルムの二乗が、トレースで書けた。同じ理由で、 1×1 の行列とみなした内積もトレースとして $\mathbf{x}^\top \mathbf{y} = \text{tr}(\mathbf{x}^\top \mathbf{y}) = \text{tr}(\mathbf{y} \mathbf{x}^\top)$ と書ける。

3つ目は、トレースの行列による偏微分である。 $\mathbf{B}, \mathbf{C} \in \mathbb{R}^{n \times Q}$ について $\text{tr}(\mathbf{B}^\top \mathbf{C}) = \sum_i \sum_m b_{im} c_{im}$ であるから、 b_{im} で偏微分すると c_{im} になる。すべての成分についての偏微分を $\mathbf{B}$ と同じ形に並べたものをトレースの偏微分と呼び(定義 3)、

$$\frac{\partial \text{tr}(\mathbf{B}^\top \mathbf{C})}{\partial \mathbf{B}} = \mathbf{C}, \quad \frac{\partial \text{tr}(\mathbf{B}^\top \mathbf{B})}{\partial \mathbf{B}} = 2\mathbf{B} \quad (9)$$

となる。2つ目は $\sum_{i,m} b_{im}^2$ を b_{im} で偏微分すると $2b_{im}$ になることによる。 $\mathbf{B}$ が 1 列なら勾配 $\partial(\mathbf{b}^\top \mathbf{c})/\partial \mathbf{b} = \mathbf{c}$ に、 1×1 なら 1 変数の微分 $d(bc)/db = c$ に戻る。谷底ですべての偏微分が 0 になるという考え方は、第 1 回の微分・偏微分・勾配と同じである。

4 つ目は特異値分解(singular value decomposition)である。任意の行列 $\mathbf{M} \in \mathbb{R}^{p \times Q}$ ($Q \leq p$) は

$$\mathbf{M} = \mathbf{K} \mathbf{\Delta} \mathbf{L}^\top, \quad \mathbf{K}^\top \mathbf{K} = \mathbf{L}^\top \mathbf{L} = \mathbf{L} \mathbf{L}^\top = \mathbf{I}_Q \quad (10)$$

と書ける(定義 4)。 $\mathbf{K} \in \mathbb{R}^{p \times Q}$ を左特異行列、 $\mathbf{L} \in \mathbb{R}^{Q \times Q}$ を右特異行列、対角行列 $\mathbf{\Delta}$ の対角成分 $\delta_1 \geq \dots \geq \delta_Q \geq 0$ を特異値と呼ぶ。行列の大きさから $\mathbf{K} \mathbf{K}^\top \neq \mathbf{I}_p$ であることに注意する。 $Q = 1$ なら、ベクトル $\mathbf{m}$ は $\mathbf{m} = (\mathbf{m}/\|\mathbf{m}\|_2) \cdot \|\mathbf{m}\|_2 \cdot 1$ と書ける。 $\mathbf{K}$ は長さ 1 にそろえた $\mathbf{m}$ 、特異値は長さ $\|\mathbf{m}\|_2$ 、 $\mathbf{L} = 1$ である。

5 つ目は部分正規直交行列である。 $\mathbf{K}^\top \mathbf{K} = \mathbf{I}$ を満たす $\mathbf{K}$ のように、正規直交行列の一部を切り出した行列を部分正規直交行列(sub-orthonormal matrix)と呼ぶ(定義 5)。部分正規直交行列どうしの積もまた部分正規直交行列であり、その特異値は 0 以上 1 以下である。正規直交行列の列は長さ 1 なので、その一部の成分はどれも絶対値が 1 以下であり、対角成分も 1 以下になる。したがって $\mathbf{T} \in \mathbb{R}^{Q \times Q}$ が部分正規直交行列で $\mathbf{\Delta}$ の対角成分が 0 以上なら

$$\text{tr}(\mathbf{T} \mathbf{\Delta}) = \sum_{m=1}^Q t_{mm} \delta_m \leq \sum_{m=1}^Q \delta_m = \text{tr}(\mathbf{\Delta}) \quad (11)$$

が成り立ち、等号は $\mathbf{T} = \mathbf{I}_Q$ のとき成り立つ。 $\mathbf{F}$ の更新には 1 つ目から 3 つ目の道具を、 $\mathbf{A}$ の更新には 4 つ目と 5 つ目の道具を使う。

定義 2 (トレース). 正方行列 $\mathbf{M}$ の対角成分の和 $\text{tr}(\mathbf{M})$ を $\mathbf{M}$ のトレースと呼ぶ。積の順番を回しても、転置しても値は変わらない。

定義 3 (トレースの偏微分). 行列 $\mathbf{B}$ の関数 $g(\mathbf{B})$ を、 $\mathbf{B}$ の各成分で偏微分した値を $\mathbf{B}$ と同じ形に並べた行列 $\partial g/\partial \mathbf{B}$ を、 $\mathbf{B}$ についての偏微分と呼ぶ。 g がトレースで書かれているとき、これをトレースの偏微分と呼ぶ。

定義 4 (特異値分解). 行列 $\mathbf{M}$ を (10) 式の形 $\mathbf{K} \mathbf{\Delta} \mathbf{L}^\top$ に書くことを特異値分解と呼ぶ。 $\mathbf{K}$ と $\mathbf{L}$ は列が長さ 1 で互いに直交な行列、 $\mathbf{\Delta}$ は特異値を降順に並べた対角行列である。

定義 5 (部分正規直交行列). 正規直交行列の部分行列を部分正規直交行列と呼ぶ。部分正規直交行列どうしの積は部分正規直交行列であり、その成分の絶対値はどれも 1 以下である。

F の更新

まず $\mathbf{A}$ を固定して $\mathbf{F}$ を更新する。スカラーから始める。軸が 1 本で、向き $\mathbf{a}$ ($\sum_j a_j^2 = 1$) が固定されているとき、(2) 式は行ごとの項 $\sum_j (x_{ij} - f_i a_j)^2$ の和である。行 i の項は、 f_i だけを含む放物線になる。したがって行ごとに 1 変数の微分を 0 とおけばよく、

$$\frac{d}{df_i} \sum_{j=1}^p (x_{ij} - f_i a_j)^2 = -2 \sum_{j=1}^p a_j (x_{ij} - f_i a_j) = 0 \implies \hat{f}_i = \frac{\sum_j a_j x_{ij}}{\sum_j a_j^2} = \sum_{j=1}^p a_j x_{ij} \quad (12)$$

を得る。これは第1回の単回帰の解 $\hat{\beta} = \sum_i x_i y_i / \sum_i x_i^2$ と同じ形であり、行 i の p 個の値を $\mathbf{a}$ に回帰した係数にあたる。図2の青い点の位置 f_i は、点から直線へ垂線を下ろした足の位置である。向きが点の雲から外れた図2(b)でも、それは変わらない。

軸が Q 本なら、(3) 式の行 i の項 $\|\tilde{\mathbf{x}}_i - \mathbf{A}\tilde{\mathbf{f}}_i\|_2^2$ を $\tilde{\mathbf{f}}_i$ で微分する。第1回の重回帰と同じ計算で、勾配を0とおくと

$$\frac{\partial}{\partial \tilde{\mathbf{f}}_i} \|\tilde{\mathbf{x}}_i - \mathbf{A}\tilde{\mathbf{f}}_i\|_2^2 = -2\mathbf{A}^\top \tilde{\mathbf{x}}_i + 2\mathbf{A}^\top \mathbf{A} \tilde{\mathbf{f}}_i = 0 \implies \hat{\tilde{\mathbf{f}}}_i = \mathbf{A}^\top \tilde{\mathbf{x}}_i \quad (13)$$

となる。第1回の正規方程式 $\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^\top \mathbf{y}$ の $\mathbf{X}$ を $\mathbf{A}$ に、 $\mathbf{y}$ を $\tilde{\mathbf{x}}_i$ に替えた形である。制約(5)式により $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$ なので、逆行列は要らない。 $Q=1$ なら $\hat{f}_i = \mathbf{a}^\top \tilde{\mathbf{x}}_i$ で(12)式に戻る。

同じ更新を行列のまま導く。(8)式により

$$\begin{aligned} J(\mathbf{F} | \mathbf{A}) &= \text{tr}((\mathbf{X} - \mathbf{F}\mathbf{A}^\top)^\top (\mathbf{X} - \mathbf{F}\mathbf{A}^\top)) \\ &= \text{tr}(\mathbf{X}^\top \mathbf{X}) - 2\text{tr}(\mathbf{X}^\top \mathbf{F}\mathbf{A}^\top) + \text{tr}(\mathbf{A}\mathbf{F}^\top \mathbf{F}\mathbf{A}^\top) \\ &= \text{tr}(\mathbf{X}^\top \mathbf{X}) - 2\text{tr}(\mathbf{F}^\top \mathbf{X}\mathbf{A}) + \text{tr}(\mathbf{F}^\top \mathbf{F}) \end{aligned} \quad (14)$$

と展開できる。2行目では $\text{tr}(\mathbf{X}^\top \mathbf{F}\mathbf{A}^\top) = \text{tr}(\mathbf{A}\mathbf{F}^\top \mathbf{X})$ (転置)を使って交差項を1つにまとめた。3行目では(7)式を使い、交差項を $\text{tr}(\mathbf{A}\mathbf{F}^\top \mathbf{X}) = \text{tr}(\mathbf{F}^\top \mathbf{X}\mathbf{A})$ と回した。最後の項は $\text{tr}(\mathbf{F}^\top \mathbf{F}\mathbf{A}^\top \mathbf{A})$ と回してから、 $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$ を用いた。(9)式で $\mathbf{B} = \mathbf{F}$ 、 $\mathbf{C} = \mathbf{X}\mathbf{A}$ とおくと

$$\frac{\partial J}{\partial \mathbf{F}} = -2\mathbf{X}\mathbf{A} + 2\mathbf{F} = \mathbf{O} \implies \hat{\mathbf{F}} = \mathbf{X}\mathbf{A} \quad (15)$$

を得る。 $\hat{\mathbf{F}}$ の第 i 行は $\tilde{\mathbf{x}}_i^\top \mathbf{A}$ であり、(13)式の $\mathbf{A}^\top \tilde{\mathbf{x}}_i$ を横にしたものに一致する。行列で書いても、行ごとに回帰した答えを縦に積んだだけである。

A の更新

次に $\mathbf{F}$ を固定して $\mathbf{A}$ を更新する。ここでも軸が1本の場合から始める。 $\mathbf{f}$ を固定し、 $\sum_j a_j^2 = 1$ を使って(2)式を展開すると

$$J = \sum_{i,j} x_{ij}^2 - 2 \sum_{j=1}^p a_j \left(\sum_{i=1}^n f_i x_{ij} \right) + \left(\sum_i f_i^2 \right) \left(\sum_j a_j^2 \right) = \text{const} - 2 \mathbf{a}^\top \mathbf{b} \quad (16)$$

となる。ただし $b_j = \sum_i f_i x_{ij}$ 、すなわち $\mathbf{b} = \mathbf{X}^\top \mathbf{f}$ であり、const は $\mathbf{a}$ によらない。 J を最小にすることは、長さ 1 の $\mathbf{a}$ の中で内積 $\mathbf{a}^\top \mathbf{b}$ を最大にすることである。 $\mathbf{a}^\top \mathbf{b} = \|\mathbf{a}\|_2 \|\mathbf{b}\|_2 \cos \theta = \|\mathbf{b}\|_2 \cos \theta$ であるから、最大になるのは $\cos \theta = 1$ のときである。すなわち図 5 のように $\mathbf{a}$ を $\mathbf{b}$ と同じ向きにそろえたときで、 $\hat{\mathbf{a}} = \mathbf{b} / \|\mathbf{b}\|_2$ を得る。制約なしで a_j ごとに回帰すると $a_j = b_j / \sum_i f_i^2$ となる。制約があるので、長さのほうは $\|\mathbf{a}\|_2 = 1$ で決まり、向きだけが $\mathbf{b}$ で決まる。




図 5: 長さ 1 の向き $\mathbf{a}$ の候補(灰)と $\mathbf{b}$ (黒)(概念図)。内積 $\mathbf{a}^\top \mathbf{b}$ は、 $\mathbf{a}$ を $\mathbf{b}$ の向きにそろえたとき最大になる

行列のまま書く。 $\mathbf{F}$ を固定すると、(14) 式と同じ展開から

$$J(\mathbf{A} \mid \mathbf{F}) = \text{tr}(\mathbf{X}^\top \mathbf{X}) + \text{tr}(\mathbf{F}^\top \mathbf{F}) - 2 \text{tr}(\mathbf{X}^\top \mathbf{F} \mathbf{A}^\top) = \text{const}_{\mathbf{A}} - 2 \text{tr}(\mathbf{X}^\top \mathbf{F} \mathbf{A}^\top) \quad (17)$$

となる。途中で $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$ を用いたので、 $\text{tr}(\mathbf{X}^\top \mathbf{X})$ と $\text{tr}(\mathbf{F}^\top \mathbf{F})$ は $\mathbf{A}$ の更新に関係しない。(17) 式は、 $\mathbf{A}$ についての最小化がトレースの最大化であることを示している。 $\mathbf{A}$ は制約 (5) 式を満たしたまま動かさなければならないので、微分を 0 とおく方法はそのままでは使えない。 $Q = 1$ なら $\text{tr}(\mathbf{X}^\top \mathbf{f} \mathbf{a}^\top) = \mathbf{a}^\top \mathbf{X}^\top \mathbf{f} = \mathbf{a}^\top \mathbf{b}$ であり、(16) 式に戻る。

もし $p = Q$ なら、 $\mathbf{A}$ は正方の正規直交行列であり、 $\mathbf{A}^\top \mathbf{A} = \mathbf{A} \mathbf{A}^\top = \mathbf{I}_p$ のもとで (17) 式を最小にする問題は、直交プロクラステス問題(orthogonal Procrustes problem)と呼ばれる(定理 1)。

定理 1 (直交プロクラステス問題). $\mathbf{X} \in \mathbb{R}^{n \times p}$ 、 $\mathbf{F} \in \mathbb{R}^{n \times p}$ が与えられ、 $\mathbf{A} \in \mathbb{R}^{p \times p}$ は $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p$ を満たすとする。 $\|\mathbf{X} - \mathbf{F} \mathbf{A}^\top\|_F^2$ を最小にする $\mathbf{A}$ は、特異値分解 $\mathbf{X}^\top \mathbf{F} = \mathbf{K} \mathbf{\Delta} \mathbf{L}^\top$ の左右の特異行列を用いて

$$\hat{\mathbf{A}} = \mathbf{K} \mathbf{L}^\top \quad (18)$$

で与えられる。

証明は次のとおりである。(17) 式より、トレース $\text{tr}(\mathbf{X}^\top \mathbf{F} \mathbf{A}^\top)$ を最大にすればよい。 $\mathbf{X}^\top \mathbf{F}$ の特異値分解と (7) 式から

$$\text{tr}(\mathbf{X}^\top \mathbf{F} \mathbf{A}^\top) = \text{tr}(\mathbf{K} \mathbf{\Delta} \mathbf{L}^\top \mathbf{A}^\top) = \text{tr}(\mathbf{A} \mathbf{L} \mathbf{\Delta} \mathbf{K}^\top) = \text{tr}(\mathbf{K}^\top \mathbf{A} \mathbf{L} \mathbf{\Delta}) = \text{tr}(\mathbf{T} \mathbf{\Delta}) \quad (19)$$

を得る。ただし $\mathbf{T} = \mathbf{K}^\top \mathbf{A} \mathbf{L}$ とした。 $\mathbf{T}^\top \mathbf{T} = \mathbf{L}^\top \mathbf{A}^\top \mathbf{K} \mathbf{K}^\top \mathbf{A} \mathbf{L} = \mathbf{I}_p$ であるから $\mathbf{T}$ は正規直交行列であり、その対角成分は 1 以下である。よって (11) 式により $\text{tr}(\mathbf{T} \mathbf{\Delta}) \leq \text{tr}(\mathbf{\Delta})$ となる。最大になるのは $\mathbf{T} = \mathbf{I}_p$ 、すなわち $\mathbf{K}^\top \mathbf{A} \mathbf{L} = \mathbf{I}_p$ のときであり、これは $\mathbf{A} = \mathbf{K} \mathbf{L}^\top$ と同じである。

ところが主成分分析の $\mathbf{A}$ は、ふつう正方ではなく $p \times Q$ ($Q < p$) の縦長の行列である。 $\mathbf{K} \mathbf{K}^\top \neq \mathbf{I}_p$ となるので、この証明はそのままでは使えない。そこで von Neumann の定理と Kristof の定理を一般化した ten Berge の定理を用いる。驚くべきことに、更新の式は正方のときと同じ (18) 式になる (定理 2)。

定理 2 (ten Berge の定理の特殊例). $\mathbf{X} \in \mathbb{R}^{n \times p}$ 、 $\mathbf{F} \in \mathbb{R}^{n \times Q}$ が与えられ、 $\mathbf{A} \in \mathbb{R}^{p \times Q}$ は $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$ を満たすとする。トレース $\text{tr}(\mathbf{X}^\top \mathbf{F} \mathbf{A}^\top)$ を最大にする $\mathbf{A}$ は、特異値分解 $\mathbf{X}^\top \mathbf{F} = \mathbf{K} \mathbf{\Delta} \mathbf{L}^\top$ ($\mathbf{K} \in \mathbb{R}^{p \times Q}$ 、 $\mathbf{L} \in \mathbb{R}^{Q \times Q}$) を用いて $\hat{\mathbf{A}} = \mathbf{K} \mathbf{L}^\top$ で与えられる。

証明は (19) 式と同じ変形から始まる。 $\mathbf{K}$ 、 $\mathbf{A}$ 、 $\mathbf{L}$ はどれも部分正規直交行列なので、その積 $\mathbf{T} = \mathbf{K}^\top \mathbf{A} \mathbf{L} \in \mathbb{R}^{Q \times Q}$ も部分正規直交行列である。よって (11) 式から $\text{tr}(\mathbf{T} \mathbf{\Delta}) \leq \text{tr}(\mathbf{\Delta})$ となる。 $\mathbf{A} = \mathbf{K} \mathbf{L}^\top$ とおくと、 $\mathbf{A}^\top \mathbf{A} = \mathbf{L} \mathbf{K}^\top \mathbf{K} \mathbf{L}^\top = \mathbf{I}_Q$ で制約を満たし、 $\mathbf{T} = \mathbf{K}^\top \mathbf{K} \mathbf{L}^\top \mathbf{L} = \mathbf{I}_Q$ となって上限 $\text{tr}(\mathbf{\Delta})$ に届く。よって $\hat{\mathbf{A}} = \mathbf{K} \mathbf{L}^\top$ である。

$Q = 1$ とおく。特異値分解の $Q = 1$ の場合として見たとおり、 $\mathbf{X}^\top \mathbf{f} = \mathbf{b}$ の特異値分解は $\mathbf{K} = \mathbf{b} / \|\mathbf{b}\|_2$ 、 $\mathbf{L} = 1$ である。よって $\hat{\mathbf{A}} = \mathbf{K} \mathbf{L}^\top = \mathbf{b} / \|\mathbf{b}\|_2$ となり、図 5 で内積から求めた答えに一致する。行列の更新 (18) 式は、1 軸のときの「 $\mathbf{X}^\top \mathbf{F}$ の向きに長さ 1 でそろえる」ことを、 Q 本の軸をまとめて行うものである。

計算の手順

2 つの更新を、実際に計算する行列の形で手順にまとめる。

1. 列の平均を 0 にしたデータ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ と、軸の数 Q を用意する
2. 初期値を置く。 $\mathbf{A}$ は観測されていないが既知として与える必要があるなので、無作為に作る。ただし制約 (5) 式を満たすように、標準正規分布から無作為に取った値を並べた $p \times Q$ 行列を特異値分解して $\mathbf{K} \mathbf{\Delta} \mathbf{L}^\top$ とし、 $\mathbf{A} \leftarrow \mathbf{K} \mathbf{L}^\top$ とする
3. $\mathbf{A}$ を固定して、(15) 式により $\mathbf{F} \leftarrow \mathbf{X} \mathbf{A}$ とする
4. $\mathbf{F}$ を固定して、 $\mathbf{X}^\top \mathbf{F} = \mathbf{K} \mathbf{\Delta} \mathbf{L}^\top$ と特異値分解し、(18) 式により $\mathbf{A} \leftarrow \mathbf{K} \mathbf{L}^\top$ とする
5. $J = \|\mathbf{X} - \mathbf{F} \mathbf{A}^\top\|_F^2$ を計算し、前回からの下がり幅が十分小さければ止める。そうでなければ 3 に戻る

手順 2 で特異値分解を使ったのは、手順 4 と同じ理由による。 $\mathbf{K} \mathbf{L}^\top$ は列が長さ 1 で互いに直角な行列になるからである。1 回の反復で行うのは、 $\mathbf{X} \mathbf{A}$ と $\mathbf{X}^\top \mathbf{F}$ の行列の積と、 $p \times Q$ の小さな行列の特異値分解だけである。

理論の帰結

(15) 式と (18) 式から、3 つのことが言える。

第 1 に、目的関数は更新のたびに下がる。 $\mathbf{F}$ の更新は、今の $\mathbf{A}$ のもとで J を最小にする $\mathbf{F}$ を選ぶので、 J は更新前より大きくならない。 $\mathbf{A}$ の更新も、今の $\mathbf{F}$ のもとで J を最小にする。 J は 0 より小さくならないので、この単調に下がる列はどこかの値に落ち着く。図 6 (a) は、図 2 の 40 点で $Q = 1$ の交互最小二乗法を、図 2 (b) の外れた向き(160 度)から始めたものである。更新のたびに直線は点の雲の長い向きへ回り、4 回目にはほとんど動かなくなる。図 6 (b) のとおり、 J は $\mathbf{F}$ の更新と $\mathbf{A}$ の更新のどちらでも下がる。初期値の 73.1 から下がり続け、11.64 に落ち着く(点の二乗和は 94.6)。




図 6: 交互最小二乗法の進み方(人工データ、図 2 の 40 点、 $Q = 1$)。(a) 更新のたびに直線の向き、(b) 目的関数 J の推移(青は $\mathbf{F}$ を、赤は $\mathbf{A}$ を更新した後)

第 2 に、答えは軸を回す自由を残す。 $\mathbf{R}$ を $Q \times Q$ の正規直交行列($\mathbf{R}^T \mathbf{R} = \mathbf{R} \mathbf{R}^T = \mathbf{I}_Q$)とし、 $\mathbf{F}$ を $\mathbf{F} \mathbf{R}$ に、 $\mathbf{A}$ を $\mathbf{A} \mathbf{R}$ に替えると

$$(\mathbf{F} \mathbf{R})(\mathbf{A} \mathbf{R})^T = \mathbf{F} \mathbf{R} \mathbf{R}^T \mathbf{A}^T = \mathbf{F} \mathbf{A}^T, \quad (\mathbf{A} \mathbf{R})^T (\mathbf{A} \mathbf{R}) = \mathbf{R}^T \mathbf{A}^T \mathbf{A} \mathbf{R} = \mathbf{I}_Q \quad (20)$$

であり、近似も制約も目的関数も変わらない。 $Q = 2$ の正規直交行列 $\mathbf{R}$ は、角 θ の回転 $\begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$ か、

裏返しを含む $\begin{bmatrix} \cos \theta & \sin \theta \\ \sin \theta & -\cos \theta \end{bmatrix}$ のどちらかの形をしている。 $Q = 1$ なら $\mathbf{R} = \pm 1$ で、軸の向きを反転しても同じ答えになることにあたる。これは、第 8 回で k-means の群の番号を付け替えても J が変わらなかったことに当たる性質である。制約 (5) 式は倍率の押し付け合いを止めたが、回転までは止めない。

第 3 に、そのため交互最小二乗法がどの $\mathbf{R}$ の答えに着くかは、初期値しだいである。図 7 では、3 列・60 点の人工データ(2 本の軸でほぼ表せる点)で、 $Q = 2$ の交互最小二乗法を初期値だけ変えて 2 回解いた。図は、着い

た $\mathbf{F}$ の 2 列を散布図にしたものである。 J はどちらも 4.339 で同じだが、点の並びは約 83 度回っている。変わらないのは J 近似 $\mathbf{FA}^\top$ 、そして $\mathbf{A}$ の 2 列が張る面であり、軸 1・軸 2 のそれぞれの向きは決まらない。




図 7: 初期値だけを変えて解いた 2 つの得点 $\mathbf{F}$ (人工データ、3 列・60 点、 $Q = 2$)。 J は同じで、点の並びは回っている。色の 3 点は同じ行

地図の中の主成分分析

表 1 は、第 8 回で並べた 3 つの目的関数に解き方を添えたものである。回帰は正規方程式を 1 回解けば済んだが、主成分分析と k-means は未知の行列どうしの積を含むので、交互に解く。本章で解いたのは主成分分析の行である。

表 1: 3 つの目的関数と解き方

モデル	近似する相手	目的関数	解き方	回
線形回帰	y	$\ \mathbf{y} - \mathbf{X}\boldsymbol{\beta}\ _2^2$	正規方程式を 1 回解く	第 1 回
主成分分析	$\mathbf{X}$	$\ \mathbf{X} - \mathbf{FA}^\top\ _F^2$	交互に解く	第 9・10 回
k-means	$\mathbf{X}$	$\ \mathbf{X} - \mathbf{GC}\ _F^2$	交互に解く	第 11 回

第 II 部 実データ解析

手書き数字と手続き

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、次の 2 つを予想できる。第 1 に、 J は $\mathbf{F}$ と $\mathbf{A}$ のどちらの更新でも上がらないので、どの初期値から始めても J は一度も上がらないはずである。第 I 部の 40 点では、4 回目の更新で直線がほとんど動かなくなった。実データでも、数回の反復で落ち着くと見込める。第 2 に、答えは (20) 式の $\mathbf{R}$ の分だけ決まらない。初期値を変えても、着いた J と近似 $\mathbf{F}\mathbf{A}^\top$ は同じで、軸のそれぞれの向きだけが回るか裏返るはずである。

データは、場面の手書きの数字の画像である。UCI の Optical Recognition of Handwritten Digits の検証用の部分 (Alpaydin & Kaynak, 1998. CC BY 4.0) で、scikit-learn に同梱されている 1,797 枚を使う。0~9 の数字がおおよそ 180 枚ずつあり、1 枚は $8 \times 8 = 64$ マスの濃さ (0~16 の整数) である。64 列はどれも同じ単位の濃さなので標準化はせず、列の平均を引くだけにした (どの画像でも 0 のマスが 3 つあり、標準化するとそこで 0 で割ることにもなる)。数字のラベルは計算には使わず、あとで得点の図を塗るためだけに使う。

手続きは次のとおりである。軸の数を $Q = 2$ とし、無作為に作り直した 3 つの初期値から、I-6 の手順で交互最小二乗法を回した。初期値は、標準正規分布から無作為に取った値を並べた 64×2 の行列を特異値分解して $\mathbf{A} = \mathbf{K}\mathbf{L}^\top$ としたものである。更新は NumPy の行列の積と特異値分解で計算し、 J の下がり幅が $\|\mathbf{X}\|_F^2 = 2,159,057$ の 10^{-12} 倍を切ったところで止めた。比べるために、第 I 部の 3 列 60 点も、同じ止め方と同じ 3 つの初期値の種で回した。答え合わせとして、ライブラリ (scikit-learn の PCA) で 2 本の軸の近似を作り、その J とも比べた。

J の推移

第 1 の予想から見る。図 8 は J の推移である。初期値での J は 2,083,566~2,104,504 であった。3 通りとも J は一度も上がらずに下がった。 $\mathbf{F}$ の更新の後と $\mathbf{A}$ の更新の後の J を並べても、上がったところは無かった。ここは予想どおりである。

一方、止まるまでには 62~84 回の反復が要った。第 I 部の 3 列 60 点を同じ止め方で回すと 10~11 回で止まるので、数回で落ち着くという予想は外れた。図のとおり、 J は最初の数回で大きく下がり、そのあと長いあいだ少しずつ下がり続ける。最後の J との差が最初の下がり幅の 1% 以内に入るまでに、手書き数字では 6~12 回、3 列 60 点では 2~3 回かかった。

理由は、軸を 1 本ずつ増やしたときの J の下がり方に表れている (表 2)。軸を 1 本、2 本、3 本として交互最小二乗法で解き、 q 本目の軸を足したことで下がった J を、 $\|\mathbf{X}\|_F^2$ に対する割合で並べた。第 I 部の 3 列 60 点は、2 本の軸の面に沿った平たい雲として作った。2 本目の軸は J を 7.5% 下げ、3 本目は 1.6% しか下げない。面の向きを誤ると J が大きく増えるので、更新のたびに面ははっきり正しい向きへ回る。手書き数字では、




図 8: 手書き数字の 1,797 枚で、3 つの初期値から回した交互最小二乗法($Q = 2$)の目的関数 J の推移。点線は $\mathbf{F} = \mathbf{O}$ のときの $J = \|\mathbf{X}\|_F^2$

2 本目の軸が 13.6%、3 本目が 11.8% と、ほぼ同じだけ J を下げる。面にどちらの向きを入れても J の差は小さく、 J が面を正しい向きへ押す力も弱い。そのため、1 回の更新で面が少しずつしか回らず、落ち着くまでに多くの反復が要った。第 I 部の直感⑥で見たとおり、交互最小二乗法は向きによる J の違いを手がかりに軸を回す。その違いが小さいデータでは、回り方も遅くなる。

表 2: 軸を 1 本ずつ増やしたときに下がる J ($\|\mathbf{X}\|_F^2$ に対する割合)と、 $Q = 2$ で止まるまでの反復の回数(同じ止め方、3 つの初期値)

		反復の回数		
$\ \mathbf{X}\ _F^2$ に対する割合	1 本目で下がる J	2 本目で下がる J	3 本目で下がる J	($Q = 2$)
第 I 部の 3 列 60 点	90.9%	7.5%	1.6%	10~11
手書き数字	14.9%	13.6%	11.8%	62~84

着いた答えを比べる

第 2 の予想に移る。表 3 は 3 つの答えを比べたものである。反復の回数は違っても、着いた J はどれも 1,543,524 で一致した。近似 $\mathbf{FA}^\top$ の各マスの差も、最大で $2.5\text{e-}04$ (濃さは 0~16)にとどまる。一方、初期値 1 の $\mathbf{A}_1$ と初期値 k の $\mathbf{A}_k$ から $\mathbf{R} = \mathbf{A}_1^\top \mathbf{A}_k$ を作り、理論の帰結で見た 2 つの形のどちらかを読んだ。すると、初期値 2 の $\mathbf{A}$ は 64 度の回転、初期値 3 の $\mathbf{A}$ は裏返しを含む形になっていた。(20) 式の $\mathbf{R}$ の分だけ答えが決まらないことが、64 列の実データでも起きている。予想どおりである。計算の確認として、どの答えも制約 $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_2$ を満たし、ライブラリの J との差も最大で $6.4\text{e-}06$ にとどまった。

表 3: 3つの初期値から着いた答えの比較(手書き数字の 1,797 枚、 $Q = 2$)

	初期値 1	初期値 2	初期値 3
反復の回数	79	62	84
最後の J	1,543,523.8	1,543,523.8	1,543,523.8
ライブラリの J との差	6.4e-06	6.4e-06	5.3e-06
$\mathbf{F}\mathbf{A}^\top$ の初期値 1 との差 (最大)	0	2.5e-04	1.1e-05
$\mathbf{A}^\top\mathbf{A}$ と $\mathbf{I}$ の差(最大)	0	0	0
初期値 1 の $\mathbf{A}$ からの $\mathbf{R}$	そのまま	回転 64°	裏返しを含む

図 9 (a) は、初期値 1 から着いた $\mathbf{F}$ の 2 列を散布図にし、点を数字のラベルで塗ったものである。1,797 枚の画像それぞれが、64 マスの濃さの代わりに 2 つの数で表されている。ラベルは計算に使っていないが、同じ数字の画像は近くに集まる。図 9 (b) は初期値 2 から着いた $\mathbf{F}$ で、 J は同じだが、数字の並びごと 64 度回っている。第 I 部の 図 7 と同じことが、64 列でも起きている。




図 9: 手書き数字の得点 $\mathbf{F}$ ($Q = 2$, 点の色は数字のラベル)。(a) 初期値 1、(b) 初期値 2 から着いた答え。黒い丸は 図 1 の 0 の画像

得点と近似を読む

得点は回っていても、近似は同じである。図 10 には、図 1 の 0 の画像について 3 枚を並べた。元の画像と、2 つの答えの近似 $\mathbf{A}\tilde{\mathbf{f}}_i$ に列の平均を足し戻した画像である。近似は元の画像そのものではなく、ぼやけた 0 になる(元の濃さとの差は最大 10.6)。着いた J は $\mathbf{F} = \mathbf{O}$ のときの $J = \|\mathbf{X}\|_F^2$ の 71% にあたり、2 本の軸では 64 マスの散らばりの 3 割ほどしか表せていない。表しきれない分は、(1) 式の誤差 $\mathbf{E}$ に残る。得点 $\tilde{\mathbf{f}}_i$ は 2 つの答え

で違うが、近似の 64 マスの差は最大で $1.9\text{e-}04$ にとどまる。(20) 式のとおり、得点を $\mathbf{R}$ で回した分を、 $\mathbf{A}$ の回転が打ち消すからである。



図 10: 図 1 の 0 の画像(左)と、2 つの答えの近似(列の平均を足し戻したもの)。得点は違うが、近似は同じ

落とし穴は、軸を 1 本ずつ読むことである。負荷量 $\mathbf{A}$ の各列は 64 マスに 1 つずつの値を持つので、 8×8 に並べると画像として見られる。図 11 は、3 つの初期値から着いた $\mathbf{A}$ の 2 列を並べたものである(赤は正、青は負)。軸 1 の模様は初期値ごとに違い、赤と青が入れ替わるものもある。「軸 1 は 0 の形を表す軸」のように軸に名前を付けても、初期値を変えて解き直せば、軸 1 は別の向きになる。得点の 2 列の相関も初期値ごとに -0.044 、 $+0.032$ 、 -0.018 と違い、0 にはならない。交互最小二乗法が決めるのは 2 本の軸が張る面までであり、その中のどの向きを軸 1 と呼ぶかは決めていないのである。

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは、 J はどの初期値からでも一度も上がらずに数回で落ち着き、着いた答えは $\mathbf{R}$ の分だけ決まらなないと予想した。 J が上がらないこと、着いた J と近似 $\mathbf{F}\mathbf{A}^\top$ が初期値によらず同じこと、軸の向きが回転や裏返しで変わることは、手書き数字でも予想どおりだった。一方、止まるまでには 62 ~ 84 回の反復が要り、数回で落ち着くという予想は外れた。手書き数字では 2 本目と 3 本目の向きが J をほぼ同じだけ下げるので、向きによる J の違いが小さく、面が少しずつしか回らなかった。第 I 部の人工データは、2 本の軸の面に沿った平たい雲として作ったので、すぐに落ち着いたのである。

締め

まとめと次回の問い

本章の問いは、 $\mathbf{X}$ 自身を少数の軸で近似するとき、 $\mathbf{F}$ と $\mathbf{A}$ をどう求めるか、であった。主成分分析は、データ行列を未知の 2 つの行列の積 $\mathbf{F}\mathbf{A}^\top$ で近似し、 $\|\mathbf{X} - \mathbf{F}\mathbf{A}^\top\|_F^2$ を制約 $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$ のもとで最小にする最小二乗法である。未知が積になっているので一度には解けないが、片方を固定すれば解ける。 $\mathbf{A}$ を固定すれば、行ごと




図 11: 3 つの初期値から着いた負荷量 $\mathbf{A}$ の 2 列を 8×8 に並べたもの (赤は正、青は負、色の範囲は 6 枚で共通)。上が軸 1、下が軸 2

の回帰と同じ計算で $\hat{\mathbf{F}} = \mathbf{X}\mathbf{A}$ を得る。 $\mathbf{F}$ を固定すれば、目的関数の最小化はトレース $\text{tr}(\mathbf{X}^\top \mathbf{F} \mathbf{A}^\top)$ の最大化になる。直交プロクラステス問題と ten Berge の定理により、 $\mathbf{X}^\top \mathbf{F} = \mathbf{K} \mathbf{\Delta} \mathbf{L}^\top$ から $\hat{\mathbf{A}} = \mathbf{K} \mathbf{L}^\top$ を得る。この 2 つを交互に繰り返すのが交互最小二乗法であり、目的関数は更新のたびに下がる。ただし答えは、軸を回す正規直交行列 $\mathbf{R}$ の分だけ決まらない。手書き数字の 64 列では、3 つの初期値がどれも同じ $J = 1,543,524$ と同じ近似に着いた。しかし $\mathbf{A}$ は初期値ごとに回っており、 8×8 に並べた軸 1 の負荷量の模様は初期値しだいで変わった。

最後に、次回への問いを置く。交互最小二乗法は、毎回 $\mathbf{X}^\top \mathbf{F}$ を特異値分解し、62~84 回の反復で、初期値によらず同じ J に着いた。では、 $\mathbf{X}$ そのものを特異値分解したらどうなるか。反復せず、1 回の計算で解けないだろうか。