第 9 回 群の数の選び方

当てはまりは群とともに良くなる。新しい行で測るか、モデルの出やすさで比べるか

本章の問いは、第 8 回の締めで残った「群の数 k をどう選ぶか」である。混合正規分布の対数尤度は k を増やせば上がり、k-means の J は下がるので、推定法そのものでは k を選べない。大きいモデルが小さいモデルを含むからである。そこで推定の外に基準を置く。新しい行での当てはまりを見積もる AIC、モデルそのものの出やすさを近似する BIC、距離だけで測るシルエット係数の 3 つを、導出とともに扱う。

第 I 部　理論

推定法では k を選べない

第 7 回の k-means は $J = \|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2$ を最小にし、第 8 回の混合正規分布は対数尤度 $\ell = \mathbf{1}_n^\top \log(\boldsymbol{\Phi}\mathbf{1}_k)$ を EM で最大にした。どちらも、群の数 k は先に決めていた。第 8 回は最後に「k をどう選ぶか」という問いを残した。本章ではこの問いを、人工データで考える。3 台のトースターで焼いたトースト 120 枚について、焼き時間と焼き色を測ったとする。どの 1 枚がどの台で焼かれたかは記録していない。1 台目の 60 枚は焼き時間が長いほど色が濃い斜めの帯に、2 台目の 25 枚は小さくまとまり、3 台目の 35 枚は丸く散らばるように作った（目盛りは標準化した値で、単位は持たない）。図 1 (a) がそのデータである。

図 1 (b) は、第 8 回の混合正規分布を、群の数 k を 1 から 6 まで変えて当てはめたときの最大の対数尤度 $\hat{\ell}$ である。共分散行列は群ごとに持たせ、初期値 10 通りのうち最良の答えを使った。$\hat{\ell}$ は $k = 1$ の -529.2 から $k = 6$ の -342.4 まで上がり続け、作った群の数 3 では止まらない。(c) は同じ 2 列に第 7 回の k-means を当てたときの J であり、1,211.7 から 65.9 まで下がり続ける。どちらの目的関数も、群を増やすほど良い値を返す。

$$\hat{\ell}_1 \le \hat{\ell}_2 \le \cdots \le \hat{\ell}_6, \qquad J_1 \ge J_2 \ge \cdots \ge J_6$$

これが 1 つ目の困りごとである。2 つ目に、k-means には確率のモデルが無いので、尤度を使う物差しは k-means には当てられない。3 つ目は、新しい行の扱いである。人工データなら、同じ作り方で新しいトーストをいくらでも焼ける。(d) は、新しく焼いた 12 万枚で各 k の答えの対数尤度を測り、120 枚あたりに直したものである。新しい行で測ると、ℓ は $k = 3$ で最大になり、その先は下がる。しかし実際のデータでは、新しい行は手元に無い。

同じ形の困りごとは前にもあった。第 2 回では、多項式の次数を上げるほど訓練誤差は下がり続けたので、テストの行で測り直した。第 4 回では、罰則の強さ λ を 0 にするほど訓練誤差は下がったので、交差検証（クロスバ

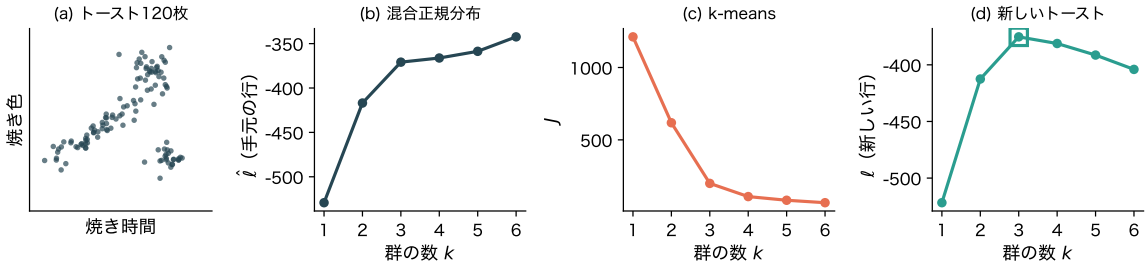


図 1: トースト 120 枚の人工データ。(a) 焼き時間と焼き色、(b) 群の数 k を変えたときの混合正規分布の最大の対数尤度 $\hat{\ell}$、(c) k-means の目的関数 J、(d) 同じ作り方の新しいトーストで測った対数尤度(120 枚あたり、四角が最大)

リデーション、CV)で λ を選んだ。第 7 回の J と第 8 回の $\hat{\ell}$ も、群の数というつまみについて同じ振る舞いをする。本章の問いは、群の数 k をどう選ぶか、である。共分散行列を群ごとにするか共通にするかという型の選び方も、同じ問題として扱う。

本章は次の順に進む。まず候補のモデルを並べ、当てはまりが群とともに良くなる理由を示す。次に、新しい行での当てはまりを手元の行だけから見積もる。これが AIC である。続いて、パラメータの値によらないモデルそのものの出やすさを近似する。これが BIC である。最後に、尤度を持たない k-means のために、行どうしの距離だけで測るシルエット係数を扱う。どれも、式がどこから来たかを導く。

候補のモデル

選ぶ候補を先に並べておく。第 8 回の混合正規分布 $f(\tilde{\boldsymbol{x}}) = \sum_q \pi_q N(\tilde{\boldsymbol{x}}; \boldsymbol{\mu}_q, \boldsymbol{\Sigma}_q)$ は、群の数 k のほかに、共分散行列 $\boldsymbol{\Sigma}_q$ にどれだけの自由を許すかでも大きさが変わる。本章では次の 4 つの型を考える(定義 1)。図 2 は、トーストの 2 変数に 4 つの型で $k = 3$ を当てはめたものである。群ごとの型は楕円の傾きと大きさが群ごとに自由であり、斜めの帯に沿った細長い楕円を描ける。共通の型では、どの群も同じ形の楕円になる。第 6 回の LDA からラベルを隠したものにあたる。対角の型は楕円の軸が座標軸に沿うものに限られ、球の型は群ごとに大きさだけが違う円である。

定義 1 (共分散の型)**.** 混合正規分布の共分散行列について、群ごとに自由な $\boldsymbol{\Sigma}_q$ を持たせるものを群ごとの型(full)、すべての群で共通の $\boldsymbol{\Sigma}$ を持たせるものを共通の型(tied)、群ごとの対角行列 $\boldsymbol{\Sigma}_q = \mathrm{diag}(\sigma_{q1}^2, \ldots, \sigma_{qp}^2)$ とするものを対角の型(diagonal)、群ごとの $\boldsymbol{\Sigma}_q = \sigma_q^2 \mathbf{I}$ とするものを球の型(spherical)と呼ぶ。

これらの候補には、大きいモデルが小さいモデルを特別な場合として含むという関係がある。$k+1$ 群のモデルで最後の群の混合比率を $\pi_{k+1} = 0$ とおけば、k 群のモデルになる。型についても、対角の型で対角の値をそろえれば球の型になる。群ごとの型で非対角を 0 にすれば対角の型に、すべての群を同じにすれば共通の型になる。次の節で見る「当てはまりは群とともに良くなる一方」は、この入れ子の関係から起きる。

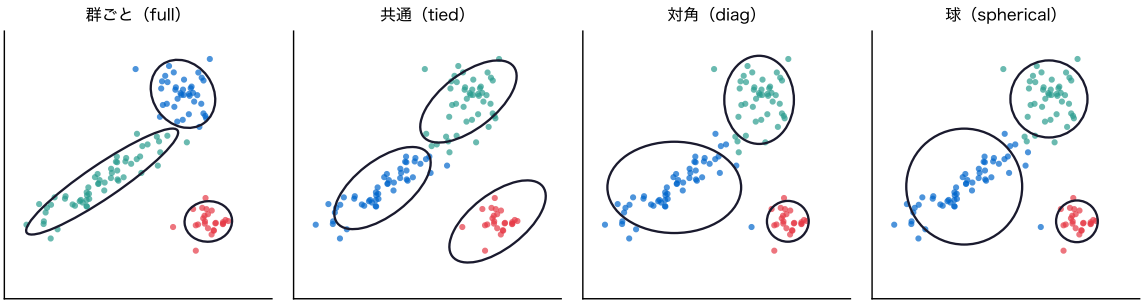


図 2: トースト 120 枚の人工データ（焼き時間と焼き色）に、4 つの共分散の型で $k = 3$ の混合正規分布を当てはめたもの。楕円は推定した $\boldsymbol{\Sigma}_q$ の形

当てはまりは群とともに良くなる

候補ごとに、第 8 回の EM で対数尤度を最大にした値を $\hat{\ell}_k$ と書く。混合比率・平均・共分散をまとめて $\boldsymbol{\theta}$ と書き、k 群のときに $\boldsymbol{\theta}$ がとれる値の範囲を Θ_k とすれば、

$$\hat{\ell}_k = \max_{\boldsymbol{\theta} \in \Theta_k} \mathbf{1}_n^\top \log(\boldsymbol{\Phi} \mathbf{1}_k) \tag{1}$$

である。$\boldsymbol{\Phi}$ は第 8 回と同じく $\phi_{iq} = \pi_q N(\tilde{\boldsymbol{x}}_i; \boldsymbol{\mu}_q, \boldsymbol{\Sigma}_q)$ を並べた $n \times k$ 行列で、$\boldsymbol{\Phi}\mathbf{1}_k$ の第 i 成分が行 i の出やすさにあたる。前の節の入れ子の関係から、k 群の最良の答えは、$\pi_{k+1} = 0$ とおけば $k+1$ 群のモデルでもそのまま作れる。すなわち $\Theta_k \subset \Theta_{k+1}$ と見なせる。最大をとる範囲が広がれば、最大値は下がらない。

$$\hat{\ell}_{k+1} = \max_{\boldsymbol{\theta} \in \Theta_{k+1}} \ell(\boldsymbol{\theta}) \;\geq\; \max_{\boldsymbol{\theta} \in \Theta_k} \ell(\boldsymbol{\theta}) = \hat{\ell}_k \tag{2}$$

図 3 は、トーストで群ごとの型の $\hat{\ell}_k$ を $k = 1, \ldots, 6$ について求めたものである。$\hat{\ell}_k$ は、データを作った群の数 3 を過ぎても上がり続ける。ただし EM は局所解に止まることがある（第 8 回）。初期値を十分に試さないと、実際の計算では (2) 式が崩れて見えることがある。

k-means の J も同じ理由で下がり続ける。第 7 回で見たとおり、1 つの群を 2 つに分けると J は下がる。k 群の最良の答えから、2 行以上ある群を 1 つ割れば $k+1$ 群の候補ができるので、$k+1$ 群の最小値 J_{k+1} は J_k を超えない。

以下では、対数尤度を -2 倍した $-2\hat{\ell}$ を「当てはまりの悪さ」として使う。小さいほど良く、第 1 回の残差平方和と同じ向きになる。共分散が共通の球 $\sigma^2\mathbf{I}$ で所属 $\mathbf{G}$ が見えていれば、-2ℓ は J/σ^2 に定数を足したものになる（第 8 回の k-means の極限で見た関係）。

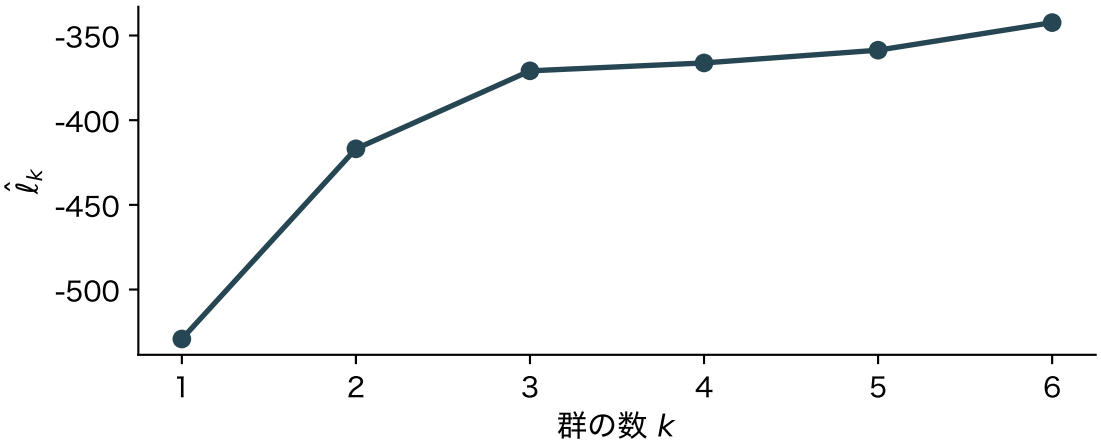


図 3: トーストの人工データで、群ごとの型の混合正規分布の最大の対数尤度 $\hat{\ell}_k$（初期値 10 通りの最良）

パラメータの数

当てはまりの悪さ $-2\hat{\ell}$ は k とともに下がり続けるので、それだけでは選べない。大きいモデルほど動かせるパラメータが多い。その多さを、候補ごとに「自由に動かせるパラメータの数」d で表す。

p 変数・k 群で群ごとの型なら、混合比率は合計が 1 なので、自由に動かせるのは $k-1$ 個である。平均ベクトル $\boldsymbol{\mu}_q$ は p 個ずつで kp 個ある。共分散行列 $\boldsymbol{\Sigma}_q$ は対称で、左下の成分は右上と同じ値なので、対角と上半分の $p(p+1)/2$ 個ずつを数える。合わせて

$$d = (k-1) + kp + k\,\frac{p(p+1)}{2} \tag{3}$$

となる。たとえば 1 変数・2 群なら、π_1、μ_1, μ_2、σ_1^2, σ_2^2 の $d = 1+2+2 = 5$ である。共分散の型を変えると、変わるのは第 3 項だけである。表 1 に、型ごとの共分散の数と、トースト（$p=2$）での d をまとめた。共通の型は k を増やしても共分散の数が増えず、球の型は群ごとに 1 個しか増えない。

表 1: 共分散の型ごとのパラメータの数 d。$p=2$ の列は k の式で書いた

型	共分散の数	d（$p=2$）	d（$p=2$、$k=3$）
群ごと（full）	$k\,p(p+1)/2$	$6k-1$	17
共通（tied）	$p(p+1)/2$	$3k+2$	11
対角（diag）	kp	$5k-1$	14
球（spherical）	k	$4k-1$	11

手元の行は甘い

困りごと③で見たとおり、新しい行で測れば対数尤度は群の数 3 で最大になった。しかし実際のデータでは新しい行は手元に無い。そこで、手元の行だけから、新しい行での当てはまりを見積もる。

データの n 行はどれも、同じ作り方（真の分布）から互いに独立に出たとする。新しく出る 1 行を $\tilde{\boldsymbol{x}}$ と書き、その出方についての期待値を E と書く。パラメータ $\boldsymbol{\theta}$ の新しい行での当てはまりを、n 行の新しいデータで測った対数尤度の期待値

$$\bar{\ell}(\boldsymbol{\theta}) = n\,\mathrm{E}\big[\log f(\tilde{\boldsymbol{x}} \mid \boldsymbol{\theta})\big] \tag{4}$$

で測る。手元の $\ell(\boldsymbol{\theta}) = \sum_{i=1}^{n} \log f(\tilde{\boldsymbol{x}}_i \mid \boldsymbol{\theta})$ と同じ目盛りである。知りたいのは、手元の行で推定した $\hat{\boldsymbol{\theta}}$ の $\bar{\ell}(\hat{\boldsymbol{\theta}})$ である。

図 6 では、トーストを同じ作り方で 100 通り焼き直し、それぞれで $k = 1, \ldots, 6$ を当てはめて平均をとった。手元の行の $-2\hat{\ell}$ は新しい行の $-2\bar{\ell}(\hat{\boldsymbol{\theta}})$ より小さく、手元の行で測ると良く見える。その差は k とともに開く。$\hat{\boldsymbol{\theta}}$ は手元の行に合わせて選んだので、手元の行では甘く測られる。第 2 回の訓練誤差がテスト誤差より小さかったのと同じである。過去問の答えを丸暗記した生徒は、過去問なら満点をとるが、本番の新しい問題では点が下がる。では、差はどれだけか。以下で、n が大きく、モデルがデータの作り方を含むとき、その差は ℓ の目盛りでおよそ d になることを導く。

AIC を導く

差 $b = \mathrm{E}[\ell(\hat{\boldsymbol{\theta}}) - \bar{\ell}(\hat{\boldsymbol{\theta}})]$ を求める。$\bar{\ell}$ を最大にする値を $\boldsymbol{\theta}^*$ とする。データの作り方をモデルが含むなら、$\boldsymbol{\theta}^*$ はデータを作ったパラメータそのものである。導出には、次の 4 つの道具を使う。

定義 2 (2 次のテイラー展開)**.** 1 変数の関数 g について、$u = \theta - \theta_0$ が小さければ

$$g(\theta) \approx g(\theta_0) + g'(\theta_0)\,u + \frac{1}{2}\,g''(\theta_0)\,u^2$$

である。右辺は、点 θ_0 での値・傾き・曲がりの 3 つで作った放物線である。d 次元のベクトル $\boldsymbol{\theta}$ の関数では、$\mathbf{u} = \boldsymbol{\theta} - \boldsymbol{\theta}_0$ として

$$g(\boldsymbol{\theta}) \approx g(\boldsymbol{\theta}_0) + \nabla g(\boldsymbol{\theta}_0)^{\top}\mathbf{u} + \frac{1}{2}\,\mathbf{u}^{\top}\nabla^2 g(\boldsymbol{\theta}_0)\,\mathbf{u}$$

となる。傾きは偏微分を並べた d 次元の勾配 ∇g に、曲がりは 2 階の偏微分を並べた $d \times d$ のヘッセ行列 $\nabla^2 g$ になる。山頂では $\nabla g(\boldsymbol{\theta}_0) = \mathbf{0}$ となり、値と曲がりだけが残る。

定義 2 の放物線は、θ_0 の近くでは g と重なり、離れると外れる（図 4 (a)）。山頂では傾きの項が消えるので、山頂のまわりの山は下向きの放物線に見える（図 4 (b)）。$g''(\theta_0)$ が大きく負なほど、山は鋭い。第 6 回のニュートン法が今の点で山を近似した放物線も、この展開である。以下の導出では、この「山頂のまわりは放物線」という見方を、手元の行の山と新しい行の山の両方に使う。

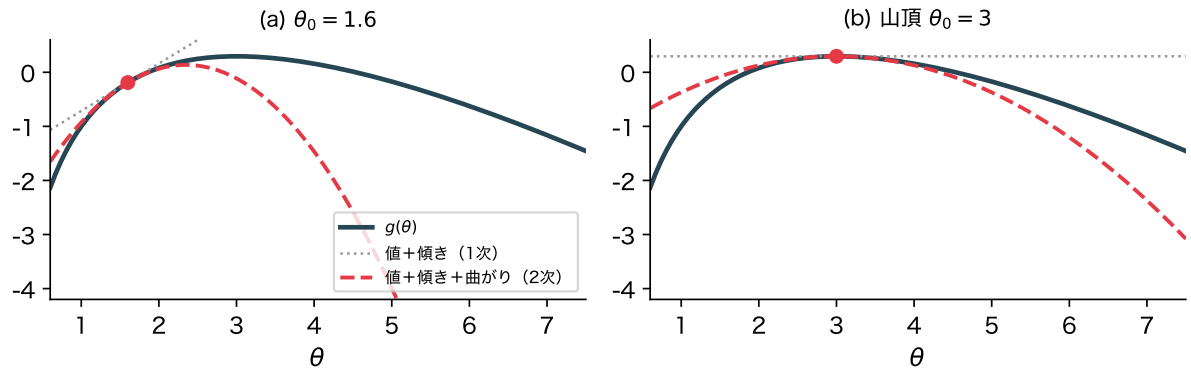


図 4: 1 変数の関数 $g(\theta) = 3\log\theta - \theta$（黒）と、点 θ_0（赤の点）での 1 次の近似（灰の点線）・2 次の近似（赤の破線）。(a) 山頂でない点、(b) 山頂

定義 3 (勾配の展開)**.** 定義 2 の両辺を $\boldsymbol{\theta}$ で微分すると、$\nabla g(\boldsymbol{\theta}) \approx \nabla g(\boldsymbol{\theta}_0) + \nabla^2 g(\boldsymbol{\theta}_0)\,\mathbf{u}$ を得る。対称行列 $\mathbf{A}$ の 2 次形式 $\frac{1}{2}\mathbf{u}^\top\mathbf{A}\mathbf{u}$ の勾配が $\mathbf{A}\mathbf{u}$ だからである（第 8 回）。

定義 4 (2 次形式の期待値)**.** 確率的に変わるベクトル $\mathbf{u}$ と決まった行列 $\mathbf{A}$ について

$$\mathrm{E}[\mathbf{u}^\top\mathbf{A}\mathbf{u}] = \mathrm{tr}(\mathbf{A}\,\mathrm{E}[\mathbf{u}\mathbf{u}^\top])$$

である。$\mathbf{u}^\top\mathbf{A}\mathbf{u}$ は 1 つの数なのでトレースをとっても変わらず、$\mathrm{tr}(\mathbf{P}\mathbf{Q}) = \mathrm{tr}(\mathbf{Q}\mathbf{P})$（第 7 回）で $\mathrm{tr}(\mathbf{A}\mathbf{u}\mathbf{u}^\top)$ と並べ替えられる。トレースは成分の和なので、期待値と順序を入れ替えてよい。

定義 5 (フィッシャー情報行列と情報量の等式)**.** $d \times d$ の行列

$$\mathbf{H} = -\mathrm{E}\big[\nabla^2 \log f(\tilde{\boldsymbol{x}} \mid \boldsymbol{\theta}^*)\big], \qquad \mathbf{V} = \mathrm{E}\big[\nabla \log f(\tilde{\boldsymbol{x}} \mid \boldsymbol{\theta}^*)\, \nabla \log f(\tilde{\boldsymbol{x}} \mid \boldsymbol{\theta}^*)^\top\big]$$

を考える。$\mathbf{H}$ をフィッシャー情報行列（Fisher information matrix）と呼ぶ。モデルがデータの作り方を含むとき、$\mathbf{V} = \mathbf{H}$ が成り立つ。これを情報量の等式と呼ぶ。本章では証明せず、結果だけを使う。

まず、差を 3 つに分ける。$\ell(\boldsymbol{\theta}^*)$ と $\bar{\ell}(\boldsymbol{\theta}^*)$ を足して引けば

$$\ell(\hat{\boldsymbol{\theta}}) - \bar{\ell}(\hat{\boldsymbol{\theta}}) = \underbrace{\ell(\hat{\boldsymbol{\theta}}) - \ell(\boldsymbol{\theta}^*)}_{\text{(i)}} + \underbrace{\ell(\boldsymbol{\theta}^*) - \bar{\ell}(\boldsymbol{\theta}^*)}_{\text{(ii)}} + \underbrace{\bar{\ell}(\boldsymbol{\theta}^*) - \bar{\ell}(\hat{\boldsymbol{\theta}})}_{\text{(iii)}} \tag{5}$$

である。(ii) の期待値は 0 になる。$\boldsymbol{\theta}^*$ はデータによらない決まった値であり、各行は新しい行と同じ作り方で出るので、$\mathrm{E}[\ell(\boldsymbol{\theta}^*)] = \sum_i \mathrm{E}[\log f(\tilde{\boldsymbol{x}}_i \mid \boldsymbol{\theta}^*)] = \bar{\ell}(\boldsymbol{\theta}^*)$ となるからである。

(i) は、定義 2 を $\hat{\boldsymbol{\theta}}$ のまわりで ℓ に使う。$\hat{\boldsymbol{\theta}}$ は ℓ の山頂なので勾配は $\mathbf{0}$ である。ヘッセ行列 $\nabla^2\ell$ は n 行の和なので、n が大きければ $-n\mathbf{H}$ に近い。$\mathbf{u} = \hat{\boldsymbol{\theta}} - \boldsymbol{\theta}^*$ と書けば

$$\ell(\boldsymbol{\theta}^*) \approx \ell(\hat{\boldsymbol{\theta}}) - \frac{1}{2}\,\mathbf{u}^\top(n\mathbf{H})\,\mathbf{u}$$

となり、(i) $\approx \frac{1}{2}\mathbf{u}^\top(n\mathbf{H})\mathbf{u}$ を得る。(iii) は、同じ展開を $\boldsymbol{\theta}^*$ のまわりで $\bar{\ell}$ に使う。$\boldsymbol{\theta}^*$ は $\bar{\ell}$ の山頂で、(4) 式より $\nabla^2\bar{\ell}(\boldsymbol{\theta}^*) = -n\mathbf{H}$ である。したがって $\bar{\ell}(\hat{\boldsymbol{\theta}}) \approx \bar{\ell}(\boldsymbol{\theta}^*) - \frac{1}{2}\mathbf{u}^\top(n\mathbf{H})\mathbf{u}$ となり、(iii) も同じ大きさになる。

図 5 は、これを 1 変数で描いたものである。手元の行の山 ℓ は、新しい行の山 $\bar{\ell}$ から頂上が u だけずれている。(i) は手元の山を $\hat{\theta}$ から θ^* まで下りた高さ、(iii) は新しい山を θ^* から $\hat{\theta}$ まで下りた高さである。山頂のまわりはどちらも同じ曲がり $-nH$ の放物線なので、2 つの高さはどちらも $\frac{1}{2}nH\,u^2$ になる。

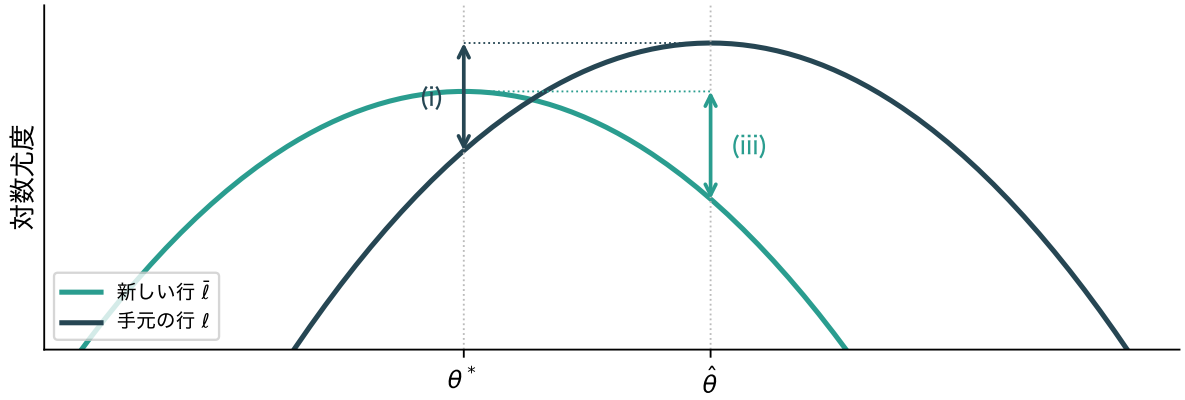


図 5: 1 変数で見た 2 つの山。新しい行の対数尤度 $\bar{\ell}$（緑、山頂 θ^*）と手元の行の対数尤度 ℓ（紺、山頂 $\hat{\theta}$）。(i) と (iii) は、それぞれの山を相手の山頂の位置まで下りた高さ

両端を足して期待値をとり、定義 4 を使えば

$$b \approx \mathrm{E}\big[\mathbf{u}^\top(n\mathbf{H})\,\mathbf{u}\big] = \mathrm{tr}(n\mathbf{H}\,\mathrm{E}[\mathbf{u}\mathbf{u}^\top]) \tag{6}$$

である。残るのは、$\hat{\boldsymbol{\theta}}$ のずれ $\mathbf{u}$ のばらつきである。定義 3 を $\boldsymbol{\theta}^*$ のまわりで $\nabla\ell$ に使えば、山頂 $\hat{\boldsymbol{\theta}}$ では勾配が $\mathbf{0}$ なので

$$\mathbf{0} = \nabla\ell(\hat{\boldsymbol{\theta}}) \approx \nabla\ell(\boldsymbol{\theta}^*) - n\mathbf{H}\,\mathbf{u}, \qquad \mathbf{u} \approx (n\mathbf{H})^{-1}\nabla\ell(\boldsymbol{\theta}^*)$$

となる（$\mathbf{H}$ に逆行列があるとした）。$\nabla\ell(\boldsymbol{\theta}^*) = \sum_i \nabla \log f(\tilde{\boldsymbol{x}}_i \mid \boldsymbol{\theta}^*)$ は独立な n 個の和である。各項の期待値は $\nabla\bar{\ell}(\boldsymbol{\theta}^*)/n = \mathbf{0}$ である。外積の期待値をとると、異なる行どうしの交差項は期待値が 0 で消え、同じ行どうしの $\mathbf{V}$ が n 個残る。よって $\mathrm{E}[\nabla\ell\,\nabla\ell^\top] = n\mathbf{V}$、$\mathrm{E}[\mathbf{u}\mathbf{u}^\top] \approx (n\mathbf{H})^{-1}n\mathbf{V}(n\mathbf{H})^{-1}$ である。これを (6) 式に入れると、n は約分で消えて

$$b \approx \mathrm{tr}(\mathbf{V}\mathbf{H}^{-1}) = \mathrm{tr}(\mathbf{I}_d) = d \tag{7}$$

となる。最後の等号は 定義 5 の $\mathbf{V} = \mathbf{H}$ である。

1 変数で読むと、なぜ 1 になるかが見える。$d = 1$ なら $b \approx nH\,\mathrm{E}[u^2]$ で、$\mathrm{E}[u^2] \approx 1/(nH)$ である。山が鋭い（nH が大きい）と、$\hat{\theta}$ はあまりずれないが、少しずれただけで大きく下がる。山がなだらかなら、$\hat{\theta}$ は大きくず

れるが、あまり下がらない。2 つが打ち消し合い、山の形によらず $b \approx 1$ になる。パラメータが d 個なら、1 ずつ足して d になる。

手元の $\hat{\ell}$ は、新しい行での当てはまりより平均でおよそ d だけ大きい。パラメータ 1 つにつき、手元の行に合わせた分だけ甘く測られる。そこで $\bar{\ell}(\hat{\boldsymbol{\theta}})$ を $\hat{\ell} - d$ で見積もり、-2 倍して比べる。

定義 6 (AIC)**.** 候補のモデルの最大の対数尤度を $\hat{\ell}$、パラメータの数を d として

$$\mathrm{AIC} = -2\hat{\ell} + 2d \tag{8}$$

を赤池情報量規準（Akaike information criterion）（AIC）と呼ぶ。AIC が最も小さい候補を選ぶ。$2d$ を罰則と呼ぶ。

図 6 の赤い線は、100 通りの平均の AIC である。$k \le 3$ では、新しい行の $-2\bar{\ell}(\hat{\boldsymbol{\theta}})$ の平均とほぼ重なり、(7) 式のとおりの見積もりになっている。$k > 3$ では、AIC が新しい行の悪さより小さく出た。表 2 のとおり、実際の差は $2d$ より大きい。

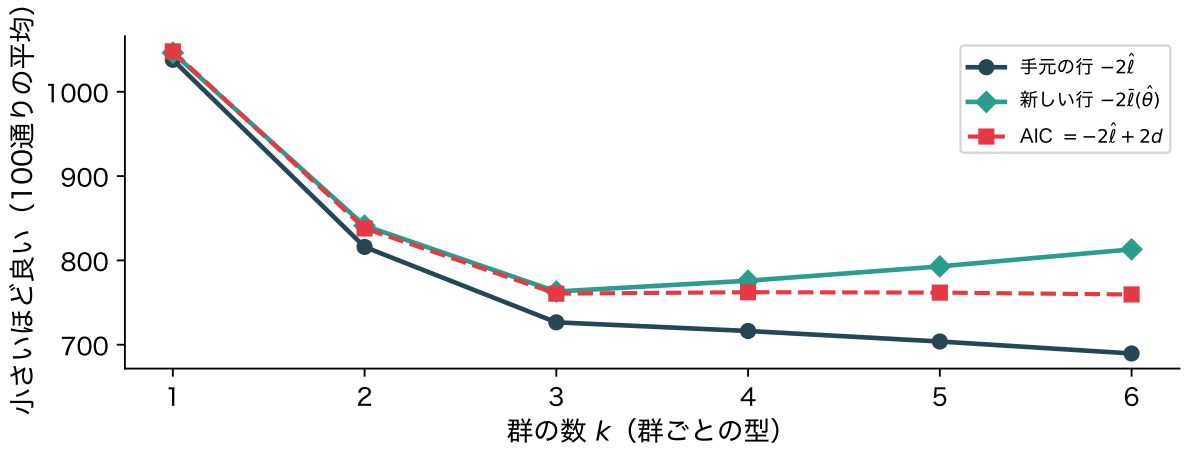


図 6: トーストを同じ作り方で 100 通り焼き直し、群ごとの型の混合正規分布を当てはめたときの、手元の行の $-2\hat{\ell}$、新しい行の $-2\bar{\ell}(\hat{\boldsymbol{\theta}})$、AIC の平均

表 2: AIC の罰則 $2d$ と、100 通りの平均で測った手元の行と新しい行の差（-2 倍の目盛り）

k	1	2	3	4	5	6
$2d$	10	22	34	46	58	70
実際の差 $-2\bar{\ell}(\hat{\boldsymbol{\theta}}) + 2\hat{\ell}$	8.3	25.3	36.6	59.6	89.1	123.5

ずれの理由は、導出の前提にある。作った群は 3 つなので、$k > 3$ のモデルには余分な群がある。余分な群は、混合比率が 0 ならどこに置いても同じ分布を表す。そのため $\bar{\ell}$ の山頂 $\boldsymbol{\theta}^*$ が 1 点に決まらず、$\mathbf{H}$ に逆行列が無い。定義 2 による近似も、定義 5 の等式も、そのままでは使えない。群の数が多すぎる候補では、AIC は新しい行

での当てはまりを甘く見積もる。それでも困りごと③には答えられる。新しい行が無くても、手元の行の $\hat{\ell}$ からパラメータの数 d を引けば、新しい行での当てはまりを見積もれる。

周辺尤度

AIC は「新しい行をよく出すモデル」を目指した。別の問い方もある。このデータは、どの群の数のモデルから出たのか。この問いには、パラメータの値によらないモデルそのものの出やすさで答える。

パラメータ $\boldsymbol{\theta}$ がデータを見る前にどう散らばっているかを、密度 $p(\boldsymbol{\theta})$ で表す。これを事前分布（prior distribution）と呼ぶ。データの出やすさ $\exp(\ell(\boldsymbol{\theta}))$ を事前分布で平均したもの

$$p(\mathbf{X} \mid M_k) = \int \exp(\ell(\boldsymbol{\theta}))\, p(\boldsymbol{\theta})\, d\boldsymbol{\theta} \tag{9}$$

を、群の数 k のモデル M_k の周辺尤度（marginal likelihood）と呼ぶ。第 6 回・第 8 回のベイズの定理を、群の代わりにモデルに使えば

$$\Pr(M_k \mid \mathbf{X}) = \frac{p(\mathbf{X} \mid M_k)\Pr(M_k)}{\sum_{k'} p(\mathbf{X} \mid M_{k'})\Pr(M_{k'})}$$

となる。どのモデルも同じ確率 $\Pr(M_k)$ で選ばれるとすれば、データを見た後で最も確からしいモデルは、周辺尤度が最大のモデルである。

周辺尤度は、最大値 $\exp(\hat{\ell})$ そのものではなく、平均である。図 7 に、1 変数の正規分布 $N(\mu, 1)$ の平均 μ だけを推定する場合の $\exp(\ell(\mu) - \hat{\ell})$ を描いた。最大値を 1 にそろえた当てはまりの山は、n が増えると幅 $1/\sqrt{n}$ で細くなる。一方、事前分布の幅は n によらない。そのため、山を事前分布で平均すると、山の幅の分だけ値が割り引かれる。パラメータが d 個なら、山は d 方向のそれぞれに細いので、割引はおよそ $n^{-d/2}$ になる。以下でこれを導く。

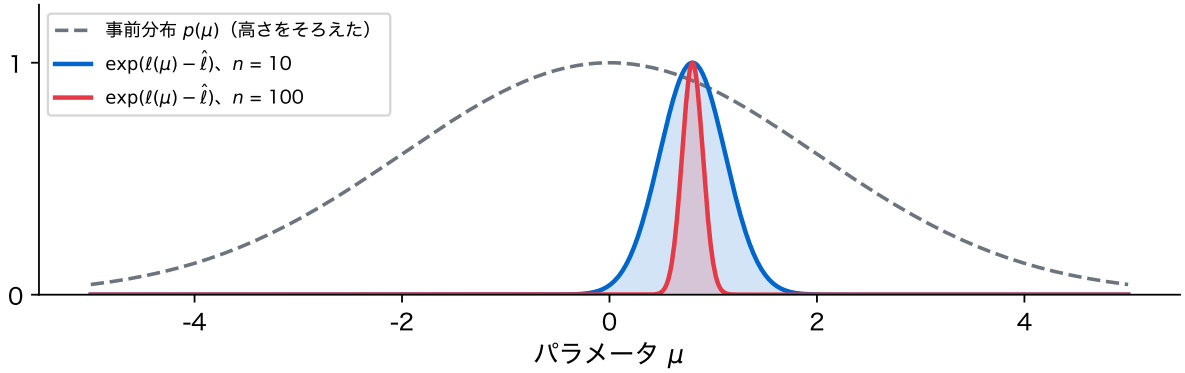


図 7: 1 変数の正規分布の平均 μ について、最大値を 1 にそろえた当てはまり $\exp(\ell(\mu) - \hat{\ell})$ と事前分布（概念図）。n が 10 倍になると、山の幅は $1/\sqrt{10}$ 倍になる

BIC を導く

周辺尤度 (9) 式を、n が大きいとして近似する。導出には、定義 2 に加えて次の 2 つの道具を使う。

定義 7 (正規分布の積分)**.** $d \times d$ の正定値行列 $\mathbf{A}$ について

$$\int \exp\Bigl(-\frac{1}{2}\,\mathbf{u}^{\top}\mathbf{A}\,\mathbf{u}\Bigr)\,d\mathbf{u} = (2\pi)^{d/2}\det(\mathbf{A})^{-1/2}$$

である。平均 $\mathbf{0}$・共分散行列 $\mathbf{A}^{-1}$ の多変量正規分布の密度(第 5 回)は、積分すると 1 になる。その密度の分母 $(2\pi)^{d/2}\det(\mathbf{A}^{-1})^{1/2}$ を払えば、この式になる。

定義 8 (行列式とスカラー倍)**.** $d \times d$ の行列 $\mathbf{A}$ とスカラー n について、$\det(n\mathbf{A}) = n^{d}\det(\mathbf{A})$ である。行列式は各列について線形なので、d 本の列をそれぞれ n 倍すると、n が d 回かかる。

最尤推定値 $\hat{\boldsymbol{\theta}}$ のまわりで、定義 2 を ℓ に使う。山頂なので勾配は $\mathbf{0}$ である。$-\nabla^{2}\ell(\hat{\boldsymbol{\theta}})$ は n 行の和なので、1 行あたりの行列 $\hat{\mathbf{H}}$ を使って $n\hat{\mathbf{H}}$ と書く。$\mathbf{u} = \boldsymbol{\theta} - \hat{\boldsymbol{\theta}}$ とすれば

$$\ell(\boldsymbol{\theta}) \approx \hat{\ell} - \frac{1}{2}\,\mathbf{u}^{\top}(n\hat{\mathbf{H}})\,\mathbf{u}$$

である。$\exp(\ell)$ は、$\hat{\boldsymbol{\theta}}$ を中心に幅がおよそ $1/\sqrt{n}$ の山になる。山の外では $\exp(\ell)$ はほぼ 0 であり、山の中では事前分布はほぼ $p(\hat{\boldsymbol{\theta}})$ のまま変わらない。したがって

$$p(\mathbf{X} \mid M_k) \approx \exp(\hat{\ell})\,p(\hat{\boldsymbol{\theta}}) \int \exp\Bigl(-\frac{1}{2}\,\mathbf{u}^{\top}(n\hat{\mathbf{H}})\,\mathbf{u}\Bigr)\,d\mathbf{u} = \exp(\hat{\ell})\,p(\hat{\boldsymbol{\theta}})\,(2\pi)^{d/2}\,n^{-d/2}\det(\hat{\mathbf{H}})^{-1/2}$$

となる。等号では 定義 7 を $\mathbf{A} = n\hat{\mathbf{H}}$ で使い、定義 8 で $\det(n\hat{\mathbf{H}}) = n^{d}\det(\hat{\mathbf{H}})$ とした。log をとれば

$$\log p(\mathbf{X} \mid M_k) \approx \hat{\ell} - \frac{d}{2}\log n + \Bigl[\log p(\hat{\boldsymbol{\theta}}) + \frac{d}{2}\log 2\pi - \frac{1}{2}\log\det\hat{\mathbf{H}}\Bigr] \tag{10}$$

である。$\hat{\ell}$ は n に比例して大きくなり、$\log n$ もゆっくり増える。かっこの中は n が増えても増えない。かっこの中を捨てて -2 倍したものが、次の BIC である。

定義 9 (BIC)**.** 候補のモデルの最大の対数尤度を $\hat{\ell}$、パラメータの数を d、行の数を n として

$$\mathrm{BIC} = -2\hat{\ell} + d\log n \tag{11}$$

をベイズ情報量規準(Bayesian information criterion)(BIC)と呼ぶ。BIC が最も小さい候補を選ぶ。

BIC は、周辺尤度の -2 倍の近似である。罰則 $d\log n$ は、当てはまりの山が d 方向に幅 $1/\sqrt{n}$ で細くなる分の割引にあたる。事前分布の形は、捨てたかっこの中にしか残らない。旅行の荷物にたとえれば、荷物を増やすほど旅先では困らないが、1 個ごとに超過料金がかかる。困る度合いと料金の合計が最小になる数で止めるのと同じである。BIC の料金は、パラメータ 1 つごとに $\log n$ である。導出では、$\hat{\boldsymbol{\theta}}$ のまわりの山が 1 つで、$\hat{\mathbf{H}}$ に逆行列があるとした。AIC と同じく、群が多すぎる候補では、この前提は成り立たない。

AIC と BIC の違い

AIC と BIC は、式の形が同じで罰則の重みだけが違う。

$$\mathrm{AIC} = -2\hat{\ell} + 2d, \qquad \mathrm{BIC} = -2\hat{\ell} + d\log n$$

$n \geq 8$ なら $\log n > 2$ なので、BIC の方が罰則が重く、小さいモデルを選びやすい。しかし違いは重みの大小だけではない。n を増やしたときの振る舞いが違う。

データを作った群の数を k_0 とする。群が足りない $k < k_0$ から 1 つ増やすと、モデルは初めてデータの作り方を表せるようになる。1 行あたりの当てはまりが一定の量だけ良くなるので、$-2\hat{\ell}$ の下がり幅は n に比例して育つ。$\log n$ で育つ BIC の罰則にも、一定の AIC の罰則にも、やがて勝つ。一方、k_0 から余分な群を足しても、作り方そのものはもう表せている。余分な群は手元の行の揺らぎに合わせるだけで、$-2\hat{\ell}$ の下がり幅は n が増えても大きくならない。AIC の罰則は一定なので、揺らぎがたまたま大きい回には負ける。BIC の罰則は $\log n$ で育つので、やがて負けなくなる。こうして、n を増やすと BIC はデータを作った群の数を選ぶ割合が 1 に近づき、AIC は多めの群を一定の割合で選び続ける。

図 8 は、トーストを同じ作り方で行の数だけ変えて（1 枚ごとに台を 60:25:35 の割合で選ぶ）、各 n で 60 通り作り直し、BIC と AIC が選んだ k を数えたものである。BIC は $n = 30$ では 3 を選んだのが 27% にとどまった（行が少なく、$k = 6$ の $d = 35$ が行の数を超える）。しかし $n = 120$ では 100% が 3 を選び、その先もいつも 3 を選んだ。AIC は $n = 1920$ でも 13% が 3 より大きい k を選んだ。

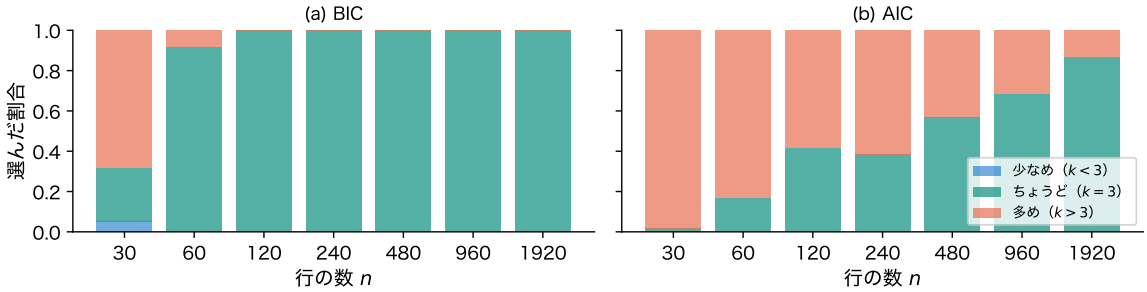


図 8: トーストの人工データを行の数 n を変えて 60 通りずつ作り直し、(a) BIC、(b) AIC が選んだ群の数を、作った 3 より少ない・ちょうど・多いで数えた割合

元のトースト 120 枚では、BIC は $k = 3$ で最小になった（図 9）。谷の位置は、群を 1 つ増やしたときの $-2\hat{\ell}$ の下がり幅と、罰則の増分を比べれば読める。群ごとの型で $p = 2$ なら、1 群あたり混合比率 1・平均 2・共分散 3 の 6 個のパラメータが増える。$k = 2$ から 3 へは $-2\hat{\ell}$ が 92.1 下がり、罰則の増分 $6\log n = 28.7$ を上回る。3 から 4 へは 9.3 しか下がらず、届かない。AIC の罰則の増分は 1 群あたり 12 しかないので、同じデータで AIC は $k = 6$ を選んだ。

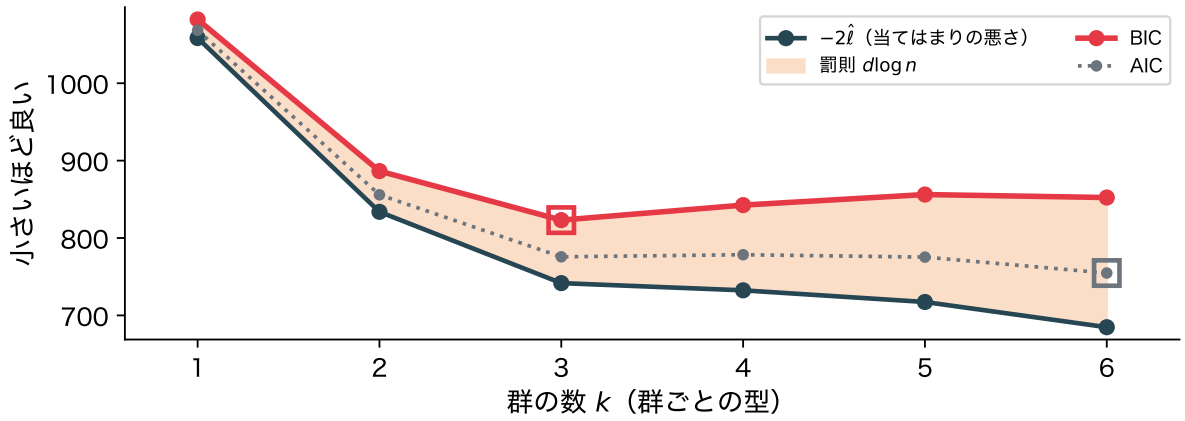


図 9: トースト 120 枚で、群ごとの型の混合正規分布の当てはまりの悪さ $-2\hat{\ell}$、BIC（橙の幅が罰則 $d\log n$）、AIC。四角は BIC と AIC が選んだ k

型も同じ表で選べる。図 10 は 4 つの型の BIC を並べたものである。最小は群ごとの型の $k = 3$（823.1）である。斜めの帯を描けない球や対角の型では、帯を何個もの群でつなぐ。そのため BIC は大きい k まで下がり続け、最小値も群ごとの型に届かない。これで困りごと①に答えられる。$\hat{\ell}$ は上がり続けても、罰則を足せば谷ができる。k と型を同じ表に並べ、谷の底を選べばよい。

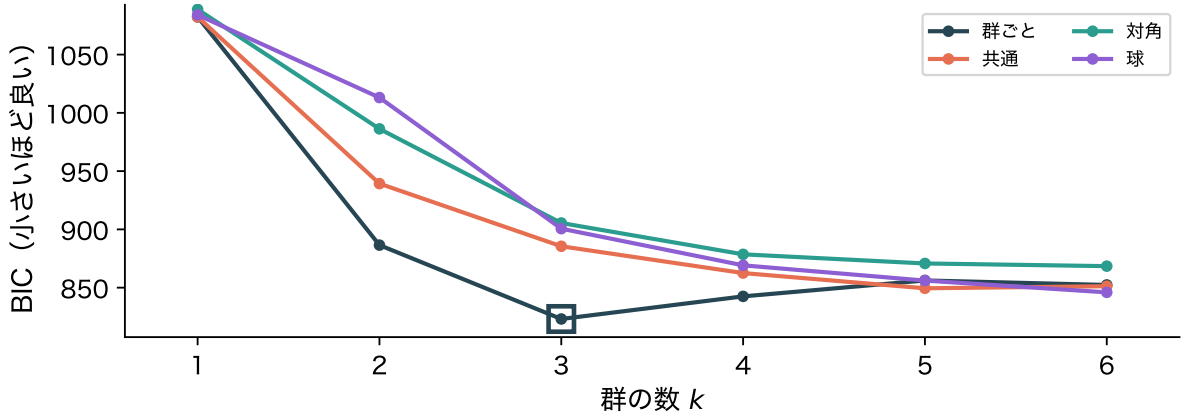


図 10: 図 9 と同じ人工データで、4 つの共分散の型の BIC を並べたもの。四角が最小

距離で測る：シルエット係数

k-means の目的関数 J は尤度ではないので、AIC にも BIC にもならない。では、新しい行で J を測ったらどうか。図 11 は、トースト 120 枚で k-means の代表点を求め、同じ作り方の新しいトースト 12 万枚で、最も近い代表点までの距離の二乗を測ったものである（120 枚あたり）。新しい行で測っても、J は 1,132.0 から 76.1 まで下がり続ける。困りごと③の対数尤度のような山は無い。

違いは、距離と密度の性質にある。代表点を 1 つ足しても、どの点にとっても「最も近い代表点までの距離」は伸

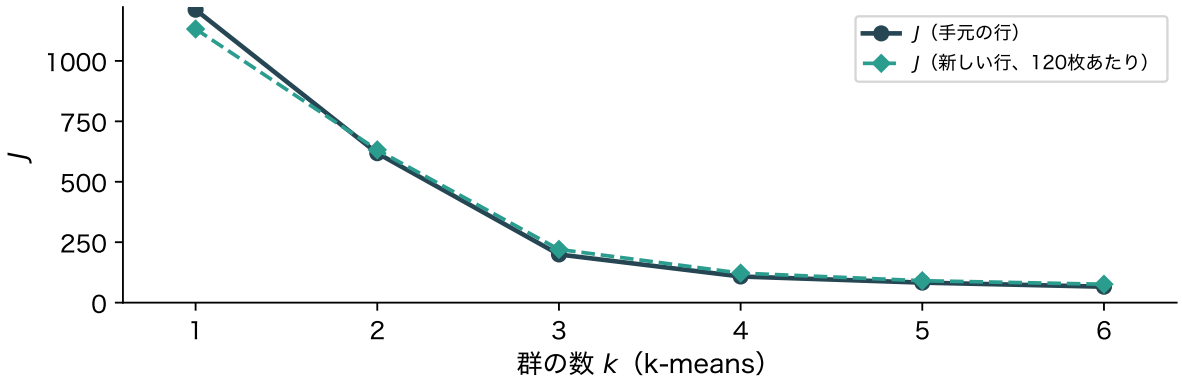


図 11: トーストの人工データで、k-means の J を手元の行と、同じ作り方の新しい行(120 枚あたり)で測ったもの

びない。最小をとる範囲が広がるだけだからである。新しい行についても同じなので、J は新しい行でも下がる。一方、混合正規分布の密度は、積分すると必ず 1 になる。群を増やして手元の行のそばに出やすさを寄せると、その分だけほかの場所の出やすさが減る。新しい行が手元の行と少しずれた所に出ると、出やすさは下がる。新しい行で測る考え方が使えるのは、モデルが新しい行の出やすさを言えるときである。そこで k-means には、確率のモデルを使わず、行どうしの距離だけで群の分け方を測る物差しを使う。

シルエット係数

確率のモデルを使わず、行どうしの距離だけで群の分け方を測る。

定義 10 (シルエット係数)**.** 群 q に属する行 i について、同じ群のほかの行までの距離の平均を a_i、ほかの群 q' の行までの距離の平均のうち最小のものを b_i とする。

$$a_i = \frac{1}{n_q - 1} \sum_{i' \in q,\ i' \neq i} \|\boldsymbol{x}_i - \boldsymbol{x}_{i'}\|_2, \qquad b_i = \min_{q' \neq q} \frac{1}{n_{q'}} \sum_{i' \in q'} \|\boldsymbol{x}_i - \boldsymbol{x}_{i'}\|_2 \tag{12}$$

$s_i = (b_i - a_i)/\max(a_i, b_i)$ を行 i のシルエット(silhouette)、その全行の平均 $\bar{s} = \frac{1}{n}\sum_i s_i$ をシルエット係数(silhouette coefficient)と呼ぶ。1 行だけの群の行は $s_i = 0$ とする。$\bar{s}$ が最も大きい k を選ぶ。

図 12 (a) は、トーストの 2 列を k-means で 3 群に分け、★の行について a_i と b_i を求めたものである($a_i = 1.63$、$b_i = 4.00$、$s_i = 0.59$)。(b) は全行の s_i を群ごとに大きい順に並べたもので、平均が $\bar{s} = 0.67$ である。

行列で書くと、第 7 回の所属行列 $\mathbf{G}$ がそのまま使える。行どうしの距離 $\|\boldsymbol{x}_i - \boldsymbol{x}_{i'}\|_2$ を並べた $n \times n$ 行列を $\mathbf{D}$ とすると、

$$\mathbf{M} = \mathbf{D}\,\mathbf{G}\,(\mathbf{G}^\top \mathbf{G})^{-1} \tag{13}$$

の (i, q) 成分 m_{iq} は、行 i から群 q の行までの距離の平均である。$\mathbf{DG}$ が群ごとの距離の和を作り、対角行列 $(\mathbf{G}^\top\mathbf{G})^{-1}$ が群の大きさで割る。b_i は、行 i の自分の群以外の列の最小値である。a_i は、自分の群の列の値 m_{iq}

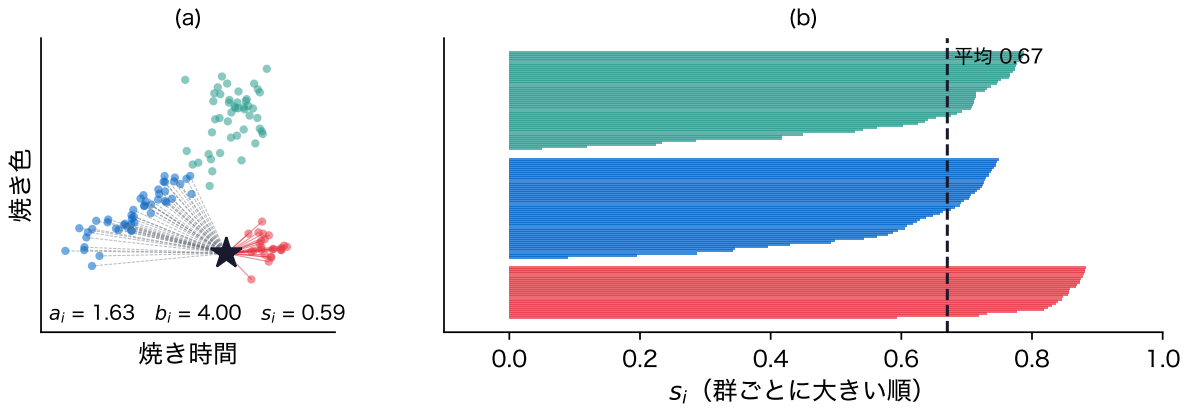


図 12: トーストの人工データを k-means で 3 群に分けたときのシルエット。(a) ★の行から同じ群の行（実線）と、隣の群の行（破線）までの距離、(b) 全行の s_i を群ごとに並べたもの。破線が平均 $\bar{s}$

に $n_q/(n_q-1)$ を掛けたものである（自分との距離 0 を平均から除くため）。

s_i には 3 つの性質がある。1 つ目に、$-1 \le s_i \le 1$ である。$a_i \le b_i$ なら $s_i = 1 - a_i/b_i$、$a_i > b_i$ なら $s_i = b_i/a_i - 1$ と書ける。距離は 0 以上なので、どちらの比も 0 以上 1 以下だからである。$s_i = 1$ になるのは $a_i = 0$、すなわち自分の群が 1 点にまとまっているときである。たとえば $a_i = 1$、$b_i = 4$ なら $s_i = 1 - 1/4 = 0.75$ となる。

2 つ目に、s_i は目盛りによらない。すべての列を c 倍（$c > 0$）すると、距離はどれも c 倍になり、$s_i = (cb_i - ca_i)/\max(ca_i, cb_i)$ は元の値に戻る。J は c^2 倍になる。s_i は距離の比だけを見るので、k の違う答えどうしを同じ物差しで比べられる。

3 つ目に、群を細かく割りすぎると $\bar{s}$ は下がる。すべての行が 1 行だけの群になる $k = n$ では、約束によりすべての s_i が 0 になり、$\bar{s} = 0$ である。J は $k = n$ で 0 になり最良なのと対照的である。花見のシートにたとえるとわかりやすい。自分のシートの仲間までの平均の距離が a、隣のシートの人までの平均の距離が b である。1 つのまとまりを無理に 2 つのシートに分けると、隣のシートがすぐそばになり、b が小さくなる。そのため $\bar{s}$ は k とともに上がり続けるとは限らない。

図 13 は、トーストの k-means の答えについて $k = 2, \dots, 6$ のシルエット係数を求めたものである。$\bar{s}$ は $k = 3$ で最大の 0.67 になった。これで困りごと②に答えられる。k-means には尤度が無くても、行どうしの距離から $\bar{s}$ は求まり、その山の k を選べばよい。

計算の手順

3 つの選び方を、実際に計算する形で手順にまとめる。

1. 候補として、群の数 $k = 1, \dots, k_{\max}$ と 4 つの共分散の型の組を並べる
2. 候補ごとに、全 n 行のデータ行列 $\mathbf{X}$ に第 8 回の EM をランダムスタートで回し、最大の対数尤度 $\hat{\ell} = \mathbf{1}_n^\top \log(\hat{\boldsymbol{\Phi}}\mathbf{1}_k)$ を求める

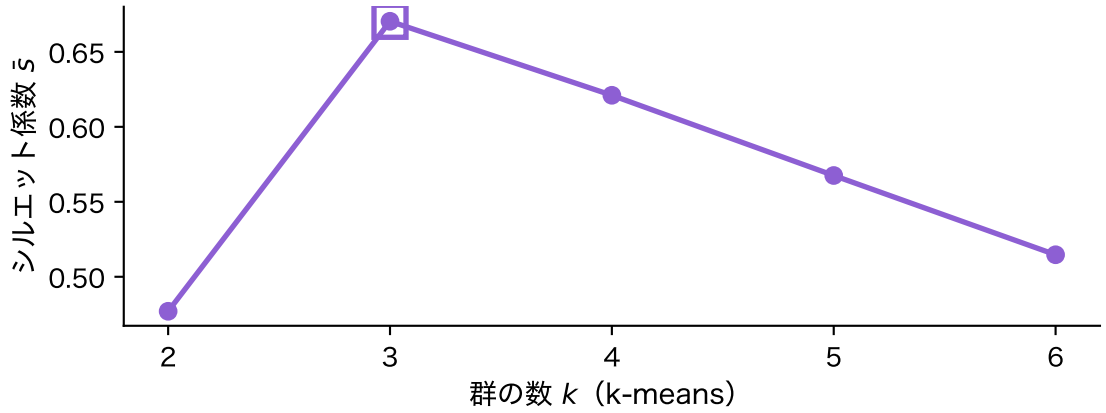


図 13: トーストの人工データを k-means で分けたときのシルエット係数 $\bar{s}$。四角が最大

3. 候補ごとに 表 1 でパラメータの数 $d(k, \text{型})$ を数え、(8) 式の AIC と (11) 式の BIC を、行が k・列が型の表 **A**、**B** に入れる
4. 新しい行をよく出すモデルが欲しければ **A** の最小を、データを作ったモデルを選びたければ **B** の最小を選ぶ
5. k-means のときは、$k = 2, 3, \ldots$ ごとに初期値を変えて最良の所属行列 **G** を求め、(13) 式の **M** から $\bar{s}$ を計算し、最大の k を選ぶ

どれも候補ごとに 1 回の当てはめで済む。

3 つの物差し

表 3 に 3 つの物差しをまとめる。AIC は新しい行での当てはまりを、手元の行の甘さ d を足し戻して見積もる。BIC は、パラメータの値によらないモデルそのものの出やすさを、当てはまりの山で近似する。シルエット係数は、行どうしの距離の比で群の離れ方を測る。尤度を使う 2 つは k-means には使えず、シルエット係数は確率のモデルを持たない k-means にも使える。

表 3: 群の数を選ぶ 3 つの物差し

	AIC	BIC	シルエット係数
測るもの	新しい行での当てはまり	モデルそのものの出やすさ	自分の群への近さ、隣からの遠さ
導き方	手元の甘さ d を足し戻す	周辺尤度を山で近似	距離の比
要るもの	尤度と d	尤度と d、n	行どうしの距離
n を増やすと	多めの k が残る	作った k に近づく	—
k-means に	使えない	使えない	使える

どの物差しも、推定そのものではない。第 1〜8 回では、推定法（最小二乗法か最尤法か）と、何をするか（y を近似

するか、行を群に分けるか）で決まるマスの中で、パラメータを推定してきた（表 4）。本章の物差しは、そのマスの中の推定を候補ごとに回し、結果を外から比べる。モデルの大きさを決める手続きは、推定の一段外側にある。

表 4: 推定法と、何をするかで並べた回。本章は各マスのモデルの大きさを選ぶ

	最小二乗法	最尤法
y を近似する	第 1 回・第 5 回	第 6 回
行を群に分ける	第 7 回（k-means）	第 8 回（混合正規分布）

第 II 部　実データ解析

間欠泉のデータと手続き

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データ（トースト）は、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

データには、イエローストーン国立公園の間欠泉オールドフェイスフルの 272 回の噴出を使う。1 行が 1 回の噴出で、列は噴出の続いた時間（平均 3.49 分、標準偏差 1.14 分）と、次の噴出までの待ち時間（平均 70.9 分、標準偏差 13.6 分）である。データは R の datasets パッケージにある faithful で、Rdatasets から CSV で取得した。出典は Härdle（1991）で、R とともに GPL で配布されている。図 14 のとおり、長く噴いた回ほど次まで長く待つ（相関 0.90）。点は短い噴出と長い噴出の 2 つの塊に分かれて見える。このデータには正解の列が無く、何種類の噴出があるかは、選んだ答えを読んで考えるしかない。

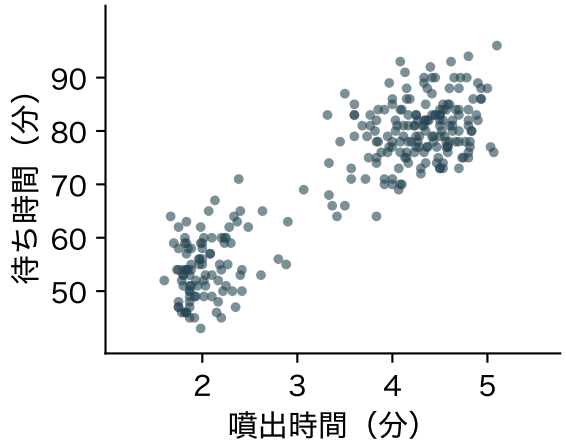


図 14: オールドフェイスフル間欠泉の 272 回の噴出。噴出時間と待ち時間（縦横は標準偏差でそろえ、目盛りは分で書いた）

第 I 部からは、次の 4 つを予想できる。1 つ目に、大きいモデルは小さいモデルを含むので、どの型でも $\hat{\ell}$ は k とともに上がり続けるはずである。2 つ目に、BIC はデータを作ったモデルを目指す。点は斜めに伸びた 2 つ

の塊に見えるので、BIC は群ごとの型・$k = 2$ を選ぶと見込める。3 つ目に、AIC は罰則が軽く、群の多い側へ振れやすいので、BIC と同じか、より多い群を選ぶはずである。4 つ目に、k-means のシルエット係数も、離れた 2 つの塊を選ぶはずである。

次の手続きで計算した。2 列はそれぞれ平均 0・標準偏差 1 にそろえた。そろえないと、対角の型や球の型の楕円が、散らばりの大きい待ち時間の向きにばかり合わせられてしまう（第 7 回で列の目盛りが J を変えたのと同じ）。候補は $k = 1, \dots, 6$ と 4 つの型の組の 24 通りである。候補ごとに、scikit-learn の GaussianMixture で EM を初期値 20 通りから回し、最大の対数尤度 $\hat{\ell}$ を求めた（共分散行列の対角に 10^{-6} を足すのは第 8 回と同じ）。パラメータの数 d は 表 1 のとおり自分で数え、AIC と BIC を計算した（ライブラリが返す BIC との差は 24 通りで最大 0.0e+00）。k-means は初期値 20 通りの最良の答えを $k = 2, \dots, 6$ で求め、(13) 式でシルエット係数を計算した。

BIC で選ぶ

予想①から見る。表 5 は 24 通りの $\hat{\ell}$ である。どの型でも k とともに下がらず、(2) 式が成り立っている。予想どおりである。

表 5: 間欠泉の 272 回の噴出（2 列、標準化）で、24 通りの候補に当てはめた最大の対数尤度 $\hat{\ell}$

型	$k=1$	$k=2$	$k=3$	$k=4$	$k=5$	$k=6$
群ごと	-545.0	-385.5	-369.6	-361.3	-357.4	-350.2
共通	-545.0	-395.4	-381.5	-376.0	-371.4	-371.3
対角	-771.9	-403.0	-382.2	-368.1	-361.0	-357.1
球	-771.9	-423.3	-401.2	-385.5	-376.9	-369.0

次に予想②を見る。表 6 に 24 通りの候補の BIC を示す。最小は共通の型・$k = 3$ の 824.7 で、2 番目の候補との差は 5.8 であった。目で見た 2 つの塊を描く群ごとの型・$k = 2$ は選ばれず、予想は外れた。

表 6: 間欠泉の 272 回の噴出で、24 通りの候補の BIC（★が最小）

型	$k=1$	$k=2$	$k=3$	$k=4$	$k=5$	$k=6$
群ごと	1,118.0	832.6	834.6	851.5	877.4	896.5
共通	1,118.0	835.6	824.7 ★	830.5	838.0	854.8
対角	1,566.2	856.5	842.9	842.7	856.5	876.7
球	1,560.6	885.9	864.0	855.2	860.4	866.9

外れた理由を、第 I 部の道具で順に見る。まず群ごとの型の中だけで比べる。第 I 部の「谷の位置」と同じく、群を 1 つ増やしたときの $-2\hat{\ell}$ の下がり幅と、罰則の増分 $6 \log n = 33.6$ を比べればよい。$1 \to 2$ では $-2\hat{\ell}$ が 319.1 下がり、罰則の増分を大きく上回る。$2 \to 3$ では 31.6 しか下がらず、罰則の増分に届かない。群ごとの型の中では、BIC は予想どおり $k = 2$ を選んでいる。

答えが変わるのは、型をまたいで比べたときである。群ごとの型・$k = 2$ の BIC は 832.6 である。パラメータの数は群ごとの型・$k = 2$ が 11 個、共通の型・$k = 3$ が 11 個で同じなので、罰則も同じになる。$\widehat{\ell}$ は共通の型・$k = 3$ の方が 3.9 大きい。楕円の傾きを群ごとに推定する分のパラメータを、3 つ目の群に回した方が当てはまりが良い、というのが BIC の答えである。

図 15 (a) は、BIC の答えを 2 列の上に描いたものである。群を分の単位に戻すと（表 7）、短い噴出の群が 1 つと、長い噴出の群が 2 つになる。長い噴出の 2 つの群は、噴出時間の平均がおよそ 3.8 分と 4.5 分で、塊の中の短めの側の裾と本体にあたる。長い噴出の塊は、正規分布の楕円 1 つで描くには形が崩れている。BIC の導出は、データを作ったモデルが候補の中にあるとしていた。この塊ではその前提が少しずれているので、BIC は罰則を払ってでも群を 1 つ足した。ただし、これは噴出の仕組みが 3 種類あるという意味ではない。群の数は、正規分布の楕円で塊を描くと決めたうえで、何を測る物差しを置いたかで決まる。

表 7: BIC が選んだ答えの群ごとの行数と、噴出時間・待ち時間の平均（分に戻した）

BIC の群	行数	噴出時間の平均	待ち時間の平均
1	97	2.04 分	54.5 分
2	42	3.81 分	77.6 分
3	133	4.47 分	80.9 分

AIC で選ぶ

予想③を見る。表 8 は同じ候補の AIC である。最小は群ごとの型・$k = 4$ の 768.6 であり、BIC より多い群を選んだ。予想どおりである。図 15 (b) のとおり、長い噴出の塊を、さらに細かい楕円でつないでいる。

表 8: 間欠泉の 272 回の噴出で、24 通りの候補の AIC（★が最小）

型	$k = 1$	$k = 2$	$k = 3$	$k = 4$	$k = 5$	$k = 6$
群ごと	1,100.0	792.9	773.3	768.6 ★	772.9	770.3
共通	1,100.0	806.8	785.0	780.1	776.7	782.7
対角	1,551.8	824.0	792.4	774.2	770.0	772.2
球	1,549.8	860.7	824.3	801.1	791.9	784.0

理由は 2 つある。1 つ目は罰則の重みである。$n = 272$ では $\log n = 5.61$ なので、BIC はパラメータ 1 つに AIC のおよそ 2.8 倍の罰則をかける。2 つ目は目指すものである。AIC は新しい行での当てはまりを見積もった。長い噴出の塊が楕円でないなら、新しい行の出やすさを細かく言うには、楕円を足して塊の形をなぞった方が得になる。罰則の軽い AIC は、その得を取りにいく。第 I 部で、AIC が群の多い側を一定の割合で選び続けたのと同じ向きである。

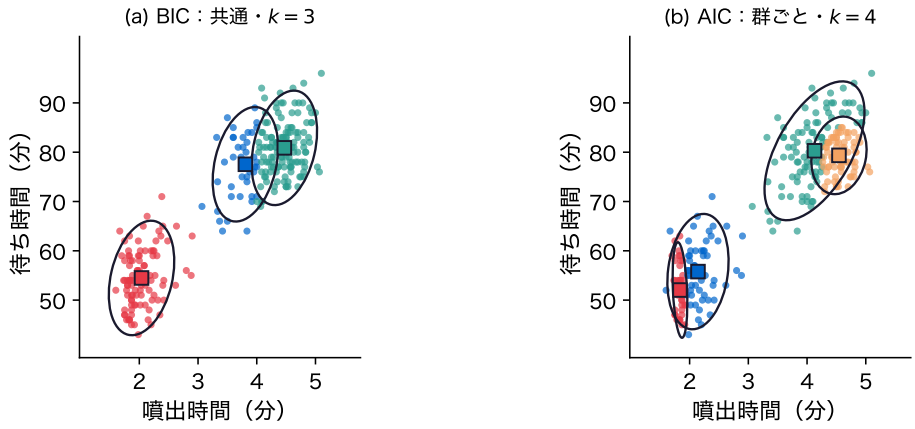


図 15: 間欠泉の 272 回の噴出で、(a) BIC、(b) AIC が選んだ混合正規分布。色は所属（責任度が最大の群）、楕円は推定した共分散の形、■は平均

シルエットで選ぶ

予想④を見る。図 16 は、k-means で $k = 2, \ldots, 6$ に分けたときのシルエット係数と、選ばれた答えである。$\bar{s}$ は $k = 2$ で最大の 0.75 になり、$k = 3$ では 0.49 に下がった。短い噴出と長い噴出の 2 つの塊を、そのまま 2 つの群にしている。予想どおりである。

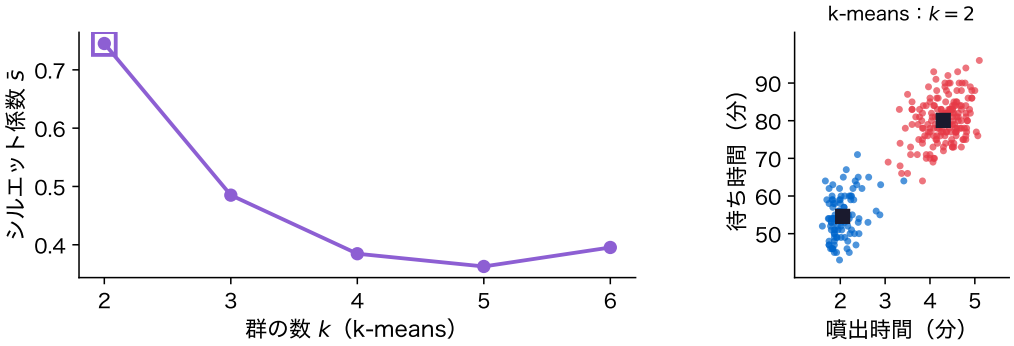


図 16: 間欠泉の 272 回の噴出に k-means を当てたときのシルエット係数（左、四角が最大）と、選ばれた k の答え（右、■は代表点）

BIC が長い噴出の塊を 2 つの群で描いたのに、シルエットが割らなかった理由は、測るものの違いにある。長い噴出の行について、$k = 2$ から $k = 3$ にすると、自分の群までの距離の平均 a_i は 0.70 から 0.54 に縮む。しかし隣の群までの距離の平均 b_i は 2.75 から 0.86 へ、もっと大きく縮む。割った 2 つの群が互いに隣の群になるからである（シルエット係数の性質③）。BIC と AIC は塊の形が楕円からずれた分を群を足して埋めたが、シルエットは塊どうしがどれだけ離れているかだけを見る。

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは 4 つを予想した。$\hat{\ell}$ がどの型でも k とともに上がり続けることは、予想どおりだった。BIC が目で見た 2 つの塊を選ぶという予想は、半分外れた。群ごとの型の中では、$2 \to 3$ の下がり幅が罰則の増分に届かず、BIC は $k = 2$ を選んだ。しかし型をまたぐと、同じ罰則で $\hat{\ell}$ の大きい共通の型・$k = 3$ が勝った。長い噴出の塊が正規分布の楕円 1 つに収まらず、BIC の前提が少しずれていたためである。AIC が BIC より多い群を選ぶという予想は当たった。罰則が軽く、新しい行の出やすさを細かく言う方を目指すからである。k-means のシルエット係数が 2 つの塊を選ぶという予想も当たった。シルエットは塊の形をなぞらず、塊どうしの離れ方だけを見るからである。どの物差しも、置いた前提と目指すものの範囲で答えを返す。

締め

まとめと次回の問い

本章の問いは、群の数 k をどう選ぶか、であった。混合正規分布の最大の対数尤度 $\hat{\ell}$ は k とともに上がり、k-means の J は下がり続ける。大きいモデルは小さいモデルを特別な場合として含むからである。そのため推定法そのものでは k は決まらない。共分散の型も同じである。そこで推定の外に物差しを置いた。

1 つ目の $\mathrm{AIC} = -2\hat{\ell} + 2d$ は、新しい行での当てはまりの見積もりである。手元の行で推定した $\hat{\ell}$ は、新しい行での当てはまりより平均でおよそ d だけ甘い。このことを、2 次のテイラー展開と情報量の等式から導いた。2 つ目の $\mathrm{BIC} = -2\hat{\ell} + d \log n$ は、モデルの周辺尤度の -2 倍の近似である。当てはまりの山が d 方向に幅 $1/\sqrt{n}$ で細くなる分の割引が、罰則 $d \log n$ になる。n を増やすと、BIC はデータを作った群の数を選ぶ割合が 1 に近づき、AIC は多めの群を一定の割合で選び続ける。どちらの導出も、$\boldsymbol{\theta}^*$ が 1 点に決まり、$\mathbf{H}$ に逆行列があるとした。群が多すぎる候補では、この前提は成り立たない。3 つ目のシルエット係数は、行どうしの距離の比で群の離れ方を測る。尤度の無い k-means にも使え、群を割りすぎると下がる。トーストの人工データでは、BIC とシルエット係数がデータを作った群の数 3 を選び、AIC は多めを選んだ。間欠泉の 272 回の噴出では、目で見た塊は 2 つであった。BIC は共通の型・$k = 3$ を、AIC は群ごとの型・$k = 4$ を、シルエット係数は $k = 2$ を選んだ。物差しが違えば答えも違う。

最後に、次回への問いを置く。第 7 回・第 8 回は、$\mathbf{X}$ の各行を k 個の代表点のどれかで近似し（$\mathbf{X} \approx \mathbf{GC}$）、本章ではその k を選んだ。では、行を代表点に置き換えるのではなく、少数の軸の組み合わせで近似したらどうなるか。列が多いデータを、少ない数でどこまで表せるか。$\mathbf{X}$ 自身を少数の軸で近似するとどうなるだろうか。

発展

発展：WAIC と WBIC

AIC も BIC も、導出の中で $\boldsymbol{\theta}^*$ が 1 点に決まり、$\mathbf{H}$ に逆行列があるとした。群が多すぎる混合正規分布では、余分な群をどこに置いても同じ分布になるので、この前提は成り立たない。それでも使える物差しとして、渡辺澄夫による WAIC（Watanabe 2010）と WBIC（Watanabe 2013）がある。ここでは考え方と数値実験だけを

紹介する。

最も小さな例で見る。1 変数・2 群のモデル $f(x \mid a, b) = (1-a)N(x; 0, 1) + aN(x; b, 1)$ $(d = 2)$を、1 群の $N(0, 1)$ から出たデータに当てはめる。$a = 0$ なら 2 群目は使われず、$b = 0$ なら 2 つの群は重なる。どちらでも真の分布になるので、真の分布を表す (a, b) は 1 点ではなく、十字形の 2 本の線になる。事前分布を $a \in [0, 1]$、$b \in [-3, 3]$ の一様分布とし、データを見た後のパラメータの散らばり $p(a, b \mid \mathbf{X}) \propto \exp(\ell(a, b))\, p(a, b)$（事後分布）を格子で計算した。図 17 のとおり、$n = 200$ でも事後分布は 1 点の周りの山にならず、十字に沿って広がる。2 次のテイラー展開で山を 1 つの楕円と見る近似は使えない。

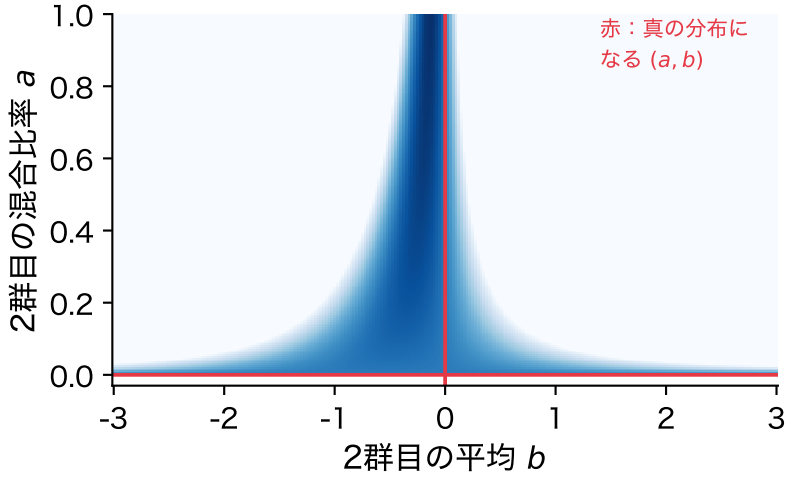


図 17: 1 群の $N(0, 1)$ から出た 200 行に、2 群のモデル $(1-a)N(0, 1) + aN(b, 1)$ を当てはめたときの事後分布（濃いほど大きい。濃さは対数の目盛り）。赤い線の上の (a, b) はどれも真の分布を表す

WAIC は、最尤推定値 1 点の代わりに、事後分布全体で平均した予測で当てはまりを測る。

$$\mathrm{WAIC} = -2\sum_{i=1}^{n} \log \mathrm{E}_{\boldsymbol{\theta}|\mathbf{X}}[f(\tilde{\boldsymbol{x}}_i \mid \boldsymbol{\theta})] + 2\sum_{i=1}^{n} \mathrm{V}_{\boldsymbol{\theta}|\mathbf{X}}[\log f(\tilde{\boldsymbol{x}}_i \mid \boldsymbol{\theta})]$$

ここで $\mathrm{E}_{\boldsymbol{\theta}|\mathbf{X}}$ と $\mathrm{V}_{\boldsymbol{\theta}|\mathbf{X}}$ は、事後分布での平均と分散である（ここでは -2 倍の目盛りで書いた）。第 1 項は手元の行の当てはまりで、第 2 項が AIC の $2d$ にあたる補正である。補正は、行ごとの $\log f$ が事後分布の中でどれだけ揺れるかを足したもので、d を数えずにデータから求まる。前提が成り立てば、この補正はおよそ $2d$ になる。

図 18 は、$n = 100$ のデータを 600 通り作り、手元の行と新しい行の差（ℓ の目盛り、(7) 式の b）を実際に測ったものである。真の分布は格子で数値積分した。1 群のモデル $N(b, 1)$ $(d = 1)$では、最尤法の差も AIC の補正も、事後分布で平均したときの差も WAIC の補正も、どれも約 1 である。2 群のモデルでは、最尤法の実際の差は 1.50 で、AIC の補正 $d = 2$ からずれる。一方、事後分布で平均したときの実際の差は 0.97 で、WAIC の補正 0.92 に近い。

WBIC は、周辺尤度 (9) 式の近似である。当てはまりを β 乗に弱めた事後分布 $p^{(\beta)}(\boldsymbol{\theta} \mid \mathbf{X}) \propto \exp(\beta\ell(\boldsymbol{\theta}))\, p(\boldsymbol{\theta})$ を、$\beta = 1/\log n$ で作る。この分布で $-2\ell(\boldsymbol{\theta})$ を平均したもの

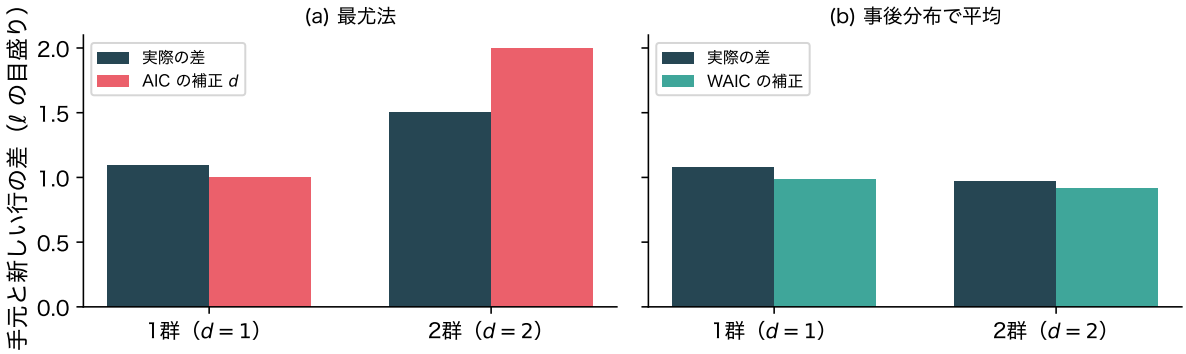


図 18: $n = 100$ の 600 通りのデータで測った、手元の行と新しい行の差（ℓ の目盛り）。(a) 最尤法の実際の差と AIC の補正 d、(b) 事後分布で平均した予測の実際の差と WAIC の補正

$$\mathrm{WBIC} = \mathrm{E}^{(\beta)}_{\boldsymbol{\theta}|\mathbf{X}}[-2\ell(\boldsymbol{\theta})]$$

が、$-2\log p(\mathbf{X})$ を近似する（Watanabe 2013 は -2 倍しない形で書くが、BIC と並べるため -2 倍した）。積分そのものをせずに、平均 1 回で求まる。図 19 は、行の数 n を 50 から 20000 まで変え、各 n で 20 通りのデータについて、周辺尤度を格子で数値積分した値とのずれを平均したものである。1 群のモデル（$d = 1$）では、BIC のずれは n が増えても広がらない。2 群のモデルでは、BIC のずれは n とともに広がり、WBIC のずれはほぼ 0 のままである。

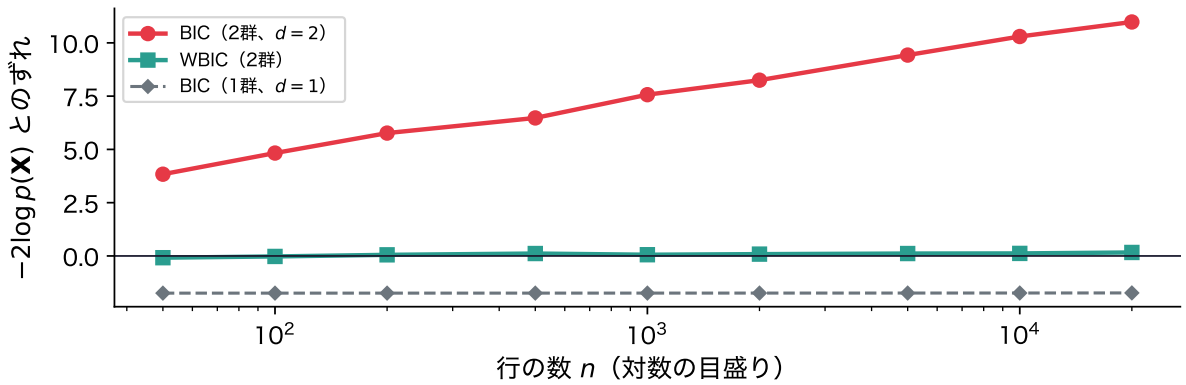


図 19: 1 群のデータに、2 群のモデルと 1 群のモデルを当てはめたときの、$-2\log p(\mathbf{X})$（格子で数値積分）からの BIC と WBIC のずれ（各 n で 20 通りの平均）

ずれが広がる理由は、罰則の傾きにある。一般に、$-\log p(\mathbf{X})$ は $-\ell(\boldsymbol{\theta}^*) + \lambda \log n$ に近い速さで増える。前提が成り立てば $\lambda = d/2$ で、これが BIC の罰則 $\frac{d}{2}\log n$ だった。前提が成り立たなければ、λ は $d/2$ より小さくなる。この λ を実対数閾値（real log canonical threshold）と呼び、この 2 群のモデルでは $\lambda = 1/2$ である（Watanabe 2009）。BIC は $d/2 = 1$ を使うので、罰則が重すぎる。WBIC は λ を知らなくても使える。混合正規分布の群の数を選ぶときも、WAIC や WBIC を事後分布のサンプルから計算できる（Watanabe 2021）。

参考文献

- Akaike, H. (1974). A new look at the statistical model identification. IEEE Transactions on Automatic Control, 19(6), 716–723.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 20, 53–65.
- Schwarz, G. (1978). Estimating the dimension of a model. The Annals of Statistics, 6(2), 461–464.
- Watanabe, S. (2009). Algebraic Geometry and Statistical Learning Theory. Cambridge University Press.
- Watanabe, S. (2010). Asymptotic equivalence of Bayes cross validation and widely applicable information criterion in singular learning theory. Journal of Machine Learning Research, 11, 3571–3594.
- Watanabe, S. (2013). A widely applicable Bayesian information criterion. Journal of Machine Learning Research, 14, 867–897.
- Watanabe, S. (2021). WAIC and WBIC for mixture models. Behaviormetrika, 48, 5–21.