

第 10 回 主成分分析②

$\mathbf{X}$ を 1 回特異値分解して、反復せずに解く

本章の問いは、第 9 回の締めで残った「反復せず 1 回で解けないか？」である。答えは、データ行列 $\mathbf{X}$ そのものを 1 回特異値分解することである。 $\mathbf{X} = \mathbf{K}\mathbf{\Delta}\mathbf{L}^\top$ の上位 Q 本を残し、 $\hat{\mathbf{F}} = \mathbf{K}_1\mathbf{\Delta}_1$ 、 $\hat{\mathbf{A}} = \mathbf{L}_1$ とすればよい (Eckart–Young の定理)。目的関数の最小値は捨てた特異値の二乗和になり、寄与率はその裏返しとして読める。

第 I 部 理論

反復せず 1 回で解く

第 9 回では、主成分分析の目的関数 $\|\mathbf{X} - \mathbf{F}\mathbf{A}^\top\|_F^2$ (ただし $\mathbf{A}^\top\mathbf{A} = \mathbf{I}_Q$) を交互最小二乗法で最小にした。 $\mathbf{A}$ を固定して $\hat{\mathbf{F}} = \mathbf{X}\mathbf{A}$ とする更新と、 $\mathbf{F}$ を固定して $\mathbf{X}^\top\mathbf{F}$ を特異値分解 (Singular Value Decomposition, SVD) し $\hat{\mathbf{A}} = \mathbf{K}\mathbf{L}^\top$ とする更新である。この 2 つを繰り返すと、初期値によらず同じ J に着いた。ただし、答えに着くまでには反復が要り、反復のたびに $p \times Q$ の行列を 1 回ずつ特異値分解していた。

本章では、写真 1 枚をデータ行列として扱う。図 1 (a) は、白黒の写真の各画素の明るさを、黒を 0、白を 1 とし、並べたものである。画素の行を行、画素の列を列とすれば、この写真は 427 行・400 列、170,800 個の数の行列になる。(b) では、その一部の 6×6 マスを拡大した。この行列を少数の軸で近似することは、第 9 回的主成分分析そのものである。

本章の問いは、この問題を反復せず 1 回で解けないか、である。以下ではまず、2 列の小さなデータ行列をそのまま特異値分解し、何が出てくるかを見る。次に、そこで見たことを一般の $n \times p$ で言うための道具をそろえ、データ行列を上位の分と残りの分に分ける。その分け方から、ランクを落として $\mathbf{X}$ に近づける問題の答えが得られ、それが主成分分析の答えでもあることを示す。最後に、その答えから寄与率と軸の順番を読む。

2 列で見る特異値分解

第 9 回で使った特異値分解は、どんな行列にも使える。そこで、データ行列そのものを分解すると何が出てくるかを、2 列の人工データで見る。図 2 の 40 点は、食パン 40 枚の焼き時間と焦げ目の濃さを、どちらも平均を引いて並べたものとして作った。列の平均は 0 である。この 40×2 の行列を $\mathbf{X} = \mathbf{K}\mathbf{\Delta}\mathbf{L}^\top$ と分解する。 $\mathbf{K}$ は 40×2 、 $\mathbf{\Delta}$ は特異値 $\delta_1 \geq \delta_2$ を並べた 2×2 の対角行列、 $\mathbf{L} = [\mathbf{l}_1, \mathbf{l}_2]$ は 2×2 である。 $\mathbf{l}_1$ と $\mathbf{l}_2$ は長さ 1 で




図 1: (a) 写真 1 枚(白黒、明るさ 0~1)。 (b) 赤い枠の中の 6×6 マスの明るさ。写真は行列である

互いに直角な 2 本の向きになる(図 2 (a))。 l_1 は点の雲の長い向き、 l_2 はそれに直角な向きである。分解の両辺に右から $\mathbf{L}$ を掛けると、 $\mathbf{L}^\top \mathbf{L} = \mathbf{I}$ から

$$\mathbf{XL} = \mathbf{K}\Delta \quad (1)$$

となる。 $\mathbf{XL}$ の第 i 行 $(\tilde{x}_i^\top l_1, \tilde{x}_i^\top l_2)$ は、点 i の座標を l_1 と l_2 の向きで測り直したものである。これが $(\delta_1 k_{i1}, \delta_2 k_{i2})$ に等しい。特異値分解は、点の雲を見る座標軸を、長い向きから順に取り直す操作である。

ここで l_1 の座標だけを残し、 l_2 の座標を捨てる。点 i は $\delta_1 k_{i1} l_1$ 、すなわち赤い直線の上の青い点で近似される(図 2 (b))。これは第 9 回の直線の上の近似と同じ形である。誤差は捨てた分 $\delta_2 k_{i2} l_2$ であり、その二乗和は $\delta_2^2 \sum_i k_{i2}^2 = \delta_2^2 = 6.98$ になる($\mathbf{K}$ の列は長さ 1)。同じ 40 点に第 9 回の交互最小二乗法($Q = 1$)を回すと、8 回の反復で $J = 6.98$ に落ち着き、この値と一致する。反復しなくても、分解して 1 本捨てるだけで同じところに着いた。

道具：X の特異値分解とランク

2 列の例で見たことを、一般の $n \times p$ のデータ行列で確かめるために、3 つの道具を用意する。どれも第 9 回の道具(トレース、二乗和のトレースによる表現、特異値分解)から出る。

1 つ目は、データ行列そのものの特異値分解である。第 9 回では $p \times Q$ の $\mathbf{X}^\top \mathbf{F}$ を分解したが、同じ分解は $n \times p$ ($p \leq n$)の $\mathbf{X}$ にも使える。

$$\mathbf{X} = \mathbf{K}\Delta\mathbf{L}^\top, \quad \mathbf{K}^\top \mathbf{K} = \mathbf{I}_p, \quad \mathbf{L}^\top \mathbf{L} = \mathbf{L}\mathbf{L}^\top = \mathbf{I}_p \quad (2)$$




図 2: 2 列の人工データ(食パン 40 枚の焼き時間と焦げ目)の特異値分解。(a) $\mathbf{L}$ の 2 本の向き、(b) 上位 1 本 l_1 だけを残した近似(青)と、捨てた l_2 の分の誤差(紫)

ここで $\mathbf{K} \in \mathbb{R}^{n \times p}$ は列が長さ 1 で互いに直角な行列、 $\mathbf{L} \in \mathbb{R}^{p \times p}$ は正方の正規直交行列、 Δ は特異値 $\delta_1 \geq \delta_2 \geq \dots \geq \delta_p \geq 0$ を対角に並べた $p \times p$ の対角行列である。 $\mathbf{L}$ は正方なので $\mathbf{L}\mathbf{L}^\top = \mathbf{I}_p$ も成り立つが、 $\mathbf{K}$ は縦長なので $\mathbf{K}\mathbf{K}^\top = \mathbf{I}_n$ は成り立たない。

2 つ目はランク(rank)である。行列 $\mathbf{Y} \in \mathbb{R}^{n \times p}$ の 0 でない特異値の個数を $\mathbf{Y}$ のランクと呼び、 $\text{rank}(\mathbf{Y})$ と書く(定義 1)。ランクが Q 以下であることは、 $\mathbf{Y}$ のすべての行が Q 本の向きの組み合わせで書けることと同じである。その Q 本の向きを長さ 1 で互いに直角にそろえて $\mathbf{A} \in \mathbb{R}^{p \times Q}$ ($\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$) とし、各行の組み合わせの重みを $\mathbf{F} \in \mathbb{R}^{n \times Q}$ に並べれば

$$\text{rank}(\mathbf{Y}) \leq Q \iff \mathbf{Y} = \mathbf{F}\mathbf{A}^\top \quad (\mathbf{F} \in \mathbb{R}^{n \times Q}, \mathbf{A} \in \mathbb{R}^{p \times Q}, \mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q) \quad (3)$$

と書ける。 $Q = 1$ なら、どの行も 1 本の向き $\mathbf{a}$ の定数倍 $f_i \mathbf{a}$ である。図 2 (b) の青い点を並べた 40×2 の行列がその例で、ランクは 1 になる。主成分分析の近似 $\mathbf{F}\mathbf{A}^\top$ は、ランクが Q 以下の行列である。

3 つ目は、列が長さ 1 で互いに直角な行列を掛けても、フロベニウスノルムが変わらないことである。 $\mathbf{K}^\top \mathbf{K} = \mathbf{I}$ なら、第 9 回の二乗和のトレースによる表現から

$$\|\mathbf{K}\mathbf{M}\|_F^2 = \text{tr}(\mathbf{M}^\top \mathbf{K}^\top \mathbf{K} \mathbf{M}) = \text{tr}(\mathbf{M}^\top \mathbf{M}) = \|\mathbf{M}\|_F^2 \quad (4)$$

となる。右から $\mathbf{L}^\top$ ($\mathbf{L}^\top \mathbf{L} = \mathbf{I}$) を掛けたときも、トレースの順番を回せば $\mathbf{L}^\top \mathbf{L}$ が隣り合って消える。2 次元でベクトルを回しても長さが変わらないことの、行列版である。(2) 式に使うと、 $\mathbf{K}$ と $\mathbf{L}^\top$ が両方消えて

$$\|\mathbf{X}\|_F^2 = \|\mathbf{\Delta}\|_F^2 = \sum_{m=1}^p \delta_m^2 \quad (5)$$

を得る。データ行列の全マスの二乗和は、特異値の二乗和に等しい。

定義 1 (ランク). 行列の 0 でない特異値の個数を、その行列のランクと呼ぶ。ランクが Q 以下の行列は、 Q 本の向きの組み合わせで全行が書ける行列であり、(3) 式の形 $\mathbf{F}\mathbf{A}^\top$ に書ける。

X を上位と残りに分ける

(2) 式を、スカラー・ベクトル・行列の順に書き下す。まず 1 マスずつ書くと、

$$x_{ij} = \sum_{m=1}^p \delta_m k_{im} l_{jm} \quad (6)$$

である。マス x_{ij} は、向き m ごとの「行の位置 $\delta_m k_{im}$ × 向きの成分 l_{jm} 」を p 本分足したものである。どの項も、第 9 回の目的関数 $\sum (x_{ij} - f_i a_j)^2$ の $f_i a_j$ と同じ形をしている。

次に、向き m の項をまとめて行列にすると

$$\mathbf{X} = \sum_{m=1}^p \delta_m \mathbf{k}_m \mathbf{l}_m^\top \quad (7)$$

となる。 $\mathbf{k}_m \in \mathbb{R}^n$ と $\mathbf{l}_m \in \mathbb{R}^p$ はそれぞれ $\mathbf{K}$ と $\mathbf{L}$ の第 m 列である。 $\mathbf{k}_m \mathbf{l}_m^\top$ は、どの行も $\mathbf{l}_m$ の定数倍になっている $n \times p$ の行列、すなわちランク 1 の行列である。その全マスの二乗和は $\|\mathbf{k}_m\|_2^2 \|\mathbf{l}_m\|_2^2 = 1$ なので、 $\mathbf{X}$ は大きさ 1 の p 枚の行列に重み δ_m を付けて重ねたものと読める。

最後に、 $\mathbf{K}$ を左から Q 列の $\mathbf{K}_1 \in \mathbb{R}^{n \times Q}$ と残りの $\mathbf{K}_2 \in \mathbb{R}^{n \times (p-Q)}$ に分ける。 $\mathbf{L}$ も同じく $\mathbf{L}_1 \in \mathbb{R}^{p \times Q}$ と $\mathbf{L}_2 \in \mathbb{R}^{p \times (p-Q)}$ に、 $\mathbf{\Delta}$ も上位 Q 個の $\mathbf{\Delta}_1$ と残りの $\mathbf{\Delta}_2$ に分ける。列で分けても列の正規直交性は保たれ、 $\mathbf{K}_1^\top \mathbf{K}_1 = \mathbf{L}_1^\top \mathbf{L}_1 = \mathbf{I}_Q$ 、 $\mathbf{K}_2^\top \mathbf{K}_2 = \mathbf{L}_2^\top \mathbf{L}_2 = \mathbf{I}_{p-Q}$ である。(7) 式の和を $m \leq Q$ と $m > Q$ に分けたものを行列で書けば

$$\mathbf{X} = [\mathbf{K}_1, \mathbf{K}_2] \begin{bmatrix} \mathbf{\Delta}_1 & \\ & \mathbf{\Delta}_2 \end{bmatrix} [\mathbf{L}_1, \mathbf{L}_2]^\top = \mathbf{K}_1 \mathbf{\Delta}_1 \mathbf{L}_1^\top + \mathbf{K}_2 \mathbf{\Delta}_2 \mathbf{L}_2^\top = \mathbf{X}_1 + \mathbf{X}_2 \quad (8)$$

となる。 $\mathbf{X}$ 、 $\mathbf{X}_1$ 、 $\mathbf{X}_2$ はどれも $n \times p$ の行列であり、 $\mathbf{X}_1$ は上位 Q 枚、 $\mathbf{X}_2$ は残りの枚を重ねたものである (図 3)。 $\mathbf{X}_1$ は $n \times Q$ の $\mathbf{K}_1 \mathbf{\Delta}_1$ と $p \times Q$ の $\mathbf{L}_1$ の積なので、 np 個のマスを持つのに $(n+p)Q$ 個の数で足りる。




図 3: データ行列の特異値分解を、上位 Q 本(青)と残り(紫)に分けたもの。箱の縦は行の数、横は列の数。積でそろ次元を赤で示す

低ランク近似と Eckart–Young の定理

(8) 式の $\mathbf{X}_1$ はランク Q 以下の行列である。だが、ランク Q 以下の行列はほかにも無数にある。その中で $\mathbf{X}$ に最も近いのはどれか。行列の大きさは $n \times p$ のままで、ランクだけを Q 以下に落とし、 $\mathbf{X}$ に最も近い行列を探す問題を考える。1 マスずつ書けば、目的関数は $\sum_i \sum_j (x_{ij} - y_{ij})^2$ であり、第 1 回からの最小二乗法の形そのものである。行列で書けば

$$\min_{\mathbf{Y}} \|\mathbf{X} - \mathbf{Y}\|_F^2 \quad \text{ただし } \text{rank}(\mathbf{Y}) \leq Q \quad (9)$$

である。 $\mathbf{X}$ のランクはふつう p である。それより低いランクの行列で近似するので、(9) 式を低ランク近似 (low-rank approximation) の問題と呼ぶ(定義 2)。特異値が降順に並んでいるとき、(9) 式を最小にする $\mathbf{Y}$ は

$$\hat{\mathbf{Y}} = \mathbf{K}_1 \Delta_1 \mathbf{L}_1^T \quad (10)$$

であり、(8) 式の $\mathbf{X}_1$ 、すなわち上位 Q 枚を重ねただけの行列である(Eckart and Young, 1936)。(9) 式の問題と(10) 式の答えを合わせて Eckart–Young の定理(Eckart–Young theorem)(Eckart–Young–Mirsky の定理)と呼ぶ(定理 1)。 $\delta_Q > 0$ なら $\text{rank}(\hat{\mathbf{Y}}) = Q$ である。

定理 1 (Eckart–Young の定理). $\mathbf{X} \in \mathbb{R}^{n \times p}$ ($p \leq n$) の特異値分解を (8) 式のように上位 Q 個と残りに分ける。ランクが Q 以下という条件のもとで $\|\mathbf{X} - \mathbf{Y}\|_F^2$ を最小にする $\mathbf{Y}$ は $\hat{\mathbf{Y}} = \mathbf{K}_1 \Delta_1 \mathbf{L}_1^T$ である。

ここで

$$\mathbf{F} = \mathbf{K}_1 \Delta_1, \quad \mathbf{A} = \mathbf{L}_1, \quad \mathbf{E} = \mathbf{K}_2 \Delta_2 \mathbf{L}_2^T \quad (11)$$

とおくと、 $\mathbf{A}^T \mathbf{A} = \mathbf{L}_1^T \mathbf{L}_1 = \mathbf{I}_Q$ で主成分分析の制約を満たし、

$$\|\mathbf{X} - \mathbf{K}_1 \mathbf{\Delta}_1 \mathbf{L}_1^\top\|_F^2 = \|\mathbf{X} - \mathbf{F} \mathbf{A}^\top\|_F^2 = \|\mathbf{E}\|_F^2$$

と書ける。(3) 式のとおり、ランクが Q 以下の行列は $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$ を満たす $\mathbf{F} \mathbf{A}^\top$ の形の行列と同じものである。したがって、低ランク近似の問題と主成分分析の問題は同じ問題であり、データ行列の特異値分解によって主成分分析のパラメータを求めることができる。目的関数の最小値は、(4) 式で $\mathbf{K}_2$ と $\mathbf{L}_2^\top$ を消して

$$\min J = \|\mathbf{K}_2 \mathbf{\Delta}_2 \mathbf{L}_2^\top\|_F^2 = \|\mathbf{\Delta}_2\|_F^2 = \sum_{m=Q+1}^p \delta_m^2 \quad (12)$$

となる。捨てた特異値の二乗和である。2 列の食パンの例($p = 2, Q = 1$)では、捨てるのは δ_2 だけであり、図 2 (b) の紫の線の二乗和 δ_2^2 がこれにあたる。

この答えは、第 9 回の交互最小二乗法から見ても答えになっている。 $\mathbf{A} = \mathbf{L}_1$ から始めると、 $\mathbf{F}$ の更新は (1) 式の左から Q 列を取って $\mathbf{F} = \mathbf{X} \mathbf{L}_1 = \mathbf{K}_1 \mathbf{\Delta}_1$ となる。続く $\mathbf{A}$ の更新では

$$\mathbf{X}^\top \mathbf{F} = \mathbf{L} \mathbf{\Delta} \mathbf{K}^\top \mathbf{K}_1 \mathbf{\Delta}_1 = \mathbf{L}_1 \mathbf{\Delta}_1^2 \mathbf{I}_Q^\top \quad (13)$$

を特異値分解する。 $\mathbf{K}^\top \mathbf{K}_1$ は $\mathbf{I}_p$ の左 Q 列なので、 $\mathbf{L} \mathbf{\Delta}$ の左 Q 列 $\mathbf{L}_1 \mathbf{\Delta}_1$ だけが残る。(13) 式はそれ自体が特異値分解の形(左特異行列 $\mathbf{L}_1$ 、特異値 δ_m^2 、右特異行列 $\mathbf{I}_Q$)であり、 $\hat{\mathbf{A}} = \mathbf{L}_1 \mathbf{I}_Q^\top = \mathbf{L}_1$ と元に戻る。交互最小二乗法の 2 つの更新を 1 回ずつ計算しても、この答えからは動かない。

定義 2 (低ランク近似). 行列 $\mathbf{X}$ を、大きさは同じでランクが Q 以下の行列 $\mathbf{Y}$ で、 $\|\mathbf{X} - \mathbf{Y}\|_F^2$ が最小になるように近似することを、低ランク近似と呼ぶ。

なぜ上位 Q 本が最もよいか

定理 1 がなぜ成り立つのかを、第 9 回の結果と本章の道具で確かめる。(3) 式により、ランク Q 以下の $\mathbf{Y}$ は $\mathbf{F} \mathbf{A}^\top$ ($\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$) と書けるので、主成分分析の形で考えればよい。第 9 回で見たとおり、 $\mathbf{A}$ を固定したときの最もよい $\mathbf{F}$ は $\hat{\mathbf{F}} = \mathbf{X} \mathbf{A}$ である。これを入れた J を $\mathbf{A}$ だけの関数として書き、それを最小にする $\mathbf{A}$ を探す。

まず軸が 1 本の場合をスカラーで書く。向き $\mathbf{a}$ ($\sum_j a_j^2 = 1$) を固定し、 $\hat{f}_i = \sum_j a_j x_{ij}$ とすると、行 i の誤差の二乗和は

$$\sum_{j=1}^p (x_{ij} - f_i a_j)^2 = \sum_j x_{ij}^2 - 2f_i \sum_j a_j x_{ij} + f_i^2 \sum_j a_j^2 = \sum_j x_{ij}^2 - f_i^2 \quad (14)$$

となる。すなわち $\|\tilde{\mathbf{x}}_i\|_2^2 = f_i^2 + \|\mathbf{e}_i\|_2^2$ であり、原点・直線の上の足・点の 3 つは直角三角形をなす(図 4)。第 3 回で、予測値 $\hat{\mathbf{y}}$ が $\mathbf{y}$ を列空間に落とした影であり、残差がそれと直交することを見た。ここでも近似 $f_i \mathbf{a}$ は点を直線へ落とした影であり、誤差 $\mathbf{e}_i$ はそれと直交する。

(14) 式を n 行分足すと、ベクトルで




図 4: 点 $\tilde{\mathbf{x}}_i$ (橙)、直線の上の足 $f_i \mathbf{a}$ 、原点がなす直角三角形(人工データ)。青が得点 f_i 、紫が誤差 $\mathbf{e}_i$

$$J(\mathbf{a}) = \sum_{i=1}^n \sum_{j=1}^p x_{ij}^2 - \sum_{i=1}^n f_i^2 = \|\mathbf{X}\|_F^2 - \|\mathbf{X}\mathbf{a}\|_2^2 \quad (15)$$

を得る。第 1 項は $\mathbf{a}$ によらないので、 J を最小にすることは、得点の二乗和 $\|\mathbf{X}\mathbf{a}\|_2^2$ を最大にすることと同じである。列の平均が 0 なので得点の平均も 0 であり、 $\|\mathbf{X}\mathbf{a}\|_2^2/n$ は得点の分散にあたる。誤差の最小化は、直線の上の散らばりの最大化と言い換えられる。

$\|\mathbf{X}\mathbf{a}\|_2^2$ を特異値で書く。(2) 式から $\mathbf{X}^\top \mathbf{X} = \mathbf{L} \mathbf{\Delta} \mathbf{K}^\top \mathbf{K} \mathbf{\Delta} \mathbf{L}^\top = \mathbf{L} \mathbf{\Delta}^2 \mathbf{L}^\top$ であるから

$$\|\mathbf{X}\mathbf{a}\|_2^2 = \mathbf{a}^\top \mathbf{X}^\top \mathbf{X} \mathbf{a} = \mathbf{a}^\top \mathbf{L} \mathbf{\Delta}^2 \mathbf{L}^\top \mathbf{a} = \sum_{m=1}^p \delta_m^2 (\mathbf{l}_m^\top \mathbf{a})^2 \quad (16)$$

となる。 $w_m = (\mathbf{l}_m^\top \mathbf{a})^2$ は 0 以上で、(4) 式から $\sum_m w_m = \|\mathbf{L}^\top \mathbf{a}\|_2^2 = \|\mathbf{a}\|_2^2 = 1$ である。(16) 式は、合計 1 の重みを $\delta_1^2, \dots, \delta_p^2$ に配った重み付きの和である。これを最大にするには、すべての重みを最も大きい δ_1^2 に置けばよい。 $w_1 = 1$ となるのは $\mathbf{a} = \pm \mathbf{l}_1$ のときで、最大値は δ_1^2 、 J の最小値は $\sum_{m \geq 2} \delta_m^2$ である。

軸が Q 本の場合も、行列で同じことが言える。 $\hat{\mathbf{F}} = \mathbf{X}\mathbf{A}$ を入れると

$$J(\mathbf{A}) = \text{tr}(\mathbf{X}^\top \mathbf{X}) - \text{tr}(\mathbf{A}^\top \mathbf{X}^\top \mathbf{X} \mathbf{A}) = \sum_{m=1}^p \delta_m^2 - \sum_{m=1}^p \delta_m^2 w_m, \quad w_m = \sum_{r=1}^Q (\mathbf{l}_m^\top \mathbf{a}_r)^2 = \|\mathbf{A}^\top \mathbf{l}_m\|_2^2 \quad (17)$$

となる。1 つ目の等号は第 9 回の $\mathbf{F}$ の更新で行ったトレースの展開に $\mathbf{F} = \mathbf{X}\mathbf{A}$ を入れたもの、2 つ目の等号は $\mathbf{X}^\top \mathbf{X} = \mathbf{L} \mathbf{\Delta}^2 \mathbf{L}^\top$ とトレースの順番の入れ替えによる。重み w_m には 2 つの性質がある。第一に、 $\mathbf{A} \mathbf{A}^\top \mathbf{l}_m$

は、長さ 1 の l_m を $\mathbf{A}$ の列が張る面に落とした影である。その長さの二乗 w_m は、(14) 式の直角三角形と同じ理由で $\|l_m\|_2^2 = 1$ を超えない。第二に、 $\sum_m w_m = \text{tr}(\mathbf{A}^\top \mathbf{L} \mathbf{L}^\top \mathbf{A}) = \text{tr}(\mathbf{A}^\top \mathbf{A}) = Q$ である。1 つの特異値には 1 までしか置けず、合計で Q を配る。だから上位 Q 個に 1 ずつ置いたときが最大で、最大値は $\sum_{m \leq Q} \delta_m^2$ になる(図 5)。それを実現するのが $\mathbf{A} = \mathbf{L}_1$ である($w_1 = \dots = w_Q = 1$)。このとき J の最小値は (12) 式に一致する。 $Q = 1$ とおけば (16) 式の議論に戻る。これで 定理 1 の答えが、ランク Q 以下のあらゆる行列の中で最もよいことが確かめられた。




図 5: 得点の二乗和 $\sum_m \delta_m^2 w_m$ の重みの配り方(概念図、 $p = 5$ 、 $Q = 2$)。棒の高さが δ_m^2 、青が $\delta_m^2 w_m$ 。(a) 1 までの重みを散らして合計 2 を配ったもの、(b) 上位 2 個に 1 ずつ置いたもの

計算の手順

反復を使わない主成分分析の計算を、Eckart–Young の定理に従って行列の形で手順にまとめる。

1. 列の平均を 0 にしたデータ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ と、軸の数 Q を用意する
2. $\mathbf{X}$ を 1 回特異値分解し、 $\mathbf{X} = \mathbf{K} \mathbf{\Delta} \mathbf{L}^\top$ を得る
3. $\mathbf{L}$ の左から Q 列を $\mathbf{L}_1$ とし、 $\mathbf{A} \leftarrow \mathbf{L}_1$ 、 $\mathbf{F} \leftarrow \mathbf{X} \mathbf{A}$ とする。(1) 式により $\mathbf{F} = \mathbf{K}_1 \mathbf{\Delta}_1$ である
4. 目的関数の値は、(12) 式により $J = \sum_{m > Q} \delta_m^2$ である

第 9 回の交互最小二乗法の手順と比べると、初期値の設定・反復・収束判定がすべて消えている(図 6)。分解は Q によらない。軸の数を変えて比べるときも、特異値分解をやり直さずに、 $\mathbf{L}$ から取る列の数を変えるだけでよい。

理論の帰結：寄与率と軸の順番

(11) 式の答えから、4 つのことが言える。

第 1 に、目的関数の最小値は捨てた特異値の二乗和 (12) 式である。図 7 は、3 列・60 点の人工データの特異値の二乗である。このデータは、ホットケーキ 60 枚の直径・厚さ・重さを、平均を引いて並べたものとして作った点で、2 本の軸でほぼ表せる。 $Q = 2$ なら、灰色の 3 本目 1.27 がそのまま J である。同じ点に第 9 回の交互最小二乗法を回して着いた $J = 1.27$ と一致する。軸を 1 本増やすごとに、 J は次の特異値の二乗だけ下がる。




図 6: 第 9 回の交互最小二乗法の流れ(左、博士論文抜粋の図 1.4 を描き直したもの)と、データ行列を 1 回特異値分解する流れ(右)




図 7: 3 列・60 点の人工データの特異値の二乗 δ_m^2 。 $Q = 2$ では青を残し、灰を捨てる。灰の高さが目的関数の最小値

第 2 に、データ行列の二乗和は、近似と誤差の二乗和にちょうど分かれる。(5) 式と (8) 式、(12) 式から

$$\|\mathbf{X}\|_F^2 = \|\mathbf{F}\mathbf{A}^\top\|_F^2 + \|\mathbf{E}\|_F^2, \quad \sum_{m=1}^p \delta_m^2 = \sum_{m \leq Q} \delta_m^2 + \sum_{m > Q} \delta_m^2 \quad (18)$$

である。近似は $\mathbf{F}\mathbf{A}^\top = \mathbf{X}\mathbf{A}\mathbf{A}^\top$ と書け、 $\mathbf{A}\mathbf{A}^\top$ は対称で $(\mathbf{A}\mathbf{A}^\top)(\mathbf{A}\mathbf{A}^\top) = \mathbf{A}\mathbf{A}^\top$ を満たす。これは第 3 回の射影行列 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$ の $\mathbf{X}$ を $\mathbf{A}$ に替えたものであり、 $\mathbf{A}^\top\mathbf{A} = \mathbf{I}_Q$ なので逆行列が消えている。回帰では $\mathbf{y}$ を列空間に落とした影が $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ であったのに対し、ここでは $\mathbf{X}$ の各行を $\mathbf{A}$ の列が張る面に落とした影が近似になる。(18) 式は、(14) 式の直角三角形を全行について足し合わせたピタゴラスの分解である。

第 3 に、(18) 式を $\|\mathbf{X}\|_F^2$ で割ると、近似が $\mathbf{X}$ の二乗和のどれだけを表したかがわかる。

$$\frac{\|\mathbf{F}\mathbf{A}^\top\|_F^2}{\|\mathbf{X}\|_F^2} = \frac{\sum_{m \leq Q} \delta_m^2}{\sum_{m=1}^p \delta_m^2} = 1 - \frac{J}{\|\mathbf{X}\|_F^2} \quad (19)$$

これを累積寄与率(cumulative contribution ratio)と呼び、1本ずつの $\delta_m^2 / \sum_m \delta_m^2$ を軸 m の寄与率(contribution ratio)と呼ぶ(定義 3)。図 7 の例では累積寄与率は 99.6% である。(19) 式は、累積寄与率が近似の誤差 J の裏返しであることを示している。 $\mathbf{X}$ と $\mathbf{F}\mathbf{A}^\top$ を np 個の数を並べたベクトルと見れば、両者のなす角 θ について $\cos^2 \theta = \|\mathbf{F}\mathbf{A}^\top\|_F^2 / \|\mathbf{X}\|_F^2$ である。これは、第 1 回の決定係数 R^2 が観測と予測値のなす角の $\cos^2$ であったのと同じ形である。回帰は $\mathbf{y}$ の影、主成分分析は $\mathbf{X}$ の影の長さの二乗の割合を測っている。

寄与率は、散らばりの割合としても読める。(11) 式の $\mathbf{F}$ について

$$\mathbf{F}^\top \mathbf{F} = \mathbf{\Delta}_1 \mathbf{K}_1^\top \mathbf{K}_1 \mathbf{\Delta}_1 = \mathbf{\Delta}_1^2 \quad (20)$$

であり、列の平均が 0 なので軸 m の得点の分散は δ_m^2/n である。全列の分散の合計は $\|\mathbf{X}\|_F^2/n = \sum_m \delta_m^2/n$ であるから、軸 m の寄与率は、全体の散らばりのうち軸 m の得点が受け持つ割合に等しい。なお $\mathbf{X}^\top \mathbf{X}/n = \mathbf{L}(\mathbf{\Delta}^2/n)\mathbf{L}^\top$ は、列の分散共分散行列を、列が長さ 1 で直交な $\mathbf{L}$ と対角行列で書いたものである。主成分分析を「分散共分散行列の固有値と固有ベクトルを求めること」と説明する教科書は、この形を見ている。(15) 式のとおり、得点の散らばりの最大化と近似の誤差の最小化は同じ問題であり、同じ $\mathbf{L}_1$ に着く。

第 4 に、軸の順番と向きが決まる。第 9 回で見たとおり、 $\mathbf{F}\mathbf{R}$ と $\mathbf{A}\mathbf{R}$ ($\mathbf{R}$ は $Q \times Q$ の正規直交行列)も同じ J を与え、交互最小二乗法はどの $\mathbf{R}$ に着くかを初期値に任せていた。図 8 (a) は同じ 60 点での交互最小二乗法(初期値 1)の答えで、得点の 2 列の相関は +0.71 である。特異値分解の答え (11) 式は、その中の 1 つである。(20) 式のとおり得点の列どうしが直交し(相関 0.00)、得点 1 の二乗和が最も大きく、以下 δ_m の順に並ぶ(図 8 (b))。特異値がすべて異なれば、残る自由は各軸の向きの反転($\mathbf{R}$ の対角が ± 1)だけである。さらに、 $Q = 1$ の答え $\mathbf{l}_1$ は $Q = 2$ の答え $\mathbf{L}_1$ の第 1 列そのものであるから、軸を 1 本足しても前の軸は変わらない。表 1 に、2 つの解き方で決まるものを並べた。

表 1: 2 つの解き方で決まるもの・決まらないもの

	交互最小二乗法(第 9 回)	特異値分解(本章)
$J \cdot$ 近似 $\mathbf{F}\mathbf{A}^\top \cdot$ 軸が張る面	決まる	決まる(同じもの)
軸 1 $\cdot$ 軸 2 それぞれの向き	初期値しだいで回る	δ_m の順に決まる(符号だけ残る)
得点の列どうし	相関が残る	相関 0
軸を 1 本足したとき	解き直す	前の軸はそのまま

定義 3 (寄与率). $\mathbf{X}$ の特異値 $\delta_1 \geq \dots \geq \delta_p$ について、 $\delta_m^2 / \sum_m \delta_m^2$ を軸 m の寄与率、上位 Q 本の和 $\sum_{m \leq Q} \delta_m^2 / \sum_m \delta_m^2$ を累積寄与率と呼ぶ。累積寄与率は $1 - J / \|\mathbf{X}\|_F^2$ に等しい。




図 8: 3 列・60 点の人工データの得点 $\mathbf{F}$ ($Q = 2$)。 (a) 交互最小二乗法(初期値 1)、 (b) 特異値分解。 J は同じ。色の 3 点は同じ行

位置づけ：3 つの目的関数

表 2 は、第 8 回で並べた 3 つの目的関数と解き方である。主成分分析の目的関数は第 9 回と同じで、本章で変わったのは解き方だけである。線形回帰が正規方程式を 1 回解けば済んだように、主成分分析もデータ行列の特異値分解を 1 回計算すれば済む。

表 2: 3 つの目的関数と解き方

モデル	近似する相手	目的関数	解き方	回
線形回帰	y	$\ \mathbf{y} - \mathbf{X}\boldsymbol{\beta}\ _2^2$	正規方程式を 1 回解く	第 1 回
主成分分析	$\mathbf{X}$	$\ \mathbf{X} - \mathbf{F}\mathbf{A}^\top\ _F^2$	交互に解く	第 9 回
主成分分析	$\mathbf{X}$	同じ	特異値分解を 1 回	第 10 回
k-means	$\mathbf{X}$	$\ \mathbf{X} - \mathbf{G}\mathbf{C}\ _F^2$	交互に解く	第 11 回

第 II 部 実データ解析

写真と手続き

第 II 部では、第 I 部の理論を写真 1 枚で試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、次の 2 つを予想できる。目的関数の最小値は捨てた特異値の二乗和 (12) 式であり、累積寄与率 (19) 式はその裏返しだった。ホットケーキの 3 列の人工データでは、2 本の軸で累積寄与率が 99.6% に達した。写真も、数本の軸で累積寄与率がほぼ 100% になるはずである。また、特異値分解の答えは、1 枚目に最もよい 1 本を置き、以下 δ_m の順に並べる。写真でも、1 枚目から番号の順に、大きな明暗を受け持つはずである。

写真は scikit-learn に付いている見本の写真 china.jpg (danielbuechele 氏の撮影、CC BY 2.0) である。これを白黒にして、明るさを黒 0・白 1 の数にした。行の数が列の数以上になるよう、左の 400 列を切り出した。画素の行 427 を行、画素の列 400 を列とする行列から各列の平均を引き、 $\mathbf{X}$ とした。どの列も同じ明るさの目盛りで測っているので、標準化はしない。

手続きは次のとおりである。I-6 の手順で $\mathbf{X}$ を NumPy の特異値分解で 1 回分解し、400 個の特異値と $\mathbf{K}$ 、 $\mathbf{L}$ を得た。 Q を 1、5、20、50 と変えて近似 $\mathbf{FA}^\top$ を作り、列の平均を足し戻して写真として見た。 $Q = 0$ から 100 までの J と累積寄与率も、同じ分解から求めた。確認のため、 $Q = 10$ で第 9 回の交互最小二乗法を 3 通りの初期値から回し、特異値分解の答えと比べた。最後に、列の平均を引かない写真そのものも同じように分解した。

結果：数本の軸で足りるか

図 9 は、 Q を 1、5、20、50 と増やしたときの近似 $\mathbf{FA}^\top$ に列の平均を足し戻した写真と、誤差 $\mathbf{E} = \mathbf{X} - \mathbf{FA}^\top$ である (誤差は赤が明るすぎ、青が暗すぎ)。 $Q = 1$ の近似は、(7) 式の 1 枚 $\delta_1 \mathbf{k}_1 \mathbf{l}_1^\top$ だけである。どの行も同じ $\mathbf{l}_1$ の定数倍なので、横の縞と縦の縞を掛け合わせた模様しか描けない。 $Q = 5$ で塔と空と水面の大きな明暗が現れ、 $Q = 20$ で屋根の段が分かれ、 $Q = 50$ ではほぼ元の写真に戻る。誤差は、 Q が増えるにつれて大きな明暗から木の葉や輪郭の細部へ移っていく。 $Q = 50$ の近似を保つのに要する数は $\mathbf{F}$ と $\mathbf{A}$ の $(n+p)Q = 41,350$ 個で、元の 170,800 個の 24% にあたる。

図 10 の線は、(12) 式の $\sum_{m>Q} \delta_m^2$ を $Q = 0$ から 100 まで並べたもので、 $Q = 0$ の値は $\|\mathbf{X}\|_F^2 = 11,948.8$ である。各 Q の誤差の二乗和を直接計算した値 ($Q = 1, 5, 20, 50$ で 5,699.3、2,599.1、1,354.3、688.4) も、この線に重なる。軸を 1 本増やすごとに、 J は次の特異値の二乗 δ_{Q+1}^2 だけ下がる。はじめの数本で大きく下がり、あとはゆっくり下がる。右の軸の累積寄与率で読むと、 $Q = 1, 5, 20, 50$ で 52.3%、78.2%、88.7%、94.2% である。2 本では 70.4% にとどまり、90% に届くのは $Q = 25$ 、99% に届くのは $Q = 155$ である。数本でほぼ 100% になるという予想は外れた。なお、特異値分解なら 1 回の分解から、すべての Q の答えと J が出る。

外れた理由は、(12) 式の和の中身を見るとわかる (表 3)。ホットケーキでは、3 本目の寄与率は 0.4% しか




図 9: 写真の低ランク近似。各行の左から、元の写真、上位 Q 本の近似に列の平均を足したもの、誤差 $\mathbf{X} - \mathbf{F}\mathbf{A}^T$ (赤は明るすぎ、青は暗すぎ)。上から $Q = 1, 5, 20, 50$




図 10: 写真の $\mathbf{X}$ の目的関数の最小値 $J = \sum_{m>Q} \delta_m^2$ (線)と、近似の誤差を直接計算した値(赤い丸、 $Q = 1, 5, 20, 50$)。累積寄与率は $1 - J/\|\mathbf{X}\|_F^2$ で、この線を裏返したもの

く、捨てる分はこの 1 本だけだった。写真でも、3 本目以降の寄与率は 1 本ずつは小さく、最大でも 3.4% である。ところが写真には捨てる軸が 398 本あり、 J はそのすべての和になる。合計すると 29.6% が残る。ホットケーキは、2 本の向きに小さなずれを足して作ったデータだった。写真には、そうした決まった数の向きがない。誤差に残った葉や輪郭のような細かな模様は、 δ_m^2 の小さい多くの軸に少しずつ散っている。

表 3: 上位 2 本と、3 本目以降の寄与率(ホットケーキは第 I 部の人工データ)

	列の数	上位 2 本の累積寄与率	3 本目以降の 1 本 (最大)	3 本目以降の合計
ホットケーキ(第 I 部)	3	99.6%	0.4%	0.4%
写真	400	70.4%	3.4%	29.6%

結果：1 枚ずつの模様

2 つ目の予想に進む前に、特異値分解 1 回の答えが交互最小二乗法の答えと同じであることを、写真でも確かめておく。 $Q = 10$ で第 9 回の交互最小二乗法を 3 通りの初期値から(J の下がり幅が $\|\mathbf{X}\|_F^2$ の 10^{-10} 倍を切るまで)回すと、30~42 回の反復で、特異値分解 1 回の $J = \sum_{m>10} \delta_m^2 = 1,945.5$ に着いた。近似 $\mathbf{FA}^\top$ の各マスの差は最大でも $7.2\text{e-}05$ である。交互最小二乗法の $\mathbf{A}$ は $\mathbf{L}_1\mathbf{R}$ ($\mathbf{R} = \mathbf{L}_1^\top\mathbf{A}$)とよく一致し、 $\mathbf{R}$ の対角の絶対値は最小で 0.01 と 1 から遠い。交互最小二乗法の答えは、 $\mathbf{L}_1$ を回したものである。 $\mathbf{A} = \mathbf{L}_1$ から 2 つの更新を 1 回ずつ計算しても、 $\mathbf{A}$ の変化は最大 $6\text{e-}16$ で、(13) 式のとおり動かなかった。

2 つ目の予想は、上位の枚が写真の大きな明暗を受け持つことだった。図 11 の上の段は、(7) 式の 1 枚ずつ $\delta_m\mathbf{k}_m\mathbf{l}_m^\top$ を $m = 1$ から 4 まで並べたものである(色の濃さは枚ごとにそろえた)。1 枚目は空と塔・木の明暗

の大きな区切りを受け持ち、番号が進むにつれてより細かい明暗の区切りを受け持つ。それぞれの枚の二乗和は δ_m^2 で、番号の順に小さくなる。予想どおりである。下の段は、交互最小二乗法(初期値 1)の答えを同じように 1 枚ずつ $\mathbf{f}_m \mathbf{a}_m^\top$ に分けたものである。10 枚の和は特異値分解の 10 枚の和と同じだが、1 枚ずつは $\mathbf{R}$ で混ざっており、二乗和も大きい順には並ばない。これも第 I 部の表 1 のとおりである。特異値分解の答えだけが、1 枚目に最もよい 1 本を、2 枚目に次によい 1 本を置く。




図 11: 1 枚ずつの模様(赤は正、青は負)。上 : 特異値分解の $\delta_m \mathbf{k}_m \mathbf{l}_m^\top$ 、下 : 交互最小二乗法($Q = 10$, 初期値 1)の $\mathbf{f}_m \mathbf{a}_m^\top$ 。 $m = 1 \sim 4$

落とし穴 : 列の平均を引かないと

最後に、本章の手順の 1 段階「列の平均を 0 にする」を省くとどうなるかを見る。写真の明るさはどこも 0 以上なので、平均を引かない写真そのものを分解すると、1 枚目 $\delta_1 \mathbf{k}_1 \mathbf{l}_1^\top$ は写真全体の明るさの大まかな形を受け持つ。図 12 のとおり、 $\mathbf{l}_1$ は列の平均の明るさとほぼ同じ形(相関 0.997)、 $\mathbf{k}_1$ は行の平均の明るさとほぼ同じ形(相関 0.992)である。1 本目は「どの列がどれだけ明るい」という平均の情報に取られる。

このとき、寄与率の数字が大きく変わる。表 4 のとおり、平均を引かない写真では $Q = 1$ の累積寄与率が 89.8% になり、平均を引いた $\mathbf{X}$ の 52.3% を大きく上回る。ところが誤差 J はむしろ大きい(6,319 と 5,699)。分母の $\|\mathbf{X}\|_F^2$ が、平均を引かないと 61,868 に膨らみ、その大半が平均の明るさだからである。累積寄与率は (19) 式のとおり $1 - J/\|\mathbf{X}\|_F^2$ であり、何を $\mathbf{X}$ にしたかで分母が変わる。異なる $\mathbf{X}$ どうして寄与率を比べることはできず、比べるなら同じ目盛りの J で比べる。




図 12: (a) 列の平均を引かない写真の 1 枚目 $\delta_1 \mathbf{k}_1 \mathbf{l}_1^\top$ 。(b) 列の平均の明るさを各行に並べたもの

表 4: 列の平均を引くかどうかで変わる寄与率と、変わりにくい誤差 J (写真の $\mathbf{X}$)

	列の平均を引いた $\mathbf{X}$	写真そのもの
$\ \mathbf{X}\ _F^2$	11,949	61,868
$Q = 1$ の累積寄与率	52.3%	89.8%
$Q = 1$ の J	5,699	6,319
$Q = 5$ の累積寄与率	78.2%	95.7%
$Q = 5$ の J	2,599	2,663

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは、写真も数本の軸で累積寄与率がほぼ 100% になると予想した。実際には、2 本で 70.4%、90% に届くのに 25 本、99% に届くのに 155 本を要し、予想は外れた。理由は、目的関数の最小値 J が捨てた特異値の二乗の和であることにある。写真の 3 本目以降の δ_m^2 は 1 本ずつは小さいが、数が多く、合わせると無視できない。2 本の向きに小さなずれを足して作ったホットケーキとは違い、写真の細かな模様は多くの軸に散っている。それでも $Q = 50$ で見た目はほぼ元に戻り、そのとき要する数は元の 24% である。一方、1 枚目から番号の順に大きな明暗から細部へと受け持つことは、予想どおり確かめられた。交互最小二乗法の答えは同じ J に着くが、1 枚ずつは混ざっていた。ただし、累積寄与率の値は何を $\mathbf{X}$ にしたかで変わる。列の平均を引かなければ、分母に平均の明るさが入る。

締め

まとめと次回の問い

本章の問いは、第 9 回で交互最小二乗法で解いた主成分分析を、反復せず 1 回で解けないか、であった。答えは、データ行列 $\mathbf{X}$ そのものを 1 回特異値分解することである。 $\mathbf{X} = \mathbf{K}\mathbf{\Delta}\mathbf{L}^\top$ を上位 Q 本と残りに分けると、Eckart–Young の定理により、ランク Q 以下で $\mathbf{X}$ に最も近い行列は上位 Q 枚を重ねた $\mathbf{K}_1\mathbf{\Delta}_1\mathbf{L}_1^\top$ になる。ランク Q 以下の行列は $\mathbf{F}\mathbf{A}^\top$ の形の行列と同じものなので、 $\hat{\mathbf{F}} = \mathbf{K}_1\mathbf{\Delta}_1$ 、 $\hat{\mathbf{A}} = \mathbf{L}_1$ が主成分分析の答えになる。それが最もよい理由は、誤差の最小化が得点の二乗和の最大化に等しく、その和が特異値の二乗に合計 Q の重みを配ったものになることにあった。目的関数の最小値は捨てた特異値の二乗和であり、データ行列の二乗和は近似と誤差にピタゴラスの分解で分かれる。累積寄与率は、その近似の側の割合、すなわち誤差の裏返しである。写真 1 枚の $\mathbf{X}$ では、 $Q = 10$ の特異値分解 1 回で、交互最小二乗法が 3 通りの初期値から反復して着いたのと同じ $J = 1,945.5$ に着いた。交互最小二乗法の答えは $\mathbf{L}_1$ を回したものであった。 Q を増やすと写真は大きな明暗から細部へと戻っていき、その誤差は捨てた δ_m^2 の和に一致した。特異値分解の答えは 1 枚ずつの模様を δ_m の順に並べるので、1 枚目が何を受け持つかを読める。ただし寄与率は、何を $\mathbf{X}$ にしたかによって変わる。列の平均を引かなければ 1 本目が平均の明るさに取られ、誤差は大きいのに寄与率だけが高く見える。

同じ学期の演習 11 では、顔画像を 50 本の軸で組み立て直し、累積寄与率 87.4% を保つ。ピクセルはどれも同じ目盛りなので標準化はしない。演習 12 では、自動車の 6 つのスペックを標準化してから 2 本の軸にまとめ、累積寄与率は 91.9% になる。どちらの数字も (19) 式の $1 - J/\|\mathbf{X}\|_F^2$ であり、何を $\mathbf{X}$ としたか(標準化したかどうか)によって値が変わる。

最後に、次回への問いを置く。主成分分析が 1 回で解けたのは、得点 $\mathbf{F}$ が連続な値をとれるので、特異値分解の上位 Q 本がそのまま答えになったからである。では、どのような問題では反復計算が必要になるのか。第 8 回で並べたもう 1 つの目的関数 $\|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2$ では、所属行列 $\mathbf{G}$ の各行に 1 が 1 つだけ立ち、残りは 0 である。行を群に分けるこの問題は、どう解けばよいのだろうか。