

第 10 回 主成分分析②

3 つの定式化と、答えの読み方

本章の問いは、第 9 回の締めで残った「残した軸は何を表し、何本残せばよいか？」である。第 9 回では、主成分分析の答えを低ランク近似として、データ行列の特異値分解 1 回で求めた。本章では、まず同じ問題が射影と分散最大化という別の 2 つの形でも書けることを、代入によって示す。分散最大化の形からは、分散共分散行列の固有値分解が自然に出てきて、固有値は軸ごとの得点の分散になる。固有値から寄与率を読み直し、負荷量とバイプロットで軸の意味を読む。列の単位がまちまちなら標準化し、相関行列の固有値分解として解く。因子分析は、誤差を列ごとの大きさを持つ独自因子として扱い、回転で読みやすい向きを選ぶ。縮めた得点は、可視化や次の解析の入力として使える。

第 I 部 理論

答えをどう読むか

第 9 回では、主成分分析の目的関数 $\|\mathbf{X} - \mathbf{F}\mathbf{A}^\top\|_F^2$ (ただし $\mathbf{A}^\top\mathbf{A} = \mathbf{I}_Q$) を低ランク近似として、データ行列 $\mathbf{X} = \mathbf{K}\mathbf{\Delta}\mathbf{L}^\top$ の特異値分解 1 回で解いた。答えは $\hat{\mathbf{F}} = \mathbf{K}_1\mathbf{\Delta}_1$ 、 $\hat{\mathbf{A}} = \mathbf{L}_1$ であった。本章では、この答えをどう読むかを考える。

例として、米国の朝食シリアル 65 銘柄の、1 カップあたりの栄養成分 8 列を使う(表 1)。8 列を標準化して第 9 回の手順で $Q = 2$ の軸を求めると、図 1 の $\mathbf{A}$ が得られる。ここで 3 つの困りごとがある。1 つ目は、この 16 個の数から軸 1・軸 2 が何を表すかをどう読むかである。2 つ目は、軸を何本残すかである。第 9 回の写真では、スクリープロットにはっきりした肘が出なかった。3 つ目は単位である。標準化せずに解くと、軸 1 はほぼカリウムとナトリウムだけで決まる。この 2 列だけが mg の単位で、数が桁違いに大きいからである。

表 1: 米国の朝食シリアルの栄養成分(1 カップあたり、65 銘柄のうち 4 銘柄)

銘柄	カロリー	たんぱく		ナトリウ		食物繊維	炭水化物	糖分	カリウム
		質	脂質	ム					
100% Bran	212	12	3	394	30	15	18		848

銘柄	カロリー	たんぱく質	脂質	ナトリウム	食物繊維	炭水化物	糖分	カリウム
Apple Cinnamon Cheerios	147	3	3	240	2	14	13	93
Double Chex	133	3	0	253	1	24	7	107
Multi-Grain Cheerios	100	2	1	220	2	15	6	90




図 1: シリアル の 8 列を標準化して主成分分析($Q = 2$)をかけたときの、軸の向き $\mathbf{A}$ の 2 列(赤は正、青は負)

本章の問いは、残した軸は何を表し、どう読めばよいか、である。以下ではまず、第 9 回と同じ問題が、射影と分散最大化という別の 2 つの形でも書けることを代入で示す。分散最大化の形からは、分散共分散行列の固有値分解が出てくる。固有値から第 9 回の寄与率を読み直して軸の数を考え、負荷量とパイプロットで軸の意味を読む。単位のまちまちな列を標準化することの意味を確かめた後、列ごとの揺れを分けてモデルにする因子分析を加え、回転で読みやすい向きを選ぶ。最後に、縮めた得点の使い道を確認する。

3 つの定式化

主成分分析には、同じ答えを与える 3 つの定式化がある。第 9 回の $\|\mathbf{X} - \mathbf{FA}^\top\|_F^2$ は、 $\mathbf{X}$ を少数の軸で作った近似 $\mathbf{FA}^\top$ で近似する低ランク近似の形であった(定式化①)。ここでは人工的なデータとして、コーヒー 40 杯の濃さと苦み(列の平均を引いた値)を使う(図 2 (a))。

まず、向き $\mathbf{A}$ を固定したときの最もよい $\mathbf{F}$ を求める。軸が 1 本で長さ 1 の向き $\mathbf{a}$ を固定すると、行 i の項 $\sum_j (x_{ij} - f_i a_j)^2$ は f_i だけの放物線であり、微分を 0 とおいて $\hat{f}_i = \sum_j a_j x_{ij} = \mathbf{a}^\top \tilde{\mathbf{x}}_i$ を得る($\sum_j a_j^2 = 1$)。これは点から直線へ下ろした垂線の足の位置である。軸が Q 本でも、第 1 回の重回帰と同じ計算で $\hat{\mathbf{f}}_i = \mathbf{A}^\top \tilde{\mathbf{x}}_i$ となり、行列では

$$\hat{\mathbf{F}} = \mathbf{X}\mathbf{A} \quad (1)$$

である。第9回の答えも $\hat{\mathbf{F}} = \mathbf{K}_1 \Delta_1 = \mathbf{X}\mathbf{L}_1$ で、この形をしている。(1) 式を目的関数に代入すると、 J は $\mathbf{A}$ だけの式

$$J(\mathbf{A}) = \|\mathbf{X} - \mathbf{X}\mathbf{A}\mathbf{A}^\top\|_F^2 = \|\mathbf{X} - \mathbf{X}\mathbf{P}\|_F^2, \quad \mathbf{P} = \mathbf{A}\mathbf{A}^\top \quad (2)$$

になる(定式化②)。 $\mathbf{P} \in \mathbb{R}^{p \times p}$ は対称で、 $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$ から $\mathbf{P}\mathbf{P} = \mathbf{A}(\mathbf{A}^\top \mathbf{A})\mathbf{A}^\top = \mathbf{P}$ を満たす。行 $\tilde{\mathbf{x}}_i$ に $\mathbf{P}$ を掛けた $\mathbf{P}\tilde{\mathbf{x}}_i$ は、点から $\mathbf{A}$ の列が張る面へ下ろした足、すなわち面に落とした影である。影の影は同じ影なので、 $\mathbf{P}$ を2回掛けても変わらない。第3回の $\mathbf{H}$ と同じ性質を持つこのような行列を、射影行列 (projection matrix) と呼ぶ。(2) 式は、各行を面への影で近似したときの誤差の二乗和を、面の向きについて最小にする問題である。

影と誤差は直角に交わる。原点・足・点は直角三角形をなし(図 2 (b))、ピタゴラスの定理から $\|\tilde{\mathbf{x}}_i\|_2^2 = \|\mathbf{P}\tilde{\mathbf{x}}_i\|_2^2 + \|\tilde{\mathbf{x}}_i - \mathbf{P}\tilde{\mathbf{x}}_i\|_2^2$ が成り立つ。影の長さの二乗は $\|\mathbf{P}\tilde{\mathbf{x}}_i\|_2^2 = \tilde{\mathbf{x}}_i^\top \mathbf{A}\mathbf{A}^\top \mathbf{A}\mathbf{A}^\top \tilde{\mathbf{x}}_i = \|\mathbf{A}^\top \tilde{\mathbf{x}}_i\|_2^2$ であり、行 i の得点の二乗和にあたる。 n 行分を足すと

$$\|\mathbf{X}\|_F^2 = \|\mathbf{X}\mathbf{A}\|_F^2 + \|\mathbf{X} - \mathbf{X}\mathbf{A}\mathbf{A}^\top\|_F^2 \quad (3)$$

となる。左辺は $\mathbf{A}$ によらない定数なので、 J を最小にすることは、得点の二乗和 $\|\mathbf{X}\mathbf{A}\|_F^2 = \text{tr}(\mathbf{A}^\top \mathbf{X}^\top \mathbf{X} \mathbf{A})$ を最大にすることと同じである。コーヒーの40点では、全体の二乗和 57.8 が、点の雲に沿う向きでは得点 52.6 と誤差 5.2 に、160度の向きでは得点 16.4 と誤差 41.5 に分かれる(図 2 (c))。

$\mathbf{X}$ は中心化してあるので、得点 $f_m = \mathbf{X}\mathbf{a}_m$ の平均も0であり、 $\frac{1}{n} \sum_i f_{im}^2$ は軸 m の得点の分散である。したがって主成分分析は、制約 $\mathbf{A}^\top \mathbf{A} = \mathbf{I}_Q$ のもとで

$$\max_{\mathbf{A}} \text{tr}(\mathbf{A}^\top \mathbf{X}^\top \mathbf{X} \mathbf{A}) \quad (4)$$

を解くこと、すなわち得点の分散の和を最大にする向きを探すことでもある(定式化③、分散最大化)。細長いパンを写真に撮るとき、横から撮れば写真の上で大きく写り、写らずに消える奥行きは小さい。誤差を小さくする向きと、得点を大きく散らばらせる向きは、同じ向きである。3つの定式化は同じ問題であり、答えの $\mathbf{A}$ も同じになる。

固有値分解

分散最大化 (4) 式の主役は $\mathbf{X}^\top \mathbf{X}$ である。 $\mathbf{X}$ は中心化してあるので、これを n で割った

$$\mathbf{S} = \frac{1}{n} \mathbf{X}^\top \mathbf{X} \quad (5)$$




図 2: コーヒー 40 杯の人工データで見る 3 つの定式化。(a) 第 9 回の答えの向き(赤)と、面への足(青)・誤差(灰)、(b) 1 点の直角三角形、(c) 2 つの向きでの得点の二乗和(青)と誤差 J (灰)の分かれ方

の対角成分は各列の分散、対角の外は 2 列の共分散であり、 $\mathbf{S}$ は分散共分散行列(variance-covariance matrix)である。

正方行列 $\mathbf{S}$ について、 $\mathbf{S}\mathbf{l} = \lambda\mathbf{l}$ を満たす長さ 1 の向き $\mathbf{l}$ を固有ベクトル(eigenvector)、 λ を固有値(eigenvalue)と呼ぶ。 $\mathbf{S}$ を掛けると、たいいていの向きは回ってしまうが、固有ベクトルの向きだけは変わらず、長さが λ 倍になる(図 3)。 $\mathbf{S}$ のような対称行列は、互いに直交な p 本の固有ベクトルを並べた正規直交行列 $\mathbf{L}$ と、固有値を対角に並べた $\mathbf{\Lambda}$ を使って

$$\mathbf{S} = \mathbf{L}\mathbf{\Lambda}\mathbf{L}^\top, \quad \mathbf{L}^\top\mathbf{L} = \mathbf{L}\mathbf{L}^\top = \mathbf{I}_p \quad (6)$$

と書ける。これを固有値分解(eigendecomposition)と呼ぶ(定義 1)。

第 9 回の特異値分解 $\mathbf{X} = \mathbf{K}\mathbf{\Delta}\mathbf{L}^\top$ を代入すると、 $\mathbf{K}^\top\mathbf{K} = \mathbf{I}$ から

$$\mathbf{X}^\top\mathbf{X} = \mathbf{L}\mathbf{\Delta}\mathbf{K}^\top\mathbf{K}\mathbf{\Delta}\mathbf{L}^\top = \mathbf{L}\mathbf{\Delta}^2\mathbf{L}^\top, \quad \mathbf{S} = \mathbf{L} \frac{\mathbf{\Delta}^2}{n} \mathbf{L}^\top \quad (7)$$

となる。これは (6) 式と同じ形であり、 $\mathbf{S}$ の固有ベクトルは $\mathbf{X}$ の右特異行列 $\mathbf{L}$ の列、固有値は $\lambda_m = \delta_m^2/n$ である。さらに軸 m の得点 $\mathbf{X}\mathbf{l}_m$ の分散は $\frac{1}{n}\|\mathbf{X}\mathbf{l}_m\|_2^2 = \mathbf{l}_m^\top\mathbf{S}\mathbf{l}_m = \lambda_m$ であり、固有値は軸ごとの得点の分散そのものである。コーヒーの例では $\lambda_1 = 1.31$ 、 $\lambda_2 = 0.13$ で、点の雲が長く伸びる向きの分散が大きい。データ行列を特異値分解しても、分散共分散行列を固有値分解しても、同じ軸の向きと得点が得られる(表 2)。主成分分析を「分散共分散行列の固有値と固有ベクトルを求めること」と説明する教科書は、後者の道を見ている。

表 2: 主成分分析の 2 つの計算の道

	データ行列の特異値分解(第 9 回)	分散共分散行列の固有値分解
分解するもの	$\mathbf{X} \ (n \times p)$	$\mathbf{S} = \mathbf{X}^\top\mathbf{X}/n \ (p \times p)$

	データ行列の特異値分解(第 9 回)	分散共分散行列の固有値分解
軸の向き $\hat{\mathbf{A}}$	$\mathbf{L}$ の左から Q 列	固有値の大きい順に Q 本の固有ベクトル
軸 m の大きさ	δ_m^2	$\lambda_m = \delta_m^2/n$ (得点の分散)
得点 $\hat{\mathbf{F}}$	$\mathbf{K}_1 \Delta_1$	$\mathbf{X} \hat{\mathbf{A}}$

定義 1 (固有値分解). 対称行列 $\mathbf{S}$ を、互いに直交な長さ 1 の固有ベクトルを並べた $\mathbf{L}$ と、固有値を対角に並べた $\mathbf{\Lambda}$ で $\mathbf{S} = \mathbf{L} \mathbf{\Lambda} \mathbf{L}^\top$ と書くことを、固有値分解と呼ぶ。

上位 Q 本が最もよい理由

第 9 回では、Eckart–Young の定理の答え(上位 Q 本を残す)が最もよいことを、2 列の例で確かめただけであった。分散最大化の形 (4) 式と固有値分解を使うと、一般に確かめられる。

軸が 1 本で長さ 1 の向き $\mathbf{a}$ のとき、得点の分散は (6) 式から

$$\frac{1}{n} \|\mathbf{X} \mathbf{a}\|_2^2 = \mathbf{a}^\top \mathbf{S} \mathbf{a} = \mathbf{a}^\top \mathbf{L} \mathbf{\Lambda} \mathbf{L}^\top \mathbf{a} = \sum_{m=1}^p \lambda_m (\mathbf{l}_m^\top \mathbf{a})^2 \quad (8)$$

となる。 $w_m = (\mathbf{l}_m^\top \mathbf{a})^2$ は 0 以上で、 $\mathbf{L}$ が正規直交行列なので $\sum_m w_m = \|\mathbf{L}^\top \mathbf{a}\|_2^2 = \|\mathbf{a}\|_2^2 = 1$ である。(8) 式は、合計 1 の重みを固有値 $\lambda_1, \dots, \lambda_p$ に配った重み付きの和である。これを最大にするには、すべての重みを最も大きい λ_1 に置けばよい。 $w_1 = 1$ となるのは $\mathbf{a} = \pm \mathbf{l}_1$ のときで、最大値は λ_1 である。

軸が Q 本なら、得点の分散の和は $\frac{1}{n} \text{tr}(\mathbf{A}^\top \mathbf{X}^\top \mathbf{X} \mathbf{A}) = \sum_m \lambda_m w_m$ 、 $w_m = \|\mathbf{A}^\top \mathbf{l}_m\|_2^2$ となる。重み w_m には 2 つの性質がある。第一に、 $\mathbf{A} \mathbf{A}^\top \mathbf{l}_m$ は長さ 1 の $\mathbf{l}_m$ を $\mathbf{A}$ の列が張る面に落とした影であり、直角三角形と同じ理由でその長さの二乗 w_m は 1 を超えない。第二に、 $\sum_m w_m = \text{tr}(\mathbf{A}^\top \mathbf{L} \mathbf{L}^\top \mathbf{A}) = \text{tr}(\mathbf{A}^\top \mathbf{A}) = Q$ である。1 つの固有値には 1 までしか置けず、合計で Q を配るので、上位 Q 個に 1 ずつ置いたときが最大で、最大値は $\sum_{m \leq Q} \lambda_m$ になる(図 4)。それを実現するのが $\mathbf{A} = \mathbf{L}_1$ であり、第 9 回の Eckart–Young の定理の答えに一致する。

寄与率とスクリープロット

固有値 λ_m は軸 m の得点の分散であり、その合計 $\sum_m \lambda_m = \text{tr}(\mathbf{S})$ は各列の分散の合計、すなわちデータ全体の散らばりである。そこで

$$\frac{\lambda_m}{\sum_{m'=1}^p \lambda_{m'}}, \quad \frac{\sum_{m \leq Q} \lambda_m}{\sum_m \lambda_m} = 1 - \frac{J}{\|\mathbf{X}\|_F^2} \quad (9)$$

は、第 9 回で定義した軸 m の寄与率と上位 Q 本の累積寄与率そのものである。 $\lambda_m = \delta_m^2/n$ なので、寄与率は全体の分散のうち軸 m の得点が受け持つ割合と読める。




図 3: コーヒー 40 杯の分散共分散行列 $\mathbf{S}$ を、長さ 1 の円(灰)の各点に掛けると楕円(黒)に移る。灰の矢印は向きが回るが、固有ベクトル(赤、長さは固有値)は向きが変わらない




図 4: 得点の分散の和 $\sum_m \lambda_m w_m$ の重みの配り方(概念図、 $p=5$ 、 $Q=2$)。棒の高さが λ_m 、青が $\lambda_m w_m$ 。(a) 1 までの重みを散らして合計 2 を配ったもの、(b) 上位 2 個に 1 ずつ置いたもの

人工的なデータで確かめる。弁当 60 個の 6 項目(ご飯・おかず・値段・カロリー・野菜・塩分)を、「量」と「野菜と塩分」の 2 つの模様から作った。単位は g・円・kcal とまちまちなので、まず列を標準化して解く。固有値を大きい順に並べたスクリープロット(第 9 回)を描く(図 5)。弁当では、2 本の後で固有値が急に小さくなり、2 本で累積寄与率は 96.7% に達する。急に平らになる手前を肘と呼び、肘までを残すのが 1 つの目安である。ほかに、累積寄与率が 80% などの線を超えるまで残す、標準化したときに固有値が 1 (1 列分の分散)より大きい軸だけを残す、という目安もよく使われる。弁当では、どの目安でも 2 本になる。しかし、どれも目安であり、正しい本数を決める規則ではない。第 8 回で見たとおり、 J は軸を増やすほど下がり続けるので、 J だけからは本数は決まらない。




図 5: 弁当 60 個の人工データ (6 項目を標準化) のスクリープロット。青の 2 本が肘の手前

負荷量とバイプロット

軸の意味は、軸の向き $\mathbf{a}_m$ の成分から読む。 $\mathbf{a}_m$ の第 j 成分 a_{jm} を主成分負荷量 (loading) と呼ぶ。得点は $f_{im} = \sum_j a_{jm} x_{ij}$ であるから、負荷量は「得点を作るとき各列の重み」である。図 6 は、弁当の標準化した 6 列の負荷量を棒で示したものである。軸 1 ではご飯・おかず・値段・カロリーの 4 列がそろって大きく、得点 1 が大きい弁当はどれも大きい。「量の軸」と読める。軸 2 では野菜と塩分が逆の符号で大きく、野菜が多く塩分が少ない弁当と、その逆を分ける。




図 6: 弁当 60 個の人工データ (6 項目を標準化) の負荷量。赤は正、青は負

標準化した列 $\mathbf{z}_j$ と得点 $\mathbf{f}_m = \mathbf{Z}\mathbf{a}_m$ の相関は、 $\mathbf{S}\mathbf{a}_m = \lambda_m \mathbf{a}_m$ と、得点の分散が λ_m であることから

$$\text{corr}(\mathbf{z}_j, \mathbf{f}_m) = \frac{\frac{1}{n} \mathbf{z}_j^\top \mathbf{Z} \mathbf{a}_m}{\sqrt{\lambda_m}} = \frac{\lambda_m a_{jm}}{\sqrt{\lambda_m}} = a_{jm} \sqrt{\lambda_m} \quad (10)$$

となる。同じ軸の中では、負荷量の大小がそのまま列と得点の相関の大小である。負荷量に $\sqrt{\lambda_m}$ を掛けたものを負荷量と呼ぶ本もあるので、読むときは定義を確かめる。

得点と負荷量を 1 枚の図に重ねたものをバイプロット (biplot) と呼ぶ (図 7)。点は行 (弁当) の得点、矢印は列の

負荷量(ここでは $a_{jm}\sqrt{\lambda_m}$)である。矢印の向きにある点ほど、その列の値が大きい。ご飯・おかず・値段・カロリーの矢印はそろって右を、野菜と塩分の矢印は上下の逆を向く。




図 7: 弁当 60 個の人工データのバイプロット。灰の点は弁当の得点、赤の矢印は各列の負荷量($a_{jm}\sqrt{\lambda_m}$ を図の大きさに合わせて伸ばした)

ただし、第 9 回で見たとおり、軸の向きは裏返しても近似も J も変わらない。負荷量の符号そのものに意味はなく、読むべきは、どの列とどの列が同じ向きに並び、どの列が逆を向くかである。

標準化の再訪

第 8 回で見たとおり、列の単位は目的関数の中で列の重みになる。弁当の 6 列を元の単位のまま主成分分析にかけると、軸 1 はほぼカロリー(kcal)と値段(円)だけで決まり、塩分(g)はほとんど 0 になる(図 8 (a))。数の大きい列が分散の大半を持ち、分散最大化 (4) 式はその列の向きを選んでしまうからである。列を標準化してから解くと、量の 4 列がそろって軸 1 に乗る(図 8 (b))。

標準化した $\mathbf{Z}$ の分散共分散行列 $\frac{1}{n}\mathbf{Z}^T\mathbf{Z}$ の (j, k) 成分は $s_{jk}/\sqrt{s_{jj}s_{kk}}$ 、すなわち元の列の相関係数であり、この行列は相関行列 $\mathbf{R}$ である。標準化してからの主成分分析は、相関行列の固有値分解にあたる。どの列も分散 1 にそろえて数えると決めたことになるので、「固有値 1 以上」の目安は、1 列分より多くの分散を受け持つ軸を残すという意味を持つ。単位のそろった列(第 9 回の写真の明るさなど)なら標準化は要らないが、単位がまちまちなら、ふつうは相関行列の主成分分析を使う。それでも標準化は、第 8 回で見たとおり中立な既定値ではなく、すべての列を同じ重さで数えるという選択である。




図 8: 弁当 60 個の人工データの軸 1 の負荷量。(a) 元の単位のまま、(b) 標準化してから

因子分析

主成分分析は、各列の分散をまるごと少数の軸で近似しようとする。しかし列には、ほかの列と共有しない、その列だけの揺れもある。そこで、列どうしが共有する部分と、列ごとの部分を分けてモデルにしたのが因子分析 (factor analysis) である。

人工的なデータで見る。パン屋 100 軒の 6 項目の評価(味・香り・食感・値段の安さ・量・駅からの近さ、どれも標準化した値)を、「おいしさ」と「お得さ」の 2 つの共通の要因から作った。駅からの近さは、共通の要因ではほとんど決まらないように作った。主成分分析で 2 本の軸を求めると、駅からの近さも軸 1 に 0.46 で乗る(図 9 (a))。主成分分析は、この列だけの揺れまで軸で近似しようとするからである。

因子分析では、行 i の列 j の値を

$$x_{ij} = \sum_{m=1}^Q \lambda_{jm} f_{im} + \varepsilon_{ij} \quad (11)$$

と書く。 f_{im} は行 i の共通因子 m の値、 λ_{jm} は列 j の因子負荷量、 ε_{ij} は列 j だけの揺れ(独自因子)である。ベクトルで書けば $\tilde{\mathbf{x}}_i = \mathbf{A}\tilde{\mathbf{f}}_i + \tilde{\boldsymbol{\varepsilon}}_i$ であり、共通因子は $\tilde{\mathbf{f}}_i \sim N(\mathbf{0}, \mathbf{I}_Q)$ 、独自因子は $\tilde{\boldsymbol{\varepsilon}}_i \sim N(\mathbf{0}, \boldsymbol{\Psi})$ に従い、互いに独立とする。 $\boldsymbol{\Psi} = \text{diag}(\psi_1, \dots, \psi_p)$ は対角行列で、独自因子どうしは無相関、大きさ ψ_j は列ごとに違ってよい。このとき $\tilde{\mathbf{x}}_i$ の分散共分散行列は

$$\boldsymbol{\Sigma} = \mathbf{A}\mathbf{A}^\top + \boldsymbol{\Psi} \quad (12)$$

となる(定義 2)。対角の外 $\sigma_{jk} = \sum_m \lambda_{jm} \lambda_{km}$ には $\boldsymbol{\Psi}$ が入らないので、列どうしの相関は共通因子だけが作る。対角 $\sigma_{jj} = \sum_m \lambda_{jm}^2 + \psi_j$ は、共通因子が説明する共通性(communality)と、列だけの独自性(uniqueness)に分かれる。

2 つの方法の違いは、誤差の扱いにある。主成分分析を $\mathbf{X} = \mathbf{F}\mathbf{A}^\top + \mathbf{E}$ と書けば、 $\mathbf{E}$ は捨てた層の残りものであり、列ごとの大きさを表す量はモデルにない。全列まとめて $\|\mathbf{E}\|^2$ を小さくするので、軸は列だけの揺れまで

拾ってしまう。パン屋のデータで2本の軸を残すと、捨てた層の分散はどの列も作るときに置いた独自の揺れより小さく、駅からの近さでは0.78（置いた値は0.87）であった。因子分析では、誤差 $\varepsilon_{ij} \sim N(0, \psi_j)$ は独自因子としてモデルの一部であり、その大きさ ψ_j を列ごとに見積もる。推定した駅からの近さの独自性は0.89で、置いた値に近い(図9(b))。主成分分析が軸に乗せた近さの揺れを、因子分析は独自性に逃がしている。同じ歌を何本かのマイクで録るとき、歌は全部のマイクに入るが、雑音の大きさはマイクごとに違う。因子分析は、マイクごとに雑音の大きさを見積もって外す方法である。

逆に、独自因子の大きさがどの列も同じ $\Psi = \sigma^2 \mathbf{I}$ なら、 $\mathbf{A}\mathbf{A}^\top \mathbf{l} = \mu \mathbf{l}$ のとき $(\mathbf{A}\mathbf{A}^\top + \sigma^2 \mathbf{I})\mathbf{l} = (\mu + \sigma^2)\mathbf{l}$ となる。 Σ の固有ベクトルは $\mathbf{A}\mathbf{A}^\top$ のものと同じで、軸は主成分分析と同じ向きになる。主成分分析は誤差をどの列も同じ大きさとみなす場合に当たり、因子分析はその大きさを列ごとに变えてよいとした方法だといえる。 $\mathbf{A}$ と Ψ を求める計算には立ち入らず、ライブラリ(scikit-learn の FactorAnalysis)に任せる。




図9: パン屋100軒の人工データ。(a) 主成分分析の軸1の $a_{j1}\sqrt{\lambda_1}$ 、(b) 主成分分析(2本)で捨てた層の分散(赤)、因子分析(2因子)の独自性(青)、作るときに置いた独自の揺れ(黒の線)、(c) バリマックス回転した因子負荷量

因子にも、第9回と同じ回転の不定性がある。 $\mathbf{R}$ を $Q \times Q$ の正規直交行列とすると $(\mathbf{A}\mathbf{R})(\mathbf{A}\mathbf{R})^\top = \mathbf{A}\mathbf{A}^\top$ であり、 Σ は変わらない。主成分分析では特異値の大きい順に軸を並べてこの自由を使い切ったが、因子分析では逆に、この自由を「読みやすい向きを選ぶ」ことに使う。よく使われるのがバリマックス回転(varimax rotation)で、

$$\max_{\mathbf{R}} \sum_{m=1}^Q \left[\frac{1}{p} \sum_{j=1}^p \lambda_{jm}^4 - \left(\frac{1}{p} \sum_{j=1}^p \lambda_{jm}^2 \right)^2 \right] \quad (13)$$

を最大にする $\mathbf{R}$ を選ぶ(λ_{jm} は回した後の負荷量)。括弧の中は、因子 m の負荷量の二乗の分散である。これを大きくすると、負荷量は0に近いものと大きいものに分かれ、各列がなるべく1つの因子だけに乗る(単純構造)。パン屋では、回転の後、因子1には味・香り・食感が、因子2には値段の安さ・量が乗り、それぞれ「おいしさ」「お得さ」と名前が付けられる(図9(c))。

表 3: 主成分分析と因子分析

	主成分分析	因子分析
モデル	$\mathbf{X} = \mathbf{F}\mathbf{A}^\top + \mathbf{E}$	$\tilde{\mathbf{x}}_i = \mathbf{A}\tilde{\mathbf{f}}_i + \tilde{\mathbf{e}}_i$
誤差	捨てた層の残りもの(列ごとの大きさを持たない)	独自因子(列ごとの大きさ ψ_j を見積もる)
近似する相手	各列の分散をまるごと	列どうしの共分散(共通の部分)
軸の向き	δ_m の順に決める	回して読みやすい向きを選ぶ

定義 2 (因子分析). 各行のベクトルを、少数の共通因子と列ごとの独自因子の和 $\tilde{\mathbf{x}}_i = \mathbf{A}\tilde{\mathbf{f}}_i + \tilde{\mathbf{e}}_i$ で表し、分散共分散行列を $\mathbf{A}\mathbf{A}^\top + \mathbf{\Psi}$ ($\mathbf{\Psi}$ は対角) の形で推定することを因子分析と呼ぶ。 $\mathbf{A}$ を因子負荷量、 $\sum_m \lambda_{jm}^2$ を共通性、 ψ_j を独自性と呼ぶ。

前処理としての低次元化

主成分分析で得た得点 $\mathbf{F}$ は、 p 列のデータを Q 列に縮めたものである。その使い道は 2 つある。1 つは見ることである。6 列のデータの散布図はそのままでは描けないが、得点の 2 列なら 1 枚の図に描ける(図 7)。近い点は、元の 6 項目がよく似た行である。列が数十や数百あるデータでも、まず 2 次元の地図にして全体を眺められる。もう 1 つは、次の解析に渡すことである。 p 列の $\mathbf{X}$ の代わりに Q 列の得点 $\mathbf{F}$ を、k-means や回帰に渡す。第 3 回で見た「似た列が多いと係数が不安定になる」問題は、似た列のまとまりを 1 本の軸にまとめることでやわらぐ。第 9 回で見たとおり、特異値の小さい層はノイズとして落ちている。このように、主成分分析はそれ自体で結論を出すよりも、高次元のデータを扱う前の下ごしらえ(前処理)として使われることが多い。

計算の手順

本章の内容を、主成分分析を実際に使う手順としてまとめる。

1. 列の平均を引いたデータ行列 $\mathbf{X}$ を用意する。単位がまちまちなら、標準化した $\mathbf{Z}$ を使う(相関行列の主成分分析)
2. $\mathbf{X}$ を特異値分解する。分散共分散行列 $\mathbf{S}$ を固有値分解しても同じ答えになる。固有値は $\lambda_m = \delta_m^2/n$ である
3. スクリーンプロットと累積寄与率を見て、軸の数 Q を決める。目安どうしが食い違うときは、その理由とともに報告する
4. $\mathbf{A} \leftarrow \mathbf{L}_1$ 、 $\mathbf{F} \leftarrow \mathbf{X}\mathbf{A}$ とする
5. 負荷量の棒とパイプロットで軸を読む。符号ではなく、どの列が同じ向き・逆向きに並ぶかを読む

地図の中の主成分分析

表 4 は、第 8 回で並べた目的関数に解き方を添えたものである。主成分分析の行は、第 9 回の低ランク近似に加えて、本章の射影と分散最大化の形で書け、データ行列の特異値分解でも、分散共分散行列の固有値分解でも解ける。

表 4: 3 つの目的関数と解き方

モデル	近似する相手	目的関数	解き方	回
線形回帰	y	$\ y - X\beta\ _2^2$	正規方程式を 1 回解く	第 1 回
主成分分析	X	$\ X - FA^T\ _F^2$ = 射影 = 分散 最大化	特異値分解・固有値分解を 1 回	第 9・10 回
k-means	X	$\ X - GC\ _F^2$	交互に解く	第 11 回

第 II 部 実データ解析

シリアルのデータと手続き

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、次の 3 つを予想できる。第 1 に、単位がまちまちな列を標準化せずに解くと、数の大きい列が分散の大半を持つので、軸 1 はその列で決まるはずである。シリアルでは、ナトリウムとカリウムが mg の単位で数が多い。第 2 に、標準化した弁当では、スクリープロットの肘・累積寄与率・固有値 1 以上の 3 つの目安がそろって 2 本を指した。シリアルでも肘が出て、目安がそろはずである。第 3 に、負荷量とパイプロットから、軸に名前が付けられるはずである。第 4 に、因子分析でバリマックス回転すると、パン屋のように各列がなるべく 1 つの因子だけに乗り、名前が付けやすくなるはずである。

データは、米国の朝食シリアル 65 銘柄の栄養成分である。1993 年の ASA 統計グラフィックス展示会のデータを、1 カップあたりの量にそろえたもので、R の MASS パッケージに UScereal として収録されている (Venables and Ripley, 2002)。Rdatasets から一度だけ取得して保存した。列はカロリー(kcal)、たんぱく質・脂質・食物繊維・炭水化物・糖分(g)、ナトリウム・カリウム(mg)の 8 列である。

手続きは次のとおりである。8 列から列の平均を引いた X と、さらに標準偏差で割った Z を作り、それぞれの特異値分解して、固有値 δ_m^2/n と負荷量を求めた。負荷量の符号は決まらないので、各軸で絶対値の最も大きい成分が正になる向きにそろえた。 Z については、スクリープロットと 3 つの目安で軸の数を調べ、負荷量の棒と

バイプロットで軸を読んだ。最後に、65 銘柄から 1 銘柄ずつ抜いて同じ計算をやり直し(65 通り)、軸 1 から 3 の向きが元の向きとどれだけそろうかを、向きのコサインの絶対値で調べた。さらに **Z** に 3 因子の因子分析を当て(scikit-learn の FactorAnalysis、バリマックス回転)、同じく 1 銘柄ずつ抜いて解き直した。因子は回転で順番が入れ替わりうるので、元の因子との対応は、向きのコサインの和が最も大きくなる組み合わせで決めた。

結果①：単位と軸 1

第 1 の予想は単位である。8 列を元の単位のまま主成分分析にかけると、軸 1 の負荷量はカリウムとナトリウムでほぼ決まった(図 10 (a))。予想どおりである。この 2 列だけが mg の単位で、数が桁違いに大きいからである。このとき軸 1 の寄与率は 77.0% と高く見えるが、それは mg の 2 列が分散のほとんどを占めているからにすぎない。標準化して相関行列の主成分分析にすると、軸 1 には 8 列がすべて同じ符号で乗り(図 10 (b))、寄与率は 53.0% になる。寄与率の分母は全体の分散なので、標準化するかどうかで分母が変わり、両者の寄与率は比べられない。以下では標準化した **Z** で調べる。




図 10: シリアル 65 銘柄の軸 1 の負荷量(赤は正、青は負)。(a) 元の単位のまま、(b) 標準化してから

結果②：本数の目安

第 2 の予想は本数である。標準化したシリアルの固有値は 4.24、1.34、1.18、0.61、0.49、0.10、0.03、0.01 であった(図 11)。1 本目の後で大きく下がるが、2 本目と 3 本目はほぼ同じ高さで、その後も少しずつ下がる。3 つの目安を当てると、肘は 1 本目の後とも 4 本目の手前とも読め、累積寄与率 80% なら 3 本、固有値 1 以上なら 3 本になる。弁当では 3 つの目安がそろって 2 本を指したが、シリアルでは目安で答えが変わった。予想は外れた。

理由は、データの作られ方にある。弁当は 2 つの模様になさなずれを足して作ったので、2 本目と 3 本目の固有値の間に 1.87 の大きな段差があった。シリアルは、決まった数の模様から作られたデータではない。2 本目と 3 本目の固有値の差は 0.17 しかなく、段差がはっきりしない。第 9 回の写真でも、細かな模様が多くの小さな層に散っていた。実データでは、本数の目安は答えをそろえてくれるとは限らない。目安が食い違うときは、何本を選んだかと、その理由を一緒に報告するしかない。




図 11: 標準化したデータのスクリープロット。上は第 I 部の弁当(人工データ)、下はシリアル 65 銘柄

結果③ : 軸を読む

第 3 の予想は軸の読み方である。図 12 (a) の軸 1 では、8 列の負荷量がすべて同じ符号である。このデータは 1 カップあたりにそろえてあるので、1 カップに詰まった中身が多い銘柄ほど、どの成分も多くなる。軸 1 は「1 杯の中身の多さ」の軸と読める。軸 2 では、食物繊維・カリウム・たんぱく質と、糖分・脂質・カロリーが逆の符号である。ふすま(ブラン)を主にした銘柄と、甘い銘柄を分ける対比と読める。図 12 (b) のパイプロットでも、上には All-Bran などのブラン系が並び、矢印の向きと合う。予想どおり、負荷量とパイプロットから軸に名前が付けられた。

落とし穴 : 軸の安定さ

軸に名前を付けるときの落とし穴を見る。シリアルの 2 本目と 3 本目の固有値はほぼ同じであった。65 銘柄から 1 銘柄ずつ抜いて解き直し、軸の向きが元の向きとどれだけそろうかを調べた(表 5)。軸 1 は、どの銘柄を抜いても向きのそろい(コサインの絶対値)が 0.995 以上で、ほとんど変わらない。一方、軸 2 と軸 3 は、All-Bran with Extra Fiberなどを抜くと向きのそろいが 0.13 まで落ち、2 本が入れ替わるように回った。固有値がほぼ同じ 2 本は、その 2 本が張る面の中では、どの向きでもほとんど同じだけ分散を受け持つ。第 9 回で見た回転の不安定性が、ほぼそのまま現れるのである。軸 2 の「ブラン系か甘い系か」という名前も、データが少し変わると別の向きに付け替わりうる。固有値の段差がはっきりしない軸に名前を付けるときは、解き直して向きが保たれるかを確かめる必要がある。




図 12: シリアル 65 銘柄(標準化)の (a) 軸 1・軸 2 の負荷量と、(b) バイプロット(灰の点が銘柄、赤の矢印が列の負荷量。名前は得点の両端の銘柄)

表 5: シリアル 65 銘柄から 1 銘柄ずつ抜いて解き直したときの、軸の向きと元の向きのコサインの絶対値

	軸 1	軸 2	軸 3
向きのそろい(最小)	0.995	0.129	0.127
0.9 を下回った回数(65 通り中)	0	2	3

結果④ : 因子分析

第 4 の予想は因子分析である。標準化した 8 列に 3 因子の因子分析を当て、バリマックス回転すると、各列はほぼ 1 つの因子だけに大きく乗った(図 13 (a))。因子 1 には炭水化物とカロリーが、因子 2 には食物繊維・カリウム・たんぱく質が、因子 3 には糖分と脂質が乗る。それぞれ「穀物の量」「ブラン系」「甘さと脂」と名前が付けられ、予想どおりである。共通性と独自性を見ると(図 13 (b))、ナトリウムの独自性は 0.60 と大きい。塩の量は 3 つの因子とは別に、銘柄ごとに決まっているとわかる。主成分分析で 3 本の軸を残したときにナトリウムで捨てた分散は 0.47 であり、因子分析のほうが塩の揺れを独自因子へ多く回している。




図 13: シリアル 65 銘柄(標準化)の 3 因子の因子分析(バリマックス回転)。(a) 因子負荷量(赤は正、青は負)、(b) 共通性(青)と独自性(灰)

因子は安定してもいた。主成分分析と同じく 1 銘柄ずつ抜いて解き直すと、3 つの因子の向きのそろいは最小でも 0.929 であり、主成分分析の軸 2・3 が 0.13 まで落ちたのと対照的である(表 6)。主成分分析の軸 2・3 は固有値がほぼ同じで、2 本が張る面の中のどの向きでもほとんど同じだけ分散を受け持つため、データが少し

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは 3 つの予想を立てた。標準化しないと軸 1 は mg の列で決まるという予想は当たり、標準化すると 8 列が同じ符号で軸 1 に乗った。スクリープロットに肘が出て本数の目安がそうという予想は外れた。2 本目と 3 本目の固有値に段差がなく、目安によって 1 本から 3 本まで答えが変わった。シリアルは、決まった数の模様から作られたデータではないからである。負荷量とパイプロットで軸に名前が付けられるという予想は当たり、軸 1 は 1 杯の中身の多さ、軸 2 はブラン系か甘い系かと読めた。ただし、軸 2 と軸 3 は 1 銘柄を抜くだけで向きが入れ替わることがあり、名前は固有値の段差しだい不安定になる。最後に、因子分析でバリマックス回転すると、各列がほぼ 1 つの因子に乗って「穀物の量」「ブラン系」「甘さと脂」と名前が付き、1 銘柄を抜いても向きが保たれた。これも予想どおりである。

締め

まとめと次回問い

本章の問いは、残した軸は何を表し、どう読めばよいか、であった。まず、第 9 回の低ランク近似の形に $\hat{\mathbf{F}} = \mathbf{X}\mathbf{A}$ を代入すると射影の形になり、行ごとの直角三角形を足し上げると分散最大化の形になることを示した。3 つは同じ問題であり、誤差を小さくする向きは得点の分散を大きくする向きである。分散最大化の形からは、分散共分散行列 $\mathbf{S} = \mathbf{X}^T \mathbf{X} / n$ の固有値分解が出てきた。 $\mathbf{S}$ の固有ベクトルは $\mathbf{X}$ の右特異行列の列であり、固有値 $\lambda_m = \delta_m^2 / n$ は軸 m の得点の分散である。得点の分散の和が固有値に重みを配った和になることから、上位 Q 本が最もよいことも確かめた。軸の本数は、第 9 回の寄与率を固有値の割合として読み、スクリープロットを目安に考える。軸の意味は、負荷量とパイプロットで、列どうしが同じ向きか逆向きかから読む。単位がまちまちな列は標準化し、相関行列の主成分分析として解く。列ごとの揺れまで近似したくなければ、誤差を列ごとの大きさを持つ独自因子として分ける因子分析を当て、回転の自由を使って各列がなるべく 1 つの因子に乗る向きを選ぶ。縮めた得点は、図に描いて眺めたり、次の解析に渡したりする前処理として使える。シリアル 65 銘柄では、標準化しないと軸 1 が mg の 2 列で決まった。標準化した後の本数の目安は食い違い、軸 2 と軸 3 は 1 銘柄を抜くだけで入れ替わることがあった。因子分析でバリマックス回転すると、3 つの因子に名前が付き、1 銘柄を抜いても向きは保たれた。

最後に、次回への問いを置く。主成分分析が特異値分解 1 回で解けたのは、得点 $\mathbf{F}$ が連続な値を自由にとれたからである。第 8 回で並べたもう 1 つの目的関数 $\|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2$ では、所属行列 $\mathbf{G}$ の各行に 1 が 1 つだけ立ち、残りは 0 である。行を群に分けるこの問題は、どう解けばよいのだろうか。

発展

発展①：遺伝子発現データと主成分分析

発展として、主成分分析が実際の研究でどう使われているかを見る。生物学では、1 つ 1 つの細胞について、約 2 万の遺伝子がどれだけ働いているかを、RNA の数として数える（シングルセル RNA-seq (single-cell

RNA-seq))。行は細胞で、数千から数百万ある。列は遺伝子で、約 2 万ある。2 万列のデータ行列は、そのままでは図に描けない。

そこで、まず主成分分析で列を縮める。図 14 はマウスの小腸の上皮の細胞を、5 つの方法で 2 次元に描いた図である (Luecken & Theis 2019)。右下の (F) は寄与率を大きい順に並べたスクリープロットで、5~7 本目に肘がある。論文でも、本章と同じ道具で残す本数を考えている。多くの解析は、上位の数十本の主成分を残してから次の計算へ進む。(A) は主成分分析の軸 1 と軸 2 である。色は細胞ごとに読み取った RNA の総数で、軸 1 の右ほど明るい。弁当やシリアルと同じく、軸 1 は量の軸として現れた。




図 14: マウス小腸の上皮の細胞を 2 次元に描いた図。(A) 主成分分析、(B) t-SNE、(C) 拡散写像、(D) UMAP、(E) 力学モデルによるグラフの配置。色は細胞ごとに読み取った RNA の総数。(F) 主成分の寄与率と肘。出典：Luecken & Theis (2019) Mol. Syst. Biol. 15: e8746, Fig. 4 (CC BY 4.0)

発展②：t-SNE と UMAP

主成分分析の 2 本だけでは、細胞の種類が重なって見えることが多い。図 15 (a) はマウス的大脑皮質の 23,822 細胞を主成分分析の軸 1・2 に描いた図で、色は 133 の細胞の種類である (Kobak & Berens 2019)。大きな塊が 3 つ見えるだけで、種類の多くは重なる。同じデータに t-SNE (t-distributed stochastic neighbor embedding) を当てると (b)、種類ごとの島に分かれる。

t-SNE は次のように考える。まず元の空間で、点ごとに近所を決め、近い点ほど大きな重みを付ける。次に 2 次元に点を置き、2 次元での近所の重みが元の重みとそろうように、点を少しずつ動かす。保とうとするのは近所の関係だけで、遠い点どうしの距離は保たない。主成分分析の射影は 1 回の特異値分解で決まったが、t-SNE は反復で解き、初期の位置や設定によって絵が変わる。初期の位置には主成分分析の得点を使うことが多い。UMAP (uniform manifold approximation and projection) も考え方は近く、近所のつながりをグラフにし、そ

のつながりが残るように 2 次元に描き直す。大きなデータでも速く、いまの論文で最もよく見る図である。描いた後は、島ごとにどの遺伝子が働いているかを調べ、幹細胞や杯細胞のように細胞の種類の名前を付ける。因子に名前を付けたのと同じ読み方である。




図 15: マウス大脳皮質の 23,822 細胞。色は 133 の細胞の種類。(a) 主成分分析の軸 1・2、(b) t-SNE (既定の設定)。出典: Kobak & Berens (2019) Nat. Commun. 10: 5416, Fig. 2b, c (一部を切り出した。CC BY 4.0)

発展③: 2 次元の図を読むときの注意

2 次元の図を読むときには注意が要る。t-SNE や UMAP が保とうとするのは近所の関係だけなので、島どうしの距離は元の距離を表さない。Chari & Pachter (2023) は、細胞の種類どうしの近さの順位が、元のデータと 2 次元の図でどれだけそろうかを、順位的一致度(1 で完全に一致)で調べた。主成分分析で残した 50 本ではおよそ 0.75 だったが、そこから描いた t-SNE と UMAP ではおよそ 0.3 まで下がった。さらに、細胞を象の形に並べた図を作ると、元の距離の保ち方は t-SNE や UMAP と同じくらいであった(図 16)。2 次元の形そのものには意味を読めない。




図 16: 細胞を象の形に並べた図(左)と、元のデータの距離との相関(右。異なる種類の細胞どうし・同じ種類の細胞どうし)。青は象、橙は主成分分析の 2 本、緑は t-SNE、赤は UMAP。出典: Chari & Pachter (2023) PLoS Comput. Biol. 19: e1011288, Fig. 7 (上の段を切り出した。CC BY 4.0)

主成分分析と t-SNE・UMAP の違いを 表 7 にまとめる。標準の流れでは、約 2 万列の遺伝子をまず主成分分析で上位の数十本に縮め、その得点に t-SNE や UMAP を当てて 2 次元に描き、島に名前を付ける。主成分分析

は、2次元の絵の手前で働く前処理である。

表 7: 主成分分析と t-SNE・UMAP

	主成分分析	t-SNE・UMAP
写し方	線形(射影 $\mathbf{XA}$)	非線形
軸	負荷量で意味を読める	軸に意味はない
保つもの	得点の分散(遠い点どうしの関係も)	近所の関係だけ
解き方	特異値分解 1 回、答えは 1 つ	反復。初期の位置と設定で絵が変わる
使いどころ	前処理、軸の解釈	島を眺め、名前を付ける

参考文献

- Luecken, M. D., & Theis, F. J. (2019). Current best practices in single-cell RNA-seq analysis: a tutorial. *Molecular Systems Biology*, 15, e8746.
- Kobak, D., & Berens, P. (2019). The art of using t-SNE for single-cell transcriptomics. *Nature Communications*, 10, 5416.
- Chari, T., & Pachter, L. (2023). The specious art of single-cell genomics. *PLoS Computational Biology*, 19, e1011288.