

第 11 回 k-means

G と C を交互に解き、初期値を変えてやり直す

本章の問いは、第 10 回の締めで残った「行を群に分けると？」である。主成分分析は得点 $\mathbf{F}$ が連続な値をとれたので、特異値分解 1 回で解けた。一方、k-means の所属行列 $\mathbf{G}$ は、各行に 1 が 1 つだけ立つ 0/1 の行列である。この問いには、第 9 回と同じ交互最小二乗法で答える。 $\mathbf{C}$ を固定すれば、各行を最も近い代表点の群に入れるのが $\mathbf{G}$ の最良の更新になる。 $\mathbf{G}$ を固定すれば、 $\hat{\mathbf{C}} = (\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T \mathbf{X}$ 、すなわち群ごとの平均が $\mathbf{C}$ の最良の更新になる。 J は毎回下がり、有限回で止まる。ただし着く先は初期値しだいなので、初期値を変えてやり直し、 J が最も小さい答えを採る(ランダムスタート)。

第 I 部 理論

行を群に分ける

第 10 回では、主成分分析を特異値分解 1 回で解き、最後に「行を群に分けると？」という問いを残した。主成分分析 $\|\mathbf{X} - \mathbf{F}\mathbf{A}^T\|_F^2$ が 1 回で解けたのは、得点 $\mathbf{F}$ が連続な値をとれるので、上位 Q 本の特異値の分をそのまま残せばよかったからである。第 8 回で並べたもう 1 つの目的関数 $\|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2$ では、所属行列 $\mathbf{G}$ の各行に 1 が 1 つだけ立ち、残りは 0 である。本章では、この式を実際に解く。

場面として、図 1 の卸売の顧客を考える。ポルトガルの卸売業者の顧客 440 件について、生鮮・乳製品・食料品・冷凍品・洗剤と紙製品・総菜の 6 品目について、1 年間に買った金額を記録したデータである。図はそのうち食料品と生鮮の 2 品目を描いたもので、1 点がデータ行列の 1 行、すなわち 1 件の顧客である。顧客は飲食店もあれば小売店もあり、買い方は顧客ごとに違う。近い点どうしは買い方が似ているので、似た顧客を群にまとめた

い。

本章では、行を群に分けるときの、0/1 の $\mathbf{G}$ と、代表点を並べた $\mathbf{C}$ をどう求めるかを問う。博士論文抜粋の言い方では「どのような問題では反復計算が必要となるのか」という問いにあたり、k-means はその代表例である。

答えは、第 9 回と同じ交互最小二乗法である。 $\mathbf{C}$ を固定すれば、各行を最も近い代表点の群に入れることが $\mathbf{G}$ の最良の選び方になる。 $\mathbf{G}$ を固定すれば、 $\hat{\mathbf{C}} = (\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T \mathbf{X}$ 、すなわち群ごとの平均が $\mathbf{C}$ の最良の選び方になる。この 2 つを交互に繰り返すと目的関数は毎回下がり、有限回で止まる。ただし、止まる先は初期値によって変わる。そこで初期値を変えてやり直し、目的関数が最も小さい答えを採る。




図 1: 卸売業者の顧客 440 件の年間購入額(6 品目のうち食料品と生鮮の 2 品目)

代表点で近似する

2 変数の人工データで、群に分けて代表点で近似するとはどういうことかを見る。図 2 (a) は、博士論文抜粋の図 1.5 と同じ形の 100 個体・2 変数のデータと、 $k = 3$ 個の代表点(セントロイド(centroid)、代表ベクトル)である。代表点の座標は論文の値を使った。k-means クラスタリング(k-means clustering)では、各個体をどれか 1 つの群(クラスター)に入れ、その群の代表点で近似する。図 2 (b) の色は各個体を入れた群、線は個体から代表点への近似の誤差である。第 9 回の主成分分析では各点を直線の上の点で近似したが、ここでは k 個の代表点のどれかで近似する。

行列で書けば、データ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ は、所属を表す $\mathbf{G} \in \{0, 1\}^{n \times k}$ と、代表点を行に並べた $\mathbf{C} = [\mathbf{c}_1, \dots, \mathbf{c}_k]^T \in \mathbb{R}^{k \times p}$ の積で近似される(図 3)。第 1 回の「データ=モデル+誤差」の形に書けば

$$\mathbf{X} = \mathbf{GC} + \mathbf{E} \quad (1)$$

である。 $\mathbf{G}$ の第 i 行は 1 が立った列だけで $\mathbf{C}$ の 1 行を拾うので、 $\mathbf{GC}$ の第 i 行は、個体 i が入った群の代表点になる(第 8 回)。第 9 回のモデル $\mathbf{FA}^T$ と同じく、 $\mathbf{GC}$ も未知の行列どうしの積である。ただし $\mathbf{G}$ の成分は 0 か 1 に限られる。

目的関数とメンバーシップ関数

(1) 式の誤差の大きさを、スカラー・ベクトル・行列の順に書く。そのために、所属を数で表す。個体 i がクラスター q に所属するとき 1、しないとき 0 をとる




図 2: 100 個体・2 変数の人工データ(博士論文抜粋の図 1.5 と同じ形)。(a) データと $k = 3$ の代表点(■)、(b) 各個体を 1 つの群に入れ、その群の代表点で近似したもの。線が近似の誤差




図 3: k-means のモデルの型(概念図)。 $n \times p$ の $\mathbf{X}$ を、 $n \times k$ の $\mathbf{G}$ と $k \times p$ の $\mathbf{C}$ の積と誤差 $\mathbf{E}$ に分ける

$$g_{iq} = \begin{cases} 1 & \text{個体 } i \text{ がクラスター } q \text{ に所属する} \\ 0 & \text{個体 } i \text{ がクラスター } q \text{ に所属しない} \end{cases} \quad (2)$$

をメンバーシップ関数(membership function)と呼ぶ(指示関数と呼ぶこともある)。k-means では 1 つの個体が複数のクラスターに所属することは許されない、任意の i について制約

$$\sum_{q=1}^k g_{iq} = 1 \quad (3)$$

が成り立つ。第 8 回で行 i の群として書いた $q(i)$ は、 $g_{iq} = 1$ となるただ 1 つの q である。

まず1マスずつ書く。個体 i の第 j 変数 x_{ij} を、所属する群の代表点の第 j 成分 c_{qj} で近似するので、目的関数は

$$J = \sum_{i=1}^n \sum_{q=1}^k g_{iq} \sum_{j=1}^p (x_{ij} - c_{qj})^2 \quad (4)$$

である。 $g_{iq} = 0$ の項は消えるので、行 i からは所属する群 $q(i)$ の項だけが残る、第8回の $\sum_i \sum_j (x_{ij} - c_{q(i)j})^2$ と同じ値になる。内側の j についての和は、個体 i のデータベクトル $\tilde{\mathbf{x}}_i \in \mathbb{R}^p$ と代表点 $\mathbf{c}_q \in \mathbb{R}^p$ のユークリッド距離の二乗であるから

$$J = \sum_{i=1}^n \sum_{q=1}^k g_{iq} \|\tilde{\mathbf{x}}_i - \mathbf{c}_q\|_2^2 \quad (5)$$

と書ける。これが博士論文抜粋の k-means の目的関数である。 $p = 1$ なら距離の二乗は $(x_i - c_q)^2$ であり、(4) 式の内側の和は1項だけになる。

最後に行列で書く。 g_{iq} を (i, q) 成分とする $\mathbf{G} \in \{0, 1\}^{n \times k}$ をメンバーシップ行列(指示行列)と呼ぶ(定義1)。 $\mathbf{G}\mathbf{C}$ の (i, j) 成分 $\sum_q g_{iq} c_{qj}$ では、(3) 式により、1が立った q の c_{qj} だけが残る。同じ理由で $\sum_q g_{iq} (x_{ij} - c_{qj})^2 = (x_{ij} - \sum_q g_{iq} c_{qj})^2$ であるから、(4) 式は $\mathbf{X} - \mathbf{G}\mathbf{C}$ の全マスの二乗和、すなわち

$$J(\mathbf{G}, \mathbf{C}) = \|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2 \quad (6)$$

に等しい。たとえば7個体を3つのクラスターに分ける。個体1~3をクラスター1に、個体4・5をクラスター2に、個体6・7をクラスター3に入れると

$$\mathbf{G} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix} \quad (7)$$

である。制約(3) 式は、各行の和が1であることを表す。 $\mathbf{1}_k$ を k 個の1を並べたベクトルとすると

$$\mathbf{G}\mathbf{1}_k = \mathbf{1}_n \quad (8)$$

と書ける。(7) 式はこれを満たしている。

定義1 (メンバーシップ行列). 個体 i がクラスター q に所属するとき1、しないとき0をとる g_{iq} をメンバーシップ関数、 g_{iq} を並べた $n \times k$ の行列 $\mathbf{G}$ をメンバーシップ行列と呼ぶ。各個体はちょうど1つのクラスターに所属し、 $\mathbf{G}\mathbf{1}_k = \mathbf{1}_n$ を満たす。

定義 2 (k-means クラスタリング). データ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ とクラスター数 k が与えられたとき、 $\mathbf{G}\mathbf{1}_k = \mathbf{1}_n$ を満たすメンバーシップ行列 $\mathbf{G}$ とセントロイド行列 $\mathbf{C} \in \mathbb{R}^{k \times p}$ について、目的関数 (6) 式を最小にすることを k-means クラスタリングという。

交互最小二乗法

(6) 式を最小にする $\mathbf{G}$ と $\mathbf{C}$ を一度に求めることはできない。第 9 回の主成分分析と同じく、未知は 2 つの行列の積になっている。そのうえ $\mathbf{G}$ の成分は 0 か 1 に限られるので、 $\mathbf{G}$ について微分して 0 とおくことができない。 n 個の個体を k 個のクラスターに入れる入れ方は k^n 通りある。卸売の顧客 440 件を 2 つに分けるだけでも 2 の 440 乗、およそ 10 の 132 乗通りになるので、すべて試すこともできない。主成分分析では $\mathbf{F}$ が連続な値をとれたので、第 10 回で特異値分解 1 回の答えが得られた。k-means にはそのような近道が無い。

そこで、第 9 回と同じ交互最小二乗法(alternating least squares)を使う(図 4)。 $\mathbf{C}$ を固定して $\mathbf{G}$ を更新し、次に $\mathbf{G}$ を固定して $\mathbf{C}$ を更新する。どちらの更新も、固定したもののもとで目的関数を最小にするので、目的関数は更新のたびに下がるか変わらない。 $\mathbf{G}$ の更新は場合分けで、 $\mathbf{C}$ の更新は微分で求める。後者を行列のまま書くために、次節で道具をそろえる。




図 4: k-means の交互最小二乗法の概要図(概念図。博士論文抜粋の図 1.4 の 2 つの更新を $\mathbf{G}$ と $\mathbf{C}$ に置き換えたもの)

道具：群の人数と和

$\mathbf{C}$ の更新を行列のまま書くための道具を 3 つ用意する。

1 つ目は $\mathbf{G}^\top \mathbf{G}$ である。 $k \times n$ の $\mathbf{G}^\top$ と $n \times k$ の $\mathbf{G}$ の積なので、 $k \times k$ の正方行列になる。その (q, l) 成分は $\sum_i g_{iq} g_{il}$ である。(3) 式により 1 つの行には 1 が 1 つしかないので、 $q \neq l$ なら $g_{iq} g_{il}$ はどの行でも 0 になる。 $q = l$ なら $g_{iq}^2 = g_{iq}$ であるから

$$\mathbf{G}^\top \mathbf{G} = \text{diag}(n_1, \dots, n_k), \quad n_q = \sum_{i=1}^n g_{iq} \quad (9)$$

となる。 n_q はクラスター q に入った個体の数で、(7) 式の例では $\mathbf{G}^\top \mathbf{G} = \text{diag}(3, 2, 2)$ である。どのクラスターにも 1 個体以上入っていれば、 $\mathbf{G}^\top \mathbf{G}$ は対角が正の対角行列である。その逆行列は、対角を逆数にしたものになる。空のクラスターがあると対角に 0 が現れ、第 3 回で見た正則でない行列になる。

2 つ目は $\mathbf{G}^\top \mathbf{X}$ である。 $k \times p$ の行列で、 $\mathbf{C}$ と同じ大きさをもつ。その (q, j) 成分は

$$(\mathbf{G}^\top \mathbf{X})_{qj} = \sum_{i=1}^n g_{iq} x_{ij} \quad (10)$$

で、クラスター q に入った個体の第 j 変数を足したものである。 $\mathbf{G}^\top \mathbf{X}$ の第 q 行は、クラスター q に入った行 $\tilde{\mathbf{x}}_i^\top$ の和になる。

3 つ目はトレースの偏微分である。第 9 回で、行列 $\mathbf{B}$ について $\partial \text{tr}(\mathbf{B}^\top \mathbf{M}) / \partial \mathbf{B} = \mathbf{M}$ を用意した。もう 1 つ、対称な行列 $\mathbf{S}$ を挟んだ二次の形について

$$\frac{\partial \text{tr}(\mathbf{B}^\top \mathbf{S} \mathbf{B})}{\partial \mathbf{B}} = 2\mathbf{S} \mathbf{B} \quad (11)$$

を使う。 $\text{tr}(\mathbf{B}^\top \mathbf{S} \mathbf{B}) = \sum_j \sum_q \sum_l s_{ql} b_{qj} b_{lj}$ を b_{qj} で偏微分すると、 $\mathbf{S}$ が対称なので $\sum_l s_{ql} b_{lj} + \sum_l s_{lq} b_{lj} = 2(\mathbf{S} \mathbf{B})_{qj}$ となる。これを $\mathbf{B}$ と同じ形に並べたものが (11) 式である。 1×1 なら $d(sb^2)/db = 2sb$ であり、 $\mathbf{S} = \mathbf{I}$ なら第 9 回の $\partial \text{tr}(\mathbf{B}^\top \mathbf{B}) / \partial \mathbf{B} = 2\mathbf{B}$ に戻る。

G の更新

まず $\mathbf{C}$ を固定して $\mathbf{G}$ を更新する。博士論文抜粋にならい、1 つの個体に注目する。図 5 には、図 2 と同じデータの個体 50 と、3 つの代表点を描いた。個体 50 のデータベクトルは $\tilde{\mathbf{x}}_{50} = (-2.03, -0.52)^\top$ である。代表点との距離の二乗は

$$\begin{aligned} \|\tilde{\mathbf{x}}_{50} - \mathbf{c}_1\|_2^2 &= (-2.03 - 3.11)^2 + (-0.52 - (-1.24))^2 \\ \|\tilde{\mathbf{x}}_{50} - \mathbf{c}_2\|_2^2 &= (-2.03 - 0.08)^2 + (-0.52 - 1.76)^2 \\ \|\tilde{\mathbf{x}}_{50} - \mathbf{c}_3\|_2^2 &= (-2.03 - (-1.67))^2 + (-0.52 - (-2.35))^2 \end{aligned} \quad (12)$$

で、値はそれぞれ 26.94、9.65、3.48 となる。

(5) 式のうち個体 50 の項は $\sum_q g_{50,q} \|\tilde{\mathbf{x}}_{50} - \mathbf{c}_q\|_2^2$ である。制約 (3) 式のもとで選べるのは、3 つの $g_{50,q}$ のどれを 1 にするかだけである。1 にした列の距離の二乗だけが残り、残りの距離は無視される。そこで、距離の二乗が最も小さいクラスター 3 を選んで $g_{50,3} = 1$ 、 $g_{50,1} = g_{50,2} = 0$ とすればよい。すると




図 5: 個体 50 (橙) と 3 つの代表点 (博士論文抜粋の図 1.6 と同じ座標)。数字は距離の二乗

$$\sum_{q=1}^3 g_{50,q} \|\tilde{\mathbf{x}}_{50} - \mathbf{c}_q\|_2^2 = \|\tilde{\mathbf{x}}_{50} - \mathbf{c}_3\|_2^2$$

となる。 g_{iq} は 0 か 1 しかとらないので、微分して 0 とおく方法は使えない。このように場合分けで求めるしかない。

同じことはすべての個体について言える。 $d_{iq} = \|\tilde{\mathbf{x}}_i - \mathbf{c}_q\|_2^2$ とおくと、 $\mathbf{C}$ を固定したときの目的関数は $J = \sum_i (\sum_q g_{iq} d_{iq})$ となる。括弧の中は、行 i の $g_{i1}, \dots, g_{ik}$ だけを含む。行ごとに別々に最小にすればよいので、 $\mathbf{G}$ の更新式は

$$\hat{g}_{iq} = \begin{cases} 1 & (q = \operatorname{argmin}_{1 \leq l \leq k} \|\tilde{\mathbf{x}}_i - \mathbf{c}_l\|_2^2) \\ 0 & (\text{それ以外}) \end{cases} \quad (13)$$

となる。つまり、各個体を最も近い代表点のクラスターに入れる。図 2 (b) の色は、論文の代表点のもとでこの更新を 100 個体すべてに行った結果である。

計算の手順として行列で書くために、距離の二乗を $d_{iq} = \|\tilde{\mathbf{x}}_i\|_2^2 - 2\tilde{\mathbf{x}}_i^\top \mathbf{c}_q + \|\mathbf{c}_q\|_2^2$ と展開する。 $a_i = \|\tilde{\mathbf{x}}_i\|_2^2$ 、 $b_q = \|\mathbf{c}_q\|_2^2$ を並べたベクトルを $\mathbf{a} \in \mathbb{R}^n$ 、 $\mathbf{b} \in \mathbb{R}^k$ とすれば、 d_{iq} を並べた $n \times k$ の行列は

$$\mathbf{D} = \mathbf{a} \mathbf{1}_k^\top - 2\mathbf{X}\mathbf{C}^\top + \mathbf{1}_n \mathbf{b}^\top \quad (14)$$

である。(13) 式は、 $\mathbf{D}$ の各行で最も小さい列に 1 を置き、残りを 0 とすることにあたる。第 1 項は行の中で一定なので、どの列が最小かは $-2\mathbf{X}\mathbf{C}^\top + \mathbf{1}_n \mathbf{b}^\top$ だけで決まる。主な計算は、 $n \times p$ と $p \times k$ の行列の積 $\mathbf{X}\mathbf{C}^\top$ である。

C の更新

次に $\mathbf{G}$ を固定して $\mathbf{C}$ を更新する。スカラーから始める。変数が 1 つ ($p = 1$) なら、(4) 式のうちクラスター q の代表点 c_q を含むのは $\sum_i g_{iq}(x_i - c_q)^2$ だけで、これは c_q の放物線である。1 変数の微分を 0 とおくと

$$\frac{d}{dc_q} \sum_{i=1}^n g_{iq}(x_i - c_q)^2 = -2 \sum_{i=1}^n g_{iq}(x_i - c_q) = 0 \implies \hat{c}_q = \frac{\sum_i g_{iq} x_i}{\sum_i g_{iq}} \quad (15)$$

を得る。分母はクラスター q の個体の数、分子はその和であるから、 $\hat{c}_q$ はクラスター q の平均である。

変数が p 個なら、(5) 式の $\mathbf{c}_q$ を含む項 $\sum_i g_{iq} \|\tilde{\mathbf{x}}_i - \mathbf{c}_q\|_2^2$ をベクトル $\mathbf{c}_q$ で偏微分し、勾配を 0 とおく。

$$\begin{aligned} \frac{\partial}{\partial \mathbf{c}_q} \sum_{i=1}^n g_{iq} \|\tilde{\mathbf{x}}_i - \mathbf{c}_q\|_2^2 &= \frac{\partial}{\partial \mathbf{c}_q} \sum_{i=1}^n g_{iq} (\tilde{\mathbf{x}}_i^\top \tilde{\mathbf{x}}_i - 2\tilde{\mathbf{x}}_i^\top \mathbf{c}_q + \mathbf{c}_q^\top \mathbf{c}_q) \\ &= \sum_{i=1}^n g_{iq} (-2\tilde{\mathbf{x}}_i + 2\mathbf{c}_q) = -2 \left(\sum_{i=1}^n g_{iq} \tilde{\mathbf{x}}_i \right) + 2\mathbf{c}_q \left(\sum_{i=1}^n g_{iq} \right) = \mathbf{0}_p \end{aligned} \quad (16)$$

したがって $\mathbf{c}_q$ の更新式は

$$\hat{\mathbf{c}}_q = \frac{\sum_{i=1}^n g_{iq} \tilde{\mathbf{x}}_i}{\sum_{i=1}^n g_{iq}} \quad (17)$$

である。これはクラスター q に入った個体のデータベクトルの平均で、 $p = 1$ なら (15) 式に戻る。

同じ更新を行列のまま導く。第 9 回の二乗和のトレースによる表現を使うと

$$J(\mathbf{C} | \mathbf{G}) = \text{tr}((\mathbf{X} - \mathbf{G}\mathbf{C})^\top (\mathbf{X} - \mathbf{G}\mathbf{C})) = \text{tr}(\mathbf{X}^\top \mathbf{X}) - 2\text{tr}(\mathbf{C}^\top \mathbf{G}^\top \mathbf{X}) + \text{tr}(\mathbf{C}^\top \mathbf{G}^\top \mathbf{G}\mathbf{C}) \quad (18)$$

と展開できる。交差項は $\text{tr}(\mathbf{X}^\top \mathbf{G}\mathbf{C}) = \text{tr}(\mathbf{C}^\top \mathbf{G}^\top \mathbf{X})$ (転置) で 1 つにまとめた。第 2 項に第 9 回の $\partial \text{tr}(\mathbf{B}^\top \mathbf{M}) / \partial \mathbf{B} = \mathbf{M}$ を、第 3 項に (11) 式を $\mathbf{S} = \mathbf{G}^\top \mathbf{G}$ として使うと

$$\frac{\partial J}{\partial \mathbf{C}} = -2\mathbf{G}^\top \mathbf{X} + 2\mathbf{G}^\top \mathbf{G}\mathbf{C} = \mathbf{0} \implies \mathbf{G}^\top \mathbf{G}\mathbf{C} = \mathbf{G}^\top \mathbf{X} \quad (19)$$

を得る。これは第 1 回の正規方程式 $\mathbf{X}^\top \mathbf{X}\boldsymbol{\beta} = \mathbf{X}^\top \mathbf{y}$ の $\mathbf{X}$ を $\mathbf{G}$ に、 $\mathbf{y}$ を $\mathbf{X}$ に替えた形である。 $\mathbf{G}$ を固定すると、(1) 式は所属の 0/1 の列を説明変数にして $\mathbf{X}$ の各列を回帰するモデルになり、 $\mathbf{C}$ はその係数にあたる。どのクラスターにも個体が入っていれば $\mathbf{G}^\top \mathbf{G}$ は正則なので

$$\hat{\mathbf{C}} = (\mathbf{G}^\top \mathbf{G})^{-1} \mathbf{G}^\top \mathbf{X} = \text{diag}\left(\frac{1}{n_1}, \dots, \frac{1}{n_k}\right) \mathbf{G}^\top \mathbf{X} \quad (20)$$

となる。2つ目の等号は(9)式による。(10)式により、第 q 行はクラスター q の行の和を n_q で割ったものになり、(17)式の $\hat{\mathbf{c}}_q^\top$ と一致する。行列で書いても、クラスターごとの平均を縦に積んだだけである。図6は、図2(b)の群を固定して $\mathbf{C}$ を1回更新したところで、代表点はそれぞれの群の平均へ動いた。




図6: 図2(b)の群を固定して $\mathbf{C}$ を1回更新したもの(人工データ)。白丸が更新の前の代表点、■が群の平均

計算の手順

2つの更新を、実際に計算する行列の形で手順にまとめる。

1. 列の目盛りをそろえたデータ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ と、クラスター数 k を用意する
2. 初期値を置く。 $\mathbf{C}$ は観測されていないが既知として与える必要があるので、 $\mathbf{X}$ の行から k 行を乱数で選んで $\mathbf{C} \in \mathbb{R}^{k \times p}$ とする
3. $\mathbf{C}$ を固定して、(14)式の $\mathbf{D}$ を作り、(13)式により各行で最小の列に1、残りに0を置いて $\mathbf{G}$ とする
4. $\mathbf{G}$ を固定して、(20)式により $\mathbf{C} \leftarrow (\mathbf{G}^\top \mathbf{G})^{-1} \mathbf{G}^\top \mathbf{X}$ とする
5. $\mathbf{G}$ が前回と同じなら止める。そうでなければ3に戻る
6. 2~5を R 通りの初期値で行い、 $J = \|\mathbf{X} - \mathbf{GC}\|_F^2$ が最も小さい答えを採用

1回の反復で行うのは、行列の積 $\mathbf{XC}^\top$ と $\mathbf{G}^\top \mathbf{X}$ 、各行の最小の列を探すこと、そして対角行列 $\mathbf{G}^\top \mathbf{G}$ の逆数である。第9回の手順と比べると、特異値分解が場合分けに、 $\hat{\mathbf{F}} = \mathbf{XA}$ が群ごとの平均に替わっている。手順6は第9回には無かった段である。なぜ要るか、手順1で目盛りをそろえるのはなぜかを、次節で見る。

理論の帰結

交互最小二乗法の 2 つの更新から、いくつかのことが言える。

第 1 に、目的関数は更新のたびに下がるか変わらない。 $\mathbf{G}$ の更新 (13) 式は $\mathbf{C}$ を固定したもとの最良の $\mathbf{G}$ で、 $\mathbf{C}$ の更新 (20) 式は $\mathbf{G}$ を固定したもとの最良の $\mathbf{C}$ である。どちらも、更新する前の値を候補に含む中から最良を選ぶので、 J を上げることはない。図 7 に、図 2 の 100 個体で、論文の 3 つの代表点を初期値として手順を回したときの J の推移を示す。 J は 689.1 から始まり、更新のたびに下がって 603.2 で止まった。




図 7: 100 個体の人工データで、博士論文抜粋の代表点を初期値にしたときの目的関数 J の推移。丸は $\mathbf{G}$ の更新の後、四角は $\mathbf{C}$ の更新の後

第 2 に、手順は有限回で止まる。 $\mathbf{G}$ のとりうる値は高々 k^n 通りの有限個である。 J が真に下がり続ける限り同じ $\mathbf{G}$ に戻ることはない。そのため、いつかは $\mathbf{G}$ が変わらなくなり、そこで $\mathbf{C}$ も変わらなくなる。この例では 4 回の反復で止まった。図 8 (a) の黒い線は、代表点が初期値(白丸)から動いた道筋である。

第 3 に、止まった先が最良とは限らない。止まった点は、 $\mathbf{C}$ を固定しても $\mathbf{G}$ を固定しても、それ以上 J を下げられない点にすぎない。図 8 (b) は、同じデータで、 $\mathbf{X}$ の行から 3 行を選んだ別の初期値から始めた答えである。その $J = 468.6$ は、(a) の 603.2 より小さい。(a) の答えは、そこから 2 つの更新のどちらを行っても動かないが、目的関数を最小にしてはいない。このような点を局所解と呼ぶ(定義 3)。k-means では、得られた解が真の解であるという保証は無い。これは目的関数の非凸性と関係している(Jain & Kar, 2017)。2 つの答えを比べるときは、群の番号の付け替え(第 8 回)を除いて、所属が違う個体を数える。(a) と (b) では、番号をそろえても 34 個の所属が違う。

そこで実際には、複数の初期値から解を求め、その中で目的関数が最も小さいものを採用する。これをランダムスタートと呼ぶ(定義 4)。図 9 は、 $\mathbf{X}$ の行から 3 行を選ぶ初期値を 300 通り試し、着いた J を並べたものである。着いた先の J は 10 通りに分かれ、最小の 468.6 に着いたのは 191 回であった。




図 8: 同じ 100 個体を $k = 3$ に分けた 2 つの答え(人工データ)。(a) 博士論文抜粋の代表点を初期値にしたもの(黒い線は代表点の道筋、白丸は初期値)、(b) 別の初期値から着いたもの




図 9: 100 個体の人工データ、 $k = 3$ 。初期値を変えて着いた J の分布。緑の線が最小、赤の破線が博士論文抜粋の代表点から着いた値

何回やり直せばよいかは、次のように考える。1 回の初期値で最小に着く割合を θ とし、初期値を独立に R 回選ぶ。 R 回とも最小に着かない見込みは $(1 - \theta)^R$ なので、少なくとも 1 回は着く見込みは

$$1 - (1 - \theta)^R \quad (21)$$

である。この例では $\theta = 0.64$ で、 $R = 3$ なら 95.2%、 $R = 5$ なら 99.4% になる。どの 1 回も最小に着くとは限らないが、やり直すほど見込みは 1 に近づく。ただし、最小に着いたことを確かめる手立ては無く、試した中で最小であることしか言えない。 θ もデータと k によって変わり、前もっては分からない。

第 4 に、2 つのクラスターの境目は直線になる。(13) 式で個体 $\tilde{\mathbf{x}}$ がクラスター 1 とクラスター 2 のどちらに入るかの境目は、 $\|\tilde{\mathbf{x}} - \mathbf{c}_1\|_2^2 = \|\tilde{\mathbf{x}} - \mathbf{c}_2\|_2^2$ である。これを展開すると、 $\|\tilde{\mathbf{x}}\|_2^2$ が両辺で消えて

$$2(\mathbf{c}_2 - \mathbf{c}_1)^\top \tilde{\mathbf{x}} = \|\mathbf{c}_2\|_2^2 - \|\mathbf{c}_1\|_2^2 \quad (22)$$

となる。 $\tilde{\mathbf{x}}$ について 1 次の式なので、境目は直線(p 変数なら超平面)になる。この直線は、2 つの代表点を結ぶ線分の垂直二等分線である。図 10 のように、平面は代表点ごとの凸な領域に切り分けられる。そして $\mathbf{G}$ は 0 か 1 なので、境目のすぐそばの個体も、どちらか一方の群に完全に入る。




図 10: 図 8 (b) の答えで、平面の各点を最も近い代表点の群に塗り分けたもの(人工データ)。灰色の線が境目

第 5 に、答えは列の目盛りで変わる。(4) 式の和の順を入れ替えると

$$J = \sum_{j=1}^p \sum_{i=1}^n (x_{ij} - c_{q(i)j})^2 \quad (23)$$

であり、 J は列ごとの誤差の二乗和を足したものである。どの列も同じ重みで足されるので、列 j を a 倍すると、その列の誤差は a^2 倍に数えられる。図 11 (b) は、図 2 と同じ 100 個体の変数 2 だけを 5 倍にして分け、元の見盛りの上に描いたものである。(a) とは違い、変数 2 の向きに 3 つの帯に切る答えになった。元の見盛りで測った J は 891.6 で、(a) の 468.6 より大きい。手順 1 で列の見盛りをそろえるのはこのためで、第 2 回の標準化はその 1 つの方法である。




図 11: 同じ 100 個体の人工データを $k = 3$ に分けた 2 つの答え。(a) そのままの見盛りで分けたもの、(b) 変数 2 を 5 倍にして分け、元の見盛りの上に描いたもの。灰色の線が境目

見盛りのそろえ方は、何を「近い」とみなすかで選ぶ。差ではなく何倍かで比べたいときは、列を対数にしてから使う。 $\log a - \log b = \log(a/b)$ なので、対数の差は比だけで決まる。たとえばコーヒー豆の 100g と 200g、1kg と 2kg は、差は 100g と 1kg で違うが、どちらも 2 倍であり、対数の差はどちらも $\log 2$ になる。

表 1 に、第 9・10 回の主成分分析と k-means を並べた。どちらも最小二乗法で、片方ずつ解けば目的関数は毎回下がる。違いは $\mathbf{F}$ が連続な値をとれるのに対し、 $\mathbf{G}$ が 0/1 に限られることにある。主成分分析はどの初期値からでも同じ J に着き、特異値分解 1 回でも解けた。一方、k-means は着く先が初期値しだいで、1 回で解く方法も無い。k-means は、反復計算とランダムスタートが要る問題の代表例である。なお、主成分分析で軸を回す $\mathbf{R}$ が決まらなかったように、k-means でも群の番号の付け替えは決まらない(第 8 回)。これは局所解とは別の話で、番号を付け替えても J は変わらない。

表 1: 主成分分析と k-means の解き方の比較

	主成分分析(第 9・10 回)	k-means (本章)
近似	$\mathbf{F}\mathbf{A}^\top$ ($\mathbf{F}$ は連続)	$\mathbf{G}\mathbf{C}$ ($\mathbf{G}$ は 0/1)
片方を固定した更新	$\hat{\mathbf{F}} = \mathbf{X}\mathbf{A}$, $\hat{\mathbf{A}} = \mathbf{K}\mathbf{L}^\top$	最も近い代表点、 $\hat{\mathbf{C}} = (\mathbf{G}^\top \mathbf{G})^{-1} \mathbf{G}^\top \mathbf{X}$

	主成分分析(第 9・10 回)	k-means (本章)
J	毎回下がる	毎回下がり、有限回で止まる
着く先	どの初期値でも同じ J	初期値しだい(局所解)
1 回で解けるか	特異値分解 1 回(第 10 回)	解けない。ランダムスタート
決まらないもの	軸の回転 $\mathbf{R}$	群の番号の付け替え(第 8 回)

定義 3 (局所解). 交互最小二乗法が止まった点のように、そこから更新しても目的関数が下がらないが、目的関数を最小にするとは限らない点を局所解と呼ぶ。

定義 4 (ランダムスタート). 複数の初期値から交互最小二乗法を行い、得られた答えのうち目的関数が最も小さいものを採用することを、ランダムスタートと呼ぶ。

地図の中の k-means

表 2 に、第 8 回で並べた 3 つの目的関数と解き方をまとめた。推定法はどれも最小二乗法である。線形回帰は正規方程式を 1 回解けば済み、主成分分析は交互最小二乗法でも特異値分解 1 回でも解けた。k-means は交互最小二乗法で解き、初期値を変えてやり直す必要がある。

表 2: 3 つの目的関数と解き方

モデル	近似する相手	目的関数	解き方	回
線形回帰	y	$\ \mathbf{y} - \mathbf{X}\boldsymbol{\beta}\ _2^2$	正規方程式を 1 回解く	第 1 回
主成分分析	$\mathbf{X}$	$\ \mathbf{X} - \mathbf{F}\mathbf{A}^\top\ _F^2$	交互に解く／ 特異値分解を 1 回	第 9・10 回
k-means	$\mathbf{X}$	$\ \mathbf{X} - \mathbf{G}\mathbf{C}\ _F^2$	交互に解く	第 11 回

第 II 部 実データ解析

卸売の顧客と手続き

第 II 部では、卸売の顧客のデータで第 I 部の手順を実際に回す。データは UCI Machine Learning Repository の Wholesale customers (Cardoso, 2014, CC BY 4.0) である。ポルトガルの卸売業者の顧客 440 件について、生鮮・乳製品・食料品・冷凍品・洗剤と紙製品・総菜 の 6 品目の年間購入額(通貨の単位)を記録している。顧客の業態(飲食店 298 件、小売 142 件)も記録されているが、 $\mathbf{G}$ と $\mathbf{C}$ を求めるのには使わず、群を読むときの突き合わせにだけ使う。

購入額は右に裾が長い。表 3 のとおり、どの品目でも最大の客は中央値の数十倍を買っており、品目によって金額の桁も違う。k-means の目的関数は (23) 式のとおり列ごとの誤差の二乗和を足すので、そのまま使えば、大口の客と金額の大きい品目が J を左右する。そこで、6 列をそれぞれ対数にしてから標準化したものをデータ行列 $\mathbf{X}$ とした(図 12)。対数にすると、購入額の差は「何倍か」で測られ、大口の客も中央値から数倍の位置に収まる。標準化すると、品目ごとの散らばりがそろう(第 2 回)。この 2 つの判断が妥当だったかは、落とし穴の節で、しなかった場合と比べて確かめる。

表 3: 卸売の顧客 440 件の年間購入額

品目	生鮮	乳製品	食料品	冷凍品	洗剤と紙製品	総菜
中央値	8,504	3,627	4,756	1,526	816	966
最大	112,151	73,498	92,780	60,869	40,827	47,943
最大 ÷ 中央値	13	20	20	40	50	50




図 12: 卸売の顧客 440 件の生鮮の年間購入額。(a) そのまま、(b) 対数にして標準化したもの

手続きは次のとおりである。I-6 の手順を NumPy の行列計算でそのまま書き、 $k = 2$ とした。 $\mathbf{X}$ の行から 2 行を乱数で選ぶ初期値を 3 通り用意し、それぞれから回した。同じ初期値を scikit-learn の KMeans (Lloyd の方法) に渡して回し、 J と所属を比べた。次に、ランダムスタートの効果を見るために、 $k = 2$ と $k = 3$ について初期値を 100 通りずつ試した。得られた群は、元の購入額の中央値と業態で読んだ。最後に、対数も標準化もしない $\mathbf{X}$ と、標準化だけした $\mathbf{X}$ でも手順を回した。

図 13 は、3 つの初期値からの J の推移である。どの初期値でも、 J は $\mathbf{G}$ と $\mathbf{C}$ のどちらの更新でも一度も上がらず、8~17 回の反復で止まった。着いた J は 1,848.00~1,848.05 で、初期値によってわずかに違う。

表 4 に、自分で書いた手順の答えを確かめた結果をまとめた。同じ初期値から回したライブラリの答えと比べると、3 通りのどれでも J の差は最大 0、所属が違う行は 0 件で、同じ答えに着いた。 $\mathbf{G}^\top \mathbf{G}$ の対角は 2 つの群の件数 189 と 251 である。(20) 式の $(\mathbf{G}^\top \mathbf{G})^{-1} \mathbf{G}^\top \mathbf{X}$ と、群ごとに行を平均したものとの差は、最大 0 であった。止まった代表点のもとで、最も近い代表点の群に入っていない行は 0 件で、(13) 式も満たしている。手順は、どちらの更新をしても動かない点で止まった。




図 13: 卸売の顧客(6 品目を対数にして標準化、 $k = 2$)で、3 通りの初期値から回した交互最小二乗法の J の推移


表 4: 卸売の顧客($k = 2$)で止まった答えの確認

確かめたこと	値
J が一度も上がらなかったか(3 通り)	はい
同じ初期値のライブラリとの J の差(最大)	0
同じ初期値のライブラリと所属が違う行(最大)	0 件
$(\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T \mathbf{X}$ と群ごとの平均の差(最大)	0
最も近い代表点の群に入っていない行	0 件

初期値と谷

$k = 2$ では初期値を 100 通り変えても、着いた J は 1,847.98 から 1,848.09 までの 4 通りで、差はごくわずかであった。最小と最大の答えで所属が違う行は、番号をそろえて数えると 3 件にすぎない。大きな分かれ目が 1 本あり、どこから始めても、答えはその近くに落ち着く。

群の数を $k = 3$ にすると様子が変わる。図 14 は、同じ 100 通りの初期値から着いた J の分布である。着いた先は 29 通りに分かれ、最小の 1,558.0 に着いたのは 3% であった。最小から 1% 以内の J に着いたのは 50% である。最小のすぐそばに、数件の所属だけが違う谷がいくつも並んでいる。最も悪い答えの J は 1,699.6 である。






図 15: 卸売の顧客を $k = 3$ に分けた 2 つの答え。(a) 100 通りのうち J が最小、(b) J が最大。群の番号は食料品の購入額の中央値が大きい順

では何回やり直せばよいか。第 I 部の (21) 式に、1 回の初期値で最小の谷に着く割合 $\theta = 0.03$ を入れる。表 5 のとおり $R = 10$ では 26.3% にとどまり、 $R = 100$ で 95.2% になる。100 個体の人工データより θ がずっと小さく、100 回近くやり直す必要がある。

表 5: 初期値の数と、最小の谷に少なくとも 1 回着く見込み(卸売の顧客、 $k = 3$)

初期値の数 R	1	10	50	100
最小の谷に 1 回は着く見込み	3.0%	26.3%	78.2%	95.2%

2 群を購入額で読む

$k = 2$ で J が最小の答えを、元の購入額に戻して読む。表 6 に、群ごとの 6 品目の購入額の中央値と、群に入った顧客のうち小売の割合を示す。群 1 (188 件) は乳製品・食料品・洗剤と紙製品を多く買い、群 2 (252 件) は生鮮と冷凍品を多く買う。業態は **G** と **C** を求めるのに使っていない。それでも群 1 の 71% は小売、群 2 の 97% は飲食店であった。第 8 回で品種と突き合わせたのと同じく、番号の付け替えの良いほうで数えると、2 群と業態が重なる割合は 85.9% である。全員を多いほうの業態とみなしたときの 67.7% より高い。買い方だけで分けた群は、店を開く側の業態とおおむね一致した。ただし、k-means は与えた k 個の群を必ず作るので、群があること自体は手順からは言えない。群が業態と重なったのは、データの側にそういう分かれ目があったからである。

表 6: 卸売の顧客を $k = 2$ に分けた答えの、群ごとの購入額の中央値と小売の割合

群	件数	生鮮	乳製品	食料品	冷凍品	洗剤と紙 製品	総菜	小売の割 合
群 1	188	5,406	7,690	11,527	1,062	4,495	1,388	71%
群 2	252	10,348	1,871	2,406	2,225	328	750	3%

目盛りを変える

第 I 部の手順 1 で、列の目盛りをそろえたデータ行列を用意した。そろえないとどうなるかを、2 通りに確かめる。

まず、対数も標準化もせず、平均を引いただけの購入額を $k = 2$ に分けた。(23) 式のとおり、目的関数はすべての列の誤差を同じ重みで足す。そのため、金額の大きい列ほど誤差も大きく数えられる。表 7 のとおり、この $\mathbf{X}$ では $\|\mathbf{X}\|_F^2$ の 44.6% を生鮮の 1 列が占め、総菜の列は 2.2% にすぎない(対数にして標準化すれば、どの列も 16.7%)。止まった答えでも、 J の 59.8% を生鮮と食料品の 2 列が占めた。群は 375 件と 65 件に分かれた。業態と重なる割合は 59.3% で、全員を飲食店とみなしたときの 67.7% にも届かない。この答えは、買い方ではなく、金額の大きい 2 品目をどれだけ買うかで顧客を分けている。第 I 部の図 11 で変数 2 を 5 倍にしたときと同じことが起きた。

表 7: 対数にして標準化するかどうかで変わる J の内訳(卸売の顧客、 $k = 2$)

$k = 2$ の答え	対数にして標準化	平均を引いただけ
$\ \mathbf{X}\ _F^2$ のうち生鮮の列の割合	16.7%	44.6%
$\ \mathbf{X}\ _F^2$ のうち総菜の列の割合	16.7%	2.2%
J のうち生鮮・食料品の 2 列の割合	33.0%	59.8%
群の件数	252・188	375・65
業態と重なる割合	85.9%	59.3%

次に、対数をとらず標準化だけした $\mathbf{X}$ を使った。列ごとの散らばりはそろうが、右に長い裾はそのまま残る。表 8 には、 k を 3 から 5 まで変え、初期値 50 通りで J が最小の答えについて、最も小さい群の件数を示した。標準化だけの $\mathbf{X}$ では、 $k = 3$ ですでに数件だけの群ができ、 $k = 5$ では 1 件だけの群ができた。その 1 件は、総菜の購入額が平均から標準偏差の 16.5 倍離れた大口の客である。距離の二乗で測ると、この客を誰と組ませても J が大きく増える。そのため、この客に専用の代表点を 1 つ置くと J が最も下がる。対数にして標準化した $\mathbf{X}$ では、最も小さい群でも数十件あった。なお、対数をとると小さい側の外れ(ある品目を年にわずかしきか買わない客)が広がるが、この範囲の k では 1 件だけの群はできなかった。

表 8: 標準化だけの $\mathbf{X}$ と、対数にして標準化した $\mathbf{X}$ で、最も小さい群の件数(卸売の顧客、初期値 50 通りで J が最小の答え)

最も小さい群の件数	対数にして標準化	標準化だけ
$k = 3$	81	2
$k = 4$	61	4
$k = 5$	54	1

どちらの失敗も、手順の中からは見えない。交互最小二乗法は、与えられた $\mathbf{X}$ に対して J を下げるだけで、 J は毎回下がって止まる。どの列の誤差をどれだけ重く見るか、大口の客をどれだけ遠くに置くかは、 $\mathbf{X}$ を用意する側が決めている。

締め

まとめと次回の問い

本章の問いは、行を群に分けるときの、0/1 の所属行列 $\mathbf{G}$ と代表点の行列 $\mathbf{C}$ をどう求めるか、であった。k-means は、メンバーシップ関数 g_{iq} を並べた $\mathbf{G}$ と $\mathbf{C}$ の積でデータ行列を近似し、 $\|\mathbf{X} - \mathbf{GC}\|_F^2$ を最小にする最小二乗法である。 $\mathbf{G}$ は 0/1 に限られるので微分できず、一度には解けない。しかし片方を固定すれば解ける。 $\mathbf{C}$ を固定すれば、場合分けにより、各個体を最も近い代表点のクラスターに入れるのが最良になる。 $\mathbf{G}$ を固定すれば、第 1 回の正規方程式と同じ形から $\hat{\mathbf{C}} = (\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T \mathbf{X}$ 、すなわちクラスターごとの平均が得られる。この 2 つを交互に繰り返すと、目的関数は毎回下がり、有限回で止まる。ただし、止まる先は初期値しだいの局所解である。主成分分析と違って 1 回で解く方法も無いので、初期値を変えてやり直し、目的関数が最も小さい答えを採用。また、目的関数は列ごとの誤差の和なので、答えは列の目盛りで変わる。卸売の顧客 440 件の 6 品目の購入額を対数にして標準化したデータでは、自分で書いた手順が、同じ初期値のライブラリと同じ J ・同じ所属に着いた。 $k = 2$ の群は、業態と 85.9% 重なった。 $k = 3$ では初期値 100 通りが 29 通りの答えに分かれ、最小に着いたのは 3% であった。また、購入額をそのまま使うと、金額の大きい 2 品目で分ける答えになった。標準化だけでは、大口の客 1 件だけの群ができた。

同じ学期の演習 13 では、142 か国を K-means で分ける。「中心を K 個置く、各国をいちばん近い中心のグループに入れる、中心をグループの平均の位置に動かす、動かなくなるまで繰り返す」という 4 つの手順は、本章の I-6 の手順そのものである。その繰り返しで慣性(各国から自分の中心までの距離の二乗の合計)が下がり続けるのは、本章の J の単調減少にあたる。GDP をそのまま使うと分け目が GDP だけで決まるのも、落とし穴で見た生鮮の列と同じ現象である。演習で GDP を対数にしてから標準化するのは、本章で購入額に行ったのと同じ手当てである。

最後に、次回への問いを置く。k-means の $\mathbf{G}$ は 0 か 1 なので、境目のすぐそばの個体も、どちらか一方の群に 100% 入る。境目は代表点どうしの垂直二等分線であり、k-means は群の形や広がりを見ていない。前半では、第 1 回の最小二乗法の答えを、第 6 回で確率のモデルを置いた最尤法から読み直した。群に分ける問題でも同じ道をたどれるだろうか。同じ群を最尤法で推定するとどうなるかを、次回に考える。