第 11 回 主成分分析②

軸を読み、誤差を列ごとに分ける：負荷量・標準化・因子分析

本章の問いは、第 10 回の締めで残った「残した軸は何を表し、どう読めばよいか」である。まず第 10 回の目的関数を読み直し、誤差を小さくすることが得点の分散を大きくすることと同じだと確かめる。分散共分散行列の固有値分解が出てきて、固有値は軸ごとの得点の分散になる。軸の意味は負荷量とバイプロットで読む。単位のまちまちな列は標準化し、相関行列の主成分分析として解く。主成分分析は、誤差がどの列も同じ大きさだとみなしている。誤差の大きさを列ごとに変えてよいとしたモデルが因子分析である。因子分析を最尤法で解き、誤差がどの列も同じ大きさなら答えの向きが主成分分析と一致することを示す。最尤法の答えは単位によらず、因子の数は第 9 回の BIC で比べられる。回転の自由を使って、読みやすい向きを選ぶ。

第 I 部　理論

答えをどう読むか

第 10 回では、主成分分析の目的関数 $\|\mathbf{X} - \mathbf{F}\mathbf{A}^\top\|_F^2$（ただし $\mathbf{A}^\top\mathbf{A} = \mathbf{I}_Q$）を、データ行列 $\mathbf{X} = \mathbf{K}\boldsymbol{\Delta}\mathbf{L}^\top$ の特異値分解 1 回で解いた。答えは $\hat{\mathbf{F}} = \mathbf{K}_1\boldsymbol{\Delta}_1$、$\hat{\mathbf{A}} = \mathbf{L}_1$ であった。本章では、この答えをどう読むかを考える。

例として、米国の朝食シリアル 65 銘柄の、1 カップあたりの栄養成分 8 列を使う（表 1）。8 列を標準化して第 10 回の手順で $Q = 2$ の軸を求めると、図 1 (a) の $\mathbf{A}$ が得られる。ここで 3 つの困りごとがある。1 つ目は、この 16 個の数から軸 1・軸 2 が何を表すかをどう読むかである。2 つ目は単位である。標準化せずに解くと、軸 1 はほぼカリウムとナトリウムだけで決まる（図 1 (b)）。この 2 列だけが mg の単位で、数が桁違いに大きいからである。3 つ目は、列だけの揺れである。2 本の軸で近似すると、ナトリウムは分散の 48% が近似しきれずに残る（図 1 (c)）。軸が足りないのか、ナトリウムにはほかの列と共有しない揺れがあるのか、主成分分析の答えからは区別できない。

表 1: 米国の朝食シリアルの栄養成分（1 カップあたり、65 銘柄のうち 4 銘柄）

銘柄	カロリー	たんぱく質	脂質	ナトリウム	食物繊維	炭水化物	糖分	カリウム
100% Bran	212	12	3	394	30	15	18	848

銘柄	カロリー	たんぱく質	脂質	ナトリウム	食物繊維	炭水化物	糖分	カリウム
Apple Cinnamon Cheerios	147	3	3	240	2	14	13	93
Double Chex	133	3	0	253	1	24	7	107
Multi-Grain Cheerios	100	2	1	220	2	15	6	90

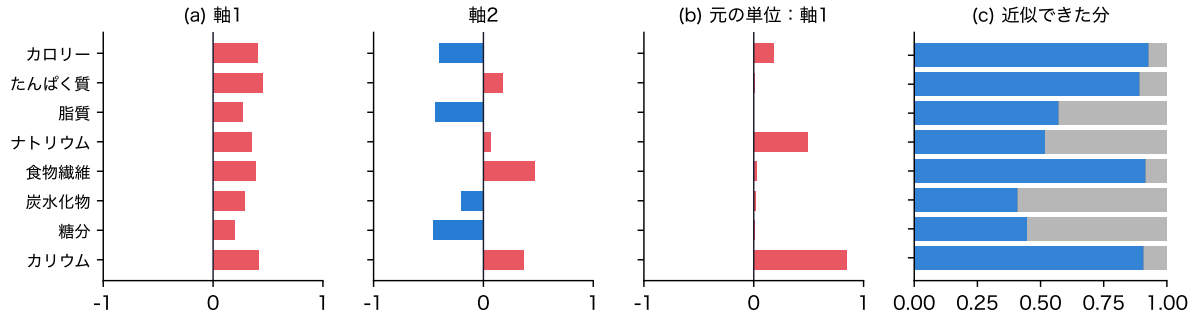


図 1: シリアルの 8 列の主成分分析。(a) 標準化して $Q = 2$ としたときの軸の向き $\mathbf{A}$ の 2 列(赤は正、青は負)、(b) 元の単位のままの軸 1、(c) 2 本の軸で近似できた分(青)と残った分(灰)

本章の問いは、残した軸は何を表し、どう読めばよいか、である。以下ではまず、第 10 回の目的関数を読み直し、誤差を小さくすることが得点の分散を大きくすることと同じだと確かめる。そこから分散共分散行列の固有値分解が出てくる。次に負荷量とバイプロットで軸の意味を読み、単位のまちまちな列を標準化することの意味を確かめる。最後に、誤差の大きさを列ごとに分けてモデルにする因子分析を、最尤法で解く。誤差がどの列も同じ大きさなら答えの向きが主成分分析と一致すること、答えが単位によらないこと、因子の数を BIC で比べられること、回転の自由で読みやすい向きを選べることを示す。

分散最大化と固有値分解

第 10 回の証明では、$\mathbf{A}$ を固定したときの最もよい得点 $\hat{\mathbf{F}} = \mathbf{X}\mathbf{A}$ を代入して、目的関数を

$$J(\mathbf{A}) = \mathrm{tr}(\mathbf{X}^\top \mathbf{X}) - \mathrm{tr}(\mathbf{A}^\top \mathbf{X}^\top \mathbf{X}\mathbf{A}) \tag{1}$$

と書き直した。第 2 項は $\mathrm{tr}(\mathbf{A}^\top \mathbf{X}^\top \mathbf{X}\mathbf{A}) = \|\mathbf{X}\mathbf{A}\|_F^2 = \sum_i \sum_m \hat{f}_{im}^2$ であり、得点の二乗和である。第 1 項は $\mathbf{A}$ によらないので、J を小さくすることは、得点の二乗和を大きくすることと同じである。人工的なデータとし

て、コーヒー 40 杯の濃さと苦み（列の平均を引いた値）で確かめる。全体の二乗和 57.8 は、点の雲に沿う向きでは得点 52.6 と誤差 5.2 に、160 度の向きでは得点 16.4 と誤差 41.5 に分かれる（図 2）。

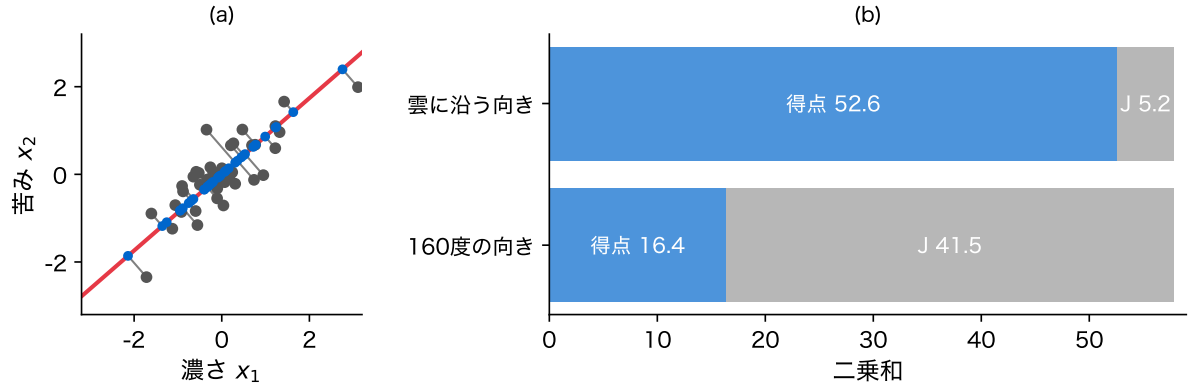


図 2: コーヒー 40 杯の人工データ。(a) 第 10 回の答えの向き（赤）と、直線への足（青）・誤差（灰）、(b) 2 つの向きでの得点の二乗和（青）と誤差 J（灰）の分かれ方

$\mathbf{X}$ は中心化してあるので、得点 $\boldsymbol{f}_m = \mathbf{X}\boldsymbol{a}_m$ の平均も 0 であり、$\frac{1}{n}\sum_i f_{im}^2$ は軸 m の得点の分散である。したがって主成分分析は、制約 $\mathbf{A}^\top\mathbf{A} = \mathbf{I}_Q$ のもとで

$$\max_{\mathbf{A}} \ \mathrm{tr}(\mathbf{A}^\top\mathbf{X}^\top\mathbf{X}\mathbf{A}) \tag{2}$$

を解くこと、すなわち得点の分散の和を最大にする向きを探すことでもある。これを分散最大化（variance maximization）と呼ぶ。細長いパンを写真に撮るとき、横から撮れば写真の上で大きく写り、写らずに消える奥行きは小さい。誤差を小さくする向きと、得点を大きく散らばらせる向きは、同じ向きである。

分散最大化の主役は $\mathbf{X}^\top\mathbf{X}$ である。これを n で割った

$$\mathbf{S} = \frac{1}{n}\mathbf{X}^\top\mathbf{X} \tag{3}$$

の対角成分は各列の分散、対角の外は 2 列の共分散であり、$\mathbf{S}$ は分散共分散行列（variance-covariance matrix）である。正方行列 $\mathbf{S}$ について、$\mathbf{S}\boldsymbol{l} = \lambda\boldsymbol{l}$ を満たす長さ 1 の向き $\boldsymbol{l}$ を固有ベクトル（eigenvector）、λ を固有値（eigenvalue）と呼ぶ。$\mathbf{S}$ を掛けると、たいていの向きは回ってしまうが、固有ベクトルの向きだけは変わらず、長さが λ 倍になる（図 3）。$\mathbf{S}$ のような対称行列は、互いに直角な p 本の固有ベクトルを並べた正規直交行列 $\mathbf{L}$ と、固有値を大きい順に対角に並べた $\boldsymbol{\Lambda}$ を使って

$$\mathbf{S} = \mathbf{L}\boldsymbol{\Lambda}\mathbf{L}^\top, \qquad \mathbf{L}^\top\mathbf{L} = \mathbf{L}\mathbf{L}^\top = \mathbf{I}_p \tag{4}$$

と書ける（定義 1）。

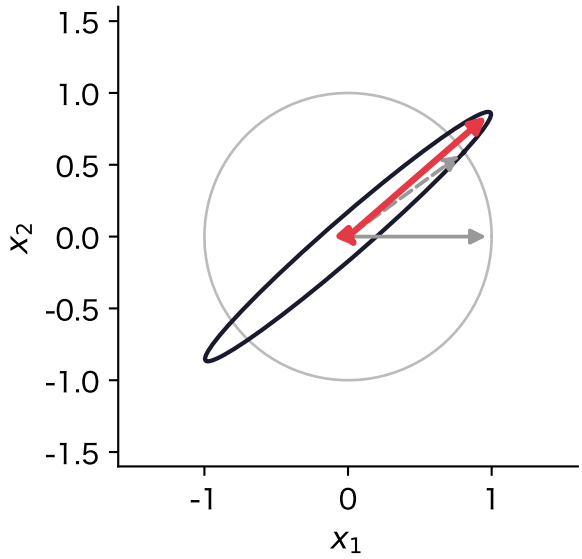


図 3: コーヒー 40 杯の分散共分散行列 $\mathbf{S}$ を、長さ 1 の円(灰)の各点に掛けると楕円(黒)に移る。灰の矢印は向きが回るが、固有ベクトル(赤、長さは固有値)は向きが変わらない

定義 1 (固有値分解)**.** 対称行列 $\mathbf{S}$ を、互いに直角な長さ 1 の固有ベクトルを並べた $\mathbf{L}$ と、固有値を対角に並べた $\boldsymbol{\Lambda}$ で $\mathbf{S} = \mathbf{L}\boldsymbol{\Lambda}\mathbf{L}^\top$ と書くことを、固有値分解(eigendecomposition)と呼ぶ。

第 10 回の特異値分解 $\mathbf{X} = \mathbf{K}\boldsymbol{\Delta}\mathbf{L}^\top$ を代入すると、$\mathbf{K}^\top\mathbf{K} = \mathbf{I}_p$ から

$$\mathbf{S} = \frac{1}{n}\mathbf{L}\boldsymbol{\Delta}\mathbf{K}^\top\mathbf{K}\boldsymbol{\Delta}\mathbf{L}^\top = \mathbf{L}\,\frac{\boldsymbol{\Delta}^2}{n}\,\mathbf{L}^\top \tag{5}$$

となる。これは (4) 式と同じ形であり、$\mathbf{S}$ の固有ベクトルは $\mathbf{X}$ の右特異行列 $\mathbf{L}$ の列、固有値は $\lambda_m = \delta_m^2/n$ である。さらに軸 m の得点 $\mathbf{X}\boldsymbol{l}_m$ の分散は $\frac{1}{n}\|\mathbf{X}\boldsymbol{l}_m\|_2^2 = \boldsymbol{l}_m^\top\mathbf{S}\boldsymbol{l}_m = \lambda_m$ であり、固有値は軸ごとの得点の分散そのものである。コーヒーの例では $\lambda_1 = 1.31$、$\lambda_2 = 0.13$ で、点の雲が長く伸びる向きの分散が大きい。データ行列を特異値分解しても、分散共分散行列を固有値分解しても、同じ軸の向きと得点が得られる(表 2)。主成分分析を「分散共分散行列の固有値と固有ベクトルを求めること」と説明する教科書は、後者の道を見ている。第 10 回の寄与率 $\delta_m^2/\sum_{m'}\delta_{m'}^2$ も、固有値の割合 $\lambda_m/\sum_{m'}\lambda_{m'}$、すなわち全体の分散のうち軸 m の得点が受け持つ割合と読める。

表 2: 主成分分析の 2 つの計算の道

	データ行列の特異値分解(第 10 回)	分散共分散行列の固有値分解
分解するもの	$\mathbf{X}$ $(n \times p)$	$\mathbf{S} = \mathbf{X}^\top\mathbf{X}/n$ $(p \times p)$
軸の向き $\hat{\mathbf{A}}$	$\mathbf{L}$ の左から Q 列	固有値の大きい順に Q 本の固有ベクトル

	データ行列の特異値分解(第10 回)	分散共分散行列の固有値分解
軸 m の大きさ	δ_m^2	$\lambda_m = \delta_m^2/n$（得点の分散）
得点 $\hat{\mathbf{F}}$	$\mathbf{K}_1\boldsymbol{\Delta}_1$	$\mathbf{X}\hat{\mathbf{A}}$

負荷量とバイプロット

軸の意味は、軸の向き $\boldsymbol{a}_m$ の成分から読む。第 10 回のとおり、$\boldsymbol{a}_m$ の第 j 成分 a_{jm} を主成分負荷量と呼ぶ。得点は $f_{im} = \sum_j a_{jm} x_{ij}$ であるから、負荷量は「得点を作るときの各列の重み」である。

人工的なデータで見る。弁当 60 個の 6 項目（ご飯・おかず・値段・カロリー・野菜・塩分）を、「量」と「野菜と塩分」の 2 つの模様から作った。単位は g・円・kcal とまちまちなので、列を標準化してから解く。図 4 は、6 列の負荷量を棒で示したものである。軸 1 ではご飯・おかず・値段・カロリーの 4 列がそろって大きく、得点 1 が大きい弁当はどれも大きい。「量の軸」と読める。軸 2 では野菜と塩分が逆の符号で大きく、野菜が多く塩分が少ない弁当と、その逆を分ける。

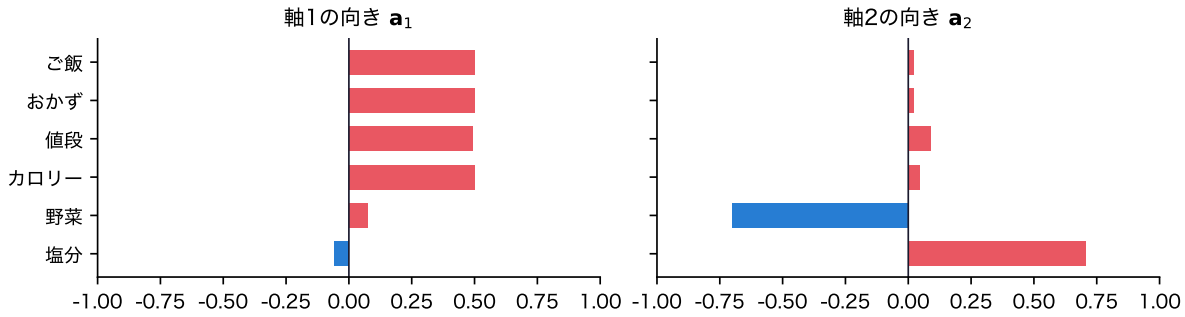


図 4: 弁当 60 個の人工データ（6 項目を標準化）の負荷量。赤は正、青は負

各列を標準化した行列を $\mathbf{Z}$ と書く。その分散共分散行列

$$\mathbf{C} = \frac{1}{n}\mathbf{Z}^\top\mathbf{Z} \tag{6}$$

の (j,k) 成分は $s_{jk}/\sqrt{s_{jj}s_{kk}}$、すなわち元の列の相関係数 r_{jk} であり、$\mathbf{C}$ を相関行列（correlation matrix）と呼ぶ。対角はすべて 1 である。標準化したデータの主成分分析は、$\mathbf{C}$ の固有値分解 $\mathbf{C} = \mathbf{L}\boldsymbol{\Lambda}\mathbf{L}^\top$ である。

負荷量と相関の関係を導く。得点 $\boldsymbol{f}_m = \mathbf{Z}\boldsymbol{a}_m$ と列 $\boldsymbol{z}_j$ の共分散は、$\boldsymbol{a}_m$ が $\mathbf{C}$ の固有ベクトルであることから

$$\frac{1}{n}\boldsymbol{z}_j^\top\mathbf{Z}\boldsymbol{a}_m = (\mathbf{C}\boldsymbol{a}_m)_j = \lambda_m a_{jm}$$

である。列の分散は 1、得点の分散は λ_m なので

$$\mathrm{corr}(\boldsymbol{z}_j, \boldsymbol{f}_m) = \frac{\lambda_m a_{jm}}{\sqrt{\lambda_m}} = a_{jm}\sqrt{\lambda_m} \tag{7}$$

となる。同じ軸の中では、負荷量の大小がそのまま列と得点の相関の大小である。たとえば $\lambda_1 = 4$、$a_{j1} = 0.45$ なら相関は 0.9 である。負荷量に $\sqrt{\lambda_m}$ を掛けたものを負荷量と呼ぶ本もあるので、読むときは定義を確かめる。

得点と負荷量を 1 枚の図に重ねたものをバイプロット（biplot）と呼ぶ（図 5）。点は行（弁当）の得点、矢印は列と得点の相関 $a_{jm}\sqrt{\lambda_m}$ である。矢印の向きにある点ほど、その列の値が大きい。ご飯・おかず・値段・カロリーの矢印はそろって右を、野菜と塩分の矢印は上下の逆を向く。

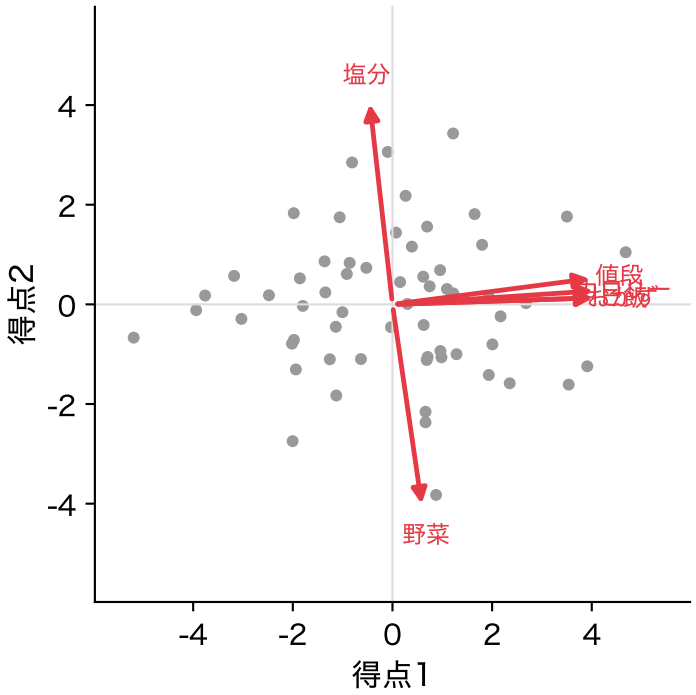


図 5: 弁当 60 個の人工データのバイプロット。灰の点は弁当の得点、赤の矢印は各列と得点の相関（$a_{jm}\sqrt{\lambda_m}$ を図の大きさに合わせて伸ばした）

ただし、第 10 回で見たとおり、軸の向きは裏返しても近似も J も変わらない。負荷量の符号そのものに意味はなく、読むべきは、どの列とどの列が同じ向きに並び、どの列が逆を向くかである。シリアルに戻ると（図 1 (a)）、軸 1 では 8 列の負荷量がすべて同じ符号で、1 カップに詰まった中身の多さと読める。軸 2 では食物繊維・カリウムと、糖分・脂質が逆を向く。

単位と標準化

第 7 回で見たとおり、列の単位は目的関数の中で列の重みになる。弁当の 6 列を元の単位のまま主成分分析にかけると、軸 1 はほぼカロリー（kcal）と値段（円）だけで決まり、塩分（g）はほとんど 0 になる（図 6 (a)）。数の大

きい列が分散の大半を持ち、分散最大化 (2) 式はその列の向きを選んでしまうからである。列を標準化してから解くと、量の 4 列がそろって軸 1 に乗る（図 6 (b)）。

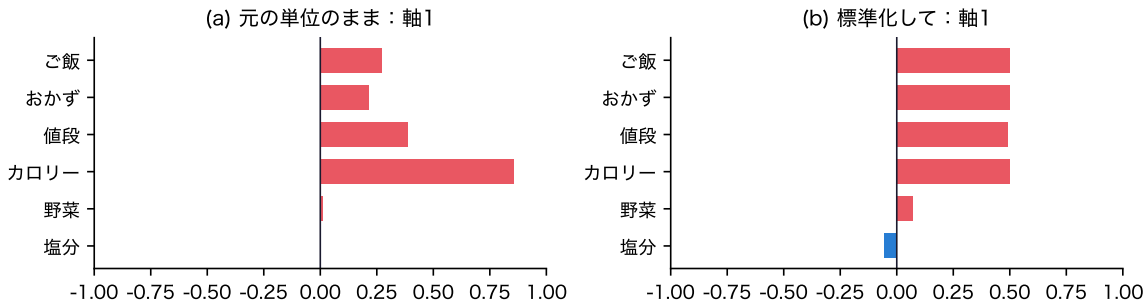


図 6: 弁当 60 個の人工データの軸 1 の負荷量。(a) 元の単位のまま、(b) 標準化してから

単位を変えることは、データ行列の右から対角行列 $\mathbf{D}$（各列の換算の倍率）を掛けることである。このとき分散共分散行列は $\mathbf{S}$ から $\mathbf{DSD}$ に変わる。$\mathbf{DSD}$ の固有ベクトルは、一般に $\mathbf{S}$ の固有ベクトルに $\mathbf{D}$ を掛けたものとは一致しない。単位を変えると、軸の向きそのものが変わるのである。標準化は、$\mathbf{D}$ を各列の標準偏差の逆数 $\mathbf{D}_s = \mathrm{diag}(1/\sqrt{s_{jj}})$ に決めることであり、そのときの分散共分散行列が相関行列 $\mathbf{C}$ である。どの列も分散 1 にそろえて数えると決めたことになる。単位のそろった列（第 10 回の写真の明るさなど）なら標準化は要らないが、単位がまちまちなら、ふつうは相関行列の主成分分析を使う。それでも標準化は、中立な既定値ではなく、すべての列を同じ重さで数えるという選択である。主成分分析の答えは、列の重みを決めないと決まらない。シリアルでも、元の単位のままでは mg の 2 列が軸 1 を決めた（図 1 (b)）。

因子分析のモデル

主成分分析は、全列の誤差をまとめた二乗和 $J = \|\mathbf{E}\|_F^2$ を小さくする。誤差の大きさを列ごとに表す量はモデルになく、軸は列だけの揺れまで拾ってしまう。人工的なデータで見る。パン屋 100 軒の 6 項目の評価（味・香り・食感・値段の安さ・量・駅からの近さ、どれも標準化した値）を、「おいしさ」と「お得さ」の 2 つの共通の要因から作った。駅からの近さは、共通の要因ではほとんど決まらないように作った。主成分分析で 2 本の軸を求めると、駅からの近さも軸 1 に 0.46 で乗る（図 7 (a)）。2 本の軸で近似して残った分散は、どの列も作るときに置いた独自の揺れより小さく、駅からの近さでは 0.78（置いた値は 0.87）であった。同じ歌を何本かのマイクで録るとき、歌は全部のマイクに入るが、雑音の大きさはマイクごとに違う。主成分分析は、古いマイクの雑音まで歌として軸に乗せてしまう。

そこで、列どうしが共有する部分と、列ごとの部分を分けてモデルにする。行列で書けば

$$\mathbf{X} = \mathbf{F}\mathbf{A}^\top + \mathbf{E} \tag{8}$$

であり、形は主成分分析と同じである。$\mathbf{F} \in \mathbb{R}^{n\times Q}$ を共通因子（common factor）、$\mathbf{A} \in \mathbb{R}^{p\times Q}$ を因子負荷量（factor loading）、$\mathbf{E} \in \mathbb{R}^{n\times p}$ を独自因子（unique factor）と呼ぶ。違いは誤差の置き方にある。行 i を縦に並べ

た $\tilde{\boldsymbol{x}}_i = \mathbf{A}\tilde{\boldsymbol{f}}_i + \tilde{\boldsymbol{\varepsilon}}_i$ について、共通因子は $\tilde{\boldsymbol{f}}_i \sim N(\mathbf{0}, \mathbf{I}_Q)$、独自因子は $\tilde{\boldsymbol{\varepsilon}}_i \sim N(\mathbf{0}, \boldsymbol{\Psi})$ に従い、互いに独立とする。$\boldsymbol{\Psi} = \mathrm{diag}(\psi_1, \ldots, \psi_p)$ は対角行列で、独自因子どうしは無相関、大きさ ψ_j は列ごとに違ってよい。$\mathbf{F}$ も $\mathbf{E}$ も、第 8 回の所属と同じく見えない量である。

$\tilde{\boldsymbol{x}}_i$ の分散共分散行列を求める。導出には、次の道具を使う。

定義 2 (共分散と行列)**.** 平均 $\mathbf{0}$ の確率ベクトル $\boldsymbol{z}$ と定数の行列 $\mathbf{M}$ について、$\mathbb{C}\mathrm{ov}(\mathbf{M}\boldsymbol{z}) = \mathbb{E}[\mathbf{M}\boldsymbol{z}\boldsymbol{z}^\top\mathbf{M}^\top] = \mathbf{M}\,\mathbb{C}\mathrm{ov}(\boldsymbol{z})\mathbf{M}^\top$ である。

期待値は足し算と定数倍を中に通すので、$\mathbf{M}$ を外に出せる。1×1 なら $\mathbb{V}\mathrm{ar}(mz) = m^2\,\mathbb{V}\mathrm{ar}(z)$ である。$\tilde{\boldsymbol{x}}_i = [\mathbf{A}\ \mathbf{I}_p][\tilde{\boldsymbol{f}}_i; \tilde{\boldsymbol{\varepsilon}}_i]$ と書けば、$\tilde{\boldsymbol{f}}_i$ と $\tilde{\boldsymbol{\varepsilon}}_i$ は独立なので、縦に並べたベクトルの分散共分散行列は対角に $\mathbf{I}_Q$ と $\boldsymbol{\Psi}$ が並び、その外は $\mathbf{O}$ である。定義 2 を使うと

$$\boldsymbol{\Sigma} = \mathbb{C}\mathrm{ov}(\tilde{\boldsymbol{x}}_i) = \mathbf{A}\mathbf{A}^\top + \boldsymbol{\Psi} \tag{9}$$

となる(定義 3)。対角の外 $\sigma_{jk} = \sum_m a_{jm}a_{km}$ には $\boldsymbol{\Psi}$ が入らないので、列どうしの相関は共通因子だけが作る。対角 $\sigma_{jj} = \sum_m a_{jm}^2 + \psi_j$ は、共通因子が説明する共通性(communality)と、列だけの独自性(uniqueness)に分かれる。標準化した列で $a_{j1} = a_{j2} = 0.6$ なら、共通性は 0.72、独自性は 0.28 である。

定義 3 (因子分析)**.** 各行を、少数の共通因子と列ごとの独自因子の和 $\tilde{\boldsymbol{x}}_i = \mathbf{A}\tilde{\boldsymbol{f}}_i + \tilde{\boldsymbol{\varepsilon}}_i$ ($\tilde{\boldsymbol{f}}_i \sim N(\mathbf{0}, \mathbf{I}_Q)$、$\tilde{\boldsymbol{\varepsilon}}_i \sim N(\mathbf{0}, \boldsymbol{\Psi})$、$\boldsymbol{\Psi}$ は対角)で表すモデルを因子分析(factor analysis)と呼ぶ。分散共分散行列は $\boldsymbol{\Sigma} = \mathbf{A}\mathbf{A}^\top + \boldsymbol{\Psi}$ である。$\sum_m a_{jm}^2$ を共通性、ψ_j を独自性と呼ぶ。

パン屋のデータに次の節の方法で当てはめると、推定した駅からの近さの独自性は 0.89 で、置いた値に近い(図 7 (b))。主成分分析が軸に乗せた近さの揺れを、因子分析は独自因子に回している。

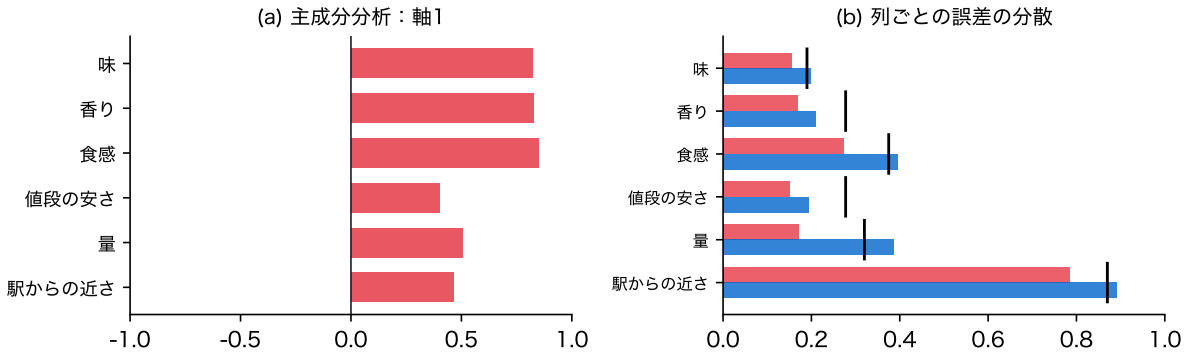


図 7: パン屋 100 軒の人工データ。(a) 主成分分析の軸 1 の $a_{j1}\sqrt{\lambda_1}$、(b) 主成分分析(2 本)で残った分散(赤)、因子分析(2 因子)の独自性(青)、作るときに置いた独自の揺れ(黒の線)

最尤法で推定する

因子分析の未知は、因子負荷量 $\mathbf{A}$ と独自性 $\boldsymbol{\Psi}$ である。行の出方を正規分布で置いたので、第 6 回・第 8 回と同じく最尤法で推定できる。$\mathbf{X}$ は中心化してあるので、各行は $N(\mathbf{0}, \boldsymbol{\Sigma})$ に従う。第 6 回の多変量正規分布の密度

の対数をとると、1 行分は

$$\log N(\tilde{\boldsymbol{x}}_i; \mathbf{0}, \boldsymbol{\Sigma}) = -\frac{1}{2}\Big[p\log 2\pi + \log|\boldsymbol{\Sigma}| + \tilde{\boldsymbol{x}}_i^\top \boldsymbol{\Sigma}^{-1}\tilde{\boldsymbol{x}}_i\Big]$$

である。1×1 の数はトレースをとっても変わらないので、第 10 回の道具②で順番を回すと $\tilde{\boldsymbol{x}}_i^\top \boldsymbol{\Sigma}^{-1}\tilde{\boldsymbol{x}}_i = \mathrm{tr}(\boldsymbol{\Sigma}^{-1}\tilde{\boldsymbol{x}}_i\tilde{\boldsymbol{x}}_i^\top)$ と書ける。$\sum_i \tilde{\boldsymbol{x}}_i\tilde{\boldsymbol{x}}_i^\top = \mathbf{X}^\top\mathbf{X} = n\mathbf{S}$ なので、n 行を足した対数尤度は

$$\ell(\mathbf{A}, \boldsymbol{\Psi}) = -\frac{n}{2}\Big[p\log 2\pi + \log|\boldsymbol{\Sigma}| + \mathrm{tr}(\boldsymbol{\Sigma}^{-1}\mathbf{S})\Big], \qquad \boldsymbol{\Sigma} = \mathbf{A}\mathbf{A}^\top + \boldsymbol{\Psi} \tag{10}$$

となる。データは分散共分散行列 $\mathbf{S}$ を通してしか入らない。因子分析の最尤法は、$\mathbf{S}$ に $\mathbf{A}\mathbf{A}^\top + \boldsymbol{\Psi}$ の形の行列を当てはめることである。

ただし、答えは 1 つには決まらない。$\mathbf{R}$ を $Q\times Q$ の正規直交行列(回転)とすると $(\mathbf{A}\mathbf{R})(\mathbf{A}\mathbf{R})^\top = \mathbf{A}\mathbf{A}^\top$ であり、$\boldsymbol{\Sigma}$ も ℓ も変わらない。第 10 回で主成分分析の軸が回転の分だけ決まらなかったのと同じである。この自由の使い方は、後の節で扱う。

主成分分析は因子分析の特別な場合

主成分分析は、全列の誤差を同じ重さで足した二乗和 J を小さくした。これを確率のモデルの言葉で言い直すと、どうなるだろうか。独自性をどの列も同じ $\boldsymbol{\Psi} = \sigma^2\mathbf{I}_p$ とした因子分析を考える。次の定理が成り立つ(Tipping & Bishop, 1999)。

定理 1 (誤差がどの列も同じ大きさの因子分析)**.** $\mathbf{S} = \mathbf{L}\boldsymbol{\Lambda}\mathbf{L}^\top$(固有値は大きい順)とし、上位 Q 本の固有ベクトルを $\mathbf{L}_1$、その固有値の対角行列を $\boldsymbol{\Lambda}_1$ とする。$\boldsymbol{\Psi} = \sigma^2\mathbf{I}_p$ のとき、*(10)* 式を最大にするのは

$$\hat{\mathbf{A}} = \mathbf{L}_1(\boldsymbol{\Lambda}_1 - \hat{\sigma}^2\mathbf{I}_Q)^{1/2}\mathbf{R}, \qquad \hat{\sigma}^2 = \frac{1}{p-Q}\sum_{m=Q+1}^{p}\lambda_m \tag{11}$$

である。$\mathbf{R}$ は任意の $Q\times Q$ の回転である。

$\mathbf{L}_1$ は、主成分分析の軸の向きと同じになる。つまり主成分分析の軸は、誤差がどの列も同じ大きさとみなした因子分析の最尤推定の向きにあたる。

定理 1 を示す。導出には、次の 4 つの道具を使う。

定義 4 (行列式の対数の偏微分)**.** $\boldsymbol{\Sigma} = \mathbf{A}\mathbf{A}^\top + \boldsymbol{\Psi}$ について、$\partial\log|\boldsymbol{\Sigma}|/\partial\mathbf{A} = 2\boldsymbol{\Sigma}^{-1}\mathbf{A}$ である。

定義 5 (逆行列のトレースの偏微分)**.** 同じ $\boldsymbol{\Sigma}$ と定数の対称行列 $\mathbf{S}$ について、$\partial\mathrm{tr}(\boldsymbol{\Sigma}^{-1}\mathbf{S})/\partial\mathbf{A}$ は $-2\boldsymbol{\Sigma}^{-1}\mathbf{S}\boldsymbol{\Sigma}^{-1}\mathbf{A}$ になる。

定義 6 (逆行列の押し込み)**.** $p\times Q$ の行列 $\mathbf{A}$ と $\sigma^2 > 0$ について、$(\sigma^2\mathbf{I}_p + \mathbf{A}\mathbf{A}^\top)^{-1}\mathbf{A} = \mathbf{A}(\sigma^2\mathbf{I}_Q + \mathbf{A}^\top\mathbf{A})^{-1}$ が成り立つ。

定義 7 (固有値で書く行列式とトレース)**.** $\boldsymbol{\Sigma} = \mathbf{L}\,\mathrm{diag}(\nu_1, \dots, \nu_p)\mathbf{L}^\top$ と $\mathbf{S} = \mathbf{L}\boldsymbol{\Lambda}\mathbf{L}^\top$ が同じ正規直交行列 $\mathbf{L}$ を持つとき、$\log|\boldsymbol{\Sigma}| = \sum_m \log \nu_m$、$\mathrm{tr}(\boldsymbol{\Sigma}^{-1}\mathbf{S}) = \sum_m \lambda_m/\nu_m$ である。

定義 4 と 定義 5 は、第 8 回の共分散行列の更新と同じく行列での微分を要するので、結果だけを使う。1×1 で確かめると、$\frac{d}{da}\log(a^2+\psi) = 2a/(a^2+\psi)$、$\frac{d}{da}\, s/(a^2+\psi) = -2as/(a^2+\psi)^2$ であり、それぞれ 定義 4 と 定義 5 の形をしている。定義 6 は、$\mathbf{A}(\sigma^2\mathbf{I}_Q + \mathbf{A}^\top\mathbf{A})$ と $(\sigma^2\mathbf{I}_p + \mathbf{A}\mathbf{A}^\top)\mathbf{A}$ がどちらも $\sigma^2\mathbf{A} + \mathbf{A}\mathbf{A}^\top\mathbf{A}$ であることから、左から $(\sigma^2\mathbf{I}_p + \mathbf{A}\mathbf{A}^\top)^{-1}$、右から $(\sigma^2\mathbf{I}_Q + \mathbf{A}^\top\mathbf{A})^{-1}$ を掛けて得られる。$p \times p$ の逆行列を、$Q \times Q$ の逆行列に押し込める。定義 7 は、行列式が固有値の積であること、$\boldsymbol{\Sigma}^{-1}\mathbf{S} = \mathbf{L}\,\mathrm{diag}(\lambda_m/\nu_m)\mathbf{L}^\top$ であることから従う。

まず、(10) 式を $\mathbf{A}$ で偏微分して $\mathbf{O}$ とおく。定義 4 と 定義 5 から

$$\frac{\partial \ell}{\partial \mathbf{A}} = -n\Big[\boldsymbol{\Sigma}^{-1}\mathbf{A} - \boldsymbol{\Sigma}^{-1}\mathbf{S}\boldsymbol{\Sigma}^{-1}\mathbf{A}\Big] = \mathbf{O}$$

であり、左から $\boldsymbol{\Sigma}$ を掛けると

$$\mathbf{S}\boldsymbol{\Sigma}^{-1}\mathbf{A} = \mathbf{A} \tag{12}$$

を得る。ここまでは $\boldsymbol{\Psi}$ が対角なら何でも成り立つ。以下 $\boldsymbol{\Psi} = \sigma^2\mathbf{I}_p$ とする。定義 6 で $\boldsymbol{\Sigma}^{-1}\mathbf{A} = \mathbf{A}(\sigma^2\mathbf{I}_Q + \mathbf{A}^\top\mathbf{A})^{-1}$ と書き換え、右から $\sigma^2\mathbf{I}_Q + \mathbf{A}^\top\mathbf{A}$ を掛けると、$\mathbf{S}\mathbf{A} = \mathbf{A}(\sigma^2\mathbf{I}_Q + \mathbf{A}^\top\mathbf{A})$ となる。

次に、$p \times Q$ の行列 $\mathbf{A}$ を第 10 回のとおり特異値分解して $\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{R}^\top$ と書く。$\mathbf{U}$ は列が長さ 1 で互いに直角な $p \times Q$ の行列、$\mathbf{D}$ は対角、$\mathbf{R}$ は $Q \times Q$ の回転である。$\mathbf{A}^\top\mathbf{A} = \mathbf{R}\mathbf{D}^2\mathbf{R}^\top$ を代入すると

$$\mathbf{S}\mathbf{U}\mathbf{D}\mathbf{R}^\top = \mathbf{U}\mathbf{D}\mathbf{R}^\top(\sigma^2\mathbf{I}_Q + \mathbf{R}\mathbf{D}^2\mathbf{R}^\top) = \mathbf{U}(\sigma^2\mathbf{I}_Q + \mathbf{D}^2)\mathbf{D}\mathbf{R}^\top$$

となる(対角行列どうしは順番を入れ替えてよい)。右から $\mathbf{R}$ と $\mathbf{D}^{-1}$ を掛ければ

$$\mathbf{S}\mathbf{U} = \mathbf{U}(\sigma^2\mathbf{I}_Q + \mathbf{D}^2) \tag{13}$$

である。$\mathbf{U}$ の各列 $\boldsymbol{u}_m$ は $\mathbf{S}$ の固有ベクトルであり、その固有値を λ とすれば $d_m^2 = \lambda - \sigma^2$ である。

σ^2 を求める。$\mathbf{U}$ が $\mathbf{S}$ の固有ベクトルのうち Q 本なら、$\boldsymbol{\Sigma} = \mathbf{U}\mathbf{D}^2\mathbf{U}^\top + \sigma^2\mathbf{I}_p$ は $\mathbf{S}$ と同じ固有ベクトルを持ち、その固有値は、残した向きで $d_m^2 + \sigma^2 = \lambda_m$、ほかの向きで σ^2 である。上位 Q 本を残したとして 定義 7 を使うと

$$-\frac{2}{n}\ell = p\log 2\pi + \sum_{m \le Q}\log\lambda_m + (p-Q)\log\sigma^2 + Q + \frac{1}{\sigma^2}\sum_{m>Q}\lambda_m$$

となる。これを σ^2 で微分して 0 とおくと $(p-Q)/\sigma^2 - \sum_{m>Q}\lambda_m/\sigma^4 = 0$ であり、$\hat{\sigma}^2$ は捨てた固有値の平均になる。たとえば固有値が $5, 3, 1.5, 0.5$ で $Q = 2$ なら、$\hat{\sigma}^2 = 1.0$、$d_1^2 = 4$、$d_2^2 = 2$ である。

最後に、どの Q 本を残すかである。$d_m^2 = \lambda - \sigma^2 \geq 0$ なので、残す固有値は $\hat{\sigma}^2$ より大きくなければならない。条件を満たす組の中で ℓ を比べると、上位 Q 本を残したときが最大になる（Tipping & Bishop, 1999。証明は省く）。パン屋の相関行列（固有値 2.716、1.583、0.857、0.357、0.287、0.202）で $Q = 2$ の組をすべて試すと、条件を満たすのは 2 組で、上位 2 本の ℓ のほうが大きい（表 3）。以上で (11) 式が示せた。

表 3: パン屋の相関行列で、$\boldsymbol{\Psi} = \sigma^2 \mathbf{I}$ の因子分析（$Q = 2$）の残す向きを変えたときの最大の対数尤度（$d_m^2 \geq 0$ を満たす組だけ）

残す向き	$\hat{\sigma}^2$	ℓ
1 本目と 2 本目	0.425	-753.3
1 本目と 3 本目	0.607	-793.7

図 8 は、パン屋の固有値を分けたものである。捨てた 4 本の固有値の平均が $\hat{\sigma}^2 = 0.425$ であり、どの向きにも同じだけの誤差として置かれる。残した 2 本の固有値のうち、共通因子の取り分は $\hat{\sigma}^2$ を差し引いた d_m^2 だけである。主成分分析は、誤差がどの列も同じ大きさだと見なす。因子分析は、その大きさを列ごとに変えてよいとした方法である。

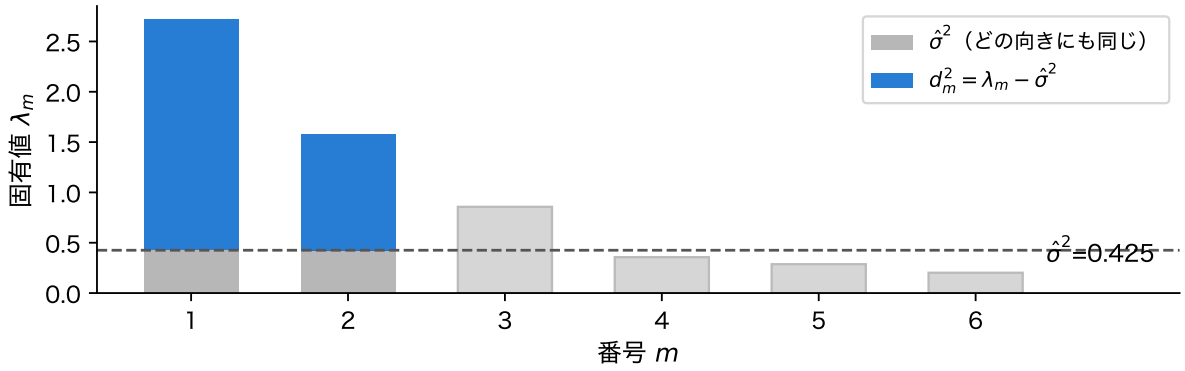


図 8: パン屋の相関行列の固有値。残した 2 本は $d_m^2 = \lambda_m - \hat{\sigma}^2$（青）と $\hat{\sigma}^2$（灰）に分かれ、捨てた 4 本の平均が $\hat{\sigma}^2$（破線）

参考文献

- Tipping, M. E., & Bishop, C. M. (1999). Probabilistic principal component analysis. Journal of the Royal Statistical Society: Series B, 61, 611–622.

Ψを固定すると固有値分解

$\boldsymbol{\Psi} = \sigma^2 \mathbf{I}$ なら固有値分解 1 回で解けた。列ごとに ψ_j が違うときも、$\boldsymbol{\Psi}$ を固定すれば同じ形に持ち込める。各列を独自因子の標準偏差 $\sqrt{\psi_j}$ で割って測り直し、$\mathbf{S}^* = \boldsymbol{\Psi}^{-1/2} \mathbf{S} \boldsymbol{\Psi}^{-1/2}$、$\mathbf{A}^* = \boldsymbol{\Psi}^{-1/2} \mathbf{A}$ とおく。すると $\boldsymbol{\Sigma}^* = \boldsymbol{\Psi}^{-1/2} \boldsymbol{\Sigma} \boldsymbol{\Psi}^{-1/2} = \mathbf{A}^* \mathbf{A}^{*\top} + \mathbf{I}_p$ となり、測り直した列では独自性がどの列も 1 になる。

行列式は積を分けられ($|\mathbf{MN}| = |\mathbf{M}||\mathbf{N}|$)、対角行列の行列式は対角の積なので、$\log|\boldsymbol{\Sigma}| = \log|\boldsymbol{\Psi}| + \log|\boldsymbol{\Sigma}^*|$ である。また $\boldsymbol{\Sigma}^{-1} = \boldsymbol{\Psi}^{-1/2}\boldsymbol{\Sigma}^{*-1}\boldsymbol{\Psi}^{-1/2}$ なので、第 10 回の道具②で順番を回すと $\mathrm{tr}(\boldsymbol{\Sigma}^{-1}\mathbf{S}) = \mathrm{tr}(\boldsymbol{\Sigma}^{*-1}\mathbf{S}^*)$ である。よって (10) 式は

$$\ell = -\frac{n}{2}\left[p\log 2\pi + \log|\boldsymbol{\Psi}| + \log|\boldsymbol{\Sigma}^*| + \mathrm{tr}(\boldsymbol{\Sigma}^{*-1}\mathbf{S}^*)\right]$$

となる。$\boldsymbol{\Psi}$ を固定すると、$\log|\boldsymbol{\Psi}|$ は定数であり、残りは $\mathbf{S}^*$ に $\sigma^2 = 1$ の因子分析を当てたときの対数尤度そのものである。定理 1 を $\sigma^2 = 1$ で使えば、$\mathbf{S}^* = \mathbf{L}^*\boldsymbol{\Gamma}\mathbf{L}^{*\top}$ の上位 Q 本から

$$\hat{\mathbf{A}} = \boldsymbol{\Psi}^{1/2}\mathbf{L}_1^*\left(\boldsymbol{\Gamma}_1 - \mathbf{I}_Q\right)^{1/2} \tag{14}$$

を得る(回転は省いた)。$\boldsymbol{\Psi}$ を固定すると、独自性で測り直した列の主成分分析で $\mathbf{A}$ が決まるのである。$\boldsymbol{\Psi}$ のほうは閉じた式にならないので、(14) 式を代入した ℓ を $\psi_1, \ldots, \psi_p$ について数値的に大きくする。2 つを繰り返すのが、因子分析の最尤法の計算の手順である。最大の点では $\psi_j = s_{jj} - \sum_m \hat{a}_{jm}^2$、すなわち各列の分散のうち共通性で説明できない残りが独自性になる(結果だけを述べる)。本章の図と第 II 部の数値は、すべてこの手順で求めた。

答えは単位によらない

単位を変えることは、データ行列の右から対角行列 $\mathbf{D}$ を掛けることであり、分散共分散行列は $\mathbf{DSD}$ に変わる。主成分分析では、$\mathbf{DSD}$ の固有ベクトルが $\mathbf{S}$ の固有ベクトルと単純な関係にないため、軸の向きが変わった。因子分析の最尤法ではどうなるだろうか。

負荷量の行と独自性を同じ倍率で直した $(\mathbf{DA}, \mathbf{D\Psi D})$ を考えると、$\mathbf{D\Psi D}$ も対角であり、$\boldsymbol{\Sigma}$ は $\mathbf{D\Sigma D}$ になる。新しい単位での対数尤度を (10) 式で計算すると、行列式の積の性質から $\log|\mathbf{D\Sigma D}| = \log|\boldsymbol{\Sigma}| + 2\log|\mathbf{D}|$、順番を回して $\mathrm{tr}((\mathbf{D\Sigma D})^{-1}\mathbf{DSD}) = \mathrm{tr}(\mathbf{D}^{-1}\boldsymbol{\Sigma}^{-1}\mathbf{SD}) = \mathrm{tr}(\boldsymbol{\Sigma}^{-1}\mathbf{S})$ となる。したがって

$$\ell_{\mathbf{D}}(\mathbf{DA}, \mathbf{D\Psi D}) = \ell(\mathbf{A}, \boldsymbol{\Psi}) - n\log|\mathbf{D}| \tag{15}$$

である。差はどの $(\mathbf{A}, \boldsymbol{\Psi})$ でも同じ定数なので、元の単位で $(\hat{\mathbf{A}}, \hat{\boldsymbol{\Psi}})$ が最大なら、新しい単位では $(\mathbf{D}\hat{\mathbf{A}}, \mathbf{D}\hat{\boldsymbol{\Psi}}\mathbf{D})$ が最大である。最大の点は換算されるだけであり、標準化して解いても、元の単位で解いてから標準化の目盛りに直しても、同じ答えになる。弁当の 6 列で確かめると、主成分分析の軸 1 は単位で大きく変わるが、因子分析の因子 1 は 2 通りの答えが一致した(図 9、差は最大 3.7e-05)。因子分析の最尤法では、標準化するかどうかに迷わずに済む。主成分分析の最小二乗法にはこの性質がない。

因子の数を BIC で選ぶ

主成分分析の軸の数は、スクリープロットや累積寄与率を目安に考えた。因子分析は尤度のあるモデルなので、第 9 回の道具がそのまま使える。必要なのはパラメータの数である。平均が p 個、因子負荷量が pQ 個、独自性

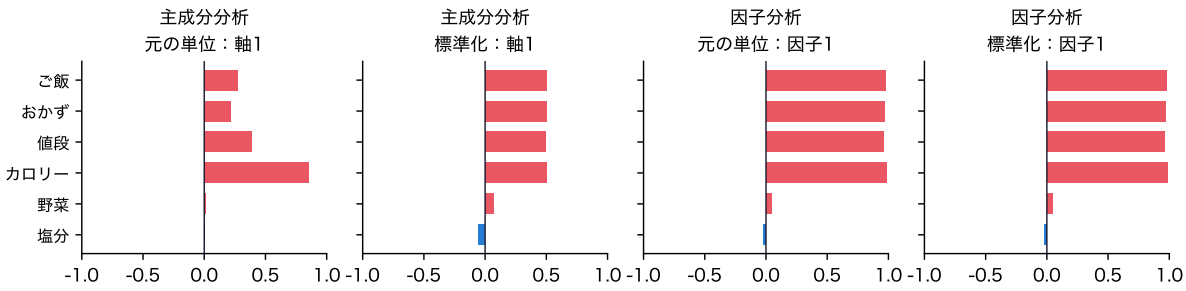


図 9: 弁当 60 個の人工データ。主成分分析の軸 1 と、因子分析（2 因子、バリマックス回転）の因子 1 を、元の単位のままと標準化してからで比べた。因子分析の元の単位の答えは、各列の標準偏差で割って標準化の目盛りにそろえた

が p 個ある。ただし、負荷量は回転の分だけ決まらず、回しても $\boldsymbol{\Sigma}$ は変わらない。$Q \times Q$ の回転は $Q(Q-1)/2$ 個の角度で決まる（$Q = 2$ なら角度 1 つ）ので、その分を引いて

$$d_Q = p + pQ + p - \frac{Q(Q-1)}{2} \tag{16}$$

とする。第 9 回の BIC $= -2\hat{\ell}_Q + d_Q \log n$ で比べると、パン屋のデータでは、最大の対数尤度は因子を増やすほど上がるが、BIC は 2 個のときに最も小さく、作ったときの要因の数と一致した（表 4）。

表 4: パン屋 100 軒の人工データで因子の数を変えたときの、最大の対数尤度・パラメータの数・BIC

因子の数 Q	$\hat{\ell}_Q$	d_Q	BIC
1	-763.1	18	1609.1
2	-723.1	23	1552.2
3	-722.5	27	1569.3

回転で読む

負荷量は回転の分だけ決まらない。主成分分析では、特異値の大きい順に軸を並べてこの自由を使い切った。因子分析では逆に、この自由を「読みやすい向きを選ぶ」ことに使う。パン屋の負荷量を平面に描くと、前の節の手順のままでは、どの列も 2 つの因子に少しずつ乗っている（図 10 (a)）。40 度回しても $\boldsymbol{\Sigma}$ も ℓ も変わらず、点の並びが回るだけである（図 10 (b)）。よく使われるのがバリマックス回転（varimax rotation）で、回した負荷量を $\mathbf{B} = \mathbf{AR}$ として

$$\max_{\mathbf{R}} \sum_{m=1}^{Q} \left[\frac{1}{p} \sum_{j=1}^{p} b_{jm}^4 - \left(\frac{1}{p} \sum_{j=1}^{p} b_{jm}^2 \right)^2 \right] \tag{17}$$

を最大にする回転 $\mathbf{R}$ を選ぶ。括弧の中は、因子 m の負荷量の二乗の分散である。これを大きくすると、負荷量は 0 に近いものと大きいものに分かれ、各列がなるべく 1 つの因子だけに乗る（単純構造）。パン屋では、回転の後、因子 1 には味・香り・食感が、因子 2 には値段の安さ・量が乗り、それぞれ「おいしさ」「お得さ」と名前が付けられる（図 10 (c)）。駅からの近さはどちらにもほぼ乗らない。

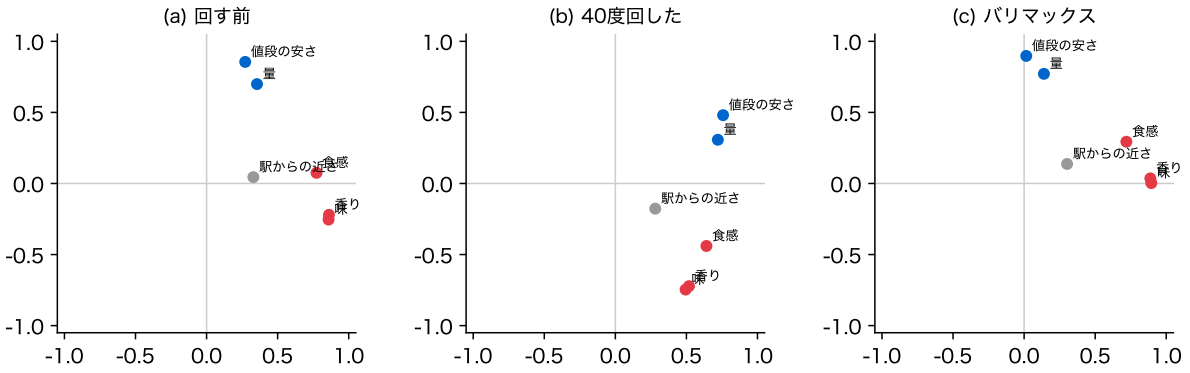


図 10: パン屋 100 軒の人工データの因子負荷量（2 因子）。(a) 回す前、(b) 40 度回したもの、(c) バリマックス回転

表 5 に、2 つの方法の違いをまとめる。モデルの形はどちらも $\mathbf{X} = \mathbf{F}\mathbf{A}^{\top} + \mathbf{E}$ であり、違いは誤差の置き方とそこから来る性質にある。

表 5: 主成分分析と因子分析

	主成分分析	因子分析
誤差	どの列も同じ重さ（$\boldsymbol{\Psi} = \sigma^2\mathbf{I}$ と同じ向き）	列ごとの大きさ ψ_j を見積もる
推定	最小二乗、固有値分解 1 回	最尤法、$\boldsymbol{\Psi}$ を固定して固有値分解
単位	単位で答えが変わる	単位によらない
本数	スクリープロット・寄与率の目安	BIC で比べられる
軸の向き	δ_m の順に決める	回して読みやすい向きを選ぶ

地図の中の因子分析

表 6 は、第 7 回から本章までのモデルを、誤差の置き方と推定の仕方で並べたものである。k-means は群ごとの代表点からのずれを最小二乗で小さくし、混合正規分布はそこに群ごとの正規分布を置いて最尤法にした。主成分分析は軸からのずれを全列同じ重さの最小二乗で小さくし、因子分析はそこに列ごとの正規分布 $N(0, \psi_j)$ を置いて最尤法にした。最小二乗のモデルに正規分布を置いて最尤法にするという一歩を、第 7 回から第 8 回、第 10 回から本章で 2 度踏んだことになる。

表 6: 4 つのモデルの誤差の置き方と推定

モデル	誤差の置き方	推定	解き方	回
k-means	群ごとの代表点からのずれ	最小二乗	交互に解く	第 7 回
混合正規分布	群ごとの正規分布	最尤法	EM	第 8 回
主成分分析	どの列も同じ重さ	最小二乗	固有値分解 1 回	第 10 回
因子分析	列ごとの正規分布 $N(0, \psi_j)$	最尤法	$\boldsymbol{\Psi}$ を固定して固有値分解	第 11 回

第 II 部　実データ解析

シリアルのデータと手続き

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、次の 5 つを予想できる。第 1 に、単位がまちまちな列を元の単位のまま主成分分析にかけると、数の大きい列が分散の大半を持つので、軸 1 はその列で決まるはずである。シリアルでは、ナトリウムとカリウムが mg の単位で数が大きい。第 2 に、負荷量とバイプロットから、軸に名前が付けられるはずである。第 3 に、因子分析の最尤法の答えは単位によらないので、元の単位で解いても標準化して解いても同じになるはずである。第 4 に、パン屋では BIC が作ったときの因子の数で最も小さくなった。シリアルでも、ある因子の数で BIC が最も小さくなるはずである。第 5 に、バリマックス回転すると、パン屋のように各列がなるべく 1 つの因子だけに乗り、名前が付けやすくなるはずである。主成分分析で近似しきれなかったナトリウムは、独自性も大きくなると予想できる。

データは、米国の朝食シリアル 65 銘柄の栄養成分である。1993 年の ASA 統計グラフィックス展示会のデータを、1 カップあたりの量にそろえたもので、R の MASS パッケージに UScereal として収録されている (Venables and Ripley, 2002)。Rdatasets から一度だけ取得して保存した。列はカロリー(kcal)、たんぱく質・脂質・食物繊維・炭水化物・糖分(g)、ナトリウム・カリウム(mg)の 8 列である。

手続きは次のとおりである。8 列から列の平均を引いた $\mathbf{X}$ と、さらに標準偏差で割った $\mathbf{Z}$ を作り、それぞれを特異値分解して、固有値 δ_m^2/n と負荷量を求めた。負荷量の符号は決まらないので、各軸で絶対値の最も大きい成分が正になる向きにそろえた。$\mathbf{Z}$ については、負荷量の棒とバイプロットで軸を読み、65 銘柄から 1 銘柄ずつ抜いて同じ計算をやり直し(65 通り)、軸 1 から 3 の向きが元の向きとどれだけそろうかを、向きのコサインの絶対値で調べた。因子分析は、第 I 部の手順($\boldsymbol{\Psi}$ を固定して固有値分解し、$\boldsymbol{\Psi}$ を数値的に大きくする)で最尤推定した。$\mathbf{Z}$ に因子の数 $Q = 1$ から 4 を当てて BIC を比べた(8 列では、$Q = 5$ 以上はパラメータの数がデ

ータの分散共分散行列の成分の数を超えるので推定できない)。$\mathbf{X}$ にも同じ方法を当て、元の単位の答えを標準化の目盛りに直して比べた。3 因子の答えをバリマックス回転して読み、共通性と独自性を求め、1 銘柄ずつ抜いても解き直した。因子は回転で順番が入れ替わりうるので、元の因子との対応は、向きのコサインの和が最も大きくなる組み合わせで決めた。

結果①：単位

第 1 の予想は単位である。8 列を元の単位のまま主成分分析にかけると、軸 1 の負荷量はカリウムとナトリウムでほぼ決まった(図 11 (a))。予想どおりである。この 2 列だけが mg の単位で、数が桁違いに大きいからである。このとき軸 1 の寄与率は 77.0% と高く見えるが、それは mg の 2 列が分散のほとんどを占めているからにすぎない。標準化して相関行列の主成分分析にすると、軸 1 には 8 列がすべて同じ符号で乗り(図 11 (b))、寄与率は 53.0% になる。寄与率の分母は全体の分散なので、標準化するかどうかで分母が変わり、両者の寄与率は比べられない。

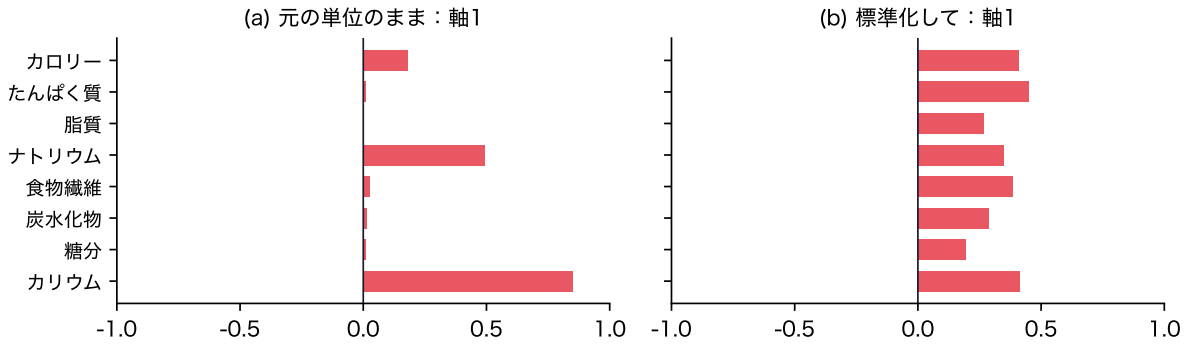


図 11: シリアル 65 銘柄の主成分分析の軸 1 の負荷量(赤は正、青は負)。(a) 元の単位のまま、(b) 標準化してから

第 3 の予想も単位に関わる。因子分析を 3 因子で、元の単位の $\mathbf{X}$ と標準化した $\mathbf{Z}$ の両方に当てた。元の単位の答えを各列の標準偏差で割って標準化の目盛りに直すと、$\hat{\mathbf{A}}\hat{\mathbf{A}}^{\top}$ の差は最大 6.4e-06、独自性の差は最大 2.2e-04 で、計算の誤差の範囲で一致した。(15) 式のとおり、因子分析の最尤法の答えは単位によらない。予想どおりである。以下では標準化した $\mathbf{Z}$ で調べる。

結果③：主成分分析の軸を読む

第 2 の予想は軸の読み方である。図 12 (a) の軸 1 では、8 列の負荷量がすべて同じ符号である。このデータは 1 カップあたりにそろえてあるので、1 カップに詰まった中身が多い銘柄ほど、どの成分も多くなる。軸 1 は「1 杯の中身の多さ」の軸と読める。軸 2 では、食物繊維・カリウム・たんぱく質と、糖分・脂質・カロリーが逆の符号である。ふすま(ブラン)を主にした銘柄と、甘い銘柄を分ける対比と読める。図 12 (b) のバイプロットでも、上には All-Bran などのブラン系が並び、矢印の向きと合う。予想どおり、負荷量とバイプロットから軸に名前が付けられた。

ただし落とし穴がある。標準化したシリアルの固有値は 4.24、1.34、1.18、0.61、0.49、0.10、0.03、0.01 で、2

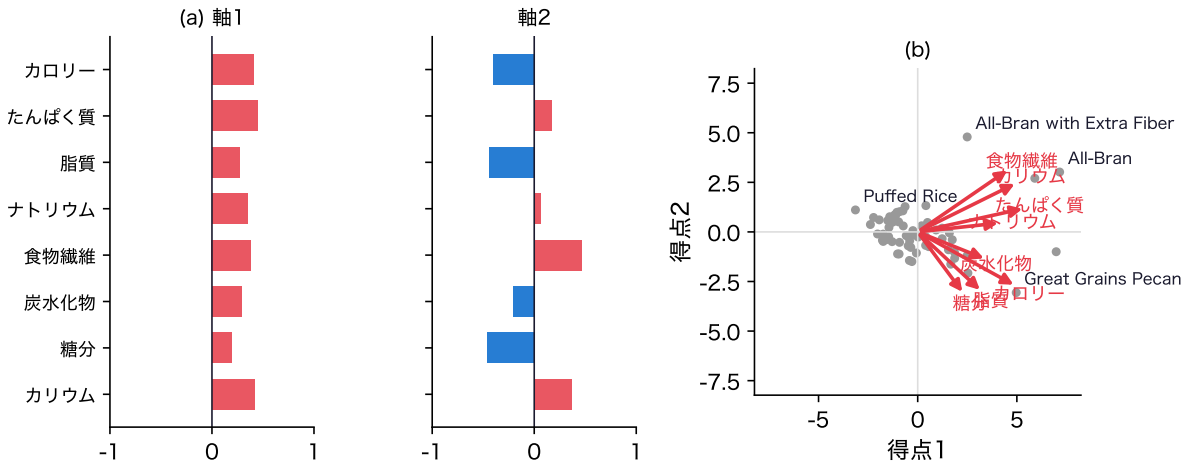


図 12: シリアル 65 銘柄(標準化)の主成分分析。(a) 軸 1・軸 2 の負荷量、(b) バイプロット(灰の点が銘柄、赤の矢印が列と得点の相関。名前は得点の両端の銘柄)

本目と 3 本目がほぼ同じである。65 銘柄から 1 銘柄ずつ抜いて解き直し、軸の向きが元の向きとどれだけそろうかを調べた(表 7)。軸 1 は、どの銘柄を抜いても向きのそろい(コサインの絶対値)が 0.995 以上で、ほとんど変わらない。一方、軸 2 と軸 3 は、All-Bran with Extra Fiber などを抜くと向きのそろいが 0.13 まで落ち、2 本が入れ替わるように回った。固有値がほぼ同じ 2 本は、その 2 本が張る面の中では、どの向きでもほとんど同じだけ分散を受け持つ。第 10 回で見た回転の不定性が、ほぼそのまま現れるのである。軸 2 の名前も、データが少し変わると別の向きに付け替わりうる。固有値の段差がはっきりしない軸に名前を付けるときは、解き直して向きが保たれるかを確かめる必要がある。

表 7: シリアル 65 銘柄から 1 銘柄ずつ抜いて解き直したときの、主成分分析の軸の向きと元の向きのコサインの絶対値

	軸 1	軸 2	軸 3
向きのそろい(最小)	0.995	0.129	0.127
0.9 を下回った回数(65 通り中)	0	2	3

結果④：因子の数

第 4 の予想は因子の数である。標準化したシリアルに因子の数 $Q = 1$ から 4 の因子分析を当て、BIC を比べると、BIC は推定できる上限の 4 個まで下がり続けた(表 8)。パン屋のような谷は無く、予想は外れた。

表 8: シリアル 65 銘柄(標準化)で因子の数を変えたときの、最大の対数尤度・パラメータの数・BIC

因子の数 Q	$\hat{\ell}_Q$	d_Q	BIC
1	-583.3	24	1266.8
2	-508.7	31	1146.8
3	-452.5	37	1059.4
4	-423.7	42	1022.7

理由は、データの作られ方にある。パン屋は「2 つの要因と、列ごとの独立な揺れ」から作ったので、因子分析のモデルがそのまま本当であった。BIC は、モデルの中に本当のものがあるときに、それを選ぶように作られている(第 9 回)。シリアルは、決まった数の要因から作られたデータではない。3 因子を当てた後も、データの相関行列と $\hat{\mathbf{A}}\hat{\mathbf{A}}^\top + \hat{\boldsymbol{\Psi}}$ の対角の外の差が最大 0.21 残る。残った相関を説明できる限り、因子を 1 個足したときの $\hat{\ell}$ の上がり幅はパラメータの増え方の罰則を上回り、BIC は因子を足すほうを選ぶ。実データでは、BIC も因子の数を 1 つに決めてはくれない。以下では、読みやすさと第 I 部のパン屋との比べやすさから 3 因子で読む。

結果⑤：因子を読む

第 5 の予想は因子の読み方である。標準化した 8 列に 3 因子の因子分析を当て、バリマックス回転すると、各列はほぼ 1 つの因子だけに大きく乗った(図 13 (a))。因子 1 には炭水化物とカロリーが、因子 2 には糖分と脂質が、因子 3 には食物繊維・カリウム・たんぱく質が乗る。それぞれ「穀物の量」「甘さと脂」「ブラン系」と名前が付けられ、予想どおりである。共通性と独自性を見ると(図 13 (b))、ナトリウムの独自性は 0.60 と大きい。塩の量は 3 つの因子とは別に、銘柄ごとに決まっているとわかる。冒頭の困りごと③で、主成分分析の 2 本の軸が近似しきれなかったナトリウムの分散は、軸の不足ではなく、ナトリウムだけの揺れであった。

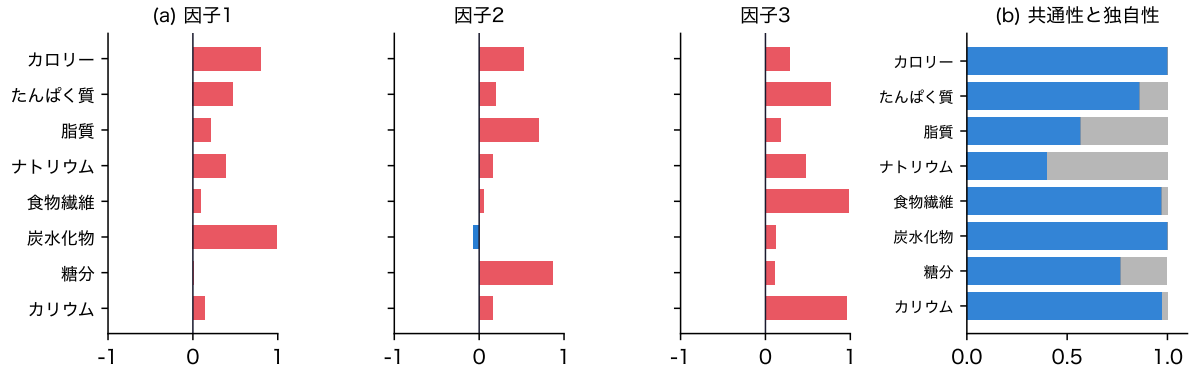


図 13: シリアル 65 銘柄(標準化)の 3 因子の因子分析(最尤法、バリマックス回転)。(a) 因子負荷量(赤は正、青は負)、(b) 共通性(青)と独自性(灰)

一方、予想していなかった結果もある。カロリーと炭水化物の独自性はほぼ 0 (0.0001 と 0.0001)になった。その列だけの揺れが全く無い、という答えである。理由は、カロリーという列の作られ方にある。カロリーをたんぱく質・脂質・炭水化物・糖分の 4 列で回帰すると、決定係数は 0.981 であった。カロリーは栄養成分から計算で

決まる量であり、その列だけの揺れはほとんど無い。独自性 ψ_j は 0 より小さくなれないので、0 に張り付く。炭水化物はカロリーとほぼ同じ因子だけで決まるため、同じく 0 になった。独自性が 0 になる答えは、モデルの「どの列にも独自の揺れがある」という前提が、その列では成り立たないことを知らせている。

最後に、因子の安定さを確かめる。主成分分析と同じく 1 銘柄ずつ抜いて解き直すと、3 つの因子の向きのそろいは最小でも 0.926 であり、主成分分析の軸 2・3 が 0.13 まで落ちたのと対照的である（表 9）。主成分分析の軸 2・3 は、2 本が張る面の中のどの向きでもほとんど同じだけ分散を受け持つため、データが少し変わると向きが入れ替わった。バリマックス回転は、その面の中から「各列がなるべく 1 つの因子だけに乗る」向きを選ぶ。単純構造の向きはデータの小さな変化ではあまり動かないので、名前も保たれた。

表 9: シリアル 65 銘柄から 1 銘柄ずつ抜いて解き直したときの、元の向きとのコサインの絶対値の最小

向きのそろい（65 通りの最小）	1 本目	2 本目	3 本目
主成分分析の軸	0.995	0.129	0.127
因子分析の因子（バリマックス）	0.926	0.941	0.993

このデータでわかったこと

第 II 部の結果をまとめる。元の単位のままでは、主成分分析の軸 1 は mg の 2 列で決まった。因子分析の最尤法は、元の単位でも標準化しても同じ答えを出した。主成分分析の軸には名前が付けられ、軸 1 は 1 杯の中身の多さ、軸 2 はブラン系か甘い系かと読めた。ただし、2 本目と 3 本目の固有値に段差がなく、軸 2 と軸 3 は 1 銘柄を抜くだけで向きが入れ替わることがあった。因子の数を BIC で比べるという予想は外れた。BIC は推定できる上限の 4 個まで下がり続けた。シリアルは、少数の要因と列ごとの独立な揺れから作られたデータではないからである。3 因子をバリマックス回転すると、「穀物の量」「甘さと脂」「ブラン系」と名前が付き、1 銘柄を抜いても向きが保たれた。ナトリウムの独自性は大きく、主成分分析で近似しきれなかった分は、ナトリウムだけの揺れであった。一方、カロリーの独自性は 0 に張り付いた。カロリーはほかの栄養成分から計算で決まる量であり、列だけの揺れが無いからである。

締め

まとめと次回の問い

本章の問いは、残した軸は何を表し、どう読めばよいか、であった。まず、第 10 回の目的関数 J が、全体の二乗和から得点の二乗和を引いたものであることを読み直した。誤差を小さくする向きは、得点の分散を大きくする向きである（分散最大化）。分散最大化の主役である分散共分散行列 $\mathbf{S}$ の固有値分解は、データ行列の特異値分解から出てくる。固有ベクトルは軸の向き、固有値 $\lambda_m = \delta_m^2/n$ は軸ごとの得点の分散である。軸の意味は、負荷量とバイプロットで、列どうしが同じ向きか逆向きかから読む。負荷量に $\sqrt{\lambda_m}$ を掛けたものは、列と得点の相関である。単位を変えると主成分分析の答えは変わるので、単位がまちまちな列は標準化し、相関行列の主成分分析として解く。ただし標準化は、すべての列を同じ重さで数えるという選択である。

主成分分析は、誤差をどの列も同じ重さで扱う。誤差の大きさを列ごとに分けてモデルにしたのが因子分析であり、分散共分散行列を $\mathbf{A}\mathbf{A}^{\top} + \boldsymbol{\Psi}$ の形で表す。最尤法で解くと、誤差がどの列も同じ大きさ（$\boldsymbol{\Psi} = \sigma^2\mathbf{I}$）なら、答えの向きは主成分分析の軸と一致し、$\hat{\sigma}^2$ は捨てた固有値の平均になる。$\boldsymbol{\Psi}$ が対角なら、列を独自性で測り直してから固有値分解すればよい。最尤法の答えは単位によらず、因子の数は第 9 回の BIC で比べられる。負荷量は回転の分だけ決まらないので、その自由を使って各列がなるべく 1 つの因子に乗る向きを選ぶ（バリマックス回転）。シリアル 65 銘柄では、主成分分析の軸 2 と軸 3 は 1 銘柄を抜くだけで入れ替わったが、因子分析で回転した 3 因子は名前が付き、向きも保たれた。ナトリウムの独自性は大きく、カロリーの独自性は 0 に張り付いた。BIC は因子の数を 1 つに決めなかった。

最後に、次回への問いを置く。これまでの列は、g・mg・kcal のような量であり、列の平均を引いて分散共分散行列を作り、分解してきた。しかし、行も列もカテゴリで、マスに「何回あったか」を数えた表もある。そのような表を数の行列とみて、そのまま分解すると、何が起きるのだろうか。行も列もカテゴリの、数えた表をどう縮めて描けばよいのだろうか。

発展

発展①：遺伝子発現データと主成分分析

発展として、主成分分析が実際の研究でどう使われているかを見る。生物学では、1 つ 1 つの細胞について、約 2 万の遺伝子がどれだけ働いているかを、RNA の数として数える（シングルセル RNA-seq（single-cell RNA-seq））。行は細胞で、数千から数百万ある。列は遺伝子で、約 2 万ある。2 万列のデータ行列は、そのままでは図に描けない。

そこで、まず主成分分析で列を縮める。図 14 はマウスの小腸の上皮の細胞を、5 つの方法で 2 次元に描いた図である（Luecken & Theis 2019）。右下の (F) は寄与率を大きい順に並べたスクリープロットで、5〜7 本目に肘がある。論文でも、本章と同じ道具で残す本数を考えている。多くの解析は、上位の数十本の主成分を残してから次の計算へ進む。(A) は主成分分析の軸 1 と軸 2 である。色は細胞ごとに読み取った RNA の総数で、軸 1 の右ほど明るい。弁当やシリアルと同じく、軸 1 は量の軸として現れた。

発展②：t-SNE と UMAP

主成分分析の 2 本だけでは、細胞の種類が重なって見えることが多い。図 15 (a) はマウスの大脳皮質の 23,822 細胞を主成分分析の軸 1・2 に描いた図で、色は 133 の細胞の種類である（Kobak & Berens 2019）。大きな塊が 3 つ見えるだけで、種類の多くは重なる。同じデータに t-SNE（t-distributed stochastic neighbor embedding）を当てると (b)、種類ごとの島に分かれる。

t-SNE は次のように考える。まず元の空間で、点ごとに近所を決め、近い点ほど大きな重みを付ける。次に 2 次元に点を置き、2 次元での近所の重みが元の重みとそろうように、点を少しずつ動かす。保とうとするのは近所の関係だけで、遠い点どうしの距離は保たない。主成分分析の射影は 1 回の特異値分解で決まったが、t-SNE は反復で解き、初期の位置や設定によって絵が変わる。初期の位置には主成分分析の得点を使うことが多い。UMAP（uniform manifold approximation and projection）も考え方は近く、近所のつながりをグラフにし、そ

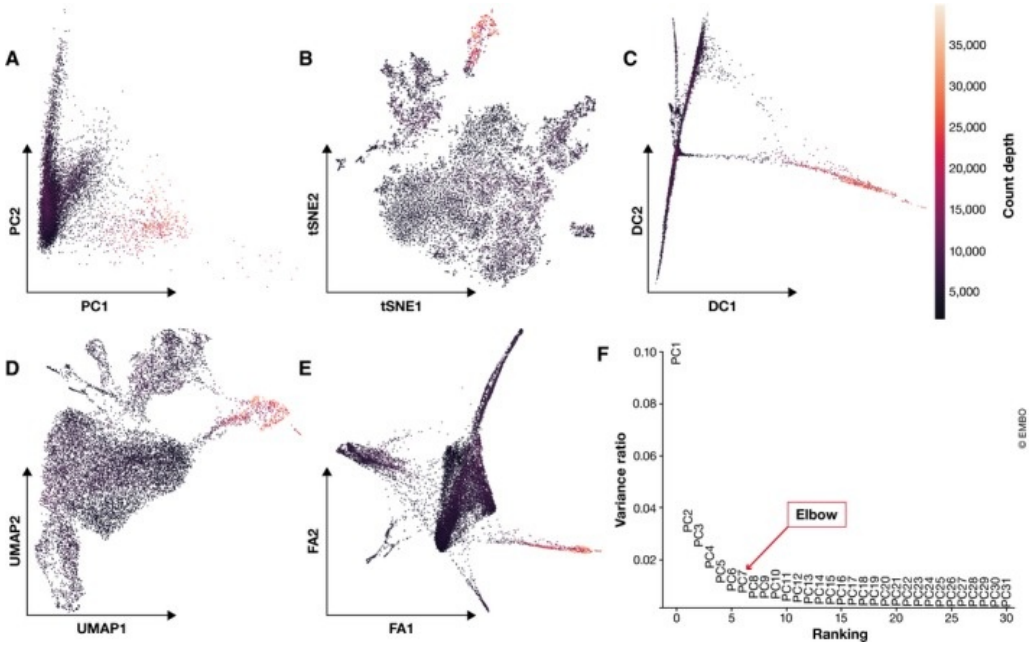


図 14: マウス小腸の上皮の細胞を 2 次元に描いた図。(A) 主成分分析、(B) t-SNE、(C) 拡散写像、(D) UMAP、(E) 力学モデルによるグラフの配置。色は細胞ごとに読み取った RNA の総数。(F) 主成分の寄与率と肘。出典：Luecken & Theis (2019) Mol. Syst. Biol. 15: e8746, Fig. 4（CC BY 4.0）

のつながりが残るように 2 次元に描き直す。大きなデータでも速く、いまの論文で最もよく見る図である。描いた後は、島ごとにどの遺伝子が働いているかを調べ、幹細胞や杯細胞のように細胞の種類の名前を付ける。因子に名前を付けたのと同じ読み方である。

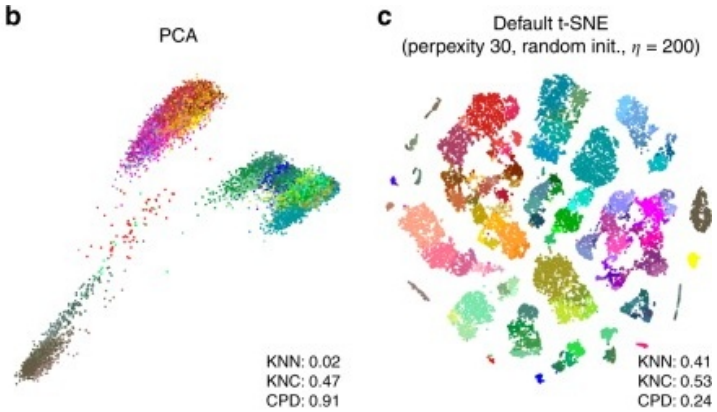


図 15: マウス大脳皮質の 23,822 細胞。色は 133 の細胞の種類。(a) 主成分分析の軸 1・2、(b) t-SNE（既定の設定）。出典：Kobak & Berens (2019) Nat. Commun. 10: 5416, Fig. 2b, c（一部を切り出した。CC BY 4.0）

発展③：2 次元の図を読むときの注意

2 次元の図を読むときには注意が要る。t-SNE や UMAP が保とうとするのは近所の関係だけなので、島どうしの距離は元の距離を表さない。Chari & Pachter (2023) は、細胞の種類どうしの近さの順位が、元のデータと 2 次元の図でどれだけそろうかを、順位の一致度（1 で完全に一致）で調べた。主成分分析で残した 50 本ではおよそ 0.75 だったが、そこから描いた t-SNE と UMAP ではおよそ 0.3 まで下がった。さらに、細胞を象の形に並べた図を作ると、元の距離の保ち方は t-SNE や UMAP と同じくらいであった（図 16）。2 次元の形そのものには意味を読めない。

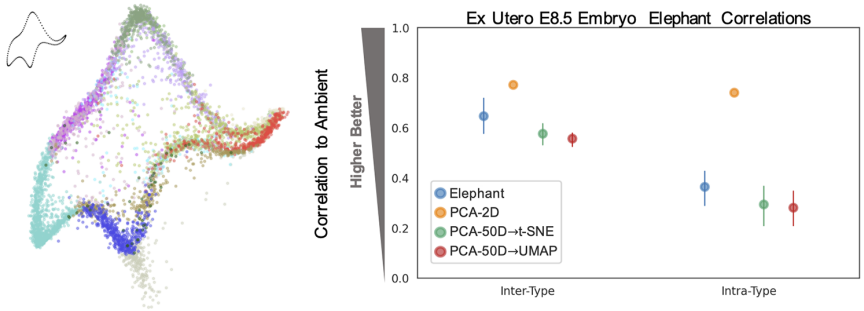


図 16: 細胞を象の形に並べた図（左）と、元のデータの距離との相関（右。異なる種類の細胞どうし・同じ種類の細胞どうし）。青は象、橙は主成分分析の 2 本、緑は t-SNE、赤は UMAP。出典：Chari & Pachter (2023) PLoS Comput. Biol. 19: e1011288, Fig. 7（上の段を切り出した。CC BY 4.0）

主成分分析と t-SNE・UMAP の違いを 表 10 にまとめる。標準の流れでは、約 2 万列の遺伝子をまず主成分分析で上位の数十本に縮め、その得点に t-SNE や UMAP を当てて 2 次元に描き、島に名前を付ける。主成分分析は、2 次元の絵の手前で働く前処理である。

表 10: 主成分分析と t-SNE・UMAP

	主成分分析	t-SNE・UMAP
写し方	線形（射影 $\mathbf{XA}$）	非線形
軸	負荷量で意味を読める	軸に意味はない
保つもの	得点の分散（遠い点どうしの関係も）	近所の関係だけ
解き方	特異値分解 1 回、答えは 1 つ	反復。初期の位置と設定で絵が変わる
使いどころ	前処理、軸の解釈	島を眺め、名前を付ける

参考文献

- Luecken, M. D., & Theis, F. J. (2019). Current best practices in single-cell RNA-seq analysis: a tutorial. Molecular Systems Biology, 15, e8746.

- Kobak, D., & Berens, P. (2019). The art of using t-SNE for single-cell transcriptomics. Nature Communications, 10, 5416.
- Chari, T., & Pachter, L. (2023). The specious art of single-cell genomics. PLoS Computational Biology, 19, e1011288.