第 11 回 k-means

G と C を交互に解き、初期値を変えてやり直す

本章の問いは、第 10 回の締めで残った「行を群に分けると、どう解くのか？」である。主成分分析は得点 $\mathbf{F}$ が連続な値をとれたので、特異値分解 1 回で解けた。一方、k-means の所属行列 $\mathbf{G}$ は、各行に 1 が 1 つだけ立つ 0/1 の行列である。この問いには、交互最小二乗法で答える。$\mathbf{C}$ を固定すれば、各行を最も近い代表点の群に入れるのが $\mathbf{G}$ の最良の更新になる。$\mathbf{G}$ を固定すれば、$\hat{\mathbf{C}} = (\mathbf{G}^\top\mathbf{G})^{-1}\mathbf{G}^\top\mathbf{X}$、すなわち群ごとの平均が $\mathbf{C}$ の最良の更新になる。J は毎回下がり、有限回で止まる。ただし着く先は初期値しだいなので、初期値を変えてやり直し、J が最も小さい答えを採る（ランダムスタート）。

第 I 部　理論

行を群に分ける

第 9 回では主成分分析を特異値分解 1 回で解き、第 10 回の最後に「行を群に分けると、どう解くのか？」という問いを残した。主成分分析 $\|\mathbf{X} - \mathbf{F}\mathbf{A}^\top\|_F^2$ が 1 回で解けたのは、得点 $\mathbf{F}$ が連続な値をとれるので、上位 Q 本の特異値の分をそのまま残せばよかったからである。第 8 回で並べたもう 1 つの目的関数

$$\min_{\mathbf{G},\mathbf{C}} \|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2$$

では、所属行列 $\mathbf{G}$ の各行に 1 が 1 つだけ立ち、残りは 0 である。本章では、この式を実際に解く。

場面として、図 1 の卸売の顧客を考える。ポルトガルの卸売業者の顧客 440 件について、生鮮・乳製品・食料品・冷凍品・洗剤と紙製品・総菜の 6 品目について、1 年間に買った金額を記録したデータである。図はそのうち食料品と生鮮の 2 品目を描いたもので、1 点がデータ行列の 1 行、すなわち 1 件の顧客である。顧客は飲食店もあれば小売店もあり、買い方は顧客ごとに違う。近い点どうしは買い方が似ているので、似た顧客を群にまとめたい。

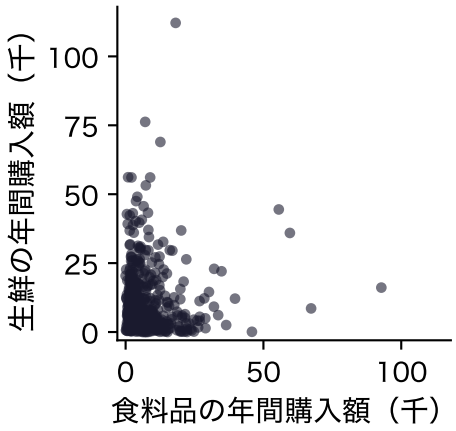


図 1: 卸売業者の顧客 440 件の年間購入額(6 品目のうち食料品と生鮮の 2 品目)

困りごとは 3 つある。1 つ目は、所属が 0 か 1 しかとれないことである。回帰では目的関数を微分して傾きを 0 とおけば答えが出たが、0 と 1 の 2 点しかとれない g_{iq} には傾きが無い。2 つ目は、分け方の多さである。n 行を k 群に分ける分け方は k^n 通りあり、顧客 440 件を 2 つに分けるだけでも 2 の 440 乗通りになる。すべて試すことはできない。3 つ目は、始め方で答えが変わることである。同じ顧客を同じ手順で 3 群に分けても、始め方を変えると分け方が変わる(図 2)。どちらを信じればよいのか。

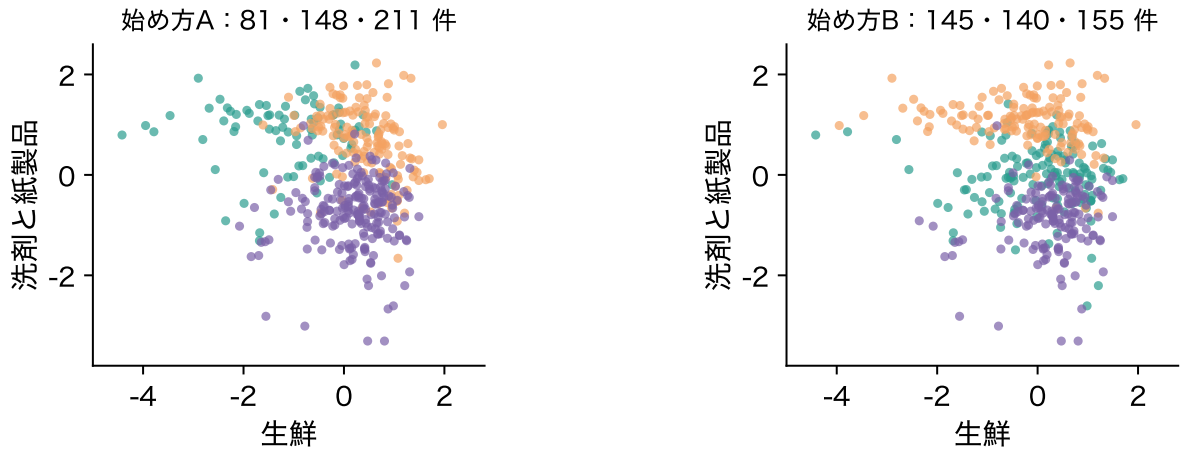


図 2: 卸売の顧客 440 件(6 品目を対数にして標準化)を、同じ手順で 3 群に分けた 2 つの答え。始め方だけが違う。描いたのは生鮮と洗剤と紙製品の 2 列

本章では、行を群に分けるとき、0/1 の $\mathbf{G}$ と、代表点を並べた $\mathbf{C}$ をどう求めるかを問う。k-means は、反復して解くしかない問題の代表例である。

答えは交互最小二乗法である。$\mathbf{C}$ を固定すれば、各行を最も近い代表点の群に入れることが $\mathbf{G}$ の最良の選び方になる。$\mathbf{G}$ を固定すれば、$\hat{\mathbf{C}} = (\mathbf{G}^\top\mathbf{G})^{-1}\mathbf{G}^\top\mathbf{X}$、すなわち群ごとの平均が $\mathbf{C}$ の最良の選び方になる。この 2 つを交互に繰り返すと目的関数は毎回下がり、有限回で止まる。ただし、止まる先は初期値によって変わる。そこ

で初期値を変えてやり直し、目的関数が最も小さい答えを採る。

代表点で近似する

2 変数の人工データで、群に分けて代表点で近似するとはどういうことかを見る。図 3 (a) は、アイスクリーム 120 個の甘さと固さ(10 点満点)を描いた人工的なデータと、$k = 3$ 個の代表点(セントロイド(centroid)、代表ベクトル)である。代表点は、データの中から 3 個を選んで置いた。k-means クラスタリング(k-means clustering)では、各個体をどれか 1 つの群(クラスター)に入れ、その群の代表点で近似する。図 3 (b) の色は各個体を入れた群、線は個体から代表点への近似の誤差である。主成分分析では各点を直線の上の点で近似したが、ここでは k 個の代表点のどれかで近似する。

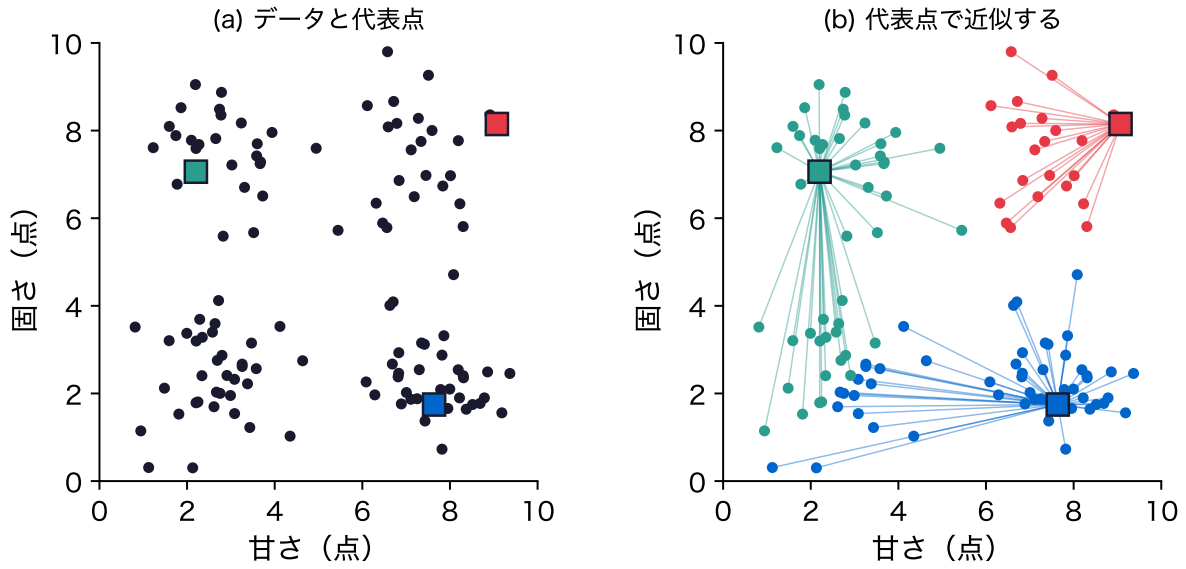


図 3: アイスクリーム 120 個の甘さと固さ(人工データ)。(a) データと $k = 3$ の代表点(■)、(b) 各個体を 1 つの群に入れ、その群の代表点で近似したもの。線が近似の誤差

行列で書けば、データ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ は、所属を表す $\mathbf{G} \in \{0, 1\}^{n \times k}$ と、代表点を行に並べた $\mathbf{C} = [\boldsymbol{c}_1, \ldots, \boldsymbol{c}_k]^\top \in \mathbb{R}^{k \times p}$ の積で近似される(図 4)。第 1 回の「データ＝モデル＋誤差」の形に書けば

$$\mathbf{X} = \mathbf{GC} + \mathbf{E} \tag{1}$$

である。$\mathbf{G}$ の第 i 行は 1 が立った列だけで $\mathbf{C}$ の 1 行を拾うので、$\mathbf{GC}$ の第 i 行は、個体 i が入った群の代表点になる(第 8 回)。主成分分析のモデル $\mathbf{FA}^\top$ と同じく、$\mathbf{GC}$ も未知の行列どうしの積である。ただし $\mathbf{G}$ の成分は 0 か 1 に限られる。

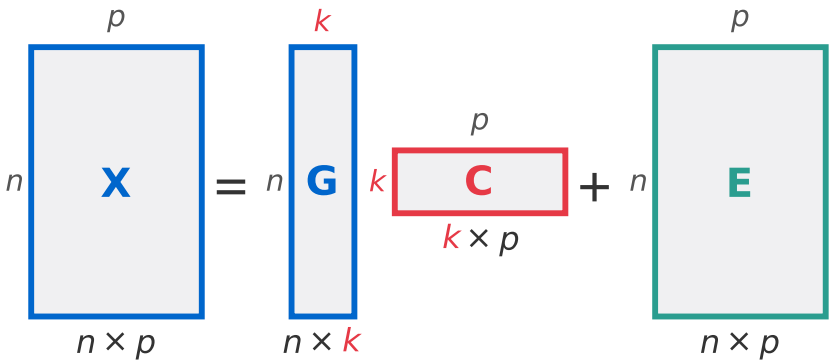


図 4: k-means のモデルの型(概念図)。$n \times p$ の $\mathbf{X}$ を、$n \times k$ の $\mathbf{G}$ と $k \times p$ の $\mathbf{C}$ の積と誤差 $\mathbf{E}$ に分ける

目的関数とメンバーシップ関数

(1) 式の誤差の大きさを、スカラー・ベクトル・行列の順に書く。そのために、所属を数で表す。個体 i がクラスター q に所属するとき 1、しないとき 0 をとる

$$g_{iq} = \begin{cases} 1 & \text{個体 } i \text{ がクラスター } q \text{ に所属する} \\ 0 & \text{個体 } i \text{ がクラスター } q \text{ に所属しない} \end{cases} \tag{2}$$

をメンバーシップ関数(membership function)と呼ぶ(指示関数と呼ぶこともある)。k-means では 1 つの個体が複数のクラスターに所属することは許されないので、任意の i について制約

$$\sum_{q=1}^{k} g_{iq} = 1 \tag{3}$$

が成り立つ。第 8 回で行 i の群として書いた $q(i)$ は、$g_{iq} = 1$ となるただ 1 つの q である。

まず 1 マスずつ書く。個体 i の第 j 変数 x_{ij} を、所属する群の代表点の第 j 成分 c_{qj} で近似するので、目的関数は

$$J = \sum_{i=1}^{n} \sum_{q=1}^{k} g_{iq} \sum_{j=1}^{p} (x_{ij} - c_{qj})^2 \tag{4}$$

である。$g_{iq} = 0$ の項は消えるので、行 i からは所属する群 $q(i)$ の項だけが残り、第 8 回の $\sum_i \sum_j (x_{ij} - c_{q(i)j})^2$ と同じ値になる。内側の j についての和は、個体 i のデータベクトル $\tilde{\boldsymbol{x}}_i \in \mathbb{R}^p$ と代表点 $\boldsymbol{c}_q \in \mathbb{R}^p$ のユークリッド距離の二乗であるから

$$J = \sum_{i=1}^{n} \sum_{q=1}^{k} g_{iq} \, \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2 \tag{5}$$

と書ける。$p = 1$ なら距離の二乗は $(x_i - c_q)^2$ であり、(4) 式の内側の和は 1 項だけになる。

最後に行列で書く。g_{iq} を (i, q) 成分とする $\mathbf{G} \in \{0, 1\}^{n \times k}$ をメンバーシップ行列（指示行列）と呼ぶ（定義 1）。$\mathbf{GC}$ の (i, j) 成分 $\sum_q g_{iq} c_{qj}$ では、(3) 式により、1 が立った q の c_{qj} だけが残る。同じ理由で $\sum_q g_{iq}(x_{ij} - c_{qj})^2 = (x_{ij} - \sum_q g_{iq} c_{qj})^2$ であるから、(4) 式は $\mathbf{X} - \mathbf{GC}$ の全マスの二乗和、すなわち

$$J(\mathbf{G}, \mathbf{C}) = \|\mathbf{X} - \mathbf{GC}\|_F^2 \tag{6}$$

に等しい。たとえば 7 個体を 3 つのクラスターに分ける。個体 1〜3 をクラスター 1 に、個体 4・5 をクラスター 2 に、個体 6・7 をクラスター 3 に入れると

$$\mathbf{G} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix} \tag{7}$$

である。制約 (3) 式は、各行の和が 1 であることを表す。$\mathbf{1}_k$ を k 個の 1 を並べたベクトルとすると

$$\mathbf{G}\mathbf{1}_k = \mathbf{1}_n \tag{8}$$

と書ける。(7) 式はこれを満たしている。

定義 1 (メンバーシップ行列)**.** 個体 i がクラスター q に所属するとき 1、しないとき 0 をとる g_{iq} をメンバーシップ関数、g_{iq} を並べた $n \times k$ の行列 $\mathbf{G}$ をメンバーシップ行列と呼ぶ。各個体はちょうど 1 つのクラスターに所属し、$\mathbf{G}\mathbf{1}_k = \mathbf{1}_n$ を満たす。

定義 2 (k-means クラスタリング)**.** データ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ とクラスター数 k が与えられたとき、$\mathbf{G}\mathbf{1}_k = \mathbf{1}_n$ を満たすメンバーシップ行列 $\mathbf{G}$ とセントロイド行列 $\mathbf{C} \in \mathbb{R}^{k \times p}$ について、目的関数 (6) 式を最小にすることを k-means クラスタリングという。

交互最小二乗法

(6) 式を最小にする $\mathbf{G}$ と $\mathbf{C}$ を一度に求めることはできない。主成分分析と同じく、未知は 2 つの行列の積になっている。そのうえ $\mathbf{G}$ の成分は 0 か 1 に限られるので、$\mathbf{G}$ について微分して 0 とおくことができない。n 個の個体を k 個のクラスターに入れる入れ方は k^n 通りある。卸売の顧客 440 件を 2 つに分けるだけでも 2 の

440 乗、およそ 10 の 132 乗通りになるので、すべて試すこともできない。主成分分析では $\mathbf{F}$ が連続な値をとれたので、特異値分解 1 回で答えが得られた（第 9 回）。k-means にはそのような近道が無い。

そこで、交互最小二乗法（alternating least squares）を使う（図 5）。$\mathbf{C}$ を固定して $\mathbf{G}$ を更新し、次に $\mathbf{G}$ を固定して $\mathbf{C}$ を更新する。どちらの更新も、固定したもののもとで目的関数を最小にするので、目的関数は更新のたびに下がるか変わらない。$\mathbf{G}$ の更新は場合分けで、$\mathbf{C}$ の更新は微分で求める。後者を行列のまま書くために、次節で道具をそろえる。公園に置いたキッチンカーにたとえると、客がそれぞれ一番近い車へ行くのが $\mathbf{G}$ の更新、車が自分の客の真ん中へ移るのが $\mathbf{C}$ の更新である。誰も車を変えなくなれば、車も動かなくなる。

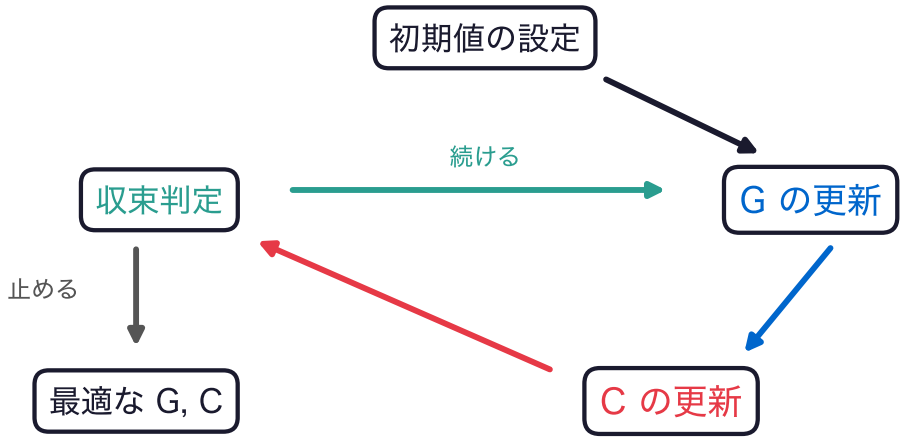


図 5: k-means の交互最小二乗法の概要図（概念図）

道具：群の人数と和

$\mathbf{C}$ の更新を行列のまま書くための道具を用意する。

1 つ目は $\mathbf{G}^\top\mathbf{G}$ である。$k \times n$ の $\mathbf{G}^\top$ と $n \times k$ の $\mathbf{G}$ の積なので、$k \times k$ の正方行列になる。その (q, l) 成分は $\sum_i g_{iq} g_{il}$ である。(3) 式により 1 つの行には 1 が 1 つしかないので、$q \neq l$ なら $g_{iq} g_{il}$ はどの行でも 0 になる。$q = l$ なら $g_{iq}^2 = g_{iq}$ であるから

$$\mathbf{G}^\top\mathbf{G} = \mathrm{diag}(n_1, \ldots, n_k), \qquad n_q = \sum_{i=1}^{n} g_{iq} \tag{9}$$

となる。n_q はクラスター q に入った個体の数で、(7) 式の例では $\mathbf{G}^\top\mathbf{G} = \mathrm{diag}(3, 2, 2)$ である。どのクラスターにも 1 個体以上入っていれば、$\mathbf{G}^\top\mathbf{G}$ は対角が正の対角行列である。その逆行列は、対角を逆数にしたものになる。空のクラスターがあると対角に 0 が現れ、第 3 回で見た正則でない行列になる。

2 つ目は $\mathbf{G}^\top\mathbf{X}$ である。$k \times p$ の行列で、$\mathbf{C}$ と同じ大きさをもつ。その (q, j) 成分は

$$(\mathbf{G}^\top \mathbf{X})_{qj} = \sum_{i=1}^{n} g_{iq}\, x_{ij} \tag{10}$$

で、クラスター q に入った個体の第 j 変数を足したものである。$\mathbf{G}^\top \mathbf{X}$ の第 q 行は、クラスター q に入った行 $\tilde{\boldsymbol{x}}_i^\top$ の和になる。

3 つ目はトレースとその偏微分である。正方行列 $\mathbf{M}$ の対角の和を $\mathrm{tr}(\mathbf{M}) = \sum_q m_{qq}$ と書き、トレースと呼んだ(第 4 回)。転置しても対角は変わらないので $\mathrm{tr}(\mathbf{M}^\top) = \mathrm{tr}(\mathbf{M})$ であり、$\mathrm{tr}(\mathbf{E}^\top \mathbf{E})$ は $\mathbf{E}$ の全マスの二乗和 $\|\mathbf{E}\|_F^2$ になる。

行列 $\mathbf{B}$ についての偏微分 $\partial f / \partial \mathbf{B}$ は、$\mathbf{B}$ の各マス b_{qj} で f を偏微分し、$\mathbf{B}$ と同じ形に並べた行列とする。$\mathbf{B}$ と $\mathbf{M}$ が同じ大きさなら、$\mathrm{tr}(\mathbf{B}^\top \mathbf{M}) = \sum_q \sum_j b_{qj} m_{qj}$ であり、これを b_{qj} で偏微分すると m_{qj} が残る。したがって

$$\frac{\partial \mathrm{tr}(\mathbf{B}^\top \mathbf{M})}{\partial \mathbf{B}} = \mathbf{M} \tag{11}$$

である。もう 1 つ、対称な行列 $\mathbf{S}$ を挟んだ二次の形について

$$\frac{\partial \mathrm{tr}(\mathbf{B}^\top \mathbf{S} \mathbf{B})}{\partial \mathbf{B}} = 2\mathbf{S}\mathbf{B} \tag{12}$$

を使う。$\mathrm{tr}(\mathbf{B}^\top \mathbf{S} \mathbf{B}) = \sum_j \sum_q \sum_l s_{ql} b_{qj} b_{lj}$ を b_{qj} で偏微分すると、$\mathbf{S}$ が対称なので $\sum_l s_{ql} b_{lj} + \sum_l s_{lq} b_{lj} = 2(\mathbf{S}\mathbf{B})_{qj}$ となる。これを $\mathbf{B}$ と同じ形に並べたものが (12) 式である。1×1 なら $d(sb^2)/db = 2sb$ であり、1 変数の微分と同じ形をしている。

G の更新

まず $\mathbf{C}$ を固定して $\mathbf{G}$ を更新する。1 つの個体に注目する。図 6 には、図 3 と同じデータの真ん中あたりの個体 104 と、3 つの代表点を描いた。個体 104 のデータベクトルは $\tilde{\boldsymbol{x}}_i = (5.45, 5.72)$である。3 つの代表点との距離の二乗 $\|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2$ は、それぞれ 19.03、20.62、12.32 となる。

(5) 式のうちこの個体の項は $\sum_q g_{iq} \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2$ である。制約 (3) 式のもとで選べるのは、3 つの g_{iq} のどれを 1 にするかだけである。1 にした列の距離の二乗だけが残り、残りの距離は無視される。そこで、距離の二乗が最も小さいクラスター 3 を選び、その列だけを 1 にすればよい。選んだ列を q^* と書けば

$$\sum_{q=1}^{3} g_{iq} \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2 = \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_{q^*}\|_2^2$$

となる。g_{iq} は 0 か 1 しかとらないので、微分して 0 とおく方法は使えない。このように場合分けで求めるしかない。

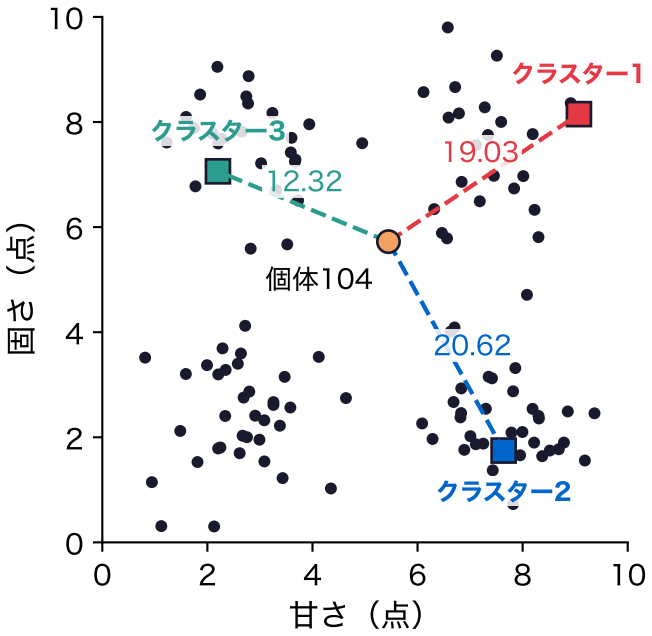


図 6: 真ん中あたりの 1 個(橙)と 3 つの代表点(人工データ)。数字は距離の二乗

同じことはすべての個体について言える。$d_{iq} = \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2$ とおくと、$\mathbf{C}$ を固定したときの目的関数は $J = \sum_i (\sum_q g_{iq} d_{iq})$ となる。括弧の中は、行 i の $g_{i1}, \ldots, g_{ik}$ だけを含む。行ごとに別々に最小にすればよいので、$\mathbf{G}$ の更新式は

$$\hat{g}_{iq} = \begin{cases} 1 & (q = \operatorname{argmin}_{1 \le l \le k} \|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_l\|_2^2) \\ 0 & (\text{それ以外}) \end{cases} \tag{13}$$

となる。つまり、各個体を最も近い代表点のクラスターに入れる。図 3 (b) の色は、はじめに置いた代表点のもとで、この更新を 120 個すべてに行った結果である。

計算の手順として行列で書くために、距離の二乗を $d_{iq} = \|\tilde{\boldsymbol{x}}_i\|_2^2 - 2\tilde{\boldsymbol{x}}_i^\top \boldsymbol{c}_q + \|\boldsymbol{c}_q\|_2^2$ と展開する。$a_i = \|\tilde{\boldsymbol{x}}_i\|_2^2$、$b_q = \|\boldsymbol{c}_q\|_2^2$ を並べたベクトルを $\boldsymbol{a} \in \mathbb{R}^n$、$\boldsymbol{b} \in \mathbb{R}^k$ とすれば、d_{iq} を並べた $n \times k$ の行列は

$$\mathbf{D} = \boldsymbol{a}\mathbf{1}_k^\top - 2\mathbf{X}\mathbf{C}^\top + \mathbf{1}_n \boldsymbol{b}^\top \tag{14}$$

である。(13) 式は、$\mathbf{D}$ の各行で最も小さい列に 1 を置き、残りを 0 とすることにあたる。第 1 項は行の中で一定なので、どの列が最小かは $-2\mathbf{X}\mathbf{C}^\top + \mathbf{1}_n \boldsymbol{b}^\top$ だけで決まる。主な計算は、$n \times p$ と $p \times k$ の行列の積 $\mathbf{X}\mathbf{C}^\top$ である。

C の更新

次に $\mathbf{G}$ を固定して $\mathbf{C}$ を更新する。スカラーから始める。変数が 1 つ($p=1$)なら、(4) 式のうちクラスター q の代表点 c_q を含むのは $\sum_i g_{iq}(x_i - c_q)^2$ だけで、これは c_q の放物線である。1 変数の微分を 0 とおくと

$$\frac{d}{dc_q}\sum_{i=1}^{n} g_{iq}(x_i - c_q)^2 = -2\sum_{i=1}^{n} g_{iq}(x_i - c_q) = 0 \quad \Longrightarrow \quad \hat{c}_q = \frac{\sum_i g_{iq} x_i}{\sum_i g_{iq}} \tag{15}$$

を得る。分母はクラスター q の個体の数、分子はその和であるから、$\hat{c}_q$ はクラスター q の平均である。

変数が p 個なら、(5) 式の $\boldsymbol{c}_q$ を含む項 $\sum_i g_{iq}\|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2$ をベクトル $\boldsymbol{c}_q$ で偏微分し、勾配を 0 とおく。

$$\begin{aligned}\frac{\partial}{\partial \boldsymbol{c}_q}\sum_{i=1}^{n} g_{iq}\|\tilde{\boldsymbol{x}}_i - \boldsymbol{c}_q\|_2^2 &= \frac{\partial}{\partial \boldsymbol{c}_q}\sum_{i=1}^{n} g_{iq}(\tilde{\boldsymbol{x}}_i^\top \tilde{\boldsymbol{x}}_i - 2\tilde{\boldsymbol{x}}_i^\top \boldsymbol{c}_q + \boldsymbol{c}_q^\top \boldsymbol{c}_q) \\ &= \sum_{i=1}^{n} g_{iq}(-2\tilde{\boldsymbol{x}}_i + 2\boldsymbol{c}_q) = -2\Big(\sum_{i=1}^{n} g_{iq}\tilde{\boldsymbol{x}}_i\Big) + 2\boldsymbol{c}_q\Big(\sum_{i=1}^{n} g_{iq}\Big) = 0_p\end{aligned} \tag{16}$$

したがって $\boldsymbol{c}_q$ の更新式は

$$\hat{\boldsymbol{c}}_q = \frac{\sum_{i=1}^{n} g_{iq}\tilde{\boldsymbol{x}}_i}{\sum_{i=1}^{n} g_{iq}} \tag{17}$$

である。これはクラスター q に入った個体のデータベクトルの平均で、$p=1$ なら (15) 式に戻る。

同じ更新を行列のまま導く。二乗和をトレースで表すと

$$J(\mathbf{C} \mid \mathbf{G}) = \operatorname{tr}((\mathbf{X} - \mathbf{G}\mathbf{C})^\top(\mathbf{X} - \mathbf{G}\mathbf{C})) = \operatorname{tr}(\mathbf{X}^\top\mathbf{X}) - 2\operatorname{tr}(\mathbf{C}^\top\mathbf{G}^\top\mathbf{X}) + \operatorname{tr}(\mathbf{C}^\top\mathbf{G}^\top\mathbf{G}\mathbf{C}) \tag{18}$$

と展開できる。交差項は $\operatorname{tr}(\mathbf{X}^\top\mathbf{G}\mathbf{C}) = \operatorname{tr}(\mathbf{C}^\top\mathbf{G}^\top\mathbf{X})$(転置)で 1 つにまとめた。第 2 項に (11) 式を、第 3 項に (12) 式を $\mathbf{S} = \mathbf{G}^\top\mathbf{G}$ として使うと

$$\frac{\partial J}{\partial \mathbf{C}} = -2\mathbf{G}^\top\mathbf{X} + 2\mathbf{G}^\top\mathbf{G}\,\mathbf{C} = \mathbf{O} \quad \Longrightarrow \quad \mathbf{G}^\top\mathbf{G}\,\mathbf{C} = \mathbf{G}^\top\mathbf{X} \tag{19}$$

を得る。これは第 1 回の正規方程式 $\mathbf{X}^\top\mathbf{X}\boldsymbol{\beta} = \mathbf{X}^\top\boldsymbol{y}$ の $\mathbf{X}$ を $\mathbf{G}$ に、$\boldsymbol{y}$ を $\mathbf{X}$ に替えた形である。$\mathbf{G}$ を固定すると、(1) 式は所属の 0/1 の列を説明変数にして $\mathbf{X}$ の各列を回帰するモデルになり、$\mathbf{C}$ はその係数にあたる。どのクラスターにも個体が入っていれば $\mathbf{G}^\top\mathbf{G}$ は正則なので

$$\hat{\mathbf{C}} = (\mathbf{G}^\top\mathbf{G})^{-1}\mathbf{G}^\top\mathbf{X} = \operatorname{diag}\Big(\frac{1}{n_1}, \ldots, \frac{1}{n_k}\Big)\mathbf{G}^\top\mathbf{X} \tag{20}$$

となる。2 つ目の等号は (9) 式による。(10) 式により、第 q 行はクラスター q の行の和を n_q で割ったものになり、(17) 式の $\hat{\boldsymbol{c}}_q^\top$ と一致する。行列で書いても、クラスターごとの平均を縦に積んだだけである。図 7 は、図 3 (b) の群を固定して $\mathbf{C}$ を 1 回更新したところで、代表点はそれぞれの群の平均へ動いた。

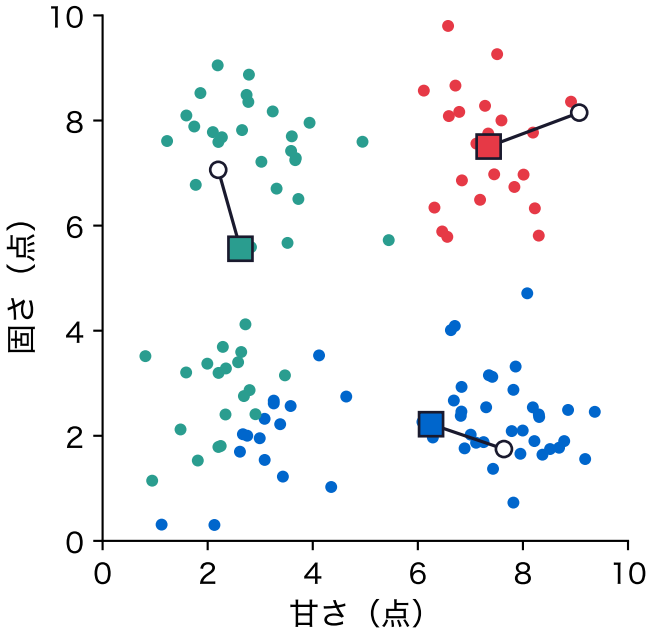


図 7: 図 3 (b) の群を固定して $\mathbf{C}$ を 1 回更新したもの（人工データ）。白丸が更新の前の代表点、■が群の平均

計算の手順

2 つの更新を、実際に計算する行列の形で手順にまとめる。

1. 列の目盛りをそろえたデータ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ と、クラスター数 k を用意する
2. 初期値を置く。$\mathbf{C}$ は観測されていないが既知として与える必要があるので、$\mathbf{X}$ の行から k 行を無作為に選んで $\mathbf{C} \in \mathbb{R}^{k \times p}$ とする
3. $\mathbf{C}$ を固定して、(14) 式の $\mathbf{D}$ を作り、(13) 式により各行で最小の列に 1、残りに 0 を置いて $\mathbf{G}$ とする
4. $\mathbf{G}$ を固定して、(20) 式により $\mathbf{C} \leftarrow (\mathbf{G}^\top \mathbf{G})^{-1} \mathbf{G}^\top \mathbf{X}$ とする
5. $\mathbf{G}$ が前回と同じなら止める。そうでなければ 3 に戻る
6. 2〜5 を R 通りの初期値で行い、$J = \|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2$ が最も小さい答えを採る

1 回の反復で行うのは、行列の積 $\mathbf{X}\mathbf{C}^\top$ と $\mathbf{G}^\top \mathbf{X}$、各行の最小の列を探すこと、そして対角行列 $\mathbf{G}^\top \mathbf{G}$ の逆数である。主成分分析の手順（特異値分解 1 回）には無かったのが、手順 6 のやり直しである。なぜ要るか、手順 1 で目盛りをそろえるのはなぜかを、次節で見る。

理論の帰結

交互最小二乗法の 2 つの更新から、いくつかのことが言える。

第 1 に、目的関数は更新のたびに下がるか変わらない。$\mathbf{G}$ の更新 (13) 式は $\mathbf{C}$ を固定したもとでの最良の $\mathbf{G}$ で、$\mathbf{C}$ の更新 (20) 式は $\mathbf{G}$ を固定したもとでの最良の $\mathbf{C}$ である。どちらも、更新する前の値を候補に含む中から最良を選ぶので、J を上げることはない。図 8 に、図 3 の 120 個で、はじめに置いた 3 つの代表点を初期値として手順を回したときの J の推移を示す。J は 953.5 から始まり、更新のたびに下がって 571.8 で止まった。

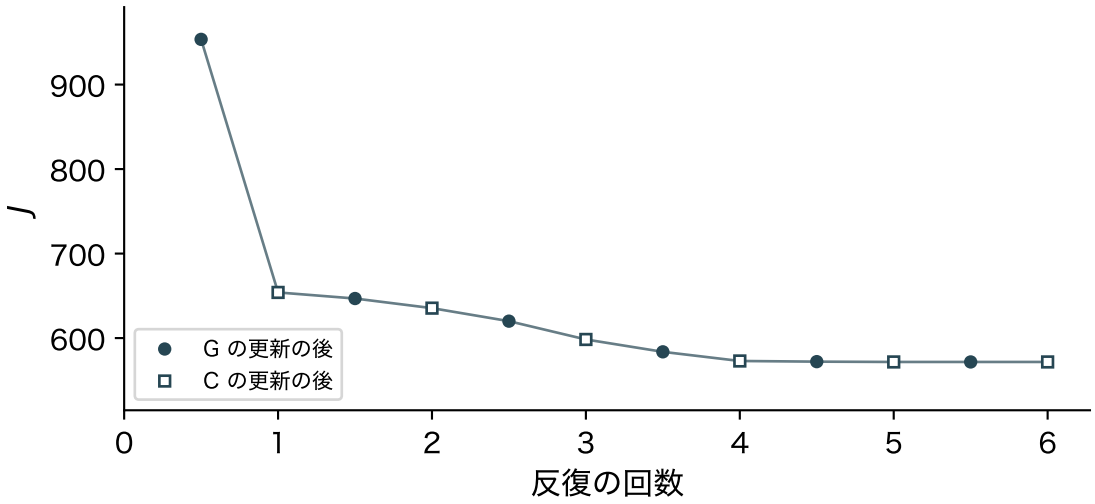


図 8: アイス 120 個の人工データで、はじめに置いた代表点を初期値にしたときの目的関数 J の推移。丸は $\mathbf{G}$ の更新の後、四角は $\mathbf{C}$ の更新の後

第 2 に、手順は有限回で止まる。$\mathbf{G}$ のとりうる値は高々 k^n 通りの有限個である。J が真に下がり続ける限り同じ $\mathbf{G}$ に戻ることはない。そのため、いつかは $\mathbf{G}$ が変わらなくなり、そこで $\mathbf{C}$ も変わらなくなる。この例では 6 回の反復で止まった。図 9 (a) の黒い線は、代表点が初期値(白丸)から動いた道筋である。

第 3 に、止まった先が最良とは限らない。止まった点は、$\mathbf{C}$ を固定しても $\mathbf{G}$ を固定しても、それ以上 J を下げられない点にすぎない。図 9 (b) は、同じデータで、$\mathbf{X}$ の行から 3 行を選んだ別の初期値から始めた答えである。その $J = 434.2$ は、(a) の 571.8 より小さい。(a) の答えは、そこから 2 つの更新のどちらを行っても動かないが、目的関数を最小にしてはいない。このような点を局所解と呼ぶ(定義 3)。k-means では、得られた解が真の解であるという保証は無い。これは目的関数の非凸性と関係している(Jain & Kar, 2017)。2 つの答えを比べるときは、群の番号の付け替え(第 8 回)を除いて、所属が違う個体を数える。(a) と (b) では、番号をそろえても 26 個の所属が違う。

そこで実際には、複数の初期値から解を求め、その中で目的関数が最も小さいものを採用する。これをランダムスタートと呼ぶ(定義 4)。図 10 は、$\mathbf{X}$ の行から 3 行を選ぶ初期値を 300 通り試し、着いた J を並べたものである。着いた先の J は 6 通りに分かれ、最小の 434.2 に着いたのは 198 回であった。

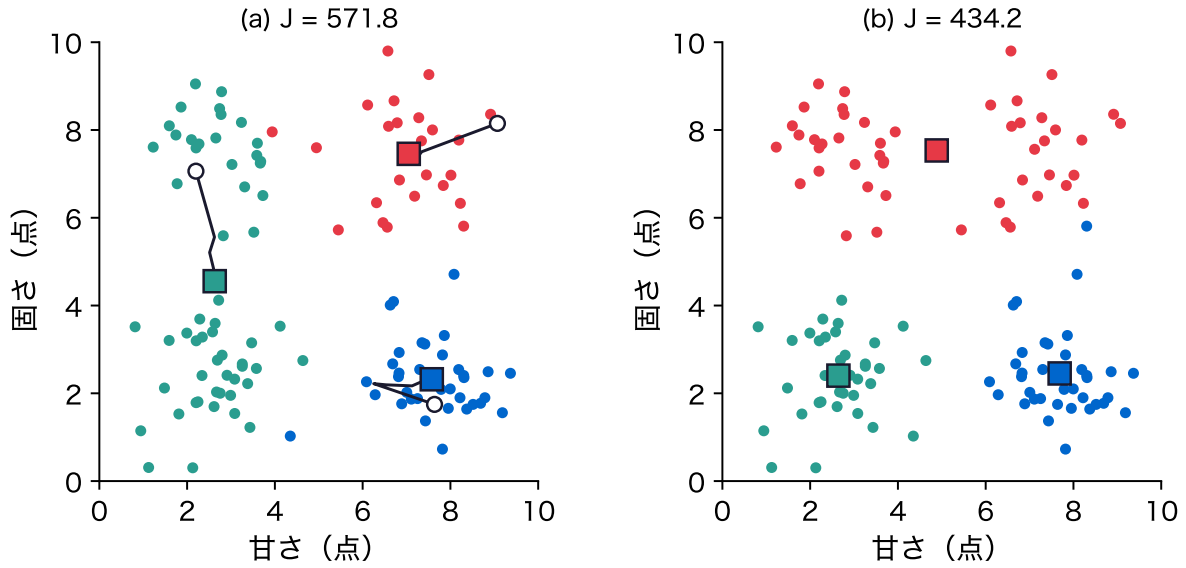


図 9: 同じアイス 120 個を $k = 3$ に分けた 2 つの答え（人工データ）。(a) はじめに置いた代表点を初期値にしたもの（黒い線は代表点の道筋、白丸は初期値）、(b) 別の初期値から着いたもの

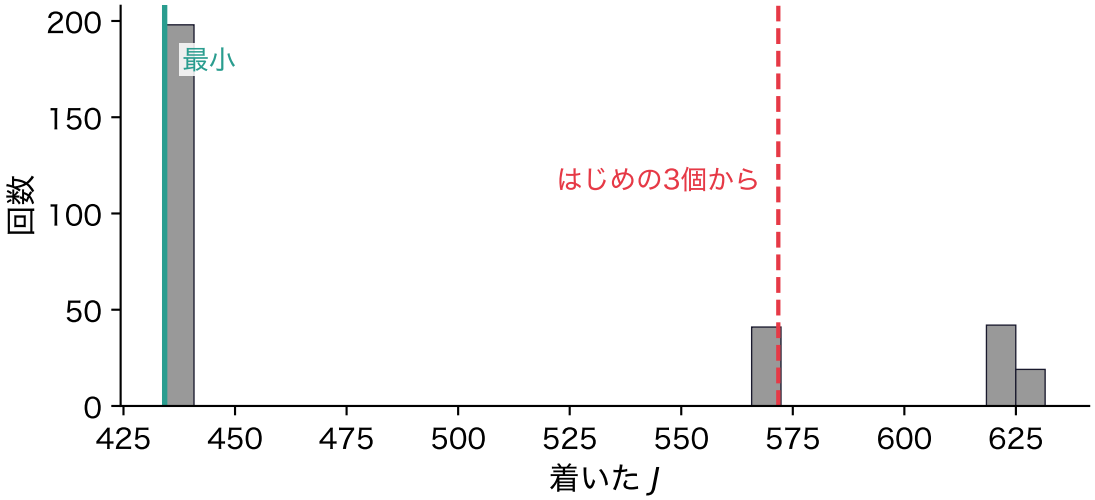


図 10: アイス 120 個の人工データ、$k = 3$。初期値を変えて着いた J の分布。緑の線が最小、赤の破線がはじめに置いた代表点から着いた値

何回やり直せばよいかは、次のように考える。1 回の初期値で最小に着く割合を θ とし、初期値を独立に R 回選ぶ。R 回とも最小に着かない見込みは $(1-\theta)^R$ なので、少なくとも 1 回は着く見込みは

$$1-(1-\theta)^R \tag{21}$$

である。この例では $\theta = 0.66$ で、$R = 3$ なら 96.1%、$R = 5$ なら 99.5% になる。どの 1 回も最小に着くとは限らないが、やり直すほど見込みは 1 に近づく。ただし、最小に着いたことを確かめる手立ては無く、試した中で最小であることしか言えない。θ もデータと k によって変わり、前もっては分からない。

第 4 に、2 つのクラスターの境目は直線になる。(13) 式で個体 $\tilde{\boldsymbol{x}}$ がクラスター 1 とクラスター 2 のどちらに入るかの境目は、$\|\tilde{\boldsymbol{x}} - \boldsymbol{c}_1\|_2^2 = \|\tilde{\boldsymbol{x}} - \boldsymbol{c}_2\|_2^2$ である。これを展開すると、$\|\tilde{\boldsymbol{x}}\|_2^2$ が両辺で消えて

$$2(\boldsymbol{c}_2 - \boldsymbol{c}_1)^\top \tilde{\boldsymbol{x}} = \|\boldsymbol{c}_2\|_2^2 - \|\boldsymbol{c}_1\|_2^2 \tag{22}$$

となる。$\tilde{\boldsymbol{x}}$ について 1 次の式なので、境目は直線(p 変数なら超平面)になる。この直線は、2 つの代表点を結ぶ線分の垂直二等分線である。図 11 のように、平面は代表点ごとの凸な領域に切り分けられる。そして $\mathbf{G}$ は 0 か 1 なので、境目のすぐそばの個体も、どちらか一方の群に完全に入る。

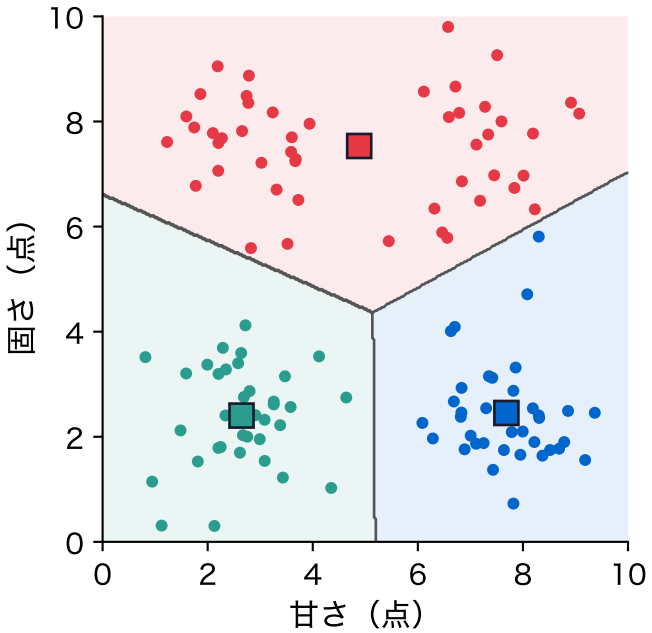


図 11: 図 9 (b) の答えで、平面の各点を最も近い代表点の群に塗り分けたもの(人工データ)。灰色の線が境目

第 5 に、答えは列の目盛りで変わる。(4) 式の和の順を入れ替えると

$$J = \sum_{j=1}^{p} \sum_{i=1}^{n} \left(x_{ij} - c_{q(i)j}\right)^2 \tag{23}$$

であり、J は列ごとの誤差の二乗和を足したものである。どの列も同じ重みで足されるので、列 j を a 倍すると、その列の誤差は a^2 倍に数えられる。図 12 (b) は、図 3 と同じアイスの固さだけを 5 倍(50 点満点)にして分け、元の目盛りの上に描いたものである。(a) とは違い、固さの向きに切る答えになった。元の目盛りで測った J は 826.8 で、(a) の 434.2 より大きい。手順 1 で列の目盛りをそろえるのはこのためで、第 2 回の標準化はその 1 つの方法である。

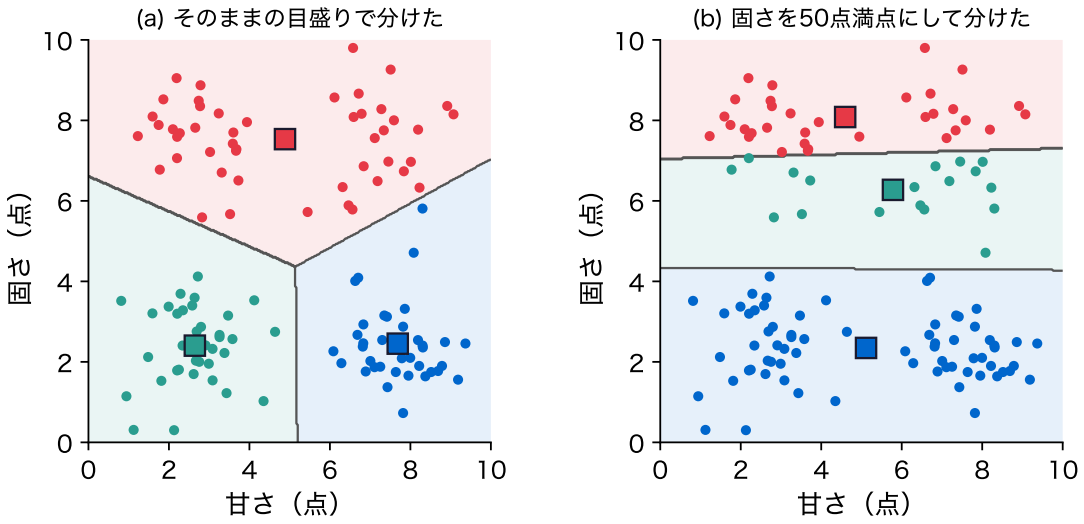


図 12: 同じアイス 120 個の人工データを $k = 3$ に分けた 2 つの答え。(a) そのままの目盛りで分けたもの、(b) 固さを 50 点満点にして分け、元の目盛りの上に描いたもの。灰色の線が境目

目盛りのそろえ方は、何を「近い」とみなすかで選ぶ。差ではなく何倍かで比べたいときは、列を対数にしてから使う。$\log a - \log b = \log(a/b)$ なので、対数の差は比だけで決まる。たとえばコーヒー豆の 100g と 200g、1kg と 2kg は、差は 100g と 1kg で違うが、どちらも 2 倍であり、対数の差はどちらも $\log 2$ になる。

表 1 に、第 9・10 回の主成分分析と k-means を並べた。どちらも、データ行列を 2 つの未知の行列の積で近似する最小二乗法である。違いは $\mathbf{F}$ が連続な値をとれるのに対し、$\mathbf{G}$ が 0/1 に限られることにある。主成分分析は特異値分解 1 回で最小の答えが得られ、上位 Q 本が最小であることも Eckart–Young の定理で保証された。一方、k-means は交互に解くしかなく、止まった先が最小である保証も無い。k-means は、反復計算とランダムスタートが要る問題の代表例である。なお、主成分分析で軸を回す $\mathbf{R}$ が決まらなかったように、k-means でも群の番号の付け替えは決まらない(第 8 回)。これは局所解とは別の話で、番号を付け替えても J は変わらない。

表 1: 主成分分析と k-means の解き方の比較

	主成分分析(第 9・10 回)	k-means（本章）
近似	$\mathbf{FA}^\top$（$\mathbf{F}$ は連続）	$\mathbf{GC}$（$\mathbf{G}$ は 0/1）
解き方	特異値分解 1 回	交互最小二乗法(最も近い代表点、群の平均)

	主成分分析（第 9・10 回）	k-means（本章）
答え	上位 Q 本で最小（Eckart–Young）	止まった先が最小とは限らない（局所解）
やり直し	要らない	要る（ランダムスタート）
決まらないもの	軸の回転 $\mathbf{R}$	群の番号の付け替え（第 8 回）

定義 3 (局所解)**.** 交互最小二乗法が止まった点のように、そこから更新しても目的関数が下がらないが、目的関数を最小にするとは限らない点を局所解と呼ぶ。

定義 4 (ランダムスタート)**.** 複数の初期値から交互最小二乗法を行い、得られた答えのうち目的関数が最も小さいものを採用することを、ランダムスタートと呼ぶ。

地図の中の k-means

表 2 に、第 8 回で並べた 3 つの目的関数と解き方をまとめた。推定法はどれも最小二乗法である。線形回帰は正規方程式を 1 回解けば済み、主成分分析は特異値分解 1 回で解けた。k-means は交互最小二乗法で解き、初期値を変えてやり直す必要がある。

表 2: 3 つの目的関数と解き方

モデル	近似する相手	目的関数	解き方	回
線形回帰	y	$\|\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2$	正規方程式を 1 回解く	第 1 回
主成分分析	$\mathbf{X}$	$\|\mathbf{X} - \mathbf{F}\mathbf{A}^\top\|_F^2$	特異値分解を 1 回	第 9・10 回
k-means	$\mathbf{X}$	$\|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2$	交互に解く	第 11 回

第 II 部　実データ解析

卸売の顧客と手続き

第 II 部では、第 I 部の理論を卸売の顧客のデータで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部では、J が更新のたびに下がって有限回で止まること、そして止まる先が初期値しだいであること（局所解）を見た。そこから 2 つの予想が立つ。1 つ目に、卸売の顧客でも、初期値を変えると着く先が変わるはずである。2 つ目に、アイスの人工データでは 1 回の初期値で最小に着く割合が $\theta = 0.66$ だった。同じように、数回やり直せば最小に着くはずである。

データは UCI Machine Learning Repository の Wholesale customers（Cardoso, 2014。CC BY 4.0）である。ポルトガルの卸売業者の顧客 440 件について、生鮮・乳製品・食料品・冷凍品・洗剤と紙製品・総菜 の 6 品目の年間購入額（通貨の単位）を記録している。顧客の業態（飲食店 298 件、小売 142 件）も記録されている。だが業態は $\mathbf{G}$ と $\mathbf{C}$ を求めるのには使わず、群を読むときの突き合わせにだけ使う。

購入額は右に裾が長い。表 3 のとおり、どの品目でも最大の客は中央値の数十倍を買っており、品目によって金額の桁も違う。k-means の目的関数は (23) 式のとおり列ごとの誤差の二乗和を足す。そのまま使えば、大口の客と金額の大きい品目が J を左右する。そこで、6 列をそれぞれ対数にしてから標準化したものをデータ行列 $\mathbf{X}$ とした（図 13）。対数にすると、購入額の差は「何倍か」で測られ、大口の客も中央値から数倍の位置に収まる。標準化すると、品目ごとの散らばりがそろう（第 2 回）。この 2 つの判断が妥当だったかは、落とし穴の節で、しなかった場合と比べて確かめる。

表 3: 卸売の顧客 440 件の年間購入額

品目	生鮮	乳製品	食料品	冷凍品	洗剤と紙製品	総菜
中央値	8,504	3,627	4,756	1,526	816	966
最大	112,151	73,498	92,780	60,869	40,827	47,943
最大 ÷ 中央値	13	20	20	40	50	50

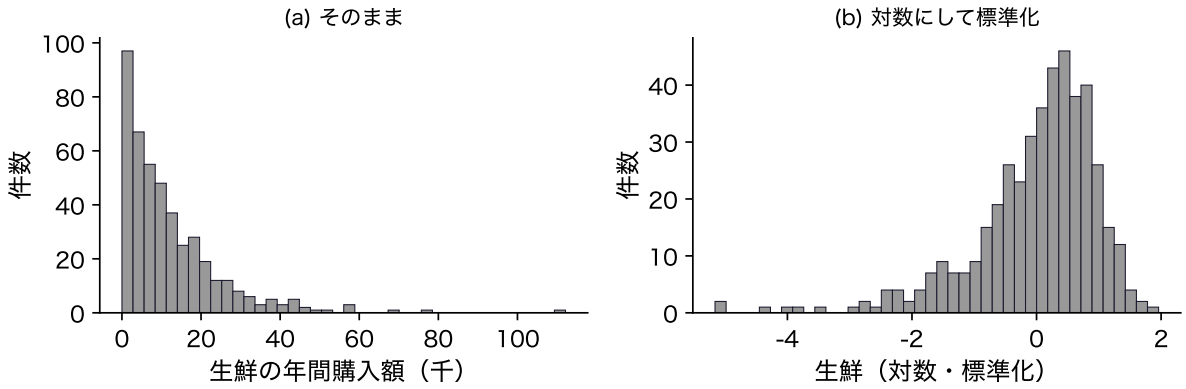


図 13: 卸売の顧客 440 件の生鮮の年間購入額。(a) そのまま、(b) 対数にして標準化したもの

手続きは次のとおりである。I-6 の手順を NumPy の行列計算でそのまま書いた。ランダムスタートの様子を見るため、$k = 2$ と $k = 3$ について、$\mathbf{X}$ の行から k 行を無作為に選ぶ初期値を 100 通りずつ試した。得られた群は、元の購入額の中央値と業態で読んだ。最後に、対数も標準化もしない $\mathbf{X}$ と、標準化だけした $\mathbf{X}$ でも手順を回した。

先に、手順そのものを確かめておく。$k = 2$ で 3 通りの初期値から回すと、J は $\mathbf{G}$ と $\mathbf{C}$ のどちらの更新でも一度も上がらず、8〜17 回の反復で止まった。同じ初期値を scikit-learn の KMeans（Lloyd の方法）に渡すと、J の差は最大 0、所属が違う行は 0 件だった。止まった答えでは、代表点は群ごとの平均に一致し（差は最大 0）、最も近い代表点の群に入っていない行は 0 件である。2 つの更新式を両方とも満たす点で止まっている。

k=2：ほぼ 1 つの谷

1 つ目の予想から確かめる。$k = 2$ で初期値を 100 通り変えて回すと、着いた J は 1,847.98 から 1,848.09 までの 4 通りで、差はごくわずかであった（図 14）。最小と最大の答えで所属が違う行は、番号をそろえて数えると 3 件にすぎない。初期値を変えると着く先が変わるという予想は、$k = 2$ では外れた。

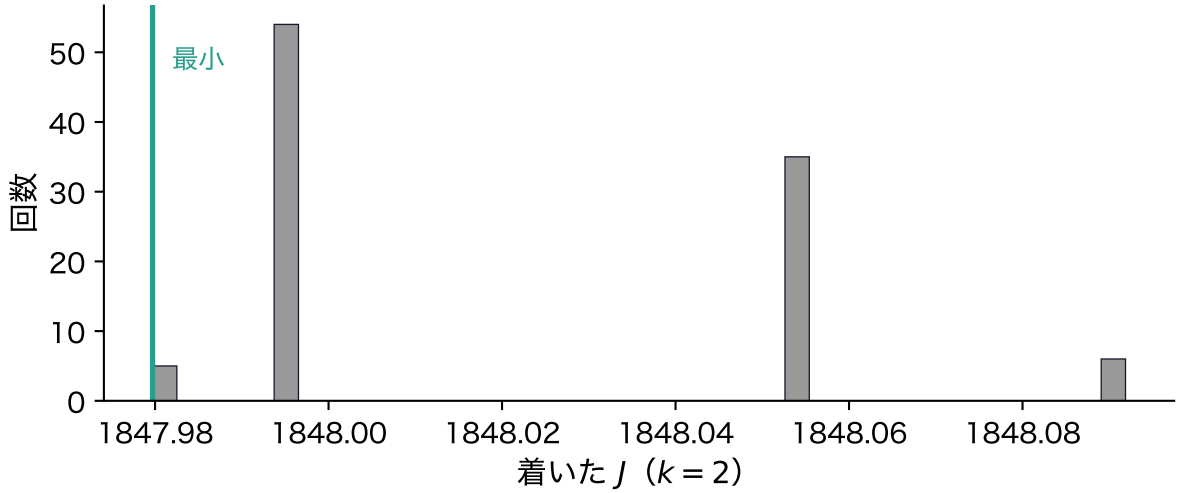


図 14: 卸売の顧客を $k = 2$ に分けたとき、初期値 100 通りから着いた J の分布。緑の線が最小

理由は、点の雲の形にある。図 15 は、J が最小の答えを、食料品と洗剤と紙製品の 2 列の上に描いたものである（描いたのは 6 列のうち 2 列）。点の雲は右上へ細長く伸びており、2 つの群の間に隙間はない。それでも 2 つに切るなら、J を大きく下げられるのは、長い向きを半分に切るときである。第 I 部の帰結のとおり、2 群の境目は垂直二等分線（6 列なら超平面）である。代表点が雲の両端の側に分かれれば、境目は長い向きを横切る。どの初期値から始めても境目はこの位置に来て、境目のそばの数件の所属だけが揺れる。

2 群を購入額で読む

$k = 2$ で J が最小の答えを、元の購入額に戻して読む。表 4 に、群ごとの 6 品目の購入額の中央値と、群に入った顧客のうち小売の割合を示す。群 1（188 件）は乳製品・食料品・洗剤と紙製品を多く買い、群 2（252 件）は生鮮と冷凍品を多く買う。業態は $\mathbf{G}$ と $\mathbf{C}$ を求めるのに使っていない。それでも群 1 の 71% は小売、群 2 の 97% は飲食店であった。第 8 回で品種と突き合わせたのと同じく、番号の付け替えの良いほうで数えると、2 群と業態が重なる割合は 85.9% である。全員を多いほうの業態とみなしたときの 67.7% より高い。買い方だけで分けた群は、店を開く側の業態とおおむね一致した。ただし、k-means は与えた k 個の群を必ず作るので、群があること自体は手順からは言えない。群が業態と重なったのは、データの側にそういう分かれ目があったからである。

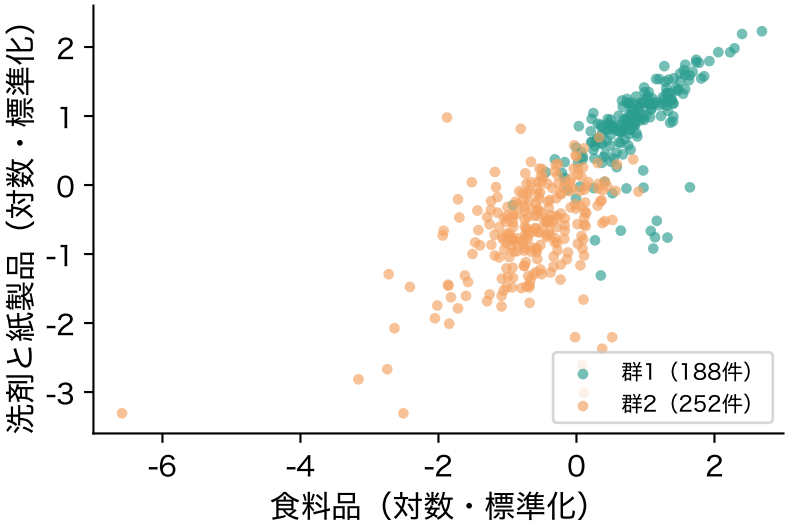


図 15: 卸売の顧客を $k = 2$ に分けた答え（100 通りのうち J が最小）。食料品と洗剤と紙製品の 2 列で描いたもの

表 4: 卸売の顧客を $k = 2$ に分けた答えの、群ごとの購入額の中央値と小売の割合

群	件数	生鮮	乳製品	食料品	冷凍品	洗剤と紙製品	総菜	小売の割合
群 1	188	5,406	7,690	11,527	1,062	4,495	1,388	71%
群 2	252	10,348	1,871	2,406	2,225	328	750	3%

k=3：着く先が分かれる

群の数を $k = 3$ にすると様子が変わる。図 16 は、同じ 100 通りの初期値から着いた J の分布である。着いた先は 41 通りに分かれた。着く先が初期値しだいであることは、$k = 3$ では予想どおりである。最も悪い答えの J は 1,699.6 で、最小の 1,558.0 より大きい。

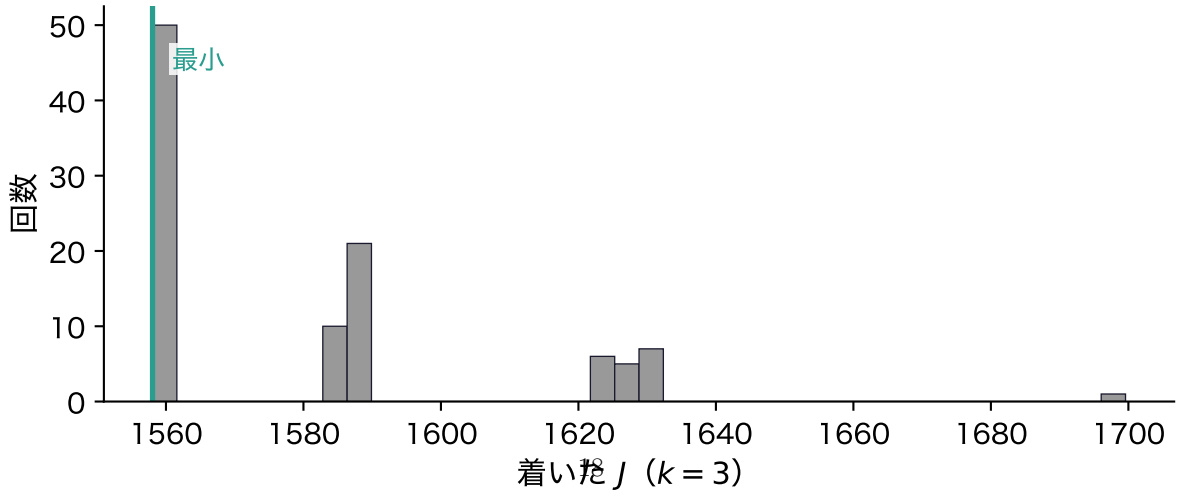


図 16: 卸売の顧客を $k = 3$ に分けたとき、初期値 100 通りから着いた J の分布。緑の線が最小

図 17 は、最小の答え (a) と最も悪い答え (b) を、食料品と生鮮の 2 列の上に描いたものである（描いたのは 6

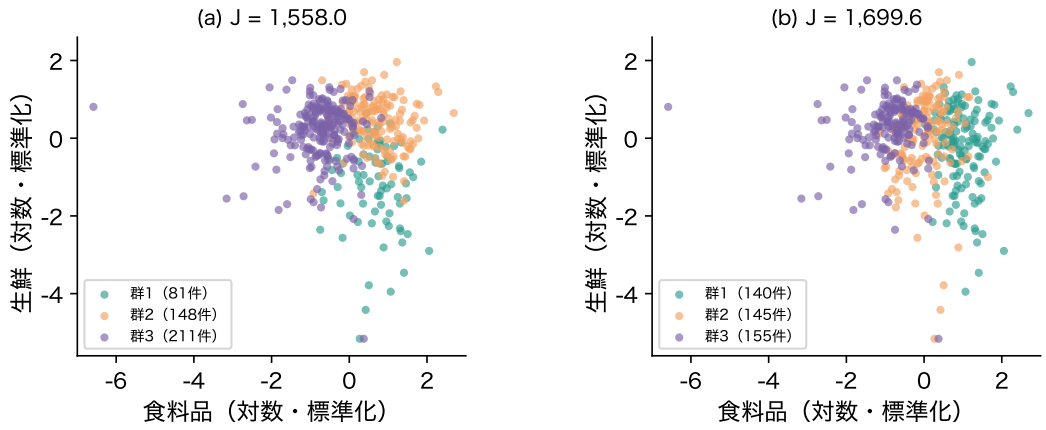


図 17: 卸売の顧客を $k = 3$ に分けた 2 つの答え。(a) 100 通りのうち J が最小、(b) J が最大。群の番号は食料品の購入額の中央値が大きい順

表 5: 初期値の数と、最小の谷に少なくとも 1 回着く見込み（卸売の顧客、$k = 3$）

初期値の数 R	1	10	50	100
最小の谷に 1 回は着く見込み	3.0%	26.3%	78.2%	95.2%

θ が小さい理由は、谷の並び方にある。図 16 の最小のすぐそばには、J の差が 0.04% 以内の谷が 16 つ集まっており、初期値の 50% がそのどれかに着いた。これらの谷は、最小の答えと 1〜9 件の所属が違うだけである。違う行は、どれも 2 つの代表点への距離がほぼ等しい、境目のすぐそばの顧客だった。第 I 部で見たとおり、$\mathbf{G}$ は 0 か 1 なので、境目のそばの個体もどちらか一方の群に完全に入る。440 件の顧客が隙間なく並んでいるので、境目のそばには顧客が多い。その数件を入れ替えた分け方も、2 つの更新をしても動かない点になる。そのため、ほぼ同じ答えが別々の谷として数えられ、最小の 1 つに着く割合が小さくなった。アイスの人工データでは、最小の谷と次の谷の J は 32% 離れていた。最小のそばの谷をまとめて 1 つと見れば、そこに着く割合は 50% であり、5 回やり直せば 97% の見込みで着く。

目盛りを変える

第 I 部の手順 1 で、列の目盛りをそろえたデータ行列を用意した。そろえないとどうなるかを、2 通りに確かめる。

まず、対数も標準化もせず、平均を引いただけの購入額を $k = 2$ に分けた。(23) 式のとおり、目的関数はすべての列の誤差を同じ重みで足す。そのため、金額の大きい列ほど誤差も大きく数えられる。表 6 のとおり、この $\mathbf{X}$ では $\|\mathbf{X}\|_F^2$ の 44.6% を生鮮の 1 列が占め、総菜の列は 2.2% にすぎない（対数にして標準化すれば、どの列も 16.7%）。止まった答えでも、J の 59.8% を生鮮と食料品の 2 列が占めた。群は 375 件と 65 件に分かれた。業態と重なる割合は 59.3% で、全員を飲食店とみなしたときの 67.7% にも届かない。この答えは、買い方ではなく、

金額の大きい 2 品目をどれだけ買うかで顧客を分けている。第 I 部の図 12 で変数 2 を 5 倍にしたときと同じことが起きた。

表 6: 対数にして標準化するかどうかで変わる J の内訳（卸売の顧客、$k = 2$）

$k = 2$ の答え	対数にして標準化	平均を引いただけ
$\|\mathbf{X}\|_F^2$ のうち生鮮の列の割合	16.7%	44.6%
$\|\mathbf{X}\|_F^2$ のうち総菜の列の割合	16.7%	2.2%
J のうち生鮮・食料品の 2 列の割合	33.0%	59.8%
群の件数	252・188	375・65
業態と重なる割合	85.9%	59.3%

次に、対数をとらず標準化だけした $\mathbf{X}$ を使った。列ごとの散らばりはそろうが、右に長い裾はそのまま残る。表 7 には、k を 3 から 5 まで変え、初期値 50 通りで J が最小の答えについて、最も小さい群の件数を示した。標準化だけの $\mathbf{X}$ では、$k = 3$ ですでに数件だけの群ができ、$k = 5$ では 1 件だけの群ができた。その 1 件は、総菜の購入額が平均から標準偏差の 16.5 倍離れた大口の客である。距離の二乗で測ると、この客を誰と組ませても J が大きく増える。そのため、この客に専用の代表点を 1 つ置くと J が最も下がる。対数にして標準化した $\mathbf{X}$ では、最も小さい群でも数十件あった。なお、対数をとると小さい側の外れ（ある品目を年にわずかしか買わない客）が広がるが、この範囲の k では 1 件だけの群はできなかった。

表 7: 標準化だけの $\mathbf{X}$ と、対数にして標準化した $\mathbf{X}$ で、最も小さい群の件数（卸売の顧客、初期値 50 通りで J が最小の答え）

最も小さい群の件数	対数にして標準化	標準化だけ
$k = 3$	81	2
$k = 4$	61	4
$k = 5$	54	1

どちらの失敗も、手順の中からは見えない。交互最小二乗法は、与えられた $\mathbf{X}$ に対して J を下げるだけで、J は毎回下がって止まる。どの列の誤差をどれだけ重く見るか、大口の客をどれだけ遠くに置くかは、$\mathbf{X}$ を用意する側が決めている。

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは、卸売の顧客でも初期値によって着く先が変わり、数回やり直せば最小に着くと予想した。$k = 2$ では、初期値を 100 通り変えても答えはほぼ 1 つで、1 つ目の予想は外れた。点の雲が 1 つの向きに細長く、2 つに切る場所が 1 通りに決まるからである。$k = 3$ では着く先が 41 通りに分かれ、こちらは予想どおりだった。ただし最小に着く割合は $\theta = 0.03$ と小さく、数回のやり直しでは足りなかった。境目のそばの数件だけが違う谷が、最小のすぐそばにいくつも並ぶからである。それらをまとめて 1 つと見れば、

50% の初期値がそこに着いた。局所解がどれだけ問題になるかは、データの形と k で変わる。また、J が下がって止まることは手順が保証するが、どの列をどれだけ重く見るかは保証しない。目盛りをそろえないと、金額の大きい列が群を決めてしまう。

締め

まとめと次回の問い

本章の問いは、行を群に分けるとき、0/1 の所属行列 $\mathbf{G}$ と代表点の行列 $\mathbf{C}$ をどう求めるか、であった。k-means は、メンバーシップ関数 g_{iq} を並べた $\mathbf{G}$ と $\mathbf{C}$ の積でデータ行列を近似し、$\|\mathbf{X}-\mathbf{G}\mathbf{C}\|_F^2$ を最小にする最小二乗法である。$\mathbf{G}$ は 0/1 に限られるので微分できず、一度には解けない。しかし片方を固定すれば解ける。$\mathbf{C}$ を固定すれば、場合分けにより、各個体を最も近い代表点のクラスターに入れるのが最良になる。$\mathbf{G}$ を固定すれば、第 1 回の正規方程式と同じ形から $\hat{\mathbf{C}}=(\mathbf{G}^\top\mathbf{G})^{-1}\mathbf{G}^\top\mathbf{X}$、すなわちクラスターごとの平均が得られる。この 2 つを交互に繰り返すと、目的関数は毎回下がり、有限回で止まる。ただし、止まる先は初期値しだいの局所解である。主成分分析と違って 1 回で解く方法も無いので、初期値を変えてやり直し、目的関数が最も小さい答えを採る。また、目的関数は列ごとの誤差の和なので、答えは列の目盛りで変わる。卸売の顧客 440 件の 6 品目の購入額を対数にして標準化したデータでは、自分で書いた手順が、同じ初期値のライブラリと同じ J・同じ所属に着いた。$k=2$ の群は、業態と 85.9% 重なった。$k=3$ では初期値 100 通りが 41 通りの答えに分かれ、最小に着いたのは 3% であった。また、購入額をそのまま使うと、金額の大きい 2 品目で分ける答えになった。標準化だけでは、大口の客 1 件だけの群ができた。

最後に、次回への問いを置く。k-means の $\mathbf{G}$ は 0 か 1 なので、境目のすぐそばの個体も、どちらか一方の群に 100% 入る。境目は代表点どうしの垂直二等分線であり、k-means は群の形や広がりを見ていない。前半では、第 1 回の最小二乗法の答えを、第 6 回で確率のモデルを置いた最尤法から読み直した。群に分ける問題でも同じ道をたどれるだろうか。同じ群を最尤法で推定するとどうなるかを、次回に考える。

発展

発展：列を選びながら群に分ける

発展として、列を選びながら群に分ける方法を紹介する。遺伝子やタンパク質のデータでは列が数千あっても、群を分けるのに効く列は一部だけのことが多い。(23) 式のとおり、k-means の目的関数はすべての列の誤差を同じ重みで足す。効かない列の揺れも、そのまま J に入る。

Sun, Wang & Fang (2012) は、k-means の目的関数に、代表点の行列 $\mathbf{C}$ の列ごとの罰を足した。本講義の記号で書けば、列の平均を引いた $\mathbf{X}$ について

$$\min_{\mathbf{G},\mathbf{C}} \ \frac{1}{n}\|\mathbf{X}-\mathbf{G}\mathbf{C}\|_F^2+\sum_{j=1}^{p}\lambda_j\|\boldsymbol{c}_{(j)}\|_2$$

である。$\boldsymbol{c}_{(j)}$ は $\mathbf{C}$ の第 j 列で、k 個の代表点の第 j 成分を並べたものである。第 4 回の lasso は係数を 1 つず

つ 0 にしたが、この罰（group lasso）は列 j の k 個の値をまとめて 0 にする。どの群の代表点も列 j で 0、つまり平均と同じ値になれば、列 j は群分けに使われない。

列ごとに重みを付けて、その重みに lasso の罰をかける方法もある（sparse k-means。Witten & Tibshirani, 2010）。図 18 は、その頑健版でヒトの視覚野の試料を 7 つのタンパク質の量で群に分けた例である（Balsor et al., 2021）。群の数を 2 から 8 まで変えても、重みが付くのは GluN2B・GluN2A・Synapsin の 3 つだけで、残りの 4 つの重みはほぼ 0 になった。

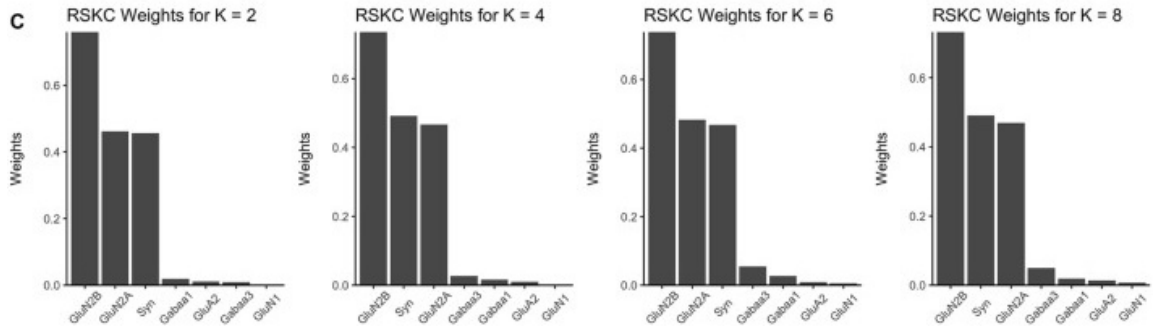


図 18: ヒトの視覚野の試料を 7 つのタンパク質の量で群に分けたときの、各タンパク質の重み（群の数 $K = 2$, 4, 6, 8）。出典：Balsor et al. (2021) Front. Neurosci. 15: 668293, Fig. 4C（一部を切り出した。CC BY 4.0）

参考文献

- Sun, W., Wang, J., & Fang, Y. (2012). Regularized k-means clustering of high-dimensional data and its asymptotic consistency. Electronic Journal of Statistics, 6, 148–167.
- Witten, D. M., & Tibshirani, R. (2010). A framework for feature selection in clustering. Journal of the American Statistical Association, 105, 713–726.
- Balsor, J. L., et al. (2021). A practical guide to sparse k-means clustering for studying molecular development of the human brain. Frontiers in Neuroscience, 15, 668293.