

第 12 回 混合正規分布と EM アルゴリズム

ラベルの见えない LDA を、所属の確率で解く

本章の問いは、第 11 回の締めで残った「同じ群を最尤法で推定すると？」である。第 6 回の LDA は、群を選んでからその群の中で正規分布に従って散らばる、という確率のモデルであった。そこから所属のラベルを隠したものが混合正規分布である。対数尤度は $\log$ の中に和を含むので、一度には解けない。所属を確率(責任度)に緩めて固定すれば、第 6 回の最尤推定に責任度の重みを付けた式で解ける。責任度を計算し直す E ステップと、重み付きの最尤推定をする M ステップを交互に繰り返す手順が、EM アルゴリズムである。共分散を共通の球にして小さくした極限が、第 11 回の k-means になる。

第 I 部 理論

群を最尤法で推定する

第 11 回では、行を k-means で群に分けた。所属は 0 か 1 の所属行列 $\mathbf{G}$ で表され、群の境目は代表点どうしの垂直二等分線であった。本章では、小麦の粒のデータでこの答え方を見直す。軟 X 線の画像から測った小麦の粒 210 粒について、粒の長さ(どちらも mm。標準化した)をとった。これを図 1 のように k-means ($k = 3$)で 3 つの群に分けた(初期値 20 通りの最良)。群の大きさは $88 \cdot 56 \cdot 66$ 粒である。所属行列 $\mathbf{G}$ は 0 か 1 なので、丸で囲んだ境目のすぐそばの粒も、どれか 1 つの群に 100% 入る。また、粒の雲は左下から右上へ斜めに伸びている。ところが垂直二等分線の境目はこの伸び方と関係なく引かれ、伸びた雲を横切っている。

前半の回では、第 1 回の最小二乗法の答えを、第 6 回で確率のモデルを置いた最尤法から読み直した。0/1 の y に対して、第 5 回の最小二乗法では確率が出なかった。第 6 回でデータの出方を確率で仮定すると、確率が出た。ところが行を群に分ける問題には、まだ最尤法の答え方が無い。本章では、ここでも同じ道をたどれるかを問う。すなわち、同じ群を最尤法で推定するとどうなるか、である。

以下ではまず、第 6 回の LDA の確率のモデルから所属のラベルを隠し、行の出方を確率で書く。次にその対数尤度を目的関数として書き、それを最大にする条件を、責任度という道具を使って導く。導いた条件は一度には解けないので、2 つの更新を交互に繰り返す手順にまとめる。最後に、その手順から言えることと、第 11 回の k-means との関係を見る。




図 1: 小麦の粒 210 粒の粒の長さ(標準化)と溝の長さ(標準化)を k-means ($k = 3$)で分けた答え。■は代表点、灰色の線が境目(垂直二等分線)、丸は境目のすぐそばの粒

ラベルの見えない LDA

まず 1 変数で、第 6 回の LDA の確率のモデルを思い出す。各行は確率 π_q で群 q に属する ($\pi_1 + \pi_2 = 1$)。群 q の中では、平均 μ_q 、分散 σ^2 の正規分布に従って x_i が出てくる。第 11 回のメンバーシップ関数 g_{iq} を使えば、 $\Pr(g_{iq} = 1) = \pi_q$ 、 $g_{iq} = 1$ のもとで $x_i \sim N(\mu_q, \sigma^2)$ と書ける(第 6 回の $y = 0, 1$ を群 1・2 と呼び直した)。ここでは人工的なデータを使う。M 玉と L 玉の卵が 1 つかごに混ざっているとす。M 玉は 120 個(平均 61 g)、L 玉は 60 個(平均 67 g)で、重さの標準偏差はどちらも 2.4 g とした。図 2 (a) は、群ごとの重さのヒストグラムにこのモデルの群ごとの密度を重ねたものである。卵がパックに入っていれば、どの卵がどちらの群かは見えている。第 6 回の LDA は、この状態で推定した。

同じ卵が 1 つかごに混ざって所属が隠れると、図 2 (b) のように見えるのは重さ x の値だけになる。 x がどちらの群から出たかは分からない。したがって x の出方は、「群 1 を選んでそこから出る」と「群 2 を選んでそこから出る」の 2 つの道の確率の和

$$f(x) = \pi_1 f_1(x) + \pi_2 f_2(x) \quad (1)$$

になる。 f_q は平均 μ_q 、分散 σ^2 の正規分布の密度である。2 つの山を割合 π_q で重み付けて足したこの分布を、混合正規分布(Gaussian mixture model)と呼ぶ。 π_q は混合比率(mixing proportion)という。

変数が p 個なら、行 i のデータベクトル $\tilde{\mathbf{x}}_i \in \mathbb{R}^p$ (第 11 回と同じ記号)について、群の中の分布を第 6 回の多変量正規分布 $N(\boldsymbol{\mu}_q, \boldsymbol{\Sigma}_q)$ に置き換えて




図 2: 1 変数・2 群の人工データ(卵 180 個の重さ)。(a) 所属が見えているとき(M 玉が青、L 玉が赤)、(b) 所属を隠したとき。黒は混合正規分布の密度、破線はその 2 つの成分(個数と幅 1 g に合わせて拡大した)

$$f(\tilde{\mathbf{x}}) = \sum_{q=1}^k \pi_q N(\tilde{\mathbf{x}}; \boldsymbol{\mu}_q, \boldsymbol{\Sigma}_q) \quad (2)$$

とする。 $N(\tilde{\mathbf{x}}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$ は第 6 回の変量正規分布の密度を $\tilde{\mathbf{x}}$ で測った値である。 $p = 1$ 、 $k = 2$ 、 $\boldsymbol{\Sigma}_q = \sigma^2$ なら (1) 式に戻る。第 6 回の LDA は、共分散行列を群で共通($\boldsymbol{\Sigma}_q = \boldsymbol{\Sigma}$)にした。混合正規分布では、群ごとに $\boldsymbol{\Sigma}_q$ を持たせてよい。2 変数の人工データとして、浜辺で拾った貝殻 120 個の長さ(高さ)と高さ(cm)を考える。ハマグリ 60 個は大きさがいろいろで、長さが高さがほぼ比例するので斜めの細長い帯になる。マテガイ 25 個は細長く大きさがそろっている、小さくまとまる。ホタテ 35 個は大きく丸く散らばる。図 3 のように、群ごとに楕円の傾きと大きさが変わる。 $\boldsymbol{\Sigma}_q$ を共通にしたものが、第 6 回の LDA からラベルを隠したものである。

行列で見ると、所属は第 11 回と同じ $n \times k$ の所属行列 $\mathbf{G}$ ($\mathbf{G}\mathbf{1}_k = \mathbf{1}_n$) で表される。ただし、その値は観測されない。推定するのは、混合比率 $\pi_1, \dots, \pi_k$ と、平均を行に並べた $\mathbf{C} = [\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_k]^\top \in \mathbb{R}^{k \times p}$ (第 11 回の代表点の行列と同じ置き方)と、共分散行列 $\boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_k$ である。

定義 1 (混合正規分布). k 個の変量正規分布 $N(\boldsymbol{\mu}_q, \boldsymbol{\Sigma}_q)$ を混合比率 π_q ($\pi_q \geq 0$ 、 $\sum_q \pi_q = 1$) で重み付けて足した分布 (2) 式を混合正規分布と呼ぶ。各行は確率 π_q で群 q を選び、その群の正規分布から出てくると見なせるが、どの群を選んだか(所属)は観測されない。

対数尤度

最尤法の目的関数を、スカラー・ベクトル・行列の順に書く。1 変数・2 群では、行 i の出やすさは (1) 式の $f(x_i) = \pi_1 f_1(x_i) + \pi_2 f_2(x_i)$ である。行が独立なら、データ全体の尤度はその積であり、対数をとると




図 3: 2 変数・3 群の人工データ(貝殻の長さと高さ。赤がハマグリ、青がマテガイ、緑がホタテ)。楕円は、データを作った 3 つの正規分布の $(\tilde{\mathbf{x}} - \boldsymbol{\mu}_q)^\top \boldsymbol{\Sigma}_q^{-1}(\tilde{\mathbf{x}} - \boldsymbol{\mu}_q) = 4$ の線、■はその平均

$$\ell(\pi_1, \mu_1, \mu_2, \sigma^2) = \sum_{i=1}^n \log(\pi_1 f_1(x_i) + \pi_2 f_2(x_i)) \quad (3)$$

となる($\pi_2 = 1 - \pi_1$)。これを最大にするパラメータを求めればよい。

第 6 回と比べると、難しさがどこにあるかが分かる。所属 g_{iq} が見えていれば、行 i の出やすさは「群 q が選ばれる確率」と「その群で x_i が出る密度」の積 $\pi_q f_q(x_i)$ である。1 が立った q の 1 項だけを掛ければよい。対数尤度は

$$\ell_{\mathbf{G}} = \sum_{i=1}^n \sum_{q=1}^2 g_{iq} [\log \pi_q + \log f_q(x_i)] \quad (4)$$

となる。これは第 6 回の同時の尤度そのものである。和が $\log$ の外にあるので、式は π の部分と各群の μ_q の部分に分かれる。そのため第 6 回では、割合・平均・分散を数えるだけで答えが出た。ところが所属が見えないと、(3) 式のように和が $\log$ の中に入る。 μ_1 を動かすと $\log$ の中の和全体が変わるので、式は群ごとに分かれられない。偏微分して 0 とおいても、閉じた式にならない。

変数が p 個、群が k 個なら、(2) 式から

$$\ell = \sum_{i=1}^n \log \sum_{q=1}^k \pi_q N(\tilde{\mathbf{x}}_i; \boldsymbol{\mu}_q, \boldsymbol{\Sigma}_q) \quad (5)$$

である。 $p = 1$ 、 $k = 2$ 、 $\Sigma_q = \sigma^2$ なら (3) 式に戻る。行列で書くために、 (i, q) 成分が $\phi_{iq} = \pi_q N(\tilde{\mathbf{x}}_i; \boldsymbol{\mu}_q, \Sigma_q)$ の $n \times k$ 行列 $\boldsymbol{\Phi}$ を置く。 $\boldsymbol{\Phi} \mathbf{1}_k$ の第 i 成分は行 i の出やすさ $f(\tilde{\mathbf{x}}_i)$ であるから、 $\log$ を成分ごとにとって足せば

$$\ell = \mathbf{1}_n^\top \log(\boldsymbol{\Phi} \mathbf{1}_k) \quad (6)$$

となる。これが本章で最大にする目的関数である。

道具：責任度と重み付きの和

導出に使う道具を 4 つそろえる。

1 つ目は第 6 回のベイズの定理である。所属が見えないとき、 $\tilde{\mathbf{x}}_i$ を見たうえで行 i が群 q に属する確率は

$$r_{iq} = \Pr(g_{iq} = 1 \mid \tilde{\mathbf{x}}_i) = \frac{\pi_q f_q(\tilde{\mathbf{x}}_i)}{\sum_{l=1}^k \pi_l f_l(\tilde{\mathbf{x}}_i)} \quad (7)$$

である ($f_q(\tilde{\mathbf{x}}) = N(\tilde{\mathbf{x}}; \boldsymbol{\mu}_q, \Sigma_q)$)。卵の例で、重さ 64 g の卵を考える。図 2 (b) の破線の高さは、この重さで M 玉の道が 7.9、L 玉の道が 5.6 である。L 玉である確率は、L 玉の道の高さを 2 つの道の高さの和で割った 0.41 になる。第 6 回では、この事後確率で新しい行の群を当てた。本章では、この値を群 q が行 i を説明する「責任」の大きさと見て、責任度(responsibility)と呼ぶ(定義 2)。 g_{iq} は 0 か 1 の値をとるので、その期待値は 1 をとる確率に等しい。したがって r_{iq} は、見えない g_{iq} の期待値でもある。

2 つ目は、責任度を並べた $n \times k$ の責任度行列 $\mathbf{R}$ である。(7) 式の分子は $\boldsymbol{\Phi}$ の (i, q) 成分、分母はその行の和であるから

$$\mathbf{R} = \text{diag}(\boldsymbol{\Phi} \mathbf{1}_k)^{-1} \boldsymbol{\Phi} \quad (8)$$

と書ける。各行の和は 1 である。 $\mathbf{R} \mathbf{1}_k = \mathbf{1}_n$ は、第 11 回の所属行列の制約 $\mathbf{G} \mathbf{1}_k = \mathbf{1}_n$ と同じ形をしている。違いは成分にあり、0 か 1 に限らず 0 から 1 の間の確率をとる。卵の重さの両端に近い卵では責任度がほぼ 0 か 1 になり、2 つの山が重なる 60 g 台の半ばでは、どちらの群にも中ほどの値が付く。

3 つ目は、対数の微分である。合成関数の微分により $d \log u(\theta)/d\theta = u'(\theta)/u(\theta)$ となる。 $\log$ の中身の微分を、中身で割ればよい。また、正規分布の密度 $f_q(x)$ を μ_q で偏微分すると、指数の中 $-(x - \mu_q)^2/(2\sigma^2)$ の偏微分 $(x - \mu_q)/\sigma^2$ が前に出る。したがって $\partial f_q(x)/\partial \mu_q = f_q(x)(x - \mu_q)/\sigma^2$ である。

4 つ目は、責任度で重み付けた人数と和である。 $n_q = \sum_i r_{iq}$ は各行が群 q に属する確率を足したもので、群 q の実質の人数にあたる。これを並べたものが $\mathbf{R}^\top \mathbf{1}_n$ で、 $\sum_q n_q = n$ となる。また $\mathbf{R}^\top \mathbf{X}$ の第 q 行は、各行を責任度 r_{iq} で重み付けて足した $\sum_i r_{iq} \tilde{\mathbf{x}}_i^\top$ である。 $\mathbf{R}$ が 0/1 の $\mathbf{G}$ なら、これらは第 11 回の $\mathbf{G}^\top \mathbf{G} = \text{diag}(n_1, \dots, n_k)$ の対角と、群ごとの和 $\mathbf{G}^\top \mathbf{X}$ に戻る。ただし $\mathbf{R}^\top \mathbf{R}$ は対角行列にならないので、第 11 回の $\mathbf{G}^\top \mathbf{G}$ の代わりには $\text{diag}(\mathbf{R}^\top \mathbf{1}_n)$ を使う。

定義 2 (責任度). 混合正規分布のパラメータのもとで、行 i が群 q に属する事後確率 (7) 式を責任度と呼ぶ。責任度を並べた $n \times k$ の行列 $\mathbf{R}$ を責任度行列と呼び、 $\mathbf{R}\mathbf{1}_k = \mathbf{1}_n$ を満たす。

導出：責任度で重み付けた LDA

(3) 式を最大にする条件を、1 変数・2 群で求める。まず μ_q で偏微分する。log 中の和のうち μ_q を含むのは $\pi_q f_q(x_i)$ だけなので、log の微分と正規分布の密度の偏微分により

$$\frac{\partial \ell}{\partial \mu_q} = \sum_{i=1}^n \frac{\pi_q f_q(x_i)}{\pi_1 f_1(x_i) + \pi_2 f_2(x_i)} \cdot \frac{x_i - \mu_q}{\sigma^2} = \sum_{i=1}^n r_{iq} \frac{x_i - \mu_q}{\sigma^2} \quad (9)$$

となる。分数の部分は (7) 式の責任度そのものである。log 中の和を微分すると、責任度が自然に現れる。これを 0 とおくと

$$\hat{\mu}_q = \frac{\sum_{i=1}^n r_{iq} x_i}{\sum_{i=1}^n r_{iq}} \quad (10)$$

を得る。責任度で重み付けた平均である。ただし、右辺の r_{iq} 自身が μ_1, μ_2 を含んでいるので、(10) 式は μ_q についての閉じた式ではない。そこで、第 11 回の交互最小二乗法と同じ考え方をとる。今の値で r_{iq} を計算して固定し、(10) 式で μ_q を更新する。新しい μ_q で r_{iq} を計算し直し、これを繰り返す。(4) 式の g_{iq} を r_{iq} に置き換えると、重み付きの対数尤度 $\sum_i \sum_q r_{iq} [\log \pi_q + \log f_q(x_i)]$ になる。 r_{iq} を固定したときの (9) 式は、これを μ_q で偏微分したものと同じである。したがって、この更新は責任度を重みとする第 6 回の最尤推定にあたる。

分散についても同じである。 σ^2 で偏微分して 0 とおき、 r_{iq} を固定して解くと

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \sum_{q=1}^2 r_{iq} (x_i - \hat{\mu}_q)^2 \quad (11)$$

となる。第 6 回の群の中の分散 s_W^2 は、各行を自分の群の平均との差だけで数えた。この式は、それを両方の群の平均との差を責任度で重み付けて数えるように替えたものである。

混合比率は、 $\pi_2 = 1 - \pi_1$ を代入して π_1 だけの関数とし、微分して 0 とおく (第 6 回と同じく制約を代入して解く)。 π_1 で微分すると、log の中身の微分は $f_1(x_i) - f_2(x_i)$ になる。 $f_q(x_i)/f(x_i) = r_{iq}/\pi_q$ であるから

$$\frac{\partial \ell}{\partial \pi_1} = \sum_{i=1}^n \frac{f_1(x_i) - f_2(x_i)}{f(x_i)} = \frac{n_1}{\pi_1} - \frac{n_2}{\pi_2} = 0 \quad (12)$$

となる ($n_q = \sum_i r_{iq}$)。 $\pi_1/\pi_2 = n_1/n_2$ と $\pi_1 + \pi_2 = 1$ 、 $n_1 + n_2 = n$ から $\hat{\pi}_1 = n_1/n$ を得る。第 6 回のコインの例と同じく、観測された (ここでは責任度で数えた) 割合がそのまま答えになる。 k 群でも、 $\pi_k = 1 - \sum_{q < k} \pi_q$ を代入すれば同じ計算で $\hat{\pi}_q = n_q/n$ となる。

変数が p 個なら、第 6 回と同じく 2 次形式の勾配を 0 ベクトルにおいて、 $\hat{\boldsymbol{\mu}}_q = \sum_i r_{iq} \tilde{\mathbf{x}}_i / n_q$ を得る。 $p = 1$ なら (10) 式に戻る。共分散行列の導出は、第 6 回と同じく行列の偏微分を要するので、結果だけを述べる。群ごとに $\boldsymbol{\Sigma}_q$ を持たせたときは

$$\hat{\boldsymbol{\Sigma}}_q = \frac{1}{n_q} \sum_{i=1}^n r_{iq} (\tilde{\mathbf{x}}_i - \hat{\boldsymbol{\mu}}_q)(\tilde{\mathbf{x}}_i - \hat{\boldsymbol{\mu}}_q)^\top \quad (13)$$

であり、共通の $\boldsymbol{\Sigma}$ にしたときは $\hat{\boldsymbol{\Sigma}} = \sum_q (n_q/n) \hat{\boldsymbol{\Sigma}}_q$ である。後者で $p = 1$ とすれば (11) 式に戻る。平均をまとめて行列で書くと、道具の 4 つ目により

$$\hat{\mathbf{C}} = \text{diag}(n_1, \dots, n_k)^{-1} \mathbf{R}^\top \mathbf{X} \quad (14)$$

となる。第 11 回の $\hat{\mathbf{C}} = (\mathbf{G}^\top \mathbf{G})^{-1} \mathbf{G}^\top \mathbf{X}$ の $\mathbf{G}$ を $\mathbf{R}$ に替えた形である。

表 1 は、第 6 回の LDA の最尤推定と、 $\mathbf{R}$ を固定した本章の最尤推定を並べたものである。違うのは所属の 0/1 を責任度に替えたところだけで、式の形はどれも変わらない。 r_{iq} が 0 か 1 なら、式は完全に一致する。混合正規分布の推定は、責任度で重み付けた LDA の推定を繰り返すことにあたる。

表 1: 第 6 回の LDA の最尤推定と、責任度を固定した混合正規分布の最尤推定

	第 6 回(LDA の最尤推定)	本章($\mathbf{R}$ を固定した最尤推定)
所属	g_{iq} (0/1、観測)	r_{iq} (確率、計算する)
割合	$\hat{\pi}_q = n_q/n$, $n_q = \sum_i g_{iq}$	$\hat{\pi}_q = n_q/n$, $n_q = \sum_i r_{iq}$
平均	$\hat{\boldsymbol{\mu}}_q = \sum_i g_{iq} \tilde{\mathbf{x}}_i / n_q$	$\hat{\boldsymbol{\mu}}_q = \sum_i r_{iq} \tilde{\mathbf{x}}_i / n_q$
共通の共分散	$\mathbf{S}_W = \frac{1}{n} \sum_i \sum_q g_{iq} (\tilde{\mathbf{x}}_i - \hat{\boldsymbol{\mu}}_q)(\tilde{\mathbf{x}}_i - \hat{\boldsymbol{\mu}}_q)^\top$	$\frac{1}{n} \sum_i \sum_q r_{iq} (\tilde{\mathbf{x}}_i - \hat{\boldsymbol{\mu}}_q)(\tilde{\mathbf{x}}_i - \hat{\boldsymbol{\mu}}_q)^\top$

計算の手順

2 つの更新を、実際に計算する行列の形で手順にまとめる。この手順が EM アルゴリズム (EM algorithm) である。責任度を計算する段は、見えない g_{iq} をその期待値 r_{iq} で置き換えるので、E ステップ (期待値 expectation の E) と呼ぶ。重み付きの対数尤度を最大にする段は、M ステップ (最大化 maximization の M) と呼ぶ。

1. データ行列 $\mathbf{X} \in \mathbb{R}^{n \times p}$ と群の数 k を用意する
2. 初期値を置く。 $\mathbf{C}$ は $\mathbf{X}$ の行から k 行を乱数で選び、 $\boldsymbol{\Sigma}_q$ はすべて $\mathbf{X}$ 全体の共分散行列、 $\pi_q = 1/k$ とする
3. E ステップ: $\phi_{iq} = \pi_q N(\tilde{\mathbf{x}}_i; \boldsymbol{\mu}_q, \boldsymbol{\Sigma}_q)$ を並べた $\boldsymbol{\Phi}$ を作り、(8) 式で $\mathbf{R}$ を、(6) 式で ℓ を計算する
4. M ステップ: $(n_1, \dots, n_k)^\top = \mathbf{R}^\top \mathbf{1}_n$ 、 $\pi_q \leftarrow n_q/n$ 、(14) 式で $\mathbf{C}$ を更新し、 $\mathbf{R}$ の第 q 列を $\mathbf{r}_q$ として $\boldsymbol{\Sigma}_q \leftarrow (\mathbf{X} - \mathbf{1}_n \boldsymbol{\mu}_q^\top)^\top \text{diag}(\mathbf{r}_q) (\mathbf{X} - \mathbf{1}_n \boldsymbol{\mu}_q^\top) / n_q$ とする。この式は (13) 式を行列で書いたものである
5. ℓ の増え方が十分小さければ止める。そうでなければ 3 に戻る

6. 2~5 を何通りかの初期値で行い、 ℓ が最も大きい答えを採る

第 11 回の手順と比べると、3 つが替わっている。距離の行列 $\mathbf{D}$ は密度の行列 Φ に、各行の最小の列に 1 を置く操作は各行を和で割る操作に、 $(\mathbf{G}^\top \mathbf{G})^{-1} \mathbf{G}^\top \mathbf{X}$ は $\text{diag}(\mathbf{R}^\top \mathbf{1}_n)^{-1} \mathbf{R}^\top \mathbf{X}$ になった。さらに、共分散と混合比率の更新が加わっている。実際の計算では、 ϕ_{iq} がきわめて小さな値になりやすい。そこで $\log \phi_{iq}$ のまま計算し、各行の最大値を引いてから指数をとる。

図 4 は、卵の重さから所属を隠し、分散を共通にした EM (ラベルを隠した LDA) を回した様子である。初期値は $\mu = (61, 63.4)$ とし、 σ^2 は x 全体の分散から始めた。初めは 2 つの山が近く、幅も広い。反復を重ねると山は左右に離れて幅が狭まり、73 回の反復で止まった。




図 4: 卵 180 個の重さ(人工データ、所属は使わない)に、分散を共通にした EM を回したときの 2 つの成分(破線)と混合正規分布の密度(黒)。(a) 初期値、(b) 反復の途中、(c) 止まったとき

EM から言えること

EM アルゴリズムから、いくつかのことが言える。

第 1 に、対数尤度は更新のたびに上がるかわからない。M ステップでは、責任度を固定したもとで重み付きの対数尤度を最大にする。E ステップでは、責任度を今のパラメータのもとの事後確率に合わせ直す。この 2 つを組み合わせると、 ℓ が下がらないことが示せる(証明は略す)。これは、第 11 回の k-means で J が毎回下がったことの、最尤法の側の対応物である。図 5 は、図 4 の卵の重さで回した EM の ℓ の推移である。 ℓ は -495.9 から始まり、一度も下がらずに 73 回の反復で -486.1 に止まった。反復 2~18 回のあたりでほとんど動かないのは、2 つの群の平均がまだ近く、責任度がどの行でも半々に近いためである。上がり方が止まったように見え

ても、止まったとは限らない。




図 5: 卵 180 個の重さ(人工データ)から所属を隠し、分散を共通にした EM を回したときの対数尤度 ℓ の推移。橙はほとんど動かない区間

第 2 に、所属を使わずに確率が出る。止まったときの推定値は $\hat{\pi}_2 = 0.340$ 、 $\hat{\mu}_1 = 60.506$ 、 $\hat{\mu}_2 = 66.772$ 、 $\hat{\sigma}^2 = 5.427$ である。これらは、所属を見て第 6 回の式で推定した値($\hat{\pi}_2 = 0.333$ 、60.660、66.594、6.418)に近い。分散が共通なので、第 6 回と同じく責任度はシグモイド関数の形になる。図 6 のとおり、所属を見ずに求めた L 玉の責任度の曲線は、所属を見た LDA の事後確率に近い S 字を描く。同じ卵を k-means で 2 つに分けると、所属は 63.2 g で 0 から 1 へ跳ぶ階段になる。




図 6: 図 2 と同じ卵の重さ(灰色の点、所属は使わない)。破線は所属を見て推定した LDA の事後確率、緑は EM で求めた L 玉の責任度、点線は k-means の所属

第 3 に、群ごとに共分散行列を持たせれば、群の形の違いを捉えられる。図 7 は、図 3 の貝殻の人工データを 2 通りに分けたものである。(a) は第 11 回の k-means、(b) は群ごとの Σ_q を持つ EM で、どちらも初期値 20 通りの最良をとった。k-means では境目が垂直二等分線なので、ハマグリ細長い帯の右上の端(大きなハマグリ)がホタテの群に入ってしまう。データを作った群と所属が違う点は 12 個あった。EM はハマグリ細長い帯に沿った細長い楕円を推定し、境目が曲がった。違う点は 3 個になった。さらに所属が確率で出るので、境目のそば

の点を「どちらとも言えない」と言える。丸で囲んだ8点は、最大の責任度が0.9未満の点である。最もあいまいな点の責任度は $0.67 \cdot 0.33$ であった。




図 7: 貝殻の人工データを、(a) k-means、(b) 群ごとの共分散を持つ EM で分けたもの。色は所属((b) は責任度が最大の群)、塗り分けと灰色の線は境目、楕円は推定した Σ_q の形、丸は最大の責任度が 0.9 未満の点

k-means は極限

k-means は、EM の極限である。共分散を共通の球 $\Sigma_q = \sigma^2 \mathbf{I}$ にし、混合比率も等しく $\pi_q = 1/k$ に固定すると、(7) 式の π_q と正規分布の密度の前の係数は分母・分子で打ち消し合い

$$r_{iq} = \frac{\exp(-\|\tilde{\mathbf{x}}_i - \boldsymbol{\mu}_q\|_2^2 / 2\sigma^2)}{\sum_{l=1}^k \exp(-\|\tilde{\mathbf{x}}_i - \boldsymbol{\mu}_l\|_2^2 / 2\sigma^2)} \quad (15)$$

となる。 $\sigma^2 \rightarrow 0$ とすると、分母の中では距離の二乗が最も小さい項が他を圧倒する。そのため r_{iq} は、最も近い代表点の q で 1、それ以外で 0 に近づく。これは第 11 回の $\mathbf{G}$ の更新そのものである。図 8 は、卵の重さの 1 変数・2 群で σ^2 を小さくしていく様子である。責任度の S 字は、中点(1 変数での垂直二等分線)での階段になる。そのとき $\mathbf{R} \rightarrow \mathbf{G}$ であるから、M ステップの (14) 式は第 11 回の $(\mathbf{G}^\top \mathbf{G})^{-1} \mathbf{G}^\top \mathbf{X}$ 、すなわち群の平均になる。また、1 つの群に入る項だけが残れば $\ell \approx \text{定数} - J/(2\sigma^2)$ であり、 ℓ の最大化は $J = \|\mathbf{X} - \mathbf{GC}\|_F^2$ の最小化に一致する。第 6 回で、誤差が正規分布なら最尤法が最小二乗法に一致したのと同じ関係である。

止まる先と、最大の無いこと

EM が止まる先は、初期値しだいである。k-means と同じく、E と M のどちらを行っても動かない点で止まる。ただし、それが ℓ の最大とは限らない(局所解)。図 9 は、図 7 の貝殻の人工データで初期値を 200 通り試




図 8: 卵の重さの 1 変数・2 群($\mu = (61, 67)$ 、 π_q は等しい)で、共通の分散 σ^2 (g^2) を小さくしたときの L 玉の責任度(概念図)。 $\sigma^2 \rightarrow 0$ で中点での階段、すなわち k-means の $\mathbf{G}$ になる

し、着いた ℓ を並べたものである。着いた値は 9 通りに分かれ、最大の -338.6 に着いたのは 180 回であった。第 11 回と同じく、初期値を変えてやり直して ℓ が最も大きい答えを採る。




図 9: 図 7 の人工データで、初期値を変えて EM を回したときに着いた対数尤度 ℓ の分布。緑の線が最大

さらに、群ごとに共分散を持たせると、最尤推定そのものが存在しなくなることがある。1 変数で群 1 の平均を 1 つの行の値 x_1 に置き、分散 σ_1^2 を 0 に近づけると、 $f_1(x_1) = 1/\sqrt{2\pi\sigma_1^2}$ はいくらでも大きくなる。他の行は群 2 が受け持てば有限の値にとどまるので、 $\ell \rightarrow \infty$ となる。多変量でも、1 つの群が数点や薄い板に潰れてその群の共分散行列が逆行列を持たなくなると、同じことが起きる。最大が無いので、EM がこの方向へ進むと止まらない。1 つの群の共分散行列は $p(p+1)/2$ 個の値を持つので、変数が多いほどパラメータの数が行の数に比べて多くなり、この方向へ進みやすい。実際の計算では、共分散行列の対角に小さな数を足してこれを防ぐ(第 4 回の罰と同じ発想)。

表 2 は、第 11 回の k-means と本章の混合正規分布を並べたものである。どちらも所属と群のパラメータを片方ずつ更新する。目的関数は単調に動き、局所解がある。違うのは、推定法(最小二乗法か最尤法か)と、所属を 0/1 で持つか確率で持つかである。その結果として、群の形と境目の形が変わる。

表 2: k-means と混合正規分布の比較

	k-means (第 11 回)	混合正規分布(本章)
推定法	最小二乗法: $\ \mathbf{X} - \mathbf{G}\mathbf{C}\ _F^2$ を最小	最尤法: $\ell = \mathbf{1}_n^\top \log(\Phi \mathbf{1}_k)$ を最大
所属	$\mathbf{G}$ (0/1)	$\mathbf{R}$ (確率)
片方を固定した更新	最も近い代表点、 $(\mathbf{G}^\top \mathbf{G})^{-1} \mathbf{G}^\top \mathbf{X}$	E: ベイズの定理、M: $\text{diag}(\mathbf{R}^\top \mathbf{1}_n)^{-1} \mathbf{R}^\top \mathbf{X}$ と Σ_q
群の形	等しい球(境目は垂直二等分線)	群ごとの楕円(境目は曲がる)
目的関数	毎回下がる、局所解	毎回上がる、局所解、1 点に縮むと ∞

定義 3 (EM アルゴリズム). 混合正規分布の対数尤度 (6) 式を最大にするために、責任度 $\mathbf{R}$ を今のパラメータの事後確率として計算する E ステップと、 $\mathbf{R}$ を固定して重み付きの最尤推定 $\pi_q = n_q/n$ 、(14) 式、(13) 式を行う M ステップを、交互に繰り返す手順を EM アルゴリズムと呼ぶ。対数尤度は毎回上がるかわ変わらないが、止まる先は局所解のことがある。

位置づけ: 空いたマスを埋める

表 3 は、これまでの回を推定法と「何をするか」で並べたものである。本章の内容は、縦に見れば第 11 回の k-means の推定法を最尤法に替えたものである。横に見れば、第 6 回の LDA からラベルを隠したものである。

表 3: 推定法と、何をするかで並べた回

	最小二乗法	最尤法
y を近似する	第 1 回・第 5 回	第 6 回(LDA・ロジスティック回帰)
行を群に分ける	第 11 回(k-means)	第 12 回(混合正規分布)

第 II 部 実データ解析

小麦の粒データ

第 II 部では、小麦の粒のデータで第 I 部の手順を回す。データは UCI Machine Learning Repository の「seeds」(Charytanowicz ほか, 2010. CC BY 4.0)である。3つの品種(カマ・ロサ・カナディアン)の小麦の粒が 70 粒ずつ、計 210 粒あり、軟 X 線の画像から測った 7 列を持つ(表 4)。1 行が 1 粒である。緊密度は、面積と周長から $4\pi \times \text{面積} / \text{周長}^2$ で計算した列である。品種の列は推定には使わない。責任度と照らすときと、図の色塗りにだけ使う。

表 4: 小麦の粒データの 7 列(210 粒)

列	単位	平均	標準偏差
面積	mm ²	14.848	2.903
周長	mm	14.559	1.303
緊密度	$4\pi \times \text{面積}/\text{周長}^2$	0.871	0.024
粒の長さ	mm	5.629	0.442
粒の幅	mm	3.259	0.377
非対称度	係数	3.700	1.500
溝の長さ	mm	5.408	0.490

$\mathbf{X}$ には、粒の長さや溝の長さの 2 列を、それぞれ平均 0・標準偏差 1 に標準化して用いた。面積・周長・粒の長さ・粒の幅は、互いの相関が 0.86~0.99 である。どれも粒の大きさをほぼ言い換えたものなので、大きさの代表として粒の長さをとった。これに、同じ mm の長さである溝の長さを組んだ。2 列にしたのは、群の楕円を目で見られるようにするためと、7 列のままでは推定がうまくいかないためである(落とし穴の節で見る)。比べる相手は、図 1 の k-means の答えである。群の大きさは 88・56・66 粒、目的関数は $J = 60.15$ であった。

計算の手続きと検証

手続きは次のとおりである。I-6 の手順は、NumPy の行列計算でそのまま書いた。 $k = 3$ とし、群ごとに共分散行列を持たせて、 $\mathbf{X}$ の行から 3 行を乱数で選ぶ初期値 3 通りから回した。初期値を 100 通りに増やしたときに、どこへ着くかも数えた。止まった答えは、scikit-learn の GaussianMixture (初期値 10 通り) と比べた。ライブラリは、共分散行列の対角に 10^{-6} を足して逆行列が無くなるのを防いでいる。自分の手順も同じにした。次に、共分散を共通の球 $\sigma^2 \mathbf{I}$ に、混合比率を $1/3$ に固定して σ^2 を小さくした。その答えを、同じ初期値から回した自分で書いた k-means と比べた。最後に、責任度を品種と照らし、7 列のままでも同じ手順を回した。

図 10 は、3 つの初期値からの ℓ の推移である。どの初期値でも ℓ は一度も下がらなかった。2 通りは 44~82 回の反復で -296.844 に着き、ライブラリの -296.844 と一致した。残りの 1 通りは -312.270 で止まった。I-7 で見た局所解が、実データでも起きている。初期値を 100 通りにすると、最大の ℓ に着いたのは 89 通りであった。

表 5 は、最大の ℓ に着いた答えの確認である。混合比率・平均・共分散行列は、ライブラリの値と一致した。最後の責任度から (14) 式で求め直した $\mathbf{C}$ も、止まった $\mathbf{C}$ と一致した。責任度の各行の和は 1 で、3 つの群の実質の粒数は 79.0・62.0・69.0 である。

表 5: 小麦の粒の 2 列($k = 3$)で止まった EM の答えの確認

確かめたこと	値
ℓ が一度も下がらなかったか(3 通り)	はい
初期値 100 通りで最大の ℓ に着いた回数	89
自分の手順とライブラリの ℓ	-296.844、-296.844

確かめたこと	値
ライブラリとの差(最大): $\pi_q \cdot \mathbf{C} \cdot \boldsymbol{\Sigma}_q$	$5.3\text{e-}06 \cdot 1.1\text{e-}05 \cdot 4.9\text{e-}06$
$\text{diag}(\mathbf{R}^\top \mathbf{1}_n)^{-1} \mathbf{R}^\top \mathbf{X}$ と $\mathbf{C}$ の差(最大)	$6.4\text{e-}07$
$\mathbf{R}\mathbf{1}_k$ と $\mathbf{1}_n$ の差(最大)	$4.4\text{e-}16$
実質の粒数 $n_1 \cdot n_2 \cdot n_3$	$79.0 \cdot 62.0 \cdot 69.0$

表 6 は、共分散を共通の球に固定して σ^2 を小さくしたときの答えである。 σ^2 が大きいと責任度はどの粒でも 1 に届かず、所属は k-means と違う。 σ^2 を小さくすると、責任度はほぼ 0 か 1 になる。 $\sigma^2 = 0.01$ では、k-means と所属が違う粒は 0 粒であった。 J は 60.15 で、同じ初期値から回した自分の k-means の 60.15 と一致した。I-7 で導いた極限が、実データでも成り立っている。

表 6: 共分散を $\sigma^2 \mathbf{I}$ 、混合比率を $1/3$ に固定した EM の答え(小麦の粒の 2 列、 $k = 3$)。 J は責任度が最大の群を所属として数えた

σ^2	1	0.5	0.2	0.1	0.05	0.01
J (責任度の最大の群で数えた)	63.95	63.61	60.61	60.28	60.20	60.15
k-means と所属が違う粒	9	21	10	4	2	0
最大の責任度が 0.99 未満の粒	199	168	146	79	39	4

楕円と所属の確率

図 11 は、場面①の k-means (a) と、群ごとの共分散を持つ EM (b) の答えを並べたものである。(b) の楕円は、推定した $\boldsymbol{\Sigma}_q$ の形である。どの群も粒の長さと溝の長さが一緒に大きくなる向きに伸びており、EM はその伸び方に沿った斜めの楕円を推定した。推定した混合比率は $0.376 \cdot 0.295 \cdot 0.329$ である。k-means の境目は代表点どうしの垂直二等分線で、伸びた雲を横切っていた。EM の境目は、楕円の間を斜めに通る。2 つの答えで所属が違う粒は 41 粒であった。丸で囲んだ 16 粒は、最大の責任度が 0.9 未満の粒で、楕円どうしが接するあたりに並ぶ。k-means ではこれらの粒も、どれか 1 つの群に 100% 入っていた。

推定に使わなかった品種で粒を塗り直すと、図 12 のようになる。混合正規分布の 3 つの群は品種によく重なり、品種と違う群に入った粒は 11 粒(94.8% が一致)であった。k-means では 51 粒(75.7%)が違った。品種ごとの粒は、どれも粒の長さと溝の長さが一緒に伸びる細長い雲をなしている。k-means で違う粒が多いのは、垂直二等分線の境目とその雲を横切ってしまうからである。群の名前は、品種と最もよく重なるように付けた。




図 10: 小麦の粒の 2 列($k = 3$)で、3 通りの初期値から回した EM の対数尤度 ℓ の推移。点線はライブラリの ℓ




図 11: 小麦の粒の 2 列を、(a) k-means、(b) 群ごとの共分散を持つ EM で 3 つに分けたもの。■は平均、楕円は推定した Σ_q の形、塗り分けと灰色の線は境目、丸は最大の責任度が 0.9 未満の粒

責任度を見れば、どの粒の所属があいまいかが分かる。表 7 は、粒を最大の責任度が 0.9 以上か未満かで分け、責任度が最大の群を品種と照らしたものである。0.9 以上の粒では 3.6% が品種とずれたのに対し、0.9 未満の粒では 25.0% がずれた。あいまいな粒ほど品種とずれやすいので、確かめ直すならその粒から、と読める。

表 7: 最大の責任度で分けた粒と、品種とのずれ(小麦の粒の 2 列、 $k = 3$)

最大の責任度	粒数	品種とずれた割合
0.9 以上	194	3.6%
0.9 未満	16	25.0%




図 12: 図 11 と同じ答えの上で、粒を品種で塗り直したものの(品種は推定に使っていない)。塗り分けと灰色の線は (a) k-means、(b) 混合正規分布の境目

ただし、群が品種に合ったのは、このデータでは品種ごとの粒が正規分布の楕円に近い形で散らばっていたからである。最尤法が最大にしているのは $\mathbf{X}$ の出やすさであって、品種との一致ではない。第 8 回で見たとおり、目的関数が品種を含まない以上、群が品種に合う保証は無い。次の節で、それが崩れる例を見る。

7 列のままで

第 II 部では 2 列を $\mathbf{X}$ にした。7 列すべてを標準化して、群ごとの共分散行列を持たせると何が起きるかを確かめる。1 つの群の共分散行列は $7 \times 8/2 = 28$ 個の値を持つ。そのため $k = 3$ のパラメータは、混合比率・平均・共分散を合わせて 107 個になる。これは 2 列のときの 17 個よりはるかに多い(粒は 210 粒)。

図 13 は、7 列の $\mathbf{X}$ で初期値を 100 通り試し、着いた ℓ を並べたものである。初期値は $\mathbf{X}$ の行から 3 行を選んだ。着いた値は 50 通りに分かれ、最大の 333.2 に着いたのは 2 回だけであった。2 列では 100 通りのうち 89 通りが同じ最大に着いたのと対照的である。しかも、最大の ℓ の答えは品種と 37 粒違った。2 列の混合正規分布(11 粒)はもちろん、同じ 7 列の k-means (17 粒)よりも品種から離れていた。

原因は、列どうしが式で結ばれていることにある。緊密度は、面積と周長から $4\pi \times \text{面積} / \text{周長}^2$ で計算した列である(書かれた値との差は最大 0.0010、丸めの分だけ)。そのため 7 列の点は、品種の中で見ると 1 つの向きにほとんど厚みを持たない。品種ごとに求めた共分散行列の最も小さい固有値は $1e-04 \cdot 7e-05 \cdot 1e-05$ である。I-7 で見たとおり、群の共分散行列が逆行列を持たない向きに潰れるほど、密度はいくらでも大きくなる。ここでは群が 1 点に縮むのではなく、薄い板に潰れる。表 8 は、共分散行列の対角に足す数を変えたときの、初期値 100 通りの最良の答えである。足す数を 10^{-2} から 10^{-6} へ小さくすると、最良の ℓ は -281.7 から 333.2 まで上がった。その答えの共分散行列では、最も細い向きの分散が足す数に付いて小さくなった(10^{-6} では $7.5e-06$)。 ℓ の伸びの大半は、品種の違いではなく、この薄い向きをどれだけ薄く見積もるかで決まっている。品種と違う粒は、足す数が $10^{-2} \sim 10^{-4}$ では 13~14 粒であった。 10^{-6} では 37 粒に増えた。




図 13: 小麦の粒の 7 列(標準化)で、群ごとの共分散を持つ EM ($k = 3$)を初期値 100 通りから回したときに着いた l の分布。緑の線が最大

表 8: 7 列の $\mathbf{X}$ で共分散行列の対角に足す数を変えたときの、初期値 100 通りの最良の答え(小麦の粒、 $k = 3$)

対角に足す数	10^{-2}	10^{-3}	10^{-4}	10^{-6}
最大の l (初期値 100 通り)	-281.7	28.1	214.2	333.2
Σ_q の最も細い向きの分散	1.0e-02	1.0e-03	1.1e-04	7.5e-06
品種と違う粒	14	13	14	37

どちらの失敗も、手順が止まったことや l の値からは気づきにくい。EM は、与えられたモデルのもとで l を上げるだけである。列が式で結ばれていないか、パラメータの数が行の数に見合っているかは、モデルを選ぶ側が確かめることである。

締め

まとめと次回の問い

本章の問いは、第 11 回の k-means で分けた群を最尤法で推定するとどうなるか、であった。第 6 回の LDA の確率のモデル(群を選び、群の中で正規分布に従って散らばる)から所属のラベルを隠すと、混合正規分布になる。その対数尤度は $\log$ の中に和を含むので、一度には解けない。ただ、 $\log$ の中の和を微分すると責任度が現れる。責任度を固定すれば、割合・平均・共分散は、第 6 回の最尤推定に責任度の重みを付けた式になる。責任度を計算し直す E ステップと、重み付きの最尤推定をする M ステップを交互に繰り返すのが、EM アルゴリズムである。平均の更新 $\text{diag}(\mathbf{R}^\top \mathbf{1}_n)^{-1} \mathbf{R}^\top \mathbf{X}$ は第 11 回の $(\mathbf{G}^\top \mathbf{G})^{-1} \mathbf{G}^\top \mathbf{X}$ の $\mathbf{G}$ を $\mathbf{R}$ に替えたものである。対数

尤度は毎回上がるが、止まる先は局所解のことがある。共分散を共通の球 $\sigma^2 \mathbf{I}$ にして $\sigma^2 \rightarrow 0$ とした極限は、第 11 回の k-means である。小麦の粒の 2 列(粒の長さとの溝の長さ)では、自分で書いた手順がライブラリと同じ $\ell = -296.8$ に着いた。手順は粒の雲に沿った斜めの楕円を推定し、その群は推定に使わなかった品種と 94.8% が一致した(k-means は 75.7%)。最大の責任度が 0.9 未満のあいまいな粒は 16 粒あり、そうした粒ほど品種とずれやすかった。一方、7 列のまま群ごとの共分散を持たせると、面積と周長から計算した緊密度のために群が薄い板に潰れた。答えは初期値ごとに違う所で止まり、最大の ℓ の答えは品種から離れた。

同じ学期の演習 13 では、142 か国を K-means で 3 つのグループに分け、国ごとのシルエット係数を計算する。いちばん低いのはイラク (-0.07) で、自分のグループより隣のグループのほうが近い。演習では、こうした境目の国はグループの方針をそのまま当てはめず、個別に確かめるべきだとした。本章の言葉で言えば、最大の責任度が低い行である。k-means の所属行列は、そうした国も 100% どちらかのグループに入れる。混合正規分布では、所属のあいまいさそのものが確率として出てくる。

最後に、次回への問いを置く。表 9 は、小麦の粒の 2 列を $k = 1, \dots, 5$ の混合正規分布に当てはめたときの対数尤度である。群を増やせば、少なくとも 1 つ前の答えを含む分だけ当てはまりは良くなるので、 ℓ は上がり続ける。第 8 回で、k-means の J が k とともに下がり続けたのと同じである。したがって、推定法(ℓ の最大化)そのものでは k を選べない。共分散を群ごとにするか共通にするかも、パラメータの数を変えるという意味で同じ問題である。では、 k をどう選べばよいか。

表 9: 群の数 k と対数尤度 ℓ (小麦の粒の 2 列、群ごとの共分散、初期値 20 通りの最良)

k	1	2	3	4	5
ℓ (小麦の粒の 2 列)	-381.6	-316.2	-296.8	-291.2	-283.4