第 13 回 残差と多重対応分析

推定に使われた分で割って、1 マスのずれを比べる

本章の問いは、第 12 回の締めで残った「1 セルのズレは大きいのか？」である。新しい表を使い、第 12 回の $(o-e)/\sqrt{e}$ を残差として見直す。独立のモデルを最尤法で推定した後の残差とみると、その分散は 1 より小さく、マスごとに $(1-r_i)(1-c_j)$ になる。この値で割った調整済み残差なら、± 2 の物差しが使える。回帰の残差を $\sqrt{1-h_{ii}}$ で割るのと同じ型である。たくさんのマスを一度に見るときの物差し（ボンフェローニ補正・ホルムの方法）が 5% を守る理由も、その場で示す。最後に、3 つ以上のカテゴリを扱う多重対応分析を第 12 回の手順で書き、2 つのカテゴリなら軸の慣性が $(1 \pm \delta)/2$ になることを証明する。

第 I 部　理論

1 マスのずれは大きいのか

第 12 回の帰結②では、χ^2 統計量がマスごとの $(o_{ij}-e_{ij})/\sqrt{e_{ij}}$ の二乗和に分かれることを見て、「1 セルのズレは大きいのか」という問いが残った。本章の問いはこれである。ここでは人工的なデータで考える。自動販売機 1 台の 1 年の売上 1,000 本を、飲み物 5 種類（缶コーヒー・お茶・水・炭酸・コーンスープ）× 季節 4 つで数えた表である。お茶 × 夏は、行と列が独立なら第 12 回の期待度数で 168.4 本のはずが、実際は 191 本だった。図 1 (a) はこの表のマスごとの $(o-e)/\sqrt{e}$ を並べたもので、お茶 × 夏は $+1.74$ である。このずれは大きいのか。

素朴には、値を標準正規分布の物差しに当てる。標準正規分布なら、絶対値が 2 を超えるのは 4.55% しかない。そこで ± 2 を超えたマスを「偶然では説明しにくいほど大きい」と読む。お茶 × 夏は ± 2 に届かないので、大きくないと答えることになる。

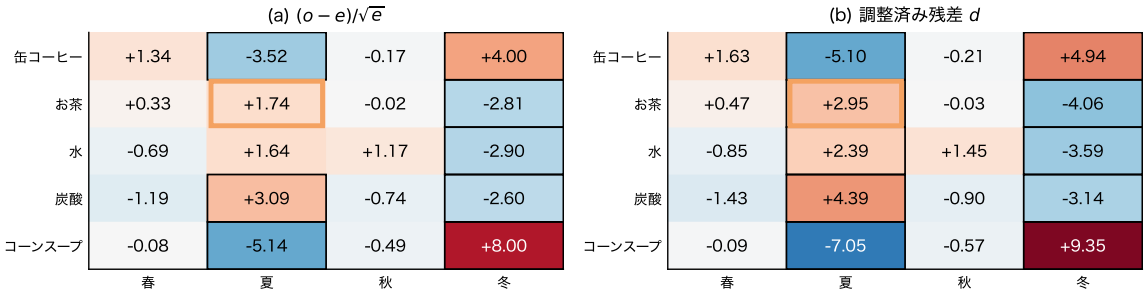


図 1: 人工の自動販売機の売上の表のマスごとのずれ。(a) $(o-e)/\sqrt{e}$、(b) 本章で導く調整済み残差。細い枠は絶対値が 2 以上のマス、橙の枠はお茶 × 夏。色の目盛りは 2 枚で共通

ところが、この物差しは当てにならない。行と列が本当に独立なモデルから、同じ周辺と同じ総数の表を 2,000 回作り、毎回同じように $(o-e)/\sqrt{e}$ を計算してみる。図 2 (a) のように山は標準正規分布より細く、分散は 0.60 しかない。関連がまったく無いのに ± 2 を超えるのは 1.1% で、4.55% よりずっと少ない。± 2 の物差しは、分散がちょうど 1 のときにしか使えない。これが 1 つ目の困りごとである。

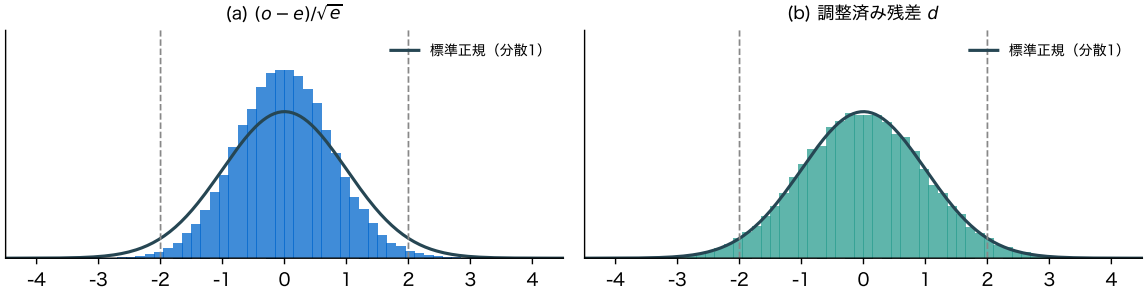


図 2: 人工の自動販売機の表と同じ周辺の独立のモデルから 2,000 回作った表の残差の分布。(a) $(o-e)/\sqrt{e}$、(b) 調整済み残差。曲線は標準正規分布の密度、破線は ± 2

山が細くなる理由の見通しを先に述べる。期待度数 $e_{ij} = nr_ic_j$ は、独立のモデルを最尤法で推定した値である。推定には表の行の合計と列の合計を使うので、残差 $o_{ij} - e_{ij}$ はそのぶん縮む。$(o-e)/\sqrt{e}$ の分散は、1 ではなく $(1-r_i)(1-c_j)$ になる。この値で割り直したものを調整済み残差(adjusted residual)と呼び、その分散は 1 になる(図 1 (b)、図 2 (b))。回帰の残差を、自分の予測に使われた度合いで割り直すのと同じ型である。

困りごとはほかに 2 つある。2 つ目は、たくさんのマスを一度に見ることである。表を眺めて ± 2 を超えたマスを拾えば、20 回比べたことになる。関連が無い表でも、どれかのマスは偶然に超えてしまう。3 つ目は、本数である。お茶 × 夏の表を、同じ形のまま 10 年分に増やしたとする。期待の何倍かは 1.13 倍のまま変わらないのに、$(o-e)/\sqrt{e}$ は $\sqrt{10}$ 倍の +5.50 になり、± 2 を大きく超える。「大きい」とは何が大きいのかを、分けて考える必要がある。

「モデル × 推定法」の地図で位置を確かめる。第 12 回は、独立のモデルにランク Q のずれを足したモデルを、

重み付き最小二乗法で当てはめた。$Q = 0$ のときの誤差が総慣性 χ^2/n であった。本章は同じ独立のモデルを最尤法の側から見直す。当てはまりの悪さを尤度で測る G^2 と、マスごとの調整済み残差を導く。続いて、たくさんのマスを見るときの物差しと、表を 1 枚の絵にするモザイク図を扱う。最後に、3 つ以上のカテゴリを扱う多重対応分析を、第 12 回の手順で書く。

道具：割合・ばらつき・射影

本章で使う道具を先にそろえる。期待度数を「モデルを推定した値」として読み直し、推定した後の残差がどれだけ揺れるかを求めるためである。

1 つ目は、割合の最尤推定である。n 回の試行のそれぞれで、k 個の結果のどれかが確率 π_q で出るとする。結果 q が n_q 回出たとき、対数尤度は定数を除いて

$$\ell(\boldsymbol{\pi}) = \sum_{q=1}^{k} n_q \log \pi_q, \qquad \sum_{q=1}^{k} \pi_q = 1 \tag{1}$$

となる。これを最大にする π_q は、観測した割合 $\hat{\pi}_q = n_q/n$ である。第 6 回のコインの例（$k = 2$）と第 8 回の混合比率 $\hat{\pi}_q = n_q/n$ で、制約を代入して微分し 0 とおいて示した。ここでも計算は同じである。

2 つ目は、数えた度数のばらつきである。平均が μ の度数 o は、μ が大きければ分散もほぼ μ で（ポアソン分布（Poisson distribution）による近似）、分布は正規分布に近い。したがって

$$z = \frac{o - \mu}{\sqrt{\mu}} \tag{2}$$

は平均 0、分散 1 になる。総数 n を固定して n 本をマスに振り分けると（多項分布（multinomial distribution））、マスの度数の分散は厳密には $n\pi(1-\pi)$ で、わずかに小さい。マスどうしにも弱い負の相関がつく。本章では、マスの度数が互いに独立で、分散が平均に等しいとみなす近似を使う。総数を固定したことによる違いは、後の導出で取り除く向きにだけ入る。そのため結果は変わらない。

3 つ目は、線形変換の分散である。成分が互いに独立で分散 1 の量を考える。スカラーなら $\mathbb{V}\mathrm{ar}(az) = a^2$ となる。ベクトル $\boldsymbol{z}$ では、$[\mathbf{A}\boldsymbol{z}]_i = \sum_{i'} a_{ii'} z_{i'}$ は独立な項の和なので、交差項の期待値は 0 になる。第 3 回で係数の分散を求めたときと同じく、分散は重みの二乗和 $[\mathbf{A}\mathbf{A}^\top]_{ii} = \sum_{i'} a_{ii'}^2$ になる。行列 $\mathbf{Z}$ に左右から掛けた $[\mathbf{A}\mathbf{Z}\mathbf{B}]_{ij} = \sum_{i'} \sum_{l} a_{ii'} z_{i'l} b_{lj}$ は独立な項の和なので

$$\mathbb{V}\mathrm{ar}\big([\mathbf{A}\mathbf{Z}\mathbf{B}]_{ij}\big) = \sum_{i'} \sum_{l} a_{ii'}^2 b_{lj}^2 = [\mathbf{A}\mathbf{A}^\top]_{ii}\, [\mathbf{B}^\top\mathbf{B}]_{jj} \tag{3}$$

となる。$\mathbf{B}$ が 1×1 の 1 なら 2 つ目の式に、さらに $\mathbf{A}$ も 1×1 ならスカラーの式に戻る。

4 つ目は、1 本の向きを除く行列である。長さ 1 のベクトル $\boldsymbol{u}$ について

$$\mathbf{Q}_{\boldsymbol{u}} = \mathbf{I} - \boldsymbol{u}\boldsymbol{u}^\top \tag{4}$$

とおく。$\mathbf{Q}_{\boldsymbol{u}}\boldsymbol{u} = \boldsymbol{u} - \boldsymbol{u}(\boldsymbol{u}^\top\boldsymbol{u}) = 0$ なので、$\mathbf{Q}_{\boldsymbol{u}}$ を掛けると $\boldsymbol{u}$ の向きの成分が取り除かれる(図 3)。第 3 回の射影行列 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$ で、$\mathbf{X}$ が長さ 1 の列 $\boldsymbol{u}$ の 1 本だけなら $\mathbf{H} = \boldsymbol{u}\boldsymbol{u}^\top$ となる。つまり $\mathbf{Q}_{\boldsymbol{u}} = \mathbf{I} - \mathbf{H}$ は、第 3 回で残差 $\boldsymbol{e} = (\mathbf{I} - \mathbf{H})\boldsymbol{y}$ を作った行列にあたる。対称かつ冪等なので $\mathbf{Q}_{\boldsymbol{u}}\mathbf{Q}_{\boldsymbol{u}}^\top = \mathbf{Q}_{\boldsymbol{u}}$ が成り立つ。対角は $1 - u_j^2$、対角の和は(次元の数) -1 である。

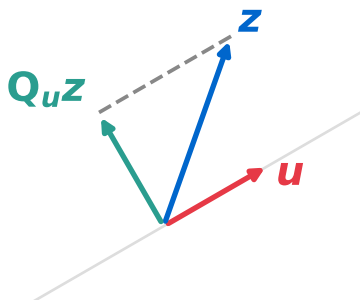


図 3: 1 本の向きを除く行列(概念図)。$\mathbf{Q}_{\boldsymbol{u}}\boldsymbol{z}$ は、$\boldsymbol{z}$ から $\boldsymbol{u}$ の向きの成分(破線)を引いたもの

5 つ目は、± 2 の根拠である。標準正規分布に従う量の絶対値が 2 を超える確率は $2\{1 - \Phi(2)\} = 4.55\%$ である(Φ は標準正規分布の累積分布関数。ちょうど 5% にするなら ± 1.96)。この確率は、分散がちょうど 1 のときの値である。分散が $v < 1$ なら、超える確率は $2\{1 - \Phi(2/\sqrt{v})\}$ に下がる。$v = 0.6$ では図 4 のように 0.98% になる。

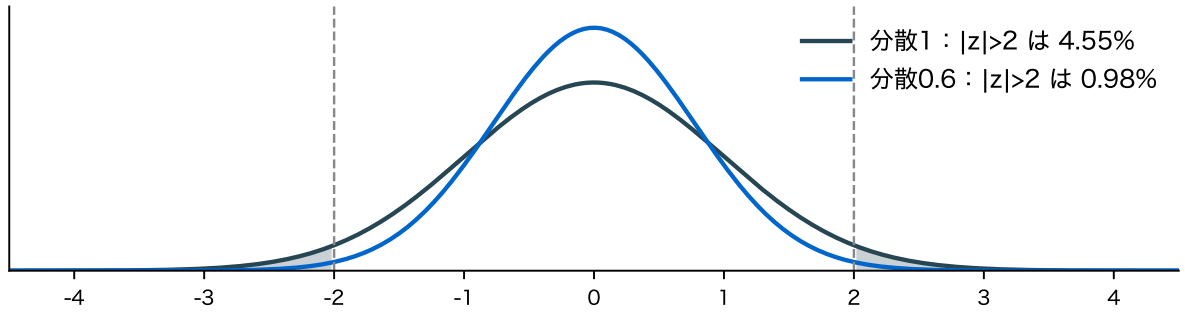


図 4: 平均 0 の正規分布の密度(概念図)。破線は ± 2。分散が 1 より小さいと、± 2 を超える確率は 4.55% より小さくなる

独立のモデルとその尤度

第 12 回は、独立の表 $\boldsymbol{r}\boldsymbol{c}^\top$ を、周辺をそのまま使って作った。本章では同じ独立のモデルを確率のモデルとして書き、その中の数を推定する。

自動販売機で売れた n 本の 1 本 1 本が、互いに独立に、確率 π_{ij} で飲み物 i × 季節 j のマスに入るとする($\sum_{i,j}\pi_{ij} = 1$)。行と列が独立であるとは

$$\pi_{ij} = \pi_{i\cdot}\,\pi_{\cdot j} \tag{5}$$

が成り立つことをいう。$\pi_{i\cdot}$ は飲み物 i が選ばれる確率、$\pi_{\cdot j}$ は季節 j に売れる確率である（$\sum_i \pi_{i\cdot} = \sum_j \pi_{\cdot j} = 1$）。第 12 回の $p_{ij} = r_i c_j$ を、観測した比率ではなく確率の言葉で書いた。行列で書けば $\boldsymbol{\Pi} = \boldsymbol{\pi}_r \boldsymbol{\pi}_c^\top$ となり、第 12 回の $Q = 0$ と同じくランク 1 である。推定するのは $\boldsymbol{\pi}_r$ と $\boldsymbol{\pi}_c$ だけになる。

当てはまりの良さは尤度で測る。1 本がマス (i, j) に入る確率は π_{ij} で、そこに o_{ij} 本が入った。したがって対数尤度は、定数を除いて

$$\ell(\boldsymbol{\Pi}) = \sum_{i=1}^{I} \sum_{j=1}^{J} o_{ij} \log \pi_{ij} \tag{6}$$

となる。(1) 式の k 個の結果を、IJ 個のマスに置き換えた形である。独立のモデル (5) 式を代入すると $\log \pi_{ij} = \log \pi_{i\cdot} + \log \pi_{\cdot j}$ となる。j について足すと行の合計 $o_{i+} = \sum_j o_{ij}$ が、i について足すと列の合計 $o_{+j} = \sum_i o_{ij}$ が出てくるので

$$\ell(\boldsymbol{\pi}_r, \boldsymbol{\pi}_c) = \sum_{i=1}^{I} o_{i+} \log \pi_{i\cdot} + \sum_{j=1}^{J} o_{+j} \log \pi_{\cdot j} \tag{7}$$

となる。対数尤度が、行の確率だけの部分と列の確率だけの部分の和に分かれた。行列で書けば、マスごとの積を $\odot$、成分ごとの対数を log として

$$\ell = \mathbf{1}_I^\top (\mathbf{O} \odot \log \boldsymbol{\Pi}) \mathbf{1}_J = (\mathbf{O}\mathbf{1}_J)^\top \log \boldsymbol{\pi}_r + (\mathbf{O}^\top \mathbf{1}_I)^\top \log \boldsymbol{\pi}_c \tag{8}$$

と書ける。$\mathbf{O}\mathbf{1}_J$ は行の合計、$\mathbf{O}^\top \mathbf{1}_I$ は列の合計を並べたベクトルである。独立のモデルの尤度は、表の中身のうち周辺しか使わない。$I = J = 1$ なら (6) 式の 1 マスに戻る。

最尤推定と当てはまりの悪さ

独立のモデルの対数尤度 (7) 式は、行の部分と列の部分に分かれている。だから別々に最大にすればよい。行の部分 $\sum_i o_{i+} \log \pi_{i\cdot}$ は、(1) 式で n_q を o_{i+} としたものである。列の部分も同じなので、道具①より

$$\hat{\pi}_{i\cdot} = \frac{o_{i+}}{n} = r_i, \qquad \hat{\pi}_{\cdot j} = \frac{o_{+j}}{n} = c_j, \qquad \hat{e}_{ij} = n\hat{\pi}_{i\cdot}\hat{\pi}_{\cdot j} = n r_i c_j \tag{9}$$

を得る。行列で書けば $\hat{\boldsymbol{\Pi}} = \boldsymbol{r}\boldsymbol{c}^\top$ となる。第 12 回で「行の合計 × 列の合計 ÷ 総数」として作った期待度数 e_{ij} は、独立のモデルを最尤法で推定したときの予測値だったわけである。以下、$\hat{e}_{ij}$ を第 12 回と同じく e_{ij} と書く。

推定した独立のモデルがどれだけ表に合っていないかも、尤度で測れる。π_{ij} に何の制約も置かないモデルを飽和モデル(saturated model)という。飽和モデルでは (6) 式が (1) 式そのものになり、$\hat{\pi}_{ij} = o_{ij}/n = p_{ij}$ で表が完全に再現される。この対数尤度と、独立のモデルの対数尤度の最大値 $\hat{\ell}$ との差の 2 倍

$$G^2 = 2(\ell_{\text{飽和}} - \hat{\ell}) = 2\sum_{i,j} o_{ij} \log \frac{o_{ij}}{e_{ij}} \tag{10}$$

を G^2 統計量(尤度比統計量、逸脱度(deviance))と呼ぶ(定義 1)。2 つ目の等号は $\log(o_{ij}/n) - \log(e_{ij}/n) = \log(o_{ij}/e_{ij})$ から出る。G^2 は第 9 回で比べた $-2\hat{\ell}$ と同じ尺度で、飽和モデルを基準にした値である。人工データでは $G^2 = 158.6$ である。

この G^2 は、第 12 回の χ^2 統計量 $\sum(o-e)^2/e$ と近い値をとる。これを示すために対数の近似を使う。x が 0 に近いとき

$$\log(1+x) \approx x - \frac{x^2}{2} \tag{11}$$

が成り立つ($\log(1+x)$ を $x = 0$ のまわりで 2 次まで展開したもの。$x = 0.1$ なら左辺は 0.0953、右辺は 0.0950)。$o = e(1+x)$、$x = (o-e)/e$ とおき、(11) 式を使うと

$$\begin{aligned} o \log \frac{o}{e} = e(1+x)\log(1+x) &\approx e(1+x)\Big(x - \frac{x^2}{2}\Big) \approx e\Big(x + \frac{x^2}{2}\Big) \\ G^2 \approx 2\sum_{i,j}(o_{ij} - e_{ij}) + \sum_{i,j} \frac{(o_{ij}-e_{ij})^2}{e_{ij}} &= \chi^2 \end{aligned} \tag{12}$$

となる。1 行目の最後では x^3 の項を捨てた。2 行目の第 1 項は、e_{ij} の合計が n なので 0 である。独立のモデルが正しく、どのマスでも o/e が 1 に近い(x が小さい)大標本を考える。そこでは、最尤法で測った当てはまりの悪さ G^2 と、第 12 回の重み付き最小二乗法で測った当てはまりの悪さ χ^2 が一致する。第 6 回では、正規誤差の線形回帰で最小二乗法と最尤法が同じ答えを与えることを見た。分割表の独立のモデルでも、2 つの推定法は同じ物差しにたどり着く。人工データの表では $\chi^2 = 163.1$ で、G^2 と同じではない(独立のモデルから遠いマスがあるため)。独立のモデルから作った表で両者が近いことは、第 II 部で確かめる。

G^2 もマスごとに分けられる。χ^2 が標準化残差の二乗和であったのと同じように

$$g_{ij} = \text{sign}(o_{ij} - e_{ij})\sqrt{2\Big(o_{ij}\log\frac{o_{ij}}{e_{ij}} - (o_{ij} - e_{ij})\Big)} \tag{13}$$

とおくと、$\sum(o-e) = 0$ より $\sum_{i,j} g_{ij}^2 = G^2$ となる。これを逸脱度残差(deviance residual)と呼ぶ(定義 1)。sign は正なら 1、負なら -1 を返す。図 5 のように、o が e に近いマスでは、逸脱度残差は標準化残差とほぼ重なる。離れるのは o/e が 1 から遠いマスである。とくに観測が 0 本のマスでは $g^2 = 2e$ で、標準化残差の二乗 e のちょうど 2 倍になる。

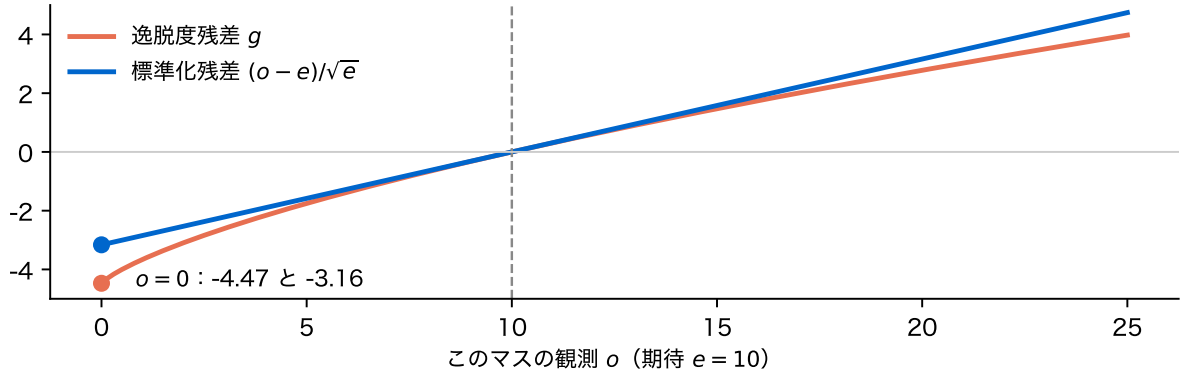


図 5: 期待度数 e = 10 のマスで観測 o を動かしたときの、逸脱度残差と標準化残差（概念図）。破線は o = e

定義 1 (G² 統計量と逸脱度残差)**.** 独立のモデルを最尤法で推定した期待度数 $e_{ij} = nr_ic_j$ について、$G^2 = 2\sum_{i,j} o_{ij}\log(o_{ij}/e_{ij})$ を G^2 統計量と呼ぶ。飽和モデルとの対数尤度の差の 2 倍であり、o/e が 1 に近いとき χ^2 統計量に近づく。G^2 をマスに分けた $g_{ij} = \mathrm{sign}(o_{ij}-e_{ij})\sqrt{2\{o_{ij}\log(o_{ij}/e_{ij}) - (o_{ij}-e_{ij})\}}$ を逸脱度残差と呼ぶ。

残差の分散

$(o-e)/\sqrt{e}$ の分散を、推定したものが少ない順に、1 マス、1 行、表全体と広げて求める。期待度数は表の行の合計と列の合計から推定したので、推定に使った分だけ残差は小さくなるはずである。導出には、道具③・④に加えて、次の近似を使う。

定義 2 (小さなずれの積を捨てる)**.** a, b, g が 0 に近いとき、$1/(1+g) \approx 1-g$ であり、小さな数どうしの積 ab、ag などを捨てると

$$\frac{(1+a)(1+b)}{1+g} \approx 1 + a + b - g$$

となる。たとえば $a = 0.1$、$b = 0.05$、$g = 0.02$ なら、左辺は 1.132、右辺は 1.13 である。

まず、何も推定しない場合を考える。本当の確率 π_{ij} がわかっていれば、期待度数は $n\pi_{ij}$ になる。道具②より

$$z_{ij} = \frac{o_{ij} - n\pi_{ij}}{\sqrt{n\pi_{ij}}} \tag{14}$$

は平均 0、分散 1 である。この z_{ij} を並べた $I \times J$ の行列を $\mathbf{Z}$ とし、マスどうしは独立とみなす。この場合なら、± 2 の物差しがそのまま使える。

次に、1 行ずつ考える。季節の確率 $\pi_{\cdot j}$ はわかっているとする。行 i の確率 $\pi_{i\cdot}$ の代わりに行の合計 o_{i+} を使い、期待度数を $o_{i+}\pi_{\cdot j}$ とする。$o_{i+} - n\pi_{i\cdot} = \sum_l (o_{il} - n\pi_{il}) = \sum_l \sqrt{n\pi_{il}}\, z_{il}$ なので、残差を $\sqrt{n\pi_{ij}} = \sqrt{n\pi_{i\cdot}}\sqrt{\pi_{\cdot j}}$ で割ると

$$\frac{o_{ij}-o_{i+}\pi_{\cdot j}}{\sqrt{n\pi_{ij}}} = z_{ij} - \sqrt{\pi_{\cdot j}}\sum_{l=1}^{J}\sqrt{\pi_{\cdot l}}\,z_{il} = \left[(\mathbf{I}-\sqrt{\boldsymbol{\pi}_c}\sqrt{\boldsymbol{\pi}_c}^{\top})\boldsymbol{z}_i\right]_j \tag{15}$$

となる。$\boldsymbol{z}_i$ は $\mathbf{Z}$ の第 i 行を縦にしたもの、$\sqrt{\boldsymbol{\pi}_c} = (\sqrt{\pi_{\cdot 1}}, \ldots, \sqrt{\pi_{\cdot J}})^{\top}$ は長さ 1 のベクトルである。行の合計を使うと、行のずれ $\boldsymbol{z}_i$ から $\sqrt{\boldsymbol{\pi}_c}$ の向きの成分を取り除くことになる。道具③・④より、その分散は $[\mathbf{Q}\mathbf{Q}^{\top}]_{jj} = 1-\pi_{\cdot j}$ で、1 より小さい。

最後に、表全体を考える。実際の期待度数 $e_{ij} = o_{i+}o_{+j}/n$ は、行の合計と列の合計の両方を使い、総数 n も表から数える。総数の期待値を μ とし、ここまでの $n\pi_{ij}$ を $\mu\pi_{ij}$ と読む。行の合計・列の合計・総数が、期待される値から割合でずれる量を α_i、β_j、γ とおくと

$$o_{i+} = \mu\pi_{i\cdot}(1+\alpha_i), \qquad o_{+j} = \mu\pi_{\cdot j}(1+\beta_j), \qquad n = \mu(1+\gamma) \tag{16}$$

である。ずれが小さければ、定義 2 より

$$e_{ij} = \frac{o_{i+}o_{+j}}{n} = \mu\pi_{ij}\frac{(1+\alpha_i)(1+\beta_j)}{1+\gamma} \approx \mu\pi_{ij}(1+\alpha_i+\beta_j-\gamma) \tag{17}$$

となる。3 つのずれは、どれも $\mathbf{Z}$ で書ける。$\boldsymbol{u} = \sqrt{\boldsymbol{\pi}_r}$、$\boldsymbol{v} = \sqrt{\boldsymbol{\pi}_c}$ とおく。行のずれは、(15) 式を導いたときと同じく $\mu\pi_{i\cdot}\alpha_i = o_{i+} - \mu\pi_{i\cdot} = \sum_l \sqrt{\mu\pi_{il}}\,z_{il}$ である。これに $\pi_{\cdot j}$ を掛け、$\sqrt{\mu\pi_{ij}} = \sqrt{\mu\pi_{i\cdot}}\sqrt{\pi_{\cdot j}}$ で割ると

$$\frac{\mu\pi_{ij}\alpha_i}{\sqrt{\mu\pi_{ij}}} = \sqrt{\pi_{\cdot j}}\sum_{l=1}^{J}\sqrt{\pi_{\cdot l}}\,z_{il} = [\mathbf{Z}\boldsymbol{v}\boldsymbol{v}^{\top}]_{ij}$$

となる。列のずれも同じ計算で $[\boldsymbol{u}\boldsymbol{u}^{\top}\mathbf{Z}]_{ij}$ になる。総数のずれは $\mu\gamma = \sum_{k,l}\sqrt{\mu\pi_{kl}}\,z_{kl}$ から $[\boldsymbol{u}\boldsymbol{u}^{\top}\mathbf{Z}\boldsymbol{v}\boldsymbol{v}^{\top}]_{ij}$ になる。$o_{ij}-\mu\pi_{ij} = \sqrt{\mu\pi_{ij}}\,z_{ij}$ から (17) 式のずれの項を引き、$\sqrt{\mu\pi_{ij}}$ で割ると

$$\frac{o_{ij}-e_{ij}}{\sqrt{\mu\pi_{ij}}} \approx \left[\mathbf{Z}-\mathbf{Z}\boldsymbol{v}\boldsymbol{v}^{\top}-\boldsymbol{u}\boldsymbol{u}^{\top}\mathbf{Z}+\boldsymbol{u}\boldsymbol{u}^{\top}\mathbf{Z}\boldsymbol{v}\boldsymbol{v}^{\top}\right]_{ij} = \left[(\mathbf{I}-\boldsymbol{u}\boldsymbol{u}^{\top})\,\mathbf{Z}\,(\mathbf{I}-\boldsymbol{v}\boldsymbol{v}^{\top})\right]_{ij}$$

となる。分母の $\sqrt{\mu\pi_{ij}}$ を $\sqrt{e_{ij}}$ に、$\boldsymbol{\pi}_r$、$\boldsymbol{\pi}_c$ を推定値 $\boldsymbol{r}$、$\boldsymbol{c}$ に置き換えても、変わるのは 2 次の項だけである。したがって

$$\sqrt{n}\,s_{ij} = \frac{o_{ij}-e_{ij}}{\sqrt{e_{ij}}} \approx \left[(\mathbf{I}-\sqrt{\boldsymbol{r}}\sqrt{\boldsymbol{r}}^{\top})\,\mathbf{Z}\,(\mathbf{I}-\sqrt{\boldsymbol{c}}\sqrt{\boldsymbol{c}}^{\top})\right]_{ij} \tag{18}$$

を得る。$\sqrt{\boldsymbol{r}} = \mathbf{D}_r^{1/2}\mathbf{1}_I$、$\sqrt{\boldsymbol{c}} = \mathbf{D}_c^{1/2}\mathbf{1}_J$ は第 12 回の帰結④の 2 本のベクトルで、$\pi_{i\cdot}$、$\pi_{\cdot j}$ をその推定値 r_i、c_j で置き換えた。s_{ij} は第 12 回の標準化残差行列 $\mathbf{S}$ のマスである。左から掛けた行列は各列から $\sqrt{\boldsymbol{r}}$ の向きを取り除く。右から掛けた行列は各行から $\sqrt{\boldsymbol{c}}$ の向きを取り除く。総数 n を固定した多項分布による $\mathbf{Z}$ のずれは、$\sqrt{\boldsymbol{r}}\sqrt{\boldsymbol{c}}^{\top}$ の向きにしか入らない。そのため、この両側の操作で消える。(3) 式と、道具④の $\mathbf{Q}\mathbf{Q}^{\top} = \mathbf{Q}$ の対角から

$$\mathbb{V}\mathrm{ar}(\sqrt{n}\, s_{ij}) \approx (1 - r_i)(1 - c_j) \tag{19}$$

となる。列の合計を使わなければ、$(1 - c_j)$ だけの (15) 式に戻る。$(o - e)/\sqrt{e}$ の分散は 1 ではなく、行の合計と列の合計の大きいマスほど小さい。

そこで、この分散の平方根で割り直す。

$$d_{ij} = \frac{o_{ij} - e_{ij}}{\sqrt{e_{ij}\,(1 - r_i)(1 - c_j)}} = \frac{\sqrt{n}\, s_{ij}}{\sqrt{(1 - r_i)(1 - c_j)}} \tag{20}$$

を調整済み残差と呼ぶ(定義 3)。独立のモデルのもとで、d_{ij} は平均 0、分散 1 の正規分布に近い。だから ± 2 の物差しを当てられる。$(1 - r_i)(1 - c_j) < 1$ なので、$|d_{ij}|$ は必ず $|\sqrt{n} s_{ij}|$ より大きい。

定義 3 (調整済み残差)**.** 独立のモデルの期待度数 $e_{ij} = n r_i c_j$ について、$d_{ij} = (o_{ij} - e_{ij})/\sqrt{e_{ij}(1 - r_i)(1 - c_j)}$ を調整済み残差と呼ぶ。$(o_{ij} - e_{ij})/\sqrt{e_{ij}} = \sqrt{n} s_{ij}$ を標準化残差(ピアソン残差)と呼ぶ。独立のモデルのもとで、標準化残差の分散は $(1 - r_i)(1 - c_j)$、調整済み残差の分散は 1 に近い。

計算の手順

分割表のマスのずれを読む計算を、行列の形でまとめる($\oslash$ はマスごとの割り算)。

1. $\mathbf{P} = \mathbf{O}/n$、$\boldsymbol{r} = \mathbf{P}\mathbf{1}_J$、$\boldsymbol{c} = \mathbf{P}^\top \mathbf{1}_I$ を求める。これは独立のモデルの最尤推定値 (9) 式である
2. 期待度数 $\mathbf{E} = n\boldsymbol{r}\boldsymbol{c}^\top$ を作り、当てはまりの悪さ $G^2 = 2\,\mathbf{1}_I^\top (\mathbf{O} \odot \log(\mathbf{O} \oslash \mathbf{E}))\mathbf{1}_J$ と $\chi^2 = n\|\mathbf{S}\|_F^2$ を求める(度数 0 のマスは G^2 の和から除く)
3. 第 12 回の標準化残差行列 $\mathbf{S} = \mathbf{D}_r^{-1/2}(\mathbf{P} - \boldsymbol{r}\boldsymbol{c}^\top)\mathbf{D}_c^{-1/2}$ を作り、$\sqrt{n}$ 倍して標準化残差を得る
4. 左右から対角行列 $(\mathbf{I} - \mathbf{D}_r)^{-1/2}$、$(\mathbf{I} - \mathbf{D}_c)^{-1/2}$ を掛けて、調整済み残差の行列 $\mathbf{D}_d = \sqrt{n}(\mathbf{I} - \mathbf{D}_r)^{-1/2}\mathbf{S}(\mathbf{I} - \mathbf{D}_c)^{-1/2}$ を得る
5. ± 2 と比べ、ずれの強さは $\mathbf{O} \oslash \mathbf{E}$(期待の何倍か)で読む

手順 3 までは第 12 回の手順 2 と同じである。違うのは手順 4 だけで、行と列の周辺から決まる対角行列を掛ける。特異値分解は要らない。

理論の帰結:推定に使われた分で割る

導出から、残差の性質がいくつか読み取れる。第 1 に、標準化残差の分散を全マスで足すと

$$\sum_{i=1}^{I}\sum_{j=1}^{J}(1 - r_i)(1 - c_j) = \Big(I - \sum_i r_i\Big)\Big(J - \sum_j c_j\Big) = (I - 1)(J - 1) \tag{21}$$

となる。この値は χ^2 統計量の自由度であり、(18) 式の両側の行列の対角の和の積でもある。χ^2 は標準化残差の二乗和なので、独立のモデルのもとでの χ^2 の期待値は自由度に等しい。1 マスあたりの平均は

$(I-1)(J-1)/(IJ)$ で、人工データの 5×4 の表では 0.60 である。図 2 (a) の分散 0.60 はこの値にあたる。図 6 はマスごとの値で、行の合計と列の合計の大きいマス（お茶 × 夏など）ほど小さい。

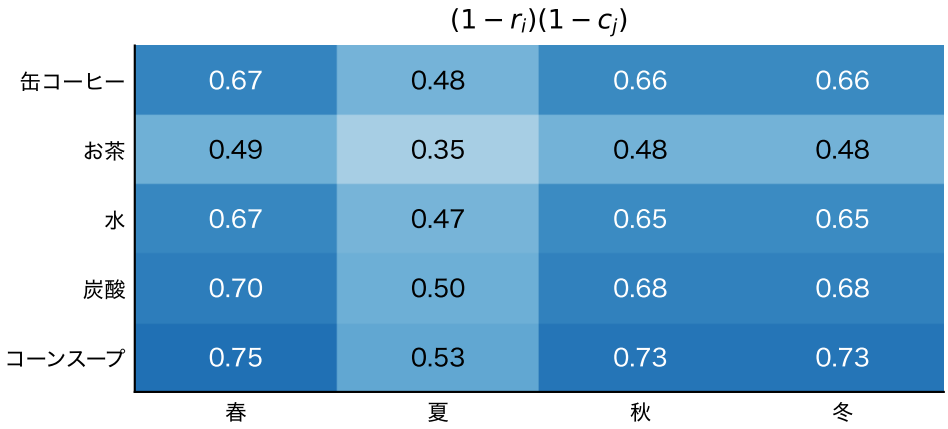


図 6: 人工の自動販売機の表の、標準化残差の分散 $(1-r_i)(1-c_j)$

第 2 に、$h_{ij}=1-(1-r_i)(1-c_j)=r_i+c_j-r_ic_j$ を、マス (i,j) が推定に使われた度合いとみると

$$\sum_{i,j} h_{ij} = IJ-(I-1)(J-1) = I+J-1 \tag{22}$$

となる。$I+J-1$ は、独立のモデルで表から推定した数の個数である。内訳は、総数 1 個、行の確率 $I-1$ 個（足すと 1 なので 1 つ少ない）、列の確率 $J-1$ 個である。推定に使われた分だけ差が縮むことは、自分も入った平均と比べる場合にも起きる。3 人の班でみかんを 9・3・3 個食べたとき、A さんとほかの 2 人の平均との差は 6 個だが、3 人の平均 5 個との差は 4 個 $=6\times(1-1/3)$ になる。平均の中で自分の重みが大きいほど、差は縮む。行の合計と列の合計の大きいマスは、期待度数を自分で引き寄せる。

第 3 に、この形は回帰とまったく同じ型をしている。第 3 回で見たとおり、回帰の残差は $\boldsymbol{e}=(\mathbf{I}-\mathbf{H})\boldsymbol{y}=(\mathbf{I}-\mathbf{H})\boldsymbol{\varepsilon}$ と誤差だけで書ける。誤差が互いに独立で分散 σ^2 なら、道具③を σ^2 倍して $\mathbb{V}\mathrm{ar}(e_i)=\sigma^2[(\mathbf{I}-\mathbf{H})(\mathbf{I}-\mathbf{H})^\top]_{ii}$ となる。$\mathbf{I}-\mathbf{H}$ は対称かつ冪等なので $(\mathbf{I}-\mathbf{H})(\mathbf{I}-\mathbf{H})^\top=\mathbf{I}-\mathbf{H}$ であり、$\mathbf{H}$ の対角を h_{ii} と書くと

$$\mathbb{V}\mathrm{ar}(e_i)=\sigma^2(1-h_{ii}),\qquad \sum_i h_{ii}=\operatorname{tr}\mathbf{H}=p \tag{23}$$

が成り立つ。和の式は第 3 回のトレース $\operatorname{tr}\mathbf{H}=p$ である。h_{ii} をてこ比（leverage）と呼ぶ。行 i が自分の予測に使われた度合いで、その和は推定した係数の個数 p になる。だから回帰の残差は $\hat{\sigma}\sqrt{1-h_{ii}}$ で割ってそろえる。表 1 のとおり、分割表の調整済み残差は、残差を $\sqrt{e_{ij}(1-h_{ij})}$ で割ったものである。どちらも「推定に使われた分だけ縮んだ残差を、縮んだ分で割り戻す」操作である。

表 1: 回帰の残差と分割表の残差

	回帰(第 3 回)	分割表(本章)
残差	$\boldsymbol{e} = (\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}$	$\sqrt{n}\mathbf{S} \approx$ $(\mathbf{I} - \sqrt{\boldsymbol{r}}\sqrt{\boldsymbol{r}}^{\top})\mathbf{Z}(\mathbf{I} - \sqrt{\boldsymbol{c}}\sqrt{\boldsymbol{c}}^{\top})$
推定に使われた度合い	てこ比 h_{ii}	$h_{ij} = r_i + c_j - r_i c_j$
その和	$\operatorname{tr}\mathbf{H} = p$	$I + J - 1$
割るもの	$\hat{\sigma}\sqrt{1 - h_{ii}}$	$\sqrt{e_{ij}(1 - h_{ij})}$

ただし、割り直しで値が変わる大きさは違う。回帰ではてこ比の平均が p/n で、行が多ければ小さい。そのため割り直しても値はほとんど変わらない。分割表では r_i の平均が $1/I$、c_j の平均が $1/J$ になる。行や列の数が少ない表ほど、割り直しで値が大きく変わる。

第 4 に、割り直せば分散は 1 になる。困りごと①で独立のモデルから作った 2,000 個の表で、調整済み残差を計算する。図 2 (b) のように山は標準正規分布に重なり、分散は 1.00、± 2 を超えるのは 4.5% である。

お茶 × 夏に戻ると、$(1 - r_2)(1 - c_2) = 0.347$ である。標準化残差 $+1.74$ をその平方根で割ると、調整済み残差は $+2.95$ となり(図 1 (b))、± 2 を超える。標準化残差に ± 2 を当てると、このようなずれを見落とす。自販機の表で ± 2 を超えるマスは、標準化残差では 8 個、調整済み残差では 10 個である。困りごと①の山が細かったのは、推定に使われた分だけ残差が縮んでいたからであった。

理論の帰結：たくさんのマスを見る

この節では、次の道具を使う。

定義 4 (確率の和で押さえる)**.** 事象 $A_1, \ldots, A_M$ のどれかが起きる確率は、それぞれの確率の和を超えない。

$$\Pr(A_1 \text{ または } \cdots \text{ または } A_M) \le \sum_{k=1}^{M} \Pr(A_k)$$

右辺は、2 つ以上が同時に起きる場合を重ねて数えるからである。

調整済み残差の ± 2 は、1 つのマスを見るときの物差しである。表のすべてのマスを眺めて ± 2 を超えたものを拾うと、何度も比べたことになる(困りごと②)。困りごと①で独立のモデルから作った表では、本当の関連はどこにも無い。それでも、20 マスのどれかが ± 2 を超えた表が 53% もあった。M 個のマスのどれか 1 つが物差しを超える確率は、定義 4 より 1 つずつの確率の和、すなわち M 倍を超えない。そこで 1 つずつの確率を $0.05/M$ に下げ、物差しを $\pm z_{0.025/M}$ にする(z_α は標準正規分布で上側の確率が α になる値)。こうすれば、どれか 1 つでも超える確率を 5% 以下に抑えられる。これをボンフェローニ補正(Bonferroni correction)と呼ぶ。20 マスなら物差しは ± 3.02 で、独立の表のどれかのマスが超える割合は 4.5% になった。第 4 回では、λ の候補をテストの行で比べて選ぶと、報告される誤差が楽観的になった。同じように、マスを何度も見ると「大きいマス」が楽観的に見つかる。見るマスを先に決めておくか、見た数に応じて物差しを上げる。計算の手順の 5 で比べる物差しは、見るマスの数 M に応じて $\pm z_{0.025/M}$ に上げる。コインを 5 回投げて 5 回とも表が出る確率は

3.1% しかない。それでも 20 人が投げれば、誰か 1 人がそうなる確率は 47% ある。その人のコインに細工があるとは言えないのと同じである。

ボンフェローニ補正は、どのマスも同じ厳しい物差しと比べるので、本当のずれを見落としやすい。そこで、$|d|$ の大きい順に並べ、k 番目のマスを $\pm z_{0.025/(M-k+1)}$ と比べる。初めて届かなかったところで止め、それより前のマスを「大きい」とする。1 番目は M マスのボンフェローニと同じ物差しである。超えたマスを 1 つ除くたびに、残りのマスの数で物差しを決め直す。これをホルムの方法（Holm method）と呼ぶ（定義 5）。ホルムの方法でも、本当のずれが無いマスを 1 つでも「大きい」とする確率は 5% 以下になる。本当のずれが無いマスを m_0 個とし、その中で最初に「大きい」とされたマスが k 番目だったとする。それより前の $k-1$ 個はすべてずれの有るマスなので、$k-1 \le M-m_0$ である。このマスと比べた物差しは $z_{0.025/(M-k+1)}$ で、$M-k+1 \ge m_0$ より $z_{0.025/m_0}$ 以上である。つまり、ずれの無いマスを拾うときには、ずれの無い m_0 マスのどれかが $\pm z_{0.025/m_0}$ を超えている。定義 4 より、その確率は $m_0 \times 0.05/m_0 = 0.05$ 以下である。m_0 がいくつでもこれが成り立つので、関連がまったく無い表（$m_0 = M$）だけでなく、ずれの有るマスが混じった表でも 5% は守られる。それでいて、物差しはボンフェローニより低いか同じなので、拾えるマスはボンフェローニより少なくならない。自販機の表では、ボンフェローニで超えるのは 8 マスで、お茶 × 夏（$|d| = 2.95$）は ± 3.02 に届かない。ホルムの方法ではお茶 × 夏は 9 番目で、物差しは ± 2.87 に下がり、超える（図 7）。

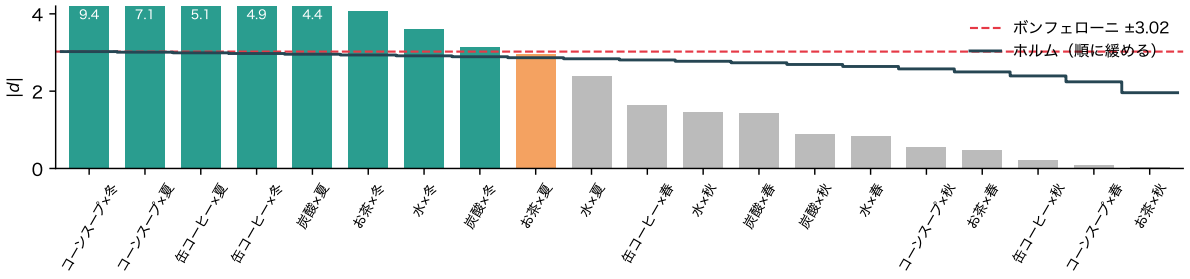


図 7: 人工の自動販売機の表の 20 マスの調整済み残差の絶対値を大きい順に並べたもの。赤の破線はボンフェローニの物差し、黒の階段はホルムの方法の物差し。緑は超えたマス、橙はお茶 × 夏。4.2 を超える棒は上を切り、値を書いた

定義 5 (ボンフェローニ補正とホルムの方法)**.** M 個のマスの調整済み残差を見るとき、どれも $\pm z_{0.025/M}$ と比べることをボンフェローニ補正と呼ぶ。絶対値の大きい順に k 番目を $\pm z_{0.025/(M-k+1)}$ と比べ、初めて届かなかったところで止めることをホルムの方法と呼ぶ。どちらも、本当のずれが無いマスを 1 つでも「大きい」とする確率を 5% 以下に抑える。

もう 1 つ、「大きい」には 2 つの意味がある。表のすべての度数を t 倍しても、r_i、c_j と o_{ij}/e_{ij} は変わらない。一方で $o_{ij}-e_{ij}$ は t 倍、$\sqrt{e_{ij}}$ は $\sqrt{t}$ 倍になるので、調整済み残差は $\sqrt{t}$ 倍になる（図 8）。χ^2 も t 倍になる。調整済み残差で分かるのは「独立のモデルの偶然のゆらぎでは説明しにくいか」である。本数が多ければ、わずかなずれでも必ず ± 2 を超える。ずれの強さを言うには、観測が期待の何倍か o_{ij}/e_{ij} を添える。表全体の強さには、クラメールの V（Cramér's V）を使う。総慣性 χ^2/n をその最大値 $\min(I,J)-1$ で割り、平方根をとった値

$$V = \sqrt{\frac{\chi^2}{n\,(\min(I,J)-1)}} \tag{24}$$

である。V は 0（独立）から 1 の間にあり、度数を t 倍しても変わらない。人工データでは $V = 0.233$ である。困りごと③の 10 年分の表では、お茶 × 夏の調整済み残差は $+9.33$ に大きくなるが、期待の何倍かと V は 1 年分と変わらない。本数で変わるのは「偶然では説明しにくいか」だけである。

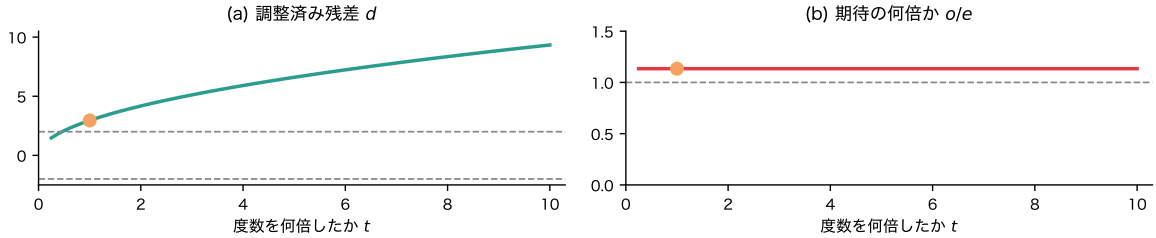


図 8: 人工の自動販売機の表の度数をすべて t 倍したときの、お茶 × 夏の (a) 調整済み残差と (b) 期待の何倍か。橙の点が元の表（t = 1）、破線は (a) ±2、(b) 1 倍

表を絵にする：モザイク図

調整済み残差の表からは、マスの本数の大小が見えない。期待の何倍かという強さと、偶然では説明しにくいかを、1 枚の絵で見せる方法がある。図 9 (a) では、まず横幅を季節（列）の本数の割合 c_j に比例させる。次に、各季節の中を、その季節に売れた飲み物の割合 o_{ij}/o_{+j} の高さで縦に区切る。四角の面積は $c_j \times o_{ij}/o_{+j} = o_{ij}/n$ となり、そのマスの本数に比例する。このような図をモザイク図（mosaic plot）と呼ぶ（定義 6）。

行と列が独立なら、どの季節でも飲み物の割合は同じ r_i である。そのため期待度数で描いた (b) では、横の線が一直線にそろう。(a) で線が上下にずれている所が、関連である。たとえばコーンスープは冬の列で背が高く、夏の列ではほとんど見えない。さらに四角を調整済み残差で塗り、± 2 を超えるマスを枠で囲めば、高さのずれで強さを、色で偶然では説明しにくいかを、同時に読める。

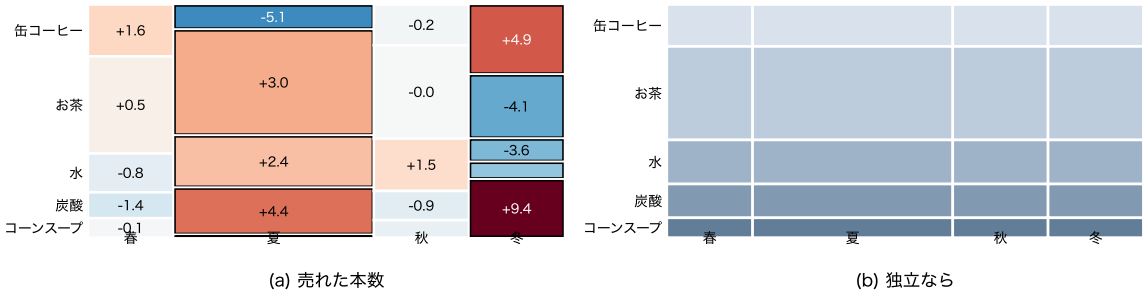


図 9: 人工の自動販売機の表のモザイク図。(a) 売れた本数（色と数は調整済み残差、赤が多く青が少ない。黒い枠は ± 2 を超えるマス）、(b) 独立のモデルの期待度数

定義 6 (モザイク図)**.** 横幅を列の合計の割合 c_j に、列の中の高さを列の中の行の割合 o_{ij}/o_{+j} に比例させ、面積をマスの度数に比例させた図をモザイク図と呼ぶ。行と列が独立なら、行の区切りの線は一直線にそろう。

3 つ以上のカテゴリ：多重対応分析

第 12 回の手順は、2 つのカテゴリの表に限られていた。飲み物・季節・温度のように 3 つ以上のカテゴリを同時に扱うには、1 本ずつを 0/1 で書く。カテゴリ a $(a = 1, \dots, p)$が J_a 個の値をとるとする。i 本目がその j 番目の値なら 1、そうでなければ 0 とした $n \times J_a$ の行列を $\mathbf{G}_a$ とする。$\mathbf{G}_a$ のどの行にも、1 がちょうど 1 つある($\mathbf{G}_a \mathbf{1}_{J_a} = \mathbf{1}_n$)。第 7 回の所属行列 $\mathbf{G}$ と同じ形である。これを横に並べた

$$\mathbf{Z} = [\mathbf{G}_1 \ \mathbf{G}_2 \ \cdots \ \mathbf{G}_p] \qquad (n \times J, \ J = J_1 + \cdots + J_p) \tag{25}$$

を指示行列(indicator matrix)と呼ぶ(図 10)。どの行の和も p である。

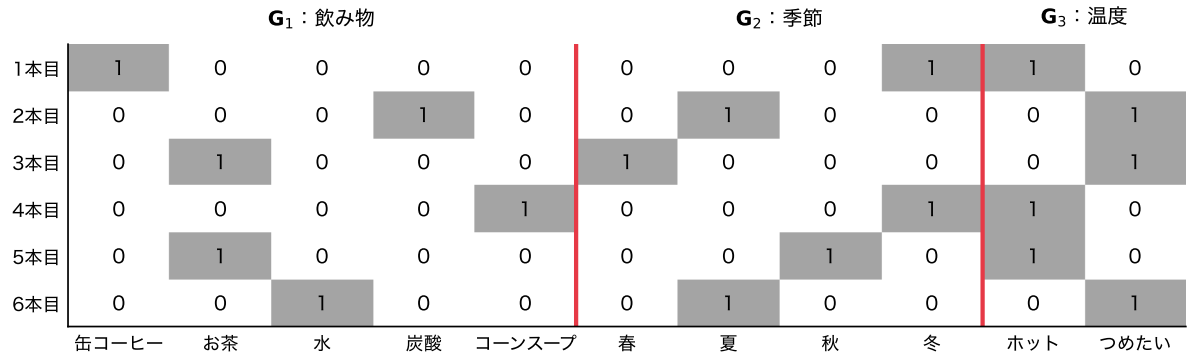


図 10: 売れた 6 本を、飲み物・季節・温度の 0/1 で書いた指示行列(概念図)。赤い線はカテゴリの区切りで、各ブロックの各行に 1 は 1 つだけある

指示行列を、行が 1 本 1 本、列がカテゴリの値の分割表とみて、第 12 回の手順を当てる。総数は np なので $\mathbf{P} = \mathbf{Z}/(np)$ となる。行の周辺は $\boldsymbol{r} = \mathbf{1}_n/n$、列の周辺は各値の出た割合を p で割った $\boldsymbol{c} = \mathbf{Z}^\top \mathbf{1}_n/(np)$ である。これらから作った行列

$$\mathbf{S}_Z = \mathbf{D}_r^{-1/2}(\mathbf{P} - \boldsymbol{r}\boldsymbol{c}^\top)\mathbf{D}_c^{-1/2} = \mathbf{K}\boldsymbol{\Delta}\mathbf{L}^\top \tag{26}$$

を 1 回特異値分解して、カテゴリの値の点 $\mathbf{D}_c^{-1/2}\mathbf{L}_1\boldsymbol{\Delta}_1$ を地図に描く。この手続きを多重対応分析(multiple correspondence analysis)と呼ぶ(定義 7)。カテゴリが違っても、すべての値が 1 枚の地図に並ぶ。

何を分解しているかは、$\mathbf{Z}^\top\mathbf{Z}$ を見るとわかる。$\mathbf{L}$ は $\mathbf{S}_Z^\top\mathbf{S}_Z$ の固有ベクトルであり、$\mathbf{S}_Z^\top\mathbf{S}_Z$ は $\mathbf{Z}^\top\mathbf{Z}$ から作られる。$\mathbf{Z}^\top\mathbf{Z}$ をブロックに分けると

$$\mathbf{Z}^\top\mathbf{Z} = \left[\mathbf{G}_a^\top\mathbf{G}_b\right]_{a,b=1,\dots,p} \tag{27}$$

となる。$\mathbf{G}_a^\top\mathbf{G}_b$ $(a \neq b)$のマスは、カテゴリ a の j 番目とカテゴリ b の l 番目が同時に出た本数である。つまり 2 つのカテゴリの分割表そのものである。対角のブロック $\mathbf{G}_a^\top\mathbf{G}_a$ は、各値の本数を並べた対角行列になる。

この行列をバート行列(Burt matrix)と呼ぶ。多重対応分析の地図は、2 つずつの分割表のずれを全部まとめて近似したものである。3 つのカテゴリが同時に絡むずれは見ていない。

総慣性は、データの中身によらず決まる。$z_{ij}^2 = z_{ij}$ であり、各列の和は値の本数 n_j である。この 2 つを使って第 12 回の総慣性の式 $\sum_{i,j} p_{ij}^2/(r_i c_j) - 1$ を計算すると

$$\|\mathbf{S}_Z\|_F^2 = \sum_{i,j} \frac{z_{ij}}{p\, n_j} - 1 = \sum_{j=1}^{J} \frac{1}{p} - 1 = \frac{J}{p} - 1 \tag{28}$$

となる。各ブロックの列の和が $\mathbf{1}_n$ になるので、0 でない特異値は高々 $J-p$ 個である。$p=2$ のときは、多重対応分析の軸の慣性が、2 つのカテゴリの分割表の対応分析から決まる。

定理 1 (2 つのカテゴリの多重対応分析)**.** *$p=2$ とする。2 つのカテゴリの分割表 $\mathbf{G}_1^\top \mathbf{G}_2$ に第 12 回の対応分析を当てた特異値を δ_m とする。このとき、指示行列 $\mathbf{Z} = [\mathbf{G}_1\ \mathbf{G}_2]$ の多重対応分析の軸の慣性は $(1 \pm \delta_m)/2$ であり、それ以外の 0 でない軸の慣性は $1/2$ である。*

証明は 4 段で進める。まず $\mathbf{S}_Z^\top \mathbf{S}_Z$ をバート行列で書く。$\mathbf{D}_r^{-1}\boldsymbol{r} = \mathbf{1}_n$、$\mathbf{P}^\top \mathbf{1}_n = \boldsymbol{c}$ を使うと、交差項がまとまって $(\mathbf{P} - \boldsymbol{r}\boldsymbol{c}^\top)^\top \mathbf{D}_r^{-1} (\mathbf{P} - \boldsymbol{r}\boldsymbol{c}^\top) = \mathbf{P}^\top \mathbf{D}_r^{-1} \mathbf{P} - \boldsymbol{c}\boldsymbol{c}^\top$ となる。各値の本数 n_j を並べた対角行列を $\mathbf{N}$ とすると $\mathbf{D}_c = \mathbf{N}/(np)$ である。$\mathbf{P} = \mathbf{Z}/(np)$、$\mathbf{D}_r = \mathbf{I}/n$ も入れると

$$\mathbf{S}_Z^\top \mathbf{S}_Z = \frac{1}{p}\, \mathbf{N}^{-1/2} \mathbf{Z}^\top \mathbf{Z}\, \mathbf{N}^{-1/2} - \sqrt{\boldsymbol{c}}\sqrt{\boldsymbol{c}}^\top \tag{29}$$

を得る。この式は p によらず成り立つ。多重対応分析は、バート行列 (27) 式を分解しているのである。

次に $p=2$ とする。カテゴリ a の各値の本数を並べた対角行列を $\mathbf{N}_a$、各値の割合を $\boldsymbol{r}_a = \mathbf{N}_a \mathbf{1}/n$ と書く。対角のブロックは $\mathbf{N}_a^{-1/2} \mathbf{N}_a \mathbf{N}_a^{-1/2} = \mathbf{I}$ なので

$$\mathbf{N}^{-1/2} \mathbf{Z}^\top \mathbf{Z} \mathbf{N}^{-1/2} = \begin{bmatrix} \mathbf{I} & \mathbf{T} \\ \mathbf{T}^\top & \mathbf{I} \end{bmatrix}, \qquad \mathbf{T} = \mathbf{N}_1^{-1/2} \mathbf{G}_1^\top \mathbf{G}_2 \mathbf{N}_2^{-1/2} = \mathbf{S}_{12} + \sqrt{\boldsymbol{r}_1}\sqrt{\boldsymbol{r}_2}^\top$$

となる。$\mathbf{S}_{12}$ は、行の周辺が $\boldsymbol{r}_1$、列の周辺が $\boldsymbol{r}_2$ の分割表 $\mathbf{G}_1^\top \mathbf{G}_2$ の、第 12 回の標準化残差行列である。

3 段目で、$\mathbf{S}_{12} = \sum_m \delta_m \boldsymbol{k}_m \boldsymbol{l}_m^\top$ の特異ベクトルを並べて当てる。第 12 回の帰結④より $\boldsymbol{k}_m \perp \sqrt{\boldsymbol{r}_1}$、$\boldsymbol{l}_m \perp \sqrt{\boldsymbol{r}_2}$ なので、足した項は消えて $\mathbf{T}\boldsymbol{l}_m = \delta_m \boldsymbol{k}_m$、$\mathbf{T}^\top \boldsymbol{k}_m = \delta_m \boldsymbol{l}_m$ となる。したがって

$$\begin{bmatrix} \mathbf{I} & \mathbf{T} \\ \mathbf{T}^\top & \mathbf{I} \end{bmatrix} \begin{bmatrix} \boldsymbol{k}_m \\ \pm \boldsymbol{l}_m \end{bmatrix} = \begin{bmatrix} \boldsymbol{k}_m \pm \delta_m \boldsymbol{k}_m \\ \delta_m \boldsymbol{l}_m \pm \boldsymbol{l}_m \end{bmatrix} = (1 \pm \delta_m) \begin{bmatrix} \boldsymbol{k}_m \\ \pm \boldsymbol{l}_m \end{bmatrix}$$

である。(29) 式の $1/p = 1/2$ を掛けると、慣性 $(1 \pm \delta_m)/2$ の向きが得られる。

最後に、残りの向きを調べる。$\mathbf{T}\sqrt{\boldsymbol{r}_2} = \sqrt{\boldsymbol{r}_1}$、$\mathbf{T}^\top \sqrt{\boldsymbol{r}_1} = \sqrt{\boldsymbol{r}_2}$ なので、$\mathbf{T}$ は 2 本を特異値 1 で結ぶ。同じ計算で、$[\sqrt{\boldsymbol{r}_1}; \pm\sqrt{\boldsymbol{r}_2}]$ の慣性は $(1 \pm 1)/2$、すなわち 1 と 0 になる。$+$ の向きは $\sqrt{2}\sqrt{\boldsymbol{c}}$ そのものなので、(29) 式の $-\sqrt{\boldsymbol{c}}\sqrt{\boldsymbol{c}}^\top$ がこの慣性 1 を 0 にする。$-$ の向きの 0 は、各ブロックの列の和が $\mathbf{1}_n$ になることから来る。これら

すべてと直交する向きは、$\mathbf{T}$ や $\mathbf{T}^\top$ を掛けると 0 になるので、慣性は 1/2 である。関連の強さ δ_m が 0 でも、慣性は 1/2 ある。総慣性 $J/p-1$ の大部分は、関連と無関係な、カテゴリが自分自身と重なる分である。そのため、多重対応分析の軸の寄与率は第 12 回の対応分析より低く出る。

自動販売機の 5×4 の表で確かめる。表を 1,000 本の指示行列（飲み物と季節の $p=2$、$J=9$）に戻して多重対応分析にかけると、図 11 のように軸は 7 本になる。軸 1 の寄与率は、対応分析では 96% だが、多重対応分析では 20% にとどまる。慣性が $1/p$ を超える軸だけを数え直す補正（Benzécri の補正）では、$\tilde{\lambda}_m=\{p/(p-1)\}^2(\delta_{Z,m}^2-1/p)^2$ の割合で寄与率を読む。$p=2$ では $\delta_{Z,m}^2=(1+\delta_m)/2$ を代入すると $\tilde{\lambda}_m=\delta_m^2$ となり、対応分析の寄与率に戻る。

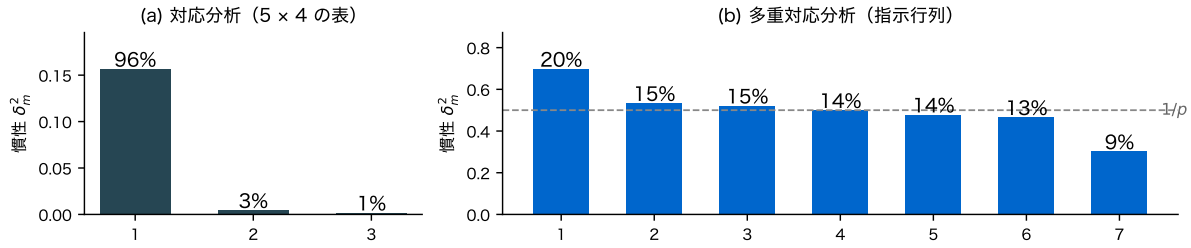


図 11: 人工の自動販売機の表の、軸ごとの慣性と寄与率。(a) 5×4 の表の対応分析、(b) 同じ表を 1,000 本の指示行列にした多重対応分析。破線は 1/p

定義 7 (多重対応分析)**.** p 個のカテゴリの指示行列 $\mathbf{Z}=[\mathbf{G}_1\ \cdots\ \mathbf{G}_p]$ を分割表とみて対応分析を行うことを、多重対応分析と呼ぶ。総慣性は $J/p-1$ で、軸は高々 $J-p$ 本である。$\mathbf{Z}^\top\mathbf{Z}$ をバート行列と呼び、その対角でないブロックは 2 つずつのカテゴリの分割表である。

同じ計算は、日本では数量化 III 類（Hayashi's quantification method III）の名で知られている。統計数理研究所の林知己夫が、1950 年代に数量化理論として組み立てた方法の 1 つである。初期の論文は、仮釈放の後の成り行きを、0/1 で書いた記録から予測する研究であった（Hayashi, 1950）。外の基準が量のときに 0/1 の列で回帰するのが I 類、群のときに判別するのが II 類で、それぞれ第 1〜3 回の線形回帰と第 5 回の判別分析を指示行列に当てたものにあたる。外の基準が無いときに、行と列に数を付けるのが III 類である。林は、1953 年に始まった「日本人の国民性調査」も主導した。

III 類の考え方は次のとおりである。i 本目に数 f_i、値 j に数 g_j を付ける。$z_{ij}=1$ のマスを 1 つの組とみて、組ごとの f_i と g_j の相関を最大にする。これは、指示行列を分割表とみたときの第 12 回の「行と列に付けた得点の相関」そのものである。したがって第 12 回の定理より、相関の最大は $\mathbf{S}_Z$ の最大の特異値 $\delta_{Z,1}$ で、そのときの数は多重対応分析の軸 1 の座標 $\boldsymbol{f}=\mathbf{D}_r^{-1/2}\boldsymbol{k}_1$、$\boldsymbol{g}=\mathbf{D}_c^{-1/2}\boldsymbol{l}_1$ になる。2 番目に大きい相関を、軸 1 の数と相関 0 の中で探すと軸 2 が得られる。行と列をこの数の順に並べ替えると、1 が対角の近くに集まる（図 12）。売れた 10 本の例では、ホット・冬・コーンスープ・缶コーヒーが一方の端に、つめたい・夏・炭酸・水が反対の端に並び、相関は 0.96 である。

同じ固有ベクトルは、ほかの場所でも別の名で見つかっている。Guttman（1941）は尺度を作る方法として、フランスの Benzécri らは 1960 年代から対応分析として、同じ計算に行き着いた（Benzécri, 1973）。2 つのカテゴリなら第 12 回の対応分析、3 つ以上なら多重対応分析で、どれも指示行列や分割表の行と列に、関連が最も

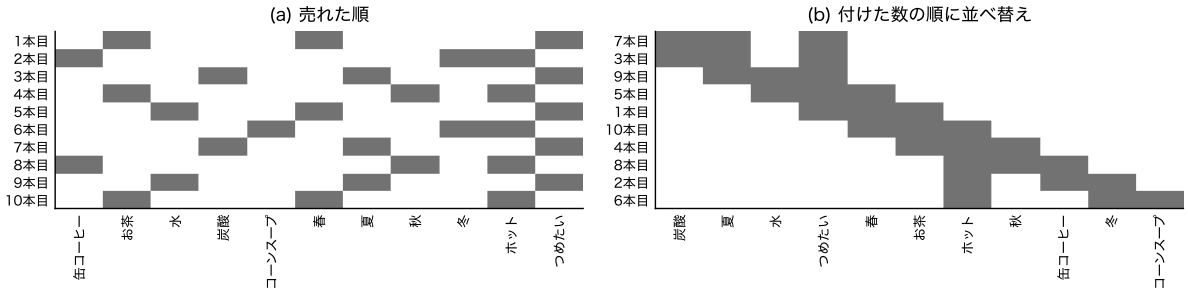


図 12: 売れた 10 本を、飲み物・季節・温度の 0/1 で書いた指示行列(人工データ)。(a) 売れた順、(b) 数量化 III 類で付けた数の順に、行と列を並べ替えたもの

強く見える数を付ける方法である。

参考文献

- Guttman, L. (1941). The quantification of a class of attributes: A theory and method of scale construction. In P. Horst (Ed.), The prediction of personal adjustment (pp. 321–348). Social Science Research Council.
- Hayashi, C. (1950). On the quantification of qualitative data from the mathematico-statistical point of view. Annals of the Institute of Statistical Mathematics, 2, 35–47.
- Hayashi, C. (1956). Theory and examples of quantification (II). Proceedings of the Institute of Statistical Mathematics, 4(2), 19–30.
- Benzécri, J.-P. (1973). L'Analyse des Données. Tome 2: L'Analyse des Correspondances. Dunod.

第 II 部　実データ解析

キノコの図鑑と手続き

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、次の 4 つを予想できる。第 1 に、期待度数は独立のモデルの最尤推定値なので、最尤法で測った当てはまりの悪さ G^2 と、重み付き二乗で測った χ^2 は、ほぼ同じ値になるはずである。(12) 式が示すとおりである。第 2 に、標準化残差の分散は $(1-r_i)(1-c_j)$ で、行が 2 つの表では $1-r_i$ がおよそ 0.5 になる。そのため、調整済み残差に割り直すと、値は $1/\sqrt{0.5} \approx 1.4$ 倍以上に大きくなると見込める。第 3 に、たくさんのマスを一度に見るとき、ホルムの方法はボンフェローニ補正より多くのマスを拾うことがあるはずである。第 4 に、多重対応分析の寄与率は、対応分析より低く出るはずである。

データには、UCI 機械学習リポジトリの Mushroom（id 73、Schlimmer 1987。The Audubon Society Field Guide to North American Mushrooms の記述から作られたもの、CC BY 4.0）を使う。ハラタケ属とキツネ

ノカラカサ属の 23 種について、図鑑の記述に合う仮想の標本を 1 本 1 行で並べたデータである。全 8,124 本あり、かさの形・色、ひだ、柄、におい、生える場所など 22 列のすべてがカテゴリである。食べられるかの列は「食べられる」と「毒」の 2 つで、毒には、食べられるかわからず勧められないものも含まれる。図鑑の記述を組み合わせた練習用のデータであり、実際のキノコの見分けに使ってはいけない。

まず、食べられるか × かさの色(10 色)の 2 × 10 の分割表($n = 8{,}124$ 本)を作った。I-6 の手順で、期待度数、標準化残差、調整済み残差を計算した。χ^2 と G^2 も計算し、マスごとに比べた。次に、同じ総数・同じ周辺の独立のモデルから、多項分布で表を 2,000 回作った。毎回残差を計算し直して、マスごとの分散を測った。10 色を一度に見る物差しとして、ボンフェローニ補正とホルムの方法を当て、モザイク図も描いた。多重対応分析には、食べられるか(2)、かさの色、生える場所(7)、傷つけると色が変わるか(2)の 4 列を使った。かさの色のうち、200 本に満たない 5 色(淡黄・ピンク・シナモン・緑・紫、合わせて 388 本)は「その他の色」にまとめ、6 色にした。第 12 回で見たとおり、まれな値は地図の端に出て、軸を 1 本使ってしまうからである。この指示行列(8,124 × 17)に第 12 回の手順を当て、NumPy の特異値分解を 1 回計算した。計算は第 I 部の式どおりに進んだ。対数尤度 (7) 式を SciPy の汎用の最適化で直接最大にした確率は周辺と一致し(差は最大 1e-08)、χ^2 と G^2 は SciPy の分割表の検定の関数の値と一致した。

当てはまりの悪さ

第 1 の予想は外れた。この表の G^2 は 406.0、χ^2 は 387.6 で、差は 18.4 ある。同じ総数・同じ周辺の独立のモデルから作った 2,000 個の表では、両者の差は平均 0.10 しかなかった。

理由は、(12) 式の導出で使った対数の近似 (11) 式にある。この近似は、$x = (o - e)/e$ が 0 に近いマスでしか成り立たない。この表では、緑と紫のかさの毒が、期待度数 7.7 本に対して観測は 0 本で、$x = -1$ である(図 13 の橙の枠)。$G^2 - \chi^2$ をマスごとの寄与 $2\{o\log(o/e) - (o-e)\} - (o-e)^2/e$ に分けると(足すと $\sum(o-e) = 0$ により $G^2 - \chi^2$ になる)、$o = 0$ のマスの寄与はちょうど e になる。差 18.4 のうち 15.4 を、この 2 マスが作っていた。逸脱度残差 (13) 式で見ると、わかりやすい(図 13 (b))。ほかのマスでは標準化残差とほぼ同じだが、観測 0 本のマスでは、標準化残差-2.78 に対して逸脱度残差は -3.93 と、二乗で 2 倍になる。独立のモデルから大きく外れたマスがあると、2 つの物差しは離れる。$G^2 \approx \chi^2$ は、モデルが正しいときの性質である。

どのマスが大きいか

第 2 の予想は当たった。図 13 の (a) は標準化残差、(c) は調整済み残差である。この表は行が 2 つしかないので、$1 - r_i$ はおよそ 0.5 になり、$(1 - r_i)(1 - c_j)$ は 0.35〜0.52 である。割り直すと、どのマスの残差も 1.39〜1.70 倍に大きくなった。標準化残差で ±2 に届かないのは、シナモン色のかさ(44 本のうち食べられるもの 32 本)の +1.93 だけである。調整済み残差では +2.79 となり、10 色すべてが ±2 を超える。ただし、判定が変わったのはシナモンだけである。20 マスのうち 18 マスは、割る前から ±2 を超えていた。総数が 8,124 本と多く、帰結⑪で見たとおり、同じ形の表でも残差は本数の平方根に比例して大きくなるからである。割り直しが判定を変えるのは、±2 の近くにあるマスだけである。

割り直しの根拠も、この表で確かめた。独立の表 2,000 個で測った標準化残差の分散は、どのマスでも $(1 - r_i)(1 - c_j)$ との差が 0.029 以内であった。調整済み残差の分散は 0.994 で、±2 を超えた割合は 4.46%

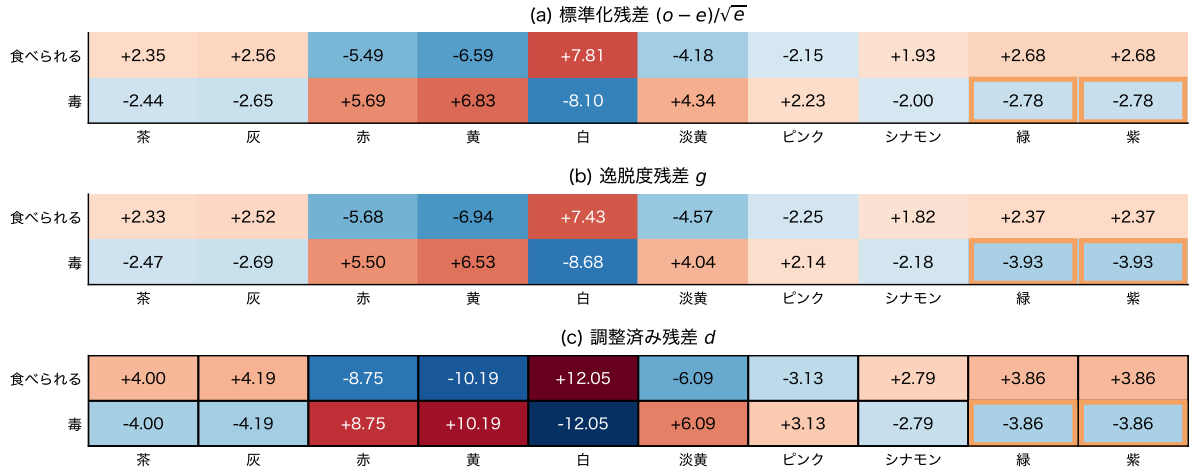


図 13: 食べられるか × かさの色の表のマスごとのずれ。(a) 標準化残差、(b) 逸脱度残差、(c) 調整済み残差。細い枠は (c) で絶対値が 2 以上のマス、橙の枠は観測が 0 本のマス。色の目盛りは共通

と、標準正規分布の 4.55% に近い。

10 色すべてを眺めて大きいものを拾うなら、物差しを上げなければならない。行が 2 つの表では $o_{1j}-e_{1j}=-(o_{2j}-e_{2j})$ であり、$e_{1j}(1-r_1)=nr_1r_2c_j=e_{2j}(1-r_2)$ でもある。そのため 2 つの行の調整済み残差は、符号だけが逆で絶対値は同じになる（差の最大 1e-14）。違う値は 10 個なので、ボンフェローニの物差しは $M=10$ の ± 2.81 になる。これを超えるのは 9 色で、シナモンだけが届かない。第 3 の予想は当たった。ホルムの方法では、1 番目の白を ± 2.81 と比べ、超えるたびに物差しを下げていく（図 14）。シナモン以外の 9 色はどれも大きく超えるので、最後のシナモンは ± 1.96 と比べることになり、$|d|=2.79$ で超える。10 色すべてが「大きい」と言える。ボンフェローニ補正は、ほかのマスがどれだけ大きくても、最後まで同じ厳しい物差しを使う。そのため、± 2 の近くのシナモンを落としていた。

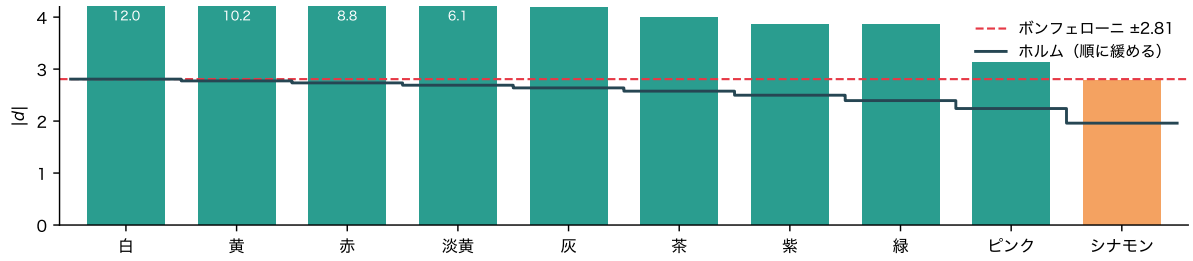


図 14: 食べられるか × かさの色の表の 10 色の調整済み残差の絶対値（食べられるの行）を大きい順に並べたもの。赤の破線はボンフェローニの物差し、黒の階段はホルムの方法の物差し。橙はシナモン。4.2 を超える棒は上を切り、値を書いた

表 2 は、いくつかのマスの観測、期待度数、期待の何倍か、2 つの残差である。白いかさでは、食べられるものが期待の 1.34 倍になっている。調整済み残差は +12.05 で、表の中で最も大きい。緑のかさは 16 本すべてが食べられるもので、期待の 1.93 倍と白より強く偏っている。それでも本数が少ないので、調整済み残差は +3.86 に

とどまる。帰結で見たとおり、「偶然では説明しにくいか」は調整済み残差で判断し、偏りの強さは「何倍か」の列で読む。表全体の関連の強さはクラメールの V で 0.218 である。図 15 のモザイク図では、横幅がかさの色の本数を表す。緑と紫は合わせて 32 本しかなく、右端で細すぎて見えない。強く偏っていても、面積は小さい。白は幅が広く、食べられる側への偏りも大きい。

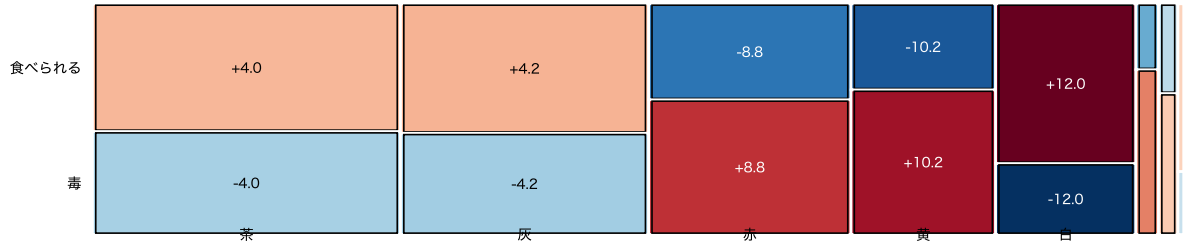


図 15: 食べられるか × かさの色の表のモザイク図。横幅はかさの色の本数、高さは色の中の食べられる・毒の割合。色と数は調整済み残差、黒い枠は ±2 を超えるマス。右端の細い色は名前を省いた

表 2: 食べられるか × かさの色の表のいくつかのマスの観測、期待度数、期待の何倍か、標準化残差、調整済み残差

マス	観測	期待度数	何倍か	標準化	調整済み
白 × 食べられる	720	538.7	1.34	+7.81	+12.05
シナモン × 食べられる	32	22.8	1.40	+1.93	+2.79
ピンク × 食べられる	56	74.6	0.75	-2.15	-3.13
緑 × 食べられる	16	8.3	1.93	+2.68	+3.86
赤 × 毒	876	723.0	1.21	+5.69	+8.75

多重対応分析の地図を読む

図 16 は、食べられるか・かさの色・生える場所・傷で色が変わるかの多重対応分析の地図である。17 の値が、すべて 1 枚に並ぶ。軸 1 の右には食べられる・傷で変色する・白・牧草地・荒れ地が、左には毒・変色しない・道ばた・落ち葉・赤が並ぶ。軸 2 の上には白・草地・牧草地・黄が、下には荒れ地・その他の色・赤・落ち葉が来る。

第 4 の予想も当たった。図 17 のとおり、軸 1 は総慣性の 15.6%、軸 2 は 11.7% しかなく、2 本で 27.3% にとどまる。総慣性は 3.2500 で $J/p - 1$ に一致し、0 でない特異値は $J - p = 13$ 個で、(28) 式のとおりであった。総慣性 $J/p - 1 = 3.25$ の大部分は、各カテゴリが自分自身と重なる分である。関連が無くても、慣性が $1/p$ 前後の軸が並ぶ。同じことは $p = 2$ でも起きる。食べられるか × かさの色の 2 × 10 の表は、対応分析なら軸 1 本だけで総慣性の 100% を表す。同じ表を指示行列にして多重対応分析にかけると、軸 1 は 12.2% になる。このとき軸の慣性は、2 × 10 の表の特異値 δ_m から $(1 + \delta_m)/2$ で求まった(差は 1e-15)。第 I 部の Benzécri の補正を 4 列の地図に当てると、軸 1 は 68.3%、軸 2 は 18.1% になる。多重対応分析の寄与率は、対応分析の寄与率と同じ物差しでは比べられない。

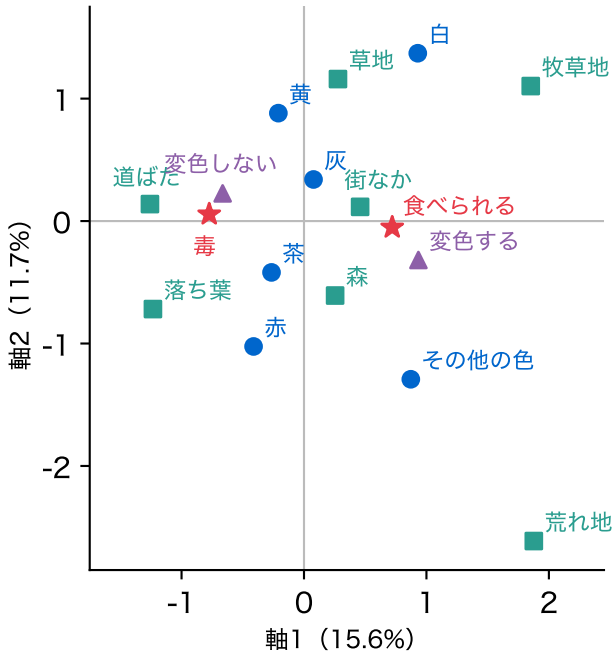


図 16: 食べられるか・かさの色・生える場所・傷で色が変わるかの多重対応分析の地図。赤の星が食べられるか、青の丸がかさの色、緑の四角が生える場所、紫の三角が傷

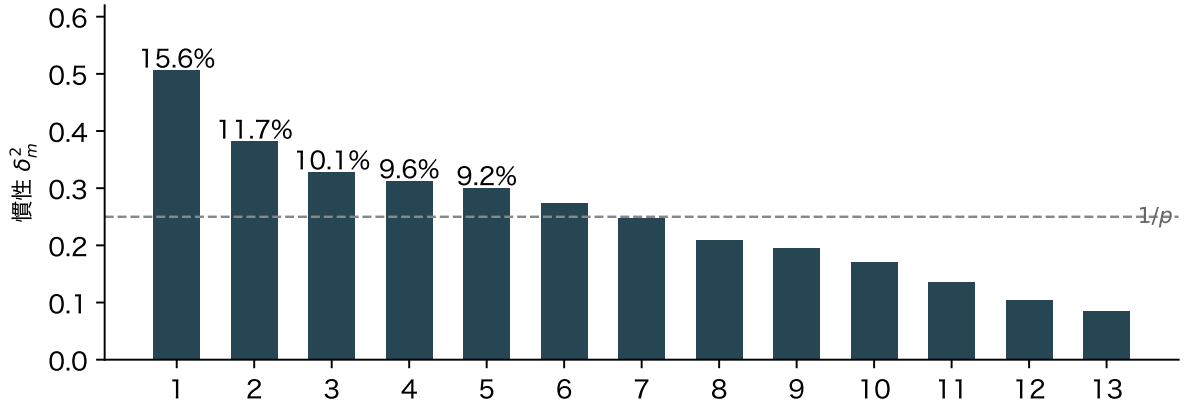


図 17: 食べられるか・かさの色・生える場所・傷で色が変わるかの多重対応分析の、軸ごとの慣性。破線は $1/p$

地図の読み方を誤らせるものが、もう 1 つある。地図の近さと直接の関連の違いである。図 16 のように、食べられると街なかは地図の上で近い（距離 0.31）。ところが食べられるか × 生える場所の分割表に戻ると、街なかに生える 368 本のうち、食べられるものは 96 本しかない。食べられる × 街なかの調整済み残差は -10.10 である。地図とは逆に、街なかのキノコは毒の側に大きく偏っている。それでも 2 つが近いのには理由がある。食べられるものには、白いかさ（調整済み残差 +12.05）と傷で色が変わるもの（+45.20）が多い。街なかのキノコにも、白いかさ（+10.36）と傷で色が変わるもの（+12.89）が多い。多重対応分析はバート行列の 2 つずつの表をまとめて近似する。バート行列の食べられるか × かさの色のブロックは、分割表そのものであった。そのため、ほ

かの列との強い関連があると、2 つの値が見かけの上で近くなる。地図で近い 2 つの値は、その 2 つのカテゴリの分割表に戻り、そのマスの調整済み残差で確かめる。

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは、期待度数が最尤推定値なので、G^2 と χ^2 はほぼ同じになると予想した。キノコの表では両者は 18.4 離れ、予想は外れた。緑と紫のかさの毒が観測 0 本で o/e が 1 から遠く、対数の近似が成り立たないからであり、差の大半をこの 2 マスが作っていた。$G^2 \approx \chi^2$ は、独立のモデルが正しく、どのマスでも o/e が 1 に近いときの性質である。次に、行が 2 つの表では、割り直すと残差は大きく変わると予想した。実際に 1.39〜1.70 倍になり、予想どおりだった。ただし本数が多いので、ほとんどのマスは割る前から ± 2 を超えており、判定が変わったのはシナモンだけだった。そのシナモンは、10 色を一度に見るボンフェローニの物差しには届かなかったが、ホルムの方法では拾えた。最後に、多重対応分析の寄与率は低く出ると予想し、2 本で 27.3% と、そのとおりになった。地図で近い食べられると街なかは、2 つの表に戻ると逆向きに結びついていた。地図の近さは、2 つずつの表のマスで確かめる必要がある。

締め

まとめと次回の問い

本章の問いは、第 12 回の締めで残した「1 セルのズレは大きいのか」であった。第 12 回の期待度数 $e_{ij} = n r_i c_j$ は、独立のモデル $\boldsymbol{\Pi} = \boldsymbol{\pi}_r \boldsymbol{\pi}_c^{\top}$ を最尤法で推定した予測値である。当てはまりの悪さを尤度で測った G^2 は、モデルが正しい大標本では、第 12 回の重み付き二乗の χ^2 に一致する。推定には行と列の合計を使うので、残差 $(o-e)/\sqrt{e}$ は左右から 1 本ずつ向きを除かれて縮む。その分散は、1 ではなく $(1-r_i)(1-c_j)$ になる。この値で割り直した調整済み残差なら、分散が 1 にそろい、± 2 の物差しが使える。回帰の残差を $\sqrt{1-h_{ii}}$ で割るのと同じ型である。推定に使われた度合いの和は、回帰では係数の個数 p、分割表では推定した確率の個数 $I + J - 1$ になる。たくさんのマスを一度に見るなら物差しを上げ（ボンフェローニ補正、ホルムの方法）、ずれの強さは期待の何倍かで読む。G^2 をマスに分けた逸脱度残差は、観測 0 本のような o/e の遠いマスで標準化残差と離れる。表全体は、面積を本数に比例させたモザイク図で 1 枚に描ける。キノコの図鑑の食べられるか × かさの色の表では、標準化残差で ± 2 に届かなかったシナモン色が、割り直すと $+2.79$ になった。ただし、10 色を一度に見るボンフェローニの物差し ± 2.81 にはわずかに届かず、ホルムの方法では拾えた。3 つ以上のカテゴリは、多重対応分析で 1 枚の地図にできる。所属行列と同じ形の 0/1 を並べた指示行列に、第 12 回の手順を当てればよい。ただし寄与率は低く出る。地図で近い食べられると街なかは、2 つの表では逆向きに結びついていた。地図の近さは、2 つずつの表のマスで確かめる必要があった。

ここまでの 13 回を「モデル × 推定法」の地図に置き直す（表 3）。第 1〜4 回は線形回帰を最小二乗法で推定し、その数字の測り方（第 2 回）、係数の揺れ（第 3 回）、罰則（第 4 回）を見た。第 5・6 回は分類を最小二乗法と最尤法の両方で解いた。第 7〜9 回はラベルの無い群分けを、k-means（最小二乗法）、混合正規分布（最尤法）、群の数の選び方の順に扱った。第 10・11 回は $\mathbf{X}$ を $\mathbf{F}\mathbf{A}^{\top}$ で近似する主成分分析と、それを確率のモデルにした因子分析を扱った。第 12 回は分割表のずれを重み付き最小二乗法で低ランク近似した。本章は同じ独立のモデルを最尤法の側から見て、マスごとのずれを測った。

表 3: 第 1〜13 回の「モデル × 推定法」の地図（数字は扱う回）

モデル	最小二乗法で推定	最尤法で推定
線形回帰	第 1〜3 回（罰則付き 第 4 回）	第 6 回
LDA ／ ロジスティック回帰	第 5 回 ／ —	第 6 回
k-means ／ 混合正規分布	第 7 回 ／ —	— ／第 8 回（群の数は第 9 回）
主成分分析 ／ 因子分析	第 10 回 ／ —	第 11 回
対応分析・多重対応分析	第 12 回・第 13 回（重み付き）	—
独立のモデル	第 12 回（χ^2）	第 13 回（G^2、残差）

どの回も、データとモデルのずれを測って小さくすることをしてきた。最小二乗法では、$\|\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2$、$\|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2$、$\|\mathbf{X} - \mathbf{F}\mathbf{A}^\top\|_F^2$、重み付きの $\|\mathbf{S} - \mathbf{Y}\|_F^2$ がずれの測り方であった。最尤法では -2ℓ が同じ役を果たした。正規誤差の回帰や分割表の独立のモデルでは、2 つの推定法は同じ答えや同じ物差しにたどり着いた。そして、小さくした後に残ったずれは、モデルを推定に使った分だけ縮んでいる。第 3 回は残差平方和を n ではなく $n - p$ で割った。本章は回帰の残差を $\hat{\sigma}\sqrt{1 - h_{ii}}$ で、分割表の $o - e$ を $\sqrt{e(1 - r_i)(1 - c_j)}$ で割った。R^2 も寄与率も χ^2 も調整済み残差も、何かを何かで割った数字である。数字を比べる前に、それが何で割られているかを確かめる。

最後に、次回への問いを置く。ここまでの表は、行と列が別のものだった。飲み物 × 季節、個体 × 変数である。一方で、行も列も同じものの表もある。駅 × 駅の乗り換えの人数や、店 × 店の同じ日に寄った客の数である。このような、つながりの表から、何を読み、どう描くのだろうか。

発展

発展：たくさん見るときの物差し

発展として、たくさんの比較を一度に行う場面を紹介する。本章では 20 マスにボンフェローニ補正とホルムの方法を当てた。脳の画像の画素、遺伝子、ウェブの指標などでは、何千から何百万の比較を一度に行う。どれか 1 つでも偶然に拾う確率を 5% に抑えようとすると、ボンフェローニの物差し $\pm z_{0.025/M}$ は、$M = 1$ 万で ± 4.56、100 万で ± 5.45 と上がり続け、本当のずれもほとんど拾えなくなる。

Benjamini & Hochberg (1995) は、抑える量を変えた。拾ったもののうち、本当は関連の無いものの割合の期待値を偽発見率（false discovery rate）（FDR）と呼ぶ。1 つも間違えないことを求める代わりに、拾ったものの 5% までは間違いを許す。手順はホルムの方法と似ている。絶対値の大きい順に並べ、k 番目を $\pm z_{0.025k/M}$ と比べ、超えた最後の k までをすべて拾う。k が大きいほど物差しが大きく下がる。図 18 の人工データでは、200 個のうち 20 個だけに本当のずれがある。ボンフェローニ補正が拾うのは 6 個、ベンジャミニ・ホッホベルクの方法は 15 個で、そのうち関連の無いものは 0 個だった。

Benjamini (2020) は、選んだものだけを報告することの危うさを 1 枚の図で示した（図 19）。0 の近くにある 20 個の量について 90% の信頼区間を作ると、全体では 20 本中 3 本が真の値を外す。ところが、0 を含まない

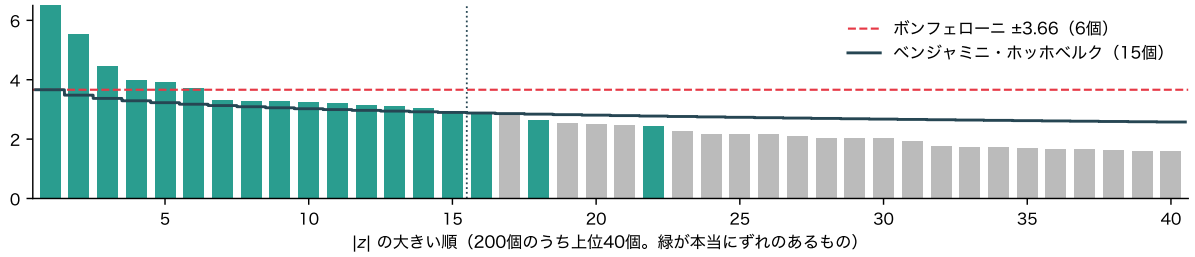


図 18: 200 個のうち 20 個にだけ本当のずれがある人工データ。絶対値の大きい順に上位 40 個を並べた。緑が本当にずれのあるもの。赤の破線はボンフェローニの物差し、黒の階段はベンジャミニ・ホッホベルクの方法の物差し

区間だけを「見つかった」として選ぶと、選んだ 4 本のうち 3 本が外れている。表を眺めて目立つマスだけを報告することも、同じ危うさを持つ。

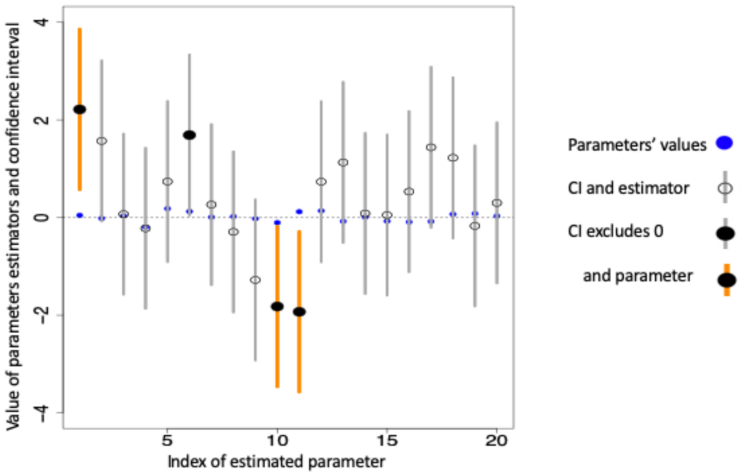


図 19: 0 の近くにある 20 個の量の推定値と 90% 信頼区間。青が真の値、黒丸が 0 を含まない区間、橙は真の値も外した区間。出典：Benjamini (2020) Harvard Data Science Review 2(4), Fig. 1（CC BY 4.0）

見た数を書かずに、物差しを超えたものだけを報告すると、何が起きるか。関連が無いとしたとき、観測した値以上に外れる確率を p 値と呼ぶ。$|d|$ が 2 を超えることは、p 値が 0.0455 を下回ることにあたる。Hartgerink ほか (2016) は、心理学の 8 誌に 1985〜2013 年に載った論文から、報告された p 値を集めた（図 20）。.01・.02・.03・.04・.05 という切りのよい値に山があり、とくに慣例の物差しである .05 に大きな山がある。いくつも試した中から、物差しをちょうど超えたものが選ばれやすいことをうかがわせる。

偽発見率の考え方は、脳の画像の画素ごとの検定（Genovese ほか 2002）、天文学の画像からの光源の検出（Miller ほか 2001）、ウェブの実験を途中で見続ける場面（Johari ほか 2022）、回帰の変数選び（Barber & Candès 2015）などに広がっている。どの分野でも、何を、いくつ見たかを書き残しておけば、あとから物差しを選び直せる。

参考文献

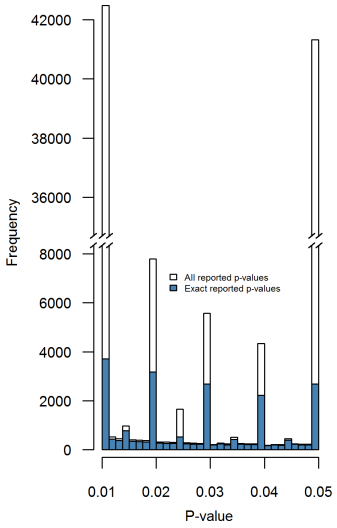


図 20: 心理学 8 誌で報告された p 値の分布。白はすべての報告値、青は値を正確に書いたもの。出典：Hartgerink, van Aert, Nuijten, Wicherts & van Assen (2016) PeerJ 4: e1935, Fig. 2（CC BY 4.0）

- Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. Journal of the Royal Statistical Society: Series B, 57(1), 289–300.
- Benjamini, Y. (2020). Selective inference: The silent killer of replicability. Harvard Data Science Review, 2(4).
- Hartgerink, C. H. J., van Aert, R. C. M., Nuijten, M. B., Wicherts, J. M., & van Assen, M. A. L. M. (2016). Distributions of p-values smaller than .05 in psychology: What is going on? PeerJ, 4, e1935.
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics, 6(2), 65–70.
- Genovese, C. R., Lazar, N. A., & Nichols, T. (2002). Thresholding of statistical maps in functional neuroimaging using the false discovery rate. NeuroImage, 15(4), 870–878.
- Miller, C. J., et al. (2001). Controlling the false-discovery rate in astrophysical data analysis. The Astronomical Journal, 122(6), 3492–3505.
- Johari, R., Koomen, P., Pekelis, L., & Walsh, D. (2022). Always valid inference: Continuous monitoring of A/B tests. Operations Research, 70(3), 1806–1821.
- Barber, R. F., & Candès, E. J. (2015). Controlling the false discovery rate via knockoffs. The Annals of Statistics, 43(5), 2055–2085.