

第 13 回 モデル選択

当てはまりは複雑さとともに良くなる。罰を足すか、外で行で測る

本章の問いは、第 12 回の締めで残った「群の数 k をどう選ぶか」である。本章では、イエローストーンの間欠泉の 272 回の噴出で考える。列は噴出時間と、次の噴出までの待ち時間である。対数尤度は k を増やせば上がり、k-means の J は下がるので、推定法そのものでは k を選べない。大きいモデルは小さいモデルを含むからである。そこで推定の外に基準を置く。1 つは、当てはまりの悪さ $-2\hat{\ell}$ にパラメータの数の罰を足す BIC である。もう 1 つは、推定に使わなかった行で対数尤度を測る交差検証(クロスバリデーション、CV)である。

第 I 部 理論

推定法では k を選べない

第 12 回は、群の数 k を決めたくて混合正規分布を当てはめ、最後に「 k をどう選ぶか」という問いを残した。本章ではこの問いを、イエローストーン国立公園の間欠泉オールドフェイスフルの 272 回の噴出で考える。1 行が 1 回の噴出で、列は噴出の続いた時間と、次の噴出までの待ち時間(どちらも分)である。データは R の datasets パッケージにある faithful で、Rdatasets から CSV で取得した。出典は Härdle (1991) で、R とともに GPL で配布されている。図 1 (a) のとおり、長く噴いた回ほど次まで長く待つ(相関 0.90)。点は短い噴出と長い噴出の 2 つの塊に分かれて見える。以下、2 列はそれぞれ平均 0・標準偏差 1 にそろえて使う(図の目盛りは分で書いた)。

図 1 (b) は、第 12 回の混合正規分布を、群の数 k を 1 から 8 まで変えて当てはめたときの最大の対数尤度 $\hat{\ell}$ である。共分散行列は群ごとに持たせ、初期値 20 通りのうち最良の答えを使った。 $\hat{\ell}$ は $k = 1$ の -545.0 から $k = 8$ の -338.8 まで上がり続け、目で見た 2 つの塊のところで止まらない。(c) は同じ 2 列に第 11 回の k-means を当てたときの目的関数 $J = \|\mathbf{X} - \mathbf{GC}\|_F^2$ であり、544.0 から 21.3 まで下がり続ける。どちらの目的関数も、群を増やすほど良い値を返す。

同じ形の困りごとは前にもあった。第 2 回では、多項式の次数を上げるほど訓練誤差は下がり続けたので、テストの行で測り直した。第 4 回では、罰の強さ λ を 0 にするほど訓練誤差は下がったので、交差検証(クロスバリデーション、CV)で λ を選んだ。第 8 回・第 11 回の J と第 12 回の $\hat{\ell}$ も、群の数というつまみについて同じ振る舞いをする。本章の問いは、群の数 k をどう選ぶか、である。共分散行列を群ごとにするか共通にするかという型の選び方も、同じ問題として扱う。

先に道筋を述べておく。まず候補のモデルを並べ、大きいモデルが小さいモデルを特別な場合として含むことを




図 1: オールドフェイスフル間欠泉の 272 回の噴出。(a) 噴出時間と待ち時間(縦横は標準偏差でそろえた)、(b) 群の数 k を変えたときの混合正規分布の最大対数尤度 $\hat{\ell}$ 、(c) k-means の目的関数 J

確かめる。そのため、推定法(ℓ の最大化や J の最小化)そのものでは k は決まらない。推定の外に基準を置くしかない。本章では 2 つを扱う。1 つは、当てはまりの悪さにパラメータの数に比例する罰を足す方法である。もう 1 つは、推定に使わなかった行で対数尤度を測る方法である。最後に、2 つの基準が人工データと間欠泉で何を選ぶかを見る。

候補のモデル

選ぶ候補を先に並べておく。第 12 回の混合正規分布 $f(\tilde{x}) = \sum_q \pi_q N(\tilde{x}; \mu_q, \Sigma_q)$ は、群の数 k のほかに、共分散行列 Σ_q にどれだけの自由を許すかでも大きさが変わる。本章では次の 4 つの型を考える(定義 1)。ここでは人工的なデータを使う。3 台のトースターで焼いたトースト 120 枚の焼き時間と焼き色を思い浮かべてほしい。どの 1 枚がどの台で焼かれたかは記録していない。1 台目の 60 枚は焼き時間が長いほど色が濃い斜めの帯に、2 台目の 25 枚は小さくまとまり、3 台目の 35 枚は丸く散らばるように作った(目盛りは標準化した値で、単位は持たない)。図 2 は、この 2 変数・3 群に 4 つの型で $k = 3$ を当てはめたものである。群ごとの型は楕円の傾きと大きさが群ごとに自由であり、斜めの帯に沿った細長い楕円を描ける。共通の型では、どの群も同じ形の楕円になる。第 6 回の LDA からラベルを隠したものに当たる。対角の型は楕円の軸が座標軸に沿うものに限られ、球の型は群ごとに大きさだけが違う円である。

定義 1 (共分散の型). 混合正規分布の共分散行列について、群ごとに自由な Σ_q を持たせるものを群ごとの型(full)、すべての群で共通の Σ を持たせるものを共通の型(tied)、群ごとの対角行列 $\Sigma_q = \text{diag}(\sigma_{q1}^2, \dots, \sigma_{qp}^2)$ とするものを対角の型(diagonal)、群ごとの $\Sigma_q = \sigma_q^2 \mathbf{I}$ とするものを球の型(spherical)と呼ぶ。

これらの候補には、大きいモデルが小さいモデルを特別な場合として含むという関係がある。1 変数・2 群の $f(x) = \pi_1 f_1(x) + \pi_2 f_2(x)$ で $\pi_2 = 0$ とおけば $f(x) = f_1(x)$ 、すなわち $k = 1$ のモデルになる。一般に、 k 群のモデルは、 $k + 1$ 群のモデルの 1 つの群の混合比率を 0 にしたものである。型についても、対角の型で対角の値をそろえれば球の型になり、群ごとの型で非対角を 0 にすれば対角の型に、すべての群を同じにすれば共通の型になる。次の節で見る「当てはまりは複雑さとともに良くなる一方」は、この入れ子の関係から起きる。




図 2: トースト 120 枚の 2 変数・3 群の人工データ(焼き時間と焼き色)に、4 つの共分散の型で $k = 3$ の混合正規分布を当てはめたもの。楕円は推定した Σ_q の形

当てはまりは複雑さとともに良くなる

候補ごとに、第 12 回の EM で対数尤度を最大にした値を $\hat{\ell}_k$ と書く。行ごとの和で書けば

$$\hat{\ell}_k = \max_{\pi, \mu, \Sigma} \sum_{i=1}^n \log \sum_{q=1}^k \pi_q N(\tilde{\mathbf{x}}_i; \mu_q, \Sigma_q) \quad (1)$$

であり、第 12 回の行列の書き方では

$$\hat{\ell}_k = \max_{\pi, \mathbf{C}, \Sigma} \mathbf{1}_n^\top \log(\Phi \mathbf{1}_k) \quad (2)$$

となる。 Φ は第 12 回と同じく $\phi_{iq} = \pi_q N(\tilde{\mathbf{x}}_i; \mu_q, \Sigma_q)$ を並べた $n \times k$ 行列で、 $\Phi \mathbf{1}_k$ の第 i 成分が (1) 式の $\log$ の中の和にあたる。前の節の入れ子の関係から、 $k+1$ 群のモデルは k 群の最良の答えをそのまま作れる (1 つの群の混合比率を 0 にすればよい)。最大化の範囲が広がるので、最大値は下がる。ない。

$$\hat{\ell}_{k+1} \geq \hat{\ell}_k \quad (3)$$

図 3 は、トーストの人工データで群ごとの型の $\hat{\ell}_k$ を $k = 1, \dots, 6$ について求めたものである。 $\hat{\ell}_k$ は、データを作った群の数 3 を過ぎても上がり続ける。ただし EM は局所解に止まることもある。初期値を十分に試さないと、実際の計算では (3) 式が崩れて見えることがある。この人工データでも、初期値 10 通りでは $k = 8$ で崩れたので、本章の人工データでは $k \leq 6$ に限った。

以下では、対数尤度を -2 倍した $-2\hat{\ell}$ を「当てはまりの悪さ」として使う。 -2ℓ が二乗誤差の仲間だからである。1 変数・1 群の正規分布では、1 つの行について

$$-2 \log f(x_i) = \frac{(x_i - \mu)^2}{\sigma^2} + \log(2\pi\sigma^2) \quad (4)$$




図 3: 2 変数・3 群の人工データで、群ごとの型の混合正規分布の最大の対数尤度 $\hat{\ell}_k$ (初期値 10 通りの最良)

であり、全行で足せば $-2\ell = \sum_i (x_i - \mu)^2 / \sigma^2 + n \log(2\pi\sigma^2)$ となる。第 1 回の残差平方和を σ^2 で割り、定数を足したものである。 p 変数で、所属 $\mathbf{G}$ が見えていて共分散が共通の球 $\sigma^2 \mathbf{I}$ なら、第 12 回で所属が見えてい
るときの対数尤度を -2 倍して

$$-2\ell_{\mathbf{G}} = \frac{\|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2}{\sigma^2} + np \log(2\pi\sigma^2) - 2 \sum_{i=1}^n \sum_{q=1}^k g_{iq} \log \pi_q \quad (5)$$

となる。 $p = 1, k = 1$ なら (4) 式の和に戻る。第 1 項は第 11 回の k-means の目的関数 J を σ^2 で割ったものである。したがって、 J が k とともに下がることと、 $\hat{\ell}$ が k とともに上がることは同じ現象である。どちらも、小さいモデルを含む大きいモデルの当てはまりが、手元の行では必ず良くなることを言っている。第 2 回の訓練誤差、第 4 回の $\lambda = 0$ と同じ構図である。

道具：パラメータの数 d

当てはまりの悪さ $-2\hat{\ell}$ は k とともに下がり続けるので、それだけでは選べない。大きいモデルほど動かせるパラメータが多いので、その多さを罰として足すことを考える。そのためには、候補ごとに「自由に動かせるパラメータの数」 d を数える必要がある。スカラー・ベクトル・行列の順に数える。

1 変数・2 群で群ごとに分散を持たせると、パラメータは混合比率 π_1, π_2 、平均 μ_1, μ_2 、分散 σ_1^2, σ_2^2 である。ただし $\pi_2 = 1 - \pi_1$ は π_1 が決まれば決まるので数えない。したがって $d = 5$ である。第 6 回の LDA のように分散を共通にすれば $d = 4$ 、 $k = 1$ なら平均と分散の $d = 2$ である。

p 変数・ k 群で群ごとの型なら、混合比率は $k - 1$ 個、平均ベクトル μ_q は p 個ずつで kp 個ある。共分散行列 Σ_q は対称で、左下の成分は右上と同じ値なので、対角と上半分の $p(p + 1)/2$ 個ずつを数える。合わせて

$$d = (k - 1) + kp + k \frac{p(p + 1)}{2} \quad (6)$$

となる。 $p = 1$ 、 $k = 2$ なら $1 + 2 + 2 = 5$ で、スカラーで数えた値に戻る。第 3 項は p の 2 乗で増えるので、列が多いと d はすぐに行の数を超える。たとえば $p = 10$ 、 $k = 3$ なら $d = 2 + 30 + 165 = 197$ である (II-6 の落とし穴で見る)。

共分散の型を変えると、変わるのは第 3 項だけである。表 1 は、型ごとの共分散の数と、本章の人工データ ($p = 2$) での d をまとめたものである。共通の型は k を増やしても共分散の数が増えず、球の型は群ごとに 1 個しか増えない。

表 1: 共分散の型ごとのパラメータの数 d 。 $p = 2$ の列は k の式で書いた

型	共分散の数	d ($p = 2$)	d ($p = 2, k = 3$)
群ごと (full)	$k p(p + 1)/2$	$6k - 1$	17
共通 (tied)	$p(p + 1)/2$	$3k + 2$	11
対角 (diag)	$k p$	$5k - 1$	14
球 (spherical)	k	$4k - 1$	11

罰を足す：BIC

当てはまりの悪さ $-2\hat{\ell}$ は k とともに下がり続け、パラメータの数 d は増え続ける。そこで、 d に比例する罰を足して比べる。

定義 2 (BIC). 候補のモデルの最大の対数尤度を $\hat{\ell}$ 、パラメータの数を d 、行の数を n として

$$\text{BIC} = -2\hat{\ell} + d \log n \quad (7)$$

をベイズ情報量規準 (Bayesian information criterion) (BIC) と呼ぶ。BIC が最も小さい候補を選ぶ。

第 1 項は当てはまりの悪さで、 k を増やすと下がる。第 2 項は罰で、 k を増やすと上がる。BIC は、パラメータを決める前の「モデルそのものの出やすさ」から導かれる。これはパラメータのあらゆる値について平均したデータの出やすさであり、その対数を n が大きいとして近似し、 -2 倍したものが BIC である。導出は略す。近似の結果は $\hat{\ell} - (d/2) \log n$ になり、パラメータを 1 つ増やすごとに $\frac{1}{2} \log n$ だけ割り引かれる。この形だけを覚えておけばよい。第 12 回の行列の書き方では、候補 (k , 型) ごとに

$$\text{BIC}(k, \text{型}) = -2 \mathbf{1}_n^\top \log(\hat{\Phi} \mathbf{1}_k) + d(k, \text{型}) \log n \quad (8)$$

である ($\hat{\Phi}$ は最尤推定値で計算した Φ)。この値を k と型の表に並べ、最小の候補を選ぶ。

第 4 回のリッジ回帰も、目的関数に罰を足した。比べると違いがはっきりする。リッジ回帰の罰は係数の大きさ $\|\beta\|_2^2$ にかかり、その重み λ は交差検証 (クロスバリデーション、CV) で選んだ。BIC の罰はパラメータの数 d にかかり、重みは $\log n$ と決まっているので、選ぶべきつまみが残らない。また、リッジ回帰では罰を推定の目的

関数の中に入れた。BIC では推定はそのまま最尤法で行い、終わった後の比べ方にだけ罰を使う。なお、罰の重み $\log n$ を 2 に替えた $-2\hat{\ell} + 2d$ を AIC (Akaike information criterion) と呼ぶ。 $n \geq 8$ なら $\log n > 2$ なので、BIC の方が罰が重く、小さいモデルを選びやすい。

外の行で測る：CV

もう 1 つの道は、第 2 回・第 4 回と同じく、推定に使わなかった行で測ることである。手元の行で測った $\hat{\ell}$ は、その行に合わせて推定したので大きく出る。推定に使わなかった行の対数尤度

$$\ell_{\text{外}} = \sum_{i \in \text{外}} \log \sum_{q=1}^k \hat{\pi}_q N(\tilde{\mathbf{x}}_i; \hat{\boldsymbol{\mu}}_q, \hat{\boldsymbol{\Sigma}}_q) \quad (9)$$

なら、新しい行がそのモデルからどれだけ出やすいかを測れる。群を増やしすぎると、手元の行に合わせた細かい群や潰れた楕円ができる。新しい行はそこから出にくくなるので、 $\ell_{\text{外}}$ は下がる。

行を 1 回だけ取り分けると、どの行を取り分けたかで値が揺れる (第 2 回)。そこで第 4 回の V 分割交差検証 (k-fold CV) と同じ手続きをとる。

定義 3 (交差検証の対数尤度). n 行を V 組に分け、第 v 組を除いた行で EM によりパラメータを推定し、そのパラメータで第 v 組の行について $\phi_{iq} = \hat{\pi}_q N(\tilde{\mathbf{x}}_i; \hat{\boldsymbol{\mu}}_q, \hat{\boldsymbol{\Sigma}}_q)$ を並べた行列を $\boldsymbol{\Phi}_v^{(-v)}$ とする。

$$\ell_{\text{CV}} = \sum_{v=1}^V \mathbf{1}^\top \log(\boldsymbol{\Phi}_v^{(-v)} \mathbf{1}_k) \quad (10)$$

を交差検証 (クロスバリデーション、CV) の対数尤度と呼び、これが最も大きい候補を選ぶ。

どの行もちょうど 1 度だけ測る側に回り、そのときのパラメータはその行を見ていない (図 4)。 ℓ_{CV} は $\hat{\ell}$ と同じく対数尤度の単位なので、 $-2\ell_{\text{CV}}$ と BIC を同じ目盛りで並べて比べられる。

行を 5 組に分ける 橙：測る行 青：EM で推定する行




図 4: 5 分割 CV の分け方 (概念図)。各行 (行) で橙の組を測り、青の組で EM を回す

計算の手順

2 つの選び方を、実際に計算する形で手順にまとめる。

1. 候補として、群の数 $k = 1, \dots, k_{\max}$ と 4 つの共分散の型の組を並べる
2. 候補ごとに、全 n 行のデータ行列 $\mathbf{X}$ に第 12 回の EM をランダムスタートで回し、最大の対数尤度 $\hat{\ell} = \mathbf{1}_n^\top \log(\hat{\Phi} \mathbf{1}_k)$ を求める
3. 候補ごとに表 1 でパラメータの数 $d(k, \text{型})$ を数え、(8) 式の BIC を、行が k ・列が型の表 $\mathbf{B}$ に入れる
4. 交差検証(クロスバリデーション、CV)をするなら、行を V 組に分け、各 v について第 v 組を除いた $\mathbf{X}_{(-v)}$ に EM を回し、そのパラメータで第 v 組の $n_v \times k$ 行列 $\Phi_v^{(-v)}$ を作る。(10) 式の ℓ_{CV} を同じ形の表に入れる
5. $\mathbf{B}$ の最小の候補、または ℓ_{CV} の最大の候補を選ぶ。CV で選んだときは、選んだ候補を全行で当てはめ直す

BIC は候補ごとに 1 回の当てはめで済む。CV は候補ごとに V 回の当てはめが要るが、要るのは外の行の尤度だけで、パラメータの数 d を数える必要がない。

理論の帰結

2 つの選び方を、候補のモデルの節で作ったトーストの人工データ (2 変数・3 群、 $n = 120$) で比べる。図 5 は、群ごとの型の混合正規分布を $k = 1, \dots, 6$ で当てはめたときの $-2\hat{\ell}$ 、罰を足した BIC、5 分割 CV の $-2\ell_{CV}$ 、罰の重みを 2 にした AIC である。




図 5: 2 変数・3 群の人工データで、群ごとの型の混合正規分布の当てはまりの悪さ $-2\hat{\ell}$ 、BIC (橙の幅が罰 $d \log n$)、5 分割 CV の $-2\ell_{CV}$ 、AIC。四角は BIC・CV・AIC が選んだ k

第 1 に、当てはまりの悪さ $-2\hat{\ell}$ は、(3) 式のとおり k とともに下がり続ける (1058.4 から 684.8)。第 2 に、罰 $d \log n$ は群が 1 つ増えるごとに $6 \log n = 28.7$ ずつ増える (群ごとの型で $p = 2$ なら、1 群あたり混合比率 $1 \cdot$ 平均 $2 \cdot$ 共分散 3 の 6 個)。第 3 に、その和の BIC は谷を持ち、 $k = 3$ で最小の 823.1 になる。 $k = 2$ から 3 へは $-2\hat{\ell}$ が 92.1 下がり、罰の増分 28.7 を上回る。3 から 4 へは 9.3 しか下がらず、罰の増分に届かない。データを作った群の数がちょうど選ばれた。

第 4 に、罰を足さずに外の行で測っても、 $-2\ell_{CV}$ は $k = 3$ で最小になり、そこから先は上がる。手元の行に合

わけて増やした群は、新しい行を出しにくいからである。第 2 回で訓練誤差が下がり続ける一方、テスト誤差が U 字を描いたのと同じである。第 5 に、罰の重みを 2 にした AIC は $k = 6$ を選ぶ。罰の重みが変われば答えも変わる。同じ作り方で作り直した 8 通りのデータでは、BIC は 8 通りで $k = 3$ を選んだ。AIC が $k = 3$ を選んだのは 5 通りで、ほかは $k = 5 \sim 6$ だった。AIC がいつも大きい k を選ぶわけではないが、罰の軽い分だけ大きい側に振れやすい。BIC と AIC は似た式である。しかし BIC は「データを作ったモデル」を、AIC と CV は「新しい行をよく出すモデル」を目指して作られている。 n が大きいと、BIC の方が小さいモデルを選ぶ。

型も同じ表で選べる。図 6 は 4 つの型の BIC を並べたものである。最小は群ごとの型の $k = 3$ (823.1) である。斜めの帯を描けない球や対角の型では、帯を何個もの群でつなぐ。そのため BIC は大きい k まで下がり続け、最小値も群ごとの型に届かない。




図 6: 図 5 と同じ人工データで、4 つの共分散の型の BIC を並べたもの。四角が最小

一方、k-means の J にはこのどちらも使えない。 J は尤度ではないので、BIC の第 1 項にならない(第 12 回の極限 $\sigma^2 \rightarrow 0$ では (5) 式の -2ℓ が発散する)。また、外の行で測っても下がり続ける。図 7 は同じ人工データで、k-means の J を手元の行と、5 分割の外の行で測ったものである。外の行の J も 1238.7 から 94.1 まで下がる。 J は各行から最も近い代表点までの距離しか見ないので、代表点を増やせば、新しい行にも近い代表点が見つかる。混合正規分布では、群を増やすと混合比率が分けられ、各群の楕円は手元の行に合わせて縮む。そのため新しい行の出やすさが下がりうる。外の行で測る方法が使えるのは、モデルが新しい行の出やすさを言えるときである。

表 2 に 2 つの選び方をまとめる。

表 2: 罰を足す選び方と、外の行で測る選び方

	罰を足す(BIC)	外の行で測る(CV)
測るもの	手元の行の $-2\hat{\ell} + d \log n$	外の行の $-2\ell_{CV}$
要るもの	尤度と、パラメータの数 d	尤度(新しい行の出やすさ)
当てはめの回数	候補ごとに 1 回	候補ごとに V 回
目指すもの	データを作ったモデル	新しい行をよく出すモデル

	罰を足す(BIC)	外で行で測る(CV)
k-means の J	尤度が無いので使えない	下がり続けるので使えない

推定の外側

本章の 2 つの選び方は、どちらも推定そのものではない。第 1～12 回では、推定法(最小二乗法か最尤法か)と、何をするか(y を近似するか、行を群に分けるか)で決まるマスの中で、パラメータを推定してきた(表 3)。BIC と CV は、そのマスの中の推定を何度も回し、結果を外から比べる。モデルの大きさを決める手続きは、推定の一段外側にある。

表 3: 推定法と、何をするかで並べた回。本章は各マスのモデルの大きさを選ぶ

	最小二乗法	最尤法
y を近似する	第 1 回・第 5 回	第 6 回
行を群に分ける	第 11 回(k-means)	第 12 回(混合正規分布)

第 II 部 実データ解析

間欠泉のデータと手続き

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データ(トースト)は、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、次の 3 つを予想できる。1 つ目に、大きいモデルは小さいモデルを含むので、どの型でも $\hat{\ell}$ は k とともに上がり続けるはずである。2 つ目に、BIC は谷を持ち、データを作ったモデルを目指す。間欠泉の点は斜めに伸びた 2 つの塊に見えるので、BIC は群ごとの型 $\cdot k = 2$ を選ぶと見込める。3 つ目に、トーストでは CV も BIC と同じ群の数を選んだので、ここでも CV は BIC と同じ答えを選ぶはずである。

データは場面①のオールドフェイスフル間欠泉の 272 回の噴出である。データ行列 $\mathbf{X}$ は噴出時間(平均 3.49 分、標準偏差 1.14 分)と次の噴出までの待ち時間(平均 70.9 分、標準偏差 13.6 分)の 2 列で、それぞれ平均 0 $\cdot$ 標準偏差 1 にそろえた。そろえないと、対角の型や球の型の楕円が、散らばりの大きい待ち時間の向きにばかり合わせられてしまう(第 4 回で列の目盛りが罰の効き方を変えたのと同じ)。このデータには正解の列が無く、何種類の噴出があるかは選んだ答えを読んで考えるしかない。候補は $k = 1, \dots, 6$ と 4 つの型の組の 24 通りである。

手続きは次のとおりである。候補ごとに、scikit-learn の GaussianMixture で EM を初期値 20 通りから回し、最大の対数尤度 $\hat{\ell}$ を求めた(共分散行列の対角に 10^{-6} を足すのは第 12 回と同じ)。パラメータの数 d は表 1 のとおり自分で数え、(7) 式で BIC を計算した。交差検証(クロスバリデーション、CV)では、行を無作為に 5




図 7: 図 5 と同じ人工データで、k-means の J を手元の行(全行で当てはめ)と外行(5 分割)で測ったもの

組に分けた。残りの 4 組で EM を回し(初期値 5 通り)、測る組の行の対数尤度を足して (10) 式を求めた。最後に、5 組への分け方を 10 通りに変えて CV を回し直した。

BIC で選ぶ

予想①から見る。表 4 は 24 通りの $\hat{\ell}$ である。どの型でも k とともに下がらず、(3) 式が成り立っている。予想どおりである。

表 4: 間欠泉の 272 回の噴出(2 列、標準化)で、24 通りの候補に当てはめた最大の対数尤度 $\hat{\ell}$

型	$k = 1$	$k = 2$	$k = 3$	$k = 4$	$k = 5$	$k = 6$
群ごと	-545.0	-385.5	-369.6	-361.3	-357.4	-350.2
共通	-545.0	-395.4	-381.5	-376.0	-371.4	-371.3
対角	-771.9	-403.0	-382.2	-368.1	-361.0	-357.1
球	-771.9	-423.3	-401.2	-385.5	-376.9	-369.0

次に予想②である。表 5 は 24 通りの候補の BIC である。最小は共通の型・ $k = 3$ の 824.7 で、2 番目の候補との差は 5.8 であった。目で見ただけで 2 つの塊を描く群ごとの型・ $k = 2$ は選ばれず、予想は外れた。

表 5: 間欠泉の 272 回の噴出で、24 通りの候補の BIC (★が最小)

型	$k = 1$	$k = 2$	$k = 3$	$k = 4$	$k = 5$	$k = 6$
群ごと	1,118.0	832.6	834.6	851.5	877.4	896.5
共通	1,118.0	835.6	824.7 ★	830.5	838.0	854.8
対角	1,566.2	856.5	842.9	842.7	856.5	876.7

型	$k = 1$	$k = 2$	$k = 3$	$k = 4$	$k = 5$	$k = 6$
球	1,560.6	885.9	864.0	855.2	860.4	866.9

外れた理由を、第 I 部の道具で順に見る。まず群ごとの型の中だけで比べる。I-7 の帰結④と同じく、群を 1 つ増やしたときの $-2\hat{\ell}$ の下がり幅と、罰の増分 $6 \log n = 33.6$ を比べればよい。1 → 2 では $-2\hat{\ell}$ が 319.1 下がり、罰の増分を大きく上回る。2 → 3 では 31.6 しか下がらず、罰の増分に届かない。群ごとの型の中では、BIC は予想どおり $k = 2$ を選んでいる。

答えが変わるのは、型をまたいで比べたときである。群ごとの型・ $k = 2$ の BIC は 832.6 である。パラメータの数は群ごとの型・ $k = 2$ が 11 個、共通の型・ $k = 3$ が 11 個で同じなので、罰も同じである。 $\hat{\ell}$ は共通の型・ $k = 3$ の方が 3.9 大きい。楕円の傾きを群ごとに推定する分のパラメータを、3 つ目の群に回した方が当てはまりが良い、というのが BIC の答えである。

図 8 (a) は、BIC の答えを 2 列の上に描いたものである。群を分の単位に戻すと(表 6)、短い噴出の群が 1 つと、長い噴出の群が 2 つになる。長い噴出の 2 つの群は、平均がおおよそ 3.8 分と 4.5 分で、塊の中の短めの側の裾と本体にあたる。長い噴出の塊は、正規分布の楕円 1 つで描くには形が崩れている。BIC が目指す「データを作ったモデル」は候補の中にあることが前提であり、この塊ではその前提が少しずれている。そこで BIC は、罰を払ってでも群を 1 つ足した。ただし、これは噴出の仕組みが 3 種類あるという意味ではない。群の数は、正規分布の楕円で塊を描くと決めたうえで、何を測る基準を置いたかで決まる。

表 6: BIC が選んだ答えの群ごとの行数と、噴出時間・待ち時間の平均(分に戻した)

BIC の群	行数	噴出時間の平均	待ち時間の平均
1	97	2.04 分	54.5 分
2	42	3.81 分	77.6 分
3	133	4.47 分	80.9 分

CV で選ぶ

最後に予想③である。表 7 は同じ候補の 5 分割 CV の対数尤度 ℓ_{CV} である。最大は対角の型・ $k = 4$ の -395.7 であり、BIC とは違う候補を選んだ。予想は外れた。図 8 (b) のとおり、対角の型なので楕円の軸が座標軸に沿い、斜めに伸びた塊をそれぞれ 2 つの楕円でつないでいる。

表 7: 間欠泉の 272 回の噴出で、24 通りの候補の 5 分割 CV の対数尤度 ℓ_{CV} (★が最大)

型	$k = 1$	$k = 2$	$k = 3$	$k = 4$	$k = 5$	$k = 6$
群ごと	-549.2	-401.0	-401.9	-406.0	-413.8	-430.3
共通	-549.2	-406.1	-396.6	-400.3	-402.6	-405.9
対角	-775.5	-417.3	-408.0	-395.7 ★	-401.0	-409.0

型	$k = 1$	$k = 2$	$k = 3$	$k = 4$	$k = 5$	$k = 6$
球	-775.5	-436.1	-429.8	-422.3	-420.7	-417.1




図 8: 間欠泉の 272 回の噴出で、(a) BIC、(b) 5 分割 CV が選んだ混合正規分布。色は所属(責任度が最大の群)、楕円は推定した共分散の形、■は平均

外れた理由は 2 つある。1 つ目は、目指すものの違いである(表 8)。I-7 で見たとおり、BIC はデータを作ったモデルを、AIC と CV は新しい行をよく出すモデルを目指す。罰を足さない $\hat{\ell}$ は、いつも最も大きい候補を選ぶ。BIC は共通の型・ $k = 3$ 、罰の軽い AIC は群ごとの型・ $k = 4$ 、CV は対角の型・ $k = 4$ を選んだ。トーストでは、作った群がちょうど正規分布だったので、BIC と CV の答えが重なった。間欠泉の塊は楕円 1 つに収まらないので、新しい行の出やすさを細かく言うには、群を細かく分けた方が得になる。AIC と CV の答えは、その分だけ大きくなった。I-7 の人工データで AIC が大きい k を選んだのと同じ向きである。

表 8: 間欠泉の 272 回の噴出で、基準ごとに選んだ答え

基準	測ったもの	選んだもの
$\hat{\ell}$ (罰なし)	手元の行の出やすさ	いつも最も大きい候補
BIC	手元の行の出やすさから罰を引いたもの	共通の型・ $k = 3$
AIC	手元の行の出やすさから軽い罰を引いたもの	群ごとの型・ $k = 4$
CV	外の行の出やすさ	対角の型・ $k = 4$
目で見える	塊の数	2 つ

2 つ目は、分け方による揺れである。表 9 は、行を 5 組に分ける分け方だけを 10 通り変え、24 通りの候補から CV が選んだものを数えたものである。BIC と同じ共通の型・ $k = 3$ が選ばれたのは 4 回で、ほかの回は別の候補が選ばれた。最初の分け方では 1 番目と 2 番目の候補の ℓ_{CV} の差が 1.0 しかなく、分け方による揺れより小さい(第 2 回の「分割しだいで数字がばらつく」)。BIC は行を分けないので、同じデータからはいつも同じ答えを返す。

表 9: 間欠泉の 2 列で、5 組への分け方を 10 通り変えたときに CV が選んだ候補

CV が選んだ候補	分け方 10 通りのうち
共通の型・ $k = 3$	4 回
対角の型・ $k = 4$	2 回
対角の型・ $k = 5$	2 回
群ごとの型・ $k = 4$	1 回
共通の型・ $k = 4$	1 回

計算の確認

計算そのものも確かめた。表 10 は数えた d である。この d で計算した BIC と、ライブラリが返す BIC の差は 24 通りで最大 $0.0e+00$ で、数え方が同じであることを確かめた。また群ごとの型・ $k = 2$ について、第 12 回の I-6 の手順をそのまま書いた自前の EM (初期値 10 通り)でも $\hat{\ell}$ を求めた。ライブラリの -385.46 との差は $6.1e-06$ であった。

表 10: 24 通りの候補のパラメータの数 d ($p = 2$)

型	$k = 1$	$k = 2$	$k = 3$	$k = 4$	$k = 5$	$k = 6$
群ごと	5	11	17	23	29	35
共通	5	8	11	14	17	20
対角	4	9	14	19	24	29
球	3	7	11	15	19	23

選び方が壊れるとき

間欠泉の 2 列では、どの候補もパラメータの数が行の数よりずっと少なかった。列が多く行が少ないと事情が変わる。間欠泉のデータでは起きないので、もっと極端な例を見ておく。ここでは人工的なデータを使う。作った群の数を知っているので、選び方が壊れたことがはっきり見える。正解の無い間欠泉のような実データでは、壊れても気づけない。候補のモデルの節と同じ 3 台のトースターで 30 枚ずつ焼いたトースト 90 枚について、表面の 10 か所の焼き色を測ったとする (台ごとに平均の違う正規分布から作った)。群ごとの型の d は (6) 式で $k = 3$ なら 197 個で、行の数 90 を超える。群ごとの共分散行列だけで 1 群 55 個あり、30 行の群からでも推定はぎりぎりである。

表 11 は、このデータで $k = 1, \dots, 5$ の BIC を、共分散行列の対角に足す数を変えて求めたものである。 $k = 5$ では 7 行しかない群ができる。行の数が列の数 10 より少ないので、その群の共分散行列は特異になり、楕円が潰れる (第 12 回の「1 点に縮むと $\ell \rightarrow \infty$ 」)。足す数を小さくするたびに $\hat{\ell}$ はいくらでも大きくなる。足す数が大きいうちは罰が重く、BIC は $k = 1$ を選ぶ。 $k = 5$ のパラメータは 329 個で、罰 1,480 は大きい。しかし罰は

決まった数なので、足す数を小さくすると、表の 3 行目から下では BIC は $k = 5$ を選ぶ。罰はパラメータの数を数えるだけである。最尤推定そのものが存在しないときの見かけの $\hat{\ell}$ は、罰では見抜けない。

表 11: トースト 90 枚・表面 10 か所の焼き色の人工データ (3 群) で、群ごとの型の共分散行列の対角に足す数を変えたときの BIC (ライブラリで初期値 5 通りの最良)

対角に足す数	$k = 1$	$k = 2$	$k = 3$	$k = 4$	$k = 5$	選ぶ k
10^{-2}	3,298	3,334	3,454	3,591	3,705	1
10^{-4}	3,298	3,334	3,454	3,540	3,474	1
10^{-6}	3,298	3,334	3,454	3,494	3,216	5
10^{-8}	3,298	3,334	3,454	3,448	2,958	5
10^{-10}	3,298	3,334	3,454	3,401	2,700	5

外の行で測ると事情が変わる (表 12)。潰れた群は、手元の数行を極端に出しやすくする。しかし外の行はその潰れた向きから外れるので、潰れた群からはほとんど出てこない。そのため ℓ_{CV} は足す数によらず $k = 1$ を選ぶ。ただし、作った群は 3 つである。4 組で推定する 72 行では、群ごとの共分散行列を 3 群分推定するには行が足りず、CV は群を分けない答えを選んだ。同じデータで、パラメータの少ない対角の型 ($k = 3$ で 62 個) の BIC を求めると $k = 3$ が最小になった。その群は、作った 3 台を 100% の行で言い当てた。列が多く行が少ないときは、 k と同時に型を小さくしないと、どちらの基準も働かない。

表 12: 同じ人工データで、群ごとの型の 5 分割 CV の対数尤度 ℓ_{CV} (初期値 3 通りの最良)

対角に足す数	$k = 1$	$k = 2$	$k = 3$	$k = 4$	$k = 5$
10^{-6}	-1,582	-1,656	-1,770	-1,956	-2,997
10^{-10}	-1,582	-1,656	-1,712	-1,956	-2,997

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは 3 つを予想した。 $\hat{\ell}$ がどの型でも k とともに上がり続けることは、予想どおりだった。BIC が目で見えた 2 つの塊を選ぶという予想は、半分外れた。群ごとの型の中では、 $2 \rightarrow 3$ の下がり幅が罰の増分に届かず、BIC は $k = 2$ を選んだ。しかし型をまたぐと、同じ罰で $\hat{\ell}$ の大きい共通の型・ $k = 3$ が勝った。長い噴出の塊が正規分布の楕円 1 つに収まらず、BIC の前提が少しずれていたためである。CV が BIC と同じ答えを選ぶという予想は外れた。CV は新しい行をよく出すモデルを目指すので、AIC と同じく大きい側へ振れた。さらに上位の候補の差が小さく、分け方で答えが揺れた。人工データの落とし穴では、列が多く行が少ないと BIC も CV も働かず、型を小さくする必要があった。どの基準も、置いた前提と目指すものの範囲で答えを返す。

締め

まとめと次回問い

本章の問いは、群の数 k をどう選ぶか、であった。混合正規分布の最大の対数尤度 $\hat{\ell}$ は k とともに上がり、k-means の J は下がり続ける。大きいモデルは小さいモデルを特別な場合として含むからである。そのため推定法そのものでは k は決まらない。共分散の型も同じである。そこで推定の外に基準を置く。1 つは当てはまりの悪さ $-2\hat{\ell}$ にパラメータの数の罰を足す BIC $-2\hat{\ell} + d \log n$ であり、 d は混合比率・平均・共分散を型ごとに数える。もう 1 つは、推定に使わなかった行の対数尤度を測る交差検証(クロスバリデーション、CV)である。トーストの人工データでは、どちらもデータを作った群の数 3 を選んだ。間欠泉の 272 回の噴出では、目で見えた塊は 2 つであったが、BIC は共通の型・ $k = 3$ を、AIC は群ごとの型・ $k = 4$ を、CV は対角の型・ $k = 4$ を選んだ。置いた基準が違えば答えも違う。列が多く行が少ないと、潰れた群で $\hat{\ell}$ がいくらでも上がるので、BIC は止まらない。外の行で測る CV も群ごとの型では群を分けられなかった。型を小さくする必要がある。その CV の答えは、行の分け方で揺れた。

罰と外の行のほかにも、推定の外に置ける物差しはある。構造の無い一様なデータで同じ k-means を回して J と比べる Gap 統計、自分の群への近さと隣の群からの遠さを比べるシルエット係数、行を取り直しても同じ群になるかを見る安定性などである。どれも推定の目的関数とは別のものを外に置いている点で、本章の 2 つと同じ型である。

最後に、次回への問いを置く。第 1~13 回のデータ行列 $\mathbf{X}$ は、行が個体、列が測った量(数)であった。今回、群の数は推定の外に基準を置いて決めた。では、行も列もカテゴリで、マスの中身が度数(その組み合わせが何件あったか)であるような表はどう扱えばよいか。行と列が独立なら、どの度数になるはずか。そこからのずれを読みたい。行と列が両方カテゴリなら、どうすればよいだろうか。