第 14 回 ネットワーク分析

つながりの表からまとまりを見つけ、表が無ければデータ行列から作る（最終回）

最終回の問いは、第 13 回の締めで残った「行も列も同じものの、つながりの表から、何を読み、どう描くか」である。前半では、点と点のつながりを 0/1 で並べた隣接行列 $\mathbf{A}$ から、まとまり（群）を見つけて描く。群をまたぐ線の数を群の大きさで割ったレシオカットを目的関数にし、群を表す値を 0/1 から実数に緩めると、グラフラプラシアン $\mathbf{L} = \mathbf{D} - \mathbf{A}$ の小さい方の固有ベクトルが答えになる。その行を第 7 回の k-means で分ける（スペクトルクラスタリング）。冒頭ではネットワーク分析の基本の言葉（ノード・エッジ・次数・ハブ・スケールフリー・スモールワールド）をそろえる。後半では、つながりの表が手元に無く、データ行列しか無いときを考える。相関で線を引くと間をはさんだ組までつながるので、精度行列の 0 で線を引き、それを第 4 回の ℓ_1 罰則付きの最尤法で推定する（Graphical Lasso）。第 II 部では、株価のデータ行列から表を作り、それを固有ベクトルで切る。最後に、全 14 回を「モデル × 推定法」の地図にまとめる。

第 I 部　理論

ネットワークの言葉

第 13 回の締めで、行も列も同じものの表を考えた。駅 × 駅の乗り換えの人数や、店 × 店の同じ日に寄った客の数である。本章の問いは、このようなつながりの表から、何を読み、どう描くかである。まず、つながりを扱う分析（ネットワーク分析（network analysis））の基本の言葉をそろえる。

点をノード（node）、点と点を結ぶ線をエッジ（edge）と呼び、その集まりをネットワーク、またはグラフ（graph）と呼ぶ。駅と路線、論文と引用、タンパク質どうしの結合などがその例である。エッジには、引用のように向きのあるものと、路線のように向きの無いものがあり、乗り換えの人数のように強さ（重み）を持つものもある。本章では向きの無いエッジを扱う。n 個のノードのつながりは、i と j にエッジがあれば $a_{ij} = 1$、無ければ 0 とした $n \times n$ の隣接行列（adjacency matrix） $\mathbf{A}$ で表す（定義 1）。向きが無いので $\mathbf{A}$ は対称で、対角は 0 である。重みがあるときは、a_{ij} にその値を入れればよい。

定義 1 (グラフと隣接行列)**.** n 個のノードと、ノードどうしを結ぶエッジの集まりをグラフと呼ぶ。i と j にエッジがあれば $a_{ij} = 1$、無ければ $a_{ij} = 0$ とした $n \times n$ の対称行列 $\mathbf{A}$ を隣接行列と呼ぶ。対角は 0 とする。

ノード i から出ているエッジの数 $d_i = \sum_j a_{ij}$ を次数（degree）と呼ぶ（定義 2）。隣接行列の行の和である。エッジの本数を m とすると、1 本のエッジは両端のノードで 1 回ずつ数えられるので、次数の和は $2m$ になる。

定義 2 (次数)**.** ノード i から出ているエッジの数 $d_i = \sum_j a_{ij}$ を次数と呼ぶ。並べると $\boldsymbol{d} = \mathbf{A}\mathbf{1}_n$ で、対角に

並べた行列を $\mathbf{D} = \mathrm{diag}(\boldsymbol{d})$ と書く。エッジの本数を m とすると $\mathbf{1}_n^\top \boldsymbol{d} = 2m$ である。

次数の並び方は、ネットワークの作られ方で大きく違う。図 1 は、どちらも 60 ノードの人工のネットワークである。(a) は、どの 2 つのノードにも同じ確率でエッジを引いたもの（ランダムグラフ）である。(b) は、ノードを 1 つずつ足し、新しいノードが、すでにあるノード i に確率 $d_i / \sum_j d_j$ でつながるように作ったものである。次数の大きいノードほど、さらにつながりやすい。これを優先的選択（preferential attachment）と呼ぶ（Barabási & Albert 1999）。よく引用された論文がさらに引用され、リンクの多いウェブページがさらにリンクされるのと同じである。(b) には、次数がとびぬけて大きいノードができる。これをハブ（hub）と呼ぶ。

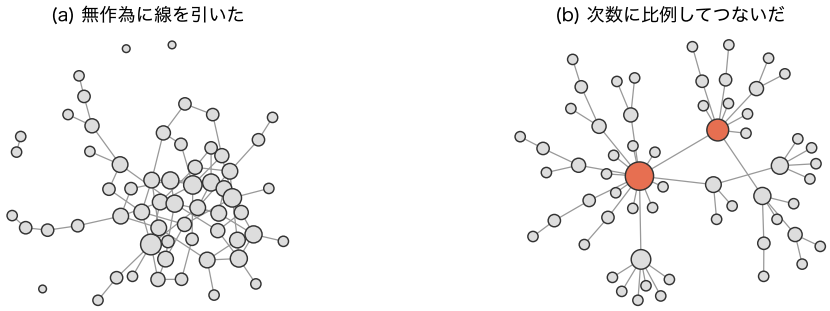


図 1: 60 ノードの人工のネットワーク。(a) どの 2 つのノードにも同じ確率でエッジを引いたもの、(b) 次数に比例してつないだもの。点の大きさは次数、橙はハブ

3000 ノードで同じように作り、次数の分布を比べる（図 2）。平均の次数はどちらも 4 である。(a) の次数は平均のまわりに集まり、最大でも 14 である。(b) は次数 1〜3 のノードが多い一方で、次数 137 のノードもある。両対数の目盛りで描くと、(b) はほぼ直線に並ぶ。次数が d のノードの割合が

$$\Pr(d) \propto d^{-\gamma} \tag{1}$$

の形（べき分布）であることを意味する。d を 10 倍すると割合は $10^{-\gamma}$ 倍になり、d がいくつのところでも同じ倍率で減る。(a) の平均のような、目安となる大きさが無い。このようなネットワークをスケールフリー（scale-free）と呼ぶ。ウェブのリンクや論文の引用は、スケールフリーに近いと報告されてきた。ただし、実際のネットワークがどこまで厳密にべき分布に従うかには議論がある（Broido & Clauset 2019）。

ハブは、ネットワークの強みであり弱みでもある（Albert, Jeong & Barabási 2000）。(b) の 3000 ノードから、ノードを無作為に 15% 外しても、84% のノードが 1 つの塊につながったままである。外れるノードの多くは次数の小さいノードだからである。ところが次数の大きい順に 15% 外すと、最大の塊は 7% まで小さくなる（図 3）。エッジの多くがハブに集まっているので、ハブを外すと残りのノードをつなぐ道が切れる。

2 つのノードの距離は、何本のエッジをたどれば着くかで測る。80 ノードを輪に並べ、両隣 2 つずつとつないだネットワークでは、平均の距離は 10.4 である。そのうち 5% のエッジを無作為な相手に付け替えると、平均の距離は 5.1 に縮む（図 4）。数本の近道で、遠いノードどうしが近くなる。ノードの数が多くても平均の距離が短

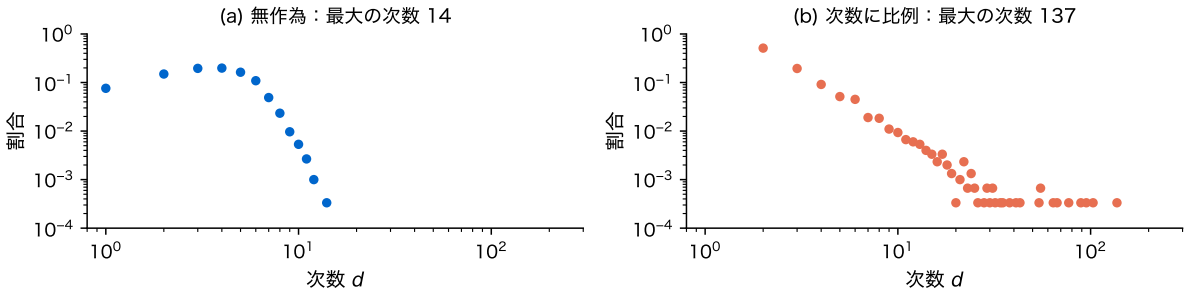


図 2: 3000 ノードの人工のネットワークの次数の分布（両対数の目盛り）。(a) 無作為にエッジを引いたもの、(b) 次数に比例してつないだもの

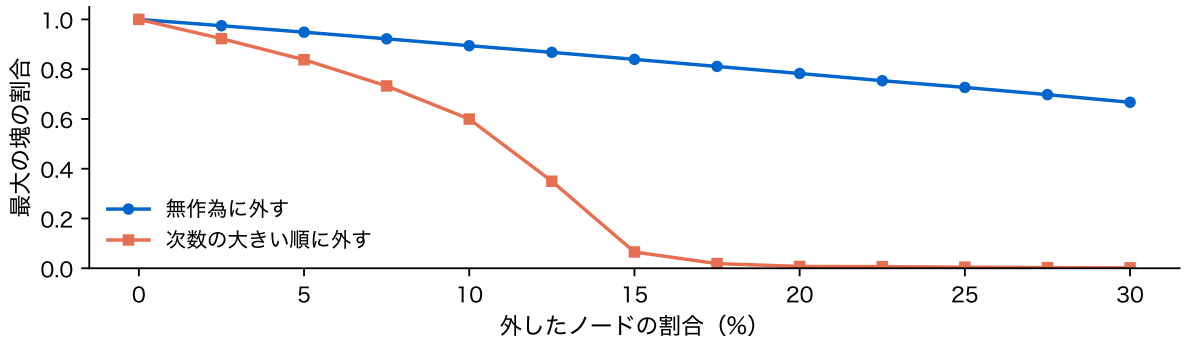


図 3: 次数に比例してつないだ 3000 ノードのネットワークから、ノードを外したときの最大の塊の割合。青は無作為に、橙は次数の大きい順に外したとき

いことを、スモールワールド（small world）と呼ぶ（Watts & Strogatz 1998）。知り合いをたどれば、誰にでも数歩で着くという話である。

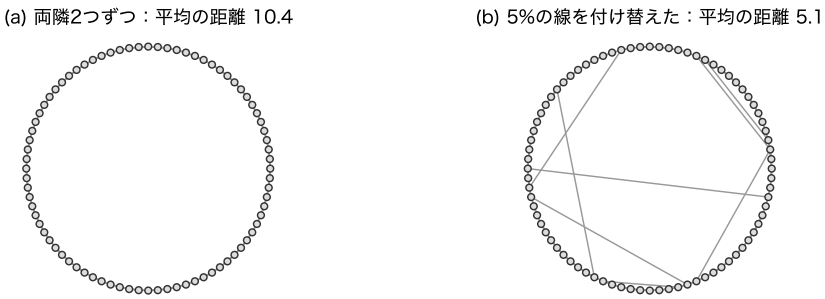


図 4: 80 ノードの輪のネットワーク。(a) 両隣 2 つずつとつないだもの、(b) そのうち 5% のエッジを無作為な相手に付け替えたもの

次数も距離も、ノードごとに計算する数である。では、どのノードとどのノードが 1 つのまとまりをなすか。これが本章の残りの問いである。

つながりの表

まとまりを見つける問題を、人工的なグラフで考える（図 5）。以下、ノードを点、エッジを線とも呼ぶ。13 個の点があり、1〜4、5〜8、9〜12 はそれぞれ全員どうしが線で結ばれている。塊の間には 2〜3 本の線があり、13 は 1 本の線で 1 とだけつながっている。

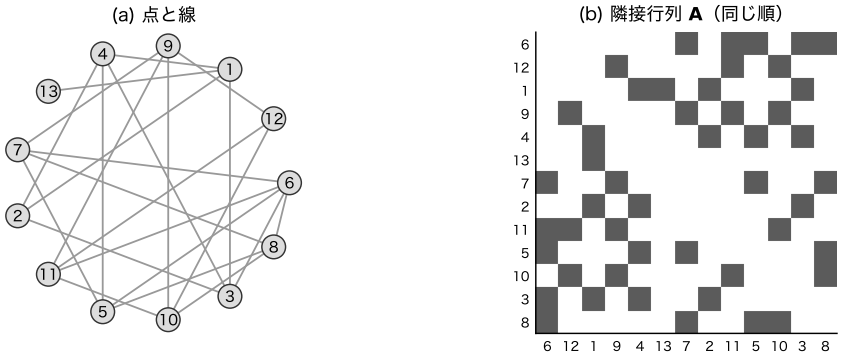


図 5: 人工のグラフ（13 点、24 本）。(a) 点を番号の分からない順に円の上に置いた図、(b) 同じ順に並べた隣接行列（黒が 1）

困りごとが 3 つある。1 つ目は、並べ方である。図 5 では、点を番号の分からない順に並べた。点と線を描いても、隣接行列を眺めても、まとまりがあるのかどうか分からない。並べ方を変えれば見えるはずだが、13! 通りの並べ方を試すわけにはいかない。2 つ目は、次数である。13 を除くどの点も次数は 3〜5 でハブは無く、次数からは、どの点とどの点が同じまとまりかは分からない。3 つ目は、切り方である。点を 2 つに分け、分け目をまたぐ線の数を最も少なくすると、13 だけが 1 本で切り離される。まとまりを見つけたいのに、1 点を切り離す答えになる。

本章では、これらに次の順で答える。まず、隣どうしで値が違うほど大きくなる量を行列で書き、分け目をまたぐ線の数をその量で表す。1 点だけを切り離さないよう、群の大きさで割る。次に、群を表す値を 0/1 から実数に緩めて、固有ベクトルで解く。k 個に分けるには、その行を第 7 回の k-means で分ける（スペクトルクラスタリング）。後半では、つながりの表が手元に無く、個体 × 変数のデータ行列しか無いときに、変数どうしのつながりの表を作る方法（Graphical Lasso）を導く。第 II 部では、株価のデータ行列から表を作り、それを固有ベクトルで切る。

表 1: 本章の位置づけ

モデル	手元の行列	解き方	回
k-means	データ行列 $\mathbf{X}$	交互に解く	第 7 回
主成分分析	データ行列 $\mathbf{X}$	特異値分解	第 10 回
対応分析	分割表 $\mathbf{O}$	特異値分解	第 12 回

モデル	手元の行列	解き方	回
スペクトルクラスタリング	隣接行列 $\mathbf{A}$	固有値分解 ＋ k-means	本章
Graphical Lasso	データ行列 $\mathbf{X}$	列ごとの Lasso	本章

まとまりを線の数で測る

点をまとまり（群）に分けることを考える。第 7 回と同じく、点 i が群 q に入るとき $g_{iq} = 1$、そうでなければ 0 とした $n \times k$ の所属行列 $\mathbf{G}$ で分け方を表す。第 7 回と違うのは、点の座標を並べたデータ行列 $\mathbf{X}$ が無く、隣接行列 $\mathbf{A}$ しか無いことである。そこで「まとまり」を、群の中に線が多く、群をまたぐ線が少ないことと考える。2 つに分けるときは、群 S とその残り $\bar{S}$ をまたぐ線の数

$$\mathrm{cut}(S, \bar{S}) = \sum_{i \in S} \sum_{j \in \bar{S}} a_{ij} \tag{2}$$

をカット（cut）と呼ぶ。

カットを行列で書くには、次数（定義 2）を使う。

2 群のとき、$i \in S$ なら $x_i = +1$、$i \in \bar{S}$ なら $x_i = -1$ とおく。線の両端が同じ群なら $(x_i - x_j)^2 = 0$、違う群なら 4 である。i, j を両方の順で足すと 1 本の線を 2 回数えるので

$$\frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} a_{ij} (x_i - x_j)^2 = 4\,\mathrm{cut}(S, \bar{S})$$

となる。左辺を展開する。$(x_i - x_j)^2 = x_i^2 + x_j^2 - 2x_i x_j$ で、$\sum_j a_{ij} x_i^2 = d_i x_i^2$、$\mathbf{A}$ が対称なので $\sum_{i,j} a_{ij} x_j^2 = \sum_j d_j x_j^2$ である。したがって

$$\frac{1}{2} \sum_{i,j} a_{ij} (x_i - x_j)^2 = \sum_i d_i x_i^2 - \sum_{i,j} a_{ij} x_i x_j = \boldsymbol{x}^\top \mathbf{D} \boldsymbol{x} - \boldsymbol{x}^\top \mathbf{A} \boldsymbol{x} = \boldsymbol{x}^\top (\mathbf{D} - \mathbf{A}) \boldsymbol{x} \tag{3}$$

を得る。$\mathbf{L} = \mathbf{D} - \mathbf{A}$ をグラフラプラシアン（graph Laplacian）と呼ぶ（定義 3）。$\boldsymbol{x}^\top \mathbf{L} \boldsymbol{x}$ は、線でつながった点どうしの値の違いの二乗和である。この式は $\boldsymbol{x}$ が ± 1 でなくても成り立つ。

カットを最も小さくすると、困りごと③のように 1 点だけを切り離しやすい。そこで、群の大きさで割った

$$\mathrm{RatioCut}(S) = \mathrm{cut}(S, \bar{S}) \Big(\frac{1}{|S|} + \frac{1}{|\bar{S}|} \Big) \tag{4}$$

をレシオカット(ratio cut)と呼ぶ。$|S|$ は群に入る点の数である。人工データでは、13 だけを切り離すとカットは 1 だが、レシオカットは 1.08 である。1〜4 と 13 を切り離すとカットは 2 で、レシオカットは 0.65 と小さい(図 6)。

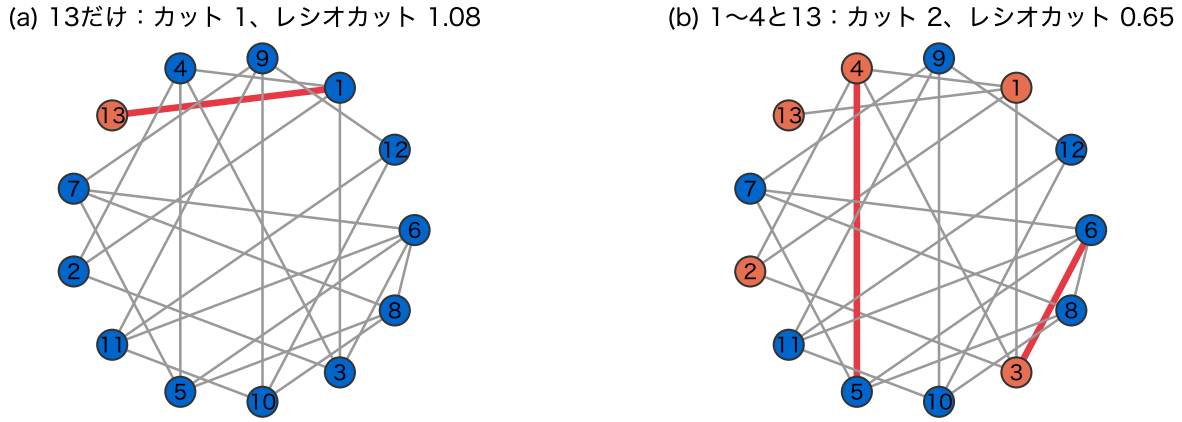


図 6: 人工のグラフの 2 通りの分け方。赤い線が群をまたぐ線。(a) 13 だけを切り離す、(b) 1〜4 と 13 を切り離す

レシオカットも 2 次形式で書ける。$i \in S$ なら $x_i = \sqrt{|\bar{S}|/|S|}$、$i \in \bar{S}$ なら $x_i = -\sqrt{|S|/|\bar{S}|}$ とおく。またぐ線 1 本では

$$(x_i - x_j)^2 = \frac{|\bar{S}|}{|S|} + \frac{|S|}{|\bar{S}|} + 2 = \frac{(|S| + |\bar{S}|)^2}{|S||\bar{S}|} = n\Big(\frac{1}{|S|} + \frac{1}{|\bar{S}|}\Big)$$

で、同じ群の線では 0 なので、(3) 式から $\boldsymbol{x}^\top \mathbf{L} \boldsymbol{x} = n\,\mathrm{RatioCut}(S)$ となる。さらに $\mathbf{1}_n^\top \boldsymbol{x} = |S|\sqrt{|\bar{S}|/|S|} - |\bar{S}|\sqrt{|S|/|\bar{S}|} = \sqrt{|S||\bar{S}|} - \sqrt{|S||\bar{S}|} = 0$、$\|\boldsymbol{x}\|_2^2 = |S| \cdot |\bar{S}|/|S| + |\bar{S}| \cdot |S|/|\bar{S}| = n$ である。

k 群に分けるときは、所属行列の列 $\boldsymbol{g}_q$ を群の大きさの平方根で割った $\mathbf{H} = \mathbf{G}(\mathbf{G}^\top \mathbf{G})^{-1/2}$ を使う。$\mathbf{G}^\top \mathbf{G}$ は群の大きさ $|C_q|$ を並べた対角行列なので、$\mathbf{H}^\top \mathbf{H} = (\mathbf{G}^\top \mathbf{G})^{-1/2} \mathbf{G}^\top \mathbf{G} (\mathbf{G}^\top \mathbf{G})^{-1/2} = \mathbf{I}_k$ である。列 $\boldsymbol{h}_q$ は、群 C_q の点で $1/\sqrt{|C_q|}$、ほかで 0 である。(3) 式で、線の両端が同じ側なら 0、群 C_q をまたぐなら $1/|C_q|$ なので、$\boldsymbol{h}_q^\top \mathbf{L} \boldsymbol{h}_q = \mathrm{cut}(C_q, \bar{C}_q)/|C_q|$ となる。トレースは対角の和なので

$$\mathrm{tr}(\mathbf{H}^\top \mathbf{L} \mathbf{H}) = \sum_{q=1}^{k} \boldsymbol{h}_q^\top \mathbf{L} \boldsymbol{h}_q = \sum_{q=1}^{k} \frac{\mathrm{cut}(C_q, \bar{C}_q)}{|C_q|} \tag{5}$$

を得る。$k = 2$ なら、$\mathrm{cut}(C_1, \bar{C}_1) = \mathrm{cut}(C_2, \bar{C}_2)$ なので (4) 式に戻る。

定義 3 (グラフラプラシアンとレシオカット)**.** 次数行列 $\mathbf{D}$ と隣接行列 $\mathbf{A}$ から作った $\mathbf{L} = \mathbf{D} - \mathbf{A}$ をグラフラプラシアンと呼ぶ。どの $\boldsymbol{x}$ についても $\boldsymbol{x}^\top \mathbf{L} \boldsymbol{x} = \frac{1}{2} \sum_{i,j} a_{ij} (x_i - x_j)^2$ である。群 S と残り $\bar{S}$ をまたぐ線の数 $\mathrm{cut}(S, \bar{S})$ をカット、それに $1/|S| + 1/|\bar{S}|$ を掛けたものをレシオカットと呼ぶ。

固有ベクトルで解く

レシオカットを最も小さくする分け方を求めたい。ところが、分け方は 2^n 通りあり、全部を試すことはできない。そこで、値を緩めて固有ベクトルで解く。導出には、次の 2 つの道具を使う。

定義 4 (2 次形式の最小)**.** $n \times n$ の対称行列 $\mathbf{M}$ を $\mathbf{M} = \mathbf{U}\boldsymbol{\Lambda}\mathbf{U}^\top$ ($\mathbf{U}^\top\mathbf{U} = \mathbf{I}$)と固有値分解し、固有値を小さい順に $\lambda_1 \le \lambda_2 \le \cdots \le \lambda_n$、固有ベクトルを $\boldsymbol{u}_1, \boldsymbol{u}_2, \ldots$ とする。$\|\boldsymbol{x}\|_2 = 1$ のもとで $\boldsymbol{x}^\top\mathbf{M}\boldsymbol{x}$ の最小は λ_1 ($\boldsymbol{x} = \boldsymbol{u}_1$)であり、さらに $\boldsymbol{x} \perp \boldsymbol{u}_1$ を課すと最小は λ_2 ($\boldsymbol{x} = \boldsymbol{u}_2$)である。

定義 5 (k 本の和の最小)**.** $n \times k$ の行列 $\mathbf{H}$ が $\mathbf{H}^\top\mathbf{H} = \mathbf{I}_k$ を満たすとき、$\mathrm{tr}(\mathbf{H}^\top\mathbf{M}\mathbf{H})$ の最小は $\lambda_1 + \cdots + \lambda_k$ であり、$\mathbf{H} = \mathbf{U}_k = [\boldsymbol{u}_1 \ \cdots \ \boldsymbol{u}_k]$ で届く。

定義 4 を示す。$\boldsymbol{c} = \mathbf{U}^\top\boldsymbol{x}$ とおくと $\boldsymbol{x} = \mathbf{U}\boldsymbol{c}$、$\|\boldsymbol{c}\|_2 = \|\boldsymbol{x}\|_2$ であり

$$\boldsymbol{x}^\top\mathbf{M}\boldsymbol{x} = \boldsymbol{c}^\top\mathbf{U}^\top\mathbf{U}\boldsymbol{\Lambda}\mathbf{U}^\top\mathbf{U}\boldsymbol{c} = \boldsymbol{c}^\top\boldsymbol{\Lambda}\boldsymbol{c} = \sum_{m=1}^{n} \lambda_m c_m^2 \tag{6}$$

となる。$\|\boldsymbol{x}\|_2 = 1$ なら $\sum_m c_m^2 = 1$ なので、これは固有値の重み付き平均で、λ_1 より小さくならない(図 7)。$\boldsymbol{x} = \boldsymbol{u}_1$ なら $c_1 = 1$ でほかは 0 になり、最小値 λ_1 に届く。さらに $\boldsymbol{x} \perp \boldsymbol{u}_1$ を課すと $c_1 = \boldsymbol{u}_1^\top\boldsymbol{x} = 0$ なので、重みは λ_2 以降にしか置けず、最小値は λ_2 ($\boldsymbol{x} = \boldsymbol{u}_2$)になる。

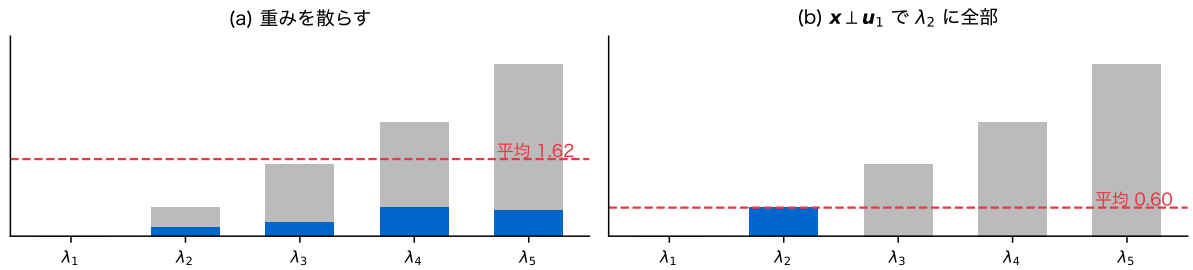


図 7: 固有値の重み付き平均(概念図)。灰色の棒が固有値、青が重みを掛けた分、赤い破線が平均。(a) 重みを散らしたとき、(b) 1 番目と直交させて 2 番目にすべての重みを置いたとき

定義 5 を示す。$\mathbf{B} = \mathbf{U}^\top\mathbf{H}$ とおくと

$$\mathrm{tr}(\mathbf{H}^\top\mathbf{M}\mathbf{H}) = \mathrm{tr}(\mathbf{B}^\top\boldsymbol{\Lambda}\mathbf{B}) = \sum_{m=1}^{n} \lambda_m w_m, \qquad w_m = \|\boldsymbol{u}_m^\top\mathbf{H}\|_2^2 \tag{7}$$

となる。$\mathbf{B}^\top\mathbf{B} = \mathbf{H}^\top\mathbf{U}\mathbf{U}^\top\mathbf{H} = \mathbf{I}_k$ なので、重みの合計は $\sum_m w_m = \mathrm{tr}(\mathbf{B}\mathbf{B}^\top) = \mathrm{tr}(\mathbf{B}^\top\mathbf{B}) = k$ である。また $\mathbf{B}\mathbf{B}^\top$ は第 3 回の射影行列と同じく対称で冪等なので、その対角 w_m は 0 以上 1 以下である。1 本あたり 1 以下、合計 k の重みを固有値に配るとき、和を最も小さくするには、小さい方の k 本に 1 ずつ配ればよい。したがって最小値は $\lambda_1 + \cdots + \lambda_k$ で、$\mathbf{H} = \mathbf{U}_k$ で届く。第 10 回の Eckart–Young の定理の証明では、同じ重みを大きい方の Q 本に配った。

この道具を $\mathbf{M} = \mathbf{L}$ に当てる。まず、(3) 式より $\boldsymbol{x}^\top \mathbf{L}\boldsymbol{x}$ は二乗の和なので、$\mathbf{L}$ の固有値はどれも 0 以上になる。また $\mathbf{L}\mathbf{1}_n = \boldsymbol{d} - \mathbf{A}\mathbf{1}_n = 0$ なので、最も小さい固有値は $\lambda_1 = 0$ で、固有ベクトルは $\boldsymbol{u}_1 = \mathbf{1}_n/\sqrt{n}$ である。

2 群のときを考える。目的関数③より、レシオカットの最小化は、$\boldsymbol{x}$ を 2 つの値しかとらない形に限ったうえで、$\mathbf{1}_n^\top \boldsymbol{x} = 0$、$\|\boldsymbol{x}\|_2^2 = n$ のもとで $\boldsymbol{x}^\top \mathbf{L}\boldsymbol{x}$ を最小にすることである。2 つの値に限るのをやめ、任意の実数を許す(緩める)と

$$\min_{\boldsymbol{x} \in \mathbb{R}^n} \boldsymbol{x}^\top \mathbf{L}\boldsymbol{x} \quad \text{s.t.} \quad \mathbf{1}_n^\top \boldsymbol{x} = 0, \quad \|\boldsymbol{x}\|_2^2 = n \tag{8}$$

となる。$\mathbf{1}_n^\top \boldsymbol{x} = 0$ は $\boldsymbol{x} \perp \boldsymbol{u}_1$ と同じなので、定義 4 (長さを $\sqrt{n}$ 倍したもの)より、答えは 2 番目に小さい固有値の固有ベクトル $\hat{\boldsymbol{x}} = \sqrt{n}\,\boldsymbol{u}_2$ で、最小値は $n\lambda_2$ である。$\boldsymbol{u}_2$ をフィードラーベクトル(Fiedler vector)と呼ぶ。緩めた答えは実数なので、符号で 2 群に戻す。人工データでは、図 8 のように 1〜4 と 13 が負になり、レシオカットが最も小さい分け方(図 6 (b))と一致する。

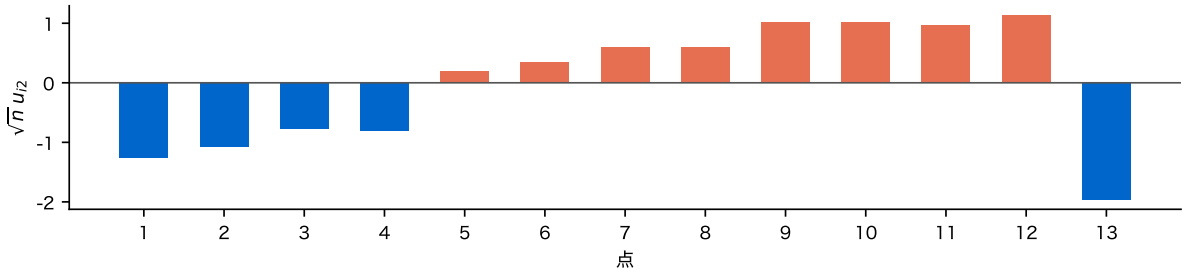


図 8: 人工のグラフのフィードラーベクトル(√ n 倍)。負を青、正を橙で塗った

k 群でも同じである。(5) 式を最小にする $\mathbf{G}$ を求める代わりに、$\mathbf{H} = \mathbf{G}(\mathbf{G}^\top \mathbf{G})^{-1/2}$ の形に限るのをやめ、$\mathbf{H}^\top \mathbf{H} = \mathbf{I}_k$ だけを残すと

$$\min_{\mathbf{H} \in \mathbb{R}^{n \times k}} \operatorname{tr}(\mathbf{H}^\top \mathbf{L}\mathbf{H}) \quad \text{s.t.} \quad \mathbf{H}^\top \mathbf{H} = \mathbf{I}_k \tag{9}$$

となる。定義 5 より、答えは小さい方から k 本の固有ベクトルを並べた $\hat{\mathbf{H}} = \mathbf{U}_k$ である。$k = 2$ なら $\boldsymbol{u}_1$ は定数なので、分け方を決めるのは $\boldsymbol{u}_2$ だけになり、2 群のときに戻る。緩める前の $\mathbf{H} = \mathbf{G}(\mathbf{G}^\top \mathbf{G})^{-1/2}$ では、同じ群の行はすべて同じ値をとる。$\mathbf{U}_k$ の行もそれに近いと期待して、行を第 7 回の k-means で k 群に分ける。この手順をスペクトルクラスタリング(spectral clustering)と呼ぶ(定義 6)。人工データで $k = 4$ とすると、図 9 のように 1〜4、5〜8、9〜12、13 の 4 群に分かれる。図 9 の点の位置は、2 番目と 3 番目の固有ベクトルの値である。

定義 6 (スペクトルクラスタリング)**.** グラフラプラシアン $\mathbf{L}$ の固有ベクトルを小さい方から k 本並べた $\mathbf{U}_k$ の行を、k-means で k 群に分ける手順をスペクトルクラスタリングと呼ぶ。$\mathbf{U}_k$ は、レシオカットの最小化を $\mathbf{H}^\top \mathbf{H} = \mathbf{I}_k$ だけ残して緩めた問題の答えである。2 群なら、2 番目の固有ベクトル(フィードラーベクトル)の符号で分けてもよい。

計算は、行列の形で次のようにまとめられる。

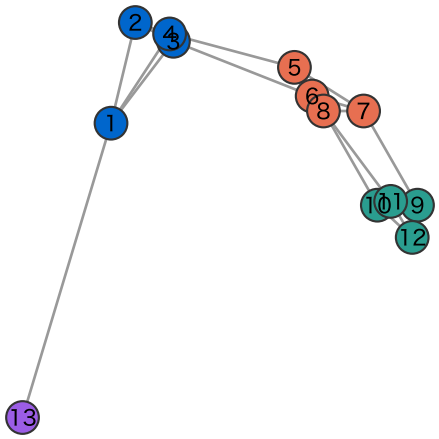


図 9: 人工のグラフを、2 番目と 3 番目の固有ベクトルの値(√ n 倍)を座標にして描いた図。色はスペクトルクラスタリング(k = 4)の群

1. 次数 $\boldsymbol{d} = \mathbf{A}\mathbf{1}_n$、$\mathbf{D} = \mathrm{diag}(\boldsymbol{d})$ を求め、$\mathbf{L} = \mathbf{D} - \mathbf{A}$ を作る
2. $\mathbf{L}$ を 1 回固有値分解し、固有値を小さい順に並べる
3. 小さい固有値の並びを見て、群の数 k を決める(後で述べる)
4. $\mathbf{U}_k$ の行を k-means で k 群に分ける。2 群なら、フィードラーベクトルの符号で分けてもよい
5. $(\sqrt{n}\,u_{i2}, \sqrt{n}\,u_{i3})$ を点 i の位置にして描き、群の順に $\mathbf{A}$ の行と列を並べ替える

第 7 回の k-means は、データ行列 $\mathbf{X}$ の行をそのまま分けた。ここでは $\mathbf{X}$ が無いので、$\mathbf{L}$ の固有ベクトルの行を点の座標の代わりにし、そのうえで第 7 回の手順を当てる。

理論の帰結 :塊と切り方

固有ベクトルから、困りごとへの答えが読み取れる。

第 1 に、並べ方である。同じ $\mathbf{A}$ を、フィードラーベクトルの値の小さい順に並べ替えると、図 10 (b) のように対角に 3 つの塊が現れる。$(\sqrt{n}\,u_{i2}, \sqrt{n}\,u_{i3})$ を点の位置にした 図 9 も、まとまりごとに点が集まる。13! 通りの並べ方を試さなくても、固有値分解 1 回で、まとまりの見える順と置き方が決まる。

第 2 に、塊の数である。(3) 式より、$\boldsymbol{x}^\top \mathbf{L}\boldsymbol{x} = 0$ となるのは、線でつながったどの 2 点でも $x_i = x_j$ のときに限る。線をたどって行ける点の集まり(つながった塊)の中では、$\boldsymbol{x}$ は一定になる。逆に、塊ごとに一定の $\boldsymbol{x}$ なら $\mathbf{L}\boldsymbol{x} = 0$ である。$\mathbf{L}$ の固有値は 0 以上なので、$\boldsymbol{x}^\top \mathbf{L}\boldsymbol{x} = 0$ と $\mathbf{L}\boldsymbol{x} = 0$ は同じ条件になる。(6) 式で $\sum_m \lambda_m c_m^2 = 0$ なら、$\lambda_m > 0$ の向きの c_m はすべて 0 だからである。したがって、固有値 0 の固有ベクトルは塊の 0/1 のベクトル $\boldsymbol{g}_q$ の組み合わせで書け、その本数は塊の数に等しい(定理 1)。人工データから塊の間の 5 本の線を抜くと、図 11 (a) のように固有値 0 がちょうど 3 個になる。線を戻すと、そのうち 2 個が 0 に近い小さな値になる。小さな固有値の後で大きく跳ぶところまでを数えれば、群の数 k の目安になる。元のグラフでは、小さな固有値が 4 個(1.71 以下)並んだ後、4.00 に跳ぶ(図 11 (b))。$k = 4$ では、13 が 1 点で 1 つの群になる。

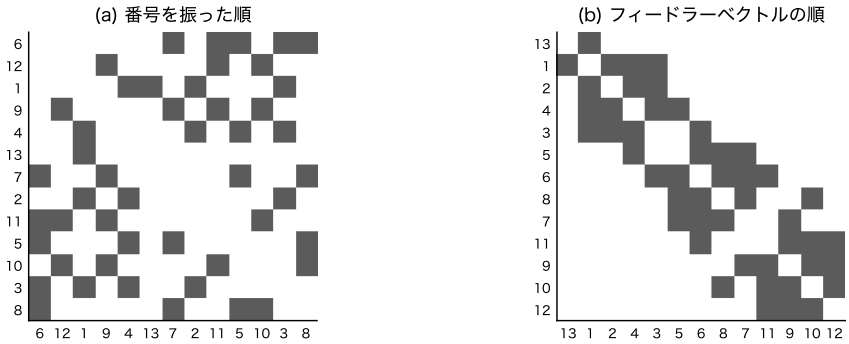


図 10: 人工のグラフの隣接行列。(a) 番号の分からない順、(b) フィードラーベクトルの値の小さい順に並べ替えたもの

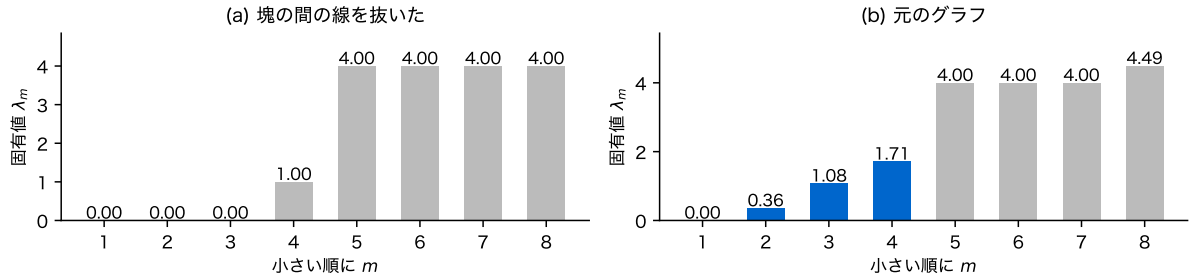


図 11: 人工のグラフのラプラシアンの固有値(小さい順に 8 個)。(a) 塊の間の 5 本の線を抜いたグラフ、(b) 元のグラフ

定理 1 (固有値 0 の数はつながった塊の数)**.** グラフラプラシアン $\mathbf{L}$ の固有値 *0* の数は、グラフのつながった塊の数に等しい。固有値 *0* の固有ベクトルは、塊ごとの *0/1* のベクトルの組み合わせで書ける。

第 3 に、点ごとの線の数(次数)である。次数は $\mathbf{L}$ の対角にしか入っていない。誰とつながるかは、対角でない $-\mathbf{A}$ が持つ。人工データでは次数がほぼそろっていても、フィードラーベクトルは塊ごとにそろった(図 8)。まとまりは、線の数ではなく、誰とつながるかで決まる。

第 4 に、切り方である。レシオカットでカットに掛かる $1/|S| + 1/|\bar{S}|$ は、$|S| = 1$ なら $1 + 1/(n-1)$、$|S| = n/2$ なら $4/n$ で、1 点だけの群を重く数える。12 点のグラフで 1 点を 1 本で切り離すとレシオカットは $1 \times (1 + 1/11) = 1.09$、6 点ずつを 3 本で切ると $3 \times (1/6 + 1/6) = 1.00$ になり、線が多くても大きさのそろった分け方を選ぶ。人工データでも、13 だけを切るレシオカットは 1.08、フィードラーベクトルの符号で切ると 0.65 である。

最後に、緩めた問題 (8) 式は、元の分け方から作った $\boldsymbol{x}$ をすべて候補に含む。だから緩めた最小値は元の最小値以下で、$\lambda_2 \leq \min_S \mathrm{RatioCut}(S)$ が成り立つ。人工データでは $\lambda_2 = 0.358$ である。λ_2 が大きいグラフは、どう切っても多くの線をまたぐ、切りにくいグラフである。

理論の帰結：次数で割る

レシオカットのスペクトルクラスタリングで $k=3$ とすると、13 が 1 点で 1 つの群になり、残りは 1〜5 と 6〜12 に分かれて、塊がくずれた（図 12）。線 1 本でしかつながらない点を 1 つの群に数えるのは、まとまりを見つけたいという目的に合わない。そこで、群の大きさを点の数ではなく次数の和 $\mathrm{vol}(S)=\sum_{i\in S} d_i$ で測る。

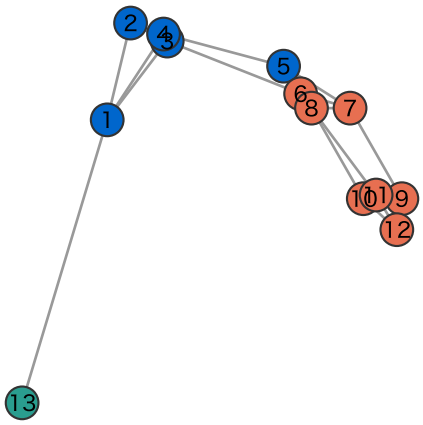


図 12: 人工のグラフを、レシオカットのスペクトルクラスタリング（k = 3）で分けた群。位置は 2 番目と 3 番目の固有ベクトルの値

$$\mathrm{Ncut}(S)=\mathrm{cut}(S,\bar{S})\Big(\frac{1}{\mathrm{vol}(S)}+\frac{1}{\mathrm{vol}(\bar{S})}\Big) \tag{10}$$

を正規化カット（normalized cut）と呼ぶ。線の少ない点は群の大きさに少ししか効かない。vol の合計は $\mathbf{1}_n^\top \boldsymbol{d}=2m$ である（定義 2）。

目的関数③と同じ計算ができる。$i\in S$ なら $x_i=\sqrt{\mathrm{vol}(\bar{S})/\mathrm{vol}(S)}$、$i\in\bar{S}$ なら $x_i=-\sqrt{\mathrm{vol}(S)/\mathrm{vol}(\bar{S})}$ とおくと、またぐ線 1 本で $(x_i-x_j)^2=2m\{1/\mathrm{vol}(S)+1/\mathrm{vol}(\bar{S})\}$ となるので

$$\boldsymbol{x}^\top\mathbf{L}\boldsymbol{x}=2m\,\mathrm{Ncut}(S),\qquad \boldsymbol{x}^\top\mathbf{D}\boldsymbol{x}=2m,\qquad \mathbf{1}_n^\top\mathbf{D}\boldsymbol{x}=0$$

を得る。2 つ目は $\sum_{i\in S} d_i x_i^2=\mathrm{vol}(S)\cdot\mathrm{vol}(\bar{S})/\mathrm{vol}(S)=\mathrm{vol}(\bar{S})$ と、$\bar{S}$ の側の同じ式を足したもの、3 つ目は $\mathrm{vol}(S)\sqrt{\mathrm{vol}(\bar{S})/\mathrm{vol}(S)}-\mathrm{vol}(\bar{S})\sqrt{\mathrm{vol}(S)/\mathrm{vol}(\bar{S})}=0$ である。値を緩め、$\boldsymbol{v}=\mathbf{D}^{1/2}\boldsymbol{x}$ とおくと、問題は

$$\min_{\boldsymbol{v}}\boldsymbol{v}^\top\mathbf{L}_{\mathrm{sym}}\boldsymbol{v}\quad\text{s.t.}\quad \boldsymbol{v}\perp\mathbf{D}^{1/2}\mathbf{1}_n,\quad \|\boldsymbol{v}\|_2^2=2m,\qquad \mathbf{L}_{\mathrm{sym}}=\mathbf{D}^{-1/2}\mathbf{L}\mathbf{D}^{-1/2}=\mathbf{I}-\mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2} \tag{11}$$

となる。$\mathbf{L}_{\mathrm{sym}}\mathbf{D}^{1/2}\mathbf{1}_n=\mathbf{D}^{-1/2}\mathbf{L}\mathbf{1}_n=0$ なので、$\mathbf{D}^{1/2}\mathbf{1}_n$ は固有値 0 の向きである。$\mathbf{L}_{\mathrm{sym}}$ も $\boldsymbol{v}^\top\mathbf{L}_{\mathrm{sym}}\boldsymbol{v}=(\mathbf{D}^{-1/2}\boldsymbol{v})^\top\mathbf{L}(\mathbf{D}^{-1/2}\boldsymbol{v})\geq 0$ より固有値は 0 以上で、定義 4 から答えは 2 番目の固有ベクトル $\boldsymbol{v}_2$、元の値は

$\boldsymbol{y}_2 = \mathbf{D}^{-1/2}\boldsymbol{v}_2$ である。k 群なら、小さい方からの $\boldsymbol{y}_m = \mathbf{D}^{-1/2}\boldsymbol{v}_m$ の行を k-means で分ける。人工データで $k = 3$ とすると、図 13 のように 13 は 1〜4 と同じ群に入り、3 つの塊に分かれる。

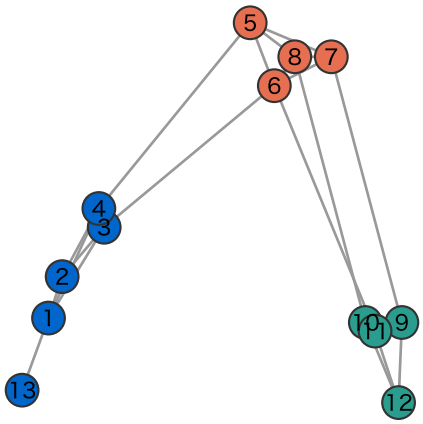


図 13: 人工のグラフを、正規化カットのスペクトルクラスタリング(k = 3)で分けた群。位置は $\boldsymbol{y}_2$、$\boldsymbol{y}_3$ の値(軸ごとに大きさをそろえた)

なぜ 13 が 1 に引き寄せられるのかは、固有ベクトルの式から読める。$\mathbf{L}_{\text{sym}}\boldsymbol{v} = \mu\boldsymbol{v}$ に $\boldsymbol{v} = \mathbf{D}^{1/2}\boldsymbol{y}$ を入れて左から $\mathbf{D}^{1/2}$ を掛けると $\mathbf{L}\boldsymbol{y} = \mu\mathbf{D}\boldsymbol{y}$、すなわち $\mathbf{A}\boldsymbol{y} = (1-\mu)\mathbf{D}\boldsymbol{y}$ となる。成分で書けば

$$y_i = \frac{1}{1-\mu} \cdot \frac{1}{d_i} \sum_{j=1}^{n} a_{ij} y_j \tag{12}$$

で、点の値は隣の点の値の平均を $1/(1-\mu)$ 倍したものである。13 の隣は 1 だけなので $y_{13} = y_1/(1-\mu_2)$ となり、13 の値は 1 の値に近い。線の少ない点は、隣に引き寄せられる。

この $\mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2}$ は、第 12 回の対応分析に現れる。隣接行列を分割表とみると、総数は $2m$、比率は $\mathbf{P} = \mathbf{A}/(2m)$、行の周辺も列の周辺も次数の割合 $\boldsymbol{r} = \boldsymbol{d}/(2m)$ である。$\mathbf{D}_r = \mathbf{D}/(2m)$ なので、標準化残差行列は

$$\mathbf{S} = \mathbf{D}_r^{-1/2}(\mathbf{P} - \boldsymbol{r}\boldsymbol{r}^\top)\mathbf{D}_r^{-1/2} = \mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2} - \sqrt{\boldsymbol{r}}\sqrt{\boldsymbol{r}}^\top \tag{13}$$

となる。$\mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2} = \mathbf{I} - \mathbf{L}_{\text{sym}}$ の固有ベクトルは $\mathbf{L}_{\text{sym}}$ と同じ $\boldsymbol{v}_m$ で、固有値は $1-\mu_m$ である。$\mu_1 = 0$ の向き $\boldsymbol{v}_1 = \sqrt{\boldsymbol{r}}$ は、第 12 回と同じく $-\sqrt{\boldsymbol{r}}\sqrt{\boldsymbol{r}}^\top$ が消す。$\mathbf{S}$ は対称なので、特異値は固有値の絶対値 $|1-\mu_m|$ で、行の点 $\mathbf{D}_r^{-1/2}\boldsymbol{k}$ は $\mathbf{D}^{-1/2}\boldsymbol{v}_m = \boldsymbol{y}_m$ に比例する。つまり、隣接行列の対応分析と正規化カットは、同じ向きの組から軸を選ぶ(定理 2)。(12) 式は、第 12 回の遷移公式(行の点は列の点の重み付き平均を $1/\delta$ 倍したもの)と同じ形である。

違うのは並べ方である。正規化カットは $1-\mu_m$ の大きい順(μ_m の小さい順)に選び、対応分析は絶対値 $|1-\mu_m|$ の大きい順に選ぶ。$1-\mu_m$ が負の向きは、群をまたいで線が多い形を表す。人工データでは、正規化カットの 1 本目($1-\mu_2 = +0.883$)は対応分析の軸 1($\delta_1 = 0.883$)と同じだが、対応分析の軸 2($\delta_2 = 0.606$)は $1-\mu_n$ = -0.606 の負の向きで、正規化カットの 2 本目($1-\mu_3 = +0.588$)は軸 3 になる。

定理 2 (隣接行列の対応分析と正規化カット)**.** 隣接行列 $\mathbf{A}$ を分割表とみた対応分析の標準化残差行列は $\mathbf{S} = \mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2} - \sqrt{\boldsymbol{r}}\sqrt{\boldsymbol{r}}^{\top}$ ($\boldsymbol{r} = \boldsymbol{d}/(2m)$)である。その特異値は $|1-\mu_m|$ (μ_m は $\mathbf{L}_{\mathrm{sym}}$ の 0 でない固有値)で、行の点は正規化カットを緩めた答え $\mathbf{D}^{-1/2}\boldsymbol{v}_m$ に比例する。

変数どうしのつながり

ここまでは、つながりの表 $\mathbf{A}$ が手元にあった。しかし多くのデータで手元にあるのは、個体 $\times$ 変数のデータ行列 $\mathbf{X}$ だけで、変数どうしのつながりの表はどこにも書かれていない。データ行列から、変数どうしのつながりの表を作れるだろうか。人工的なデータで考える。$n = 200$ 行、$p = 8$ 列のデータ行列で、列どうしの本当のつながりは 2 本の鎖($1 - 2 - 3 - 4$ と $5 - 6 - 7 - 8$)になるように作った(作り方は後で述べる)。

素朴には、列どうしの相関を計算し、絶対値の大きい組に線を引く(図 14)。相関の絶対値が 0.2 を超える組を結ぶと、線は 9 本になる。

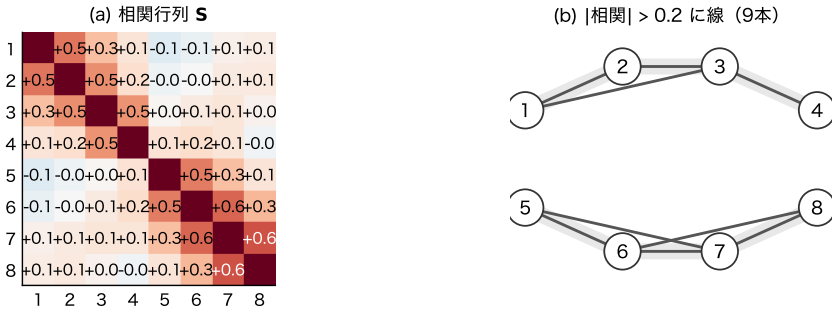


図 14: 人工データ(8 列)の (a) 相関行列と、(b) 相関の絶対値が 0.2 を超える組に引いた線。灰色の太線は本当のつながり(鎖 2 本)

困りごとが 3 つある。1 つ目は、間をはさんだ組である。1 と 3 は直接にはつながっていないが、どちらも 2 とつながっているので、相関は 0.30 になる。相関は、間に別の変数をはさんだだけの組まで拾う。2 つ目は、どこで切るかである。線を引く相関の大きさを 0.1、0.2、0.3、0.4 と変えると、線は 18、9、8、6 本と変わり、どこで切るかの根拠が無い。3 つ目は、行の数である。最初の 6 行だけで分散共分散行列 $\mathbf{S}$ を作ると、8×8 なのにランクは 5 しかなく、逆行列が無い。第 3 回で、列が行より多いと $\mathbf{X}^{\top}\mathbf{X}$ が逆行列を持たないことを見た。それと同じである。

以下では、ほかの列を固定したときの関係を行列で書き、それを罰則付きの最尤法で推定する。第 4 回の ℓ_1 罰則(Lasso)と第 11 回の最尤法を組み合わせた形であり、解き方は列ごとの Lasso に帰着する。

精度行列と条件付き独立

「ほかの列を固定したときの関係」を行列で書く。行 $\boldsymbol{x}$ が平均 0、分散共分散行列 $\boldsymbol{\Sigma}$ の p 変量正規分布に従うとし、その逆行列 $\boldsymbol{\Theta} = \boldsymbol{\Sigma}^{-1}$ を精度行列(precision matrix)と呼ぶ。

精度行列の列が何を表すかを見るために、1 つ道具を用意する(定義 7)。$\boldsymbol{\Sigma}$ と $\boldsymbol{\Theta}$ を、最後の列とそれ以外に分ける。$\boldsymbol{\Sigma}_{11}$ は残り $p-1$ 列どうしの部分、$\boldsymbol{\sigma}_{12}$ は残りと最後の列の共分散、σ_{22} は最後の列の分散で、$\boldsymbol{\Theta}$ も同じく $\boldsymbol{\Theta}_{11}$、$\boldsymbol{\theta}_{12}$、θ_{22} に分ける。$\boldsymbol{\Sigma}\boldsymbol{\Theta} = \mathbf{I}$ の最後の列を、上の $p-1$ 成分と最後の成分に分けて書くと

$$\boldsymbol{\Sigma}_{11}\boldsymbol{\theta}_{12} + \boldsymbol{\sigma}_{12}\theta_{22} = 0, \qquad \boldsymbol{\sigma}_{12}^\top\boldsymbol{\theta}_{12} + \sigma_{22}\theta_{22} = 1$$

である。1 つ目から $\boldsymbol{\theta}_{12} = -\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\sigma}_{12}\theta_{22}$、これを 2 つ目に代入して $(\sigma_{22} - \boldsymbol{\sigma}_{12}^\top\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\sigma}_{12})\theta_{22} = 1$ となり

$$\theta_{22} = \frac{1}{\sigma_{22} - \boldsymbol{\sigma}_{12}^\top\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\sigma}_{12}}, \qquad \boldsymbol{\theta}_{12} = -\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\sigma}_{12}\,\theta_{22} \tag{14}$$

を得る。

定義 7 (ブロックに分けた逆行列)**.** 対称で逆行列を持つ $\boldsymbol{\Sigma}$ を最後の列とそれ以外に分け、$\boldsymbol{\Theta} = \boldsymbol{\Sigma}^{-1}$ も同じく分ける。このとき $\theta_{22} = 1/(\sigma_{22} - \boldsymbol{\sigma}_{12}^\top\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\sigma}_{12})$、$\boldsymbol{\theta}_{12} = -\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\sigma}_{12}\theta_{22}$ である。

最後の列 x_p を、残りの列 $\boldsymbol{x}_{-p}$ で回帰することを考える。正規分布では、残りの列を固定したときの x_p の平均は $\boldsymbol{x}_{-p}$ の 1 次式で、係数は第 1 回の正規方程式の母集団版 $\boldsymbol{\beta} = \boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\sigma}_{12}$ である。その分散は、説明できなかった分 $\sigma_{22} - \boldsymbol{\sigma}_{12}^\top\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\sigma}_{12}$ である。(14) 式と見比べると

$$\boldsymbol{\beta} = -\frac{\boldsymbol{\theta}_{12}}{\theta_{22}}, \qquad \mathbb{V}\mathrm{ar}(x_p \mid \boldsymbol{x}_{-p}) = \frac{1}{\theta_{22}} \tag{15}$$

となる。精度行列の列は、その列を残りで回帰したときの係数と、説明しきれなかった分散を表している。どの列を最後に置いても同じなので、$\theta_{jk} = 0$ は「x_j を残りで回帰したとき x_k の係数が 0」と同じである。正規分布では、これは x_j と x_k が、ほかの列を固定すると独立であることを意味する(条件付き独立(conditional independence))。ほかの列を固定したときの相関、すなわち偏相関(partial correlation)は

$$\rho_{jk\cdot\mathrm{rest}} = -\frac{\theta_{jk}}{\sqrt{\theta_{jj}\theta_{kk}}} \tag{16}$$

で、$\theta_{jk} = 0$ なら 0 になる(定義 9)。

傘と長靴の売上で考えると分かりやすい(図 15)。雨の多い日にはどちらもよく売れるので、2 つの売上には相関がある。しかし雨の量を固定すると、関係はほとんど消える。線を引くべきは「雨 − 傘」と「雨 − 長靴」だけで、「傘 − 長靴」には引かない。困りごと④の 1 と 3 も同じで、2 をはさんでいるだけである。

そこで、精度行列の 0 でないところに線を引く。この組をガウシアングラフィカルモデル(Gaussian graphical model)と呼ぶ。つながりの表は、$\boldsymbol{\Theta}$ の 0 の並びである。人工データの本当の精度行列は、鎖の隣どうしだけが −0.45、対角が 1、ほかは 0 になるように作った。

精度行列を最尤法で推定する。平均 0 の p 変量正規分布から n 行が独立に得られたとき、$\mathbf{S} = \mathbf{X}^\top\mathbf{X}/n$ を使って、対数尤度は

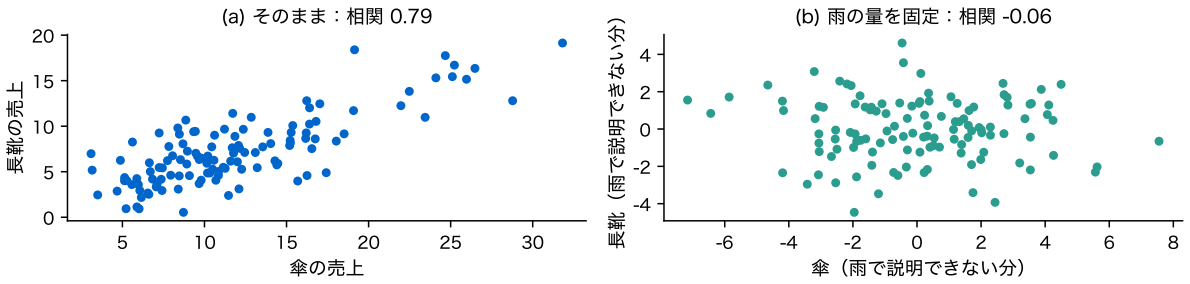


図 15: 傘と長靴の売上(概念図)。(a) そのまま、(b) 雨の量で説明できない分どうし

$$\ell(\boldsymbol{\Sigma}) = -\frac{n}{2}\Big(\log\det\boldsymbol{\Sigma} + \operatorname{tr}(\mathbf{S}\boldsymbol{\Sigma}^{-1})\Big) + \text{定数} \tag{17}$$

である。第 11 回の因子分析で使った式と同じである。$\boldsymbol{\Sigma}^{-1} = \boldsymbol{\Theta}$、$\log\det\boldsymbol{\Sigma} = -\log\det\boldsymbol{\Theta}$ を入れると

$$\ell(\boldsymbol{\Theta}) = \frac{n}{2}\Big(\log\det\boldsymbol{\Theta} - \operatorname{tr}(\mathbf{S}\boldsymbol{\Theta})\Big) + \text{定数} \tag{18}$$

となる。微分には、次の公式を使う(定義 8)。

定義 8 (行列の微分)**.** 対称行列 $\boldsymbol{\Theta}$ について $\partial\log\det\boldsymbol{\Theta}/\partial\boldsymbol{\Theta} = \boldsymbol{\Theta}^{-1}$、$\partial\operatorname{tr}(\mathbf{S}\boldsymbol{\Theta})/\partial\boldsymbol{\Theta} = \mathbf{S}$ である。1×1 なら $(\log\theta)' = 1/\theta$、$(s\theta)' = s$ にあたる。

第 11 回と同じく結果だけを使う。微分して 0 とおくと $\frac{n}{2}(\boldsymbol{\Theta}^{-1} - \mathbf{S}) = \mathbf{O}$、すなわち $\hat{\boldsymbol{\Theta}} = \mathbf{S}^{-1}$ である。しかし、$\mathbf{S}$ に逆行列が無ければ存在しない。あっても、データの揺れのため成分がちょうど 0 になることはない。どの成分を 0 とみなすかは、相関で線を引いたときと同じく決められない。

そこで、第 4 回の Lasso と同じく ℓ_1 罰則を足す。

$$\max_{\boldsymbol{\Theta}}\ \log\det\boldsymbol{\Theta} - \operatorname{tr}(\mathbf{S}\boldsymbol{\Theta}) - \lambda\|\boldsymbol{\Theta}\|_1, \qquad \|\boldsymbol{\Theta}\|_1 = \sum_{j,k}|\theta_{jk}| \tag{19}$$

これを Graphical Lasso と呼ぶ(Friedman ほか 2008)。λ が大きいほど、ちょうど 0 になる成分が増える。

定義 9 (精度行列とガウシアングラフィカルモデル)**.** p 変量正規分布の分散共分散行列の逆行列 $\boldsymbol{\Theta} = \boldsymbol{\Sigma}^{-1}$ を精度行列と呼ぶ。$\theta_{jk} = 0$ のとき、x_j と x_k はほかの変数を固定すると独立であり、偏相関 $-\theta_{jk}/\sqrt{\theta_{jj}\theta_{kk}}$ は 0 である。$\theta_{jk} \neq 0$ の組に線を引いたグラフを、ガウシアングラフィカルモデルと呼ぶ。

列ごとの Lasso で解く

(19) 式を解く。導出には、定義 8 (行列の微分)と定義 7 (ブロックに分けた逆行列)のほかに、第 4 回の軟しきい値を使う。

定義 10 (軟しきい値)**.** $a > 0$ のとき、$\frac{a}{2}b^2 - cb + \lambda|b|$ を最小にする b は $\mathrm{soft}(c,\lambda)/a$ である。$\mathrm{soft}(c,\lambda) = \mathrm{sign}(c)\max(|c| - \lambda, 0)$ を軟しきい値と呼ぶ。$|c| \le \lambda$ ならちょうど 0 になる。

まず、$\boldsymbol{\Theta}$ で微分して 0 とおく。$\mathbf{W} = \boldsymbol{\Theta}^{-1}$ と書くと、定義 8 より $\log\det\boldsymbol{\Theta}$ の微分は $\mathbf{W}$、トレースの微分は $\mathbf{S}$ である。$|\theta|$ は 0 で尖っているので、第 4 回と同じく、傾きを $\theta \neq 0$ なら $\mathrm{sign}(\theta)$、$\theta = 0$ なら -1 以上 1 以下のどれかとする。すると最適の条件は

$$\mathbf{W} - \mathbf{S} - \lambda\boldsymbol{\Gamma} = \mathbf{O} \tag{20}$$

となる。$\boldsymbol{\Gamma}$ はその傾きを並べた行列である。精度行列の対角は、(15) 式より説明しきれなかった分散の逆数で正なので、$\gamma_{jj} = 1$、すなわち $w_{jj} = s_{jj} + \lambda$ が初めから決まる。

次に、最後の列を取り出す。$\mathbf{W}\boldsymbol{\Theta} = \mathbf{I}$ の最後の列の上のブロックは $\mathbf{W}_{11}\boldsymbol{\theta}_{12} + \boldsymbol{w}_{12}\theta_{22} = 0$ である(定義 7 と同じ計算)。$\boldsymbol{\beta} = -\boldsymbol{\theta}_{12}/\theta_{22}$ とおくと

$$\boldsymbol{w}_{12} = \mathbf{W}_{11}\boldsymbol{\beta}$$

を得る。$\boldsymbol{\beta}$ は、(15) 式の回帰の係数にあたる。(20) 式の最後の列の上のブロック $\boldsymbol{w}_{12} - \boldsymbol{s}_{12} - \lambda\boldsymbol{\gamma}_{12} = 0$ にこれを入れる。$\theta_{22} > 0$ なので θ_{jk} と β_k の符号は逆で、$-\boldsymbol{\gamma}_{12}$ は $\boldsymbol{\beta}$ の傾きになる。したがって

$$\mathbf{W}_{11}\boldsymbol{\beta} - \boldsymbol{s}_{12} + \lambda\boldsymbol{\gamma} = 0, \qquad \gamma_k \in \partial|\beta_k| \tag{21}$$

となる。これは

$$\min_{\boldsymbol{\beta}} \ \frac{1}{2}\boldsymbol{\beta}^\top\mathbf{W}_{11}\boldsymbol{\beta} - \boldsymbol{s}_{12}^\top\boldsymbol{\beta} + \lambda\|\boldsymbol{\beta}\|_1 \tag{22}$$

の最適の条件そのものである。$\mathbf{W}_{11} = \mathbf{X}^\top\mathbf{X}/n$、$\boldsymbol{s}_{12} = \mathbf{X}^\top\boldsymbol{y}/n$ なら、$\frac{1}{2n}\|\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \lambda\|\boldsymbol{\beta}\|_1$ を展開して定数を除いたものに等しく、第 4 回の Lasso になる。

(22) 式は、第 4 回と同じく座標降下で解ける。ほかの成分を固定すると、β_k だけの問題は $\frac{a}{2}\beta_k^2 - c\beta_k + \lambda|\beta_k|$ の形になり、$a = [\mathbf{W}_{11}]_{kk}$、$c = s_{12,k} - \sum_{l\neq k}[\mathbf{W}_{11}]_{kl}\beta_l$ である。定義 10 より $\beta_k \leftarrow \mathrm{soft}(c,\lambda)/a$ と更新する。

最後に、列を回す。どの列も「最後の列」として扱えるので、列を 1 本ずつ取り出して (22) 式を解き、$\boldsymbol{w}_{12} \leftarrow \mathbf{W}_{11}\hat{\boldsymbol{\beta}}$ と書き換える。$\mathbf{W}$ が変わらなくなったら止め、定義 7 で $\hat{\theta}_{22} = 1/(w_{22} - \boldsymbol{w}_{12}^\top\hat{\boldsymbol{\beta}})$、$\hat{\boldsymbol{\theta}}_{12} = -\hat{\boldsymbol{\beta}}\hat{\theta}_{22}$ として $\boldsymbol{\Theta}$ に戻す。$\hat{\beta}_k = 0$ なら $\hat{\theta}_{jk} = 0$ で、線は引かれない(定義 11)。手順をまとめると次のとおりである(Friedman ほか 2008)。

1. 列を標準化して $\mathbf{S}$ を作り、$\mathbf{W} \leftarrow \mathbf{S} + \lambda\mathbf{I}$ とする(対角は $s_{jj} + \lambda$ のまま変わらない)
2. 列 $j = 1, \ldots, p$ を順に「最後の列」として、$\mathbf{W}_{11}$ と $\boldsymbol{s}_{12}$ を取り出す
3. (22) 式を座標降下で解く
4. $\boldsymbol{w}_{12} \leftarrow \mathbf{W}_{11}\hat{\boldsymbol{\beta}}$ と書き換える。$\mathbf{W}$ が変わらなくなるまで 2〜4 を繰り返す

5. $\hat{\boldsymbol{\Theta}}$ に戻し、0 でない組に線を引く

定義 11 (Graphical Lasso)**.** $\log\det\boldsymbol{\Theta} - \mathrm{tr}(\mathbf{S}\boldsymbol{\Theta}) - \lambda\|\boldsymbol{\Theta}\|_1$ を最大にする $\hat{\boldsymbol{\Theta}}$ を求め、$\hat{\theta}_{jk} \neq 0$ の組に線を引く方法を Graphical Lasso と呼ぶ。$\mathbf{W} = \hat{\boldsymbol{\Theta}}^{-1}$ の列ごとに、$\frac{1}{2}\boldsymbol{\beta}^\top \mathbf{W}_{11}\boldsymbol{\beta} - \boldsymbol{s}_{12}^\top\boldsymbol{\beta} + \lambda\|\boldsymbol{\beta}\|_1$ の Lasso を解く操作を繰り返して求める。

理論の帰結：罰則が決めるもの

罰則の強さ λ を動かすと、何が起きるかを見る。

第 1 に、λ を上げるほど偏相関は 0 へ縮み、ちょうど 0 になった組から線が消える（図 16）。人工データでは本当でない線が先に消え、さらに上げると本当の線も消えていく。$\lambda = 0$ では最尤推定 $\mathbf{S}^{-1}$ に戻り、どの組にも線が引かれる。

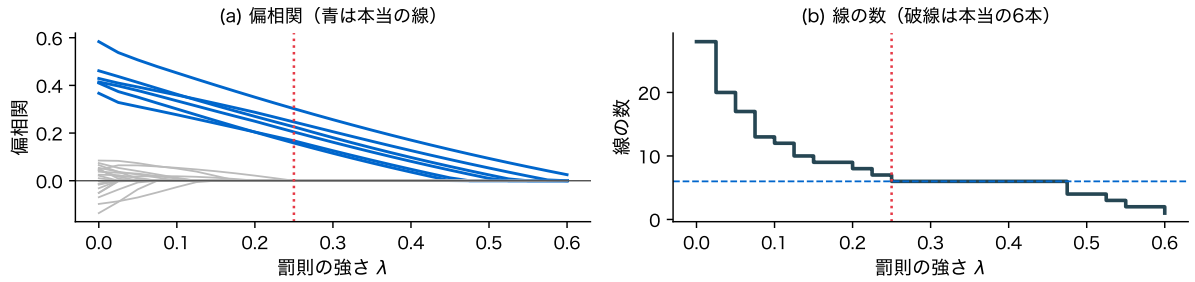


図 16: 人工データの Graphical Lasso で、罰則の強さ λ を動かしたときの (a) 偏相関と (b) 線の数。青は本当の線、赤い点線は BIC で選んだ λ

第 2 に、λ は第 9 回の BIC で選ぶ。λ ごとに線の並びが決まるので、それぞれの線の並びを 1 つのモデルとみる。モデルの比べ方は第 9 回と同じく、そのモデルの最尤推定で測った -2ℓ に、推定した数（線の数と対角の p 個）の $\log n$ 倍を足す。罰則で縮んだ推定値のままでは尤度が小さく出るので、選んだ線だけを持つモデルを罰則なしで推定し直した $\tilde{\boldsymbol{\Theta}}_\lambda$ で測る。これは、線の無い組の罰則を大きく、線のある組の罰則を 0 にして同じ手順を回せば求まる。

$$\mathrm{BIC}(\lambda) = -2\ell(\tilde{\boldsymbol{\Theta}}_\lambda) + \log n \times (\text{線の数} + p) \tag{23}$$

人工データでは、$\lambda = 0.25$ で最小になった（図 17）。このとき残った線は 6 本で、本当の鎖と一致した（図 18）。相関で引いた線にあった 1 と 3 の線は消えた。偏相関は、2 を固定したときの 1 と 3 の関係を測るからである。「どこで切るか」も、相関の大きさではなく BIC で決まった。

第 3 に、行が列より少なくても解ける。$\mathbf{W}$ は $\mathbf{S} + \lambda\mathbf{I}$ から始まり、$\lambda > 0$ なら固有値はどれも λ 以上になる。各列の Lasso の $\mathbf{W}_{11}$ は逆行列を持ち、答えの $\hat{\boldsymbol{\Theta}} = \mathbf{W}^{-1}$ も存在する。最初の 6 行（ランク 5）だけでも、$\lambda = 0.3$ で推定できた（図 19）。ただし 6 行では情報が足りず、本当の 6 本のほかに、本当でない線も 13 本残った。

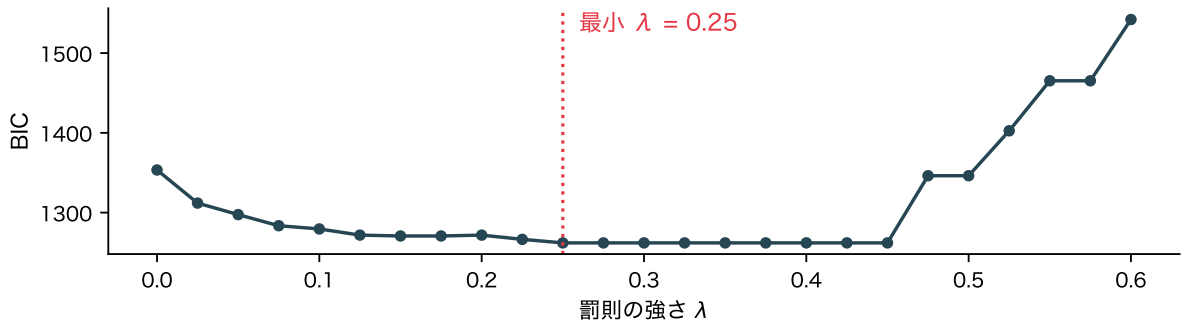


図 17: 人工データの BIC（選んだ線で推定し直した対数尤度で測った）。赤い点線が最小

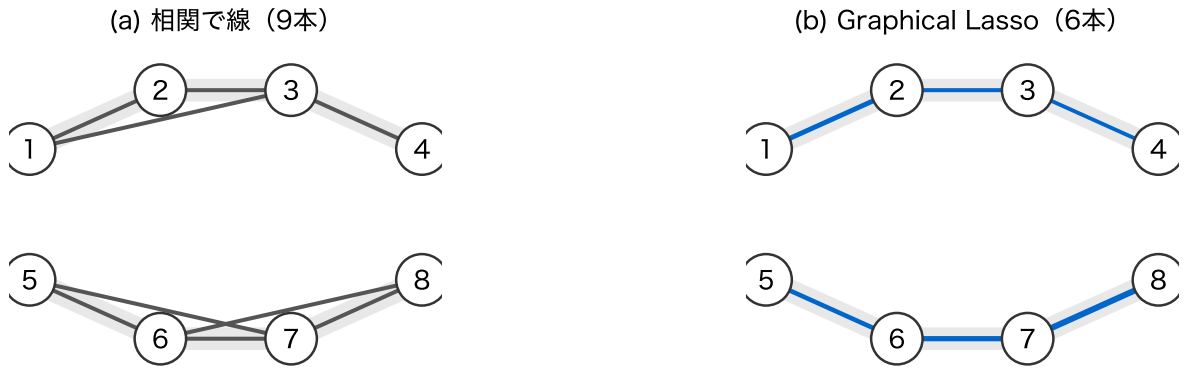


図 18: 人工データ（200 行）の (a) 相関で引いた線と (b) BIC で選んだ λ の Graphical Lasso の線。灰色の太線は本当のつながり、線の色は偏相関の符号（青が正）と大きさ

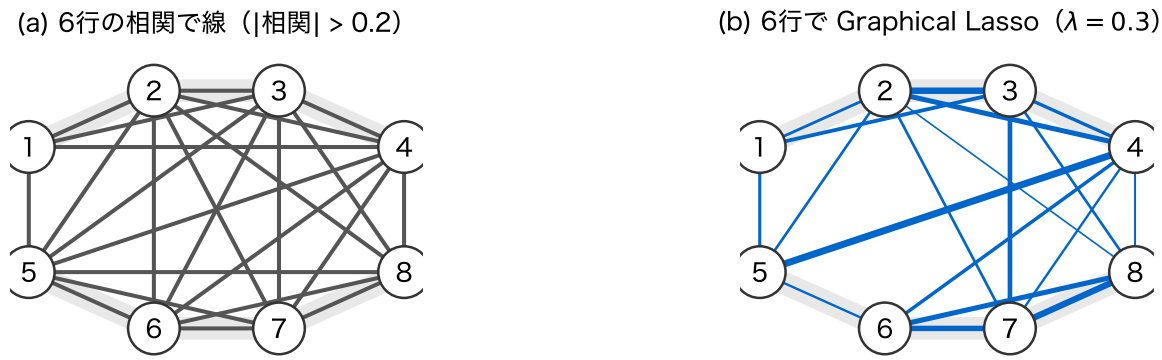


図 19: 人工データの最初の 6 行だけで、(a) 相関で引いた線と (b) Graphical Lasso（$\lambda = 0.3$）の線。灰色の太線は本当のつながり、線の色は偏相関の符号（青が正）

第 4 に、λ が大きいと、列は塊に分かれる（定理 3）。列が 2 つの塊 C_1、C_2 に分かれ、塊をまたぐ相関がどれも $|s_{jk}| \le \lambda$ だとする。それぞれの塊だけで (19) 式を解いた $\hat{\boldsymbol{\Theta}}_1$、$\hat{\boldsymbol{\Theta}}_2$ を対角に並べた行列を考える。その逆行列 $\mathbf{W}$ も同じく対角に並ぶので、またぐ組では $w_{jk} = 0$、$\theta_{jk} = 0$ である。(20) 式は $0 - s_{jk} - \lambda\gamma_{jk} = 0$ となり、$\gamma_{jk} = -s_{jk}/\lambda$ は -1 以上 1 以下なので選べる。塊の中の条件は、塊ごとに解いたので満たされている。(19) 式の目的関数は上に凸で答えは 1 つなので、これが答えである。

定理 3 (塊に分かれる条件)**.** 列が C_1 と C_2 に分かれ、$j \in C_1$、$k \in C_2$ のすべてで $|s_{jk}| \le \lambda$ なら、*Graphical Lasso* の答えは $\hat{\theta}_{jk} = 0$（塊の間に線が無い）である。

最後に、Graphical Lasso で作った表 $\hat{\mathbf{A}}$（$\hat{\theta}_{jk} \neq 0$ なら 1）は隣接行列なので、前半の道具がそのまま使える。人工データで BIC が選んだ表のラプラシアンは、固有値 0 をちょうど 2 個持つ（図 20）。定理 1 により、つながった塊は 2 つで、本当の鎖の数と一致する。定理 3 は相関から塊を前もって知る方法、定理 1 は作った表から塊を数える方法である。第 II 部では、作った表を固有ベクトルで切る。

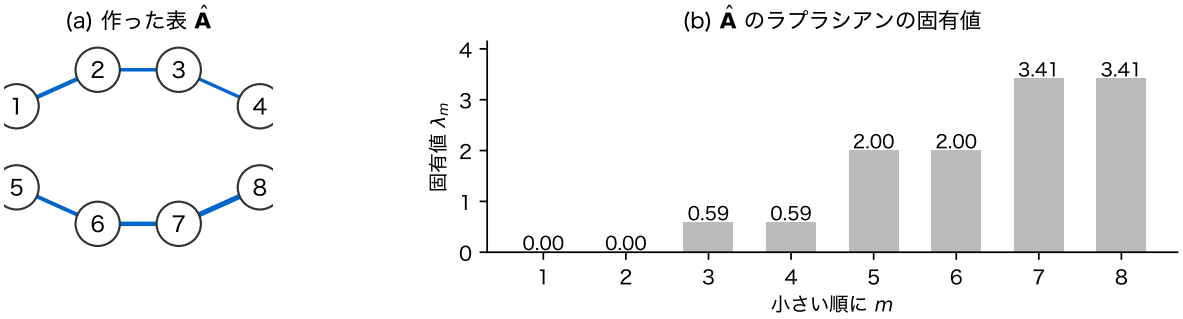


図 20: 人工データで BIC が選んだ Graphical Lasso の表。(a) 線、(b) そのラプラシアンの固有値（小さい順に 8 個）

なお、$\mathbf{W}_{11}$ を書き換えず $\mathbf{S}_{11}$ のまま、列ごとに (22) 式を 1 回ずつ解き、β_{jk} と β_{kj} のどちらかが 0 でなければ線を引く近道もある（近傍選択、Meinshausen & Bühlmann 2006）。各列を残りの列で Lasso 回帰するのと同じで、第 4 回の手順をそのまま p 回使う。ただし近道は、精度行列そのものは出さない。

第 II 部　実データ解析

株価と手続き

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、塊や鎖がはっきり出るように作った。実データは理論どおりにいくとは限らない。外れたときは、その理由を第 I 部の道具で考える。

使うデータは、米国の大企業の株価（S&P 500）である。R の huge パッケージ（Zhao ほか 2012）に収められた、452 銘柄の 2003〜2007 年の終値と業種の分類を使った。日々の値動きを、終値の対数の差（対数収益率）で測る。株式分割などで 1 日に $\pm 30\%$ を超えて値が飛ぶ銘柄を除き、エネルギー・公益（電力とガス）・金融・IT・ヘルスケアの 5 業種から、銘柄記号のアルファベット順に 8 銘柄ずつ、計 40 銘柄を選んだ。期間は 2007 年の 251 営業日である。業種の分類は計算には使わず、答え合わせだけに使う。

第 I 部からは、次の 4 つを予想した。第 1 に、相関で線を引くと、ほとんどすべての組がつながる。株価は市場全体の上げ下げにつられて一緒に動くからである。傘と長靴の売上が雨につられて一緒に動くのと同じで、市場全体が共通の原因にあたる。第 2 に、市場の動きを引いてから Graphical Lasso をかけ、BIC で λ を選ぶと、同じ業種どうしの線が残る。同じ業種の会社は、同じ材料（原油の値段、金利、規制）に反応するからである。第 3 に、作った表は業種ごとの塊になり、そのラプラシアンの固有値 0 は業種の数の 5 個になる（定理 1）。第 4 に、正規化カットのスペクトルクラスタリングで切ると、群は業種に分かれる。

手続きは次のとおりである。市場の動きとして、除いた後に残った 275 銘柄の平均の収益率を使った。各銘柄の収益率を市場の動きで回帰し（第 1 回）、その残りを標準化して相関行列 $\mathbf{S}$（40×40）を作った。これに Graphical Lasso をかけ、λ を 0.1 から 0.45 まで 0.025 刻みで動かし、(23) 式の BIC が最小のものを選んだ。選んだ $\hat{\boldsymbol{\Theta}}$ の 0 でない組を 1 とした表 $\hat{\mathbf{A}}$ を隣接行列とみて、そのラプラシアンの固有値を求めた。さらに、最大の塊の $\mathbf{L}_{\text{sym}}$ の固有ベクトルの行を k-means で分けた（正規化カット）。群の数 k は、小さい固有値の後の跳びで決めた。

結果：作った表と群

結果は次のとおりである。まず、市場の動きを引く前の相関は、780 組のどれも正で、最小 0.05、平均 0.38 だった（図 21）。相関で線を引けば、ほとんどすべての組がつながる。予想どおりである。

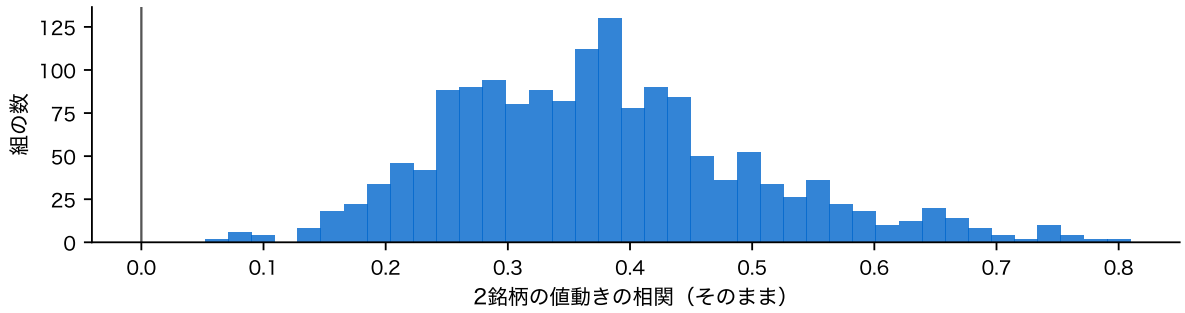


図 21: S&P 500 の 40 銘柄（2007 年）の、2 銘柄ずつの値動きの相関（市場の動きを引く前）

市場の動きを引いた残りに Graphical Lasso をかけると、BIC は $\lambda = 0.2$ で最小になった。残った線は 780 組のうち 74 本で、その 82% が同じ業種どうしである（図 22）。でたらめに線を引けば同じ業種どうしは 18% なので、予想どおり業種の線が残った。

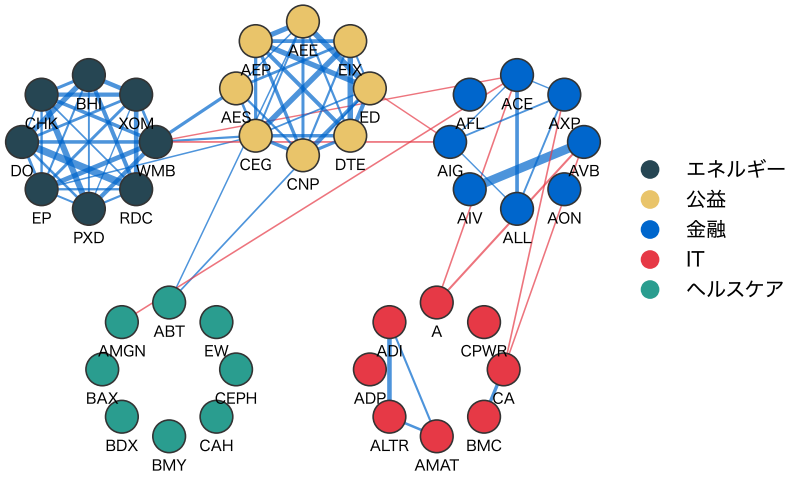


図 22: S&P 500 の 40 銘柄(2007 年、市場の動きを引いた残り)に、BIC で選んだ λ の Graphical Lasso をかけた線。色は業種、線の太さは偏相関の大きさ(青が正、赤が負)

ところが、作った表 $\hat{\mathbf{A}}$ のラプラシアンの固有値 0 は、業種の数の 5 個ではなく 12 個だった(図 23 (a))。定理 1 のとおり、これはつながった塊の数である。内訳は、27 銘柄の最大の塊、半導体の ADI・ALTR・AMAT の小さな塊、そして線が 1 本も無い 10 銘柄である。線の無い銘柄は、それ 1 つで 1 つの塊と数えられる。そのうち 6 銘柄がヘルスケアだった。ヘルスケアの業種には製薬・医療機器・医薬品の卸が混ざり、市場の動きを引いた残りは、同じ材料に反応しない。業種ごとの塊になるという予想は外れた。

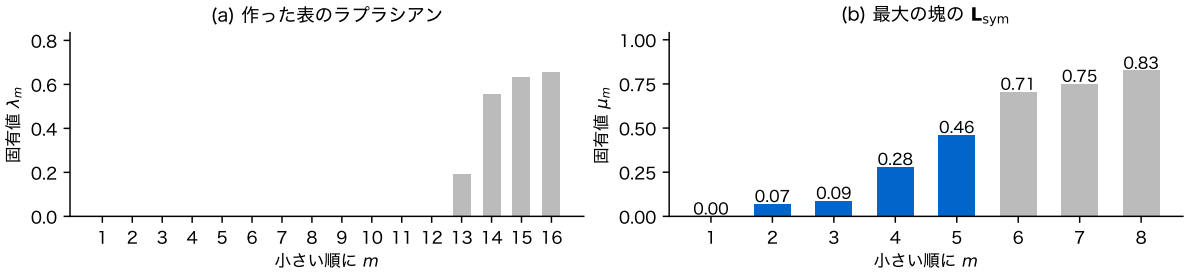


図 23: S&P 500 の作った表の固有値。(a) 表全体のラプラシアンの固有値(小さい順に 16 個、青が 0)、(b) 最大の塊の L_sym の固有値(小さい順に 8 個、青が跳びの手前まで)

最大の塊の $\mathbf{L}_{\mathrm{sym}}$ の固有値は、小さい方から 5 個の後、0.46 から 0.71 へ跳んだ(図 23 (b))。そこで $k = 5$ として、正規化カットのスペクトルクラスタリングで切った(図 24)。群と業種を突き合わせると、次のとおりである。

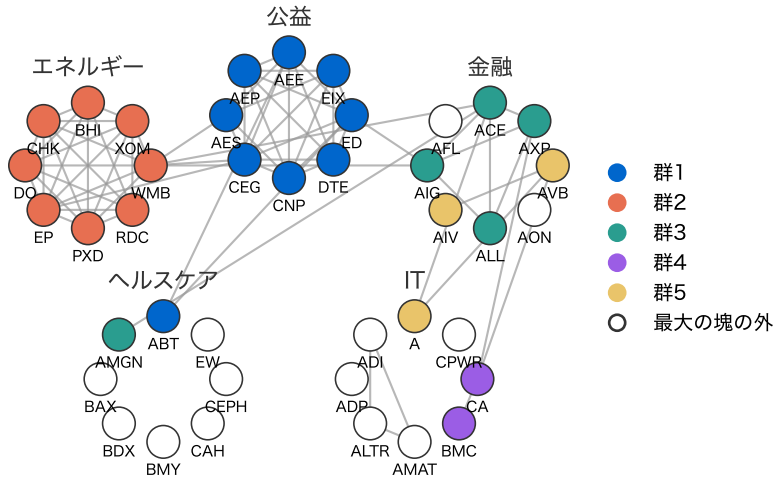


図 24: S&P 500 の作った表の最大の塊を、正規化カットのスペクトルクラスタリングで分けた群。点の位置は業種ごと（図の文字）、色は群、白は最大の塊の外の銘柄

表 2: 最大の塊の群（列）と業種（行）の銘柄の数

業種 ＼ 群	群 1	群 2	群 3	群 4	群 5
公益	8	0	0	0	0
エネルギー	0	8	0	0	0
金融	0	0	4	0	2
IT	0	0	0	2	1
ヘルスケア	1	0	1	0	0

公益とエネルギーは、ほぼそのまま 1 つずつの群になった（表 2）。予想どおりである。一方、金融は 2 つの群に分かれた。保険の ACE・AIG・ALL とカードの AXP の群と、集合住宅の不動産投資信託である AIV・AVB の群である。IT では、企業向けソフトウェアの BMC と CA が 2 社で 1 つの群になった。業種の分類は粗く、同じ「金融」の名前でも、反応する材料（保険金の支払い、家賃と金利）が違えば、市場の動きを引いた残りは一緒に動かない。

また、群には、ほかの業種の銘柄が 1 つずつ入った。この外れにも、第 I 部の理由がある。ヘルスケアの ABT は公益の AEE・ED とだけ、AMGN は金融の ACE とだけ、IT の A は金融の ACE・AVB とだけつながり、どの線も偏相関の大きさは 0.03 以下である。BIC の選んだ線には、このような細い線も含まれる。0/1 の表では細い線も 1 本と数えるので、次数の小さい銘柄は、(12) 式のとおり隣の値の平均に引き寄せられ、隣の群に入る。

エネルギーと公益は別の群に分かれたが、同じ塊には入っていた。2 つをつなぐいちばん太い線は、天然ガスのパイプラインを持つ WMB と、発電の AES の間（+0.09）である。ガスは発電の燃料なので、業種をまたぐこの線には商売の上の理由がある。塊は 1 つでも、正規化カットは間の線が少ないところで切った。

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは 4 つを予想した。相関で線を引くとほぼすべてがつながること、市場の動きを引いて Graphical Lasso をかけると同じ業種どうしの線が残ること、作った表が業種ごとの塊になること、正規化カットで切ると群が業種に分かれることである。1 つ目と 2 つ目は予想どおりだった。3 つ目は外れ、固有値 0 の数（つながった塊の数）は 12 個だった。ヘルスケアの多くは、ほかのどの銘柄とも線を持たなかった。4 つ目は半分が予想どおりで、公益とエネルギーはほぼそのまま 1 つずつの群になった。金融は保険と不動産投資信託に分かれ、企業向けソフトウェアの 2 社が 1 つの群になった。業種の一覧より細かいまとまりである。ほかの業種から群に入った銘柄は、偏相関がほぼ 0 の細い線 1〜2 本で隣の業種とつながり、0/1 の表で隣の平均に引き寄せられたものだった。データ行列から表を作り、それを固有ベクトルで切ると、業種の一覧と、市場の動きを引いた値動きのまとまりとの違いが見えた。

締め

まとめと全 14 回の地図

本章の問いは、つながりの表から、何を読み、どう描くかであった。はじめに、ネットワーク分析の基本の言葉をそろえた。ノードとエッジ、次数、次数のとびぬけて大きいハブ、次数の分布がべき分布になるスケールフリー、平均の距離が短いスモールワールドである。次に、まとまりを「群をまたぐ線が少ないこと」と考えた。線でつながった点どうしの値の違いの二乗和は、グラフラプラシアン $\mathbf{L} = \mathbf{D} - \mathbf{A}$ の 2 次形式で書け、群の大きさで割ったレシオカットもこの形で表せる。0/1 を実数に緩めると、小さい方の固有ベクトルが答えになり、その行を第 7 回の k-means で分ける（スペクトルクラスタリング）。固有値 0 の数はつながった塊の数で、次数の和で割る正規化カットは、第 12 回の対応分析と同じ向きの組を使う。

表が無く、データ行列しか無いときは、ほかの列を固定したときの関係で線を引いた。p 変量正規分布では、精度行列 $\boldsymbol{\Theta} = \boldsymbol{\Sigma}^{-1}$ の 0 が条件付き独立を表す。精度行列の最尤推定 $\mathbf{S}^{-1}$ には 0 がちょうど出ないので、第 4 回の ℓ_1 罰則を足した（Graphical Lasso）。最適の条件を列ごとに書くと、第 4 回の Lasso と同じ形になる。λ は第 9 回と同じく BIC で選んだ。S&P 500 の 40 銘柄では、市場の動きを引いた残りから作った表の線の大半が同じ業種どうしで、それを固有ベクトルで切ると、公益とエネルギーがほぼそのまま群になり、金融は保険と不動産投資信託に分かれた。

最後に、全 14 回を「モデル × 推定法」の地図に置き直す（表 3）。第 1〜4 回は線形回帰を最小二乗法で推定し、その数字の測り方（第 2 回）、係数の揺れ（第 3 回）、罰則（第 4 回）を見た。第 5・6 回は分類を最小二乗法と最尤法の両方で解いた。第 7〜9 回はラベルの無い群分けを、k-means（最小二乗法）、混合正規分布（最尤法）、群の数の選び方の順に扱った。第 10・11 回は $\mathbf{X}$ を $\mathbf{F}\mathbf{A}^{\top}$ で近似する主成分分析と、それを確率のモデルにした因子分析を扱った。第 12・13 回は分割表のずれを、重み付き最小二乗法と最尤法の両方から見た。第 14 回はネットワークで、つながりの表があれば固有ベクトルでまとまりを描き、表が無ければ罰則付きの最尤法で表を作った。

表 3: 全 14 回の「モデル × 推定法」の地図(数字は扱う回)

モデル	最小二乗法で推定	最尤法で推定
線形回帰	第 1〜3 回(罰則付き 第 4 回)	第 6 回
LDA ／ ロジスティック回帰	第 5 回 ／ —	第 6 回
k-means ／ 混合正規分布	第 7 回 ／ —	— ／第 8 回(群の数は第 9 回)
主成分分析 ／ 因子分析	第 10 回 ／ —	第 11 回
対応分析・多重対応分析	第 12・13 回(重み付き)	—
独立のモデル	第 12 回(χ^2)	第 13 回(G^2、残差)
グラフのまとまり	第 14 回(カットを緩めて固有ベクトル)	—
ガウシアングラフィカルモデル	—	第 14 回(ℓ_1 罰則付き)

どの回も、データとモデルのずれを測って小さくすることをしてきた。最小二乗法では、$\|\boldsymbol{y}-\mathbf{X}\boldsymbol{\beta}\|_2^2$、$\|\mathbf{X}-\mathbf{G}\mathbf{C}\|_F^2$、$\|\mathbf{X}-\mathbf{F}\mathbf{A}^\top\|_F^2$、重み付きの $\|\mathbf{S}-\mathbf{Y}\|_F^2$、隣どうしの違いの $\boldsymbol{x}^\top\mathbf{L}\boldsymbol{x}$ がずれの測り方であった。最尤法では -2ℓ が同じ役を果たした。第 4 回と本章では、ずれに罰則を足し、ずれが少し大きくなるのと引きかえに、0 の多い簡単な答えを得た。そして数字の読み方では、何で割った数字か(第 13 回)と並んで、何を固定した数字かを確かめることが大切である。相関と偏相関は、同じ 2 つの変数について、まったく違うことを言う。データとモデルのずれを測り、その数字が何を前提にしているかを確かめること。それが、この 14 回を通じて繰り返してきたことである。

発展

発展：時間とともに変わるつながり

発展として、つながりが時間とともに変わる場合を考える。第 II 部と同じ 40 銘柄・同じ $\lambda = 0.2$ で、2003 年から 2007 年まで 1 年ずつ(約 250 営業日ずつ) Graphical Lasso をかけた(図 25)。業種ごとの線の数は年によって変わり、前の年の線が次の年にも残る割合は 60〜82% だった。会社どうしの関係が本当に変わったのか、約 250 日のデータの揺れなのかは、別々に推定しただけでは区別できない。

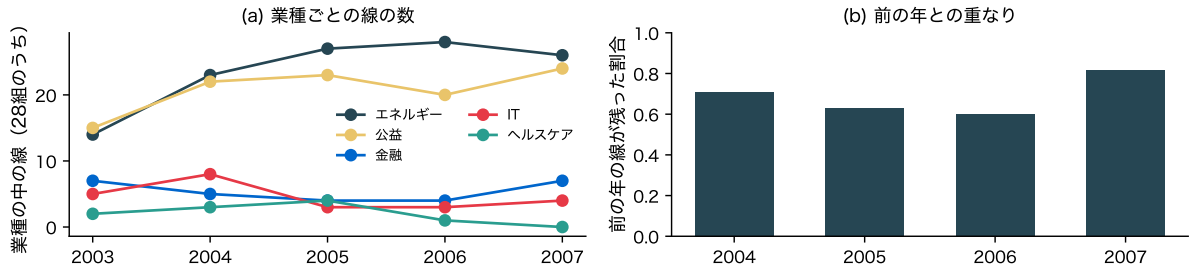


図 25: S&P 500 の 40 銘柄を 1 年ずつ Graphical Lasso で推定した結果(λ は本編で選んだ値)。(a) 業種ごとの業種の中の線の数、(b) 前の年の線が次の年にも残った割合

隣の年どうしは、たいてい似ているはずである。そこで、時点 $t = 1, \ldots, T$ の精度行列 $\boldsymbol{\Theta}_t$ を一緒に推定し、隣ど

うしの差にも ℓ_1 罰則を足す。

$$\max_{\boldsymbol{\Theta}_1,\ldots,\boldsymbol{\Theta}_T} \sum_{t=1}^{T}\Big(\log\det\boldsymbol{\Theta}_t - \mathrm{tr}(\mathbf{S}_t\boldsymbol{\Theta}_t)\Big) - \lambda\sum_t\|\boldsymbol{\Theta}_t\|_1 - \lambda_2\sum_{t\geq 2}\|\boldsymbol{\Theta}_t - \boldsymbol{\Theta}_{t-1}\|_1$$

ℓ_1 罰則は成分をちょうど 0 にするので、2 つ目の罰則は、隣の時点との差をちょうど 0 にする。変わらない所は同じ値のままで、変わった所だけが変わる。これを Time-Varying Graphical Lasso と呼ぶ(Hallac ほか 2017)。時間の順が無い群、たとえば病気の人と健康な人や、国ごとのデータでも、すべての組の差や、成分ごとの群をまたぐ大きさ $\sqrt{\sum_t \theta_{t,jk}^2}$ に罰則を足して、群どうしを似せながら一緒に推定できる(Joint Graphical Lasso、Danaher ほか 2014)。後者は、群のどれかで線があれば全部の群で線を残しやすくする。どちらも、何を簡単にしたいかを罰則の形で書き、それを目的関数に足したものである。

この考え方は、金融(年や景気の局面ごとの銘柄のつながり)、脳科学(課題の前後や患者と健常者での脳の領域どうしのつながり)、遺伝子(がんの種類ごとの発現のつながり)、マーケティング(店や季節ごとの商品の売上のつながり)で使われている。

参考文献

- Danaher, P., Wang, P. & Witten, D. M. (2014). The joint graphical lasso for inverse covariance estimation across multiple classes. Journal of the Royal Statistical Society Series B 76: 373–397.
- Friedman, J., Hastie, T. & Tibshirani, R. (2008). Sparse inverse covariance estimation with the graphical lasso. Biostatistics 9: 432–441.
- Hallac, D., Park, Y., Boyd, S. & Leskovec, J. (2017). Network inference via the time-varying graphical lasso. KDD 2017: 205–213.
- Meinshausen, N. & Bühlmann, P. (2006). High-dimensional graphs and variable selection with the Lasso. Annals of Statistics 34: 1436–1462.
- Zhao, T., Liu, H., Roeder, K., Lafferty, J. & Wasserman, L. (2012). The huge package for high-dimensional undirected graph estimation in R. Journal of Machine Learning Research 13: 1059–1062.