第 14 回 ネットワーク分析①

つながりの表から、まとまりを固有ベクトルで見つけて描く

本章の問いは、第 13 回の締めで残った「行も列も同じものの、つながりの表から、何を読み、どう描くか」である。点と点のつながりを 0/1 で並べた隣接行列 $\mathbf{A}$ から、まとまり（群）を見つけて描く。群をまたぐ線の数（カット）を目的関数にすると、1 点だけを切り離す答えになりやすい。そこで群の大きさで割ったレシオカットを使う。群を表す値を 0/1 から実数に緩めると、目的関数はグラフラプラシアン $\mathbf{L} = \mathbf{D} - \mathbf{A}$ の 2 次形式になり、第 10 回と同じ固有値の重みの議論で、小さい方の固有ベクトルが答えになる。その行を第 7 回の k-means で分ければ群が得られる（スペクトルクラスタリング）。固有値 0 の数はつながった塊の数に等しい。次数で割る正規化カットの答えは、隣接行列を分割表とみた第 12 回の対応分析と同じ向きの組から選ばれる。

第 I 部　理論

つながりの表

第 13 回の締めで、行も列も同じものの表を考えた。駅 × 駅の乗り換えの人数や、店 × 店の同じ日に寄った客の数である。本章の問いは、このようなつながりの表から、何を読み、どう描くかである。ここでは、点（ノード（node））と点を結ぶ線（エッジ（edge））の集まりをグラフ（graph）と呼ぶ。人工的なグラフで考える（図 1）。13 個の点があり、1〜4、5〜8、9〜12 はそれぞれ全員どうしが線で結ばれている。塊の間には 2〜3 本の線があり、13 は 1 本の線で 1 とだけつながっている。

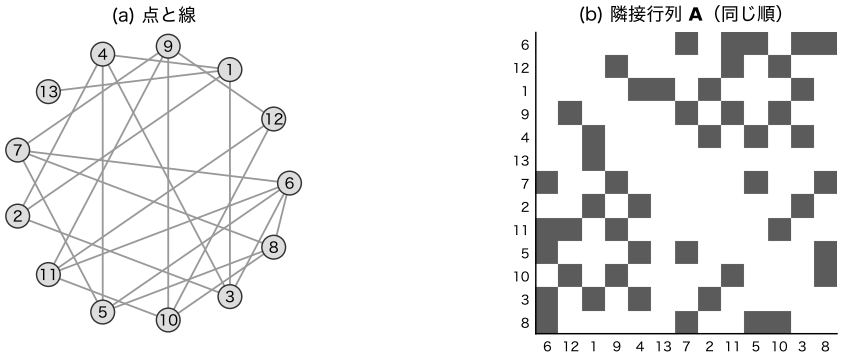


図 1: 人工のグラフ(13 点、24 本)。(a) 点を番号の分からない順に円の上に置いた図、(b) 同じ順に並べた隣接行列(黒が 1)

n 個の点のつながりを、i と j に線があれば $a_{ij} = 1$、無ければ $a_{ij} = 0$ とした $n \times n$ の行列 $\mathbf{A}$ で表す。これを隣接行列(adjacency matrix)と呼ぶ(定義 1)。行も列も同じ点なので、$\mathbf{A}$ は対称で、対角は 0 である。線に強さ(乗り換えの人数など)があるときは、a_{ij} にその値を入れてよい。以下の話はそのまま成り立つ。

困りごとが 3 つある。1 つ目は、並べ方である。図 1 では、点を番号の分からない順に並べた。点と線を描いても、隣接行列を眺めても、まとまりがあるのかどうか分からない。並べ方を変えれば見えるはずだが、13! 通りの並べ方を試すわけにはいかない。2 つ目は、点ごとの線の数である。13 を除くどの点も 3〜5 本の線を持ち、線の数からは、どの点とどの点が同じまとまりかは分からない。3 つ目は、切り方である。点を 2 つに分け、分け目をまたぐ線の数を最も少なくすると、13 だけが 1 本で切り離される。まとまりを見つけたいのに、1 点を切り離す答えになる。

本章では、これらに次の順で答える。まず、隣どうしで値が違うほど大きくなる量を行列で書き、分け目をまたぐ線の数をその量で表す。1 点だけを切り離さないよう、群の大きさで割る。次に、群を表す値を 0/1 から実数に緩めて、固有ベクトルで解く。k 個に分けるには、その行を第 7 回の k-means で分ける。最後に、次数で割る版が、第 12 回の対応分析と同じ向きを使うことを示す。

表 1: 本章の位置づけ

モデル	手元の行列	解き方	回
k-means	データ行列 $\mathbf{X}$	交互に解く	第 7 回
主成分分析	データ行列 $\mathbf{X}$	特異値分解	第 10 回
対応分析	分割表 $\mathbf{O}$	特異値分解	第 12 回
スペクトルクラスタリング	隣接行列 $\mathbf{A}$	固有値分解 ＋ k-means	本章

定義 1 (グラフと隣接行列)**.** n 個の点と、点どうしを結ぶ線の集まりをグラフと呼ぶ。i と j に線があれば $a_{ij} = 1$、無ければ $a_{ij} = 0$ とした $n \times n$ の対称行列 $\mathbf{A}$ を隣接行列と呼ぶ。対角は 0 とする。

道具：次数と固有値

本章で使う道具を先にそろえる。

1 つ目は次数である。点 i から出ている線の数 $d_i = \sum_j a_{ij}$ を次数(degree)と呼ぶ。並べると $\boldsymbol{d} = \mathbf{A}\mathbf{1}_n$ で、対角に並べた行列を $\mathbf{D} = \mathrm{diag}(\boldsymbol{d})$ と書く。線の本数を m とすると、1 本の線は両端の点で 1 回ずつ数えられるので、$\mathbf{1}_n^\top \boldsymbol{d} = 2m$ となる。

2 つ目は、対称行列の固有値分解である。第 11 回で見たとおり、$n \times n$ の対称行列 $\mathbf{M}$ は、互いに直交する長さ 1 の固有ベクトル $\boldsymbol{u}_1, \ldots, \boldsymbol{u}_n$ と実数の固有値で $\mathbf{M} = \mathbf{U}\boldsymbol{\Lambda}\mathbf{U}^\top$（$\mathbf{U}^\top\mathbf{U} = \mathbf{I}$）と分解できる。主成分分析では大きい固有値に関心があったが、本章では小さい固有値を使うので、$\lambda_1 \le \lambda_2 \le \cdots \le \lambda_n$ と小さい順に並べる。

3 つ目は、2 次形式の最小である。$\boldsymbol{c} = \mathbf{U}^\top \boldsymbol{x}$ とおくと $\boldsymbol{x} = \mathbf{U}\boldsymbol{c}$、$\|\boldsymbol{c}\|_2 = \|\boldsymbol{x}\|_2$ であり

$$\boldsymbol{x}^\top \mathbf{M} \boldsymbol{x} = \boldsymbol{c}^\top \boldsymbol{\Lambda} \boldsymbol{c} = \sum_{m=1}^{n} \lambda_m c_m^2 \tag{1}$$

となる。$\|\boldsymbol{x}\|_2 = 1$ なら $\sum_m c_m^2 = 1$ なので、これは固有値の重み付き平均で、λ_1 より小さくならない。$\boldsymbol{x} = \boldsymbol{u}_1$ なら $c_1 = 1$ でほかは 0 になり、最小値 λ_1 に届く。さらに $\boldsymbol{x} \perp \boldsymbol{u}_1$ を課すと $c_1 = 0$ なので、重みは λ_2 以降にしか置けず、最小値は λ_2（$\boldsymbol{x} = \boldsymbol{u}_2$）になる（定義 2）。

4 つ目は、k 本の和の最小である。$n \times k$ の行列 $\mathbf{H}$ が $\mathbf{H}^\top\mathbf{H} = \mathbf{I}_k$ を満たすとする。$\mathbf{B} = \mathbf{U}^\top\mathbf{H}$ とおくと

$$\mathrm{tr}(\mathbf{H}^\top \mathbf{M} \mathbf{H}) = \mathrm{tr}(\mathbf{B}^\top \boldsymbol{\Lambda} \mathbf{B}) = \sum_{m=1}^{n} \lambda_m w_m, \qquad w_m = \|\boldsymbol{u}_m^\top \mathbf{H}\|_2^2 \tag{2}$$

となる。$\mathbf{B}^\top\mathbf{B} = \mathbf{H}^\top\mathbf{H} = \mathbf{I}_k$ なので、重みの合計は $\sum_m w_m = \mathrm{tr}(\mathbf{B}\mathbf{B}^\top) = \mathrm{tr}(\mathbf{B}^\top\mathbf{B}) = k$ である。また $\mathbf{B}\mathbf{B}^\top$ は第 3 回の射影行列と同じく対称で冪等なので、その対角 w_m は 0 以上 1 以下である。1 本あたり 1 以下、合計 k の重みを固有値に配るとき、和を最も小さくするには、小さい方の k 本に 1 ずつ配ればよい。したがって最小値は $\lambda_1 + \cdots + \lambda_k$ で、$\mathbf{H} = \mathbf{U}_k = [\boldsymbol{u}_1 \ \cdots \ \boldsymbol{u}_k]$ で届く（定義 3）。第 10 回の Eckart–Young の定理の証明では、同じ重みを大きい方の Q 本に配った。

定義 2 (2 次形式の最小)**.** 対称行列 $\mathbf{M}$ の固有値を小さい順に $\lambda_1 \le \lambda_2 \le \cdots$、固有ベクトルを $\boldsymbol{u}_1, \boldsymbol{u}_2, \ldots$ とする。$\|\boldsymbol{x}\|_2 = 1$ のもとで $\boldsymbol{x}^\top\mathbf{M}\boldsymbol{x}$ の最小は λ_1（$\boldsymbol{x} = \boldsymbol{u}_1$）であり、さらに $\boldsymbol{x} \perp \boldsymbol{u}_1$ を課すと最小は λ_2（$\boldsymbol{x} = \boldsymbol{u}_2$）である。

定義 3 (k 本の和の最小)**.** $\mathbf{H}^\top\mathbf{H} = \mathbf{I}_k$ のもとで $\mathrm{tr}(\mathbf{H}^\top\mathbf{M}\mathbf{H})$ の最小は $\lambda_1 + \cdots + \lambda_k$ であり、$\mathbf{H} = [\boldsymbol{u}_1 \ \cdots \ \boldsymbol{u}_k]$ で届く。

まとまりを線の数で測る

点をまとまり(群)に分けることを考える。第 7 回と同じく、点 i が群 q に入るとき $g_{iq}=1$、そうでなければ 0 とした $n\times k$ の所属行列 $\mathbf{G}$ で分け方を表す。第 7 回と違うのは、点の座標を並べたデータ行列 $\mathbf{X}$ が無く、隣接行列 $\mathbf{A}$ しか無いことである。そこで「まとまり」を、群の中に線が多く、群をまたぐ線が少ないことと考える。2 つに分けるときは、群 S とその残り $\bar{S}$ をまたぐ線の数

$$\mathrm{cut}(S,\bar{S})=\sum_{i\in S}\sum_{j\in\bar{S}}a_{ij} \tag{3}$$

をカット(cut)と呼ぶ。

カットを行列で書く。2 群のとき、$i\in S$ なら $x_i=+1$、$i\in\bar{S}$ なら $x_i=-1$ とおく。線の両端が同じ群なら $(x_i-x_j)^2=0$、違う群なら 4 である。i,j を両方の順で足すと 1 本の線を 2 回数えるので

$$\frac{1}{2}\sum_{i=1}^{n}\sum_{j=1}^{n}a_{ij}(x_i-x_j)^2=4\,\mathrm{cut}(S,\bar{S})$$

となる。左辺を展開すると、$\sum_j a_{ij}=d_i$ と $\mathbf{A}$ の対称性から

$$\frac{1}{2}\sum_{i,j}a_{ij}(x_i-x_j)^2=\sum_i d_i x_i^2-\sum_{i,j}a_{ij}x_ix_j=\boldsymbol{x}^\top(\mathbf{D}-\mathbf{A})\boldsymbol{x} \tag{4}$$

を得る。$\mathbf{L}=\mathbf{D}-\mathbf{A}$ をグラフラプラシアン(graph Laplacian)と呼ぶ(定義 4)。$\boldsymbol{x}^\top\mathbf{L}\boldsymbol{x}$ は、線でつながった点どうしの値の違いの二乗和である。この式は $\boldsymbol{x}$ が ±1 でなくても成り立つ。

カットを最も小さくすると、困りごと③のように 1 点だけを切り離しやすい。そこで、群の大きさで割った

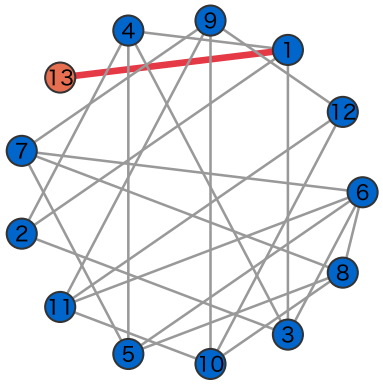
$$\mathrm{RatioCut}(S)=\mathrm{cut}(S,\bar{S})\Big(\frac{1}{|S|}+\frac{1}{|\bar{S}|}\Big) \tag{5}$$

をレシオカット(ratio cut)と呼ぶ。$|S|$ は群に入る点の数である。人工データでは、13 だけを切り離すとカットは 1 だが、レシオカットは 1.08 である。1〜4 と 13 を切り離すとカットは 2 で、レシオカットは 0.65 と小さい(図 2)。

レシオカットも 2 次形式で書ける。$i\in S$ なら $x_i=\sqrt{|\bar{S}|/|S|}$、$i\in\bar{S}$ なら $x_i=-\sqrt{|S|/|\bar{S}|}$ とおく。またぐ線 1 本では

$$(x_i-x_j)^2=\frac{|\bar{S}|}{|S|}+\frac{|S|}{|\bar{S}|}+2=\frac{(|S|+|\bar{S}|)^2}{|S||\bar{S}|}=n\Big(\frac{1}{|S|}+\frac{1}{|\bar{S}|}\Big)$$

(a) 13だけ：カット 1、レシオカット 1.08



(b) 1〜4と13：カット 2、レシオカット 0.65

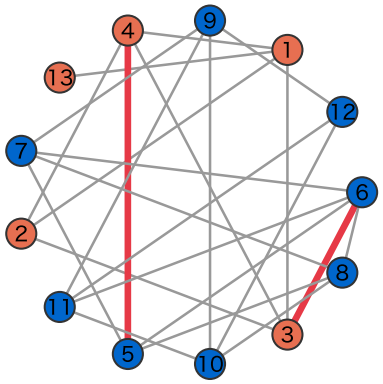


図 2: 人工のグラフの 2 通りの分け方。赤い線が群をまたぐ線。(a) 13 だけを切り離す、(b) 1〜4 と 13 を切り離す

なので、(4) 式から $\boldsymbol{x}^\top \mathbf{L}\boldsymbol{x} = n\,\mathrm{RatioCut}(S)$ となる。さらに $\mathbf{1}_n^\top \boldsymbol{x} = |S|\sqrt{|\bar{S}|/|S|} - |\bar{S}|\sqrt{|S|/|\bar{S}|} = 0$、$\|\boldsymbol{x}\|_2^2 = |\bar{S}| + |S| = n$ である。

k 群に分けるときは、所属行列の列 $\boldsymbol{g}_q$ を群の大きさの平方根で割った $\mathbf{H} = \mathbf{G}(\mathbf{G}^\top\mathbf{G})^{-1/2}$ を使う。$\mathbf{G}^\top\mathbf{G}$ は群の大きさ $|C_q|$ を並べた対角行列なので、$\mathbf{H}^\top\mathbf{H} = \mathbf{I}_k$ である。列 $\boldsymbol{h}_q$ は、群 C_q の点で $1/\sqrt{|C_q|}$、ほかで 0 なので、(4) 式から $\boldsymbol{h}_q^\top \mathbf{L}\boldsymbol{h}_q = \mathrm{cut}(C_q, \bar{C}_q)/|C_q|$ となり

$$\mathrm{tr}(\mathbf{H}^\top\mathbf{L}\mathbf{H}) = \sum_{q=1}^{k} \frac{\mathrm{cut}(C_q, \bar{C}_q)}{|C_q|} \tag{6}$$

を得る。$k = 2$ なら (5) 式に戻る。

定義 4 (グラフラプラシアンとレシオカット)**.** 次数行列 $\mathbf{D}$ と隣接行列 $\mathbf{A}$ から作った $\mathbf{L} = \mathbf{D} - \mathbf{A}$ をグラフラプラシアンと呼ぶ。どの $\boldsymbol{x}$ についても $\boldsymbol{x}^\top\mathbf{L}\boldsymbol{x} = \frac{1}{2}\sum_{i,j} a_{ij}(x_i - x_j)^2$ である。群 S と残り $\bar{S}$ をまたぐ線の数 $\mathrm{cut}(S, \bar{S})$ をカット、それに $1/|S| + 1/|\bar{S}|$ を掛けたものをレシオカットと呼ぶ。

固有ベクトルで解く

レシオカットを最も小さくする分け方を求めたい。ところが、分け方は 2^n 通りあり、全部を試すことはできない。そこで、値を緩めて固有ベクトルで解く。

まず、(4) 式より $\boldsymbol{x}^\top\mathbf{L}\boldsymbol{x}$ は二乗の和なので、$\mathbf{L}$ の固有値はどれも 0 以上になる。また $\mathbf{L}\mathbf{1}_n = \boldsymbol{d} - \mathbf{A}\mathbf{1}_n = 0$ なので、最も小さい固有値は $\lambda_1 = 0$ で、固有ベクトルは $\boldsymbol{u}_1 = \mathbf{1}_n/\sqrt{n}$ である。

次に、2 群のときを考える。目的関数⑦より、レシオカットの最小化は、$\boldsymbol{x}$ を 2 つの値しかとらない形に限ったうえで、$\mathbf{1}_n^\top\boldsymbol{x} = 0$、$\|\boldsymbol{x}\|_2^2 = n$ のもとで $\boldsymbol{x}^\top\mathbf{L}\boldsymbol{x}$ を最小にすることである。2 つの値に限るのをやめ、任意の実数を許す(緩める)と

$$\min_{\boldsymbol{x}\in\mathbb{R}^n} \boldsymbol{x}^\top \mathbf{L}\boldsymbol{x} \quad \text{s.t.} \quad \mathbf{1}_n^\top \boldsymbol{x} = 0, \quad \|\boldsymbol{x}\|_2^2 = n \tag{7}$$

となる。$\mathbf{1}_n^\top \boldsymbol{x} = 0$ は $\boldsymbol{x} \perp \boldsymbol{u}_1$ と同じなので、定義 2 より、答えは 2 番目に小さい固有値の固有ベクトル $\hat{\boldsymbol{x}} = \sqrt{n}\,\boldsymbol{u}_2$ で、最小値は $n\lambda_2$ である。$\boldsymbol{u}_2$ をフィードラーベクトル(Fiedler vector)と呼ぶ。緩めた答えは実数なので、符号で 2 群に戻す。人工データでは、図 3 のように 1〜4 と 13 が負になり、レシオカットが最も小さい分け方(図 2 (b))と一致する。

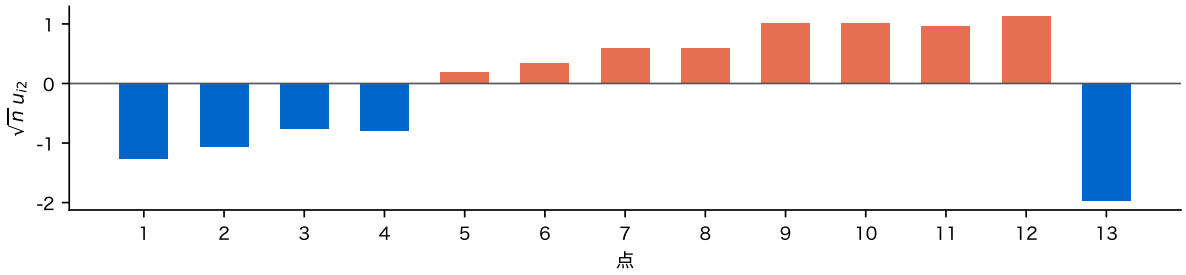


図 3: 人工のグラフのフィードラーベクトル(√ n 倍)。負を青、正を橙で塗った

k 群でも同じである。(6) 式を最小にする $\mathbf{G}$ を求める代わりに、$\mathbf{H} = \mathbf{G}(\mathbf{G}^\top\mathbf{G})^{-1/2}$ の形に限るのをやめ、$\mathbf{H}^\top\mathbf{H} = \mathbf{I}_k$ だけを残すと

$$\min_{\mathbf{H}\in\mathbb{R}^{n\times k}} \operatorname{tr}(\mathbf{H}^\top\mathbf{L}\mathbf{H}) \quad \text{s.t.} \quad \mathbf{H}^\top\mathbf{H} = \mathbf{I}_k \tag{8}$$

となる。定義 3 より、答えは小さい方から k 本の固有ベクトルを並べた $\hat{\mathbf{H}} = \mathbf{U}_k$ である。$k = 2$ なら $\boldsymbol{u}_1$ は定数なので、分け方を決めるのは $\boldsymbol{u}_2$ だけになり、2 群のときに戻る。緩める前の $\mathbf{H} = \mathbf{G}(\mathbf{G}^\top\mathbf{G})^{-1/2}$ では、同じ群の行はすべて同じ値をとる。$\mathbf{U}_k$ の行もそれに近いと期待して、行を第 7 回の k-means で k 群に分ける。この手順をスペクトルクラスタリング(spectral clustering)と呼ぶ(定義 5)。人工データで $k = 4$ とすると、図 4 のように 1〜4、5〜8、9〜12、13 の 4 群に分かれる。図 4 の点の位置は、2 番目と 3 番目の固有ベクトルの値である。

定義 5 (スペクトルクラスタリング)**.** グラフラプラシアン $\mathbf{L}$ の固有ベクトルを小さい方から k 本並べた $\mathbf{U}_k$ の行を、k-means で k 群に分ける手順をスペクトルクラスタリングと呼ぶ。$\mathbf{U}_k$ は、レシオカットの最小化を $\mathbf{H}^\top\mathbf{H} = \mathbf{I}_k$ だけ残して緩めた問題の答えである。2 群なら、2 番目の固有ベクトル(フィードラーベクトル)の符号で分けてもよい。

計算の手順

隣接行列からまとまりを見つけて描く計算を、行列の形でまとめる。

1. 次数 $\boldsymbol{d} = \mathbf{A}\mathbf{1}_n$、$\mathbf{D} = \operatorname{diag}(\boldsymbol{d})$ を求め、$\mathbf{L} = \mathbf{D} - \mathbf{A}$ を作る
2. $\mathbf{L}$ を 1 回固有値分解し、固有値を小さい順に並べる

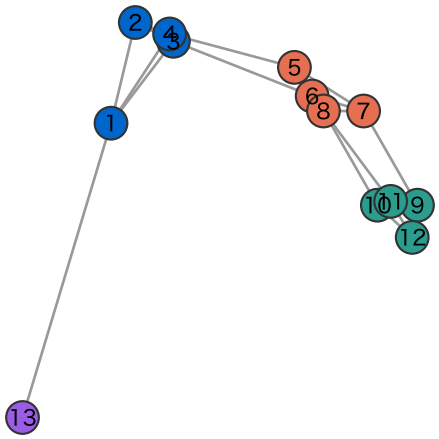


図 4: 人工のグラフを、2 番目と 3 番目の固有ベクトルの値(√ n 倍)を座標にして描いた図。色はスペクトルクラスタリング(k = 4)の群

3. 小さい固有値の並びを見て、群の数 k を決める(帰結②)
4. $\mathbf{U}_k$ の行を k-means で k 群に分ける。2 群なら、フィードラーベクトルの符号で分けてもよい
5. $(\sqrt{n}\,u_{i2}, \sqrt{n}\,u_{i3})$ を点 i の位置にして描き、群の順に $\mathbf{A}$ の行と列を並べ替える

第 7 回の k-means は、データ行列 $\mathbf{X}$ の行をそのまま分けた。ここでは $\mathbf{X}$ が無いので、$\mathbf{L}$ の固有ベクトルの行を点の座標の代わりにし、そのうえで第 7 回の手順を当てる。

理論の帰結：塊と切り方

固有ベクトルから、困りごとへの答えが読み取れる。

第 1 に、並べ方である。同じ $\mathbf{A}$ を、フィードラーベクトルの値の小さい順に並べ替えると、図 5 (b) のように対角に 3 つの塊が現れる。$(\sqrt{n}\,u_{i2}, \sqrt{n}\,u_{i3})$ を点の位置にした 図 4 も、まとまりごとに点が集まる。13! 通りの並べ方を試さなくても、固有値分解 1 回で、まとまりの見える順と置き方が決まる。

第 2 に、塊の数である。(4) 式より、$\boldsymbol{x}^\top \mathbf{L}\boldsymbol{x} = 0$ となるのは、線でつながったどの 2 点でも $x_i = x_j$ のときに限る。線をたどって行ける点の集まり(つながった塊)の中では、$\boldsymbol{x}$ は一定になる。逆に、塊ごとに一定の $\boldsymbol{x}$ なら $\mathbf{L}\boldsymbol{x} = 0$ である。$\mathbf{L}$ の固有値は 0 以上なので、$\boldsymbol{x}^\top \mathbf{L}\boldsymbol{x} = 0$ と $\mathbf{L}\boldsymbol{x} = 0$ は同じ条件になる($\mathbf{L} = \mathbf{U}\boldsymbol{\Lambda}\mathbf{U}^\top$ で $\sum_m \lambda_m c_m^2 = 0$ なら、$\lambda_m > 0$ の向きの c_m はすべて 0)。したがって、固有値 0 の固有ベクトルは塊の 0/1 のベクトル $\boldsymbol{g}_q$ の組み合わせで書け、その本数は塊の数に等しい(定理 1)。人工データから塊の間の 5 本の線を抜くと、図 6 (a) のように固有値 0 がちょうど 3 個になる。線を戻すと、そのうち 2 個が 0 に近い小さな値になる。小さな固有値の後で大きく跳ぶところまでを数えれば、群の数 k の目安になる。元のグラフでは、小さな固有値が 4 個(1.71 以下)並んだ後、4.00 に跳ぶ(図 6 (b))。$k = 4$ では、13 が 1 点で 1 つの群になる。

定理 1 (固有値 0 の数はつながった塊の数)**.** *グラフラプラシアン $\mathbf{L}$ の固有値 0 の数は、グラフのつながった塊の数に等しい。固有値 0 の固有ベクトルは、塊ごとの 0/1 のベクトルの組み合わせで書ける。*

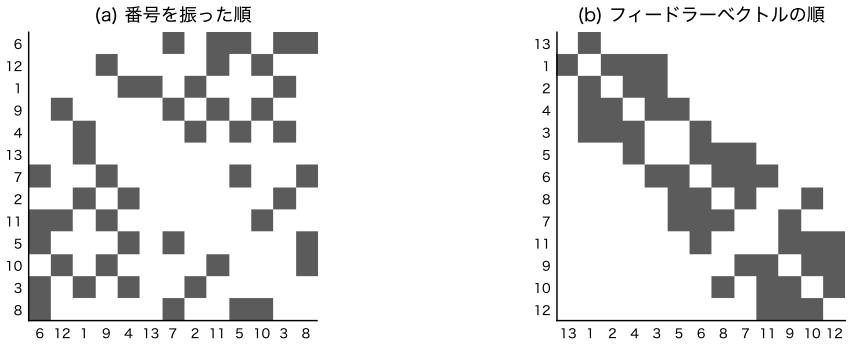


図 5: 人工のグラフの隣接行列。(a) 番号の分からない順、(b) フィードラーベクトルの値の小さい順に並べ替えたもの

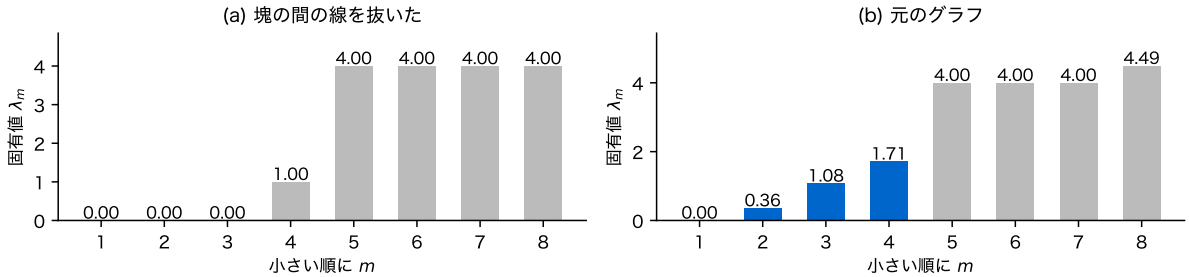


図 6: 人工のグラフのラプラシアンの固有値(小さい順に 8 個)。(a) 塊の間の 5 本の線を抜いたグラフ、(b) 元のグラフ

第 3 に、点ごとの線の数(次数)である。次数は $\mathbf{L}$ の対角にしか入っていない。誰とつながるかは、対角でない $-\mathbf{A}$ が持つ。人工データでは次数がほぼそろっていても、フィードラーベクトルは塊ごとにそろった(図 3)。まとまりは、線の数ではなく、誰とつながるかで決まる。

第 4 に、切り方である。レシオカットでは、1 点だけの群は $1/|S| = 1$ となり、重く数えられる。12 点のグラフで 1 点を 1 本で切り離すとレシオカットは $1\times(1+1/11) = 1.09$、6 点ずつを 3 本で切ると $3\times(1/6+1/6) = 1.00$ になり、線が多くても大きさのそろった分け方を選ぶ。人工データでも、13 だけを切るレシオカットは 1.08、フィードラーベクトルの符号で切ると 0.65 である。

最後に、緩めた問題 (7) 式は、元の分け方から作った $\boldsymbol{x}$ をすべて候補に含む。だから緩めた最小値は元の最小値以下で、$\lambda_2 \le \min_S \mathrm{RatioCut}(S)$ が成り立つ。人工データでは $\lambda_2 = 0.358$ である。λ_2 が大きいグラフは、どう切っても多くの線をまたぐ、切りにくいグラフである。

理論の帰結：次数で割る

レシオカットのスペクトルクラスタリングで $k = 3$ とすると、13 が 1 点で 1 つの群になり、残りは 1〜5 と 6〜12 に分かれて、塊がくずれた(図 7)。線 1 本でしかつながらない点を 1 つの群に数えるのは、まとまりを見つ

けたいという目的に合わない。そこで、群の大きさを点の数ではなく次数の和 $\mathrm{vol}(S) = \sum_{i \in S} d_i$ で測る。

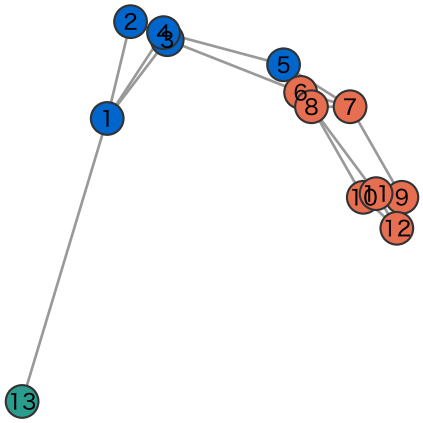


図 7: 人工のグラフを、レシオカットのスペクトルクラスタリング(k = 3)で分けた群。位置は 2 番目と 3 番目の固有ベクトルの値

$$\mathrm{Ncut}(S) = \mathrm{cut}(S, \bar{S}) \Big(\frac{1}{\mathrm{vol}(S)} + \frac{1}{\mathrm{vol}(\bar{S})} \Big) \tag{9}$$

を正規化カット(normalized cut)と呼ぶ。線の少ない点は群の大きさに少ししか効かない。vol の合計は $\mathbf{1}_n^\top \boldsymbol{d} = 2m$ である(道具①)。

目的関数⑥⑦と同じ計算ができる。$i \in S$ なら $x_i = \sqrt{\mathrm{vol}(\bar{S})/\mathrm{vol}(S)}$、$i \in \bar{S}$ なら $x_i = -\sqrt{\mathrm{vol}(S)/\mathrm{vol}(\bar{S})}$ とおくと、またぐ線 1 本で $(x_i - x_j)^2 = 2m\{1/\mathrm{vol}(S) + 1/\mathrm{vol}(\bar{S})\}$ となるので

$$\boldsymbol{x}^\top \mathbf{L} \boldsymbol{x} = 2m\,\mathrm{Ncut}(S), \qquad \boldsymbol{x}^\top \mathbf{D} \boldsymbol{x} = 2m, \qquad \mathbf{1}_n^\top \mathbf{D} \boldsymbol{x} = 0$$

を得る。2 つ目と 3 つ目は、$\sum_{i \in S} d_i x_i^2 = \mathrm{vol}(\bar{S})$ などから出る。値を緩め、$\boldsymbol{v} = \mathbf{D}^{1/2} \boldsymbol{x}$ とおくと、問題は

$$\min_{\boldsymbol{v}} \boldsymbol{v}^\top \mathbf{L}_{\mathrm{sym}} \boldsymbol{v} \quad \text{s.t.} \quad \boldsymbol{v} \perp \mathbf{D}^{1/2} \mathbf{1}_n, \quad \|\boldsymbol{v}\|_2^2 = 2m, \qquad \mathbf{L}_{\mathrm{sym}} = \mathbf{D}^{-1/2} \mathbf{L} \mathbf{D}^{-1/2} = \mathbf{I} - \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2} \tag{10}$$

となる。$\mathbf{L}_{\mathrm{sym}} \mathbf{D}^{1/2} \mathbf{1}_n = \mathbf{D}^{-1/2} \mathbf{L} \mathbf{1}_n = 0$ なので、$\mathbf{D}^{1/2} \mathbf{1}_n$ は固有値 0 の向きである。$\mathbf{L}_{\mathrm{sym}}$ も $\boldsymbol{v}^\top \mathbf{L}_{\mathrm{sym}} \boldsymbol{v} = (\mathbf{D}^{-1/2} \boldsymbol{v})^\top \mathbf{L} (\mathbf{D}^{-1/2} \boldsymbol{v}) \geq 0$ より固有値は 0 以上で、定義 2 から答えは 2 番目の固有ベクトル $\boldsymbol{v}_2$、元の値は $\boldsymbol{y}_2 = \mathbf{D}^{-1/2} \boldsymbol{v}_2$ である。k 群なら、小さい方からの $\boldsymbol{y}_m = \mathbf{D}^{-1/2} \boldsymbol{v}_m$ の行を k-means で分ける。人工データで $k = 3$ とすると、図 8 のように 13 は 1〜4 と同じ群に入り、3 つの塊に分かれる。

この $\mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}$ は、第 12 回の対応分析に現れる。隣接行列を分割表とみると、総数は $2m$、比率は $\mathbf{P} = \mathbf{A}/(2m)$、行の周辺も列の周辺も次数の割合 $\boldsymbol{r} = \boldsymbol{d}/(2m)$ である。$\mathbf{D}_r = \mathbf{D}/(2m)$ なので、標準化残差行列は

$$\mathbf{S} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \boldsymbol{r}\boldsymbol{r}^\top) \mathbf{D}_r^{-1/2} = \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2} - \sqrt{\boldsymbol{r}} \sqrt{\boldsymbol{r}}^\top \tag{11}$$

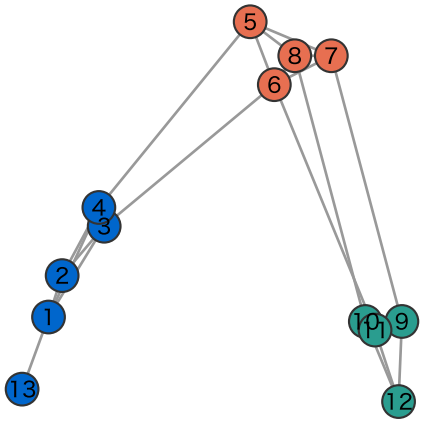


図 8: 人工のグラフを、正規化カットのスペクトルクラスタリング(k = 3)で分けた群。位置は $\boldsymbol{y}_2$、$\boldsymbol{y}_3$ の値(軸ごとに大きさをそろえた)

となる。$\mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2} = \mathbf{I} - \mathbf{L}_{\text{sym}}$ の固有ベクトルは $\mathbf{L}_{\text{sym}}$ と同じ $\boldsymbol{v}_m$ で、固有値は $1-\mu_m$ である。$\mu_1 = 0$ の向き $\boldsymbol{v}_1 = \sqrt{\boldsymbol{r}}$ は、第 12 回の帰結④と同じく $-\sqrt{\boldsymbol{r}}\sqrt{\boldsymbol{r}}^{\top}$ が消す。$\mathbf{S}$ は対称なので、特異値は固有値の絶対値 $|1-\mu_m|$ で、行の点 $\mathbf{D}_r^{-1/2}\boldsymbol{k}$ は $\mathbf{D}^{-1/2}\boldsymbol{v}_m = \boldsymbol{y}_m$ に比例する。つまり、隣接行列の対応分析と正規化カットは、同じ向きの組から軸を選ぶ(定理 2)。

違うのは並べ方である。正規化カットは $1-\mu_m$ の大きい順(μ_m の小さい順)に選び、対応分析は絶対値 $|1-\mu_m|$ の大きい順に選ぶ。$1-\mu_m$ が負の向きは、群をまたいで線が多い形を表す。人工データでは、正規化カットの 1 本目は対応分析の軸 1 と同じだが、対応分析の軸 2 は $1-\mu_n$ = -0.606 の負の向きで、正規化カットの 2 本目($1-\mu_3$ = +0.588)は軸 3 になる。

定理 2 (隣接行列の対応分析と正規化カット)**.** 隣接行列 $\mathbf{A}$ を分割表とみた対応分析の標準化残差行列は $\mathbf{S} = \mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2} - \sqrt{\boldsymbol{r}}\sqrt{\boldsymbol{r}}^{\top}$ ($\boldsymbol{r} = \boldsymbol{d}/(2m)$)である。その特異値は $|1-\mu_m|$ (μ_m は $\mathbf{L}_{\text{sym}}$ の *0* でない固有値)で、行の点は正規化カットを緩めた答え $\mathbf{D}^{-1/2}\boldsymbol{v}_m$ に比例する。

最後に、$\mathbf{L}_{\text{sym}}\boldsymbol{v} = \mu\boldsymbol{v}$ に $\boldsymbol{v} = \mathbf{D}^{1/2}\boldsymbol{y}$ を入れて左から $\mathbf{D}^{1/2}$ を掛けると $\mathbf{L}\boldsymbol{y} = \mu\mathbf{D}\boldsymbol{y}$、すなわち $\mathbf{A}\boldsymbol{y} = (1-\mu)\mathbf{D}\boldsymbol{y}$ となる。成分で書けば

$$y_i = \frac{1}{1-\mu} \cdot \frac{1}{d_i} \sum_{j=1}^{n} a_{ij} y_j \tag{12}$$

で、点の値は隣の点の値の平均を $1/(1-\mu)$ 倍したものである。第 12 回の遷移公式(行の点は列の点の重み付き平均を $1/\delta$ 倍したもの)と同じ形である。13 の隣は 1 だけなので $y_{13} = y_1/(1-\mu_2)$ となり、13 の値は 1 の値に近い。線の少ない点は、隣に引き寄せられる。

第 II 部　実データ解析

酵母のタンパク質と手続き

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、塊がはっきり出るように作った。実データは理論どおりにいくとは限らない。外れたときは、その理由を第 I 部の道具で考える。

使うデータは、出芽酵母（パン酵母）のタンパク質相互作用である。細胞の中では、いくつものタンパク質が結合して複合体を作り、1 つの仕事をする。複合体の一覧と、どのタンパク質がどれに属するかは、EBI Complex Portal（Meldal ほか 2022）に記録されている。そこから、働きのはっきりした 8 つの複合体を選んだ。要らないタンパク質を分解するプロテアソーム、核の膜に開いた出入り口の核膜孔、細胞分裂を先に進める APC（後期促進複合体）、DNA から RNA を写す RNA ポリメラーゼ II・III、写し始めを調節するメディエーター・TFIID・SAGA である。構成するタンパク質は 154 個で、うち 10 個は 2 つの複合体に共有されている（ポリメラーゼ II と III、TFIID と SAGA）。

つながりは、STRING v12.0（Szklarczyk ほか 2023、CC BY 4.0）の物理的な相互作用から取った。実験や文献から集めた「2 つのタンパク質が結合する」という記録に、0〜1 の信頼度が付いている。信頼度 0.7 以上の組だけを線で結ぶと 1,881 本になる（図 9）。線の有無だけを使い、信頼度は使わなかった。複合体の所属は計算には使わず、答え合わせだけに使う。

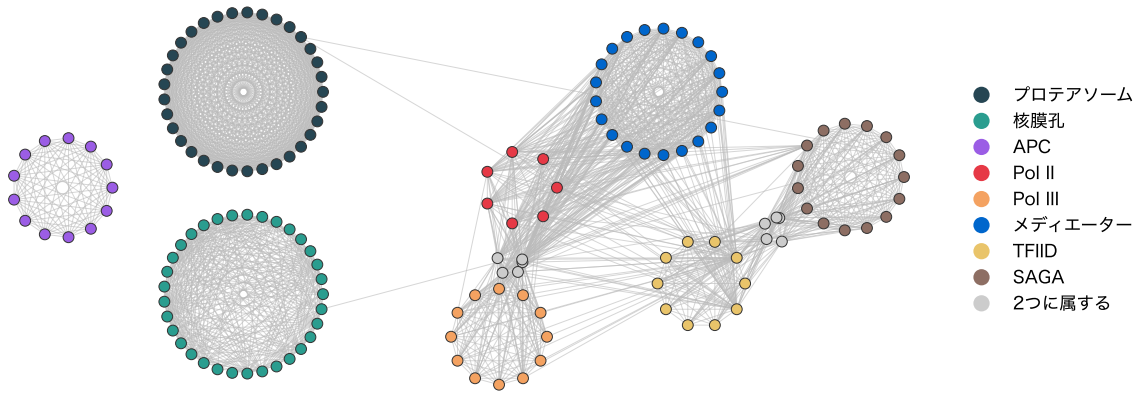


図 9: 出芽酵母の 8 つの複合体のタンパク質（154 個）と、物理的な相互作用（信頼度 0.7 以上、1,881 本。STRING v12.0）。色は Complex Portal の複合体、灰色は 2 つの複合体に属するもの。点は複合体ごとに円に並べた（並べ方は計算には使わない）

第 I 部からは、次の 4 つを予想した。第 1 に、複合体どうしも相互作用でつながり、固有値 0 は 1 個になる（定理 1）。第 2 に、正規化カットで 8 群に分けると、複合体ごとに分かれる。第 3 に、レシオカットでは、線の少ないタンパク質が 1 点の群になりやすい。第 4 に、小さい固有値が複合体の数の 8 個だけ並び、その後で跳ぶ。

手続きは次のとおりである。隣接行列を作り、I-6 の手順でラプラシアン $\mathbf{L}$ と正規化した $\mathbf{L}_{\mathrm{sym}}$ を固有値分解

した。固有ベクトルの行を k-means で 8 群に分け、群と複合体の対応を数えた。

結果：複合体に分かれるか

結果は次のとおりである。まず、ラプラシアンの固有値 0 は 2 個あった（図 10）。全体は線でたどれない 2 つの塊に分かれており、予想は外れた。APC の 13 個は、ほかの 7 つの複合体と信頼度 0.7 以上の線を 1 本も持たない（図 9 の紫）。定理 1 のとおり、離れた塊は固有値 0 を 1 つ増やす。細胞分裂を進める APC は、転写や分解の機械と直接には結合しない、別の仕事をする複合体である。

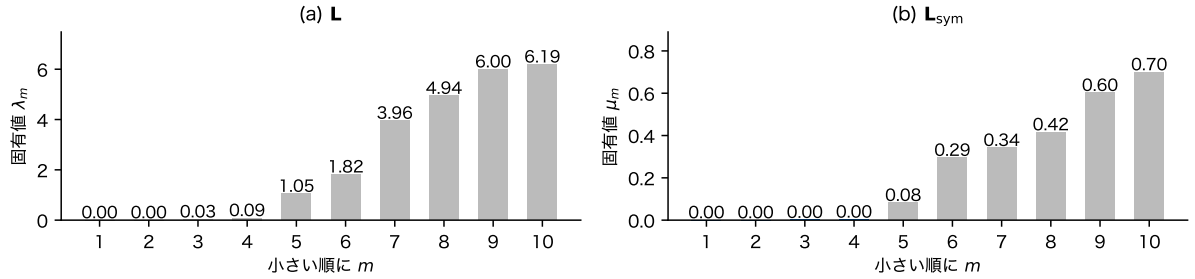


図 10: 酵母のタンパク質相互作用の固有値（小さい順に 10 個）。(a) ラプラシアン $\mathbf{L}$、(b) 正規化した $\mathbf{L}_{\mathrm{sym}}$

次に、正規化カットで 8 群に分けた（図 11 (a)）。プロテアソーム・APC・RNA ポリメラーゼ III・SAGA は全部が、TFIID も 10 個中 8 個が 1 つの群にまとまった。外れは 2 つある。1 つは、RNA ポリメラーゼ II とメディエーターが 1 つの群になったことである。2 つの間の線は 105 本あり、ポリメラーゼ II の中の線 21 本より多い。群をまたぐ線が多いので、カットを小さくする分け方はこの 2 つを切らない。細胞の中でも、メディエーターはポリメラーゼ II に結合して 1 つの大きな塊として働く。もう 1 つは、核膜孔が 30 個と 3 個に分かれたことである。3 個（POM34、NDC1、POM152）は膜に埋まった輪の部分で、ほかの部分との線が少ない。線の数で見れば、核膜孔の中の小さなまとまりである。

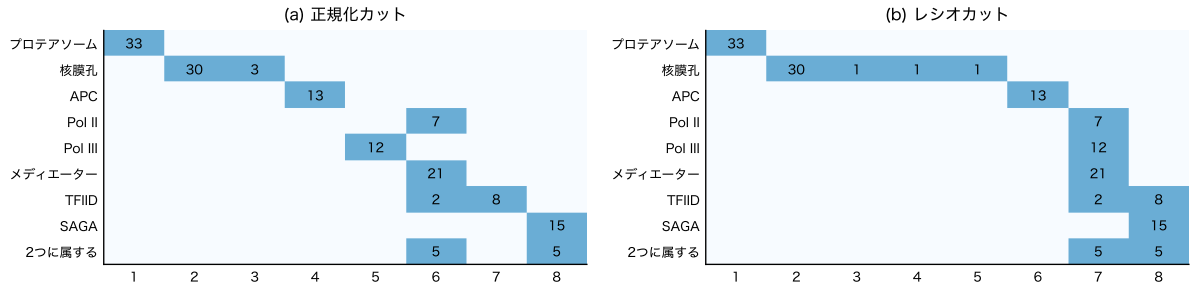


図 11: 酵母のタンパク質を 8 群に分けた結果と複合体の対応（数はタンパク質の個数）。(a) 正規化カット、(b) レシオカット

2 つの複合体に属する 10 個は、どちらか一方の群にしか入れない。TFIID と SAGA が共有する TAF は SAGA の群に、ポリメラーゼ II と III が共有する 5 個はポリメラーゼ II の群に入った。k-means は 1 つの点を 1 つの群に入れるので、共有されたタンパク質は境目の点になる。

レシオカットでは、予想どおり 1 点の群が現れた(図 11 (b))。核膜孔から 1 個ずつの群が 3 つでき、その分、ポリメラーゼ III はポリメラーゼ II の群にのみ込まれた。点の数で割るレシオカットは、線の少ない点を切り離しても大きく割り引かない。次数の和で割る正規化カットのほうが、この表には合っている(帰結⑦)。

最後に、固有値の跳びを見る。$\mathbf{L}_{\mathrm{sym}}$ の固有値は、0 に近いものが 4 個並んだ後で跳ぶ(図 10 (b))。複合体の数の 8 ではなく、予想は外れた。4 群に分けると、プロテアソーム・核膜孔・APC と、転写に関わる 5 つ(ポリメラーゼ II・III、メディエーター、TFIID、SAGA)にきれいに分かれる(図 12)。転写に関わる 5 つは、共有するタンパク質と多くの線で互いに結びつき、粗く見ると 1 つの塊になっている。固有値の跳びは、複合体の一覧ではなく、線のつながりで見たまとまりの数を教える。

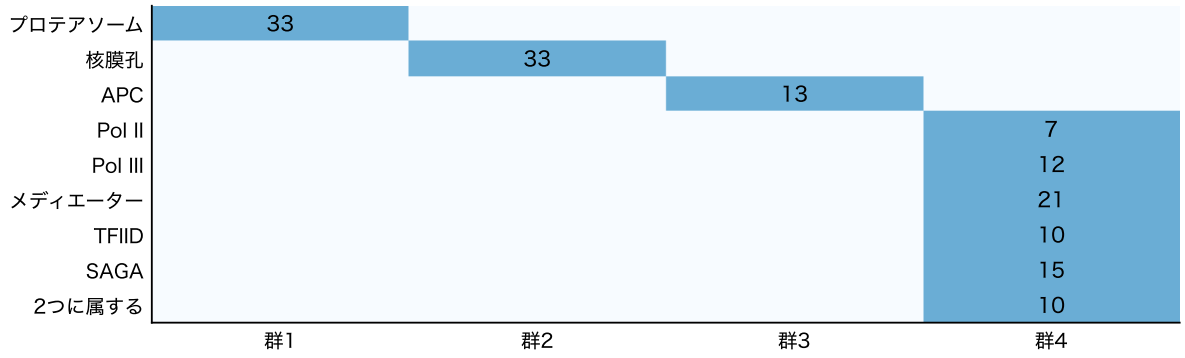


図 12: 正規化カットで 4 群に分けた結果と複合体の対応

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは 4 つを予想した。複合体どうしもつながって固有値 0 は 1 個になること、正規化カットで複合体ごとに分かれること、レシオカットでは 1 点の群ができやすいこと、小さい固有値が複合体の数だけ並んでから跳ぶことである。1 つ目は外れ、APC はほかの複合体と線でつながらない別の塊だった。2 つ目はおおむね予想どおりで、8 つのうち 4 つの複合体は全部が、TFIID は 10 個中 8 個が 1 つの群になった。外れた RNA ポリメラーゼ II とメディエーターは間の線が多く、細胞の中でも結合して働く。核膜孔の膜に埋まった輪の 3 個は、ほかの部分との線が少ない。3 つ目は予想どおりで、レシオカットでは核膜孔から 1 個ずつの群ができた。4 つ目は外れ、跳びは 4 個の後にあった。転写に関わる 5 つの複合体は、線のつながりで見ると 1 つの大きな塊である。複合体の一覧と、線のつながりで見たまとまりは、同じとは限らない。外れたところは、どれも線の数で説明できた。

締め

まとめと次回の問い

本章の問いは、行も列も同じものの、つながりの表から、何を読み、どう描くかであった。点と点のつながりを隣接行列 $\mathbf{A}$ で表し、まとまりを「群をまたぐ線が少ないこと」と考えた。線でつながった点どうしの値の違いの二乗和は、グラフラプラシアン $\mathbf{L} = \mathbf{D} - \mathbf{A}$ の 2 次形式 $\boldsymbol{x}^{\top}\mathbf{L}\boldsymbol{x}$ で書け、群をまたぐ線の数(カット)もこの形で表

せる。カットだけを最小にすると 1 点を切り離しやすいので、群の大きさで割ったレシオカットを使った。0/1 を実数に緩めると、第 10 回と同じ固有値の重みの議論で、小さい方の固有ベクトルが答えになる。2 群ならフィードラーベクトルの符号で、k 群なら固有ベクトルの行を第 7 回の k-means で分ける（スペクトルクラスタリング）。固有ベクトルを座標にすれば、まとまりの見える置き方と並べ方が、固有値分解 1 回で決まる。固有値 0 の数はつながった塊の数で、小さい固有値の後の跳びが群の数の目安になる。群の大きさを次数の和で測る正規化カットは、隣接行列を分割表とみた第 12 回の対応分析と同じ向きの組を使い、点の値は隣の点の値の平均に寄る。出芽酵母の 8 つの複合体のタンパク質相互作用では、正規化カットで分けた群の多くが複合体と重なった。外れたところ（線でつながらない APC、結合して働く RNA ポリメラーゼ II とメディエーター、膜に埋まった核膜孔の輪）は、どれも線の数で説明できた。固有値の跳びは、転写に関わる 5 つの複合体を 1 つの塊として数えた。

最後に、次回への問いを置く。本章では、つながりの表 $\mathbf{A}$ が手元にあった。しかし多くのデータで手元にあるのは、個体 $\times$ 変数のデータ行列 $\mathbf{X}$ だけで、変数どうしのつながりの表はどこにも書かれていない。データ行列から、変数どうしのつながりの表を作れるだろうか。

発展

発展：見つけられる境目

発展として、群が本当にあるとき、それをいつ見つけられるかを考える。線を確率で引くモデルを置く。n 個の点を半分ずつ 2 群に分け、同じ群の 2 点は確率 a/n で、違う群の 2 点は確率 b/n で、互いに独立に線を引く（図 13）。これを確率ブロックモデル（stochastic block model）と呼ぶ。平均の次数は $(a+b)/2$ で、n を大きくしても変わらない。

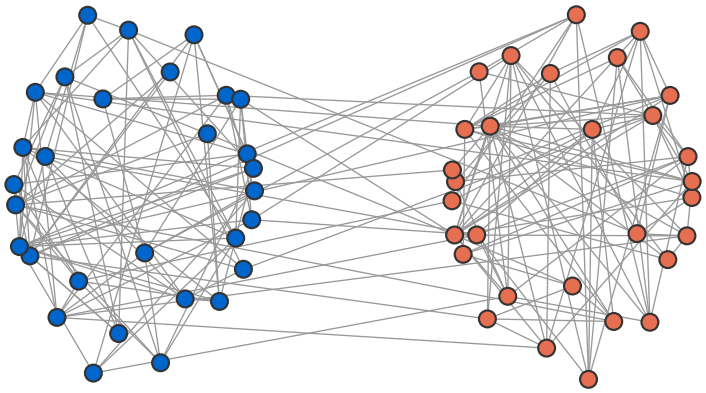


図 13: 確率ブロックモデルから作ったグラフの例（n = 60、a = 12、b = 2）。色は本当の群

$s = (a-b)^2/\{2(a+b)\}$ とおく。Decelle ほか（2011）は統計物理の方法から、$s = 1$ が境目であると予想した。$s < 1$ では、どんな方法でも当て推量より良く群を当てられない。これは Mossel, Neeman & Sly（2015）が証明した。$s > 1$ なら当て推量より良く当てられる方法があることも、Massoulié（2014）と Mossel ほか（2018）が示した。

$n = 2{,}000$、平均の次数を 6 に固定し、s を変えて、正規化カットの 2 番目の固有ベクトルの符号で 2 群に分けた(図 14。4 回の平均)。$s < 1$ では正解率は当て推量の 0.5 のままで、s が大きくなると 1 に近づく。ただし s が 1 を少し超えたところでは、伸びは遅い。線の少ないグラフでは、たまたま次数の大きい点や、木のように枝分かれした部分に固有ベクトルが引っぱられるからである。Krzakala ほか(2013)は、線をたどってすぐ引き返す道を数えない行列(非バックトラック行列)の固有ベクトルを使えば、境目まで届くことを示した。

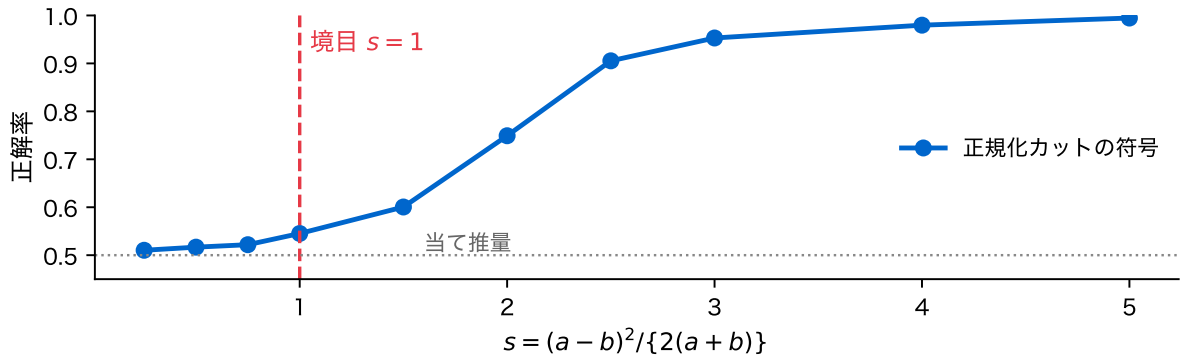


図 14: 確率ブロックモデル(n = 2,000、平均の次数 6)で、正規化カットの 2 番目の固有ベクトルの符号が本当の群を当てた割合(4 回の平均)。赤の破線は境目 s = 1

参考文献

- Decelle, A., Krzakala, F., Moore, C. & Zdeborová, L. (2011). Asymptotic analysis of the stochastic block model for modular networks and its algorithmic applications. Physical Review E 84: 066106.
- Krzakala, F., Moore, C., Mossel, E., Neeman, J., Sly, A., Zdeborová, L. & Zhang, P. (2013). Spectral redemption in clustering sparse networks. PNAS 110: 20935–20940.
- Massoulié, L. (2014). Community detection thresholds and the weak Ramanujan property. STOC 2014: 694–703.
- Mossel, E., Neeman, J. & Sly, A. (2015). Reconstruction and estimation in the planted partition model. Probability Theory and Related Fields 162: 431–461.
- Mossel, E., Neeman, J. & Sly, A. (2018). A proof of the block model threshold conjecture. Combinatorica 38: 665–708.
- Meldal, B. H. M. et al. (2022). Complex Portal 2022: new curation frontiers. Nucleic Acids Research 50: D578–D586.
- Szklarczyk, D. et al. (2023). The STRING database in 2023: protein–protein association networks and functional enrichment analyses for any sequenced genome of interest. Nucleic Acids Research 51: D638–D646.