

第 14 回 対応分析

独立の表からのずれを、重みを付けて低ランク近似する

本章の問いは、第 13 回の締めで残った「行と列が両方カテゴリなら？」である。行も列もカテゴリで、マスの中身が度数の表を分割表という。分割表を第 10 回のようにそのまま特異値分解すると、1 本目の軸は行と列の合計の大きさ(独立なら期待される表)を拾うだけになる。そこで、独立なら期待される表を先に引く。残ったずれは期待度数で割る重み付きの二乗で測り、第 10 回の Eckart–Young の定理で低ランク近似する。これが対応分析であり、重み付き誤差の最小値は総慣性 χ^2/n の捨てた分になる。

第 I 部 理論

行も列もカテゴリの表

第 1～13 回のデータ行列 $\mathbf{X}$ は、行が個体、列が測った量であった。本章で扱うのは、行も列もカテゴリで、マスの中身がその組み合わせの度数である表、すなわち分割表(contingency table)である。例として、あるラーメン屋の 1 か月の注文 1,210 杯を、メニュー(5 種類)と時間帯(4 つ)で数えた図 1 (a) の表を考える。人工的なデータである。知りたいのは、豚骨は深夜によく出るのか、つけ麺は昼か、という関連の形である。

(a) 注文の数					(b) そのまま分解：1 本目 (75%)					(c) 行の合計×列の合計÷ n				
醤油	90	150	90	30	醤油	102	100	106	62	醤油	98	83	110	68
塩	110	60	60	30	塩	73	72	76	45	塩	71	60	80	49
味噌	10	20	110	30	味噌	47	47	49	29	味噌	46	39	52	32
豚骨	10	40	70	120	豚骨	57	56	59	35	豚骨	65	56	73	46
つけ麺	110	10	40	20	つけ麺	51	50	53	31	つけ麺	49	42	55	34
	昼	夕方	夜	深夜		昼	夕方	夜	深夜		昼	夕方	夜	深夜

図 1: 人工のラーメン屋の注文の分割表。(a) 観測した注文の数、(b) (a) をデータ行列とみてそのまま特異値分解したときの 1 本目の近似、(c) 行の合計 × 列の合計 ÷ 総数。色の目盛りは 3 枚で共通

数の表なら、第 10 回のように特異値分解して上位の軸を見ればよさそうに思える。ところが (a) をそのまま特異値分解すると、1 本目の軸だけで二乗和の 75.2% を表す。その近似 (b) は、行の合計と列の合計を掛けて総数で割った (c) とほとんど同じになる(差は最大 17.1 杯)。(c) は「醤油はよく出る」「夜は客が多い」という、行

と列それぞれの大きさだけから作った表である。どの時間帯にどのメニューがよく出るかという関連については、何も表していない。分割表を素朴に分解すると、最も大きな軸は量に取られてしまう。

本章の問いは、行と列が両方カテゴリのとき、この関連の形をどう取り出すか、である。答えの見通しを先に述べる。まず、行と列が独立なら期待される表、すなわち (c) を引く。次に、残ったずれを、期待度数で割った二乗で測る。期待度数の大きいマスでは多少のずれは当たり前なので、割って軽くするのである。この重み付きの誤差を最小にする低ランク近似は、第 10 回の Eckart–Young の定理によって、特異値分解を 1 回計算するだけで求まる。その結果、行と列を同じ平面に置いた地図が得られる。この手法を対応分析(correspondence analysis)と呼ぶ。

表 1 のとおり、対応分析は第 10 回の主成分分析と同じく「特異値分解 1 回」で解ける低ランク近似である。違うのは、近似する相手(比率の表)と、二乗誤差に掛ける重みである。推定法の列に、第 4 回の罰則付き最小二乗法に続いて、重み付き最小二乗法が加わる。

表 1: 低ランク近似の目的関数と解き方。記号は次の節で定義する

モデル	近似する相手	目的関数	解き方	回
主成分分析	$\mathbf{X}$	$\ \mathbf{X} - \mathbf{FA}^\top\ _F^2$	特異値分解を 1 回	第 10 回
k-means	$\mathbf{X}$	$\ \mathbf{X} - \mathbf{GC}\ _F^2$	交互に解く	第 11 回
対応分析	比率の表 $\mathbf{P}$	$\sum_{i,j} (p_{ij} - \hat{p}_{ij})^2 / (r_i c_j)$	特異値分解を 1 回	第 14 回

道具：比率・周辺・対角行列

本章で使う道具を先にそろえる。分割表 $\mathbf{O}$ は I 行 J 列($I \geq J$)で、マス o_{ij} は行のカテゴリ i と列のカテゴリ j の組み合わせが数えられた回数、総数を $n = \sum_{i,j} o_{ij}$ とする。度数は総数が変わると全部が変わるので、比率に直しておく。また、行の大きさ(よく出るメニューか)と行の中の形(いつ出るか)を分けて書きたい。

1 つ目は比率の表と周辺である。各マスを総数で割った $p_{ij} = o_{ij}/n$ を並べた $I \times J$ の行列を $\mathbf{P}$ と書く。その行の和 $r_i = \sum_j p_{ij}$ を行の周辺、列の和 $c_j = \sum_i p_{ij}$ を列の周辺と呼び、ベクトルで書けば

$$\mathbf{r} = \mathbf{P}\mathbf{1}_J, \quad \mathbf{c} = \mathbf{P}^\top\mathbf{1}_I, \quad \mathbf{1}_I^\top\mathbf{r} = \mathbf{1}_J^\top\mathbf{c} = 1 \quad (1)$$

である($\mathbf{1}_J$ は 1 を J 個並べた縦ベクトル)。図 1 の表では、豚骨の行の周辺は $r_4 = 0.198$ 、深夜の列の周辺は $c_4 = 0.190$ である。

2 つ目は、周辺を対角に並べた行列 $\mathbf{D}_r = \text{diag}(r_1, \dots, r_I)$ 、 $\mathbf{D}_c = \text{diag}(c_1, \dots, c_J)$ である。対角行列を左から掛けると各行に、右から掛けると各列に、対角の数が掛かる。したがって $\mathbf{D}_r^{-1}\mathbf{P}$ は各行を r_i で割った行列であり、 $\mathbf{D}_r^{-1/2}\mathbf{A}\mathbf{D}_c^{-1/2}$ は任意の $I \times J$ 行列 $\mathbf{A}$ のマス a_{ij} を $\sqrt{r_i c_j}$ で割った行列である。マスごとの割り算を、行列の掛け算で書けることになる。

3つ目は行プロファイル(row profile)である。行 i を行の周辺で割ったベクトル $\mathbf{a}_i = (p_{i1}/r_i, \dots, p_{iJ}/r_i)^\top$ は、その行の中で各列が占める割合であり、成分を足すと 1 になる(定義 1)。 $\mathbf{D}_r^{-1}\mathbf{P}$ の第 i 行を縦にしたものである。行プロファイルは行の大きさを消した「形」である。図 2 のように比べると、豚骨は深夜の割合が大きく、つけ麺と塩は昼の割合が大きい。行プロファイルを行の周辺で重み付けして平均すると $\sum_i r_i \mathbf{a}_i = \mathbf{P}^\top \mathbf{1}_I = \mathbf{c}$ となるので、列の周辺 $\mathbf{c}$ は平均の形である。




図 2: 人工のラーメン屋の表の行プロファイル(各メニューの注文が、どの時間帯にどれだけの割合で出たか)と、平均の形 $\mathbf{c}$

4つ目は第 10 回の Eckart–Young の定理である。第 10 回ではデータ行列 $\mathbf{X}$ に使ったが、定理そのものはどの行列にも成り立つ。 $I \times J$ の行列 $\mathbf{S}$ を $\mathbf{S} = \mathbf{K}\mathbf{\Delta}\mathbf{L}^\top$ と特異値分解し、上位 Q 本を $\mathbf{K}_1, \mathbf{\Delta}_1, \mathbf{L}_1$ とすると

$$\min_{\text{rank}(\mathbf{Y}) \leq Q} \|\mathbf{S} - \mathbf{Y}\|_F^2 \text{ の答えは } \hat{\mathbf{Y}} = \mathbf{K}_1 \mathbf{\Delta}_1 \mathbf{L}_1^\top, \quad \text{最小値は } \sum_{m>Q} \delta_m^2 \quad (2)$$

である。本章の目的関数を、この形に持ち込むのが導出の要である。

定義 1 (周辺・行プロファイル). 比率の表 $\mathbf{P}$ の行の和 $\mathbf{r} = \mathbf{P}\mathbf{1}_J$ を行の周辺、列の和 $\mathbf{c} = \mathbf{P}^\top \mathbf{1}_I$ を列の周辺と呼ぶ。行 i を r_i で割ったベクトル $\mathbf{a}_i$ ($\mathbf{D}_r^{-1}\mathbf{P}$ の第 i 行)を行プロファイルと呼ぶ。列プロファイルも同様に $\mathbf{P}\mathbf{D}_c^{-1}$ の列として定める。

独立のモデルと、そのずれ

関連の形を取り出すには、まず「関連が無い」とはどういう表かを決めておく必要がある。行と列が独立であるとは、どの行プロファイルも平均の形と同じ、すなわち $\mathbf{a}_i = \mathbf{c}$ がすべての行で成り立つことである。どのメニューも、店全体と同じ割合で各時間帯に注文される、という状態である(図 3)。

$a_{ij} = p_{ij}/r_i$ であるから、1 マスずつ書けば

$$p_{ij} = r_i c_j \quad (3)$$




図 3: 人工のラーメン屋の表の行プロファイル。(a) 実際の形、(b) 行と列が独立なら、どの行も平均の形 c と同じになる

となり、度数に直した $e_{ij} = nr_i c_j$ (行の合計 $\times$ 列の合計 $\div$ 総数) を期待度数 (expected frequency) と呼ぶ (定義 2)。行列で書けば $\mathbf{P} = \mathbf{r}\mathbf{c}^\top$ であり、縦ベクトルと横ベクトルの積、すなわちランク 1 の行列である。図 1 (c) は、この $\mathbf{nr}\mathbf{c}^\top$ を描いたものにあたる。素朴な特異値分解の 1 本目が (c) に近かったのは、分割表の最も大きな成分がランク 1 の独立の表だからである。周辺 $\mathbf{r}, \mathbf{c}$ は表から決まるので、独立のモデルには、ほかに推定するものは無い。

実際の表は独立のモデルからずれる。豚骨 $\times$ 深夜の期待度数は 45.6 杯であるが、観測は 120 杯である。このずれを、独立のときの比率に掛ける形で書く。

$$p_{ij} = r_i c_j (1 + b_{ij}), \quad b_{ij} = \frac{p_{ij}}{r_i c_j} - 1 = \frac{o_{ij}}{e_{ij}} - 1 \quad (4)$$

b_{ij} は観測が期待の何倍かから 1 を引いた数であり、豚骨 $\times$ 深夜では +1.63 である。正なら期待より多く、負なら少ない。(4) 式の両辺を r_i で割り、行 i の J 個のマスを縦に並べると

$$\mathbf{a}_i = \mathbf{c} + \mathbf{D}_c \mathbf{b}_i \quad (5)$$

となる ($\mathbf{b}_i = (b_{i1}, \dots, b_{iJ})^\top$)。行の形は、平均の形にずれを足したものであり、 $\mathbf{b}_i = \mathbf{0}$ なら (3) 式に戻る。全行をまとめて行列で書けば

$$\mathbf{P} = \mathbf{r}\mathbf{c}^\top + \mathbf{D}_r \mathbf{B} \mathbf{D}_c \quad (6)$$

である ($\mathbf{B}$ は b_{ij} を並べた $I \times J$ 行列。 $\mathbf{D}_r \mathbf{B} \mathbf{D}_c$ のマスは $r_i b_{ij} c_j$)。 $\mathbf{B}$ に制約が無ければ (6) 式はどの表にも当てはまる恒等式にすぎない。そこで、第 10 回と同じく、ずれ $\mathbf{B}$ のランクを Q 以下に制限したものを本章のモデルとする。 $Q = 0$ なら $\mathbf{B}$ はすべて 0 で独立のモデルであり、 Q を上げるほど、ずれを細かく表せる。対応分析は、独立のモデルにランク Q の補正を足したモデルである。

定義 2 (独立のモデル・期待度数). すべての行プロファイルが平均の形 c に等しい、すなわち $p_{ij} = r_i c_j$ ($\mathbf{P} = \mathbf{r}\mathbf{c}^\top$) であるとき、行と列は独立であるという。 $e_{ij} = nr_i c_j$ を期待度数と呼ぶ。

重み付きの最小二乗

モデル (6) 式の $\mathbf{B}$ を、表に最も近くなるように選ぶ。近さの測り方を、スカラー・ベクトル・行列の順に組み立てる。

まず、どのマスの差も同じ重さで足してよいかを考える。表 2 の 2 つのマスは、どちらも観測が期待度数より 5 杯多い。しかし、期待度数 10 杯のマスの 15 杯出るのは期待の 1.5 倍であり、期待度数 100 杯のマスの 105 杯出るのは 1.05 倍にすぎない。前者の方がはるかに目立つずれである。 $(o-e)^2/e$ に直すと前者は 2.5、後者は 0.25 となる。期待度数で割れば、このずれの重さの違いを誤差に入れられる。

表 2: 同じ差でも、期待度数で割ると重さが変わる

マス	期待度数 e	観測 o	差 $o-e$	何倍か	$(o-e)^2/e$
少ないマス	10 杯	15 杯	5 杯	1.5 倍	2.5
多いマス	100 杯	105 杯	5 杯	1.05 倍	0.25

そこで 1 マスについては、モデルの値 $\hat{p}_{ij} = r_i c_j (1 + b_{ij})$ と観測 p_{ij} の差の二乗を、独立のときの比率 $r_i c_j$ で割った

$$\frac{(p_{ij} - \hat{p}_{ij})^2}{r_i c_j} \quad (7)$$

を誤差とする。割らずに二乗誤差を足すと、度数の大きいマスのずればかりを合わせることになる。その結果、場面②の素朴な分解と同じく、量の大きい行と列に引きずられる。全マスで足した

$$\mathcal{E}(\mathbf{B}) = \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - \hat{p}_{ij})^2}{r_i c_j} \quad (8)$$

が本章の目的関数である。第 1 回の残差平方和 $\sum_i (y_i - \hat{y}_i)^2$ の各項に、重み $w_{ij} = 1/(r_i c_j)$ を付けた形である。このように、重みを付けた二乗誤差の和を最小にする推定法を重み付き最小二乗法(weighted least squares)と呼ぶ。

1 行ずつまとめると、別の見方が出てくる。(7) 式の分子と分母を r_i^2 で割れば $(p_{ij} - \hat{p}_{ij})^2 / (r_i c_j) = r_i (a_{ij} - \hat{a}_{ij})^2 / c_j$ であるから $(\hat{a}_{ij} = \hat{p}_{ij} / r_i)$ 、

$$\sum_{j=1}^J \frac{(p_{ij} - \hat{p}_{ij})^2}{r_i c_j} = r_i \sum_{j=1}^J \frac{(a_{ij} - \hat{a}_{ij})^2}{c_j} = r_i d_{\chi}^2(\mathbf{a}_i, \hat{\mathbf{a}}_i) \quad (9)$$

となる。ここで $d_\chi^2(\mathbf{x}, \mathbf{y}) = \sum_j (x_j - y_j)^2 / c_j$ は、2つの形の差を列ごとに平均の割合 c_j で割って二乗和をとったものであり、 χ^2 距離(chi-square distance)と呼ぶ(定義 3)。目的関数は、各行の形とモデルの形の χ^2 距離の二乗を、行の重み r_i を付けて足したものである。

行列で書くには道具②を使う。 $\mathbf{D}_r^{-1/2}(\mathbf{P} - \hat{\mathbf{P}})\mathbf{D}_c^{-1/2}$ のマスは $(p_{ij} - \hat{p}_{ij})/\sqrt{r_i c_j}$ であるから、

$$\mathcal{E}(\mathbf{B}) = \|\mathbf{D}_r^{-1/2}(\mathbf{P} - \hat{\mathbf{P}})\mathbf{D}_c^{-1/2}\|_F^2, \quad \hat{\mathbf{P}} = \mathbf{r}\mathbf{c}^\top + \mathbf{D}_r \mathbf{B} \mathbf{D}_c \quad (10)$$

と書ける。 $I = 1$ 行なら (9) 式の 1 行分、さらに $J = 1$ 列なら (7) 式に戻る。

$Q = 0$ 、すなわち独立のモデル $\hat{p}_{ij} = r_i c_j$ で残る誤差は

$$\mathcal{E}_0 = \sum_{i,j} \frac{(p_{ij} - r_i c_j)^2}{r_i c_j} = \frac{1}{n} \sum_{i,j} \frac{(o_{ij} - e_{ij})^2}{e_{ij}} = \frac{\chi^2}{n} = \sum_{i=1}^I r_i d_\chi^2(\mathbf{a}_i, \mathbf{c}) \quad (11)$$

である。2つ目の等号は分子と分母に n^2 を掛けたもの、最後の等号は (9) 式で $\hat{\mathbf{a}}_i = \mathbf{c}$ としたものである。 $\chi^2 = \sum_{i,j} (o_{ij} - e_{ij})^2 / e_{ij}$ はピアソンの χ^2 統計量(Pearson's chi-square statistic)であり、(11) 式の値を総慣性(total inertia)と呼ぶ(定義 3)。総慣性は、行の形が平均の形のまわりにどれだけ散らばっているかを、 χ^2 距離と行の重みで測ったものである。第 10 回の主成分分析で、全体の散らばりが $\|\mathbf{X}\|_F^2$ であったのに当たる。人工データでは総慣性は 0.4121、 χ^2 統計量は 498.6 である。対応分析は、この総慣性をできるだけ少ない本数の軸で説明しようとする。

定義 3 (χ^2 距離・総慣性)。 $\mathbf{x}, \mathbf{y}$ について $d_\chi^2(\mathbf{x}, \mathbf{y}) = \sum_j (x_j - y_j)^2 / c_j$ を χ^2 距離(の二乗)と呼ぶ。独立のモデルで残る重み付き誤差 $\mathcal{E}_0 = \chi^2 / n = \sum_i r_i d_\chi^2(\mathbf{a}_i, \mathbf{c})$ を総慣性と呼ぶ。

特異値分解で解く

目的関数 (10) 式の重みを消して、道具④の形に持ち込む。まず、独立のモデルからのずれをマスごとに $\sqrt{r_i c_j}$ で割った行列を作る。

$$s_{ij} = \frac{p_{ij} - r_i c_j}{\sqrt{r_i c_j}}, \quad \mathbf{S} = \mathbf{D}_r^{-1/2}(\mathbf{P} - \mathbf{r}\mathbf{c}^\top)\mathbf{D}_c^{-1/2} \quad (12)$$

これを標準化残差行列(matrix of standardized residuals)と呼ぶ。(11) 式から $\|\mathbf{S}\|_F^2 = \mathcal{E}_0 = \chi^2 / n$ である。度数で書けば $\sqrt{n} s_{ij} = (o_{ij} - e_{ij}) / \sqrt{e_{ij}}$ であり、豚骨 × 深夜では +11.01 となる(図 4)。

(10) 式に $\hat{\mathbf{P}} = \mathbf{r}\mathbf{c}^\top + \mathbf{D}_r \mathbf{B} \mathbf{D}_c$ を代入して、括弧を 2 つに分ける。

$$\begin{aligned} \mathcal{E}(\mathbf{B}) &= \|\mathbf{D}_r^{-1/2}(\mathbf{P} - \mathbf{r}\mathbf{c}^\top)\mathbf{D}_c^{-1/2} - \mathbf{D}_r^{-1/2}\mathbf{D}_r \mathbf{B} \mathbf{D}_c \mathbf{D}_c^{-1/2}\|_F^2 \\ &= \|\mathbf{S} - \mathbf{Y}\|_F^2, \quad \mathbf{Y} = \mathbf{D}_r^{1/2} \mathbf{B} \mathbf{D}_c^{1/2} \end{aligned} \quad (13)$$

$$\sqrt{n} s_{ij} = (o_{ij} - e_{ij}) / \sqrt{e_{ij}}$$

醤油	-0.83	+7.31	-1.91	-4.65
塩	+4.64	-0.02	-2.19	-2.76
味噌	-5.34	-3.08	+8.05	-0.41
豚骨	-6.85	-2.08	-0.40	+11.01
つけ麺	+8.69	-4.90	-2.03	-2.43
	昼	夕方	夜	深夜

図 4: 人工のラーメン屋の表の $\sqrt{n} s_{ij} = (o_{ij} - e_{ij}) / \sqrt{e_{ij}}$ 二乗して全マスで足すと χ^2 統計量になる

2 行目では (12) 式と $\mathbf{D}_r^{-1/2} \mathbf{D}_r = \mathbf{D}_r^{1/2}$ を用いた。 $\mathbf{D}_r^{1/2}$ と $\mathbf{D}_c^{1/2}$ は対角に正の数が並ぶ正則な行列なので、掛けてもランクは変わらず、 $\text{rank}(\mathbf{Y}) = \text{rank}(\mathbf{B}) \leq Q$ である。したがって、 $\mathbf{B}$ についての重み付き最小二乗の問題は、 $\mathbf{Y}$ についての重みの無い低ランク近似の問題に変わった。これは第 10 回の問題そのものである。重みは、近似する相手を $\mathbf{S}$ に替えることで吸収されている。

標準化残差行列を $\mathbf{S} = \mathbf{K} \mathbf{\Delta} \mathbf{L}^\top$ ($\mathbf{K}$ は $I \times J$ 、 $\mathbf{\Delta}$ と $\mathbf{L}$ は $J \times J$ 、 $\delta_1 \geq \dots \geq \delta_J \geq 0$) と特異値分解すれば、Eckart–Young の定理 (2) 式から

$$\hat{\mathbf{Y}} = \mathbf{K}_1 \mathbf{\Delta}_1 \mathbf{L}_1^\top, \quad \min_{\text{rank}(\mathbf{B}) \leq Q} \mathcal{E}(\mathbf{B}) = \sum_{m>Q} \delta_m^2 \quad (14)$$

を得る。 $\mathbf{B}$ に戻すと

$$\hat{\mathbf{B}} = \mathbf{D}_r^{-1/2} \mathbf{K}_1 \mathbf{\Delta}_1 \mathbf{L}_1^\top \mathbf{D}_c^{-1/2} = \mathbf{F} \mathbf{\Delta}_1^{-1} \mathbf{G}^\top, \quad \mathbf{F} = \mathbf{D}_r^{-1/2} \mathbf{K}_1 \mathbf{\Delta}_1, \quad \mathbf{G} = \mathbf{D}_c^{-1/2} \mathbf{L}_1 \mathbf{\Delta}_1 \quad (15)$$

である。 $\mathbf{F} \mathbf{\Delta}_1^{-1} \mathbf{G}^\top$ を展開すると $\mathbf{\Delta}_1 \mathbf{\Delta}_1^{-1} \mathbf{\Delta}_1 = \mathbf{\Delta}_1$ となり、真ん中の式に戻る。 $\mathbf{F}$ の第 i 行 $\mathbf{f}_i$ を行 i の点、 $\mathbf{G}$ の第 j 行 $\mathbf{g}_j$ を列 j の点と呼び、これらを主座標(principal coordinates)と呼ぶ(定義 4)。1 マスで書けば、(4) 式から

$$\frac{\hat{o}_{ij}}{e_{ij}} = 1 + \hat{b}_{ij} = 1 + \sum_{m=1}^Q \frac{f_{im} g_{jm}}{\delta_m} \quad (16)$$

となる。観測が期待の何倍かを、行の点と列の点の軸ごとの積を δ_m で割って足したもので近似している。 $Q = 0$ なら右辺は 1、すなわち独立のモデルである。

定義 4 (対応分析). 分割表の比率 $\mathbf{P}$ を、独立のモデルにランク Q のずれを足した $\mathbf{rc}^\top + \mathbf{D}_r \mathbf{B} \mathbf{D}_c$ で、重み $1/(r_i c_j)$ の重み付き最小二乗法 (8) 式により近似することを対応分析と呼ぶ。解は標準化残差行列 $\mathbf{S}$ の特異値

分解で与えられ、 $\mathbf{F} = \mathbf{D}_r^{-1/2} \mathbf{K}_1 \mathbf{\Delta}_1$ を行の主座標、 $\mathbf{G} = \mathbf{D}_c^{-1/2} \mathbf{L}_1 \mathbf{\Delta}_1$ を列の主座標と呼ぶ。 δ_m^2 を軸 m の慣性と呼ぶ。

計算の手順

対応分析の計算を、行列の形で手順にまとめる。

1. 分割表 $\mathbf{O}$ から $\mathbf{P} = \mathbf{O}/n$ 、 $\mathbf{r} = \mathbf{P} \mathbf{1}_J$ 、 $\mathbf{c} = \mathbf{P}^\top \mathbf{1}_I$ を求め、 $\mathbf{D}_r = \text{diag}(\mathbf{r})$ 、 $\mathbf{D}_c = \text{diag}(\mathbf{c})$ を作る
2. 標準化残差行列 $\mathbf{S} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{D}_c^{-1/2}$ を作る
3. $\mathbf{S}$ を 1 回特異値分解し、 $\mathbf{S} = \mathbf{K} \mathbf{\Delta} \mathbf{L}^\top$ を得る
4. 軸の数 Q を決め、 $\mathbf{F} \leftarrow \mathbf{D}_r^{-1/2} \mathbf{K}_1 \mathbf{\Delta}_1$ 、 $\mathbf{G} \leftarrow \mathbf{D}_c^{-1/2} \mathbf{L}_1 \mathbf{\Delta}_1$ として、行の点と列の点を同じ平面に描く
5. 軸 m の慣性 δ_m^2 、寄与率 $\delta_m^2 / \sum_{m'} \delta_{m'}^2$ 、 χ^2 統計量 $n \sum_m \delta_m^2$ を求める

第 10 回の主成分分析の手順とは、次の点だけが違う。データ行列の代わりに、独立のモデルを引いて $\sqrt{r_i c_j}$ で割った $\mathbf{S}$ を分解し、得た特異ベクトルに重みを戻す ($\mathbf{D}_r^{-1/2}$ 、 $\mathbf{D}_c^{-1/2}$ を掛ける)。手順 2 を飛ばして $\mathbf{O}$ をそのまま分解すると、場面②のとおり 1 本目の軸が量に取られる。

理論の帰結：慣性と軸

導出から、対応分析の性質がいくつか読み取れる。まず特異値の側から見る。第 1 に、総慣性は軸ごとに分かれる。第 10 回と同じく、特異値分解では全マスの二乗和が特異値の二乗和に等しいので、

$$\frac{\chi^2}{n} = \|\mathbf{S}\|_F^2 = \sum_{m=1}^J \delta_m^2 = \underbrace{\sum_{m \leq Q} \delta_m^2}_{\text{地図が表す分}} + \underbrace{\sum_{m > Q} \delta_m^2}_{\min \mathcal{E}} \quad (17)$$

である。 Q 本の地図が表す慣性と、残る重み付き誤差の和が総慣性になる、ピタゴラスの分解である。 $\delta_m^2 / \sum_{m'} \delta_{m'}^2$ を軸 m の寄与率と呼ぶ。第 10 回と同じく累積寄与率は $1 - \min \mathcal{E} / \mathcal{E}_0$ であり、重み付き誤差の裏返しとして読める。図 5 は人工データの軸ごとの慣性であり、2 本で 82.1% を表す。

第 2 に、総慣性はマスごとにも分かれる。 $\chi^2 = \sum_{i,j} (\sqrt{n} s_{ij})^2$ であり、図 4 のように $\sqrt{n} s_{ij} = (o_{ij} - e_{ij}) / \sqrt{e_{ij}}$ を並べると、どのマスが χ^2 の大きさを作っているかが見える。人工データでは豚骨 × 深夜の 1 マスだけで χ^2 の 24% を占める。 χ^2 統計量は、これらを二乗して足した 1 つの数であり、行と列が独立かどうかを判定する χ^2 検定はこの 1 つの数だけを見る。対応分析は、同じ総慣性を、マスではなく軸に分けて地図にする。

第 3 に、軸の数は $J - 1$ 本を超えない。 $\mathbf{D}_c^{1/2} \mathbf{1}_J = (\sqrt{c_1}, \dots, \sqrt{c_J})^\top$ を右から掛けると

$$\mathbf{S} \mathbf{D}_c^{1/2} \mathbf{1}_J = \mathbf{D}_r^{-1/2} (\mathbf{P} \mathbf{1}_J - \mathbf{r} \mathbf{c}^\top \mathbf{1}_J) = \mathbf{D}_r^{-1/2} (\mathbf{r} - \mathbf{r}) = \mathbf{0} \quad (18)$$

となる。2 つ目の等号には (1) 式を用いた。 $\mathbf{S}$ には 0 に潰される向きが 1 本あるので、0 でない特異値は高々 $J - 1$ 個である。行プロファイルは足すと 1 になるので、 J 個の成分のうち自由に動けるのは $J - 1$ 個だけだ、




図 5: 人工のラーメン屋の表の、軸ごとの慣性 δ_m^2 と寄与率

ということの言い換えである。4 列の人工データでは、4 本目の特異値は $5e-17$ で、計算の誤差を除けば 0 になる。一般に、軸は $\min(I, J) - 1$ 本までである。

第 4 に、場面②の素朴な分解の 1 本目の正体がわかる。標準化の引き算をせず、 $\mathbf{P}$ をマスごとに $\sqrt{r_i c_j}$ で割っただけの行列は

$$\mathbf{D}_r^{-1/2} \mathbf{P} \mathbf{D}_c^{-1/2} = (\mathbf{D}_r^{1/2} \mathbf{1}_I)(\mathbf{D}_c^{1/2} \mathbf{1}_J)^\top + \mathbf{S} \quad (19)$$

と分かれる。第 1 項は独立の表 $\mathbf{r} \mathbf{c}^\top$ を割ったものであり、 $\mathbf{D}_r^{1/2} \mathbf{1}_I$ と $\mathbf{D}_c^{1/2} \mathbf{1}_J$ はどちらも長さ 1 ($\sum_i r_i = \sum_j c_j = 1$) なので、特異値 1 のランク 1 の行列である。(18) 式とその行の版 $\mathbf{1}_I^\top \mathbf{D}_r^{1/2} \mathbf{S} = \mathbf{0}^\top$ から、第 1 項と $\mathbf{S}$ は互いに直交な向きを使っている。そのため (19) 式を特異値分解すると、独立の表が特異値 1 の 1 本として分かれ、残りが $\mathbf{S}$ の特異値になる ($\delta_1 \leq 1$ が示せる)。場面②では割らずに $\mathbf{O}$ を分解したので厳密には一致しないが、1 本目がほぼ独立の表になったのは同じ理由である。対応分析で「独立のモデルを引く」ことは、この量だけを表す 1 本を先に取り除くことにあたる。

理論の帰結：地図の読み方

得られた点を 1 枚の地図に描くと、行と列の関連の形が見える。読み方を、行どうし、行と列、まれなカテゴリの順に述べる。

行の点どうしの距離は、行の形の χ^2 距離である。(12) 式に右から $\mathbf{L}$ を掛けると $\mathbf{S} \mathbf{L} = \mathbf{K} \mathbf{\Delta}$ であるから、すべての軸 ($Q = J$) を使った行の点は

$$\mathbf{F} = \mathbf{D}_r^{-1/2} \mathbf{K} \mathbf{\Delta} = \mathbf{D}_r^{-1} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{D}_c^{-1/2} \mathbf{L}, \quad \mathbf{f}_i^\top = (\mathbf{a}_i - \mathbf{c})^\top \mathbf{D}_c^{-1/2} \mathbf{L} \quad (20)$$

と書ける。 $\mathbf{L}$ は正方の正規直交行列で長さを変えないので、 $\|\mathbf{f}_i - \mathbf{f}_{i'}\|_2^2 = (\mathbf{a}_i - \mathbf{a}_{i'})^\top \mathbf{D}_c^{-1} (\mathbf{a}_i - \mathbf{a}_{i'}) =$

$d_\chi^2(\mathbf{a}_i, \mathbf{a}_{i'})$ となる。同じく $\|\mathbf{f}_i\|_2^2 = d_\chi^2(\mathbf{a}_i, \mathbf{c})$ であり、原点は平均の形にあたる。地図で近い行は、形の似た行である。ただし上位 Q 本だけを描いた地図では、捨てた軸の分だけ距離が縮む。人工データの味噌と豚骨の χ^2 距離は 0.988 であり、2 本の地図の上では 0.399 である (図 6 (a))。




図 6: 人工のラーメン屋の表の対応分析の地図(主座標)。(a) 行の点(点線は味噌と豚骨の距離)、(b) 列の点を重ね、豚骨と深夜の向きを矢印で示したもの

どの点がどれだけ縮んだかは、点ごとに測れる。行の点の長さの二乗 $\|\mathbf{f}_i\|_2^2 = \sum_m f_{im}^2$ のうち、地図の 2 本が表す割合 $(f_{i1}^2 + f_{i2}^2)/\|\mathbf{f}_i\|_2^2$ を、2 本で表す割合と呼ぶことにする(定義 5)。1 に近い点は地図の上の位置がほぼ正しく、0 に近い点は捨てた軸の方向に大きくずれている。人工データでは、醤油から順に 0.95、0.99、0.38、0.88、0.99 である。3 本目の軸が総慣性の 17.9% を持つので、その軸に沿って動く点は 2 本の地図では正しく描けない。夜に偏った味噌は割合が 0.38 しかなく、その形の違いの多くは 3 本目の軸に入っている。地図で近い 2 点を「形が似ている」と読む前に、両方の点がこの割合で 1 に近いかを確認する。

行と列を同じ平面に置けるのは、両者が互いの平均として結ばれているからである。 $\mathbf{SL}_1 = \mathbf{K}_1 \mathbf{\Delta}_1$ を (15) 式で書き直し、(18) 式から $\mathbf{c}^\top \mathbf{G} = \mathbf{0}^\top$ となることを用いると

$$\mathbf{F} = \mathbf{D}_r^{-1} \mathbf{P} \mathbf{G} \mathbf{\Delta}_1^{-1}, \quad \mathbf{G} = \mathbf{D}_c^{-1} \mathbf{P}^\top \mathbf{F} \mathbf{\Delta}_1^{-1} \quad (21)$$

を得る。 $\mathbf{D}_r^{-1} \mathbf{P}$ の第 i 行は行プロファイル $\mathbf{a}_i$ である。したがって行 i の点は、列の点をその行の形で重み付けして平均し、軸ごとに $1/\delta_m$ 倍に広げた位置にある。これを遷移公式(transition formula)と呼ぶ。豚骨は深夜の割合が大きいの、深夜の点の側に引き寄せられる。

ただし、行の点と列の点の距離には意味が無い。両者を結ぶのは (16) 式であり、 $o_{ij}/e_{ij} - 1$ は $\mathbf{f}_i$ と $\mathbf{g}_j$ の軸ごとの積を δ_m で割って足したもの、すなわち内積の仲間である。原点から見て同じ向きにあり、どちらも原点から遠いほど、そのマスは期待より多い。逆向きなら期待より少なく、直角なら期待に近い。図 6 (b) の豚骨と深夜は同じ向きに遠く、豚骨 $\times$ 深夜は期待の 2.63 倍である。

最後に、 χ^2 距離の重み $1/c_j$ には代償がある。列の周辺が小さいほど、同じ割合の差が重く効く。人工データでは、深夜($c_4 = 0.190$)の割合の差は、昼($c_1 = 0.273$)の同じ差の 1.4 倍に数えられる。この重みは、行の形を「起

きやすさ」でならして比べるためのものである。同じ形の 2 つの列をまとめても行の点が変わらない(分布同値性(distributional equivalence))という利点もある。一方で、ごくまれな列は少数の度数で大きく動き、地図の端に置かれやすい。実データでのこの影響は第 II 部の落とし穴で見る。

定義 5 (2 本で表す割合). 行の点 $\mathbf{f}_i$ (すべての軸) の長さの二乗 $\|\mathbf{f}_i\|_2^2 = d_\chi^2(\mathbf{a}_i, \mathbf{c})$ のうち、地図に描く上位 2 本の軸が表す割合 $(f_{i1}^2 + f_{i2}^2) / \|\mathbf{f}_i\|_2^2$ を、その点の 2 本で表す割合と呼ぶ。上位 Q 本についても同様に定める。

第 II 部 実データ解析

ラーメンの一覧と手続き

第 II 部では、即席麺の評価の一覧で対応分析を行う。The Ramen Rater というサイトの評者が、世界の即席麺を食べて星の数で評価してきた一覧である。TidyTuesday (2019 年 6 月 4 日) に収録されたものを一度だけ取得して保存した。1 件は評価された即席麺 1 品で、全 3,180 品ある。各品にはブランドの国と容器の形が記録されている。品数の多い 10 か国を行に、容器のうち袋・どんぶり・カップ・トレーの 4 つを列にとり、品数を数えて 10×4 の分割表 $\mathbf{O}$ ($n = 2,597$ 品) を作った。箱・缶など品数の少ない形の 37 品は除いた(箱を入れた場合は落とし穴で見る)。この表は評者が食べた品の一覧であって、各国で売られている即席麺の代表ではない。読み取れるのは、この一覧の中での国と容器の関連である。

図 7 (a) が表、(b) が国ごとの行プロファイルである。台湾やインドネシアは袋の割合が大きく、日本はどんぶり、米国はトレーの割合が大きい。この表も、場面②と同じくそのまま特異値分解すると、1 本目だけで二乗和の 91.8% を表し、その近似は独立の表とほとんど変わらない(差は最大 54.1 品)。




図 7: 即席麺の評価の一覧から作った、国 $\times$ 容器の分割表。(a) 品数、(b) 国ごとの容器の割合(行プロファイル)と平均の形

手続きは次のとおりである。表 $\mathbf{O}$ から I-6 の手順で $\mathbf{P}$ 、周辺 $\mathbf{r}$ 、 $\mathbf{c}$ 、標準化残差行列 $\mathbf{S}$ を作った。NumPy の特異値分解を 1 回計算して、特異値 δ_m と行の点 $\mathbf{F}$ 、列の点 $\mathbf{G}$ を得た。特異ベクトルの符号は決まらないので、軸 1 は袋、軸 2 はカップの座標が正になる向きにそろえた。結果は、SciPy の分割表の検定の関数が返す χ^2 統計量と比べ、さらに第 I 部の帰結を数値で確かめた。最後に、箱の列を足した表と、箱の品を動かした表で地図を描き

直した。

表 3 のとおり、自分の特異値分解から求めた $n \sum_m \delta_m^2$ は SciPy の χ^2 統計量と一致した。総慣性は 0.1758 であり、4 本目の特異値は計算の誤差の大きさに、帰結③のとおり軸は 3 本である。

表 3: 国 × 容器の表で、特異値の二乗和と χ^2 統計量

	値
$n \sum_m \delta_m^2$ (自分の特異値分解)	456.4234
χ^2 統計量(SciPy)	456.4234
総慣性 $\sum_m \delta_m^2 = \chi^2/n$	0.1758
4 本目の特異値	6e-17

表 4 は、ほかの帰結の確かめである。行の形どうしの χ^2 距離は、3 本すべての軸を使った行の点の距離と一致し、(20) 式が確かめられた。遷移公式 (21) 式も成り立ち、3 本の軸で (16) 式を計算すると元の品数が戻る。2 本で近似したときの重み付き誤差は、捨てた 3 本目の慣性 δ_3^2 に等しく、(14) 式のとおりである。

表 4: 国 × 容器の表で、第 I 部の帰結を数値で確かめたもの

確かめたこと	差の最大、または値
行の形の χ^2 距離と、行の点(3 本すべて)の距離	4e-16
遷移公式 (21) 式(2 本)	6e-16
3 本で表を戻したときの品数の差	6e-14
2 本の重み付き誤差と δ_3^2	0.01918 と 0.01918

地図を読む

図 8 は軸ごとの慣性である。1 本目が 69.0%、2 本目が 20.0% で、2 本の地図は総慣性の 89.1% を表す。残る 10.9% は地図には描かれない。

図 9 が 2 本の地図(主座標)である。軸 1 の右には袋、左にはトレーとどんぶりがある。国の点は、袋の多い台湾・マレーシア・インドネシアが右に、容器入りの多い日本・米国が左に並ぶ。軸 1 は「袋か、容器か」の軸と読める。軸 2 の上にはカップ、下にはどんぶりがある。カップの多いシンガポール・香港・タイが上に、どんぶりの多い中国・台湾が下に並ぶ。韓国は原点の近くにあり、容器の割合が平均の形に近い。

行と列の点の関係は、距離ではなく向きで読む(帰結⑧)。表 5 には、いくつかのマスについて、観測が期待度数の何倍かと、2 本の地図から (16) 式で計算した近似を並べた。台湾と袋は同じ向き(右)にあり、台湾 × 袋は期待の 1.45 倍である。台湾とカップは逆向きにあり、台湾のカップは 2 品しかない。インドネシアのどんぶりは 0 品で、倍率 0 であり、地図の近似もそれに近い値を返す。




図 8: 国 × 容器の表の、軸ごとの慣性 δ_m^2 と寄与率




図 9: 国 × 容器の表の対応分析の地図(主座標)。青の丸が国、赤の三角が容器

表 5: 国 × 容器の表で、観測が期待度数の何倍かと、2 本の地図による近似 (16) 式

マス	観測	期待度数	何倍か	2 本の地図の近似
台湾 × 袋	265	182.2	1.45	1.45
台湾 × カップ	2	52.0	0.04	0.04
米国 × トレー	53	19.6	2.70	1.69
日本 × どんぶり	185	114.2	1.62	1.51

マス	観測	期待度数	何倍か	2本の地図の近似
シンガポール × カップ	34	21.7	1.57	1.55
インドネシア × どんぶり	0	32.3	0.00	0.15

まれな列と、描かれない軸

帰結⑨で見たとおり、 χ^2 距離は列の周辺 c_j で割るので、まれな列ほど重く効く。図 10 は、除いていた箱(30品、全体の 1.1%)を 5 列目として足した表の地図である。箱は地図の端に置かれ、品数ではわずかなのに総慣性の 6.8% を作る。さらに、インドネシアの箱の品数を 1 品ずつ 4 品まで増やすと、箱の点は紫の線のように 0.23 動く。同じ 4 品をインドネシアの袋に足しても、袋の点は 0.001 しか動かない。品数の少ない列の位置は、数品の出入りで大きく変わる。地図の端にある小さなカテゴリを読むときは、その度数を確かめる必要がある。




図 10: 箱の列を足した国 × 容器の表の地図。紫の線は、インドネシアの箱を 0 品から 4 品まで足したときの箱の点の動き

もう 1 つは、2 本の地図に描かれない軸である。地図の上の距離は、捨てた軸の分だけ縮む(帰結⑤)。日本と米国は図 11 のように地図の上では 0.163 しか離れていないが、行の形の χ^2 距離は 0.410 である。日本はどんぶりが期待の 1.62 倍、米国はトレーが 2.70 倍で、この違いは 3 本目の軸に入っている。帰結⑥の 2 本で表す割合は、米国で 0.64、日本で 0.94 であった。地図で近い 2 点を「形が似ている」と読む前に、その点が 2 本でよく表されているかを確かめる。




図 11: 国 × 容器の表の地図(国の点)。点線は日本と米国の距離

締め

まとめと次回の問い

本章の問いは、行と列が両方カテゴリのとき、その関連の形をどう取り出すか、であった。分割表をデータ行列とみてそのまま特異値分解すると、1 本目の軸は行と列の大きさから作った独立の表を拾うだけになる。そこで、独立のモデル $\mathbf{P} = \mathbf{r}\mathbf{c}^\top$ にランク Q のずれ $\mathbf{D}_r\mathbf{B}\mathbf{D}_c$ を足したモデルを、重み $1/(r_i c_j)$ を付けた重み付き最小二乗法で当てはめた。重みは、行の形を χ^2 距離で比べることにあたる。目的関数は標準化残差行列 $\mathbf{S}$ の低ランク近似 $\|\mathbf{S} - \mathbf{Y}\|_F^2$ に書き直せるので、第 10 回の Eckart–Young の定理により、 $\mathbf{S}$ を 1 回特異値分解すれば解ける。独立のモデルで残る誤差は総慣性 $\chi^2/n = \sum_m \delta_m^2$ であり、寄与率は第 10 回と同じく、重み付き誤差の裏返しとして読める。行の点どうしの距離は χ^2 距離、行と列は向きで読む。即席麺の一覧の国 × 容器の表では、2 本の軸が総慣性の 89.1% を表し、軸 1 は袋か容器か、軸 2 はカップかどんぶりかと読めた。まれな箱の列は数品の出入りで大きく動き、日本と米国の違いは 2 本の地図には描かれなかった。

本章の手順は 2 つのカテゴリの表に限られる。3 つ以上のカテゴリを同時に扱うには、1 品ごとに各カテゴリの 0/1 を並べた指示行列を作り、同じ手順を当てる。これを多重対応分析と呼ぶ。

同じ学期の演習 14 では、映画のジャンル × 年代のクロス表(延べ 18,544 本)を対応分析にかけた。 χ^2 は 548.4 で、総慣性は $548.4 \div 18,544 = 0.0296$ であった。2 本の軸で 83.9% (67.3% と 16.6%) を表し、横軸は時代の軸であった。本章の言葉で言えば、総慣性は独立のモデルで残る重み付き誤差 χ^2/n である。83.9% は 2 本の低ランク近似の累積寄与率、時代の軸は標準化残差行列の 1 本目の特異ベクトルにあたる。

最後に、次回への問いを置く。地図は総慣性を軸に分けて全体の形を見せたが、同じ総慣性はマスごとにも分か

れる(帰結②)。国 × 容器の表では、台湾 × カップの $(o - e)/\sqrt{e}$ は -6.94、韓国 × カップは -1.69 である。独立のモデルを表から推定した後に残ったこの 1 マスのずれは、大きいのか。次回は、残差を何で割れば比べられるかという問いに答える。