第 15 回 ネットワーク分析②

データ行列から、つながりの表を罰則付き最尤法で作る（最終回）

最終回の問いは、第 14 回の締めで残った「データ行列から、変数どうしのつながりの表を作れるか」である。相関で線を引くと、間に別の変数をはさんだだけの組までつながる。そこで、ほかの変数を固定したときの関係（偏相関）を見る。多変量正規分布では、それは精度行列 $\boldsymbol{\Theta} = \boldsymbol{\Sigma}^{-1}$ の成分に現れ、$\theta_{jk} = 0$ なら線は無い。精度行列を最尤法で推定すると答えは $\mathbf{S}^{-1}$ で、列が行より多いと存在せず、0 もちょうどには出ない。そこで第 4 回の ℓ_1 罰則を足す（Graphical Lasso）。最適性の条件を列ごとに書くと、第 4 回の Lasso と同じ形になり、座標降下で解ける。λ が大きいと変数は塊に分かれ、λ は第 9 回の BIC で選ぶ。最後に、全 15 回を「モデル × 推定法」の地図にまとめる。

第 I 部　理論

変数どうしのつながり

第 14 回の締めで、データ行列から変数どうしのつながりの表を作れるか、という問いを置いた。本章の問いはこれである。人工的なデータで考える。$n = 200$ 行、$p = 8$ 列のデータ行列で、列どうしの本当のつながりは 2 本の鎖（1 − 2 − 3 − 4 と 5 − 6 − 7 − 8）になるように作った（作り方は後で述べる）。

素朴には、列どうしの相関を計算し、絶対値の大きい組に線を引く（図 1）。相関の絶対値が 0.2 を超える組を結ぶと、線は 9 本になる。

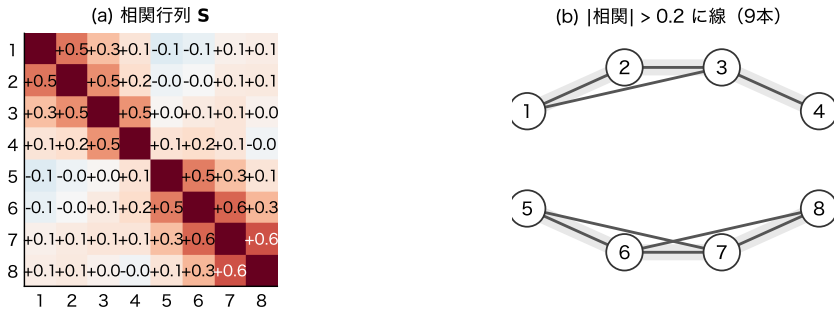


図 1: 人工データ（8 列）の (a) 相関行列と、(b) 相関の絶対値が 0.2 を超える組に引いた線。灰色の太線は本当のつながり（鎖 2 本）

困りごとが 3 つある。1 つ目は、間をはさんだ組である。1 と 3 は直接にはつながっていないが、どちらも 2 とつながっているので、相関は 0.30 になる。相関は、間に別の変数をはさんだだけの組まで拾う。2 つ目は、どこで切るかである。線を引く相関の大きさを 0.1、0.2、0.3、0.4 と変えると、線は 18、9、8、6 本と変わり、どこで切るかの根拠が無い。3 つ目は、行の数である。最初の 6 行だけで分散共分散行列 $\mathbf{S}$ を作ると、8×8 なのにランクは 5 しかなく、逆行列が無い。第 3 回で、列が行より多いと $\mathbf{X}^\top\mathbf{X}$ が逆行列を持たないことを見た。それと同じである。

本章では、ほかの列を固定したときの関係を行列で書き、それを罰則付きの最尤法で推定する。第 4 回の ℓ_1 罰則(Lasso)と第 11 回の最尤法を組み合わせた形であり(表 1)、解き方は列ごとの Lasso に帰着する。

表 1: 本章の位置づけ

モデル	推定法	罰則	回
線形回帰	最小二乗法	ℓ_1（Lasso）	第 4 回
因子分析	最尤法	—	第 11 回
$\boldsymbol{\Sigma} = \mathbf{A}\mathbf{A}^\top + \boldsymbol{\Psi}$			
ガウシアングラフィカルモデル	最尤法	ℓ_1	本章
$\boldsymbol{\Theta} = \boldsymbol{\Sigma}^{-1}$			

道具：尤度・微分・ブロック・しきい値

本章で使う道具を先にそろえる。

1 つ目は、多変量正規分布の対数尤度である。平均 0、分散共分散行列 $\boldsymbol{\Sigma}$ の p 変量正規分布から n 行が独立に得られたとき、$\mathbf{S} = \mathbf{X}^\top\mathbf{X}/n$ を使って

$$\ell(\boldsymbol{\Sigma}) = -\frac{n}{2}\Big(\log\det\boldsymbol{\Sigma} + \operatorname{tr}\big(\mathbf{S}\boldsymbol{\Sigma}^{-1}\big)\Big) + \text{定数} \tag{1}$$

となる。第 11 回の因子分析で使った式と同じである。

2 つ目は、行列の微分である。対称行列 $\boldsymbol{\Theta}$ について $\partial\log\det\boldsymbol{\Theta}/\partial\boldsymbol{\Theta} = \boldsymbol{\Theta}^{-1}$、$\partial\operatorname{tr}(\mathbf{S}\boldsymbol{\Theta})/\partial\boldsymbol{\Theta} = \mathbf{S}$ が成り立つ。第 11 回と同じく結果だけを使う。1×1 なら $(\log\theta)' = 1/\theta$、$(s\theta)' = s$ である。

3 つ目は、ブロックに分けた逆行列である(定義 1)。$\boldsymbol{\Sigma}$ と $\boldsymbol{\Theta} = \boldsymbol{\Sigma}^{-1}$ を、最後の列とそれ以外に分ける。$\boldsymbol{\Sigma}\boldsymbol{\Theta} = \mathbf{I}$ の最後の列を、上の $p-1$ 成分と最後の成分に分けて書くと

$$\boldsymbol{\Sigma}_{11}\boldsymbol{\theta}_{12} + \boldsymbol{\sigma}_{12}\theta_{22} = 0, \qquad \boldsymbol{\sigma}_{12}^\top\boldsymbol{\theta}_{12} + \sigma_{22}\theta_{22} = 1$$

である。1 つ目から $\boldsymbol{\theta}_{12} = -\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\sigma}_{12}\theta_{22}$、これを 2 つ目に代入して

$$\theta_{22} = \frac{1}{\sigma_{22} - \boldsymbol{\sigma}_{12}^\top \boldsymbol{\Sigma}_{11}^{-1} \boldsymbol{\sigma}_{12}}, \qquad \boldsymbol{\theta}_{12} = -\boldsymbol{\Sigma}_{11}^{-1} \boldsymbol{\sigma}_{12}\, \theta_{22} \tag{2}$$

を得る。

4 つ目は、軟しきい値である。$a > 0$ のとき、$\frac{a}{2}b^2 - cb + \lambda|b|$ を最小にする b は $\hat{b} = \mathrm{soft}(c, \lambda)/a$ で、$\mathrm{soft}(c, \lambda) = \mathrm{sign}(c)\max(|c| - \lambda, 0)$ である（定義 2）。$|c| \le \lambda$ ならちょうど 0 になる。第 4 回で Lasso を座標降下で解いたときの 1 変数の答えと同じである。

定義 1 (ブロックに分けた逆行列)**.** 対称で逆行列を持つ $\boldsymbol{\Sigma}$ を最後の列とそれ以外に分け、$\boldsymbol{\Theta} = \boldsymbol{\Sigma}^{-1}$ も同じく分ける。このとき $\theta_{22} = 1/(\sigma_{22} - \boldsymbol{\sigma}_{12}^\top \boldsymbol{\Sigma}_{11}^{-1} \boldsymbol{\sigma}_{12})$、$\boldsymbol{\theta}_{12} = -\boldsymbol{\Sigma}_{11}^{-1} \boldsymbol{\sigma}_{12} \theta_{22}$ である。

定義 2 (軟しきい値)**.** $a > 0$ のとき、$\frac{a}{2}b^2 - cb + \lambda|b|$ を最小にする b は $\mathrm{soft}(c, \lambda)/a$ である。$\mathrm{soft}(c, \lambda) = \mathrm{sign}(c)\max(|c| - \lambda, 0)$ を軟しきい値と呼ぶ。

精度行列と条件付き独立

「ほかの列を固定したときの関係」を行列で書く。行 $\boldsymbol{x}$ が平均 0、分散共分散行列 $\boldsymbol{\Sigma}$ の p 変量正規分布に従うとし、その逆行列 $\boldsymbol{\Theta} = \boldsymbol{\Sigma}^{-1}$ を精度行列（precision matrix）と呼ぶ。

最後の列 x_p を、残りの列 $\boldsymbol{x}_{-p}$ で回帰することを考える。正規分布では、残りの列を固定したときの x_p の平均は $\boldsymbol{x}_{-p}$ の 1 次式で、係数は第 1 回の正規方程式の母集団版 $\boldsymbol{\beta} = \boldsymbol{\Sigma}_{11}^{-1} \boldsymbol{\sigma}_{12}$ である。その分散は、説明できなかった分 $\sigma_{22} - \boldsymbol{\sigma}_{12}^\top \boldsymbol{\Sigma}_{11}^{-1} \boldsymbol{\sigma}_{12}$ である。定義 1 と見比べると

$$\boldsymbol{\beta} = -\frac{\boldsymbol{\theta}_{12}}{\theta_{22}}, \qquad \mathbb{V}\mathrm{ar}(x_p \mid \boldsymbol{x}_{-p}) = \frac{1}{\theta_{22}} \tag{3}$$

となる。精度行列の列は、その列を残りで回帰したときの係数と、説明しきれなかった分散を表している。どの列を最後に置いても同じなので、$\theta_{jk} = 0$ は「x_j を残りで回帰したとき x_k の係数が 0」と同じである。正規分布では、これは x_j と x_k が、ほかの列を固定すると独立であることを意味する（条件付き独立（conditional independence））。ほかの列を固定したときの相関、すなわち偏相関（partial correlation）は

$$\rho_{jk \cdot \mathrm{rest}} = -\frac{\theta_{jk}}{\sqrt{\theta_{jj}\theta_{kk}}} \tag{4}$$

で、$\theta_{jk} = 0$ なら 0 になる（定義 3）。

傘と長靴の売上で考えると分かりやすい（図 2）。雨の多い日にはどちらもよく売れるので、2 つの売上には相関がある。しかし雨の量を固定すると、関係はほとんど消える。線を引くべきは「雨 − 傘」と「雨 − 長靴」だけで、「傘 − 長靴」には引かない。困りごと①の 1 と 3 も同じで、2 をはさんでいるだけである。

そこで、精度行列の 0 でないところに線を引く。この組をガウシアングラフィカルモデル（Gaussian graphical model）と呼ぶ。つながりの表は、$\boldsymbol{\Theta}$ の 0 の並びである。人工データの本当の精度行列は、鎖の隣どうしだけが -0.45、対角が 1、ほかは 0 になるように作った。

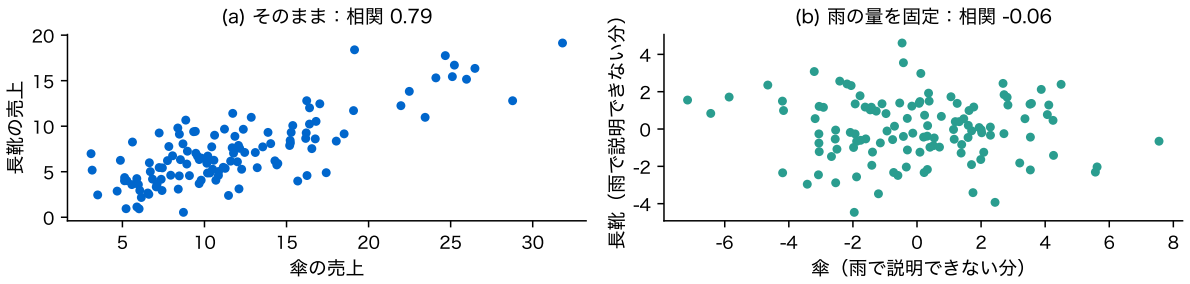


図 2: 傘と長靴の売上(概念図)。(a) そのまま、(b) 雨の量で説明できない分どうし

精度行列を最尤法で推定する。(1) 式に $\boldsymbol{\Sigma}^{-1} = \boldsymbol{\Theta}$、$\log\det\boldsymbol{\Sigma} = -\log\det\boldsymbol{\Theta}$ を入れると

$$\ell(\boldsymbol{\Theta}) = \frac{n}{2}\Big(\log\det\boldsymbol{\Theta} - \operatorname{tr}(\mathbf{S}\boldsymbol{\Theta})\Big) + \text{定数} \tag{5}$$

となる。道具②で微分して 0 とおくと $\boldsymbol{\Theta}^{-1} = \mathbf{S}$、すなわち $\hat{\boldsymbol{\Theta}} = \mathbf{S}^{-1}$ である。しかし、$\mathbf{S}$ に逆行列が無ければ存在しない(困りごと③)。あっても、データの揺れのため成分がちょうど 0 になることはない。どの成分を 0 とみなすかは、困りごと②と同じく決められない。

そこで、第 4 回の Lasso と同じく ℓ_1 罰則を足す。

$$\max_{\boldsymbol{\Theta}} \ \log\det\boldsymbol{\Theta} - \operatorname{tr}(\mathbf{S}\boldsymbol{\Theta}) - \lambda\|\boldsymbol{\Theta}\|_1, \qquad \|\boldsymbol{\Theta}\|_1 = \sum_{j,k}|\theta_{jk}| \tag{6}$$

これを Graphical Lasso と呼ぶ(Friedman ほか 2008)。λ が大きいほど、ちょうど 0 になる成分が増える。

定義 3 (精度行列とガウシアングラフィカルモデル)**.** p 変量正規分布の分散共分散行列の逆行列 $\boldsymbol{\Theta} = \boldsymbol{\Sigma}^{-1}$ を精度行列と呼ぶ。$\theta_{jk} = 0$ のとき、x_j と x_k はほかの変数を固定すると独立であり、偏相関 $-\theta_{jk}/\sqrt{\theta_{jj}\theta_{kk}}$ は 0 である。$\theta_{jk} \neq 0$ の組に線を引いたグラフを、ガウシアングラフィカルモデルと呼ぶ。

列ごとの Lasso で解く

(6) 式を解く。導出には、道具② (行列の微分)、道具③ (ブロックに分けた逆行列)、道具④ (軟しきい値)を使う。

まず、$\boldsymbol{\Theta}$ で微分して 0 とおく。$\mathbf{W} = \boldsymbol{\Theta}^{-1}$ と書くと、道具②より $\log\det\boldsymbol{\Theta}$ の微分は $\mathbf{W}$、トレースの微分は $\mathbf{S}$ である。$|\theta|$ は 0 で尖っているので、第 4 回と同じく、傾きを $\theta \neq 0$ なら $\operatorname{sign}(\theta)$、$\theta = 0$ なら -1 以上 1 以下のどれかとする。すると最適の条件は

$$\mathbf{W} - \mathbf{S} - \lambda\boldsymbol{\Gamma} = \mathbf{O} \tag{7}$$

となる。$\boldsymbol{\Gamma}$ はその傾きを並べた行列である。精度行列の対角は、(3) 式より説明しきれなかった分散の逆数で正なので、$\gamma_{jj} = 1$、すなわち $w_{jj} = s_{jj} + \lambda$ が初めから決まる。

次に、最後の列を取り出す。$\mathbf{W}\boldsymbol{\Theta} = \mathbf{I}$ の最後の列の上のブロックは $\mathbf{W}_{11}\boldsymbol{\theta}_{12} + \boldsymbol{w}_{12}\theta_{22} = 0$ である。$\boldsymbol{\beta} = -\boldsymbol{\theta}_{12}/\theta_{22}$ とおくと

$$\boldsymbol{w}_{12} = \mathbf{W}_{11}\boldsymbol{\beta}$$

を得る。$\boldsymbol{\beta}$ は、(3) 式の回帰の係数にあたる。(7) 式の最後の列の上のブロック $\boldsymbol{w}_{12} - \boldsymbol{s}_{12} - \lambda\boldsymbol{\gamma}_{12} = 0$ にこれを入れる。$\theta_{22} > 0$ なので θ_{jk} と β_k の符号は逆で、$-\boldsymbol{\gamma}_{12}$ は $\boldsymbol{\beta}$ の傾きになる。したがって

$$\mathbf{W}_{11}\boldsymbol{\beta} - \boldsymbol{s}_{12} + \lambda\boldsymbol{\gamma} = 0, \qquad \gamma_k \in \partial|\beta_k| \tag{8}$$

となる。これは

$$\min_{\boldsymbol{\beta}} \ \frac{1}{2}\boldsymbol{\beta}^\top\mathbf{W}_{11}\boldsymbol{\beta} - \boldsymbol{s}_{12}^\top\boldsymbol{\beta} + \lambda\|\boldsymbol{\beta}\|_1 \tag{9}$$

の最適の条件そのものである。$\mathbf{W}_{11} = \mathbf{X}^\top\mathbf{X}/n$、$\boldsymbol{s}_{12} = \mathbf{X}^\top\boldsymbol{y}/n$ なら、$\frac{1}{2n}\|\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \lambda\|\boldsymbol{\beta}\|_1$ を展開して定数を除いたものに等しく、第 4 回の Lasso になる。

(9) 式は、第 4 回と同じく座標降下で解ける。ほかの成分を固定すると、β_k だけの問題は $\frac{a}{2}\beta_k^2 - c\beta_k + \lambda|\beta_k|$ の形になり、$a = [\mathbf{W}_{11}]_{kk}$、$c = s_{12,k} - \sum_{l\neq k}[\mathbf{W}_{11}]_{kl}\beta_l$ である。道具④より $\beta_k \leftarrow \mathrm{soft}(c,\lambda)/a$ と更新する。

最後に、列を回す。どの列も「最後の列」として扱えるので、列を 1 本ずつ取り出して (9) 式を解き、$\boldsymbol{w}_{12} \leftarrow \mathbf{W}_{11}\hat{\boldsymbol{\beta}}$ と書き換える。$\mathbf{W}$ が変わらなくなったら止め、道具③で $\hat{\theta}_{22} = 1/(w_{22} - \boldsymbol{w}_{12}^\top\hat{\boldsymbol{\beta}})$、$\hat{\boldsymbol{\theta}}_{12} = -\hat{\boldsymbol{\beta}}\hat{\theta}_{22}$ として $\boldsymbol{\Theta}$ に戻す。$\hat{\beta}_k = 0$ なら $\hat{\theta}_{jk} = 0$ で、線は引かれない(定義 4)。

計算の手順

Graphical Lasso の計算を、行列の形でまとめる(Friedman ほか 2008)。

1. 列を標準化して $\mathbf{S}$ を作り、$\mathbf{W} \leftarrow \mathbf{S} + \lambda\mathbf{I}$ とする(導出①より対角は $s_{jj} + \lambda$ のまま変わらない)
2. 列 $j = 1, \ldots, p$ を順に「最後の列」として、$\mathbf{W}_{11}$ と $\boldsymbol{s}_{12}$ を取り出す
3. (9) 式を座標降下で解く
4. $\boldsymbol{w}_{12} \leftarrow \mathbf{W}_{11}\hat{\boldsymbol{\beta}}$ と書き換える。$\mathbf{W}$ が変わらなくなるまで 2〜4 を繰り返す
5. 道具③で $\hat{\boldsymbol{\Theta}}$ に戻し、0 でない組に線を引く

第 4 回の Lasso は、1 本の $\boldsymbol{y}$ を $\mathbf{X}$ で回帰する問題を 1 回解いた。ここでは、どの列も順に $\boldsymbol{y}$ の役になり、$\mathbf{X}^\top\mathbf{X}/n$ の代わりに、書き換えていく $\mathbf{W}_{11}$ を使う。列の数だけ Lasso を解き、それを何周か繰り返す。

定義 4 (Graphical Lasso)**.** $\log\det\boldsymbol{\Theta} - \mathrm{tr}(\mathbf{S}\boldsymbol{\Theta}) - \lambda\|\boldsymbol{\Theta}\|_1$ を最大にする $\hat{\boldsymbol{\Theta}}$ を求め、$\hat{\theta}_{jk} \neq 0$ の組に線を引く方法を Graphical Lasso と呼ぶ。$\mathbf{W} = \hat{\boldsymbol{\Theta}}^{-1}$ の列ごとに、$\frac{1}{2}\boldsymbol{\beta}^\top\mathbf{W}_{11}\boldsymbol{\beta} - \boldsymbol{s}_{12}^\top\boldsymbol{\beta} + \lambda\|\boldsymbol{\beta}\|_1$ の Lasso を解く操作を繰り返して求める。

理論の帰結：罰則が決めるもの

罰則の強さ λ を動かすと、何が起きるかを見る。

第 1 に、λ を上げるほど偏相関は 0 へ縮み、ちょうど 0 になった組から線が消える（図 3）。人工データでは本当でない線が先に消え、λ が 0.375〜0.45 では本当の鎖の 6 本だけが残った。さらに上げると、本当の線も消えていく。$\lambda = 0$ では最尤推定 $\mathbf{S}^{-1}$ に戻り、どの組にも線が引かれる。

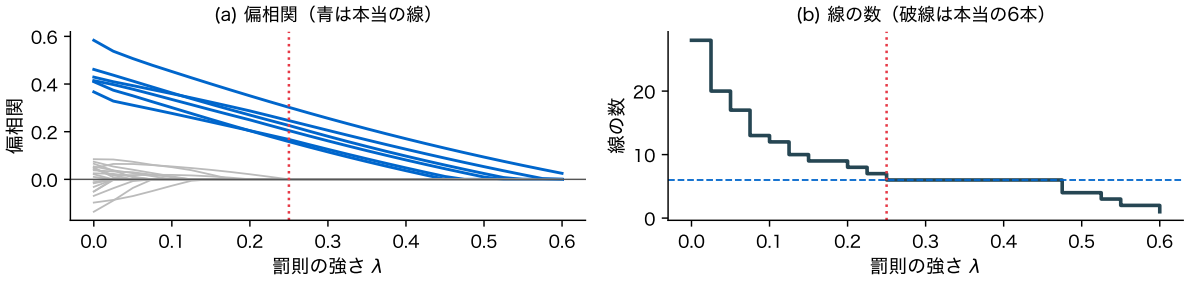


図 3: 人工データの Graphical Lasso で、罰則の強さ λ を動かしたときの (a) 偏相関と (b) 線の数。青は本当の線、赤い点線は BIC で選んだ λ

第 2 に、行が列より少なくても解ける。$\mathbf{W}$ は $\mathbf{S} + \lambda\mathbf{I}$ から始まり、$\lambda > 0$ なら固有値はどれも λ 以上になる。各列の Lasso の $\mathbf{W}_{11}$ は逆行列を持ち、答えの $\hat{\boldsymbol{\Theta}} = \mathbf{W}^{-1}$ も存在する。困りごと③の 6 行（ランク 5）でも、$\lambda = 0.3$ で推定できた（図 4）。ただし 6 行では情報が足りず、本当の 6 本のほかに、本当でない線も 13 本残った。

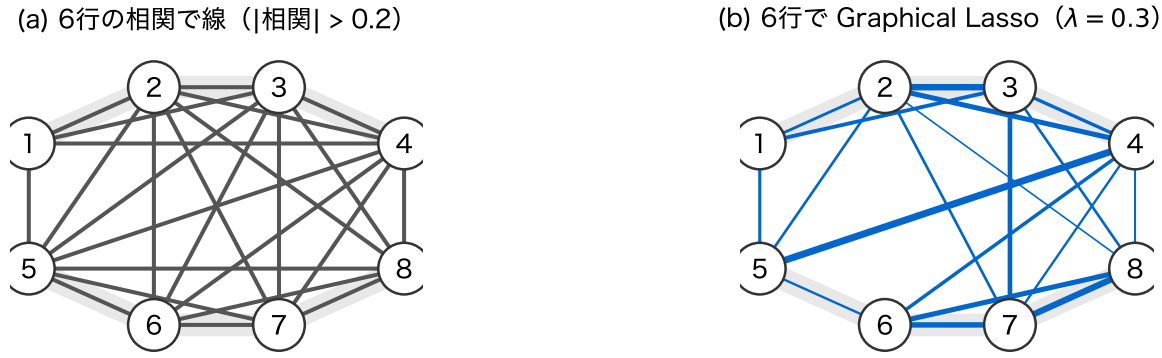


図 4: 人工データの最初の 6 行だけで、(a) 相関で引いた線と (b) Graphical Lasso（$\lambda = 0.3$）の線。灰色の太線は本当のつながり、線の色は偏相関の符号（青が正）

第 3 に、λ が大きいと、列は塊に分かれる（定理 1）。列が 2 つの塊 C_1、C_2 に分かれ、塊をまたぐ相関がどれも $|s_{jk}| \le \lambda$ だとする。それぞれの塊だけで (6) 式を解いた $\hat{\boldsymbol{\Theta}}_1$、$\hat{\boldsymbol{\Theta}}_2$ を対角に並べた行列を考える。その逆行列 $\mathbf{W}$ も同じく対角に並ぶので、またぐ組では $w_{jk} = 0$、$\theta_{jk} = 0$ である。(7) 式は $0 - s_{jk} - \lambda\gamma_{jk} = 0$ となり、

$\gamma_{jk} = -s_{jk}/\lambda$ は -1 以上 1 以下なので選べる。塊の中の条件は、塊ごとに解いたので満たされている。(6) 式の目的関数は上に凸で答えは 1 つなので、これが答えである。第 14 回では、固有値 0 の数が線でつながった塊の数になった。ここでは、相関の小さな組を見るだけで、塊が前もって分かる。

定理 1 (塊に分かれる条件)**.** 列が C_1 と C_2 に分かれ、$j \in C_1$、$k \in C_2$ のすべてで $|s_{jk}| \le \lambda$ なら、*Graphical Lasso* の答えは $\hat{\theta}_{jk} = 0$（塊の間に線が無い）である。

第 4 に、間をはさんだ組の線は消える。BIC で選んだ $\lambda = 0.25$ では、残った線は 6 本で、本当の鎖と一致した（図 5）。相関で引いた線にあった 1 と 3 の線は消えた。偏相関は、2 を固定したときの 1 と 3 の関係を測るからである。

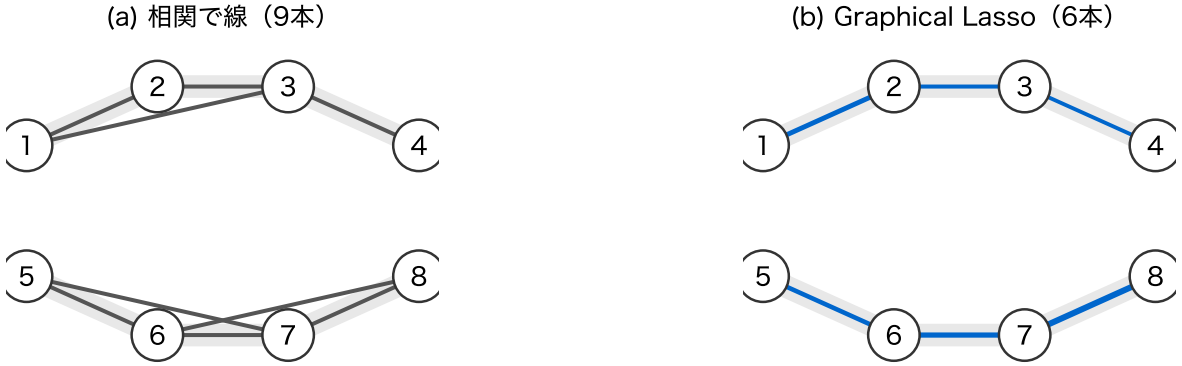


図 5: 人工データ（200 行）の (a) 相関で引いた線と (b) BIC で選んだ λ の Graphical Lasso の線。灰色の太線は本当のつながり、線の色は偏相関の符号（青が正）と大きさ

第 5 に、λ は第 9 回の BIC で選ぶ。λ ごとに線の並びが決まるので、それぞれの線の並びを 1 つのモデルとみる。モデルの比べ方は第 9 回と同じく、そのモデルの最尤推定で測った -2ℓ に、推定した数（線の数と対角の p 個）の $\log n$ 倍を足す。罰則で縮んだ推定値のままでは尤度が小さく出るので、選んだ線だけを持つモデルを罰則なしで推定し直した $\tilde{\boldsymbol{\Theta}}_\lambda$ で測る。これは、線の無い組の罰則を大きく、線のある組の罰則を 0 にして同じ手順を回せば求まる。

$$\mathrm{BIC}(\lambda) = -2\ell(\tilde{\boldsymbol{\Theta}}_\lambda) + \log n \times (\text{線の数} + p) \tag{10}$$

人工データでは、$\lambda = 0.25$ で最小になった（図 6）。困りごと②の「どこで切るか」を、相関の大きさではなく BIC で決めたことになる。

最後に、近道を述べる。$\mathbf{W}_{11}$ を書き換えず $\mathbf{S}_{11}$ のまま、列ごとに (9) 式を 1 回ずつ解き、β_{jk} と β_{kj} のどちらかが 0 でなければ線を引く方法がある（近傍選択、Meinshausen & Bühlmann 2006）。各列を残りの列で Lasso 回帰するのと同じで、第 4 回の手順をそのまま p 回使う。人工データでは、同じ λ で Graphical Lasso と同じ線になった。ただし近道は、精度行列そのものは出さない。

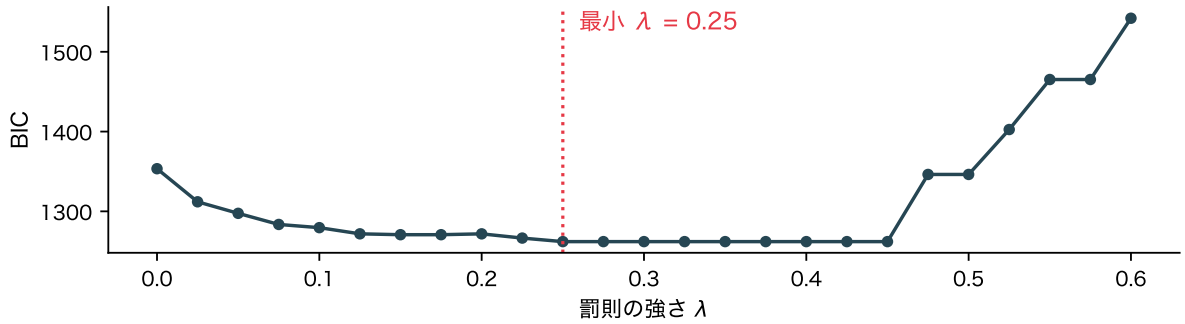


図 6: 人工データの BIC（選んだ線で推定し直した対数尤度で測った）。赤い点線が最小

第 II 部　実データ解析

株価と手続き

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、本当のつながりが鎖になるように作った。実データは理論どおりにいくとは限らない。外れたときは、その理由を第 I 部の道具で考える。

使うデータは、米国の大企業の株価（S&P 500）である。R の huge パッケージ（Zhao ほか 2012）に収められた、452 銘柄の 2003〜2007 年の終値と業種の分類を使った。日々の値動きを、終値の対数の差（対数収益率）で測る。株式分割などで 1 日に ±30% を超えて値が飛ぶ銘柄を除き、エネルギー・公益（電力とガス）・金融・IT・ヘルスケアの 5 業種から、銘柄記号のアルファベット順に 8 銘柄ずつ、計 40 銘柄を選んだ。期間は 2007 年の 251 営業日である。業種の分類は計算には使わず、答え合わせだけに使う。

第 I 部からは、次の 4 つを予想した。第 1 に、相関で線を引くと、ほとんどすべての組がつながる。株価は市場全体の上げ下げにつられて一緒に動くからである。傘と長靴の売上が雨につられて一緒に動くのと同じで、市場全体が共通の原因にあたる。第 2 に、市場の動きを引いてから Graphical Lasso をかけ、BIC で λ を選ぶと、同じ業種どうしの線が残る。同じ業種の会社は、同じ材料（原油の値段、金利、規制）に反応するからである。第 3 に、どの業種でも業種の中の線が密になる。第 4 に、λ を上げると、業種ごとの塊に分かれる（定理 1）。

手続きは次のとおりである。市場の動きとして、除いた後に残った 275 銘柄の平均の収益率を使った。各銘柄の収益率を市場の動きで回帰し（第 1 回）、その残りを標準化して相関行列 $\mathbf{S}$（40×40）を作った。これに I-6 の手順で Graphical Lasso をかけ、λ を 0.1 から 0.45 まで 0.025 刻みで動かし、(10) 式の BIC が最小のものを選んだ。

結果：業種のつながり

結果は次のとおりである。まず、市場の動きを引く前の相関は、780 組のどれも正で、最小 0.05、平均 0.38 だった（図 7）。相関で線を引けば、ほとんどすべての組がつながる。予想どおりである。

市場の動きを引いた残りに Graphical Lasso をかけると、BIC は $\lambda = 0.2$ で最小になった。残った線は 780 組

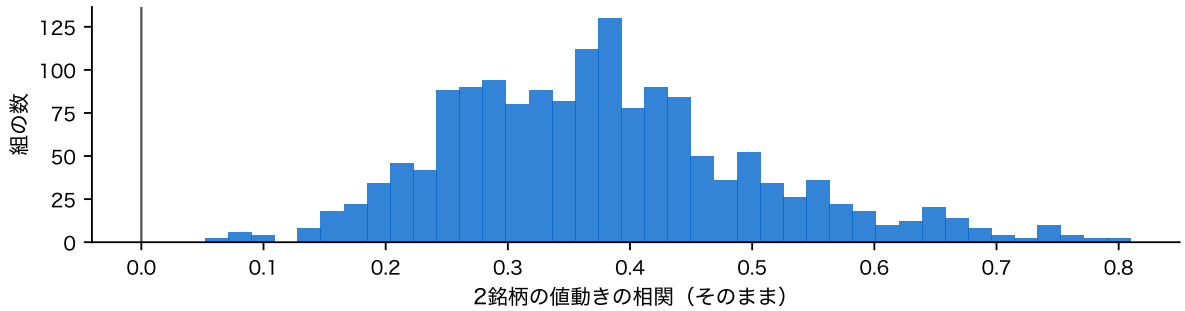


図 7: S&P 500 の 40 銘柄(2007 年)の、2 銘柄ずつの値動きの相関(市場の動きを引く前)

のうち 74 本で、その 82% が同じ業種どうしである(図 8)。でたらめに線を引けば同じ業種どうしは 18% なので、予想どおり業種の線が残った。

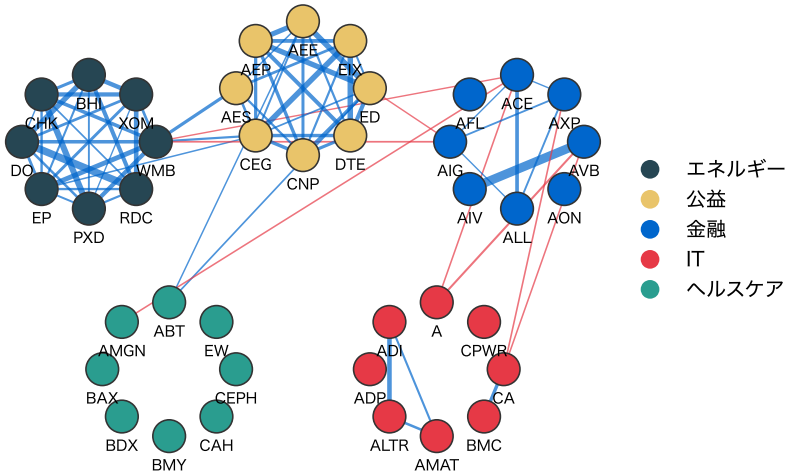


図 8: S&P 500 の 40 銘柄(2007 年、市場の動きを引いた残り)に、BIC で選んだ λ の Graphical Lasso をかけた線。色は業種、線の太さは偏相関の大きさ(青が正、赤が負)

ただし、業種の中の線の数は業種によって大きく違った。28 組のうち、エネルギーは 26 組、公益は 24 組に線があったが、金融は 7、IT は 4、ヘルスケアは 0 組だった。どの業種も密になるという予想は外れた。理由は、業種の分類が粗いことにある。金融でいちばん太い線は、どちらも集合住宅の不動産投資信託である AIV と AVB の間で、偏相関は 0.36 である。損害保険どうしの ACE と ALL にも線がある。IT は、半導体の ADI・ALTR・AMAT と、企業向けソフトウェアの BMC・CA の 2 つの小さな塊に分かれた。ヘルスケアには製薬・医療機器・医薬品の卸が混ざっている。同じ業種の名前でも、反応する材料(家賃と金利、保険金の支払い、半導体の需要)が違えば、市場の動きを引いた残りは一緒に動かない。エネルギーは原油とガスの値段に、公益は金利と電気料金の規制に、そろって反応する。

業種をまたぐ線は 13 本で、どれも細い。いちばん太いのは、天然ガスのパイプラインを持つ WMB と、発電の AES の間(+0.09)である。ガスは発電の燃料なので、エネルギーと公益をつなぐ線には商売の上の理由がある。

最後に、λ を 0.35 に上げると、業種をまたぐ線は消え、エネルギー・公益・金融・IT の塊に分かれた(図 9)。定理 1 のとおり、塊をまたぐ相関が λ 以下になれば、間の線は切れる。

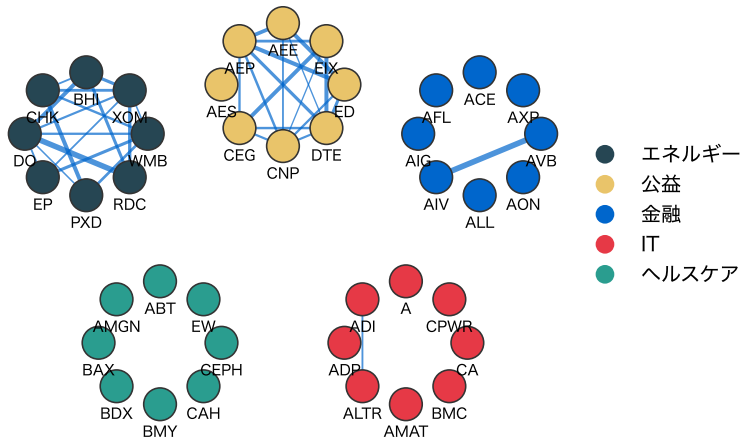


図 9: 同じデータで $\lambda = 0.35$ にしたときの線

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは 4 つを予想した。相関で線を引くとほぼすべてがつながること、市場の動きを引いて Graphical Lasso をかけると同じ業種どうしの線が残ること、どの業種でも業種の中の線が密になること、λ を上げると業種の塊に分かれることである。1 つ目、2 つ目、4 つ目は予想どおりだった。3 つ目は外れ、エネルギーと公益は密だったが、金融・IT・ヘルスケアは疎だった。業種の分類は粗く、金融や IT の中には、不動産投資信託・損害保険・半導体・企業向けソフトウェアのような、別の材料に反応する小さな塊があった。業種をまたぐいちばん太い線はガスと電力をつなぎ、商売の上の理由があった。偏相関で引いた線は、業種の一覧よりも細かいまとまりを教えてくれた。

締め

まとめと全 15 回の地図

本章の問いは、データ行列から変数どうしのつながりの表をどう作るか、であった。相関で線を引くと、間に別の変数をはさんだだけの組までつながる。そこで、ほかの列を固定したときの関係を見た。p 変量正規分布では、ある列を残りの列で回帰した係数は、精度行列 $\boldsymbol{\Theta} = \boldsymbol{\Sigma}^{-1}$ の列で $\boldsymbol{\beta} = -\boldsymbol{\theta}_{12}/\theta_{22}$ と書ける。$\theta_{jk} = 0$ なら、ほかの列を固定すると x_j と x_k は独立で、偏相関も 0 になる。精度行列を最尤法で推定すると $\mathbf{S}^{-1}$ になるが、行が少ないと存在せず、0 もちょうどには出ない。そこで第 4 回の ℓ_1 罰則を足した。最適の条件を列ごとに書くと、第 4 回の Lasso と同じ形になり、座標降下で解ける(Graphical Lasso)。$\lambda > 0$ なら行が少なくても解け、塊をまたぐ相関がどれも λ 以下なら、間の線は消える。λ は第 9 回と同じく、選んだ線で推定し直した BIC で選んだ。人工データでは本当の鎖が選ばれた。S&P 500 の 40 銘柄では、市場の動きを引いた残りの線の大半が同じ業種どうしで、金融や IT の中には業種より細かい塊があった。

最後に、全 15 回を「モデル × 推定法」の地図に置き直す（表 2）。第 1〜4 回は線形回帰を最小二乗法で推定し、その数字の測り方（第 2 回）、係数の揺れ（第 3 回）、罰則（第 4 回）を見た。第 5・6 回は分類を最小二乗法と最尤法の両方で解いた。第 7〜9 回はラベルの無い群分けを、k-means（最小二乗法）、混合正規分布（最尤法）、群の数の選び方の順に扱った。第 10・11 回は $\mathbf{X}$ を $\mathbf{F}\mathbf{A}^\top$ で近似する主成分分析と、それを確率のモデルにした因子分析を扱った。第 12・13 回は分割表のずれを、重み付き最小二乗法と最尤法の両方から見た。第 14・15 回はネットワークで、つながりの表があれば固有ベクトルでまとまりを描き、表が無ければ罰則付きの最尤法で表を作った。

表 2: 全 15 回の「モデル × 推定法」の地図（数字は扱う回）

モデル	最小二乗法で推定	最尤法で推定
線形回帰	第 1〜3 回（罰則付き 第 4 回）	第 6 回
LDA ／ ロジスティック回帰	第 5 回 ／ —	第 6 回
k-means ／ 混合正規分布	第 7 回 ／ —	— ／第 8 回（群の数は第 9 回）
主成分分析 ／ 因子分析	第 10 回 ／ —	第 11 回
対応分析・多重対応分析	第 12・13 回（重み付き）	—
独立のモデル	第 12 回（χ^2）	第 13 回（G^2、残差）
グラフのまとまり	第 14 回（カットを緩めて固有ベクトル）	—
ガウシアングラフィカルモデル	—	第 15 回（ℓ_1 罰則付き）

どの回も、データとモデルのずれを測って小さくすることをしてきた。最小二乗法では、$\|\boldsymbol{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2$、$\|\mathbf{X} - \mathbf{G}\mathbf{C}\|_F^2$、$\|\mathbf{X} - \mathbf{F}\mathbf{A}^\top\|_F^2$、重み付きの $\|\mathbf{S} - \mathbf{Y}\|_F^2$、隣どうしの違いの $\boldsymbol{x}^\top \mathbf{L} \boldsymbol{x}$ がずれの測り方であった。最尤法では -2ℓ が同じ役を果たした。第 4 回と本章では、ずれに罰則を足し、ずれが少し大きくなるのと引きかえに、0 の多い簡単な答えを得た。そして数字の読み方では、何で割った数字か（第 13 回）と並んで、何を固定した数字かを確かめることが大切である。相関と偏相関は、同じ 2 つの変数について、まったく違うことを言う。データとモデルのずれを測り、その数字が何を前提にしているかを確かめること。それが、この 15 回を通じて繰り返してきたことである。

発展

発展：時間とともに変わるつながり

発展として、つながりが時間とともに変わる場合を考える。第 II 部と同じ 40 銘柄・同じ $\lambda = 0.2$ で、2003 年から 2007 年まで 1 年ずつ（約 250 営業日ずつ）Graphical Lasso をかけた（図 10）。業種ごとの線の数は年によって変わり、前の年の線が次の年にも残る割合は 60〜82% だった。会社どうしの関係が本当に変わったのか、約 250 日のデータの揺れなのかは、別々に推定しただけでは区別できない。

隣の年どうしは、たいてい似ているはずである。そこで、時点 $t = 1, \ldots, T$ の精度行列 $\boldsymbol{\Theta}_t$ を一緒に推定し、隣どうしの差にも ℓ_1 罰則を足す。

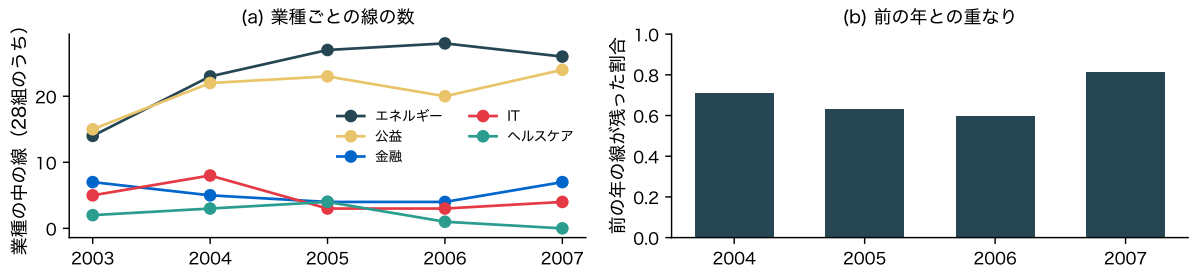


図 10: S&P 500 の 40 銘柄を 1 年ずつ Graphical Lasso で推定した結果（λ は本編で選んだ値）。(a) 業種ごとの業種の中の線の数、(b) 前の年の線が次の年にも残った割合

$$\max_{\boldsymbol{\Theta}_1,\dots,\boldsymbol{\Theta}_T} \sum_{t=1}^{T}\Big(\log\det \boldsymbol{\Theta}_t - \operatorname{tr}(\mathbf{S}_t\boldsymbol{\Theta}_t)\Big) - \lambda\sum_{t}\|\boldsymbol{\Theta}_t\|_1 - \lambda_2\sum_{t\ge 2}\|\boldsymbol{\Theta}_t - \boldsymbol{\Theta}_{t-1}\|_1$$

ℓ_1 罰則は成分をちょうど 0 にするので、2 つ目の罰則は、隣の時点との差をちょうど 0 にする。変わらない所は同じ値のままで、変わった所だけが変わる。これを Time-Varying Graphical Lasso と呼ぶ（Hallac ほか 2017）。時間の順が無い群、たとえば病気の人と健康な人や、国ごとのデータでも、すべての組の差や、成分ごとの群をまたぐ大きさ $\sqrt{\sum_t \theta_{t,jk}^2}$ に罰則を足して、群どうしを似せながら一緒に推定できる（Joint Graphical Lasso、Danaher ほか 2014）。後者は、群のどれかで線があれば全部の群で線を残しやすくする。どちらも、何を簡単にしたいかを罰則の形で書き、それを目的関数に足したものである。

この考え方は、金融（年や景気の局面ごとの銘柄のつながり）、脳科学（課題の前後や患者と健常者での脳の領域どうしのつながり）、遺伝子（がんの種類ごとの発現のつながり）、マーケティング（店や季節ごとの商品の売上のつながり）で使われている。

参考文献

- Danaher, P., Wang, P. & Witten, D. M. (2014). The joint graphical lasso for inverse covariance estimation across multiple classes. Journal of the Royal Statistical Society Series B 76: 373–397.
- Friedman, J., Hastie, T. & Tibshirani, R. (2008). Sparse inverse covariance estimation with the graphical lasso. Biostatistics 9: 432–441.
- Hallac, D., Park, Y., Boyd, S. & Leskovec, J. (2017). Network inference via the time-varying graphical lasso. KDD 2017: 205–213.
- Meinshausen, N. & Bühlmann, P. (2006). High-dimensional graphs and variable selection with the Lasso. Annals of Statistics 34: 1436–1462.
- Zhao, T., Liu, H., Roeder, K., Lafferty, J. & Wasserman, L. (2012). The huge package for high-dimensional undirected graph estimation in R. Journal of Machine Learning Research 13: 1059–1062.