

第 15 回 残差と多重対応分析

推定に使われた分で割って、1 マスのずれを比べる(最終回)

最終回の問いは、第 14 回の締めで残った「1 セルのズレは大きいのか？」である。新しい表を使い、第 14 回の $(o - e)/\sqrt{e}$ を残差として見直す。独立のモデルを最尤法で推定した後の残差とみると、その分散は 1 より小さく、マスごとに $(1 - r_i)(1 - c_j)$ になる。この値で割った調整済み残差なら、 ± 2 の物差しが使える。回帰の $\sqrt{1 - h_{ii}}$ で割るのと同じ型である。最後に、3 つ以上のカテゴリを扱う多重対応分析を第 14 回の手順で書く。そして全 15 回を「モデル × 推定法」の地図として振り返る。

第 I 部 理論

1 マスのずれは大きいのか

第 14 回の帰結②では、 χ^2 統計量がマスごとの $(o_{ij} - e_{ij})/\sqrt{e_{ij}}$ の二乗和に分かれることを見て、「1 セルのズレは大きいのか」という問いが残った。本章の問いはこれである。ここでは人工的なデータで考える。自動販売機 1 台の 1 年の売上 1,000 本を、飲み物 5 種類(缶コーヒー・お茶・水・炭酸・コーンスープ) × 季節 4 つで数えた表である。お茶 × 夏は、行と列が独立なら第 14 回の期待度数で 168.0 本のはずが、実際は 190 本だった。図 1 (a) はこの表のマスごとの $(o - e)/\sqrt{e}$ を並べたもので、お茶 × 夏は +1.70 である。このずれは大きいのか。

素朴には、値を標準正規分布の物差しに当てる。標準正規分布なら、絶対値が 2 を超えるのは 4.55% しかない。そこで ± 2 を超えたマスを「偶然では説明しにくいほど大きい」と読む。お茶 × 夏は ± 2 に届かないので、大きくないと答えることになる。

ところが、この物差しは当てにならない。行と列が本当に独立なモデルから、同じ周辺と同じ総数の表を 2,000 回作り、毎回同じように $(o - e)/\sqrt{e}$ を計算してみる。図 2 (a) のように山は標準正規分布より細く、分散は 0.59 しかない。関連がまったく無いのに ± 2 を超えるのは 1.0% で、4.55% よりずっと少ない。 ± 2 の物差しは、分散がちょうど 1 のときにしか使えない。

山が細くなる理由の見通しを先に述べる。期待度数 $e_{ij} = nr_i c_j$ は、独立のモデルを最尤法で推定した値である。推定には表の行の合計と列の合計を使うので、残差 $o_{ij} - e_{ij}$ はそのぶん縮む。 $(o - e)/\sqrt{e}$ の分散は、1 ではなく $(1 - r_i)(1 - c_j)$ になる。この値で割り直したものを調整済み残差(adjusted residual)と呼び、その分散は 1 になる(図 1 (b)、図 2 (b))。第 3 回・第 4 回で回帰の残差を $\sqrt{1 - h_{ii}}$ で割ったのと同じ型である。

「モデル × 推定法」の地図で位置を確かめる。第 14 回は、独立のモデルにランク Q のずれを足したモデルを、重み付き最小二乗法で当てはめた。 $Q = 0$ のときの誤差が総慣性 χ^2/n であった。本章は同じ独立のモデルを

(a) $(o - e)/\sqrt{e}$					(b) 調整済み残差 d				
缶コーヒー	+1.34	-3.52	-0.17	+4.00	缶コーヒー	+1.63	-5.10	-0.21	+4.94
お茶	+0.35	+1.70	-0.00	-2.80	お茶	+0.50	+2.88	-0.00	-4.03
水	-0.72	+1.70	+1.14	-2.92	水	-0.88	+2.48	+1.41	-3.63
炭酸	-1.19	+3.09	-0.74	-2.60	炭酸	-1.43	+4.39	-0.90	-3.14
コーンスープ	-0.08	-5.14	-0.49	+8.00	コーンスープ	-0.09	-7.05	-0.57	+9.35
	春	夏	秋	冬		春	夏	秋	冬

図 1: 人工の自動販売機の売上の表のマスごとのずれ。(a) $(o - e)/\sqrt{e}$ 、(b) 本章で導く調整済み残差。細い枠は絶対値が 2 以上のマス、橙の枠はお茶 × 夏。色の目盛りは 2 枚で共通




図 2: 人工の自動販売機の表と同じ周辺の独立のモデルから 2,000 回作った表の残差の分布。(a) $(o - e)/\sqrt{e}$ 、(b) 調整済み残差。曲線は標準正規分布の密度、破線は ± 2

最尤法の側から見直す。当てはまりの悪さを尤度で測る G^2 と、マスごとの調整済み残差を導く。最後に、3 つ以上のカテゴリを扱う多重対応分析を、第 14 回の手順で書く。

道具：割合・ばらつき・射影

本章で使う道具を先にそろえる。期待度数を「モデルを推定した値」として読み直し、推定した後の残差がどれだけ揺れるかを求めるためである。

1 つ目は、割合の最尤推定である。 n 回の試行のそれぞれで、 k 個の結果のどれかが確率 π_q で出るとする。結果 q が n_q 回出たとき、対数尤度は定数を除いて

$$\ell(\boldsymbol{\pi}) = \sum_{q=1}^k n_q \log \pi_q, \quad \sum_{q=1}^k \pi_q = 1 \quad (1)$$

となる。これを最大にする π_q は、観測した割合 $\hat{\pi}_q = n_q/n$ である。第 6 回のコインの例($k = 2$)と第 12 回の混合比率 $\hat{\pi}_q = n_q/n$ で、制約を代入して微分し 0 とおいて示した。ここでも計算は同じである。

2つ目は、数えた度数のばらつきである。平均が μ の度数 o は、 μ が大きければ分散もほぼ μ で(ポアソン分布(Poisson distribution)による近似)、分布は正規分布に近い。したがって

$$z = \frac{o - \mu}{\sqrt{\mu}} \quad (2)$$

は平均0、分散1になる。総数 n を固定して n 本をマスに振り分けると(多項分布(multinomial distribution))、マスの度数の分散は厳密には $n\pi(1-\pi)$ で、わずかに小さい。マスどうしにも弱い負の相関がつく。本章では、マスの度数が互いに独立で、分散が平均に等しいとみなす近似を使う。総数を固定したことによる違いは、後の導出で取り除く向きにだけ入る。そのため結果は変わらない。

3つ目は、線形変換の分散である。成分が互いに独立で分散1の量を考える。スカラーなら $\text{Var}(az) = a^2$ となる。ベクトル $\mathbf{z}$ では、第3回の道具② $\text{Var}(\mathbf{A}\mathbf{y}) = \mathbf{A}\mathbf{\Sigma}\mathbf{A}^\top$ で $\mathbf{\Sigma} = \mathbf{I}$ とおく。すると $[\mathbf{A}\mathbf{z}]_i$ の分散は $[\mathbf{A}\mathbf{A}^\top]_{ii} = \sum_{i'} a_{ii'}^2$ になる。行列 $\mathbf{Z}$ に左右から掛けた $[\mathbf{AZB}]_{ij} = \sum_{i'} \sum_l a_{ii'} z_{i'l} b_{lj}$ は独立な項の和なので

$$\text{Var}([\mathbf{AZB}]_{ij}) = \sum_{i'} \sum_l a_{ii'}^2 b_{lj}^2 = [\mathbf{A}\mathbf{A}^\top]_{ii} [\mathbf{B}^\top \mathbf{B}]_{jj} \quad (3)$$

となる。 $\mathbf{B}$ が 1×1 の1なら2つ目の式に、さらに $\mathbf{A}$ も 1×1 ならスカラーの式に戻る。

4つ目は、1本の向きを除く行列である。長さ1のベクトル $\mathbf{u}$ について

$$\mathbf{Q}_u = \mathbf{I} - \mathbf{u}\mathbf{u}^\top \quad (4)$$

とおく。 $\mathbf{Q}_u \mathbf{u} = \mathbf{u} - \mathbf{u}(\mathbf{u}^\top \mathbf{u}) = 0$ なので、 $\mathbf{Q}_u$ を掛けると $\mathbf{u}$ の向きの成分が取り除かれる(図3)。第3回の射影行列 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ で、 $\mathbf{X}$ が長さ1の列 $\mathbf{u}$ の1本だけなら $\mathbf{H} = \mathbf{u}\mathbf{u}^\top$ となる。つまり $\mathbf{Q}_u = \mathbf{I} - \mathbf{H}$ は、第3回・第4回で残差 $\mathbf{e} = (\mathbf{I} - \mathbf{H})\mathbf{y}$ を作った行列にあたる。対称かつ冪等なので $\mathbf{Q}_u \mathbf{Q}_u^\top = \mathbf{Q}_u$ が成り立つ。対角は $1 - u_j^2$ 、対角の和は(次元の数) -1 である。




図3: 1本の向きを除く行列(概念図)。 $\mathbf{Q}_u \mathbf{z}$ は、 $\mathbf{z}$ から $\mathbf{u}$ の向きの成分(破線)を引いたもの

5つ目は、 ± 2 の根拠である。標準正規分布に従う量の絶対値が2を超える確率は $2\{1 - \Phi(2)\} = 4.55\%$ である (Φ は標準正規分布の累積分布関数。ちょうど5%にするなら ± 1.96)。この確率は、分散がちょうど1のときの値である。分散が $v < 1$ なら、超える確率は $2\{1 - \Phi(2/\sqrt{v})\}$ に下がる。 $v = 0.6$ では図4のように0.98%になる。




図4: 平均0の正規分布の密度(概念図)。破線は ± 2 。分散が1より小さいと、 ± 2 を超える確率は4.55%より小さくなる

独立のモデルとその尤度

第14回は、独立の表 $rc^\top$ を、周辺をそのまま使って作った。本章では同じ独立のモデルを確率のモデルとして書き、その中の数を推定する。

自動販売機で売れた n 本の1本1本が、互いに独立に、確率 π_{ij} で飲み物 $i \times$ 季節 j のマスに入るとする ($\sum_{i,j} \pi_{ij} = 1$)。行と列が独立であるとは

$$\pi_{ij} = \pi_{i\cdot} \pi_{\cdot j} \quad (5)$$

が成り立つことをいう。 $\pi_{i\cdot}$ は飲み物 i が選ばれる確率、 $\pi_{\cdot j}$ は季節 j に売れる確率である ($\sum_i \pi_{i\cdot} = \sum_j \pi_{\cdot j} = 1$)。第14回の $p_{ij} = r_i c_j$ を、観測した比率ではなく確率の言葉で書いた。行列で書けば $\boldsymbol{\Pi} = \boldsymbol{\pi}_r \boldsymbol{\pi}_c^\top$ となり、第14回の $Q = 0$ と同じくランク1である。推定するのは $\boldsymbol{\pi}_r$ と $\boldsymbol{\pi}_c$ だけになる。

当てはまりの良さは尤度で測る。1本がマス (i, j) に入る確率は π_{ij} で、そこに o_{ij} 本が入った。したがって対数尤度は、定数を除いて

$$\ell(\boldsymbol{\Pi}) = \sum_{i=1}^I \sum_{j=1}^J o_{ij} \log \pi_{ij} \quad (6)$$

となる。(1) 式の k 個の結果を、 IJ 個のマスに置き換えた形である。独立のモデル (5) 式を代入すると $\log \pi_{ij} = \log \pi_{i\cdot} + \log \pi_{\cdot j}$ となる。 j について足すと行の合計 $o_{i+} = \sum_j o_{ij}$ が、 i について足すと列の合計 $o_{+j} = \sum_i o_{ij}$ が出てくるので

$$\ell(\boldsymbol{\pi}_r, \boldsymbol{\pi}_c) = \sum_{i=1}^I o_{i+} \log \pi_{i\cdot} + \sum_{j=1}^J o_{+j} \log \pi_{\cdot j} \quad (7)$$

となる。対数尤度が、行の確率だけの部分と列の確率だけの部分の和に分かれた。行列で書けば、マスごとの積を $\odot$ 、成分ごとの対数を $\log$ として

$$\ell = \mathbf{1}_I^\top (\mathbf{O} \odot \log \boldsymbol{\Pi}) \mathbf{1}_J = (\mathbf{O} \mathbf{1}_J)^\top \log \boldsymbol{\pi}_r + (\mathbf{O}^\top \mathbf{1}_I)^\top \log \boldsymbol{\pi}_c \quad (8)$$

と書ける。 $\mathbf{O} \mathbf{1}_J$ は行の合計、 $\mathbf{O}^\top \mathbf{1}_I$ は列の合計を並べたベクトルである。独立のモデルの尤度は、表の中身のうち周辺しか使わない。 $I = J = 1$ なら (6) 式の 1 マスに戻る。

最尤推定と当てはまりの悪さ

独立のモデルの対数尤度 (7) 式は、行の部分と列の部分に分かれている。だから別々に最大にすればよい。行の部分 $\sum_i o_{i+} \log \pi_{i\cdot}$ は、(1) 式で n_q を o_{i+} としたものである。列の部分も同じなので、道具①より

$$\hat{\pi}_{i\cdot} = \frac{o_{i+}}{n} = r_i, \quad \hat{\pi}_{\cdot j} = \frac{o_{+j}}{n} = c_j, \quad \hat{e}_{ij} = n \hat{\pi}_{i\cdot} \hat{\pi}_{\cdot j} = n r_i c_j \quad (9)$$

を得る。行列で書けば $\hat{\boldsymbol{\Pi}} = \mathbf{r} \mathbf{c}^\top$ となる。第 14 回で「行の合計 $\times$ 列の合計 $\div$ 総数」として作った期待度数 e_{ij} は、独立のモデルを最尤法で推定したときの予測値だったわけである。以下、 $\hat{e}_{ij}$ を第 14 回と同じく e_{ij} と書く。

推定した独立のモデルがどれだけ表に合っていないかも、尤度で測れる。 π_{ij} に何の制約も置かないモデルを飽和モデル(saturated model)という。飽和モデルでは (6) 式が (1) 式そのものになり、 $\hat{\pi}_{ij} = o_{ij}/n = p_{ij}$ で表が完全に再現される。この対数尤度と、独立のモデルの対数尤度の最大値 $\hat{\ell}$ との差の 2 倍

$$G^2 = 2(\ell_{\text{飽和}} - \hat{\ell}) = 2 \sum_{i,j} o_{ij} \log \frac{o_{ij}}{e_{ij}} \quad (10)$$

を G^2 統計量(尤度比統計量、逸脱度(deviance))と呼ぶ(定義 1)。2 つ目の等号は $\log(o_{ij}/n) - \log(e_{ij}/n) = \log(o_{ij}/e_{ij})$ から出る。 G^2 は第 13 回で比べた $-2\hat{\ell}$ と同じ尺度で、飽和モデルを基準にした値である。人工データでは $G^2 = 158.7$ である。

この G^2 は、第 14 回の χ^2 統計量 $\sum(o - e)^2/e$ と近い値をとる。これを示すために対数の近似を使う。 x が 0 に近いとき

$$\log(1 + x) \approx x - \frac{x^2}{2} \quad (11)$$

が成り立つ($\log(1 + x)$ を $x = 0$ のまわりで 2 次まで展開したもの。 $x = 0.1$ なら左辺は 0.0953、右辺は 0.0950)。 $o = e(1 + x)$ 、 $x = (o - e)/e$ とおき、(11) 式を使うと

$$o \log \frac{o}{e} = e(1+x) \log(1+x) \approx e(1+x) \left(x - \frac{x^2}{2} \right) \approx e \left(x + \frac{x^2}{2} \right) \quad (12)$$

$$G^2 \approx 2 \sum_{i,j} (o_{ij} - e_{ij}) + \sum_{i,j} \frac{(o_{ij} - e_{ij})^2}{e_{ij}} = \chi^2$$

となる。1行目の最後では x^3 の項を捨てた。2行目の第1項は、 e_{ij} の合計が n なので0である。独立のモデルが正しく、どのマスでも o/e が1に近い(x が小さい)大標本を考える。そこでは、最尤法で測った当てはまりの悪さ G^2 と、第14回の重み付き最小二乗法で測った当てはまりの悪さ χ^2 が一致する。第6回では、正規誤差の線形回帰で最小二乗法と最尤法が同じ答えを与えるを見た。分割表の独立のモデルでも、2つの推定法は同じ物差しにたどり着く。人工データの表では $\chi^2 = 163.2$ で、 G^2 と同じではない(独立のモデルから遠いマスがあるため)。独立のモデルから作った表で両者が近いことは、第II部で確かめる。

定義 1 (G^2 統計量). 独立のモデルを最尤法で推定した期待度数 $e_{ij} = nr_i c_j$ について、 $G^2 = 2 \sum_{i,j} o_{ij} \log(o_{ij}/e_{ij})$ を G^2 統計量と呼ぶ。飽和モデルとの対数尤度の差の2倍であり、 o/e が1に近いとき χ^2 統計量に近づく。

残差の分散

$(o - e)/\sqrt{e}$ の分散を、推定したものが少ない順に、1マス、1行、表全体と広げて求める。期待度数は表の行の合計と列の合計から推定したので、推定に使った分だけ残差は小さくなるはずである。

まず、何も推定しない場合を考える。本当の確率 π_{ij} がわかっていれば、期待度数は $n\pi_{ij}$ になる。道具②より

$$z_{ij} = \frac{o_{ij} - n\pi_{ij}}{\sqrt{n\pi_{ij}}} \quad (13)$$

は平均0、分散1である。この z_{ij} を並べた $I \times J$ の行列を $\mathbf{Z}$ とし、マスどうしは独立とみなす。この場合なら、 ± 2 の物差しがそのまま使える。

次に、1行ずつ考える。季節の確率 $\pi_{.j}$ はわかっているとする。行 i の確率 π_i の代わりに行の合計 o_{i+} を使い、期待度数を $o_{i+}\pi_{.j}$ とする。 $o_{i+} - n\pi_i = \sum_l (o_{il} - n\pi_{il}) = \sum_l \sqrt{n\pi_{il}} z_{il}$ なので、残差を $\sqrt{n\pi_{ij}} = \sqrt{n\pi_i} \sqrt{\pi_{.j}}$ で割ると

$$\frac{o_{ij} - o_{i+}\pi_{.j}}{\sqrt{n\pi_{ij}}} = z_{ij} - \sqrt{\pi_{.j}} \sum_{l=1}^J \sqrt{\pi_{.l}} z_{il} = [(\mathbf{I} - \sqrt{\pi_c} \sqrt{\pi_c}^\top) \mathbf{z}_i]_j \quad (14)$$

となる。 $\mathbf{z}_i$ は $\mathbf{Z}$ の第 i 行を縦にしたもの、 $\sqrt{\pi_c} = (\sqrt{\pi_{.1}}, \dots, \sqrt{\pi_{.J}})^\top$ は長さ1のベクトルである。行の合計を使うと、行のずれ $\mathbf{z}_i$ から $\sqrt{\pi_c}$ の向きの成分を取り除くことになる。道具③・④より、その分散は $[\mathbf{Q}\mathbf{Q}^\top]_{jj} = 1 - \pi_{.j}$ で、1より小さい。

最後に、表全体を考える。実際の期待度数 $e_{ij} = o_{i+}o_{+j}/n$ は、行の合計と列の合計の両方を使う。 o_{i+} 、 o_{+j} 、 n は、それぞれ期待される値の近くで動くとする。その動きの1次の項だけを残す(2つの小さな動きの積は捨てる)と同じ計算を行と列の両方で行うことになり

$$\sqrt{n} s_{ij} = \frac{o_{ij} - e_{ij}}{\sqrt{e_{ij}}} \approx \left[(\mathbf{I} - \sqrt{\mathbf{r}}\sqrt{\mathbf{r}}^\top) \mathbf{Z} (\mathbf{I} - \sqrt{\mathbf{c}}\sqrt{\mathbf{c}}^\top) \right]_{ij} \quad (15)$$

を得る。 $\sqrt{\mathbf{r}} = \mathbf{D}_r^{1/2} \mathbf{1}_I$ 、 $\sqrt{\mathbf{c}} = \mathbf{D}_c^{1/2} \mathbf{1}_J$ は第 14 回の帰結④の 2 本のベクトルで、 π_i 、 π_j をその推定値 r_i 、 c_j で置き換えた。 s_{ij} は第 14 回の標準化残差行列 $\mathbf{S}$ のマスである。左から掛けた行列は各列から $\sqrt{\mathbf{r}}$ の向きを取り除く。右から掛けた行列は各行から $\sqrt{\mathbf{c}}$ の向きを取り除く。総数 n を固定した多項分布による $\mathbf{Z}$ のずれは、 $\sqrt{\mathbf{r}}\sqrt{\mathbf{c}}^\top$ の向きにしか入らない。そのため、この両側の操作で消える。(3) 式と、道具④の $\mathbf{Q}\mathbf{Q}^\top = \mathbf{Q}$ の対角から

$$\text{Var}(\sqrt{n} s_{ij}) \approx (1 - r_i)(1 - c_j) \quad (16)$$

となる。列の合計を使わなければ、 $(1 - c_j)$ だけの (14) 式に戻る。 $(o - e)/\sqrt{e}$ の分散は 1 ではなく、行の合計と列の合計の大きいマスほど小さい。

そこで、この分散の平方根で割り直す。

$$d_{ij} = \frac{o_{ij} - e_{ij}}{\sqrt{e_{ij}(1 - r_i)(1 - c_j)}} = \frac{\sqrt{n} s_{ij}}{\sqrt{(1 - r_i)(1 - c_j)}} \quad (17)$$

を調整済み残差と呼ぶ(定義 2)。独立のモデルのもとで、 d_{ij} は平均 0、分散 1 の正規分布に近い。だから ± 2 の物差しを当てられる。 $(1 - r_i)(1 - c_j) < 1$ なので、 $|d_{ij}|$ は必ず $|\sqrt{n} s_{ij}|$ より大きい。

定義 2 (調整済み残差)。独立のモデルの期待度数 $e_{ij} = nr_i c_j$ について、 $d_{ij} = (o_{ij} - e_{ij})/\sqrt{e_{ij}(1 - r_i)(1 - c_j)}$ を調整済み残差と呼ぶ。 $(o_{ij} - e_{ij})/\sqrt{e_{ij}} = \sqrt{n} s_{ij}$ を標準化残差(ピアソン残差)と呼ぶ。独立のモデルのもとで、標準化残差の分散は $(1 - r_i)(1 - c_j)$ 、調整済み残差の分散は 1 に近い。

計算の手順

分割表のマスのずれを読む計算を、行列の形でまとめる(⑦ はマスごとの割り算)。

1. $\mathbf{P} = \mathbf{O}/n$ 、 $\mathbf{r} = \mathbf{P}\mathbf{1}_J$ 、 $\mathbf{c} = \mathbf{P}^\top \mathbf{1}_I$ を求める。これは独立のモデルの最尤推定値 (9) 式である
2. 期待度数 $\mathbf{E} = n\mathbf{r}\mathbf{c}^\top$ を作り、当てはまりの悪さ $G^2 = 2\mathbf{1}_I^\top (\mathbf{O} \odot \log(\mathbf{O} \oslash \mathbf{E})) \mathbf{1}_J$ と $\chi^2 = n\|\mathbf{S}\|_F^2$ を求める(度数 0 のマスは G^2 の和から除く)
3. 第 14 回の標準化残差行列 $\mathbf{S} = \mathbf{D}_r^{-1/2}(\mathbf{P} - \mathbf{r}\mathbf{c}^\top)\mathbf{D}_c^{-1/2}$ を作り、 $\sqrt{n}$ 倍して標準化残差を得る
4. 左右から対角行列 $(\mathbf{I} - \mathbf{D}_r)^{-1/2}$ 、 $(\mathbf{I} - \mathbf{D}_c)^{-1/2}$ を掛けて、調整済み残差の行列 $\mathbf{D}_d = \sqrt{n}(\mathbf{I} - \mathbf{D}_r)^{-1/2}\mathbf{S}(\mathbf{I} - \mathbf{D}_c)^{-1/2}$ を得る
5. ± 2 と比べ、ずれの強さは $\mathbf{O} \oslash \mathbf{E}$ (期待の何倍か)で読む

手順 3 までは第 14 回の手順 2 と同じである。違うのは手順 4 だけで、行と列の周辺から決まる対角行列を掛ける。特異値分解は要らない。

理論の帰結：推定に使われた分で割る

導出から、残差の性質がいくつか読み取れる。第 1 に、標準化残差の分散を全マスで足すと

$$\sum_{i=1}^I \sum_{j=1}^J (1 - r_i)(1 - c_j) = \left(I - \sum_i r_i\right) \left(J - \sum_j c_j\right) = (I - 1)(J - 1) \quad (18)$$

となる。この値は χ^2 統計量の自由度であり、(15) 式の両側の行列の対角の和の積でもある。 χ^2 は標準化残差の二乗和なので、独立のモデルのもとでの χ^2 の期待値は自由度に等しい。1 マスあたりの平均は $(I - 1)(J - 1)/(IJ)$ で、人工データの 5×4 の表では 0.60 である。図 2 (a) の分散 0.59 はこの値にあたる。図 5 はマスごとの値で、行の合計と列の合計の大きいマス(場面のお茶 × 夏など)ほど小さい。

	$(1 - r_i)(1 - c_j)$			
缶コーヒー	0.67	0.48	0.66	0.66
お茶	0.49	0.35	0.48	0.48
水	0.66	0.47	0.65	0.65
炭酸	0.70	0.50	0.68	0.68
コーンスープ	0.75	0.53	0.73	0.73
	春	夏	秋	冬

図 5: 人工の自動販売機の表の、標準化残差の分散 $(1 - r_i)(1 - c_j)$

第 2 に、 $h_{ij} = 1 - (1 - r_i)(1 - c_j) = r_i + c_j - r_i c_j$ を、マス (i, j) が推定に使われた度合いとみると

$$\sum_{i,j} h_{ij} = IJ - (I - 1)(J - 1) = I + J - 1 \quad (19)$$

となる。 $I + J - 1$ は、独立のモデルで表から推定した数の個数である。内訳は、総数 1 個、行の確率 $I - 1$ 個(足すと 1 なので 1 つ少ない)、列の確率 $J - 1$ 個である。

第 3 に、この形は回帰とまったく同じ型をしている。第 4 回で見たとおり、回帰の残差は $\mathbf{e} = (\mathbf{I} - \mathbf{H})\mathbf{y} = (\mathbf{I} - \mathbf{H})\boldsymbol{\epsilon}$ と誤差だけで書ける。 $\mathbf{I} - \mathbf{H}$ は対称かつ冪等なので $\text{Var}(\mathbf{e}) = \sigma^2(\mathbf{I} - \mathbf{H})$ 、すなわち

$$\text{Var}(e_i) = \sigma^2(1 - h_{ii}), \quad \sum_i h_{ii} = \text{tr } \mathbf{H} = p \quad (20)$$

が成り立つ。てこ比 h_{ii} は行 i が自分の予測に使われた度合いで、その和は推定した係数の個数 p になる。だから

ら回帰の残差は $\hat{\sigma}\sqrt{1-h_{ii}}$ で割ってそろえる。表 1 のとおり、分割表の調整済み残差は、残差を $\sqrt{e_{ij}(1-h_{ij})}$ で割ったものである。どちらも「推定に使われた分だけ縮んだ残差を、縮んだ分で割り戻す」操作である。

表 1: 回帰の残差と分割表の残差

	回帰(第 3・4 回)	分割表(本章)
残差	$\mathbf{e} = (\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}$	$\sqrt{n}\mathbf{S} \approx (\mathbf{I} - \sqrt{\mathbf{r}}\sqrt{\mathbf{r}^\top})\mathbf{Z}(\mathbf{I} - \sqrt{\mathbf{c}}\sqrt{\mathbf{c}^\top})$
推定に使われた度合い	てこ比 h_{ii}	$h_{ij} = r_i + c_j - r_i c_j$
その和	$\text{tr } \mathbf{H} = p$	$I + J - 1$
割るもの	$\hat{\sigma}\sqrt{1-h_{ii}}$	$\sqrt{e_{ij}(1-h_{ij})}$

ただし、割り直して値が変わる大きさは違う。回帰ではてこ比の平均が p/n で、行が多ければ小さい。そのため割り直しても値はほとんど変わらない。分割表では r_i の平均が $1/I$ 、 c_j の平均が $1/J$ になる。行や列の数が少ない表ほど、割り直して値が大きく変わる。

第 4 に、割り直せば分散は 1 になる。場面の独立のモデルから作った 2,000 個の表で、調整済み残差を計算する。図 2 (b) のように山は標準正規分布に重なり、分散は 0.99、 ± 2 を超えるのは 4.4% である。

場面のお茶 $\times$ 夏に戻ると、 $(1-r_2)(1-c_2) = 0.348$ である。標準化残差 +1.70 をその平方根で割ると、調整済み残差は +2.88 となり(図 1 (b))、 ± 2 を超える。標準化残差に ± 2 を当てると、このようなずれを見落とす。

理論の帰結 : たくさんのマスを見る

調整済み残差の ± 2 は、1 つのマスを見るとききの物差しである。表のすべてのマスを眺めて ± 2 を超えたものを拾うと、何度も比べたことになる。場面の独立のモデルから作った表では、本当の関連はどこにも無い。それでも、20 マスのどれかが ± 2 を超えた表が 52% もあった。 M 個のマスのどれか 1 つが物差しを超える確率は、1 つずつの確率の M 倍を超えない。そこで 1 つずつの確率を $0.05/M$ に下げ、物差しを $\pm z_{0.025/M}$ にする(z_α は標準正規分布で上側の確率が α になる値)。こうすれば、どれか 1 つでも超える確率を 5% 以下に抑えられる。これをボンフェローニ補正(Bonferroni correction)と呼ぶ。20 マスなら物差しは ± 3.02 で、独立の表のどれかのマスを超える割合は 3.7% になった。第 2 回では、テストの行を何度も見ると誤差が楽観的になった。同じように、マスを何度も見ると「大きいマス」が楽観的に見つかる。見るマスを先に決めておくか、見た数に応じて物差しを上げる。計算の手順の 5 で比べる物差しは、見るマスの数 M に応じて $\pm z_{0.025/M}$ に上げる。

もう 1 つ、「大きい」には 2 つの意味がある。表のすべての度数を t 倍しても、 r_i 、 c_j と o_{ij}/e_{ij} は変わらない。一方で $o_{ij} - e_{ij}$ は t 倍、 $\sqrt{e_{ij}}$ は $\sqrt{t}$ 倍になるので、調整済み残差は $\sqrt{t}$ 倍になる(図 6)。 χ^2 も t 倍になる。調整済み残差で分かるのは「独立のモデルの偶然のゆらぎでは説明しにくい」である。本数が多ければ、わずかなずれでも必ず ± 2 を超える。ずれの強さを言うには、観測が期待の何倍か o_{ij}/e_{ij} を添える。表全体の強さには、クラメールの V (Cramér's V)を使う。総慣性 χ^2/n をその最大値 $\min(I, J) - 1$ で割り、平方根をとった値

$$V = \sqrt{\frac{\chi^2}{n(\min(I, J) - 1)}} \quad (21)$$

である。 V は 0 (独立) から 1 の間にあり、度数を t 倍しても変わらない。人工データでは $V = 0.233$ である。




図 6: 人工の自動販売機の表の度数をすべて t 倍したときのお茶 $\times$ 夏の (a) 調整済み残差と (b) 期待の何倍か。橙の点が元の表 ($t = 1$)、破線は (a) ± 2 、(b) 1 倍

3 つ以上のカテゴリ：多重対応分析

第 14 回の手順は、2 つのカテゴリの表に限られていた。飲み物・季節・温度のように 3 つ以上のカテゴリを同時に扱うには、1 本ずつを 0/1 で書く。カテゴリ a ($a = 1, \dots, p$) が J_a 個の値をとるとする。 i 本目とその j 番目の値なら 1、そうでなければ 0 とした $n \times J_a$ の行列を $\mathbf{G}_a$ とする。 $\mathbf{G}_a$ のどの行にも、1 がちょうど 1 つある ($\mathbf{G}_a \mathbf{1}_{J_a} = \mathbf{1}_n$)。第 8 回・第 11 回の所属行列 $\mathbf{G}$ と同じ形である。これを横に並べた

$$\mathbf{Z} = [\mathbf{G}_1 \ \mathbf{G}_2 \ \dots \ \mathbf{G}_p] \quad (n \times J, \ J = J_1 + \dots + J_p) \quad (22)$$

を指示行列(indicator matrix)と呼ぶ(図 7)。どの行の和も p である。

	$\mathbf{G}_1$: 飲み物					$\mathbf{G}_2$: 季節			$\mathbf{G}_3$: 温度		
1本目	1	0	0	0	0	0	0	0	1	1	0
2本目	0	0	0	1	0	0	1	0	0	0	1
3本目	0	1	0	0	0	1	0	0	0	0	1
4本目	0	0	0	0	1	0	0	0	1	1	0
5本目	0	1	0	0	0	0	0	1	0	1	0
6本目	0	0	1	0	0	0	1	0	0	0	1
	缶コーヒー	お茶	水	炭酸	コーンスープ	春	夏	秋	冬	ホット	つめたい

図 7: 売れた 6 本を、飲み物・季節・温度の 0/1 で書いた指示行列(概念図)。赤い線はカテゴリの区切りで、各ブロックの各行に 1 は 1 つだけある

指示行列を、行が 1 本 1 本、列がカテゴリの値の分割表とみて、第 14 回の手順を当てる。総数は np なので $\mathbf{P} = \mathbf{Z}/(np)$ となる。行の周辺は $\mathbf{r} = \mathbf{1}_n/n$ 、列の周辺は各値の出た割合を p で割った $\mathbf{c} = \mathbf{Z}^\top \mathbf{1}_n/(np)$ である。これらから作った行列

$$\mathbf{S}_Z = \mathbf{D}_r^{-1/2}(\mathbf{P} - \mathbf{r}\mathbf{c}^\top)\mathbf{D}_c^{-1/2} = \mathbf{K}\mathbf{A}\mathbf{L}^\top \quad (23)$$

を 1 回特異値分解して、カテゴリの値の点 $\mathbf{D}_c^{-1/2}\mathbf{L}_1\mathbf{A}_1$ を地図に描く。この手続きを多重対応分析(multiple correspondence analysis)と呼ぶ(定義 3)。カテゴリが違って、すべての値が 1 枚の地図に並ぶ。

何を分解しているかは、 $\mathbf{Z}^\top \mathbf{Z}$ を見るとわかる。 $\mathbf{L}$ は $\mathbf{S}_Z^\top \mathbf{S}_Z$ の固有ベクトルであり、 $\mathbf{S}_Z^\top \mathbf{S}_Z$ は $\mathbf{Z}^\top \mathbf{Z}$ から作られる。 $\mathbf{Z}^\top \mathbf{Z}$ をブロックに分けると

$$\mathbf{Z}^\top \mathbf{Z} = [\mathbf{G}_a^\top \mathbf{G}_b]_{a,b=1,\dots,p} \quad (24)$$

となる。 $\mathbf{G}_a^\top \mathbf{G}_b$ ($a \neq b$) のマスは、カテゴリ a の j 番目とカテゴリ b の l 番目が同時に出了た本数である。つまり 2 つのカテゴリの分割表そのものである。対角のブロック $\mathbf{G}_a^\top \mathbf{G}_a$ は、各値の本数を並べた対角行列になる。この行列をバート行列(Burt matrix)と呼ぶ。多重対応分析の地図は、2 つずつの分割表のずれを全部まとめて近似したものである。3 つのカテゴリが同時に絡むずれは見えていない。

総慣性は、データの中身によらず決まる。 $z_{ij}^2 = z_{ij}$ であり、各列の和は値の本数 n_j である。この 2 つを使って第 14 回の総慣性の式 $\sum_{i,j} p_{ij}^2/(r_i c_j) - 1$ を計算すると

$$\|\mathbf{S}_Z\|_F^2 = \sum_{i,j} \frac{z_{ij}}{p n_j} - 1 = \sum_{j=1}^J \frac{1}{p} - 1 = \frac{J}{p} - 1 \quad (25)$$

となる。各ブロックの列の和が $\mathbf{1}_n$ になるので、0 でない特異値は高々 $J - p$ 個である。 $p = 2$ のときを考える。2 つのカテゴリの分割表に第 14 回の対応分析を当てた特異値を δ_m とすると、指示行列の軸の慣性は $(1 \pm \delta_m)/2$ になる(それ以外の軸は $1/2$)。関連の強さ δ_m が 0 でも、慣性は $1/2$ ある。総慣性 $J/p - 1$ の大部分は、関連と無関係な、カテゴリが自分自身と重なる分である。そのため、多重対応分析の軸の寄与率は第 14 回の対応分析より低く出る。

自動販売機の 5×4 の表で確かめる。表を 1,000 本の指示行列(飲み物と季節の $p = 2$ 、 $J = 9$)に戻して多重対応分析にかけると、図 8 のように軸は 7 本になる。軸 1 の寄与率は、対応分析では 96% だが、多重対応分析では 20% にとどまる。慣性が $1/p$ を超える軸だけを数え直す補正(Benzécri の補正)では、 $\tilde{\lambda}_m = \{p/(p-1)\}^2(\delta_{Z,m}^2 - 1/p)^2$ の割合で寄与率を読む。 $p = 2$ では $\delta_{Z,m}^2 = (1 + \delta_m)/2$ を代入すると $\tilde{\lambda}_m = \delta_m^2$ となり、対応分析の寄与率に戻る。

定義 3 (多重対応分析). p 個のカテゴリの指示行列 $\mathbf{Z} = [\mathbf{G}_1 \dots \mathbf{G}_p]$ を分割表とみて対応分析を行うことを、多重対応分析と呼ぶ。総慣性は $J/p - 1$ で、軸は高々 $J - p$ 本である。 $\mathbf{Z}^\top \mathbf{Z}$ をバート行列と呼び、その対角でないブロックは 2 つずつのカテゴリの分割表である。




図 8: 人工の自動販売機の表の、軸ごとの慣性と寄与率。(a) 5 × 4 の表の対応分析、(b) 同じ表を 1,000 本の指示行列にした多重対応分析。破線は $1/p$

第 II 部 実データ解析

キノコの図鑑と手続き

第 II 部では、第 I 部の理論を実データで試す。第 I 部の人工データは、現象がはっきり出るように作ったものだった。実データは、理論どおりにいくとは限らない。予想が外れたときは、その理由を第 I 部の道具で考える。もちろん、予想どおりにいけばそれでよい。

第 I 部からは、次の 3 つを予想できる。第 1 に、期待度数は独立のモデルの最尤推定値なので、最尤法で測った当てはまりの悪さ G^2 と、重み付き二乗で測った χ^2 は、ほぼ同じ値になるはずである。(12) 式が示すとおりである。第 2 に、標準化残差の分散は $(1 - r_i)(1 - c_j)$ で、行が 2 つの表では $1 - r_i$ がおよそ 0.5 になる。そのため、調整済み残差に割り直すと、値は $1/\sqrt{0.5} \approx 1.4$ 倍以上に大きくなると見込める。第 3 に、多重対応分析の寄与率は、対応分析より低く出るはずである。

データには、UCI 機械学習リポジトリの Mushroom (id 73、Schlimmer 1987。The Audubon Society Field Guide to North American Mushrooms の記述から作られたもの、CC BY 4.0)を使う。ハラタケ属とツツネノカラカサ属の 23 種について、図鑑の記述に合う仮想の標本を 1 本 1 行で並べたデータである。全 8,124 本あり、かさの形・色、ひだ、柄、におい、生える場所など 22 列のすべてがカテゴリである。食べられるかの列は「食べられる」と「毒」の 2 つで、毒には、食べられるかわからず勧められないものも含まれる。図鑑の記述を組み合わせた練習用のデータであり、実際のキノコの見分けに使ってはいけない。

まず、食べられるか × かさの色(10 色)の 2×10 の分割表($n = 8,124$ 本)を作った。I-6 の手順で、期待度数、標準化残差、調整済み残差を計算した。 χ^2 と G^2 も計算し、マスごとに比べた。次に、同じ総数・同じ周辺独立のモデルから、多項分布で表を 2,000 回作った。毎回残差を計算し直して、マスごとの分散を測った。多重対応分析には、食べられるか(2)、かさの色、生える場所(7)、傷つけると色が変わるか(2)の 4 列を使った。かさの色のうち、200 本に満たない 5 色(淡黄・ピンク・シナモン・緑・紫、合わせて 388 本)は「その他の色」にまとめ、6 色にした。第 14 回で見たとおり、まれな値は地図の端に出て、軸を 1 本使ってしまうからである。この指示行列($8,124 \times 17$)に第 14 回の手順を当て、NumPy の特異値分解を 1 回計算した。

当てはまりの悪さ

第1の予想は外れた。この表の G^2 は 406.0、 χ^2 は 387.6 で、差は 18.4 ある。同じ総数・同じ周辺の独立のモデルから作った 2,000 個の表では、両者の差は平均 0.10 しかなかった。

理由は、(12) 式の導出で使った対数の近似 (11) 式にある。この近似は、 $x = (o - e)/e$ が 0 に近いマスでしか成り立たない。この表では、緑と紫のかさの毒が、期待度数 7.7 本に対して観測は 0 本で、 $x = -1$ である (図 9)。 $G^2 - \chi^2$ をマスごとの寄与 $2\{o \log(o/e) - (o - e)\} - (o - e)^2/e$ に分けると (足すと $\sum(o - e) = 0$ により $G^2 - \chi^2$ になる)、 $o = 0$ のマスの寄与はちょうど e になる。差 18.4 のうち 15.4 を、この 2 マスが作っていた。独立のモデルから大きく外れたマスがあると、2 つの物差しは離れる。 $G^2 \approx \chi^2$ は、モデルが正しいときの性質である。

食べられるか × かさの色の本数 o

食べられる	1264	1032	624	400	720	48	56	32	16	16
毒	1020	808	876	672	320	120	88	12	0	0
	茶	灰	赤	黄	白	淡黄	ピンク	シナモン	緑	紫

図 9: 食べられるか × かさの色の本数。橙の枠は観測が 0 本のマス (緑 × 毒、紫 × 毒)

最尤推定と計算そのものは、第 I 部の式どおりであった。対数尤度 (7) 式を SciPy の汎用の最適化 (BFGS 法) で直接最大にすると、求めた確率は周辺 r_i 、 c_j と一致し (差は最大 1e-08)、期待度数が最尤推定値であること (9) 式が確かめられた。 χ^2 と G^2 も、SciPy の分割表の検定の関数の値と一致した。

どのマスが大きい

第2の予想は当たった。図 10 は、食べられるか × かさの色の表の標準化残差 (a) と調整済み残差 (b) である。この表は行が 2 つしかないの、 $1 - r_i$ はおよそ 0.5 になり、 $(1 - r_i)(1 - c_j)$ は 0.35~0.52 である。割り直すと、どのマスの残差も 1.39~1.70 倍に大きくなった。標準化残差で ± 2 に届かないのは、シナモン色のかさ (44 本のうち食べられるもの 32 本) の +1.93 だけである。調整済み残差では +2.79 となり、10 色すべてが ± 2 を超える。ただし、判定が変わったのはシナモンだけである。20 マスのうち 18 マスは、割る前から ± 2 を超えていた。総数が 8,124 本と多く、帰結⑩で見たとおり、同じ形の表でも残差は本数の平方根に比例して大きくなるからである。割り直しが判定を変えるのは、 ± 2 の近くにあるマスだけである。

割り直しの根拠も、この表で確かめた。独立の表 2,000 個で標準化残差の分散を測ると、20 マスのどれでも、 $(1 - r_i)(1 - c_j)$ との差は 0.029 以内であった (図 11)。平均は 0.448 で、(18) 式の $(I - 1)(J - 1)/(IJ) = 0.450$ に近い。関連の無い表でも、標準化残差が ± 2 を超えた割合は 0.25% しかなかった。調整済み残差の分散は 0.994 で、 ± 2 を超えた割合は 4.46% と、標準正規分布の 4.55% に近い。

10 色すべてを眺めて大きいものを拾うなら、物差しを上げなければならない。行が 2 つの表では $o_{1j} - e_{1j} =$




図 10: 食べられるか × かさの色の表のマスごとのずれ。(a) 標準化残差、(b) 調整済み残差。細い枠は絶対値が 2 以上、橙の枠はシナモン × 食べられる。色の目盛りは共通




図 11: 食べられるか × かさの色の表と同じ周辺の独立のモデルから作った 2,000 表での、標準化残差の分散。横軸は $(1 - r_i)(1 - c_j)$ 、線は $y = x$

$-(o_{2j} - e_{2j})$ であり、 $e_{1j}(1 - r_1) = nr_1r_2c_j = e_{2j}(1 - r_2)$ でもある。そのため 2 つの行の調整済み残差は、符号だけが逆で絶対値は同じになる (差の最大 $1e-14$)。違う値は 10 個なので、ボンフェローニの物差しは $M = 10$ の ± 2.81 になる。これを超えるのは 9 色で、シナモンだけが届かない。シナモンを「大きい」と言えるのは、シナモンを見ると先に決めていた場合だけである。

表 2 は、いくつかのマスの観測、期待度数、期待の何倍か、2 つの残差である。白いかさでは、食べられるものが期待の 1.34 倍になっている。調整済み残差は +12.05 で、表の中で最も大きい。緑のかさは 16 本すべてが食べられるもので、期待の 1.93 倍と白より強く偏っている。それでも本数が少ないので、調整済み残差は +3.86 にとどまる。帰結で見たとおり、「偶然では説明しにくい」は調整済み残差で判断し、偏りの強さは「何倍か」の列で読む。表全体の関連の強さはクラメールの V で 0.218 である。

表 2: 食べられるか × かさの色の表のいくつかのマスを観測、期待度数、期待の何倍か、標準化残差、調整済み残差

マス	観測	期待度数	何倍か	標準化	調整済み
白 × 食べられる	720	538.7	1.34	+7.81	+12.05
シナモン × 食べられる	32	22.8	1.40	+1.93	+2.79
ピンク × 食べられる	56	74.6	0.75	-2.15	-3.13
緑 × 食べられる	16	8.3	1.93	+2.68	+3.86
赤 × 毒	876	723.0	1.21	+5.69	+8.75

多重対応分析の地図を読む

図 12 は、食べられるか・かさの色・生える場所・傷で色が変わるかの多重対応分析の地図である。17 の値が、すべて 1 枚に並ぶ。軸 1 の右には食べられる・傷で変色する・白・牧草地・荒地が、左には毒・変色しない・道ばた・落ち葉・赤が並ぶ。軸 2 の上には白・草地・牧草地・黄が、下には荒地・その他の色・赤・落ち葉が来る。




図 12: 食べられるか・かさの色・生える場所・傷で色が変わるかの多重対応分析の地図。赤の星が食べられるか、青の丸がかさの色、緑の四角が生える場所、紫の三角が傷

第 3 の予想は当たった。図 13 のとおり、軸 1 は総慣性の 15.6%、軸 2 は 11.7% しかなく、2 本で 27.3% にとどまる。総慣性は 3.2500 で $J/p - 1$ に一致し、0 でない特異値は $J - p = 13$ 個で、(25) 式のとおりであった。総慣性 $J/p - 1 = 3.25$ の大部分は、各カテゴリが自分自身と重なる分である。関連が無くても、慣性が $1/p$ 前

後の軸が並ぶ。同じことは $p = 2$ でも起きる。食べられるか × かさの色の 2×10 の表は、対応分析なら軸 1 本だけで総慣性の 100% を表す。同じ表を指示行列にして多重対応分析にかけると、軸 1 は 12.2% になる。このとき軸の慣性は、 2×10 の表の特異値 δ_m から $(1 + \delta_m)/2$ で求まった(差は $1e-15$)。第 I 部の Benzécri の補正を 4 列の地図に当てると、軸 1 は 68.3%、軸 2 は 18.1% になる。多重対応分析の寄与率は、対応分析の寄与率と同じ物差しでは比べられない。




図 13: 食べられるか・かさの色・生える場所・傷で色が変わるかの多重対応分析の、軸ごとの慣性。破線は $1/p$

地図の読み方を誤らせるものが、もう 1 つある。地図の近さと直接の関連の違いである。図 14 のように、食べられると街なかは地図の上で近い(距離 0.31)。ところが食べられるか × 生える場所の分割表に戻ると、街なかに生える 368 本のうち、食べられるものは 96 本しかない。食べられる × 街なかの調整済み残差は -10.10 である。地図とは逆に、街なかのキノコは毒の側に大きく偏っている。それでも 2 つが近いのには理由がある。食べられるものには、白いかさ(調整済み残差 +12.05)と傷で色が変わるもの(+45.20)が多い。街なかのキノコにも、白いかさ(+10.36)と傷で色が変わるもの(+12.89)が多い。多重対応分析はパート行列の 2 つずつの表をまとめて近似する。パート行列の食べられるか × かさの色のブロックは、分割表そのものであった。そのため、ほかの列との強い関連があると、2 つの値が見かけの上で近くなる。地図で近い 2 つの値は、その 2 つのカテゴリの分割表に戻り、そのマスの調整済み残差で確かめる。

このデータでわかったこと

第 II 部の結果をまとめる。第 I 部からは、期待度数が最尤推定値なので、 G^2 と χ^2 はほぼ同じになると予想した。キノコの表では両者は 18.4 離れ、予想は外れた。緑と紫のかさの毒が観測 0 本で o/e が 1 から遠く、対数の近似が成り立たないからであり、差の大半をこの 2 マスが作っていた。 $G^2 \approx \chi^2$ は、独立のモデルが正しく、どのマスでも o/e が 1 に近いときの性質である。次に、行が 2 つの表では、割り直すと残差は大きく変わると予想した。実際に 1.39~1.70 倍になり、予想どおりだった。ただし本数が多いので、ほとんどのマスは割る前から ± 2 を超えており、判定が変わったのはシナモンだけだった。最後に、多重対応分析の寄与率は低く出ると予想し、2 本で 27.3% と、そのとおりになった。地図で近い食べられると街なかは、2 つの表に戻ると逆向きに結びついていた。地図の近さは、2 つずつの表のマスで確かめる必要がある。




図 14: 多重対応分析の地図で、食べられる・街なか・白・傷で変色するだけを濃く描いたもの

締め

まとめと全 15 回の地図

本章の問いは、第 14 回の締めで残した「1 セルのズレは大きいのか」であった。第 14 回の期待度数 $e_{ij} = nr_i c_j$ は、独立のモデル $\mathbf{II} = \pi_r \pi_c^\top$ を最尤法で推定した予測値である。当てはまりの悪さを尤度で測った G^2 は、モデルが正しい大標本では、第 14 回の重み付き二乗の χ^2 に一致する。推定には行と列の合計を使うので、残差 $(o - e)/\sqrt{e}$ は左右から 1 本ずつ向きを除かれて縮む。その分散は、1 ではなく $(1 - r_i)(1 - c_j)$ になる。この値で割り直した調整済み残差なら、分散が 1 にそろい、 ± 2 の物差しが使える。回帰の残差を $\sqrt{1 - h_{ii}}$ で割るのと同じ型である。推定に使われた度合いの和は、回帰では係数の個数 p 、分割表では推定した確率の個数 $I + J - 1$ になる。たくさんのマスを一度に見るなら物差しを上げ、ずれの強さは期待の何倍かで読む。キノコの図鑑の食べられるか × かさの色の表では、標準化残差で ± 2 に届かなかったシナモン色が、割り直すと $+2.79$ になった。ただし、10 色を一度に見る物差し ± 2.81 にはわずかに届かなかった。3 つ以上のカテゴリは、多重対応分析で 1 枚の地図にできる。所属行列と同じ形の 0/1 を並べた指示行列に、第 14 回の手順を当てればよい。ただし寄与率は低く出る。地図で近い食べられると街なかは、2 つの表では逆向きに結びついていた。地図の近さは、2 つずつの表のマスで確かめる必要があった。

最後に、全 15 回を「モデル × 推定法」の地図に置き直す。第 1 回で示した表(表 3)に、第 14 回の対応分析と、本章の独立のモデルと多重対応分析が加わり、地図が完成する。第 1～4 回は線形回帰を最小二乗法で推定し、その数字の測り方(第 2 回)、係数の揺れ(第 3 回)、罰(第 4 回)を見た。第 5～7 回は分類を最小二乗法と最尤法の

両方で解き、確率をどこで切るかを決めた。第 8 回で、近似する相手が $\mathbf{y}$ か $\mathbf{X}$ かという境目を引いた。第 9～11 回は $\mathbf{X}$ そのものを $\mathbf{FA}^\top$ や $\mathbf{GC}$ で近似する最小二乗法を扱った。第 12 回は同じ群分けを最尤法で推定し、第 13 回で群の数を選んだ。第 14 回は分割表のずれを重み付き最小二乗法で低ランク近似した。本章は同じ独立のモデルを最尤法の側から見て、マスごとのずれを測った。

表 3: 全 15 回の「モデル × 推定法」の地図(数字は扱う回)

モデル	最小二乗法で推定	最尤法で推定
線形回帰	第 1～3 回(罰則付き 第 4 回)	第 6 回
LDA / ロジスティック回帰	第 5 回 / —	第 6 回(しきい値は第 7 回)
主成分分析	第 9・10 回	—
k-means / 混合正規分布	第 11 回 / —	— / 第 12 回(群の数は第 13 回)
対応分析・多重対応分析	第 14 回・第 15 回(重み付き)	—
独立のモデル	第 14 回(χ^2 、重み付き)	第 15 回(G^2 、残差)

どの回も、データとモデルのずれを測って小さくすることをしてきた。最小二乗法では、 $\|\mathbf{y} - \mathbf{X}\beta\|_2^2$ 、 $\|\mathbf{X} - \mathbf{FA}^\top\|_F^2$ 、 $\|\mathbf{X} - \mathbf{GC}\|_F^2$ 、重み付きの $\|\mathbf{S} - \mathbf{Y}\|_F^2$ がずれの測り方であった。最尤法では -2ℓ が同じ役を果たした。正規誤差の回帰や分割表の独立のモデルでは、2 つの推定法は同じ答えや同じ物差しにたどり着いた。そして、小さくした後に残ったずれは、モデルを推定に使った分だけ縮んでいる。第 3 回は残差平方和を n ではなく $n - p$ で割り、第 4 回は抜いた行の誤差を $e_i / (1 - h_{ii})$ で求めた。第 14 回は $o - e$ を $\sqrt{e}$ で、本章は $\sqrt{e(1 - r_i)(1 - c_j)}$ で割った。 R^2 も寄与率も χ^2 も調整済み残差も、何かを何かで割った数字である。数字を比べる前に、それが何で割られているかを確かめること。それが、この 15 回を通じて繰り返してきたことである。